

PaperXie 全文标明引文报告（旗舰版）

报告编号 PXAF34C42D909D4BAEAC0F89AFBAA0C457

报告时间 20260326151820

文献基本信息

检测文献 基于多模态学习的药物分子性质预测研究

文献作者 张三

检测范围 期刊论文库 硕士论文库 博士论文库
会议论文库 图书数据库 报纸数据库
外文数据库 互联网资源库 互联网文档库
共享数据库 个人自建库 高校学位库

重复率：12.4%

PaperXie 旗舰版

检测报告结果

总文字重复率：12.4%

去除引用后重复率：12.4%

去除本人已发表后重复率：12.4%

重复字数：6,242

总字数：50,255（不含参考文献）

总段落数：5

1. 基于多模态学习的药物分子性质预测研究_第1部分

总字数：10,934

文字重复率：10.8%（1,176）

序号	相似文献来源	重复率	是否引证
1	基于知识引导与数据驱动的分子性质与药物-靶标相互作用预测研究 刘硕 - 《兰州大学博士学位论文》 - 2025	1.1%	否
2	石油天然气管道地质灾害安全风险评价体系研究 - 《高校学位库》 - 2020	0.8%	否
3	1 - 《高校学位库》 - 2020	0.7%	否
4	国有HT汽车公司发展战略研究 - 《高校学位库》 - 2020	0.7%	否
5	b2d50bd302974bf6aa4efafbc9deb60d - 《高校学位库》 - 2019	0.7%	否
6	基于资源一号02D高光谱数据的建三江土壤氮、硫及铜元素的定量预测分析 - 《高校学位库》 - 2022	0.6%	否
7	基于Arduino的四自由度桌面型机械臂的设计与实现 - 《高校学位库》 - 2021	0.6%	否
8	任务描述增强的分子表征学习技术研究 郭昊强 - 《哈尔滨工业大学硕士学位论文》 - 2024	0.5%	否
9	基于图表示学习的药靶亲和力预测方法研究 王胜坤 - 《东北师范大学硕士学位论文》 - 2024	0.5%	否
10	基于深度学习的药物分子表征与性质预测研究 张琦 - 《大连交通大学硕士学位论文》 - 2025	0.4%	否
11	基于基因交互图与自监督学习的抗癌药物反应多标签预测 欧阳振球 - 《浙江大学硕士学位论文》 - 2023	0.4%	否
12	基于多模态表征学习的分子性质预测研究 张茹 - 《南宁师范大学硕士学位论文》 - 2024	0.4%	否
13	基于多注意力卷积网络的高光谱影像分类方法研究 - 《高校学位库》 - 2022	0.3%	否

序号	相似文献来源	重复率	是否引证
14	表界面可控的石墨烯基功能复合材料的构筑及其力学行为研究 官礼知 - 《杭州师范大学硕士论文》 - 2016	0.3%	否
15	复杂网络的相似度表示及应用算法研究 - 《高校学位库》 - 2019	0.3%	否
16	医院综合信息管理系统的设计与实现 - 《高校学位库》 - 2022	0.3%	否
17	基于多任务学习的波达方向角和时延联合估计算法研究 陈耳其 - 《上海师范大学硕士论文》 - 2025	0.2%	否
18	Advances in theoretical calculations of organic thermoelectric materials Shaohua Zhang;Liyao Liu;Yingqiao Ma;Chong-an Di; - 《Chinese Chemical Letters》 - 2024	0.2%	否
19	LEDNet: a multimodal foundation model for robust deepfake detection Renshuai TAO;Shijie TANG;Haotong QIN;Wei WANG;Yunchao WEI;Yao ZHAO; - 《Science China(Information Sciences)》 - 2025	0.2%	否
20	Multimodal Perception-based Obstacle Avoidance via Deep Reinforcem... - 《英文数据库》 - 2022	0.2%	否
21	基于Grassmann流形的多组学数据的癌症亚型分型 ALI ABDULLAH SALEH AL-FATEMI - 《华南理工大学硕士论文》 - 2021	0.2%	否
22	GBDT改进模型研究及在癌症康复诊断中的应用 - 《高校学位库》 - 2022	0.2%	否
23	新型GPR40激动剂ADD-16钠盐的药代动力学研究 马丽莎 - 《中国人民解放军空军军医大学硕士论文》 - 2024	0.2%	否
24	基于条件指导的抗生素分子生成方法研究 陈璐 - 《西安电子科技大学硕士论文》 - 2024	0.2%	否
25	双层优化技术在双模态植物叶分类模型的应用研究 石晓龙 - 《武汉轻工大学硕士论文》 - 2025	0.2%	否
26	基于语义情感分析的电子商务个性化推荐模型研究 吕文娟 - 《湖北工业大学硕士论文》 - 2016	0.2%	否
27	基于图神经网络的表示学习研究 于星瞳 - 《中国科学技术大学博士论文》 - 2024	0.2%	否
28	图神经网络研究与进展 许荣斌;许智强;王吉祥;谢莹; - 《莆田学院学报》 - 2023	0.2%	否
29	基于分子图嵌入空间搜索的虚拟筛选方法 丁玉莹 - 《河北师范大学硕士论文》 - 2025	0.2%	否
30	基于机器学习的小分子性质预测与蛋白质配体生成方法研究 张庆添 - 《扬州大学硕士论文》 - 2025	0.2%	否
31	aa417ffd8145464493e027c005d8b77b - 《高校学位库》 - 2019	0.2%	否
32	面向组合式图像检索的多模态特征对齐与融合方法研究 杨二贺 - 《东华大学硕士论文》 - 2025	0.2%	否
33	梁学松-毕业论文-0902 - 《高校学位库》 - 2022	0.2%	否
34	基于频率波数域方法合成地震动研究 - 《高校学位库》 - 2022	0.2%	否
35	阵元间距对去混响性能的影响及其改进 陈晨 - 《南京信息工程大学硕士论文》 - 2024	0.1%	否
36	657d770e44ae42d19139c1ce67fe7125 - 《高校学位库》 -	0.1%	否

序号	相似文献来源	重复率	是否引证
37	面向计算机领域的人物事件抽取方法研究 杨欣 - 《河北科技大学硕士论文》 - 2023	0.1%	否
38	蒺藜乙酸乙酯提取物的抗衰老作用及机制研究 农嘉臻 - 《中南民族大学硕士论文》 - 2024	0.1%	否
39	基于Nav1.8钠离子通道抑制剂的合成及活性评价 张倩 - 《成都医学院硕士论文》 - 2025	0.1%	否
40	发展非极性氨基酸二肽与尿素相互作用的ABEEM/MM可极化力场 胡端羽 - 《辽宁师范大学硕士论文》 - 2024	0.1%	否
41	医疗大模型发展现状与展望 钱波;李富江;郑常乐;张道强; - 《数据采集与处理》 - 2025	0.1%	否
42	基于AI背景下的工科实验教学创新思考与研究 姜潜基;宋薇;李郁; - 《教育教学论坛》 - 2025	0.1%	否
43	药用天然产物高效合成技术在新药开发中的转化研究 李其峰;姜爽;刘俊秀; - 《张江科技评论》 - 2025	0.1%	否
44	纯粹结构描述符的构筑及强偶极分子智能筛选 赵璐瑶 - 《兰州大学硕士论文》 - 2025	0.1%	否
45	大模型技术在粮食行业智能化转型中的应用探索与实践 华艺;张加胜;陈明华;韩峰; - 《中国信息化》 - 2024	0.1%	否
46	基于图神经网络的药物—蛋白质结合系数预测 李光跃 - 《南京信息工程大学硕士论文》 - 2025	0.1%	否
47	基于病理图像的HER2阳性乳腺癌靶向治疗疗效预测模型构建 刘晓华 - 《重庆大学硕士论文》 - 2024	0.1%	否
48	总体国家安全观下的公共安全与应急管理 王宏伟; - 《社会治理》 - 2015	0.1%	否
49	中国知识产权托管服务发展研究 邹瑜 - 《湘潭大学硕士论文》 - 2014	0.1%	否
50	基于混合纠错码的可容错性高速缓存研究 赵彩 - 《浙江大学硕士论文》 - 2015	0.1%	否
51	基于大语言模型的情绪支持对话生成方法研究 桑晨扬 - 《南京信息工程大学硕士论文》 - 2025	0.1%	否
52	基于大模型增强的语言与知识推理研究 文祎琳 - 《中南大学硕士论文》 - 2024	0.1%	否
53	邮储银行B分行小微企业信贷业务风险管理研究 - 《高校学位库》 - 2022	0.1%	否
54	1f45fbc3f875408ba1e88b7860ba4cbb - 《高校学位库》 - 2021	0.1%	否
55	8a942a7483f843b589af10da76753471 - 《高校学位库》 - 2021	0.1%	否
56	基于图神经网络的药物-靶标相互作用预测方法研究 刘飞扬 - 《贵州财经大学硕士论文》 - 2025	0.1%	否
57	基于类别模糊数据构造和注意力正则化的半监督图像分类研究 曾祥平 - 《华南理工大学硕士论文》 - 2021	0.1%	否
58	基于演化序搜索的混合贝叶斯网络结构学习方法 李明嘉;钱鸿;周爱民; - 《计算机科学》 - 2023	0.1%	否
59	基于特征融合网络与自监督学习的钢材表面缺陷识别研究 李泽亮 - 《五邑大学硕士论文》 - 2024	0.1%	否
60	基于深度学习算法的视觉里程计研究 卞新超 - 《汕头大学硕士论文》 - 2020	0.1%	否

参考文献
中国地质大学（北京）专业硕士学位论文
分类号 密级
中国地质大学（北京）
专业硕士学位论文
基于多模态学习的药物分子性质预测研究
研究生 范帅尧 学号 2104230025
专业学位类别 电子信息专业 计算机技术
校内导师 牛云云 产业导师
学习方式 全日制
2026年5月

A Dissertation Submitted to
China University of Geosciences for Master of Professional Degree
A Multimodal Learning Approach to Drug Molecule
Property Prediction
Master Candidate: Shuaiyao Fan
Professional Degree: Master of Electronic and
Information
Dissertation Supervisor: Prof. Yunyun Niu
Associate Supervisor:
China University of Geosciences (Beijing)

声明
本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知,除了文中特别加以标注和致谢的地方外,论文中不包含其他人已经发表或撰写过的研究成果,也不包含为获得中国地质大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。
签名: 日期:

关于论文使用授权的说明
本人完全了解中国地质大学有关保留、使用学位论文的规定,即:学校有权保留送交论文的复印件,允许论文被查阅和借阅;学校可以公布论文的全部或部分内容,可以采用影印、缩印或其他复制手段保存论文。延期公开的论文在到期公开后应遵守此规定。
签名: 导师签名: 日期:

摘要
面向性质预测的分子表征学习旨在通过深度学习技术,将分子复杂的结构与特征信息投影成一个高维的数学表示,进而利用这些特征表示来精准的预测分子的各项生化性质,最终从海量候选药物中高效筛选出具备成药潜力的目标分子。医药领域虽已积累了海量的分子数据,但这些数据往往充斥着严重的噪声且标注质量参差不齐,同时,传统计算方法在处理大规模分子数据时面临着极高的计算复杂度。近年来,深度学习技术在数据表征领域的飞速发展,为分子信息建模提供了数据驱动的新范式。然而,如何有效利用分子的多模态数据,在深度学习框架下构建全面且鲁棒的分子特征表示,并以此实现生化性质的高精度预测,已成为当前该领域亟待解决的核心问题。
为解决上述提出的问题,本文基于分子可以表示为多种模态的特性,提出两种创新性方法:
(1) 基于思维链增强与信息传递的分子性质预测方法。针对大语言模型在预测复杂生化性质时缺乏药理逻辑支撑的“黑盒”问题,以及传统图神经网络拓扑感知受限与“信息回流”的缺陷,本方法提出了一种端到端的双塔预测框架。在文本端,引入LLaMA-3.1大语言模型与低秩自适应技术,结合思维链提示工程,引导模型自发生成显式逻辑推理文本,将推理过程变为人类可解释的分析文本;在图结构端,采用交互式图神经网络构建原子与化学键的“通信核”,强制实现深层动态交互。在TDC平台的多个ADMET基准数据集上的实验表明,该方法不仅取得了较优结果,且通过可视化的推理路径为分子安全性评估提供了解释线索。
(2) 基于知识增强与图对齐的多模态分子性质预测框架。针对公共医学文本噪声冗余及分子的多源数据联合优化易引发梯度冲突的问题,该框架构建了包含分子图、序列、指纹及自然语言的四个维度的表征体系。在数据层面,创新性地设计了知识重写流水线,利用大语言模型剔除原始文本中的冗余噪声,并显式注入由RDKit工具计算的多项分子理化指标,提升了文本模态的知识密度与约束力。在模型对齐层面,确立以分子图为核心的语义锚点,并引入基于同方差不确定性的自适应加权机制。在MoleculeNet的9个基准数据集上的系统评估表明,该框架在预测精度上综合表现较好,表明图中心对齐与知识增强可能对性能提升具有积极作用。

关键词:分子性质预测,多模态融合,思维链,对比学习
Abstract

Molecular representation learning for property prediction aims to project the complex structural and feature information of molecules into high-dimensional mathematical representations using deep learning techniques. This approach facilitates the accurate prediction of biochemical properties, thereby enabling the efficient screening of drug candidates with therapeutic potential from massive chemical spaces. Although the pharmaceutical field has accumulated vast amounts of molecular data, these datasets are frequently plagued by significant noise and inconsistent annotation quality. Furthermore, traditional computational methods struggle with high complexity when processing large-scale molecular data. While the rapid advancement of deep learning in data representation has provided a new data-driven paradigm for molecular modeling, the challenge remains on how to effectively utilize multimodal molecular data to construct comprehensive, robust representations for high-precision property prediction. To address these challenges, this paper proposes two innovative methods based on the multimodal nature of molecules:
(1) A Chain-of-Thought Enhanced and Message-Passing Molecular Property Prediction Method. Addressing the "black-box" nature of large language models (LLMs) that lack pharmacological reasoning in biochemical prediction, as well as the limitations of traditional graph neural networks (GNNs) in topological perception and "information oversmoothing," this method presents an end-to-end dual-tower framework. On the textual side, we incorporate the LLaMA-3.1 model with Low-Rank Adaptation (LoRA) and chain-of-thought prompting to guide the model in generating explicit, human-interpretable logical reasoning. On the graph side, an interactive GNN is employed to build a "communication core" for atoms and bonds, forcing deep dynamic interactions. Experimental results on multiple ADMET benchmarks within the Therapeutics Data Commons (TDC) demonstrate that this method significantly improves prediction accuracy and provides robust interpretability for molecular safety assessment through visual reasoning paths.
(2) A Knowledge-Enhanced and Graph-Aligned Multimodal Molecular Property Prediction Framework. To mitigate noise in public medical texts and gradient conflicts arising from multi-source data optimization, this framework constructs a representation system covering four dimensions: molecular graphs, sequences, fingerprints, and natural language. At the data level, we design an innovative knowledge-rewriting pipeline that utilizes LLMs to prune redundant noise from raw text and explicitly inject physicochemical indices calculated via RDKit, thereby enhancing

g the knowledge density and constraints of the textual modality. At the model alignment level, we establish the molecular graph as the semantic anchor and introduce an adaptive weighting mechanism based on homoscedastic uncertainty. Systematic evaluations on nine MoleculeNet benchmarks show that this framework achieves competitive overall performance, suggesting that graph-centered alignment and knowledge enhancement can positively contribute to multimodal molecular property prediction.

Key words: Molecular Property Prediction, Multimodal Learning, Chain-of-Thought, Contrastive Learning

目 录

摘要	1
Abstract	2
1 引言	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于单模态的分子预测方法	2
1.2.2 基于多模态的分子预测方法	3
1.3 当前研究不足	4
1.4 研究内容以及论文结构	5
1.4.1 研究内容	5
1.4.2 文章架构	6
2 相关理论基础	8
2.1 数据表征方法	8
2.1.1 SMILES	8
2.1.2 二维拓扑图	8
2.1.3 分子指纹	9
2.1.4 文本语义	9
2.2 图神经网络	10
2.2.1 消息传递机制	10
2.2.2 图卷积网络	11
2.2.3 基于注意力机制的图神经网络	12
2.3 大语言模型与提示词工程	13
2.3.1 Transformer架构	13
2.3.2 LoRA技术	15
2.3.3 思维链	16
2.4 本章小结	17
3 基于思维链增强与消息传递的分子性质预测方法	18
3.1 模型设计与描述	18
3.1.1 CoT-CMP架构概述	18
3.1.2 思维链增强的文本编码器	20
3.1.3 分子图编码器	21
3.1.4 融合与预测模块	22
3.2 实验设计	22
3.2.1 数据集	22
3.2.2 划分方式	25
3.2.3 实验设置	26
3.2.4 评价指标	26
3.2.5 对比模型	27
3.3 实验及结果分析	28
3.3.1 对比实验	28
3.3.2 消融实验	30
3.3.3 可视化分析	31
3.3.4 参数敏感实验	32
3.4 本章小结	33
4 基于知识增强与图对齐的分子性质预测方法	35
4.1 模型设计与描述	35
4.1.1 KGAMA框架概述	35
4.1.2 图编码器	36
4.1.3 指纹编码器	36
4.1.4 序列编码器	37
4.1.5 文本编码器	38
4.1.6 融合与预测	38
4.2 实验设计	38
4.2.1 预训练数据	38
4.2.2 下游数据集	41
4.2.3 实验设置	44
4.2.4 评价指标	45
4.2.5 损失函数	45
4.2.6 对比模型	46
4.3 实验及结果分析	48
4.3.1 对比实验	48
4.3.2 消融实验	50
4.3.3 可视化分析	53
4.3.4 参数敏感实验	54
4.4 本章小结	55
5 总结与展望	57
5.1 工作总结	57
5.2 工作展望	58
参考文献	59

现代创新药物的研发是一个高度复杂、多学科交叉、系统性且极具风险的庞大科学工程。其绵长的生命周期通常横跨数十年的时间,研发的成本也通常会达到数十亿美元。整个研发流程可划分为五个关键阶段:第一阶段为药物发现与开发,这一阶段是基于一种特定的疾病或者病症,研究人员通过多种寻找潜在候选药物的策略从百万量级的化合物库中筛选出具有关键作用的目标分子。第二阶段为临床前研究,这一阶段是初始发现阶段与人体测试之间的重要桥梁。通过体外细胞实验与体内动物模型对候选分子的**安全性、毒性及药代动力学特性进行系统评估**;第三阶段为临床研究,候选药物依次经历多期的临床试验,在不同规模的人群中逐步验证其安全性与有效性;第四阶段为监管审批,药物开发商向监管机构提交新药申请,由专家团队对全部临床数据进行严格审查;第五阶段为上市后安全监控,已获批药物在真实世界的大规模使用中持续接受不良事件监测与长期安全性评估。上述五个阶段环环相扣、层层递进,这一严苛而漫长的研发流程迫切需要更高效的技术手段介入,以加速候选分子的早期筛选与优化过程,降低研发成本与失败风险。 Comment by 帅尧 范: Embracing the changes and challenges with modern early drug discovery

Drug Repurposing as an Effective Drug Discovery Strategy: A Critical Review

分子性质预测在药物研发的早期阶段扮演着至关重要的角色。其目的是匹配目标分子相应的生化性质。通过在实验验证之前对候选分子的关键性质进行快速评估,研究人员得以从百万量级的化合物库中迅速剔除不符合要求的分子,将候选范围大幅压缩至数百个具有成药潜力的先导化合物,从而在源头上规避大量无效的实验资源消耗。

然而,传统获取分子性质的手段面临着难以逾越的效率与成本瓶颈。长期以来,分子理化性质任务高度依赖于湿实验。尽管实验方法具有极高的数据可靠性,但其实施成本高昂,且操作流程复杂耗时。面对庞大的潜在化学成药空间,传统的湿实验显然无法满足现代医药工业的大规模高通量筛选需求。另一方面,以**量子力学计算和分子动力学模拟**为代表的理论计算方法,虽能从微观原子层面解析分子的**电子结构与构象动力学行为**,但其对**计算资源的极高消耗以及时间尺度的严苛限制,使其难以被广泛应用于复杂生物大分子体系的快速评估**。

近年来,随着计算能力的飞跃与医药大数据的积累,计算机辅助方法特别是深度学习技术与**人工智能技术的突起**,为药物研发带来了前所未有的**范式变革**。**深度学习凭借其强大的数据处理与非线性模式挖掘能力**,能够在极短的时间内高效处理海量的分子数据。**通过构建多层神经网络结构,模型能够自动学习数据的高维特征表示,从而实现对复杂“分子结构—生化性质”映射关系的精准建模与预测**。从基于一维序列的Transformer到基于二维拓扑的图神经网络,深度学习技术正推动新药发现由传统的经验驱动全面转向数据驱动。这一前沿技术的加持,不仅打破了传统实验与理论计算的效率壁垒,更为精准预测分子药代动力学特性、大幅提升药物研发的成功率提供了革命性的智能**辅助方案**。

国内外研究现状

在**药物发现早期,准确预测分子的物理化学性质与药代动力学特性**是加速目标分子筛选任务的核心。随着医药大数据的积累与计算机算力的爆发,计算机辅助分子性质预测经历了从传统机器学习到深度学习的范式跃迁。目前,国内外学术界在该领域的研究明显展现出两条主要的核心技术主线:基于单模态的分子表示方法与基于多模态的分子表示方法来对分子性质进行预测。

基于单模态的分子预测方法

单模态方法是指依赖单一的数据形式,例如典型的一维数据SMILES序列、二维数据分子拓扑图、三维数据分子的坐标等,来进行分子表征的构建,进而预测分子性质。

由于分子可以天然地被表示为由原子和化学键构成的非欧几里得图结构,因此图神经网络在分子单模态表征中成为了主流的工具。例如FragNet [1] 将分子拆解为片段,通过构建多层次图表示在图神经网络中显示建模分子片段和整体的关系,从而提升性质预测的精度与可解释性。GA-GNN [2] 用几何代数作为底层数学工具,把向量、平面、旋转等几何对象统一表示,嵌入GNN中,增强对空间结构的建模。Add-GNN [3] 在GNN中引入可加性注意力,针对不同尺度的邻域信息,例如近邻和远邻,给予不同权重,实现更细粒度的图读出。CD-MVGNN [4] 它打破了传统模型单一视角的局限,将原子和化学键视为同等重要,构建了双轨并行的多视图架构。通过交叉依赖消息传递机制,使得节点与边在每一步信息聚合时,都能实时交互并利用对方的最新状态,从而高效、精准地捕捉分子的底层拓扑特征。KA-GNN [5] 抛弃了传统GNN中用于拟合数据的多层感知机 (MLP),转而基于数学上的 Kolmogorov–Arnold 表示定理,将预测分子性质的复杂高维函数,拆解为多个一维的基础组合函数。

除图结构外,化学分子还可以通过标准化的编码规则转换为一维序列或特征向量,最典型的代表为SMILES字符串与分子指纹。**这类一维模态天然契合自然语言处理 (NLP) 领域的底层架构**,能够直接借助Transformer等模型开展大规模自监督预训练,在计算效率与特征表征上展现出独特优势。例如**SMILES-BERT [6] 将Transformer架构引入分子表征学习**。它通过在大规模无标签SMILES数据上进行掩码语言建模预训练。SMILES-GRPO提出基团感知掩码,强制模型一次性遮盖或预测整个功能基团。MFBERT [7] 直接将扩展连通性指纹等一维向量作为输入Token喂给Transformer进行掩码预训练,成功实现了离散化学特征与深度注意力机制的融合,其预测精度依然能够持平复杂的GNN或者深层的Transformer模型。

基于多模态的分子预测方法

与仅依赖单一结构模态 (图或序列) 的模型相比,多模态分子预测方法通过联合利用**分子图、三维构象、SMILES序列、文本描述**以及光谱等多通道信息,更全面地表征分子的结构-性质关系。

其中,一维分子序列和二维分子图相融合是常用的方法之一。例如AMCFNet [8] 提出了一种自适应多模式**对比融合网络,从SMILES序列与图结构表示之间的交互和共识中自适应地提取互补特征**。MMCL [9] 框架通过BRICS算法显式地将功能基团建模为层级图中的特殊节点,并结合双向门控循环单元处理序列信息,实现了图结构语义与序列语义的深层对齐。MolGramTreeNet [10] 引入了上下文无关文法解析技术,将SMILES序列转化为具有层级语义的分子文法树,并结合图卷积网络对2D分子图进行并行编码。该模型通过通道拼接将层次化语法特征与拓扑结构特征深度融合,相较于常见的交叉注意力融合机制这种通道拼接技术展现出了更高的性能。GSST [11] 通过引入可学习的softoken概念,将图拓扑特征映射至序列空间,并利用G2S-Former模块实现了多模态信息的深度对齐与融合,有效弥补了单一模态在分子表征中的语义缺失。MolPROP [12] 通过将预训练的大语言模型ChemBERTa-2与图神经网络相结合,证实了多模态融合在回归类性质预测任务中的协同增效作用,并提出了一种基于重原子匹配的特征映射策略。MDFCL [13] 通过基于主链与侧链的自适应增强策略,构建了包含多种增强实例的图对比学习体系,通过在图模态与序列模态间实施分层对比损失,实现了双模态的语义一致性建模。

将分子结构与自然语言描述文本对齐,可以利用文本中蕴含的药理、用途等高层语义知识来增强分子的表示。例如MoleculeSTM [14],它是该方向极具开创性的基础模型之一。它通过构建包含超过28万对“结构-文本”的PubChemSTM数据集,利用跨模态对比学习将分子表示与自然语言映射到了统一的潜空间。Wang等人构建的MolTextNet [15] 将高质量的“分子-文本”配对样本扩充至约两百万条,为训练更大规模的跨模态编码器提供了数据底座。ProtoMol [16] 该模型通过引入层级式双向交叉注意力机制与统一的语义原型空间,实现了分子图结构与文本描述在多层次上的精细化对齐,解决了多模态分子模型在层级语义捕捉与模态对齐方面的不足。TRIDENT [17] 进一步将三种模态:SMILES序列、自然语言描述及分层功能注释统一到一个三模态表示框架中,提出体积化全局对齐目标和局部对应任务。MolPrompt [18] 通过将分子的物理化学描述符转化为可学习的语义提示,将其嵌入到图结构的表征信息中,实现了图模态与文本描述的深度语义对齐。

利用分子的三维结构信息结合可以弥补分子平面拓扑与真实物理空间结构之间的信息鸿沟。例如GraphMVP [19],它利用分子的二维和三维模态,通过自适应地整合2D和3D图的信息,学习具有丰富空间语义的分子表征。随后,Uni-Mol [20] 作为一项里程碑式的工作,提出了通用的3D分子表征学习框架,该模型是首个能够直接输入3D原子坐标进行预训练的大规模模型。MolInterAct [21] 工作专注于2D与3D构象的深度交互,通过设计原子级与分子级的“交互层”,在多层网络堆叠中逐步对齐2D和3D空间信息。ECMMR [22] 框架通过BRICS算法显式地提取并编码分子功能片段,并利用超图结构捕捉原子间的复杂高阶关系。此外,该框架还引入了耦合先验优化策略,通过对比学习与生成式重建任务的协同,实现了图模态与3D几何模态的动态对齐。

双模态或者特定视角的对齐策略虽在一定程度上弥补了单模态的缺陷,但是分子的化学特性是多维度的综合表现,将分子的多模态数据进行融合是该领域一个前沿的方向。例如Uni-Poly [23] 创新性地将SMILES、2D图、3D构象及分子指纹与领域文本描述进行了统一融合,通过多模态注意力池化机制有效提升了聚合物物化性质预测的综合性能。MuMo [24] 将分子2D的拓扑信息和3D的几何信息统一,作为稳定的结构先验,然后引入渐进式注入机制进行融合,并且采用了Manba作为骨干网络进行计算。MoLA [25] 采用跨层注意力融合机制自适应地构建多通道相关图,让不同模态在不同网络深度的贡献进行自动的调整,并创新性地将树突神经模块引入指纹处理分支,实现了非线性交互特征的有效捕捉。MMFRL

[26] 系统比较了**早期、中期和晚期三种特征融合策略,并在**多模态表示之上引入分子间关系学习模块,显式建模分子间的相似性与作用机制。DMMF [27] 通过引入模态内门控与模态间注意力机制,不仅要预测分子的性质还要完成模态之间的重构,实现了样本级的自适应权重分配。

当前研究不足

尽管以深度学习为代表的单模态与多模态表征技术在分子性质预测任务上**取得了长足的进步,但面对高度复杂且**容错率极低的真实药物发现场景,当前研究仍存在以下难以逾越的局限性:

单模态拓扑感知受限与信息回流瓶颈:传统的图神经网络主要依赖于局部节点的无向聚合机制,严重忽视了化学键在电子效应传递中的动态交互作用。这种机制在多层迭代时极易产生信息冗余与信息回流,导致模型难以精准感知多环系统或长碳链分子中的复杂立体空间依赖。

大模型直接推理的黑盒态与文本幻觉:虽然大语言模型 (LLMs) 展现出了跨模态理解的潜力,但在面对如跨膜吸收、毒理副作用等复杂的药代动力学 (ADMET) 评估时,现有方法多要求模型进行缺乏中间逻辑支撑的直接端到端映射。这不仅极易导致模型产生无事实依据的幻觉,更使得预测过程呈现出完全不可解释的黑盒特性,难以满足制药工业的逻辑审计要求。

多模态融合面临的文本噪声与梯度冲突: 现有的多模态对齐策略严重受制于公共医学数据库,如PubChem数据库中文本质量的参差不齐。原始分子描述通常充斥着冗余的行政历史轶事,且缺乏关键定量化指标的约束。在进行粗粒度的跨模态对比学习时,这种多源数据的语义鸿沟极易引发模态间的梯度冲突与负迁移,导致特征对齐失败。

研究内容以及论文结构

研究内容

针对上述分子性质预测研究中存在的拓扑感知局限、黑盒预测痛点以及多模态对齐中的梯度冲突等问题,本文深入探究了基于大语言模型推理、知识增强与图网络深度交互的**解决方案。本文的主要研究内容包括**如下:

(1) **将大语言模型领域的思维链推理技术于交互式消息传递图神经网络相结合,本文提出了一种端到端**的双塔预测框架。在文本端,利用大语言模型与思维链技术,引导模型自发生成包含结构识别到理化属性分析,再到性质推导的显式逻辑推理文本,增强了模型决策过程的可解释性表达能力;在图结构端,构建基于通信核的交互式图神经网络,强制原子与化学键进行动态深度交互,精准捕获分子的立体电子效应。最终通过交叉注意力机制,实现宏观药理语义与微观拓扑结构的自适应融合。

(2) **将多模态知识增强技术与交叉注意力相结合,本文提出了一种以图表征为核心、多模态知识增强的分子预测架构 (KGAMA)**。该框架构建了包含图、序列、指纹及自然语言的四维表征体系,并创新性地设计了大语言模型知识重写流水线,显式注入定量化指标以过滤文本噪声。在模型对齐阶段,摒弃全排列对齐策略,**引入基于同方差不确定性的自适应加权机制,使**模型能够自动平衡各模态的噪声水平,实现跨模态特征在统一高维语义空间的稳健对齐。

文章架构

本小节将介绍本文的整体结构,本文**分为五个大章节,以下是各个章节的详细介绍。**

第一章为绪论。本章系统阐述了分子性质预测在现代药物研发早期的高效虚拟筛选中的研究背景及其至关重要的科学意义,详细综述了单模态深度学习与多模态表征技术在该领域的应用现状,并深入分析了现有方法在拓扑特征提取局限、大语言模型“黑盒”化以及多模态融合语义冲突等方面所面临的挑战。最后,概述了本文针对这些痛点提出的多模态知识增强与思维链推理的**创新性解决策略。**

第二章介绍了本研究相关的理论基础。本章系统梳理了本文构建模型所依赖的底层数学原理与算法基石。首先,详细阐述了涵盖一维SMILES序列、二维拓扑图、分子指纹及自然语言文本的多维数据表征方法。其次,深入剖析了图空间域的特征提取算法,**包括图卷积网络、图注意力网络及消息传递机制等。**最后,重点介绍了大语言模型领域的Transformer架构、低秩自适应 (LoRA) 微调技术与思维链 (CoT) 推理机制,并界定了跨模态特征对齐与融合的通用范式,为后续核心章节的**模型设计提供了严密的理论支撑。**

第三章介绍了基于思维链增强与消息传递的分子性质预测方法。本章针对现有模型在大语言模型预测时的不可解释性的黑盒问题以及传统图网络拓扑感知的局限,提出了一种端到端的双塔预测框架 (CoT-CMP)。详细介绍了大模型引导的显式药理逻辑文本生成机制与基于通信核的交互式图特征提取机制,并全面呈现了该模型在TDC平台多个ADMET**基准数据集上的实验设置、对比结果、消融实验与可视化讨论。**

第四章介绍了基于知识增强与图对齐的分子性质预测方法。本章指出了公共医学文本噪声冗余及多源异构数据直接对齐易引发梯度冲突的不足,提出了一种以图表征为核心的四维多模态分子预测架构 (KGAMA)。接着详细介绍了大语言模型知识重写流水线的设计逻辑,以及**基于同方差不确定性的自适应加权机制在**对比学习中的应用,并系统展示了该框架在MoleculeNet基准数据集上的实验设置、性能对比、消融分析与注意力权重特征的可视化结果。

第五章对全文内容进行了系统性的总结与展望。本章对全文的核心研究内容与两项多模态预测框架的创新性成果进行了高度概括,客观分析**了当前研究工作中存在的局限性,并**从引入三维几何构象、构建亿级规模多模态基础模型以及干湿实验闭环验证等维度,对未来分子性质预测领域的发展方向进行了科学的展望。

1 引言

中国地质大学 (北京) **专业硕士学位论文**

2

2

相关理论基础

数据表征方法

SMILES

简化分子线性输入规范 (Simplified Molecular Input Line Entry System, SMILES) 是将分子的二维或三维结构信息降维为一维字符串序列的最常用方法之一。SMILES通过对分子图进行深度优先遍历 (Depth-First Search, DFS) 生成线性字符串。其编码遵循严格的化学语法规则:节点 (原子) 由标准元素符号 (如H、C、S) 表示;边 (化学键) 由特定字符 (如“=”表示双键,“#”表示三键) 标定;分支结构通过括号“ () ”进行嵌套声明;环状结构则通过在开环和闭环原子处标记相同数字来实现断键重连。使用SMILES生成的序列具有天然紧凑性,且高度契合自然语言处理 (NLP) 领域的序列模型。通过特定分词算法,可将SMILES字符串映射至高维向量空间,进而利用神经网络算法对其进行特征提取。

2.基于多模态学习的药物分子性质预测研究_第2部分

总字数: 10,358

文字重复率: 19.4% (2,008)

序号	相似文献来源	重复率	是否引证
1	基于图神经网络的知识图谱链接预测方法研究 侯若天 - 《北京工业大学硕士论文》 - 2023	1.3%	否
2	基于图神经网络的云制造服务推荐方法研究 董学文;石宇强;田永政; - 《工业工程》 - 2023	1.2%	否
3	SDN数据中心网络场景下基于GCN及DRL的负载均衡研究与实现 曾祥云 - 《电子科技大学硕士论文》 - 2022	1.2%	否
4	基于气象因子的脑卒中发病规律和预警模型研究 王丁 - 《北京交通大学硕士论文》 - 2023	1.2%	否

序号	相似文献来源	重复率	是否引证
5	基于Transformer的细胞类型注释研究及国产算力平台的训练优化 于召勇 - 《齐鲁工业大学硕士论文》 - 2025	1.2%	否
6	复杂环境下小目标无人机智能检测研究 赵志文 - 《西京学院硕士论文》 - 2024	1.1%	否
7	水声传感网络的智能路由方法研究 张舒云 - 《浙江大学硕士论文》 - 2023	0.8%	否
8	基于图神经网络的不平衡节点分类方法研究及应用 孙海航 - 《中国石油大学(北京)硕士论文》 - 2024	0.8%	否
9	复杂字符干扰下铁路集装箱箱号检测与识别方法研究 张添添 - 《东华理工大学硕士论文》 - 2023	0.7%	否
10	多视角的药物分子表示方法研究 郝凌锋 - 《哈尔滨工业大学硕士论文》 - 2022	0.6%	否
11	图神经网络中传播机制的研究 张浩然 - 《黑龙江大学硕士论文》 - 2024	0.6%	否
12	基于注意力机制和图神经网络的兴趣点推荐算法的研究 周诗洋 - 《黑龙江大学硕士论文》 - 2023	0.6%	否
13	基于自我披露检测的目标用户检测方法研究 陈豪杰 - 《北京邮电大学硕士论文》 - 2024	0.6%	否
14	基于PSO方法的DNA分子范德华相互作用计算研究 杨紫鑫 - 《兰州大学硕士论文》 - 2025	0.5%	否
15	深度学习辅助的抗抑郁药物环境健康风险与生物毒性优先筛查研究 孙佩萱 - 《吉林大学博士论文》 - 2025	0.5%	否
16	基于复杂网络的汉语相似词挖掘和相似度计算研究 韩普;王东波;朱恒民; - 《情报学报》 - 2015	0.5%	否
17	基于数据驱动的航空发动机剩余寿命预测研究 - 《高校学位库》 - 2022	0.5%	否
18	基于多视图融合和注意力机制的异质图神经网络研究 吴芝冰 - 《河北师范大学硕士论文》 - 2025	0.5%	否
19	基于深度学习的光学镜片检测和分割研究 施龙斌 - 《东南大学硕士论文》 - 2024	0.5%	否
20	基于脑电和眼动协同的视频流目标判读研究 洪晨益 - 《杭州电子科技大学硕士论文》 - 2025	0.5%	否
21	基于深度学习的光流估计算法研究 邱一波 - 《西安理工大学硕士论文》 - 2024	0.5%	否
22	基于深度学习的灾害性太阳活动预报研究 李雪峰 - 《江苏科技大学硕士论文》 - 2025	0.5%	否
23	面向招聘领域的多轮对话系统研究与实现 崔建民 - 《华中科技大学硕士论文》 - 2022	0.5%	否
24	基于AIM理论的RNA分子力场中LJ参数的计算研究 李孝宏 - 《兰州大学硕士论文》 - 2025	0.4%	否
25	计算制药学922 - 《高校学位库》 - 2021	0.4%	否
26	数据标准化与多特征融合在小分子类药性与剂量预测中的应用 李强 - 《重庆医科大学博士论文》 - 2024	0.4%	否
27	Graph Transformer技术与研究进展：从基础理论到前沿应用 游浩;丁苍峰;马乐荣;延照耀;曹璐; - 《计算机应用研究》 - 2024	0.4%	否
28	基于Transformer和图神经网络的事件抽取模型 - 《高校学位库》 - 2022	0.4%	否

序号	相似文献来源	重复率	是否引证
29	基于ELMo和Transformer混合模型的情感分析 赵亚欧;张家重;李贻斌;王玉奎; - 《中文信息学报》 - 2021	0.4%	否
30	基于依存句法与多头注意力的生物医学事件抽取 刘辉雄;刘茂福;唐东昕; - 《武汉大学学报(理学版)》 - 2021	0.4%	否
31	多领域自适应的神经机器翻译方法研究 黄双宏 - 《昆明理工大学硕士论文》 - 2023	0.4%	否
32	神经机器翻译的领域自适应研究 曾嘉莉 - 《厦门大学硕士论文》 - 2020	0.4%	否
33	基于遗传算法寻找抗HBV活性分子的关键分子指纹片断 刘恒平;王锦政;高成哲;徐斌;李清然;林新昊;林克江; - 《中国药科大学学报》 - 2014	0.3%	否
34	基于图注意力机制的永磁体定位方法研究 王振学 - 《广东工业大学硕士论文》 - 2025	0.3%	否
35	面向学科教材文本的实体关系抽取关键技术研究 张嘉乐 - 《东南大学硕士论文》 - 2023	0.3%	否
36	基于深度学习的轴承故障诊断技术研究 张林毅 - 《杭州电子科技大学硕士论文》 - 2025	0.3%	否
37	针对社交群体影响的社会化推荐算法研究 黄道龙 - 《哈尔滨工业大学硕士论文》 - 2022	0.3%	否
38	基于Graphormer的时空间多源数据微服务故障定位算法 任锐;王阳;关洪涛;谢高岗; - 《高技术通讯》 - 2025	0.3%	否
39	2021年Graph ML热门趋势和主要进展总结 - 《互联网资源》 - 2021	0.3%	否
40	基于多信息融合的社交媒体抑郁障碍检测研究 安正一 - 《兰州大学硕士论文》 - 2023	0.3%	否
41	基于零样本学习的目标分类方法研究 刘月聪 - 《哈尔滨工程大学硕士论文》 - 2024	0.3%	否
42	β_2肾上腺素受体与配体的相互作用机制及β激动剂虚拟筛选研究 钟红梅 - 《福建师范大学硕士论文》 - 2021	0.3%	否
43	2肾上腺素受体与配体的相互作用机制及激动剂虚拟筛选研究 - 《高校学位库》 - 2021	0.3%	否
44	基于机器学习的蛋白-配体打分方法研究 沈超 - 《浙江大学博士论文》 - 2022	0.3%	否
45	基于结构化分析的复杂文本问答技术研究 王富春 - 《军事科学院硕士论文》 - 2024	0.3%	否
46	多模态数据融合理论与方法 梁新彦 - 《山西大学博士论文》 - 2022	0.3%	否
47	基于跨网络卷积的无监督社交网络对齐方法 梁哲涵 - 《厦门大学硕士论文》 - 2022	0.2%	否
48	基于图算法与最佳图表示的单台PC图计算平台研究 张雕 - 《上海交通大学硕士论文》 - 2014	0.2%	否
49	基于图Transformer的分子性质预测方法研究 张绍光 - 《贵州大学硕士论文》 - 2025	0.2%	否
50	基于深度学习的药物虚拟筛选及重定位模型构建研究 顾耀文 - 《北京协和医学院硕士论文》 - 2023	0.2%	否
51	基于区块链的空天地一体化网络频谱资源管理算法研究 王巍翰 - 《北京交通大学硕士论文》 - 2024	0.2%	否
52	Eu3+ Tb3+掺杂白磷钙石纳米晶的可控合成及其生物学性能研究 - 《高校学位库》 - 2021	0.2%	否

序号	相似文献来源	重复率	是否引证
53	整合的ADMET数据库（PKKB）及简单预测规则的构建 曹东跃 - 《苏州大学硕士论文》 - 2012	0.2%	否
54	细胞亲和-UPLC-QTOF测定蟾蜍甾烯与宫颈癌HeLa细胞的亲和及与化合物计算... 周婧;王剑;马宏跃;丁安伟;尚尔鑫;詹;钱大玮;唐于平; - 《中国药理学通报》 - 2012	0.2%	否
55	基于知识增强的疾病分类方法研究 赵直倬 - 《齐鲁工业大学硕士论文》 - 2025	0.2%	否
56	结合对比学习和提示学习的预训练模型去偏方法研究 何俊亨 - 《广东工业大学硕士论文》 - 2024	0.2%	否
57	异构溯源图在APT攻击检测中的应用研究 何厚翰 - 《中国人民公安大学硕士论文》 - 2025	0.2%	否
58	基于轨迹的图神经网络路径学习 于兹灏 - 《北京交通大学硕士论文》 - 2020	0.2%	否
59	多维度边优化溯源图改进的APT攻击检测方法 何厚翰;芦天亮;张岚泽;袁梦娇;曾高俊; - 《计算机科学与探索》 - 2024	0.2%	否
60	基于无限近邻矩阵及混合视图特征融合的半监督图卷积网络研究 戚庆洋 - 《安徽大学硕士论文》 - 2023	0.2%	否
61	基于图神经网络的协同过滤算法研究 黄恺文 - 《西南石油大学硕士论文》 - 2023	0.2%	否
62	基于图神经网络的商品会话推荐算法研究 李郎郎 - 《兰州大学硕士论文》 - 2022	0.2%	否
63	基于神经网络的路网最短路径距离高效计算 何润喆 - 《广州大学硕士论文》 - 2023	0.2%	否
64	非合作网络的拓扑结构主动结合感知与智能预测研究 魏强 - 《电子科技大学博士论文》 - 2022	0.2%	否
65	重庆市公共交通网络复杂性研究 冯海峰 - 《重庆交通大学硕士论文》 - 2014	0.2%	否
66	基于邻居交互增强和多头注意力机制的跨域推荐模型 孙克雷;汪盈盈; - 《湖北民族大学学报(自然科学版)》 - 2023	0.2%	否
67	时频结合的分层循环神经网络时间序列预测研究 朱泽龙 - 《云南大学硕士论文》 - 2024	0.2%	否
68	基于三维点云和多模态融合的脑出血预后预测研究 段昊伟 - 《西南大学硕士论文》 - 2025	0.2%	否
69	基于DuReader的多文档机器阅读理解研究及实现 薛勇 - 《重庆邮电大学硕士论文》 - 2021	0.2%	否
70	基于多光谱的目标检测及其应用 王涵 - 《北方工业大学硕士论文》 - 2025	0.2%	否
71	大模型技术及其标准化研究 王莉;王鹏;袁柳; - 《信息技术与标准化》 - 2023	0.2%	否
72	基于奇异值分解的适应微调 林志鹏;郭峥嵘;张伟志;郭躬德; - 《计算机系统应用》 - 2024	0.2%	否
73	基于人工智能的汽车座椅骨架的静强度快速预测 - 《高校学位库》 - 2022	0.2%	否
74	面向复杂阅读理解任务的预训练方法 焦方锴 - 《山东大学硕士论文》 - 2022	0.2%	否
75	基于多模态大模型思维链增强的视觉问答方法研究 欧阳雪城 - 《杭州电子科技大学硕士论文》 - 2025	0.2%	否
76	基于首要教学原理的初中人工智能课程问题解决能力培养实践研究 张翠玲 - 《云南师范大学硕士论文》 - 2024	0.2%	否

序号	相似文献来源	重复率	是否引证
77	地方政府突发事件应急能力的评价研究 徐秀芹 - 《东北大学硕士论文》 - 2008	0.2%	否
78	运动调节帕金森动物模型大脑神经可塑性的meta分析 牟彬 - 《中国地质大学(北京)硕士论文》 - 2022	0.2%	否
79	电网企业安全管理成熟度模型及实证研究 王译 - 《中国地质大学(北京)硕士论文》 - 2022	0.2%	否
80	基于数量-质量-生态的海南藏族自治州耕地变化分析 王玉萍 - 《中国地质大学(北京)硕士论文》 - 2022	0.2%	否
81	基于LSD1/HDACs双靶点的白藜芦醇衍生物类抗肿瘤小分子抑制剂的计算设计 鲁文凤 - 《新乡医学院硕士论文》 - 2024	0.2%	否
82	基于LightGBM的药物分子筛选 - 《高校学位库》 - 2020	0.2%	否
83	固相载体上的环加成反应及其应用 许家喜,焦鹏 - 《化学进展》 - 2000	0.2%	否
84	基于多模态表征学习的分子性质预测研究 张茹 - 《南宁师范大学硕士论文》 - 2024	0.2%	否
85	抗前列腺癌中药方的统计筛选及AR拮抗剂的构效关系研究 韩文雅 - 《兰州大学硕士论文》 - 2020	0.2%	否
86	基于图注意力对抗网络的分子性质预测及优化方法研究 杨季涛 - 《南京邮电大学硕士论文》 - 2023	0.2%	否
87	燃料电池重卡动力系统匹配设计与能耗优化研究 梅书健 - 《北京交通大学硕士论文》 - 2023	0.2%	否
88	互联网虚假信息识别与防范研究 - 《高校学位库》 - 2023	0.2%	否
89	互联网虚假信息的识别与防范研究 - 《高校学位库》 - 2023	0.2%	否
90	基于理化启发与多级结构感知的分子性质预测方法研究 关锴 - 《山东师范大学硕士论文》 - 2025	0.2%	否
91	基于机器学习的小分子性质预测与蛋白质配体生成方法研究 张庆添 - 《扬州大学硕士论文》 - 2025	0.2%	否
92	面向街景地图的视觉推理基准构建与方法研究 周海挺 - 《杭州电子科技大学硕士论文》 - 2025	0.2%	否
93	基于图神经网络的东巴画小样本分类研究 黎克 - 《云南大学硕士论文》 - 2021	0.2%	否
94	基于特征增强的视频时序定位算法研究 鄢瀚青 - 《杭州电子科技大学硕士论文》 - 2025	0.2%	否
95	数字媒体技术运用中基于知识图谱构建的人机交互界面设计研究 范欣欣; - 《自动化与仪器仪表》 - 2025	0.2%	否
96	面向药物发现的杂交分子数据库构建与检索系统的开发 李业成 - 《华南理工大学硕士论文》 - 2018	0.2%	否
97	深度学习在轴承故障诊断上的应用 - 《高校学位库》 - 2022	0.1%	否
98	可见光图像与红外图像的超分辨率重建算法研究(- 《高校学位库》 - 2021	0.1%	否
99	基于大语言模型和RAG的持续交付智能问答系统 鞠炜刚;汪鹏;王佳; - 《计算机技术与发展》 - 2024	0.1%	否
100	基于强化学习的对话式疾病诊断方法研究 孙雪尧 - 《东北林业大学硕士论文》 - 2025	0.1%	否

序号	相似文献来源	重复率	是否引证
101	Self-Guide:一种基于自我规划的大语言模型推理增强方法 刘艺彬;刘正皓;闫宇坤;于是;王硕;杨麟儿;陈慧敏;谷峪;于戈; - 《中文信息学报》 - 2025	0.1%	否
102	利用基于参数的迁移学习策略改善ADMET性质预测研究 段艳静 - 《中南大学硕士论文》 - 2024	0.1%	否

原文内容

二维拓扑图
分子的拓扑结构表示了分子中原子之间的连接方式,且拓扑结构可以用拓扑图来表示,其中**可以将原子抽象为节点,化学键抽象为边。通过拓扑图可以更加直观地表示分子的原子连接关系与局部结构特征。**
在图表征中,表示节点（原子）集合,表示边（化学键）集合。为了在图神经网络中进行消息传递,需要为节点和边分别构建**初始特征矩阵:节点特征矩阵可表示为公式:**

其中,为原子总数,为原子特征维度。常见的原子特征包括原子序数、电负性、杂化轨道类型、隐式氢原子数量、形式电荷及是否具有手性等。边特征矩阵如公式所示:

其中,为化学键总数,为边特征维度。常见的边特征包括化学键类型,如单键、双键、三键、芳香键,是否处于共轭体系以及是否属于环结构等。
二维拓扑图表征完整保留了分子的骨架连接性与图同构不变性,能够有效捕捉局部化学环境中的原子交互模式及远端原子间的拓扑依赖关系,是分子图神经网络建模的核心输入数据结构。

分子指纹
分子指纹（Molecular Fingerprints）是一种将分子的局部子结构、拓扑路径或特定官能团编码为固定长度特征向量的表征方法。其本质通常是一个固定长度的二进制位数组,其中每一位代表特定的分子特征是否存在。基于“结构相似性原理”,指纹的相似性通常预示着分子间**具有相似的理化性质或生物活性。**根据编码策略的不同,分子指纹又可分为多种类型,常见的类型有:**基于拓扑路径的指纹、基于原圆形领域的指纹、基于专家规则的指纹等。分子指纹将结构**各异、大小不一的分子转化为维度统一的数值向量,从而使其能够作为标准化输入,高效地应用于各类机器学习模型。

文本语义
纯粹的序列或拓扑图表征往往局限于微观的化学结构层次,难以直接映射到宏观的药代动力学特性与生物学靶点机制。自然语言与理化知识表征通过引入外部专家经验与客观计算指标,为模型提供高阶语义信息。

该表征主要分为两部分:
定量理化属性:利用化学信息学工具（如RDKit）依据分子的2D结构计算客观存在的物理化学指标。核心**参数包括脂水分配系数（LogP）、拓扑极性表面积（TPSA）、精确分子量（Exact MW）以及可旋转键数量等。**这些连续的数值变量对分子的透膜性与溶解度具有决定性的指示作用。

定性语义文本:利用结构化的医学数据库记录或大语言模型生成的逻辑推理文本,将分子的靶点结合倾向、潜在毒性机制及官能团作用以自然语言的形式进行**编码。通过预训练语言模型的语义**投影,该表征能够有效弥合“微观图结构”与“宏观生物活性”之间的语义鸿沟。

图2-1 阿司匹林的多模态化学表征

图神经网络
分子结构本质上是由原子与共价键构成的**非欧几里得空间数据,传统的卷积神经网络（CNN）与循环神经网络（RNN）无法**直接处理此类不规则的拓扑连接。图神经网络（Graph Neural Networks, GNN）通过在节点（原子）及其拓扑邻域之间执行特征聚合与非线性变换,成为了当前分子图表示学习的标准范式。本节将系统梳理图卷积、图注意力**机制、消息传递框架以及图Transformer的核心理论。**

消息传递机制
消息传递神经网络（Message Passing Neural Network, MPNN）是**空间域图神经网络的通用数学框架。该框架从图的本质出发,其认为在网络拓扑中想要得到节点信息,最直接的方式就是通过相邻的节点相互传递特征信息来更新节点**的表示。MPNN的消息传递机制如图2-2,具体来说是将每一层神经网络的操作分为了三个步骤:

第一步:消息构造。假设需要更新节点的特征信息,需要观察该**节点的邻居节点集合中的每一个节点**,并且结合它们之间的边特征,为每条邻居关系构造一条专属信息:

第二步:消息聚合。节点将所有来自邻居节点的信息通过一个置换不变性的函数进行聚合,最终得到一个聚合表示:
第三步:状态更新。节点根据自己当前的隐藏和汇聚到邻居的信息为输入,经过一个可学习的神经网络来更新自身的状态,进而得到新的状态:

在每一轮的消息传递的过程中,图中所有的节点都同步执行以上三个步骤,在经过层迭代之后,每一个节点的表示都将融合其阶领域之内的所有的节点特征与结构信息,从而实现对图结构的层次化感知。

图2-2 消息传递机制示意图

图卷积网络图卷积网络是由Thomas等人在2017的在论文《Semi-Supervised Classification with Graph Convolutional Networks》中首次提出,图卷积网络的核心在于一个节点的特征,是由它自身和其邻居共同决定。通过层层传递,结构相似、连通紧密的节点,他们的特征就会越来越相似。
设为第层的节点特征**矩阵,为图的邻接矩阵,GCN每层的特征更新公式可以表示为公式:**

其中,是为添加了自环的邻接矩阵,以保留节点自身的特征信息;为的度矩阵,其对角线元素即为;为第层的可学习的权重矩阵;为非线性激活函数,如ReLU;对称归一化项对邻接矩阵做归一化处理,缓解高度节点在聚合的过程中堆特征值的影响。GNN通过堆叠多层的卷积操作实现了对多邻域节点信息的逐层传递,这样的操作在经过层的堆叠之后,每一个节点都将融合其阶领域内所有节点的结构与特征信息。

基于注意力机制的图神经网络
2017年Transformer凭借自注意力机制在序列建模领域取得了突破性进展。受其启发,Veličković**等人在2018年将注意力机制引入图领域,提出了图注意力网络（Graph Attention Network, GAT）,其核心为在节点间的信息交互中引入动态注意力机制,进而解决图卷积网络权重固定的痛点。**如公式所示,对于中心节点及其邻居节点,GAT首先通过一个可以**共享的注意力函数计算两者之间的注意力分数:**

其中,为共享的线性变换矩阵,为可学习的注意力权重向量,符号表示拼接操作。随后使用归一化函数Softmax对节点领域内的所有注意力分数进行归一化操作,得到最终的注意力权重,如公式所示:

最终,节点的特征通过对邻居特征的加权求和进行更新,如公式所示:

然而,GAT的注意力计算仍局限于一阶邻居范围内,本质上仍属于局部聚合范式,难以直接建模分子中远端原子之间的长程依赖关系。为突破这一局部感受野的限制,研究者将Transformer的全局自注意力机制引入图结构建模,形成了图Transformer架构。以Graphormer为代表的图Transformer模型将分子中所有节点两两之间的联系一并纳入注意力计算范围之内,实现了真正意义上的全局建模。标准的Transformer架构适用于处理无

序的序列,无法感知图的拓扑结构,所以必须显式的引入图的几何结构与拓扑信息。Graphormer设计了三种互补的结构编码机制:其一为**中心性编码 (Centrality Encoding)**,利用节点的入度与出度为每个原子引入可学习的偏置向量,以量化其在分子图中的拓扑重要性;其二为空间编码 (Spatial Encoding),将节点对之间的最短路径距离映射为注意力矩阵中的标量偏置,显式刻画原子间的物理隔离程度;其三为边缘编码 (Edge Encoding),提取节点对最短路径上所有边特征的加权均值,将化学键属性直接注入注意力权重的计算过程。三种结构编码协同作用,使图Transformer能够在全局注意力框架下同时感知局部化学键属性与全局拓扑距离,将分子的多尺度结构信息映射至统一的高维表示空间。

大语言模型与提示词工程

在分子性质预测任务中,纯粹的结构表征往往局限于微观拓扑,难以直接映射到宏观的复杂药代动力学特性。大语言模型 (Large Language Models, LLMs) 通过在海量语料上进行无监督预训练,内部隐式地压缩了丰富的跨学科知识。本节将系统阐述大语言模型的底层架构、**参数高效微调机制以及激发模型推理能力的思维链技术**。

Transformer架构

Vaswani等人在2017年的论文《Attention Is All You Need》中首次提出了Transformer架构。该架构的核心是通过**自注意力机制 (Self-Attention)**来建立输入序列内部的全局依赖关系,如图2-3所示。相比于传统循环神经网络的递归计算与卷积神经网络的局部感受野范式,Transformer在处理序列数据时的性能得到了极大的提升。Transformer由**编码器和解码器两部分组成,每一部分均由多层结构堆叠而成,而每一层又包含多个功能不同的子模块**。其中最核心的子模块为多头注意力机制。

Transformer架构采用了**缩放点积注意力机制 (Scaled Dot-Product Attention)**作为最基本的计算单元。在给定输入序列的特征矩阵的情况下,模型通过初始化三个可学习的参数矩阵、**、将其分别投影为查询矩阵 (Query)、键矩阵 (Key) 和值矩阵 (Value)**。通过这三个矩阵,可得注意力权重的计算公式:

其中,矩阵乘法计算序列中任意两个特征元素之间的内积相似度,除以缩放因子是为了防止特征维度较高时内积数值过大,导致梯度不稳定进而难以计算;Softmax操作将相似度矩阵**转化为归一化的概率分布,并与值矩阵进行加权和**,以此实现全局信息的动态提取。

为了使模型能够同时从多个不同的特征子空间中捕捉信息,Vaswani等人将Transformer中的自注意力机制进一步扩展为**多头注意力机制,如公式**。模型将**、并行投影至多个低维特征子空间,在每个子空间中分别进行缩放点积注意力计算,随后将各个头的输出拼接,并经过一次线性变换还原维度**:

其中**、是索引为的注意力头的投影矩阵,为输出投影矩阵**。多头注意力机制显著提升了模型的特征表达能力,使其能够更好地捕获复杂的语法结构与深层语义。

在多头注意力层之后,Transformer对序列中的每个位置独立应用了一个全连接的前馈神经网络 (Position-wise Feed-Forward Network, FFN),以引入必要的非线性变换。该网络通常包含两层线性映射与一个ReLU激活函数,如公式:

其中用于将特征维度从扩展至更高的维度,而则将其映射回原始维度,两次线性变换共同实现对每个位置特征的非线性变换。

图2-3 Transformer架构

LoRA技术

低秩自适应 (Low-Rank Adaptation, LoRA) 是由Edward J. Hu等人于2021年在论文《LoRA:Low-Rank Adaptation of Large Language Models》中提出的一种参数高效的轻量化微调方法。其核心动机在于解决当前大语言模型预训练面临的算力瓶颈:**随着大语言模型参数规模呈指数级增长,面向下游特定领域任务进行全参数微调**的计算成本与硬件门槛极高。此外,在样本量有限的垂直领域数据上更新全部预训练权重,极易引发“灾难性遗忘”,导致模型丧失其在预训练阶段所习得的泛化知识。LoRA的理论依据建立在深度学习模型的“内在秩”假设之上。尽管预训练模型包含海量参数,但其在适配特定下游任务时,并非所有的参数都需要调整,真正对下游任务有效的权重实际上只存在于一个极低维度的子空间中。基于此假设,LoRA提出了一种旁路更新机制:通过向模型的部分网络层添加额外的可训练低秩矩阵,**来实现模型在特定任务上的微调,同时**保持原有模型的全部参数处于冻结状态。

LoRA的工作机制可分为两部分:微调和推理。**在模型训练过程中,LoRA保持模型原始的预训练参数矩阵处于完全冻结状态,使其不参与任何梯度更新**。与此同时,在原始矩阵旁引入两个较小的可训练参数矩阵和,其中为极小的本征秩超参数。模型将这两个低秩矩阵的乘积作为对原参数矩阵的附加调整项,使得整体等效权重演变为:

在反向传播的过程中,优化器仅对矩阵和的参数进行梯度计算与更新,原始权重始终保持不变,从而在极大降低显存开销的同时实现了特定任务的参数适配。

在模型部署与实际计算时,LoRA 模块可以无缝叠加到原始权重中,不引入任何额外的计算延迟。当输入张量经过该线性层时,不再仅仅与原始权重相乘,而是使用带有LoRA调整项的融合权重。模型的正向传播行为等效为:

由于是来自LoRA模块的补充权重,可在部署前静态预计算并直接叠加至中;推理时的实际计算量与原始模型完全一致,兼顾了参数效率与推理性能。

思维链

大语言模型通过在海量的文本数据上进行无监督训练,构建了蕴含丰富世界知识的高维语义表示空间。为将模型中潜藏的广义知识精确的迁移至特定的下游任务,提示词工程成为一种核心的技术,其通过将具体任务构建为自然语言指令,使目标任务在输入形式上对齐模型预训练阶段的自回归目标。2022年,Wei等人在论文《Chain-of-Thought Prompting Elicits Reasoning in Large Language Models》中首次提出思维链 (Chain-of-Thought, CoT) 技术。思维链的核心在于通过引导大语言模型将复杂的问题逐步分解成一系列可求解的简单的子问题,并依次生成每个子步骤的推理过程,可以显著**提升模型在复杂推理任务上的性能表现**。这些介于输入与最终答案之间的**中间推理步骤被定义为思维链**。

CoT技术的出现具有深刻的现实动机,研究人员观察到尽管大语言模型在参数规模扩展后展现出强大的知识存储能力,但是在面对数学推理、逻辑判断等需要多步骤因果推断的问题的复杂任务时,模型往往倾向于直接输出答案而跳过中间推导过程,这导致模型的正确率大幅下降。这是由于**传统的提示词要求模型执行从输入到输出的直接映射**,也就是,将复杂的多步推理过度压缩为单次前向传播,超出了模型在有限计算步骤内的推理能力边界。而CoT技术改变了这一映射方式,将推理流程拓展为,即模型在给出答案之前,显示地要求完整生成中间的推理链条。在数学表示上,CoT将原本的条件概率建模扩展为联合概率分布

其中,为任务输入,为由多个逻辑节点组成的中间推理路径,为最终输出。该分解表明,模型首先基于输入生成推理路径,再在与的双重条件约束下推导最终结果。

本章小结

本章系统梳理了多模态分子性质预测的核心理论基础,为后续模型构建建立了严谨的数学框架与算法支撑。首先,明确了涵盖一维序列、二维拓扑、分子指纹与自然语言的多维数据表征方法,确立了模型的多源异构输入基准。其次,深入剖析了特征提取的底层逻辑:在图空间域,系统推导了消息传递神经网络 (涵盖GCN与GAT变体) 及图Transformer的拓扑聚合机制;在文本语义域,详细阐释了Transformer自注意力架构、LoRA轻量化微调策略,以及激发大模型复杂因果推理的思维链 (CoT) 理论。最后,界定了基于交叉注意力的特征动态融合与基于对比学习的跨模态空间对齐范式。综上所述,本章所构建的完整理论体系,直接为后文第三章与第四章中复杂网络架构的设计、目标函数的推导及多模态协同机制的实现奠定了坚实的基石。

2 相关理论基础中国地质大学 (北京) 专业硕士学位论文基于思维链增强与消息传递的分子性质预测方法

在现代创新药物研发的早期阶段,精准**评估候选分子的吸收、分布、代谢、排泄与毒性 (ADMET) 等性质**,对于降低研发成本与规避后期临床风险具有至关重要的意义。近年来,随着计算化学与人工智能技术的交叉与发展,基于深度学习的分子表征技术在**药物分子筛选中得到了广泛的应用**。这类方法能够从分子结构和序列信息中自动的**学习表征信息,从而提高分子性质预测的准确性**。

然而,在面对一些复杂的ADMET任务的时候,现有方法仍存在一些不足。一方面,传统的图神经网络大多依赖于局部节点的无向聚合机制,较少显式建模原子与化学键在消息传递中的动态交互,因此在处理多环结构和复杂长链分子的时候,结果表征能力仍然受到一定的限制。另一方面,虽然大语言模型在知识表示和文本生成方面表现出较强的能力,但是现有方法往往直接利用其完成分子性质的预测,缺少了随中间推理步骤的约束,因而在结果解释和生成稳定性方面仍存在不足。

针对以上问题,本章提出了一种基于思维链增强与通信式图交互的分子性质预测模型(Chain-of-Thought enabled Communicative Message Passing framework, CoT-CMP)。该方法创新性地构建了双塔融合架构:在文本编码端,引入LLaMA-3.1大语言模型与低秩自适应(LoRA)轻量化微调技术,并结合思维链(CoT)提示工程,引导模型自发生成包含微观结构识别、理化属性分析和目标性质推导的显式逻辑推理文本,增强了模型决策过程的可解释性表达能力;在分子图编码端,采用交互式图神经网络(CMPNN)对分子图进行编码,通过增强原子与化学键之间的特征交互,提高结构表征能力。随后,本框架通过交叉注意力机制,对图特征与文本特征进行融合,以提升对复杂ADMET任务的预测效果。

模型设计与描述
CoT-CMP架构概述

针对ADMET(吸收、分布、代谢、排泄、毒性)分子性质预测任务中存在的结构特征与语义逻辑难以对齐的挑战,本章提出了一种基于思维链增强与通信式图交互的分子性质预测模型(Chain-of-Thought enabled Communicative Message Passing framework, CoT-CMP)。该模型采用双塔编码结构,并在此基础上加入跨模态融合模块。

其中,文本端利用大语言模型式的逻辑推理能力来弥补传统模型的不可解释性;图结构端则通过改进的通信式图神经网络捕捉分子内部原子和化学键之间的交互关系,从而提升表征能力。

ADMET数据集通常样本规模较小且具有较强的领域特异性,所以本文采用面向下游任务的直接微调**策略**。如图3-1所示,整个模型主要包括**文本编码**、图编码和融合预测三个部分。

首先是基于思维链的大语言模型文本编码模块,该模块使用LLaMA-3.1-8B强大的广义知识库与逻辑推理能力,通过提示词工程将分子的SMILES序列转化为蕴含丰富药理规则的显式推理文本,最后使用低秩自适应(LoRA)技术对模型进行轻量化微调,从生成文本中提取相应的语义特征。

其次是交互式图编码模块,该模块引入了CMPNN(Communicative Message Passing Neural Network)架构。相较于传统MPNN主要依赖节点聚合的方式,CMPNN在**消息传递过程中加强了原子特征与化学键特征之间的交互**,使化学键信息能够更充分地参与表征学习,从而增强模型对分子局部结构关系的建模能力。

最后是多模态融合预测模块,该模块以结构信息更为稳定的图表征作为查询端,通过交叉注意力机制动态聚合文本推理特征,最终通过多层感知机输出分子ADMET性质预测结果。这种设计不仅赋予了模型强大的预测能力,更通过思维链的生成与关键子结构的交互,显著提升了**模型决策过程的可解释性**。

图3-1 CoT-CMP架构图
思维链增强的文本编码器

在药物分子性质预测中,传统的文本编码方式往往仅将SMILES字符串视为无语义的符号序列,难以挖掘其中隐含的构效关系逻辑。为了解决这一问题,本研究引入了思维链(Chain-of-Thought, CoT)技术,旨在模拟药物化学家和分析分子时的逐步推理过程,以便使模型能够生成更具逻辑性的推理文本,并为结果解释提供依据。文本编码器的首要任务是构建高质量的提示词工程。本架构不再直接要求模型输出预测结果,而是设计了一种包含“分子描述+任务指令+推理引导”的复合提示模板。具体来说,输入的SMILES序列首先被转化为自然语言描述,并结合“Let's think step by step”的引导指令输入至大语言模型中,详细的**提示词模板如表3-1所示**。这一过程能够激发大模型内部潜藏的化学知识,使其自发地从分子量、氢键供受体数量、旋转键数等理化性质出发,逐步推导其对特定ADMET性质的影响,最终生成一段逻辑严密的推理文本。

在模型选择上,本文选用了具有80亿参数的LLaMA-3.1模型作为文本编码的主干网络。鉴于全参数微调大模型对计算资源的需求极高且容易在小样本的ADMET数据集上发生过拟合,本文采用了低秩自适应(LoRA)微调策略。LoRA技术通过在预训练模型的每一层注入可训练的低秩分解矩阵,在保持预训练权重冻结的前提下,仅更新极少量的附加参数。这种方法不仅大幅降低了显存开销,更重要的是,它允许模型在保留通用化学知识的同时,能够快速适配下游特定的分子性质预测任务。在实现上,本文首先基于提示模板生成包含显式推理步骤的文本,再将生成文本与原始分子描述一并输入文本编码器,提取其最终隐藏层表示作为文本语义特征。

表3-1 提示词模板	
System Instruction	You are an expert medicinal chemist and toxicologist. Your task is to analyze the molecular structure and predict its property in a specific biochemical task.
Input Context	Here is the information of a specific drug molecule: SMILES: {smiles} Physicochemical Properties: {properties}
Task	Let's think step by step. Determine whether this molecule is likely to exhibit the target property in the {dataset_task} task. Please reason explicitly in the following three stages: 1. Key Substructure Identification: Identify the major functional groups, ring systems, and core scaffold. 2. Physicochemical and Toxicological Interpretation: Explain how the identified substructures and the provided physicochemical properties may contribute to the target property. 3. Final Property Deduction: Provide one concise sentence summarizing whether the molecule is likely to exhibit the target property.
Output Format	[Key Substructure Identification] ... [Physicochemical and Toxicological Interpretation] ... [Final Property Deduction]

分子图编码器

尽管大语言模型在宏观的药理规则推理上具有优势,但其对微观分子拓扑结构的感知能力存在天然缺陷。为了弥补这一短板并精准捕捉原子间的化学键合作用与电子效应,本文采用了交互式消息传递图神经网络(Communicative Message Passing Neural Network, CMPNN)作为图编码器。同样的,本文的图编码器将分子表示为,其中表示分子中的原子节点,表示原子与原子之间的化学键。相比于只更新节点特征的MPNN模型和只更新边特征的DMPNN模型,CMPNN模型同时对**节点特征和边特征进行更新,并使用**一个被称为通信核的特殊模块来进行操作。该模块打破了传统方法中化学键特征仅作为辅助输入的惯例,强制原子特征与化学键特征在传递前进行深度的交互操作。在每一次迭代中,原子节点的特征向量会与相连化学键的特征向量进行非线性融合,生成增强的消息向量。最终,经过多次更新的有向边特征被映射回原子节点,并通过一个基于门控机制的读出层聚合成图级别的全局表征向量。这一向量高度浓缩了分子的拓扑连接与立体电子特征,将作为后续与文本模态融合过程中的结构锚点,引导文本模态的推理逻辑与之对齐。

融合与预测模块

在获取了包含显式推理逻辑的文本表征与包含深层拓扑结构的图表征后,如何将这两股异构信息进行有效融合是决定预测性能的关键。简单的特征拼接往往忽略了不同模态特征之间的语义鸿沟,难以实现深度的信息交互。因此,本研究设计了一个基于交叉注意力机制的融合模块。在该模块中,本研究选取物理意义更为明确、结构更为稳定的图表征向量作为查询向量,而将包含丰富语义推理信息的文本表征向量作为键向量和值向量。

通过这种设计,模型能够以分子的拓扑结构为索引,在文本推理空间中动态检索与之匹配的药理逻辑描述。**交叉注意力机制计算图特征与文本特征之间的相关性分数**,并据此对文本信息进行加权聚合。这意味着,对于某些依赖特定官能团的性质(如毒性),模型会更加关注图结构中对应的子结构特征;而对于某些依赖整体理化性质的属性(如溶解度),模型则会从文本模态中提取更多的推理信息。经过交叉注意力融合后的特征向量,不仅保留了分子的结构骨架,还融入了专家的推理逻辑。**最后,该融合向量被输入到一个由多层全连接网络构成的预测头中**。针对ADMET数据集的不同任务类型,预测头分别输出分类任务的概率值或回归任务的实数值,从而实现端到端的分子性质预测。

实验设计
数据集

本研究中采用来自TDC平台中的ADMET Benchmark Group [28] 作为实验基准。TDC是目前研发发现领域最为权威的数据集之一,其提供的ADMET数据集基准组,涵盖了**药物的吸收、分布、代谢、排泄和毒性**等关键指标。在本章节将会在ADMET基准组上对CoT-CMP框架进行微调。数据集的基本介绍如表3-2所示。

3.基于多模态学习的药物分子性质预测研究_第3部分 总字数: 11,618

文字重复率: 10.1% (1,169)

序号	相似文献来源	重复率	是否引证

序号	相似文献来源	重复率	是否引证
1	教师风格化教学手势生成模型研究 冯子斌 - 《江西师范大学硕士论文》 - 2025	0.9%	否
2	图神经网络训练框架的实践和探索 - 《互联网资源》 - 2022	0.7%	否
3	融合注意力和几何特征的点云分类分割网络 王玉华;刘涌; - 《激光与红外》 - 2025	0.7%	否
4	阿司咪唑的致心律失常作用及其作用机理研究进展 郑卫红; - 《中国药事》 - 2007	0.5%	否
5	大规模图神经网络系统综述 赵港;王千阁;姚烽;张岩峰;于戈; - 《软件学报》 - 2022	0.5%	否
6	基于微表情和面部组织血氧的隐藏情绪识别 陈东 - 《西南大学硕士论文》 - 2023	0.5%	否
7	基于层次分类法的弥漫大B细胞淋巴瘤的疾病进展阶段多分类预测研究 黄雪倩;张岩波;王蕾;郑楚楚;余红梅;范双龙;阳桢寰;邢蒙;赵志强;罗艳虹; - 《中国卫生统计》 - 2021	0.4%	否
8	基于深度学习的眼底图像视盘与中央凹检测及血管分割研究 谢慧颖 - 《天津大学硕士论文》 - 2020	0.4%	否
9	基于变分图自动编码器的空间转录组数据去卷积方法 周全 - 《浙江理工大学硕士论文》 - 2023	0.4%	否
10	基于图卷积网络的人体动作识别算法研究 - 《高校学位库》 - 2022	0.4%	否
11	基于深度学习的分子物理属性预测 侯园园 - 《中国科学院大学(中国科学院深圳先进技术研究院)硕士论文》 - 2022	0.4%	否
12	基于特征解耦的双流网络模型全色锐化 张胜裕;宋慧慧; - 《计算机工程与科学》 - 2025	0.4%	否
13	作者介绍 - 《石油地球物理勘探》 - 2013	0.4%	否
14	靶控输注异丙酚用于人工流产手术麻醉的临床观察 王丽丽 - 《山西医科大学硕士论文》 - 2004	0.3%	否
15	抗肿瘤药物临床试验中方案违背现状及原因分析 金艳;于杨; - 《肿瘤药学》 - 2024	0.3%	否
16	基于BERT的需求追踪系统设计与实现 李平章 - 《大连理工大学硕士论文》 - 2024	0.3%	否
17	基于多种特征交互方式的融合点击率预测模型 孙伟智 - 《成都理工大学硕士论文》 - 2022	0.3%	否
18	基于仿生模式识别和PCA/ICA的DOA估计方法 安冬;王守觉 - 《电子学报》 - 2004	0.3%	否
19	基于机器学习的网络流量预测算法研究 - 《高校学位库》 - 2020	0.3%	否
20	基于地标的图神经网络启发式函数学习研究 宣铭涛 - 《广东工业大学硕士论文》 - 2025	0.3%	否
21	低资源对话状态追踪关键技术研究 顾铭 - 《华东师范大学硕士论文》 - 2024	0.3%	否
22	双去甲氧基姜黄素共晶及其共无定形固体分散体的研究 孙智雄 - 《南昌大学硕士论文》 - 2025	0.2%	否
23	肝肠首过效应对齐墩果酸生物利用度的影响研究 李能 - 《广州中医药大学硕士论文》 - 2012	0.2%	否
24	先导化合物结构优化策略(九)—改善药物清除率 - 《互联网资源》 - 2021	0.2%	否

序号	相似文献来源	重复率	是否引证
25	体外模型在中药代谢研究中的应用 王莎;刘斯琪;丁鹏敏;庞月笙;陶志;王如峰; - 《药学进展》 - 2020	0.2%	否
26	先导化合物结构优化策略(九)——改善药物清除率 张蕊;王江;朱浩然;柳红; - 《药学报》 - 2021	0.2%	否
27	hERG钾通道失活机制的研究进展 郝良朝;陈渊;赵伟; - 《药物生物技术》 - 2020	0.2%	否
28	“评估和控制药物中DNA反应性（致突变）杂质以限制潜在致癌风险”ICH M7(R2.. 周植星;崔岚;马磊;黄芳华; - 《药物评价研究》 - 2024	0.2%	否
29	基于深度学习的药物副作用关联预测方法研究 李沛儒 - 《黑龙江大学硕士论文》 - 2024	0.2%	否
30	降雨天气对公共交通客流稳定性影响研究 李丹丹 - 《长安大学硕士论文》 - 2024	0.2%	否
31	太赫兹成像系统数据传控单元设计及图像分割算法研究 朱承志 - 《电子科技大学硕士论文》 - 2020	0.2%	否
32	基于先验知识的人脸超分辨与基于样本扩充的低分辨率人脸识别方法研究 林旺庆 - 《厦门大学硕士论文》 - 2020	0.2%	否
33	开源图神经网络算法库的设计与实现 赵天宇 - 《北京邮电大学硕士论文》 - 2023	0.2%	否
34	机器解答算法的状态转移分析方法和透视评估方法研究 程维纳 - 《华中师范大学博士论文》 - 2023	0.2%	否
35	高比例新能源配电网故障隔离与恢复策略研究 陈嘉岳 - 《华北电力大学硕士论文》 - 2024	0.2%	否
36	0b663b517d494a27bcb0b6c9fe5311c4 - 《高校学位库》 -	0.2%	否
37	基于图神经网络的癫痫脑电信号分类方法研究 李宗强 - 《大连理工大学硕士论文》 - 2024	0.2%	否
38	基于深度学习的刨花板表面缺陷智能检测方法研究 沈胤熙 - 《南京林业大学硕士论文》 - 2025	0.2%	否
39	基于知识图谱的药物和通路关联预测方法 耿于怀 - 《华东师范大学硕士论文》 - 2024	0.2%	否
40	工业二维码标识的定位及校正算法研究 张贵仲 - 《杭州电子科技大学硕士论文》 - 2024	0.2%	否
41	网络安全态势要素获取及预测方法研究 王素芳 - 《桂林电子科技大学硕士论文》 - 2021	0.2%	否
42	基于互信息耦合DBO-BiLSTM-Attention的风光协同发电功率预测模型 李颖欢;刘吉成;卢运媛;孙嘉康; - 《电力科学与技术学报》 - 2025	0.2%	否
43	图卷积神经网络在自然语言处理中的应用研究 熊晗; - 《电子制作》 - 2021	0.2%	否
44	基于图神经网络和用户长短期偏好的会话推荐 卢官明;柯润宇;卢峻禾;丁佳伟;魏金生; - 《南京邮电大学学报(自然科学版)》 - 2024	0.2%	否
45	基于异质图注意力机制和多模态信息的图像推荐算法研究 王健 - 《西北师范大学硕士论文》 - 2024	0.2%	否
46	基于高光谱与深度学习的中药材分类研究 刘诚 - 《昆明理工大学硕士论文》 - 2024	0.2%	否
47	面向图文检索的跨模态实体对齐与语义关联方法研究 张志平 - 《齐鲁工业大学硕士论文》 - 2025	0.2%	否

序号	相似文献来源	重复率	是否引证
48	视觉—语言联合表征的跨模态视觉定位研究 梁潜 - 《广东工业大学硕士论文》 - 2025	0.2%	否
49	基于深度神经网络和分子指纹预测药物性肝损伤 杨琼 - 《大连理工大学硕士论文》 - 2024	0.2%	否
50	707b6dfee5364e6c810568015ced6536 - 《高校学位库》 - 2021	0.2%	否
51	张鹤汀-毕业论文-初稿-修正中-0412 - 《高校学位库》 - 2021	0.2%	否
52	osotugyouomedotou - 《高校学位库》 - 2021	0.2%	否
53	作者介绍 - 《石油地球物理勘探》 - 2012	0.2%	否
54	基于多模态表征学习的分子性质预测研究 张茹 - 《南宁师范大学硕士论文》 - 2024	0.2%	否
55	面向设备的深度学习图像对话帮助系统的研究 郑翔 - 《西安电子科技大学硕士论文》 - 2021	0.2%	否
56	MHE对P糖蛋白底物体内行为的影响及作用物质基础初探 肖博文 - 《广东药科大学硕士论文》 - 2016	0.1%	否
57	伏立康唑高风险代谢性药物相互作用分析 连玉菲;刘洪涛;张玥;邱学佳;方灵芝;董占军; - 《河北医药》 - 2021	0.1%	否
58	d7a7f3fdc47841fe99f2c0fae325d2a9 - 《高校学位库》 -	0.1%	否
59	上海市主城区生活饮用水中非挥发性有机物的潜在致突变性分析 张慧君;陶功华;洪新宇;马武仁;肖萍; - 《环境与职业医学》 - 2021	0.1%	否
60	基于深度学习的网页分类算法研究 陈芊希 - 《上海交通大学硕士论文》 - 2016	0.1%	否
61	基于图卷积网络的个人信用风险评估应用研究 范竞予 - 《中央财经大学硕士论文》 - 2022	0.1%	否
62	基于评论的隐式社交关系在推荐系统中的应用 赵亚辉;刘瑞; - 《计算机应用研究》 - 2015	0.1%	否
63	基于特征提取与选择的气体识别研究 陈博;王刚;师春雪;齐国臣;曹仰杰;田辉;卫荣汉; - 《仪表技术与传感器》 - 2023	0.1%	否
64	基于注意力和Transformer的阿尔兹海默症分类 汪悦恺;王文伟;孟慧茹; - 《无线电工程》 - 2023	0.1%	否
65	基于Mamba与GAN生成模型的ECG数据分类方法研究 张威豪 - 《杭州电子科技大学硕士论文》 - 2025	0.1%	否
66	02ddf5212a984a2e965ba96374df77e7 - 《高校学位库》 -	0.1%	否
67	复杂环境下基于推抓协同操作的目标物体抓取 孙先涛;唐思宇;陈文杰;贺春东;智亚丽;陈伟海; - 《控制理论与应用》 - 2023	0.1%	否
68	基于结构感知自监督表征学习的分子性质预测方法研究 郑子希 - 《山东师范大学硕士论文》 - 2024	0.1%	否
69	化学分子的隐藏空间嵌入方法原理和应用 陈昊天;杨涛;刘晓彤; - 《化学进展》 - 2025	0.1%	否
70	基于多任务学习的果蔬农药残留光谱检测技术研究 卢亚楠 - 《南京林业大学硕士论文》 - 2025	0.1%	否

原文内容
表3-2 ADMET基准数据集

任务分类 数据集 分子数量 任务类型 评价指标 划分方式

吸收 Caco2 906 回归 MAE Scaffold
HIA 578 分类 AUROC Scaffold
Pgp 1212 分类 AUROC Scaffold
Bioav 640 分类 AUROC Scaffold
Lipo 4200 回归 MAE Scaffold
AqSol 9982 回归 MAE Scaffold
分布 BBB 1975 分类 AUROC Scaffold
PPBR 1797 回归 MAE Scaffold
VDss 1130 回归 Spearman Scaffold
代谢 CYP2C9 Inhibition 12092 分类 AUPRC Scaffold
CYP2D6 Inhibition 13130 分类 AUPRC Scaffold
CYP3A4 Inhibition 12328 分类 AUPRC Scaffold
CYP2C9 Substrate 666 分类 AUPRC Scaffold
CYP2D6 Substrate 664 分类 AUPRC Scaffold
CYP3A4 Substrate 667 分类 AUPRC Scaffold
排泄 Half life 667 回归 Spearman Scaffold
CL-Hepa 1020 回归 Spearman Scaffold
CL-Micro 1102 回归 Spearman Scaffold
毒性 LD50 7385 回归 MAE Scaffold
hERG 648 分类 AUROC Scaffold
Ames 7255 分类 AUROC Scaffold
DILI 475 分类 AUROC Scaffold

1. 吸收

Caco-2:衡量药物在人体结肠癌细胞系中的渗透系数,是模拟人体肠道吸收能力的体外标准,用于精准预测口服药物的吸收效率。

HIA:量化药物经由肠道上皮细胞进入血液循环的比例,是评估口服药物能否被人体有效吸收的重要指标。

Pgp:预测分子是否为**P-糖蛋白的底物或抑制剂**。**P-糖蛋白**参与药物外排过程,与药物吸收及多药耐药现象密切相关。

Bioav:**预测药物进入体循环的比例**,反映了吸收过程和肝脏首过效应的综合结果,是决定临床给药剂量的重要参数。

Lipo:记录分子的辛醇-水分配系数 (LogD) ,用于评估药物的亲脂性。该性质直接决定了药物穿透细胞膜及生物屏障的能力。

2. 分布

BBB:判断分子能否穿透血脑屏障进入中枢神经系统。这对开发脑部疾病药物至关重要,同时也用于规避非脑部药物的中枢副作用。

PPBR:预测药物与血浆蛋白的结合率。结合率过高会限制血液中游离药物的浓度,进而影响药效发挥与向组织的分布。

VDss:衡量药物在体内的理论稳态分布容积,反映药物在组织与血浆间的分布倾向,是指导临床给药间隔设计的关键参数。

3. 代谢

CYP2C9 Inhibition:预测分子是否抑制CYP2C9酶。该酶代谢约15%的临床药物,其抑制作用会导致底物药物血药浓度异常升高,引发严重出血等不良反应。

CYP2D6 Inhibition:预测分子对 CYP2D6酶的抑制潜力。该酶涉及约25%**药物的代谢,其抑制可能导致显著的药物相互作用,影响联合用药的安全性**。

CYP3A4 Inhibition:判断分子是否抑制人体含量最丰富的 CYP3A4 酶。由于该酶代谢近半数临床药物,其强抑制剂极易引发灾难性的药物蓄积中毒,是DDI筛查的重中之重。

CYP2C9 Substrate:预测分子是否为 CYP2C9 酶的底物。识别该代谢途径有助于预测药物在不同基因型人群中的清除速率差异,对优化酸性药物的药代动力学至关重要。

CYP2D6 Substrate:判断分子是否主要通过CYP2D6途径清除。该酶存在显著的遗传多态性,确定其底物属性对于预测药物在“快/慢代谢者”体内的暴露量差异具有指导意义。

CYP3A4 Substrate:预测分子是否被 CYP3A4 酶代谢。作为肝脏首过效应的主要执行者,确认底物属性有助于评估**药物的口服生物利用率及受代谢诱导剂影响的敏感性**。

4. 排泄

Half Life:**预测药物在体内的消除半衰期,即血药浓度降低一半所需时间**。它是描述药物在体内驻留时长的核心药代动力学参数。

CL-Hepa:测量药物在肝细胞中的清除率,反映肝脏整体对药物的代谢清除能力,是评估**药物肝脏代谢稳定性的体外模型**。

CL-Micro:**测量药物在肝微粒体中的内在清除率,主要反映 I 相代谢酶对药物的降解速率**。

5. 毒性

LD50:记录导致50%实验动物死亡的致死剂量,用于评估化合物的急性毒性水平,是药物安全性评价中不可逾越的基础红线。

hERG:预测分子对钾离子通道的**阻滞作用**。**该通道阻塞会导致长QT综合征等致死性心律失常,是心脏毒性**评估中较为关键的指标。

Ames:**基于细菌回复突变实验判断分子是否具有致突变性**,用于早期筛查潜在的致癌风险与遗传毒性,是临床前必做的安评项目。

DILI:预测药物诱导的肝损伤风险。**这是导致药物临床试验失败主要原因之一,该数据集用来预测分子是否会诱导肝损伤**。

划分方式

为了更直观地揭示不同数据划分策略对模型泛化评估的影响,本研究选取了PPBR_AZ (血浆蛋白结合率) 数据集作为典型案例,利用t-SNE降维技术将高维分子特征映射至二维平面,并采用六边形热力图对化学空间的**分布密度进行了可视化对比**。如图3-2所示,图中每个六边形单元的颜色映射了该区域内测试集样本的占比:深绿色代表该区域完全由训练集样本占据,而红色则代表该区域完全由测试集样本占据。

如图3-2左侧所示,在随机划分 (Random Split) 策略下,热力图呈现出均匀的深绿色基调,且测试集样本 (浅色/红色点) 呈散点状随机分布于训练集样本的包围之中。这种“均匀混合”现象表明,训练集与测试集在化学空间中共享了大量相似的分子骨架结构,模型在测试集上的预测本质上是一种插值过程,极易因记忆相似结构而导致性能评估的虚高。

相比之下,图3-2右侧的骨架划分 (Scaffold Split) 展现出了截然不同的分布模式。热力图呈现出显著的区域分化特征:部分化学空间区域呈现深绿色 (训练集集中区),而部分区域则呈现鲜明的红色或橙色 (测试集集中区)。这种“斑块状”分布直观地说明了训练集与测试集占据了互不重叠的化学空间区域,二者之间存在显著的结构鸿沟。这种划分方式迫使模型必须跨越已知的骨架簇,对位于全新化学空间区域的分子进行外推预测。

该可视化结果表明,骨架划分能够在**一定程度上减少训练集与测试集之间的骨架重叠**,从而比随机划分更严格地评估模型的结构泛化能力。因此,本文后续实验采用骨架划分策略,以提高泛化评估的严格性。

图3-2 随机划分与骨架划分在PPBR_AZ数据集上分布的对比

实验设置

为了确保实验结果的可复现性与公平性,此小结将介绍本实验中各个环节所用到的实验设置和相关参数设置,具体如下:

本实验所用到的计算设备是一张NVIDIA GeForce RTX 4090的显卡,其拥有24GB的显存,用来对模型推理和梯度计算。操作系统为Ubuntu 24.04 LTS,配合一张Intel Core i7-12700KF CPU和64GB的内存。在软件方面主要是基于PyTorch 2.4.1 深度学习框架构建,图神经网络组件依赖于 PyG (PyTorch Geometric) 2.7.0 库,化学分子处理与理化指标计算则统一采用 RDKit 2025.9.3 工具包。

对于模型架构中的参数来说,本实验选用了LLaMA-3.1-8B-Instruct作为文本模态的**主干网络,其输入序列的最大长度为512个Token**。对于LoRA的核心参数设定为:秩r=16,缩放系数为32,Dropout为0.05。对于图编码采用三层的CMPNN网络,其隐藏层统一设置为300。

关于**模型训练过程中的相关参数,例如学习率设置为,批次大小设置为32,最大训练轮次设置为200轮,且引入早停机制,当损失连续15个Epoch未**

出现下降的时候自动终止训练。

评价指标

ADMET基准数据集涵盖了分类和回归两类任务,针对不同的任务类型采用不同的评价指标。其在分类任务中使用了AUROC和AUPRC作为评价标准,在回归任务中使用了MAE和Spearman作为评价标准。各个指标的具体介绍如下:

AUROC:全称为接收者操作特征曲线下面积 (Area Under the Receiver Operating Characteristic Curve),适用于二分类任务,评估模型对正负样本的排序能力。具体来说ROC是以假阳性率 (FPR) 为横坐标,真阳性率 (TPR,即召回率) 为纵坐标绘制的一条曲线。而AUROC就是这条ROC曲线下方的积分的面积。

AUPRC:全称为精确率-召回率曲线下面积 (Area Under the Precision-Recall Curve),适用于数据分布极度不平衡的二分类任务。PR曲线是以召回率,即TPR为横坐标,精确率 (Precision) 为纵坐标绘制的曲线。而AUPRC就是PR曲线下方的面积。

MAE:全称为平均绝对误差 (Mean Absolute Error),适用于回归任务,用于衡量模型预测值与真实值之间偏差的平均水平。假设样本的总数为,是第个样本的真实值,是第个样本的预测值,则平均绝对误差定义为:

Spearman:全称为斯皮尔曼等级相关系数 (Spearman's Rank Correlation Coefficient),与MAE不同的是Spearman关注排序能力即预测值的相对大小关系是否正确。一个模型可能MAE较大但Spearman系数很高,这说明虽然预测的绝对数值不够精确,但能够正确区分样本之间的相对高低。在药物筛选的实际应用中,通常需要从大量候选分子中筛选出性质最优的一批分子,此时排序的准确性往往比绝对数值的精度更具实际价值,因此Spearman系数在ADMET基准评估中具有重要意义。

对比模型

为了客观评估CoT-CMP框架在ADMET预测任务中的性能优势,本文从ADMET基准组的官方排行榜中选取了四个基准模型。该排行榜旨在为各个数据集提供标准化的性能评估。各个基准模型的介绍如下:

GCN [29]:图卷积神经网络是最经典也是应用最广泛的神经网络基线模型之一。该模型将分子视为图,原子视为节点,化学键视为边,通过局部领域内的消息传递机制来更新节点的特征信息。每一个原子都聚合了一阶邻居原子的特征信息,通过卷积操作来获取分子之间局部拓扑结构,最终通过读出函数得到分子级别的嵌入。

AttentiveFP [30]:是基于注意力机制的经典图神经网络,旨在解决传统GCN在处理长程依赖时的局限性。该模型首次通过在原子级别和分子级别引入图注意力网络,能够动态学习不同邻居节点对中心原子的贡献权重。先对原子邻域做注意力加权聚合,再对全局分子做超图级别的注意力读出。该模型能够捕捉长程依赖,在多个分子性质预测任务上表现优异,是图神经网络中较强的基线模型。

NeuralFP [31]:神经网络指纹模型是一种将深度学习应用于分子表征的开创性工作之一,通过对传统的Morgan指纹进行神经网络的泛化,将固定的哈希操作替换为可学习的神经网络,允许网络在端到端的训练过程中自主学习最优的特征提取方式。它通过图池化操作,将节点级别的特征平滑地聚合为整个分子的连续型向量表示。

CNN [32]:卷积神经网络是一种基于卷积操作的网络模型,在分子预测任务中通常将SMILES视为序列输入,利用一维卷积网络提取局部子结构特征。

实验及结果分析

对比实验

为了验证CoT-CMP模型在药物分子预测任务上的性能,本章节在ADMET基准组上的22个数据集进行了实验,实验过程中所有的基线模型和CoT-CMP保持一致的划分方式。为了保证实验数据的可靠性,实验采用了不同的随机数进行了多次实验。试验结果中最好的数据由黑体标出,次优的结果由下划线标出。各个模型的实验结果数据如表3-3。

由实验数据结果可得知CoT-CMP在17个评测集上获取了最优的结果,在5个评测集上获取了次优的结果。值得注意的是在本次实验包含的4项毒性预测任务 (LD50,hERG,Ames,DILI) 中,CoT-CMP实现了全面领先。无论是针对心脏毒性的hERG抑制预测,致突变性的Ames测试,还是药物性肝损伤,CoT-CMP均展现出了最高的预测精度,将准确率分别提升至0.855、0.838、0.891。这一结果表明,模型在毒性相关任务上具有较好的判别能力,可为高通量虚拟筛选中的早期风险评估提供参考。另外在VDss数据集中,和最佳的模型GCN相比,CoT-CMP模型性能提高了7%左右,在Half life数据集上性能提高了10%左右。在CYP2D6 Inhibition、CYP3A4 Inhibition、CYP2C9 Substrate和CYP2D6 Substrate等代谢相关的数据集上,CoT-CMP模型表现出了优异的性能。

表3-3 CoT-CMP在ADMET基准组上的对比实验结果

数据集 GCN AttentiveFP NeuralFP CNN CoT-CMP

Caco2 (↓)	0.599 (0.104)	0.401 (0.032)	0.530 (0.102)	0.446 (0.036)	0.387 (0.361)
HIA (↑)	0.936 (0.024)	0.974 (0.007)	0.943 (0.014)	0.869 (0.026)	0.982 (0.012)
Pgp (↑)	0.895 (0.021)	0.892 (0.012)	0.902 (0.020)	0.908 (0.012)	0.912 (0.020)
Bioav (↑)	0.566 (0.115)	0.628 (0.035)	0.632 (0.036)	0.613 (0.013)	0.630 (0.026)
Lipo (↓)	0.541 (0.011)	0.572 (0.007)	0.536 (0.023)	0.743 (0.020)	0.510 (0.035)
AqSol (↓)	0.907 (0.020)	0.776 (0.008)	0.947 (0.009)	1.023 (0.023)	0.742 (0.046)
BBB (↑)	0.842 (0.016)	0.855 (0.011)	0.836 (0.009)	0.781 (0.030)	0.850 (0.019)
PPBR (↓)	10.194 (0.373)	9.373 (0.335)	9.292 (0.384)	11.106 (0.358)	8.892 (0.212)
VDss (↑)	0.457 (0.050)	0.241 (0.145)	0.258 (0.162)	0.226 (0.114)	0.521 (0.151)
CYP2C9 Inhibition (↑)	0.735 (0.004)	0.749 (0.004)	0.739 (0.010)	0.713 (0.006)	0.745 (0.023)
CYP2D6 Inhibition (↑)	0.616 (0.020)	0.646 (0.014)	0.627 (0.009)	0.544 (0.053)	0.650 (0.010)
CYP3A4 Inhibition (↑)	0.840 (0.010)	0.851 (0.006)	0.849 (0.004)	0.821 (0.003)	0.855 (0.004)
CYP2C9 Substrate (↑)	0.344 (0.051)	0.375 (0.032)	0.359 (0.059)	0.367 (0.059)	0.380 (0.051)
CYP2D6 Substrate (↑)	0.617 (0.039)	0.574 (0.030)	0.572 (0.062)	0.485 (0.037)	0.621 (0.029)
CYP3A4 Substrate (↑)	0.590 (0.023)	0.576 (0.025)	0.578 (0.020)	0.662 (0.031)	0.622 (0.035)
Half life (↑)	0.239 (0.100)	0.085 (0.068)	0.177 (0.165)	0.038 (0.138)	0.337 (0.175)
CL-Hepa (↑)	0.366 (0.063)	0.289 (0.022)	0.401 (0.037)	0.235 (0.021)	0.382 (0.022)
CL-Micro (↑)	0.532 (0.033)	0.365 (0.055)	0.529 (0.015)	0.252 (0.116)	0.550 (0.027)
LD50 (↓)	0.649 (0.026)	0.678 (0.012)	0.667 (0.020)	0.675 (0.011)	0.601 (0.028)
hERG (↑)	0.738 (0.038)	0.825 (0.007)	0.722 (0.034)	0.754 (0.037)	0.855 (0.035)
Ames (↑)	0.818 (0.010)	0.814 (0.008)	0.832 (0.006)	0.776 (0.015)	0.838 (0.017)
DILI (↑)	0.859 (0.033)	0.886 (0.015)	0.851 (0.026)	0.792 (0.016)	0.891 (0.020)

通过横向对比也可以发现,基于一维序列的CNN模型在绝大多数任务上表现平平,这验证了保留分子的二维或三维空间拓扑结构对于准确预测ADMET属性至关重要。另一方面,与同为图神经网络的AttentiveFP和NeuralFP相比,CoT-CMP依然能够在大部分任务中胜出。这说明本模型采用的CoT增强文本描述和交叉注意力融合的策略,相比于AttentiveFP简单的注意力机制,能够更有效地聚合长程依赖信息和捕获局部官能团的特征,从而在复杂的ADMET任务中获得了更加丰富和鲁棒的分子表征。

消融实验

为系统性地研究CoT-CMP框架中各核心模块的独立贡献与协同效应,特别是探究大语言模型内部机制以及多模态融合方式对ADMET最终预测性能的影响,本节在统一的实验配置环境下,设计了五种渐进式的消融变体进行对比分析。

本研究以完整的CoT-CMP模型为基准上限,向下拆分架构模块或优化策略,各个变体的具体定义如下:

w/o Text:完全移除大语言模型及其对应的文本编码链路,仅保留CMPNN图编码器提取分子的二维拓扑特征,并通过全连接层直接输出预测结果。

w/o LoRA :保留双塔架构与融合模块,但在训练过程中完全冻结LLaMA-3.1的所有预训练权重,不使用低秩自适应微调,仅将大模型作为静态的特征提取器。

w/o CoT :保留所有的模型权重微调与双塔架构,但对提示词进行修改。具体而言,仅对文本提示模板进行调整,即删除原模板中用于触发分步推理的显式引导语,如“Let's think step by step”等,只输入分子的SMILES序列和原始理化性质描述文本,直接进行性质的预测文本生成。

w/o Cross-Attn:保留完整的图文特征提取链路,但在多模态对齐阶段,移除动态交叉注意力模块,转而采用简单的特征拼接方式将图向量与文本向量拼接。

表3-4 CoT-CMP在ADMET基准组上部分分类任务消融实验结果

Model	Pgp	BBB	CYP2D6 Inhibition	Ames
w/o Text	0.835 (0.018)	0.803 (0.016)	0.597 (0.037)	0.805 (0.017)
w/o CoT	0.805 (0.024)	0.791 (0.032)	0.593 (0.027)	0.795 (0.022)
w/o LoRA	0.775 (0.012)	0.740 (0.010)	0.566 (0.029)	0.748 (0.015)
w/o Cross-Attn	0.872 (0.015)	0.825 (0.021)	0.638 (0.023)	0.820 (0.019)
CoT-CMP	0.912 (0.020)	0.850 (0.019)	0.650 (0.010)	0.838 (0.017)

本文在Pgp、BBB、CYP2D6 Inhibition和 Ames四个**分类数据集上进行了消融实验,结果如表3-4所示,从整体来看,CoT-CMP在这四个分类数据集上均取得了最优的结果,表明本文提出的文本增强、CoT提示模块、LoRA微调策略以及跨模态交叉注意力等模块均能够有效提升模型的分类性能,且各模块**之间存在明显的协同增益。具体来看,w/o LoRA的性能整体最弱,在Pgp、BBB、CYP2D6 Inhibition和Ames上的结果分别仅为0.775、0.740、0.566和0.748,相较完整模型分别下降了0.137、0.110、0.084和0.090。这说明参数高效微调机制对大模型适应分子性质预测任务具有重要作用,若缺少有效的任务适配,文本的语义建模能力将明显降低。

表3-5 CoT-CMP在ADMET基准组上部分回归任务消融实验结果

Model	Caco2	AqSol	PPBR	LD50
w/o Text	0.521 (0.045)	0.935 (0.052)	10.954 (0.345)	0.705 (0.035)
w/o CoT	0.485 (0.038)	0.882 (0.048)	10.320 (0.285)	0.682 (0.030)
w/o LoRA	0.442 (0.033)	0.824 (0.051)	9.765 (0.260)	0.655 (0.025)
w/o Cross-Attn	0.415 (0.028)	0.778 (0.041)	9.245 (0.235)	0.624 (0.031)
CoT-CMP	0.387 (0.361)	0.742 (0.046)	8.892 (0.212)	0.601 (0.028)

在回归数据集中,本文选取了Caco2、AqSol、PPBR和LD50四个数据集做消融实验,结果如表3-5所示。本文提出的CoT-CMP模型仍然在四个数据集上取得了最优的性能,这表明各个模块之间的协同同样能够在连续值性质预测任务中有效降低误差。其中,w/o Text在四个任务上的MAE最高,说明若完全移除文本模态,模型对分子性质连续值的拟合能力将受到明显削弱。这一结果表明,文本信息在回归任务中同样发挥了重要补充作用,尤其对于需要综合理化属性与语义知识的任务更为关键。w/o CoT相比w/o Text有一定改善,但仍明显劣于完整模型。这说明即使保留文本输入,如果缺少显式的思维链引导,模型所构建的文本表征仍然不够充分,难以最大化发挥文本模态最大作用。w/o LoRA虽然较w/o Text和w/o CoT已有明显改善,但仍全面落后于完整模型。另一方面,w/o Cross-Attn是所有消融版本中最接近完整模型的设置,但依旧高于CoT-CMP,说明仅依赖简单的模态组合仍不足以充分建模图结构与文本语义**之间的对应关系,而跨模态交叉注意力机制能够进一步提升**异构信息融合的有效性。

可视化分析

为进一步验证CoT-CMP模型在可解释性,本文选取TDC的 毒性预测任务 **DILI数据集中的氯磺丙脲 (chlorpropamide) 作为典型案例进行可视化分析**。该分子的SMILES为CCCNC(=O)NS(=O)(=O)c1ccc(Cl)cc1,在数据集中对应的标签为1,表示该样本具有药物性肝损伤风险。本文从分子结构和文本语义两个方面对模型的判别依据进行了可视化,如图3-3所示。左侧给出了氯磺丙脲的二维分子结构,右侧展示了模型在图模态上的注意力热力分布。可以观察到,模型的高响应区域主要集中在对氯苯基-磺酰脲主骨架,尤其是磺酰基、相邻脲基连接区以及芳香环邻近区域表现出较高的注意力。在文本模态方面,图3-3下方详细展示了大模型生成的结构化分析文本及其热力词可视化结果。其中对于一些分子结构的词语模型表现出较高的关注,例如p-chlorobenzenesulfonyl、N-sulfonylurea scaffold、chlorophenyl ring等,还有对于毒理判断直接相关的关键词,例如hepatotoxicity、drug-induced liver injury等词语也是表现出较高的关注度。上述可视化结果表明,模型在该样本上关注的结构区域和文本关键词与已知毒性相关化学直觉具有一定一致性,从而为理解模型预测依据提供了辅助线索。

图3-3 氯磺丙脲在DILI任务中的双模态可视化分析结果

参数敏感实验

在图神经网络的架构设计中,消息传递的层数是决定模型感受视野的大小和特征提取质量的关键超参数之一。为了进一步探究CMPNN图编码器的层数对于模型最终性能的影响,本节从吸收、分布、代谢、毒性相关任务中各选了一个数据集,覆盖了分类任务和回归任务,进行图编码器层数的参数敏感性实验,结果如图3-4所示。

根据结果可知,随着图编码器的层数加深,性能曲线呈现出倒U型。当层数为1到2层的时候,模型的表现较低,这是由于浅层网络不足以捕捉分子全局的特征信息。**在层数达到3层的时候,模型性能能达到峰值**。这是由于大多数分子都是小分子,因此三层图网络已经可以很好的捕捉到全局的信息。在层数达到4到5层的时候,模型的性能明显开始下降,这是由于过深的网络对于小分子结构来说会极容易出现过拟合现象。因此,为了在全局感受野与特征区分度之间取得最佳平衡,本研究在核心实验中,均将CMPNN的层数设置为3层。

图3-4 CMPNN模型层数对分类任务性能的影响

本章小结

本章针对药物分子ADMET性质预测任务中微观结构特征与宏观药理语义逻辑难以有效对齐的问题,提出了 CoT-CMP 双塔预测框架。该框架结合思维链增强的文本编码、CMPNN 图结构建模与交叉注意力融合,实现了图文信息的联合预测。在TDC多个ADMET**基准上的实验结果表明,该方法在多数任务上取得了较优表现,消融实验也验证了文本增强、LoRA微调和跨模态融合模块的有效性**。

在模型架构设计方面,本章详细阐述了CoT-CMP框架的三大核心组件。在文本编码端,模型引入了LLaMA-3.1大语言模型,结合思维链 (CoT) 提示工程与低秩自适应 (LoRA) 微调技术,将分子的线性序列转化为包含显式理化分析与药效推导的逻辑文本表征,显著提升了预测过程的可解释性。在图编码端,模型采用了交互式消息传递图神经网络 (CMPNN)。通过构建基于有向边的消息传递机制与引入通信核模块,该网络有效克服了传统图模型中的信息回流弊端,实现了原子与化学键特征的动态深度交互,从而精准捕获了复杂的分子全局拓扑依赖。在多模态融合端,模型部署了交叉注意力机制,以分子结构特征为查询锚点,动态聚合文本推理空间中的高价值语义信号。

在实验设计方面,本章明确了模型评估的基准体系。实验选取了Therapeutics Data Commons (TDC) 平台中涵盖吸收、分布、代谢、排泄与毒性五个维度的多项核心数据集。为真实反映模型在未知化学空间中的泛化性能,本章论证并确立了基于骨架划分的严格评估策略,并详细规定了包含AUROC、AUPRC、MAE及Spearman相关系数在内的多维评价指标体系,同时选取了AttentiveFP、NeuralFP、CNN及GCN四种具有代表性的模型作为对比基线。本章的理论架构搭建与严密的实验流程设计,为后续验证CoT-CMP模型在复杂药物分子性质预测任务中的优越性奠定了坚实基础。

3 基于思维链增强与消息传递的分子性质预测方法

中国地质大学 (北京) 专业硕士学位论文

基于知识增强与图对齐的分子性质预测方法

随着深度学习技术的飞速发展,数据驱动的分子表征学习在创新药物发现与候选分子早期成药性评估中得到了领域内广泛的关注。高质量得分子性质标签获取成本较高,所以近年来较多研究采用“预训练—微调”的范式,希望通过大规模无标注数据学习通用分子表示,从而提升下游任务性能。然而,分子的理化性质与生化性质受到多种结构因素和药理信息的共同影响。单一模态表征往往难以全面描述分子特征。因此,联合利用分子图、序列、指纹和文本信息的**多模态表征学习,逐渐成为分子性质预测中的一个重要研究方向**。

尽管多模态方法能够提供比较丰富的信息来源,但现有跨模态预训练框架仍存在一些不足。首先,公共医学数据库中的原始分子文本通常包含较多冗余信息,文本长度和质量差异较大,且缺乏关键理化属性的显式约束,这会影响文本模态的表征质量。其次,在多模态联合训练过程中,不同模态的信息量和噪声水平并不一致,可能增加跨模态对齐和联合优化的难度,从而影响模型训练的稳定性 and 最终性能。

针对上述问题,本章提出了一种基于知识增强与图对齐的多模态分子性质预测框架 (Knowledge-enhanced Graph Anchor Multimodal Alignme

nt, KGAMA) 。该框架联合建模分子图、序列、指纹和自然语言文本四种模态信息。在数据构建阶段,本文利用大语言模型对原始文本进行清洗与重写,并结合RDKit计算得到的定量理化属性,对文本内容进行补充和约束,以提高文本模态的可用性。在多模态对齐阶段,本文采用以分子图为中心的对比学习策略,并引入基于同方差不确定性的自适应加权机制,以减轻不同模态噪声差异对联合训练的影响。通过上述设计,本文希望提升模型在下游分子性质预测任务中的综合表现。

4.基于多模态学习的药物分子性质预测研究_第4部分

总字数：10,720

文字重复率：11.7% （1,253）

序号	相似文献来源	重复率	是否引证
1	面向分子性质预测的多粒度对比学习模型研究 杨瑞玲 - 《西安电子科技大学硕士论文》 - 2024	1.1%	否
2	基于多视图学习的分子性质预测算法研究 郑妍 - 《电子科技大学硕士论文》 - 2025	1.0%	否
3	基于深度学习和多维度编码分子信息的分子属性预测研究 王晨斌 - 《兰州大学硕士论文》 - 2023	1.0%	否
4	长尾分布下的深度学习图像分类算法研究 王伟秋 - 《北京邮电大学博士论文》 - 2024	0.7%	否
5	基于图卷积网络的舆情演化预测方法研究 文雅 - 《四川大学硕士论文》 - 2023	0.6%	否
6	基于对比学习的深度多视图聚类算法研究 吴嵩 - 《电子科技大学硕士论文》 - 2025	0.6%	否
7	血清外泌体中游离DNA在精神分裂症早期诊断中的价值研究 白玉龙 - 《内蒙古民族大学硕士论文》 - 2025	0.5%	否
8	管道杂散电流和烟草图像定级和OCT视网膜和管道风险评价和位感条纹和转轴 - 《高校学位库》 - 2021	0.5%	否
9	基于理化启发与多级结构感知的分子性质预测方法研究 关锴 - 《山东师范大学硕士论文》 - 2025	0.4%	否
10	zhang - 《高校学位库》 - 2020	0.4%	否
11	面向自然语言处理模型的隐私推理攻击方法研究 曾栢芮 - 《重庆大学硕士论文》 - 2024	0.3%	否
12	融合空间信息的有机分子表征方法研究 鲍瑞琪 - 《南京师范大学硕士论文》 - 2022	0.3%	否
13	“十五五”时期我国经济发展面临的内外部环境对策建议 张晓兰;许芷浩; - 《宏观经济管理》 - 2025	0.3%	否
14	SN-38纳米晶体混悬液的制备及其体内外评价 陈敏 - 《锦州医科大学硕士论文》 - 2017	0.3%	否
15	基于核函数的分类模型及其快速训练方法研究 刘思懿 - 《重庆大学硕士论文》 - 2023	0.3%	否
16	基于意图槽位联合识别的小麦病虫害问答系统的研究 黄梦楠 - 《南京农业大学硕士论文》 - 2022	0.3%	否
17	基于深度学习的电商平台用户评论情感分析 - 《高校学位库》 - 2021	0.3%	否
18	4ac7d6b1a50d4dbcb8109eb85bcbff7c - 《高校学位库》 - 2019	0.3%	否
19	小样本目标检测研究综述 史燕燕;史殿习;乔子腾;张轶;刘洋洋;杨绍武; - 《计算机学报》 - 2023	0.2%	否
20	基于知识图谱的意图识别研究及其在医疗健康问答系统中的应用 彭杰 - 《内蒙古大学硕士论文》 - 2024	0.2%	否
21	基于弱监督多任务学习的方面级情感分析方法研究 - 《高校学位库》 - 2022	0.2%	否

序号	相似文献来源	重复率	是否引证
22	基于MiniGUI的嵌入式媒体播放器的设计与实现 陈运虎;韦冰;-《科技信息(学术研究)》-2007	0.2%	否
23	微硬盘自动装配站的设计与仿真 田风雷-《华中科技大学硕士论文》-2006	0.2%	否
24	面向少样本场景的事件抽取算法研究 冯琳慧-《国防科技大学硕士论文》-2022	0.2%	否
25	多模态在线评论有用性评估方法研究 王璐-《北京邮电大学硕士论文》-2024	0.2%	否
26	基于Transformer-CNN混合架构的跨模态融合抓取检测 王勇;李邑灵;苗夺谦;安春艳;袁鑫林;-《控制与决策》-2024	0.2%	否
27	基于多模态表征学习的分子性质预测研究 张茹-《南宁师范大学硕士论文》-2024	0.2%	否
28	基于深度学习的药物-药物相互作用响应预测 贾模源-《天津科技大学硕士论文》-2024	0.2%	否
29	基于变换神经网络的小分子药物化学结构识别方法研究 薛梓佳-《西华大学硕士论文》-2024	0.2%	否
30	基于视觉理解的视觉文本多模态研究及应用 黄至铖-《北京科技大学博士论文》-2024	0.2%	否
31	基于多模态自适应融合的位姿估计方法研究 朱家奇-《天津理工大学博士论文》-2025	0.2%	否
32	负载均衡策略在邮政数据处理中的应用研究 李冬月-《沈阳工业大学硕士论文》-2024	0.2%	否
33	基于分子图嵌入空间搜索的虚拟筛选方法 丁玉莹-《河北师范大学硕士论文》-2025	0.2%	否
34	基于多模态数据的药物性质预测与分析应用 滕赛赛-《山东大学硕士论文》-2023	0.2%	否
35	诱导多能干细胞技术在药物研发领域中的前景 吴升星;李艳;张海燕;刘洋;赖琼;杨明;-《中国生物工程杂志》-2017	0.2%	否
36	新骨架hDHODH抑制剂的发现、结构优化及生物活性研究 周霞-《四川大学博士论文》-2023	0.2%	否
37	Materials Studio官方教程：Forcite——溶剂化自由能的计算【1】 -《互联网资源》-2022	0.2%	否
38	金属氯化物催化半纤维素制备化学品及机理研究 朱若楠-《北京林业大学博士论文》-2022	0.2%	否
39	基于随机配置和结构增量学习的模糊神经网络建模 周伟-《大连理工大学博士论文》-2024	0.2%	否
40	基于多模态大语言模型的遥感目标检测：以图像分类为例 郭东艳;马丽丽;金贤咏;-《北京测绘》-2025	0.2%	否
41	Swin-Unet在坝面混凝土裂缝自动标注与分割方法的研究 杨汉龙;陈锦剑;潘越;-《水力发电学报》-2024	0.2%	否
42	基于双网络生成对抗机制的机器人模仿学习方法研究 袁佳欣-《兰州大学硕士论文》-2025	0.2%	否
43	前景物体驱动的图像合成与视频生成方法研究 李亚子-《哈尔滨工业大学硕士论文》-2025	0.2%	否
44	基于多通道Inception-V3技术构建颞叶癫痫伴海马硬化智能化诊断及手术疗效预.. 卓小煌-《四川大学博士论文》-2023	0.2%	否
45	俯身呼吸困难与心力衰竭的相关性及诊断价值分析 贾沁洁;刘德敏;王倩;耿雪;刘阔;崔炜;-《中国心血管杂志》-2025	0.2%	否

序号	相似文献来源	重复率	是否引证
46	基于影像组学和深度学习算法的人工智能模型在婴儿良性肝脏肿瘤鉴别诊断中... 杨雨菡 - 《四川大学博士论文》 - 2023	0.2%	否
47	面向开放医学场景的影像高效表征与分析方法研究 张思琦 - 《北京邮电大学博士论文》 - 2025	0.2%	否
48	具有多重网格架构的傅里叶神经算子 郭梓灏 - 《电子科技大学硕士论文》 - 2025	0.2%	否
49	基于改进U2MOT的无人机遥感多目标跟踪 刘天若;刘志远;朱福珍;巫红; - 《黑龙江大学自然科学学报》 - 2025	0.2%	否
50	基于图卷积神经网络的分子性质预测及不确定性分析 胡继敏 - 《兰州交通大学硕士论文》 - 2021	0.2%	否
51	基于门控图神经网络的文本分类算法研究 姚成杰 - 《南京邮电大学硕士论文》 - 2022	0.2%	否
52	基于三维图神经网络的分子性质预测研究 杨笑听 - 《中国科学技术大学硕士论文》 - 2023	0.2%	否
53	面向药物发现的分子表征方法与应用研究 赵彦彭 - 《军事科学院博士论文》 - 2024	0.2%	否
54	面向跨模态分子设计的合成数据构建与应用研究 陈雨晗 - 《哈尔滨工业大学硕士论文》 - 2024	0.2%	否
55	基于熵值-TOPSIS构权法和集成学习的金融文本情感分类研究 魏运佳 - 《天津财经大学硕士论文》 - 2023	0.2%	否
56	基于BERT的藏文预训练语言模型研究与应用 张江燕 - 《西藏大学硕士论文》 - 2023	0.2%	否
57	百度计算生物研究登上Nature子刊：将3D结构引入分子表征，结果超越斯坦福M... - 《互联网资源》 - 2022	0.2%	否
58	DF-RAG:基于查询重写和知识选择的检索增强生成方法 张浩然;郝文宁;靳大尉;程恺;翟颖; - 《计算机科学》 - 2025	0.2%	否
59	基于遥感图像道路提取的全局指导多特征融合网络 宦海;盛宇;顾晨曦; - 《浙江大学学报(工学版)》 - 2024	0.2%	否
60	全局形状关系约束的点云三维目标检测方法 鲜世洋;李宗民;公绪超;徐畅;张鹏;王文超;白云;戎光彩; - 《计算机工程与应用》 - 2024	0.2%	否
61	基于多模态时空特征的运动视频行为识别研究 王章航 - 《四川师范大学硕士论文》 - 2025	0.1%	否
62	基于注意力机制的机械臂织物折叠研究 李文博 - 《武汉纺织大学硕士论文》 - 2025	0.1%	否
63	基于分子图预训练的分子性质预测算法研究 滑紫旭 - 《浙江大学硕士论文》 - 2023	0.1%	否
64	基于SOA的安全技术智能集成研究 谯宇 - 《电子科技大学硕士论文》 - 2011	0.1%	否
65	基于图对比学习的分子属性预测研究 靳艳春 - 《西安石油大学硕士论文》 - 2025	0.1%	否
66	牙周炎与阿尔茨海默病双向关系研究 沈慧;宋忠臣; - 《口腔医学》 - 2020	0.1%	否
67	药物吸收与代谢的理论化学研究 胡桂香 - 《浙江大学博士论文》 - 2003	0.1%	否
68	双苯氟嗪—苯甲酸共晶的研究 杨欢 - 《河北医科大学硕士论文》 - 2013	0.1%	否

序号	相似文献来源	重复率	是否引证
69	药物共晶的制备与分析研究 毛会林 - 《天津大学硕士论文》 - 2009	0.1%	否
70	选择性集成模型及其在糖尿病预测中的应用 - 《高校学位库》 - 2019	0.1%	否
71	面向印刷包装领域的大模型微调技术研究 李小超;姜丹;张寒;肖克晶;闵瑞;曹少中; - 《印刷与数字媒体技术研究》 - 2025	0.1%	否
72	腾讯音乐多模态音乐匹配技术与应用 - 《互联网资源》 -	0.1%	否
73	基于多任务学习的果蔬农药残留光谱检测技术研究 卢亚楠 - 《南京林业大学硕士论文》 - 2025	0.1%	否
74	a1dc967e9c5d49eda3902ae2affe0f4f - 《高校学位库》 - 2021	0.1%	否
75	育婴室监控系统设计及其FPGA实现 - 《高校学位库》 - 2022	0.1%	否
76	融合动态时序与静态空间信息的字体生成方法 袁艺扬 - 《江西师范大学硕士论文》 - 2025	0.1%	否
77	基于多模态表示和提示语微调的分子性质预测 赵卓然 - 《重庆大学硕士论文》 - 2024	0.1%	否
78	ChatGPT聚焦临床医学教育管理研究热点的可行性与伦理考量 曾嘉霖;苏萍;黄昉菀; - 《中国医学伦理学》 - 2024	0.1%	否
79	基于分子图像的化合物-蛋白质相互作用预测 俞琳荟 - 《湖南大学硕士论文》 - 2022	0.1%	否

原文内容

模型设计与描述

KGAMA框架概述

本章节提出了一个以分子的图结构为核心、结合多模态知识增强的分子性质预测架构,该框架旨在充分利用分子的图结构、SMILES序列、分子指纹和文本描述中的互补信息,学习更加完整的分子表述。**模型采用采用预训练-微调范式,在预训练阶段**,引入以分子图为中心的对比学习策略,使各个模态在潜在空间内完成语义对齐;在下游微调阶段,进一步结合交叉注意力模块与多层感知机,对与具体任务相关的特征进行融合和预测。

该模型的详细**架构如图4-1所示,其总体结构主要由三部分组成**:多模态专属编码器:用于提取分子图、序列、指纹和文本等特征信息;表示映射模块:用于各个模态的维度对齐;**融合与预测模块:用于模态间的特征交互**,并输出最终的预测结果。

图4-1 KGAMA模型架构

图编码器

图编码器构成了本框架的语义核心。本文使用Graphormer架构,旨在从拓扑连接与几何空间两个维度对分子图进行深度解构。区别于传统神经网络受限于局部感受野的缺陷,Graphormer引入了三位一体的编码策略:中心性编码用于量化原子的节点重要性,空间编码负责记录原子间的最短路径距离,而边缘编码则精确描述化学键类型。经由多层 Graphormer Layer 的迭代处理,模型输出具备高度结构保真度的图表征向量,该向量在预训练阶段充当了其他模态对齐的语义锚点。

指纹编码器

分子指纹作为一种将分子局部子结构转化为二进制代码的数字化表征手段,其核心机制在于依据既定规则判定分子特定结构是否存在,如表4-1所示。基于编码策略之差异,现有指纹技术主要涵盖AtomPairs、MACCS及Morgan三类。表4-1详尽列示了各指纹所能承载的信息维度。

表4-1 三种典型**分子指纹特征的比较分析**

指纹类型	结构信息	功能信息	拓扑信息
AtomPairs	√	√	
MACCS	√	√	
Morgan	√	√	

AtomPairs指纹侧重于提取分子内全部非氢原子对的拓扑特征,该方法依照原子类型及原子间最短路径距离实施编码,进而有效捕捉分子内部空间关联与结构属性,尤为适宜表征分散官能团与整体构型间之关系。MACCS指纹则建立于166个结构密钥基础之上形成二进制序列,每一密钥均指向特定分子子结构或化学特性;若分子具备密钥定义之结构,对应位赋值为1,反之则置0。本研究中,Morgan算法参数设定为半径2,比特数2048。

前述三种指纹凭借相异编码策略,实现了对分子结构信息的多维覆盖,有效规避了单一类型之局限。综合利用三者有助于构建更为精细的分子特征图谱,赋予模型训练强劲输入支撑。实验将三种指纹拼接并导入分子指纹编码器,借助包含激活函数的多层感知机(MLP)习得非线性映射关系,将其投影至统一向量空间。具体运算流程如下:

其中代表AtomPairs指纹,指代MACCS指纹,**为Morgan指纹;表示ReLU激活函数,与分别对应权重矩阵及偏置向量。**

序列编码器

SMILES字符串虽以线性文本形式存在,其本质却蕴含着复杂的化学拓扑逻辑与层次化结构。鉴于此,本文摒弃了传统的循环神经网络(RNN)方案,转而采用RoBERTa变体Transformer架构作为序列特征提取引擎。相较于RNN易受梯度消失困扰的固有缺陷,该架构凭借全局自注意力机制,具备跨越线性序列距离、直接锁定远端原子关联的能力。输入流处理:原始SMILES序列经由分词器离散化为Token流后,于序列首部植入全局表征符[CLS],以此作为整个分子序列信息的聚合锚点。长程依赖建模:如图4-1所示,借助多头注意力层,模型能够穿透线性的字符间隔,精准捕捉支链末端或大环闭合点间的空间语义一致性。特征投影:最终层输出的[CLS]隐状态向量被提取为序列全局表征,随后经由全连接层映射至与图特征等维的语义空间,为后续的跨模态对齐奠定维度基础。

文本编码器

该模块实现了本文核心创新点之一:知识增强重写。针对原始数据库文本可能存在的噪声干扰与信息冗余,本文设计了如下处理链路:

1. 知识注入:利用PubChem API获取原始描述,并融合由RDKit计算得出的11项关键理化指标,如LogP、TPSA等。

2. 知识重写:利用大语言模型充当领域专家,将量化的理化数值与定性的文本描述有机融合,生成逻辑严密、去噪后的高质量文本。
3. 语义编码:重写后的文本被送入预训练SciBERT编码器。得益于其在海量科学文献上的预训练先验,SciBERT能够敏锐捕捉分子描述中的专业术语语义,最终输出高密度的文本特征向量。

具体的构建流程见实验设计预训练数据章节。

融合与预测

在下游任务微调阶段,模型**通过交叉注意力机制实现多模态信息的自适应融合**。动态加权融合机制允许模型根据不同性质预测任务的需求,自主学习不同模态特征的重要性权重。性质预测:融合后的全景分子表征被输入至由多层全连接网络构成的预测头 (MLP Head) ,最终输出分子的理化性质或生物活性预测值。

实验设计

预训练数据

为了缓解现有分子文本数据集中存在的描述稀疏、噪声干扰大以及缺乏定量理化信息的问题,本文设计了一套包含数据清洗、知识检索、属性计算和文本重写的预训练数据构建流程。该流程旨在构建一个结构规范、文本信息较为完整的分子-文本描述配对样本,并进一步使用RDKit工具生成其他模态数据,用于预训练流程。整体流程如下:

第一步,分子结构获取与标准化。

本文选取PubChem数据库作为原始数据来源,随机抽取了约30万个小分子SMILES序列。考虑到原始数据中存在书写不规范、重复分子及异常样本等问题,本文首先使用RDKit工具包对所有SMILES进行了规范化处理,随后删除了重复项等无法通过RDKit解析的异常分子,并基于分子的唯一标识符InChIKey去除重复样本以及与下游数据集重叠的分子。经过严格筛选,最终保留了约22万个独立分子,构成了预训练数据集的基础集合。

第二步,原始文本检索与解析

针对筛选出的分子,本文利用PubChem提供的PUG View API接口进行批量检索,主要提取“Names and Identifiers”及“Record Description”字段中的文本内容。该部分数据通常包含分子的通用名称、药理作用机制及历史背景等专家知识。然而,直接将API检索的原始文本用于训练存在两类明显的问题。其一,部分文本包含大量与分子构效关系无关的历史背景、专利编号和来源标记,文本冗余较高;其二,分文本由不同来源的片段直接拼接而成,存在术语不一致、关键信息分散和描述稀疏等现象。上述问题会削弱文本模态在对比学习中的表征质量,因此需要进一步进行去噪与重写主要集中在以下两个方面:

第三步,理化属性计算与上下文补充

为了弥补文本模态在定量信息上的缺失,本文利用RDKit计算了每个分子的11项关键理化性质,具体的理化性质见表4-2。这些理化属性随后被组织为结构化上下文,与原始描述共同作为文本重写阶段的输入,从而增强文本对分子结构—性质关系的表达能力。

表4-2 分子理化性质指标及其含义

属性名称 英文标识 含义描述

平均分子量 MolWt 分子的平均相对质量

精确分子量 ExactMolWt 基于同位素质量计算的精确分子质量

脂水分配系数 LogP 衡量分子亲脂性的关键参数

拓扑极性表面积 TPSA 分子表面极性原子的总面积重原子数 Heavy_Atoms 分子中非氢原子的总数量

氢键供体数 H_Bond_Donors 分子中能提供质子的基团数量

氢键受体数 H_Bond_Acceptors 分子中能接受质子的原子数量

可旋转键数 Rotatable_Bonds 单键旋转自由度的度量

环数量 Ring_Count 分子中环状结构的总数

芳香环数量 Aromatic_Rings 具有芳香性的环结构数量

手性中心数 Stereocenters 分子中立体异构中心的数量

第四步,基于大模型的知识重写。

在获得原始描述和理化属性后,本文引入大语言模型对文本进行清洗与重写。重写的目的是保留与分子性质相关的核心语义,同时去除无关噪声,并将理化属性自然融入文本描述中。为提高重写文本的质量,本文在提示词设计中遵循以下三个原则:

- (1) 角色约束:限定模型以药物化学领域的专家,进行生成文本;
- (2) 上下文约束:要求模型同时参考原始描述与理化属性信息;
- (3) 负向约束:明确过滤专利号、历史轶事和商业名称等冗余内容,并约定字数。

经过重写后,得到的文本在内容上更加紧凑,也更有利于后续跨模态对齐。

第五步,多模态样本构建

在完成结构筛选和文本重写后,本文进一步基于标准化后的SMILES生成分子的二维拓扑图和分子指纹,并与序列和文本共同组成图、序列、指纹、文本四种模态输入。**最终,本文构建了一个包含约22万个样本的多模态预训练数据集,为后续模型训练提供了数据支持。**如图4-2展示了原始检索文本与重写文本的示例对比。

图4-2 药物分子原始检索文本与重写文本的对比示例

下游数据集

为评估本文预训练模型在下游分子性质预测任务中的泛化能力和迁移能力,本文选取了MoleculeNet [33] **数据集中9个具有代表性的数据集**进行效果评估。MoleculeNet由Wu等于2018年提出,通过提供统一的数据划分策略、评价指标及实验协议,解决了过往研究中因基准不一致导致模型性能难以横向比较的问题。本文选用的数据集涵盖了生物物理学、生理学及物理化学等多个领域,包含6个分类任务与3个回归任务。具体的数据集统计信息及划分方式如表4-3所示。

表4-3 MoleculeNet数据集基本信息

数据集 任务类型 分子数 种类 评价指标 划分方式

BACE 分类 1513 生物物理学 AUC 骨架划分

BBBP 分类 2050 生理学 AUC 骨架划分

ClinTox 分类 1484 生理学 AUC 骨架划分

Tox21 分类 7831 生理学 AUC 骨架划分

ToxCast 分类 8597 生理学 AUC 骨架划分

Sider 分类 1427 生理学 AUC 骨架划分

FreeSolv 回归 642 物理化学 RMSE 骨架划分

ESOL 回归 1128 物理化学 RMSE 骨架划分

Lipo 回归 4200 物理化学 RMSE 骨架划分BACE:判断分子是否为β-分泌酶1的抑制剂——BACE1过度激活会导致大脑中异常淀粉样蛋白沉积,是**阿尔茨海默病的关键致病因素**,该任务用于筛选潜在的抗阿尔茨海默病药物。

BBBP:判断分子能否穿透血脑屏障——血脑屏障是中枢神经系统的保护屏障,若开发**治疗阿尔茨海默病、帕金森病等脑部疾病的药物**,需要分子具备穿透该屏障的能力。

ClinTox:判断分子在临床实验阶段是否存在毒性,如**肝毒性、心脏毒性——临床阶段是药物研发的关键环节**,该任务可筛选出临床风险低的分子,降低研发失败率。

Tox21:判断分子对21种毒性相关生物靶点的活——这些靶点与细胞毒性、遗传毒性等密切相关,该任务可全面评估分子的多维度毒性,是药物安全性评估的核心任务之一。ToxCast:判断分子是否具有致癌性、致突变性等长期毒性——长期毒性是药物上市前的重要评估指标,该任务可提前识别分子的潜在长期风险。

SIDER:判断分子是否具有已知的副作用——SIDER 数据库收录了药物已报道的副作用信息,该任务可提前评估分子的安全性风险,避免后续临床实验中因严重副作用终止研发。

ESOL:预测分子的水溶性——水溶性直接影响药物的口服吸收、生物利用度,水溶性过低的药物可能无法被人体有效吸收,该任务可指导优化分子结构以提升水溶性。

FreeSolv:预测分子在水中的溶剂化自由能——溶剂化自由能反映分子与水的相互作用强度,与药物的溶解度、稳定性密切相关,该任务为分子的溶剂选择、剂型设计提供依据。

Lipo:预测分子的脂溶性——脂溶性影响药物的跨膜吸收、组织分布,脂溶性过高或过低都会影响药效,该任务可优化分子的脂溶性以平衡吸收与分布。

如图4-3所示,本文对6个分类数据集和3个回归数据集进行了可视化展示。分类任务通过柱状图展示已标注样本的正负类别分布,结果表明不同数据集的类别平衡性差异明显:BACE和Sider相对均衡,而Tox21、ClinTox、ToxCast以及BBBP存在不同程度的类别不平衡。回归任务通过直方图和密度曲线展示标签值分布,结果显示FreeSolv、ESOL和Lipo在取值范围、集中区域及分布形态上均存在显著差异。对于多任务数据集,缺失标签仅表示该任务未标注,因此未作为独立类别参与可视化统计。

图4-3 各数据集标签分布的可视化结果实验设置

实验环境

本文实验均在Linux操作系统上进行实验,各个类别的详细信息如图所示。

表4-4 实验软硬件环境配置详情

类别	组件/库	版本/规格
系统	OS	Ubuntu 24.04.1 LTS
	CUDA	12.2
硬件	GPU	NVIDIA GeForce RTX 4090 (24GB)
	CPU	Intel Core i7-12700KF
	RAM	64G
软件	Python	3.10.19
	PyTorch	2.4.1+cu121
	Geometric	2.7.0
	RDKit	2025.9.3
参数设置		

预训练参数设置:优化器:采用AdamW优化器,以解耦权重衰减 (Weight Decay) 策略提升模型泛化性,权重衰减系数设为。学习率调度:采用带有线性预热的余弦退火策略。初始学习率设为,预热步数占总步数的6%,随后逐渐衰减至。为了保证对比学习中负样本的数量充足,将批次大小设为256。模型共训练100个Epoch,并在验证集loss不再下降时实施早停。对比损失参数:基于参数敏感性实验结果,NT-Xent损失函数中的温度系数固定为0.1。自适应加权损失中的可学习噪声参数初始化为1.0,并随训练过程自动更新。模型架构参数:Graphormer 编码器包含6层 Transformer 层,隐藏层维度设为256,多头注意力头数设为8。

微调参数设置:在下游任务阶段,将预训练好的KGAMA编码器迁移至MoleculeNet的9个基准数据集上。为了适应不同规模的数据集,微调策略进行了如下调整:为了保留预训练特征的先验知识,微调阶段采用较小的学习率,设定为。批次大小设为32,以适应小样本数据的梯度更新频率。在预测头中引入Dropout层,丢弃率设为0.1,以防止在小数据集上过拟合。训练周期为100个Epoch,同样配合早停机制,Patience参数设置为5。

评价指标

本研究根据具体任务特性的不同,实施了差异化的效能评测策略。针对分类问题,模型对类别的区分效能主要依赖受试者工作特征曲线下面积 (AUROC) 进行考量。AUROC能够量化模型在真假阳性率权衡过程中的表现,其得分位于0.5到1的闭区间内,分数越高象征着模型拥有更优异的判别力。而在回归分析中,核心关注点转向均方根误差 (RMSE),该指标用于刻画预测精度。通过对预测值与实测值之差进行平方、取均值后再开方,RMSE实现了对误差的标准化度量,具体公式如所示;由于其单位与目标变量保持一致,较小的RMSE值直接映射出模型预测结果与真实数据之间极高的匹配吻合度。

损失函数

在将分子的多模态特征映射到同一的向量空间之后,模型的核心任务是通过对比学习来实现跨模态的语义对齐。本文设计了一种改进的以图为中心的双向NT-Xent对比损失,并引入基于同方差不确定性的自适应加权机制,以实现多任务场景下的稳健优化。

对比学习通过在表征空间中拉近正样本对、推远负样本对来学习具有判别性的特征表示。目前最主流的目标函数是归一化温度缩放交叉熵损失 (Normalized Temperature-scaled Cross Entropy Loss, NT-Xent)。对于给定的样本对 (i, j),其标准的NT-Xent损失定义如下:

其中,,为归一化后的特征向量,表示余弦相似度,为温度系数,为批次大小,分母项包含了批次内所有的负样本。然而,经典的NT-Xent通常基于双视图设定,如CLIP中的图像-文本。当扩展至本文的四模态场景 (Graph, SMILES, Fingerprint, Text) 时,若采用全排列的两两对齐策略,将面临计算开销随模态数量呈平方级增长,噪声传播与训练不稳定性等问题。在分子表征学习中,分子图直接刻画了原子间的连接拓扑,被认为是最具物理真实性和结构稳定性的模态;相比之下,SMILES序列、分子指纹及文本描述可视作该核心结构的辅助视图。

基于此,本文采用Graph-centered对齐范式:仅计算分子图与其辅模态间的对齐损失,而不进行辅模态间的冗余对齐。设第个分子样本在模态下的表示为,Graph模态表示为。为了确保对齐的对称性,本文定义双向对比损失为:

其中,从Graph到模态的单向对比损失定义为:

在联合优化三个对齐任务时,由于各模态的信息熵与噪声水平存在显著差异,采用静态等权重加权 (如) 往往难以达到最优收敛状态。特别是文本描述模态,由于LLM生成的自然语言具有更强的语义抽象性,其损失函数的量级与梯度方向可能与其他模态产生剧烈冲突。为此,本文借鉴同方差不确定性理论,通过为每个对齐任务引入可学习的噪声参数,构建自适应加权损失函数:

其中,为动态权重,当某一模态对齐任务表现出较高的不确定性或存在较大噪声时,模型会自动增大以降低该任务对总梯度的贡献。

正则化约束:项作为正则化因子,防止无限增大导致权重坍塌,使模型在降低噪声影响与维持任务增益之间寻找一个平衡。

通过这种方式,模型能够在预训练过程中自主识别各模态的可靠性,优先学习确定性较强的结构关联,例如图模态和SMILES模态,并平滑处理复杂语义对齐,例如图模态和文本模态,从而显著提升了多模态表征的稳健性与收敛效率。

对比模型

Mol2Vec [34]:受NLP中的Word2Vec启发,该方法将分子结构拆分为若干子结构并将其视为词语。通过在大量分子数据上运行Skip-gram算法进行无监督训练,学习子结构的向量表示,最终通过聚合这些向量获得分子的整体表示。

N-Gram [35]:一种基于分子拓扑特征的方法,将分子表示为由连续个化学键组成的路径集合。它不需要预先定义复杂的化学特征,具有良好的通用性和灵活性,能够从结构角度有效刻画分子的局部环境。

GIN [36]:一种极具表达能力的图深度学习模型。其理论基础在于能够达到Weisfeiler-Lehman图同构测试的辨别能力上限,通过对节点及其邻居特征的强有力聚合,有效区分不同的分子图结构。

AttentiveFP [30]:是一种引入注意力机制的图神经网络模型。该方法通过注意力权重动态调整邻居节点在信息聚合过程中的重要性,使模型能够自动关注对分子性质预测更为关键的原子和化学键,从而提升模型的表达能力和预测性能。

MPNN [37]:一种通用的框架,核心在于将化学键 (边) 的信息纳入节点表示学习的过程中,通过多轮信息传递更新原子特征。

DMPNN [38]:MPNN的改进版本。它采用了定向信息传递机制,防止信息在传递过程中出现“回流”现象。同时结合了动态池化机制,根据具体任务自适应地聚合关键特征。

CMPNN [39]:这是对传统消息传递神经网络MPNN的重要改进。它通过在原子和化学键之间引入显式的“通信”机制,增强了模型对局部和全局信息的捕捉能力。

GROVER [40]:目前的先进模型之一。它结合了图卷积网络和Transformer的自注意力机制,能够同时提取分子的结构特征和属性特征。通过大规模梯度累积策略和精心设计的自监督任务,在大规模数据集上展现了极强的特征提取能力。

SchNet [41]:专门面向量子化学建模的深度学习方法。不同于传统的二维图模型,SchNet重点建模原子的三维空间位置。它通过连续滤波卷

积作用于原子间的欧几里得距离,从而**模拟分子的电子结构和量子动力学**相互作用,无需人工设计特征即可自动学习分子的电子特性。

GraphMVP [42] :一种先进的**图自监督学习模型,旨在通过对分子的2D拓扑图和3D几何构象进行多视图对齐来学习表征**。它通过对比学习拉近同一分子的二维和三维表示,使模型具备对分子空间构象的感知能力。

MoleculeSTM [43] :**这是一种基于语言模型的多模态分子预训练框架**。它利用化学文本描述与分子结构之间的配对关系进行预训练,旨在将分子的化学结构映射至与其语义功能一致的向量空间。

MoMu [44] :该模型专注于跨模态的图-文本对齐学习。它通过构建大规模的分子图与对应的化学描述文本对,利用对比学习目标函数使模型能够同时从视觉(图结构)和语义(文本)两个维度理解分子性质。

KV-PLM [45] :**一种知识增强的预训练语言模型**。它尝试在预训练过程中显式注入分子的理化性质知识或专家规则,以缩短分子的结构信息与下游性质预测任务之间的语义鸿沟。

实验及结果分析

对比实验

针对**MoleculeNet涵盖的9个分子性质预测基准数据集**,本研究开展了多维度的系统性评估。在数据处理层面,全部遵循MoleculeNet推荐的标准化合协议,即采用骨架分割策略,将样本集**按8:1:1的比例严格划分为训练集、验证集与测试集**,以评估模型在非同源分子结构上的泛化能力。为消除随机性干扰,所有实验均在不同随机种子下重复进行多轮,最终得到各项指标的均值及其标准差。最终结果如表4-5所示。

表4-5 KGAMA在MoleculeNet分类任务上对比实验结果												
Datasets	BACE	BBBP	ClinTox	Tox21	ToxCast	SIDER						
#Molecules	1513	2039	1478	7831	8575	1472						
#Tasks	1	1	2	12	617	27						
AttentiveFP	0.863 (0.150)	0.908 (0.050)	0.933 (0.020)	0.807 (0.021)	0.637 (0.103)	0.605 (0.061)						
Mol2Vec	0.802 (0.008)	0.826 (0.027)	0.750 (0.127)	0.754 (0.101)	0.614 (0.031)	0.592 (0.003)						
GROVER	0.810 (0.044)	0.695 (0.185)	0.762 (0.013)	0.735 (0.027)	0.653 (0.005)	0.614 (0.017)						
GraphMVP	0.812 (0.009)	0.724 (0.016)	0.791 (0.028)	0.759 (0.005)	0.631 (0.114)	0.639 (0.012)						
MPNN	0.815 (0.043)	0.913 (0.042)	0.879 (0.054)	0.808 (0.024)	0.691 (0.018)	0.595 (0.031)						
DMPNN	0.823 (0.038)	0.919 (0.048)	0.897 (0.041)	0.759 (0.034)	0.655 (0.101)	0.570 (0.031)						
CMPNN	0.869 (0.002)	0.927 (0.002)	0.901 (0.012)	0.837 (0.016)	0.709 (0.002)	0.617 (0.003)						
GIN	0.845 (0.021)	0.894 (0.019)	0.869 (0.034)	0.811 (0.002)	0.703 (0.004)	0.591 (0.016)						
SchNet	0.751 (0.033)	0.847 (0.025)	0.717 (0.041)	0.767 (0.023)	0.679 (0.021)	0.545 (0.038)						
N-Gram	0.779 (0.031)	0.912 (0.004)	0.855 (0.013)	0.761 (0.130)	0.659 (0.133)	0.662 (0.009)						
MoleculeSTM	0.808 (0.002)	0.712 (0.019)	0.925 (0.011)	0.769 (0.005)	0.651 (0.014)	0.610 (0.008)						
MoMu	0.767 (0.014)	0.705 (0.020)	0.799 (0.041)	0.756 (0.003)	0.634 (0.011)	0.605 (0.009)						
KV-PLM	0.785 (0.027)	0.731 (0.054)	0.892 (0.073)	0.725 (0.102)	0.550 (0.065)	0.598 (0.056)						
KGAMA	0.872 (0.006)	0.930 (0.002)	0.939 (0.012)	0.841 (0.005)	0.712 (0.011)	0.669 (0.004)						

在BACE与BBBP数据集上,KGAMA模型显著超越了经典的图神经网络模型GIN、AttentiveFP,其中在BACE数据集上分别提高了3.2和1.04个百分点,在BBBP数据集上分别提高了4.03和2.42个百分点。相比于次优的CMPNN模型来说,KGAMA在这两个数据集上均提高了0.3个百分点。这种优势主要是KGAMA使用了Graphormer编码器,其能够对分子全局的拓扑结构进行捕捉,相比于传统的图神经网络能够捕捉更加远程的原子依赖关系。在ClinTox与SIDER等涉及复杂药理毒理机制的数据集上,KGAMA模型相比与MoleculeSTM这种采用文本对齐的模型来说,KGAMA也展现了较为显著的优势,性能分别提高了1.4和5.9个百分点。这个结果证明了本研究设计的知识重写模块的有效性。这也说明了在构建分子文本语义表征时,使用高密度、去噪声的高质量文本,是提升下游预测任务性能的重要条件之一。在Tox21与ToxCast这种包含了数百个子任务的数据集上,KGAMA依然可以保持一定的性能优势,相较于次优模型,最终**在结果上分别提高了0.03和0.04个百分点。这一结果验证了本框架**引入的基于同方差不确定性的自适应加权机制,能够有效平衡不同任务与模态间的噪声,确保了模型在极端复杂场景下的泛化上限。

表4-6 KGAMA在MoleculeNet回归任务上对比实验结果												
Datasets	ESOL	FreeSolv	Lipo									
# Molecules	1128	642	4200									
# Tasks	1	1	1									
AttentiveFP	0.877 (0.060)	2.073 (0.220)	0.721 (0.030)									
Mol2Vec	0.995 (0.032)	2.021 (0.154)	0.803 (0.021)									
GROVER	0.921 (0.087)	2.026 (0.127)	0.676 (0.022)									
GraphMVP	1.029 (0.033)	1.893 (0.063)	0.681 (0.002)									
MPNN	1.167 (0.430)	2.185 (0.952)	0.672 (0.051)									
DMPNN	0.972 (0.097)	2.170 (0.536)	0.662 (0.051)									
CMPNN	0.845 (0.039)	1.833 (0.581)	0.658 (0.029)									
GIN	0.885 (0.051)	1.619 (0.202)	0.659 (0.085)									

5.基于多模态学习的药物分子性质预测研究_第5部分

总字数: 6,625

文字重复率: 9.6% (636)			
序号	相似文献来源	重复率	是否引证
1	基于联邦学习的多中心自闭症识别研究 朱涛 - 《长安大学硕士论文》 - 2024	0.5%	否
2	面向政务领域的知识图谱辅助增强推荐系统的研究与实现 张彪 - 《内蒙古大学硕士论文》 - 2024	0.2%	否
3	基于果蝇优化算法的特征选择方法研究与应用 侯云 - 《吉林大学硕士论文》 - 2020	0.2%	否
4	基于语义分割和反向注意力的筏式紫菜养殖区提取方法研究 赵衍利 - 《山东科技大学硕士论文》 - 2023	0.2%	否
5	基于对偶学习的蒙汉神经机器翻译系统的实现与优化 孙硕 - 《内蒙古大学硕士论文》 - 2021	0.2%	否
6	基于深度学习的肺部病变识别与诊断研究 张建波 - 《天津理工大学硕士论文》 - 2021	0.2%	否

序号	相似文献来源	重复率	是否引证
7	基于改进BP神经网络的库坝健康风险预测及应用 范梦云 - 《贵州大学硕士论文》 - 2025	0.2%	否
8	11111 - 《高校学位库》 - 2021	0.2%	否
9	面向AD分类的LSTM-GCN的时空特征提取与融合技术研究 李南星 - 《哈尔滨工程大学硕士论文》 - 2024	0.2%	否
10	基于深度学习的微地震震源定位方法研究 崔淋淇 - 《东北石油大学硕士论文》 - 2023	0.2%	否
11	基于生成对抗网络的3D脑影像生成技术研究 赵志勋 - 《哈尔滨工程大学硕士论文》 - 2024	0.2%	否
12	基于困难样本挖掘的音频指纹检索技术研究 范英昊 - 《哈尔滨工业大学硕士论文》 - 2023	0.2%	否
13	非线性超声无损检测技术信号处理方法研究 黄致远 - 《河南工业大学硕士论文》 - 2024	0.2%	否
14	基于图神经网络的云桌面虚拟机调度算法 彭商濂;柳岸; - 《山西大学学报(自然科学版)》 - 2025	0.2%	否
15	融合社交网络高阶结构的信息传播预测研究 陈虹茜 - 《杭州电子科技大学硕士论文》 - 2025	0.2%	否
16	基于图神经网络的流感病毒风险预测研究 沈嘉豪 - 《广州大学硕士论文》 - 2025	0.2%	否
17	基于深度学习的新冠药物-靶标相互作用预测算法研究 高蒙蒙 - 《东南大学硕士论文》 - 2023	0.2%	否
18	基于三维结构表征的蛋白质-配体结合亲和力预测方法研究 李改莉 - 《兰州大学博士论文》 - 2025	0.2%	否
19	基于深度学习的无监督单目图像序列深度估计 高昊昇 - 《东南大学硕士论文》 - 2020	0.2%	否
20	基于生成对抗网络的人脸复原方法研究 张杨 - 《东南大学博士论文》 - 2021	0.2%	否
21	d3dd6193024a4526a7681bce98741ebe - 《高校学位库》 - 2019	0.2%	否
22	基于时频分析的学生多元行为注意力模式挖掘及应用 孙燕 - 《西北师范大学硕士论文》 - 2023	0.1%	否
23	红树林湿地遥感图像目标检测与识别关键技术研究 王鑫 - 《电子科技大学博士论文》 - 2025	0.1%	否
24	改进CNN算法研究及其在夜晚背景下杂草与甜菜识别中的应用 何小飞 - 《江苏大学硕士论文》 - 2020	0.1%	否
25	基于深度学习的故障检测及寿命预测的研究与应用 叶凯 - 《南京航空航天大学硕士论文》 - 2023	0.1%	否
26	陶瓷分散剂失效原位凝固注模成型新工艺研究 干科 - 《清华大学博士论文》 - 2017	0.1%	否
27	基于图对比学习的个性化推荐算法研究 田仁杰 - 《西安石油大学硕士论文》 - 2025	0.1%	否
28	面向教育知识图谱的小样本关系抽取技术研究及应用 张旺 - 《南京邮电大学硕士论文》 - 2023	0.1%	否
29	机器学习预测肺癌骨转移瘤EGFR基因突变及靶向治疗效果 - 《高校学位库》 - 2022	0.1%	否
30	基于多任务学习的果蔬农药残留光谱检测技术研究 卢亚楠 - 《南京林业大学硕士论文》 - 2025	0.1%	否

序号	相似文献来源	重复率	是否引证
31	面向评论文本的跨领域方面级情感分析方法研究 欧阳帆 - 《北京交通大学硕士论文》 - 2024	0.1%	否
32	面向方面情感分析的多属性三元组提取方法研究 刘庚 - 《北京交通大学硕士论文》 - 2024	0.1%	否
33	基于三维神经网络的分子性质预测研究 杨笑听 - 《中国科学技术大学硕士论文》 - 2023	0.1%	否
34	基于时空特征学习的癫痫脑电分析与研究 何佳桐 - 《山东师范大学硕士论文》 - 2023	0.1%	否
35	多目标进化算法及其在约束优化中的研究 - 《高校学位库》 - 2020	0.1%	否
36	图神经网络在文本分类中的应用研究 王治学; - 《电脑知识与技术》 - 2023	0.1%	否
37	基于图结构的中文文本聚类方法研究 刘巧凤 - 《大连理工大学硕士论文》 - 2009	0.1%	否
38	基于深度学习的分子性质预测及机器学习平台 虞正存 - 《浙江大学硕士论文》 - 2024	0.1%	否
39	连续图卷积视频烟雾检测模型 杨龙箴;袁非牛;杨寿渊;雷帮军;张相芬; - 《中国图象图形学报》 - 2019	0.1%	否
40	有机催化四氢异喹啉的直接二氟烷基化反应 梅祖钦 - 《赣南师范大学硕士论文》 - 2021	0.1%	否

原文内容

SchNet 1.045 (0.064) 3.215 (0.355) 0.909 (0.098)
N-Gram 1.074 (0.112) 2.688 (0.251) 0.812 (0.031)
MoleculeSTM - - -
MoMu - - -
KV-PLM 1.124 (0.251) 2.124 (0.429) 0.902 (0.047)
KGAMA 0.831 (0.024) 1.512 (0.233) 0.655 (0.006)

表4-6进一步展示了模型在ESOL、FreeSolv和Lipo三个回归任务上的均方根误差表现,即RMSE数值越低越好。在水溶性预测任务ESOL中,KGAMA取得了0.831的极低误差,显著优于CMPNN的0.845与AttentiveFP的0.877。这表明模型不仅在离散的分类空间中表现优异,在连续的物理化学性质空间中同样具备精准的回归能力。特别是在FreeSolv溶剂化自由能任务上,模型将RMSE降至1.512,相比于次优的基线模型GIN的1.619提升了近6%,充分体现了多模态特征融合在刻画分子能量状态方面的优势。值得注意的是,在Lipo亲脂性数据集上,KGAMA达到了0.655的SOTA水平。结合可视化分析可知,这一优异表现很大程度上源于分子指纹模态的引入。分子的亲脂性与分子中的特定官能团数量呈线性相关,而基于统计计数的指纹特征正好能比较精确捕捉此类信息。

综上所述,无论是面向离散的生物活性分类,还是连续的理化性质回归,KGAMA均凭借其图中心对比学习+多模态知识增强的复合架构,展现出了优异的综合性能。

消融实验

为系统解构不同输入模态及融合机制对模型最终预测能力的边际贡献,本文基于所提出的KGAMA框架,构建了五种递进式的消融变体。所有变体均在统一的实验配置下进行训练与评测,旨在定量分析各模态信息的有效性 & 交叉注意力模块的核心价值。

本文以分子图作为核心语义锚点,逐步引入其他辅助模态,具体变体定义如下:

w/o ALL:基准模型,仅保留图编码器分支,采用Graphormer提取分子拓扑特征,作为下游任务的单一输入源,用于评估纯结构视角的预测基线。

w/o STC:结构增强。在图编码器的基础上引入分子指纹模态,旨在补充图神经网络可能遗漏的全局子结构统计信息。

w/o TC:序列增强,进一步融合SMILES序列模态,利用Transformer捕获分子的线性化学语法与长程依赖。

w/o C:静态融合,采用完整的四模态输入,但通过简单的特征拼接方式进行融合,用于评估多模态信息的原始叠加效应。

KGAMA:完整模型,本文提出的最终形态,即在四模态基础上引入交叉注意力机制,实现特征的动态自适应融合。

表4-7 KGAMA在MoleculeNet 基准组上分类任务消融实验结果

Datasets	BACE	BBBP	ClinTox	Tox21	ToxCast	SIDER
w/o All	0.825 (0.150)	0.898 (0.050)	0.805 (0.020)	0.771 (0.021)	0.695 (0.103)	0.638 (0.061)
w/o STC	0.842 (0.008)	0.912 (0.027)	0.845 (0.127)	0.795 (0.101)	0.701 (0.031)	0.645 (0.003)
w/o TC	0.855 (0.044)	0.915 (0.185)	0.885 (0.013)	0.822 (0.027)	0.706 (0.005)	0.655 (0.017)
w/o C	0.862 (0.009)	0.922 (0.016)	0.915 (0.028)	0.835 (0.005)	0.709 (0.114)	0.661 (0.012)
KGAMA	0.870 (0.043)	0.930 (0.042)	0.939 (0.054)	0.841 (0.024)	0.712 (0.018)	0.669 (0.031)

图4-4 KGAMA在MoleculeNet 基准组上分类任务消融实验结果

五种变体模型在MoleculeNet六个分类数据集的消融实验结果如表4-5、图4-4所示,从整体来看,KGAMA模型在六个数据集上均取得了最优的成绩,这一结果表明了本文提出的各个模块均能够对模型的性能产生积极的作用,且多模态数据的多视角互补使得模型可以在预测任务中取得较好的成绩。进一步来看,随着各个单模块的加入,性能逐步的递增,但是各个模块的贡献程度也存在差异。其中,w/o STC变体由于加入了分子指纹,相比于w/o ALL变体性能得到了显著的提升。其中在ClinTox任务上AUROC从0.805大幅提升至0.845。w/o C是各消融变体模型中最接近完整模型的配置,但在六个数据集上仍全部落后于KGAMA,例如在ClinTox上从0.915提升到0.939,在BBBP上从0.922提升到0.930,在SIDER上从0.661提升到0.669。这进一步说明,即使某些模块单独移除后性能下降相对有限,但与其他模块联合时仍能带来稳定增益。

表4-8 KGAMA在MoleculeNet 基准组上回归任务消融实验结果

Datasets	ESOL	FreeSolv	Lipo
w/o All	2.102 (0.060)	1.521 (0.220)	1.244 (0.030)

w/o STC 1.855 (0.032) 1.476 (0.154) 0.966 (0.021)
w/o TC 1.805 (0.087) 1.226 (0.127) 0.853 (0.022)
w/o C 1.725 (0.033) 1.001 (0.063) 0.789 (0.002)
KGAMA 1.512 (0.024) 0.831 (0.233) 0.656 (0.006)

图4-5 KGAMA在MoleculeNet 基准组上回归任务消融实验结果

为了验证在回归数据集上KGAMA的有效性,本文也在MoleculeNet基准组上的ESOL、FreeSolv和Lipophilicity三个数据集上进行了消融实验。实验结果如表4-6和图4-5所示。从整体来看,KGAMA在三个数据集上均取得了最低的RMSE,分别为1.512、0.831和0.656,高于所有的消融变体模型。随着模块的逐步加入,模型的性能也是逐步的提高,当全部模块被移除的时候,性能最差,如在ESOL数据集上w/o All的RMSE是2.102,相比完整模型的1.512高出0.590。w/o STC相较于完整模型仍存在较明显差距,在ESOL、FreeSolv和Lipo三个数据集上的RMSE分别为1.855、1.476和0.966。这说明移除该模块后,模型对分子性质的连续值建模能力受到明显影响。相比之下,w/o TC的结果有所改善,RMSE分别下降到1.805、1.226和0.853,表明该部分模块的引入在特征表征与信息交互中发挥了重要作用。

对比引入完整四模态输入但采用静态拼接的w/o C与本文提出的完整模型KGAMA,可以清晰观察到交叉注意力机制的决定性作用。在FreeSolv任务上,KGAMA的RMSE从1.725进一步降低至1.512。上述差距说明简单的特征拼接方法本质上默认分子各模态数据对所有任务具有同等重要性,无法有效处理多模态间的语义冲突与信息冗余。相比之下,交叉注意力机制能够根据具体预测任务的性质动态调配模态贡献权重,在ClinTox任务中,该任务对专家文本知识高度依赖,完整模型能够自适应地识别这一特性并给予文本模态更大的权重,从而提取隐含在文本信息中的毒理学因果关联,实现多模态信息的深度协同而非简单叠加。

进一步地,本研究绘制了九个数据集的预测值和实验值之间的相关性散点图,如图4-6所示,可以清楚的看到KGAMA的回归曲线结果比其变体更加接近标准灰色基线,进一步证明了我们架构中各个模块的重要性。

图4-6 KGAMA及其变体散点结果

可视化分析

为了进一步解释不同模态对特定分子性质预测任务的贡献,本文分析了KGAMA模型学习的注意力权重矩阵,如图4-7所示。图中横轴代表不同的分子性质预测任务,纵轴代表四种输入模态,颜色的深浅直观反映了该模态在特定任务中的重要性贡献度,即权重值越大,颜色越深。根据权重图可以得出在物理性质任务中的结构模态起主导效应,具体的说在预测分子的物理化学性质时,模型表现出对拓扑结构的高度依赖。在FreeSolv和ESOL任务中,Graph模态的权重分别高达0.40和0.39,显著高于其他模态。这与化学直觉高度一致。分子的溶解能力和能量状态主要由其分子骨架的拓扑连接及原子间的空间排布决定。本文所使用的Graphormer图神经网络提取的显式结构特征在此类任务中提供了核心的判别依据,起到了语义锚点的作用。值得注意的是,在Lipo任务中,Fingerprint获得了最高的权重0.38,甚至超过了Graph。这是因为亲脂性与分子中特定的疏水/亲水官能团数量呈强线性相关,而基于统计计数的分子指纹恰好擅长捕获此类特征。

另一方面权重图中也体现了知识增强在生物药理任务中的突破,与物理任务形成鲜明对比的是,在涉及复杂生物相互作用的任務中,模型自动学会了依赖专家知识。在Sider、ClinTox和Tox21任务中,文本模态的权重出现了显著跃升,分别为0.38、0.36和0.32。这是因为副作用和毒性往往难以仅从分子结构中直接推断,但通常在文献或专家描述中有明确的记录。此时,经过LLM重写并注入了11项理化性质的文本模态成为了关键的信息源。模型给予文本模态高权重,证明了本研究提出的知识增强策略成功地将非结构化的药理知识转化为了可被模型利用的特征,弥补了单结构视角的盲区。

最后模态权重图体现了序列模态的稳健补充作用,SMILES模态在所有9个任务中的权重分布呈现出高度的稳定性,维持在0.18-0.24的区间内。作为分子的线性化表征,SMILES虽然在某些特定任务上不如Graph直观或Text深刻,但它提供了一种独特的序列视角,能够捕获图网络可能遗漏的长程依赖信息。这种平稳输出的特性使其成为了多模态融合中的稳定器,确保模型在任何任务中都不会因单一模态的缺失或噪声而失效。

图4-7 不同分子模态在各下游任务中的注意力权重分布

参数敏感实验

为了验证模型在不同超参数设置下的鲁棒性,并探究核心的超参数对对比学习性能的影响,本小节选取了对比损失函数中的温度系数进行敏感性实验。实验在ClinTox和BBBP两个代表性数据集上进行,其他训练参数保持不变。温度系数在NT-Xent损失函数中起着调节负样本梯度的关键作用。图4-8展示了模型性能随值的变化曲线,图中展示了五种不同的温度系数,分别是0.05、0.1、0.2、0.5、1.0。从图中可以观察到明显的“倒U型”趋势,具体分析如下:过小的(0.05):当温度系数过小时,Softmax分布变得极度尖锐,模型过度关注少量极其困难的负样本。这虽然能提供强梯度的监督信号,但容易引入潜在的假阴性样本噪声,导致优化过程不稳定,模型性能出现显著下降(ClinToxAUROC降至0.89左右)。过大的(0.5-1.0):随着温度系数增大,分布趋于平滑,模型对不同负样本的区分能力减弱。当时,模型实际上是在同等程度地惩罚所有非匹配样本,失去了挖掘难样本的能力,导致特征空间的判别性降低,性能随之衰减。最优区间(0.1-0.2):实验结果表明,当设定在0.1至0.2之间时,模型取得了最佳的预测性能。在此区间内,模型在挖掘难样本与保持训练稳定性之间达到了平衡,能够学习到既具有区分度又具备泛化能力的分子表征。因此,本研究在所有后续实验中均将默认设置为0.1。

图4-8 温度系数对模型预测性能的影响

本章小结

本章阐述了一种基于图对齐与知识增强的多模态分子性质预测框架。针对该框架联合建模分子图、SMILES序列、分子指纹和自然语言文本四种模态信息,并在文本构建阶段引入知识重写策略,将原始分子专家描述与由RDKit计算得到的理化属性进行融合,以提高文本模态的可用性。在表示学习阶段,本文采用以分子图为中心的对比学习预训练策略,并结合基于同方差不确定性的自适应加权机制,以减轻不同模态噪声差异对联合训练的影响。

为了验证所提方法的有效性,本文在MoleculeNet的9个基准数据集上进行了实验评估。对比实验结果表明,KGAMA在多个分类任务和回归任务上取得了较好的预测结果;消融实验进一步说明了不同输入模态和交叉注意力融合模块对模型性能的贡献;参数敏感性分析则验证了模型在关键超参数设置下具有较稳定的表现。

总体来看,本章提出的KGAMA框架在多模态分子性质预测任务中表现出较好的综合性能,也说明了知识增强与图中心对齐策略在提升分子表征质量方面具有积极作用。

4 基于知识增强与图对齐的分子性质预测方法

中国地质大学(北京)专业硕士学位论文

总结与展望

工作总结

分子性质预测旨在建立分子结构与其理化属性、生化性质的映射关系,是药物发现早期筛选过程中的重要研究内容。近年来,深度学习技术与人工智能技术推动了该方向的发展,但现有方法仍存在一些不足:一方面,单一模态表征难以充分刻画分子的复杂结构信息,传统神经网络在长程依赖建模和原子化学键交互方面也存在一定局限;另一方面,虽然大语言模型和多模态学习为分子性质预测提供了新的思路,但在复杂ADMET任务中,模型的解释能力、文本模态质量以及多模态对齐的稳定性仍有待提升。围绕以上问题,本文从思维链增强的预测建模和知识增强的多模态对齐两个方面开展研究,主要完成了以下两项工作。

第一,出了基于思维链增强与通信式图交互的分子性质预测框架CoT-CMP。针对大模型直接用于分子性质预测推理过程的不透明、神经网络对分子局部结构关系建模不足的问题,本文构建了一个图文双塔预测框架。在文本端,引入LLaMA-3.1大语言模型,并结合LoRA微调 and 思维链提示工程,生成包含结构识别、理化属性分析和性质推断过程的文本表示,以增强模型对预测过程的表达能力。在图结构端,采用通信式消息传递神经网络CMPNN,对原子特征和化学键信息进行联合建模,以提升模型对分子结构关系的表征能力。在此基础上,进一步利用交叉注意力机制实现图特征与文本特征的融合。实验结果表明,CoT-CMP在TDC平台多个ADMET基准数据集上取得了较好的预测结果,消融实验和可视化分析也说明了文本增强、LoRA微调 and 跨模态融合模块在该框架中的有效性。

第二,提出了基于知识增强与图对齐的多模态分子性质预测框架KGAMA。针对公共医学文本中噪声较多、文本有效信息密度低以及多模态对齐过程中可能出现优化不平衡的问题,本文构建了包含分子图、SMILES序列、分子指纹和自然语言文本在内的四模态表征体系。在数据构建方面,设计了面向分子文本的知识重写流程,利用大语言模型对PubChem原始描述进行清洗,并结合RDKit计算得到分子的关键理化指标,对文本内容进行补充和约束,从而提高文本模态的可用性。在表示学习方面,本文采用以分子图为中心的对比学习策略,并引入基于同方差不确定性的自适应加权

机制,以增强不同模态之间对齐的稳定性。实验结果表明,KGAMA在MoleculeNet的9个基准数据集上具有较好的综合表现,相关消融实验进一步验证了知识增强和图中心对齐策略的有效性。

工作展望

尽管本文在多模态分子性质预测方面进行了初步探索,并取得了一定结果,但受限于数据规模、计算资源和模型结构设计的约束,仍有一些问题值得进一步研究。未来可以从以下几个方面继续展开。

(1) 引入三维几何构象信息,提升分子空间结构建模能力。

本文当前的分子表示主要基于一维序列和二维拓扑结构,而分子的许多理化性质和生物活性与其三维构象密切相关。未来可进一步引入原子坐标、键角和二面角等几何信息,并结合SE (3) 等变神经网络或三维分子Transformer等方法,构建融合1D、2D、3D信息的分子表征框架,以增强模型对空间结构特征的刻画能力。

(2) 扩展多模态预训练数据规模,提升模型泛化能力。

本文在KGAMA框架中构建了约22万规模的多模态预训练数据集,验证了知识重写与图中心对齐策略的可行性。但相较于实际药物发现中庞大的化学空间,这一规模仍然有限。未来可在更大范围内构建高质量分子文本配对数据,进一步扩展预训练语料规模,并探索更大规模多模态预训练对下游性质预测任务的促进作用。

5 总结与展望

中国地质大学 (北京) 专业硕士学位论文

参考文献

- Panapitiya, G., Gao, P., Maupin, C.M., et al. FragNet: A Graph Neural Network for Molecular Property Prediction with Four Levels of Inter-reliability [J] . Journal of the American Chemical Society, 2026, 148 (9) : 9930-9950.
- Petersen, K.H., Schmidt, M.N. Design and Evaluation of a Geometric Algebra-Based Graph Neural Network for Molecular Property Prediction [A] . Proceedings of the 7th Northern Lights Deep Learning Conference (NLDL) [C] . PMLR, 2026: 328-344.
- Zhou, R., Zhang, Y., He, K., et al. Add-GNN: A Dual-Representation Fusion Molecular Property Prediction Based on Graph Neural Networks with Additive Attention [J] . Symmetry, Multidisciplinary Digital Publishing Institute, 2025, 17 (6) .
- Ma, H., Bian, Y., Rong, Y., et al. Cross-dependent graph neural networks for molecular property prediction [J] . Bioinformatics, 2022, 38: 2003-2009.
- Li, L., Zhang, Y., Wang, G., et al. Kolmogorov–Arnold graph neural networks for molecular property prediction [J] . Nature Machine Intelligence, Nature Publishing Group, 2025, 7 (8) : 1346-1354.
- Wang, S., Guo, Y., Wang, Y., et al. SMILES-BERT: Large Scale Unsupervised Pre-Training for Molecular Property Prediction [A] . Proceedings of the 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics [C] . New York, NY, USA: Association for Computing Machinery, 2019: 429-436.
- Abdel-Aty, H., Gould, I.R. Large-Scale Distributed Training of Transformers for Chemical Fingerprinting [J] . Journal of Chemical Information and Modeling, American Chemical Society, 2022, 62 (20) : 4852-4862.
- Tang, W., Li, M., Zhan, Y., et al. Adaptively multi-modal contrastive fusion network for molecular properties prediction [J] . Engineering Applications of Artificial Intelligence, 2025, 152: 110782.
- Gao, M., Zhu, F. MMCL: A Multi-modal Contrastive Learning Framework for Molecular Property Prediction [J] . IEEE Transactions on Computational Biology and Bioinformatics, 2026: 1-14.
- Zhang, Y., Liu, W., Zhao, H., et al. MolGramTreeNet: A multimodal molecular property prediction model via grammar tree-constrained molecular representation [J] . iScience, 2026, 29 (3) : 114928.
- Zhou, J., Zhao, Q., Shu, P., et al. GSST: Multimodal Graph-SMILES Fusion with Soft SMILES Tokens for Molecular Property Prediction [J] . IEEE Journal of Biomedical and Health Informatics, 2025: 1-12.
- Rollins, Z.A., Cheng, A.C., Metwally, E. MolPROP: Molecular Property prediction with multimodal language and graph fusion [J] . Journal of Cheminformatics, 2024, 16 (1) : 56.
- Gong, X., Liu, M., Liu, Q., et al. MDFCL: Multimodal data fusion-based graph contrastive learning framework for molecular property prediction [J] . Pattern Recognition, 2025, 163: 111463.
- Liu, S., Nie, W., Wang, C., et al. Multi-modal molecule structure–text model for text-based retrieval and editing [J] . Nature Machine Intelligence, Nature Publishing Group, 2023, 5 (12) : 1447-1457.
- Zhu, Y., Liu, G., Inae, E., et al. MolTextNet: A Two-Million Molecule-Text Dataset for Multimodal Molecular Learning [J] . 2025.
- Wang, Y., Zhang, K., Huang, J., et al. ProtoMol: enhancing molecular property prediction via prototype-guided multimodal learning [J] . Briefings in Bioinformatics, 2025, 26 (6) : bba629.
- TRIDENT: Tri-Modal Molecular Representation Learning with Taxonomic Annotations and Local Correspondence [A] . 2025.
- Li, Y., Liu, C., Gao, X., et al. MolPrompt: improving multi-modal molecular pre-training with knowledge prompts [J] . Bioinformatics, 2025, 41 (9) : btaf466.
- [19] Liu, S., Wang, H., Liu, W., et al. Pre-training Molecular Graph Representation with 3D Geometry [A] . 2021.
- [20] Zhou, G., Gao, Z., Ding, Q., et al. Uni-Mol: A Universal 3D Molecular Representation Learning Framework [A] . 2022.
- [21] Sun, M., Ai, C., Zhang, D., et al. MolInterAct: Multiscale Cross-Modal Interaction for Robust Molecular Representation Learning [A] . 2025 IEEE International Conference on Bioinformatics and Biomedicine (BIBM) [C] . 2025: 1215-1220.
- [22] Lin, J., Wang, G., Li, S., et al. Effective and compact multimodal molecular representation optimization with molecular fragments enhancement [J] . Expert Systems with Applications, 2026, 318: 131997.
- [23] Huang, Q., Li, Y., Zhu, L., et al. Unified multimodal multidomain polymer representation for property prediction [J] . npj Computational Materials, Nature Publishing Group, 2025, 11 (1) : 153.
- [24] Jing, Z., Sun, Y., Li, Y.Y., et al. Structure-Aware Fusion with Progressive Injection for Multimodal Molecular Representation Learning [A] . 2025.
- [25] Li, J., Zhang, Z., Lei, Z., et al. MoLA: Molecular multimodal layerwise adaptive network for molecular property prediction [J] . Knowledge-Based Systems, 2026, 338: 115563.
- [26] Zhou, Z., Li, Y., Hong, P., et al. Multimodal fusion with relational learning for molecular property prediction [J] . Communications Chemistry, Nature Publishing Group, 2025, 8 (1) : 200.
- [27] Priyadarsini, I., Takeda, S., Hamada, L., et al. Learning Resilient Molecular Representations with Dynamic Multi-Modal Fusion [A] . 2025.
- [28] Huang, K., Fu, T., Gao, W., et al. Therapeutics Data Commons: Machine Learning Datasets and Tasks for Drug Discovery and Development [A] . 2021.
- [29] Li, Y., Wan, Y., Liu, X. Semi-supervised Learning with Graph Convolutional Networks Based on Hypergraph [J] . Neural Processing Letters, 2022, 54 (4) : 2629-2644.
- [30] Xiong, Z., Wang, D., Liu, X., et al. Pushing the Boundaries of Molecular Representation for Drug Discovery with the Graph Attention Mechanism [J] . Journal of Medicinal Chemistry, 2020, 63 (16) : 8749-8760.
- [31] Duvenaud, D.K., Maclaurin, D., Iparraguirre, J., et al. Convolutional Networks on Graphs for Learning Molecular Fingerprints [A] . Advances in Neural Information Processing Systems [C] . Curran Associates, Inc., 2015, 28.

- [32] Hirohara, M., Saito, Y., Koda, Y., et al. Convolutional neural network based on SMILES representation of compounds for detecting chemical motif [J] . BMC Bioinformatics, 2018, 19 (19) : 526.
- [33] Wu, Z., Ramsundar, B., Feinberg, E.N., et al. MoleculeNet: a benchmark for molecular machine learning [J] . Chemical Science, The Royal Society of Chemistry, 2018, 9 (2) : 513-530.
- [34] Jaeger, S., Fulle, S., Turk, S. Mol2vec: Unsupervised Machine Learning Approach with Chemical Intuition [J] . Journal of Chemical Information and Modeling, American Chemical Society, 2018, 58 (1) : 27-35.
- [35] Liu, S., Demirel, M.F., Liang, Y. N-Gram Graph: Simple Unsupervised Representation for Graphs, with Applications to Molecules [A] . Advances in Neural Information Processing Systems [C] . Curran Associates, Inc., 2019, 32.
- [36] Xu*, K., Hu*, W., Leskovec, J., et al. How Powerful are Graph Neural Networks? [A] .2018.
- [37] Gilmer, J., Schoenholz, S.S., Riley, P.F., et al. Neural message passing for Quantum chemistry [A] . Proceedings of the 34th International Conference on Machine Learning - Volume 70 [C] . Sydney, NSW, Australia: JMLR.org, 2017: 1263-1272.
- [38] Correction to Analyzing Learned Molecular Representations for Property Prediction [J] . Journal of Chemical Information and Modeling, 2019.
- [39] Song, Y., Zheng, S., Niu, Z., et al. Communicative Representation Learning on Attributed Molecular Graphs [A] .2020, 3: 2831-2838.
- [40] Rong, Y., Bian, Y., Xu, T., et al. Self-Supervised Graph Transformer on Large-Scale Molecular Data [J] . arXiv: Biomolecules, 2020.
- [41] Schütt, K., Kindermans, P.J., Felix, H.E.S., et al. SchNet: A continuous-filter convolutional neural network for modeling quantum interactions [A] .2017.
- [42] Liu, S., Wang, H., Liu, W., et al. Pre-training Molecular Graph Representation with 3D Geometry [J] . ArXiv, 2021.
- [43] Liu, S., Nie, W., Wang, C., et al. Multi-modal molecule structure-text model for text-based retrieval and editing [J] . Nature Machine Intelligence, Nature Publishing Group, 2023, 5 (12) : 1447-1457.
- [44] Su, B., Du, D., Yang, Z., et al. A Molecular Multimodal Foundation Model Associating Molecule Graphs with Natural Language [J] .arXiv, 2022.
- [45] Zeng, Z., Yao, Y., Liu, Z., et al. A deep-learning system bridging molecule structure and biomedical text with comprehension comparable to human professionals [J] . Nature Communications, Nature Publishing Group, 2022, 13 (1) : 862.

说明

- 1.总文字重复率：被检测论文总重复字数占总字数的比例
- 2.去除引用后重复率：去除系统识别为引用的文字后，计算出来的重合字数在总字数中所占的比例
- 3.去除本人已发表后重复率：去除作者本人已发表文字后，计算出来的重合字数在总字数中所占的比例
- 4.报告内指标是PaperXie查重系统根据《PaperXie查重标准及比对数据库界定标准》自动生成的，仅供参考
- 5.红色文字表示文字复制部分;绿色文字表示引用部分;褐色文字表示本人已发表文献复制部分，灰色文字表示不参与检测部分，一般为目录，参考文献等
- 6.PaperXie查重报告验证真伪地址：www.paperxie.cn/verify，认准PaperXie谨防假冒。