



中国地质大学

CHINA UNIVERSITY OF GEOSCIENCES

北京 BEIJING

基于多模态学习的药物分子性质预测研究

姓名：范帅尧

导师：牛云云教授

时间：2026.05.18



目 录

CONTENTS

01 / 研究背景与意义

药物发现早筛需求与多模态分子性质预测价值

02 / 研究现状

单模态、多模态方法进展及其主要不足

03 / 研究内容


CoT-CMP 与 KGAMA 两项核心方法及实验验证

04 / 结论与展望

研究贡献、局限性与未来工作方向



现代创新药物研发流程复杂、周期长、成本高，早期筛选结果会直接影响后续研发效率。



研发周期长

1

研发链条长、阶段多，后期失败会显著放大早期筛选误差。

候选空间大

2

候选分子数量庞大，湿实验难以覆盖全部潜在化学空间。

实验成本高

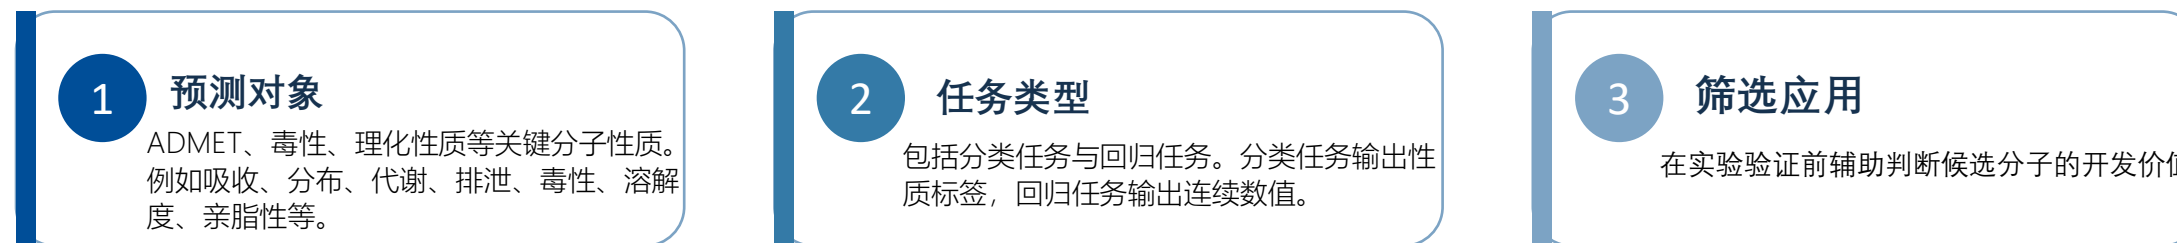
3

湿实验可靠性高，但成本高、流程复杂，难以支撑大规模高通量筛选

因此，在实验验证前对候选分子进行快速性质预测，是降低研发成本和失败风险的重要手段。





分子性质预测旨在学习分子结构与理化属性、生化性质之间的映射关系，并输出分类标签或连续数值，为候选分子的早期筛选提供依据



分子性质预测既是药物早筛中的关键计算任务，也是后续多模态分子表征学习的直接应用目标。

分子性质预测的关键在于分子表征。同一分子可以由**图结构**、**SMILES序列**、**分子指纹**和**文本语义**等多种模态共同刻画。

中文名	阿司匹林	SMILES	<chem>CC(=O)OC1=CC=CC=C1C(=O)O</chem>
二维拓扑图		分子指纹	
文本	This molecule is acetylsalicylic acid, a widely utilized non-steroidal anti-inflammatory drug, non-narcotic analgesic, antipyretic, and platelet aggregation inhibitor. Appearing as an odorless white crystalline powder with a slightly bitter taste, it is structurally a benzoic acid derivative in which the phenolic hydroxyl hydrogen has been replaced by an acetoxy group. The compound features a simple architecture consisting of a single aromatic benzene ring, an ester linkage, and two rotatable bonds. With a low molecular weight of 180.16g/mol, it is a highly compact molecule. Its moderate lipophilicity, reflected by a LogP of 1.31, alongside a topological polar surface area of 63.6 Å², provides an optimal balance of aqueous solubility and cellular membrane permeability. Additionally, its capacity to form intermolecular interactions through one hydrogen bond donor and three hydrogen bond acceptors facilitates efficient absorption, ensuring high oral bioavailability.		

SMILES序列

简化分子线性输入规范，将分子结构编码为一维字符串，适合序列模型建模。

二维拓扑图

以原子为节点、化学键为边，刻画拓扑连接关系。

分子指纹

将子结构、官能团或拓扑路径编码为固定长度向量。

文本语义

补充理化性质、药理作用和毒性机制等高层语义信息。

不同模态从**结构**、**序列**、**统计特征**和**语义知识**等角度提供互补信息，多模态学习有助于构建更全面、鲁棒的分子表示。



目 录

CONTENTS

01 / 研究背景与意义

药物发现早筛需求与多模态分子性质预测价值

02 / 研究现状

单模态、多模态方法进展及其主要不足

03 / 研究内容


CoT-CMP 与 KGAMA 两项核心方法及实验验证

04 / 结论与展望

研究贡献、局限性与未来工作方向


图结构方法

- **核心思想**：以原子为节点、化学键为边，利用图神经网络建模分子拓扑结构。
- **代表模型**：GAT、MPNN、FragNet
- **特点**：能够有效的捕捉局部领域关系和官能团信息，是当前比较主流的方法



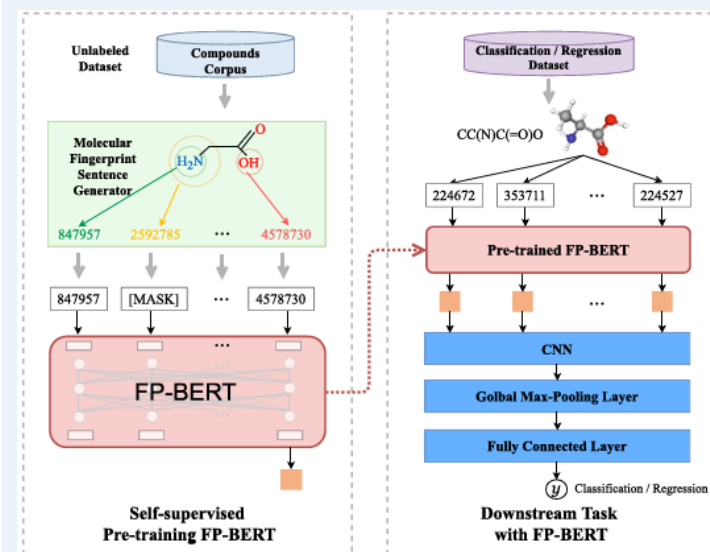
序列建模方法

- **核心思想**：将 SMILES 作为一维字符串，利用序列模型学习分子线性语法表示。
- **代表模型**：SMILES-BERT、ChemBERTa 等。
- **特点**：能够借助自然语言处理模型。计算效率高，但对拓扑结构表达有限。



指纹特征方法

- **核心思想**：将分子子结构、官能团或拓扑路径编码为固定长度向量。
- **代表模型**：ECFP、MACCS 等分子指纹。
- **特点**：特征紧凑、计算高效，但可能压缩掉部分结构细节。



由于单一模态难以完整刻画分子的结构、语义与理化特征，**多模态融合逐渐成为分子性质预测的重要趋势**，但不同模态之间的噪声差异与语义鸿沟也带来了新的对齐挑战。

1. 图+序列

- 核心：融合二维拓扑图与 SMILES 序列，同时利用结构连接关系和线性语法信息。
- 代表方法：AMCFNet、MMCL、MolGramTreeNet

2. 图+文本

- 核心：将分子结构与自然语言描述映射到统一语义空间，引入药理、用途、毒性机制等高层知识。
- 代表方法：AMCFNet、MMCL、MolGramTreeNet

3. 多模态统一融合

- 核心：联合图、序列、指纹、文本等多源信息，构建更全面的分子表示。
- 代表方法：Uni-Poly、MoLA、MMFRL、DMMF

现有方法虽然提升了分子性质预测性能，但在结构建模、推理解释和多模态对齐方面仍存在不足

1

图结构建模交互不足

- 主要依赖节点邻域聚合，对原子与化学键之间的动态交互建模不足
- 容易出现拓扑感知受限和信息回流问题。

2

大模型预测缺少显式推理

- 大语言模型直接用于分子性质预测时，预测过程可解释性不足。

3

多模态融合存在噪声与对齐困难

- 公共医学文本存在冗余噪声
- 不同模态语义粒度和噪声水平不同
- 融合或全模态对齐容易引入训练干扰。



目 录

CONTENTS

01 / 研究背景与意义

药物发现早筛需求与多模态分子性质预测价值

02 / 研究现状

单模态、多模态方法进展及其主要不足

03 / 研究内容


CoT-CMP 与 KGAMA 两项核心方法及实验验证

04 / 结论与展望

研究贡献、局限性与未来工作方向

模型设计

针对传统图神经网络原子与化学键交互不足，以及大语言模型直接预测缺少药理推理过程的问题，本研究提出 CoT-CMP 图文双塔预测框架。



文本编码端

LLaMA-3.1-8B + LoRA + CoT 提示，生成结构识别、理化分析、性质推断的显式推理文本。


图结构编码端

采用 CMPNN 建模原子与化学键之间的通信关系，增强局部官能团与长程依赖表征。


融合预测端

通过交叉注意力实现图特征与文本特征的自适应融合，服务分类与回归任务。

CoT 提示并非直接要求大语言模型给出预测标签，而是引导其生成“结构识别—理化分析—性质推断”的分步推理文本，为后续图文融合提供可解释语义特征。



直接提示



思维链提示

System Instruction [↵]	You are an expert medicinal chemist and toxicologist. Your task is to analyze the molecular structure and predict its property in a specific biochemical task. [↵]
Input Context [↵]	Here is the information of a specific drug molecule: [↵] SMILES: {smiles} [↵] Physicochemical Properties: {properties} [↵]
Task [↵]	Let's think step by step. Determine whether this molecule is likely to exhibit the target property in the {dataset_task} task. [↵] Please reason explicitly in the following three stages: [↵] 1. Key Substructure Identification: [↵] Identify the major functional groups, ring systems, and core scaffold. [↵] 2. Physicochemical and Toxicological Interpretation: [↵] Explain how the identified substructures and the provided physicochemical properties may contribute to the target property. [↵] 3. Final Property Deduction: [↵] Provide one concise sentence summarizing whether the molecule is likely to exhibit the target property. [↵]
Output Format [↵]	[Key Substructure Identification] [↵] ... [↵] [Physicochemical and Toxicological Interpretation] [↵] ... [↵] [Final Property Deduction] [↵] ... [↵]

系统指令

设定模型为药物化学与毒理学专家

上下文输入

输入分子 SMILES 与理化性质

推理任务

按照三阶段生成推理文本：

- ① 关键子结构识别
- ② 理化性质解释
- ③ 目标性质推断

文本语义

输出结构化文本

为验证 CoT-CMP 在复杂药物分子性质预测中的有效性，本文采用 TDC 平台 ADMET Benchmark Group 的 22 个任务进行系统评估。

数据集:TDC ADMET Benchmark Group

1. 吸收 Absorption: 6个任务

Caco2、HIA、Pgp、Bioav、Lipo、AqSol

2. 分布 Distribution: 3个任务

BBB、PPBR、VDss

3. 代谢 Metabolism: 6个任务

CYP2C9 / CYP2D6 / CYP3A4 Inhibition
CYP2C9 / CYP2D6 / CYP3A4 Substrate


4. 排泄 Excretion: 3个任务

Half-life、CL-Hepa、CL-Micro

5. 毒性 Toxicity: 4个任务

LD50、hERG、Ames、DILI

对比模型



GCN

图结构基线模型

AttentiveFP

注意力图神经网络
模型

NeuralFP

分子指纹学习模型

CCN

SMILES序列建模
模型

评价指标

分类任务

- AUROC: 正负样本排序能力
- AUPRC: 类别不平衡下的正类识别能力

回归任务

- MAE: 预测值与真实值的平均绝对误差，越低越好
- Spearman: 预测排序与真实排序的一致性

CoT-CMP 在 22 个 ADMET 任务上的对比实验结果



数据集	GCN	AttentiveFP	NeuralFP	CNN	CoT-CMP
Caco2(↓)	0.599 _(0.104)	<u>0.401_(0.032)</u>	0.530 _(0.102)	0.446 _(0.036)	0.387_(0.033)
HIA(↑)	0.936 _(0.024)	<u>0.974_(0.007)</u>	0.943 _(0.014)	0.869 _(0.026)	0.982_(0.012)
Pgp(↑)	0.895 _(0.021)	0.892 _(0.012)	0.902 _(0.020)	<u>0.908_(0.012)</u>	0.912_(0.020)
Bioav(↑)	0.566 _(0.115)	0.628 _(0.035)	0.632_(0.036)	0.613 _(0.013)	<u>0.630_(0.026)</u>
Lipo(↓)	0.541 _(0.011)	0.572 _(0.007)	<u>0.536_(0.023)</u>	0.743 _(0.020)	0.510_(0.035)
AqSol(↓)	0.907 _(0.020)	<u>0.776_(0.008)</u>	0.947 _(0.009)	1.023 _(0.023)	0.742_(0.046)
BBB(↑)	0.842 _(0.016)	0.855_(0.011)	0.836 _(0.009)	0.781 _(0.030)	<u>0.850_(0.019)</u>
PPBR(↓)	10.194 _(0.373)	9.373 _(0.335)	<u>9.292_(0.384)</u>	11.106 _(0.358)	8.892_(0.212)
VDss(↑)	<u>0.457_(0.050)</u>	0.241 _(0.145)	0.258 _(0.162)	0.226 _(0.114)	0.521_(0.151)
CYP2C9 Inhibition(↑)	0.735 _(0.004)	0.749_(0.004)	0.739 _(0.010)	0.713 _(0.006)	<u>0.745_(0.023)</u>
CYP2D6 Inhibition(↑)	0.616 _(0.020)	<u>0.646_(0.014)</u>	0.627 _(0.009)	0.544 _(0.053)	0.650_(0.010)
CYP3A4 Inhibition(↑)	0.840 _(0.010)	<u>0.851_(0.006)</u>	0.849 _(0.004)	0.821 _(0.003)	0.855_(0.004)
CYP2C9 Substrate(↑)	0.344 _(0.051)	<u>0.375_(0.032)</u>	0.359 _(0.059)	0.367 _(0.059)	0.380_(0.051)
CYP2D6 Substrate(↑)	<u>0.617_(0.039)</u>	0.574 _(0.030)	0.572 _(0.062)	0.485 _(0.037)	0.621_(0.029)
CYP3A4 Substrate(↑)	0.590 _(0.023)	0.576 _(0.025)	0.578 _(0.020)	0.662_(0.031)	<u>0.622_(0.035)</u>
Half life(↑)	<u>0.239_(0.100)</u>	0.085 _(0.068)	0.177 _(0.165)	0.038 _(0.138)	0.337_(0.175)
CL-Hepa(↑)	0.366 _(0.063)	0.289 _(0.022)	0.401_(0.037)	0.235 _(0.021)	<u>0.382_(0.022)</u>
CL-Micro(↑)	<u>0.532_(0.033)</u>	0.365 _(0.055)	0.529 _(0.015)	0.252 _(0.116)	0.550_(0.027)
LD50(↓)	<u>0.649_(0.026)</u>	0.678 _(0.012)	0.667 _(0.020)	0.675 _(0.011)	0.601_(0.028)
hERG(↑)	0.738 _(0.038)	<u>0.825_(0.007)</u>	0.722 _(0.034)	0.754 _(0.037)	0.855_(0.035)
Ames(↑)	0.818 _(0.010)	0.814 _(0.008)	<u>0.832_(0.006)</u>	0.776 _(0.015)	0.838_(0.017)
DILI(↑)	0.859 _(0.033)	<u>0.886_(0.015)</u>	0.851 _(0.026)	0.792 _(0.016)	0.891_(0.020)

17/22

22 个 ADMET 任务中 17 个
排名第一

5/22

其余 5 个任务排名第二

4/4

毒性任务全面领先

对比实验结论

CoT-CMP 在 22 个 ADMET 任务中取得 17 个最优、5 个次优；
在 LD50、hERG、Ames、DILI 四项毒性预测任务上均取得最优表现。

性能提升原因

CoT 推理文本补充分子药理语义，CMPNN 强化原子—化学键交互建模，交叉注意力进一步实现图结构特征与文本语义特征的自适应融合。

结果表明，**显式推理文本与分子图结构的联合建模**能够有效提升复杂 ADMET 性质预测表现。


Model↵	Pgp↵	BBB↵	CYP2D6 Inhibition↵	Ames↵
w/o LLM↵	0.835 _(0.018) ↵	0.803 _(0.016) ↵	0.597 _(0.037) ↵	0.805 _(0.017) ↵
w/o CoT↵	0.805 _(0.024) ↵	0.791 _(0.032) ↵	0.593 _(0.027) ↵	0.795 _(0.022) ↵
w/o LoRA↵	0.775 _(0.012) ↵	0.740 _(0.010) ↵	0.566 _(0.029) ↵	0.748 _(0.015) ↵
w/o Cross-Attn↵	0.872 _(0.015) ↵	0.825 _(0.021) ↵	0.638 _(0.023) ↵	0.820 _(0.019) ↵
CoT-CMP↵	0.912_(0.020)↵	0.850_(0.019)↵	0.650_(0.010)↵	0.838_(0.017)↵

分类任务消融结果

通过**消融实验**验证 LLM、CoT、LoRA 与交叉注意力模块的有效性，并通过 **CMPNN 层数敏感性实验**分析图结构编码器的合理深度。

消融结论

- 结论一：完整 CoT-CMP 在四个分类任务上均取得最优表现。
- 结论二：移除 LLM、CoT、LoRA 或交叉注意力后性能下降，说明文本推理、任务适配和图文融合均有效。




CMPNN 层数敏感性实验

参数敏感结论

- 层数过浅：结构邻域信息聚合不足。
- 层数适中：3层时整体性能最优或接近最优。
- 层数过深：可能引入冗余传播、噪声累积或过平滑。

以 DILI 药物性肝损伤预测任务为例，模型同时从**分子结构关注区域**和**文本推理关键词**两个层面提供解释线索。



This molecule contains a p-chlorobenzenesulfonyl group attached to a urea moiety, which is further substituted with a propyl group, forming an N-sulfonylurea scaffold. The core substructure consists of a chlorophenyl ring, a sulfonamide group ($-\text{SO}_2\text{NH}-$), and an amide/urea linkage ($-\text{NH}-\text{C}(=\text{O})-\text{NH}-\text{propyl}$).

Chlorpropamide has a moderate molecular weight and lipophilicity, which are favorable for oral bioavailability. From a toxicological perspective, the sulfonylurea class, including chlorpropamide, is known to be associated with hepatotoxicity, albeit with a generally low frequency. In FDA-linked databases, such as the Liver Toxicity Knowledge Base, chlorpropamide is categorized as having less-DILI-concern, indicating established evidence of its potential to cause drug-induced liver injury, often manifesting as cholestatic or hepatocellular damage. This class of drugs is primarily metabolized in the liver, a process that can produce reactive intermediates and contribute to its potential for hepatotoxicity.

Based on standard toxicological database classifications, chlorpropamide is considered a compound that exhibits potential for drug-induced liver injury.

DILI 任务中的双模态可视化案例

图结构端解释

注意力热力区域集中在对氯苯基、磺酰脲骨架及脲基连接片段附近，说明模型在结构端关注到了与毒性风险相关的关键化学子结构。


文本语义解释端

文本高亮集中在 hepatotoxicity、DILI-concern、drug-induced liver injury、liver toxicity knowledge base 等关键词上，表明 CoT 推理文本为模型提供了任务相关的毒理语义信息。

解释结论

结构注意力区域与文本毒理关键词共同指向药物性肝损伤风险，说明 CoT-CMP 能够从微观结构和宏观语义两个层面提供预测解释线索。

针对公共医学文本噪声冗余，以及多模态直接对齐训练不稳定的问题，本文提出 KGAMA 多模态分子性质预测框架。



四模态表征

联合分子图、SMILES 序列、分子指纹和自然语言文本，构建更完整的分子表示体系。

知识重写

利用 PubChem 原始文本和 RDKit 计算的 11 项理化指标，经 LLM 去噪重写后输入 SciBERT。


图中心对齐

以图表征作为稳定语义锚点，并用同方差不确定性权重降低噪声模态干扰。

自适应融合

通过交叉注意力根据具体任务动态调配不同模态贡献，而非静态拼接。

KGAMA 的核心思想：以知识增强提升文本质量，以图中心对齐稳定多模态融合。



SMILES	<chem>CC(=O)OC1=CC=CC=C1C(=O)O</chem>	<chem>CC(=O)OC1=CC=CC=C1C(=O)O</chem>
二维结构		
检索数据	Aspirin can cause developmental toxicity and female reproductive toxicity according to an independent committee of scientific and health experts. Acetylsalicylic acid appears as odorless white crystals or crystalline powder with a slightly bitter taste. (NTP, 1992) In 1853, a French chemist named Charles Frederic Gerhardt neutralized salicylic acid by buffering it with sodium (sodium salicylate) and acetyl chloride, creating acetosalicylic anhydride. Gerhardt's product worked, but he had no desire to market it and abandoned his discovery. In 1897, researcher Arthur Eichengrun and Felix Hoffmann, a research assistant at Friedrich Bayer & Co. in Germany, derivatized one of the hydroxyl functional groups in salicylic acid with an acetyl group (forming the acetyl ester), which greatly reduced the negative effects. This was the first synthetic drug, not a copy of something that existed in nature, and the start of the pharmaceuticals industry.	Acronycine is a yellow powder. (NTP, 1992)Acronycine is an alkaloid antineoplastic agent isolated from Acronychia baueri. It has a role as a metabolite and an antineoplastic agent. It is an alkaloid and a member of acridone derivatives.Acronycine is a small molecule drug. Acronycine has a monoisotopic molecular weight of 321.14 Da.Acronycine has been reported in Sarcomelicope argyrophylla, Swinglea glutinosa, and Sarcomelicope simplicifolia with data available.Acronycine is a natural alkaloid with an acridine structure isolated from the bark of the plant Acronychia baueri (Australian scrub ash) with antineoplastic properties. Acronycine appears to alkylate DNA and interfere with DNA replication. (NCI04)A pyrano-acridone alkaloid found in RUTACEAE plants.
知识重写	Aspirin acts as an inhibitor of cyclooxygenase which results in the inhibition of the biosynthesis of prostaglandins. Aspirin also inhibits platelet aggregation and is used in the prevention of arterial and venous thrombosis. (From Martindale, The Extra Pharmacopoeia, 30th ed, p5). The prototypical analgesic used in the treatment of mild to moderate pain. It has anti-inflammatory and antipyretic properties and acts as an inhibitor of cyclooxygenase which results in the inhibition of the biosynthesis of prostaglandins. Aspirin also inhibits platelet aggregation and is used in the prevention of arterial and venous thrombosis. (From Martindale, The Extra Pharmacopoeia, 30th ed, p5) See also: Acetaminophen; Aspirin; Caffeine (component of); Aspirin; Omeprazole (component of); Aspirin; caffeine; orphenadrine citrate (component of)	This molecule is acronycine (also known as acronine), a natural pyrano-acridone alkaloid isolated from plants in the Rutaceae family, notably the bark of Acronychia baueri. Appearing as a yellow powder, it functions as an antineoplastic agent that alkylates DNA and interferes with DNA replication. Structurally, it is a highly rigid acridone derivative consisting of four fused rings—three of which are aromatic—alongside ether linkages and a complete absence of stereocenters. With a molecular weight of 321.38 g/mol and 24 heavy atoms, it is a moderately sized small molecule. Its highly lipophilic nature, reflected by a LogP of 3.88, alongside a relatively low topological polar surface area (TPSA) of 40.46 Å², suggests excellent cell membrane permeability, a crucial trait allowing it to efficiently traverse lipid bilayers to reach intracellular DNA targets. This conformational stability is further reinforced by having only a single rotatable bond. The molecule's interaction profile is strictly acceptor-based; it lacks hydrogen bond donors entirely but features four hydrogen bond acceptors. This specific hydrogen bonding arrangement, combined with its hydrophobic aromatic core, heavily influences its membrane transport kinetics and its mechanism of intercalating or alkylating DNA, ultimately facilitating its potent antineoplastic activity.

药物分子原始检索文本与重写文本对比示例

以分子图为中心，把序列、指纹、文本统一拉到图结构语义空间中




图 $\leftrightarrow$ SMILES序列

图 $\leftrightarrow$ 分子指纹

图 $\leftrightarrow$ 文本描述

以图为锚点，以不确定性权重调节模态贡献，实现稳定的多模态语义对齐。

1. 对比学习目标

$$L_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j) / \tau)}{\sum_{k=1}^{2B} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k) / \tau)}$$

其中，sim 表示余弦相似度， τ 为温度系数，B 为批次大小。

2. 图中心双向对齐

$$L_{G,m} = \frac{1}{2} (L_{G \rightarrow m} + L_{m \rightarrow G}), \quad m \in \{S, F, T\}$$

保证 Graph 到辅助模态、辅助模态到 Graph 的语义一致性。

3. 自适应加权总和

$$L_{\text{total}} = \sum_{m \in \{S, F, T\}} \left(\frac{1}{2\sigma_m^2} L_{G,m} + \log \sigma_m \right)$$

通过可学习的不确定性参数自动调节不同模态对齐损失的贡献

以图为中心进行跨模态对齐，以不确定性权重抑制噪声模态干扰。

数据集: MoleculeNet Benchmark

6个分类任务

- BACE
- BBBP
- ClinTox
- Tox21
- ToxCast
- SIDER

3个回归任务

- ESOL
- Free Solv
- Lipo

评价指标与划分方式

分类任务

AUROC: 衡量正负样本排序能力, 数值越高越好。

回归任务

RMSE: 衡量预测值与真实值之间的误差, 数值越低越好。

数据划分

Scaffold Split: 按照分子骨架划分训练集、验证集和测试集, 更能评估模型在未知化学空间中的泛化能力。

对比模型

图结构模型

- GIN
- MPNN
- DMPNN
- CMPNN
- AttentiveFP

预训练模型

- GROVER
- GraphMVP

序列模型

- N-Gram
- Mol2Vec

多模态模型

- MMCL
- MMFRL
- MoleculeSTM
- MoMu
- KV-PLM

KGAMA在 MoleculeNet 上的对比实验结果



Datasets↵	BACE↵	BBBP↵	ClinTox↵	Tox21↵	ToxCast↵	SIDER↵
#Molecules↵	1513↵	2050↵	1484↵	7831↵	8597↵	1427↵
#Tasks↵	1↵	1↵	2↵	12↵	617↵	27↵
MMCL↵	0.868 _(0.002) ↵	0.895 _(0.012) ↵	0.921 _(0.031) ↵	0.836 _(0.009) ↵	0.699 _(0.005) ↵	0.660 _(0.023) ↵
MMFRL↵	<u>0.869_(0.014)</u> ↵	0.901 _(0.021) ↵	0.924 _(0.021) ↵	0.821 _(0.031) ↵	0.701 _(0.009) ↵	0.659 _(0.018) ↵
AttentiveFP↵	0.863 _(0.150) ↵	0.908 _(0.050) ↵	0.933 _(0.020) ↵	0.807 _(0.021) ↵	0.637 _(0.103) ↵	0.605 _(0.061) ↵
Mol2Vec↵	0.802 _(0.008) ↵	0.826 _(0.027) ↵	0.750 _(0.127) ↵	0.754 _(0.101) ↵	0.614 _(0.031) ↵	0.592 _(0.003) ↵
GROVER↵	0.810 _(0.044) ↵	0.695 _(0.185) ↵	0.762 _(0.013) ↵	0.735 _(0.027) ↵	0.653 _(0.005) ↵	0.614 _(0.017) ↵
GraphMVP↵	0.812 _(0.009) ↵	0.724 _(0.016) ↵	0.791 _(0.028) ↵	0.759 _(0.005) ↵	0.631 _(0.114) ↵	0.639 _(0.012) ↵
MPNN↵	0.815 _(0.043) ↵	0.913 _(0.042) ↵	0.879 _(0.054) ↵	0.808 _(0.024) ↵	0.691 _(0.018) ↵	0.595 _(0.031) ↵
DMPNN↵	0.823 _(0.038) ↵	0.919 _(0.048) ↵	0.897 _(0.041) ↵	0.759 _(0.034) ↵	0.655 _(0.101) ↵	0.570 _(0.031) ↵
CMPNN↵	0.866 _(0.002) ↵	<u>0.927_(0.002)</u> ↵	0.901 _(0.012) ↵	<u>0.837_(0.016)</u> ↵	<u>0.709_(0.002)</u> ↵	0.617 _(0.003) ↵
GIN↵	0.845 _(0.021) ↵	0.894 _(0.019) ↵	0.869 _(0.034) ↵	0.811 _(0.002) ↵	0.703 _(0.004) ↵	0.591 _(0.016) ↵
SchNet↵	0.751 _(0.033) ↵	0.847 _(0.025) ↵	0.717 _(0.041) ↵	0.767 _(0.023) ↵	0.679 _(0.021) ↵	0.545 _(0.038) ↵
N-Gram↵	0.779 _(0.031) ↵	0.912 _(0.004) ↵	0.855 _(0.013) ↵	0.761 _(0.130) ↵	0.659 _(0.133) ↵	<u>0.662_(0.009)</u> ↵
MoleculeSTM↵	0.808 _(0.002) ↵	0.712 _(0.019) ↵	<u>0.925_(0.011)</u> ↵	0.769 _(0.005) ↵	0.651 _(0.014) ↵	0.610 _(0.008) ↵
MoMu↵	0.767 _(0.014) ↵	0.705 _(0.020) ↵	0.799 _(0.041) ↵	0.756 _(0.003) ↵	0.634 _(0.011) ↵	0.605 _(0.009) ↵
KV-PLM↵	0.785 _(0.027) ↵	0.731 _(0.054) ↵	0.892 _(0.073) ↵	0.725 _(0.102) ↵	0.550 _(0.065) ↵	0.598 _(0.056) ↵
KGAMA↵	0.872_(0.006) ↵	0.930_(0.002) ↵	0.939_(0.012) ↵	0.841_(0.005) ↵	0.712_(0.011) ↵	0.669_(0.004) ↵

KGAMA 在 MoleculeNet 分类任务上的对比实验结果

Datasets↵	ESOL↵	FreeSolv↵	Lipo↵
# Molecules↵	1128↵	642↵	4200↵
# Tasks↵	1↵	1↵	1↵
MMCL↵	0.865 _(0.045) ↵	1.669 _(0.103) ↵	0.705 _(0.032) ↵
MMFRL↵	0.850 _(0.034) ↵	<u>1.619_(0.202)</u> ↵	0.663 _(0.042) ↵
AttentiveFP↵	0.877 _(0.060) ↵	2.073 _(0.220) ↵	0.721 _(0.030) ↵
Mol2Vec↵	0.995 _(0.032) ↵	2.021 _(0.154) ↵	0.803 _(0.021) ↵
GROVER↵	0.921 _(0.087) ↵	2.026 _(0.127) ↵	0.676 _(0.022) ↵
GraphMVP↵	1.029 _(0.033) ↵	1.893 _(0.063) ↵	0.681 _(0.002) ↵
MPNN↵	1.167 _(0.430) ↵	2.185 _(0.952) ↵	0.672 _(0.051) ↵
DMPNN↵	0.972 _(0.097) ↵	2.170 _(0.536) ↵	0.662 _(0.051) ↵
CMPNN↵	<u>0.845_(0.039)</u> ↵	1.833 _(0.581) ↵	<u>0.658_(0.029)</u> ↵
GIN↵	0.885 _(0.051) ↵	1.636 _(0.102) ↵	0.659 _(0.085) ↵
SchNet↵	1.045 _(0.064) ↵	3.215 _(0.355) ↵	0.909 _(0.098) ↵
N-Gram↵	1.074 _(0.112) ↵	2.688 _(0.251) ↵	0.812 _(0.031) ↵
MoleculeSTM↵	↵	↵	↵
MoMu↵	↵	↵	↵
KV-PLM↵	1.124 _(0.251) ↵	2.124 _(0.429) ↵	0.902 _(0.047) ↵
KGAMA↵	0.831_(0.024) ↵	1.512_(0.233) ↵	0.655_(0.006) ↵

KGAMA 在 MoleculeNet 回归任务上的对比实验结果

0.939

ClinTox AUROC

0.930

BBBP AUROC

0.872

BACE AUROC

0.831


ESOL RMSE

1.512

FreeSolv RMES

0.655

LIPO RMSE



消融结论一

随着指纹、序列和文本模态逐步加入，模型性能整体提升，说明不同模态具有互补价值。

消融结论二

加入知识增强文本后，ClinTox、Tox21、ToxCast 等毒性相关任务进一步提升，说明文本语义能够补充结构模态难以表达的高层知识。


消融结论三

完整 KGAMA 优于 w/o C，说明动态融合机制比简单特征拼接更能根据任务分配模态贡献。

消融结论四

消融结果表明，四模态互补与交叉注意力融合共同提升了 KGAMA 的预测性能。

- **w/o ALL**: 仅保留图编码器分支，作为纯图结构基线。
- **w/o STC**: 在图基础上加入分子指纹。
- **w/o TC**: 进一步加入 SMILES 序列模态。
- **w/o C**: 使用完整四模态输入，但采用静态拼接融合。
- **KGAMA**: 完整模型，在四模态基础上引入交叉注意力，实现动态自适应融合。



Graph 作为稳定结构锚点

Graph 在多数任务中保持较高权重，说明分子拓扑结构是性质预测中最稳定、最核心的信息来源。

Fingerprint 补充子结构统计信息


Fingerprint 在 BACE、FreeSolv、Lipo 等任务中贡献明显，说明分子指纹能够补充官能团、子结构和局部化学片段信息。

Text 提供高层语义补充

Text 在 ClinTox、Tox21、SIDER 等毒性和副作用相关任务中权重较高，说明知识增强文本能够补充药理、毒性和安全性语义。

SMILES 提供线性序列辅助信息

SMILES 在各任务中的权重相对稳定，说明其能够从分子线性语法角度提供辅助表示，补充图结构与指纹模态的信息。



实验目的

分析对比学习温度系数 τ 对模型性能的影响，验证 KGAMA 对核心超参数的稳定性。

实验设置

在 MoleculeNet 六个分类任务上设置不同 τ 取值，比较 AUROC 变化趋势。

实验结论

当 $\tau = 0.1$ 时，多数任务取得最优或接近最优表现，说明适中的温度系数有助于形成更稳定的跨模态对比学习空间。

趋势分析

τ 过小会使模型过度关注少量难样本，训练不稳定； τ 过大则会削弱正负样本区分度，导致对齐效果下降。

参数敏感实验表明，KGAMA 在合理温度范围内表现稳定，本文最终选择 $\tau = 0.1$ 作为对比学习温度系数。



目 录

CONTENTS

01 / 研究背景与意义

药物发现早筛需求与多模态分子性质预测价值

02 / 研究现状

单模态、多模态方法进展及其主要不足

03 / 研究内容

CoT-CMP 与 KGAMA 两项核心方法及实验验证

04 / 结论与展望

研究贡献、局限性与未来工作方向



01

结论一：CoT-CMP

提出思维链增强与通信式图交互的图文双塔框架，在 ADMET 基准组上取得较优预测结果，并提供可解释线索

02

结论二：KGAMA

提出知识增强与图中心对齐的四模态框架，在 MoleculeNet 基准组上验证了知识重写和自适应融合的有效性。

展望一：引入三维几何构象

进一步融合原子坐标、键角、二面角及 SE(3) 等变模型，提升空间结构建模能力。

展望二：扩展预训练数据规模

构建更大规模、高质量的图、序列、文本配对数据，增强泛化能力。

展望三：干湿实验闭环验证

将模型预测与真实实验反馈联动，服务候选分子的持续优化。

敬请各位老师批评指正！