

分类号

密级

中国地质大学（北京）
专业硕士学位论文

基于图神经网络的符号感知推荐
算法研究

研究生 曾燕 学 号 2104230026

专业学位类别 电子信息 专 业 计算机技术

校内导师 牛云云 产业导师 张永虹

学习方式 全日制

2026 年 4 月

**A Dissertation Submitted to
China University of Geosciences for Master of Professional
Degree**

**Research on Sign-Aware Recommendation Algorithms Based
on Graph Neural Networks**

Master Candidate: Yan Zeng

Professional Degree: Electronic and Information Engineering

Dissertation Supervisor: Prof. Yunyun Niu

Associate Supervisor: Yonghong Zhang

China University of Geosciences (Beijing)

声 明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国地质大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签 名：_____日 期：_____

关于论文使用授权的说明

本人完全了解中国地质大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。延期公开的论文在到期公开后应遵守此规定。

签 名：_____导师签名：_____日 期：_____

摘要

随着移动互联网的普及和在线信息服务的快速发展，互联网数据呈现指数级增长态势，信息过载问题日益突出。推荐系统作为一种有效的个性化信息过滤技术，已广泛应用于电子商务、新闻资讯、短视频和社交网络等各大领域，成为解决信息过载问题的核心技术手段。近年来，基于图神经网络的推荐方法通过建模用户-物品交互中的高阶协同关系，显著提升了推荐性能。然而，现有方法在推荐场景的应用大多基于静态图或单一时间衰减机制，难以同时刻画用户兴趣的短期波动与长期演化，且现有研究大多仅关注用户的显式或隐式正反馈，对负向反馈信息利用不足，且在复杂图结构下易受到过平滑和噪声传播的影响。此外，传统基于成对比较的优化目标与实际列表级排序指标之间仍存在一定差异，限制了模型性能的进一步提升。针对上述问题，本文提出以下两种算法：

首先，针对推荐系统用户兴趣时序演化与数据稀疏性问题，提出多尺度时序融合的动态图推荐算法（TDGRec）。通过构建时间感知的用户-物品交互图，设计多尺度时间衰减机制，精准捕获用户的近期兴趣波动与长期稳定偏好。在此基础上，设计了动静结合的联合建模策略，将动态时序信息与静态结构信息相融合，有效缓解了时间衰减带来的图结构稀疏与冷启动问题。同时，配合时间感知的排序优化机制，确保模型在训练过程中能够对近期关键交互行为赋予更高的关注权重，使得推荐结果更符合用户当前的兴趣状态。

其次，针对推荐系统负向反馈信息利用不足问题，进一步提出符号感知的跨层对比学习推荐算法（TDGRec-SR）。通过构建符号感知的正负双图结构，对不同语义的交互关系进行区分建模，并采用双分支编码器分别学习用户的正向偏好与负向非偏好特征。设计跨层对比学习自监督机制，复用图卷积中间层输出构造对比视图，无需额外数据增强与冗余计算的同时，有效抑制噪声传播并缓解多层卷积带来的过平滑问题，进一步增强稀疏与冷启动场景下的模型鲁棒性；设计引入基于动量更新的教师模型，构建列表级排序蒸馏策略，缩小训练目标与实际排序指标的差异，同时保障大规模数据下的训练与推理效率。

实验结果验证，本文提出的算法在 MovieLens-1M、Amazon-Book 和 Yelp 等公开数据集上，Recall 和 NDCG 等核心指标均显著优于现有主流基线模型，尤其在用户交互行为极度稀疏的数据场景下提升明显，验证了所提算法的有效性与鲁棒性。

关键词：推荐系统，图神经网络，符号二分图，对比学习，排序蒸馏

Abstract

With the popularization of mobile Internet and the rapid development of online information services, Internet data has shown an exponential growth trend, and the problem of information overload has become increasingly prominent. As an effective personalized information filtering technology, recommendation system has been widely used in major fields such as e-commerce, news and information, short video and social networks, and has become the core technical means to solve the problem of information overload. In recent years, the recommendation method based on graph neural network has significantly improved the recommendation performance by modeling the high-order synergy relationship in user-item interaction. However, most of the existing methods are based on static graphs or a single time decay mechanism, which is difficult to depict the short-term fluctuations and long-term evolution of user interest at the same time. In addition, there are still some differences between the traditional optimization objectives based on pairwise comparison and the actual list-level ranking indexes, which limits the further improvement of model performance. To solve the above problems, the following two algorithms are proposed:

Firstly, aiming at the problems of user interest temporal evolution and data sparsity of the recommendation system, a dynamic graph recommendation algorithm (TDGRec) with multi-scale temporal series fusion is proposed. By constructing a time-aware user-item interaction graph, a multi-scale time decay mechanism is introduced to accurately capture users' recent interest fluctuations and long-term stable preferences. On this basis, a joint modeling strategy combining dynamic and static is designed, which integrates dynamic timing information with static structure information, which effectively alleviates the graph structure sparseness and cold start problems caused by time attenuation. At the same time, with the time-aware sorting optimization mechanism, it ensures that the model can give higher attention weight to recent key interaction behaviors during the training process, so that the recommendation results are more in line with the user's current interest status.

Secondly, aiming at the problem of insufficient utilization of negative feedback information in the recommendation system, a cross-layer comparative learning recommendation algorithm (TDGRec-SR) with symbol perception is further proposed. By constructing a symbol-aware

positive and negative double-graph structure, the interaction relationship of different semantics is differentiated and modeled, and the user's positive preference and negative non-preference features are learned by using a two-branch encoder. The cross-layer comparative learning self-supervision mechanism is designed, and the intermediate output of graph convolution is used to construct a comparison view, which does not require additional data enhancement and redundant calculation, effectively suppresses noise propagation and alleviates the over-smoothing problem caused by multi-layer convolution, and further enhances the robustness of the model in sparse and cold start scenarios. Furthermore, by introducing a teacher model based on momentum updates, a list-level sorting distillation strategy is constructed to narrow the difference between the training target and the actual ranking index, and at the same time ensure the training and inference efficiency under large-scale data.

Experimental results show that the proposed algorithm is significantly better than the existing mainstream baseline models in the core indicators such as Recall and NDCG on public datasets such as MovieLens-1M, Amazon-Book and Yelp, especially in the data scenario where user interaction behavior is extremely sparse, which verifies the effectiveness and robustness of each innovation module.

Key words: Recommendation System, Graph Neural Network, Signed Bipartite Graph, Contrastive Learning, Ranking Distillation

目 录

摘要	1
Abstract	2
1 引言	1
1.1 研究背景和意义	1
1.2 国内外研究现状	3
1.2.1 基于图神经网络的推荐研究现状	3
1.2.2 基于大语言模型的推荐研究现状	6
1.2.3 时序动态研究现状	7
1.2.4 符号网络研究现状	9
1.2.5 对比学习研究现状	10
1.3 研究内容及论文结构	12
1.3.1 研究内容	12
1.3.2 论文结构	13
2 相关理论与技术基础	15
2.1 推荐系统基础	15
2.1.1 协同过滤推荐算法	15
2.1.2 时序推荐算法	16
2.2 图神经网络相关理论和技术	18
2.3 符号图学习	21
2.4 对比学习	22
2.4.1 对比学习基础	23
2.4.2 推荐系统中的图对比学习	23
2.5 排序学习与推荐优化目标	24
2.6 本章小结	26
3 基于多尺度时序融合动态感知的图推荐算法	27
3.1 研究动机	27
3.2 模型设计与描述	27
3.2.1 时间加权图构建模块	29

3.2.2	动静融合表示模块	30
3.2.3	图神经网络传播模块	32
3.2.4	时间感知排序优化	33
3.3	实验设计	33
3.3.1	实验设置	33
3.3.2	对比算法	35
3.3.3	参数设置	36
3.4	实验结果与分析	36
3.4.1	模型对比分析	36
3.4.2	消融实验分析	37
3.4.3	模型通用性分析	39
3.4.4	稀疏度分析	40
3.4.5	超参数分析	42
3.5	本章小结	43
4	基于符号感知的跨层对比学习推荐算法	45
4.1	研究动机	45
4.2	模型设计与描述	46
4.2.1	符号感知双分支表示学习	48
4.2.2	噪声增强跨层对比学习	51
4.2.3	动量排序蒸馏	53
4.2.4	注意力融合	54
4.2.5	多任务联合总损失函数	55
4.3	实验设计	55
4.3.1	实验设置	56
4.3.2	对比算法	56
4.3.3	参数设置	56
4.4	实验结果与分析	56
4.4.1	模型对比分析	56
4.4.2	消融实验分析	57

4.4.3 负向图编码器架构对比分析	59
4.4.4 超参数分析	60
4.5 本章小结	63
5 结论与展望	64
5.1 论文结论	64
5.2 未来展望	65
参考文献	66
致谢	72
附录	73

1 引言

1.1 研究背景和意义

随着信息技术、移动互联网以及大数据技术的快速发展，人类社会正在进入以数据驱动为核心特征的信息化时代。互联网平台、移动终端设备以及物联网传感器在日常运行过程中持续产生海量数据，信息资源呈现出规模巨大、类型多样和更新迅速等特点。《中国互联网络发展状况统计报告》^[1]显示，我国网民规模已超过十亿，互联网普及率持续提升，用户在电商、社交媒体、在线视频、音乐平台等多种应用场景中产生了大量交互行为数据。在信息资源极大丰富的同时，人们接受、处理和利用信息的能力是有限的，如何在庞大的信息空间中为用户提供高效、准确的内容筛选与推荐，成为互联网服务系统面临的核心挑战之一。

为了应对信息过载的难题，谷歌、百度等主流互联网搜索引擎工具诞生，通过关键词匹配的方式帮助用户定位目标信息。然而，搜索引擎属于被动式信息获取方式，它的性能高度依赖于用户能够准确表达自身需求。当用户存在潜在需求却不知如何准确描述，或者缺乏明确的搜索目标时，就不能找到想要的信息。在此背景下，推荐系统逐渐成为互联网平台的重要基础模块，通过分析用户历史行为数据，自动预测用户潜在兴趣，从而主动向用户推送可能感兴趣的内容，有效缓解信息过载问题。当前推荐系统已经广泛应用于电子商务、短视频平台、在线音乐、新闻推荐以及社交网络等领域，并在提升用户体验和平台商业价值方面发挥着关键作用。例如，淘宝、京东等电商平台会根据用户的浏览、点击记录以及相似用户的购物习惯，推荐感兴趣的商品；抖音等短视频平台会根据用户的观看时长、点赞评论以及完播率，推送定制化的短视频流；微信、QQ等社交网络平台会根据共同好友或地理位置，推荐可能认识的人；网易云音乐等平台则通过分析用户听过的歌曲标签与风格，推送“每日推荐”歌单。

推荐系统的核心在于推荐算法的设计与优化，其目标是从信息过载的环境中精准挖掘用户偏好，实现个性化服务。传统推荐方法主要可归纳为基于内容的推荐、协同过滤和混合推荐三类模型。基于内容的推荐源自信息检索与过滤思想，通过抽取物品的内容特征和构建用户兴趣画像，计算物品与用户历史偏好物品的相似度，从而推荐高度匹配的对象。该方法的优势在于不依赖其他用户数据，具有天然的独立性、强可解释性，且对新物品能够即时推荐。协同过滤是目前应用最广泛的推荐技术，其核心思想是利用集体智慧，基于

用户与物品的交互行为挖掘用户或物品的相似性。它可进一步分为基于记忆的方法和基于模型的方法。协同过滤无需领域知识，能够发现用户潜在的兴趣点，推荐的新颖性较强。但它在实践中常面临冷启动问题；同时数据稀疏性和系统可扩展性也是制约其性能的主要瓶颈。混合推荐旨在取长补短，将基于内容的推荐与协同过滤等多种策略有机组合，以克服单一模型的固有缺陷。常见混合策略包括加权融合、动态切换、级联过滤和特征组合等。合理的混合设计能在准确率、召回率、多样性及覆盖率等多维指标上取得更好的平衡。

上述传统方法虽在工业界取得了广泛应用，但在建模用户与物品间的高阶关系时仍存在问题。以协同过滤为例，其核心在于利用用户-物品的交互矩阵，但通常只能捕获直接相连或路径较短的用户相似性与物品相似性，对于“用户的相似用户所喜欢的物品”这类跨越多个节点的间接偏好传播路径，缺乏建模能力。推荐场景中的核心数据是用户与物品的交互，本质上构成了一张二分图。随着图表示学习，特别是图神经网络的发展，研究者开始尝试直接在交互图上进行建模，通过节点间的消息传递机制显式捕获这种高阶协同信号，从而突破了传统方法在关系建模深度上的瓶颈，开启了图推荐研究的新范式。近年来，图神经网络（Graph Neural Network, GNN）^[2]凭借在非欧几里得图结构数据上的强大建模能力，成为推荐系统领域内的研究热点。用户与物品的交互关系天然构成二分图，图中的节点即为用户与物品，观测到的交互则通过边来表征。借助图神经网络的邻域消息传递机制，模型可以对高阶连通性进行迭代聚合，从而捕获传统方法难以显式编码的协同关系，提升用户与物品嵌入表示的表达能力^[3]。具体而言，Wang 等人^[4]提出的 NGCF 首次将图卷积操作引入协同过滤框架，通过高阶邻居的信息传播增强用户与物品的嵌入表示；随后的 He 等人^[5]提出的 LightGCN 对模型结构进行轻量化简化，去除了冗余的非线性变换与特征映射模块，验证了图结构传播本身在推荐任务中的核心作用，成为当前 GNN 推荐领域的经典基准模型。基于图神经网络的推荐方法在多个公开数据集和工业场景中均取得了优于传统方法的效果，已成为推荐算法研究的重要方向。

尽管图神经网络在推荐系统中取得了显著进展，但现有研究仍然面临许多问题。首先，多数图推荐模型基于静态交互图进行建模，默认用户兴趣在整个训练过程中保持不变。然而在真实应用场景中，用户兴趣具有明显的时间动态特征，既包含长期稳定偏好，也包含短期阶段性兴趣变化。如果忽略时间信息，模型容易过度依赖历史行为的平均特征，难以捕捉用户近期兴趣漂移，导致推荐结果的时效性下降。部分研究尝试通过时间衰减函数或序列建模方法引入时间因素，但这类操作常以破坏图拓扑连通性为代价，削弱了高阶协同

信号的传播效能。因此如何在保持图拓扑完整性的同时引入时间动态信息，仍是动态图推荐研究中的重要问题。

其次，现有大多数图推荐方法通常将用户-物品交互视为单一语义的正向关系，在图传播过程中对所有交互边进行统一聚合。然而在实际推荐场景中，不同类型的交互行为往往包含不同程度的兴趣信息，例如点击、收藏、购买等行为具有不同的偏好强度，而跳过、差评等行为则隐含负向反馈。如果在图建模阶段忽略交互关系的语义差异，容易造成不同语义信息的混叠，降低节点表示的判别能力。符号网络理论通过对正负关系进行区分建模，可以更细粒度地刻画实体间的关联特征，将其引入图推荐模型，可以提升用户兴趣表示的准确性。

在深层图传播过程中，节点还面临“过平滑”这一普遍现象，即随着传播层数增加，不同节点的嵌入向量逐渐趋于一致，导致个性化特征减弱。近年来，对比学习被广泛用于提升图表示学习的鲁棒性，通过构造不同视图并引入一致性约束，可以在一定程度上缓解表示退化问题。但现有图推荐中的对比学习方法多采用随机丢边或扰动等增强策略，可能破坏原始交互图中的关键结构信息，同时不同传播层所包含的语义特征存在差异，如何在多层表示之间建立合理的一致性约束仍有待进一步研究。此外，相当一部分图推荐模型在训练阶段使用基于成对比较的排序损失，而在评估阶段却采用列表级排序指标，训练目标与评测准则之间的不一致客观上影响了最终的排序质量。在图结构表示学习之上，引入与推荐任务评价目标更为一致的排序优化机制，对提升整体推荐效果具有现实意义。

综合来看，在大规模推荐背景下，如何在同一图神经网络框架内协同处理用户兴趣的时间动态、交互关系的语义差异以及深层表示的稳定性，构成了当前研究的关键挑战。围绕上述问题展开系统性的模型设计与优化，对于增强推荐系统在高维稀疏数据环境下的表示能力和排序性能，具有理论价值与应用前景。

1.2 国内外研究现状

1.2.1 基于图神经网络的推荐研究现状

在大规模推荐场景中，用户-物品交互数据具有稀疏性，同时不同用户之间、不同物品之间往往存在潜在的高阶关联，传统基于矩阵分解或协同过滤的方法难以充分利用用户与物品之间复杂的高阶关联关系，仅依赖显式交互信息难以准确刻画用户兴趣。因此，如何有效利用高阶结构关系来增强表示学习，成为推荐算法研究的关键突破口之一。推荐系统

中，用户与物品的交互可自然抽象为二分图，用户与物品为节点，交互行为为边，这为图神经网络的应用提供了天然的数据基础。

图神经网络的概念最早可追溯至 Marco Gori^[6]等人的研究，该工作开创性地提出了在图结构数据上直接进行神经网络建模的思路。近年来，受益于图卷积网络（Graph Convolutional Network, GCN）^[7]与图注意力网络（Graph Attention Network, GAT）^[8]等基础架构的突破，基于图神经网络的推荐算法已从最初的浅层网络向深层表征、异构图建模、自监督学习等方向全面拓展，极大提升了推荐系统的特征表达能力，基于图神经网络的推荐方法逐渐成为当前推荐系统研究的主流方向之一。

在早期研究中，NGCF^[4]模型首次将图卷积操作引入协同过滤框架，通过特征变换和非线性激活细化表征来学习高阶协同信号，有效解决了传统方法难以传播和捕获深层交互特征的挑战。随后，LightGCN^[5]对图卷积结构进行了简化，去除了非线性激活函数和特征变换，仅保留邻域加权聚合操作，并通过多层传播累积高阶协同信息。该方法在保持模型结构简洁的同时取得了较好的推荐效果，成为后续图推荐研究的重要基准模型。在此基础上，UltraGCN^[9]进一步针对计算效率问题，通过构造约束损失函数来直接近似无限层图传播的极限状态，避免了显式的、代价高昂的多层迭代计算，显著提升了模型在大规模数据上的可扩展性。

在实际推荐场景中，用户产生的交互行为往往包含多种动机，不同交互可能对应不同兴趣方向。为了解决单一嵌入表示难以刻画多重偏好的问题，部分研究引入解耦表示学习思想，通过将用户兴趣划分为多个潜在子空间，分别进行建模，以提升表示的表达能力。例如，解纠缠图协同过滤（DGCF）^[10]模型通过对用户-物品关系进行意图分解，使模型能够同时学习多个兴趣通道，从而在一定程度上缓解单一表示带来的信息混叠问题。在模型框架的扩展上，Hamilton 等人^[11]提出的 GraphSAGE 算法，通过图采样与邻居信息聚合来学习节点表示，进而生成节点的嵌入向量，用于个性化推荐。PinSage^[12]在此基础上引入重要性池化和高效采样，成功在 Pinterest 上部署了拥有数十亿节点和边的超大规模图推荐系统，验证了图神经网络在工业级场景的巨大潜力。此外，Berg 等人^[13]提出 GCMC 算法，该算法将用户-物品交互矩阵建模为二部图，并利用图注意力机制学习用户和物品的嵌入表示，以实现矩阵补全，从而填补缺失的交互信息。

在多关系建模方面，现有多数图推荐模型默认所有交互边均代表正向关系，即认为用户与物品之间的连接均反映兴趣相似性。然而在真实应用环境中，用户行为不仅包含正向

反馈，还可能包含弱兴趣甚至负向偏好。如果在图传播过程中对所有交互关系进行统一聚合，可能导致不同语义的信息混合，从而降低节点表示的判别能力。针对这一问题，部分研究开始探索多关系图或符号图建模方法，通过对不同类型的交互关系进行区分建模，以更细粒度地刻画用户与物品之间的关联特征。例如，Xie 等人^[14]提出的 SiGRec 首次系统地分析了推荐系统中隐含负反馈的三种类型，并在此基础上构造带符号的用户-物品交互图。该模型的核心思想在于放弃传统方法将所有交互统一建模的模式，转为通过正图神经网络编码器和负图神经网络编码器分别学习用户与物品的正、负反馈嵌入，从而在嵌入空间中显式区分偏好与厌恶信号。同时，SiGRec 定义了符号余弦损失函数以适配不同类型负反馈的特征学习。

当模型试图通过堆叠更多传播层来捕获更高阶的协同信号时，又面临图神经网络固有的过平滑问题，即节点嵌入会逐渐丧失个性化。为此，在推荐系统引入自监督学习和对比学习方法，通过构造不同视图并施加一致性约束，提高节点表示的区分度。例如，SGL^[15]通过对原始图进行随机的节点或边丢弃来构造数据增强视图，并最大化视图间的一致性以学习更具鲁棒性的表征。SimGCL^[16]则通过在嵌入空间中直接注入均匀分布的随机扰动来增强数据多样性。对比学习通过最大化多视图间的互信息，显著缓解了标注数据稀缺的问题。尽管对比学习能够在一定程度上缓解表示退化问题，但现有方法通常依赖随机增强策略，可能破坏原始图结构中的关键连接关系，从而影响模型对真实偏好的刻画。此外，不同传播层所包含的语义信息存在差异，浅层表示更关注局部邻域，而深层表示包含更多全局协同特征，如何在不同层级之间建立合理的约束关系，使模型在保持差异性的同时提高稳定性，仍然是当前图推荐研究中的一个重要问题。

在推荐系统的优化目标方面，当前多数图推荐模型采用基于贝叶斯个性化排序（Bayesian Personalized Ranking, BPR）^[17]损失函数进行训练，而在测试阶段通常使用列表级指标对推荐结果进行评估，这种训练目标与评价指标之间的不一致可能影响最终排序效果。因此，在图结构表示学习的基础上，引入更加符合推荐任务目标的排序优化机制，对于提升模型性能具有重要意义。

纵观基于图神经网络的推荐研究现状可知，基于图神经网络的推荐方法在高阶关系建模方面具有明显优势，但现有研究在时间动态建模、多语义关系表达以及深层传播稳定性等方面仍存在不足。针对这些问题，进一步设计能够同时刻画时间变化特征、区分交互语义并增强表示稳定性的图推荐模型，对于提升推荐系统在复杂场景下的表现具有重要研究

价值。

1.2.2 基于大语言模型的推荐研究现状

近年来，大语言模型（Large Language Models, LLMs）的快速发展推动了推荐系统研究范式的演进。大语言模型是基于人工神经网络的语言模型，通常拥有数十亿至数千亿参数，通过在海量文本数据上进行预训练，能够在自然语言理解和生成任务中表现出卓越性能^[18]。与传统推荐方法主要依赖用户与物品离散 ID 建模不同，基于大语言模型的推荐方法更加关注文本语义理解、知识迁移以及生成能力，通过将推荐任务转化为自然语言处理任务，实现用户兴趣与物品特征的统一语义建模。

代表性工作如 P5^[19]提出了统一推荐框架，将评分预测、序列推荐、解释生成等多种任务转化为 Prompt 驱动的文本生成任务，从而实现多任务联合学习。随后，Chat-REC^[20]等研究进一步探索了大模型在对话推荐中的应用，通过多轮自然语言交互动态捕捉用户偏好，并利用 LLM 内部蕴含的通用知识增强冷启动场景下的推荐能力。在零样本（Zero-shot）与少样本（Few-shot）推荐任务中，生成式推荐展现出了较强的泛化性能与可解释性，因此逐渐成为当前推荐系统研究的重要发展方向之一^[21]。

与此同时，推荐系统正经历从被动推荐向具备自主规划能力的智能体（Agent）范式的交互升级。基于大语言模型的对话推荐系统不仅能理解复杂的语言结构，还能根据对话历史动态调整推荐策略，提供自然流畅的交互体验。更前沿的探索如 AgentCF^[22]，将用户和物品均视作拥有记忆与反思能力的智能体，通过模拟多轮自主交互与协作反思来学习用户偏好。这类方法赋予了系统推理规划与工具调用的能力，推动推荐流程向主动智能迈进。

然而，尽管大语言模型在语义推理上展现出巨大的优势，但其在复杂工业级图推荐场景中的规模化落地仍面临着难以逾越的现实壁垒。首先是高昂的计算成本与延迟瓶颈，大模型庞大的参数量导致其训练与实时推理极度消耗算力资源，难以适配工业界对毫秒级响应的严苛要求。其次是高阶协同信号的捕捉困境，纯基于自回归文本序列的生成式建模，在面对海量、极度稀疏的隐式反馈数据时，难以高效且精准地刻画用户与物品之间错综复杂的图拓扑结构。当处理长序列行为时，纯文本生成往往会出现注意力分散、信息压缩不足及核心协同信号弱化等问题，甚至引发模型“幻觉”，从而直接削弱推荐的准确性与鲁棒性。最后，LLM 在训练过程中可能“记忆”用户敏感信息，存在被恶意攻击者提取的风险。同时，在模型服务过程中，用户数据的流转与使用也面临合规性挑战。

因此，基于图神经网络的协同过滤方法在当前推荐系统中仍具有重要研究价值。相较

于生成式大语言推荐模型，图推荐方法能够更加高效地建模用户与物品之间的高阶拓扑依赖关系，在海量稀疏交互场景下依然具备较好的可扩展性与推理效率。近年来，研究者开始探索将大模型的语义理解能力与图协同过滤的结构建模能力进行融合，以兼顾语义表达与协同信号学习。在此背景下，如何进一步提升轻量级图推荐模型的表示能力与结构建模效果，仍然是值得深入研究的问题。

1.2.3 时序动态研究现状

用户兴趣并非静止不变，而是随着时间推移不断演化。不同阶段的行为往往指向不同的偏好状态，短期交互反映当前意图，而长期稳定的行为则体现较为固定的兴趣。若在推荐模型中忽略这一时间维度，将所有历史行为等同处理，很容易导致模型过度依赖早期数据，使得推荐结果失去时效性。因此，如何在推荐模型中有效刻画用户兴趣的动态变化过程，一直是推荐系统研究中的重要问题。

早期的推荐算法大多基于静态假设，将用户历史行为视为无序集合进行建模，典型方法包括矩阵分解和协同过滤模型。这类方法虽然在稠密数据场景中表现良好，但难以刻画用户兴趣随时间变化的过程。为了解决这一问题，引入序列建模方法通过对用户行为按时间顺序进行建模来捕捉兴趣演化特征。在序列推荐领域，基于马尔可夫链的方法较早被用于建模用户行为转移关系，例如，FPMC^[23]模型通过对用户长期偏好与相邻行为间的转移规律进行联合建模，在稀疏序列数据上取得了性能提升。然而，马尔可夫模型受限于固定的状态转移阶数，通常仅使用一阶转移，难以有效捕捉长距离的依赖关系，面对较长行为序列时表达能力明显不足。

随着深度学习的发展，循环神经网络被广泛应用于序列推荐任务。GRU4Rec^[24]模型利用门控循环单元对用户点击序列进行建模，通过依次编码点击序列来捕捉短期兴趣变化，在高稀疏度的会话场景中展现出了良好的适应性，在会话推荐任务中取得了较好的效果。随后，研究者进一步引入长短期记忆网络（LSTM）^[25]和双向循环网络，以增强对长序列依赖的建模能力。但循环结构在处理长序列时计算效率较低，难以满足大规模推荐系统的需求。

近年来，自注意力机制在序列建模中的应用推动了时序推荐模型的发展。SASRec^[26]模型利用多头注意力机制对用户历史行为进行加权建模，使模型能够自适应地关注不同时间位置的交互信息，从而同时捕捉长期和短期兴趣。TiSASRec^[27]在此基础上进一步引入时间间隔编码，将行为之间的时间差显式融入注意力权重计算，使模型能够更精细地刻画兴

趣随时间衰减的过程。**BERT4Rec**^[28]通过双向编码结构对用户行为序列进行建模，在多个公开数据集上取得了较好的效果。这类基于序列的推荐方法能够较好地刻画个体用户的行为演化过程，但通常将每个用户独立处理，难以充分利用跨用户的协同信息。

为了利用时序动态特征与全局网络结构信息，部分研究开始将时间序列与图神经网络相结合。**SR-GNN**^[29]模型将会话序列转化为局部有向图结构，利用图卷积聚合节点信息，显著提升了短序列的推荐准确性。**GC-SAN**^[30]结合图卷积与自注意力机制，在保持序列顺序信息的同时引入图结构传播，提高了表示能力。

面向更复杂的全局交互，离散时间与连续时间动态图模型成为当前研究的重点。在离散时间动态图建模中，主流架构通常将时间轴离散化为多个序列快照，结合时空图卷积网络跨层传递时序节点状态。而在连续时间动态图领域，**EvolveGCN**^[31]通过引入递归更新机制，使图卷积参数能够随时间变化，从而适应动态图环境。**JODIE**^[32]模型通过为用户和物品维护可更新的动态嵌入，在每次交互发生时对节点表示进行增量更新，实现了连续时间建模。**TGN**^[33]进一步引入记忆模块和时间编码机制，使模型能够处理高频交互事件，在动态图学习任务中表现出较好的性能。

除上述模型层面的动态化设计外，另一类研究采用时间加权或时间衰减策略，在构建交互图时根据交互发生时间对边进行重新赋权，使近期行为在传播过程中具有更高影响力。这类方法实现简单，能够在一定程度上提升推荐结果的时效性，但过强的时间衰减可能导致图结构稀疏化，从而削弱高阶协同信息的传播效果。此外，如果仅依赖时间衰减而忽略原始图结构，容易造成长期偏好信息丢失，影响模型稳定性。因此，如何在引入时间信息的同时保持图拓扑结构的完整性，是动态图推荐模型需要解决的关键问题之一。

此外，用户兴趣往往同时包含长期稳定偏好与短期动态兴趣，不同时间尺度的信息对推荐结果具有不同影响。部分研究尝试通过多兴趣建模或多尺度建模来解决这一问题，例如 **MIND**^[34]模型通过多兴趣提取层和动态路由机制将用户历史行为聚合为多个兴趣向量，以解耦的方式表示不同偏好方向，**DIEN**^[35]通过注意力机制动态选择与当前行为相关的历史兴趣。这些方法在一定程度上提升了兴趣表达能力，但多数工作仍基于序列模型，未能充分利用图结构中的高阶协同关系。工业界的实践强烈推动了动态图时序推荐向超大规模与流式计算方向发展。**Pinterest**^[36]提出的流式图神经网络方案支持对千亿级图结构的增量实时更新，保障了节点嵌入的时效性。阿里巴巴构建的动态多兴趣网络通过捕捉用户在电商场景下的实时交互子图，实现了精准的秒级意图猜测。这些落地应用验证了动态图架构在

低延迟、高并发业务中的巨大商业价值^[37]。

综上所述，现有时序推荐研究主要集中在序列建模、动态图学习以及时间加权图结构等方向。尽管这些方法能够在一定程度上刻画用户兴趣的动态变化，但仍存在一些不足：一是部分序列模型忽略全局协同信息，难以充分利用跨用户关系；二是部分动态图模型结构复杂，计算开销较大，难以直接应用于大规模推荐场景；三是简单的时间衰减策略可能破坏图结构的连通性，影响高阶信息传播。因此，在图神经网络框架下设计既能保持图结构完整性，又能有效刻画用户兴趣时间变化的动态建模方法，仍具有重要的研究价值。

1.2.4 符号网络研究现状

随着社交网络与电商平台的深入发展，网络中实体间的关联关系呈现出高度复杂性和强异质性。例如，在电商平台中，点击、收藏和购买通常表示正向兴趣，但兴趣强度存在差异；而跳过、取消关注或差评等行为则可能反映负向偏好。如果在推荐模型中仅使用单一的交互关系进行建模，将所有连接统一视为正向关联，容易导致不同语义信息混合，从而降低用户表示的判别能力。因此，如何在推荐模型中刻画多语义关系，成为近年来推荐算法研究的重要方向之一。

早期推荐方法通常基于无符号图结构进行建模，即假设图中所有边均表示正向关系。在传统协同过滤和矩阵分解模型中，用户-物品交互通常被表示为评分或隐式反馈，模型通过拟合评分矩阵来学习用户偏好。这类方法在数据较为稠密时能够取得较好效果，但在复杂交互场景下难以区分不同类型的行为语义。随着推荐系统应用场景不断扩展，研究者逐渐认识到，仅依赖单一关系建模难以充分表达真实用户兴趣，需要在模型中引入更加细粒度的关系表示。

在网络表示学习领域，符号网络被用于刻画实体之间的正负关系。在符号图中，边不仅表示是否存在连接，还包含关系的符号信息，通常用正边表示相似或友好关系，用负边表示不相似或对立关系。符号网络研究最早来源于社会网络分析中的结构平衡理论，该理论认为网络中的正负关系满足一定的平衡结构，例如“朋友的朋友可能是朋友”，“敌人的敌人可能是朋友”。基于这一理论，研究者提出了一系列符号网络嵌入方法，用于学习包含正负关系的节点表示。

在早期的图嵌入研究中，DeepWalk^[38]利用截断随机游走获得的局部信息，通过将游走视为句子等价物来学习潜在表示，LINE^[39]则进一步显式建模节点间的一阶和二阶邻近度，保留局部与全局图结构信息，但这些方法仅考虑无符号图结构，无法处理负关系信息。为

了解决这一问题，后续研究开始专门针对符号网络设计表示学习方法。早期的符号网络嵌入方法如 Wang 等人^[40]提出的面向社交媒体的符号网络嵌入模型 SINE 基于结构平衡理论构造目标函数，通过将正、负链接映射到不同的嵌入空间中，显式保留了用户间的信任与反对关系，Yuan 等人^[41]提出的 SNE 模型采用对数双线性模型，使用沿路径所有节点的特征表示，并进一步包含两个带符号向量以捕捉路径上每条边的正负关系。在此基础上，进一步的研究引入了深度学习架构，SDGNN^[42]通过同时重构边的符号和方向信息，使模型能够在嵌入空间中区分正向和负向关系，SGCN^[43]将图卷积网络扩展到符号图，通过分别聚合正邻居和负邻居的特征，实现对不同语义关系的差异化建模；SiGAT^[44]进一步结合注意力机制，根据邻居节点的重要程度动态调整正负关系的传播权重，从而提高表示的表达能力。SNEA^[45]提出了一种通用的有符号网络嵌入框架，利用注意力机制自适应地聚合正负边信息，精准地筛选和融合关键邻居特征。GS-GNN^[46]设计了一种双通道图神经网络架构，能够协同学习节点的全局群组结构与局部邻域表示，有效解决了复杂社会网络中的多群落建模问题。

受符号网络建模思路的启发，在推荐系统中显式引入负向反馈信息逐渐成为受到关注的研究方向。传统隐式反馈推荐通常将未交互物品视为负样本，但这种假设并不一定准确，因为未交互可能仅表示用户尚未看到该物品，而不一定表示不感兴趣。部分研究尝试显式建模负反馈信息，例如利用差评、跳过或低评分数据构建负边，从而提升模型的判别能力。相关研究表明，适当利用负向关系可以提高推荐模型对用户偏好的区分能力，但如果直接将负边与正边混合传播，容易破坏图神经网络的同质性假设，导致表示学习不稳定。因此，如何在保持传播稳定性的同时利用负关系信息，是符号图推荐模型需要解决的重要问题。

1.2.5 对比学习研究现状

随着图神经网络在推荐系统中的广泛应用，在多层图传播过程中节点表示容易出现退化现象。当传播层数增加时，不同节点的嵌入向量趋于相似，个性化特征被逐渐削弱，存在过平滑问题。在推荐场景中，由于用户-物品交互数据本身具有高度稀疏性，过平滑问题会更加明显，从而影响模型对用户偏好的区分能力。因此，如何在稀疏数据下既保留高阶拓扑信息，又增强节点表征的判别力，成为近年来图推荐研究的重要方向之一。

为应对上述挑战，自监督对比学习为解决过平滑问题提供了一种有效思路，其核心思想是通过构造不同视图的正样本对，并拉近其嵌入距离，同时拉远负样本对的距离，从而增强特征表达能力。对比学习的性能上限，核心取决于两大关键环节：一是高质量正负样

本对的构造策略，二是适配任务场景的损失函数设计。SimCLR^[47]通过对原始图像执行多类型随机数据增强构造同一样本的不同视图，以此生成正样本对，同时基于余弦相似度设计对比损失函数完成模型优化，最终在无监督学习场景下，取得了与监督学习方法相当的特征表征效果。但该方法依赖的随机数据增强策略，仅适配图像数据的特性，无法直接迁移至图结构、序列数据等其他场景，存在较强的场景局限性。针对这一问题，MoCo^[48]通过设计动态字典队列与动量编码器机制，构建了可动态更新的负样本池，有效解决了小批量训练场景下负样本数量不足的瓶颈，大幅提升了特征表征的一致性。BYOL^[49]则突破了传统对比学习的范式约束，摒弃了显式负样本对的构造，通过动量编码器与在线网络的协同优化，结合自训练机制完成表征学习，进一步提升了模型的特征学习能力。SwAV^[50]等方法则融合了聚类学习的思想，直接在嵌入空间中对特征分布进行对比学习，充分展现了对比学习范式的多样性与可拓展性。这些工作共同确立了对比学习的基本框架，并揭示了其核心在于正负样本对的构造策略与损失函数的设计。

随后，这一思想被引入图推荐领域。SGL^[15]模型将自监督学习引入图协同过滤框架，通过对用户-物品交互图进行随机丢边或随机游走生成多个子图，并在不同子图上学习节点表示，再通过对比学习使同一节点在不同视图中的嵌入保持一致，从而提升推荐性能。然而，显式的图结构扰动不仅增加了计算开销，还存在破坏核心协同链路的风险。随后的SimGCL^[16]提出在嵌入空间中直接加入随机噪声来构造不同视图，在保持较低复杂度的同时取得了与复杂增强方法相近的效果，该研究进一步剖析了对比学习在推荐中生效的本质动机是基于 InfoNCE 的对比损失能够促使节点在表征空间中呈现更均匀的分布，从而有效缓解了推荐系统中常见的长尾流行度偏差。SGCL^[51]设计了自对齐模块与子图模块，通过子图采样减轻高阶邻居的影响。

尽管上述方法取得了成功，但随机增强仍然面临破坏关键协同信号的潜在风险。具体而言，随机的边删除可能恰好移除了对刻画用户核心偏好至关重要的高阶连接，而统一的噪声注入则忽视了不同节点和传播层对扰动的敏感度差异。为了解决这一瓶颈，研究重心开始从“如何生成更好的增强视图”转向“如何利用模型自身结构构造天然视图”，跨层对比学习应运而生。

与依赖外部数据增强的方法不同，跨层对比学习的核心思想是将图传播过程中不同层的节点嵌入视为“天然”的多视图。例如，L²CL^[52]明确指出现有图对比学习方法依赖随机图增强可能破坏关键信息并引入不必要的噪声，通过对比不同层的表示进行学习，对齐不

同层之间的语义相似性能够学习复杂的结构关系，摆脱随机数据增强中的噪声干扰。NLGCL^[53]则提出利用图神经网络中天然存在的邻居层间对比视图，将节点与下一层的邻居视为正对，从而避免基于增强的噪声注入和额外的计算开销。此外，为了将局部与全局结构信息统一到对比框架中。HMCFL^[54]设计了层级多视图图对比学习框架，利用消息传递机制在不同层级上引入不同粒度的视图增强，从而为训练过程提供丰富的自监督信号，并能够解释原始图中的层级拓扑结构和节点间的相对距离。NPGCL^[55]采用嵌入扰动策略和层间对比学习来缓解多层图卷积带来的噪声影响。HNECL^[56]则从结构和语义双视角出发，通过利用图神经网络多图上的层融合输出和层次聚类策略，分别建模节点的局部和全局结构邻居以及层次化语义邻居，构建出更丰富的对比视图。

总体来看，对比学习通过促使表征空间更加均匀分布，为缓解图推荐模型中的过平滑与长尾问题提供了强有力的手段。尽管现有研究在视图构造上已从初期的结构增强演进为更精细的嵌入扰动与层级挖掘，但主流方法在提升推荐性能的同时，普遍引入了不可忽视的计算开销与过度设计的复杂性。具体而言，显式的图结构增强容易破坏关键的协同链路。基于噪声注入的策略虽然降低了复杂度，但其引入的人工扰动仍具有一定的盲目性，无法确保对比视图与节点的真实偏好语义完全对齐。此外，部分现有的多视图和层次化对比方法往往依赖复杂的聚类或层级聚合机制，不仅牺牲了模型训练的效率，也偏离了图协同过滤追求轻量高效的初衷。因此，如何减少冗余的人工数据增强与复杂的辅助模块，探索一种极致轻量且能高度保留原始协同语义的视图构造方式，是当前图推荐对比学习的关键问题之一。

1.3 研究内容及论文结构

1.3.1 研究内容

图神经网络通过构建用户-物品异质图结构，能够完整捕捉并保留用户行为序列中的高阶连接关系，有效突破了传统方法仅能建模用户-物品二元显式交互的表达瓶颈。但当前基于图神经网络的推荐算法仍面临一些关键问题。首先，多数图推荐模型基于静态交互图进行表示学习，难以刻画用户兴趣随时间变化的动态特征，导致模型在长时间跨度数据上的表现不稳定。其次，现有模型通常将用户-物品交互统一视为正向关系，忽略了不同交互行为所包含的语义差异，容易造成表示混叠，影响模型的判别能力。此外，在深层图传播过程中，节点表示容易出现过平滑现象，而现有自监督增强方法大多依赖随机扰动生成对比

视图，会破坏原始图结构中的有效信息。最后，当前多数推荐模型在训练阶段采用局部排序损失，而在评估阶段使用列表级指标，二者之间存在不一致性，限制了模型性能的进一步提升。

针对上述问题，本文聚焦于图结构网络推荐算法的研究现状与挑战，从模型架构设计、算法实验验证等维度提出创新性优化策略，本文的研究工作主要包括以下两个方面。

(1) 针对传统图推荐网络难以刻画用户兴趣时间变化的问题，提出了一种基于多尺度时序融合的动态感知图推荐算法 TDGRec。该方法在保持原始用户-物品交互图拓扑结构不变的基础上，引入时间衰减机制，通过时间差函数对交互边进行重加权，构建时间加权邻接矩阵，使图传播过程具备时间选择性。在此基础上，设计动静融合传播机制，将时间动态邻接矩阵与原始静态邻接结构进行线性融合，在保持全局拓扑连通性的同时增强近期兴趣表达能力。尤其适用于电商图书、本地生活服务等用户兴趣具有明显时间动态性的场景，同时在数据稀疏与工业级大规模推荐场景中也展现出良好的计算效率与泛化能力。此外，TDGRec 保持传播机制的简洁性与模型无关性，可嵌入主流图推荐框架，实现时间动态增强而不显著增加计算复杂度。通过时间加权邻接矩阵与融合传播机制的协同设计，在表示层面引入时间动态建模能力，为后续结构增强阶段提供稳定的时间感知嵌入基础。

(2) 针对 TDGRec 单一正向关系建模难以刻画复杂语义结构与深层图传播表征同质化问题，提出了符号感知的跨层对比学习动态图推荐算法 TDGRec-SR。该算法首先根据交互关系的语义差异构建正向时序子图与负向静态子图，采用异构双分支编码框架分别进行特征学习，正向分支继承 TDGRec 的多尺度时序建模能力，负向分支则采用多层感知机进行独立编码，避免了负向关系与图神经网络同质性假设的冲突，实现了用户偏好与厌恶特征的精准解耦。在此基础上，设计同象限噪声增强的跨层对比学习机制，复用图卷积中间层输出构造对比视图，无需额外数据增强与冗余计算即可有效抑制噪声传播、缓解深层网络的过平滑问题。同时，设计基于指数移动平均的动量教师模型，构建列表级排序蒸馏策略，将训练目标从局部成对比较扩展至全局排序空间，显著缩小了训练目标与实际推荐评估指标之间的差异。适用于短视频、电商平台等存在丰富显式/隐式负反馈的场景，在对排序精度要求较高的信息流推荐以及极度稀疏的长尾推荐场景中，相比现有主流模型展现出更优的鲁棒性与推荐性能。

1.3.2 论文结构

本文围绕基于图神经网络的符号感知推荐算法展开深入研究，全文共分为五个章节，

具体组织结构如下：

第一章：引言。阐述课题的研究背景与实际意义，分析当前图神经网络推荐方法在时间动态建模与结构表达方面存在的主要问题。随后系统梳理国内外相关研究现状，并在此基础上明确本文的研究目标与技术路线。最后给出全文整体结构安排。

第二章：相关理论与技术基础。对本文工作相关的技术与理论知识进行详细的介绍，介绍图神经网络、时序推荐模型、符号网络表示学习以及对比学习等与本文工作相关的基础理论。

第三章：多尺度时序融合动态感知的图推荐算法 TDGRec。本章介绍了多尺度时序融合动态感知的图推荐算法，首先分析现有基于图神经网络的推荐方法在邻接矩阵构建阶段忽略时间信息所带来的兴趣滞后问题，在此基础上构建时间加权邻接矩阵，通过时间衰减函数对用户-项目交互边进行加权，设计动静融合传播机制，将时间动态邻接矩阵与原始静态图结构进行融合，在保持全局拓扑连通性的同时增强对近期兴趣的建模能力，从而实现时间动态与图结构传播的统一建模。在三个公开数据集上对该方法进行实验，并基于实验结果进行详细分析与讨论。

第四章：基于符号感知的跨层对比学习动态图推荐算法 TDGRec-SR。本章介绍了符号感知的跨层对比学习动态图推荐算法，针对深层图传播中存在的结构表达能力不足与排序目标不一致问题，首先构建符号双图结构，在时间动态图基础上对节点关系进行正负语义划分，通过双分支传播机制分别学习吸引关系与区分关系表示，从结构层面增强节点嵌入的判别能力。随后引入跨层对比增强机制，通过对不同传播层级的表示进行一致性约束，抑制深层传播引发的表征同质化问题，针对训练阶段成对排序目标与测试阶段列表级评价指标之间存在差异的问题，设计排序一致性增强策略，以缩小优化目标与评价指标之间的偏差，提升推荐结果的排序合理性与泛化能力。在三个公开数据集上对该方法进行实验，并基于实验结果进行详细分析与讨论。

第五章：结论与展望。对全文的研究工作与实验成果进行高度总结，并剖析当前研究存在的局限性，对未来图神经网络在推荐系统领域的发展方向进行展望。

2 相关理论与技术基础

2.1 推荐系统基础

2.1.1 协同过滤推荐算法

协同过滤（Collaborative Filtering, CF）^[57]是推荐系统中最经典的建模方法。核心思想是利用用户历史交互行为中的相似性信息进行偏好预测，该方法基于一个基本假设：具有相似历史的用户往往具有相似的兴趣偏好，而经常被同一类用户交互的物品往往具有某种潜在的相关性。协同过滤算法主要通过分析用户与物品之间的历史交互数据来挖掘信息，进而预测目标用户对未接触物品的偏好程度。

在推荐系统的形式化定义中，通常设 $U = \{u_1, u_2, \dots, u_M\}$ 表示包含 M 个用户的集合， $I = \{i_1, i_2, \dots, i_N\}$ 表示包含 N 个物品的集合。用户与物品之间的交互可以表示为一个维度为 $M \times N$ 的用户-物品交互矩阵 $\mathbf{Y}$ ，矩阵中的元素 y_{ui} 如公式 2-1 所示：

$$y_{ui} = \begin{cases} 1, & \text{如果用户 } u \text{ 与物品 } i \text{ 存在交互} \\ 0, & \text{如果用户 } u \text{ 与物品 } i \text{ 未发生过交互} \end{cases} \quad (2-1)$$

传统的协同过滤算法主要分为基于内存的协同过滤^[58]与基于模型的协同过滤两大类，基于内存的协同过滤主要包括基于用户（User-CF）和基于物品（Item-CF）的邻域方法，该类方法通过计算用户之间或物品之间的相似度（如余弦相似度、皮尔逊相关系数等），利用邻居节点的历史行为对目标用户的偏好进行预测。以 Item-CF 为例，预测用户 u 对物品 i 的偏好得分 $\hat{y}_{ui}$ 主要是通过聚合用户 u 历史交互过的物品与目标物品 i 的相似度来实现。尽管邻域方法直观且具备一定的可解释性，但在面对高度稀疏的交互矩阵时，两个冷门节点之间往往缺乏历史交互信息，导致相似度计算频繁失效，泛化能力极其有限。

为了克服基于内存方法的稀疏性与计算扩展性瓶颈，基于模型的协同过滤逐渐成为研究的主流，其中最为经典的是矩阵分解（Matrix Factorization, MF）技术^[59]。矩阵分解的核心思想是将高维且极其稀疏的离散交互矩阵 $\mathbf{Y}$ ，映射到一个低维的连续稠密潜在特征空间中。具体而言，矩阵分解为每个用户 u 和每个物品 i 分别分配一个维度为 d 的可学习隐向量，记为 $\mathbf{e}_u \in \mathbb{R}^d$ 和 $\mathbf{e}_i \in \mathbb{R}^d$ （其中 $d \ll \min(M, N)$ ）。在低维隐空间中，用户 u 对物品 i 的预测偏好得分 $\hat{y}_{ui}$ 被定义为这两个隐向量的内积如公式 2-2 所示：

$$\hat{y}_{ui} = \mathbf{e}_u^T \mathbf{e}_i \quad (2-2)$$

通过在训练集中不断减小预测得分 $\hat{y}_{ui}$ 与真实标签 y_{ui} 之间的误差,模型能够自动学习到用户与物品的深层隐语义表示。因此,矩阵分解极大地提升了模型处理稀疏数据的泛化能力。

随着深度学习(Deep Learning)^[60]在推荐系统领域的发展,传统的矩阵分解仅利用简单的线性内积,难以充分拟合用户与物品之间复杂的非线性交互模式。为此,神经协同过滤(Neural Collaborative Filtering, NCF)^[61]等深度学习框架被提出。NCF放弃了固定的内积操作,转而将用户向量 $\mathbf{e}_u$ 与物品向量 $\mathbf{e}_i$ 进行拼接或元素级乘积后,输入到多层感知机中,利用神经网络强大的函数拟合能力来捕捉隐语义空间中复杂的非线性依赖关系。这一思路突破了线性模型的表达瓶颈,将特征交叉的维度推向了更深层次。

尽管从矩阵分解到神经协同过滤,模型在特征表示与非线性特征交叉能力上取得了很大进步,但这类传统协同过滤算法在底层机制上均存在一个共同的理论盲区,在构建预测模型时,仅将用户与物品的单次交互视为独立的数据对,未能显式地建模全局交互的图拓扑结构,只能利用用户与物品之间的一阶直接连通性,而无法有效挖掘潜藏在“用户-物品-相似用户-候选物品”这条传播路径上的高阶协同信号。这种对全局图结构拓扑视野的缺失,严重制约了模型在长尾分布与极端稀疏场景下的表现,因此,研究者逐渐将推荐问题扩展到图结构建模,通过显式构建用户-物品交互图,使模型能够在更大范围内传播协同信息,这也成为图神经网络推荐方法研究的重要基础。

2.1.2 时序推荐算法

在实际推荐场景中,用户兴趣通常会随着时间动态变化^[62]。例如,在电子商务场景下,用户消费偏好会受到季节变化、热点商品以及阶段性需求的影响。在内容推荐场景中,用户对新闻、视频等内容的关注具有明显的时间依赖性。因此,仅基于静态交互数据进行建模的传统推荐方法难以准确刻画用户兴趣的动态演化过程,容易导致推荐结果与用户当前需求产生偏差。

为解决静态建模的局限性,时序感知推荐模型应运而生。其核心目标是在推荐建模中显式引入时间维度信息,捕捉用户兴趣的演化规律,从而提升推荐结果的时效性、准确性与用户满意度。早期的探索如 TimeSVD++^[63]明确揭示了时间因素在偏好预测中的重要性,通过为潜在因子引入时间偏置项来拟合兴趣的随时间漂移。在此基础上,时序推荐将用户的历史交互转化为带时间戳的有序序列。时序推荐不仅关注用户与物品之间是否发生交互,还强调交互行为发生的时间顺序与动态演化过程。通常可将用户交互行为表示为带时间戳

的三元组集合，如公式 2-3 所示：

$$S=\{(u, i, t) \mid u \in U, i \in I, t \in T\} \quad (2-3)$$

其中， U 表示用户集合， I 表示物品集合， T 为时间戳集合， t 表示 u 与物品 i 发生交互的绝对时间。

随后，研究者进一步将用户行为按照时间顺序组织为行为序列，推动了序列推荐（Sequential Recommendation）的发展。序列推荐将用户 u 的历史交互按时间先后顺序排列，构建有序的行为序列 $S_u = (i_1, i_2, \dots, i_{|S_u|})$ ，并利用序列中的上下文依赖关系预测用户下一时刻可能交互的物品。代表性工作 FPMC 模型将矩阵分解与马尔可夫链相结合，在建模用户长期偏好的同时，引入序列转移关系以刻画用户短期兴趣变化。

随着深度学习技术的发展，循环神经网络（Recurrent Neural Network, RNN）成为序列推荐的主流建模工具，有效解决了传统方法的长序列依赖捕捉难题。GRU4Rec 是循环神经网络在序列推荐中的经典应用，它基于门控循环单元（GRU）按时间步顺序处理用户行为序列，通过门控机制选择性保留历史信息、过滤无效信息，有效缓解了传统循环神经网络的梯度消失问题，能够更精准地捕捉用户会话内的短期意图与长序列的兴趣演化规律。但基于循环结构的模型受限于从左至右的串行计算逻辑，无法并行处理序列数据，且难以自适应区分序列中不同行为的重要程度。

为进一步提升长序列建模能力，研究者提出基于自注意力机制的序列推荐方法。代表性模型 SASRec 利用自注意力机制对用户历史行为进行动态建模，能够自适应学习序列中不同行为的重要程度，并有效缓解传统循环网络在长序列场景下的依赖建模问题。相比于 RNN 类方法，基于注意力机制的模型具有更强的并行计算能力与全局依赖捕获能力，因此逐渐成为当前序列推荐的重要研究方向。

尽管序列推荐方法能够有效建模用户行为的时间顺序信息，但大多数方法主要关注单个用户自身的行为演化过程，对跨用户之间的协同关系利用不足，在数据稀疏场景下仍存在一定局限。为进一步融合时间演化信息与全局协同关系，研究者开始将动态图建模思想引入推荐系统。近年来，研究者开始尝试将时间信息与图结构建模相结合，提出动态图推荐方法。根据对动态时序过程的建模方式，动态图模型进一步可划分为离散动态图模型和连续动态图模型。部分早期研究采用离散方法，将时间序列划分为多个时间快照（Snapshot）切片进行处理。然而，这种切片方式不可避免地会导致细粒度的时序动态信息丢失，进而影响模型的表达能力。为了克服这一缺陷，研究者提出了基于连续时间的时序图（Temporal

Graph) 模型。

在时序图范式下, 用户-物品交互关系不再被视为静态结构, 而是随时间不断演化的动态网络。时序图能够保留动态过程的完整信息, 将动态过程中发生的每一次结构变化转化为流式的事件集合。假设用 s^t 来表示时序图中 t 时刻的交互事件, 其数学定义可以扩展为如公式 2-4 所示:

$$s^t = (u, i, x, t) \quad (2-4)$$

其中, u 与 i 分别表示节点, x 表示事件类型, t 表示事件发生的时序。由所有时序事件构成的动态图可表示如公式 2-5 所示:

$$TG = \{s^t | 0 < t \leq T\} \quad (2-5)$$

在这种建模方式下, 动态图的演化过程被转化为一个事件流, 用最小粒度的方式对整个时间序列进行建模, 从而完整保留了所有的关联信息。在图表示学习框架下, 时序图推荐的核心目标是通过神经网络将每个节点的结构特征、属性特征及时序特征融合为同一表征空间内的分布。其表示学习的映射过程如公式 2-6 所示:

$$f_\theta: (TG, v(t)) \rightarrow z(t) \in \mathbb{R}^d \quad (2-6)$$

其中, $v(t)$ 代表节点在 t 时刻的输入状态, R 代表表征空间, d 代表其维度, f_θ 则是通过数据训练得到的神经网络映射函数。

通过在图传播过程中引入时间因素, 模型在聚合邻域信息时能够更加关注近期交互, 从而更准确地反映用户当前兴趣。代表性工作 TGN 通过记忆模块对节点状态随时间的变化过程进行建模, 实现了连续时间动态图上的动态表示学习。随后, DyGformer^[65]突破了传统时间步的限制, 通过时序邻居共现机制与 Transformer^[66]架构的深度结合, 实现了对任意时刻动态事件交互的细粒度特征提取。

尽管在时序特征提取与抗噪鲁棒性上取得了突破, 但在实际的大规模图计算中, 仍有两个问题存在: 其一, 长短期多尺度解耦困境。无论是单一指数衰减还是现有的多头注意力机制, 往往难以通过统一的权重同时精准量化用户长期固有的基础画像与高频突发的瞬时兴趣; 其二, 拓扑结构脆弱性与孤岛效应。引入严格的时间惩罚或时间窗口截断旧边时, 原本在全局二部图中负责连接不同长尾社区的“老旧边”将面临断裂风险。这种单纯的时序加权会严重割裂图的连通性, 导致大量节点沦为孤立节点, 阻断高阶协同信号的传播。

2.2 图神经网络相关理论和技术

随着推荐系统数据规模的不断扩大以及用户行为关系的日益复杂, 传统协同过滤方法

在刻画高阶协同关系方面逐渐受到限制，传统方法仅能建模用户与物品间的一阶交互关联，无法有效捕捉用户-物品二部图中多跳路径隐含的高阶协同信号。例如，两个用户即使未直接交互相同物品，仍可能通过“用户-物品-用户”路径建立潜在兴趣关联。因此，研究者开始将推荐问题表示为图结构学习问题，通过构建用户-物品交互图，在图结构中传播与聚合邻域信息，从而学习更加丰富的节点表示。图神经网络能够在图结构上进行端到端表示学习，通过邻域信息传播机制不断聚合高阶结构特征，因此在近年来的推荐系统研究中得到广泛应用，并逐渐成为主流建模方法之一。在图推荐模型中，通常将用户集合与物品集合共同表示为一个二部图如公式 2-7 所示：

$$G=(V, E) \quad (2-7)$$

其中节点集合 $V = U \cup I$ ， U 和 I 分别表示用户节点与物品节点，边集合 E 表示用户与物品的交互关系，当用户 u 与物品 i 发生交互时，在图中建立一条无向边 (u, i) 。

在经典的图神经网络（如 GraphSAGE 及 GCN）中，节点表征的更新遵循标准的“聚合-更新”消息传递范式。每一次迭代中，节点通过权重矩阵 W 对邻居特征进行线性变换，并经过非线性激活函数 $\sigma(\cdot)$ 来更新自身状态。设 $h_v^{(k)}$ 表示节点 v 在第 k 层的嵌入向量，初始的第 0 层嵌入 $h_v^{(0)}$ 通常由节点的 One-hot ID 映射而来， $N(v)$ 表示节点 v 的一阶邻居节点集合。第 k 层前向传播过程可形式化定义为以下两个核心步骤：

（1）消息聚合：收集目标节点 v 所有邻居节点在上一层的表征信息，构建局部邻域特征向量 $m_v^{(k)}$ 如公式 2-8 所示：

$$m_v^{(k)} = \text{AGGREGATE}^{(k)}(\{h_u^{(k-1)} : u \in N(v)\}) \quad (2-8)$$

（2）节点更新：将聚合得到的邻域信息 $m_v^{(k)}$ 与目标节点自身的上一层表征 $h_v^{(k-1)}$ 进行融合，生成当前层的最新表征 $h_v^{(k)}$ 如公式 2-9 所示：

$$h_v^{(k)} = \text{COMBINE}^{(k)}(h_v^{(k-1)}, m_v^{(k)}) \quad (2-9)$$

在经典的图卷积网络中，上述两个步骤通常被耦合为一个包含特征矩阵变换和非线性激活函数的公式，耦合后如公式 2-10 所示：

$$h_v^{(k)} = \sigma \left(W^{(k)} \sum_{u \in N(v) \cup \{v\}} \frac{1}{\sqrt{|N(v)| |N(u)|}} h_u^{(k-1)} \right) \quad (2-10)$$

其中, $W^{(k)}$ 是第 k 层的可学习权重矩阵, $\sigma(\cdot)$ 是非线性激活函数, $1/\sqrt{|N(v)||N(u)|}$ 是用于防止度数过大节点主导梯度的对称归一化系数。

上述“聚合-更新”的两步式计算, 构成了 GNN 最核心的消息传递 (Message Passing) 框架, 每一轮迭代中, 节点都会从邻域收集并聚合信息, 完成自身特征的更新, 从而将图的拓扑结构与邻域语义信息编码到节点表示中, 图 2-1 给出了典型的消息传播过程示意图。




图 2-1 消息传播框架

随着图神经网络在推荐系统中的应用不断深入, 研究者发现传统 GCN 中的特征变换与非线性激活操作并不一定适用于协同过滤任务。由于推荐系统中的节点特征通常仅由可学习 ID 嵌入构成, 复杂的非线性变换反而可能增加训练难度并引入噪声传播问题。为此, NGCF 首次将图卷积网络显式引入协同过滤任务, 通过多层邻域传播学习用户与物品之间的高阶协同关系。随后, LightGCN 进一步对图卷积结构进行简化, 移除了特征变换矩阵与非线性激活函数, 仅保留最核心的邻域聚合操作, 从而实现更加轻量且高效的高阶协同建模。LightGCN 采用层间表示融合策略, 对不同传播层得到的节点表示进行加权求和, 节点最终表示如公式 2-11 所示:

$$h_v = \sum_{k=0}^K \alpha_k h_v^{(k)} \quad (2-11)$$

其中, α_k 表示第 k 层表示的权重系数。该融合方式能够同时保留局部邻域信息和高阶协同信息, 从而提高节点表示的稳定性。在得到用户与物品的嵌入向量后, 采用内积形式预测用户对物品的偏好程度 $\hat{y}_{ui}$ 如公式 2-12 所示:

$$\hat{y}_{ui} = e_u^T e_i \quad (2-12)$$

其中, e_u 和 e_i 分别表示用户节点与物品节点的最终嵌入向量。预测值越大, 表示用户越可能对该物品产生兴趣。模型训练阶段, 通过最小化预测值与真实交互标签的损失函数, 端到端优化所有可学习参数, 完成用户与物品的表示学习。

2.3 符号图学习

在现有的基于图神经网络的推荐模型中，用户-物品交互网络通常被简化为仅含正向关联的无符号图结构，模型默认图中所有连通边均对应用户对物品的积极偏好，并基于同质性假设完成邻域特征聚合与节点表示学习。然而在真实推荐场景中，用户的行为反馈天然具备双向情感属性。除了显式的正向偏好，还存在大量高信息量的负向反馈，既包括差评、主动屏蔽、标记“不感兴趣”等显式负向行为，也涵盖曝光未点击、内容快速划走、长视频短时间跳出等隐式负向信号。这类负向反馈直接反映了用户的厌恶偏好与兴趣边界，是缩小推荐候选空间、过滤无效内容、提升推荐精准度的核心依据，但传统无符号图推荐模型忽略了负向交互的建模价值，无法刻画用户完整的偏好画像。为了对用户-物品间的双向交互行为进行数学层面的精准建模，符号图（Signed Graph）理论被引入推荐系统领域，成为处理双向交互信号的核心理论框架。带符号的用户-物品二部图可形式化定义为公式 2-13：

$$G=(V, E^+, E^-) \quad (2-13)$$

其中 $V = U \cup I$ 为用户与物品的节点集合， E^+ 表示代表正向偏好的正边集合， E^- 表示代表负向厌恶的负边集合。

无符号正向交互图与带符号双向交互图的核心结构差异如图 2-2 所示。符号图推荐的核心挑战，在于如何有效挖掘负向边蕴含的用户厌恶偏好信息，同时避免负向交互对用户偏好表示的混淆，这也是当前图推荐领域的前沿研究热点。




图 2-2 无符号正向交互图与带符号双向交互图对比

然而，将主流的图神经网络直接应用于包含负向边的符号图时，会遭遇极大的理论阻碍。这源于图神经网络在底层设计上极其依赖一个不可妥协的图论基石——同质性假设。同质性假设源于社会学中的“物以类聚，人以群分”原理。在图机器学习语境下，它假设“图中通过边相连的两个节点，在隐空间中应当具有相似的特征、语义或标签”。从信号处理的视角来看，传统图神经网络中的邻域聚合机制，本质上是一种作用于图谱域的低通

滤波器。每一次消息传递，目标节点都会吸收并平均其邻居节点的特征。以拉普拉斯平滑（Laplacian Smoothing）的矩阵形式为例，如公式 2-14 所示：

$$\mathbf{H}^{(k)} = (\mathbf{I} - \alpha \tilde{\mathbf{L}}) \mathbf{H}^{(k-1)} \quad (2-14)$$

其中， $\tilde{\mathbf{L}}$ 为归一化图拉普拉斯矩阵， α 为平滑系数。经过多层传播，这种平滑机制会不可逆地拉近连通节点在特征空间中的距离。

经过多次迭代，这种平滑机制会强行拉近连通节点在向量空间中的欧氏距离或余弦距离。对于正向交互图 $\mathbf{E}^+$ 而言，同质性假设完美成立，用户购买了某个物品，说明用户画像与物品属性高度匹配，图卷积的平滑操作恰好促进了这种协同信号的无损注入。但是，负向交互 $\mathbf{E}^-$ 在严格意义上具有强烈的“异质性”，它与图神经网络的同质性前提不匹配。

如果用户 u 对物品 i 产生了负向反馈，两者的底层语义特征是相互排斥的。如果此时在负向边上盲目执行图卷积的聚合操作，模型会将用户与其厌恶的物品特征进行混合平均，等同于混淆了用户的真实偏好表示。

传统社交网络中的结构平衡理论（Structural Balance Theory）认为“敌人的敌人是朋友”，但在极度稀疏且语义复杂的推荐系统中，这一逻辑常常失效。例如，一个用户可能同时讨厌“极度惊悚的恐怖片”和“过于甜腻的爱情片”，这两类物品在图拓扑上通过该用户的负向节点产生了高阶连通。如果使用传统的多跳消息传递，图网络会将这两类在属性上不相同的物品特征错误地融合在一起，导致整个隐特征空间发生严重的特征表示混淆。

综上所述，图神经网络的邻域聚合机制与负向反馈的异质性之间存在着不可调和的理论冲突。这种底层物理机制的错位表明：在处理带符号二部图时，可以对正向反馈和负向反馈进行分别处理。对于符合同质性假设的正向图，应当继续发挥 GNN 强大的结构特征提取优势。而对于高度异质的负向图，则必须摒弃依赖拓扑连通性的消息传递范式，转而探索能够实现独立非线性映射、避免邻居特征错误混合的纯节点级表征学习方案。这一基于同质性理论的深刻反思，为构建具备鲁棒抗噪能力的下一代符号图推荐系统指明了关键的演进方向。

2.4 对比学习

在协同过滤和图神经网络推荐模型中，由于真实业务场景下的长尾分布特性，用户与物品的交互数据往往呈现出极度稀疏的状态。冷门物品和低活跃用户由于缺乏足够的连通边，在图卷积的消息传递过程中难以获取高质量的协同信号，从而极易导致深层网络陷入“过平滑”困境，最终严重制约推荐系统的泛化性能。为了突破这一标注数据稀缺的瓶颈，

自监督学习(Self-Supervised Learning, SSL),特别是图对比学习(Graph Contrastive Learning, GCL),被广泛引入现代推荐系统的理论架构中。

2.4.1 对比学习基础

对比学习的核心在于通过比较进行学习,其不依赖于外部的人工标注标签,而是直接从数据本身提取自监督的训练信号。在图表示学习范式中,对比学习旨在最大化同一节点在不同增强视图下的互信息,同时最小化不同节点之间的相似度。

具体而言,给定一个原始图 G ,对比学习框架首先通过某种数据增强算子 $\mathcal{T}(\cdot)$ 生成两个不同的图视图 G' 和 G'' 。对于图中的任意节点 v ,其在两个视图对应的隐层表征分别记为 $\mathbf{h}_v$ 和 $\mathbf{h}_{v''}$ 。在构建学习目标时,对比学习遵循实例级判别原则,将同一个节点 v 在不同视图下的表征对 $(\mathbf{h}_v, \mathbf{h}_{v''})$ 视为正样本对,而将节点 v 在某一个视图下的表征与图中其他任意节点 u 的表征构成的对 $(\mathbf{h}_v, \mathbf{h}_{u''})$ 视为负样本对。

为了在隐空间中拉近正样本对的距离并推开负样本对,推荐系统领域最广泛采用的优化目标是 InfoNCE 损失函数。基于图节点的 InfoNCE 损失可形式化定义为公式 2-15:

$$\mathcal{L}_{cl} = - \sum_{v \in V} \log \frac{\exp(\text{sim}(\mathbf{h}_v, \mathbf{h}_{v''})/\tau)}{\sum_{u \in V} \exp(\text{sim}(\mathbf{h}_v, \mathbf{h}_{u''})/\tau)} \quad (2-15)$$

其中, $\text{sim}(\cdot, \cdot)$ 是用于衡量两个向量在隐空间中接近程度的相似度度量函数,通常采用余弦相似度(Cosine Similarity),即 $\text{sim}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$ 。 τ 是一个被称为温度系数(Temperature Hyper-parameter)的超参数,用于控制模型对困难负样本的惩罚力度。通过最小化 $\mathcal{L}_{cl}$,模型能够在极度稀疏的原始监督信号之外,获得海量额外的自监督梯度,显著增强节点表征的鲁棒性与区分度。

2.4.2 推荐系统中的图对比学习

在推荐系统中,对比学习被用于缓解数据稀疏性与冷启动问题,例如通过对比用户历史行为序列与候选物品的嵌入,挖掘隐式偏好,或利用用户-物品交互图的对比增强,提升长尾物品的曝光率。在将图对比学习应用于推荐系统时,决定模型性能上限的核心在于数据增强策略的设计。早期的经典图对比推荐架构(如 SGL)主要依赖于拓扑结构层面的启发式增强,例如通过随机的节点丢弃(Node Dropout)、边丢弃(Edge Dropout)或随机游走来遮蔽部分交互信息。尽管这类结构级增强有效缓解了过平滑,但它们不仅破坏了图结构原本就脆弱的协同连通性,且在每一轮训练中动态重建拉普拉斯矩阵的计算开销极大。

为了克服拓扑增强的高昂代价与结构破坏，SimGCL 提出放弃图结构层面的扰动，提出在连续的特征嵌入空间中直接进行隐式增强。具体做法是向节点的原始表征 $\mathbf{h}_v$ 中直接注入均匀分布的随机噪声向量 Δ ，以生成增强视图，具体过程如公式 2-16 所示：

$$\mathbf{h}_{v'} = \mathbf{h}_v + \Delta, \Delta \sim \mathcal{U}(-\epsilon, \epsilon) \quad (2-16)$$

其中， ϵ 控制了噪声的强度范围。这种特征级增强在保持图结构完整的同时，以极低的计算成本实现了数据多样性的提升。

然而，随着这一机制在复杂工业推荐场景中的深度应用，其底层的理论隐患逐渐暴露。在纯粹的协同过滤隐空间中，一个多维表征向量的方向严格代表了用户对某一特定品类或语义的偏好象限。现有的特征增强策略通常采用无约束的各向同性噪声或均匀噪声，这种随机注入的 Δ 向量极具盲目性。如果在隐空间中施加了一个跨越原点的反向大尺度噪声，会导致增强后的特征向量 $\mathbf{h}_{v'}$ 与原始向量 $\mathbf{h}_v$ 处于完全不同的超空间象限中。无限制的随机扰动容易偏离节点的原始语义，引发语义漂移。若将这类漂移严重的增强视图当作自监督学习的正样本，InfoNCE 损失会迫使模型同时学习两个相互冲突的分布，反而让特征空间变得更加混乱。

关键在于，如何在追求互信息最大化的同时，对注入的噪声施加足够的方向性约束，使增强视图与原始节点在语义上保持一致。基于这一考虑，本文采用对比学习与符号网络相结合的跨视图对比策略，避免使用可能破坏图结构的传统增强操作。

2.5 排序学习与推荐优化目标

在推荐系统中，模型的优化目标直接影响最终的推荐效果。与传统分类或回归任务不同，推荐系统通常更加关注物品的排序结果，而不是单个预测值的准确性。因此，研究者提出基于排序学习的优化方法，通过直接优化推荐列表的排序质量，使模型能够更好地满足实际应用需求。

根据优化目标的不同，排序学习方法通常可以分为 Pointwise、Pairwise 和 Listwise 三类。Pointwise 方法将推荐问题转化为独立的预测任务，对每个用户-物品交互单独计算损失，典型方法包括基于均方误差或交叉熵的优化目标。这类方法实现简单，但由于忽略了物品之间的相对顺序关系，在推荐任务中的表现通常不如排序优化方法。Pairwise 方法通过比较正样本与负样本的预测得分，直接优化物品之间的相对顺序，从而更符合推荐系统的实际需求。Listwise 方法则以整个推荐列表为优化对象，通过直接优化排序指标来提升推荐质量，但通常计算复杂度较高，在大规模推荐任务中应用较少。

在图推荐模型中，Pairwise 排序学习被广泛采用，其中最常用的方法是 BPR，通过约束模型对正样本的预测得分高于负样本，从而提升推荐列表的排序性能，其一般形式可以表示为公式 2-17：

$$\mathcal{L}_{BPR} = - \sum_{(u,i,j)} \log \sigma(\hat{y}_{ui} - \hat{y}_{uj}) + \lambda \|\Theta\|^2 \quad (2-17)$$

其中，i 表示用户已交互物品，j 表示未交互物品， $\sigma(\cdot)$ 为 Sigmoid 函数用于将得分差值映射至概率空间， λ 为防止模型过拟合的正则化系数。 Θ 涵盖了模型中所有的可学习嵌入参数。

随着自监督学习在推荐领域的兴起，研究者发现仅依赖稀疏的监督信号进行 BPR 优化，容易导致模型陷入局部最优，且极易放大流行度偏差。因此，在主任务排序损失之外引入辅助优化目标成为提升表征鲁棒性的标准范式。其中，前文所述的基于 InfoNCE 的对比学习损失 $\mathcal{L}_{cl}$ 被广泛作为正则化项引入。在联合优化过程中，对比损失通过约束节点在多视图间的一致性，促使隐空间分布更加均匀（Uniformity），有效提高了模型对稀疏交互和噪声数据的抵抗能力。

此外，为了进一步提升模型的排序一致性与泛化潜能，知识蒸馏（Knowledge Distillation）也被引入推荐系统中，用于提升模型的排序一致性与泛化能力。知识蒸馏最早由 Hinton 等人^[67]提出，其核心思想是通过教师-学生框架，将复杂模型学习到的知识迁移到结构更简单的模型中。在推荐系统中，He 等人^[68]在 Ranking Distillation 工作中首次将蒸馏思想应用于 Top-N 推荐任务，通过让学生模型学习教师模型生成的排序概率分布，使轻量级模型能够保持与教师模型一致的排序结构，从而提高推荐性能。

在排序蒸馏框架中，给定用户 u 、正样本项目 i 以及 K 个负样本 $\{j_1, j_2, \dots, j_K\}$ ，可以构建一个候选列表 $R_u = [i, j_1, j_2, \dots, j_K]$ 。为了将模型的离散评分转化为列表上的概率分布，排序蒸馏引入了带有温度缩放（Temperature Scaling）的 Softmax 函数。学生模型 S 和教师模型 T 对于列表内第 k 个物品的偏好概率分布定义为公式 2-18 和 2-19 所示：

$$P_u^S[k] = \frac{\exp(s_{uk}^S/T)}{\sum_{k'=0}^K \exp(s_{uk'}^S/T)} \quad (2-18)$$

$$P_u^T[k] = \frac{\exp(s_{uk}^T/T)}{\sum_{k'=0}^K \exp(s_{uk'}^T/T)} \quad (2-19)$$

其中 s_{uk}^S 和 s_{uk}^T 分别为学生和教师模型输出的预测评分（通常为嵌入向量的内积）， $T > 1$ 是温度参数，用于软化概率分布，使学生模型不仅关注排序第一的物品，也能学习到次优物

品之间的相对顺序关系。

通过计算学生概率分布与教师概率分布之间的 KL 散度，可以构建列表级排序蒸馏损失 $\mathcal{L}_{RD}$ ，迫使学生模型的输出在全局分布上逼近教师模型。综合来看，现代图推荐模型通常采用多目标联合优化策略，同时优化排序损失、对比学习损失以及蒸馏损失，以获得更加稳定且具有泛化能力的用户表示与物品表示。

2.6 本章小结

本章围绕动态图推荐模型的研究需求，对相关理论基础与关键技术进行了总结。首先介绍了推荐系统与图神经网络的基本原理，并分析了图表示学习在建模用户-物品高阶关系方面的优势。在此基础上，进一步梳理了动态图建模方法及时间信息在推荐任务中的作用，说明了传统静态图推荐模型在刻画用户兴趣演化过程方面的不足。随后，本章重点介绍了推荐系统中的排序学习方法以及常用的优化策略，为后续第三章和第四章提出 TDGRec 动态增强框架与 TDGRec-SR 符号感知排序算法提供了数学支撑与理论依据。

3 基于多尺度时序融合动态感知的图推荐算法

3.1 研究动机

基于用户历史行为的协同过滤算法是推荐系统的重要范式，通过建模用户与项目之间的交互关系，推断用户潜在的兴趣偏好。近年来，图神经网络在推荐系统领域取得了显著进展，大量研究将图神经网络引入协同过滤框架，通过将用户-项目交互建模为二部图结构，充分利用图结构中的高阶邻域信息，借助多层特征聚合与信息传播机制，显著提升了推荐性能。

然而，现有基于图神经网络的推荐方法大多建立在静态图结构之上，默认历史交互具有相同重要性，忽视了用户兴趣随时间动态演化这一关键特性。用户兴趣通常兼具长期稳定性与短期动态性，静态图结构虽能有效建模全局协同信号，却难以刻画兴趣漂移现象；而完全采用动态图结构又会导致模型复杂度急剧上升，训练成本高，且可能破坏长期协同关系的稳定表达。尽管已有研究尝试在推荐中引入时间信息，如通过时间衰减加权边权重或在序列模型中捕捉近期行为依赖，但仍存在以下问题：一方面，部分方法仅将时间作为辅助特征输入，未从根本上改变图传播过程；另一方面，现有时间感知图推荐方法大多采用单一时间衰减策略，难以精准解耦用户的多粒度兴趣演化模式，且在传播层面缺乏动静协同的融合机制，无法兼顾长期偏好保持与短期兴趣响应。

为解决上述问题，本文提出一种多尺度时序融合动态感知的图推荐算法 TDGRec。该方法在保持原始用户-物品二分图结构的基础上，构建时间加权邻接矩阵，引入多尺度混合指数时序核函数，通过融合不同衰减速率，实现对用户长短期兴趣的精细化建模。同时，保留静态拓扑结构以维持稳定的全局协同信号，通过动静融合的信息传播机制，实现时间动态与图结构的高效协同建模，在提升推荐准确性的同时，有效控制模型复杂度。

3.2 模型设计与描述

在 TDGRec 模型中，将多尺度连续时间建模与动静拓扑融合机制紧密结合，其核心优势在于不仅能够打破传统 GNN 的静态时序盲区，精准解耦并捕获用户极易漂移的短期兴趣与长久稳定的历史偏好；同时，通过保留静态拓扑连通性先验，有效化解了动态加权图在稀疏数据集上极易引发的“孤岛效应”。此外，模型无关的通用传播框架极大降低了算法的计算复杂度，使其能够轻易扩展至大型工业级推荐数据集。TDGRec 的核心前向传播与优化流程如算法 3-1 所示。

算法 3-1 TDGRec 模型伪代码

```

Input:  $G=(U,I,E),t,\lambda_s,\lambda_l,\alpha,\beta,L$ 

Output:  $\mathbf{E}^*$ 

1:      Initialization:  $\Theta \leftarrow \text{random initialization}, \mathbf{E}^{(0)}$ 
2:       $T_{\text{norm}} \leftarrow \max(t_{\text{curr}} - t_{ui})$ 
3:      for  $(u,i) \in E$  do
4:           $\Delta \tilde{t}_{ui} \leftarrow (t_{\text{curr}} - t_{ui}) / T_{\text{norm}}$ 
5:           $w_{ui} \leftarrow \alpha e^{-\lambda_s \Delta \tilde{t}_{ui}} + (1-\alpha) e^{-\lambda_l \Delta \tilde{t}_{ui}}$ 
6:      end for
7:       $\tilde{\mathbf{A}}_{\text{dyn}} \leftarrow \text{RowNormalize}([w_{ui}])$ 
8:       $\tilde{\mathbf{A}}_{\text{static}} \leftarrow \mathbf{D}^{-\frac{1}{2}} \mathbf{A} \mathbf{D}^{-\frac{1}{2}}$ 
9:      while not converged do
10:         for  $l=0$  to  $L-1$  do
11:              $\mathbf{E}^{(l+1)} \leftarrow \hat{\mathbf{A}} \mathbf{E}^{(l)} \mathbf{W}^{(l)}$ 
12:         end for
13:         
$$\mathbf{E}^* = \frac{1}{L+1} \sum_{l=0}^L \mathbf{E}^{(l)}$$

14:          $L_{\text{T-BPR}} \leftarrow \text{Loss}_{\text{T-BPR}}(\mathbf{E}^*, \{w_{ui}\})$ 
15:          $\Theta \leftarrow \text{Adam}(\nabla_{\Theta} L_{\text{T-BPR}})$ 
16:     end while
17:     return  $\mathbf{E}^*$ 

```

具体来说，本文提出的 TDGRec 模型主要由四个紧密耦合的核心模块构成，其整体架构如图 3-1 所示。

时间加权图构建模块：该模块以原始用户-物品交互数据为输入，包括用户 ID、物品 ID 以及对应的时间戳信息。通过计算交互时间与当前时间之间的间隔，为每条边构建时间衰减权重，为克服单一时间衰减函数难以同时刻画短期兴趣变化与长期稳定偏好的问题，引入双尺度混合指数核函数，精细化量化每一次历史交互在当前决策中的时间置信度权重，生成时间加权邻接矩阵。

动静融合表示模块：该模块以时间加权邻接矩阵与静态邻接矩阵为输入，同时结合初

始用户与物品嵌入表示。在每一层传播过程中，模型分别基于静态结构与时间结构进行信息聚合，并通过融合系数对两类传播结果进行加权整合。通过这种动静融合策略，模型能够在嵌入更新过程中同时保留长期稳定的协同关系与短期动态兴趣信号。

图神经网络传播模块：在获得融合传播矩阵后，模型在该图结构上执行多层图神经网络传播过程。首先初始化用户和物品节点的嵌入表示，然后通过多层邻域信息传播逐步更新节点表示，经过 L 层传播后，通过层间嵌入融合策略整合不同阶邻域信息，得到最终的用户与物品嵌入表示。

时间感知排序优化模块：该模块以动静融合传播得到的最终嵌入表示为输入，通过内积函数计算用户-物品之间的亲和力分数。为了优化推荐排序效果，模型采用基于成对比较的排序损失函数，对正负样本之间的相对偏好关系进行约束。




图 3-1 TDGRec 模型架构

3.2.1 时间加权图构建模块

在推荐场景中，核心输入为用户-物品交互二部图 $G = (U, I, E)$ 和时序交互信息，其中 U 表示用户集合（含 M 个用户）， I 表示物品（含 N 个物品），而用户与项目之间交互边的集合则用 E 表示。每条交互边 $(u, i) \in E$ 均对应唯一的交互时刻 t_{ui} ，用于刻画用户与物品交互的时序关系，用户与项目之间的交互矩阵用 R 表示。同时，为每个用户和物品初始化低维嵌入向量，用户 u 的初始嵌入为 $e_u^{(0)} \in R^d$ ，物品 i 的初始嵌入为 $e_i^{(0)} \in R^d$ ，所有节点的初始嵌入构成嵌入矩阵 $E^{(0)} = [e_{u_1}^{(0)}, \dots, e_{u_M}^{(0)}, e_{i_1}^{(0)}, \dots, e_{i_N}^{(0)}]^T$ 。

为刻画兴趣随时间变化的规律，引入时间衰减函数对交互边进行重加权。为解决绝对时间尺度的影响，确保后续时序衰减函数的稳定性，本文采用用户级平均交互间隔进行时间归一化。首先计算每个用户的平均交互时间间隔，再取所有用户的平均值作为全局归一化常数 T_{norm} ，定义用户 u 与物品 i 的相对时间间隔为 Δt_{ui} ，具体公式如 3-1 和 3-2 所示：

$$T_{norm} = \frac{1}{|U|} \sum_{u \in U} \frac{1}{|S_u| - 1} \sum_{k=2}^{|S_u|} (t_{u,k} - t_{u,k-1}) \quad (3-1)$$

$$\Delta t_{ui} = \frac{t_{max} - t_{ui}}{T_{norm}} \quad (3-2)$$

其中 S_u 为用户 u 按时间排序的交互序列， $t_{u,k}$ 为用户 u 第 k 次交互的时间戳。该定义避免了原全局平均交互年龄方法对长期历史数据的过度平滑，能够更准确地反映不同用户的兴趣演化速率。

为了精确捕获异质化的兴趣漂移，设计了由两个具备不同半衰期的指数核函数线性组合而成的混合衰减函数。引入尺度平衡系数 $\alpha \in [0,1]$ 用于动态调节长短期兴趣的贡献比例，定义交互边 (u, i) 原始时序权重 w_{ui} 的计算表达式如公式 3-3：

$$w_{ui} = \alpha \cdot e^{-\lambda_{short} \cdot \Delta t_{ui}} + (1-\alpha) \cdot e^{-\lambda_{long} \cdot \Delta t_{ui}} \quad (3-3)$$

其中， λ_{short} 为短期衰减率，核心作用是快速过滤陈旧的短期交互，聚焦用户近期兴趣，避免过时短期偏好干扰模型判断； λ_{long} 为长期衰减率，用来缓慢衰减长期交互，保留用户稳定偏好，避免丢失核心兴趣特征； α 为权重贡献系数，确保长/短期兴趣的贡献平衡。

基于上述时间权重，构建时间加权邻接矩阵如公式 3-4 所示：

$$A_{dyn} = \begin{cases} w_{ui}, & (u, i) \in E \\ 0, & (u, i) \notin E \end{cases} \quad (3-4)$$

3.2.2 动静融合表示模块

针对动态图在时序权重衰减过程中部分历史交互边的权重可能趋近于零引发的图拓扑稀疏化与“孤岛效应”问题，提出了“静态拓扑流+动态时序流”的双流自适应融合策略。通过在谱图空间内对静态连通性先验与动态时序注意力进行线性组合，构建出兼具结构稳定性和时序敏锐度的增强传播矩阵。该策略既能依托静态流保障 GNN 聚合时的全局信息传播效率，又能依托动态流引导模型聚焦用户近期的核心意图。本模块的具体实现分为以下三个步骤：

(1) 静态拓扑流构建

静态拓扑流基于原始用户-物品交互二部图构建，核心为静态邻接矩阵 A_{static} 及其对称归一化拉普拉斯矩阵 $\tilde{A}_{\text{static}}$ ，用于保留原始图结构的连通性，避免动态时序流过度衰减导致的图结构断裂，静态邻接矩阵 $A_{\text{static}} \in \mathbb{R}^{(M+N) \times (M+N)}$ 为二值矩阵，其元素定义如公式 3-5 所示：

$$A_{\text{static}} = \begin{cases} 1, & (u, i) \in E \\ 0, & (u, i) \notin E \end{cases} \quad (3-5)$$

为缓解图卷积过程中的尺度偏差问题，避免高维节点度差异导致的聚合偏差，对 A_{static} 进行标准的对称归一化处理，得到静态归一化传播矩阵如公式 3-6 所示：

$$\tilde{A}_{\text{static}} = D_{\text{static}}^{-1/2} A_{\text{static}} D_{\text{static}}^{-1/2} \quad (3-6)$$

其中， D_{static} 为静态二部图的对角度矩阵，其对角元素 $D_{ii} = \sum_j A_{ij}$ 为节点在原始图中的度数，对称归一化确保了信息在图上传播时特征方差的稳定性。

(2) 动态时序流构建

动态时序流基于多尺度时序衰减模块输出的动态时序权重矩阵 A_{dyn} 构建动态加权邻接矩阵，并完成归一化处理，用于注入时序动态信息，聚焦用户近期交互，动态加权邻接矩阵 $A_{\text{dyn}} \in \mathbb{R}^{(M+N) \times (M+N)}$ 为加权矩阵，与静态邻接矩阵维度完全匹配，为保证动态时序流与静态拓扑流的可融合性，对 A_{dyn} 进行对称归一化，得到动态归一化传播矩阵如公式 3-7 所示：

$$\tilde{A}_{\text{dyn}} = D_{\text{dyn}}^{-1/2} W_{\text{dyn}} D_{\text{dyn}}^{-1/2} \quad (3-7)$$

其中 D_{dyn} 为动态加权重度矩阵，其对角元素 $D_{ii} = \sum_j A_{ij}$ ，计算逻辑与静态度矩阵保持一致，确保两类传播矩阵的尺度统一。

(3) 混合图自适应融合策略

为在引入时序信息的同时保持图结构的连通性，平衡静态拓扑与动态时序的贡献，采用线性加权融合策略构建最终的传播矩阵，将静态拓扑的结构先验与动态时序的注意力修正相结合，公式如 3-8 所示：

$$\tilde{A}_{\text{final}} = \text{RowNormalize}((1 - \beta) \cdot \tilde{A}_{\text{static}} + \beta \cdot \tilde{A}_{\text{dyn}}) \quad (3-8)$$

其中融合系数 $\beta \in [0, 1]$ ，用于平衡静态结构和动态时序的贡献，其取值逻辑如下， β 越大，模型越关注近期的时序交互信息，适合用户偏好漂移较快的场景； β 越小，模型越依赖原

始的图结构连通性，适合用户偏好较稳定的场景。

本模块的核心输出为动静融合统一传播矩阵 $\tilde{\mathbf{A}}_{\text{final}}$ ，该传播矩阵在保留原始图结构的协同过滤信息的同时，引入时间动态信息，实现对用户兴趣变化的有效建模。

3.2.3 图神经网络传播模块

本模块是实现 TDGRec “模型无关、即插即用”特性的核心。针对现有时序推荐模型与特定 GNN 架构深度绑定的工程痛点，通过泛化图网络传播方程将上一节输出的动静融合传播矩阵 $\tilde{\mathbf{A}}_{\text{final}}$ 适配至主流 GNN 基座中。同时，针对模型参数的更新过程，提出了时间感知排序优化目标，实现了端到端的时序动态增强。

(1) 泛化 GNN 传播过程

对于任意基于空间域或者谱域的图神经网络（转导式的 LightGCN、GCN，或归纳式的 GraphSAGE、GAT），其第 1 层的特征传播与聚合过程可被统一抽象并泛化为如下矩阵运算如公式 3-9 所示：

$$\mathbf{E}^{(l+1)} = \text{AGGREGATE}(\tilde{\mathbf{A}}_{\text{final}} \cdot \mathbf{E}^{(l)} \cdot \mathbf{W}^{(l)}) \quad (3-9)$$

其中， $\tilde{\mathbf{A}}_{\text{final}}$ 为动静融合传播矩阵， $\mathbf{E}^{(l)}$ 为第 l 层的节点嵌入矩阵，初始值为 $\mathbf{E}^{(0)}$ 。

传播公式中的可学习权重矩阵 $\mathbf{W}^{(l)}$ 采用自适应适配逻辑，若基座模型为 LightGCN 等无特征变换的模型，则 $\mathbf{W}^{(l)} = \mathbf{I}$ （单位矩阵），直接复用 LightGCN 的加权求和逻辑，若基座模型为 GCN、GAT 等有特征变换的模型，则 $\mathbf{W}^{(l)}$ 为模型自带的可学习权重，保留其原有激活函数与聚合逻辑。

(2) 多阶动态增强嵌入聚合

用户与物品的初始嵌入矩阵为 $\mathbf{E}^{(0)} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times d}$ ，第 1 层图传播过如公式 3-10 所示：

$$\mathbf{E}^{(l+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(l)} \quad (3-10)$$

经过 L 层传播后，融合各层的嵌入特征生成节点的动态增强嵌入，充分利用多阶邻居的时序结构信息，避免单一层嵌入的局限性，公式如 3-11 所示：

$$\mathbf{e}_u^* = \sum_{l=0}^L \beta_l \cdot \mathbf{e}_u^{(l)}, \mathbf{e}_i^* = \sum_{l=0}^L \beta_l \cdot \mathbf{e}_i^{(l)} \quad (3-11)$$

其中 β_l 为第 l 层嵌入的权重系数，取等权系数 $\beta_l = 1/(L+1)$ ，简化模型结构，降低调参难度； $\mathbf{e}_u^*$ 和 $\mathbf{e}_i^*$ 分别为用户 u 和物品 i 的最终动态增强嵌入，融合了多阶邻居信息与时序动态特征，更精准刻画用户偏好与物品特性。

3.2.4 时间感知排序优化

在获得用户与物品嵌入表示后，通过用户和物品动态增强嵌入的内积，计算用户 u 对物品 i 的预测评分，来量化用户对未交互物品的偏好匹配程度如公式 3-12 所示：

$$\hat{y}_{ui} = \mathbf{e}_u^{*T} \cdot \mathbf{e}_i^* \quad (3-12)$$

预测评分 $\hat{y}_{ui}$ 越高，表明用户 u 对物品 i 的兴趣越大，通过对预测评分排序生成 Top-N 推荐列表，完成推荐任务。

传统隐式反馈推荐广泛采用贝叶斯个性化排序损失，其假设所有观测到的正样本具有相同的置信度。然而，用户的核心意图是随时间漂移的，近期的交互理应比陈旧的历史对当前参数优化具有更大的指导意义。基于贝叶斯最大后验估计的时序先验假设，本模块将公式 3-3 计算得出的每条边的连续时间权重 w_{ui} 升格为样本梯度惩罚项，直接注入对数似然估计中，正式推导出时间感知加权 BPR 损失（Time-aware BPR Loss）如公式 3-13 所示：

$$\mathcal{L}_{T-BPR} = - \sum_{(u,i,j) \in \mathcal{D}} w_{ui}(u,i) \cdot \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) \quad (3-13)$$

其中， $\mathcal{D} = \{(u,i,j) | (u,i) \in \mathcal{E}, (u,j) \notin \mathcal{E}\}$ 为训练三元组集合， i 为正样本， j 为随机采样的负样本， $\sigma(\cdot)$ 为 Sigmoid 函数。

在该机制下，近期交互（ w_{ui} 较大）将产生强烈的梯度信号，迫使网络权重优先拟合用户最新的兴趣转移；而远期交互的梯度贡献被平滑削弱，仅作为协同过滤的背景约束。结合 L_2 正则化防止过拟合，模型最终的端到端联合优化目标定义如公式 3-14 所示：

$$\mathcal{L}_{total} = \mathcal{L}_{T-BPR} + \lambda_{reg} \|\Theta\|_2^2 \quad (3-14)$$

其中 Θ 表示模型中所有可学习的嵌入矩阵参数， λ_{reg} 为正则化衰减系数。

3.3 实验设计

为了验证本文提出的 TDGRec 模型在推荐任务中的有效性，本节通过在多个公开数据集上的实验，对模型的推荐性能进行系统评估。实验主要包括数据集选择、评价指标设定、对比方法选取以及实验参数设置等内容。

3.3.1 实验设置

本实验在 Ubuntu 22.04 操作系统上实施，Python3.8 为开发语言，Pytorch1.13.1 深度学习工具作为开发框架。

(1) 数据集介绍

为了全面评估模型性能，本文选取了多个常用的公开推荐数据集进行实验，MovieLens-1M(ML-1M)、Amazon-Book 和 Yelp。这三个数据集在领域属性、数据规模以及图结构的稀疏程度上各具代表性，能够从多维度检验模型的时序捕获能力与结构稳定性。三个数据集的统计数据总结如表 3-1 所示。

表 3-1 数据集

Dataset	Users	Items	Interactions	Density
ML-1M	6040	3952	1000209	4.19%
Amazon-Books	35736	38121	1960674	0.14%
Yelp	41772	30037	2116215	0.16%

MovieLens-1M(ML-1M): 由 GroupLens 研究团队发布的经典电影推荐数据集。该数据集记录了用户对电影的评分行为及具体的时间戳。该数据集的特点是交互图极其稠密，用户兴趣随时间的演变周期相对较长，适合用于验证模型在稠密图下长短期兴趣解耦的有效性。

Amazon-Book: 选自庞大的亚马逊电商评论产品数据集。图书类目的商品更迭较快，用户的购买往往伴随着强烈的时效性与阶段性任务驱动。该数据集规模巨大且极其稀疏。

Yelp: 源自美国最大的点评网站，包含了用户对本地商家的签到与评分数据。此类本地生活服务具有极强的地理位置与时间周期依赖性，用户偏好随外部环境漂移明显，能够充分检验模型对短期动态兴趣的敏锐度。

在表 3-1 中，分别统计了三个数据集的用户数量，项目数量和用户与项目的交互次数。计算得到数据集密度。观察可知，Yelp 数据集中的交互次数远大于其他两个数据集，ML-1M 数据集拥有更加稠密的数据。

(2) 评价指标介绍

实验中主要关注 Top - k 推荐任务，评价指标选用了推荐系统中常用的 Recall@K 和 NDCG@K。

召回率: Recall@K 用于衡量推荐系统从海量候选集中成功检索出用户真实感兴趣物品的能力。它关注的是推荐的“覆盖率”，即测试集中的正样本有多少被包含在了推荐列表的前 K 位中。对于用户 u ，其 Recall@K 定义如公式 3-15 所示：

$$\text{Recall@K} = \frac{|\mathcal{R}_u \cap \mathcal{T}_u|}{|\mathcal{T}_u|} \quad (3-15)$$

其中, $\mathcal{R}_u$ 表示模型为用户 u 预测生成的 Top-K 推荐物品列表, $\mathcal{T}_u$ 表示用户 u 在测试集中实际交互的真实物品集合。Recall@K 的值介于 [0,1] 之间, 数值越大, 表明模型遗漏用户偏好的概率越低, 查全率越高。

归一化折损累计增益: NDCG@K 是一种用于评估推荐列表排序质量的指标。NDCG 与折损累计增益(DCG)和理想折损累计增益(IDCg)有着密切联系, 其结果是两者的比值。DCG 反映了用户对于位于推荐列表前面的项目的更高偏好, 其定义如公式 3-16 所示。

$$\text{DCG@K} = \sum_{i=1}^K \frac{2^{r_i} - 1}{\log_2(i + 1)} \quad (3-16)$$

其中, i 表示物品在推荐列表中的排序位置, r_i 表示第 i 个物品的相关性分数。在隐式反馈场景中, 若第 i 个物品属于测试集 $\mathcal{T}_u$, 则 $r_i = 1$, 否则 $r_i = 0$ 。

为了在不同用户之间进行公平比较, 需要通过理想情况下的最大增益 (IDCG) 进行归一化。IDCG@K 表示在理想排序下的 DCG 值。其 NDCG@K 定义如公式 3-17 所示:

$$\text{NDCG@K} = \frac{\text{DCG@K}}{\text{IDCG@K}} \quad (3-17)$$

NDCG@K 的值同样介于 [0,1] 之间。数值越大, 表明模型不仅成功预测了用户感兴趣的物品, 而且将这些物品精准地推送到了列表的显眼位置, 具有更好的全局排序能力。

3.3.2 对比算法

为了证明我们所提出的 TDGRec 模型在捕捉时序动态演化与维持图拓扑连通性方面的先进性, 我们将所提出的模型与以下 6 种代表性方法进行比较:

BPR-MF^[17]: 基于贝叶斯个性化排序的经典矩阵分解模型。该方法通过最大化正负样本对之间的后验概率差值来优化用户和物品的潜在特征向量, 有效解决隐式反馈场景下的排序问题, 是推荐系统领域评估模型性能的通用基准。

NeuMF^[69]: 作为另一种流行的基线模型, NeuMF 是一种神经 CF 模型, 它泛化了标准 MF, 并通过多层隐藏层生成用户和项目的嵌入向量。

NGCF^[4]: 基于图结构的协同过滤推荐框架。该模型在嵌入传播层中显式引入了特征变换矩阵与非线性激活函数, 通过堆叠多层图卷积网络来捕捉用户与物品之间的高阶连通性, 有效解决了传统协同过滤无法利用协作信号的问题。

LightGCN^[5]: 通过理论论证去除了 NGCF 中的特征变换与非线性激活, 仅保留最核心的邻域加权聚合操作, 在大幅降低计算复杂度的同时提升了推荐性能。

SASRec^[26]: 是基于 Transformer 架构的序列推荐方法。该模型通过 Self-Attention 赋予模型全序列视野, 能够自适应地捕捉长距离依赖关系并实现并行计算, 相较于传统 RNN 模型, 其在处理长序列依赖和稀疏数据时具有显著优势。

TGN^[33]: 连续时间动态图表示学习模型。该模型提出了一个通用的时间图神经网络框架, 通过引入记忆模块与时间编码机制, 将节点状态的更新与图拓扑结构的动态演化紧密结合, 能够有效处理高频交互事件流, 是连续时间动态图表示学习领域的标志性工作。

3.3.3 参数设置

为保证基线模型与本文提出算法对比的公平性, 在模型训练阶段, 将所有底层图推荐模型的用户与物品嵌入向量维度统一固定为 64, 采用 Adam 优化器进行端到端的梯度更新优化, 并使用 Xavier 均匀分布方法初始化所有的嵌入参数。模型的基础学习率默认设置为 0.001, 默认小批量大小设置为 1024, 在防止过拟合与网络深度设置方面, 正则化系数、早期停止和验证策略等其他部分与 LightGCN 保持一致。

3.4 实验结果与分析

3.4.1 模型对比分析

为验证本文 TDGRec 算法的推荐性能优越性, 在 ML-1M、Amazon-Book、Yelp 三个基准数据集上, 以 Recall@20 和 NDCG@20 为核心评价指标, 将本文算法与 7 类主流对比算法进行全面性能对比。所有算法均在相同实验环境、相同超参数设置下训练测试, 实验结果取 5 次独立实验的平均值, 确保结果的可靠性与公平性, 具体对比结果如下表 3-2 所示。

表 3-2 与其他模型的性能比较

Dataset	ML-1M		Amazon-Book		Yelp	
Methods	Recall@20	NDCG@20	Recall@20	NDCG@20	Recall@20	NDCG@20
BPR-MF	0.2015	0.1780	0.0195	0.0258	0.0385	0.0450
NeuMF	0.2088	0.1853	0.0223	0.0280	0.0410	0.0480
NGCF	0.2458	0.2213	0.0285	0.0361	0.0485	0.0560
LightGCN	0.2635	0.2395	0.0330	0.0435	0.0585	0.0685
SASRec	0.2550	0.2302	0.0305	0.0391	0.0540	0.0656
TGN	0.2669	0.2435	0.0342	0.0446	0.0604	0.0704
TDGRec	0.2688	0.2455	0.0351	0.0458	0.0612	0.0718

本文提出的 TDGRec 在所有数据集和评价指标上均取得了最佳的推荐性能，表明该模型在不同稀疏程度的数据环境下都具有稳定且优越的表现。在 Yelp 数据集上，相比于动态图建模的 TGN，TDGRec 在 NDCG@20 指标上提升约 2.3%。说明在推荐系统高度稀疏的交互环境中，仅依赖时间点过程刻画用户行为演化仍然存在一定局限。TDGRec 通过引入多尺度时间衰减机制，并融合动态图与静态图结构信息，不仅能够有效捕捉用户短期兴趣的快速变化，还能够保持用户长期偏好的稳定表示。

从整体趋势来看，引入时间动态信息的图推荐模型整体优于传统的静态图模型。动态图模型 TGN 和 TDGRec 在三个数据集上的性能优于 LightGCN。用户-物品交互图在真实推荐场景中的动态演化特性。静态图模型通常将所有历史交互视为等权信息，在邻域聚合过程中难以区分近期行为与陈旧行为的重要性，从而容易引入历史噪声。而动态建模机制能够通过时间衰减函数对不同时间的交互赋予不同权重，使模型更加关注近期行为信号，从而更准确地刻画用户兴趣的动态变化过程。

从模型类型角度来看，基于图神经网络的推荐方法整体优于纯序列推荐模型。尽管序列推荐模型 SASRec 利用自注意力机制能够有效捕捉用户行为序列中的时序依赖关系，并在一定程度上优于传统的协同过滤模型，但其整体性能仍然略低于图神经网络方法。这主要是因为序列模型通常仅将用户历史行为视为一维时间序列，而忽略了全局用户-物品二部图中所蕴含的丰富协同过滤信号，相比之下，图神经网络能够通过多层邻域传播有效挖掘高阶协同关系，从而提升推荐准确性。TDGRec 在此基础上进一步融合了图结构协同信息与时间演化建模机制，实现了高阶协同信号传播与用户兴趣动态演化建模的统一，从而在所有数据集上取得了最优的推荐性能。

从不同数据集的性能变化可以观察到，TDGRec 在稀疏度较高的数据集 Amazon-Book 上的性能提升更为明显。这说明在交互信息有限的情况下，引入时间动态信息能够有效增强用户行为信号的表达能力，从而缓解数据稀疏问题带来的推荐性能下降。TDGRec 通过联合建模用户兴趣的时间动态变化与图结构协同关系，能够更加全面地刻画用户偏好，从而在多个数据集上均取得显著优于现有方法的推荐效果。

3.4.2 消融实验分析

为了验证本文提出的 TDGRec 模型中各个时序与融合模块的具体贡献及有效性，我们在 Yelp、Amazon-Book 和 ML-1M 三个数据集上进行了控制变量的消融对比实验。我们将完整的 TDGRec 模型作为基准，分别移除核心的时序权重模块、多尺度机制以及全局静态

图，构建了以下三个变体：

w/o Temporal: 移除基于时间衰减的边权重计算机制，将所有用户-物品交互边视为等权重，退化为不考虑时间权重的动态图结构。

w/o Static: 丢弃长期的全局静态图，仅保留近期的动态交互子图进行消息传递，用以验证长期固有偏好对推荐精度的影响。

w/o Multi-Scale: 仅使用单一的时间衰减尺度，不进行长短期权重的自适应融合，用以验证多时间粒度建模的必要性。

各变体与完整模型在三个数据集上的对比实验结果如图 3-2 所示。




图 3-2 消融实验结果对比

首先，移除时间权重模块（w/o Temporal）会带来最大的性能下降。在三个数据集上，该变体均显著低于完整模型。在 ML-1M 数据集上，Recall@20 从 0.2688 下降至 0.2642，下降幅度约为 1.7%。这一现象表明时间信息在推荐系统中具有重要作用。如果不对用户交互进行时间加权，模型在邻域信息聚合时将无法区分近期行为与历史行为的重要性，从而引入过时交互噪声，降低推荐精度。移除静态图结构（w/o Static）同样会导致性能下降。在 Yelp 数据集上，Recall@20 下降约 2.8%。这说明仅依赖短期动态交互信息不足以全面刻画用户偏好。长期历史交互中包含的重要稳定兴趣模式对推荐任务仍然具有重要意义。TDGRec 通过融合动态交互图与全局静态图，有效兼顾了用户短期兴趣变化与长期偏好稳定性。移除多尺度时间建模机制（w/o Multi-Scale）也会带来一定程度的性能下降。在 Amazon-Book 数据集上，Recall@20 下降约 2.3%。这说明单一时间衰减尺度难以适应不同用户行为模式的时间动态特性。多尺度时间建模能够在不同时间粒度上刻画用户兴趣变化，使模型更加灵活地拟合复杂的兴趣演化过程。

消融实验结果表明 TDGRec 的三个核心模块均对最终推荐性能具有积极贡献，其中时间权重建模带来的性能提升最为显著，其次是动静图融合机制，而多尺度时间建模则进一步细化了时间动态建模能力。这些模块的协同作用共同提升了模型对用户兴趣演化过程的刻画能力，从而实现了更优的推荐效果。

3.4.3 模型通用性分析

为了验证本文提出的多尺度时序动静融合（Multi-scale Temporal Dynamic Fusion, MTDF）策略不仅适用于特定的网络架构，而是一个模型无关通用动态增强框架，本节选取四种具有代表性的图神经网络模型作为基座模型进行拓展实验——GCN、NGCF、GraphSAGE 以及 LightGCN。在实验过程中，我们保持各基座模型的网络结构、传播层数以及训练超参数不变，仅将原始的静态用户-物品二部图替换为由 MTDF 构建的时序动静融合图结构，从而评估 MTDF 对不同图神经网络架构的通用增强能力。具体而言，对于每个基座模型设置两组实验：

原始基座(Original)：使用原始的静态二部图邻接矩阵进行训练，保持模型原论文中的默认参数设置。

增强模型(+MTDF)：保持基座模型的网络架构与超参数不变，仅将输入的静态邻接矩阵替换为本文提出的 MTDF 时序动静融合矩阵。

从图 3-3 可以观察到，在 ML-1M 数据集上，引入 MTDF 后，四种基座模型的 Recall 指标平均提升约 2%，NDCG 指标平均提升约 2.5%。这表明，将时序信息与多尺度动态关系显式融入图结构，能够有效增强模型对用户兴趣演化轨迹的特征表达能力，从而在整体召回率与头部排序质量上取得双重增益。

对比不同基线模型可以观察到，LightGCN 模型在结合 MTDF 后的性能增益最为显著。其原因在于，LightGCN 为追求计算效率去除了特征变换与非线性激活函数，导致其自身对高阶时序动态信号的拟合能力相对受限。MTDF 策略在输入层面对时序特征的补充，有效弥补了该轻量级网络在动态信息捕捉上的结构性不足，这也进一步验证了 MTDF 在特征增强方面的有效性。

此外，尽管不同基座模型的网络层数与聚合机制存在差异，但 MTDF 策略为其带来的相对性能提升保持了一致性。这证明了 MTDF 模块在架构设计上具有良好的跨模型通用性。该模块独立于底层的图卷积传播算子，能够在不改变基座模型原有网络参数的前提下，以“即插即用”的方式优化输入图数据的底层表征。




图 3-3 TDGRec 模型通用性分析

3.4.4 稀疏度分析

为了研究冷启动场景下对推荐模型性能的影响，本节通过控制训练数据比例来构建不同稀疏程度的实验环境。具体而言，将原始数据集划分为 20%、40%、60% 和 80% 四种训练比例，其中 20% 表示极度稀疏场景，平均每个用户仅保留 3-5 次交互，而 80% 则接近完整数据训练。实验结果如表 3-3 所示。

从整体趋势来看，随着训练数据比例的逐步增加，各模型在三个数据集上的 Recall 和 NDCG 指标均呈现出稳定提升的趋势。这表明随着数据稀疏度的降低，模型能够获得更加充分的用户-物品交互信息，从而学习到更加准确的用户偏好表示，提高最终的推荐效果。该结果与推荐系统领域的普遍认知一致，即更丰富的交互数据能够帮助模型更全面地刻画用户兴趣和物品特征。

进一步比较不同模型的表现可以发现，在所有稀疏度设置下，TDGRec 始终取得最佳性能，其次为 TGN、LightGCN 和 NGCF，而传统的矩阵分解模型 BPR-MF 表现最弱。这

说明基于图结构的推荐模型能够更有效地利用用户-物品关系信息，而动态图模型通过引入时间演化关系进一步增强了表示能力。尤其是在数据较为稀疏的 20%和 40%场景下，TDGRec 相比 TGN 表现出更加明显的优势，这是因为 TGN 采用事件驱动的碎片化图结构，冷启动用户交互极少时无法有效更新节点记忆，形成节点孤岛，证明了当监督信号极度匮乏时，TDGRec 仍能通过全局图结构挖掘高阶协同信息，为交互极少的用户提供了有效的偏好表示。

表 3-3 稀疏度分析

Group	Dataset	ML-1M		Amazon-Book		Yelp	
	Method	Recall@20	NDCG@20	Recall@20	NDCG@20	Recall@20	NDCG@20
[0,20)	BPR-MF	0.1420	0.1250	0.0090	0.0115	0.0195	0.0235
	NGCF	0.1785	0.1560	0.0145	0.0185	0.0285	0.0325
	LightGCN	0.1950	0.1785	0.0175	0.0225	0.0345	0.0405
	TGN	0.1980	0.1810	0.0185	0.0240	0.0375	0.0425
	TDGRec	0.2150	0.1985	0.0225	0.0295	0.0420	0.0495
[20,40)	BPR-MF	0.1650	0.1450	0.0125	0.0165	0.0260	0.0305
	NGCF	0.2055	0.1820	0.0190	0.0245	0.0355	0.0410
	LightGCN	0.2220	0.2015	0.0235	0.0315	0.0435	0.0510
	TGN	0.2250	0.2050	0.0245	0.0325	0.0460	0.0535
	TDGRec	0.2360	0.2175	0.0275	0.0365	0.0495	0.0575
[40,60)	BPR-MF	0.1850	0.1625	0.0160	0.0210	0.0320	0.0375
	NGCF	0.2280	0.2045	0.0240	0.0305	0.0425	0.0490
	LightGCN	0.2450	0.2225	0.0285	0.0380	0.0515	0.0605
	TGN	0.2480	0.2255	0.0298	0.0392	0.0535	0.0625
	TDGRec	0.2540	0.2320	0.0315	0.0415	0.0560	0.0655
[60,80)	BPR-MF	0.2015	0.1780	0.0195	0.0258	0.0385	0.0450
	NGCF	0.2458	0.2213	0.0285	0.0360	0.0485	0.0560
	LightGCN	0.2635	0.2395	0.0330	0.0435	0.0585	0.0685
	TGN	0.2660	0.2420	0.0340	0.0445	0.0600	0.0700
	TDGRec	0.2688	0.2455	0.0351	0.0458	0.0612	0.0718

在 Amazon-Book 数据集整体指标相对较低，由于其用户-物品交互极为稀疏，使得模型难以学习到稳定的协同信号；相比之下，ML-1M 数据集由于交互更为密集，各模型均取得了更高的推荐性能。综合来看，上述实验结果验证了 TDGRec 在不同数据稀疏度条件下均具有良好的稳定性和鲁棒性，尤其在稀疏场景中能够有效提升推荐效果。

3.4.5 超参数分析

(1) 不同传播层数

为了研究图卷积网络深度对模型推荐性能的影响，并验证本文提出的动静融合策略在缓解“过平滑”问题上的有效性，本节在 Yelp 数据集上针对不同传播层数 ($L \in \{1,2,3,4,5\}$) 进行了对比实验。实验选取了 GCN、NGCF、GraphSAGE、LightGCN 四种经典基线与本文的 TDGRec 模型进行评估，具体结果如图 3-4 所示。




图 3-4 不同传播层数 L

从整体趋势来看，随着传播层数从 1 层增加到 3 层，各模型的推荐性能均呈现出明显提升，而当层数继续增加时，模型性能开始逐渐下降。说明适当增加传播层数能够帮助模型捕获更高阶的用户-物品协同关系，从而提升推荐效果。因为随着层数的增加，节点表示会出现过平滑问题，使不同节点的表示趋于一致，进而降低模型的判别能力。

随着传播层数从 3 层增加到 6 层，模型性能开始逐渐下降，但是 DGRec 的性能下降幅度远小于其他模型，在深层仍保持较高水平。表明本文提出的动静融合矩阵能够同时保留长期稳定的结构关系以及短期动态交互信息，使得高阶协同信号在多层传播过程中不会被快速稀释，有效缓解传统静态图模型在深层传播中的信息退化问题。

(2) 动静融合系数的 β 参数实验

动静图融合系数是控制拓扑连通性与时序时效性权衡的核心超参数。它决定了消息传递矩阵中“短期动态兴趣”与“长期固有偏好”的平衡权重。为了探究不同数据集的图拓扑稀疏度对该参数最佳取值的影响规律，本节在 ML-1M、Yelp 和 Amazon-Book 三个基准数据集上，控制 β 从 0.0 逐步递增至 1.0，步长设定为 0.2。为保证评估的直观性与准确性，选取推荐排序核心指标 NDCG@20 记录模型性能变化轨迹。实验结果如图 3-5 所示。




图 3-5 动静融合系数的 β 参数实验

实验结果表明，在所有数据集上，模型在 β 取值区间的两端均表现出明显的性能滑坡。这一对称的衰减现象揭示了用户行为决策的二元机制，单纯依赖近期动态图（ $\beta = 0$ ）会导致长尾节点失去结构化关联，产生严重的“孤岛效应”，使模型丧失对用户长期固有偏好的刻画能力；而完全摒弃时序动态图（ $\beta = 1$ ）则会引入海量的过期历史噪声，引发“过时平滑”，从而掩盖用户当下的真实意图。将两者进行合理比例的融合是突破性能瓶颈的必要条件。在交互极为稠密的 ML-1M 数据集中，模型在 $\beta = 0.4$ 处达到全局最优。说明在数据密集的场景下，近期动态事件信息完整，赋予“短期时序动态图”更高的权重，能够帮助模型更敏锐地捕捉用户的即时兴趣转移。在极度稀疏的 Amazon-Book 数据集中，最佳融合系数大幅右移至 $\beta = 0.7$ 。在稀疏的数据集中，近期动态交互边极其匮乏，过度依赖短期动态图会破坏图结构的全局连通性。

TDGRec 模型通过动静融合机制不仅有效抑制了过平滑现象，且展现出了极强的数据分布自适应能力。在实际工业应用中，对于高频交互场景应适当偏向动态侧，取值 0.3 ~ 0.5，而对于低频、长尾场景则必须提高静态融合比例，取值 0.6 ~ 0.8，以利用长期的结构连通性对抗数据稀疏性。

3.5 本章小结

本章围绕动态图推荐场景中用户行为随时间变化的问题，提出了一种基于多尺度时序融合的动态图推荐算法 TDGRec。首先，通过分析传统图推荐模型在处理动态交互时存在

的不足，指出现有方法在建模用户兴趣随时间演化方面仍存在对时间信息利用不足、动态图结构连通性下降以及模型难以同时刻画长期偏好与短期兴趣等问题。提出了利用多尺度时间建模与动静图融合策略来提升推荐模型对时序信息的刻画能力。对 TDGRec 模型的整体结构进行了系统设计。通过引入双指数时间衰减函数，对不同时间尺度下的用户-物品交互关系进行建模，并在此基础上构建动静融合的图结构，以同时保留稳定的全局协同关系与动态行为信息。该融合图结构可以作为通用输入应用于多种图神经网络推荐模型，从而在保持图结构连通性的同时增强模型对用户兴趣演化的表达能力。

在实验部分，本章基于多个真实推荐数据集对模型性能进行了系统评估，并与多种主流推荐方法进行了对比分析。实验结果表明，TDGRec 在不同数据集上均取得了稳定的性能提升。同时，通过模型通用性实验、数据稀疏性分析以及参数敏感性实验，进一步验证了该方法在不同图神经网络架构和不同数据密度场景下均具有较好的稳定性和鲁棒性。证明本章提出的 TDGRec 模型能够有效融合多尺度时序信息与静态协同关系，为后续进一步增强图推荐模型的表达能力奠定了基础。

4 基于符号感知的跨层对比学习推荐算法

4.1 研究动机

近年来，随着图神经网络的快速发展，基于图结构的推荐方法逐渐成为推荐系统研究的重要方向。通过将用户与物品之间的交互关系表示为二部图结构，图神经网络能够在图拓扑中传播信息，从而捕获用户与物品之间的高阶协同关系。相比传统协同过滤模型，图推荐模型能够更加全面地利用用户-物品关系网络中的结构信息，从而学习更加准确和鲁棒的节点表示。尤其是在以 LightGCN、NGCF 等为代表的图推荐模型提出之后，利用图卷积传播机制建模高阶协同信号已经成为当前推荐系统研究的重要范式，并在多个公开数据集上显著提升了推荐性能。

尽管图神经网络在推荐系统领域取得了显著进展，但现有研究仍然存在若干关键问题有待进一步解决。首先，大多数图推荐方法主要依赖用户与物品之间的正向交互信息，例如点击、购买或收藏等行为，而对负向反馈信息的建模相对不足。然而，在真实应用场景中，用户决策不仅受到“喜欢什么”的积极驱动，也会受到“讨厌什么”的显著约束。例如，用户对某些物品的低评分、短时间退出、快速滑过等行为，都能够反映用户的潜在厌恶偏好。与正向交互相比，负向交互往往具有更高的信息密度，可以更快速地缩小推荐候选空间。因此，如果忽略这些重要的负向信号，将会导致模型对用户偏好理解不充分，从而限制推荐性能的进一步提升。

现有图推荐方法在处理用户行为关系时，往往默认用户-物品交互关系具有静态一致性，即历史偏好可以长期代表用户兴趣。然而在实际应用环境中，用户兴趣往往具有明显的时序动态特征。用户在不同时间阶段可能呈现出不同的兴趣模式，例如“过去喜欢”与“当前喜欢”之间往往存在显著差异。如果忽略这种时间演化特征，模型在构建用户表示时就可能引入过时的历史信息，从而降低推荐结果的准确性。传统的符号图建模方法在处理正向关系时通常将其视为固定结构，缺乏对交互时间演化过程的细粒度刻画，这在一定程度上限制了模型对复杂行为模式的表达能力。

在深层图神经网络的特征传播过程中，随着传播层数不断增加，节点表示容易出现过平滑问题，即不同节点的特征逐渐趋同，导致模型难以保持节点之间的差异性。特别是在推荐系统中，用户-物品交互数据通常具有高度稀疏的特点，稀疏结构本身就包含大量噪声与不确定信息。当深层图卷积传播叠加在稀疏数据结构之上时，噪声信息可能被不断扩散，

从而对模型训练造成负面影响，最终降低节点表示的判别能力，影响推荐系统的整体鲁棒性。

针对上述问题，本文在第三章提出的 TDGRec 动态图推荐模型基础上，进一步提出一种融合正负符号关系建模与跨层对比学习的动态图推荐方法 TDGRec-SR。该方法旨在同时刻画用户行为中的正向偏好与负向厌恶信息，并结合跨层对比学习缓解过度平滑。

具体而言，TDGRec-SR 构建了一种异构双分支编码框架。在正向交互建模方面，模型继承并扩展了第三章提出的多尺度时序动态图推荐网络 TDGRec，通过多尺度时间权重与动静图融合机制对用户兴趣演化进行建模，从而有效捕捉用户长期偏好与短期兴趣之间的动态变化。而在负向交互建模方面，考虑到负向关系往往不满足图邻域同质性假设，在图结构中传播可能导致错误信息扩散，因此本文采用多层感知机 (Multilayer Perceptron, MLP) 对负向交互进行独立编码，从而提取更加稳定的厌恶特征表示，在避免噪声传播的同时降低模型计算复杂度。

为了进一步缓解深层图神经网络中的过平滑问题并增强模型对噪声数据的鲁棒性，本文设计了一种跨层对比学习机制。通过在不同图卷积层之间注入保持语义一致性的受控噪声，并对不同层的节点表示进行对比学习约束，模型能够在保持表征一致性的同时增强特征区分能力，复用图卷积中间层输出构造对比视图，无需额外数据增强与前向传播。

同时，为了解决传统推荐模型训练目标与最终评估指标之间的不一致问题，本文进一步设计基于指数移动平均 (Exponential Moving Average, EMA) 的动量教师模型，通过构建稳定的教师网络生成全局排序分布，并将其作为软标签指导学生模型进行学习。该机制能够将局部成对优化目标扩展到全局排序空间，从而在整体拓扑结构层面提高模型的排序一致性与泛化能力。

本章提出的 TDGRec-SR 模型在第三章 TDGRec 的基础上进一步融合了符号关系建模、跨层对比学习以及排序一致性优化机制，从多个层面提升了图推荐模型对复杂用户行为关系的表达能力，为构建更加准确与鲁棒的动态图推荐系统提供了一种新的解决思路。

4.2 模型设计与描述

TDGRec-SR 模型以用户-物品带评分与时序信息的交互数据为输入，通过四大模块的协同工作，实现端到端的推荐优化，整体架构主要由四个紧密协同的核心部分构成，核心前向传播与优化流程如算法 4-1 所示：

算法 4-1 TDGRec-SR 模型伪代码

```

Input:  $G=(U,I,E), \tau, \epsilon, N_{\text{neg}}, \lambda_{\text{reg}}, \lambda_{\text{CL}}, \lambda_{\text{RD}}$ 

Output:  $E^*$ 

1:      Initialization:  $\Theta \leftarrow$  random initialization
2:      Construction of  $G^s$  from  $G$  along with  $\tau$ 
3:      Splitting  $G^s$  into  $G_p$  and  $G_n$ 
4:      while not converged do
5:           $E_p \leftarrow \text{TDGRec}(G_p)$ 
6:           $E_n \leftarrow \text{MLP}(G_n)$ 
7:           $\tilde{E}_p \leftarrow E_p + \epsilon$ 
8:           $(\alpha_p, \alpha_n) \leftarrow \text{ATTENTION}(E_p, E_n)$ 
9:           $E^* \leftarrow \alpha_p \odot E_p + \alpha_n \odot E_n$ 
10:          $E_T \leftarrow \text{EMA}(E^*)$ 
11:          $L_{\text{RD}} \leftarrow \text{Distill}(E^*, E_T)$ 
12:          $L_{\text{BPR}} \leftarrow \text{sign-aware BPR loss}$ 
13:          $L \leftarrow L_{\text{BPR}} + \lambda_{\text{CL}} L_{\text{XCL}} + \lambda_{\text{RD}} L_{\text{RD}} + \lambda_{\text{reg}} \|\Theta\|^2$ 
14:          $\Theta \leftarrow \text{Adam}(\nabla_{\Theta} L)$ 
15:     end while
16:     return  $E^*$ 

```

模型的整体数据流转流程如图 4-1 所示：首先，系统接收包含评分和时间戳的原始交互日志，根据评分阈值将其划分为正向时序子图与负向静态子图，同时为节点生成符号感知位置嵌入，消除拓扑歧义。其次，正向子图连同时序权重输入 TDGRec 动态图编码器，生成融合时序信息的多阶正向表征，负向子图输入至独立的 MLP 编码器中，通过非线性变换提取出用户的纯粹厌恶表征，彻底阻断错误信息在图上的传递；随后，对正向分支不同卷积层的嵌入注入同象限受控噪声，构建跨层对比学习任务，优化节点表征的辨识度，从而有效缓解深层图网络的过平滑问题。同时，通过 EMA 动量教师模型生成全局排序软标签，执行列表级排序蒸馏；最终，通过注意力机制自适应融合正负双分支表征，结合符号感知 BPR 损失、对比损失与蒸馏损失，完成多任务联合优化，输出最终的节点表征与推

荐列表。




图 4-1 TDGRec-SR 模型框架图

4.2.1 符号感知双分支表示学习

在推荐系统中，用户与物品之间的交互不仅包含点击、购买等正向反馈，还包含低评分、快速退出等负向行为。这些负向交互同样蕴含着用户的偏好信息，对准确刻画用户兴趣具有重要作用。然而，大多数现有图推荐方法通常仅利用正向交互数据构建用户-物品二部图，并在图结构上进行表示学习，从而忽略了负向反馈所蕴含的厌恶信息。为充分利用不同类型的交互信号，本文在用户-物品交互图上引入符号关系建模机制，并构建符号感知的双分支编码结构。本模块的核心目标是对原始的交互数据进行正负向语义解耦，同时通过注入位置编码消除拓扑结构等价但语义不同的节点表征歧义，为后续双分支编码提供高质量的图结构输入。

（1）符号时序二部图的时序解耦与构建

设用户集合为 U （含 M 个用户），物品集合为 I （含 N 个用户），原始交互边集合为 E 。对任意交互边 $(u, i) \in E$ ，用户 u 对物品 i 的原始反馈分值为 r_{ui} ，交互时间戳为 t_{ui} 引入一个预设的反馈中性阈值 τ 。定义交互的符号权重为 $S_{ui} = r_{ui} - \tau$ ，基于符号权重的正负性，将原始图划分为两个边不相交的子图：

正向时序子图 $G_p = (U, I, E_p)$ ：当 $S_{ui}^s > 0$ 时，表明用户对物品具有明确的正向偏好，构建正向图，正向子图使用本文第三章提到的多尺度时序建模与动静融合图构建机制，用于

捕捉用户偏好的时序动态演化。

负向静态子图 $G_n = (U, I, E_n)$ ：当 $S_{ui}^s < 0$ 时，表明用户对物品产生明确不喜欢情绪，构建负向图，负向子图使用 MLP 独立编码，避免负向关系不满足同质性导致的错误信息扩散。

（2）符号感知位置编码

标准的 GNN 仅依赖图拓扑结构进行消息传递，无法区分结构等价但语义不同的节点，如所图 4-2 所示，在推荐场景下，两个度数相同的物品节点，例如一个是被大量用户反复购买的经典商品，另一个是因短期促销被频繁点击但转化率低的商品，标准 GNN 会为它们生成高度相似的嵌入。这种结构性歧义在推荐系统中会带来大量噪声，它将用户因长期偏好产生的“深度交互”与因偶然曝光产生的“浅层浏览”混为一谈，导致模型无法准确刻画用户兴趣的真实语义。

为解决这一问题，本文设计符号感知位置嵌入，通过为节点注入正向交互度数的结构信号来消除歧义。具体而言，该嵌入利用用户-物品交互图中不同行为类型所蕴含的语义差异，将交互行为的正负属性编码为节点的位置特征，使模型在消息传递过程中不仅感知节点在图中的拓扑位置，更能区分该位置是由何种语义的交互关系所定义。这一定义直接服务于推荐系统的核心需求，区分用户真正偏好的物品与那些仅因流行度高或偶然曝光而被交互的物品，从而提升节点表示的判别能力与推荐结果的精准度。




图 4-2 语义结构等价

首先，计算节点在正向子图中的度数，对于用户节点 u ，正向度数 d_u^+ 为其正向交互的物品总数；对于物品节点 i ，正向度数 d_i^+ 为其获得的正向交互用户总数。通过 Z-Score 标准化，将度数映射为维度匹配的位置嵌入如公式 4-1 和 4-2 所示：

$$PE_x^{raw} = \frac{d_x^+ - \min_{y \in U \cup I} d_y^+}{\max_{y \in U \cup I} d_y^+ - \min_{y \in U \cup I} d_y^+ + \epsilon} \quad (4-1)$$

$$PE_x = \frac{PE_x^{raw} - \mu}{\sigma + \epsilon} \quad (4-2)$$

其中 $\epsilon = 10^{-6}$ 防止除零, x 为任意用户/物品节点, μ 为全节点 PE_x^{raw} 的均值, σ 为全节点 PE_x^{raw} 的标准差, 将度数映射至 $[0,1]$ 区间。

最终, 将标准化后的度数转换为嵌入, 将位置嵌入与节点初始 ID 嵌入进行加法融合, 得到模型的初始输入嵌入矩阵如公式 4-3 所示:

$$E^{(0)} = E_{ID} + \alpha_{pe} \cdot PE \otimes \mathbf{1}_d \quad (4-3)$$

其中 $E_{ID} \in \mathbb{R}^{(M+N) \times d}$ 为可学习的节点 ID 初始嵌入, α_{pe} 为位置嵌入的缩放系数, $\mathbf{1}_d$ 为 d 维全 1 向量, $\otimes$ 为外积运算, 确保位置嵌入与 ID 嵌入维度匹配。

(3) 双分支编码结构

本小节针对正向交互与负向交互底层物理特性的本质差异, 设计异构双分支编码器, 分别对正负向子图进行特征提取, 精准捕捉时序偏好的同时, 避免负向交互的语义污染。正向交互契合图神经网络的同质性假设, 且具有强烈的时序动态性。因此, 对正向子图集成第三章提出的 TDGRec 动态图卷积框架, 设 $E_+^{(l)}$ 为第 l 层的正向节点嵌入矩阵, 其传播更新如公式 4-4 所示:

$$E_+^{(l+1)} = \tilde{A}_{final} E_+^{(l)} \quad (4-4)$$

其中 $\tilde{A}_{final}$ 为第三章推导的动静融合归一化传播矩阵, 经过 L 层动态传播后, 采用层级加权聚合生成正向子图的最终嵌入矩阵 E_p , 充分融合多阶邻居的时序协同信息如公式 4-5 所示:

$$E_p = \frac{1}{L+1} \sum_{l=0}^L E_+^{(l)} \quad (4-5)$$

其中 $E_p \in \mathbb{R}^{(M+N) \times d}$, 每一行对应一个用户/物品节点的正向表征。

与正向交互相反, 负向子图中的交互不满足同质性假设。例如, 用户可能同时因为过度惊悚给恐怖电影打低分, 又因为节奏缓慢讨厌古典音乐。强行使用图神经网络进行邻居聚合会导致完全无关的厌恶特征混合, 为了彻底阻断错误信息的图上蔓延, 本节为负向子图设计了 MLP 非线性独立编码器。放弃了拓扑消息传递, 仅基于节点自身的初始特征进

行非线性映射，独立提取每个节点的厌恶特征。对于任意节点 x ，其初始嵌入为 $e_x^{(0)} \in \mathbb{R}^d$ ，经过两层 MLP 变换后，生成最终的负向表征 $e_{x,-}^*$ 如公式 4-6 和 4-7 所示：

$$e_{u,-}^* = \text{MLP}(e_u^{(0)}) = \text{LeakyReLU}(W_2 \cdot \text{LeakyReLU}(W_1 e_u^{(0)} + b_1) + b_2) \quad (4-6)$$

$$e_{i,-}^* = \text{MLP}(e_i^{(0)}) = \text{LeakyReLU}(W_2 \cdot \text{LeakyReLU}(W_1 e_i^{(0)} + b_1) + b_2) \quad (4-7)$$

其中 $W_1, W_2 \in \mathbb{R}^{d \times d}$ 为可学习权重矩阵， $b_1, b_2 \in \mathbb{R}^d$ 为偏置向量，LeakyReLU 为带泄露的线性整流激活函数，避免负向特征的梯度消失，经过 MLP 映射后得到负向子图的最终嵌入矩阵 $Z^n \in \mathbb{R}^{(M+N) \times d}$ 。

该机制阻断了负向子图中错误的消息传递，确保每个节点的厌恶特征完全独立，不会被无关的邻居节点污染；同时，MLP 的非线性变换能力足以捕捉用户厌恶偏好的复杂边界，且计算复杂度远低于 GNN，大幅降低模型的整体开销。

4.2.2 噪声增强跨层对比学习

为缓解深层图卷积的过平滑问题，提升模型对稀疏噪声数据的鲁棒性，本节设计了同象限噪声增强的跨层对比学习机制。该机制摒弃了传统随机丢边/丢节点的破坏式增强方式，通过向不同卷积层的嵌入中注入语义一致的受控噪声生成增强视图，将同一节点不同网络层的表征视为正样本对，通过 InfoNCE 损失最大化层间互信息，在不破坏核心语义的前提下，增强节点表征的个性化辨识度。

(1) 同象限噪声增强

为确保噪声注入不会改变节点嵌入的核心语义，向节点嵌入注入同象限噪声，注入的噪声在每个维度上的符号，与原始嵌入对应维度的符号一致，确保嵌入向量在特征空间中不会发生反向偏移，语义方向始终保持一致，给定第 L 层的节点嵌入 $h_x^{(l)} \in \mathbb{R}^d$ ，首先，生成与嵌入维度一致的随机向量 $r_x \sim \text{Uniform}(0,1)$ ，与原始嵌入的符号向量做哈达玛积，得到噪声方向向量如公式 4-8 所示：

$$d_x = r_x \odot \text{sign}(h_x^{(l)}) \quad (4-8)$$

对方向向量做 L2 归一化，乘以预设的噪声幅度 ϵ ，得到最终的受控噪声向量如公式 4-9 所示：

$$\delta_x^{(l)} = \epsilon \cdot \frac{d_x}{\|d_x\|_2} \quad (4-9)$$

将噪声与原始嵌入融合，生成增强视图如公式 4-10 所示：

$$\tilde{\mathbf{h}}_x^{(l)} = \mathbf{h}_x^{(l)} + \delta_x^{(l)} \quad (4-10)$$

原始嵌入 $\mathbf{h}_x^{(l)}$ 与增强嵌入 $\tilde{\mathbf{h}}_x^{(l)}$ 的夹角为 θ ，则 $\cos \theta > 0$ 恒成立，噪声注入不会导致向量反向，确保了增强视图与原始视图的语义一致性，避免了传统增强方式引发的语义偏移问题，如图 4-3 所示。




图 4-3 同象限噪声增强

(2) 跨层正样本对构造

本节将同一节点在不同网络层的增强嵌入视为正样本对，将批次内其他节点的嵌入视为负样本对，构建跨层对比学习任务。同一节点在不同卷积层的表征，是其自身偏好的不同粒度刻画，具有天然的语义一致性；通过对齐层间表征，能够迫使模型在深层传播中保留节点的个性化特征，有效缓解过平滑。

对于任意节 x ，将其第 0 层的增强嵌入 $\tilde{\mathbf{h}}_0^{(l)}$ ，与第 1 至第 L 层的增强嵌入 $\tilde{\mathbf{h}}_x^{(l)}$ 分别构成正样本对；当前批次 $\mathcal{B}$ 内的其他节点 $y \neq x$ ，与节点 x 构成负样本对。采用 InfoNCE 损失函数构建跨层对比损失如公式 4-11 所示：

$$\mathcal{L}_{\text{XCL}} = \frac{1}{L} \sum_{l=1}^L \mathcal{L}_{\text{XCL}}^{(l)} \quad (4-11)$$

其中第 L 层的损失如公式 4-12 所示：

$$\mathcal{L}_{\text{XCL}}^{(l)} = -\frac{1}{|\mathcal{B}|} \sum_{x \in \mathcal{B}} \log \frac{\exp(\text{sim}(\tilde{\mathbf{h}}_x^{(l)}, \tilde{\mathbf{h}}_x^{(0)})/\tau)}{\sum_{y \in \mathcal{B}} \exp(\text{sim}(\tilde{\mathbf{h}}_x^{(l)}, \tilde{\mathbf{h}}_y^{(0)})/\tau)} \quad (4-12)$$

其中 $\mathcal{B}$ 为当前批次的节点集合， τ 为对比损失的温度超参数，控制分布的锐度； $\text{sim}(\cdot, \cdot)$

为余弦相似度函数，定义为 L2 归一化后向量的内积公式 4-13 所示：

$$\text{sim}(z_a, z_b) = \frac{z_a^T z_b}{\|z_a\|_2 \cdot \|z_b\|_2} \quad (4-13)$$

与传统图对比学习相比，该机制具有显著的效率优势，仅需一次全局前向传播即可同时完成图卷积编码与对比损失计算，无需额外的编码器与多次前向推理，计算复杂度与原生 LightGCN 基本持平。同时，同象限噪声增强进一步提升了对比视图的语义一致性，使得模型在稀疏交互与噪声数据场景下具有更强的鲁棒性。

4.2.3 动量排序蒸馏

推荐系统的核心目标是为每个用户生成 Top-K 排序列表，而非精确预测评分。传统的点态损失（如 MSE）或成对损失（如 BPR）虽然优化了相对偏好，但未显式建模全局排序结构。本文设计基于指数移动平均（EMA）动量教师模型的列表级排序蒸馏框架，将泛化性更强的教师模型输出的全局排序分布作为软标签，引导学生模型学习全局排序结构，提升推荐列表的排序精度与稳定性。

（1）EMA 动量教师模型构建

教师模型的参数是学生模型历史参数的滑动平均，其输出的表征与排序结果具有更强的稳定性与泛化能力，不会因单轮训练的梯度波动发生剧烈变化，是排序知识蒸馏的优质软标签来源。动量教师模型与学生模型共享完全一致的网络架构，不参与反向传播更新，仅通过指数移动平均的方式，实时复制学生模型的参数，如公式 4-14 所示：

$$\Theta'_t = m \cdot \Theta'_{t-1} + (1-m) \cdot \Theta_t \quad (4-14)$$

其中 Θ'_t 为第 t 步教师模型的参数， Θ_t 为第 t 步学生模型的参数， m 为动量系数，初始化 $\Theta'_0 = \Theta_0$ 。

（2）列表级排序蒸馏损失计算

排序蒸馏损失聚焦于将教师模型的排序知识迁移至学生模型，让学生模型的输出排序分布，在全局上逼近教师模型的输出分布，对于任意用户 u ，取其 1 个正样本物品 i 与 K 个负样本物品 $j_1, j_2, \dots, j_K$ ，构建候选排序列表 $R_u = i, j_1, j_2, \dots, j_K$ 。学生模型与教师模型分别计算列表内所有物品的偏好评分，学生模型评分向量 $s_u^S = [\hat{y}_{ui}, \hat{y}_{uj_1}, \dots, \hat{y}_{uj_K}]$ ，教师模型评分向量 $s_u^T = [\hat{y}_{ui}^T, \hat{y}_{uj_1}^T, \dots, \hat{y}_{uj_K}^T]$ ，其中偏好评分由用户与物品最终表征的内积计算得到，即 $\hat{y}_{ui} =$

$\mathbf{z}_u^T \mathbf{z}$ 。

通过带温度缩放的 Softmax 函数，将离散评分转换为列表上的概率分布，软化分布以凸显物品间的相对排序关系，如公式 4-15 和 4-16 所示：

$$P_u^S[k] = \frac{\exp(s_u^S[k]/T)}{\sum_{k'=0}^K \exp(s_u^S[k']/T)} \quad (4-15)$$

$$P_u^T[k] = \frac{\exp(s_u^T[k]/T)}{\sum_{k'=0}^K \exp(s_u^T[k']/T)} \quad (4-16)$$

其中 $T > 1$ 为蒸馏温度系数， T 越大，概率分布越平滑，模型越关注次优物品的相对顺序，而非仅聚焦排序第一的物品。

采用 KL 散度衡量学生模型与教师模型概率分布的差异，构建排序蒸馏损失如公式 4-17 所示：

$$\mathcal{L}_{RD} = \frac{1}{|\mathcal{B}|} \sum_{u \in \mathcal{B}} D_{KL}(P_u^T \parallel P_u^S) \quad (4-17)$$

其中，忽略教师分布熵的常数项，蒸馏损失可简化为交叉熵形式如公式 4-18 所示：

$$\mathcal{L}_{RD} = -\frac{1}{|\mathcal{B}|} \sum_{u \in \mathcal{B}} \sum_{k=0}^K P_u^T[k] \cdot \log P_u^S[k] \quad (4-18)$$

该损失能够优化学生模型的全局排序结构，迫使学生模型学习教师模型更稳定、更泛化的排序偏好，解决了成对损失与列表级评估指标的不匹配问题，显著提升推荐列表的排序质量与稳定性。

4.2.4 注意力融合

本节针对上述输出的正向表征 $\mathbf{E}_p$ 与负向表征 $\mathbf{E}_n$ ，采用注意力机制自适应融合双分支的输出，根据每个节点的特征动态调整正负表征的贡献权重。对于任意节点 $\mathbf{x}$ （用户/物品），其正向表征为 $\mathbf{E}_x^p$ ，负向表征为 $\mathbf{E}_x^n$ ，首先通过注意力网络^[70]计算两个分支的注意力权重如公式 4-19 和 4-20 所示：

$$\mathbf{w}_x^p = \mathbf{q}^T \tanh(\mathbf{W}_{\text{attn}}(\mathbf{E}_x^p)^T + \mathbf{b}_{\text{attn}}) \quad (4-19)$$

$$\mathbf{w}_x^n = \mathbf{q}^T \tanh(\mathbf{W}_{\text{attn}}(\mathbf{E}_x^n)^T + \mathbf{b}_{\text{attn}}) \quad (4-20)$$

其中 $\mathbf{W}_{\text{attn}} \in \mathbb{R}^{d' \times d}$ 为注意力权重变换矩阵， $\mathbf{q} \in \mathbb{R}^{d' \times 1}$ 为注意力查询向量， $\mathbf{b}_{\text{attn}} \in \mathbb{R}^{d' \times 1}$ 为偏置向量， d' 为注意力隐藏层维度。通过 Softmax 函数对权重进行归一化，得到最终的融合

权重如公式 4-21 和 4-22 所示所示：

$$\alpha_x^p = \frac{\exp(w_x^p)}{\exp(w_x^p) + \exp(w_x^n)} \quad (4-21)$$

$$\alpha_x^n = 1 - \alpha_x^p \quad (4-22)$$

最终，节点的融合表征为正负表征的加权和如公式 4-23 所示：

$$E_x = \alpha_x^p \cdot E_x^p + \alpha_x^n \cdot E_x^n \quad (4-23)$$

所有节点的融合表征构成最终的表征矩阵 $E_x^* \in \mathbb{R}^{(M+N) \times d}$ ，用于后续的偏好预测与模型优化。

4.2.5 多任务联合总损失函数

本节采用多任务联合优化策略，总损失函数由四部分构成：符号感知 BPR 主任务损失、跨层对比学习辅助损失、列表级排序蒸馏损失，以及 L2 正则化项，如公式 4-24 与公式 4-25 所示：

$$\mathcal{L}_{total} = \mathcal{L}_{BPR} + \lambda_{CL}(t) \cdot \mathcal{L}_{XCL} + \lambda_{RD} \cdot \mathcal{L}_{RD} + \lambda_{reg} \cdot \|\Theta\|_2^2 \quad (4-24)$$

$$\lambda_{CL}(t) = \lambda_{CL,max} \cdot \frac{1 + \cos(\pi \cdot t / T_{total})}{2} \quad (4-25)$$

其中 $\lambda_{CL}(t)$ 为对比损失的动态权重，采用余弦退火衰减策略，在训练初期赋予对比学习较高权重以学习通用的节点表征，训练后期逐步降低权重让主任务主导优化过程， λ_{RD} 为排序蒸馏损失的固定权重， λ_{reg} 为 L2 正则化系数， Θ 为模型所有可训练参数。

核心的符号感知 BPR 损失，在传统 BPR 损失的基础上，区分了正向与负向交互的优化强度，对正向交互与负向交互设置差异化的优化目标，对于正向交互，优化目标是让正样本评分高于负样本；对于负向交互，放大优化强度，让负向交互物品的评分远低于未交互物品，进一步收紧用户的厌恶偏好边界，提升推荐的精准度，如公式 4-26 示：

$$\mathcal{L}_{BPR} = - \sum_{(u,i,j) \in \mathcal{D}_S} [\mathbb{1}_{w_{ui}^s > 0} \cdot \log \sigma(\hat{y}_{ui} - \hat{y}_{uj}) + \mathbb{1}_{w_{ui}^s < 0} \cdot \log \sigma(c \cdot (\hat{y}_{ui} - \hat{y}_{uj}))] \quad (4-26)$$

其中 $\mathcal{D}_S = \{(u,i,j) | (u,i) \in E^p \cup E^n, j \notin \mathcal{N}_u\}$ 为训练三元组集合， i 为用户 u 的交互物品， j 为未交互的负采样物品， $\mathcal{N}_u$ 为用户 u 的所有交互物品集合， $\mathbb{1}$ 为指示函数，满足条件时取值为 1，否则为 0， $\sigma(\cdot)$ 为 Sigmoid 激活函数； $c > 1$ 为负向反馈的惩罚强度系数，确保用户明确厌恶的物品被更强力地压低排序，精准刻画用户的偏好边界。

4.3 实验设计

4.3.1 实验设置

在本节中，采用与第三章完全一致的实验环节，在 ML-1M、Amazon-Book 和 Yelp 这三个真实世界的数据集上进行了实验，以评估模型的性能，对每个数据集，按 8:1:1 比例划分为训练集、验证集与测试集。采用 3.5 分作为阈值区分正负交互。

4.3.2 对比算法

为充分验证 TDGRec-SR 模型的优越性，选取 7 类主流算法作为对比基线，涵盖传统协同过滤、经典 GNN 推荐、序列推荐、符号感知推荐、对比学习推荐五大类，同时包含第三章提出的 TDGRec 模型，具体如下：

BPR-MF^[17]：基于贝叶斯个性化排序的矩阵分解模型，是推荐系统的经典基线，仅利用正向交互优化成对排序目标。

NeuMF^[69]：神经协同过滤模型，通过多层神经网络替代传统矩阵分解，融合线性与非线性特征交互，提升协同过滤的表达能力。

NGCF^[4]：神经图协同过滤模型，首次将 GCN 引入协同过滤，通过嵌入传播显式建模用户-物品的高阶连通关系。

LightGCN^[5]：简化了原始的 GCN 模型，去除了冗余的特征变换和非线性激活函数，仅保留图卷积的邻居聚合核心操作；同时引入残差连接与层归一化，减少训练参数、加速训练过程，有效缓解过拟合，提升模型泛化能力。

SGCN^[43]：符号图卷积网络，基于结构平衡理论对正负向边进行统一的图卷积聚合，是符号网络表示学习的经典基线。

SiReN^[72]：构建带符号的二分图以更精准表征用户偏好，该图被划分为正负边互不重叠的两个子图。

4.3.3 参数设置

所有模型的用户与物品嵌入维度统一固定为 64，采用 Xavier 均匀分布初始化所有可学习参数，批量大小统一设置为 1024，基础学习率设置为 0.001，L2 正则化系数、早停策略与第三章保持一致。

4.4 实验结果与分析

4.4.1 模型对比分析

为了全面评估本文提出的 TDGRec-SR 算法在 Top-K 推荐任务中的性能，本节在 Yelp、Amazon-Book 和 ML-1M 三个基准数据集上进行了对比实验。将 TDGRec-SR 与包括本文第三章提出的 TDGRec 在内的 7 种主流基线模型进行了评估，对比指标为 Recall20 和 NDCG@20。所有实验结果如表 4-1 所示。

TDGRec-SR 在所有数据集的各项评价指标上均取得了全局最优的推荐性能。与表现最强的前沿基线模型 SiReN 相比，TDGRec-SR 展现出了显著的性能跨越。这一提升证明，本文将正负图解耦机制、跨层对比学习与列表级排序蒸馏相融合的整体架构，能够更精准地刻画用户的多维偏好边界。

图神经网络在挖掘高阶协同信号方面相比传统模型具有压倒性优势。传统的矩阵分解算法 BPR-M、NeuMF 在三个数据集上的表现垫底；而基于 GNN 的 NGCF 和 LightGCN 由于能够利用多跳邻域聚合机制捕获全局图结构关联，其性能均远超浅层学习算法。符号感知与对比学习机制能够有效突破传统 GNN 的性能瓶颈。引入了专门针对符号网络设计的 SGCN 和 SiReN，其性能均稳定优于基础的 LightGCN。这表明，单纯依赖正向邻域聚合极易导致信息冗余和过平滑，而引入负向边缘信息能够为模型提供额外的判别力。TDGRec-SR 进一步整合了跨层对比优势，彻底激活了符号图中的高熵信息。

表 4-1 与其他模型的性能比较

Dataset	ML-1M		Amazon-Book		Yelp	
Method	Recall@20	NDCG@20	Recall@20	NDCG@20	Recall@20	NDCG@20
BPR-MF	0.2015	0.1780	0.0195	0.0258	0.0385	0.0450
NeuMF	0.2088	0.1850	0.0220	0.0280	0.0410	0.0480
NGCF	0.2458	0.2213	0.0285	0.0360	0.0485	0.0560
LightGCN	0.2635	0.2395	0.0330	0.0435	0.0585	0.0685
SGCN	0.2652	0.2415	0.0338	0.0442	0.0592	0.0695
SiReN	0.2670	0.2435	0.0345	0.0450	0.0601	0.0705
TDGRec	0.2688	0.2455	0.0351	0.0458	0.0612	0.0718
TDGRec-SR	0.2765	0.2542	0.0385	0.0492	0.0652	0.0775

4.4.2 消融实验分析

为了验证本文提出的 TDGRec-SR 模型中各个创新组件的有效性以及它们对整体推荐性能的独立贡献，我们在 Yelp、Amazon-Book 和 ML-1M 三个数据集上进行了系统的增量与消融实验。使用“PE”来表示符号感知位置编码模块，“CL”表示同象限噪声跨层对比学习模块，“RD”表示基于 EMA 动量教师的列表级排序蒸馏模块。在完整的 TDGRec-SR 模型中分别移除核心的对比、蒸馏以及位置编码模块，分别标记为 w/o CL、w/o RD、w/o PE 进行消融对比。我们比较了上述所有变体，实验结果如图 4-4 所示。

观察数据可见，将所有机制合并至完整的 TDGRec-SR 模型中使得模型达到了最佳性能，移除任何单一模块均会导致性能下滑，这表明我们设计的模块的有效性，且彼此之间存在良好的协同效应。

实验结果证明了“CL”模块在缓解稀疏数据集特征同质化问题中的关键作用。没有“CL”的 w/o CL 模型在所有数据集上的性能均出现了最为明显的衰减。尤其是在数据极其稀疏的 Amazon-Book 数据集中，移除 CL 模块导致模型的 Recall@20 指标从 0.0385 下降至 0.0368。这表明，注入同象限噪声并对齐跨层视图的对比学习机制，能够有效打破节点特征的过度平滑，迫使模型在深层传播中保留高阶邻居信息的独特辨识度。




图 4-4 消融实验结果对比

从实验观察中我们得出列表级排序蒸馏（RD）能够显著提升 NDCG 指标的表现。在 ML-1M 数据集上，移除“RD”模块使得 NDCG@20 发生了明显下降。对排序评估指标的本质进行分析后发现，传统 BPR 损失仅关注局部正负样本的成对关系，而 RD 模块引入的教师软标签则提供了一个类似于全局排序锚点的分布约束，能够有效纠正绝对位置偏差。

对“PE”模块的消融实验（w/o PE）同样证明了位置编码的不可或缺性。在移除该模块后，模型性能发生了一定程度的下滑。这表明在复杂的符号二部图中，单纯依赖拓扑消

息传递无法有效区分结构等价但语义截然不同的长尾节点。显式地注入符号感知位置编码，为网络提供了打破拓扑对称性的关键先验信息。

4.4.3 负向图编码器架构对比分析

在面对包含用户真实喜好与厌恶的复杂交互环境时，如何合理处理负向反馈数据仍是一个关键问题，为了探究针对负向子图 G_n 的最佳模型架构，并验证正负图解耦机制的必要性，本文设计了多种图处理架构进行对比试验：

Mixed-GNN：不进行图结构解耦，将正负交互边保留在同一图中，整体应用图卷积网络进行传播；

No- G_n ：舍弃负向交互图 G_n ，仅利用正向图 G_p 生成的表征作为最终节点表征，作为常规纯正向图推荐的基线；

GNN- G_n ：对正负图进行解耦后，在负向子图 G_n 上同样应用图卷积网络进行邻域聚合；

MLP- G_n ：即 TDGRec-SR 所采用的架构。在负向子图 G_n 上应用多层感知机进行特征提取，阻断拓扑消息传递。

上述四种架构在 Yelp、Amazon-Book 和 ML-1M 数据集上的性能测试结果如图 4-5 所示。




图 4-5 负向图编码器架构对比分析

基于 MLP 的负向图编码器（MLP- G_n ）相比于完全不使用负向图（No- G_n ），在所有数据集上均取得了显著的性能提升。这一结果表明，负面交互数据中包含了有助于系统识别并过滤不相关物品的有效信息。当在负向图上采用图卷积操作（GNN- G_n ）时，模型性能相比 No- G_n 出现了明显的下降。在 ML-1M 数据集中，GNN- G_n 的 NDCG@20 为 0.2420，

低于 No-Gn 的 0.2455。是因为负面反馈形成的复杂动因，用户对物品产生厌恶情绪的原因往往是多种多样且互不相关的，例如，某件商品可能因为价格高昂被拒绝，而另一件可能因为质量不佳被拒绝。图神经网络的核心机制是基于同质性假设的邻域聚合，如果在负向图上强行使用 GNN，会将这些复杂多样的负向特征进行平滑与混合，从而导致节点表征产生严重的噪音污染。

未对图结构进行正负解耦的 Mixed-GNN 架构表现最差。这表明简单地将正负反馈混合在同一网络中进行消息传递，会导致正向偏好特征与负向厌恶特征发生严重的语义混淆，进一步证实了在符号网络中进行图解耦处理的前提必要性。

实验证明，采用 MLP 对负向图进行编码是更为合理的选择。MLP 能够通过非线性变换有效提取负面反馈特征，同时避免了因邻域聚合而引入的冗余噪音，从而保证了特征表征的准确性与推荐性能的稳定性。

4.4.4 超参数分析

为本文提出的 TDGRec-SR 模型主要包含三个关键的超参数：跨层对比学习任务的权重系数 λ_{CL} 、同象限噪声注入的幅度 ϵ ，以及图卷积网络的传播层数 L 。本节系统性地分析了模型对这些超参数的敏感特性，并深入探讨了模型在深层网络架构下的鲁棒性。

(1) 对比权重 λ_{CL} 与噪声幅度 ϵ 的联合影响分析

为了探究对比任务与噪声扰动对推荐主任务的联合影响，我们在 Yelp、Amazon-Book 和 ML-1M 三个数据集上进行了多变量网格搜索实验。我们设置 $\lambda_{CL} \in \{0.01, 0.05, 0.1, 0.2, 0.5, 1.0\}$ ， $\epsilon \in \{0, 0.01, 0.05, 0.1, 0.2, 0.5\}$ 构建全组合空间进行验证。为了控制变量，本组实验固定图卷积层数 $L = 3$ 。通过逐步调整 λ_{CL} 值，可以观察对比学习梯度对主任务的影响程度；而 ϵ 的调整则用于模拟不同程度的特征空间扰动。这种参数组合设计覆盖了从无对比监督（ $\lambda_{CL} = 0$ ）到强对比约束，以及从无噪声（ $\epsilon = 0$ ）到强扰动的极端情况，为评估模型的泛化能力提供了详实的数据支撑。

实验结果如图 4-6 所示，随着对比学习权重和扰动强度的增加，推荐性能整体表现为先提升后下降的规律。当 λ_{CL} 从较小值逐渐增大时，适度的对比学习约束能够有效提升用户与物品表示的判别能力，使模型在嵌入空间中学习到更加稳定的语义结构，从而改善推荐效果；当权重继续增大至较高水平时，模型性能开始出现下降，是因为过强的对比约束会使模型过度强调不同视图之间的一致性，从而削弱对推荐主任务排序目标的优化能力。

噪声扰动幅度对模型性能也具有显著影响，当 ϵ 取较小值 0.01 或 0.05 时，轻量级扰动

能够构建有效的数据增强视图，从而为对比学习提供更加丰富的训练信号，同时在一定程度上缓解图神经网络中的过平滑问题，使节点表示保持更高的区分度，因此模型能够取得更好的推荐效果；但当扰动幅度进一步增大时，过强的噪声会破坏原始嵌入空间中的语义结构，导致用户与物品表示不再稳定，从而使推荐性能明显下降。进一步比较不同数据集可以发现，数据稀疏度对参数变化的敏感性具有一定影响，其中相对稠密的 MovieLens-1M 数据集在较宽的参数范围内仍能保持稳定性能，而交互更加稀疏的 Amazon-Book 数据集则对参数变化更加敏感，当扰动或对比权重过大时性能下降更加明显。

综合以上实验结果可以看出，适度的对比学习权重与轻量级噪声扰动能够在提升表示质量与保持结构稳定之间取得较好的平衡，因此在后续实验中本文采用 $\lambda_{CL} = 0.2$ 和 $\epsilon = 0.05$ 作为默认参数设置，以获得更加稳定且优良的推荐性能。




图 4-6 对比权重 λ_{CL} 与噪声幅度 ϵ 的联合影响分析

(2) 深层网络架构下的抗过平滑鲁棒性分析

在图推荐系统中，模型性能高度依赖于图卷积网络的深度 L 。适当增加层数能够捕获高阶协同过滤信号，但过深的网络会导致不同节点的特征趋于同质化，引发严重的“过平滑”问题。为验证 TDGRec-SR 中跨层对比机制在缓解过平滑方面的有效性，我们控制传播层数 $L \in \{1, 2, 3, 4, 5, 6\}$ ，对 NGCF、LightGCN、SGCN、第三章基线 TDGRec 以及完整模

型 TDGRec-SR 进行了逐层性能衰减测试。各图推荐模型在 Yelp 数据集上的 Recall@20 表现如图 4-7 所示。




图 4-7 不同传播层数 L

在 Yelp 上进一步分析不同图卷积深度对模型性能的影响,可以观察到各模型随着传播层数 L 的变化呈现出明显不同的性能趋势。当 L 从 1 增加到 2 或 3 时,大多数模型的 Recall@20 均出现一定程度的提升,这表明适当增加图卷积层数能够有效捕获更高阶的用户-物品协同过滤信号,从而丰富节点表示并改善推荐效果。然而,当网络继续加深时,传统图推荐模型的性能普遍开始下降。NGCF 与 SGCN 在 $L \geq 4$ 时出现明显的性能衰减,而 LightGCN 虽然在浅层结构下表现较为稳定,但随着层数进一步增加,其性能同样逐渐下降。这一现象主要源于图神经网络在深层传播过程中容易产生“过平滑”问题,即节点表示在多次邻域聚合后逐渐趋于一致,从而削弱了用户与物品之间的个性化差异,最终影响推荐效果。

相比之下,第三章提出的 TDGRec 在中等深度时能够保持较为稳定的性能,但在更深层网络中仍然不可避免地出现一定程度的性能下降。进一步观察完整模型 TDGRec-SR 的表现可以发现,其在较深网络结构下仍然保持相对稳定的 Recall@20 表现,即使当传播层数增加到 $L = 5$ 或 $L = 6$ 时,性能下降幅度依然明显小于其他对比模型。这一结果表明,TDGRec-SR 中引入的跨层对比学习机制能够在不同层的节点表示之间建立一致性约束,使模型在深层传播过程中仍能保持表示空间中的结构差异,从而有效缓解过平滑带来的性能退化。同时,跨层对比信号能够强化不同层语义信息之间的互补关系,使高阶协同信息在传播过程中得到更加稳定的保留。

综合来看,实验结果验证了 TDGRec-SR 在深层图卷积架构下具备更强的抗过平滑能

力，相比传统图推荐模型能够在更深的传播层数下维持稳定且有效的推荐性能，从而提升模型在复杂用户-物品交互网络中的鲁棒性。

4.5 本章小结

本章在第三章提出的 TDGRec 模型基础上，针对动态图推荐系统中表示学习稳定性不足以及结构噪声影响较大的问题，进一步提出了增强模型 TDGRec-SR。该模型通过构建正负关系的双图结构，对用户-物品交互关系进行更加细粒度的建模，同时引入跨层对比学习机制，以增强不同层表示之间的一致性约束，从而提升节点表示的判别能力并缓解深层图传播过程中产生的过平滑问题。在模型训练过程中，通过对比学习损失与推荐任务目标进行联合优化，使模型能够在保持推荐准确性的同时提升表示鲁棒性。

为了验证所提出模型的有效性，本章在 Yelp、Amazon-Book 和 MovieLens-1M 三个公开数据集上进行了系统实验，并与多种主流图推荐模型进行了对比。实验结果表明，TDGRec-SR 在 Recall@20 与 NDCG@20 等指标上均取得了优于对比模型的性能。同时，通过消融实验、参数敏感性分析以及深层网络架构实验，进一步验证了模型中双图结构与跨层对比机制在提升推荐性能和缓解过平滑问题方面的有效性。特别是在较深的图卷积层数下，TDGRec-SR 仍能够保持稳定的性能表现，体现出更强的鲁棒性。本章提出的 TDGRec-SR 模型能够有效提升动态图推荐系统中的表示学习能力，并在多种实验设置下展现出良好的推荐性能与稳定性，为后续动态图推荐模型的研究提供了新的思路。

5 结论与展望

5.1 论文结论

在数字经济快速发展的背景下，互联网平台中的信息规模持续增长，用户在海量信息环境中高效获取所需内容面临较大挑战。推荐系统作为缓解信息过载的重要技术手段，在实际应用中对模型的表达能力与泛化性能提出了更高要求。然而，用户-物品交互数据通常具有高维稀疏、动态变化等特征，传统基于协同过滤或静态图结构的推荐方法在刻画用户兴趣演化与复杂交互关系方面仍存在一定局限。

围绕上述问题，本文以图神经网络推荐建模为研究主线，结合图神经网络、自监督对比学习以及排序蒸馏等技术，构建了一个分阶段的推荐模型框架，并通过多组实验对方法有效性进行了验证。整体来看，本文的研究工作可以归纳为以下几个方面：

(1) 针对用户兴趣随时间演化难以刻画的问题，本文提出了多尺度时序融合的动态图推荐模型（TDGRec）。该方法从用户行为的时间属性出发，在用户-物品交互图中引入时间感知机制，对历史交互行为进行动态加权建模。通过设置不同时间尺度的衰减函数，模型能够同时刻画短期兴趣波动与长期偏好趋势。在此基础上，将动态时序信息与静态结构信息进行联合建模，使图结构保持整体连通性的同时，对近期行为变化具有更高敏感性，从而在表示层面实现对用户兴趣演化过程的细粒度刻画，并进一步提升表示学习的表达能力。

(2) 针对负向反馈利用不足以及复杂交互语义表达能力有限的问题，本文进一步提出了符号感知的动态图推荐模型（TDGRec-SR）。该方法通过构建正负双图结构，将用户交互关系划分为正向反馈与负向反馈，并分别建立对应的交互图；在此基础上，利用双分支编码器对两类关系进行独立建模，在捕捉用户兴趣偏好的同时刻画其潜在的排斥关系，从而在表示空间中形成更加完整的用户行为语义描述。进一步地，引入跨层对比学习机制，通过在节点表示中施加适度扰动构造增强视图，并对不同层级表示进行一致性约束，使模型在保留结构信息的同时提高表示的区分能力，从而在一定程度上缓解过平滑现象，并增强模型在稀疏数据环境下的稳定性。在此基础上，结合排序蒸馏策略，通过引入教师模型对候选物品生成相对稳定的排序分布，引导学生模型学习更完整的排序结构，使优化目标由局部样本对关系扩展至整体列表层面，从而进一步提升推荐结果的一致性与泛化能力。

(3) 在 MovieLens-1M、Amazon-Book 和 Yelp 等多个公开数据集上的实验结果表明，

所提出方法在 Recall 与 NDCG 等指标上均取得了稳定提升。结合消融实验可以看出，各个关键模块在模型性能提升过程中均发挥了积极作用；进一步结合表示分布分析结果，可以验证模型在动态建模与语义表达方面的有效性，说明整体框架设计具有较好的合理性与稳定性。

总体而言，本文从时间建模、语义建模以及优化策略三个层面对图神经网络推荐问题进行了系统探索，在提升推荐准确性与模型稳定性方面取得了一定进展，验证了图神经网络在处理高维稀疏数据与动态时序建模问题中的应用潜力，同时也为后续相关研究提供了可参考的建模思路。

5.2 未来展望

尽管本文围绕动态图推荐建模，在时间建模、符号关系建模以及排序优化等方面进行系统探索，并在多个数据集上取得了较为稳定的性能提升，但从实际应用需求与相关技术的发展趋势来看，当前研究在模型泛化能力与复杂场景适应性方面仍存在进一步提升空间。基于此，后续研究可从以下两个方面展开：

（1）引入大规模预训练模型以提升表示泛化能力。随着自监督预训练技术的发展，大模型在通用表征学习方面展现出良好的迁移能力。未来可以尝试将预训练模型的语义表达能力与动态图推荐模型相结合，例如通过知识蒸馏或参数高效微调等方式，将通用表示迁移至推荐任务中，从而增强模型在长尾分布及复杂交互场景下的建模能力。

（2）探索多源信息融合与跨模态推荐建模方法。本文主要基于用户-物品交互数据进行建模，而实际应用中往往伴随文本、图像等多模态信息。未来可以在图推荐框架中引入跨模态表示学习机制，对不同模态特征进行统一建模与语义对齐，在提升表示能力的同时拓展推荐系统的交互方式，从而更好地适应复杂应用场景。

参考文献

- [1] 中国互联网络信息中心. 第 55 次中国互联网络发展状况统计报告[R/OL]. 北京: 中国互联网络信息中心, 2025[2026-01-18]. <https://www.cnnic.net.cn/n4/2025/0203/c108-8157.html>.
- [2] Corso G, Stark H, Jegelka S, et al. Graph neural networks[J]. Nature Reviews Methods Primers, 2024, 4(1): 17.
- [3] Gao C, Wang X, He X, et al. Graph neural networks for recommender system[C]//Proceedings of the fifteenth ACM international conference on web search and data mining. 2022: 1623-1625.
- [4] Wang X, He X, Wang M, et al. Neural graph collaborative filtering[C]//Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval. 2019: 165-174.
- [5] He X, Deng K, Wang X, et al. Lightgcn: Simplifying and powering graph convolution network for recommendation[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 639-648.
- [6] Gori M, Monfardini G, Scarselli F. A new model for learning in graph domains[C]//Proceedings. 2005 IEEE international joint conference on neural networks, 2005. IEEE, 2005, 2: 729-734.
- [7] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.
- [8] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017.
- [9] Mao K, Zhu J, Xiao X, et al. UltraGCN: ultra simplification of graph convolutional networks for recommendation[C]//Proceedings of the 30th ACM international conference on information & knowledge management. 2021: 1253-1262.
- [10] Wang X, Jin H, Zhang A, et al. Disentangled graph collaborative filtering[C]//Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval. 2020: 1001-1010.
- [11] Hamilton W, Ying Z, Leskovec J. Inductive representation learning on large graphs[J]. Advances in neural information processing systems, 2017, 30.
- [12] Ying R, He R, Chen K, et al. Graph convolutional neural networks for web-scale recommender systems[C]//Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining. 2018: 974-983.
- [13] Van Den Berg R, Thomas N K, Welling M. Graph convolutional matrix completion[J]. arXiv preprint

arXiv:1706.02263, 2017, 2(8): 9.

[14] Huang J, Xie R, Cao Q, et al. Negative can be positive: Signed graph neural networks for recommendation[J]. Information Processing & Management, 2023, 60(4): 103403.

[15] Wu J, Wang X, Feng F, et al. Self-supervised graph learning for recommendation[C]//Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval. 2021: 726-735.

[16] Yu J, Yin H, Xia X, et al. Are graph augmentations necessary? simple graph contrastive learning for recommendation[C]//Proceedings of the 45th international ACM SIGIR conference on research and development in information retrieval. 2022: 1294-1303.

[17] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian personalized ranking from implicit feedback[J]. arXiv preprint arXiv:1205.2618, 2012.

[18] MINAE S, MIKOLOV T, NIKZAD N, et al. Large language models: a survey [J]. arXiv:2402.06196, 2024.

[19] GENG S J, LIU S C, FU Z H, et al. Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5) [C]// Proceedings of the 16th ACM Conference on Recommender Systems. New York: ACM, 2022: 299-315.

[20] GAO Y, SHENG T, XIANG Y, et al. Chat-rec: Towards interactive and explainable llmsaugmented recommender system [J]. arXiv:2303.14524, 2023.

[21] LIU P, ZHANG L M, GULLA J A. Pre-train, prompt and recommendation: A comprehensive survey of language modelling paradigm adaptations in recommender systems[J]. Transactions of the Association for Computational Linguistics, 2023, 11: 1553-1571.

[22] ZHANG J J, HOU Y P, XIE R B, et al. AgentCF: collaborative learning with autonomous language agents for recommender systems [C]// Proceedings of the ACM Web Conference 2024. New York: ACM, 2024: 3679-3689.

[23] Rendle S, Freudenthaler C, Schmidt-Thieme L. Factorizing personalized markov chains for next-basket recommendation[C]//Proceedings of the 19th international conference on World wide web. 2010: 811-820.

[24] Hidasi B, Karatzoglou A, Baltrunas L, et al. Session-based recommendations with recurrent neural networks[J]. arXiv preprint arXiv:1511.06939, 2015.

[25] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.

- [26] Kang W C, McAuley J. Self-attentive sequential recommendation[C]//2018 IEEE international conference on data mining (ICDM). IEEE, 2018: 197-206.
- [27] Li J, Wang Y, McAuley J. Time interval aware self-attention for sequential recommendation[C]//Proceedings of the 13th international conference on web search and data mining. 2020: 322-330.
- [28] Sun F, Liu J, Wu J, et al. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer[C]//Proceedings of the 28th ACM international conference on information and knowledge management. 2019: 1441-1450.
- [29] Wu S, Tang Y, Zhu Y, et al. Session-based recommendation with graph neural networks[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 346-353.
- [30] Xu C, Zhao P, Liu Y, et al. Graph contextualized self-attention network for session-based recommendation[C]//Ijcai. 2019, 19(2019): 3940-3946.
- [31] Pareja A, Domeniconi G, Chen J, et al. Evolvegc: Evolving graph convolutional networks for dynamic graphs[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(04): 5363-5370.
- [32] Kumar S, Zhang X, Leskovec J. Predicting dynamic embedding trajectory in temporal interaction networks[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 1269-1278.
- [33] Rossi E, Chamberlain B, Frasca F, et al. Temporal graph networks for deep learning on dynamic graphs[J]. arXiv preprint arXiv:2006.10637, 2020.
- [34] Li C, Liu Z, Wu M, et al. Multi-interest network with dynamic routing for recommendation at Tmall[C]//Proceedings of the 28th ACM international conference on information and knowledge management. 2019: 2615-2623.
- [35] Zhou G, Mou N, Fan Y, et al. Deep interest evolution network for click-through rate prediction[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 5941-5948.
- [36] Pal A, Eksombatchai C, Zhou Y, et al. Pinnersage: Multi-modal user embedding framework for recommendations at pinterest[C]//Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 2020: 2311-2320.
- [37] Xiao Z, Yang L, Jiang W, et al. Deep multi-interest network for click-through rate prediction[C]//Proceedings of the 29th ACM international conference on information & knowledge management. 2020: 2265-2268.

- [38] Perozzi B, Al-Rfou R, Skiena S. Deepwalk: Online learning of social representations[C]//Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. 2014: 701-710.
- [39] Tang J, Qu M, Wang M, et al. Line: Large-scale information network embedding[C]//Proceedings of the 24th international conference on world wide web. 2015: 1067-1077.
- [40] Wang S, Tang J, Aggarwal C, et al. Signed network embedding in social media[C]//Proceedings of the 2017 SIAM international conference on data mining. Society for Industrial and Applied Mathematics, 2017: 327-335.
- [41] Yuan S, Wu X, Xiang Y. SNE: signed network embedding[C]//Pacific-Asia conference on knowledge discovery and data mining. Cham: Springer International Publishing, 2017: 183-195.
- [42] Huang J, Shen H, Hou L, et al. SDGNN: Learning node representation for signed directed networks[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(1): 196-203.
- [43] Derr T, Ma Y, Tang J. Signed graph convolutional networks[C]//2018 IEEE international conference on data mining (ICDM). IEEE, 2018: 929-934.
- [44] Huang J, Shen H, Hou L, et al. Signed graph attention networks[C]//International conference on artificial neural networks. Cham: Springer International Publishing, 2019: 566-577.
- [45] Li Y, Tian Y, Zhang J, et al. Learning signed network embedding via graph attention[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(04): 4772-4779.
- [46] Liu H, Zhang Z, Cui P, et al. Signed graph neural network with latent groups[C]//Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining. 2021: 1066-1075.
- [47] Chen T, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations[C]//International conference on machine learning. PmLR, 2020: 1597-1607.
- [48] He K, Fan H, Wu Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 9729-9738.
- [49] Grill J B, Strub F, Althé F, et al. Bootstrap your own latent-a new approach to self-supervised learning[J]. Advances in neural information processing systems, 2020, 33: 21271-21284.
- [50] Caron M, Misra I, Mairal J, et al. Unsupervised learning of visual features by contrasting cluster assignments[J]. Advances in neural information processing systems, 2020, 33: 9912-9924.
- [51] Ma J, Qin J, Ji P, et al. Subgraph collaborative graph contrastive learning for

- recommendation[C]//International Conference on Artificial Neural Networks. Cham: Springer Nature Switzerland, 2024: 105-120.
- [52] Jin X, Li J, Chen L, et al. L²CL: Embarrassingly Simple Layer-to-Layer Contrastive Learning for Graph Collaborative Filtering[J]. arXiv preprint arXiv:2407.14266, 2024.
- [53] Xu J, Chen Z, Yang S, et al. NLGCL: Naturally Existing Neighbor Layers Graph Contrastive Learning for Recommendation[C]//Proceedings of the Nineteenth ACM Conference on Recommender Systems. 2025: 319-329.
- [54] Liu Z, Xiang H, Liang R, et al. Graph contrastive learning via hierarchical multiview enhancement for recommendation[J]. IEEE Transactions on Industrial Informatics, 2024, 21(3): 2403-2412.
- [55] Wu X, Wang H, Yao J, et al. NPGCL: neighbor enhancement and embedding perturbation with graph contrastive learning for recommendation: X. Wu et al[J]. Applied Intelligence, 2025, 55(6): 407.
- [56] Wei H, Wang J, Ji Y, et al. Hierarchical neighbor-enhanced graph contrastive learning for recommendation[J]. Knowledge-Based Systems, 2025, 315: 113263.
- [57] Hsieh C K, Yang L, Cui Y, et al. Collaborative metric learning[C]//Proceedings of the 26th international conference on world wide web. 2017: 193-201.
- [58] Ebesu T, Shen B, Fang Y. Collaborative memory network for recommendation systems[C]//The 41st international ACM SIGIR conference on research & development in information retrieval. 2018: 515-524.
- [59] Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.
- [60] Han J, Zheng L, Xu Y, et al. Adaptive deep modeling of users and items using side information for recommendation[J]. IEEE transactions on neural networks and learning systems, 2019, 31(3): 737-748.
- [61] He X, Liao L, Zhang H, et al. Neural collaborative filtering[C]//Proceedings of the 26th international conference on world wide web. 2017: 173-182.
- [62] Yu L, Sun L, Du B, et al. Towards better dynamic graph learning: New architecture and unified library[J]. Advances in Neural Information Processing Systems, 2023, 36: 67686-67700.
- [63] Koren Y. Collaborative filtering with temporal dynamics[C]//Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining. 2009: 447-456.
- [64] Cai X, Huang C, Xia L, et al. LightGCL: Simple yet effective graph contrastive learning for recommendation[J]. arXiv preprint arXiv:2302.08191, 2023.

- [65] Yu L, Sun L, Du B, et al. Towards better dynamic graph learning: New architecture and unified library[J]. *Advances in Neural Information Processing Systems*, 2023, 36: 67686-67700.
- [66] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. *Advances in neural information processing systems*, 2017, 30.
- [67] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. *arXiv preprint arXiv:1503.02531*, 2015.
- [68] Tang J, Wang K. Ranking distillation: Learning compact ranking models with high performance for recommender system[C]//*Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 2018: 2289-2298.
- [69] He X, Liao L, Zhang H, et al. Neural collaborative filtering[C]//*Proceedings of the 26th international conference on world wide web*. 2017: 173-182.
- [70] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. *arXiv preprint arXiv:1409.0473*, 2014..
- [71] Trivedi R, Farajtabar M, Biswal P, et al. Dyrep: Learning representations over dynamic graphs[C]//*International conference on learning representations*. 2019.
- [72] Seo C, Jeong K J, Lim S, et al. SiReN: Sign-Aware Recommendation Using Graph Neural Networks[J]. *IEEE transactions on neural networks and learning systems*, 2024, 35(4): 4729-4743.

致谢

“行而不辍，未来可期。”

岁月不居，时节如流。转眼间，三年的研究生学习生活已接近尾声。当真正提笔写下这篇致谢时，心中却久久难以平静。回望这段求学时光，从最初的迷茫与探索，到逐渐明确方向、不断积累与成长，点点滴滴都成为记忆中弥足珍贵的片段。这段时光不仅记录着学术上的积累与突破，也见证了个人心境的变化与成长。论文的完成，既是阶段性的终点，更是未来继续前行的新起点。

首先，我要向我的导师牛云云老师致以最诚挚的感谢和最崇高的敬意。在整个研究生阶段，从课题的选择、研究方向的确立，到论文的结构设计与反复修改，牛老师始终给予我耐心而细致的指导。老师严谨认真的学术态度、扎实深厚的专业素养以及对科研一丝不苟的精神，使我深受启发。在论文研究过程中，无论是研究思路上的困惑，还是实验过程中的困难，牛老师总是耐心指导、悉心点拨，使我能够不断完善研究思路、逐步推进研究工作。老师不仅教会我如何做科研，更让我学会以严谨和踏实的态度面对学术与人生。能够在研究生阶段得到牛云云老师的指导，是我莫大的幸运，在此谨致以衷心的感谢。

同时，衷心感谢在研究生学习阶段给予我帮助和指导的各位任课教师。老师们严谨的治学精神和认真负责的教学态度，使我在专业知识和科研能力方面得到了系统的训练，也为本论文的顺利完成奠定了坚实的基础。

感谢实验室的同学和朋友们。感谢王鹏程、刘尉琪、刘少林、刘日葵、陈心怡、杜松芝、童兴燕、范帅尧、付国宁、连文迪等各位同门、室友、朋友。正是你们的理解、鼓励和陪伴，让我在面对困难和压力时依然能够保持前行的勇气。在那些或迷茫或焦虑的时刻，你们的鼓励让我重新找回信心，也让我更加坚定地走下去，我还要感谢两位特别的朋友连文迪和王鹏程同学，无数个熬夜做实验写论文的深夜，是你们的积极乐观给了我热爱生活的动力，祝你们前途似锦。

最后，我要感谢一直默默支持我的家人。无论身处何地，你们始终给予我最坚定的支持与最温暖的牵挂。正是你们的理解与包容，让我能够安心投入到学习与研究之中。家人的支持是我不断努力的动力，也是我能够坚持走到今天的重要力量。

求学之路虽有终点，但人生的旅程仍在继续。愿未来的自己始终保持热爱与初心，在更广阔的天地中不断探索与成长。谨以此文，向所有曾给予我帮助、支持与鼓励的人致以最真诚的感谢。

附录

曾燕，来自湖南省衡阳市。

2019 年 9 月至 2023 年 6 月就读于湖南工商大学计算机学院，修计算机科学与技术专业并取得工学学士学位。

2023 年 9 月至今，于中国地质大学（北京）信息工程学院攻读硕士研究生学位，专业为计算机技术。

2025 年 8 月取得软件著作权《基于符号感知的图神经网络推荐算法优化系统 V1.0》，登记号：2025SR1548471。