

分类号

密级

中国地质大学(北京)
专业硕士学位论文

基于多模态特征融合的药物-靶点相互作用预测

研究生 付国宁 学号 2104230028

专业学位类别 电子信息 专业 计算机技术

校内导师 牛云云 产业导师 张永虹

学习方式 全日制

2026 年 4 月

**A Dissertation Submitted to
China University of Geosciences for Master of Professional
Degree**

**Drug-Target Interaction Prediction Based on Multimodal
Feature Fusion**

Master Candidate: Guoning Fu

Professional Degree: Electronic and Information Engineering

Dissertation Supervisor: Prof. Yunyun Niu

Associate Supervisor: Yonghong Zhang

China University of Geosciences (Beijing)

声 明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国地质大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签 名：_____日 期：_____

关于论文使用授权的说明

本人完全了解中国地质大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。**延期公开的论文在到期公开后应遵守此规定。**

签 名：_____导师签名：_____日 期：_____

摘要

药物-靶点相互作用预测是新药研发和药物重定位的重要环节,传统的实验方法周期长且成本高。生物信息学方法与计算机模拟技术的引入在一定程度上提升了药物发现效率,其中深度学习方法在药物-靶点相互作用预测任务中表现出较好的性能。但是,现有的预测算法仍存在一些不足。首先,模型提取蛋白质长序列和分子图特征的能力有限。其次,异构的药物与靶点数据分布于不同的特征空间,模型难以实现跨模态的有效融合。最后,已知的药物靶点网络非常稀疏,限制了模型的泛化能力。针对上述问题,本文深入研究了图神经网络、状态空间模型和多模态技术,提出了两种新的药物靶点相互作用预测算法,主要研究内容如下:

(1) 针对长序列计算量大和网络数据稀疏的问题,提出了基于 Mamba 和图对比学习的多模态药物靶点相互作用预测算法,即 MGCL-DTI。在微观层面,该算法引入了 Mamba 架构,通过构建图 Mamba 和双向 MambaFormer,高效提取了药物和靶点的局部特征。在宏观层面,该算法构建了同构相似性网络,结合图对比学习机制,模型能够挖掘全局的拓扑关系。最后,该算法通过自适应权重融合了宏观和微观特征。这种方法有效缓解了数据稀疏问题,提升了预测性能。

(2) 针对图神经网络感受野受限和多模态特征未对齐的问题,提出了基于图 Transformer 和文本语义融合的药物靶点相互作用预测算法,即 GTCM-DTI。该算法利用增强的图 Transformer 作为编码器,通过加入原子中心性、空间位置和边特征编码,精准刻画了分子的微观结构,并沿用双向 Mamba 机制高效提取靶点序列特征。此外,本文设计了跨模态双向自适应引导融合模块,该模块利用注意力机制,实现了分子图和 SMILES 文本的双向信息交互。这种设计弥补了模态间的语义差异,增强了分子特征的表达能力。

(3) 在多个公开数据集上进行了全面的实验验证。本文在 C.elegans、Human 和 DrugBank 数据集上测试了所提出的算法。实验结果表明, MGCL-DTI 和 GTCM-DTI 模型在 AUC 和 AUPR 指标上均优于现有的主流方法。配对 t 检验结果进一步证实,本文模型的性能提升在所有数据集上均具有统计学显著性 ($p < 0.05$)。此外,本文还进行了消融实验和参数分析,证明了各个核心模块的有效性以及模型的稳定性。同时,本文结合特征聚类与多模态注意力的可视化分析,直观展示了模型特征学习与跨模态对齐的可解释性;并结合针对性靶点的应用案例分析,进一步印证了所提算法在临床前药物研发与智能药物筛选中的潜力。本文的研究为智能药物研发提供了有效的计算辅助工具。

关键词: 药物-靶点相互作用, 状态空间模型, 图对比学习, 图 Transformer, 多模态融合

Abstract

Predicting drug-target interaction (DTI) is a crucial step in the drug discovery pipeline, while traditional experimental methods are notoriously time-consuming and costly. The introduction of bioinformatics methods and computational simulations has improved the efficiency of drug discovery to a certain extent, among which deep learning approaches have demonstrated favorable performance in DTI prediction tasks. However, existing computational models still face several major limitations: inadequate feature extraction capabilities for long protein sequences and complex molecular graphs, distinct feature spaces of heterogeneous drug and target data that hinder effective cross-modal fusion, and extreme sparsity in known drug-target networks that restricts model generalization. To address these challenges, this study investigates advanced graph neural networks, state space models, and multimodal learning techniques, proposing two novel DTI prediction algorithms. The main contributions are as follows:

(1) To tackle the computational bottleneck of long sequences and network sparsity, we propose a multimodal DTI prediction framework based on the Mamba architecture and graph contrastive learning, termed MGCL-DTI. At the micro-level, this method leverages the Mamba architecture by constructing a Graph Mamba and a Bi-MambaFormer to efficiently extract local structural features of drugs and targets. At the macro-level, we construct homogeneous similarity networks and employ a graph contrastive learning mechanism to mine global topological relationships. Finally, macro and micro features are integrated via an adaptive weighting strategy. This approach effectively mitigates the data sparsity issue and significantly boosts predictive performance.

(2) To overcome the limited receptive fields of graph neural networks and the misalignment of multimodal features, we introduce GTCM-DTI, an algorithm based on Graph Transformers and text semantic fusion. This model utilizes an enhanced Graph Transformer as its encoder, precisely characterizing molecular microstructures by incorporating atom centrality, spatial position, and edge feature encodings. Meanwhile, a bidirectional Mamba mechanism is employed to efficiently extract the features of target proteins. Furthermore, we design a cross-modal bidirectional adaptive guided fusion module. Driven by attention mechanisms, this module enables bidirectional information flow between molecular graphs and SMILES

sequences. Such a design bridges the semantic gap between different modalities and enhances the representational power of molecular features.

(3) Comprehensive experiments were conducted on benchmark datasets, including C.elegans, Human, and DrugBank. The results demonstrate that both MGCL-DTI and GTCM-DTI outperform state-of-the-art methods in terms of AUC and AUPR metrics. Paired t-tests further verify that these performance improvements are statistically significant across all datasets ($p < 0.05$). Additionally, ablation studies and parameter analyses validate the efficacy of the core modules and the overall stability of the models. We also provide visual analyses combining feature clustering and multimodal attention, offering an intuitive interpretation of the models' feature learning and cross-modal alignment behaviors. Supported by specific target case studies, the findings confirm the immense potential of the proposed algorithms in preclinical drug discovery and intelligent virtual screening. Ultimately, this research provides powerful computational tools to facilitate AI-driven pharmaceutical development.

Key words: Drug-target interaction, State space model, Graph contrastive learning, Graph Transformer, Multimodal fusion

目 录

摘要	1
Abstract	2
1 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	1
1.2.1 基于序列与图特征的预测方法	2
1.2.2 基于网络拓扑与图对比学习的预测方法	2
1.2.3 基于多模态融合的预测方法	3
1.2.4 蛋白质结构预测时代下的 DTI 研究定位	4
1.3 本文研究内容	5
1.4 本文架构	6
2 相关理论与技术基础	8
2.1 生物分子数据的数字化表征	8
2.1.1 药物分子的数字化表征	8
2.1.2 蛋白质靶点的数字化表征	9
2.2 序列建模演进与状态空间模型	9
2.2.1 序列建模技术演进	9
2.2.2 状态空间模型	10
2.2.3 Mamba 架构	12
2.3 图神经网络与图 Transformer	14
2.3.1 图神经网络	14
2.3.2 图 Transformer 架构	15
2.4 自监督对比学习	16
2.4.1 对比学习范式	16
2.4.2 互信息最大化原理	16
2.4.3 InfoNCE 损失函数	17
2.5 多模态特征融合机制	17
2.5.1 交叉注意力	17
2.5.2 特征聚合与输出	18

2.6 本章小结	18
3 基于 Mamba 增强与图对比学习的多模态 DTI 预测模型	20
3.1 概述	20
3.2 算法设计	20
3.2.1 模型整体架构	20
3.2.2 基于 Mamba 的微观结构特征提取	21
3.2.3 基于图对比学习的宏观关系增强	23
3.2.4 多模态自适应特征融合	26
3.3 实验结果分析	27
3.3.1 数据集	27
3.3.2 实验设置	28
3.3.3 评价指标	29
3.3.4 基线模型	30
3.3.5 对比实验	31
3.3.6 消融实验	34
3.3.7 参数分析	36
3.3.8 可视化分析	38
3.3.9 案例研究	39
3.3.10 模型计算效率分析	40
3.4 本章小结	41
4 基于图 Transformer 与文本语义融合的 DTI 预测模型	42
4.1 引言	42
4.2 算法设计	42
4.2.1 模型整体架构	42
4.2.2 基于图 Transformer 的药物分子结构编码	44
4.2.3 跨模态双向自适应引导融合模块	46
4.2.4 基于双向 Mamba 机制的靶点蛋白质序列编码	49
4.2.5 药物-靶点特征交互预测与模型优化	49
4.3 实验分析	50
4.3.1 实验数据与设置	50

4.3.2 对比实验	51
4.3.3 消融实验	54
4.3.4 参数分析	55
4.3.5 可视化分析	57
4.3.6 案例研究	58
4.4 本章小结	59
5 总结与展望	62
5.1 全文总结	62
5.2 研究展望	63
参考文献	64
致谢	70
附录	71

1 绪论

1.1 研究背景及意义

准确预测药物-靶点相互作用 (Drug-Target Interaction, DTI) 是理解药效机制、挖掘药物新用途的关键环节。药物发挥疗效的机制通常是通过药物小分子与体内特定蛋白质靶点结合。这种结合会引起蛋白质构象的变化或功能调节，来干预相关的生物信号通路，最终达到治疗疾病的目的^[1]。因此，准确识别药物与蛋白质之间的相互作用关系，有助于理解药物作用机制，并为开发高效能药物提供基础。

新药开发过程通常周期较长且成本较高。在传统的研发模式下，一种新药从最初的实验室筛选到获批上市，往往需要耗费 10 至 20 年的研发周期，且综合投入成本高达数亿甚至数十亿美元^[2]。在庞大的候选化学分子空间与复杂的蛋白质组空间中，传统的生化实验方法（如表面等离子共振 SPR、等温滴定热法 ITC 等）虽然结果准确，但受限于通量低、操作复杂且实验周期长^[3]。面对指数级增长的候选药物对，单纯依靠人工实验进行逐一筛选不仅效率低下，而且面临巨大的资金投入风险。统计数据表明，由于缺乏有效的早期筛选手段，传统实验筛选出的候选药物进入临床试验后的成功率往往低于 14%^[4]，这种高投入、低产出的现状已成为制约现代医药创新的主要瓶颈。

随着高性能计算能力的提升以及生物医药大数据不断积累^[5]，基于计算的 DTI 预测方法展现出显著的优势。相比传统的生物实验，计算机辅助预测能够在全基因组规模上对大量的小分子配体进行高效评估，从而在研发早期快速锁定具有潜力的候选药物^[6]。这不仅极大缩短了临床前研究的周期，还为药物重定位提供了可能，即通过发现已上市药物的新靶点来拓展其临床用途，进而降低药物研发的风险与成本。同时，单纯追求研发速度的提升是不够的，计算机辅助预测在药物研发中的最大价值应是提高早期决策的质量，从而在根本上降低临床阶段的高失败率^[7]。

因此，开发高精度、高效率的 DTI 预测算法，不仅能够为实验验证提供可靠的候选列表，降低湿实验的盲目性，还能在研发早期规避潜在的脱靶风险，对于提升药物研发效率、优化医疗资源配置有重要的理论价值与现实意义。

1.2 国内外研究现状

DTI 预测作为解析药物小分子与生物体内靶点蛋白之间潜在联系的关键任务，旨在判断给定的药物-靶点对是否存在相互作用^[8]。然而，在实际应用中，生物医药数据具有高度的异质性与稀疏性，且通过湿实验获取已知交互对的成本极高，这严重制约了模型对药物

与靶点间深层生化语义的学习^[9]。为了突破这一局限，国内外学者开展了广泛的研究，试图从微观结构特征提取、宏观关系网络挖掘以及多源信息融合等维度提升预测精度。现有研究主要呈现出三大趋势：一是基于序列与图特征的微观表征方法，侧重于从分子底层序列或拓扑结构中提取生化属性；二是基于网络拓扑与图对比学习的增强方法，利用全局关联信息提升模型泛化能力；三是基于多模态自适应融合的综合预测框架，通过整合异构视图信息实现优势互补^[10]。

1.2.1 基于序列与图特征的预测方法

准确提取并表征生物分子与药物的多维度特征，是构建高性能 DTI 预测模型的基础^[11]。该类方法的核心假设是：药物的化学结构和蛋白质的氨基酸序列蕴含了决定两者是否结合的关键语义信息。根据特征提取维度的不同，此类方法主要分为基于序列的建模和基于图结构的表征。在基于序列的建模方面，研究者最初利用卷积神经网络 (Convolutional Neural Network, CNN) 或循环神经网络 (Recurrent Neural Network, RNN) 自动提取生化特征^{[12][13]}。例如，Öztürk 等人提出的 DeepDTA 模型^[6]利用一维卷积捕捉药物 SMILES 序列和蛋白质序列的局部模式，突破了传统手工特征指纹的局限。随后，为了解决序列中的长程依赖问题，基于 Transformer 架构的模型逐渐成为主流。Huang 等人提出的 MolTrans 模型^[14]利用频繁子序列挖掘技术将生物分子分解为子结构，并通过 Transformer 编码器捕捉这些子结构间的显式相互作用。

在基于图结构的表征方面，考虑到药物分子天然的非欧几里得结构，图神经网络 (Graph Neural Network, GNN) 展现出一定的优势。Nguyen 等人提出的 GraphDTA 模型^[15]将药物分子视为图结构，利用 GNN 提取拓扑特征，验证了图表征在处理药物空间模式上的优越性。然而，在真实的生物数据处理中，上述微观表征方法仍存在不足。一方面，单纯依赖序列建模的模型往往忽略了分子内部的空间拓扑关联；另一方面，传统的 GNN 或 Transformer 在捕捉药物分子远端官能团之间的复杂相互作用时能力有限。此外，现有模型多将药物-靶点对视为独立样本，往往忽略了已知交互网络中节点间的关联信息。这些局限性促使研究者转向探索更具计算效率的序列建模架构以及能够挖掘全局拓扑信息的对比学习机制。

1.2.2 基于网络拓扑与图对比学习的预测方法

基于网络拓扑的方法通过构建大规模异质网络，利用药物、靶点、疾病及副作用之间的复杂关联来推断潜在的相互作用模式。早期研究如 Luo 等人提出的 DTINet^[16]利用重启

随机游走算法在多元异质网络中获取药物和靶点的低维表示，并通过矩阵补全实现预测。An 等人提出的 NEDTP^[17]则利用 Word2Vec 算法将网络拓扑信息转换为特征向量，并结合提升决策树模型进行分类。此类方法虽然能够利用宏观拓扑信息，但在面对生物网络固有的高度稀疏性及噪声干扰时，其特征表示的鲁棒性仍有待提升。

为了进一步挖掘生物网络中的隐性关联并增强模型对噪声数据的抵抗力，DTI 预测任务中引入了图对比学习 (Graph Contrastive Learning, GCL)^{[18][19]}机制。图对比学习的核心思想是通过构建不同的增强视图，并利用 InfoNCE 等损失函数最大化同一节点在不同视图间表示的互信息，从而学习到具有视图不变性的全局特征。例如，Li 等人提出的 SGCL-DTI 模型^[20]采用监督协同对比学习方法，通过聚合相同标签样本的表示来优化特征空间。

然而，现有的图对比学习方法在 DTI 预测中仍面临挑战^[21]。一方面，对比视图的生成方式直接影响特征学习的质量，不当的扰动可能破坏生物网络中的关键拓扑结构。另一方面，如何在挖掘宏观全局关系的同时，捕捉微观理化性质，实现宏观关系特征与微观结构特征的有效融合，是当前提升模型预测准确性与泛化能力的关键。这促使研究者开始探索更具自适应性的多模态融合机制，以充分发挥多源异构信息的互补优势。

1.2.3 基于多模态融合的预测方法

随着深度学习技术的演进，DTI 预测研究开始向微观结构精细化与宏观关系全局化协同的方向演进，通过整合异构视图信息实现优势互补。此类方法的核心在于整合多模态信息，以弥补单一模态在表征生物分子时的不足。

在特征提取架构的创新方面，为了克服 Transformer 在处理蛋白质超长序列时 $O(N^2)$ 计算复杂度的瓶颈，具有线性复杂度的选择性状态空间模型 Mamba^[22]逐渐成为研究热点。Mamba 架构能够高效捕捉蛋白质序列的长程依赖关系，同时降低推理速度与显存占用。例如，Lou 等人提出的 MambaTransDTA 模型^[23]将 Mamba 与 Transformer 架构深度融合，利用其互补性提升了长短序列特征的建模质量。此外，图 Transformer (Graph Transformer)^[24]架构通过引入结构编码，能够有效刻画分子图的几何结构。

在多源信息交互与融合策略方面，研究者们设计了更为复杂的跨模态交互机制，以充分利用生物实体深层的生化特征。例如，Yang 等人提出的 CM-DTA 模型^[25]整合了药物文本表示、分子图以及靶点蛋白的结构图，通过多感知邻域注意力增强了特征的表达深度。此外，为了进一步挖掘异质网络中的高阶关联，Su 等人提出的 AMGDTI 模型^[26]引入了自适应元图学习机制，实现了对药物与靶点间复杂路径信息的动态建模。针对语义鸿沟问题，一些前沿模型开始尝试探索文本与图特征的跨模态双向交互机制^{[27][28]}。然而，现有的多模

态融合方法大多仍依赖于简单的特征拼接或单向注意力引导，往往无法充分利用图拓扑特征来辅助筛选文本中的核心语义，导致分子图的关键子结构与序列语义之间难以实现细粒度的对齐。因此，如何设计一种更为高效的双向信息交互与引导机制，突破结构与语义融合的瓶颈，是当前该领域待解决的核心难点。

当前 DTI 预测领域正处于从单一模态向跨模态深度交互、从计算密集型架构向高效线性架构转型的阶段。然而，如何在大量的稀疏生物网络中实现更稳健的特征融合，并进一步提升对冷启动场景下新型药物分子的泛化预测能力，仍是本研究及未来相关工作的探索重点。

1.2.4 蛋白质结构预测时代下的 DTI 研究定位

近些年来，以 AlphaFold2^[29]、AlphaFold3^[30]等为代表的技术取得了蛋白质结构预测的突破性进展，可以达到原子级的精度来预测蛋白质的三维构象，对 DTI 领域造成了深远的影响。传统的药物设计很大程度上依靠耗时的 X 射线晶体衍射或者冷冻电镜技术，但是高精度结构预测工具的出现使得基于结构的药物设计 (Structure-Based Drug Design, SBDD) 的逻辑更加完善。AlphaFold3 用扩散模型直接预测蛋白质-配体复合物结构，部分挑战了传统序列预测、基于图预测。

然而，尽管高精度结构数据日益丰富，基于序列和分子图的快速计算方法在现阶段及未来仍具备不可替代的科研与工业价值，其必要性体现在以下三个维度：

计算效率和超大规模筛选之间的关系。虽然结构预测精度大幅提升，但是对百万量级的小分子库和数万个潜在靶点进行全空间的分子对接或者端到端的复合物结构模拟，其计算开销仍然非常大。基于序列和图特征的 DTI 预测模型一般具有线性或者准线性的时间复杂度，可以在短时间内完成高通量的初筛任务，作为前端筛选环节，有效地缩小候选药物的空间^[31]。

其次是蛋白质的动态性以及构象多变性。蛋白质在生理环境里不是静止的结构，其生物学功能一般依靠构象转换来达成。目前 AlphaFold 类工具预测的大多只是静态或者某个状态下的结构，不能完全覆盖药物结合过程中所发生的诱导契合 (Induced Fit) 效应。而深度学习模型可以利用大量的相互作用数据，隐式地捕捉序列中蕴含的动态演化规律和结合偏好，对于结构比较柔性的靶点来说，它的鲁棒性要强得多^[32]。

最后是多模态信息的互补性。DTI 本质就是多物理场、多维度的复杂相互作用。单一的结构信息不能完全解释所有的生物活性规律。采用 SMILES 文本语义、分子图拓扑结构和进化序列信息来对结合机理进行补全，多模态模型可以从不同的特征空间对结合机理进

行补全。图神经网络可以捕捉到分子的空间拓扑特征，在关联预测中也证明了它有明显的优势^[28]。

因此高精度结构预测技术并不是取代了序列和图的方法，而是和序列、图的方法一起起到互补的作用。后 AlphaFold 时代，怎样高效融合结构先验和多模态序列/图特征来构建精度和效率并存的预测体系，依然是 DTI 领域亟待解决的核心问题^[33]。

1.3 本文研究内容

针对现有研究在长序列建模效率、微观结构表征精度以及多模态语义对齐等方面的局限性，本文提出了一套递进式的深度学习解决方案。首先，本文设计了一种基于 Mamba 增强与图对比学习的多模态预测模型，旨在利用线性复杂度的状态空间模型突破蛋白质长序列建模的性能瓶颈，并结合对比学习机制挖掘生物网络中的全局关联信息。然而，在研究过程中发现，尽管该模型在长序列和全局关系挖掘上表现优异，但在药物分子微观几何结构的精细表征以及图文跨模态语义的一致性对齐上仍有提升空间。基于此，本文进一步提出了一种基于图 Transformer 与文本语义融合的预测模型，通过引入具备结构归纳偏置的图 Transformer 并设计双向自适应引导融合机制，实现了对药物分子多维特征的深度集成。本文具体工作内容如下：

(1) 本文提出了一个基于 Mamba 增强与图对比学习的药物靶点相互作用预测模型 MGCL-DTI，分为微观特征提取、宏观关系增强和特征融合预测三个阶段。在微观特征提取阶段，模型利用具有线性计算复杂度的 Mamba 架构分别构建双向 MambaFormer 和图 Mamba，以高效捕捉蛋白质序列与药物分子序列的长程依赖关系。在宏观关系增强阶段，本文通过构建药物与靶点的同构相似性网络并引入图对比学习机制，利用自监督学习策略最大化不同增强视图间的互信息，从而挖掘生物异质网络中潜在的拓扑结构特征，缓解了数据稀疏带来的泛化难题。最后，模型通过自适应特征融合模块将多尺度特征进行整合，实现更精准的相互作用预测。

(2) 本文进一步提出了一个基于图 Transformer 与文本语义融合的药物靶点相互作用预测模型 GTCM-DTI。该模型由结构特征提取、文本语义对齐和双向引导融合三个核心模块组成。为了提升药物分子的表征精细度，本文利用增强型图 Transformer 作为结构编码器，通过注入原子中心性编码、空间位置编码及边特征编码，精准刻画分子的微观拓扑结构。针对图结构与文本描述间的语义鸿沟问题，本文设计了跨模态双向自适应引导融合模块，利用注意力机制实现药物分子图与 SMILES 文本语义的双向信息对齐与互补增强。该模型在克服了单一图拓扑表征的局限性的同时，提升了模型对复杂分子的表征能力和预测精度。

(3) 在实验方面, 本文在三个不同规模的基准数据集上对上述两个模型进行了性能分析实验, 并采用十折交叉验证方法确保实验结果的公平性与可靠性。通过与多个先进的 SOTA 基线模型进行性能对比, 验证了本文模型在 AUC 和 AUPR 等指标上的领先地位; 通过引入显著性水平为 0.05 的配对 t 检验, 从统计学角度验证了模型改进效果的显著性; 通过消融实验验证了 Mamba 架构、图对比学习机制、图 Transformer 编码以及跨模态融合模块对模型性能的贡献; 通过参数分析实验探究了隐藏层维度、层数及对比学习超参数对模型性能的影响。此外, 本文还结合可视化分析, 展示了模型融合多模态特征的过程, 并通过苯丙胺与肾上腺素能受体的预测案例, 探讨了所提模型在虚拟筛选中的实际应用价值。

1.4 本文架构

本文围绕药物-靶点相互作用预测任务展开研究, 针对现有深度学习模型在特征提取效率、结构表征精度以及多模态语义融合方面存在的问题, 提出了两种递进式的多模态预测模型。全文共分为五章, 具体内容安排如下:

第一章: 绪论。主要阐述了药物-靶点相互作用预测的研究背景与现实意义, 系统梳理了国内外相关领域的研究现状并分析了现有计算方法的局限性, 最后明确了本文的研究内容与整体的章节架构。

第二章: 相关理论与技术基础。重点介绍了药物分子与靶点蛋白的数字化表征方法, 并详细阐述了本文算法构建所依赖的核心深度学习技术, 包括状态空间模型、图 Transformer、图对比学习以及多模态特征融合机制, 为后续章节的模型设计奠定了理论基础。

第三章: 本章提出了一个基于 Mamba 增强与图对比学习的多模态预测模型 MGCL-DTI。首先详细介绍了模型架构, 包括基于 Mamba 的微观结构特征提取、基于图对比学习的宏观关系增强和多模态自适应特征融合三个模块的设计。通过实验设计, 对实验数据集、评价指标、实验环境及参数设置和基线模型进行详细介绍。最后通过对模型进行对比、配对 t 检验、消融、参数分析等实验, 并结合特征可视化与潜在药物-靶点相互作用案例, 对该模型的性能与效率进行了全面的评估与验证。

第四章: 本章提出了一个基于图 Transformer 与文本语义融合的预测模型 GTCM-DTI。首先详细描述了模型架构, 包括基于图 Transformer 的分子结构编码、基于双向 Mamba 的蛋白质序列编码和跨模态双向自适应引导融合三个模块的设计。其次, 对实验数据集、评价指标、实验环境及参数设置进行介绍。最后, 通过对比实验、消融实验、参数分析实验验证模型性能, 并借助注意力可视化与肾上腺素能受体的案例研究及配对 t 检验分析, 对

该模型的实际预测能力与应用价值进行了分析与验证。

第五章：总结与展望。对全文的主要研究工作与核心成果进行了总结，分析了当前研究设计中存在的不足，并结合计算生物学领域的发展趋势对未来的优化与探索方向进行了展望。

2 相关理论与技术基础

2.1 生物分子数据的数字化表征

在药物-靶点相互作用预测的研究中，数据预处理是构建深度学习模型的基石。由于药物分子与蛋白质靶点在物理化学性质、空间结构尺度以及生物学功能上存在明显差异，计算机无法直接理解其原始的生化形式。因此，首要任务是把这些非结构化的生物信息转化为计算机可处理的数值向量或图结构数据。本节将分别阐述药物分子与蛋白质靶点的数字化表征方法，为后续章节中构建多模态特征提取网络奠定数据基础。

2.1.1 药物分子的数字化表征

药物分子通常是具有特定空间构型的有机小分子，其数字化表征主要涵盖序列形式与图结构形式。简化分子线性输入规范 (SMILES) 是目前化学信息学中最通用的序列化标准，它依据特定的语法规则，将分子的原子符号、化学键类型、分支以及环状拓扑结构映射为一串线性的 ASCII 字符串^[34]。例如，苯环结构可被编码为线性字符。由于 SMILES 具有类似于自然语言的线性属性，它非常适合作为 RNN 或状态空间模型 (State Space Model, SSM) 的输入，以提取隐含在化学语言中的全局语义特征^[6]。如图 2-1 所示，药物分子的二维拓扑结构可以通过深度优先遍历算法被精确转换为对应的 SMILES 字符串。




图 2-1 药物分子数字化表征示意图

除了序列表示，分子图是另一种能够更直观反映药物拓扑结构的数据形式^[35]。在数学上，药物分子被定义为无向图 $G=(V,E)$ ，其中节点集合 V 代表原子，边集合 E 代表化学键。每个节点 v_i 关联一个特征向量，包含原子序数、度数、形式电荷、手性状态及杂化类型等理化属性；每条边 e_{ij} 则包含化学键类型，如单键、双键、芳香键等，以及是否处于环系中等信息。这种基于图论的表征方式保留了原子间的空间连接性，使得 GNN 或图 Transformer 能够通过消息传递机制聚合局部邻域信息，从而捕获分子的微观结构特征^[36]。

2.1.2 蛋白质靶点的数字化表征

蛋白质是由氨基酸残基通过肽键缩合而成，其表征维度直接决定了模型对结合位点的感知精度。蛋白质的一级结构表现为由 20 种标准氨基酸组成的线性序列 $P = \{p_1, p_2, \dots, p_L\}$ ，其中 L 代表序列长度^[37]。由于蛋白质序列通常包含数百甚至数千个残基，捕捉其长程依赖关系一直是建模的难点。传统 Transformer 架构处理此类超长序列时计算复杂度呈二次方增长，而本研究引入的 SSM 凭借其线性计算复杂度的优势，能够高效编码蛋白质全长序列的特征^[22]。




图 2-2 蛋白质序列与接触图矩阵示意图

蛋白质的功能在很大程度上取决于其折叠后的三维空间结构^[38]。为了将复杂的三维构象转化为适合图神经网络处理的二维形式，研究者通常采用接触图矩阵来表征蛋白质的拓扑结构^[39]。如图 2-2 所示，该方法基于距离阈值判定残基间的相互作用：若序列中第 i 个残基与第 j 个残基在三维空间中的 C_α 原子欧氏距离小于设定阈值，则在接触矩阵对应位置记为 1，表示两者存在空间接触或潜在的相互作用；否则记为 0。通过这种方式，蛋白质被构建为残基相互作用图，模型得以利用图拓扑学习算法捕捉氨基酸在三维空间中的邻近关系，从而更准确地模拟药物分子嵌入蛋白质结合口袋时的物理化学过程。

2.2 序列建模演进与状态空间模型

2.2.1 序列建模技术演进

在计算生物学与药物发现领域，蛋白质氨基酸序列与药物 SMILES 字符串本质上均属于具有强长程依赖属性的一维序列数据。深度学习模型对此类数据的建模能力，经历了从递归神经网络到自注意力机制的演进，但现有的主流架构在处理超长生物序列时仍面临计算瓶颈。

早期的序列建模主要依赖于 RNN 及其变体长短期记忆网络 (Long Short-Term Memory, LSTM)^[40]。RNN 通过维护一个隐含状态向量 h_t 来编码历史信息，其状态更新遵循递归方程，

计算公式如下：

$$h_t = \sigma(W_h h_{t-1} + W_x x_t + b) \quad (2-1)$$

其中， W_h 与 W_x 为权重矩阵， b 为偏置项， σ 为非线性激活函数。虽然这种递归机制在理论上具备图灵完备性，能够处理任意长度的序列，但在实际应用中存在两大缺陷：其一是串行计算限制，即 t 时刻的状态计算必须等待 $t-1$ 时刻完成，导致无法利用 GPU 在大规模数据集上进行并行训练；其二是梯度消失问题，随着序列长度增加，反向传播的梯度在多次连乘后呈指数级衰减，使得模型难以捕捉距离超过几百个时间步的氨基酸残基间的相互作用。

为了突破串行计算的限制，Vaswani 等人提出了基于自注意力机制的 Transformer 架构^[41]。该架构通过并行计算序列中所有位置对之间的相互作用，实现了全局感受野。对于输入序列矩阵 $X \in \mathbb{R}^{L \times d}$ ，标准缩放点积注意力 (Scaled Dot-Product Attention) 的计算公式如下：

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-2)$$

其中， Q, K, V 是由输入 X 经线性投影得到的查询、键和值矩阵， d_k 为特征维度。尽管 Transformer 在捕捉全局上下文信息方面表现卓越，但其核心缺陷在于计算复杂度与显存占用呈二次方增长^[42]。注意力分数矩阵 $A = QK^T$ 的维度为 $L \times L$ ，这意味着当序列长度 L 从 512 增加到 4096 时，计算量将增加 64 倍。对于平均长度往往超过 2000 甚至达到数万的蛋白质序列， $O(L^2)$ 的时间与空间复杂度使得 Transformer 在大规模生物序列分析任务中显得极其昂贵且难以部署。

2.2.2 状态空间模型

结构化状态空间模型是连接连续时间动态系统与离散序列建模的数学桥梁^[43]。其核心思想是将一维输入信号 $x(t) \in \mathbb{R}$ 通过一个高维隐状态 $h(t) \in \mathbb{R}^N$ 进行编码，再投影回一维输出 $y(t) \in \mathbb{R}$ 。在连续时间域内，该过程由线性常微分方程描述，计算公式如下：

$$h'(t) = Ah(t) + Bx(t), \quad y(t) = Ch(t) + Dx(t) \quad (2-3)$$

其中, $A \in \mathbb{R}^{N \times N}$ 为状态演化矩阵, 它决定了系统的动力学特性; $B \in \mathbb{R}^{N \times 1}$ 为输入控制矩阵; $C \in \mathbb{R}^{1 \times N}$ 为输出观测矩阵; $D \in \mathbb{R}^{1 \times 1}$ 为直接传递项 (通常假设为 0)。然而, 生物序列数据, 如蛋白质序列或药物 SMILES, 本质上是离散采样的信号, 无法直接输入连续系统。因此, 必须引入时间步长参数 Δ , 采用零阶保持 (Zero-Order Hold, ZOH) 原理将连续参数 (A, B) 转化为离散参数 $(\bar{A}, \bar{B})$ 。




图 2-3 连续时间信号的零阶保持 (ZOH) 离散化示意图

这一离散化过程的物理含义如图 2-3 所示, 根据 ZOH 假设, 系统在时间区间 $[t, t+\Delta]$ 内, 输入信号 $x(t)$ 被视为保持恒定, 即表现为阶梯状。基于此假设, 通过对式 2-3 求解解析积分, 可推导出离散化后的状态转移公式。离散状态矩阵 $\bar{A}$ 的计算公式如下, 其本质是矩阵指数函数的近似:

$$\bar{A} = \exp(\Delta A) = I + \Delta A + \frac{1}{2!}(\Delta A)^2 + \dots \approx (I - \Delta A/2)^{-1}(I + \Delta A/2) \quad (2-4)$$

在上式的最后一步中, 采用双线性变换进行近似计算, 以保证系统在离散化后的稳定性。

在推导离散输入控制矩阵 $\bar{B}$ 时, 离散化过程涉及对输入信号在时间区间内的积分运算, 其闭式解为:

$$\bar{B} = (\Delta A)^{-1}(\exp(\Delta A) - I)\Delta B \quad (2-5)$$

经过上述离散化处理，连续 SSM 转化为离散线性递归模型，计算公式如下：

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t \quad (2-6)$$

这种递归形式赋予了模型在推理阶段 $O(1)$ 的高效性，即生成下一个时间步仅需依赖当前状态，无需回溯历史。同时，由于该系统是线性时不变 (Linear Time-Invariant, LTI) 系统，其递归过程在数学上等价于全局卷积运算。通过展开递归项 $y_k = \bar{C}\bar{A}^k\bar{B}x_0 + \dots + \bar{C}\bar{A}^{L-1-k}\bar{B}x_k$ ，可以将输出序列表示为输入序列 x 与全局卷积核 $\bar{K}$ 的卷积，计算公式如下：

$$y = x * \bar{K}, \quad \bar{K} = (\bar{C}\bar{B}, \bar{C}\bar{A}\bar{B}, \dots, \bar{C}\bar{A}^{L-1}\bar{B}) \quad (2-7)$$

这种训练时并行卷积，推理时串行递归的双重特性，解决了长序列建模中效率与效果的矛盾。此外，为了解决梯度在长距离传播中的衰减问题，状态矩阵 A 通常采用 HiPPO (High-Order Polynomial Projection Operator) 矩阵进行初始化^[44]。HiPPO 矩阵能够将历史信息正交投影到多项式基底上，从数学上保证了模型能够记忆理论上无限长的历史信息，这对于捕获蛋白质三维折叠中的远端残基相互作用至关重要。

2.2.3 Mamba 架构

尽管以 S4^[43]为代表的结构化状态空间模型有效解决了长序列建模的计算效率问题，但在处理具有复杂上下文依赖的生物序列时仍存在局限性。其根本缺陷在于 LTI 的建模假设，即状态转移矩阵 A 与输入投影矩阵 B 在所有时间步均保持恒定。这意味着模型以相同的动力学规则处理序列中的每一个元素，无法实现基于输入内容的自适应信息筛选。针对这一问题，Mamba 架构提出了一种基于选择性扫描 (Selective Scan) 的时变参数化机制，从数学本质上赋予了模型内容感知能力^[22]。

Mamba 的核心创新在于打破了 LTI 系统的参数静态性，将关键参数 (B, C, Δ) 设计为当前输入 x_t 的函数。如图 2-4 所示，对于序列中的第 t 个时间步，模型不再使用全局共享的常数矩阵，而是通过线性投影层动态生成参数，计算公式如下：

$$B_t = \text{Linear}_B(x_t), \quad C_t = \text{Linear}_C(x_t), \quad \Delta_t = \text{Softplus}(\text{Parameter}(x_t)) \quad (2-8)$$

其中, $Linear()$ 表示线性映射层, $Parameter()$ 为用于动态计算步长 Δ_t 的可学习权重, $Softplus()$ 为激活函数以保证时间步长非负。这种参数化机制使得模型能够根据当前的氨基酸残基特征自适应地调节信息流, 将原本固定的递归更新方程转化为时变递归方程, 定义如下:

$$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t, \quad y_t = C_t h_t \quad (2-9)$$




图 2-4 Mamba 选择性扫描机制

在此机制下, 当 Δ_t 较小时, 模型倾向于忽略当前输入以保持历史状态 h_{t-1} ; 而当 Δ_t 较大时, 模型则倾向于重置状态以聚焦于当前输入。这种选择性机制对于识别蛋白质序列中的活性位点基序至关重要, 因为它允许模型在长距离非功能区域中保持上下文, 从而在遇到关键功能域时快速更新状态。

虽然引入时变参数解决了内容感知问题, 但也破坏了 LTI 系统的卷积等价性, 导致无法使用快速傅里叶变换 (FFT) 进行并行训练。为了在保持递归特性的同时实现高效计算, Mamba 引入了硬件感知并行扫描算法 (Hardware-aware Parallel Scan)。该算法利用 GPU 的内存层级结构, 采用前缀和思想, 在静态随机存取存储器 (SRAM) 中执行核融合操作, 直接计算最终状态而不是频繁读写高带宽内存 (HBM)。这种 IO 优化策略使得 Mamba 在训练速度上能够媲美经过高度优化的 Transformer, 其训练时间与显存占用均优化至线性级 $O(L)$, 成功解决了传统 RNN 无法并行与传统 Transformer 计算昂贵的困境。

为了直观展示 Mamba 架构的技术优势, 表 2-1 对比了不同主流序列建模架构在处理长度为 L 的序列时的时空复杂度差异。

表 2-1 序列建模架构时空复杂度对比表

架构特性	RNN / LSTM	Transformer	Mamba
时间复杂度（训练）	$O(L)$	$O(L^2)$	$O(L)$ （并行扫描）
时间复杂度（推理）	$O(1)$	$O(L)$ （随 Cache 增长）	$O(1)$
空间复杂度（显存）	$O(L)$	$O(L^2)$	$O(L)$
长程依赖建模能力	较弱（梯度消失）	强（全局关注）	强（内容感知选择）

综上所述，Mamba 凭借其在线性复杂度下实现全局上下文建模的能力，为本研究中处理超长蛋白质序列与药物分子 SMILES 提供了理想的骨干网络。

2.3 图神经网络与图 Transformer

2.3.1 图神经网络

在本研究中，药物分子被建模为图结构 $G=(V,E)$ ，其中节点 V 代表原子，边 E 代表化学键。GNN 的核心思想是基于消息传递机制的邻域聚合策略。与传统卷积神经网络在欧氏空间网格上滑动不同，GNN 通过递归地聚合邻居节点的特征来更新中心节点的表示。

经典的图卷积网络是最具代表性的架构之一^[45]。对于第 l 层的节点特征矩阵 $H^{(l)}$ ，其层间传播规则定义如下：

$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}) \quad (2-10)$$

其中， $\tilde{A} = A + I$ 为添加了自环的邻接矩阵， $\tilde{D}$ 为 $\tilde{A}$ 的度矩阵， $W^{(l)}$ 为第 l 层的可学习的权重参数， σ 为非线性激活函数。这一过程本质上是对邻域信息进行加权平均，使得每个节点在经过 L 层堆叠后能够感知到 L 阶邻居的结构信息。

然而，传统的 GNN 架构面临着严重的过度平滑问题^[46]。随着网络层数的增加，节点特征在拉普拉斯平滑的作用下趋于收敛到同一子空间，导致不同节点的表示变得无法区分。数学上，当层数 $l \rightarrow \infty$ 时，特征矩阵 $H^{(l)}$ 将退化为与输入特征无关的稳态分布。由于深层网络会导致局部信息的丢失，这一固有缺陷限制了 GNN 捕获长距离依赖的能力，使其难以有效捕捉复杂药物分子中远端原子或核心官能团之间的潜在相互作用。这也是本研究引入图 Transformer 架构的主要动机。

2.3.2 图 Transformer 架构

为了克服图卷积网络在长距离依赖捕获与过度平滑问题上的缺陷，本研究引入了图 Transformer 架构^{[24][36]}。不同于 GCN 局限于局部邻域的聚合范式，图 Transformer 将图中的任意两个节点视为潜在相连，利用自注意力机制动态计算节点间的相互作用权重。这种全局视角的建模方式使得处于蛋白质结构两端的残基能够直接进行信息交换，不再受限于图的直径或层数。




图 2-5 结构感知的图 Transformer 计算流程

图 Transformer 的核心计算单元是多头自注意力层 (Multi-Head Self-Attention)^[41]，以下计算过程以其中一个独立的注意力头为例进行说明。对于第 l 层的节点特征 $h_i^{(l)}$ ，模型通过线性投影计算节点 i 与图中所有其他节点 j 之间的注意力系数 α_{ij} ，该系数衡量了节点 j 对节点 i 的重要性，计算公式如下：

$$\alpha_{ij} = \frac{\exp((h_i W_Q)(h_j W_K)^T / \sqrt{d})}{\sum_{k \in V} \exp((h_i W_Q)(h_k W_K)^T / \sqrt{d})} \quad (2-11)$$

其中， W_Q, W_K 为可学习的投影矩阵， d 为特征维度， $\sqrt{d}$ 为缩放因子以防止梯度消失。

然而，纯粹的注意力机制具有排列不变性，即它无法感知图的拓扑结构信息，例如节点的度以及节点间的距离等。为了弥补这一结构信息的缺失，必须向输入特征中注入图位置编码 (Graph Positional Encoding, PE)。通常采用拉普拉斯矩阵的特征向量作为位置编码^[47]，因为它们能够自然地捕捉图的谱几何特性。此外，在处理药物分子等具有明确理化意义的图结构时，基于最短路径距离等空间位置编码也常被引入以精准刻画原子间的相对位

置。融合了残差连接^[48]与层归一化^[49]后的层级更新规则定义如下：

$$h_i^{(l+1)} = \text{FFN}(\text{LayerNorm}(h_i^{(l)} + \sum_{j \in V} \alpha_{ij} (W_V h_j^{(l)}))) \quad (2-12)$$

通过堆叠多个这样的 Transformer 层，模型不仅保留了对局部化学环境的感知能力，更具备了对全局分子构象和长程相互作用的建模能力，从而解决传统 GNN 在深层网络中的性能退化问题。

2.4 自监督对比学习

2.4.1 对比学习范式

在深度学习中，获得确定的药物-靶点结合亲和力数值等大规模的高质量标注数据，通常极其昂贵且耗时。为了充分利用大量的无标签生化数据，本研究引入自监督对比学习 (Self-Supervised Contrastive Learning) 范式^[50]。其核心思想是通过数据增强或多模态视图构建，学习在不同视图下保持不变的特征表示，即拉近正样本对在特征空间中的距离，同时推开负样本对。

假设给定一个输入样本 x ，通过两个不同的增强策略或编码器，生成两个相关联的视图 v_i 和 v_j 。对比学习的目标是训练编码器 $f(\cdot)$ 和投影头 $g(\cdot)$ ，使得特征表示 $z_i = g(f(v_i))$ 与 $z_j = g(f(v_j))$ 之间的相似度最大化，同时与其他无关样本的特征表示区分开来。

2.4.2 互信息最大化原理

从信息论的角度来看，对比学习的本质是最大化输入样本的不同视图之间的互信息 (Mutual Information, MI)。互信息用于衡量两个随机变量之间的依赖程度，对于变量 X 和 Y ，其定义为：

$$I(X;Y) = \sum_{x,y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \quad (2-13)$$

其中， $p(x,y)$ 是联合概率分布， $p(x)$ 和 $p(y)$ 是边缘概率分布。在 DTI 预测任务中，最大化药物分子表征与靶点蛋白表征之间的互信息，意味着模型能够从分子图这一特定模态

中，最大程度地预测出氨基酸序列这一模态的相关特征，从而实现跨模态的语义对齐。

2.4.3 InfoNCE 损失函数

直接计算高维连续变量的互信息在计算上是不可行的。因此，本研究采用 InfoNCE (Noise Contrastive Estimation) 损失函数^[51]作为互信息的下界估计。对于一个包含 N 个样本的批次，每个样本生成一对正样本，共有 $2N$ 个数据点。对于给定的正样本对 (i, j) ，其损失函数定义如下：

$$\mathcal{L}_{ij} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} 1_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} \quad (2-14)$$

其中， $1_{[k \neq i]}$ 是指示函数，当且仅当条件 $k \neq i$ 成立时取值为 1，否则为 0。 τ 是调节分布平滑度的温度参数，用于控制模型对困难负样本 (Hard Negative Samples) 的关注程度。 $\text{sim}(u, v)$ 通常采用余弦相似度函数，定义为：

$$\text{sim}(u, v) = \frac{u^T v}{\|u\| \|v\|} \quad (2-15)$$

通过最小化 $\mathcal{L}_{ij}$ ，模型被迫在特征空间中将匹配的药物-靶点对聚集在一起以实现分子对齐，并将不匹配的对分散开来，从而满足分母项的均匀性约束^[52]。这种机制能够有效解决多模态特征融合中的语义鸿沟问题，提升下游预测任务的鲁棒性。

2.5 多模态特征融合机制

2.5.1 交叉注意力

药物分子与靶点蛋白的相互作用常被比喻为一个“锁-钥”匹配过程。仅仅将药物的图特征 H_G 与靶点的序列特征 H_S 进行简单的拼接并不足以捕获两者之间复杂的生物化学关联，因为这种方式忽略了模态间的细粒度语义对齐。为了模拟药物原子与蛋白质残基之间的结合倾向，引入交叉注意力 (Cross-Attention) 机制作为特征融合的核心组件^{[41][53]}。

与自注意力机制不同，交叉注意力的查询向量 (Query) 来自一个模态，而键向量 (Key) 和值向量 (Value) 来自另一个模态。具体而言，将药物特征作为查询 Q ，将靶点特征作为键 K 和值 V ，以此来计算药物分子中的特定原子关注蛋白质序列中哪些区域。投影变换定

义如下：

$$Q=H_GW_Q, \quad K=H_SW_K, \quad V=H_SW_V \quad (2-16)$$

其中， W_Q, W_K, W_V 是可学习的线性投影矩阵。基于此，药物对靶点的注意力权重矩阵通过缩放点积注意力计算得出：

$$CrossAttention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-17)$$

公式 2-17 中的 *softmax* 操作归一化了每一行的注意力分数，使得生成的融合特征 $Attention(Q, K, V)$ 不仅包含了药物的结构信息，还加权融合了与其结合最紧密的蛋白质序列上下文信息。

2.5.2 特征聚合与输出

为了增强模型的表达能力并防止梯度消失，通常在交叉注意力层之后引入残差连接^[48]和层归一化^[49]，并通过前馈神经网络 (FFN) 进行非线性变换。最终的多模态融合表示 Z_{fused} 计算如下：

$$Z_{fused} = LayerNorm(H_G + FFN(CrossAttention(Q, K, V))) \quad (2-18)$$

其中，FFN 包含了两层线性变换及激活函数，用于对交互后的跨模态特征进行非线性映射，通过这种深度的特征交互，模型能够在潜在空间中精确地对齐药物的小分子结构与靶点的大分子序列，从而为下游的亲和力预测任务提供富含物理化学意义的联合表征。

2.6 本章小结

本章对药物-靶点相互作用预测中涉及的核心深度学习理论与关键技术进行了总结。针对蛋白质长序列建模难题，重点介绍了具有线性复杂度的 Mamba 状态空间模型；针对药物分子结构表征，探讨了结合结构位置编码的图 Transformer。此外，详细阐述了用于跨模态特征对齐的自监督对比学习范式，以及实现药物与靶点深度交互的交叉注意力融合机制。

这些理论方法为后续章节构建高效、精准的 DTI 预测模型奠定了坚实的基础。

3 基于 Mamba 增强与图对比学习的多模态 DTI 预测模型

3.1 概述

近年来，深度学习技术在 DTI 预测领域取得了长足进展，为大规模虚拟筛选提供了有力的计算辅助。然而，在真实的药物研发场景中，面对大量的候选化合物与复杂的蛋白质靶点，现有模型在处理这些生物学数据时仍面临两大核心挑战：一是靶点蛋白质通常包含成百上千个氨基酸残基，传统的 Transformer 架构在处理此类超长序列时面临着呈二次方增长的计算与显存开销，难以实现高效特征提取；二是已知的药物-靶点交互矩阵极度稀疏，常规模型大多将药物-靶点对作为独立样本进行训练，忽视了生物网络中普遍存在的关联推断^[54](Guilty By Association, GBA) 效应，导致模型在应对少样本或冷启动场景时泛化能力受限。

针对上述提及的问题，本章提出了一种基于 Mamba 增强与图对比学习的多模态 DTI 预测模型 MGCL-DTI (Multimodal DTI prediction model based on Mamba and Graph Contrastive Learning)。MGCL-DTI 模型通过构建双向 MambaFormer (Bi-MambaFormer) 与图 Mamba (Graph Mamba) 模块，在维持低计算开销的同时，建模药物分子拓扑特征与蛋白质全长序列的复杂依赖关系。其次，通过构建药物-药物、靶点-靶点相似性网络，并引入图对比学习机制，以自监督方式挖掘全局拓扑关系，缓解数据稀疏问题。最后，将自适应多模态特征融合模块与上述机制相结合，动态整合微观与宏观特征。通过 Mamba 架构的高效序列建模、图对比学习的全局拓扑挖掘以及自适应特征融合的多模态整合，MGCL-DTI 模型实现了对药物-靶点相互作用的精准预测。

3.2 算法设计

3.2.1 模型整体架构

MGCL-DTI 模型是一种基于 Mamba 增强与图对比学习的多模态 DTI 预测模型，其模型结构如图 3-1 所示。该模型主要包括三个协同工作的核心部分：微观特征提取阶段、宏观关系增强阶段以及多模态融合预测阶段。

在微观特征提取阶段，模型利用 Mamba 具备线性计算复杂度的优势，并行处理药物分子图与蛋白质氨基酸序列。其中，图 Mamba 模块负责聚合分子图节点信息，而双向 MambaFormer 则执行蛋白质序列的全局上下文建模。此过程将原始的生化数据转化为高维空间的微观结构特征向量，为后续的计算奠定坚实基础。

在宏观关系增强阶段，模型通过构建的药物与靶点同构相似性网络，利用 GCL 机制

对节点表示进行结构增强，从全局交互网络中挖掘潜在的拓扑结构信息。这一机制不仅弥补了仅依赖微观特征时 GBA 效应的缺失，还通过最大化视图间的互信息，增强了特征表示对噪声数据的鲁棒性，确保模型能够充分利用异质全局相似性中的宏观信息。

在多模态融合预测阶段，本文设计了一个自适应加权融合机制来整合微观与宏观特征，通过门控单元动态学习不同模态特征的重要性权重，并将融合后的向量输入分类器进行最终的概率预测。同时，模型采用联合优化策略，结合主任务损失与辅助对比损失进行端到端训练。通过这一设计，模型能够实现多视图信息的优势互补，从而提高药物-靶点相互作用预测的准确性和鲁棒性。




图 3-1 MGCL-DTI 模型整体架构图

3.2.2 基于 Mamba 的微观结构特征提取

鉴于长序列建模效率瓶颈以及传统图神经网络的局部感受野限制，本节在微观特征提取阶段引入了 Mamba 架构。具体而言，针对药物和靶点的数据特性，分别设计了图 Mamba 和双向 MambaFormer 模块。如图 3-2 所示，旨在从微观层面高效、精准地提取药物和靶点的结构特征。

1. 药物分子图特征提取

药物分子被建模为无向图 $G = (V, E)$ ，其中 V 表示原子节点集合， E 表示化学键边集合。为了从该图结构中提取深层表征，本节构建了图 Mamba 网络 (GMN) 作为药物分子的特

征编码器。GMN 采用串行结构，依次包含边增强的局部图注意力层与双向 Mamba 层。




图 3-2 基于 Mamba 架构的微观结构特征提取模块

(1) 局部特征聚合

首先，利用局部图注意力机制对节点特征进行更新。对于任意原子节点 v_i ，其第 l 层的特征表示 $h_i^{(l)}$ 通过聚合邻居节点 $N(i)$ 的信息获得：

$$h_i^{(l)} = h_i^{(l-1)} W_1 + \sum_{j \in N(i)} \alpha_{ij} (h_j^{(l-1)} W_2 + e_{ij} W_3) \quad (3-1)$$

其中， e_{ij} 表示边的特征向量， W_1, W_2, W_3 为可学习的权重矩阵。注意力系数 α_{ij} 通过自注意力机制计算，以衡量不同邻居节点对中心原子的贡献度。这一计算过程将原子的局部微观化学环境编码到节点表示中。

(2) 全局拓扑建模

为了进一步捕捉分子图中相距较远的原子间的潜在依赖关系，本文将图注意力层输出的节点拼接为矩阵 H_{local} ，随后输入双向 Mamba 层。模型分别沿正向和反向对 H_{local} 执行状态空间建模，并将两组隐藏状态进行对应元素相加融合：

$$H_{drug} = Mamba_{fwd}(H_{local}) + Mamba_{bwd}(H_{local}) \quad (3-2)$$

最终，对上述融合结果进行全局最大池化 (Global Max Pooling) 操作，输出药物分子的微观结构特征向量 V_{drug}^{struct} 。

2. 蛋白质序列特征提取

蛋白质的一级结构通常较长，且残基间存在复杂的长程交互。双向 MambaFormer 模块采用双分支并行结构，对长度为 L 、维度为 d 的蛋白质初始嵌入矩阵 $E_p \in \mathbb{R}^{L \times d}$ 进行特征提取：

(1) 局部语义捕获

第一分支引入局部窗口多头自注意力机制，重点关注氨基酸序列内部的局部残基交互模式：

$$H_{attn} = LocalMHA(LayerNorm(E_p)) \quad (3-3)$$

(2) 全局依赖建模

第二分支则通过双向 Mamba 模块对全长序列进行扫描，从而捕获远端残基间的全局依赖关系：

$$H_{mamba} = Bi-Mamba(LayerNorm(E_p)) \quad (3-4)$$

特征提取完成后，利用残差连接与层归一化操作将双分支输出与原始输入特征相融合：

$$H_{seq} = LayerNorm(H_{attn} + H_{mamba} + E_p) \quad (3-5)$$

该融合矩阵即作为蛋白质的微观结构特征表示 V_{target}^{struct} ，用于后续的计算与预测。

3.2.3 基于图对比学习的宏观关系增强

尽管微观特征提取模块能够一定程度刻画生物实体的底层理化性质，但离散的样本对输入方式往往无法利用生物异质网络中普遍存在的 GBA 效应。为充分挖掘同类节点间的全局拓扑关联，如图 3-3 所示，本节引入 GCL 机制，通过构建同构相似性网络与自监督优化策略，进一步增强多模态特征的宏观关系表达。




图 3-3 基于图对比学习的宏观关系增强与特征初始化流程

1. 关系相似性网络构建

已知药物-靶点交互矩阵 $Y \in \{0,1\}^{N_d \times N_t}$ ，其中 N_d 和 N_t 分别表示药物和靶点的数量。为了挖掘同类生物实体间的潜在关联，需将二部图转化为同构图。

以药物为例，若两个药物 d_i 和 d_j 作用于相似的靶点集合，则它们在功能上具有高度的相似性。本研究利用余弦相似度度量药物交互谱 (Interaction Profile) 之间的相关性：

$$Sim(d_i, d_j) = \frac{y_i \cdot y_j}{\|y_i\| \|y_j\| + \epsilon} \quad (3-6)$$

其中， y_i 表示矩阵 Y 中第 i 行的向量， ϵ 为防止分母为零的微小常数。为了构建稀疏且鲁棒的药物相似性网络 $G_d = (V_d, E_d)$ ，设定相似度阈值 τ_{sim} 进行过滤：仅当 $Sim(d_i, d_j) > \tau_{sim}$ 时，在节点 i 和 j 之间建立连接边。同理，可构建靶点-靶点相似性网络 G_t 。

阈值 τ_{sim} 的设定对相似性网络 G_d 和 G_t 的拓扑性质及特征学习质量具有决定性影响。在图对比学习的框架下，该参数起到了拓扑噪声过滤器的作用。具体而言，若 τ_{sim} 取值过低，网络会保留大量基于微弱关联的连接，使得节点间的界限模糊，在图卷积传播过程中易引发过度平滑现象，导致模型无法区分细微的功能差异。若 τ_{sim} 取值过高，网络将退化为离散的孤立节点，使得模型无法利用生物网络中的 GBA 效应。

通过合理的阈值筛选，模型能够聚焦于具有明显生化关联的拓扑结构，从而在对比损失优化过程中，帮助编码器学习到更具判别力的视图不变性特征。

2. 增强视图生成与特征编码

为了使模型学习到视图不变性 (View-invariant) 特征, 本研究对于构建好的相似性网络, 通过随机删边 (Edge Dropping) 和特征掩码 (Feature Masking), 生成两个增强视图 $G^{(1)}$ 和 $G^{(2)}$ 。

在特征掩码阶段, 为了实现微观特征与宏观特征的深度耦合, 将提取的微观结构特征 V^{struct} 直接作为图编码器的初始节点状态。模型利用共享权重的 GCN 做邻域信息聚合, 第 l 层的特征更新逻辑定义为:

$$Z^{(v)} = \tilde{D}^{-\frac{1}{2}} \tilde{A}^{(v)} \tilde{D}^{-\frac{1}{2}} H^{(l-1)} \Theta \quad (3-7)$$

其中, $v \in \{1, 2\}$ 表示视图索引, $\tilde{A}^{(v)}$ 为增强视图 $G^{(v)}$ 添加了自环的邻接矩阵, $\tilde{D}$ 为其对应的度矩阵, Θ 为可学习的权重参数。经过 L 层传播后, 得到两个视图下的药物宏观关系表征。

3. 对比损失优化

在对比损失的优化上, 本节构建了针对药物节点的具体对比损失。对于批次中的任意药物节点 i , 其在视图 $G^{(1)}$ 和 $G^{(2)}$ 中的特征表示分别记为 $z_i^{(1)}$ 和 $z_i^{(2)}$, 二者构成正样本对; 而该节点与其他节点在不同视图下的表示则构成负样本对。节点 i 的具体对比损失 $\mathcal{L}_i^{drug}$ 定义如下:

$$\mathcal{L}_i^{drug} = -\log \frac{\exp(s(z_i^{(1)}, z_i^{(2)})/\tau)}{\exp(s(z_i^{(1)}, z_i^{(2)})/\tau) + \sum_{k=1, k \neq i}^{N_d} [\exp(s(z_i^{(1)}, z_k^{(2)})/\tau) + \exp(s(z_i^{(2)}, z_k^{(1)})/\tau)]} \quad (3-8)$$

其中, $s(\cdot)$ 为计算两个特征向量余弦相似度的函数, τ 为调节对困难负样本敏感度的温度参数。该机制通过拉近正样本对距离、推远负样本对距离, 使编码器从受扰动的拓扑结构中提取稳定的全局特征。

整合药物与靶点双端的监督信号, 最终的宏观关系增强总损失 $\mathcal{L}_{cl}$ 计算如下:

$$\mathcal{L}_{cl} = \frac{1}{N_d} \sum_{i=1}^{N_d} \mathcal{L}_i^{drug} + \frac{1}{N_t} \sum_{j=1}^{N_t} \mathcal{L}_j^{target} \quad (3-9)$$

通过优化 $\mathcal{L}_{cl}$, 图编码器能够学习到节点在全局网络中的结构特征, 从而输出宏观关系

特征向量 V_{rel} 。这种结合全局网络信息的方法，缓解了交互数据稀疏导致的模型泛化能力不足的问题

3.2.4 多模态自适应特征融合

经过前述特征提取模块，本文分别获得了药物和靶点的微观结构特征 V^{struct} 与宏观关系特征 V^{rel} 。考虑到不同模态特征对特定样本的贡献度存在差异，例如，冷启动药物往往更依赖宏观网络关联，而具有全新骨架的药物则更依赖微观几何结构。为此，本节设计了一个自适应的特征融合模块，并定义了联合优化损失函数。

1. 多模态加权融合机制

设输入的药物微观特征和宏观特征分别为 $f_d^{struct} \in \mathbb{R}^d$ 和 $f_d^{rel} \in \mathbb{R}^d$ ，为实现两组异构特征的深度交互，融合过程划分为以下两步：

(1) 初级特征交互

首先，将两组特征进行拼接，通过一个 FFN 和 Sigmoid 激活函数计算初步的门控权重 W_1 ：

$$W_1 = \sigma(\text{FFN}_1([f_d^{struct} \| f_d^{rel}])) \quad (3-10)$$

其中， $[\|]$ 表示向量拼接， σ 为 Sigmoid 激活函数。利用 W_1 对原始特征进行加权组合，生成中间特征表示 f_{mid} ：

$$f_{mid} = f_d^{struct} \odot W_1 + f_d^{rel} \odot (1 - W_1) \quad (3-11)$$

此处 $\odot$ 表示逐元素乘法。这一步计算过程实现了双视图信息的初步整合。

(2) 次级特征提纯

为了进一步削弱交互过程中可能产生的冗余信息，模型基于中间特征 f_{mid} 计算第二组权重 $W_2 = \sigma(\text{FFN}_2(f_{mid}))$ ，并生成最终的融合特征 V_{drug} ：

$$V_{drug} = f_{mid} \odot W_2 \quad (3-12)$$

同理，对于靶点，利用相同的机制融合其微观序列特征 f_t^{struct} 和宏观关系特征 f_t^{rel} ，得到

最终的靶点表示 V_{target} 。这种两阶段的融合策略有助于突出对预测任务贡献度更高的模态特征。

2. 预测层与损失函数

(1) 预测层

获得药物和靶点的最终融合特征后，将其拼接输入到预测层。预测层由多层感知机 (Multilayer Perceptron, MLP) 构成。层间使用 ReLU 激活函数和 Dropout 策略，最终映射为预测分数 $\hat{y}_{ij}$ ，表示药物 i 与靶点 j 存在相互作用的概率：

$$\hat{y}_{ij} = \sigma(MLP([V_{drug}^{(i)} \| V_{target}^{(j)}])) \quad (3-13)$$

(2) 联合损失函数

为了兼顾预测准确性与特征表示的鲁棒性，本模型采用多任务联合优化策略，主任务采用二元交叉熵损失 (BCE) 进行监督：

$$\mathcal{L}_{pred} = -\frac{1}{N} \sum_{(i,j) \in D} [y_{ij} \log \hat{y}_{ij} + (1-y_{ij}) \log (1-\hat{y}_{ij})] \quad (3-14)$$

其中， D 为当前训练批次中的样本集合， N 为批次大小， $y_{ij} \in \{0,1\}$ 为真实标签。

结合图对比学习损失 $\mathcal{L}_{cl}$ ，模型的总损失函数 $\mathcal{L}_{total}$ 定义为：

$$\mathcal{L}_{total} = \mathcal{L}_{pred} + \lambda \mathcal{L}_{cl} \quad (3-15)$$

其中， λ 是一个非负超参数，用于平衡主预测任务与辅助对比任务的权重。通过最小化 $\mathcal{L}_{total}$ ，模型能够在学习准确的药物-靶点映射关系的同时，保持对全局网络拓扑结构的感知能力。

3.3 实验结果分析

3.3.1 数据集

为了全面评估 MGCL-DTI 模型在不同生物物种、不同数据规模及不同网络拓扑下的泛

化性能与鲁棒性，本研究选取了药物-靶点相互作用预测领域中三个广泛使用的基准数据集：Human（人类）、C.elegans（线虫）以及 DrugBank 数据集。

其中 Human 和 C.elegans 数据集分别代表了人类与非人类物种的生物学特征，常被用于检验模型在不同生物体系下的泛化能力。而 DrugBank 数据集不仅汇集了大量经过实验验证的高置信度药物-靶点相互作用对，且网络节点规模大、拓扑结构复杂，因此主要用于检验模型在面对大规模、高稀疏度真实临床数据时的综合预测与抗噪性能。

由于现有生物实验数据库普遍缺乏明确的负样本记录，因此本实验采用了该领域通用的负采样策略来构建数据集。在负采样过程中常会面临假阴性问题，即随机抽取的未标记样本对中，可能包含实际存在但尚未被实验证实的相互作用。为了降低该问题对模型训练造成的负面影响，本文引入了基于相似性的过滤约束机制。具体而言，在抽取负样本时，除了剔除已知的正样本外，还会利用药物指纹相似性和蛋白序列相似性对候选负样本进行二次筛选。此举旨在避免抽取与已知正样本在化学结构或蛋白质序列上高度相似的样本对，从而降低将潜在真阳性相互作用误采为负样本的概率。这三个数据集的详细统计信息如表 3-1 所示。

表 3-1 数据集统计信息

数据集	药物数	靶点数	正样本数	负样本数
C.elegans	1,767	2,039	3,893	3,893
Human	2,726	2,001	3,363	3,363
DrugBank	6,459	2,888	11,885	14,442

3.3.2 实验设置

硬件核心配置为 NVIDIA GeForce RTX 4090 (24GB) 显卡与 Intel Core i9-13900K 处理器，内存为 64GB。

软件环境基于 Ubuntu 22.04 LTS 操作系统，编程语言为 Python 3.9。深度学习框架采用 PyTorch 2.1.0，图神经网络库使用 PyTorch Geometric (PyG) 2.4.0 以支持图 Mamba 模块的构建，化学分子处理使用 RDKit 2023.09 工具包。

在实验流程上，为了客观评估模型的泛化性能，本文采用 10 折交叉验证策略。具体而言，采用基于边的随机划分方法，将数据集集中的所有药物-靶点相互作用边随机打乱并均匀分割成 10 个互不相交的子集。每次迭代中，选取一个子集作为测试集，从剩余的 9 个

子集中挑选一个作为验证集，其余 8 个子集组合用于模型训练，由此确保了训练集、验证集和测试集的比例严格为 8:1:1。整个流程重复执行 10 次，最终的模型性能评估指标取这 10 次独立实验结果的平均值与标准差。在每次迭代的训练过程中，验证集仅用于监控模型的收敛状态，并在验证集 AUC 指标达到最优时保存模型参数，以此防止过拟合，测试集则被严格隔离，仅用于最终的性能评估。

针对核心超参数的配置，本研究进行了如下统一设置：采用 Adam 优化器^[55]对模型参数进行更新，模型训练的最大轮数 (Epochs) 设定为 2000，批量大小 (Batch Size) 对于 C.elegans 和 Human 数据集设定为 256，对于 DrugBank 数据集设定为 512，初始学习率 (Learning Rate) 设定为 1×10^{-3} ，并引入参数权重衰减 (Weight Decay) 设定为 1×10^{-4} 作为 L2 正则化约束。在模型结构参数方面，药物分子与靶点序列的嵌入维度均映射为 128，为了防止特征过拟合，Dropout 率^[56]设定为 0.1。此外，针对图 Mamba 模块，其内部隐状态维度 (State Dimension) 设定为 16；针对图对比学习模块，温度系数 τ 设定为 0.2，在生成数据增强视图时，为保证拓扑扰动的合理性，随机删边率和特征掩码率均设定为 0.2。

3.3.3 评价指标

为了全面、客观地评估模型在 DTI 预测任务中的性能，本研究选取了五项广泛应用于二分类任务的核心评价指标：受试者工作特征曲线下面积 (Area Under ROC Curve, AUC)、精确率-召回率曲线下面积 (Area Under Precision-Recall Curve, AUPR)、准确率 (Accuracy)、精确率 (Precision) 和召回率 (Recall)。

其中，AUC 和 AUPR 主要用于衡量模型在不同阈值下的综合预测能力与鲁棒性，而准确率、精确率和召回率则从不同维度反映了模型对正负样本的分类效能。

AUC 是评估二分类模型性能最常用的指标之一^[57]。ROC 曲线以假正类率 (False Positive Rate, FPR) 为横坐标，真正类率 (True Positive Rate, TPR) 为纵坐标绘制而成。AUC 值即为 ROC 曲线下的面积。AUC 值越接近 1，表明模型区分正负样本的能力越强；若 AUC 为 0.5，则代表模型的预测效果等同于随机猜测。

AUPR 是 PR 曲线下的面积，该曲线以召回率为横坐标，精确率为纵坐标。与 AUC 相比，AUPR 在处理类别不平衡数据 (Imbalanced Datasets) 时更为敏感和有效^[58]。由于真实的药物-靶点相互作用网络通常负样本数量远多于正样本数量，AUPR 能够更准确地反映模型在识别少数正样本方面的性能，避免了因负样本过多而导致的评估偏差。

Accuracy 是指模型正确预测的样本数占总样本数的比例，它直观地反映了模型的整体判断能力，其计算公式如下^[59]：

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (3-16)$$

式中，TP (True Positive) 表示真阳性，即模型正确预测为存在相互作用的样本数；TN (True Negative) 表示真阴性，即模型正确预测为不存在相互作用的样本数；FP (False Positive) 表示假阳性；FN (False Negative) 表示假阴性。

Precision 是指在所有被模型预测为正类的样本中，实际确实为正类的比例。该指标主要衡量模型预测结果的查准能力，计算公式如下^[59]：

$$Precision = \frac{TP}{TP+FP} \quad (3-17)$$

Recall 是指在所有实际为正类的样本中，被模型正确预测为正类的比例。该指标主要衡量模型覆盖正类样本的查全能力，计算公式如下^[59]：

$$Recall = \frac{TP}{TP+FN} \quad (3-18)$$

3.3.4 基线模型

为了全面、客观地评估本文提出的 MGCL-DTI 模型的预测性能，本研究选取了 10 个在药物-靶点相互作用预测领域具有代表性的 SOTA 模型进行对比。这些基线模型涵盖了从图神经网络、Transformer 架构到最新的注意力机制与特征融合策略，代表了该领域近年来的技术演进路线：

CPI-GNN^[60]：作为图神经网络在 DTI 领域的早期代表性方法，该模型利用 GNN 提取药物分子的拓扑结构特征，并结合一维 CNN 提取蛋白质序列特征。该模型通过单边注意力机制分析蛋白质子序列与药物之间的相关性。

MolTrans^[14]：基于 Transformer 架构的经典模型。该方法利用 Transformer 编码药物与蛋白质特征，并采用 CNN 与全连接网络进行预测。此外，它引入了子词标记化技术将药物和蛋白质分解为子结构单元，通过 Transformer 编码器捕捉这些子结构之间的显式相互作用。

MCL-DTI^[61]：一种基于多模态交叉注意力学习的预测框架。该模型通过整合药物的多种模态信息，利用双向多头交叉注意力机制进行特征融合，实现了药物空间结构与化学属

性的互补表示。

HyperAttentionDTI^[62]: 该模型引入了超注意力机制 (Hyper-Attention), 通过在特征矩阵上利用注意力块, 为每个原子和氨基酸分配注意力向量, 从而在语义层面上捕捉分子间复杂的非共价相互作用, 增强了模型对关键结合位点的关注度。

GIFDTI^[63]: 侧重于全局交互特征的学习。该方法通过 CNN 提取药物 SMILES 序列和蛋白质氨基酸序列的特征, 并利用 Transformer 捕捉全局交互信息, 通过融合药物与靶点的全局特征表示来进行亲和力预测。

MHSADTI^[64]: 一种结合了多头自注意力机制 (Multi-Head Self-Attention) 的混合架构。该模型旨在同时捕捉蛋白质序列内部的长距离依赖与药物分子图的空间结构特征, 解决了传统 CNN 在长序列建模上的局限性。

MCANet^[65]: 一种基于图注意力网络 (GAT) 与多头交叉注意力网络 (Multi-Head Cross-Attention Network) 的端到端混合架构。该模型利用自注意力机制捕获了蛋白质氨基酸序列内部的长距离依赖关系, 同时通过 GAT 提取药物分子图的空间拓扑特征。

DO-GMA^[66]: 一种端到端的预测框架。该方法结合了深度超参数化卷积网络 (DO-Conv) 与 GCN, 能够同时处理药物的 SMILES 序列与图结构信息, 并利用门控机制与注意力机制实现药物与靶点特征的高效融合。

LAM-DTI^[67]: 引入了基于联结主义时间分类 (CTC) 的预测模型。该模型通过 CTC 模块生成归一化的特征序列, 解决了药物与靶点之间序列长度差异明显的问题, 并结合注意力机制捕捉局部与全局的关联特征。

FOTF-CPI^[68]: 一种基于碎片化与最优传输融合的模式 (Fragmentation and Optimal Transport Fusion)。该模型利用最优传输理论建立药物碎片与蛋白质片段之间的关联, 通过分段建模与融合注意力机制, 实现了对复杂结合模式的精准捕捉。

3.3.5 对比实验

为了客观评估 MGCL-DTI 模型的预测性能与优越性, 本研究在上述三个基准数据集上, 将其与该领域现有的多种主流基线模型进行了系统的性能对比。为保证评估的公平性, 所有基线模型均在相同的软硬件环境与前文所述的 10 折交叉验证策略下进行训练与测试。

表 3-2、表 3-3 和表 3-4 分别详细记录了 MGCL-DTI 模型与基线模型在上述三个数据集上的性能对比结果。为确保评估的客观性, 所有实验结果均以“平均值±标准差”的形式呈现。为便于直观对比, 表中列出的最优结果采用粗体标注, 次优结果使用下划线标示。

表 3-2 不同模型在 DrugBank 数据集上的性能对比

模型名称	AUC	AUPR	Accuracy	Precision	Recall
MCL-DTI	0.8514 $\pm$ 0.004	0.7743 $\pm$ 0.009	0.7834 $\pm$ 0.002	0.7945 $\pm$ 0.004	0.8169 $\pm$ 0.006
HyperAttentionDTI	0.9105 $\pm$ 0.003	0.9289 $\pm$ 0.003	0.8272 $\pm$ 0.005	0.8160 $\pm$ 0.008	0.8802 $\pm$ 0.006
GIFDTI	0.9115 $\pm$ 0.005	0.9201 $\pm$ 0.006	0.8265 $\pm$ 0.009	0.8091 $\pm$ 0.011	0.8982$\pm$0.009
MHSADTI	0.8695 $\pm$ 0.009	0.8622 $\pm$ 0.010	0.7912 $\pm$ 0.012	0.7967 $\pm$ 0.024	0.8381 $\pm$ 0.025
MCANet	<u>0.9295$\pm$0.005</u>	<u>0.9490$\pm$0.005</u>	0.8520 $\pm$ 0.006	<u>0.8587$\pm$0.006</u>	0.8751 $\pm$ 0.015
DO-GMA	0.9234 $\pm$ 0.006	0.9383 $\pm$ 0.007	<u>0.8619$\pm$0.011</u>	0.8423 $\pm$ 0.013	0.8841 $\pm$ 0.018
LAM-DTI	0.9213 $\pm$ 0.005	0.9357 $\pm$ 0.008	0.8490 $\pm$ 0.008	0.8223 $\pm$ 0.015	0.8721 $\pm$ 0.012
MGCL-DTI	0.9315$\pm$0.006[*]	0.9518$\pm$0.004[*]	0.8657$\pm$0.010[*]	0.8653$\pm$0.012[*]	<u>0.8853$\pm$0.014</u>

注：*表示本文模型相较于最优的基线模型，经配对 t 检验具有统计学显著性提升 ($p < 0.05$)。

表 3-3 不同模型在 C.elegans 数据集上的性能对比

模型名称	AUC	AUPR	Accuracy	Precision	Recall
CPI-GNN	0.9536 $\pm$ 0.008	0.9422 $\pm$ 0.012	0.9146 $\pm$ 0.010	0.9185 $\pm$ 0.009	0.8292 $\pm$ 0.020
MolTrans	0.9918 $\pm$ 0.002	0.9920 $\pm$ 0.003	0.9670 $\pm$ 0.003	0.9626 $\pm$ 0.005	0.9342 $\pm$ 0.006
MCL-DTI	0.9706 $\pm$ 0.003	0.9769 $\pm$ 0.003	0.9072 $\pm$ 0.006	<u>0.9744$\pm$0.011</u>	0.8486 $\pm$ 0.016
HyperAttentionDTI	<u>0.9934$\pm$0.001</u>	<u>0.9939$\pm$0.001</u>	0.9551 $\pm$ 0.009	0.9466 $\pm$ 0.013	<u>0.9677$\pm$0.010</u>
GIFDTI	0.9880 $\pm$ 0.006	0.9902 $\pm$ 0.005	0.9422 $\pm$ 0.014	0.9366 $\pm$ 0.016	0.9529 $\pm$ 0.018
MHSADTI	0.9776 $\pm$ 0.006	0.9808 $\pm$ 0.006	0.9242 $\pm$ 0.005	0.9002 $\pm$ 0.006	0.9652 $\pm$ 0.007
MCANet	0.9920 $\pm$ 0.002	0.9925 $\pm$ 0.001	0.9661 $\pm$ 0.005	0.9666 $\pm$ 0.005	0.9674 $\pm$ 0.009
DO-GMA	0.9926 $\pm$ 0.003	0.9905 $\pm$ 0.005	<u>0.9716$\pm$0.003</u>	0.9715 $\pm$ 0.003	0.9645 $\pm$ 0.006
LAM-DTI	0.9929 $\pm$ 0.001	0.9914 $\pm$ 0.001	0.9690 $\pm$ 0.005	0.9690 $\pm$ 0.005	0.9382 $\pm$ 0.010
FOTF-CPI	0.9919 $\pm$ 0.003	0.9909 $\pm$ 0.005	0.9663 $\pm$ 0.005	0.9651 $\pm$ 0.005	0.9436 $\pm$ 0.009
MGCL-DTI	0.9958$\pm$0.001[*]	0.9970$\pm$0.004[*]	0.9782$\pm$0.002[*]	0.9805$\pm$0.006[*]	0.9783$\pm$0.005[*]

注：*表示本文模型相较于最优的基线模型，经配对 t 检验具有统计学显著性提升 ($p < 0.05$)。

如表 3-2 所示，MGCL-DTI 模型在 DrugBank 数据集上的 AUC (0.9315) 与 AUPR

(0.9518) 均取得了最优值。这表明图 Mamba 架构与图对比学习机制适用于大规模稀疏图数据。在基准模型中, MCANet 表现次优 (AUC 0.9295, AUPR 0.9490)。尽管 GIFDTI 在 Recall 指标上达到最高 (0.8982), 但 MGCL-DTI 的 Recall (0.8853) 紧随其后, 且在综合预测精度上更具优势。这说明本模型能在维持较高查准率的同时, 有效挖掘潜在的生物实体关联。

表 3-3 展示了各模型在 C.elegans 数据集上的性能。由于该数据集样本分布相对均衡, 多数先进基线模型 (如 MCANet、DO-GMA 和 LAM-DTI) 的 AUC 均超过了 0.99。在此基准下, MGCL-DTI 依然在所有评价指标上取得了最优结果, 其 AUC 和 AUPR 分别达到 0.9958 和 0.9970。此外, 相较于 DO-GMA 和 MCL-DTI, MGCL-DTI 在 Accuracy 与 Precision 上均有提升, 且 Recall 达到了 0.9783。这种在查准与查全上的双重优势, 验证了模型设计的合理性, 即图 Mamba 模块提取了分子的全局拓扑特征, 而图对比学习则进一步增强了特征空间的判别性。

表 3-4 不同模型在 Human 数据集上的性能对比

模型名称	AUC	AUPR	Accuracy	Precision	Recall
CPI-GNN	0.9329 $\pm$ 0.009	0.9174 $\pm$ 0.016	0.8899 $\pm$ 0.008	0.8858 $\pm$ 0.010	0.7798 $\pm$ 0.017
MolTrans	0.9799 $\pm$ 0.003	0.9785 $\pm$ 0.004	0.9418 $\pm$ 0.010	0.9207 $\pm$ 0.029	0.8823 $\pm$ 0.020
MCL-DTI	0.9850 $\pm$ 0.003	0.9516 $\pm$ 0.004	0.9459 $\pm$ 0.005	0.9452 $\pm$ 0.007	0.9482 $\pm$ 0.005
HyperAttentionDTI	0.9805 $\pm$ 0.003	0.9516 $\pm$ 0.004	0.9348 $\pm$ 0.005	0.9226 $\pm$ 0.007	0.9586 $\pm$ 0.005
GIFDTI	0.9715 $\pm$ 0.005	0.9807 $\pm$ 0.007	0.9140 $\pm$ 0.013	0.9022 $\pm$ 0.034	0.9197 $\pm$ 0.016
MHSADTI	0.9693 $\pm$ 0.001	0.9225 $\pm$ 0.005	0.9117 $\pm$ 0.006	0.8992 $\pm$ 0.016	0.9311 $\pm$ 0.014
MCANet	<u>0.9937$\pm$0.002</u>	<u>0.9902$\pm$0.002</u>	<u>0.9572$\pm$0.003</u>	0.9519 $\pm$ 0.010	<u>0.9615$\pm$0.010</u>
DO-GMA	0.9891 $\pm$ 0.003	0.9870 $\pm$ 0.007	0.9541 $\pm$ 0.005	0.9544$\pm$0.005	0.9598 $\pm$ 0.010
LAM-DTI	0.9860 $\pm$ 0.004	0.9854 $\pm$ 0.002	0.9502 $\pm$ 0.006	0.9497 $\pm$ 0.006	0.9407 $\pm$ 0.011
FOTF-CPI	0.9834 $\pm$ 0.002	0.9803 $\pm$ 0.004	0.9413 $\pm$ 0.007	0.9326 $\pm$ 0.009	0.9511 $\pm$ 0.015
MGCL-DTI	0.9952$\pm$0.001*	0.9935$\pm$0.006*	0.9680$\pm$0.002*	<u>0.9524$\pm$0.003</u>	0.9716$\pm$0.002*

注: *表示本文模型相较于最优的基线模型, 经配对 t 检验具有统计学显著性提升 ($p < 0.05$)。

Human 数据集包含大量长序列蛋白质, 对模型捕捉长距离依赖的能力要求较高, 如表 3-4 所示, 在该数据集上, MGCL-DTI 的 AUC (0.9952) 与 AUPR (0.9935) 同样保持最优。进一步分析 Precision 与 Recall 指标可以发现, 基于图掩码自编码的 DO-GMA 取得了最高

的 Precision (0.9544)，但其 Recall 相对较低 (0.9598)，容易造成潜在交互关系的遗漏。相比之下，MGCL-DTI 采取了更为均衡的预测策略：其 Precision (0.9524) 虽略低于 DO-GMA，但 Recall 大幅提升至 0.9716。这表明，在处理复杂长蛋白序列时，图 Mamba 架构缓解了传统网络中长程信息丢失的问题，使得模型能够在维持高精度的同时，挖掘出更多潜在的 药物-靶点相互作用。

为了在统计学层面上严格评估本章提出方法的改进效果，本文利用配对 t 检验(paired t-test) 进行了显著性分析。具体而言，本研究提取了模型在 10 折交叉验证中产生的 10 次独立测试结果，将其与在该指标上表现次优的基线模型结果进行配对检验。检验结果表明，在绝大多数核心评价指标上，MGCL-DTI 相较于次优模型的性能提升均达到了 $p < 0.05$ 的统计学显著性水平。虽然在个别细分指标上，本文模型未取得绝对最优，但这反映出模型在维持高精确度的前提下，通过合理的参数权衡实现了更为出色的综合预测性能。特别是在衡量全局预测能力的 AUC 与 AUPR 指标上，本模型均保持显著最优。整体而言，该检验结果客观地证实了所提的图 Mamba 与图对比学习机制在提升模型推断能力上的稳定性和有效性。

3.3.6 消融实验

为了验证 MGCL-DTI 模型中各核心组件的有效性，本节在 C.elegans 和 Human 数据集上开展了消融实验。实验构建了三个变体模型以进行对比评估：移除图对比学习模块的 w/o GCL、移除图 Mamba 编码器的 w/o Mamba，以及移除自适应特征融合机制的 w/o Fusion。实验结果分别详见表 3-5 与表 3-6，所有实验结果均采用“平均值 $\pm$ 标准差”的格式。

表 3-5 MGCL-DTI 及其变体模型在 C.elegans 数据集上的消融实验结果

模型变体	AUC	AUPR	Accuracy	Precision	Recall
MGCL-DTI	0.9958$\pm$0.001	0.9970$\pm$0.004	0.9782$\pm$0.002	0.9805$\pm$0.006	0.9783 $\pm$ 0.005
w/o GCL	0.9845 $\pm$ 0.003	0.9923 $\pm$ 0.004	0.9717 $\pm$ 0.004	0.9512 $\pm$ 0.006	0.9845$\pm$0.004
w/o Mamba	0.9915 $\pm$ 0.002	0.9754 $\pm$ 0.005	0.9656 $\pm$ 0.005	0.9745 $\pm$ 0.004	0.9325 $\pm$ 0.006
w/o Fusion	0.9783 $\pm$ 0.005	0.9810 $\pm$ 0.006	0.9521 $\pm$ 0.007	0.9580 $\pm$ 0.008	0.9468 $\pm$ 0.008

如表 3-5 及图 3-4 所示，在 C.elegans 数据集上，w/o GCL 变体的 Recall 达到了 0.9845，高于完整模型的 0.9783，但其 Precision 下降至 0.9512。这表明图对比学习通过引入拓扑一致性约束，起到了过滤噪声连接的作用；移除该模块虽能覆盖更多正样本，但也引入了较多伪阳性干扰。另一方面，w/o Mamba 变体虽保持了较高的 AUC 和 Precision，但其 Recall

跌至 0.9325。这说明 Mamba 架构在序列建模上的缺失，会导致模型难以从长序列中挖掘隐蔽的相互作用模式，进而削弱对困难样本的识别能力。




图 3-4 MGCL-DTI 及其变体模型在 C.elegans 数据集上的性能对比

相比于 C.elegans 数据集，针对网络拓扑结构更稀疏的 Human 数据集，相应的消融实验结果如表 3-6 及图 3-5 所示。完整模型的表现依然最为稳健，其 AUC 与 AUPR 分别达到 0.9952 和 0.9935。当移除 GCL 模块后，模型的 Accuracy 和 Precision 分别降至 0.9425 和 0.9324，但 Recall 升至 0.9785，印证了 GCL 机制在过滤噪声、平衡查准率与查全率方面的关键作用。在微观表征方面，移除 Mamba 编码器导致 Recall 降至 0.9430，反映出模型捕捉长序列依赖的能力明显减弱。此外，采用简单特征拼接的 w/o Fusion 变体在各项指标上均为最低，证明了自适应门控机制在多模态特征对齐与融合中的必要性。

表 3-6 MGCL-DTI 及其变体模型在 Human 数据集上的消融实验结果

模型变体	AUC	AUPR	Accuracy	Precision	Recall
MGCL-DTI	0.9952$\pm$0.001	0.9935$\pm$0.006	0.9680$\pm$0.002	0.9524$\pm$0.003	0.9716 $\pm$ 0.002
w/o GCL	0.9842 $\pm$ 0.004	0.9815 $\pm$ 0.007	0.9425 $\pm$ 0.005	0.9324 $\pm$ 0.006	0.9785$\pm$0.004
w/o Mamba	0.9895 $\pm$ 0.003	0.9820 $\pm$ 0.008	0.9542 $\pm$ 0.004	0.9458 $\pm$ 0.004	0.9430 $\pm$ 0.006
w/o Fusion	0.9756 $\pm$ 0.005	0.9710 $\pm$ 0.006	0.9385 $\pm$ 0.007	0.9312 $\pm$ 0.008	0.9415 $\pm$ 0.007




图 3-5 MGCL-DTI 及其变体模型在 Human 数据集上的性能对比

3.3.7 参数分析

本文利用 Human 数据集进行了详尽的参数分析，重点探究图对比学习模块的训练轮数、初始学习率以及相似度阈值对预测性能的影响。所有实验数据均采用“平均值±标准差”的格式。




图 3-6 不同训练轮数对模型性能的影响

训练轮数直接影响图对比学习中特征表示的收敛质量。不同训练轮数下模型的预测性能变化如图 3-6 所示。在训练 1000 轮至 1500 轮期间，模型仍处于有效的特征学习阶段，各项性能指标保持稳步上升；当训练推进至 1500 至 2000 轮区间时，指标增速逐渐收敛放缓，模型逐步逼近最优解；当训练轮数超过 2000 后，性能提升趋于平缓。具体而言，AUC 和 AUPR 在 2000 轮时达到最优水平，继续增加至 3000 轮并未带来明显的边际收益，反而增加了计算成本。这表明模型在 2000 轮左右已能充分捕捉视图间的结构特征，因此本研究将图对比学习模块的训练轮数设定为 2000。

表 3-7 初始学习率对模型性能的影响

初始学习率	AUC	AUPR	Accuracy	Precision	Recall
0.0001	0.9642 $\pm$ 0.005	0.9718 $\pm$ 0.006	0.9363 $\pm$ 0.007	0.9112 $\pm$ 0.008	0.9445 $\pm$ 0.006
0.0005	0.9818 $\pm$ 0.004	0.9885 $\pm$ 0.004	0.9512 $\pm$ 0.005	0.9395 $\pm$ 0.005	0.9708 $\pm$ 0.005
0.001	0.9952$\pm$0.001	0.9935$\pm$0.006	0.9680$\pm$0.002	0.9524$\pm$0.003	0.9716$\pm$0.002
0.005	0.9825 $\pm$ 0.006	0.9787 $\pm$ 0.007	0.9552 $\pm$ 0.008	0.9328 $\pm$ 0.004	0.9711 $\pm$ 0.006
0.01	0.9651 $\pm$ 0.010	0.9456 $\pm$ 0.012	0.9254 $\pm$ 0.015	0.8855 $\pm$ 0.016	0.9680 $\pm$ 0.014




图 3-7 初始学习率的参数敏感性分析

初始学习率对模型收敛轨迹的影响如表 3-7 及图 3-7 所示，模型性能对学习率的变化表现出明显的单峰分布特征。当学习率较小为 0.0001 时，参数更新缓慢，在预设的 2000 轮内难以充分逼近最优解，导致 AUC 和 AUPR 分别停留在 0.9642 和 0.9718。当学习率增加至 0.001 时，模型性能达到峰值。当学习率进一步增大至 0.005 和 0.01 时，过大的步长导致损失函数在最优解附近震荡，特别是在学习率为 0.01 时，Accuracy 和 Precision 分别下跌至 0.92 和 0.88 左右，且标准差增大，训练稳定性遭到破坏。因此，本研究选取 0.001 作为默认初始学习率。

为验证理论推导的准确性，本研究在 Human 数据集上还探讨了 τ_{sim} 对预测性能的影响。实验结果表明，模型性能随 τ_{sim} 的增加呈现出先升后降的趋势。

当 $\tau_{sim} < 0.5$ 时，由于保留了过多噪声边，AUC 指标表现欠佳，证明了网络过密会稀释关键特征。

当 $\tau_{sim} \in [0.6, 0.8]$ 时，模型性能最为稳定，其中在 $\tau_{sim} = 0.7$ 时取得了最优的 AUC 与 AUPR

结果，这表明该阈值能有效平衡生物关联的完整性与网络的稀疏性。

当 $\tau_{sim} > 0.8$ 后，性能出现断崖式下跌，验证了网络过疏会导致宏观关系特征因拓扑信息缺失而失效。

3.3.8 可视化分析

本节采用 t-SNE (t-distributed Stochastic Neighbor Embedding) 降维算法对 MGCL-DTI 模型的特征学习过程进行可视化分析。t-SNE 能够将高维的特征表示投影到二维空间中，以便于直观观察样本的分布情况。在本实验中，我们旨在展示模型在不同训练阶段区分正负药物-靶点相互作用对的能力，从而验证其对特征空间的优化效果。

在模型的训练过程中，在关键的训练节点提取药物和靶点的高维特征并组合成联合表示，随后，利用 t-SNE 算法将其压缩至二维空间，并绘制为散点图。图 3-8 描绘了药物-靶点联合特征在三个关键训练阶段的演变过程，图中绿色圆点代表正样本对，紫色圆点代表负样本对。




图 3-8 MGCL-DTI 模型在不同训练周期的 t-SNE 特征空间分布图

在训练初期，如图 3-8 (a) 所示，正负样本在二维空间中呈现出大面积的重叠与高度混杂。此时模型参数尚未有效优化，提取的特征表示缺乏判别力，导致模型无法将不同类别的节点对有效区分。随着 GCL 机制的不断介入与模型参数的迭代更新，特征空间在训练中期开始发生明显的重构。如图 3-8 (b) 所示，正负类样本开始呈现出初步的分离趋势，同类样本逐渐向各自的区域聚集。这表明模型通过最大化同构网络中的视图互信息，逐步在特征空间中拉近相似节点的距离并推远不相关节点。当模型训练进入后期并趋于收敛时，如图 3-8 (c) 所示，尽管在边界处仍存在极少量的难分样本重叠，说明模型对部分难分样本

的区分能力仍有提升空间，但整体上正样本与负样本在特征空间中已经形成了相对清晰的界限和各自紧凑的聚类簇。

t-SNE 可视化结果显示，随着训练进行，正负样本的分离程度逐渐增加。这表明图对比学习机制有助于改善特征空间的判别性。

3.3.9 案例研究

本案例分析旨在评估 MGCL-DTI 模型预测潜在药物-靶点相互作用的能力。鉴于直接通过湿实验验证所有预测结果存在局限性，本节采用了两步方法进行初始验证。

表 3-8 MGCL-DTI 模型预测的苯丙胺前 15 个潜在靶点

排名	靶点蛋白名称	预测概率	文献支持
1	Norepinephrine transporter	0.998	PMID:31912366
2	Acetylcholinesterase	0.997	PMID:7155357
3	Solute carrier family 6 member 1	0.996	PMID:15615700
4	Sodium-dependent serotonin transporter	0.995	PMID:16722230
5	Monoamine oxidase type B	0.993	PMID:26841904
6	Prostaglandin E2 receptor EP1 subtype	0.991	未证实
7	5-hydroxytryptamine receptor 2B	0.989	PMID:16996724
8	D(4) dopamine receptor	0.988	PMID:20118172
9	Muscarinic acetylcholine receptor M1	0.986	PMID:11752469
10	Monoamine oxidase type A	0.984	PMID:9393679
11	Alpha-1A adrenergic receptor	0.982	PMID:16794571
12	Alpha-2C adrenoreceptor	0.980	PMID:25522417
13	Serotonin receptor 2A	0.977	PMID:23879373
14	Cholinesterase	0.975	PMID:19423342
15	Alpha-2A adrenergic receptor	0.973	PMID:8945686

本次案例分析重点聚焦于经典药物苯丙胺 (Amphetamine)，主要因为模型对其潜在靶点蛋白给出了高预测概率。具体而言，苯丙胺排名前 15 的潜在靶点蛋白预测概率均超过了 0.97，其中排名前 5 的预测结果更是达到了 0.99 以上。这些较高的预测得分，充分表明 MGCL-DTI 模型在精准捕获该药物与其相关蛋白相互作用方面具有较高的可信度。

在实验实施过程中，本研究首先从预测矩阵中剔除了所有已知的正样本。随后，提取了苯丙胺预测得分最高的前 15 个潜在靶点蛋白。为了验证这些预测的可靠性，本研究对已发表的研究文献进行了全面的检索。验证结果如表 3-8 所示，表中详细列出了具体的靶点蛋白名称、对应的预测排名，以及提供验证支持的研究论文 PMID 编号。

此次案例分析证明了 MGCL-DTI 模型在识别潜在药物-靶点相互作用方面的有效性。值得注意的是，在苯丙胺前 15 个预测潜在靶点蛋白中，有高达 14 个靶点成功通过了现有文献的印证。这些优异的结果显示了 MGCL-DTI 模型在为后续药理学调查筛选、鉴定高潜力候选靶标方面的能力。

3.3.10 模型计算效率分析

实际的药物虚拟筛选任务需要处理大量的化合物数据，因此计算效率是评估模型工程可行性的关键指标。如前文所述，Transformer 架构模型在处理长序列靶点时面临着算力与显存瓶颈。为直观验证不同架构的资源消耗趋势，本文在上述实验环境下实施了显存占用对比实验，通过人为将输入蛋白质序列的长度在 500 至 4000 以上的区间内进行梯度递增，观察不同模型的压力负载情况。

实验结果表明，MolTrans 等 Transformer 架构模型在推理阶段需要维护庞大的键值缓存矩阵，其显存消耗随序列加长呈现出急剧上升的趋势。在测试过程中，当序列长度接近 4000 时，由于显存占用超过硬件承载上限，此类模型会因显存溢出导致推理进程中断。相比之下，本文提出的 MGCL-DTI 模型得益于线性递归隐状态更新机制，无需在显存中存储全局交互矩阵。实验监控证实，本文模型的显存占用随序列长度呈平缓的线性增长，这保证了在有限算力下依然能够稳定完成对超长蛋白质序列的特征提取。

表 3-9 单样本平均训练与推理耗时

模型名称	训练时间（秒）	推理时间（秒）
MGCL-DTI	0.0183	0.0011
MolTrans	0.0675	0.0036
DO-GMA	0.0016	0.0004
CPI-GNN	0.0015	0.0005

除了压力测试，本文还测量了各模型处理单个样本的平均训练与推理耗时，统计结果如表 3-9 所示。为确保数据准确性，所有耗时均为批量大小设为 1 时循环 1000 次取平均值

的结果。测试数据进一步印证了运行效率上的差异，MolTrans 因复杂的矩阵点乘开销，其推理耗时在所有对比方法中最高。而 MGCL-DTI 在推理效率上得到优化，单样本推理时间仅为 0.0011 秒，处理速度约为前者的三倍，吞吐量大幅提升。

此外，表中数据显示 DO-GMA 与 CPI-GNN 这类基于 CNN 或 GNN 架构的模型推理耗时极短，均低于 0.0006 秒。然而，受限于局部感受野，它们难以充分捕捉靶点蛋白的长程空间结构，导致预测精度表现略低。综合时间与空间开销的测试结果可以得出，MGCL-DTI 既规避了 Transformer 架构带来的效率瓶颈，又克服了局部感受野受限的缺陷。模型通过一维序列与二维图特征的高效融合，实现了预测精度与计算效率之间的理想平衡，为临床前药物筛选提供了更具实用性的计算方案。

3.4 本章小结

本章提出了基于图对比学习与图 Mamba 的药物-靶点相互作用预测模型 MGCL-DTI，旨在通过引入高效的状态空间模型与自监督对比机制，提升模型对复杂生物分子特征的捕捉能力与预测性能。首先，本章概述了 MGCL-DTI 模型的研究背景与设计目标，详细描述了模型的整体架构，包括多模态特征的预处理、基于图 Mamba 的特征编码器、图对比学习辅助模块以及多模态特征融合机制的设计与实现。接着，本章系统地设计了实验方案，包括数据集的选取、评价指标的确定、实验环境的设置以及主流基线模型的对比说明。在实验结果分析部分，通过对比实验验证了 MGCL-DTI 相较于基线模型的优越性，结合配对 t 检验在统计学上证实了这种性能提升的显著性，并通过消融实验证实了各核心模块对提升模型性能的必要性。此外，本章还通过参数分析实验探讨并确立了最优实验配置。随后，通过特征可视化直观展示了模型的聚类效果，并利用苯丙胺的潜在药物-靶点相互作用预测案例，验证了模型在发现新药靶点方面的泛化能力。同时，计算效率分析进一步验证了模型在实际应用中的可行性。实验结果表明，MGCL-DTI 在药物-靶点相互作用预测任务中具有一定优势。本章的研究为解决 DTI 预测中的特征稀疏与长程依赖问题提供了新的思路，并为后续研究奠定了坚实基础。

4 基于图 Transformer 与文本语义融合的 DTI 预测模型

4.1 引言

上一章提出的 MGCL-DTI 模型有效缓解了蛋白质长序列建模的计算瓶颈与交互网络稀疏性问题，取得了较好的预测效果。然而，在处理 DrugBank 等包含复杂化合物的数据集时，该模型在药物分子微观特征提取方面的局限性逐渐显现。传统的图神经网络主要依赖局部邻域的消息传递，在层数较浅时难以感知分子的全局构象，而加深网络又易引发过度平滑，这使得模型难以准确捕捉分子内远端原子或官能团间的复杂相互作用。此外，单纯的二维拓扑结构也难以全面反映分子内在的物理化学属性与药理学语义。

要实现更精细的微观表征，引入全局注意力机制是一个可行的方向。对于动辄数千长度的蛋白质序列，Transformer 的二次复杂度是主要瓶颈，因此第三章采用了具有线性复杂度的 Mamba 架构。而对于通常不超过 200 个原子的药物分子，Transformer 的二次复杂度在可控的计算成本之内，且其全局注意力机制能提供更精细的结构建模。另一方面，药物的 SMILES 序列包含明确的药理学语义，可以作为图结构的可靠补充。将图拓扑空间特征与文本序列语义相融合，有助于克服单一模态的表征局限，提升模型对未知药物骨架的泛化能力。

为此，本章在第三章工作的基础上，保留了针对大分子蛋白质的高效 Mamba 序列编码器，重点聚焦微观表征的精细化与跨模态语义融合，提出了一种基于图 Transformer 与文本语义融合的 DTI 预测模型 GTCM-DTI (Graph Transformer based Cross-Modal Drug-Target Interaction prediction model)。该模型引入增强型图 Transformer 作为分子结构编码器，通过注入原子中心性、空间位置和边特征编码，捕捉分子的全局依赖关系；同时，设计了跨模态双向自适应引导融合模块 (Bidirectional Adaptive Guided Fusion, BAGF)，利用双向注意力机制实现图拓扑与文本语义的特征对齐与动态重构。该机制利用文本语义辅助锁定图结构中的核心药效团，以进一步提升模型对复杂药物-靶点相互作用的解析能力。

4.2 算法设计

4.2.1 模型整体架构

如图 4-1 所示，GTCM-DTI 模型的整体架构包含三个协同工作的核心组件：多模态特征编码层、BAGF 模块以及预测层。




图 4-1 GTCM-DTI 模型整体架构示意图

(1) 多模态特征编码层

该层负责将原始的生物化学数据转化为高维特征向量，包含药物和靶点两个分支：

药物特征分支：采用双流编码策略。在结构流中，利用增强型图 Transformer 对药物分子图进行编码，提取包含全局依赖的几何结构特征；在语义流中，利用双向门控循环单元 (Bi-GRU)^{[69][70]}对药物的 SMILES 字符串序列进行处理，提取上下文语言学特征。

靶点特征分支：为承接前文并控制计算开销，采用与第三章相同的双向 Mamba 架构作为主干网络，将蛋白质的超长氨基酸序列映射为具备长程依赖信息的序列特征向量。

(2) BAGF 模块

该模块接收药物的图结构特征与文本语义特征，利用交叉注意力机制进行异构信息的对齐。计算过程包含两个互为导向的子过程：

文本引导图：以文本特征为查询向量，引导网络聚焦分子图中的关键活性子结构。

图引导文本：以图特征为查询向量，辅助筛选并校准 SMILES 序列中的重要语义片段。完成双向交互后，模块通过一个自适应门控机制动态计算两类模态的权重，输出整合后的药物综合表征。

(3) 预测层

最后，融合后的药物综合表征与靶点序列特征被拼接为一个联合向量，输入至 MLP 构成的预测头中。经过非线性映射，输出一个概率值，代表该药物-靶点对存在相互作用的预测结果。

4.2.2 基于图 Transformer 的药物分子结构编码

本节采用图 Transformer 架构对药物分子进行微观结构编码。为了弥补标准 Transformer 在处理图数据时结构信息的缺失，本文在注意力计算中显式注入了三种关键的结构归纳偏置。给定包含 n 个原子和 m 条化学键的药物分子图 $G = (V, E)$ ，其具体的特征编码与计算流程如下：

(1) 原子中心性编码

在药物分子图中，不同位置的原子具有不同的拓扑重要性。例如，处于分子骨架中心的碳原子通常比末端的氢原子具有更高的连接度。标准 Transformer 无法区分这种节点重要性。为此，根据原子的度数 $\text{deg}(v_i)$ ，为每个节点添加可学习的中心性嵌入向量。

输入层节点的初始特征 $h_i^{(0)}$ 计算如下：

$$h_i^{(0)} = x_i + z_{\text{deg}(v_i)} \quad (4-1)$$

其中， x_i 表示包含原子类型、电荷等信息的原始化学特征， $z_{\text{deg}(v_i)}$ 表示根据原子度数映射的可学习嵌入向量。这种编码使得模型能够根据原子的连接稠密程度自适应地分配注意力权重，从而更准确地识别分子活性中心。

(2) 空间位置编码

为了捕捉分子内部的长程依赖，必须保留原子间的相对位置信息。由于分子图是非欧几里得结构，主要依赖拓扑距离而非几何坐标。通过计算任意两个原子 v_i, v_j 在图上的最短路径距离 (Shortest Path Distance, SPD)，记为 $\phi(v_i, v_j)$ ，将这一距离映射为一个可学习的标量偏置 $b_{\phi(v_i, v_j)}$ ，并将其直接加入到自注意力机制的注意力分数计算中。对于图 Transformer 的第 l 层，给定来自上一层的节点特征 $h_i^{(l-1)}$ 和 $h_j^{(l-1)}$ ，融入空间位置编码的注意力分数 e_{ij} ，计算如下：

$$e_{ij}^{(l)} = \frac{(h_i^{(l-1)} W_Q)(h_j^{(l-1)} W_K)^T}{\sqrt{d}} + b_{\phi(v_i, v_j)} \quad (4-2)$$

其中, h_i 和 h_j 分别表示原子 v_i 和 v_j 的特征向量, $W_Q, W_K \in \mathbb{R}^{d \times d}$ 是查询和键的投影矩阵, d 是隐藏层维度。通过引入 $b_{\phi(v_i, v_j)}$, 模型能够根据原子间的距离动态调整关注度, 不仅能捕捉邻近原子的化学环境, 还能感知分子的全局构象。如果两个原子不可达, 则设定 $\phi(v_i, v_j) = \infty$, 对应的偏置置为极小值。

(3) 边特征编码

化学键的类型对药物的理化性质至关重要。传统的图注意力网络往往忽略了边特征或仅将其作为辅助信息。在图 Transformer 中, 对连接原子 v_i 和 v_j 的最短路径上的所有边特征进行编码融合。

设 $SP_{ij} = (e_{p_1}, e_{p_2}, \dots, e_{p_k})$ 为从 v_i 到 v_j 的最短路径上的边序列。通过计算路径上的边特征嵌入的均值作为边编码偏置 c_{ij} :

$$c_{ij} = \frac{1}{k} \sum_{r=1}^k x_{e_{p_r}} W_E \quad (4-3)$$

其中, k 为序列 SP_{ij} 的长度, $x_{e_{p_r}}$ 表示最短路径上第 r 条边 e_{p_r} 的原始特征向量, W_E 为可学习的边特征投影权重矩阵。若两节点在图中不可达, 则该序列为空, 对应的 c_{ij} 设为零向量。

(4) 融合后的自注意力机制

如图 4-2 所示, 结合了上述所有结构信息后, 图 Transformer 第 l 层的自注意力系数 α_{ij} 及节点特征更新公式定义为:

$$\alpha_{ij} = \text{softmax}(e_{ij}^{(l)} + c_{ij}) \quad (4-4)$$

$$h_i^{(l+1)} = \text{FFN} \left(\text{LayerNorm} \left(h_i^{(l)} + \sum_{j \in V} \alpha_{ij} (h_j^{(l)} W_V) \right) \right) \quad (4-5)$$

其中, W_V 为可学习的值向量投影矩阵。通过堆叠 L 层图 Transformer, 模型最终输出包含丰富几何结构信息和全局依赖关系的药物节点表征 $H_{graph} \in \mathbb{R}^{N \times d}$, 其中 N 为原子节点数。该表征不仅克服了 GCN 的过平滑问题, 还通过显式的结构编码刻画了药物分子的微观化学环境。




图 4-2 基于图 Transformer 的药物分子结构编码机制

4.2.3 跨模态双向自适应引导融合模块

为本节详细阐述 BAGF 的具体计算流程。该模块通过构建双向交叉注意力机制, 对齐分子的图拓扑结构与线性序列特征, 实现多源异构信息的深度对齐与动态重构。

(1) 文本模态特征提取

对于药物的 SMILES 字符串序列, 本文首先将其映射为词嵌入向量, 然后利用 Bi-GRU 提取上下文语义特征。设输入 SMILES 序列长度为 M , 经过处理后得到的文本特征矩阵表示为 $H_{text} \in \mathbb{R}^{M \times d}$:

$$H_{text} = \text{Bi-GRU}(\text{Embedding}(\text{SMILES})) \quad (4-6)$$

同时, 来自图 Transformer 输出的药物分子结构特征记为 $H_{graph} \in \mathbb{R}^{N \times d}$, 其中 N 为原子节点数。

(2) 双向交叉注意力交互

为了实现结构与语义的深度对齐, 本文设计了两个对称的交叉注意力单元。这种设计允许不同模态的信息流相互渗透, 修正各自的特征表达:

文本引导的图特征增强：该过程旨在利用全局文本语义来动态调整对局部原子结构的关注度。在此阶段， H_{graph} 作为查询矩阵 (Q)，将文本特征 H_{text} 作为键矩阵 (K) 和值向矩阵 (V)。通过计算图节点与文本词元 (token) 之间的相关性，将相关的语义信息注入到图结构中：

$$H'_{graph} = \text{softmax} \left(\frac{(H_{graph} W_{Q1})(H_{text} W_{K1})^T}{\sqrt{d}} \right) (H_{text} W_{V1}) + H_{graph} \quad (4-7)$$

其中， W_{Q1}, W_{K1}, W_{V1} 为可学习的交叉注意力投影矩阵，残差连接用于保留原始的结构信息，防止语义噪声破坏图的拓扑特征。输出 H'_{graph} 表示融合了文本语义上下文的增强型分子图表征。

图引导的文本特征增强：反之，为了利用分子的几何拓扑信息来消除 SMILES 序列中的语法歧义，将文本特征 H_{text} 作为 Q ，图特征 H_{graph} 作为 K 和值 V ，生成具有结构感知能力的文本表征：

$$H'_{text} = \text{softmax} \left(\frac{(H_{text} W_{Q2})(H_{graph} W_{K2})^T}{\sqrt{d}} \right) (H_{graph} W_{V2}) + H_{text} \quad (4-8)$$

其中， W_{Q2}, W_{K2}, W_{V2} 为该分支的投影矩阵。

(3) 全局特征池化

如图 4-3 所示，经过节点与词元交互后，需要将变长的特征矩阵转换为固定长度的全局特征向量。为了自动识别并聚合对预测任务贡献最大的关键节点或关键词，本节采用基于注意力的加权池化 (Attention Pooling) 策略。

对于药物的图分支，全局结构表征 $v_{graph} \in \mathbb{R}^d$ 计算如下：

$$w_i = \sigma(h'_{graph,i} W_{att} + b_{att}) \quad (4-9)$$

$$v_{graph} = \sum_{i=1}^N \frac{\exp(w_i)}{\sum_{k=1}^N \exp(w_k)} h'_{graph,i} \quad (4-10)$$

其中, W_{att} 和 b_{att} 为可学习的注意力参数, σ 为 $\tanh$ 激活函数, $h'_{graph,i}$ 为增强后特征矩阵的第 i 行向量。同理, 对于药物的文本分支, 本文采用相同的机制将 H_{text} 聚合为全局语义表征 $v_{text} \in \mathbb{R}^d$ 。




图 4-3 跨模态双向自适应引导融合机制示意图

注：该模块展示了图特征与文本特征如何通过双向交叉注意力进行交互，并利用自适应门控机制 α 实现动态加权融合。

(4) 自适应门控融合

考虑到对于不同的药物分子, 其结构信息的复杂度和文本描述的丰富度可能不同。例如, 某些具有特定立体异构的药物, 其关键性质主要取决于三维构象, 而另一些药物的关键性质, 则更清晰地体现在 SMILES 序列的官能团描述中。简单的平均融合无法捕捉这种差异。为此, 本文引入了一个自适应门控系数来动态调节两个模态的贡献度。

首先将图表征与文本表征拼接, 通过 MLP 生成门控系数 $\alpha \in [0,1]$:

$$\alpha = \sigma(W_{gate}[v_{graph} \parallel v_{text}] + b_{gate}) \quad (4-11)$$

其中, W_{gate} 和 b_{gate} 分别为门控机制中可学习的权重矩阵和偏置向量, $\parallel$ 表示向量拼接。 α 的值越接近 1, 表示模型越依赖图结构信息, 反之则越依赖文本语义信息。

最终的药物多模态融合表征计算为:

$$v_{drug}^{final} = \alpha v_{graph} + (1-\alpha) v_{text} \quad (4-12)$$

通过上述自适应门控机制，最终生成的向量 v_{drug}^{final} 实现了分子拓扑结构与生化语义的特征对齐。该向量将作为药物端的全局多模态表征，输出至后续的交互预测模块。

4.2.4 基于双向 Mamba 机制的靶点蛋白质序列编码

为与药物分支引入的计算密集型图 Transformer 形成算力负载平衡，并确保模型整体训练的高效性，本节沿用第三章中已验证的双向 Mamba 作为蛋白质的序列编码骨干网络。

给定靶点蛋白质序列 P ，首先将其输入到嵌入层得到初始特征矩阵 E_P 。随后，利用双向 Mamba 模块分别从前向和后向扫描序列，以捕捉氨基酸残基间的双向长程语义依赖。与 3.2.2 节中融合多头注意力的复杂设计不同，为适配本章的跨模态融合框架，直接提取双向 Mamba 层的输出，并通过全局均值池化 (Global Average Pooling) 将其压缩为固定维度的靶点特征向量 $v_{target} \in \mathbb{R}^d$ ：

$$H_{seq} = Bi\text{-}Mamba(E_P) \quad (4-13)$$

$$v_{target} = Pooling(H_{seq}) \quad (4-14)$$

其中， H_{seq} 表示经过双向上下文建模后的序列特征矩阵。最终得到的向量 v_{target} 浓缩了蛋白质的序列语义与结构依赖信息。这种针对不同模态特征复杂度进行参数非对称分配的提取策略，不仅优化了整体模型的推理速度，还可以避免因单一模态过度参数化而引发的过拟合风险。

4.2.5 药物-靶点特征交互预测与模型优化

经过前述模块的特征提取与增强，分别获得了跨模态融合的药物特征向量 v_{drug}^{final} 与包含长程依赖的靶点特征向量 v_{target} 。本节旨在通过非线性交互层输出最终预测结果，并基于监督信号实现模型参数的端到端优化。

(1) 联合表征与亲和力预测

为捕获药物与靶点在特征空间中的共现模式, 本文放弃了简单的点积操作, 而是将 v_{drug}^{final} 和 v_{target} 在通道维度进行拼接, 构建包含完整上下文信息的联合特征表示 $v_{joint} \in \mathbb{R}^{2d}$:

$$v_{joint} = [v_{drug}^{final} \parallel v_{target}] \quad (4-15)$$

考虑到简单的线性组合难以拟合药物与靶点间复杂的生化结合机制, 本文将联合特征 v_{joint} 输入到一个由 MLP 构成的非线性预测头中。为增强模型的泛化能力并防止过拟合, 在隐藏层之间引入 ReLU 激活函数与 Dropout 正则化机制。最终的相互作用概率 $\hat{y}_{ij}$ 计算如下:

$$\hat{y}_{ij} = \sigma(\text{Dropout}(\text{ReLU}(v_{joint}W_h + b_h))W_{out} + b_{out}) \quad (4-16)$$

其中, W_h, b_h 与 W_{out}, b_{out} 分别为隐藏层与输出层的可学习权重与偏置参数; σ 为 Sigmoid 激活函数, 旨在将最终输出值映射至区间 (0,1), 以表示药物 i 与靶点 j 发生相互作用的预测概率。

(2) 目标函数与训练策略

为实现端到端的模型优化, 本研究采用 BCE 作为主优化目标, 旨在最小化预测概率分布与真实标签分布之间的差异。假设当前训练批次的样本集合为 D , 包含 N 个药物-靶点对样本, 总损失函数 $\mathcal{L}_{total}$ 定义为:

$$\mathcal{L}_{total} = -\frac{1}{N} \sum_{(i,j) \in D} [y_{ij} \log(\hat{y}_{ij}) + (1-y_{ij}) \log(1-\hat{y}_{ij})] + \lambda \|\theta\|_2^2 \quad (4-17)$$

其中, $y_{ij} \in \{0,1\}$ 为真实的相互作用标签, $\hat{y}_{ij}$ 为模型预测概率; $\lambda \|\theta\|_2^2$ 为 L_2 正则化项, 用于约束模型中所有可学习参数 θ 的范数, 以进一步降低过拟合风险。

4.3 实验分析

4.3.1 实验数据与设置

为确保实验的一致性与可比性, 本章 GTCM-DTI 模型的性能评估均采用与第三章相同

的数据集（详见 3.3.1 节）、评价指标（详见 3.3.3 节）以及十折交叉验证划分策略。

GTCM-DTI 模型的超参数设置如下：模型继续采用 Adam 优化器进行参数更新，其权重衰减率为 1×10^{-4} ，初始学习率为 5×10^{-4} 。模型训练共进行 100 个轮次，批量大小设置为 128，Dropout 率设置为 0.1，并引入早停策略 (Patience = 20) 以防止过拟合。在特征提取模块中，图 Transformer 的层数设置为 2，隐藏特征维度为 128，注意力头数设置为 8，文本分支采用 2 层 Bi-GRU。这些参数经过多次实验调优，以确保模型在药物靶点相互作用预测任务中的最佳性能。

4.3.2 对比实验

表 4-1、表 4-2、表 4-3 分别展示了 GTCM-DTI 模型与基线模型在 C.elegans、Human 和 DrugBank 数据集上的性能对比。本节实验均基于十折交叉验证，各项评价指标的数据以“平均值 $\pm$ 标准差”形式呈现，并使用粗体标示最优结果。

表 4-1 不同模型在 C.elegans 数据集上的性能对比

模型名称	AUC	AUPR	Accuracy	Precision	Recall
CPI-GNN	0.9536 $\pm$ 0.008	0.9422 $\pm$ 0.012	0.9146 $\pm$ 0.010	0.9185 $\pm$ 0.009	0.8292 $\pm$ 0.020
MolTrans	0.9918 $\pm$ 0.002	0.9920 $\pm$ 0.003	0.9670 $\pm$ 0.003	0.9626 $\pm$ 0.005	0.9342 $\pm$ 0.006
MCL-DTI	0.9706 $\pm$ 0.003	0.9769 $\pm$ 0.003	0.9072 $\pm$ 0.006	0.9744 $\pm$ 0.011	0.8486 $\pm$ 0.016
HyperAttentionDTI	0.9934 $\pm$ 0.001	0.9939 $\pm$ 0.001	0.9551 $\pm$ 0.009	0.9466 $\pm$ 0.013	<u>0.9677$\pm$0.010</u>
GIFDTI	0.9880 $\pm$ 0.006	0.9902 $\pm$ 0.005	0.9422 $\pm$ 0.014	0.9366 $\pm$ 0.016	0.9529 $\pm$ 0.018
MHSADTI	0.9776 $\pm$ 0.006	0.9808 $\pm$ 0.006	0.9242 $\pm$ 0.005	0.9002 $\pm$ 0.006	0.9652 $\pm$ 0.007
MCANet	0.9920 $\pm$ 0.002	0.9925 $\pm$ 0.001	0.9661 $\pm$ 0.005	0.9666 $\pm$ 0.005	0.9674 $\pm$ 0.009
DO-GMA	0.9926 $\pm$ 0.003	0.9905 $\pm$ 0.005	0.9716 $\pm$ 0.003	0.9715 $\pm$ 0.003	0.9645 $\pm$ 0.006
LAM-DTI	0.9929 $\pm$ 0.001	0.9914 $\pm$ 0.001	0.9690 $\pm$ 0.005	0.9690 $\pm$ 0.005	0.9382 $\pm$ 0.010
FOTF-CPI	0.9919 $\pm$ 0.003	0.9909 $\pm$ 0.005	0.9663 $\pm$ 0.005	0.9651 $\pm$ 0.005	0.9436 $\pm$ 0.009
MGCL-DTI	0.9958$\pm$0.001	0.9970$\pm$0.004	0.9782$\pm$0.002	<u>0.9805$\pm$0.006</u>	0.9783$\pm$0.005
GTCM-DTI	<u>0.9942$\pm$0.002</u>	<u>0.9965$\pm$0.002</u>	<u>0.9767$\pm$0.003</u>	0.9815$\pm$0.005*	0.9623 $\pm$ 0.004

注：*表示本文模型相较于最优的基线模型，经配对 t 检验具有统计学显著性提升 ($p < 0.05$)。

如表 4-1 所示，GTCM-DTI 模型在 C.elegans 数据集上的 AUC 与 Accuracy 略低于第三章的 MGCL-DTI。这主要归因于 C.elegans 数据集的样本规模有限且特征同质性较强，轻

量化的图 Mamba 架构已能实现充分表征。相比之下，GTCM-DTI 复杂的结构编码与多模态融合机制在小规模样本下产生了一定程度的过拟合倾向，导致泛化性能出现边际递减。但该模型在 Precision (0.9815) 指标上仍优于所有基线模型，证明其对正样本的判别精度并未因参数量增加而受损。

如表 4-2 所示，在 Human 数据集上，GTCM-DTI 展现了稳健的性能，AUC 达到 0.9956，略优于 MGCL-DTI (0.9952)。Human 数据集具有一定的稀疏性特征，且 CPI-GNN、MolTrans 等基线模型的 AUC 普遍低于 0.98。在此背景下，GTCM-DTI 能够维持与 MGCL-DTI 略优的预测精度，证明了引入文本语义信息能够辅助模型在稀疏的图拓扑结构中进行推断，弥补了仅依赖结构信息时的连接缺失问题。

表 4-2 不同模型在 Human 数据集上的性能对比

模型名称	AUC	AUPR	Accuracy	Precision	Recall
CPI-GNN	0.9329 $\pm$ 0.009	0.9174 $\pm$ 0.016	0.8899 $\pm$ 0.008	0.8858 $\pm$ 0.010	0.7798 $\pm$ 0.017
MolTrans	0.9799 $\pm$ 0.003	0.9785 $\pm$ 0.004	0.9418 $\pm$ 0.010	0.9207 $\pm$ 0.029	0.8823 $\pm$ 0.020
MCL-DTI	0.9850 $\pm$ 0.003	0.9516 $\pm$ 0.004	0.9459 $\pm$ 0.005	0.9452 $\pm$ 0.007	0.9482 $\pm$ 0.005
HyperAttentionDTI	0.9805 $\pm$ 0.003	0.9516 $\pm$ 0.004	0.9348 $\pm$ 0.005	0.9226 $\pm$ 0.007	0.9586 $\pm$ 0.005
GIFDTI	0.9715 $\pm$ 0.005	0.9807 $\pm$ 0.007	0.9140 $\pm$ 0.013	0.9022 $\pm$ 0.034	0.9197 $\pm$ 0.016
MHSADTI	0.9693 $\pm$ 0.001	0.9225 $\pm$ 0.005	0.9117 $\pm$ 0.006	0.8992 $\pm$ 0.016	0.9311 $\pm$ 0.014
MCANet	0.9937 $\pm$ 0.002	0.9902 $\pm$ 0.002	0.9572 $\pm$ 0.003	0.9519 $\pm$ 0.010	0.9615 $\pm$ 0.010
DO-GMA	0.9891 $\pm$ 0.003	0.9870 $\pm$ 0.007	0.9541 $\pm$ 0.005	<u>0.9544$\pm$0.005</u>	0.9598 $\pm$ 0.010
LAM-DTI	0.9860 $\pm$ 0.004	0.9854 $\pm$ 0.002	0.9502 $\pm$ 0.006	0.9497 $\pm$ 0.006	0.9407 $\pm$ 0.011
FOTF-CPI	0.9919 $\pm$ 0.003	0.9909 $\pm$ 0.005	0.9663 $\pm$ 0.005	0.9651 $\pm$ 0.005	0.9436 $\pm$ 0.009
MGCL-DTI	<u>0.9952$\pm$0.001</u>	<u>0.9935$\pm$0.006</u>	<u>0.9680$\pm$0.002</u>	0.9524 $\pm$ 0.003	<u>0.9716$\pm$0.002</u>
GTCM-DTI	0.9956$\pm$0.001*	0.9942$\pm$0.005*	0.9715$\pm$0.002*	0.9553$\pm$0.003*	0.9745$\pm$0.003*

注：*表示本文模型相较于最优的基线模型，经配对 t 检验具有统计学显著性提升 ($p < 0.05$)。

相比于前两个数据集，DrugBank 包含大量结构复杂且药理机制多样的药物分子，是检验模型处理异质图数据能力的关键基准。如表 4-3 所示，GTCM-DTI 在该数据集上取得了整体的性能优势。

具体而言，GTCM-DTI 的 AUC 达到了 0.9435，AUPR 达到 0.9612，不仅优于基于序

列的 MCANet (AUC 为 0.9295), 与第三章的 MGCL-DTI (AUC 为 0.9315) 相比, 更实现了约 1.2%的提升。为了进一步检验模型在未知药物分子上的泛化能力, 本文对 DrugBank 数据集进行了专门的未见药物预测测试 (Unseen Drug Prediction)。在此设置下, 测试集中所有的药物分子在训练过程中都没有出现过, 因此可以对图 Transformer 捕捉分子结构普适特征的能力进行严格的测试。实验结果表明, GTCM-DTI 在新药预测场景下的 AUC 指标比传统的随机划分要低约 1.8%, 远好于基线模型中普遍超过 5%的性能下降。

这一结果支持了本章的核心假设, 在面对 DrugBank 等包含复杂分子结构的大规模网络时, 仅依靠宏观拓扑关联存在特征表达的局限性。GTCM-DTI 利用图 Transformer 精准刻画分子微观几何特征, 并借助 SMILES 文本语义辅助识别细微的官能团差异, 弥补单一模态的不足。此外, 模型在冷启动场景下展现出的性能优势, 充分表明微观结构精细化与语义互补相结合的策略, 能增强模型对全新药物骨架的泛化能力与预测鲁棒性。

表 4-3 不同模型在 DrugBank 数据集上的性能对比

模型	AUC	AUPR	Accuracy	Precision	Recall
MCL-DTI	0.8514 $\pm$ 0.004	0.7743 $\pm$ 0.009	0.7834 $\pm$ 0.002	0.7945 $\pm$ 0.004	0.8169 $\pm$ 0.006
HyperAttention DTI	0.9105 $\pm$ 0.003	0.9289 $\pm$ 0.003	0.8272 $\pm$ 0.005	0.8160 $\pm$ 0.008	0.8802 $\pm$ 0.006
GIFDTI	0.9115 $\pm$ 0.005	0.9201 $\pm$ 0.006	0.8265 $\pm$ 0.009	0.8091 $\pm$ 0.011	<u>0.8982$\pm$0.009</u>
MHSADTI	0.8695 $\pm$ 0.009	0.8622 $\pm$ 0.010	0.7912 $\pm$ 0.012	0.7967 $\pm$ 0.024	0.8381 $\pm$ 0.025
MCANet	0.9295 $\pm$ 0.005	0.9490 $\pm$ 0.005	0.8520 $\pm$ 0.006	0.8587 $\pm$ 0.006	0.8751 $\pm$ 0.015
DO-GMA	0.9234 $\pm$ 0.006	0.9383 $\pm$ 0.007	0.8619 $\pm$ 0.011	0.8423 $\pm$ 0.013	0.8841 $\pm$ 0.018
LAM-DTI	0.9213 $\pm$ 0.005	0.9357 $\pm$ 0.008	0.8490 $\pm$ 0.008	0.8223 $\pm$ 0.015	0.8721 $\pm$ 0.012
MGCL-DTI	<u>0.9315$\pm$0.006</u>	<u>0.9518$\pm$0.004</u>	<u>0.8657$\pm$0.010</u>	<u>0.8653$\pm$0.012</u>	0.8853 $\pm$ 0.014
GTCM-DTI	0.9435$\pm$0.005 *	0.9612$\pm$0.002 *	0.8797$\pm$0.009 *	0.8790$\pm$0.008 *	0.9085$\pm$0.012 *

注: *表示本文模型相较于最优的基线模型, 经配对 t 检验具有统计学显著性提升 ($p < 0.05$)。

为从统计学角度严格评估 GTCM-DTI 模型的改进效果, 本节沿用第三章的配对 t 检验方法进行了显著性分析。检验结果表明, 在绝大多数核心评价指标上, 特别是针对分子结构更为复杂、难度更高的 DrugBank 数据集, GTCM-DTI 相较于次优模型的性能提升均达到了 $p < 0.05$ 的统计学显著性水平。尽管在相对简单的 C.elegans 数据集的部分指标上, GTCM-DTI 并未全面超越 MGCL-DTI 模型, 这主要是因为轻量化网络已足以充分提取同

质化较高的小规模样本特征，复杂的跨模态融合机制并未带来额外的增益。然而，在应对具有高度异质性的真实临床网络时，GTCM-DTI 展现出了优势，这充分证实了 BAGF 机制及图 Transformer 架构在应对复杂特征时，对于增强模型精准推断与泛化能力具有显著的统计学意义与实际应用价值。

4.3.3 消融实验

为了深入剖析 GTCM-DTI 模型中各个核心组件对预测性能的具体贡献，本节在 DrugBank 数据集上设计了消融实验。实验遵循控制变量原则，以包含所有核心机制的完整模型作为性能基准，构建了三种变体网络。具体而言，w/o Text 变体移除了 SMILES 文本语义分支，仅保留基于图 Transformer 的结构编码器，以评估文本语义在互补几何特征中的作用；w/o BAGF 变体保留了双模态特征提取，但去除了融合模块中的交叉注意力与门控机制，退化为简单的特征通道拼接，旨在验证精细化特征对齐与去噪机制的优势；Repl-GCN 变体则将核心的图 Transformer 替换为传统的 GCN，用于考察图结构编码器的选择对整体模型性能的影响。本节消融实验均基于十折交叉验证，各项评价指标的数据以“平均值±标准差”形式呈现，并使用粗体标示最优结果。

表 4-4 及图 4-4 详细展示了完整模型与各变体模型在 DrugBank 数据集上的性能对比结果。首先，SMILES 文本语义在互补几何结构缺失方面发挥了至关重要的作用，当采用仅保留图结构特征的 w/o Text 时，模型性能出现了最明显的下滑，其 AUC 仅为 0.9287，相比完整模型 GTCM-DTI 的 0.9435 下降了约 1.5%，是所有变体中性能损失最大的。这一结果证明了 SMILES 文本序列中蕴含的显式语言学特征，例如对特定远端官能团的描述，包含了图拓扑结构难以编码的补充信息。当缺失这一模态时，模型退化为纯结构特征提取，在面对结构高度相似但药理活性截然不同的分子时，难以捕捉关键的语义差异。

其次，BAGF 机制在特征对齐与去噪方面展现了一定优势。具体而言，采用简单拼接变体的 Recall 高达 0.9120，略高于完整模型，但其 Precision 仅为 0.8603，显著低于完整模型的 0.8790。如图所示，w/o BAGF 变体呈现出高召回、低精确的现象，这表明，简单的特征拼接虽然引入了更多信息量从而提升了召回率，但也同时引入了大量未对齐的跨模态噪声，导致模型误判率上升。相比之下，完整模型采用的 BAGF 机制利用交叉注意力有效过滤了冗余干扰，在维持高召回率的同时大幅提升了精确率，实现了最佳的综合性能。此外，Repl-GCN 变体的表现 AUC 为 0.9314，显著弱于完整模型，进一步验证了在处理复杂药物分子时，传统的 GCN 因过度平滑问题难以捕捉长程原子依赖，而图 Transformer 的引入为多模态融合提供了更优质的结构特征基础。

表 4-4 GTCM-DTI 及其变体模型在 DrugBank 数据集上的消融实验结果

模型变体	AUC	AUPR	Accuracy	Precision	Recall
GTCM-DTI (完整)	0.9435$\pm$0.005	0.9612$\pm$0.002	0.8797$\pm$0.009	0.8790$\pm$0.008	0.9085 $\pm$ 0.012
w/o Text (仅图结构)	0.9287 $\pm$ 0.007	0.9453 $\pm$ 0.005	0.8612 $\pm$ 0.011	0.8658 $\pm$ 0.008	0.8914 $\pm$ 0.016
Repl-GCN (GCN+文本)	0.9314 $\pm$ 0.008	0.9468 $\pm$ 0.005	0.8643 $\pm$ 0.008	0.8617 $\pm$ 0.009	0.8892 $\pm$ 0.010
w/o BAGF (简单拼接)	0.9384 $\pm$ 0.007	0.9519 $\pm$ 0.006	0.8678 $\pm$ 0.013	0.8603 $\pm$ 0.008	0.9120$\pm$0.007




图 4-4 GTCM-DTI 及其变体模型在 DrugBank 数据集上的性能对比

4.3.4 参数分析

为了全面验证 GTCM-DTI 模型在不同超参数配置下的鲁棒性，并确定能够平衡预测精度、计算效率与泛化能力的最佳参数组合，本节选取了对模型性能影响最为显著的两个关键超参数即隐藏层特征维度 d_{model} 与图 Transformer 编码层数 L 进行了敏感性分析。本节所有参数分析实验均在 DrugBank 数据集上进行，采用十折交叉验证，最终结果以“平均值 $\pm$ 标准差”的形式呈现。

隐藏层特征维度是决定 GTCM-DTI 模型特征表达能力与计算复杂度的关键参数。如表 4-5 及图 4-5 所示，模型性能随维度的变化呈现出由欠拟合向过参数化转变的演变规律。在 d_{model} 为 32 和 64 时，受限于特征空间，模型难以有效编码复杂的跨模态交互信息，各项指标均未达到最优水平，表现出典型的欠拟合特征。当维度增加至 128 时，模型达到了性能的最优平衡点，AUC 达到 0.9435，AUPR 达到 0.9612。然而，当维度进一步扩展至 256 乃至 512 时，模型性能并未继续提升，反而出现了下滑，512 维度下的 AUC 已跌至 0.9312。

同时，随着维度从 256 增加到 512，实验结果的标准差呈扩大趋势，这表明过大的特征维度破坏了模型训练的稳定性，使其极易陷入局部最优解或产生震荡。因此，本研究最终选取 128 作为最佳维度设置。

表 4-5 DrugBank 数据集上不同隐藏层特征维度 d_{model} 对模型性能的影响

隐藏层维度	AUC	AUPR	Accuracy	Precision	Recall
32	0.9254 $\pm$ 0.005	0.9382 $\pm$ 0.006	0.8584 $\pm$ 0.008	0.8523 $\pm$ 0.007	0.8756 $\pm$ 0.006
64	0.9368 $\pm$ 0.004	0.9515 $\pm$ 0.005	0.8692 $\pm$ 0.007	0.8658 $\pm$ 0.006	0.8884 $\pm$ 0.011
128	0.9435$\pm$0.005	0.9612$\pm$0.002	0.8797$\pm$0.009	0.8790$\pm$0.008	0.9085$\pm$0.012
256	0.9397 $\pm$ 0.008	0.9566 $\pm$ 0.009	0.8714 $\pm$ 0.010	0.8680 $\pm$ 0.012	0.9011 $\pm$ 0.015
512	0.9312 $\pm$ 0.012	0.9480 $\pm$ 0.015	0.8623 $\pm$ 0.014	0.8559 $\pm$ 0.015	0.8958 $\pm$ 0.021





图 4-5 隐藏层特征维度 d_{model} 对模型性能的影响

图编码层数 L 决定节点在分子图上进行消息传递的跳数，直接影响模型对长程原子依赖的捕捉能力和最终预测性能，实验结果如表 4-6 及图 4-6 所示。当 $L = 1$ 时，由于感受野受限，模型漏掉了许多长程依赖的潜在正样本，Recall 仅为 0.8825。随着层数增加至 $L = 2$ ，模型性能达到峰值。值得注意的是，当层数继续增加至 3 层及以上时，模型性能出现震荡下行趋势。与维度参数不同的是，层数过深主要引发了图神经网络的过平滑效应。在 $L = 5$ 时 Precision 的下降幅度明显大于 Recall，这表明深层网络导致不同节点的特征表示趋于同质化，严重丧失了区分细微结构差异的判别能力。基于上述分析，本研究选取 $L = 2$ 作为模型的默认层数设置。

表 4-6 DrugBank 数据集上不同图 Transformer 编码层数 L 对模型性能的影响

编码层数	AUC	AUPR	Accuracy	Precision	Recall
1	0.9315 $\pm$ 0.006	0.9452 $\pm$ 0.004	0.8617 $\pm$ 0.011	0.8649 $\pm$ 0.006	0.8825 $\pm$ 0.014
2	0.9435$\pm$0.005	0.9612$\pm$0.002	0.8797$\pm$0.009	0.8790$\pm$0.008	0.9085$\pm$0.012
3	0.9418 $\pm$ 0.004	0.9582 $\pm$ 0.004	0.8762 $\pm$ 0.010	0.8745 $\pm$ 0.005	0.9048 $\pm$ 0.013
4	0.9385 $\pm$ 0.009	0.9538 $\pm$ 0.003	0.8715 $\pm$ 0.012	0.8682 $\pm$ 0.007	0.9017 $\pm$ 0.021
5	0.9342 $\pm$ 0.010	0.9488 $\pm$ 0.008	0.8657 $\pm$ 0.015	0.8563 $\pm$ 0.014	0.8985 $\pm$ 0.018

图 4-6 图 Transformer 编码层数 L 对模型性能的影响

4.3.5 可视化分析

为了进一步验证 BAGF 模块在物理上具有解释性，本文用典型的药物分子阿司匹林 (Aspirin, SMILES: CC(=O)OC1=CC=CC=C1C(=O)O) 做注意力可视化实验。

在文本引导图的过程中，BAGF 模块利用文本语义引导模型关注分子的核心药效团。如图 4-7 左侧所示，注意力高权重区域准确集中在阿司匹林的乙酰基 (-COCH₃) 和羧基 (-COOH) 附近。从药理学角度看，阿司匹林的乙酰基能使靶点蛋白发生共价修饰，而羧基则在氢键形成中起关键作用。模型捕捉到这些活性位点，证明其能够从 SMILES 序列中识别出药效片段，并将其精准映射到分子图的物理坐标上，克服了传统图神经网络在全局池化时容易丢失局部细节的问题。

在图引导文本阶段，模型则利用图拓扑信息修正了 SMILES 序列的线性偏差。如图 4-7 右侧所示，SMILES 中的苯环闭环标记 1 在序列中物理距离较远，但图结构引导模型将注

注意力集中在 OC1=CC=CC=C1 这一环状语义片段上。这种双向引导机制实现了分子图与文本描述的深度对齐，证明 GTCM-DTI 模型能够学习到结构与语义间的深层映射。实验结果表明，BAGF 模块可以对分子微观结构和文本语义进行精确的双向对齐，证明了该融合机制可以很好地捕捉到药物分子的核心生化属性。




图 4-7 阿司匹林跨模态注意力可视化图

4.3.6 案例研究

为了进一步验证 GTCM-DTI 模型的可靠性与实际应用潜力，本节针对肾上腺素能受体家族进行了一项 DTI 预测案例研究。肾上腺素能受体是去甲肾上腺素和肾上腺素的主要作用靶点，多种临床药物均可通过与其结合发挥药效。根据对神经递质的不同反应，它们主要被划分为 Alpha 受体和 Beta 受体。具体而言，Alpha 受体包含两个亚型，每个亚型又分为三个亚类，共计 6 个靶点蛋白^[71]；Beta 受体则包含三个亚型^[72]。

本案例研究在 DrugBank 数据集上开展，旨在对比 GTCM-DTI 与 MGCL-DTI 模型在识别有效药物分子方面的能力。在实验设置上，我们将 DrugBank 中与上述 9 种受体存在已知相互作用的药物分子按 4:1 的比例划分为训练集和测试集。模型训练完成后，为了模拟真实的虚拟筛选场景，我们将测试集中的已知阳性药物混入包含大量未知相互作用的候选药物池中。随后计算该候选池中所有药物分子与这 9 种肾上腺素能受体发生相互作用的概率，并根据预测得分进行降序排列。

图 4-8 以雷达图的形式，直观地展示了 GTCM-DTI 与 MGCL-DTI 在 9 种肾上腺素能受体预测结果中，排名前 20 的候选预测中已知药物命中数量的对比。从图中可以看出，GTCM-DTI 模型在识别真实药物方面表现出更强的识别实力。在绝大部分受体的预测中，GTCM-DTI 成功命中的已知药物数量均多于或等于 MGCL-DTI 模型。特别是在 Alpha-1B

和 Alpha-2B 受体上，GTCM-DTI 展现了明显的性能优势。这一结果证明，通过引入图 Transformer 进行微观结构的精细化表征，并结合 BAGF 机制，GTCM-DTI 能够更精准地捕获决定药物与靶点结合的关键生化属性。这也进一步凸显了该模型在辅助相关疾病药物研发与虚拟筛选中的广阔应用前景。




图 4-8 两种模型在肾上腺素能受体前 20 个候选分子中的已知药物命中数量对比

4.4 本章小结

本章提出了基于图 Transformer 与文本语义融合的药物-靶点相互作用预测模型 GTCM-DTI，旨在提升模型对复杂药物分子微观结构与多源语义信息的捕捉能力。首先，本章概述了 GTCM-DTI 模型的研究背景与设计方案，详细描述了模型的整体架构，包括基于图 Transformer 的药物结构编码器、文本语义提取分支、基于蛋白质序列的双向 Mamba 编码器以及跨模态双向自适应引导融合模块的设计与实现。接着，本章系统地设计了实验方案，包括数据集的选取、评价指标的确定、实验环境的设置以及主流基线模型的对比说明。在实验结果分析部分，通过对比实验验证了 GTCM-DTI 相较于前述 MGCL-DTI 模型及其他 SOTA 方法的性能优势，特别是在处理 DrugBank 等复杂异质图数据时展现出更强的准确性，且配对 t 检验结果进一步确证了该模型及其核心机制对性能改善的统计学显著性。同时，通过消融实验证实了文本语义信息和 BAGF 融合机制在弥补结构缺失、提升模型判别力方面的关键作用。此外，本章还通过参数敏感性实验，探讨了隐藏层特征维度与编码层数对模型性能的影响，确立了最优实验配置。最后，结合可视化分析与肾上腺素能受体案例，验证了模型的可解释性与实际应用价值。实验结果表明，GTCM-DTI 在面对新

颖药物分子骨架时具有更强的泛化能力和鲁棒性。本章的研究为解决 DTI 预测中的语义鸿沟与结构表征不精细问题提供了新的思路，并进一步完善了多模态特征利用的理论框架。

5 总结与展望

5.1 全文总结

药物-靶点相互作用预测是新药研发与药物重定位的关键环节。针对现有计算模型在微观特征提取不精细、超长序列建模效率低以及多模态语义信息利用不充分等问题，本文深入研究了图神经网络、状态空间模型与序列表示学习技术在生物信息学中的应用，提出了两种递进式的 DTI 预测模型。本文的主要工作与创新点总结如下：

(1) 提出了基于 Mamba 增强与图对比学习的 DTI 预测模型 MGCL-DTI。针对传统 Transformer 在处理长蛋白质序列时存在的计算量过大问题，该模型引入了 Mamba 架构，分别构建了图 Mamba 与双向 MambaFormer 以提取微观结构特征。同时，为解决生物数据稀疏的问题，本文构建了相似性网络并引入图对比学习机制，从宏观层面捕捉了药物与靶点之间的全局关联，同时保持了较低的计算复杂度。由于该模型在长序列建模效率与全局关系挖掘上的优势，其更适用于大规模药物库的高通量初筛场景，能够快速锁定具有潜力的候选药物分子。

(2) 提出了基于图 Transformer 与文本语义融合的 DTI 预测模型 GTCM-DTI。为解决传统图神经网络容易丢失长距离节点信息的问题，该模型通过整合了节点中心性、空间位置和边特征编码的图 Transformer 刻画药物分子的几何形态。更重要的是，为填补结构特征与序列文本之间的语义鸿沟，本文设计了跨模态双向自适应引导融合模块 BAGF，实现了分子图与 SMILES 文本语义的融合与对齐。凭借对药物分子微观结构的表征及跨模态信息的深度对齐，该模型更适合用于先导化合物的精准优化阶段，能够辅助研究人员识别细微的官能团差异并提升预测精度。

(3) 在多个公开数据集上进行了全面的实验验证。本文在 C.elegans、Human 和 DrugBank 三个不同规模的基准数据集上对所提出的模型进行了系统评估。通过与现有主流基线模型的对比实验，证明了 MGCL-DTI 在长序列任务中的高效性，以及 GTCM-DTI 在复杂结构对齐中的高精度优势。此外，本文还设计了详细的消融实验与参数分析，充分验证了各核心模块的有效性，并确立了模型的最佳配置。配对 t 检验结果显示，本文提出的两种模型相比于主流基线方法在性能上均取得了统计学意义上的显著提升。最后，本文通过特征聚类与注意力权重的可视化，解释了模型对齐多模态特征的内部原理；结合苯丙胺与肾上腺素能受体的实际案例，进一步证明了本文模型在真实新药发现与虚拟筛选中的应用潜力。

5.2 研究展望

虽然本文提出的 MGCL-DTI 与 GTCM-DTI 模型在药物-靶点相互作用预测任务中取得了较好的效果，但真实的生物体环境极其复杂，目前的计算模型仍有很大的进步空间。未来的研究可以从以下几个方面展开：

(1) 引入药物和靶点的三维空间结构。现有的研究主要依赖药物的平面二维图和蛋白质的一维线性序列进行预测。在 AlphaFold3 等高精度结构预测技术广泛使用之后，药物和蛋白质的结合本质上是三维空间中复杂的诱导契合过程。未来研究可尝试引入蛋白质的三维折叠表面电荷分布以及药物分子的手性立体构象数据，利用几何深度学习更真实地模拟药物分子与蛋白质靶点间特异性结合的物理过程，从而进一步提升模型在复杂口袋结合场景下的预测精度。

(2) 提高模型的可解释性以及生物学辅助决策能力。本文在第 4 章中用 BAGF 模块对阿司匹林进行了注意力可视化尝试，初步验证了结构和语义对齐的物理意义。未来的工作应该致力于开发更普适的可解释性框架，例如用外部生物医学知识库或者生物本体论 (Gene Ontology) 信息来给模型提供先验知识约束。同时，可以尝试将模型判断出的高贡献度原子或氨基酸残基与真实的蛋白质活性位点数据库进行比对，使预测结果更加透明且具备临床指导价值。

(3) 闭环实验验证和药物重定位应用。本文目前的预测结果主要依靠计算机算法以及历史公开数据集。未来实际应用中会将模型筛选出的高潜力候选药物，特别是将新药预测测试中表现优异的分子送到实验室进行湿实验验证，用表面等离子共振等生化实验检测亲和力和力。依靠干湿实验相结合的闭环迭代，持续改进模型对于全新药效团的泛化能力，从而达成计算机辅助预测同生物化学实验的深度整合。

参考文献

- [1] Vamathevan J, Clark D, Czodrowski P, et al. Applications of machine learning in drug discovery and development[J]. *Nature Reviews Drug Discovery*, 2019, 18(6): 463-477.
- [2] Schlender M, Hernandez-Villafuerte K, Cheng C Y, et al. How much does it cost to research and develop a new drug? A systematic review and assessment[J]. *Pharmacoeconomics*, 2021, 39(11): 1243-1269.
- [3] Schirle M, Jenkins J L. Identifying compound efficacy targets in phenotypic drug discovery[J]. *Drug Discovery Today*, 2016, 21(1): 82-89.
- [4] Wong C H, Siah K W, Lo A W. Estimation of clinical trial success rates and related parameters[J]. *Biostatistics*, 2019, 20(2): 273-286.
- [5] Wishart D S, Feunang Y D, Guo A C, et al. DrugBank 5.0: a major update for the DrugBank database for 2018[J]. *Nucleic Acids Research*, 2018, 46(D1): D1074-D1082.
- [6] Öztürk H, Özgür A, Ozkirimli E. DeepDTA: deep drug-target binding affinity prediction[J]. *Bioinformatics*, 2018, 34(17): i821-i829.
- [7] 朱晓飞. 基于注意力感知和模态融合的药物-靶点相互作用预测方法 [J]. 太原理工大学学报, 2024.
- [8] 饶晓洁, 张通, 孟献兵, 等. 基于多层注意力和消息传递网络的药物相互作用预测方法 [J]. 自动化学报, 2023, 49(12): 2507-2519.
- [9] Debnath K, Rana P, Ghosh P. A survey on deep learning for drug-target binding prediction: models, benchmarks, evaluation, and case studies[J]. *Briefings in Bioinformatics*, 2025, 26(5): bbaf491.
- [10] Bagherian M, Sabeti E, Wang K, et al. Machine learning approaches and databases for prediction of drug-target interaction: a survey paper[J]. *Briefings in Bioinformatics*, 2021, 22(1): 247-269.
- [11] Ezzat A, Wu M, Li X L, et al. Computational prediction of drug-target interactions using chemogenomic approaches: an empirical survey[J]. *Briefings in Bioinformatics*, 2019, 20(4): 1337-1357.
- [12] Lee I, Keum J, Nam H. DeepConv-DTI: Prediction of drug-target interactions via deep learning with convolution on protein sequences[J]. *PLoS Computational Biology*, 2019, 15(6): e1007129.
- [13] Karimi M, Wu D, Wang Z, et al. DeepAffinity: interpretable deep learning of compound-protein affinity through unified recurrent and convolutional networks[J]. *Bioinformatics*, 2019, 35(18): 3329-3338.
- [14] Huang K, Xiao C, Glass L M, et al. MolTrans: Molecular Interaction Transformer for drug-target interaction prediction[J]. *Bioinformatics*, 2021, 37(6): 830-836.
- [15] Nguyen T, Le H, Quinn T P, et al. GraphDTA: predicting drug-target binding affinity with graph neural networks[J]. *Bioinformatics*, 2021, 37(8): 1140-1147.

- [16] Luo Y, Zhao X, Zhou J, et al. A network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information[J]. *Nature Communications*, 2017, 8(1): 573.
- [17] An Q, Yu L. A heterogeneous network embedding framework for predicting similarity-based drug-target interactions[J]. *Briefings in Bioinformatics*, 2021, 22(6): bbab275.
- [18] You Y, Chen T, Sui Y, et al. Graph contrastive learning with augmentations[C]//*Advances in Neural Information Processing Systems*. 2020, 33: 5812-5823.
- [19] Kong D, Jin X, Xie M, et al. A heterogeneous ranking contrastive learning method for drug-target interaction prediction[C]//*2023 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*. IEEE, 2023: 237-240.
- [20] Li Y, Qiao G, Gao X, et al. Supervised graph co-contrastive learning for drug-target interaction prediction[J]. *Bioinformatics*, 2022, 38(10): 2847-2854.
- [21] Zhu Y, Xu Y, Yu F, et al. Graph contrastive learning with adaptive augmentation[C]//*Proceedings of the Web Conference 2021*. 2021: 2069-2080.
- [22] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. *arXiv preprint arXiv:2312.00752*, 2023.
- [23] Lou X, Cai J, Liu Q, et al. MambaTransDTA: A hybrid Mamba-Transformer architecture for accurate drug-target binding affinity prediction[J]. *Journal of Chemical Information and Modeling*, 2025, 66(1): 259-270.
- [24] Ying C, Cai T, Luo S, et al. Do transformers really perform badly for graph representation?[J]. *Advances in Neural Information Processing Systems*, 2021, 34: 28877-28888.
- [25] Yang J, Ren F. Drug-target affinity prediction based on cross-modal fusion of text and graph[J]. *Applied Sciences*, 2025, 15(6): 2901.
- [26] Su Y, Hu Z, Wang F, et al. AMGDTI: drug-target interaction prediction based on adaptive meta-graph learning in heterogeneous network[J]. *Briefings in Bioinformatics*, 2024, 25(1): bbad474.
- [27] Cao Z, Xie J, Xu J, et al. Cross-modal interaction-aware progressive fusion network for drug - target interaction prediction[J]. *Journal of Chemical Information and Modeling*, 2025, 65(19): 10713-10726.
- [28] Chen Q, Nie G, Li X, et al. BioFusionDTI: assimilating graph and sequence modalities for generalizable drug-target interaction prediction[J]. *Journal of Chemical Information and Modeling*, 2025, 65(24): 13187-13202.

- [29] Jumper J, Evans R, Pritzel A, et al. Highly accurate protein structure prediction with AlphaFold[J]. *Nature*, 2021, 596(7873): 583-589.
- [30] Abramson J, Adler J, Dunger J, et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3[J]. *Nature*, 2024, 630(8016): 493-500.
- [31] Krasoulis A, Antonopoulos N, Pitsikalis V, et al. DENVIS: scalable and high-throughput virtual screening using graph neural networks with atomic and surface protein pocket features[J]. *Journal of Chemical Information and Modeling*, 2022, 62(19): 4642-4659.
- [32] Fang Z, Ran H, Zhang Y, et al. AlphaFold 3: an unprecedented opportunity for fundamental research and drug development[J]. *Precision Clinical Medicine*, 2025, 8(3): pbaf015.
- [33] Yu Q, Zhou C, Jiang J, et al. GS-DTI: a graph-structure-aware framework leveraging large language models for drug-target interaction prediction[J]. *Bioinformatics*, 2025, 41(8): btaf445.
- [34] Weininger D. SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules[J]. *Journal of Chemical Information and Computer Sciences*, 1988, 28(1): 31-36.
- [35] Gilmer J, Schoenholz S S, Riley P F, et al. Neural message passing for quantum chemistry[C]//International Conference on Machine Learning. PMLR, 2017: 1263-1272.
- [36] Rong Y, Bian Y, Xu T, et al. Self-supervised graph transformer on large-scale molecular data[J]. *Advances in Neural Information Processing Systems*, 2020, 33: 12559-12571.
- [37] Alley E C, Khimulya G, Biswas S, et al. Unified rational protein engineering with sequence-based deep representation learning[J]. *Nature Methods*, 2019, 16(12): 1315-1322.
- [38] Anfinsen C B. Principles that govern the folding of protein chains[J]. *Science*, 1973, 181(4096): 223-230.
- [39] Wang S, Sun S, Li Z, et al. Accurate de novo prediction of protein contact map by ultra-deep learning model[J]. *PLoS Computational Biology*, 2017, 13(1): e1005324.
- [40] Hochreiter S, Schmidhuber J. Long short-term memory[J]. *Neural Computation*, 1997, 9(8): 1735-1780.
- [41] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. *Advances in Neural Information Processing Systems*, 2017, 30.
- [42] Tay Y, Dehghani M, Bahri D, et al. Efficient transformers: A survey[J]. *ACM Computing Surveys*, 2022, 55(6): 1-28.
- [43] Gu A, Goel K, Ré C. Efficiently modeling long sequences with structured state spaces[J]. *arXiv preprint arXiv:2111.00396*, 2021.
- [44] Gu A, Dao T, Ermon S, et al. Hippo: Recurrent memory with optimal polynomial

- projections[C]//Advances in Neural Information Processing Systems. 2020, 33: 1474-1487.
- [45] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[C]//International Conference on Learning Representations. 2017.
- [46] Li Q, Han Z, Wu X M. Deeper insights into graph convolutional networks for semi-supervised learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1).
- [47] Dwivedi V P, Bresson X. A generalization of transformer networks to graphs[J]. arXiv preprint arXiv:2012.09699, 2020.
- [48] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [49] Xu J, Sun X, Zhang Z, et al. Understanding and improving layer normalization[C]//Advances in Neural Information Processing Systems. 2019, 32: 164-173.
- [50] Velickovic P, Fedus W, Hamilton W L, et al. Deep graph infomax[C]//International Conference on Learning Representations. 2019.
- [51] Oord A, Li Y, Vinyals O. Representation learning with contrastive predictive coding[J]. arXiv preprint arXiv:1807.03748, 2018.
- [52] Wang T, Isola P. Understanding contrastive representation learning through alignment and uniformity on the hypersphere[C]//International Conference on Machine Learning. PMLR, 2020: 9929-9939.
- [53] Tsai Y H, Bai S, Liang P P, et al. Multimodal transformer for unaligned multimodal language sequences[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019: 6558-6569.
- [54] Oliver S. Guilt-by-Association Goes Global[J]. Nature, 2000, 403(6770): 601-602.
- [55] Kingma D P, Adam B A J. A method for stochastic optimization[C]//International Conference on Learning Representations. 2015, 5(6).
- [56] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. The Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [57] Fawcett T. An introduction to ROC analysis[J]. Pattern Recognition Letters, 2006, 27(8): 861-874.
- [58] Davis J, Goadrich M. The relationship between Precision-Recall and ROC curves[C]//Proceedings of the 23rd international conference on Machine learning. 2006: 233-240.
- [59] Powers D M W. Evaluation: from precision, recall and F-measure to ROC, informedness, markedness & correlation[J]. arXiv preprint arXiv:2010.16061, 2020.

- [60] Tsubaki M, Tomii K, Sese J. Compound-protein interaction prediction with end-to-end learning of neural networks for graphs and sequences[J]. *Bioinformatics*, 2019, 35(2): 309-318.
- [61] Qian Y, Li X, Wu J, et al. MCL-DTI: using drug multimodal information and bi-directional cross-attention learning method for predicting drug-target interaction[J]. *BMC Bioinformatics*, 2023, 24(1): 323.
- [62] Zhao Q, Zhao H, Zheng K, et al. HyperAttentionDTI: improving drug-protein interaction prediction by sequence-based deep learning with attention mechanism[J]. *Bioinformatics*, 2022, 38(3): 655-662.
- [63] Zhao Q, Duan G, Zhao H, et al. GIFDTI: prediction of drug-target interactions based on global molecular and intermolecular interaction representation learning[J]. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 2023, 20(3): 1943-1952.
- [64] Cheng Z, Yan C, Wu F X, et al. Drug-target interaction prediction using multi-head self-attention and graph attention network[J]. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 2021, 19(4): 2208-2218.
- [65] Bian J, Zhang X, Zhang X, et al. MCANet: shared-weight-based multiheadcrossattention network for drug-target interaction prediction[J]. *Briefings in Bioinformatics*, 2023, 24(2): bbad082.
- [66] Peng L, Mao J, Huang G, et al. DO-GMA: an end-to-end drug-target interaction identification framework with a depthwise overparameterized convolutional network and the gated multihead attention mechanism[J]. *Journal of Chemical Information and Modeling*, 2025, 65(3): 1318-1337.
- [67] Wei Z, Wang Z, Tang C. Dynamic prediction of drug-target interactions via cross-modal feature mapping with learnable association information[J]. *Journal of Chemical Information and Modeling*, 2025, 65(8): 3915-3927.
- [68] Yin Z, Chen Y, Hao Y, et al. FOTF-CPI: a compound-protein interaction prediction transformer based on the fusion of optimal transport fragments[J]. *Iscience*, 2024, 27(1).
- [69] Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[C]//*Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*. 2014: 1724-1734.
- [70] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. *arXiv preprint arXiv:1409.0473*, 2014.
- [71] Taylor B N, Cassagnol M. Alpha-adrenergic receptors[M]//*StatPearls [Internet]*. StatPearls Publishing, 2023.

[72] Barnes P J. Beta-adrenergic receptors and their regulation[J]. American Journal of Respiratory and Critical Care Medicine, 1995, 152(3): 838-860.

致谢

春华秋实，岁月不居。伴随着这篇论文的最终定稿，我在地大的研究生求学生涯也即将画上句号。回首这几年的点点滴滴，有焦虑、喜悦，更有无数师长、同门与亲友的鼎力支持与温暖陪伴。借此毕业之际，谨向所有在我成长道路上给予帮助的人表达最诚挚的谢意。

首先，我要向我的导师牛云云教授致以最崇高的敬意和最深切的感谢。从我踏入师门起，牛老师便以渊博的学识、严谨的治学态度和宽泛的学术视野悉心指导我的学业。在我推进课题与其他科研项目时，老师严格的把关与反馈让我深刻认识到了学术研究的严密性。牛老师不仅传授了我解决具体技术问题方法，更教会了我求真务实、精益求精的科研精神，这份恩情我将铭记于心。

同时，我要感谢同实验室的师兄弟及同窗好朋友们，是你们的陪伴，化解了科研过程中的枯燥与迷茫。我们一起分享的喜悦，也一起分担苦恼。这份纯粹的同窗情谊，是我研究生阶段最宝贵的财富。

我还要特别感谢我的父母和家人。二十多年来，你们始终是最坚实的后盾。无论我面临多大的学业压力，你们总是给予我无条件的理解、包容与物质上的支持，让我能够心无旁骛地坐在电脑前追逐自己的目标。你们的养育之恩与辛勤付出，我唯有用更加优异的成绩和脚踏实地的行动来回报。

求学之途虽充满挑战，但因有你们同行而熠熠生辉。行文至此，百感交集，愿师长身体健康、桃李芬芳，愿同窗万事胜意、前程似锦！

附录

一、 个人简介

付国宁，男，2001 年 12 月 23 日出生，黑龙江省哈尔滨市人，2023 年 6 月取得东北农业大学电气与信息学院软件工程学士学位。2023 年 9 月至 2026 年 6 月于中国地质大学（北京）人工智能学院攻读计算机技术专业全日制工程硕士学位，专注于计算机辅助药物发现与人工智能方向的研究。目前，已经与江苏银行总行签订三方协议，即将入职。

二、 硕士期间主要研究成果

1. 软件著作权：药物分子与靶标蛋白亲和力量化评估平台 V1.0，登记号：2025SR1537551。