

分类号

密级

中国地质大学（北京）
专业硕士学位论文

基于渐进式分解的交通流预测研究

研究生杜松芝学号2104230041

专业学位类别电子信息专业计算机技术

校内导师牛云云产业导师张永虹

学习方式全日制

2026年4月

A Dissertation Submitted to
China University of Geosciences for Master of
Professional Degree

Research on Traffic Flow Prediction Based on
Progressive Decomposition

Master Candidate: SongZhi Du

Professional Degree: Electronic and Information
Engineering

Dissertation Supervisor: Prof.YunYun Niu

Associate Supervisor: YongHong Zhang

China University of Geosciences (Beijing)

声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国地质大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签名：_____日期：_____

关于论文使用授权的说明

本人完全了解中国地质大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。延期公开的论文在到期公开后应遵守此规定。

签名：_____导师签名：_____日期：_____

摘要

随着城市化进程加速，交通问题日益成为影响城市发展和居民生活质量的重要因素。当前在交通流预测领域，图神经网络与 Transformer 是两大热门架构，现有的研究对于时空依赖的捕捉还不够充足。针对现有方法的不足，本文提出两种时空神经网络架构，主要工作与创新如下：

(1) 现有方法在模型输入阶段将时间、空间嵌入与交通流数据进行静态拼接，导致时空特征耦合不足且易受冗余信息干扰。针对该问题，本文提出一种基于自适应时空融合的预测网络 (ASTNet)。该模型设计了分层次的时空信息引入机制。具体而言，模型在每一层网络中均设置时空融合门控单元，根据当前层级的特征表达动态调整时间信息与空间信息的融合权重；在每次融合操作后，通过专属的特征优化学习模块对融合后的特征进行自适应提炼与强化，剔除冗余干扰信息，使模型能够自主感知不同交通场景下数据的实际分布规律。

(2) 交通流数据固有的多尺度特性，包含长期趋势、周期性波动与短期突发事件等多重模式的交织，使得直接对原始数据进行建模容易引发过拟合与预测偏差。现有基于离散小波变换等方法的静态分解技术属于离线预处理手段，仅依赖历史数据确定分解参数，无法适应实时输入数据的动态分布变化。针对该问题，本文提出一种基于多通道渐进式分解的交通流预测模型 (MPDNet)。该模型以分解模块为核心，采用动态递进的分解逻辑，将输入交通数据逐步解耦为长期趋势分量与短期波动事件分量。在分量建模阶段，模型设计双通道并行架构实现差异化时空特征提取：趋势分量通道利用多层感知器对具备长期稳定性的趋势分量进行建模，精准捕获其缓慢演化的时间规律；波动事件分量通道则采用时空编码器，针对具有高度不确定性的波动分量，高效捕捉其短期波动特征与动态空间关联。最终，模型对双通道输出的这些特征进行融合，并通过输出层生成交通流预测。

本文在四个真实的城市交通基准数据集 METRLA、PEMS04、PEMS07 和 PEMS08 上进行了广泛的实验评估。实验结果表明，ASTNet 在所有数据集上均取得最佳性能；进一步引入渐进式分解策略的 MPDNet，在 MAE、RMSE 和 MAPE 三项指标上均优于现有最优基线模型，充分验证了所提方法在交通流预测任务中的有效性。

关键词：交通流预测，自适应时空融合，渐进式分解，注意力机制

Abstract

As urbanization accelerates, traffic problems are increasingly becoming a critical factor affecting urban development and residents' quality of life. Currently, graph neural networks and Transformers are two popular architectures in the field of traffic flow prediction, yet existing research still inadequately captures spatiotemporal dependencies. To address the limitations of existing methods, this thesis proposes two spatiotemporal neural network architectures. The main contributions and innovations are as follows:

(1) Existing methods perform static concatenation of temporal embeddings, spatial embeddings, and raw traffic flow data at the model input stage, resulting in insufficient spatiotemporal feature coupling and vulnerability to redundant information interference. To address this problem, this thesis proposes an Adaptive Spatiotemporal Fusion Network (ASTNet). This model designs a hierarchical spatiotemporal information introduction mechanism. Specifically, the model incorporates a spatiotemporal fusion gating unit in each network layer to dynamically adjust the fusion weights of temporal and spatial information based on the feature representation of the current layer. After each fusion operation, a dedicated feature optimization learning module adaptively refines and enhances the fused features, eliminating redundant interference information and enabling the model to autonomously perceive the actual distribution patterns of data under different traffic scenarios.

(2) The inherent multi-scale characteristics of traffic flow data, involving the intertwining of multiple patterns such as long-term trends, periodic fluctuations, and short-term unexpected events, make direct modeling of raw data prone to overfitting and prediction bias. Existing static decomposition techniques based on methods such as discrete wavelet transform are offline preprocessing approaches that determine decomposition parameters solely based on historical data, failing to adapt to the dynamic distribution changes of real-time input data. To address this problem, this thesis proposes a Multi-channel Progressive Decomposition Network (MPDNet) for traffic flow prediction. The model adopts a decomposition module as its core component, employing a dynamic progressive decomposition logic to gradually decouple the input traffic data into long-term trend components and short-term fluctuation event components. In the component modeling stage, the model designs a dual-channel parallel architecture for differentiated spatiotemporal feature extraction: the trend component channel utilizes a multi-layer perceptron to model the long-term stable trend component, accurately capturing its slowly evolving temporal patterns; the fluctuation event component channel employs a spatiotemporal encoder to efficiently capture short-term fluctuation characteristics and dynamic spatial correlations for the highly uncertain fluctuation component. Finally, the model fuses the features output from both channels and

generates traffic flow predictions through the output layer.

This thesis conducts extensive experimental evaluations on four real-world urban traffic benchmark datasets: METRLA, PEMS04, PEMS07, and PEMS08. Experimental results demonstrate that ASTNet achieves optimal performance on all datasets. Furthermore, MPDNet, which incorporates a progressive decomposition strategy, outperforms existing state-of-the-art baseline models across the three metrics of MAE, RMSE, and MAPE, fully validating the effectiveness of the proposed methods in traffic flow prediction tasks.

Key words: Traffic Flow Prediction, Adaptive Spatial-Temporal Fusion, Progressive Decomposition, Attention Mechanism

目录

摘要	1
Abstract	2
1 引言	1
1.1 研究背景和意义	1
1.2 国内外研究现状	2
1.2.1 传统的交通预测	2
1.2.2 基于图卷积的交通预测	2
1.2.3 基于 transformer 的交通预测	3
1.2.4 基于分解的序列预测	3
1.3 研究内容	4
1.4 论文组织结构	5
2 交通流预测理论与技术基础	6
2.1 交通流理论基础	6
2.1.1 交通流基本参数	6
2.1.2 交通流特性分析	6
2.1.3 交通流问题定义	8
2.1.4 交通流数据介绍	9
2.2 注意力机制	9
2.3 transformer	11
2.4 时间序列预测	12
2.5 时间序列分解	13
2.6 评价指标介绍	16
2.7 本章小结	17
3 基于自适应时空融合网络	18
3.1 引言	18
3.2 总体框架	19
3.2.1 数据嵌入模块	19
3.2.2 时间自适应融合模块	20
3.2.3 空间自适应融合模块	22

3.2.4 时间自注意力模块	22
3.2.5 空间自注意力模块	23
3.2.6 预测输出层模块	23
3.3 实验设置	23
3.3.1 数据集	23
3.3.2 实验环境和参数设置	24
3.3.3 基线模型	25
3.4 实验结果与分析	26
3.4.1 模型性能比较	26
3.4.2 消融实验	26
3.4.3 计算效率分析	30
3.4.4 超参数敏感性分析	30
3.4.5 预测可视化分析	31
3.5 本章小结	34
4 基于渐进式分解的双通道网络	35
4.1 引言	35
4.2 总体框架	35
4.2.1 分解模块	36
4.2.2 事件分量提取	37
4.2.3 趋势分量提取	39
4.2.4 输出层	39
4.3 实验设置	39
4.3.1 数据集	39
4.3.2 实验环境和参数设置	40
4.3.3 基线模型	41
4.4 实验结果与分析	42
4.4.1 模型性能比较	42
4.4.2 消融实验	45
4.4.3 计算效率分析	46
4.4.4 超参数敏感性分析	47

4.4.5 预测可视化分析	47
4.5 本章小结	49
5 总结与展望	51
5.1 研究总结	51
5.2 未来展望	51
参考文献	53
致谢	58
附录	59

1 引言

1.1 研究背景和意义

随着近年来传感技术和物联网技术的飞速发展，城市中生成并记录了大量的时空数据，这些时空数据不仅与空间位置密切相关，随着时间的推移，此类数据往往展现出显著的动态演化特性。时空数据中的这种异质性和复杂性给现有预测建模带来重大挑战。作为构建智能交通系统的基石，预测准确性直接关系到城市的管理效率提升和公共交通服务质量的改善。因此，研究交通流量预测技术具有重要的理论意义和应用价值^[1]。

首先，站在国家战略角度看，交通基础设施建设已经成为中国经济发展的关键目标。近几年来，国务院及交通运输部等主管部门相继出台了一些政策文件，如“十四五”规划中提出要在交通运输领域广泛应用大数据及人工智能等技术，以提高交通运输的智能化。交通流预测是构建智能交通系统的核心组成部分，其核心价值在于将多源数据转化为管理层面的决策辅助信息。精准的预测模型有助于实现路网管控与资源调配的精细化，从而在降低城市交通拥堵频率的同时，大幅度释放道路设施的通行潜力，确保公共交通保障资源得到最优化利用^[2]。

其次，从社会需求层面来看，对可靠交通流预测的需求日益迫切，这主要源于城市扩容与车辆密度增加所带来的负面效应。频繁的交通拥堵增加了能源消耗。在此背景下，流量预测技术充当了智能向导的角色，辅助用户在多变的交通环境中识别最优方案，从而节省时间开支^[3]。同时，这种技术赋能了现代交通治理，使管理部门能基于数据反馈进行前瞻性干预，大幅度提升了城市公共服务的治理水平。

此外，从技术的发展角度看，传统预测的一些方法通常受限于历史统计规律和线性模型框架，在捕捉交通网络中复杂的时空耦合关联时效果不好。相比之下，时空注意力机制通过引入动态权重分配，能够精准刻画流量数据中的非线性演化轨迹与瞬时波动特征^[4]，从而克服了传统方法对时空依赖建模能力的不足。通过将自注意力机制与时空数据深度结合，模型可以更精准地捕捉交通网络中长距离的空间关联与随时间演化的非线性规律，从而显著提高交通流量预测的准确性。基于时空注意力机制的交通流量预测技术研究，有利于交通预测领域的进步，还为其他领域中的复杂时空序列的建模提供了宝贵的见解。

最后，从经济角度来看，精确的交通流预测能够带来经济效益。与此同时，交通流的预测还能为物流、出租车服务和外卖等行业提供一些数据资源，帮它们提升运营效率并降低成本，使得这些行业得以快速发展。

总而言之，全面探讨交通流预测算法具有重要意义。这项技术能显著推动交通强国战略实施，为出行规划提供前瞻性指导，从而改善个人通勤体验。

1.2 国内外研究现状

交通流预测作为智能交通系统的核心支撑技术^[5]，其研究正从传统统计模型全面转为以深度学习为主导的方法，并在交通数据的复杂时空依赖性的建模上取得了显著进展。

1.2.1 传统的交通预测

交通流量预测本质上属于多维时间序列分析范畴，其核心任务在于利用历史观测值对未来路网状态进行推演^[6]。早期研究主要依赖于统计学模型，例如历史平均法（HA）^[7]和自回归积分滑动平均模型（ARIMA）^[8]等。这些方法受到线性平稳性的假设以及特征工程复杂性的限制，难以应对高维时空数据的复杂性。随后，以支持向量回归（SVR）^[9]和随机森林（RF）^[10]为代表的机器学习算法通过引入核函数与集成学习，初步具备了刻画非线性关系的能力，但在处理路网拓扑的空间约束时仍存在较大局限。

1.2.2 基于图卷积的交通预测

深度学习的兴起为捕捉深度时空依赖提供了可能^[11]。循环神经网络（RNN）^[12]和长期记忆网络（LSTM）^[13]通过引入门控机制，有效缓解了长序列训练中的梯度问题^[14]。该类模型虽擅长捕获时间维度的演化规律，但在空间相关性的表征上存在短板^[15]。为此，图神经网络（GCN）作为一种具备非欧几里得数据处理能力的深度学习方法^[16]，已成为当前交通流时空建模领域的核心研究工具。通过将离散的邻近交通观测点映射为图结构的节点，GNN 能够精准地解析并提取路网节点间交织的空间关联特征。Fang 等人提出的 STGODE^[17]通过神经常微分方程拓展了节点的空间感知边界。然而，预设邻接矩阵的限制使得多数 GNN 模型难以适应路网的动态波动。近期，Yu 等人提出的 STGCN^[18]将 GCN 和一维卷积神经网络（CNN）相结合，高效地捕获了交通流数据中复杂的空间拓扑关联与动态时间演化规律。Li 等人提出的 DCRNN^[19]将扩散卷积巧妙嵌入到循环神经网络（RNN）的门控单元中，通过模拟交通流的随机扩散过程来捕获路网的有向空间特征，从而实现对时空动态依赖的联合建模。Song 等人提出的 STSGCN^[20]通过构建时空融合图与多层图卷积模块，并结合局部时空子图，实现对时间步与空间邻域特征的关联建模，有效克服了传统模型因时空特征进行解耦处理带来的信息滞后问题。Li 等人提出的 STFGCN^[21]则通过构建时空融合图并结合多层图卷积模块，实现了对隐含时空相关性与非局部空间依赖的深度提取。这些方法有效克服了传统预测模型的局限性，并显著提高交通流预测准确率。

1.2.3 基于 transformer 的交通预测

鉴于 Transformer 架构在视觉与语言处理领域的卓越表现，其核心的注意力机制已被广泛迁移至时间序列分析任务中。Traffic Transformer^[22]通过在标准的 Transformer 架构中引入时空编码机制与多头注意力模块，实现了对交通流序列中长距离时间依赖性与周期性模型的深度挖掘，TERMCast^[23]通过解构交通序列中的邻近性、周期性与趋势性成分，实现了复杂城市路网多维度时空特征的精细化建模。为了持续突破预测精度的瓶颈，学术界对 Transformer 架构已开展大量研究与开发工作，主要集中在以下两个方面。首先，优化 transformer 框架核心组件。例如，Sparse Transformer^[24]通过引入卷积自注意力机制，在保留全局建模能力的同时显著强化了对局部上下文信息的感知，并有效降低了传统 Transformer 在处理长序列数据时的计算开销。Informer^[25]通过引入自注意力的有效查询筛选和自注意力蒸馏技术，在大幅降低计算复杂度的同时，显著增强了模型捕获长程时序依赖的能力。Pyraformer^[26]引入了基于金字塔注意力模块的分层网络架构，通过在不同尺度分辨率下构建节点间的特征路径，以极低的计算复杂度实现了对交通序列中局部密集关联与跨尺度长程依赖的同步捕捉。Crossformer^[27]通过引入跨维度自注意力机制，实现了对多变量时间序列中时间依赖与变量间关联的协同建模。其次，对 Transformer 架构进行创新性优化。例如，Scaleformer^[28]通过引入跨尺度迭代缩放，显著增强了模型对多尺度时间规律的捕捉精度；而 GBT^[29]通过构建两阶段的 Transformer 结构，将生成式建模与贝叶斯推断相结合，显著增强了模型在处理非平稳时间序列时的鲁棒性。此外，最新的线性模型挑战了传统观点，提出了新的可能性，但 TDformer^[30]表明，相较于趋势数据，基于注意力的模型在季节性数据上表现更为优越。PDFormer^[31]应用掩码机制，分别关注远距离与近距离节点的交通相似性，同时兼顾时延问题。STAEformer^[32]采用自适应嵌入，架构简洁且性能优良。然而，现有的方法在处理时空特征信息嵌入时，将时间嵌入、空间嵌入与原始交通流数据直接进行静态融合，导致时空特征信息不足且易受冗余信息干扰。

1.2.4 基于分解的序列预测

交通流数据具有典型的多变量时间序列属性，大量研究表明引入序列分解方法可显著优化多变量预测的鲁棒性。Tempo^[33]将原始观测值分解为趋势、周期及残差等核心分量，通过解构不同维度间的耦合关系，实现了对复杂交通的深度感知。STHMLP^[34]在模型中引入基于减法的残差连接，将时间模式分解为趋势周期分量与季节分量。MSDGCN^[35]通过离散傅里叶变换（DFT）将原始交通序列分解为低频、中频和高频分量。STWave^[36]通

过引入双分支小波算子，在时域和频域同步对交通序列进行多尺度解耦，并利用动态图卷积捕获不同频率分量下的空间关联。STADNN^[37]指出现有方法在分解时往往忽略了个体传感器间的动态交互，且对所有分解分量采用同质化特征提取器。为此，STADNN 引入时空感知嵌入来指导分解过程，使模型能根据具体的空间位置和时间语义，自适应地将交通序列解耦为趋势项与周期项，随后，针对趋势项的缓慢演化特性采用注意力机制捕获长程依赖，针对周期项的短期波动特性采用时序卷积网络（TCN）提取局部模式，实现了真正意义上的分量特异性建模。DSM-STWave^[38]则在经典的小波分解模型 STWave 基础上，针对其静态架构易受分布漂移影响的缺陷进行改进。该框架通过引入轻量级自适应记忆模块，使模型能够在推理阶段根据新流入的数据动态调整预测策略，有效应对实时交通环境中数据分布变化，实现了从静态分解向在线自适应分解的跨越。然而，现有基于离散小波变换等方法的静态分解技术属于离线预处理手段，仅依赖历史数据确定分解参数，无法适应实时输入数据的动态分布变化。

1.3 研究内容

为了突破交通流预测中时空特征静态融合瓶颈与多尺度复杂模式解耦难题，深入开展了交通流时空序列预测模型的构建与优化研究。主要研究内容包括以下三个方面：

（1）针对复杂模型不断发展，有效的时空数据嵌入表示却常常被忽视。现有方法通常通过简单拼接对空间嵌入与时间嵌入进行静态融合，这可能过度简化交通数据状态与时空上下文之间的复杂关联，不可避免地导致时空表示不足，进而丢失部分重要的时空信息。本文采用自适应时空融合方法捕获交通数据中的时空信息嵌入，减少了因时空特征信息直接融合所造成的信息丢失。

（2）针对交通流数据中长期稳定趋势与短期突发波动（如交通事故、恶劣天气等）交织导致的预测困难问题。现有方法如 STWave 采用离散小波变换对交通流数据进行静态分解，仅依赖历史数据确定分解参数，无法适应实时输入数据的动态分布变化。本文提出了一种渐进式分解-融合架构，模型通过渐进式方法将交通流序列解耦为稳定的趋势分量和波动的事件分量，并采用双通道网络对趋势的全局一致性与波动的局部动态性进行特征提取。

（3）为了全面评估所提模型在实际交通场景中的预测性能与鲁棒性，本文在 METRLA、PEMS04、PEMS07 和 PEMS08 四个公开的城市交通基准数据集上开展了系统的验证实验。通过与十余种主流基线模型（包括传统统计学模型、时空图神经网络及 Transformer 基线模型）进行对比，并进行消融实验、计算效率分析与时空注意力矩阵的

可视化分析，全面验证了自适应时空融合机制与渐进式分解架构在提升交通流预测精度与应对非平稳突发场景上的显著优越性。

1.4 论文组织结构

本文共分为五章，各章节内容安排如下：

第一章，引言。阐述研究背景与意义，强调高精度交通预测在缓解拥堵、优化调度中的核心价值。通过系统梳理国内外研究现状，对比传统统计、深度学习及现有时空注意力机制的进展，提出时空特征信息融合静态化、非平稳序列下动态变化问题。最后明确本文研究内容和创新点，并介绍全文组织架构。

第二章，相关理论基础。定义交通流基本参数、特性分析、问题定义和数据介绍，并明确 MAE、RMSE 等评价指标，并深入解析本文模型依托的关键技术，包括注意力机制、transformer、时间序列预测及时间序列分解原理，为后续章节的模型构建提供算法支撑。

第三章，基于自适应时空融合网络。提出自适应时空融合架构，重点详述 Mixer 算子驱动的时间和空间自适应融合模块，实现观测特征对先验信息的动态调制。

第四章，基于渐进式分解的双通道网络。针对流量序列中长期趋势与短时波动耦合的难题，提出渐进式分解机制。将原始序列渐进式解耦为趋势与波动分量，并通过双通道网络实现独立建模。

第五章，总结与展望。总结自适应时空融合机制与渐进式分解对交通预测的贡献并对未来进行展望。

2 交通流预测理论与技术基础

2.1 交通流理论基础

交通流理论基础旨在从物理和数学层面刻画车辆在道路网络中的运动规律与相互作用机理。以下将具体介绍交通流基本参数、特性、问题定义和数据。

2.1.1 交通流基本参数

交通流理论的核心在于使用一组相互关联的动力学参数，对道路系统的运行态势进行定量刻画。其中，流量、速度与密度构成了交通状态的基础维度^[39]。流量被定义为单位观测时间内穿过特定道路断面或路段的车辆总数，通常以辆每小时作为其标准度量单位。在实际交通环境中，流量的演化规律受制于车辆的聚集程度与移动效率。若定义某一瞬时下的行驶速度为 v ，车道上车辆的密度为 k ，根据交通流的基本一致性原理，则流量 q 可以表示为：

$$q = k \times v \quad (2-1)$$

在评价交通运行质量的指标体系中，流量占据着至关重要的地位，它揭示了基础设施在特定时空维度下的实际承载率。流量波动的时变特性，是实时判断道路通行状况与演化趋势的核心依据。

车速反映了车辆通过道路断面的平均通行效率，其量值大小直接关系到交通系统的运行秩序与安全红线。在交通流基本图中，速度对流量变化十分敏感，随着交通需求的增长，车速通常会逐步下降，尤其在需求峰值和拥堵蔓延阶段，这种减速效应更为剧烈。此外，车速的分布特征受限于道路物理线形、管控方案以及车辆性能，且与交通流密度的实时变化存在强耦合关联。

密度是道路占用程度的指标，通常定义为单位里程内的车辆分布密度。密度的波动会引发流量与速度的连锁反应。当空间分布趋于稠密时，车辆间的交互干涉增强，迫使平均速度下降并可能触发系统性瘫痪；而当密度处于较低水平时，则暗示交通供给存在潜在的闲置空间。

在交通流的分析中这些参数扮演着重要作用，它们可用于推导更繁杂的交通流模型，还能预测在各种交通条件下的交通流量和车速间的关系。

2.1.2 交通流特性分析

对交通流的特征分析，组成了当代交通流理论的基石，深度剖析其演化规律，对于提升路网管控效能与资源配置效率具有不可替代的价值。交通流是个体驾驶行为、路网拓扑约束及管控策略共同驱动的复杂动力学过程。通过对交通流系统化的特性分析，可

以为交通流预测、拥堵治理和交通网络设计提供理论依据^[40]。以下将讨论交通流的一些特性。

在交通流建模中，时空相互依存性尤为明显，如图 2-1 所示。交通流系统是一种时空特征耦合非常密切的模型，它的动态演变既受道路网络空间制约，也受时间的影响。在空间层面，道路网络的连通性决定了交通流传播过程中的路径，关键节点上流量的变化会沿着拓扑连接关系向周边区域逐级扩散。Vlahogianni 等人提出在城市主干道的交通流量与相邻交叉口的相关系数可达 0.78-0.92^[41]，而这种空间相关性会随着路网距离的增加呈指数形式衰减。在时间层面，交通流表现出非平稳自相关性，这意味着当前的交通状况通常与过去时间段的观测数据紧密相关。吴等人^[42] 对北京二环路的数据分析发现，交通流量在滞后 15 分钟的情况下，其自相关系数仍然保持在 0.65 以上的显著水平，并具有明显的周期性波动。时间和空间依赖性的相互作用，使得传统模型所依赖的独立同分布数据假设难以成立，因此预测模型需要捕捉空间相关性和时间演变的综合效应。




图 2-1 交通流的时空依赖性

作为典型的复杂的适应性系统，交通流系统在其演化过程中凸显出鲜明的非线性特征。在此系统中，车辆、行人及交通基础设施等各类实体通过行为交互和调整，形成了宏观的动态模式。城市道路网络中的交通流传播具有强烈的非线性，主要表现为流量状态之间的相变行为、拥堵的形成与扩散机制以及系统内部的自组织现象。例如，每当交通密度的值超过一定阈值的时候，系统就会迅速的从畅通状态转变为拥堵状态，这种突发性转变是传统线性方法难以有效描述的。此外，即使是微小的扰动，也可能在非线性作用下引发大规模的拥堵蔓延，这也充分凸显了该系统的敏感性。

从以上特征可以看出，交通流系统的演变不仅受局部运行规则约束，还受整体交互作用和反馈机制的调节，从而在整体上呈现出一个复杂、非线性的发展过程。

2.1.3 交通流问题定义

交通数据分析与预测是实现智能交通系统（ITS）高效运行的关键技术，在缓解拥堵、优化资源配置以及提升出行效率方面具有重要作用。如图 2-2 所示，交通流预测任务遵循系统化流程：首先，获取多模态交通数据，如地铁刷卡记录、道路速度数据及共享单车使用记录等；其次，开展系统的数据分析，包括制定采集方案、按类型与来源对数据进行归类，以及提取隐含的时空特征、周期模式与随机特性；在此基础上，对交通的时空动态变化进行建模，建模需构建空间表示模块以刻画路网拓扑及监测点间的关联，构建时间表示模块以捕捉趋势、周期及长程依赖等时间规律，然后形成融合时空信息的综合表示。最后对时空信息的综合表示使用损失函数优化训练。




图 2-2 交通流预测任务

为了对基于图结构的交通流预测问题进行精准建模，首先给出形式化定义。将交通网络建模为图 $G=(V, E)$ 。其中 V 为节点集合，共 $N=|V|$ 个节点，每个节点 $V_i \in V$ 代表一个传感器监测点或路段。 E 为边集合，表示节点间的连接关系。节点间的空间依赖强度由邻接矩阵 $A \in R^{N \times N}$ 来表示。矩阵 A_{ij} 中的元素基于地理距离、网络连通性或历史数据相关性计算，无关联节点对应值设为 0。

在时间步 t ，传感器观测信号构成特征矩阵 $X_t \in R^{N \times C}$ 。其中， N 是节点总数， C 是每个节点在时刻 t 观测到的特征数量。这些随时间 t 连续记录的信号 X_t 共同构成了一个多变量的时空时间序列。基于上述定义，交通流预测任务可形式化为：给定图结构 G 以及过去 P 时间步的历史交通信号观测序列 $X(t-P+1):t$ ，目标是学习一个预测模型 $F(\cdot)$ ，用以预测未来 Q 个时间步的交通信号 $\hat{Y}_{(t+1):(t+Q)}$ 。这个过程可以通过以下映射关系表示：

$$[X_{(t-p+1):t}, G] \xrightarrow{F} \hat{Y}_{(t+1):(t+Q)} \quad (2-2)$$

其中，历史输入序列定义为：

$$X_{(t-p+1):t} = (X_{t-p+1}, X_{t-p+2}, \dots, X_t) \in R^{P \times N \times C} \quad (2-3)$$

输出的预测序列定义为：

$$\hat{Y}_{(t+1):(t+Q)} = (\hat{Y}_{(t+1)}, \hat{Y}_{(t+2)}, \dots, \hat{Y}_{(t+Q)}) \in R^{Q \times N \times C'} \quad (2-4)$$

其中，输出特征维度 C' 可能与输入特征维度 C 不同，只预测流量这个指标时 $C'=1$ ，最终目标是构建并优化模型 F ，使其能够高效捕捉和利用数据中蕴含的时间依赖性和空间依赖性，从而使得预测值 $\hat{Y}_{(t+1):(t+Q)}$ 与未来的真实观测值 $Y_{(t+1):(t+Q)}$ 之间的误差尽可能小。

2.1.4 交通流数据介绍

基于城市交通路网的时空关联特性，研究采用图结构建模方法对交通序列进行形式化表征^[43]。具体而言，物理路网被抽象为图模型 $G = (V, E, A)$ ，其节点集 V 对应 N 个传感器监测点，边集 E 表示空间关联，邻接矩阵 A 刻画节点间的空间联通性。在时间维度上， X_t 为 t 时刻全路网节点的多特征观测矩阵，包含流量、平均速率及占有率等特征。进一步， T 个时间步的交通状态演替被统一建模为高阶三维张量 $X \in R^{T \times N \times D}$ ，如图 2-3 所示，其时间轴捕捉动态演变规律，节点维度映射空间传播机制。据此，交通流预测任务可形式化为学习映射函数。




图 2-3 交通流数据

2.2 注意力机制

注意力机制的核心思想来源于人类在感知外部信息时所展现出的选择性注意能力。在面对复杂信息或长序列时，人类不会平均地处理所有信息，而是有选择地关注其中对当前任务更关键的部分^[44]。深度学习中的注意力机制正是对这一现象的模拟，它使得神经网络在处理序列或结构化数据时，能够动态地调整对不同信息部分的关注程度。传统

的神经网络在处理序列输入时，往往将所有输入编码成一个固定维度的向量。这种方法在短序列上表现尚可，但在面对长序列时，容易导致关键信息的丢失。注意力机制通过引入可学习的权重，对输入序列中的每一个元素动态赋权，使得模型可以聚焦于与当前预测任务更相关的信息，从而提升表达能力与泛化性能。2014 年，注意力机制首次被引入自然语言处理任务中^[45]，最初的注意力机制可视为一种条件概率的计算，公式如下：

$$p(y_t|y_1, y_2, \dots, y_{t-1}) = g(y_{t-1}, s_t, c_t) \quad (2-5)$$

$$c_t = \sum_{i=1}^{T_x} \alpha_{t,i} h_i \quad (2-6)$$

$$\alpha_{t,i} = \frac{\exp(e_{t,i})}{\sum_{i=1}^{T_x} \exp(e_{t,i})} \quad (2-7)$$

$$e_{t,i} = a(s_{t-1}, h_i) \quad (2-8)$$

其中， y 代表输出序列， h 为编码层中各隐藏层的状态向量， s 表示解码层隐藏层的状态， c 为注意力分布。将编码层隐藏层状态以键值对的形式进行表达，即分别为 **key** 与 **value**，同时将解码层隐藏层的状态表示为 **query**，便可得到当前广泛使用的注意力机制结构图如图 2-4 所示，公式表达如下：

$$attention = \sum_{k=1}^N softmax(f(query, key)) * value_i \quad (2-9)$$

其中 $f(c)$ 为相似度计算函数，当前大多所使用的都是 Transformer 中的缩放点积注意力，即：

$$S = \frac{QK^T}{\sqrt{d_k}} \quad (2-10)$$

注意力机制可用来动态地调整各元素的重要性，从而更好地捕捉全局依赖关系和上下文信息。




图 2-4 注意力机制

2.3 transformer

Transformer 是一种用于自然语言处理和其他序列到序列任务的深度学习模型框架，它在 2017 年由 Vaswani 等人首次提出。Transformer 架构引入了自注意力机制，这是一个关键的创新，使其处理序列数据时表现出色。Transformer 的一些重要组成部分和特点如图 2-5 所示。

编码器和解码器：Transformer 通常包括一个编码器用于处理输入序列和一个解码器用于生成输出序列^[46]，这使其适用于序列到序列的任务，如机器翻译。

自注意力机制（Self-Attention）：这是 Transformer 的核心概念之一，它使模型能够同时考虑输入序列中的所有位置，而不是像循环神经网络（RNN）或卷积神经网络（CNN）一样逐步处理。自注意力机制允许模型根据输入序列中的不同部分来赋予不同的注意权重，从而更好地捕捉语义关系。

多头注意力（Multi-Head Attention）：Transformer 中的自注意力机制被扩展为多个注意力头，每个头可以学习不同的注意权重，以更好地捕捉不同类型的关系。多头注意力允许模型并行处理不同的信息子空间。

堆叠层（Stacked Layers）：Transformer 通常由多个相同的编码器和解码器层堆叠而成。这些堆叠的层有助于模型学习复杂的特征表示和语义。

位置编码（Positional Encoding）：由于 Transformer 没有内置的序列位置信息，它需要额外的位置编码来表达输入序列的位置顺序。

残差连接和层归一化（Residual Connections and Layer Normalization）：这些技术有助于减轻训练过程中的梯度消失和爆炸问题，使模型更容易训练^[47]。

为了理解数据输入顺序，Transformer 为每个输入的词嵌入添加了一个向量，这样能够更好表达输入数据之间的关系。位置编码的计算公式如下：

$$PE_{(pos,2i)} = \sin \frac{pos}{10000^{\frac{2i}{d}}} \quad (2-11)$$

$$PE_{(pos,2i+1)} = \cos \frac{pos}{10000^{\frac{2i}{d}}} \quad (2-12)$$

其中， pos 是位置索引， i 是维度索引， d 是词嵌入的维度。其向量进行了映射，保证每个词之间的距离是相等的，来保证输入的有序性。




图 2-5 transformer 架构

2.4 时间序列预测

时间序列预测主要包含单步与多步两类策略，如图 2-6 所示，实际应用中通常依据具体预测任务来选取合适的方式。

(1) 单步预测

单步预测是在已知过去 s 个时间步观测序列的前提下，只对未来下一个时刻 $t+1$ 的目标值进行预测。

$$f(y_t, y_{t-1}, \dots, y_{t-s+1}) = \hat{y}_{t+1} \quad (2-13)$$

单步预测时模型输出为单个标量，主要聚焦下一时刻预测精度，常用于短期预警、实时预测等场景。

（2）多步预测

多步预测则是依据历史观测序列，对未来连续多个时间步 $t+1$ 到 $t+H$ 的目标值进行预测，其中 H 是预测步长。

$$f(y_t, y_{t-1}, \dots, y_{t-s+1}) = [\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+H}] \quad (2-14)$$

多步预测要求模型捕获长时序依赖关系，相比单步预测，其输出维度更高，也相应提升了模型训练难度。采用直接输出多时间步结果的方式时，各步预测既可独立完成，也可仅基于原始输入进行，从而避免了单步预测中前序误差逐步传递带来的累积偏差问题。同时，多步预测的损失函数可同步优化多个时间步的输出，有利于维持预测序列整体在时序上的连续性与一致性。




图 2-6 单步和多步预测

2.5 时间序列分解

经典时间序列分解通常认为序列由趋势、季节与残差三部分构成，以此挖掘数据内在规律，如图 2-7 所示。该类方法主要分为加法模型与乘法模型^[48]，具体选用哪种模型取决于数据波动幅度与趋势的关联程度，假设原始序列为 Y_t ， T_t 、 S_t 、 R_t 分别为趋势项，季节项和残差项，则加法模型表示为：

$$Y_t = T_t + S_t + R_t \quad (2-15)$$

乘法模型为：

$$Y_t = T_t \times S_t \times R_t \quad (2-16)$$

下面以加法模型为例说明时间序列分解的具体步骤，假设原始序列 $Y_i = \{y_1, y_2, \dots, y_t\}$ ，该时间序列的周期长度为 L ，则针对 $y_i \in Y_i$ 进行时序分解的过程如下：

(1) 提取趋势成分 T_t 采用移动平均法，先选取计算窗口，通常为原始序列所对应周期 L ，之后对时间点 y_i 计算其前后共 L 个时间步的平均值（需调整窗口位置以对齐时间点）。得到 y_i 所对应的趋势成分 T_i ，计算得到所有时间点所对应趋势成分后，得到 T_t 。

$$T_i = \frac{y_{i-\frac{L}{2}} + y_{i-\frac{L}{2}+1} + \dots + y_{i+\frac{L}{2}+1}}{L} \quad (2-17)$$

(2) 在计算季节成分前，需要将趋势成分从原始序列中剥离得到 $\hat{Y}_t$ ，方式如下：

$$\hat{Y}_t = Y_t - T_t \quad (2-18)$$

得到 $\hat{Y}_t$ 后，按周期间隔计算平均季节效应，首先取得 $\hat{Y}_t$ 一个周期内每个时间步的季节子序，如第 k ($k < L$) 个季节子序为 $\hat{S}_k = \{\hat{y}_k, \hat{y}_{k+L}, \hat{y}_{k+2L}, \dots\}$ ，获得一个周期中的 L 个季节子序后，计算各季节子序的平均数 S_k 记作季节指数。其次为确保各季节指数的和为 0，需要计算季节指数的调整指数 C ， $C = \frac{\bar{S}_1 + \bar{S}_2 + \dots + \bar{S}_L}{L}$ 。最后将 S_k 减去 C ，得到季节成分 S_k ， $S_t = \{S_1, \dots, S_L\}$ 。

在趋势项与季节项成分都提取后，那么剩下的部分就是残差项。时间步 i 的残差计算如下： $R_i = \hat{Y}_i - S_k \mid \hat{y}_i \in \hat{S}_k$ ，最后得到 R_t 。经典的时序分解方法在应用中面临多重局限：其一，模型强制设定趋势、季节成分与残差之间为固定的线性组合方式，难以反映季节波动幅度随趋势变化产生的非线性联动，例如，在趋势上升阶段，节假日效应往往同步增强；其二，该方法假设季节模式具有固定的周期与幅度，无法适应季节形态的动态演化，如移动假日或突发冲击所导致的季节性结构突变；其三，模型通常忽视残差序列中可能存在的自相关和异方差特征，从而削弱了预测区间估计的可靠性。针对以上不足，学界已提出多种改进策略。STL^[49] 将传统线性平滑替换为局部加权回归方法，可对非线性趋势进行灵活拟合，同时支持季节性分量随时间动态变化，有效摆脱了经典模型对固定周期与固定波动幅度的严格限定；该方法还加入鲁棒性迭代加权策略，能够减弱异常值对趋势项与季节项估计的影响，解决了移动平均类方法在数据上存在缺失或噪声较大时易出现拟合失真的问题。Prophet^[50] 利用分段线性函数实现趋势突变点的自动识别与适配，打破了传统时序方法对趋势平稳性的依赖；模型将可自定义的节假日影响以及多尺度季节性（日、周、年度周期）作为独立回归项进行显式建模，可直接刻画外部事件与复杂周期特征；此外，该方法基于贝叶斯后验采样实现预测区间的量化估计，并支持对各时序分量的贡献度进行直观解析。为解决传统分解方法对强周期性的过度依赖问

题，研究人员进一步提出了基于时频转换的时序分解方案。与传统分解方法相比，时频分解技术借助联合时频分析手段，可动态捕捉信号中的高频突变信息与低频趋势成分，有效打破了传统方法对固定周期以及线性叠加关系的严苛假设，同时能够精准分离出信号中的非线性交互模式，尤其适用于包含瞬态事件、复杂噪声或时变频谱特性的应用场景。在时域层面，该方法可清晰呈现信号的时间动态变化特征，便于研究人员观察信号的瞬态波动的过程与波形细微特征；而在频域层面，则能够深入解析信号的频率组成结构，在挖掘信号内在周期规律与噪声分布特征方面具有显著优势。在实际应用中，通常采用傅里叶变换实现信号从时域到频域的转换，其对应的变换公式如下：

$$X(f) = \int_{-\infty}^{+\infty} x(t) e^{-\pi f t} dt \quad (2-19)$$

其中， $x(t)$ 代表时域信号， $X(f)$ 为信号的频域表达形式， f 表示频率（单位： Hz ）。常用的时频转换分解方法主要包括三类：其一为短时傅里叶变换（STFT）^[51]，该方法通过对信号进行分帧加窗处理，逐帧执行傅里叶变换操作，进而生成时频谱图；其二是小波变换（DWT）^[52]，其核心是通过对母小波函数进行缩放与平移操作，实现多尺度的时频分析；其三为变分模态分解（VMD）^[53]，该方法依托变分框架将原始信号分解为多个模态分量，每个模态分量均围绕自身中心频率呈紧凑分布状态。




图 2-7 时间序列分解

2.6 评价指标介绍

在评估预测模型所产生的结果时，通常需要综合多项指标来衡量预测输出与真实观测值之间的偏差。单一的指标往往只能反映模型性能的一个侧面，因此，本文挑选了三种在时间序列预测，特别是交通流量预测领域使用频率最高的度量方式，即平均绝对误差（MAE）^[54]、平均绝对百分比误差（MAPE）^[55]与均方根误差（RMSE）^[56]，并对其各自的特点、应用范围以及相互间的联系做具体介绍。

（1）平均绝对误差（MAE）

平均绝对误差（MAE）先计算每个样本的预测值与真实值之间误差的绝对值，再对这些绝对值进行平均，来反映预测结果在数值上偏离真实情况的平均程度。这一处理方式能够有效避免正负误差相互抵消的问题。其具体计算公式如下所示：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2-20)$$

其中， n 表示样本数， y_i 为的实际值，而 $\hat{y}_i$ 为对应的预测输出。MAE 的直观意义在于它反映了预测误差的平均大小，单位与目标变量一致，便于解释和理解。

（2）均方根误差（RMSE）

RMSE 是另一种衡量预测误差的常用标准。其计算过程是先对预测偏差进行平方（即得到均方误差），然后取平均值，最后再对结果进行开方运算。RMSE 非常适用于那些对大误差容忍度低、需要强力惩罚显著偏离的应用场景，例如在交通安全预警中，低估拥堵程度可能带来严重后果。其计算公式为：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2-21)$$

与 MAE 相比，RMSE 能在一定程度上突出极值误差的影响。通常，MAE 的值会小于或等于 RMSE。两者之间的差距越大，表明预测误差的方差越大，即模型在大多数时候表现良好，但在某些时刻会出现较大的预测失误。因此，结合 MAE 和 RMSE 可以判断模型预测的稳定性。

（3）平均绝对百分比误差（MAPE）

MAPE 进一步考察了预测误差在相对意义上的大小，并以百分比的形式展示。MAPE 便于在不同流量规模的路段或时段之间进行公平比较。其计算方式如下：

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\% \quad (2-22)$$

2.7 本章小结

本章系统梳理了论文所依托的理论知识体系与关键技术手段，为后续工作的推进奠定了必要的理论根基与实践参考。在理论层面，从交通流预测的基本问题出发，对交通流数据的表达形式及研究问题进行了清晰界定。在技术层面，深入解析了本研究所采用的核心深度学习方法，例如注意力机制。在评估层面，详细阐述了实验所涉及的评价标准。通过从理论、技术及数据三个维度的综合论述，本章构建起完整的研究逻辑框架，为后续模型构建、实验设计及结果讨论提供了有力支撑。

3 基于自适应时空融合网络

3.1 引言

近年来，随着智能交通系统的快速发展与城市路网数据的不断积累，交通流预测作为交通管控、路径规划与拥堵疏导的核心技术支撑，成为交通工程与人工智能交叉领域的研究热点。得益于深度学习在非线性特征建模与复杂数据拟合方面的突出优势，基于深度学习的交通流预测方法得到了广泛研究与落地应用，逐步取代传统的时间序列分析、卡尔曼滤波^[57]等浅层模型，成为当前主流的技术方案。现有主流研究普遍意识到，交通流数据兼具显著的时间周期性、动态波动性与空间关联性，单一维度的特征建模难以满足实际预测需求，因此多数先进模型均引入时间嵌入与空间嵌入模块，分别对交通流的时间周期规律、路网空间拓扑关联进行显性建模，有效弥补了传统模型对时空双维度特征挖掘不足的缺陷，大幅提升了交通流预测的基础精度。

尽管现有方法取得了长足进步，以 STAEformer 为代表的时空预测模型，仍存在较为明显的技术局限。这类模型大多采用静态拼接的融合策略，在模型输入阶段便将时间嵌入、空间嵌入与原始交通流数据进行一次性直接融合，时空信息的融合顺序、融合权重与作用强度均由人工预先设定，属于固定的融合模式，无法根据实时交通数据的动态变化做出灵活调整。而实际交通场景具有高度复杂性与非平稳性，交通流数据会受早晚高峰、恶劣天气、突发事件、节假日等多重因素影响^[58]，呈现出明显的动态波动与时空异质性特征^[59]，固定的融合方式无法适配不同时段、不同路段下时空信息的差异化程度，容易出现时间信息与空间信息利用不充分、关键特征耦合程度低、冗余信息干扰建模等问题，进而导致模型对复杂时空依赖关系的捕捉能力不足，限制了预测精度与泛化性能的进一步提升，难以适配大规模复杂路网下高精度交通流预测的实际应用需求。

针对上述挑战，本文提出一种自适应时空融合网络 ASTNet，旨在构建灵活且高效的时空特征融合框架。与传统的静态拼接策略不同，该机制通过动态引入时间与空间特征信息，有效克服了人工预设融合模式的缺陷。在特征融合阶段，本文设计了专属特征优化学习模块，对融合后的表征进行自适应提炼与强化。该模块能够实时感知不同交通场景下的数据分布规律，动态调节时空信息的融合权重、时机与作用强度，从而实现特征的深度耦合。这种动态化融合方式不仅能精准捕捉复杂多变的长短期时间依赖与非线性空间关联，还显著增强了模型在非平稳、强异质性交通环境下的预测精度与鲁棒性。

3.2 总体框架

ASTNet 是一种专为捕获复杂交通流时空异质性而设计的深度学习架构，核心由以下六个模块组成：（1）数据嵌入模块：原始交通流数据从低维观测空间投影至高维特征空间；时间嵌入对交通流的日周期和周周期进行建模，通过位置编码将离散的时间戳转化为连续的高维时间向量 E_t ，有效弥补了原始序列中隐性时间语义的缺失；针对城市路网非欧几里得拓扑的复杂性，采用可学习的随机初始化节点矩阵 E_s 。在模型训练过程中，通过反向传播算法动态优化节点表征，自主学习路网中潜在的邻近关系和区域集聚特性，从而捕捉空间信息。（2）时间自适应融合模块：该模块旨在解决交通流时间非平稳性导致的融合信息丢失问题。摒弃了人工预设权重的静态拼接方式，利用实时观测特征作为动态门控，自适应地调节日、周周期性时间嵌入与基础特征的耦合强度。（3）空间自适应融合模块：该模块将可学习的节点空间嵌入与基础特征进行交互建模。通过自主学习不同路段节点（如干道与支路、上游与下游）间的关联紧密程度，模块能够动态调整空间信息在整体表征中的占比。这种自适应机制使模型能灵活适配不同城市路网的物理构型，精准捕获复杂的空间关联。（4）时间自注意力模块：该模块聚焦于捕捉交通流序列中的长程时间依赖。（5）空间自注意力模块：该模块聚焦于捕捉交通流序列中的不同节点的关联强度。（6）预测输出层模块：该模块对结果进行预测并输出。具体框架如图 3-1 所示。

3.2.1 数据嵌入模块

原始交通数据 $\mathcal{X} \in \mathbb{R}^{T \times N \times C}$ 通常仅包含有限的数值信息，其中 T 为历史观测时间步， N 为路网节点总数， C 为初始输入通道数。由于原始观测值难以直接揭示交通流背后复杂的时空依赖性，设计了一个综合性的数据嵌入模块。该模块将原始交通数据从低维物理空间映射至高维特征空间，并显式地注入时空先验知识。该模块由三个核心子模块构成：时间嵌入、空间嵌入和交通特征映射。

交通流数据展现出显著的日周期和周周期特征。为精准捕捉这些多尺度的时间依赖性，引入了两个具有节点感知能力的可学习的时间嵌入矩阵。具体而言，假设交通数据每日包含 T 个时间步的观测值（例如，以 5 分钟为间隔，则 $T=288$ ）。为建模日周期内的演变模式，初始化嵌入矩阵 $E_{td} \in \mathbb{R}^{T \times N \times D_{td}}$ 。其中， D_{td} 是日周期嵌入的维度。该矩阵中的每一个元素都是可训练的参数，不仅能为每个时间步 $t(t = 1, \dots, T)$ 学习一个独特的表示，而且还可以为每个节点 $n(n = 1, \dots, N)$ 学习其个性化的日模式，从而适应不同路段（如住宅区道路与商业区道路）在一天内流量波动的差异性。同样地，为捕捉周周期内的相似性与差异性，初始化另一个嵌入矩阵 $E_{wd} \in \mathbb{R}^{7 \times T \times N \times D_{wd}}$ ，其中 D_{wd} 是周周期嵌入的

维度。空间嵌入模块旨在通过学习路网节点的固有空间属性，捕捉地理位置对交通流产生的约束。传统研究通常依赖于预定义的邻接矩阵或基于相似度度量的静态和动态图结构。然而，在大规模路网中，显式地构建和计算基于图的结构会带来 $\mathcal{O}(N^2)$ 的空间复杂度，为解决这一难题，借鉴了多维时间序列预测的最新研究思路，将路网中的每一个传感器视为一个独立的数据维度。模型不再显式依赖预定义的图结构，而是通过端到端的学习来自动发现节点间的隐含空间关联。为此，引入一个可学习的空间嵌入矩阵 $E_{sd} \in \mathbb{R}^{N \times D_{sd}}$ 。其中， D_{sd} 是空间嵌入的维度。

在获得了时间和空间的嵌入表征后，也需要将原始数据从低维观测空间投影至高维特征空间，初始化嵌入矩阵 $Y_{data} \in \mathbb{R}^{T \times N \times D_{ad}}$ 。其中， D_{ad} 是数据嵌入的维度。




图 3-1 ASTNet 框架

3.2.2 时间自适应融合模块

时间自适应融合模块 T-Mixer 旨在实现原始交通特征与时间嵌入的动态、自适应耦合。该模块改变了传统模型中固定权重、静态拼接的融合模式，在理解原始交通流数据规律的基础上，逐步融入交通流的周期性时间特征。当交通流出现突发拥堵、流量骤增骤减等强波动场景时，此时原始特征信号具有极高的信息熵，足以作为预测的主导依据。该模块会自动削弱时间嵌入的权重，防止预设的周期性规律对实时突发态势产生干扰，确保模型精准聚焦于异常路况；当交通流处于平峰、夜间等平稳运行场景时，此时原始数

据特征较为单一，波动不显著。模块将自动强化时间嵌入的引导作用，利用先验的周期性语义弥补实时特征信息的不足，从而提升预测的稳定性。

该模块输入为初始数据特征提取模块输出的纯数据特征 Y_{data} 与日、周周期的时间嵌入特征 E_{td} 和 E_{wd} 组成。在阐述模块核心操作前，本文首先定义所采用的 Mixer 组件：该组件是基于多层感知机（MLP）构建的轻量级特征变换单元。与复杂的自注意力机制或图卷积运算不同，Mixer 组件通过空间域或通道域的线性映射实现特征的高效集成，在保证特征提取深度的同时，兼顾了模型的计算效率与轻量化需求。给定输入特征 $X_{mixer} \in \mathbb{R}^{N \times d}$ ，Mixer 组件的核心计算逻辑可形式化表示：

$$Y_{mixer} = LayerNorm\left(X_{mixer} + MLP_2\left(\sigma\left(MLP_1(X_{mixer})\right)\right)\right) \quad (3-1)$$

其中， $MLP_1: \mathbb{R}^d \rightarrow \mathbb{R}^{d_{hidden}}$ 为第一层全连接变换，负责将输入特征映射到更高维的隐藏空间，以增强特征表达能力；LayerNorm 为层归一化操作，对每个样本的特征维度进行归一化处理，稳定训练过程； $\sigma(\cdot)$ 为激活函数，引入非线性表达能力，其数学定义为 $\sigma(x) = x \cdot \Phi(x)$ ，其中 $\Phi(x)$ 为标准高斯分布的累积分布函数； MLP_2 为第二层全连接变换，负责将特征从隐藏空间映射回原始维度；最后的残差连接 X_{mixer} 确保梯度有效传播，缓解深层网络的退化问题。通过上述两层 MLP 的变换与非线性激活，Mixer 组件能够对输入特征进行全局重加权、特征归一化与深度提纯，自主挖掘特征内部的关联规律，适配交通流数据的实时性建模需求。

模块将逐元素聚合与 Mixer 自适应重构整合为统一的映射过程。具体而言，首先对输入的本原表征 Y_{data} 与时间嵌入 E_{td} 和 E_{wd} 执行逐元素融合操作，然后经过 Mixer 组件，具体逻辑可形式化为：

$$F_t = Mixer_t(Mixer(Y_{data}) + (E_{td} + E_{wd})) \quad (3-2)$$

先通过加法操作将时间上下文信息 E_{td} 和 E_{wd} 注入原始数据特征 Y_{data} ，再利用 Mixer 组件的深度非线性变换对融合特征进行自适应重构与提纯。这种端到端的集成设计使得 Mixer 能够根据当前的时间上下文信息（如是否为早晚高峰、节假日或平峰时段），动态地调整特征变换的权重参数，从而实现自适应融合，即模型会针对不同时间场景，自主筛选关键时序特征、抑制冗余噪声，完成深度特征提纯。例如，在早高峰时段，模型可能放大与通勤流量相关的特征维度；而在深夜平峰时段，模型则可能抑制这些维度的响应，转而关注与背景交通流相关的模式。

综上所述，时间自适应融合模块实现了时间先验知识的高效注入与时空特征的自适应重构。该设计在保持计算架构轻量化的同时，赋予了模型敏锐的时间上下文感知能力，从根本上提升了复杂交通场景下的预测精度与泛化性能。

3.2.3 空间自适应融合模块

空间自适应融合模块 **S-Mixer** 旨在实现时序增强特征与空间嵌入的深度动态耦合，旨在克服传统模型在处理空间信息时由于固定加权和静态融合所导致的建模僵化。该模块在模型已捕获时间周期规律的基础上，能够精准适配路网中不同节点间的空间关联强度差异，从而深度挖掘交通流在复杂拓扑结构中的空间传播特性与地理依赖关系，显著提升整体时空特征的表征精度。该模块的输入包括上一级时间自适应融合模块输出的时序增强特征 F_t ，以及空间嵌入模块生成的空间嵌入向量 E_s 。其中，空间嵌入 E_s 承载了路段等级、功能区连通性及路网拓扑约束等核心地理语义与空间先验信息。为了保持模型架构的一致性并实现高效的特征交互，本模块使用了 **Mixer** 组件。通过对时序增强特征与空间嵌入向量进行逐元素融合，并利用 **Mixer** 组件生成的动态权重进行自适应重加权，模型能够自主诱导空间先验知识在不同交通态势下的作用强度。具体的数学表达如下：

$$F_{ts} = \text{Mixer}_s(F_t + E_s) \quad (3-3)$$

3.2.4 时间自注意力模块

通过时空自适应融合处理后，交通流表征已初步具备了丰富的时空语义。由于交通态势的演变往往跨越较长的时间周期，且受到历史多尺度波动的持续影响，模型仍需进一步挖掘其深层的长程时间依赖。为此，本文引入时间自注意力机制（**T-attention**）在时间维度上进行全局建模，旨在通过计算序列内不同时间步之间的交互强度，捕捉交通流中复杂的动态非线性关联。给定经过自适应融合后的时空特征张量 $F_{ts} \in \mathbb{R}^{T \times N \times d_h}$ ，其中 T 为时间步长， N 为空间节点总数， d_h 为隐层特征维度。为了提取节点自身在时间维度上的演化特性，模型通过线性变换获取查询矩阵（**Query**）、键矩阵（**Key**）、值矩阵（**Value**）：

$$Q^{(te)} = ZW_Q^{(te)}, K^{(te)} = ZW_K^{(te)}, V^{(te)} = ZW_V^{(te)} \quad (3-4)$$

其中， $W_Q^{(te)}, W_K^{(te)}, W_V^{(te)}$ 为可学习的权重参数。

随后，通过计算缩放点积注意力来衡量不同时间步之间的关联强度：

$$A^{(te)} = \text{Softmax}\left(\frac{Q^{(te)}(K^{(te)})^T}{\sqrt{d_h}}\right) \quad (3-5)$$

此处得到的注意力评分矩阵 $A^{(te)} \in \mathbb{R}^{N \times T \times T}$ 精确刻画了在不同空间节点下，各历史时刻对当前交通状态的贡献程度。通过将该评分矩阵作用于值矩阵 $V^{(te)}$ ，得到时间 Transformer 层的输出：

$$Z^{(te)} = A^{(te)} V^{(te)} \quad (3-6)$$

该过程实现了在全时间轴上的信息聚合，使得每个时间步的表征都蕴含了全局的时间上下文信息。

3.2.5 空间自注意力模块

在获取时间感知特征 $Z^{(te)}$ 后，模块进一步执行空间自注意力（S-Attention）运算，以捕获路网节点间的动态空间交互：

$$Z^{(sp)} = \text{Self-Attention}(Z^{(te)}) \quad (3-7)$$

空间自注意力遵循与时间维度相同的映射逻辑，通过计算节点间的关联权重，实现交通流在空间拓扑上的传播建模。为了增强模型的训练稳定性并缓解深层特征退化，模块在各层注意力运算后均应用了层归一化、残差连接以及多头注意力机制。

3.2.6 预测输出层模块

最终，模型利用提取的深度时空特征 $Z' \in \mathbb{R}^{T \times N \times d_h}$ ，通过全连接回归层将隐层表征映射至预测空间：

$$\hat{Y} = FC(Z') \quad (3-8)$$

其中， $\hat{Y} \in \mathbb{R}^{T' \times N \times d}$ 为模型生成的预测值， T' 为预测步长， d 为输出特征维度。该回归层将时间帧 T 与隐藏维度 d_h 进行线性组合，最终输出未来时段的路网交通状态，完成从历史感知到未来预测的完整建模流程。

3.3 实验设置

实验设置主要介绍交通流预测领域中常用的几个公开数据集，并详细说明实验环境配置、关键超参数设置，以及作为对比依据的多个基线模型。

3.3.1 数据集

为全面验证本文所提模型的泛化性能与稳健性，在四个公开的城市交通基准数据集上进行了广泛实验。这些数据集涵盖了不同的路网规模与空间拓扑结构，如表 3-1 所示。METRLA 数据集源自洛杉矶高速公路系统部署的 207 个传感器，记录了 2012 年 3 月 1 日至 6 月 30 日期间的交通流速度信息。该数据具有显著的非线性特征与时空耦合性，是评估大规模路网长期时序预测性能的典型基准。PEMS04、PEMS07、PEMS08 数据集由加

利福尼亚州运输部的交通性能监测系统（PeMS）实时采集。PeMS 系统通过分布在加州各主要都市区高速公路上的传感器，以 30 秒为基准频率进行原始数据提取，并进一步聚合合成 5 分钟间隔的统计数据。PEMS04 涵盖旧金山湾区 307 个检测点，记录了包括流量、平均速度及占有率在内的多维交通态势指标。PEMS07 规模相对较大，包含加州路网中 883 个传感器节点，数据维度丰富，对模型的计算效率与空间伸缩性提出了更高要求。PEMS08 聚焦于圣贝纳迪诺地区的 170 个观测点，常用于验证模型对区域性局部交通演化模式的捕捉能力。

表 3-1 数据集

数据集	时间跨度	节点	边	时间片
METRLA	03/2012-06/2012	207	1515	34272
PEMS04	01/2018-02/2018	307	340	16992
PEMS07	05/2017-08/2017	883	548	28224
PEMS08	07/2016-08/2016	170	295	17856

3.3.2 实验环境和参数设置

本研究的所有模型均基于 PyTorch 1.11.0 深度学习框架实现，并部署于搭载 NVIDIA GeForce RTX 3090 显卡（24 GB 显存）的计算平台完成训练过程。为保证实验对比的公平性与有效性，本研究严格遵循基线模型的核心实验配置：在数据集划分方面，METRLA 数据集按 7:1:2 的比例划分为训练集、验证集与测试集；PEMS04、PEMS07 及 PEMS08 数据集则采用 6:2:2 的比例完成数据集划分。数据预处理阶段，所有交通流量数据集均通过 Z-Score 标准化方法进行归一化处理，以消除数据量纲差异对模型训练的干扰，提升模型收敛效率与稳定性。

为全面评估模型在不同时间尺度下的预测性能，实验选取第 3、6、12 个时间步作为关键评估节点，分别对应一小时预测任务中的短时、中时与长时预测场景，并采用平均绝对误差 MAE、均方根误差 RMSE 和平均绝对百分比误差 MAPE 三项核心指标量化模型预测效果。其中，MAE 反映预测值与真实值的平均绝对偏差，RMSE 对异常值更为敏感，可衡量预测误差的离散程度，MAPE 则以百分比形式直观体现预测精度，三者结合可全面表征模型在不同时间跨度下的预测能力。

模型训练过程中，选用 Adam 优化器进行参数更新，以 MAE 作为损失函数引导模型优化方向；初始学习率设置为 0.001，批处理大小（batch size）设为 64。为平衡模型表达能力与计算复杂度，经多次对比实验验证，最终将网络层数 L 确定为 3 层，以在充分挖掘

交通数据时空特征的同时，避免过拟合与梯度消失问题，保障模型的预测精度与泛化能力。

3.3.3 基线模型

本章将与以下模型进行对比：

- (1) VAR^[60]：作为多元时间序列分析方法，可有效刻画多变量间的动态关联特性。
- (2) ARIMA^[61]：融合自回归与滑动平均机制，通过拟合序列的自相关、偏自相关结构实现预测，适合平稳及含季节性特征的时序数据。
- (3) SVR^[62]：作为支持向量机的重要分支，通过在高维空间构建最优超平面完成拟合，可处理非线性与复杂数据关系。
- (4) FC-LSTM^[63]：采用带全连接层的 LSTM 结构，提取时序数据中的长短期依赖信息。
- (5) GWN^[64]：一类时空图神经网络，通过自适应邻接矩阵与扩散图卷积挖掘图数据的潜在空间依赖，结合空洞因果卷积实现深度时空数据建模。
- (6) GMAN^[65]：是一种用于交通预测的图多注意力网络模型。该模型采用编码器-解码器架构，旨在解决交通系统中复杂的时空关系和误差传播问题。
- (7) AGCRN^[66]：使用自适应图卷积和 GRU，自动学习节点专属模式与动态空间依赖，解决传统 GCN 依赖预定义静态图、全局参数共享的局限。
- (8) DCRNN^[19]：扩散卷积循环神经网络模型，将扩散卷积运算与 GRU 结合，以建模时空关系。
- (9) MTGNN^[67]：基于图神经网络的多变量时间序列使用图学习模块计算邻接矩阵，并将其作为图卷积的输入，以捕捉变量之间隐藏的空间依赖关系。
- (10) STNorm^[68]：核心是通过时间归一化和空间归一化分离时序高频和低频、空间全局和局部信号，大幅提升预测精度。
- (11) STID^[69]：设计了一种基于序列、时间、空间编码的简单模型结构，在多维序列预测任务上运行速度快，同时效果好。
- (12) PDFormer^[31]：设计了一种交通延迟感知特征转换模块，该模型可以显式地对空间信息传播中的时间延迟进行建模。
- (13) STAEformer^[32]：设计了一种新的时空自适应嵌入，将复杂的模型设计转向更有效的表征技术。

3.4 实验结果与分析

为了更好地验证 ASTNet 模型的有效性，将其与多个基线模型开展了一系列对比实验，并对实验结果进行了详细分析。

3.4.1 模型性能比较

模型 ASTNet 与基准模型在 METRLA 数据集上的对比结果如表 3-2 所示，表 3-3 则详细列出了在 PEMS04、PEMS07 及 PEMS08 三个数据集上的预测表现。通过对实验数据的深入分析，可以得出以下结论：ARIMA、VAR 和 SVR 等传统统计学及机器学习模型的预测效果显著弱于各类基于神经网络的模型。主要原因在于这些方法难以有效捕捉交通流中的复杂非线性依赖关系，且过度依赖人工构造的特征，泛化能力受限。自适应图学习模型 MTGNN、AGCRN 和 GWNNet 的性能普遍优于采用预定义邻接矩阵的 GCN 模型 DCRNN。这一现象强调了学习节点特定模式对于提升交通流预测精度的重要性。PDFormer 引入图拉普拉斯嵌入与时间周期嵌入，并通过局部地理掩蔽与全局语义掩蔽引导注意力计算，同时额外设计了传播时延感知模块，使其在捕捉信号传播延迟方面优于 GMAN。然而，其时空嵌入方式仍依赖于预定义的图结构与固定周期编码，缺乏对动态交通模式的自适应调整能力，难以应对复杂多变的交通场景。STAEformer 则采用简单的固定时空编码，具备较高的训练与推理效率，但其嵌入方式缺乏对输入数据分布的动态响应机制。在面临突发交通事件或非平稳场景时，固定时空表征难以捕捉实时变化的时间依赖与空间关联。相比之下，ASTNet 采用的自适应时空嵌入实现了多维度的优势。其嵌入过程与模型训练端到端融合，能够根据实时输入数据的分布特征动态调整嵌入权重，充分挖掘时空维度间的深层关联。这些特性使 ASTNet 在预测精度与泛化能力上均显著优于 PDFormer、STAEformer 等对比模型。

此外，图 3-2 展示了 ASTNet 与其他基线模型在 PEMS04 和 PEMS08 数据集上每个时间步的预测结果。从图中可以看出，从第 4 个时间步开始，ASTNet 性能开始逐渐优于其他基线模型，并且这一趋势随着时间步长的增加愈加明显，这表明，在更长时的预测下，ASTNet 具有更强的预测能力。

3.4.2 消融实验

在 PEMS04 和 PEMS08 数据集上，进行了消融实验，通过逐步去除或替换模型中的不同模块，来验证 ASTNet 模型中各个组件的有效性。为此设计了如下变体：


(1) w/o T-mixer: 移除时间自适应融合模块，探讨实时观测驱动的时间先验调制机制对捕捉周期性规律的影响。

表 3-2 ASTNet 与基线模型在 METRLA 数据集上的比较


模型	15min			30min			60min		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
VAR	4.42	7.89	10.20%	5.14	9.13	12.70%	6.52	10.11	15.80%
ARIMA	3.99	8.12	9.60%	5.15	10.45	12.70%	6.90	13.23	17.40%
SVR	3.39	8.45	9.30%	5.05	10.87	12.10%	6.72	13.76	16.70%
FC-LSTM	3.44	6.30	9.60%	3.77	7.23	10.90%	4.37	8.69	13.20%
GWNet	2.69	5.12	6.80%	3.06	6.22	8.40%	3.49	7.30	10.00%
GMAN	2.80	5.55	7.41%	3.12	6.49	8.73%	3.44	7.35	10.07%
AGCRN	2.85	5.53	7.63%	3.20	6.52	9.00%	3.59	7.45	10.47%
DCRNN	2.67	5.16	6.86%	3.12	6.27	8.42%	3.54	7.47	10.32%
MTGNN	2.69	5.16	6.89%	3.05	6.13	8.16%	3.47	7.21	9.70%
STNorm	2.81	5.57	7.40%	3.18	6.59	8.47%	3.57	7.51	10.24%
STID	2.82	5.53	7.75%	3.19	6.57	9.39%	3.55	7.55	10.95%
PDFormer	2.83	5.45	7.77%	3.20	6.46	9.19%	3.62	7.47	10.91%
STAEformer	2.65	5.11	6.85%	2.97	6.00	8.13%	3.34	7.02	9.70%
ASTNet (our)	2.64	5.10	6.80%	2.94	5.98	7.94%	3.30	6.93	9.41%

表 3-3 ASTNet 与基线模型在 PEMS04、PEMS08 和 PEMS07 数据集上的比较


模型	PEMS04			PEMS08			PEMS07		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
VAR	24.54	38.60	17.24%	22.32	33.83	18.09%	50.22	75.63	32.22%
ARIMA	33.73	48.80	24.18%	31.09	44.32	22.73%	38.17	59.27	19.46%
SVR	26.18	38.91	22.84%	20.92	31.23	14.24%	32.49	50.22	14.26%
FC-LSTM	27.14	41.59	18.20%	22.20	34.06	14.20%	29.98	45.94	13.20%
GWNet	18.53	29.92	12.89%	14.40	23.39	9.21%	20.25	33.32	8.63%
GMAN	19.14	31.60	13.19%	15.31	24.92	10.13%	20.97	34.10	9.05%
AGCRN	19.38	31.25	13.40%	15.32	24.41	11.03%	22.37	36.55	9.12%
DCRNN	19.63	31.26	13.59%	15.22	24.17	8.42%	25.22	38.61	11.82%
MTGNN	19.17	31.70	13.37%	15.18	24.24	10.20%	22.15	34.06	9.00%
STNorm	18.96	30.98	12.69%	15.41	24.77	9.76%	20.50	34.10	8.75%
STID	18.38	29.95	12.04%	14.21	23.28	9.72%	19.54	32.85	8.25%
PDFormer	18.36	30.03	12.00%	13.58	23.41	9.05%	19.97	32.95	8.55%
STAEformer	18.22	30.18	11.98%	13.46	23.25	8.88%	19.14	32.60	8.01%
ASTNet (our)	18.18	29.87	11.97%	13.40	23.11	8.86%	19.13	32.50	7.96%




(a) PEMS04 数据的 MAE




(b) PEMS08 数据的 MAE




(c) PEMS04 数据的 RMSE



(d) PEMS08 数据的 RMSE



(e) PEMS04 数据的 MAPE



(f) PEMS08 数据的 MAPE


图 3-2 PEMS04 和 PEMS08 数据集上每个时间步预测

(2) **w/o S-mixer**: 移除空间自适应融合模块, 验证地理语义锚点对时序特征进行空间校准的必要性。


(3) **w/o T-Attention**: 移除时间自注意力模块, 评估长程时间依赖关系对预测精度的贡献

(4) **w/o S-Attention**: 移除空间自注意力模块, 考察动态空间交互建模在处理路网复杂关联时的作用。

除上述不同外, 上述变体的设置都与 ASTNet 模型一致。图 3-3 展示了 ASTNet 及其变体在 PEMS04 和 PEMS08 数据集上未来 12 个预测步长的平均误差 (MAE, RMSE, MAPE)。实验结果表明, ASTNet 在所有评价指标上均优于任何单一变体模型, 这有力地证明了各模块在时空特征学习过程中具有协同增强作用。移除 T-mixer 或 S-mixer 后, 模型性能出现显著下降。这说明基于 Mixer 结构的自适应融合机制能够有效地根据实时路况动态调节先验知识的注入强度, 解决了传统模型中时空特征静态拼接导致的信息失真问题。移除 T-Attention 和 S-Attention 的性能退化表明, Transformer 结构提供的全局感受野对于捕捉长程时间演化趋势和复杂的动态空间关联至关重要。



(a) PEMS04 数据的 MAE (b) PEMS04 数据的 RMSE (c) PEMS04 数据的 MAPE



(d) PEMS08 数据的 MAE (e) PEMS08 数据的 RMSE (f) PEMS08 数据的 MAPE

图 3-3 PEMS04 和 PEMS08 数据集的消融实验。A 表示 w/o T-mixer; B 表示 w/o S-mixer; C 表示 w/o T-attention; D 表示 w/o S-attention; E 表示 ASTNet

3.4.3 计算效率分析

为评估 ASTNet 的计算效率，表 3-4 展示了 ASTNet 与相关基线模型在 PEMS04 数据集上的平均每轮训练时间和推理时间。从中可以看出，ASTNet 在训练与推理效率上表现优异，这主要归因于其简洁高效的自适应时空嵌入设计。具体而言，GMAN 与 PDFormer 等基于多头注意力的模型在时空嵌入构建上引入了较高的计算开销。GMAN 采用 Node2Vec 生成静态空间嵌入，并结合时间周期编码，通过逐元素相加得到时空嵌入，随后在空间与时间注意力模块中将该嵌入与输入特征拼接，参与成对注意力计算。PDFormer 则引入图拉普拉斯嵌入与时间周期嵌入，并通过局部地理掩蔽与全局语义掩蔽引导注意力计算，同时额外设计了传播时延感知模块，进一步增加了计算负担。相较之下，STAEformer 采用简单的固定时空编码，因而具备较高的训练与推理效率。然而，STAEformer 嵌入方式缺乏自适应性，限制了特征表达能力。ASTNet 在 STAEformer 的基础上，引入自适应时空嵌入模块，在仅增加少量计算开销（训练时间增加约 5.95%，推理时间增加约 6.99%）的前提下，显著提升了预测精度。


综合来看，ASTNet 通过轻量级自适应嵌入结构，实现了训练与推理效率的双重优势，在计算效率与预测性能之间取得了更优的平衡。

表 3-4 PEMS04 数据集上不同模型的计算效率

模型	训练（单位：s）	推理（单位：s）
GMAN	501.578	38.844
PDFormer	133.871	8.120
ASTNet	75.334	7.653
STAEformer	71.099	7.156

3.4.4 超参数敏感性分析

本节通过开展超参数敏感性实验，深入探讨了不同参数配置对本文所提出的 ASTNet 模型预测性能的影响。如图 3-4 所示，在 PEMS04 和 PEMS08 数据集上，Mixer 组件的堆叠层数 l 直接决定了模型对高阶时空特征的提取能力。当层数从 1 层增加到 3 层时，预测误差 MAE 和 MAPE 呈现明显的下降趋势。这表明通过增加多层 MLP，模型能够逐步构建从局部观测到全局语义的层级映射，有效捕捉了路网中深层的非线性时空演化逻辑。然而，当层数进一步增加到 4 时，预测精度并未获得持续提升，还出现了性能下降。这主要是由于过深的架构引入了冗余的参数数量，导致模型在有限的交通样本下产生了过拟合风险；同时，深层网络带来的计算开销增加，也降低了模型的实时推理效率。

(a) PEMS04 的网络层数 l (b) PEMS08 的网络层数 l 图 3-4 PEMS04 与 PEMS08 数据集上网络层数 l 的影响

3.4.5 预测可视化分析

为了更全面、直观地展示 ASTNet 在实际交通预测中的性能，图 3-5 和图 3-6 分别可视化了 PEMS04 数据集中节点 153 和节点 254 的预测结果。从图中所展示的预测结果对比可以看出，本文提出的 ASTNet 在多个时间点，如 06:00、12:00、15:00、18:00 上的预测值与真实交通流量值保持高度一致，整体拟合程度显著优于对比模型 STAEformer。这一优势主要得益于 ASTNet 所采用的自适应时空融合机制。具体而言，STAEformer 在输入阶段将时间嵌入、空间嵌入与交通流数据进行静态拼接，导致模型难以动态适应不同交通场景下的数据分布变化，尤其在流量快速上升或下降的时段容易产生预测偏差。相比之下，ASTNet 设计了分层次的时空信息引入机制，在每一层网络中通过时空融合门控单元，根据当前层级的特征表达动态调整时空融合权重。这种设计使得模型能够自主感知不同时刻下时间依赖与空间关联的相对重要性，从而在交通流呈现多模态动态变化时，依然保持精准的预测能力。此外，ASTNet 在每次融合操作后引入特征优化模块，对融合后的特征进行自适应提炼与强化，有效剔除了冗余干扰信息。这一机制在图中的平滑预测曲线上得到了体现，ASTNet 在各时间点的预测值均未出现明显的异常波动，表现出良好的鲁棒性与泛化能力。综上所述，自适应时空融合机制通过动态调整融合权重与特征优化，显著提升了模型对复杂交通流模式的建模能力，是实现高精度预测的关键技术支撑。

为了进一步验证本文设计的自适应时空融合的有效性，剖析了 PEMS08 数据集上多个传感器在交通状态演变过程中的注意力分布特征，如图 3-7 所示。图 3-7 (a) 展示了传感器 8、42、44、101 和 115 位于同一行驶方向的车道上，而传感器 14 则位于反向车道。为了深入探究模型在预测过程中动态注意力矩阵的变化机理，选取传感器 42 作为观测核心，分析其在交通状态演变下的注意力分布特征。图 3-7 (b) 展示了在凌晨 5:00 至上午 6:40

期间，交通状态经历了从低流量平稳期向早高峰拥堵期的过渡。通过对比图 3-7（c）与图 3-7（d）可以发现，在非高峰期间，传感器 42 对传感器 14、42、101 和 44 分配了较高的注意力分值。相比之下，传感器 8 和 115 由于地理空间距离较远，获得的权重相对较低。




图 3-5 PEMS04 数据集节点 153 单日交通流量可视化





图 3-6 PEMS04 数据集节点 254 单日交通流量可视化

从 5:00 到 6:40 拥堵程度加剧，传感器 42 对同向传感器（44、8、115、101）的注意力权重显著增强，而对反向传感器 14 的关联度则持续下降。这一趋势高度符合现实世界的交


通物理特性，即在交通拥堵蔓延过程中，同向行驶的车道受到的波及效应远大于对向车道。

此外，如图 3-7（e）所示，在缺失自适应时空融合模块的情况下，传感器 42 和传感器 14 的注意力权重很大。这表明时空特征的直接通道混合会导致严重的语义信息丢失，使模型无法准确识别真实的地理位置关联，也进一步验证了自适应时空融合架构的必要性。


综上所述，自适应时空融合模块对于增强时空嵌入的表达能力至关重要。它能够引导模型根据实时路况动态调整注意力分布，从而实现对路网时空演变过程的精准建模。




（a）传感器分布




（b）节点 42 的交通流



（c）5:00 的节点



(d) 6:40 的 ASTNet



(e) 6:40 去除时空自适应融合模块

图 3-7 PEMS08 数据集在不同模型下的交通传感器注意力矩阵

3.5 本章小结

本章详细阐述了面向交通流预测的自适应时空融合网络 ASTNet 的构建过程。首先，针对交通数据多维异构的特性，设计了多维时空嵌入层，通过引入节点感知的周期嵌入与空间嵌入，实现了对交通流数据特征与时空先验知识的深度表征。其次，提出了自适应融合机制。通过构建时间与空间自适应融合模块，引入轻量化 Mixer 算子作为动态门控，有效解决了传统静态融合模式下特征利用不充分及信息丢失的问题。该机制能够根据实时流量波动的强度，动态调节先验规律与实时观测的比例，确保了模型在非平稳态下的灵敏度和平稳态下的鲁棒性。最后，引入了基于 Transformer 架构的双重自注意力时空模块。利用长程时间自注意力与动态空间自注意力，进一步捕捉了跨时段的时间依赖与复杂空间关联。

4 基于渐进式分解的双通道网络

根据第二章介绍的信号分解、多头注意力机制和 transformer 等相关理论基础，本章针对交通流任务中采用离散小波变换等方法，依赖历史数据确定分解参数，无法适应实时输入数据的动态分布变化的问题，提出一种基于渐进式分解的双通道网络，并设计一系列实验对模型的预测性能进行验证与评估。

4.1 引言

现有的时空预测研究通常将原始交通流量序列直接作为模型输入，旨在通过端到端的学习提取时空特征并映射未来演化态势。然而，交通流表征并非单一维度的线性演变，而是由多种时空尺度下的物理模式交织而成的复合信号。交通流量并非单一时序信号，而是由多种复杂模式耦合形成的。其变化受多重因素共同作用：长期维度上，城市规划、人口流动及经济发展等宏观因素，会使交通流量整体呈现上升或下降的趋势性变化。周期维度上，季节更替、节假日效应以及工作日与休息日交替，会带来规律性波动，如春节出行高峰、暑期旅游旺季引发的拥堵等。此外，道路施工、突发事件及极端天气等随机不可控因素，会使流量在短时间内剧烈波动，并以噪声形式体现在数据中。各类成分相互叠加，共同构成了交通流量的完整数据特征。

这种复杂的耦合结构使数据具有很强的动态性与不确定性。若直接对原始数据整体建模，通常难以有效提取其内在变化规律，进而降低预测精度。例如，突发事件虽会造成数据分布短时突变，但对长期趋势影响有限；而数据分布的不稳定性也会使模型预测结果产生较大波动，最终导致预测效果变差。现有 STWave^[36]和 STWave+^[70]模型采用离散小波变换（DWT）对交通数据进行静态分解，以分离稳定趋势和波动事件。静态分解属于离线预处理手段，仅基于历史数据确定分解参数与分量划分规则，当新的交通数据持续输入，如早晚高峰时段迁移、突发事件、极端天气等场景时，交通序列的统计分布会发生动态变化，而静态分解的固定规则无法自适应调整，导致分解结果与实时交通特征脱节，进而影响预测精度。渐进式分解嵌入模型训练过程，采用动态递进的分解-融合机制，可根据实时输入数据的分布特征，动态调整各层分解的权重与阈值，实现对非平稳序列的动态适配，从根源上提升模型的泛化能力。

4.2 总体框架

总体框架与思路如图 4-1 所示，该框架以分解模块（MASD）为核心起点，采用动态递进的分解逻辑，将输入交通数据逐步解耦为趋势分量 X_t 与波动事件分量 X_e ；与传统离线静态分解方法不同，该分解过程深度嵌入模型端到端训练流程，能够根据实时输入数

据的分布特征动态调整分解权重，彻底规避了固定分解规则对新数据分布适配性不足的缺陷。在分量建模阶段，框架设计双通道并行结构实现差异化时空特征提取：趋势分量通道（TCE）利用多层感知器（MLP）对具备长期稳定性的 X_t 进行建模，精准捕获其缓慢演化的时间规律；波动事件分量通道（ECE）则采用时间编码器-空间编码器的架构，针对具有高度不确定性的 X_e ，高效捕捉其短期波动特征与动态空间关联。最终，框架对双通道输出的特征进行融合，并通过输出层生成交通流量预测结果。




图 4-1 MPDNet 框架

4.2.1 分解模块

精准解析交通时序数据中的多尺度耦合信息，是提升预测模型泛化能力与可解释性的关键前提。基于贝叶斯结构时间序列模型^[71]与因果马尔可夫条件^[72]的理论框架，交通时间序列可视为由不同动力学特性的潜在线性分量叠加而成。其中，趋势分量反映了由人类通勤规律、周期性社会活动所驱动的长期平稳演化过程，而事件分量则表征了由交通事故、临时交通管制或极端天气等外部干预因素所引发的瞬时冲击。上述理论框架的一个重要推论是，趋势项与事件项在生成机制上满足因果马尔可夫条件，即在给定父节点条件下，二者相互独立。这意味着当交通序列中某一局部成分发生动态突变时，交通流趋势仍能保持统计意义上的稳定性。因此，通过可控的分解操作将原始观测信号解耦为统计特性各异的正交分量，能够有效降低后续建模任务的复杂度，使模型能够更充分地捕捉复杂交通时空数据中的全局演化规律与局部扰动特征。基于上述理论分析，设计了一个渐进式分解模块 MASD，与传统的信号分解方法，如 STL 分解、小波变换作为离线预处理步骤不同，MASD 模块被深度集成于整个预测模型的训练流程之中。其核心

思想在于利用滑动平均的物理平滑特性，通过可调整的感受野机制从原始数据中渐进式地剥离长期趋势分量，从而实现趋势与波动分量的有效解耦。

设原始交通数据张量为 $X \in R^{T \times N \times d}$ ，其中 T 为时间步长， N 为路网节点数， d 为特征维度。由于滑动窗口操作不可避免地会导致序列两端的信息损失，而交通预测中最近的时刻往往包含最重要的信息，因此本模块首先对输入序列进行边界填充（Padding）操作。具体而言，在时间轴的首尾两端分别填充长度为 p 的数据片段，以保证后续池化操作后序列长度的不变性。通过矩阵乘法对原始序列 X 进行左右填充，以保留边界信息。

$$x_l = X \otimes A_{[1]}^{\frac{(w-1-\lfloor \frac{w-1}{2} \rfloor)}{2}} \quad (4-1)$$

$$x_r = X \otimes A_{[1]}^{\lfloor \frac{w-1}{2} \rfloor} \quad (4-2)$$

其中， $\otimes$ 表示特定维度的矩阵乘法， $A_{(1)}^{(k)}$ 为用于序列延拓的变换矩阵， W 为滑动窗口大小， $\lfloor \cdot \rfloor$ 为向下取整运算。

将原始序列与左右填充部分拼接，得到扩展后的序列：

$$x' = \text{concat}(x_l, x, x_r) \quad (4-3)$$

在扩展序列上应用滑动窗口平均，提取趋势分量 X_t ：

$$X_t = \frac{1}{W} \sum_{i=a}^b x_i, \begin{cases} a = \max\left(1, T - \frac{W-1}{2}\right) \\ b = \min\left(T, T + \frac{W-1}{2}\right) \end{cases} \quad (4-4)$$

其中， T 为原始序列长度， a 和 b 为滑动窗口的起止索引，其约束条件保证了窗口始终位于序列有效范围内。通过原始序列与趋势分量的残差计算波动事件分量：

$$X_e = X - X_t \quad (4-5)$$

4.2.2 事件分量提取

交通流量时间序列可视为由多种隐含模式叠加而成，其中事件分量代表了由非常规扰动引发的瞬时波动。这类波动事件，如交通事故导致的拥堵、大型活动散场后的流量激增，通常会在时间轴上呈现非对称的传播特性，即拥堵的向后传播与向前传播往往遵循不同的动力学模式。为了精准捕捉这类由突发因素引发的、区别于常规早晚高峰的短期波动，设计了一种时序动态编码器模块。该模块采用多头自注意力机制，专注于挖掘序列内部不同时间点之间的动态关联权重。该编码器首先将输入序列 $X_e^{1:T}$ 通过线性变换投影至查询、键与值向量空间。随后，模块利用缩放点积注意力机制计算各时间步间的动态依赖强度，从而精准捕捉局部拥堵的形成规律与消散演化过程。其具体的数学表达

如下:

$$Attn = \text{Concat}(head_1, head_2, \dots, head_h) \quad (4-6)$$

$$head_h = \text{Attention}(Q_n^{(T)}, K_n^{(T)}, V_n^{(T)}) = \text{Softmax}\left(\frac{Q_n^{(T)}(K_n^{(T)})^T}{\sqrt{d'}}\right)V_n^{(T)} \quad (4-7)$$

$$y^{l,t} = \text{LN}\left(\text{Dropout}\left(\text{Attn}(X_e^{l-1,t})\right) + X_e^{l-1,t}\right) \quad (4-8)$$

$$z^{l,t} = \text{LN}\left(\text{Dropout}\left(\text{FeedForward}(y^{l,t})\right) + y^{l,t}\right) \quad (4-9)$$

其中, $Z_Q^T, Z_K^T, Z_V^T \in \mathbb{R}^{d \times d'}$ 为可学习参数, $Q_n^{(T)}, K_n^{(T)}, V_n^{(T)}$ 分别为节点 n 在所有时间片下的查询矩阵、键矩阵与值矩阵, d 为特征维度。然而, 交通事件的影响在空间维度上呈现出显著的扩散性与区域耦合性。当路网中某一特定位置发生交通扰动时, 其影响将沿拓扑结构发生时空扩散, 相邻路段及上下游节点流量的联动演化。为此, 设计了一种空间编码器以捕捉交通数据中的动态空间依赖关系, 其数学表达式如下:

$$\text{Attn} = \text{Concat}(head_1, head_2, \dots, head_h) \quad (4-10)$$

$$head_h = \text{Attention}(Q_t^{(S)}, K_t^{(S)}, V_t^{(S)}) = \text{Softmax}\left(\frac{Q_t^{(S)}(K_t^{(S)})^T}{\sqrt{d'}}\right)V_t^{(S)} \quad (4-11)$$

$$y^{l,s} = \text{LN}\left(\text{Dropout}\left(\text{Attn}(X_e^{l-1,s})\right) + X_e^{l-1,s}\right) \quad (4-12)$$

$$z^{l,s} = \text{LN}\left(\text{Dropout}\left(\text{FeedForward}(y^{l,s})\right) + y^{l,s}\right) \quad (4-13)$$

其中, $Z_Q^S, Z_K^S, Z_V^S \in \mathbb{R}^{d \times d'}$ 为可学习参数, $Q_n^{(S)}, K_n^{(S)}, V_n^{(S)}$ 分别为所有节点在时间 t 上的查询矩阵、键矩阵与值矩阵。尽管上述时空编码器能够有效提取事件分量的初步特征, 但经过这一层处理后的中间表示 $z^{l,s}$ 中, 往往仍存在长期趋势分量的部分信息。这是因为在实际场景中, 突发事件往往叠加在稳定的周期性趋势之上, 二者在底层特征空间中存在非线性耦合与动态交互。若直接基于这种混叠的表示进行预测, 模型容易将趋势的惯性延续误判为事件的持续, 或将事件的突发性干扰归因于趋势的突变, 从而影响预测的精准度。

为了解决分量混叠问题, 保证预测过程的准确性与可解释性, 引入渐进式分解模块 MASD。具体而言, 它首先对输入的 $z^{l,s}$ 进行平滑处理以提取趋势分量, 然后通过残差连接获取事件波动。这种渐进式分解不仅实现了信息的分离, 还通过残差连接机制将每一层提取出的趋势进行累加, 确保了信息的传递。该分解过程可形式化为:

$$X_e^l, X_t^l = \text{MASD}(z^{l,s}) \quad (4-14)$$

$$X_t^l = X_t^{l-1} + X_t^l \quad (4-15)$$

其中, X_e^l 和 X_t^l 分别表示初步渐进式分解得到的事件分量与趋势分量。

4.2.3 趋势分量提取

基于自注意力机制的 Transformer 架构虽然擅长捕捉长距离的语义依赖, 但其在设计上更侧重于对输入信息的加权聚合, 而非对函数本身的外推。已有研究表明, 注意力模型在处理超出预训练长度或未见过的趋势变化时, 往往由于缺乏对线性空间的归纳偏置, 而难以准确外推趋势的走向, 导致预测误差累积放大。相比之下, 多层感知机本质上是一个通用函数逼近器, 其全连接结构能够通过线性变换与非线性激活的组合, 在有限参数数量的情况下精确拟合趋势分量所蕴含的单调或周期性变化规律, 因此采用这种轻量级的多层感知机模块对趋势分量进行建模。多层感知机模块以前一层分解出的趋势状态 X_t^l 作为输入, 通过一个隐藏层进行维度变换与特征映射, 最后输出对下一时刻趋势的预测。其计算过程可形式化为:

$$y_t = w_2 \left(\sigma(w_1(X_t^l) + b_1) \right) + b_2 \quad (4-16)$$

其中, w_1 和 w_2 为可学习的权重矩阵, b_1 和 b_2 为对应的偏置项, $\sigma(\cdot)$ 表示 ReLU 激活函数用于引入非线性变换以增强模型的表达能力。该 MLP 模块直接作用于经过多阶段分解后的趋势分量上, 避免了事件分量的高频噪声对趋势预测的干扰, 从而确保了模型能够精准地把握交通流量的长期演进规律。

4.2.4 输出层

在完成了对交通流量序列的深度分解与独立建模后, 得到了两个中间表示, 分别为 MLP 提取的长期趋势分量 y_t 和时空编码器捕捉的事件波动分量 y_s 。趋势分量反映了路网运行的惯性规律与周期性基底, 而事件分量则捕捉了由突发因素导致的瞬时扰动与空间扩散效应。对这两个中间表示进行输出层预测如下:

$$Y = y_t + y_s \quad (4-17)$$

$$\hat{Y} = FC(Y) \quad (4-18)$$

4.3 实验设置

实验设置主要介绍交通流预测领域中常用的几个公开数据集, 并详细说明实验环境配置、关键超参数设置, 以及作为对比依据的多个基线模型。

4.3.1 数据集

为全面验证本文所提模型的泛化性能与稳健性, 在四个公开的城市交通基准数据集上进行了广泛实验。这些数据集涵盖了不同的路网规模与空间拓扑结构, 其统计细节如

表 4-1 所示。METRLA 数据集来源于洛杉矶高速公路系统部署的 207 个传感器，涵盖 2012 年 3 月 1 日至 6 月 30 日的交通流速度记录。该数据具有显著的非线性特征与时空耦合性，是评估大规模路网长期时序预测性能的典型基准。PEMS04、PEMS07、PEMS08 数据集由加利福尼亚州运输部的交通性能监测系统（PeMS）实时采集。PeMS 系统通过分布在加州各主要都市区高速公路上的传感器，以 30 秒为基准频率进行原始数据提取，并进一步聚合成 5 分钟间隔的统计数据。PEMS04 涵盖旧金山湾区 307 个检测点，记录了包括流量、平均速度及占有率在内的多维交通态势指标。PEMS07 规模相对较大，包含加州路网中 883 个传感器节点，数据维度丰富，对模型的计算效率与空间伸缩性提出了更高要求。PEMS08 聚焦于圣贝纳迪诺地区的 170 个观测点，常用于验证模型对区域性局部交通演化模式的捕捉能力。

表 4-1 数据集

数据集	时间跨度	节点	边	时间片
METRLA	03/2012-06/2012	207	1515	34272
PEMS04	01/2018-02/2018	307	340	16992
PEMS07	05/2017-08/2017	883	548	28224
PEMS08	07/2016-08/2016	170	295	17856

4.3.2 实验环境和参数设置

本研究的所有模型均基于 PyTorch 1.11.0 深度学习框架实现，并部署于搭载 NVIDIA GeForce RTX 3090 显卡（24 GB 显存）的计算平台完成训练过程。为保证实验对比的公平性与有效性，本研究严格遵循基线模型的核心实验配置：在数据集划分方面，METRLA 数据集按 7:1:2 的比例划分为训练集、验证集与测试集；PEMS04、PEMS07 及 PEMS08 数据集则采用 6:2:2 的比例完成数据集划分。数据预处理阶段，所有交通流量数据集均通过 Z-Score 标准化方法进行归一化处理，以消除数据量纲差异对模型训练的干扰，提升模型收敛效率与稳定性。

为全面评估模型在不同时间尺度下的预测性能，实验选取第 3、6、12 个时间步作为关键评估节点，分别对应一小时预测任务中的短时、中时与长时预测场景，并采用 MAE、RMSE、MAPE 三项核心指标量化模型预测效果。其中，MAE 反映预测值与真实值的平均绝对偏差，RMSE 对异常值更为敏感，可衡量预测误差的离散程度，MAPE 则以百分比形式直观体现预测精度，三者结合可全面表征模型在不同时间跨度下的预测能力。

模型训练过程中，选用 Adam 优化器进行参数更新，以 MAE 作为损失函数引导模型

优化方向；初始学习率设置为 0.001，批处理大小设为 64。为平衡模型表达能力与计算复杂度，经多次对比实验验证，最终将窗口大小设置为 25。

4.3.3 基线模型

本章将与以下模型进行对比：

- (1) VAR^[60]：作为多元时间序列分析方法，可有效刻画多变量间的动态关联特性。
- (2) ARIMA^[61]：融合自回归与滑动平均机制，通过拟合序列的自相关、偏自相关结构实现预测，适合平稳及含季节性特征的时序数据。
- (3) SVR^[62]：作为支持向量机的重要分支，通过在高维空间构建最优超平面完成拟合，可处理非线性与复杂数据关系。
- (4) FC-LSTM^[63]：采用带全连接层的 LSTM 结构，提取时序数据中的长短期依赖信息。
- (5) GWN^[64]：一类时空图神经网络，通过自适应邻接矩阵与扩散图卷积挖掘图数据的潜在空间依赖，结合空洞因果卷积实现深度时空数据建模。
- (6) GMAN^[65]：是一种用于交通预测的图多注意力网络模型。该模型采用编码器-解码器架构，旨在解决交通系统中复杂的时空关系和误差传播问题。
- (7) AGCRN^[66]：使用自适应图卷积和 GRU，自动学习节点专属模式与动态空间依赖，解决传统 GCN 依赖预定义静态图、全局参数共享的局限。
- (8) DCRNN^[19]：扩散卷积循环神经网络模型，将扩散卷积运算与 GRU 结合，以建模时空关系。
- (9) MTGNN^[67]：基于图神经网络的多变量时间序列使用图学习模块计算邻接矩阵，并将其作为图卷积的输入，以捕捉变量之间隐藏的空间依赖关系。
- (10) STNorm^[68]：核心是通过时间归一化和空间归一化分离时序高频和低频、空间全局和局部信号，大幅提升预测精度。
- (11) DDGCRN^[73]：区分了正常和异常的交通信号和模型。通过分析时空嵌入的情况，可以研究交通状况与时间点之间的关系。
- (12) STWave^[36]：设计了一种新的解纠缠-融合时空预测框架，并在模型层面为完全图注意力设计高效的采样机制以及富含结构信息的图小波位置编码。
- (13) DSM-STWave^[38]：在 STWave 的基础上引入双空间注意力机制和自适应记忆模块。

4.4 实验结果与分析

为了更好地验证 MPDNet 模型的有效性，将其与多个基线模型开展了一系列对比实验，并对实验结果进行了详细分析。

4.4.1 模型性能比较

表 4-2 展示了本文模型 MPDNet 与各基线模型在 METRLA 数据集上的性能对比，表 4-3 则呈现了在 PEMS04、PEMS07 和 PEMS08 三个公开交通数据集上的详细实验结果。通过对多个数据集、多时间尺度下的系统比较，可以得出以下结论：首先，传统统计学习模型 VAR、ARIMA 在所有任务上均显著劣于基于神经网络的模型。这类方法难以有效建模交通流中复杂的非线性与长时序依赖，且对人工特征工程依赖较强，导致其泛化能力受限。在基于图神经网络的模型中，采用自适应图结构的模型，如 GWNNet、MTGNN、AGCRN 普遍优于使用预定义邻接矩阵的模型 DCRNN。这表明，通过学习节点之间的动态依赖关系，能够更精准地刻画交通流的空间交互特性，从而提升预测精度。然而，这些模型仍采用单一的图卷积结构对时空特征进行联合建模，缺乏对不同时间尺度模式的显式分离与差异化建模，导致其在处理包含平稳趋势与突发波动并存的复杂交通序列时，难以同时兼顾预测的稳定性与灵敏性。基于分解交通流的模型性能提升很多，DDGCRN 区分正常和异常的交通信号，并对不同的信号分别建模。DSM-STWave 在 STWave 的基础上引入双空间注意力机制和自适应记忆模块，更好地捕捉了空间特性，所以性能更好一点。然而，上述分解方法仍存在一定局限性，STWave 和 DSM-STWave，均采用小波变换作为数据预处理的静态分解手段。这种先验式的静态分解将分解与预测视为两个独立阶段，分解结果无法根据下游预测任务进行自适应调整，且固定的分解方式难以应对测试阶段出现的数据分布偏移。本文提出的 MPDNet 通过渐进式分解架构，将复杂的交通序列在特征提取过程中动态、充分地解耦为趋势分量与波动分量，并设计双通道处理模块分别进行针对性建模。这种渐进式分解机制，使得分解过程能够感知预测任务的损失反馈，从而自适应地调整分离出的成分表征。相较于静态分解方法，MPDNet 不仅实现了更彻底的成分解耦，更关键的是，通过让分解过程参与联合优化，显著增强了模型对复杂交通模式的拟合能力以及对动态分布的泛化能力。


图 4-2 呈现了 MPDNet 与各基线模型在 PEMS04 和 PEMS08 数据集上，随预测时间步变化的误差演化曲线。观察可知，在第 4 个预测步之后，MPDNet 的预测性能开始逐步超越所有对比模型；且随着预测步长的增大，该模型的优势愈发显著。这充分证明，在长时预测任务中，MPDNet 在时序依赖建模与结果稳定性方面均表现出更强的综合能力。

表 4-2 MPDNet 与基线模型在 METRLA 数据集上的比较


模型	15min			30min			60min		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
VAR	4.42	7.89	10.20%	5.14	9.13	12.70%	6.52	10.11	15.80%
ARIMA	3.99	8.12	9.60%	5.15	10.45	12.70%	6.90	13.23	17.40%
SVR	3.39	8.45	9.30%	5.05	10.87	12.10%	6.72	13.76	16.70%
FC-LSTM	3.44	6.30	9.60%	3.77	7.23	10.90%	4.37	8.69	13.20%
GWNet	2.69	5.12	6.80%	3.06	6.22	8.40%	3.49	7.30	10.00%
GMAN	2.80	5.55	7.41%	3.12	6.49	8.73%	3.44	7.35	10.07%
AGCRN	2.85	5.53	7.63%	3.20	6.52	9.00%	3.59	7.45	10.47%
DCRNN	2.67	5.16	6.86%	3.12	6.27	8.42%	3.54	7.47	10.32%
MTGNN	2.69	5.16	6.89%	3.05	6.13	8.16%	3.47	7.21	9.70%
STNorm	2.81	5.57	7.40%	3.18	6.59	8.47%	3.57	7.51	10.24%
DDGCRN	2.72	5.23	7.11%	3.04	6.02	8.17%	3.39	7.16	9.69%
MPDNet (our)	2.63	5.08	6.82%	2.92	5.97	7.91%	3.28	6.91	9.44%

表 4-3 MPDNet 与基线模型在 PEMS04、PEMS08 和 PEMS07 数据集上的比较


模型	PEMS04			PEMS08			PEMS07		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
VAR	24.54	38.60	17.24%	22.32	33.83	18.09%	50.22	75.63	32.22%
ARIMA	33.73	48.80	24.18%	31.09	44.32	22.73%	38.17	59.27	19.46%
SVR	26.18	38.91	22.84%	20.92	31.23	14.24%	32.49	50.22	14.26%
FC-LSTM	27.14	41.59	18.20%	22.20	34.06	14.20%	29.98	45.94	13.20%
GWNet	18.53	29.92	12.89%	14.40	23.39	9.21%	20.25	33.32	8.63%
GMAN	19.14	31.60	13.19%	15.31	24.92	10.13%	20.97	34.10	9.05%
AGCRN	19.38	31.25	13.40%	15.32	24.41	11.03%	22.37	36.55	9.12%
DCRNN	19.63	31.26	13.59%	15.22	24.17	8.42%	25.22	38.61	11.82%
MTGNN	19.17	31.70	13.37%	15.18	24.24	10.20%	22.15	34.06	9.00%
STNorm	18.96	30.98	12.69%	15.41	24.77	9.76%	20.50	34.10	8.75%
DDGCRN	18.38	30.91	12.25%	14.36	23.74	9.44%	19.79	33.11	8.35%
STWave	18.50	30.39	12.43%	13.42	23.40	8.90%	19.94	33.88	8.38%
DSM-STWave	18.18	29.86	12.34%	13.55	23.24	8.93%	19.05	32.63	7.95%
MPDNet (our)	18.17	29.85	11.97%	13.38	23.03	8.92%	19.12	32.40	7.93%




(a) PEMS04 数据的 MAE




(b) PEMS08 数据的 MAE




(c) PEMS04 数据的 RMSE



(d) PEMS08 数据的 RMSE



(e) PEMS04 数据的 MAPE



(f) PEMS08 数据的 MAPE

图 4-2 PEMS04 和 PEMS08 数据集上每个时间步预测

4.4.2 消融实验

在 PEMS04 和 PEMS08 数据集上开展消融实验，通过逐步移除或替换模型的不同模块，验证 MPDNet 各组件的有效性，并设计了如下模型变体：


（1）w/o MASD：移除渐进式分解模块。该变体忽略了交通流序列中趋势模式与事件模式之间的潜在交互。

（2）w/o temporal-encoder：移除对波动事件的时间关系建模，仅捕获其空间依赖性。


（3）w/o spatial-encoder：移除空间自注意力模块。

（4）w/o trend-MLP：移除用于建模趋势成分的 MLP 模块。该变体无法对交通流中的平稳周期性模式进行显式拟合，仅依赖波动通道进行预测。

除上述区别外，各模型变体的其他参数设置均与原始 MPDNet 保持一致。图 4-3 给出了 MPDNet 及其各变体在 PEMS04 和 PEMS08 数据集上，对未来 12 个时间步的平均预测误差 MAE、RMSE 和 MAPE。实验结果表明，MPDNet 在所有评价指标上均优于单一变体模型，验证了各模块在时空特征学习中的协同增强作用。移除 MASD 后，模型性能出现全面下降。MPDNet 中的分解模块并非一次性静态操作，而是贯穿整个网络深度的动态机制。该模块首先对原始交通流进行初始分解，获得基础的波动与趋势成分，随后在网络每一层中持续嵌入，对上一层的波动输出进行再次分解，从中迭代剥离出更为纯净的趋势信息。通过这种方式，模型能够在深层特征空间中实现趋势与波动的渐进式解耦，使二者的特征表达随网络加深不断纯化。移除 trend-MLP 后，模型对长时平稳趋势的拟合能力显著减弱，误差累积加剧。这说明分解出的趋势成分仍需专门建模，MLP 凭借其平滑拟合的归纳偏置，能够有效提取稳态周期信息；若移除该模块，则会导致趋势信息流失。移除 temporal-encoder 后，模型对波动的时间演化规律失去建模能力，对突发流量的响应出现滞后，MAPE 显著劣化。这表明 Transformer 的全局感受野对于捕捉波动的长程依赖至关重要，仅靠空间关联难以还原其动态演化过程。移除 spatial-encoder 后，模型忽略了节点间的空间交互，性能下降尤为显著。这印证了交通领域中的局部突发事件会迅速扩散至相邻区域，而空间自注意力模块正是捕捉这种多节点动态传播效应的关键。



(a) PEMS04 数据的 MAE (b) PEMS04 数据的 RMSE (c) PEMS04 数据的 MAPE



(d) PEMS08 数据的 MAE (e) PEMS08 数据的 RMSE (f) PEMS08 数据的 MAPE

图 4-3 PEMS04 和 PEMS08 数据集的消融实验。A 表示 w/o MASD；B 表示 w/o temporal-encoder；C 表示 w/o spatial-encoder；D 表示 w/o trend-MLP；E 表示 MPDNet

4.4.3 计算效率分析

为评估 MPDNet 的计算效率，表 4-4 展示了 MPDNet 与相关基线模型在 PEMS04 数据集上的平均每轮训练时间和推理时间。从中可以看出，MPDNet 在训练与推理效率上表现优异。MPDNet 通过渐进式分解法逐步分离时空序列中的趋势与波动分量，将复杂的时空依赖建模分解为多个轻量级子问题。在分量建模阶段，框架设计双通道并行结构实现差异化时空特征提取，趋势分量通道利用 MLP 对长期稳定性分量进行建模，波动事件分量通道则采用时间编码器-空间编码器架构捕捉短期波动与动态空间关联。相比之下，STWave 与 DSM-STWave 虽同样引入分解机制，但其采用的单次小波分解方法存在固有的结构局限性。二者在模型输入端对原始时间序列进行一次性的趋势-波动分离后，分解结果以静态方式输入后续网络，缺乏跨成分的交互机制与细粒度调制能力，难以依据预测目标动态调整分解尺度或重构分解结果。DSM-STWave 虽在 STWave 基础上进一步引入双空间注意力与自适应记忆模块以提升预测精度，但其核心分解模块仍是单次静态分离，未从架构层面解决分解与预测任务之间的耦合与协同优化问题。综上所述，在计算效率与建模能力两个维度上，MPDNet 实现了对复杂时空模式的精细化建模与高效计算。

表 4-4 PEMS04 数据集上不同模型的计算效率

模型	训练（单位：s）	推理（单位：s）
GMAN	501.578	38.844
STWave	97.335	8.099
DSM-STWave	77.809	7.908
MPDNet	72.565	7.431

4.4.4 超参数敏感性分析

通过开展超参数敏感性实验，旨在深入探讨核心参数配置对 MPDNet 模型预测性能的影响规律。图 4-4 展示了在 PEMS04 和 PEMS08 数据集上，分解模块中滑动窗口尺寸 w 对模型精度的干预情况。窗口尺寸 w 直接决定了趋势分量剥离的平滑粒度。模型性能随窗口尺寸的变换呈现先升后降的趋势，且在 $w=25$ 时，MPDNet 展现出最优的预测性能。这表明在该尺度下，模型能够实现对宏观演化规律与微观随机扰动的最佳平衡。当窗口尺寸 $w=13$ 过小时，滑动平均算子的低通滤波能力受限，导致趋势分量中混叠了过多的高频噪声。这种欠平滑现象增强了模型对数据离群值的敏感度，极易引发预测结果的剧烈波动，降低了模型的稳定性。当窗口尺寸 $w=37$ 过大时，由于其等效感受野过宽，会导致滑动平均过程过度平滑掉序列中蕴含的有效语义特征。这种过平滑效应造成了严重的信息有损压缩，使得模型无法精准捕获流量变化的非线性逻辑，进而导致模型欠拟合。




图 4-4 PEMS04 与 PEMS08 数据集上超参数窗口大小 w 的影响

4.4.5 预测可视化分析

为了更全面、直观地展示模型在实际交通预测中的性能，图 4-5 展示了 PEMS04 数据集中节点 4 和节点 62 的预测结果可视化。根据图中所示的预测结果，MPDNet 在多个时间点上的预测值与真实交通流量值保持了较高的一致性，整体预测性能要优于 STWave。

针对数据平稳时段凌晨 0:00-3:00，在该时段，交通数据波动极小，MPDNet 表现出良好的预测性能。这一优势归因于渐进式分解机制对平稳趋势与波动的有效分离，趋势分量保留了数据的整体稳态规律，使模型能够输出平滑、稳定的预测曲线。针对高峰时段 6 点左右，随着通勤需求激增，交通流量呈现快速、持续的上升趋势。渐进式分解机制将这一稳态演化过程完整归入趋势分量，使得 trend-MLP 能够专注建模从平缓到快速攀升的单调变化规律，避免短时波动的干扰。相比之下，直接对原始数据进行建模容易混淆趋势变化与随机波动，导致拟合偏差。MPDNet 则通过趋势分量的纯净提取，实现了对高峰时段流量演化的精准拟合。在面对突发状况时，如中午 12 点左右，MPDNet 的预测性能优于 STWave，这得益于渐进式分解机制更强的适应能力。具体而言，趋势分量继续维持对整体背景态势的稳定估计，而突发扰动被动态归入波动分量，由时空自注意力模块处理。该模块利用路网拓扑约束，深度挖掘周边节点间的关联传播规律，对局部异常波动进行校准。同时，动态分解逻辑使模型能够实时调整分解边界，在无固定周期可循的干扰下快速适配真实交通流变化。综上所述，MPDNet 在复杂、非平稳环境下具有很强的鲁棒性与泛化性能。

为进一步验证 MPDNet 模型在长周期时序预测中的稳定性与泛化能力，避免单日预测结果存在偶然性，在 PEMS04 数据集中的节点 41 和节点 67 开展连续一周的长时序交通流预测可视化实验，全面检验模型对周内周期性规律、工作日与休息日差异化交通模式的捕捉能力，进一步夯实模型有效性的实验依据，如图 4-6 和图 4-7 所示。实验结果显示，MPDNet 的预测曲线与真实交通流轨迹表现出高度的重合性，完整复刻了路网流量的日周期行与周周期性。




图 4-5 PEMS04 数据集节点 62 和节点 4 单日交通流量可视化




图 4-6 PEMS04 数据集节点 41 一周交通流量可视化




图 4-7 PEMS04 数据集节点 67 一周交通流量可视化

综上所述，MPDNet 能够针对不同交通场景实现灵活且精准的应对。无论是波动较小的凌晨平稳时段、流量急剧变化的早晚高峰，还是受意外因素影响的突发波动场景，MPDNet 均能稳定输出高精度预测结果，准确捕捉交通流的动态演化特性。这进一步验证了渐进式分解与双通道模块分别建模的有效性。

4.5 本章小结

本章提出渐进式分解网络 MPDNet，可实现交通流趋势与波动分量的渐进式解耦。与传统静态分解不同，该网络将分解过程嵌入网络各层，以纯化特征表达。同时，本章设

计了双通道并行结构，其中通过 MLP 捕捉趋势分量规律，通过时空编码器捕捉波动分量特性，两者特征融合后完成预测。实验验证表明，MPDNet 在各类交通场景中均表现出优异的预测性能，证实了渐进式分解与双通道建模的有效性，为时空序列预测提供了兼具可解释性与鲁棒性的解决方案。

5 总结与展望

5.1 研究总结

本文针对城市交通流预测中时空特征融合不足、多尺度特性难以有效建模等问题，开展了深入系统的研究，提出了两种新颖的时空神经网络架构，主要工作与贡献总结如下：

提出了基于自适应时空融合的预测网络 **ASTNet**，针对现有方法在时空特征融合方面存在的静态拼接缺陷，本文设计了自适应时空融合模块，在每一层网络中设置时空融合门控单元，根据当前层级的特征表达动态调整时间信息与空间信息的融合权重；同时，通过专属的特征优化学习模块对融合后的特征进行自适应提炼与强化，有效剔除冗余干扰信息。模型能够自主感知不同交通场景下数据的实际分布规律，克服了传统方法中时空特征耦合不足的问题。在四个公开交通流数据集上的实验结果表明，**ASTNet** 在预测精度上显著优于 **STAEformer** 等对比模型，验证了自适应时空融合的有效性。

提出了基于多通道渐进式分解的交通流预测模型 **MPDNet**，针对交通流数据中长期趋势、周期性波动与短期突发事件等多重模式交织带来的建模难题，本文设计了渐进式分解机制。与传统的静态分解方法不同，**MPDNet** 将分解过程深度嵌入网络每一层，实现趋势分量与波动事件分量的渐进式解耦。模型首先对原始交通流进行初始分解，随后在网络各层中持续迭代，逐步剥离出更为纯净的趋势信息，使特征表达随网络加深不断纯化。在分量建模阶段，模型采用双通道并行架构，趋势分量通道利用多层感知器捕获长期平稳演化规律；波动事件分量通道通过时空编码器捕捉短期波动的时间依赖与动态空间传播特性。在四个公开交通流数据集上的实验结果表明，**MPDNet** 在 **MAE**、**RMSE** 及 **MAPE** 等评价指标上均优于现有主流方法，特别是在数据分布变化场景下展现出更强的鲁棒性，充分验证了渐进式分解与双通道并行建模的有效性。

综上所述，本文所提出的两种模型从不同角度解决了交通流预测中的关键问题，**ASTNet** 侧重于时空特征的自适应融合，**MPDNet** 侧重于多尺度特征的渐进式解耦。二者互为补充，共同为智能交通系统中的精准预测提供了有效的解决方案。

5.2 未来展望

尽管本文提出的 **ASTNet** 与 **MPDNet** 在交通流预测任务上取得了较为理想的实验结果，但仍存在若干值得深入探索的研究方向。未来工作可从以下几个方面展开：

随着大语言模型和多模态大模型的快速发展，其在时间序列预测领域的应用潜力日益显现。未来可探索将大模型的涌现能力引入交通预测任务，利用其强大的语义理解与

模式识别能力，实现对交通文本数据、图像数据与数值数据的联合建模，构建更加智能、通用、高效的交通预测系统。

交通预测本质上是一个高度不确定性的问题，仅提供点预测结果难以满足实际需求。未来可探索在现有模型基础上引入概率预测机制，量化预测结果的不确定性范围，为交通管理者提供更全面的决策依据。例如，可采用贝叶斯神经网络或分位数回归等方法，实现预测区间的可靠估计，增强模型在风险敏感场景下的可用性。

参考文献

- [1] AHMED S F, KULDEEP S A, RAFA S J, et al. Enhancement of traffic forecasting through graph neural network-based information fusion techniques[J]. Information Fusion, 2024, 110: 102466.
- [2] LIN W, ZHANG Z, REN G, et al. MGCN: Mamba-integrated spatiotemporal graph convolutional network for long-term traffic forecasting[J]. Knowledge-Based Systems, 2025, 309: 112875.
- [3] CHEN C, LIU Y, CHEN L, et al. Bidirectional spatial-temporal adaptive transformer for urban traffic flow forecasting[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 34(10): 6913-6925.
- [4] PRAVEEN R, HUNDEKARI S, PARIDA P, et al. Autonomous Vehicle Navigation Systems: Machine Learning for Real-Time Traffic Prediction[C]//2025 International Conference on Computational, Communication and Information Technology (ICCCIT). IEEE, 2025: 809-813.
- [5] ZHENG C, FAN X, PAN S, et al. Spatio-temporal joint graph convolutional networks for traffic forecasting[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 36(1): 372-385.
- [6] FAN Y, CHEN J, XU W, et al. DADiffNet: Delay-Aware Diffusion Networks with Adaptive Subgraphs for Large Scale Traffic Forecasting[J]. Neural Networks, 2026: 108756.
- [7] AHMED S F, KULDEEP S A, RAFA S J, et al. Enhancement of traffic forecasting through graph neural network-based information fusion techniques[J]. Information Fusion, 2024, 110: 102466.
- [8] FERREIRA G O, RAVAZZI C, DABBENE F, et al. Forecasting network traffic: A survey and tutorial with open-source comparative evaluation[J]. IEEE Access, 2023, 11: 6018-6044.
- [9] WENG W, FAN J, WU H, et al. A decomposition dynamic graph convolutional recurrent network for traffic forecasting[J]. Pattern Recognition, 2023, 142: 109670.
- [10] LIU Y, WU H. Prediction of road traffic congestion based on random forest[C]//2017 10th international symposium on computational intelligence and design (ISCID), 2017, 2: 361-364.
- [11] SHAO Z, WANG Z, YAO X, et al. ST-MambaSync: Complement the power of Mamba and Transformer fusion for less computational cost in spatial-temporal traffic forecasting[J]. Information Fusion, 2025, 117: 102872.
- [12] GUO K, HU Y, QIAN Z, et al. Optimized graph convolution recurrent neural network for traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(2): 1138-1149.
- [13] KAVEHMADAVANI F, NGUYEN V D, VU T X, et al. Intelligent traffic steering in beyond 5G open RAN based on LSTM traffic prediction[J]. IEEE Transactions on Wireless Communications, 2023, 22(11): 7727-7742.
- [14] NARMADHA S, VIJAYAKUMAR V. Spatio-Temporal vehicle traffic flow prediction using multivariate CNN and LSTM model[J]. Materials today: proceedings, 2023, 81: 826-833.
- [15] LI G, ZHAO Z, GUO X, et al. Towards integrated and fine-grained traffic forecasting: A spatio-temporal heterogeneous graph transformer approach[J]. Information Fusion, 2024, 102: 102063.
- [16] LABLACK M, SHEN Y. Spatio-temporal graph mixformer for traffic forecasting[J]. Expert systems with applications, 2023, 228: 120281.
- [17] FANG Z, LONG Q, SONG G, et al. Spatial-temporal graph ode networks for traffic flow forecasting[C]//Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining. 2021: 364-373.
- [18] YU B, YIN H, ZHU Z. Spatio-temporal graph convolutional networks: A deep learning framework for

- traffic forecasting[J]. arXiv preprint arXiv:1709.04875, 2017.
- [19] LI Y, YU R, SHAHABI C, et al. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting[J]. arXiv preprint arXiv:1707.01926, 2017.
- [20] SONG C, LIN Y, GUO S, et al. Spatial-temporal synchronous graph convolutional networks: A new framework for spatial-temporal network data forecasting[C]//Proceedings of the AAAI conference on artificial intelligence, 2020, 34: 914-921.
- [21] LI H, LIU J, HAN S, et al. STFGCN: Spatial-temporal fusion graph convolutional network for traffic prediction[J]. Expert Systems with Applications, 2024, 255: 124648.
- [22] CAI L, JANOWICZ K, MAI G, et al. Traffic transformer: Capturing the continuity and periodicity of time series for traffic forecasting[J]. Transactions in GIS, 2020, 24(3): 736-755.
- [23] XUE H, SALIM F D. TERMCast: Temporal relation modeling for effective urban flow forecasting[C]//Pacific-Asia Conference on Knowledge Discovery and Data Mining. Springer, 2021: 741-753.
- [24] CORREIA G M, NICULAE V, MARTINS A F. Adaptively sparse transformers[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 2174-2184.
- [25] ZHOU H, ZHANG S, PENG J, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI conference on artificial intelligence, 2021, 35: 11106-11115.
- [26] LIU S, YU H, LIAO C, et al. Pyraformer: Low-complexity pyramidal attention for long-range time series modeling and forecasting[C]//International conference on learning representations. 2021.
- [27] ZHANG Y, YAN J. Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting[C]//The eleventh international conference on learning representations. 2023.
- [28] SHABANI A, ABDI A, MENG L, et al. Scaleformer: Iterative multi-scale refining transformers for time series forecasting[J]. arXiv preprint arXiv:2206.04038, 2022.
- [29] SHEN L, WEI Y, WANG Y. GBT: Two-stage transformer framework for non-stationary time series forecasting[J]. Neural Networks, 2023, 165: 953-970.
- [30] ZHANG X, JIN X, GOPALSWAMY K, et al. First de-trend then attend: Rethinking attention for time-series forecasting[J]. arXiv preprint arXiv:2212.08151, 2022.
- [31] JIANG J, HAN C, ZHAO W X, et al. Pdformer: Propagation delay-aware dynamic long-range transformer for traffic flow prediction[C]//Proceedings of the AAAI conference on artificial intelligence, 2023, 37: 4365-4373.
- [32] LIU H, DONG Z, JIANG R, et al. Spatio-temporal adaptive embedding makes vanilla transformer sota for traffic forecasting[C]//Proceedings of the 32nd ACM international conference on information and knowledge management. 2023: 4125-4129.
- [33] CAO D, JIA F, ARIK S O, et al. Tempo: Prompt-based generative pre-trained transformer for time series forecasting[J]. arXiv preprint arXiv:2310.04948, 2023.
- [34] QIN Y, LUO H, ZHAO F, et al. Spatio-temporal hierarchical MLP network for traffic forecasting[J]. Information Sciences, 2023, 632: 543-554.
- [35] LEI T, YANG K, LI J, et al. Multichannel spatial-temporal graph convolution network based on spectrum decomposition for traffic prediction[J]. Expert Systems with Applications, 2024, 238: 122281.

- [36] FANG Y, QIN Y, LUO H, et al. When spatio-temporal meet wavelets: Disentangled traffic forecasting via efficient spectral graph attention networks[C]//2023 IEEE 39th international conference on data engineering (ICDE). IEEE, 2023: 517-529.
- [37] WANG Y, LI R, LI X, et al. STADNN: Spatio-temporal adaptive decomposition neural network for traffic prediction[J]. Neurocomputing, 2025: 132486.
- [38] LIANG Y, LIU S, BAI Y, et al. DSM-STWave: Enhancing traffic flow prediction for both offline and online scenarios[J]. Neurocomputing, 2025: 131836.
- [39] CAO L, WANG B, JIANG G, et al. Spatiotemporal-aware trend-seasonality decomposition network for traffic flow forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39: 11463-11471.
- [40] YANG S, WU Q, LI M, et al. Temporal identity interaction dynamic graph convolutional network for traffic forecasting[J]. IEEE Internet of Things Journal, 2025, 12(11): 15057-15072.
- [41] VLAHOIANNI E I, KARLAFTIS M G, GOLIAS J C. Optimized and meta-optimized neural networks for short-term traffic flow prediction: A genetic approach[J]. Transportation research part c: Emerging technologies, 2005, 13(3): 211-234.
- [42] 吴晨. 北京二环路局部下穿与旧城风貌复兴的探索[J]. 北京规划建设, 2011(1): 94-100.
- [43] SHIN Y, YOON Y. PGCN: Progressive graph convolutional networks for spatial-temporal traffic forecasting[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(7): 7633-7644.
- [44] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [45] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [46] TOV O, ALALUF Y, NITZAN Y, et al. Designing an encoder for stylegan image manipulation[J]. ACM Transactions on Graphics (TOG), 2021, 40(4): 1-14.
- [47] SZEGEDY C, IOFFE S, VANHOUCKE V, et al. Inception-v4, inception-resnet and the impact of residual connections on learning[C]//Proceedings of the AAAI conference on artificial intelligence, 2017, 31.
- [48] HAMILTON J D. Time series analysis[M]. Princeton university press, 2020.
- [49] CLEVELAND R B, CLEVELAND W S, MCRAE J E, et al. STL: A seasonal-trend decomposition[J]. J. off. Stat, 1990, 6(1): 3-73.
- [50] TAO Z, WU P, JIN Z, et al. Prophet: An inferable future forecasting benchmark with causal intervened likelihood estimation[J]. arXiv preprint arXiv:2504.01509, 2025.
- [51] STURMEL N, DAUDET L, OTHERS. Signal reconstruction from STFT magnitude: A state of the art[C]//International conference on digital audio effects (DAFx). 2011: 375-386.
- [52] ZHANG D. Wavelet transform[M]//Fundamentals of image data mining: Analysis, Features, Classification and Retrieval. Springer, 2019: 35-44.
- [53] DRAGOMIRETSKIY K, ZOSSO D. Variational mode decomposition[J]. IEEE transactions on signal processing, 2013, 62(3): 531-544.
- [54] CHAI T, DRAXLER R R. Root mean square error (RMSE) or mean absolute error (MAE)?—Arguments against avoiding RMSE in the literature[J]. Geoscientific model development, 2014, 7(3): 1247-1250.

- [55] GOODWIN P, LAWTON R. On the asymmetry of the symmetric MAPE[J]. International journal of forecasting, 1999, 15(4): 405-408.
- [56] CHAI T, DRAXLER R R. Root mean square error (RMSE) or mean absolute error (MAE)?—Arguments against avoiding RMSE in the literature[J]. Geoscientific model development, 2014, 7(3): 1247-1250.
- [57] KHODARAHMI M, MAIHAMI V. A review on Kalman filter models[J]. Archives of Computational Methods in Engineering, 2023, 30(1): 727-747.
- [58] CARIANNI A, GEMMA A. Overview of traffic flow forecasting techniques[J]. IEEE Open Journal of Intelligent Transportation Systems, 2025.
- [59] AOUEDI O, LE V A, PIAMRAT K, et al. Deep learning on network traffic prediction: Recent advances, analysis, and future directions[J]. ACM computing surveys, 2025, 57(6): 1-37.
- [60] PRIMICERI G E. Time varying structural vector autoregressions and monetary policy[J]. The Review of economic studies, 2005, 72(3): 821-852.
- [61] SHUMWAY R H, STOFFER D S. ARIMA models[M]//Time series analysis and its applications: with R examples. Springer, 2017: 75-163.
- [62] XUE H, YANG Q, CHEN S. SVM: Support vector machines[M]//The top ten algorithms in data mining. Chapman and Hall/CRC, 2009: 51-74.
- [63] SHI X, CHEN Z, WANG H, et al. Convolutional LSTM network: A machine learning approach for precipitation nowcasting[J]. Advances in neural information processing systems, 2015, 28.
- [64] WU Z, PAN S, LONG G, et al. Graph wavenet for deep spatial-temporal graph modeling[J]. arXiv preprint arXiv:1906.00121, 2019.
- [65] ZHENG C, FAN X, WANG C, et al. Gman: A graph multi-attention network for traffic prediction[C]//Proceedings of the AAAI conference on artificial intelligence, 2020, 34: 1234-1241.
- [66] BAI L, YAO L, LI C, et al. Adaptive graph convolutional recurrent network for traffic forecasting[J]. Advances in neural information processing systems, 2020, 33: 17804-17815.
- [67] WU Z, PAN S, LONG G, et al. Connecting the dots: Multivariate time series forecasting with graph neural networks[C]//Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 2020: 753-763.
- [68] DENG J, CHEN X, JIANG R, et al. St-norm: Spatial and temporal normalization for multi-variate time series forecasting[C]//Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining. 2021: 269-278.
- [69] SHAO Z, ZHANG Z, WANG F, et al. Spatial-temporal identity: A simple yet effective baseline for multivariate time series forecasting[C]//Proceedings of the 31st ACM international conference on information & knowledge management. 2022: 4454-4458.
- [70] FANG Y, QIN Y, LUO H, et al. STWave+: A Multi-Scale Efficient Spectral Graph Attention Network With Long-Term Trends for Disentangled Traffic Flow Forecasting[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 36(6): 2671-2685.
- [71] BARBER D, CEMGIL A T, CHIAPPA S. Bayesian time series models[M]. Cambridge University Press, 2011.
- [72] HAUSMAN D M, WOODWARD J. Independence, invariance and the causal Markov condition[J]. The

British journal for the philosophy of science, 1999, 50(4): 521-583.

[73] WENG W, FAN J, WU H, et al. A decomposition dynamic graph convolutional recurrent network for traffic forecasting[J]. Pattern Recognition, 2023, 142: 109670.

致谢

行文至此，落笔为终。意味着我的硕士生涯即将画上句号。回首研究生三年，百感交集。

首先，我要向我的恩师牛云云教授致以最崇高的敬意和最衷心的感谢。从论文的选题、构思到定稿，每一步都离不开牛老师的悉心指导。您严谨的治学态度、渊博的专业知识和平易近人的人格魅力，不仅让我在学术上受益匪浅，更将是我未来职业生涯中学习的楷模。

感谢人工智能学院的所有授课老师，感谢你们在开题和预答辩中提出的宝贵意见，让我的论文得以不断完善。

感谢我的同门、师兄师姐以及我的室友。在无数个挑灯夜战的日子里，是你们的陪伴和鼓励让我感受到了温暖。

特别感谢我的父母。你们永远是最坚强的后盾，感谢你们二十多年来的养育之恩，以及对我学业无条件的支持与理解。

最后，感谢那个曾经努力过的自己。凡是过往，皆为序章。我将带着这份感恩，奔赴下一场山海。

附录

一、个人信息：

杜松芝，女，2000年10月出生，河南商丘人，中共党员。2019年9月-2023年6月于河南中医药大学信息技术学院攻读学士学位，专业为计算机科学与技术；2023年9月-2026年6月于中国地质大学（北京）人工智能学院攻读硕士学位，专业为计算机技术，研究方向为智能交通流预测。

二、教育背景：

2023.09-2026.06：中国地质大学(北京)

2019.09-2023.06：河南中医药大学

三、科研成果：

非第一作者 2 篇

1) Zhu G, Niu Y, Du S, et al. Dynamic graph convolutional recurrent network with spatiotemporal category information embedding for traffic flow prediction[J]. IEEE Internet of Things Journal, 2024, 11(24): 39473-39486.

2) Zhu G, Zhang X, Niu Y, et al. Multiscale Spatiotemporal Graph Convolutional Networks With Dynamic Delay Awareness for Traffic Forecasting[J]. IEEE transactions on neural networks and learning systems, 2025.

计算机软件著作权（1 项）

1) 交通流数据融合与动态预测管理系统