

分类号

密级

中国地质大学（北京）  
专业硕士学位论文

面向遥感图像检索的语义增强和特征  
自适应融合方法研究

研究生 王鹏程 学 号 2104230027

专业学位类别 电子信息 专 业 计算机技术

校内导师 牛云云 产业导师 张永虹

学习方式 全日制

2026 年 4 月

**A Dissertation Submitted to  
China University of Geosciences for Master of Professional  
Degree**

**Research on Semantic Enhancement and Adaptive Feature  
Fusion Methods for Remote Sensing Image Retrieval**

**Master Candidate: Pengcheng Wang**

**Professional Degree: Electronic and Information Engineering**

**Dissertation Supervisor: Prof. Yunyun Niu**

**Associate Supervisor: Yonghong Zhang**

**China University of Geosciences (Beijing)**

# 声 明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国地质大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签 名：\_\_\_\_\_日 期：\_\_\_\_\_

## 关于论文使用授权的说明

本人完全了解中国地质大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。延期公开的论文在到期公开后应遵守此规定。

签 名：\_\_\_\_\_导师签名：\_\_\_\_\_日 期：\_\_\_\_\_



## 摘要

随着遥感技术的飞速发展，遥感图像数据规模呈爆炸式增长。海量数据在提供丰富对地观测信息的同时，也对图像的高效组织与精准检索提出了严峻挑战。深度哈希学习凭借其强大的特征表示能力和极高的运算效率，成为当前大规模遥感图像检索（RSIR）的主流技术方案。然而，遥感图像具有视角多变、地物尺度跨度大、背景纹理复杂等固有属性，导致判别性特征提取困难，且底层视觉特征与高层语义之间存在显著的语义鸿沟。这些特性使得传统深度哈希方法在特征表示的精细度与鲁棒性方面仍存在局限，难以满足复杂场景下的检索需求。针对上述挑战，本文深入研究了面向遥感图像的高效深度哈希检索算法，主要研究内容如下：

（1）针对遥感图像中同质化背景面积大、目标信息易被噪声淹没的问题，本文提出了特征解耦引导的联合注意力深度哈希检索方法（FDG-JA）。该方法引入频域解耦骨干网络，利用离散小波变换实现背景平滑信息与高频结构信息的解耦分离；并进一步通过特征解耦门控模块生成纯净先验信号，引导空间与通道双向注意力机制聚焦判别性语义区域。该机制有效抑制了背景噪声，显著提升了特征提取的纯度与语义保真度。

（2）针对遥感地物尺度变化剧烈、几何分布非对称导致目标边界难以精准锚定的难题，在 FDG-JA 算法基础上，本文提出了分层非对称感知与尺度自适应融合的深度哈希检索方法（AP-THNet）。该方法构建了层次化非对称感知架构，利用带状池化精准建模大长宽比及不规则目标的几何骨架，有效抑制冗余背景；同时设计金字塔特征融合与重校准机制，实现了微观细节与宏观语义的深度对齐。最后，结合联合度量优化策略指导哈希码学习，增强其类别区分度，确保了模型在极端尺度变化下的检索鲁棒性。

（3）本文在 UCMD、AID 和 NWPU-RESISC45 遥感图像基准数据集上进行了系统的实验验证。结果显示所提方法在不同位长下的平均检索精度均优于现有的深度哈希算法。尤其在 AP-THNet 方法的高维编码下，MAP 分别达到了 99.54%，97.98%和 97.08%。特别是在类别规模最大、地物分布最为复杂的 NWPU-RESISC45 数据集上，本算法表现出优异的抗干扰能力与泛化鲁棒性。结合 t-SNE 高维特征可视化、注意力热力图分析以及检索结果 Top-K 定性对比，充分验证了本文方法在大规模遥感图像检索中的优秀性能。

**关键词：**遥感图像检索，深度哈希学习，特征解耦，非对称感知，多尺度融合

## Abstract

With the rapid advancement of remote sensing technology, the volume of remote sensing image data has experienced explosive growth. While this massive volume of data provides rich information for Earth observation, it also poses formidable challenges regarding the efficient organization and precise retrieval of images. Leveraging its powerful feature representation capabilities and exceptional computational efficiency, deep hashing learning has emerged as the dominant technical solution for large-scale remote sensing image retrieval (RSIR). However, remote sensing images possess inherent attributes—such as variable viewpoints, objects spanning a wide range of scales, and complex background textures—that render the extraction of discriminative features difficult and create a significant "semantic gap" between low-level visual features and high-level semantics. These characteristics mean that traditional deep hashing methods still exhibit limitations in terms of feature representation granularity and robustness, making it difficult for them to satisfy retrieval demands in complex scenarios. Addressing these challenges, this thesis conducts an in-depth investigation into efficient deep hashing retrieval algorithms tailored for remote sensing images; the primary contributions are outlined as follows:

(1) To address the issues prevalent in remote sensing images—specifically, the large areas of homogeneous background and the tendency for target information to be obscured by noise—this thesis proposes a Feature Decoupling-Guided Joint Attention Deep Hashing Retrieval method (FDG-JA). This method introduces a frequency-domain decoupling backbone network that utilizes the Discrete Wavelet Transform to decouple and separate background smoothing information from high-frequency structural information. Furthermore, a feature decoupling gating module is employed to generate "pure" prior signals, which guide a dual spatial-channel attention mechanism to focus on discriminative semantic regions. This mechanism effectively suppresses background noise, thereby significantly enhancing the purity and semantic fidelity of the extracted features.

(2) To tackle the difficulties associated with the drastic scale variations and asymmetric geometric distributions of remote sensing objects—which make the precise localization of object boundaries challenging—this thesis proposes an Asymmetric Perception and Scale-Adaptive Fusion Deep Hashing Retrieval method (AP-THNet). This method constructs a hierarchical asymmetric perception architecture that utilizes strip pooling to accurately model the geometric

skeletons of objects with large aspect ratios or irregular shapes, thereby effectively suppressing redundant background information. Simultaneously, a pyramidal feature fusion and recalibration mechanism is designed to achieve deep alignment between fine-grained details and high-level semantics. Finally, a joint metric optimization strategy is incorporated to guide the learning of hash codes, enhancing their class discriminability and ensuring the model's retrieval robustness even under extreme scale variations.

(3) This thesis conducts systematic testing and multi-dimensional experimental validation on the UCMD, AID, and NWPU-RESISC45 remote sensing image benchmark datasets. The results demonstrate that the proposed method achieves superior average retrieval precision across various bit lengths compared to existing deep hashing algorithms. Notably, under the high-dimensional encoding scheme of the AP-THNet method, the MAP reached 99.54%, 97.98%, and 97.08%, respectively. In particular, on the NWPU-RESISC45 dataset—characterized by the largest number of classes and the most complex distribution of ground objects—the proposed algorithm exhibited exceptional resistance to interference and robust generalization capabilities. Furthermore, through a combination of t-SNE visualization of high-dimensional features, attention heatmap analysis, and a qualitative Top-K comparison of retrieval results, the superior performance of the proposed method in large-scale remote sensing image retrieval has been thoroughly validated.

**Key words:** Remote Sensing Image Retrieval, Deep Hashing Learning, Feature Decoupling, Asymmetric Perception, Multi-scale Fusion

# 目 录

|                                  |          |
|----------------------------------|----------|
| 摘要 .....                         | 1        |
| <b>Abstract .....</b>            | <b>2</b> |
| 1 绪论 .....                       | 1        |
| 1.1 研究背景和意义 .....                | 1        |
| 1.2 国内外研究现状 .....                | 2        |
| 1.2.1 基于人工特征的遥感图像检索方法 .....      | 2        |
| 1.2.2 基于深度学习的遥感图像检索方法 .....      | 4        |
| 1.3 论文主要工作 .....                 | 8        |
| 1.4 论文结构组织 .....                 | 8        |
| 2 相关理论基础 .....                   | 10       |
| 2.1 基于内容的图像检索 .....              | 10       |
| 2.2 注意力机制 .....                  | 11       |
| 2.2.1 通道注意力机制 .....              | 12       |
| 2.2.2 空间注意力机制 .....              | 13       |
| 2.2.3 自注意力机制 .....               | 14       |
| 2.3 多尺度机制 .....                  | 16       |
| 2.3.1 特征金字塔网络 .....              | 16       |
| 2.3.2 多尺度卷积与空洞卷积 .....           | 17       |
| 2.3.3 渐进式多尺度机制 .....             | 19       |
| 2.4 对比学习 .....                   | 20       |
| 2.4.1 对比损失 .....                 | 20       |
| 2.4.2 三元组损失 .....                | 21       |
| 2.4.3 InfoNCE 损失 .....           | 22       |
| 2.5 本章小结 .....                   | 24       |
| 3 基于特征解耦引导的联合注意力遥感深度哈希检索方法 ..... | 25       |
| 3.1 引言 .....                     | 25       |
| 3.2 算法框架 .....                   | 25       |
| 3.2.1 特征提取模块 .....               | 27       |



|                                      |    |
|--------------------------------------|----|
| 3.2.2 特征增强模块 .....                   | 28 |
| 3.2.3 哈希生成模块 .....                   | 30 |
| 3.2.4 损失函数模块 .....                   | 31 |
| 3.3 实验与分析 .....                      | 32 |
| 3.3.1 数据集介绍 .....                    | 32 |
| 3.3.2 评价指标 .....                     | 34 |
| 3.3.3 实验设置 .....                     | 36 |
| 3.3.4 消融实验 .....                     | 37 |
| 3.3.5 算法对比分析 .....                   | 38 |
| 3.3.6 检索结果可视化 .....                  | 41 |
| 3.4 本章小结 .....                       | 44 |
| 4 基于分层非对称感知与尺度自适应融合的遥感深度哈希方法研究 ..... | 46 |
| 4.1 引言 .....                         | 46 |
| 4.2 算法框架 .....                       | 47 |
| 4.2.1 分层骨干网络模块 .....                 | 48 |
| 4.2.2 层次化非对称感知模块 .....               | 49 |
| 4.2.3 特征融合与 RSA 重校准模块 .....          | 51 |
| 4.2.4 哈希编码与优化模块 .....                | 53 |
| 4.3 实验与分析 .....                      | 56 |
| 4.3.1 实验设置 .....                     | 56 |
| 4.3.2 消融实验 .....                     | 57 |
| 4.3.3 算法对比分析 .....                   | 59 |
| 4.3.4 超参数分析 .....                    | 62 |
| 4.3.5 特征可视化分析 .....                  | 63 |
| 4.3.6 检索结果可视化 .....                  | 66 |
| 4.4 本章小结 .....                       | 68 |
| 5 总结与展望 .....                        | 70 |
| 5.1 总结 .....                         | 70 |
| 5.2 展望 .....                         | 71 |

|           |    |
|-----------|----|
| 参考文献..... | 72 |
| 致谢.....   | 79 |
| 附录.....   | 80 |

# 1 绪论

## 1.1 研究背景和意义

随着航天观测技术的飞速变革，以高分系列、Sentinel 系列为代表的对地观测卫星星座已构建起覆盖全球的周期性监测网络，驱动遥感数据迈入 PB 级爆发式增长的大数据时代<sup>[1][2][3]</sup>。这些海量影像在国土资源调查、环境监测及应急响应等领域发挥着愈发关键的作用。然而如何从数以亿计的异构数据中高效检索目标影像，已成为制约遥感数据应用效能的瓶颈<sup>[4]</sup>。传统依赖人工标注元数据的管理方式，不仅在处理海量增量数据时面临高昂的成本与主观性偏差，且无法有效捕捉影像深层的视觉内容，难以支撑以图搜图等对语义内容高度敏感的实际需求<sup>[5][6]</sup>。

在此背景下，基于内容的图像检索技术（CBIR）因摆脱了对人工标注的依赖而备受关注<sup>[7][8]</sup>。然而，早期基于手工特征的 CBIR 方法表达能力有限，难以有效刻画遥感图像复杂的语义内涵，检索性能在实际应用中往往差强人意<sup>[7]</sup>。深度学习技术的兴起为遥感图像检索领域带来了新的突破契机。以卷积神经网络（CNN）为代表的深度模型，通过端到端的特征学习方式，能够从大量图像数据中自动挖掘出层次化的语义表征，有效克服了手工特征的局限性<sup>[9][10]</sup>。在此基础上发展起来的深度哈希学习方法，将深度特征学习与哈希编码有机结合，通过将图像映射为紧凑的二值哈希码，在大幅压缩存储空间的同时实现了亚线性时间复杂度的快速检索，为大规模遥感图像检索提供了切实可行的解决思路，并在近年来的研究中取得了一系列令人瞩目的成果<sup>[11][12][13][14]</sup>。

尽管如此，遥感图像检索任务本身的特殊性使得该问题未得到根本解决。首先，遥感影像采用垂直俯视角成像，地物目标具有明显的旋转不变性要求，且缺乏中心主体，背景噪声干扰剧烈<sup>[15][16]</sup>；其次，影像中存在严重的同物异谱与异物同谱现象，即同类地物受季节、气候、地域影响导致类内差异大，而不同地物因表观接近导致类间差异小<sup>[17][18]</sup>；再者，地物目标具有极端的跨尺度性，从单体建筑到连片农田，其尺度跨度可达数个量级<sup>[19][20]</sup>。这些特点共同决定了遥感图像特征提取的复杂性，也是当前主流检索方法性能提升的主要制约因素<sup>[4][19]</sup>。

从更深层次来看，现有遥感图像检索方法普遍面临语义鸿沟问题的困扰。底层视觉特征与高层语义概念之间存在天然的鸿沟，简单的特征提取网络往往只能捕捉图像的表观信息，而难以理解图像所蕴含的深层语义<sup>[21][22]</sup>。以一幅包含居民区的高分辨率遥感图像为例，

其底层特征可能与某些工业区图像高度相似，但两者在语义上却截然不同。如何设计更具表达力的特征提取架构，使模型在学习底层视觉特征的同时有效感知高层语义信息，是当前遥感图像检索研究的核心任务<sup>[8][19][21][23]</sup>。

开展高性能遥感图像检索方法研究具有重要的理论价值与实践意义。针对遥感影像尺度跨度大、类内差异显著等特有挑战，探索更具判别力的深度特征提取与高效哈希索引机制，能够有效缓解底层视觉特征与高层地物语义不匹配的难题，为大规模数据的快速处理提供可行方案<sup>[11][12][19]</sup>。从实际应用来看，构建精准、响应迅速的检索体系，能将研究人员从繁重的人工筛选与目视解译中解放出来，大幅缩短信息提取周期，提升遥感数据在防灾减灾、城市规划等领域的实战效能<sup>[3][4][24]</sup>。

## 1.2 国内外研究现状

遥感图像检索方法的发展历程与图像处理技术及人工智能技术的演进轨迹高度吻合，大致经历了从基于传统人工特征到基于深度学习特征的范式转变。本节从上述两个阶段出发，系统梳理国内外遥感图像检索领域的代表性研究工作，分析各类方法的核心思路、技术优势及现存不足，为后续方法设计提供依据。

### 1.2.1 基于人工特征的遥感图像检索方法

早期的遥感图像检索研究主要依赖人工设计的视觉特征描述子，通过提取图像的颜色、纹理、形状等底层统计信息来度量图像间的相似性<sup>[25]</sup>。这一阶段的研究奠定了图像检索的基本范式，但也逐渐暴露出人工特征固有的表达瓶颈。

颜色是图像最直观的视觉属性之一，也是早期图像检索研究中应用最为广泛的特征类型<sup>[26]</sup>。Swain 等人<sup>[25]</sup>最早将颜色直方图引入图像检索任务，通过统计图像中各颜色区间的像素分布来表征图像的整体色调信息。此后，研究者相继提出颜色矩、颜色相关图等改进描述子，在一定程度上引入了颜色的空间分布信息，弥补了颜色直方图忽略空间关系的不足<sup>[27][28]</sup>。然而，由于遥感图像的成像质量受传感器类型、成像时间、大气条件等多种因素影响，同一地物在不同时相、不同光照条件下呈现出的颜色差异极为显著<sup>[29]</sup>。因此，颜色特征虽然计算简便，却难以作为遥感图像检索的可靠依据。

纹理特征能够捕捉图像中像素灰度值的空间分布规律，对遥感图像中大面积均质地物（如农田、林地、水体等）具有较好的描述能力，因而在遥感图像检索研究中得到了广泛应用。灰度共生矩阵（GLCM）是最具代表性的纹理统计方法之一，通过建模像素对之间

的灰度共现概率来量化图像的纹理粗糙度、对比度、相关性等属性<sup>[30]</sup>。Gabor 滤波器通过在不同尺度和方向上对图像进行滤波，能够有效提取多方向、多频率的纹理响应，在遥感场景分类与检索中表现出较强的鉴别能力<sup>[31][32]</sup>。此外，局部二值模式（LBP）因其计算效率高、对光照变化具有一定鲁棒性等优点，也在遥感图像特征描述中得到了广泛采用<sup>[33][34]</sup>。然而，纹理特征同样存在明显局限。遥感图像中地物类型繁多，不同类别的地物有时呈现出高度相似的纹理模式，仅凭纹理信息难以实现有效的语义区分<sup>[4][35]</sup>。更重要的是，上述纹理描述子均为全局或局部统计量，缺乏对图像结构信息的整体建模能力，在面对类内差异显著的复杂遥感场景时，检索精度往往难以令人满意<sup>[19]</sup>。

形状特征主要针对图像中的目标轮廓与结构信息进行描述，在包含特定人造目标（如机场、港口、桥梁等）的遥感图像检索中具有一定的应用价值。方向梯度直方图（HOG）通过统计图像局部区域内梯度方向的分布来刻画目标的边缘结构，对遥感图像中规则形状的人造目标具有较好的描述能力<sup>[36][37]</sup>。尺度不变特征变换（SIFT）通过检测图像中的关键点并构建局部梯度描述子，在一定程度上实现了对尺度变化和旋转变换的不变性，被广泛用于遥感图像的局部特征匹配与检索<sup>[38][39]</sup>。然而值得注意的是，遥感图像的俯视成像视角与自然图像存在本质差异，地物目标通常缺乏清晰的主体轮廓，且受分辨率限制，许多目标的形状细节难以有效提取。此外，形状特征对图像分割质量高度敏感，而遥感图像中复杂的背景环境给精确的目标分割带来了极大挑战，进一步制约了形状特征在实际检索中的应用效果。

为克服单一特征描述能力不足的问题，研究者尝试将颜色、纹理、形状等多种特征进行融合，以期获得更为全面的图像表征。Yue 等人<sup>[40][41]</sup>将颜色直方图与 Gabor 纹理特征拼接为联合特征向量，并引入相关反馈机制来动态调整各特征维度的权重，在一定程度上提升了检索的交互性与精度。Newsam 等人<sup>[42]</sup>则提出利用多尺度纹理特征对遥感场景进行层次化描述，通过在不同分辨率层次上提取 Gabor 特征并加以融合，改善了对复杂遥感场景的表征能力。尽管多特征融合策略在一定程度上缓解了单一特征的局限性，但这类方法本质上仍未跳出人工设计特征的框架。融合后的特征维度往往较高，带来了显著的存储与计算开销<sup>[43]</sup>；更关键的是，各特征分量之间的最优融合权重难以自动确定，通常依赖大量先验知识或繁琐的人工调参，泛化能力十分有限<sup>[19][21]</sup>。

纵观基于传统人工特征的遥感图像检索研究，这一阶段的方法在特定场景下验证了视觉特征用于图像检索的可行性，并积累了宝贵的工程经验。但从根本上来看，人工设计特

征存在两方面难以克服的内在缺陷：其一，特征的设计依赖研究者的先验知识与经验，难以自适应地捕捉不同遥感场景下的关键判别信息；其二，底层视觉统计量与图像所蕴含的高层语义概念之间存在难以弥合的语义鸿沟，导致检索系统在面对语义复杂、类内差异大的遥感图像时表现乏力。这些局限性促使研究者寻求具备自动特征学习能力的新方法，也直接推动了深度学习技术在遥感图像检索领域的引入与快速发展。

### 1.2.2 基于深度学习的遥感图像检索方法

随着深度学习技术的兴起与快速发展，以卷积神经网络为代表的深度模型凭借其强大的自动特征学习能力，逐渐成为遥感图像检索领域的主流研究范式<sup>[9]</sup>。与人工设计特征相比，深度学习方法能够通过端到端的训练机制，从海量影像中自动挖掘层次化的语义表征<sup>[7]</sup>。根据技术发展脉络与方法侧重点的不同，现有研究可归纳为深度特征提取、注意力机制感知、多尺度特征学习以及深度哈希优化四个主要方向。

卷积神经网络的引入是深度学习进入图像检索领域的直接驱动力。自 AlexNet<sup>[44]</sup>在 ImageNet 大规模视觉识别挑战赛中取得突破以来，以 VGGNet<sup>[45]</sup>、GoogLeNet<sup>[46]</sup>、ResNet<sup>[47]</sup>为代表的深度卷积网络相继被提出，网络的特征提取能力随着结构的演进而持续提升<sup>[9]</sup>。早期研究表明，在自然图像数据集上预训练的 CNN 模型所提取的深度特征，通过迁移学习的方式同样能够有效描述遥感图像的视觉内容，并在遥感场景分类与检索任务中取得了远超传统人工特征的性能表现<sup>[4]</sup>。在此基础上，部分研究者针对遥感图像的特殊性对网络结构进行了定向改造。Tong 等人<sup>[48]</sup>较早系统性地探讨了深度卷积特征在遥感图像检索中的适用性，通过对比不同网络层次输出特征的检索性能，发现中高层特征的语义表达能力显著优于浅层特征，为后续研究提供了重要参考。Deepan 等人<sup>[49]</sup>则通过引入空洞卷积扩大网络的有效感受野，使模型在不损失空间分辨率的前提下获取更为丰富的上下文信息，改善了对大尺度地物目标的特征描述能力。

然而，直接利用 CNN 提取的深度特征用于检索存在明显的实用性瓶颈：一方面，全连接层输出的特征向量维度通常高达数千维，在大规模图像库中进行相似性度量时面临巨大的计算与存储开销，难以满足实际系统对检索效率的要求；另一方面，标准 CNN 结构在设计上以分类任务为导向，提取的特征未必能够最优地服务于检索任务所需的相似性度量，特征的判别性与紧凑性仍有较大提升空间<sup>[50]</sup>。为缓解高维连续特征在大规模检索中的存储与度量负担，一批将深度特征学习和哈希编码统一起来的端到端框架被提出，并逐渐演化为后续遥感深度哈希方法的通用基线。其中，DHN<sup>[51]</sup>通过在卷积特征之上联合优化相似性

保持损失与量化损失，实现从像素到二值码的端到端学习，在多种通用图像检索数据集上显著优于传统浅层哈希方法；DPSH<sup>[52]</sup>直接利用成对相似度标签，同时优化特征提取子网与哈希层，将先特征后编码的流程统一到一个网络中，提高了检索性能和工程简洁性；IDHN<sup>[53]</sup>在此基础上引入软成对相似度，将多标签样本之间的语义重叠程度显式编码进损失函数，在复杂语义场景下取得了更好的排序效果；Greedy Hash<sup>[54]</sup>则从优化视角出发，采用贪心策略在离散空间中直接更新哈希码与网络参数，在保证检索精度的同时显著加快了离散优化收敛。这些通用深度哈希模型为后续面向遥感场景的专门化网络结构与损失设计提供了重要借鉴。

针对 CNN 特征缺乏空间和通道选择性的问题，注意力机制被引入图像特征学习框架，通过引导网络有选择地聚焦于图像中信息量更为丰富的区域或特征通道，显著提升了特征表示的判别能力<sup>[21]</sup>。在通道注意力方向，Hu 等人<sup>[55]</sup>提出的压缩激励网络（Squeeze-and-Excitation Network, SENet）通过全局平均池化对特征图进行通道级压缩，再经由全连接层建模通道间的相互依赖关系，生成各通道的重要性权重并对特征响应进行动态重校准，以极小的参数代价实现了通道特征的自适应选择，相关思想已被广泛引入遥感场景分类与检索网络设计中。在空间注意力方向，卷积块注意力模块（CBAM）在 SENet 的基础上引入了空间维度的注意力建模，通过联合通道与空间两个维度的注意力响应，使网络能够同时感知哪些通道重要与哪些空间位置重要，进一步增强了特征的空间感知能力<sup>[56]</sup>。

近年来，以 Vision Transformer（ViT）<sup>[57]</sup>为代表的自注意力机制在自然图像理解领域取得了令人瞩目的成果，研究者随即将其引入遥感图像处理与检索任务中。自注意力通过建模图像中任意位置对之间的长程依赖关系，突破了卷积操作局部感受野的限制，能够有效捕捉遥感图像中地物目标之间的全局空间关联。基于此，部分工作将自注意力结构嵌入深度哈希框架，从全局语义关系建模出发优化检索性能。例如，SCFR<sup>[58]</sup>在主干网络中引入全局-局部双分支结构，分别聚合图像整体场景语义与关键区域细节，并通过监督对比学习约束拉近同类样本、推远异类样本，使得在生成哈希码前特征空间已具备较好的语义分离性。实验表明，SCFR 在多个遥感场景数据集上取得了优于传统卷积结构的检索性能，说明在特征学习阶段显式结合注意力与对比学习，有助于缩小遥感影像底层表现与高层语义之间的鸿沟。

然而，Transformer 模型对训练数据量的需求较大，且计算复杂度随图像分辨率增加呈二次方增长，在高分辨率遥感图像场景下面临较大的计算压力<sup>[57]</sup>。同时，现有多数注意力

方法往往在单一尺度特征图上施加注意力约束，难以兼顾尺度变化巨大的地物目标。如何在保持全局建模优势的同时控制计算成本，并将通道/空间注意力与多尺度特征学习有机融合，实现跨尺度的自适应特征感知，是当前研究中的突出难点。

针对遥感影像中地物目标尺度差异悬殊的挑战，多尺度特征学习成为另一研究热点。小型目标（如单体车辆、独立建筑）与大型目标（如机场跑道、湖泊水体）可能同时出现在同一幅图像中，这对特征提取网络的多尺度感知能力提出了较高要求。单一尺度的特征提取策略在面对这类场景时往往顾此失彼，难以同时保证对细粒度局部信息与宏观语义信息的有效捕捉<sup>[33]</sup>。特征金字塔网络（Feature Pyramid Network, FPN）<sup>[59]</sup>是多尺度特征学习领域最具代表性的工作之一，通过自顶向下的特征融合路径将高层语义信息逐步传递至低层特征图，在保留空间细节的同时丰富了浅层特征的语义内涵。研究者将 FPN 结构引入遥感图像检索任务，通过融合不同层次的金字塔特征构建多尺度联合表征，有效改善了检索系统对不同尺度目标的识别能力<sup>[60]</sup>。Wang 等人<sup>[61]</sup>进一步提出多分支并行特征提取框架，通过在不同感受野范围内并行提取特征并加以自适应融合，使网络能够同时感知不同尺度下的地物信息，在多个遥感图像检索基准数据集上取得了竞争性的性能表现。

在此基础上，一些工作开始尝试将多尺度特征学习与哈希编码过程更紧密耦合。例如，FAH<sup>[62]</sup>学习框架面向内容检索任务显式划分深特征学习模块和对抗式哈希学习模块：前者通过卷积网络融合多尺度、多视角的遥感场景语义信息，后者利用对抗训练优化哈希码分布的均衡性和位间独立性。这类“多尺度语义-哈希一体化”策略表明，多尺度信息不仅可用于提升分类/检测性能，同样能够为后续高效索引与相似性检索提供更适宜的表征基础。

需要指出的是，现有多尺度特征学习方法大多采用静态的特征融合策略，各尺度特征的融合权重在训练完成后即固定不变，缺乏针对具体图像内容动态调整尺度感知侧重点的能力<sup>[63]</sup>。在遥感图像场景高度多样、地物分布极不均衡的条件下，这种静态融合方式的适应性明显不足，难以在不同类型场景下均保持稳定的特征提取和检索性能。如何结合注意力或元学习机制，在多尺度特征层面实现更细粒度的自适应选择，是多尺度遥感检索方法的重要发展方向。

尽管上述方法在特征提取质量上取得了显著进步，但高维连续特征向量在大规模检索场景下面临的存储与计算效率问题始终未得到根本解决。深度哈希学习方法通过将图像映射为紧凑的二值哈希码，利用汉明距离代替欧氏距离进行相似性度量，将检索的时间复杂度降至亚线性级别，为大规模遥感图像的高效检索提供了切实可行的技术路径，因而受到



了广泛关注<sup>[50][64]</sup>。

在无监督哈希方法方面，局部敏感哈希（LSH）<sup>[65]</sup>通过随机投影将相似的数据点以高概率映射至相同的哈希桶中，是最早被应用于图像检索的哈希方法之一，但其检索精度对哈希函数的随机性依赖较强，性能上限有限。迭代量化哈希（ITQ）<sup>[66]</sup>通过最小化量化误差来优化哈希码的生成过程，在无监督方法中取得了相对较好的检索性能，但仍受限于未能利用类别语义信息的固有缺陷。有监督深度哈希方法的出现从根本上改变了这一局面。深度监督离散哈希（DSDH）<sup>[67]</sup>将离散约束直接纳入网络训练过程，有效缓解了连续松弛带来的量化误差问题；HashNet<sup>[68]</sup>通过连续性激活函数的渐进式收紧策略，在保证梯度可传播的前提下逼近离散哈希码，在多个图像检索基准上取得了出色表现；CSQ<sup>[69]</sup>则抛弃了传统的成对或三元组相似性监督方式，直接为每个类别分配语义哈希中心，并优化样本与其中心之间的中心相似性，显著提升了哈希码的语义一致性和检索稳定性。

针对遥感图像的特殊性，研究者在上述通用框架基础上进行了进一步的定制化探索。Li 等人<sup>[70]</sup>将遥感图像的多标签语义信息引入哈希学习过程，通过设计多标签感知的哈希损失函数，使生成的哈希码能够同时反映图像的多维语义属性。Tan 等人<sup>[71]</sup>则将对对比学习思想引入遥感图像哈希检索，通过构建正负样本对来强化哈希码的类间区分能力，在小样本遥感场景下取得了较为稳健的检索性能。更进一步，DGSSH<sup>[72]</sup>从全局语义结构保持出发，基于 Swin Transformer 提取全局上下文特征，并通过校正三元组损失在哈希空间中同时约束局部邻域相似性与全局类间结构关系，在多种遥感场景数据集上取得了优于通用方法的检索性能。AHCL<sup>[73]</sup>则突破了传统查询库对称编码的框架，为查询特征与数据库特征分别学习不同的哈希映射，以降低大规模数据库侧的量化误差并提高检索效率，特别适用于遥感图像库规模巨大、类别分布不均的场景<sup>[74]</sup>。FAH<sup>[21]</sup>等“特征-哈希一体化”框架通过专门设计的特征子网与对抗式哈希子网联合优化，使得所学哈希码在保持判别性的同时具备更好的分布均衡性与位间独立性。此外，前述 SCFR<sup>[58]</sup>在特征学习阶段就通过对比学习与全局-局部特征融合显式增强了哈希表征的区分性，也可视为深度哈希优化方向的重要组成部分。

尽管包括 DHN、DPSH、IDHN、CSQ 以及 DGSSH、AHCL、FAH、SCFR、CIDH 等在内的一系列深度哈希方法，分别从网络结构、量化策略、全局语义保持和对比学习等角度推动了遥感图像检索性能的持续提升，但现有框架在实现统一建模时仍存在明显的共性瓶颈。首先，在特征提取层面，多数方法对多尺度信息的建模尚不充分，难以自适应地应

对遥感图像中地物目标尺度跨度巨大的挑战<sup>[75]</sup>；其次，在注意力机制层面，现有工作多局限于单一尺度上的约束，缺乏跨尺度的层次化特征感知能力<sup>[19]</sup>；在哈希优化层面，损失函数未能有效兼顾类间分离性与类内紧凑性的协同约束，在一定程度上制约了哈希码语义质量与检索精度的进一步提升<sup>[76]</sup>。

### 1.3 论文主要工作

针对现有遥感图像检索方法在复杂背景干扰、非对称几何感知以及哈希空间优化策略等方面存在的不足，本文深入开展了面向大规模遥感图像的深度哈希检索研究。本文以特征解耦与多尺度几何感知两大核心技术为驱动，构建了两种深度哈希检索框架，共同构成了一套完整的遥感图像检索解决方案。本文的主要工作与创新点可归纳为以下三个方面：

(1) 提出了基于特征解耦引导的联合注意力遥感深度哈希检索方法 (FDG-JA)：为突破复杂背景导致特征提取纯度不足的瓶颈，本文构建了频域与语义双重解耦机制。在物理频域层，引入离散小波变换分离高、低频子带，初步剥离冗余平滑背景；在高级语义层，创新设计了特征解耦门控 (FDG) 模块以生成纯净先验信号，进而引导空间-通道双向注意力机制自适应聚焦核心目标。该机制显著提升了哈希量化前的特征纯度，有效缓解了语义漂移现象。

(2) 构建了基于分层非对称感知与尺度自适应融合的深度哈希网络 (AP-THNet)：针对目标尺度剧变与非对称几何形态。在网络结构上，设计了层次化非对称感知模块 (HAP)，利用带状池化精准锚定不规则目标的几何骨架；同时引入尺度自适应重校准 (RSA) 模块动态重分配跨尺度通道权重，实现微观与宏观语义的深度聚合。在度量优化上，使用了修正圆损失与中心聚类损失协同优化的双重度量策略，同步强化了哈希空间的类间排斥与类内紧凑性，大幅增强了模型对极端几何畸变的鲁棒性。

(3) 进行了多维度的检索性能评估与视觉感知机理解释：本文在 UCMD、AID 和 NWPU-RESISC45 三大遥感图像基准数据集上，开展了横向对比与消融实验。定量结果证实，所提两套框架在不同哈希码长下均取得了优于现有前沿方法的检索精度。在定性分析方面，本文综合运用 t-SNE 特征流形可视化、Grad-CAM 注意力热力图及 Top-K 检索实例，从底层视觉感知到高层数学度量空间验证了本文特征学习与优化策略的有效性。

### 1.4 论文结构组织

本文共分为五章，各章节内容安排如下：

第一章为绪论，首先阐述了遥感图像检索的研究背景与应用价值，明确了海量遥感数据背景下检索任务所面临的技术挑战；随后系统梳理了国内外研究现状，重点分析了基于人工特征与基于深度学习的遥感图像检索方法的发展脉络与现存瓶颈；在此基础上，明确本文的研究内容与技术路线，概述所提出方法的主要创新点。

第二章为相关理论基础，介绍本文涉及的核心理论与技术体系。首先介绍了基于内容的图像检索的基本流程与核心概念；随后重点论述了本文模型构建所依赖的关键技术，包括注意力机制、多尺度机制，以及对比学习相关的基本原理和算法模型。

第三章提出了一种基于特征解耦引导的联合注意力遥感深度哈希检索方法。针对遥感图像背景复杂导致核心目标容易被淹没的问题，设计了一种名为 FDG-JA 的哈希检索框架。阐述了频域解耦特征提取模块、基于特征解耦门控（FDG）的特征增强模块、哈希生成模块以及损失函数模块的具体设计。最后，在公开遥感数据集上开展了实验配置与性能验证，通过消融实验与检索结果可视化，证实了该方法在剥离背景噪声、提升量化前特征纯度方面的有效性。

第四章提出了一种基于分层非对称感知与尺度自适应融合的遥感深度哈希检索方法。在第三章的基础上实现逻辑与架构的递进，提出 AP-THNet 模型，以解决地物尺度剧烈变化与几何分布高度非对称的难题。深入解释了分层骨干网络、层次化非对称感知模块（HAP）、金字塔特征融合与尺度自适应重校准（RSA）模块的内部机理，并详细推导了哈希空间解码器与双重度量损失函数的设计。通过系统的消融实验、算法对比分析、超参数敏感性评估以及 t-SNE 与 Grad-CAM 特征可视化，证明了该架构在复杂检索任务中的优秀表现。

第五章为总结与展望。主要回顾本文的核心研究内容与主要结果，并结合当前研究的不足之处，探讨未来的改进方向与研究前景。

## 2 相关理论基础

### 2.1 基于内容的图像检索

基于内容的图像检索（Content-Based Image Retrieval, CBIR）是指通过自动分析和提取图像本身的视觉内容特征，以图像的颜色、纹理、形状等底层视觉信息或深度语义信息作为检索依据，从大规模图像数据库找出与查询图像在视觉内容或语义上最为相似的图像集合的技术体系<sup>[77]</sup>。在遥感领域，面对日益庞大的对地观测图像数据库，CBIR 技术的引入为遥感图像的高效管理与智能利用提供了全新的技术路径，并逐渐发展成为遥感信息处理领域的重要研究前沿<sup>[78]</sup>。

从系统工程与信息论的角度来看，一个完整的标准 CBIR 系统通常由图像预处理、特征提取、特征索引、相似性度量与结果排序五个核心模块构成协同反馈闭环<sup>[79]</sup>。设遥感图像数据库为  $\mathcal{I} = \{I_1, I_2, \dots, I_N\}$ ，其中  $N$  为数据库样本总数，给定查询图像为  $I_q$ 。

作为系统的输入前置环节，预处理旨在消除成像过程中的环境干扰，并将图像标准化以适配后续的特征提取网络。针对遥感图像的特殊性，预处理通常包括辐射校正、尺度统一、像素值归一化以及数据增强等。这一阶段有效降低了光照、传感器差异对检索结果的负面影响，提升了系统的鲁棒性。

特征提取是 CBIR 系统的基础与核心环节，其任务是将原始图像矩阵转化为紧凑、有效的数值特征向量，使图像间的语义相似关系能够在特征空间中得到有效的量化表达。设特征映射函数为  $\Phi(\cdot)$ ，则提取过程可表示为  $v = \Phi(I)$ ，其中  $v \in \mathbb{R}^d$ ， $d$  为特征空间的维度。理想的映射函数需要满足两个条件：一是对旋转、尺度差异、背景干扰等类内变化具有较强的鲁棒性；二是具备高度的判别力，能够将不同语义类别的遥感图像在特征空间中有效分离。

在海量遥感数据库中，直接使用实值向量进行全局遍历比对会带来难以承受的计算与存储开销。特征索引模块的作用是对数据库中所有特征向量集合进行离线组织与结构化存储。近年来，为了突破高维连续特征带来的维度灾难，深度哈希（Deep Hashing）索引成为主流范式。该方法通过一个符号量化函数  $\text{sgn}(\cdot)$ ，将连续特征向量映射为离散的二值哈希码  $H \in \{-1, 1\}^K$  或  $\{0, 1\}^K$ 。这种机制实现了存储空间的极度压缩，并为后续的高效检索奠定了数据结构基础。

相似性度量根据特征空间中的距离来判定图像间的语义相关性。特征空间的性质直接决定了度量方式的选择：

在连续实值特征空间中，最常用的度量标准是余弦相似度。对于任意两个特征向量  $v_1$  和  $v_2$ ，其余弦相似度定义为：

$$\cos(v_1, v_2) = \frac{v_1 \cdot v_2}{\|v_1\| \|v_2\|} \quad (2-1)$$

引入哈希编码后，相似性度量便转移至离散的汉明空间（Hamming Space）。汉明距离  $D_H$  衡量了两个等长二值字符串之间对应位置符号不同的个数。设二值哈希码  $h_1, h_2 \in \{-1, 1\}^K$ ，其汉明距离与内积之间存在严格的数学换算关系：

$$D_H(h_1, h_2) = \frac{1}{2}(K - h_1^T h_2) \quad (2-2)$$

在实际底层硬件中，汉明距离可通过异或操作与比特计数指令在极短的 CPU 时钟周期内完成。这种将欧氏空间的复杂浮点运算转化为位运算的机制，是实现亚线性时间复杂度检索的核心数学原理。

度量完成后，系统需按相似度由高到低对结果进行排序并返回给用户。在实际的大规模深度哈希检索系统中，为了平衡检索速度与检索精度，通常采用粗检-精排的非对称检索策略：首先利用汉明距离在全局数据库中进行极速粗筛选，召回前  $M$  个候选图像（ $M \ll N$ ）；随后，利用未被量化的连续特征（或更深层的语义特征）对这  $M$  个候选图像进行欧氏/余弦距离的精确计算与二次重排。这种级联排序机制既保留了哈希索引的速度优势，又弥补了二值量化带来的信息损失误差。

## 2.2 注意力机制

注意力机制（Attention Mechanism）的核心思想源自人类视觉认知系统的工作方式，人在观察复杂场景时，并非对视野中所有区域给予同等关注，而是有选择地将有限的认知资源聚焦于最具信息价值的局部区域，从而在信息过载的环境下实现高效的场景理解<sup>[80]</sup>。受此启发，深度学习领域的研究者将这一机制引入神经网络的特征表征过程，通过设计可学习的权重分配机制，使网络能够自适应地对不同位置或不同特征通道的响应强度进行动态调整，从而在提取特征时突出关键信息、抑制冗余干扰。

在数学形式上，注意力机制的核心运算可以抽象为一种基于查询（Query）、键（Key）和值（Value）的加权聚合过程。给定查询向量  $q$ 、键向量集合  $K = [k_1, k_2, \dots, k_n]$  以及对应

的值向量集合  $V = [v_1, v_2, \dots, v_n]$ ，注意力输出可表示为：

$$\text{Attention}(q, K, V) = \sum_{i=1}^n \alpha_i v_i \quad (2-3)$$

其中，注意力权重  $\alpha_i$  由查询向量  $q$  与第  $i$  个键向量  $k_i$  的相似度经归一化后得到：

$$\alpha_i = \frac{\exp(f_{\text{sim}}(q, k_i))}{\sum_j \exp(f_{\text{sim}}(q, k_j))} \quad (2-4)$$

这里的  $f_{\text{sim}}(\cdot, \cdot)$  为相似度度量函数，常见形式包括点积（Dot-product）、缩放点积（Scaled Dot-product）及加性多层感知机（Additive MLP）等。上述通用框架在应用于卷积特征图时，根据注意力施加的维度不同，主要衍生出通道注意力、空间注意力和自注意力三种典型形式，三者在建模目标、计算方式及适用场景上各有侧重，共同构成了当前深度视觉特征增强研究的主要技术路径。

### 2.2.1 通道注意力机制

卷积神经网络的特征图是一个三维张量，其通道维度对应网络在不同滤波器作用下提取的特定语义响应。理想情况下，不同通道所承载的特征信息对特定任务的贡献程度应有所差异，但标准卷积操作对所有通道给予同等权重，无法自适应地突出与任务高度相关的关键特征通道。




图 2-1 通道注意力机制结构图

压缩激励网络<sup>[55]</sup>是通道注意力领域最具代表性的工作。如图 2-1 所示，其核心设计由压缩和激励两个步骤构成。在压缩阶段，对输入特征图  $F \in \mathbb{R}^{C \times H \times W}$  进行全局平均池化操作，

将每个通道的空间信息聚合为一个标量，得到通道描述符  $z \in \mathbb{R}^C$ ，其第  $c$  个元素的计算过程如下：

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_c(i, j) \quad (2-5)$$

在激励阶段，为了捕捉各个通道之间的非线性依赖关系，系统将描述符  $z$  送入一个包含降维和升维操作的全连接结构。具体而言，首先通过一个权重参数为  $W_1 \in \mathbb{R}^{\frac{C}{r} \times C}$  的全连接层（FC1）进行维度压缩（其中  $r$  为降维缩放比），经 ReLU 激活函数  $\delta$  处理后，再通过权重参数为  $W_2 \in \mathbb{R}^{C \times \frac{C}{r}}$  的全连接层（FC2）恢复至原始通道维度  $C$ 。最后，经由 Sigmoid 激活函数  $\sigma$  生成最终的通道权重掩码  $M_c \in \mathbb{R}^{C \times 1}$ ：

$$M_c = \sigma(W_2 \delta(W_1 z)) \quad (2-6)$$

这一阶段通过神经网络的自适应学习，显式地建模了通道间的相互关系，计算出每个通道对于当前任务的重要程度。最终，将得到的通道权重  $M_c$  与原始特征图  $F$  进行逐元素相乘，完成特征的自适应重校准，得到输出特征图  $F' \in \mathbb{R}^{C \times H \times W}$ ：

$$F' = M_c \otimes F \quad (2-7)$$

通过上述机制，网络能够更加智能地抑制遥感图像中复杂的背景噪声通道，并显著放大关键地物目标的语义响应。

### 2.2.2 空间注意力机制

与通道注意力关注哪些特征通道更重要不同，空间注意力机制<sup>[81]</sup>聚焦于特征图中哪些空间位置更值得关注，通过对不同空间位置分配差异化的响应权重，引导网络将感知重心集中于图像中语义信息更为丰富的局部区域。卷积块注意力模块（Convolutional Block Attention Module, CBAM）<sup>[56]</sup>提出了一种经典的通道与空间串联协同范式。在通道注意力模块完成特征重校准之后，CBAM 进一步引入了空间注意力分支。给定输入特征图  $F \in \mathbb{R}^{C \times H \times W}$ ，该模块首先沿通道维度分别执行全局平均池化（Average Pooling）和全局最大池化（Max Pooling）。这两种池化操作能够互补地捕获空间信息：平均池化有助于保留整体的背景上下文，而最大池化则能有效提取显著的纹理边缘。这一步骤生成了两个二维的空间描述符  $F_{avg}^s \in \mathbb{R}^{1 \times H \times W}$  和  $F_{max}^s \in \mathbb{R}^{1 \times H \times W}$ 。随后，将这两个描述符在通道维度进行拼接，并

送入一个大感受野的标准卷积层进行通道降维，最后通过 Sigmoid 激活函数生成二维的空间注意力掩码  $M_s(F) \in \mathbb{R}^{1 \times H \times W}$ 。其完整的数学抽象可表示为：

$$M_s(F) = \sigma(f^{7 \times 7}([F_{avg}^s; F_{max}^s])) \quad (2-8)$$

其中， $[:, :]$  表示沿通道维度的拼接操作， $f^{7 \times 7}$  表示滤波器大小为  $7 \times 7$  的卷积操作， $\sigma$  为 Sigmoid 激活函数。最终，生成的空间注意力掩码与输入特征图进行空间维度的逐元素相乘，实现空间特征的自适应增强。




图 2-2 空间注意力机制结构图

对于遥感图像检索任务而言，空间注意力机制具有重要的实用价值。高分辨率遥感影像幅面广阔，包含大面积的冗余背景（如广袤的均质水体、裸地或荒漠）。这些区域对于区分图像核心语义的贡献极低，甚至会作为噪声干扰检索系统在特征空间中的距离度量。空间注意力机制充当了一种自适应的软掩码，能够有效引导网络过滤背景噪声，将有限的特征表达容量集中于建筑群、道路网络或特定目标等核心语义区域，从而显著提升图像整体表征的判别性与纯净度。

### 2.2.3 自注意力机制

自注意力机制（Self-Attention）<sup>[82]</sup>最初由 Vaswani 等人在 Transformer 架构中提出，其核心贡献在于突破了卷积操作固有的局部感受野限制，使模型能够直接建模输入序列中任意两个位置之间的长程依赖关系。

具体而言，给定输入特征序列  $\mathbf{X} \in \mathbb{R}^{N \times d}$ （其中  $N$  为序列长度， $d$  为特征维度），自注意力机制首先通过三个独立的线性投影矩阵  $W_Q, W_K, W_V$  将其映射至不同的特征空间，分别



生成查询矩阵  $Q$ 、键矩阵  $K$  和值矩阵  $V$ 。缩放点积注意力的核心计算过程可表示为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-9)$$

其中， $d_k$  为键向量的特征维度。除以  $\sqrt{d_k}$  的缩放操作目的在于平滑内积结果的方差，防止因点积数值过大而导致 Softmax 函数陷入梯度消失问题，从而保证网络训练的稳定性。

为了进一步增强模型在不同语义维度上的表征潜力，Transformer 引入了多头注意力机制（Multi-Head Attention, MHA）<sup>[82]</sup>。该机制将输入特征投影至  $h$  个相互独立的表示子空间中，在每个子空间内并行执行缩放点积注意力运算。最后，将各头（Head）的输出结果沿通道维度拼接，并经由一个线性变换矩阵  $W^O$  融合为最终输出：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (2-10)$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2-11)$$

这种多头并行设计使模型能够在多个表示子空间中同时捕捉不同粒度与侧重点的特征关联，极大提升了注意力机制的特征表达容量。

视觉 Transformer（Vision Transformer, ViT）将上述机制成功迁移至视觉领域，通过将图像切分为固定大小的图块（Patch）序列并引入位置编码，将二维视觉特征的建模问题转化为序列处理任务，如图 2-3 所示。然而，ViT 的标准实现对大规模训练数据的依赖较强，且计算复杂度  $\mathcal{O}(N^2)$  随输入分辨率的增大呈二次方增长。针对遥感高分辨率图像的处理需求，这一计算代价在实际应用中较为显著，如何在保留全局建模能力的同时有效控制计算开销，是将自注意力机制应用于遥感图像检索时需要重点权衡的工程问题。

遥感影像特殊的俯视成像几何与非结构化地物分布，赋予了注意力机制在该领域的应用必要性。由于高分辨率影像中蕴含极端的尺度跨度，且关键语义目标往往被大面积的背景噪声所淹没，固定权重的传统卷积范式难以自适应地响应该类高度不均匀的信息分布需求。然而，直接将现有注意力模型迁移至遥感检索任务仍面临两项核心瓶颈：一是经典的通道或空间注意力（如 SENet、CBAM）多局限于单一特征尺度上的权重分配，缺乏跨层次的协同感知能力，极易导致多变尺度下语义信息的遗漏；二是具备全局建模能力的自注意力机制（如 ViT）受限于  $\mathcal{O}(N^2)$  的二次方计算复杂度，在处理高分辨率遥感数据时面临难以承受的算力开销与内存瓶颈。




图 2-3 ViT 模型架构图

## 2.3 多尺度机制

尺度问题是计算机视觉领域长期以来的核心挑战之一，在遥感图像分析场景下尤为突出。从成像机理来看，遥感图像的空间分辨率跨越极大：亚米级高分辨率影像中，单栋建筑、单辆车辆等细粒度目标清晰可辨；而中低分辨率影像中，一个像素往往对应数十甚至数百平方米的地表区域，宏观地貌结构才是主要的语义载体。即使在同一幅高分辨率遥感图像中，小型目标（如独立树木、停车场车辆）与大型目标（如机场跑道、湖泊水体、农田斑块）也可能同时出现，两者在图像平面上的像素占比相差数个数量级。这一特点对特征提取网络提出了两个相互制约的要求：一方面，网络需要足够精细的局部感知能力，以捕捉细粒度目标的纹理与形状细节；另一方面，网络又需要足够宏观的全局感知能力，以理解大范围地物的空间布局与语义关联。单一感受野的卷积特征提取策略在两者之间难以兼顾，感受野过小则丢失大尺度上下文，感受野过大则淹没细粒度局部细节。如何在同一特征学习框架内同时满足上述两方面需求，是多尺度特征建模方法所要解决的核心问题。

### 2.3.1 特征金字塔网络

多尺度特征提取的最直接思路是图像金字塔，即对原始输入图像进行多次下采样，分别在不同分辨率层级上提取特征，再将各层级的特征进行融合。这种方式概念清晰，能够在物理层面保证不同尺度信息的独立提取，但代价是每个尺度层级均需执行完整的前向推理过程，推理时间随金字塔层数线性增长，在大规模遥感图像检索场景下实用性较差。

特征金字塔网络 (Feature Pyramid Network, FPN)<sup>[59]</sup> 的提出从根本上改变了这一局面。FPN 的核心洞察在于：卷积神经网络在提取特征的过程中，其内部不同深度的特征图本身就天然构成了一种尺度金字塔结构。FPN 充分利用这一固有的层次性，通过自顶向下的特征融合路径，将深层的高级语义信息逐步上采样并与对应分辨率的浅层特征进行横向融合。设  $C_i$  为骨干网络第  $i$  阶段输出的特征图， $P_i$  为特征金字塔第  $i$  层的输出，其融合过程可形式化表示为：

$$P_i = \text{Conv}_{1 \times 1}(C_i) + \text{Upsample}(P_{i+1}) \quad (2-12)$$

其中， $\text{Conv}_{1 \times 1}$  用于统一通道维度，Upsample 通常采用最近邻插值 (Nearest Neighbor) 或双线性插值进行空间分辨率的上采样对齐。经过融合后，金字塔各级别的特征图同时兼具丰富的局部细节与充分的语义信息，从而克服了浅层语义贫乏与深层空间信息损失的双重困境。FPN 最初面向目标检测任务设计，但其多尺度特征融合的思想被广泛借鉴并引入遥感图像检索、场景分类等下游任务中，成为多尺度特征建模的重要基础框架。




图 2-4 特征金字塔网络图

### 2.3.2 多尺度卷积与空洞卷积

除了利用网络深度方向的层次结构获取多尺度感知能力外，研究者还探索了在同一网络层内并行捕捉多尺度信息的方法，其中多分支多尺度卷积与空洞卷积是两类最具代表性的技术路线。

多分支并行卷积通过在同一网络层内实例化多个具有不同感受野尺寸的卷积分支，分别提取不同粒度的局部语义，随后在通道维度上进行特征融合。如图 2-5(a)所示，GoogLeNet 中的 Inception 模块是该思想的经典范式。其在单一特征提取阶段并行部署了  $1 \times 1$ 、 $3 \times 3$  和

5×5等多种尺度的卷积核。这种设计使得网络在单次前向传播中，能够同时捕获微小目标的边缘响应与较大范围的局部上下文。为了有效控制多分支大卷积核带来的算力激增，该机制通常会引入1×1卷积作为瓶颈层（Bottleneck）进行通道降维，在极大丰富特征多样性的同时保证了网络的高效性。

空洞卷积（又称膨胀卷积）<sup>[83]</sup>则提供了另一种在不引入额外参数和计算量的前提下，有效扩大感受野的优雅方案，如图 2-5(b)所示。在标准卷积中，卷积核的采样点在空间上是连续相邻的；而空洞卷积通过在标准卷积核的相邻权重之间人为插入零值，强制扩大了卷积核的采样步幅。引入空洞率（Dilation Rate）参数后，一个物理尺寸为 $k \times k$ 的标准卷积核，其等效感受野 $R_k$ 的边长可由下式计算得到<sup>[84]</sup>：

$$R_k = (k-1) \times r + 1 \quad (2-13)$$

对于基础尺寸 $k=3$ 的卷积核，当空洞率 $r=1$ 时，其退化为标准卷积，感受野为3×3；当 $r=2$ 时，卷积核覆盖的感受野扩大至5×5；当 $r=3$ 时，感受野进一步扩张至7×7。在整个感受野扩张的过程中，卷积核的实际可学习参数量始终保持为 $3 \times 3 = 9$ 不变。通过合理堆叠不同空洞率的卷积层，或采用并行多分支的空洞空间金字塔池化等模块，网络能够在严格保持特征图空间分辨率的同时，大幅扩大感受野的覆盖区域。这一机制在遥感图像检索与密集预测任务中具有极高的应用价值，它不仅有效增强了模型对大尺度宏观地物的上下文感知能力，还避免了传统池化操作带来的细粒度空间细节丢失问题。




图 2-5 多尺度卷积和空洞卷积

### 2.3.3 渐进式多尺度机制

上述并行多分支机制（如 Inception）大多采用静态独立的特征提取策略，各尺度分支之间缺乏交互。面对遥感图像中复杂交织的地物分布，孤立的尺度感知往往难以保证上下文的语义连贯性。因此，渐进式（或层次化）多尺度特征聚合机制应运而生，其核心思路是将多尺度特征的提取过程分解为若干递进的细粒度步骤，使粗粒度特征的生成建立在细粒度特征的基础之上。

在数学表示上，设输入特征图被沿通道维度均匀切分为  $S$  个子集，记为  $x_1, x_2, \dots, x_S$ 。渐进式感知通过串联的卷积操作实现跨尺度信息传递：

$$y_i = \begin{cases} x_i, & i = 1 \\ \text{Conv}(x_i + y_{i-1}), & 1 < i \leq S \end{cases} \quad (2-14)$$

最终输出：

$$Y = \text{Concat}(y_1, y_2, \dots, y_S) \quad (2-15)$$

进一步审视上述公式，这种渐进式结构的精妙之处在于，它在通道切分的微观层面实现了一种感受野的指数级扩张。在传统的单路径卷积中，感受野的增长是线性的；而在上式中，由于后续分支  $y_i$  在进行卷积前，融合了前置分支  $y_{i-1}$  的输出，这意味着  $y_i$  的等效感受野不仅包含了当前卷积核的覆盖范围，还叠加了  $y_{i-1}$  所累积的所有历史感受野。

具体到遥感图像的物理场景中，这种机制允许网络在  $y_1$  层面聚焦于细粒度的边缘和角点（如独立的房屋个体），在  $y_2$  层面捕获房屋与周围道路的拓扑关系，并在后续更深层的  $y_S$  层面掌握整个街区的宏观功能区属性。通过最终的通道拼接，输出张量  $Y$  中同时蕴含了多个离散感知粒度且语义相互关联的特征子集。这种细粒度引导粗粒度的渐进机制，打破了传统卷积孤立感知的壁垒，支持更灵活的尺度感受野组合，极大增强了网络对复杂多变遥感场景的特征解耦与重组能力。

综上所述，多尺度特征建模在遥感图像检索任务中扮演着至关重要的角色，是连接底层视觉像素与高层复杂语义的核心桥梁。多尺度特征建模机制赋予了网络由微观至宏观的层次化感知能力，使其提取的表征能够同时包容单体建筑的纹理细节与城市街区的宏观拓扑，极大削弱了因查询目标与库中图像尺度不匹配而诱发的语义错位。



更为关键的是，从系统整体链路来看，多尺度特征的构建质量直接决定了后续深度哈希检索的性能上限。将连续特征向量压缩为离散二值哈希码 ( $\{-1, 1\}^K$ ) 不可避免地会引入量化误差。而具备丰富层次性、经过有效解耦的多尺度连续表征，能够为哈希映射网络提供更纯净、判别力更强的先验输入。这从根本上缓解了二值化截断过程中的语义流失，保障了最终生成的哈希码在汉明空间中依然具备极高的语义区分度。

## 2.4 对比学习

对比学习 (Contrastive Learning)<sup>[85]</sup> 是自监督表示学习领域近年来发展最为迅速的方法范式之一，其核心思想是通过构造样本间的相似性关系来驱动特征表示的学习：使语义相近的正样本对在特征空间中相互靠拢，同时使语义差异较大的负样本对在特征空间中相互远离，从而在无需大量人工标注的条件下学习到具有良好判别性的紧凑特征表示。

这一思想的本质是对特征嵌入空间的几何结构施加显式约束：理想的特征空间应当是语义一致的区域彼此聚集、语义不同的区域彼此分离的有序结构，而非随机分散的高维混沌分布。与监督分类学习通过类别标签间接约束特征分布不同，对比学习直接在样本对或样本组的层次上建模特征间的相对关系，更直接地面向特征空间几何结构的优化目标。这一特点使对比学习天然契合图像检索任务在特征空间中进行相似性度量这一核心需求，特征空间的语义组织质量直接决定了检索系统的精度上限。

### 2.4.1 对比损失

经典对比损失<sup>[86]</sup> (Contrastive Loss) 由 Chopra 等人在早期的度量学习研究中正式提出，奠定了基于样本对的度量学习基本范式。该损失函数直接作用于图像对，其优化目标如图 2-6 所示：




图 2-6 对比损失图

设输入样本对为  $(x_i, x_j)$ ，网络提取的对应特征向量为  $f(x_i)$  和  $f(x_j)$ 。定义二者在特征

空间中的欧氏距离为：

$$d(x_i, x_j) = \|f(x_i) - f(x_j)\|_2 \quad (2-16)$$

引入相似性标签  $y$ ，当  $(x_i, x_j)$  为语义相关的正样本对时  $y=1$ ；当其为语义无关的负样本对时  $y=0$ 。经典对比损失函数的数学形式可表示为：

$$L(x_i, x_j, y) = y \cdot \frac{1}{2} d(x_i, x_j)^2 + (1-y) \cdot \frac{1}{2} \max(0, m - d(x_i, x_j))^2 \quad (2-17)$$

正样本对优化（ $y=1$ ）：网络以基准图像（Anchor，记为  $x_1$ ）和正样本（Positive，记为  $x_2$ ）为输入，损失函数通过最小化距离  $d(x_1, x_2)$ ，强迫相似样本在特征空间中相互聚拢（如图中+号所示）。

负样本对优化（ $y=0$ ）：网络以基准图像（Anchor,  $x_1$ ）和负样本（Negative，记为  $x_3$ ）为输入，引入了间隔超参数（Margin,  $m$ ）。只有当负样本对之间的距离  $d(x_1, x_3)$  小于设定的安全间隔  $m$  时，才会产生损失惩罚，迫使它们相互排斥（如图中-号及 margin 边界所示）；若距离已大于  $m$ ，则损失为 0，网络不再对其进行过度优化。

经典对比损失形式简洁且物理意义明确，但其局限性也较为显著：该机制仅考虑孤立的样本两两关系，在面对海量数据时，负样本的组合空间呈爆炸式增长，导致模型在训练时对难负样本的挖掘与利用效率较低，在大规模遥感图像检索数据集上容易遇到性能瓶颈。

## 2.4.2 三元组损失

为了克服经典对比损失仅关注孤立样本对的局限性，三元组损失<sup>[87]</sup>（Triplet Loss）在度量学习中引入了更为复杂的结构。该机制构建了由锚点（Anchor）、正样本（Positive）和负样本（Negative）组成的三元组，通过同时建模正负样本相对于基准锚点的距离关系，来实现对特征空间的联合约束。

如图 2-7 所示，设三元组为  $(x_a, x_p, x_n)$ ，它们在特征空间中的嵌入向量对应为  $f(x_a)$ 、 $f(x_p)$  和  $f(x_n)$ 。定义锚点与正样本之间的距离为  $d_{ap} = \|f(x_a) - f(x_p)\|_2^2$ ，锚点与负样本之间的距离为  $d_{an} = \|f(x_a) - f(x_n)\|_2^2$ 。三元组损失的标准数学形式可表示为：

$$L_{triplet} = \max(0, d_{ap} - d_{an} + m) \quad (2-18)$$

其中， $m$  为设定的间隔超参数（Margin）。




图 2-7 三元组损失图

结合图 2-7 的整体优化过程可以直观地理解其运作机制：网络不再要求正样本对的绝对距离趋近于零，而是要求锚点与负样本之间的距离  $d_{an}$  必须比锚点与正样本之间的距离  $d_{ap}$  至少大出一个安全边界  $m$ 。如果满足  $d_{an} > d_{ap} + m$ ，则当前三元组不产生损失；反之，网络将同时拉近  $x_a$  与  $x_p$ ，并推开  $x_a$  与  $x_n$ 。

三元组损失的巨大优势在于，其相对距离约束的优化逻辑高度贴合实际检索任务的评判标准，系统真正关心的是正确的图像是否排在错误的图像前面，即正样本比负样本更接近查询图像，而并不苛求它们之间的绝对距离为零。然而，三元组损失在实际训练中面临着严峻的工程挑战，其模型性能对负样本挖掘策略高度敏感。由于三元组的组合空间呈立方级数爆炸，如果在训练时采用随机采样，绝大多数三元组都能轻易满足间隔约束，这些简单三元组产生的梯度为零，对网络判别能力的提升毫无贡献；反之，如果过度追求极难负样本，又极易受到数据集中错误标签或异常噪声的干扰，导致训练过程发生震荡甚至模型坍塌。因此，如何设计高效、稳健的难负样本挖掘机制，在挖掘信息量与维持训练稳定性之间取得平衡，是三元组学习方法乃至整个度量检索领域的核心命题。

### 2.4.3 InfoNCE 损失

为了克服三元组损失在负样本利用效率上的瓶颈，InfoNCE<sup>[88]</sup> (Information Noise-Contrastive Estimation) 被提出并迅速成为当前主流视觉对比学习框架(如 MoCo、SimCLR)的核心优化目标。该机制将对比学习问题重构为一种实例级的多分类任务，在包含一个正样本和  $K$  个负样本的庞大候选集合中，网络致力于最大化查询样本与正样本之间的相似度，同时集体抑制查询样本与所有负样本之间的相似度，从而实现特征空间的全局拉扯与优化。其标准的数学形式可表示为如下对数似然损失：



$$L_{\text{InfoNCE}} = -\log \frac{\exp(q \cdot k^+ / \tau)}{\exp(q \cdot k^+ / \tau) + \sum_{i=1}^K \exp(q \cdot k_i^- / \tau)} \quad (2-19)$$

其中， $q$  为基准查询特征（Query）， $k^+$  为与之匹配的正样本特征（Positive Key）， $k_i^-$  为集合中第  $i$  个不匹配的负样本特征，分子与分母中的点积（ $\cdot$ ）代表特征向量间的余弦相似度度量。

公式中的  $\tau$  为极其关键的温度超参数，主要用于调节 Softmax 概率分布的集中程度。温度参数对网络的训练动态具有决定性影响：较小的  $\tau$  值会呈指数级放大样本间的相似度差异，使得模型在计算梯度时自动将重心倾斜于那些距离查询样本最近的难负样本，从而起到隐式的难负样本挖掘作用；而较大的  $\tau$  则会使概率分布趋于平滑，梯度分布更加均匀，有助于提升模型在嘈杂数据下的训练平稳性。

此外，InfoNCE 损失在理论上具有深远的数学意义。研究表明，最小化 InfoNCE 损失严格等价于最大化查询样本  $q$  与正样本  $k^+$  潜在表示之间的互信息下界。这一深层性质从信息论的角度为对比学习提供了坚实的数学保证。对于遥感图像检索而言，这种信息论级别的约束不仅有效避免了模型陷入平凡解，还能促使网络从复杂的背景噪声中剥离出最本质的地物语义，从而提取出兼具紧凑性与高度判别力的鲁棒特征。

对比学习的优化思想与图像检索任务在核心诉求上具有天然的契合度，二者均致力于构建一个语义组织合理、同类紧凑且异类分离的高维特征空间。因此，该思想被迅速引入到图像检索与深度哈希编码的前沿研究中。在深度度量学习方向，对比学习通过正负样本的自监督或弱监督构造，赋予了模型对视角、光照及局部遮挡等复杂变换极强的鲁棒性，显著提升了特征的泛化能力。在哈希学习领域，对比学习则为打破传统离散优化的瓶颈提供了全新视角。例如，中心相似哈希（CSQ）等方法通过构建语义哈希中心，将对比学习中的推拉机制与离散二值化约束有机结合，在大幅缓解量化误差的同时，显著提升了哈希码串的全局语义一致性。

当这一框架被进一步引入遥感图像检索领域时，研究者针对遥感场景的高度复杂性进行了定制化拓展。遥感图像通常具有典型的多标签语义特性，即同一幅图幅内往往交织着多种地物类型（如水体、建筑与林地共存）。简单的二元相似性标签（非 0 即 1）难以准确刻画这种极其细腻的语义关联。因此，部分前沿工作尝试引入软性的语义相似度矩阵来替代硬标签，使对比学习的监督信号能够更精确地量化样本间的语义距离，为多标签遥感场

景提供更平滑的优化梯度。

综上所述，对比学习在遥感图像检索中的应用已从单纯的二元判别向精细化距离度量转变。然而，在结合深度哈希技术时，现有的对比机制仍面临类内紧凑性与类间判别性之间的平衡难题：过强的排斥力虽能拉开类别间距，却往往导致同类特征在汉明空间中分布稀疏；而过度的聚拢约束则可能压缩判别边界，难以应对遥感影像中严峻的异物同谱挑战。这种在离散空间内难以调和的博弈困境，构成了当前深度哈希检索性能提升的主要瓶颈，也正是本文后续研究中互补损失函数设计的出发点。

## 2.5 本章小结

本章系统梳理了本文研究工作所依托的理论基础与关键技术，为后续章节算法的设计提供了支撑。首先，本文从系统工程视角重构了基于内容的图像检索（CBIR）的基本框架，剖析了特征提取、深度哈希索引与汉明空间相似性度量等核心环节，明确了哈希检索在应对海量遥感数据时的速度优势与量化误差挑战。其次，深入分析了注意力机制在抑制遥感图像复杂背景噪声、聚焦关键语义目标方面的机理；同时，系统论述了特征金字塔与空洞卷积等多尺度建模技术和渐进式多尺度聚合在应对遥感地物极端尺度跨度时的必要性，为打破单一感受野的局限提供了技术路径。最后，梳理了对比学习在度量检索领域的演进脉络，从经典对比损失、三元组损失到基于信息论的 InfoNCE 损失，解释了其在构建同类紧凑、异类分离的高维特征空间中的核心作用

### 3 基于特征解耦引导的联合注意力遥感深度哈希检索方法

#### 3.1 引言

大规模遥感图像检索面临的核心挑战在于如何从高空俯视的复杂背景中提取具备高度判别力的语义特征。深度哈希技术因能将高维特征映射为紧凑的二进制码，成为提升检索效率的重要手段。然而，目前的深度学习方法在处理遥感图像时，标准卷积算子往往缺乏对关键区域的选择性感知。这种局限性导致大面积同质化背景产生强烈的冗余响应，进而掩盖了尺度相对较小的核心目标。这种背景噪声的严重干扰显著降低了特征提取的信噪比，使得模型难以准确捕捉表达图像核心语义的关键信息。

为了提升特征表达能力，注意力机制被广泛引入深度哈希网络中，但在应对遥感图像时仍存在显著的局限性。首先，传统注意力机制多采用黑盒式的自适应加权策略，忽视了遥感图像中全局环境与局部目标间的特征解耦需求，导致注意力分配在面对复杂背景干扰时容易出现感知钝化，难以有效剥离噪声。其次，现有的通道与空间注意力往往独立计算，缺乏深层的关联引导，难以在复杂背景下精准锁定微小或密集目标的轮廓。最后，哈希检索的核心在于离散化过程，这对特征的纯度要求极高。若前端注意力机制不能优先且稳定地聚焦于判别性区域，连续特征中的冗余噪声将被带入哈希码中，导致量化过程发生严重的语义丢失。

为应对上述挑战，打破现有注意力哈希模型在特征表达上的性能瓶颈，本章提出了一种基于特征解耦引导的联合注意力遥感图像深度哈希检索方法（FDG-JA）。针对背景干扰导致的激活不准与感知钝化问题，本文提出了特征解耦门控模块（FDG），通过显式地将显著性目标特征与上下文背景特征进行分离，为后续的特征强化提供纯净、抗干扰的引导信号。在此基础上，针对空间与通道特征关联不足的痛点，本文设计了双向引导的联合注意力机制，利用 FDG 模块的解耦先验知识实现跨维度校准，确保模型不仅能看清目标区域，还能锁定关键特征通道。此外，为了缓解量化过程中的信息丢失，本章构建了协同优化的端到端哈希学习架构，通过注意力增强高纯度特征分布，很大程度上保留了二进制映射前后的语义保真度。在多个公开遥感图像基准数据集上的实验结果表明，FDG-JA 模型在抗干扰能力、检索精度与效率上表现出色，优于现有的主流哈希算法。

#### 3.2 算法框架

针对遥感图像中大面积同质化背景对微小目标的特征掩盖问题，本章提出了一种全链

路解耦引导联合注意力哈希网络 FDG-JA (Full-Link Decoupling Guided Joint Attention Hash Network)。该架构的设计理念是从底层感知阶段开始，对图像进行物理层面的频域拆解，并以此为基础在深层语义阶段实施精确的特征增强与解耦，从而打破现有模型在复杂背景下对核心目标感知不准的性能瓶颈。如图 3-1 所示，FDG-JA 网络的整体处理流程遵循由粗到精、由物理到语义、由连续到离散的设计思路，主要包含四个关键模块：

(1) 基于频域解耦的谱-空协同特征提取模块：利用离散小波变换 (2D-DWT) 将输入遥感图像分解为多尺度、互补的频率子带。随后建立低频全局上下文与高频显著性目标双路径协同感知网络，初步提取兼顾全局语义与局部细节的频域先验特征。

(2) 频率调制特征解耦门控模块：针对骨干网络输出中目标与背景的语义耦合，特征解耦门控 (FDG) 模块利用频域先验进行调制，通过显式分离显著性目标特征与上下文背景特征，生成纯净的先验引导信号。

(3) 双向引导联合注意力增强模块：基于 FDG 模块提供的纯净解耦信号，设计了双向引导的通道注意力 (GCA) 与空间注意力 (GSA) 模块。利用空间先验强化核心通道，利用通道信息精准锁定空间轮廓，最终通过联合融合输出高信噪比的增强特征。

(4) 协同优化的哈希码生成与网络优化模块：增强特征经全局压缩与哈希维度映射后，通过量化函数和多任务损失函数协同优化，生成离散、紧凑且具备丰富语义的二进制哈希码，完成最终的高效检索任务。




图 3-1 FDG-JA 算法框架图

### 3.2.1 特征提取模块

基础特征提取层是模型感知遥感图像多尺度信息的起点。考虑到遥感图像中目标与背景在特征频率上的巨大差异（目标表现为高频突变信号，背景表现为低频平滑信号），本研究设计并采用了一种基于频域解耦的谱-空协同骨干网络(Frequency-Decoupled Spectral-Spatial Backbone, FDSS-Backbone)。该骨干网络不局限于传统的空间域卷积，而是引入了小波分析来捕获图像的多频段特征，为后续的精确保语义解耦提供物理先验的支持。




图 3-2 特征提取模块图

具体而言，给定输入的原始遥感图像  $I \in \mathbb{R}^{H_0 \times W_0 \times 3}$ ，FDSS-Backbone 首先利用一级二维离散小波变换(2D-DWT)及其内置的滤波器组对图像进行多尺度分解。通过该变换，原始信号被拆解为四个互补的子带特征：其中，低频近似分量  $X_{LL}$  集中了图像的全局轮廓与背景分布信息；而三个高频细节分量  $X_{LH}, X_{HL}, X_{HH}$ （分别对应水平、垂直和对角方向）则包含了边缘、纹理及微小目标信息。

在完成频域初步解耦后，模型针对不同频段的特性构建了并行处理的表征路径。低频全局上下文路径接收分量  $X_{LL}$ ，并利用轻量化的全局自注意力算子建模场景中的长距离空间拓扑关系，以此捕获宏观背景表征  $F_{low}$ 。与此同时，高频显著性目标路径针对高频分量  $X_{LH}, X_{HL}, X_{HH}$ ，引入具备动态选择特性的稀疏卷积重点提取核心目标的细粒度特征，从而在抑制同质化背景噪声的同时生成判别性强的目标表征  $F_{high}$ 。最后，借鉴逆小波变换的物

理重构思想，网络通过频域协同融合模块将两路特征进行深度交互映射与空间域还原。该过程的数学表达如下：

$$F = \text{I-DWT}(\text{Interaction}(F_{\text{low}}, F_{\text{high}})) \quad (3-1)$$

其中， $\text{Interaction}(\cdot)$  表示图 3-2 中的交叉交互融合操作， $\text{I-DWT}(\cdot)$  表示二维逆离散小波变换。最终网络输出空间维度为  $H \times W \times C$  的频域调制基础特征图  $F$ 。这种设计确保了输出特征  $F$  在进入后续网络时已经内嵌了清晰的频率分离属性，降低了后续特征解耦门控(FDG)的优化难度。

### 3.2.2 特征增强模块

FDG-JA 核心模块是本算法的核心创新部分，旨在利用骨干网络预先赋予的频域判别力，消除残存的背景冗余。其处理逻辑为解耦-引导-增强-融合。




图 3-3 特征增强模块图

首先，频率调制特征解耦门控（FDG）针对骨干网络输出特征中目标与背景仍存在的语义交织问题，利用频域属性实施显式分离。具体而言，该模块通过并行构建显著性提取与上下文提取两条支路：

一方面，利用全局最大池化（Global Max Pooling, GMP）强化高频响应点，提取纯粹的核心目标显著性特征  $F_{\text{salient}}$ ：

$$F_{\text{salient}} = \text{GMP}(F) \quad (3-2)$$

另一方面，利用全局平均池化（Global Average Pooling, GAP）平滑聚合低频信息，捕

捉宏观的全局上下文特征  $F_{context}$  :

$$F_{context} = \text{GAP}(F) \quad (3-3)$$

这一解耦过程将复杂的混合特征转化为纯净的先验信号，为后续的精确定特征校准提供了引导基础。

在此基础上，本模块引入了双向引导注意力机制，其核心创新在于通过建立背景对目标的约束以及目标对空间的锚定，实现跨维度的特征增强。

(1) 引导式通道注意力 (GCA) 支路：该支路旨在筛选出对识别核心目标最具贡献的特征通道。不同于传统的自适应加权，GCA 在处理显著性向量  $F_{salient}$  时，显式引入上下文特征  $F_{context}$  作为引导信号，共同通过多层感知机实现频率信息的非线性重调制，生成的通道权重系数为：

$$W_c = \sigma(\text{MLP}(F_{salient} \oplus F_{context})) \quad (3-4)$$

其中  $\oplus$  表示元素相加， $\sigma$  表示 Sigmoid 激活函数。随后，将  $W_c$  与输入特征  $F$  逐通道相乘，得到 GCA 增强特征：

$$F_{GCA} = W_c \otimes F \quad (3-5)$$

(2) 引导式空间注意力 (GSA) 支路：与此同时，GSA 支路在空间维度上精确定位目标的轮廓区域。为了实现在杂乱背景下的精准聚焦，GSA 以  $F_{context}$  为基础，显式地引入了由  $F_{salient}$  提供的空间引导信号。两者在通道维度拼接后，共同通过一个感受野广阔的  $7 \times 7$  大核卷积层，捕获长程空间依赖。生成的空间权重映射图  $M_s \in \mathbb{R}^{1 \times H \times W}$  为：

$$M_s = \sigma(\text{Conv}_{7 \times 7}([F_{context}; F_{salient}])) \quad (3-6)$$

其中， $[:,:]$  表示沿通道维度的拼接 (Concatenation)， $\text{Conv}_{7 \times 7}$  为大核卷积。该支路的交叉引导强制空间权重跳出低频背景的干扰，精准锚定高频目标所在的像素区域。得到的 GSA 增强特征为：

$$F_{GSA} = M_s \otimes F \quad (3-7)$$

(3) 联合融合输出：最后，网络将 GCA 与 GSA 支路分别从语义 (通道) 和定位 (空间) 两个互补维度进行特征融合。通过逐元素乘法 ( $\otimes$ ) 操作，模型完成最终的频率-空间精细校准：

$$F' = F_{GCA} \otimes F_{GSA} \quad (3-8)$$

这种并行的交叉引导机制不仅最大限度地保留了显著目标的语义保真度，还通过双向引导信号的联合约束，极大地抑制了同质化背景带来的冗余激活。输出的高信噪比融合增强特征图  $F'$ ，为后续高精度的哈希码生成提供了纯净的特征底座，从而有效缓解了离散量化过程中的信息丢失问题。

### 3.2.3 哈希生成模块

经过 FDG-JA 特征增强模块充分提纯后，融合增强特征图  $F' \in \mathbb{R}^{C \times H \times W}$  已经具备了高语义信噪比。本模块的核心目标是将该连续的高维张量映射为紧凑的  $L$  位二进制哈希码，以支撑后续的海量图像检索。

首先，为了在降维的同时最大限度地保留空间维度的多重感知信息，网络采用全局平均池化（GAP）与全局最大池化（GMP）双支路并行的空间聚合策略。GAP 能够有效捕获全局的统计上下文分布，而 GMP 则负责截留最具判别力的显著性极值响应。两者提取的一维向量通过逐元素相乘进行融合，得到最终的聚合特征向量  $V_{pool} \in \mathbb{R}^{C \times 1 \times 1}$ ：

$$V_{pool} = \text{GAP}(F') \otimes \text{GMP}(F') \quad (3-9)$$

随后，利用一个全连接层作为哈希映射层（Hash FC Layer），将聚合特征向量线性投影至预设的  $L$  维连续隐空间，得到连续的哈希表示  $V_{fc} \in \mathbb{R}^L$ ：

$$V_{fc} = W_h V_{pool} + b_h \quad (3-10)$$

其中， $W_h \in \mathbb{R}^{L \times C}$  和  $b_h \in \mathbb{R}^L$  分别为该全连接层的可学习权重矩阵与偏置项。

在将连续特征  $V_{fc}$  转化为离散二进制码的过程中，最理想的量化方式是直接应用符号函数。然而，由于  $\text{sgn}(x)$  函数在零点处不可导，且在其余所有位置的导数均为零，直接将其嵌入端到端网络中会导致反向传播时的梯度消失问题，使得网络参数无法更新。

为了打破这一离散优化壁垒，本章在训练阶段引入了连续松弛策略。具体而言，采用带有缩放因子的双曲正切函数（ $\tanh$ ）作为符号函数的平滑近似替代方案，生成近似的连续哈希码  $H \in \mathbb{R}^L$ ：

$$H = \tanh(\alpha V_{fc}) \quad (3-11)$$



其中,  $\alpha$  为控制量化函数陡峭度的缩放超参数。随着  $\alpha$  值的增大,  $\tanh(\alpha x)$  的形态将无限逼近于  $\text{sgn}(x)$ 。通过这种连续化处理, 模型能够利用标准的反向传播算法平滑、稳定地优化哈希特征空间。

而在推理与实际检索阶段, 网络将直接恢复使用标准的符号函数, 以确保生成的特征编码  $B \in \{-1, 1\}^L$  具备绝对的离散二值属性:

$$B = \text{sgn}(V_{fc}) \quad (3-12)$$




图 3-4 哈希生成模块图

### 3.2.4 损失函数模块

为了确保生成的哈希码既能在汉明空间中严格保持遥感图像间的原始语义相似性, 又能最大限度地减少离散量化过程带来的信息折损, FDG-JA 网络构建了一个端到端协同优化的多任务联合损失函数。该总损失由成对语义相似性项与哈希量化约束项两部分协同构成。

(1) 成对语义相似性损失 (Pairwise Semantic Loss): 本模型采用基于对数似然 (Log-Likelihood) 的成对监督信号来约束哈希空间的几何分布与语义一致性。给定一个训练批次 (Batch) 内的图像特征对  $(H_i, H_j)$  及其对应的真实语义相似性标签  $S_{i,j}$  (若两幅图像语义相似/属于同类则  $S_{i,j} = 1$ , 否则  $S_{i,j} = 0$ )。定义两张图像连续哈希向量的内积作为相似度量, 即  $\Theta_{i,j} = \frac{1}{2} H_i^T H_j$ 。模型的目标是使相似样本的内积尽可能大, 而不相似样本的内积尽可能小。其标准的负对数似然语义损失定义如下:

$$L_{sem} = - \sum_{(i,j) \in \Omega} (S_{i,j} \Theta_{i,j} - \log(1 + \exp(\Theta_{i,j}))) \quad (3-13)$$

其中,  $\Omega$  表示当前训练批次内所有构建的样本对集合。通过该项交叉熵形式的约束, 网络在连续的高维隐空间中强行拉近正样本对并推开负样本对, 奠定了哈希码全局判别性的基础。

(2) 哈希量化约束损失 (Quantization Loss): 如前文所述, 为了突破离散符号函数不可导的瓶颈, 网络在训练时引入了连续松弛策略 (即使用  $H = \tanh(\alpha V_{fc})$  代替  $\text{sgn}$  函数)。然而, 这种平滑近似不可避免地会扩大连续特征向量与理想二进制码之间的物理距离, 从而在最终二值化截断时引发语义丢失。为了缓解这一量化误差, 模型引入了量化约束项, 旨在强制连续实值哈希向量  $H$  的每一个分量尽最大可能向  $\{-1, +1\}$  两极靠拢, 其数学表达为:

$$L_{quant} = \sum_{i=1}^N \| |H_i| - \mathbf{1} \|_2^2 \quad (3-14)$$

其中,  $N$  为批次大小,  $\|\cdot\|_2^2$  表示 L2 范数 (欧几里得距离的平方),  $|H_i|$  为对向量分量取绝对值,  $\mathbf{1} \in \mathbb{R}^L$  为全 1 向量。通过最小化连续松弛特征与理想离散极值之间的距离, 该损失项显著降低了松弛截断误差, 大幅提升了最终生成的二进制码的特征纯度与质量。

(3) 总体优化目标: 综上所述, FDG-JA 网络的总损失函数可表示为语义相似性项与量化约束项的加权融合:

$$L_{total} = L_{sem} + \lambda L_{quant} \quad (3-15)$$

其中,  $\lambda$  为平衡超参数, 用于在语义结构保持与离散量化精度之间进行动态权衡。在实际实验训练中, 该参数通过在验证集上的网格搜索确定最优取值。在这一多任务协同优化目标的驱动下, 网络能够自适应地学习到既具备丰富语义保真度、又具有高信噪比的紧凑二进制编码, 从而出色地完成复杂背景下的遥感图像检索任务。

### 3.3 实验与分析

#### 3.3.1 数据集介绍

为了全面且客观地评估本文提出的 FDG-JA 深度哈希模型的检索性能与泛化能力, 实验选取了遥感领域三个最具代表性的公开场景分类与检索基准数据集进行测试。从早期的经典小型数据集到近年来的大规模复杂数据集, 这三个数据集在规模、类内/类间差异及空间分辨率上呈现出明显的难度递进关系。实验的数据划分策略上, 为保证对比的公平性,

针对这三个数据集均采用一致的协议：随机抽取每个类别 80% 的样本构建训练集，剩余 20% 的样本作为查询集进行测试。

### （1）UCMD 数据集（UC Merced Land Use Dataset）

UCMD 数据集<sup>[90]</sup>是遥感图像检索领域的经典早期基准，包含 21 类共 2100 张航空遥感图像，每类 100 张，图像尺寸统一为  $256 \times 256$  像素，空间分辨率约为 0.3 米/像素，涵盖农业用地、建筑区、森林、停车场、河流等典型城乡地物类型，如图 3-5 所示。该数据集类间视觉相似度较高，部分类别（如中密度住宅与高密度住宅）之间的边界模糊，对特征类间区分能力要求较高。




图 3-5 UCMD 数据集示例

### （2）AID 数据集（Aerial Image Dataset）

为应对更加复杂的实际应用场景，AID 数据集<sup>[91]</sup>在规模和多样性上进行了大幅扩充。该数据集包含 30 类共 10000 张航空遥感图像，每类图像数量在 220 至 420 张之间，图像尺寸为  $600 \times 600$  像素，空间分辨率在 0.5 至 8 米/像素之间，如图 3-6 所示，场景类型涵盖机场、棒球场、海滩、森林、工业区、住宅区等多样化地物类型。与 UCMD 相比，AID 数据集的类内差异（如同一类别在不同光照、季节下的表现）更为显著，且空间分辨率的多变性进一步考验了模型的多尺度感知能力。





图 3-6 AID 数据集示例

### (3) NWPU-RESISC45 数据集

NWPU-RESISC45 数据集<sup>[92]</sup>是目前遥感图像场景识别与检索领域规模最大的公开基准之一，45 个复杂场景类别，共计 31500 张遥感图像（每类 700 张），图像尺寸为 $256 \times 256$  像素，空间分辨率从 0.2 米至 30 米不等。如图 3-7 所示，场景类别横跨自然地貌、人造目标与农业用地等多个大类，类内外差异均极为显著。




图 3-7 NWPU 数据集示例

### 3.3.2 评价指标

评价指标的选取是衡量图像检索系统性能的重要基础。为了从多个维度对所提方法的检索性能进行全面、客观的量化评估，本文使用平均精度均值（mAP）、截断平均精度均值（mAP@K）、截断召回率（Recall@K）以及精确率-召回率曲线（P-R 曲线）四项核心指标，

对所提 FDG-JA 方法与当前主流的前沿深度哈希方法进行系统、公正的比较与分析。

(1) 平均精度均值 (mAP): 平均精度均值是图像检索领域最为常用的综合性评价指标, 对检索结果的排序质量具有较强的区分能力。对于给定的查询图像  $q$ , 其平均精度  $AP(q)$  定义为在不同召回水平下精确率的加权均值, 具体计算公式为:

$$AP(q) = \frac{1}{|R_q|} \sum_{k=1}^{|D_q|} P(k) \cdot \text{rel}(k) \quad (3-16)$$

其中,  $|R_q|$  表示查询  $q$  对应的相关图像总数,  $|D_q|$  为检索结果集合的大小,  $P(k)$  为前  $k$  个检索结果中的精确率,  $\text{rel}(k)$  为二值指示函数, 当第  $k$  个检索结果与查询图像语义相关时取值为 1, 否则为 0。该公式的设计使得排名越靠前的相关图像对 AP 值的贡献越大, 从而有效体现了检索结果排序质量的重要性。

在此基础上, mAP 通过对测试集中所有查询图像的 AP 值取均值来获得整体性能的单一样化指标, 计算公式为:

$$\text{mAP} = \frac{1}{|Q|} \sum_{q \in Q} AP(q) \quad (3-17)$$

其中,  $|Q|$  为查询集中的查询图像总数。mAP 值越高, 表明检索系统在全局层面具有越强的排序质量与语义匹配能力。

(2) 截断平均精度均值 (mAP@K): 在实际检索应用场景中, 用户通常只关注排名最靠前的少数检索结果, 而非完整的检索列表。为此, 本文引入截断平均精度均值 (mAP@K) 作为补充指标, 该指标将评估范围限定在前  $K$  个检索结果之内, 能够更直接地反映系统在实用场景下的检索有效性。mAP@K 的计算公式为:

$$\text{mAP@K} = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{K} \sum_{k=1}^K \text{rel}(q, k) \quad (3-18)$$

其中,  $\text{rel}(q, k)$  为二值指示函数, 若查询  $q$  的第  $k$  个检索结果与查询图像相关则取值为 1, 否则为 0。

(3) 截断召回率 (Recall@K): 召回率关注的是检索系统对相关图像的覆盖能力。截断召回率 (Recall@K) 衡量在前  $K$  个检索结果中成功召回的相关图像数量占全部相关图像总数的比例, 计算公式为:

$$\text{Recall@K} = \frac{R_K(q)}{R(q)} \quad (3-19)$$

其中,  $R_K(q)$  表示前  $K$  个检索结果中相关图像的数量,  $R(q)$  为数据库中与查询图像  $q$  相

关的图像总数。

(4) 精确率-召回率曲线 (P-R 曲线): 精确率-召回率曲线 (Precision-Recall Curve, P-R 曲线) 通过在不同决策阈值下同时绘制精确率与召回率的变化轨迹, 直观呈现检索系统在不同操作点下精确性与完整性之间的权衡关系。精确率与召回率的定义分别为:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3-20)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3-21)$$

其中,  $TP$ 、 $FP$ 、 $FN$  分别表示真正例 (True Positive)、假正例 (False Positive) 与假负例 (False Negative) 的数量。随着返回结果的增多, 召回率呈上升趋势, 而精确率则相应下降。P-R 曲线不仅能通过曲线下面积 (AUC-PR) 提供综合数值评估, 还能通过将不同方法的曲线绘制在同一坐标系中, 直观地展示出各算法在不同查全率要求下的性能优劣。

### 3.3.3 实验设置

为确保实验的高效性与可重复性, 本文所有模型的训练与测试均在同一高性能计算节点上完成。硬件端配置为 Intel Xeon Gold 6430 处理器 (16 vCPU) 与单张 NVIDIA RTX 4090 GPU (24GB VRAM)。软件环境基于 Ubuntu 22.04 LTS 操作系统, 核心深度学习框架采用 PyTorch 1.7.0, 并辅以 CUDA 11.0 进行 GPU 加速。

在模型初始化阶段, FDG-JA 骨干网络 (FDSS-Backbone) 加载在 ImageNet-1K 上的预训练权重以加速收敛。模型参数优化采用 Adam 优化器, 总训练周期 (Epochs) 设定为 150。学习率采用 StepLR 衰减策略: 初始学习率设为  $1 \times 10^{-4}$ , 每经过 50 个 Epoch, 学习率按 0.1 的比例进行阶跃衰减。模型训练的具体超参数如表 3-1 所示:

表 3-1 FDG-JA 模型训练核心超参数配置

| 参数名称                  | 配置值                |
|-----------------------|--------------------|
| 优化器 (Optimizer)       | Adam               |
| 训练批大小 (Batch Size)    | 128                |
| 初始学习率 (Learning Rate) | $1 \times 10^{-4}$ |
| 权重衰减 (Weight Decay)   | $5 \times 10^{-4}$ |
| 动量参数 (Momentum)       | 0.9                |
| 哈希位长度 (Hash Bits)     | {32, 64, 128, 256} |

针对遥感图像成像视角多变的特性，输入阶段采用了标准化的数据增强管线：所有遥感样本首先被统一重采样至  $256 \times 256$  像素的空间分辨率，随后在训练时随机应用水平/垂直翻转以及色彩抖动，以提升模型抗噪鲁棒性。

在性能评估与超参数调优方面，本实验分别针对 32、64、128 和 256 四种主流二进制哈希码长进行全面评估。此外，对于联合损失函数中平衡语义与量化精度的权重超参数  $\lambda$ ，本文通过验证集网格搜索将其锁定在  $[0.01, 0.1]$  的动态微调区间内，以确保最佳的检索精度。

3.3.4 消融实验

为了深入验证本章提出的全链路解耦引导联合注意力网络（FDG-JA）中各个核心模块的有效性，及其对遥感图像哈希检索整体性能的具体贡献，本节在统一的实验设置与网络超参数下，进行了详尽的模块剥离与消融实验。本研究采用由底层至高层、由单模块至多模块的递进集成策略，构建了六种互补的网络变体（M1 至 M6）。具体的模块组合配置如表 3-2 所示。

表 3-2 FDG-JA 网络不同消融变体的模块配置

| 模型变体          | 基础网络<br>(Baseline) | 频域解耦骨干<br>(FDSS) | 解耦门控<br>块 (FDG) | 引导通道注<br>意力 (GCA) | 引导空间注意<br>力 (GSA) |
|---------------|--------------------|------------------|-----------------|-------------------|-------------------|
| M1 (Baseline) | ✓                  | ✗                | ✗               | ✗                 | ✗                 |
| M2            | ✓                  | ✓                | ✗               | ✗                 | ✗                 |
| M3            | ✓                  | ✓                | ✓               | ✗                 | ✗                 |
| M4            | ✓                  | ✓                | ✓               | ✓                 | ✗                 |
| M5            | ✓                  | ✓                | ✓               | ✗                 | ✓                 |
| M6 (Ours)     | ✓                  | ✓                | ✓               | ✓                 | ✓                 |

在上述变体中：首先，模型 M1 作为基线（Baseline），仅由标准的 ResNet50 骨干网络配合基础全连接哈希层构成。在 M1 的基础上，变体 M2 引入了本章设计的 FDSS-Backbone 替换标准骨干网络，实现了从物理频域层面对原始影像信息的初步过滤。随后，变体 M3 在频域解耦的基础上进一步嵌入了特征解耦门控（FDG）模块，完成了从物理频率到深层语义特征的显式分离。为了验证双向引导机制在不同维度的性能增益，变体 M4 与 M5 分别在 M3 的输出端单独接入了引导式通道注意力（GCA）支路与引导式空间注意力（GSA）支路。最后，M6 即为本文提出的完整 FDG-JA 网络，它集成了上述所有模块，通过通道与空间的交叉协同优化，实现最终的高纯度哈希映射。各网络变体在三个数据集、不同哈希

码长下的平均检索精度（mAP）测试结果如表 3-3 所示。

表 3-3 不同消融配置在不同数据集、不同哈希码长度下的 mAP 对比（%）

| Methods    | UCMD         |              |              |              | AID          |              |              |              | NWPU-RESISC45 |              |              |              |
|------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|---------------|--------------|--------------|--------------|
|            | 32bit        | 64bit        | 128bit       | 256bit       | 32bit        | 64bit        | 128bit       | 256bit       | 32bit         | 64bit        | 128bit       | 256bit       |
| <b>M-1</b> | 97.60        | 96.75        | 96.76        | 96.63        | 93.17        | 93.85        | 93.79        | 93.44        | 89.78         | 90.23        | 90.10        | 89.37        |
| <b>M-2</b> | 97.67        | 98.04        | 98.17        | 98.25        | 93.34        | 93.93        | 94.13        | 94.18        | 90.17         | 90.85        | 91.09        | 91.39        |
| <b>M-3</b> | 97.63        | 98.38        | 98.31        | 98.44        | 93.82        | 94.07        | 94.59        | 94.53        | 90.39         | 91.09        | 91.57        | 91.94        |
| <b>M-4</b> | 97.65        | 97.95        | 98.29        | 98.14        | 93.79        | 94.42        | 94.59        | 94.53        | 90.48         | 91.11        | 91.78        | 91.79        |
| <b>M-5</b> | 97.21        | 97.68        | 97.76        | 98.27        | 93.67        | 94.01        | 94.34        | 94.46        | 89.89         | 91.02        | 91.35        | 91.56        |
| <b>M-6</b> | <b>98.62</b> | <b>98.71</b> | <b>98.81</b> | <b>99.04</b> | <b>96.12</b> | <b>96.74</b> | <b>96.79</b> | <b>97.25</b> | <b>94.18</b>  | <b>94.34</b> | <b>94.55</b> | <b>94.05</b> |

消融实验结果表明，完整模型(M6)在所有数据集及码长下均取得了最优的检索精度，验证了全链路解耦架构的有效性。首先，对比 M1 与 M2 可知，频域解耦骨干（FDSS）能从物理层面显著抑制背景噪声，带来基础性能的稳步提升；进一步引入 FDG 门控（M3）后，模型实现了语义层面的特征净化，精度再次跃升。其次，针对双向引导机制，M4 与 M5 的单维度增益验证了背景先验对通道筛选及空间定位的辅助作用，且二者在 M6 中的协同效应最为突出。例如，在 AID 数据集 32bit 下，联合增强（M6, 96.10%）较单支路（M4, 93.79%）提升了约 2.3%。值得注意的是，FDG-JA (M6) 展现出了极其强悍的信息压缩能力。其在规模最大、背景最复杂的 NWPU 数据集 32bit 下的精度（94.18%），超越了基线模型 M1 在 256bit 下的表现（89.37%）。对比结果证明了本章方法在极端背景干扰下，依然能够为短哈希码保留极高的语义保真度。

### 3.3.5 算法对比分析

为了全面评价本章提出的 FDG-JA 模型的性能，本实验选取了九种具有代表性的深度哈希检索算法进行系统对比。这些算法涵盖了当前深度哈希领域的主流架构，可归纳为以下两类：

遥感专用深度哈希方法：包括 FAH<sup>[21]</sup>、IDHN<sup>[53]</sup>、SCFR<sup>[58]</sup>、DGSSH<sup>[72]</sup>以及 AHCL<sup>[73]</sup>。这些算法针对遥感任务的特定尺度问题或空间特性进行了专门优化，是衡量 FDG-JA 核心创新力的关键基准。

通用深度哈希方法：包括 DHN<sup>[51]</sup>、DPSH<sup>[52]</sup>、Greedy<sup>[54]</sup>以及 CSQ<sup>[69]</sup>。这类方法在自然图像检索任务中表现优异，主要通过优化量化损失或相似性度量函数来提升检索精度。然



而，它们在处理遥感图像时，往往忽略了极端空间异质性与同质化背景带来的干扰。

表 3-4 不同方法在不同数据集、不同哈希码长度下的 mAP 对比（%）

| Methods | UCMD  |       |        |        | AID   |       |        |        | NWPU-RESISC45 |       |        |        |
|---------|-------|-------|--------|--------|-------|-------|--------|--------|---------------|-------|--------|--------|
|         | 32bit | 64bit | 128bit | 256bit | 32bit | 64bit | 128bit | 256bit | 32bit         | 64bit | 128bit | 256bit |
| FDG-JA  | 98.63 | 98.75 | 98.81  | 99.04  | 96.18 | 96.73 | 96.79  | 97.25  | 94.18         | 94.35 | 94.55  | 94.05  |
| DGSSH   | 98.21 | 98.6  | 98.58  | 98.67  | 95.31 | 96.61 | 96.74  | 96.77  | 92.31         | 93.45 | 93.42  | 94.75  |
| SCFR    | 97.65 | 97.95 | 98.03  | 98.14  | 93.79 | 94.42 | 94.59  | 94.53  | 90.48         | 91.11 | 91.78  | 91.79  |
| FAH     | 93.73 | 95.87 | 97.07  | 97.06  | 92.42 | 91.99 | 92.71  | 93.24  | 89.48         | 89.83 | 90.77  | 90.68  |
| AHCL    | 95.93 | 96.51 | 96.81  | 97.14  | 92.46 | 92.75 | 93.48  | 93.54  | 86.51         | 90.13 | 91.86  | 93.88  |
| CSQ     | 97.64 | 97.84 | 97.76  | 97.62  | 92.99 | 93.42 | 93.34  | 93.11  | 89.28         | 89.66 | 89.33  | 89.37  |
| IDHN    | 93.27 | 93.59 | 94.83  | 95.04  | 91.91 | 92.56 | 92.63  | 92.79  | 88.78         | 87.99 | 88.28  | 88.48  |
| Greedy  | 96.16 | 95.60 | 93.75  | 93.28  | 92.39 | 93.24 | 93.73  | 94.18  | 89.53         | 90.59 | 90.83  | 91.19  |
| DPSH    | 80.91 | 82.03 | 83.62  | 85.51  | 92.09 | 92.25 | 92.45  | 92.24  | 67.53         | 88.85 | 88.01  | 85.62  |
| DHN     | 76.04 | 74.25 | 80.29  | 81.58  | 90.92 | 92.53 | 92.55  | 92.16  | 67.82         | 84.06 | 83.72  | 81.67  |

根据表 3-4 所示的对比实验结果，本章提出的 FDG-JA 模型在 UCMD、AID 和 NWPU-RESISC45 三个主流遥感图像数据集上，均展现出了全面领先的检索性能。在不同哈希码长的测试中，FDG-JA 的平均检索精度（mAP）始终保持在最优水平，显著高于目前的 SOTA 算法。

在规模相对较小且类别判别性较强的 UCMD 数据集上，FDG-JA 在 32bit 到 256bit 下的 mAP 分别达到了 98.63%至 99.04%。相比于表现次优的遥感专用方法 DGSSH，FDG-JA 在各码长下均有稳定提升。值得注意的是，相比于传统的深度哈希方法（如 DPSH 和 DHN），FDG-JA 的优势明显，mAP 提升幅度最高超过了 20%，这充分验证了在处理遥感图像时，简单的特征映射难以捕捉复杂语义，而 FDG-JA 的解耦机制能够更有效地提取具备判别力的哈希特征。

针对场景更为复杂、样本量更大的 AID 数据集，FDG-JA 依然保持了强劲的性能，其 mAP 值在各码长下均突破了 96%。与通用的深度哈希算法 CSQ 相比，FDG-JA 在 128bit 下的领先优势达到了 3.45%；而与针对遥感图像优化的 SCFR 和 FAH 相比，FDG-JA 同样展现出了更好的鲁棒性。这主要归功于引导式联合注意力机制（GCA&GSA）能够在 AID 数据集多变的目标尺度下，通过空间与通道的协同校准，精准地锁定显著性目标并抑制背景干扰。

在类别最多、背景干扰最为剧烈的 NWPU-RESISC45 数据集上，FDG-JA 的领先地位

更加稳固。在该数据集的 32bit 低位宽测试中, FDG-JA 的 mAP 依然达到 94.18%, 超过了大多数对比算法 (如 DGSSH, SCFR) 在 256bit 高位宽下的检索精度。这意味着 FDG-JA 能够在保持极高检索效率的同时, 极大程度地降低大规模遥感库的存储开销。实验数据表明, 通过全链路的频域与语义解耦, FDG-JA 有效解决了遥感图像中同质化背景导致的感知钝化问题, 在复杂语义检索任务中展现出了卓越的性能。

为了更直观地展现所提方法在多维评价体系下的综合优势, 图 3-8 至图 3-10 分别绘制了 FDG-JA 与主流对比算法在 UCMD、AID 和 NWPU-RESISC45 三个数据集上 (统一采用 128-bit 码长) 的 Recall@K、Precision@K 以及 Precision-Recall (P-R) 曲线。在所有图表中, 红色曲线均代表本文提出的 FDG-JA 模型。




图 3-8 FDG-JA 在 UCMD 检索性能曲线




图 3-9 FDG-JA 在 AID 检索性能曲线




图 3-10 FDG-JA 在 NWPU-RESISC45 检索性能曲线

综合分析上述三组实验曲线, 可以得出以下核心结论:

(1) Recall@K 曲线展示了极致的查全效率。无论是在相对小型的 UCMD 数据集，还是在检索深度扩展至 Top-4000 的巨型 NWPU 数据集中，FDG-JA 的 Recall@K 曲线均呈现出最陡峭的上升斜率，并最先收敛至饱和状态。例如在 UCMD 中，当 K 仅为 100 左右时，其召回率便已逼近 1.0。这表明得益于全链路频域解耦机制对核心语义的提纯，模型能够将绝大部分高度相关的遥感样本排列在检索序列的最前端，查全效率显著优于 DGSSH 和 SCFR 等针对遥感任务设计的基线方法。

(2) Precision@K 曲线印证了卓越的查准稳定性。随着检索返回样本数量 K 的不断增加，大多数对比算法（如 AHCL、Greedy Hash）在面对遥感图像的同质化背景干扰时，均出现了明显的准确率滑坡。相反，FDG-JA 的下降趋势最为平缓，曲线始终稳居坐标系的最上方。这一现象充分证明，引导式联合注意力机制（GCA & GSA）能够在多变的目标尺度下，精准锚定显著性区域并抑制背景诱发的语义漂移，在深层检索序列中依然提供了性能保障。

(3) P-R 曲线彰显了查准与查全的最优平衡。P-R 曲线是评价哈希检索综合性能的标准。在三大数据集中，FDG-JA 的曲线均呈现出最理想的右上角偏移态势，完整包裹了其他所有对比算法，获得了最大的曲线下面积（AUC）。值得注意的是，在召回率达到 0.8 至 1.0 的高值区域，传统的 DPSH 或 DHN 等方法往往会出现断崖式跌落，而 FDG-JA 依然能维持平稳的高准确率水平。

### 3.3.6 检索结果可视化

为了进一步直观地验证本章提出的 FDG-JA 模型在复杂遥感场景下的特征判别能力，本节展示了在不同数据集上的检索结果可视化对比。实验各选取一张具有代表性的影像作为查询样本（Query），并分别展示了 FDG-JA 与九种对比算法返回的前 10 位检索结果。图中绿色边框表示检索正确，红色边框则表示检索错误。

如图 3-11 所示，实验选取了细节丰富、结构密集的密集住宅区（Dense Residential）作为查询样本。此类场景的难点在于其包含大量细碎的屋顶纹理与交错的街道网络。观察结果可见，FDG-JA 展现出了卓越的检索性能，其返回的 Top-10 样本全为绿框，且在 P@50 指标上达到了满分 100%。相比之下，各基线模型均出现了严重的语义漂移：AHCL 虽然保持了较高的准确率（P@50 为 90%），但在序列中仍出现了误判；而 SCRF、FAH 和 CSQ 等算法几乎全部失效（P@50 仅为 2%至 6%）。从视觉特征来看，这些失效模型返回的错误样本多为普通住宅或停车场。这是因为它们过度依赖全局像素的灰度与颜色统计，被相似的

水泥材质与植被点缀所欺骗。这表明，FDG-JA 能够利用高频支路精准锚定建筑群的密集拓扑结构，有效避免了局部材质相似带来的感知钝化。

| Query                                                                                     | Retrieval Results                                                                   |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                      |                                                                                       |                                                                                       |                                                                                       |                           |
|-------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------|
| <br>UCMD |    |    |    |    |    |    |    |    |    |    | FDG-JA<br>P@50<br>100%    |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | DGSSH<br>P@50<br>52%      |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | SCRF<br>P@50<br>2%        |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | AHCL<br>P@50<br>90%       |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | FAH<br>P@50<br>2%         |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | CSQ<br>P@50<br>6%         |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | IDHN<br>P@50<br>48%       |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | GreedyHash<br>P@50<br>74% |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | DPSH<br>P@50<br>48%       |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | DHN<br>P@50<br>46%        |

图 3-11 FDG-JA 在 UCMD 检索效果

针对尺度变化更大、类内差异更显著的 AID 数据集，图 3-12 展示了以公园为查询样本的检索对比。公园场景兼具大面积的同质化绿植背景与局部的人工步道、凉亭等微小目标，极易导致模型特征的严重耦合。在此极端干扰下，FDG-JA 依然实现了 Top-10 全绿的完美表现（P@100 高达 99%）。反观对比算法，即便在遥感领域表现尚可的 IDHN（96%），其前 10 位结果中也混入了纯视觉特征高度相似的草地或森林类别。而 AHCL 和 SCRF 则遭遇了毁灭性的失效（P@100 仅为 1%），Top-10 几乎全被标红。这种巨大反差直观地证明：通用哈希方法极易被占据图像主导地位的绿色像素所绑架；而 FDG-JA 则能够透过大面积植被背景的掩护，通过特征解耦门控（FDG）精准剥离低频环境噪声，进而利用空间注意力捕捉到公园特有的几何拓扑规律。



| Query                                                                                    | Retrieval Results                                                                   |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                      |                                                                                       |                                                                                       |                                                                                       |                            |
|------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|----------------------------|
| <br>AID |    |    |    |    |    |    |    |    |    |    | FDG-JA<br>P@100<br>99%     |
|                                                                                          |    |    |    |    |    |    |    |    |    |    | DGSSH<br>P@100<br>70%      |
|                                                                                          |    |    |    |    |    |    |    |    |    |    | SCRF<br>P@100<br>1%        |
|                                                                                          |    |    |    |    |    |    |    |    |    |    | AHCL<br>P@100<br>1%        |
|                                                                                          |    |    |    |    |    |    |    |    |    |    | FAH<br>P@100<br>99%        |
|                                                                                          |    |    |    |    |    |    |    |    |    |    | CSQ<br>P@100<br>97%        |
|                                                                                          |    |    |    |    |    |    |    |    |    |    | IDHN<br>P@100<br>96%       |
|                                                                                          |   |   |   |   |   |   |   |   |   |   | GreedyHash<br>P@100<br>14% |
|                                                                                          |  |  |  |  |  |  |  |  |  |  | DPSH<br>P@100<br>28%       |
|                                                                                          |  |  |  |  |  |  |  |  |  |  | DHN<br>P@100<br>38%        |

图 3-12 FDG-JA 在 AID 检索效果

在类别最庞杂、空间异质性最强的 NWPU 数据集上，图 3-13 展示了火车站（Railway Station）的检索结果。该场景不仅包含复杂的线性轨道与站台建筑，且伴随强烈的周边工业或城市景观干扰，具有极强的跨尺度语义模糊性。FDG-JA 在前 10 位检索结果中仅出现一例语义偏差（P@100 达 99%），稳定地锁定了火车站的核心特征。相比之下，传统的通用深度哈希方法（如 DPSH 和 DHN，P@100 均为 3%）无法提取具备类间区分度的特征，其返回的错误样本多为包含相似线性轮廓的高速公路或具有大面积水泥地坪的机场跑道与工业区。这进一步凸显了本文方法在处理海量任务时的优势：FDG-JA 并没有机械地比对宏观几何线条，而是通过双向引导机制实现了通道与空间的交叉校准，在极高维度的语义空间中完成了对火车站专有特征的精准聚类。



| Query                                                                                     | Retrieval Results                                                                   |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                      |                                                                                       |                                                                                       |                                                                                       |                           |
|-------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------|
| <br>NWPU |    |    |    |    |    |    |    |    |    |    | FDG-JA<br>P@100<br>99%    |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | DGSSH<br>P@100<br>97%     |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | SCRf<br>P@100<br>2%       |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | AHCL<br>P@100<br>1%       |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | FAH<br>P@100<br>100%      |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | CSQ<br>P@100<br>92%       |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | IDHN<br>P@100<br>77%      |
|                                                                                           |   |   |   |   |   |   |   |   |   |   | GreedyHash<br>P@100<br>2% |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | DPSH<br>P@100<br>3%       |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | DHN<br>P@100<br>3%        |

图 3-13 FDG-JA 在 NWPU-RESISC45 检索效果

综合上述三组极端场景的视觉定性与指标定量分析，说明传统的深度网络在面对遥感图像中类间相似度高、同质化干扰强的挑战时，往往因特征严重耦合而陷入局部纹理陷阱或全局色彩陷阱，无法生成纯净的哈希码。而 FDG-JA 凭借全链路解耦架构，成功从物理频域和深层语义两个维度显式剥离了背景噪声，并通过双向引导注意力死死锁定了真正决定图像语义的核心目标。这确保了模型在离散的二值映射过程中，很大程度上保留了具有较强判别力的语义信息，在真实场景的查准率及视觉保真度上实现了突破。

### 3.4 本章小结

本章针对遥感图像在大规模检索任务中面临的同质化背景干扰及特征语义耦合问题，提出了一种基于特征解耦引导的联合注意力深度哈希检索方法（FDG-JA）。

首先，本章创新性地构建了基于频域解耦的谱-空协同骨干网络，通过离散小波变换在底层物理层面实现了高、低频信息的初步分离。随后，设计了特征解耦门控（FDG）与双向引导联合注意力机制，利用解耦后的背景与目标先验信号实现跨维度（通道与空间）的

特征精确校准。这种由物理频域到深层语义的层层过滤机制，显著抑制了复杂背景的冗余激活，较大程度上保留了二进制映射过程中的核心语义保真度。最后，在 UCMD、AID 和 NWPU-RESISC45 三个主流遥感图像基准数据集上进行了系统的实验验证。定量对比与定性可视化结果一致表明，FDG-JA 模型在不同哈希码长下的检索性能均显著优于现有 9 种前沿深度哈希算法。消融实验进一步证实了频域解耦与双向引导机制的联合协同增益。本章提出的 FDG-JA 方法有效缓解了遥感影像检索中的感知钝化与语义漂移问题，在保证高检索效率的同时，实现了查准率与查全率平衡。

## 4 基于分层非对称感知与尺度自适应融合的遥感深度哈希方法研究

### 4.1 引言

第3章提出的FDG-JA网络通过特征解耦与双向引导机制有效抑制了背景噪声，提升了哈希特征的判别性。然而，遥感影像检索的挑战不仅在于背景干扰，更在于地物目标极其显著的尺度多样性与几何非对称性。深入分析FDG-JA的工作机制可以发现，其注意力权重始终作用于单一尺度的特征层，感受野规模在训练完成后趋于固定。这种设计在面对尺度跨度极大的地景（如细粒度单体建筑与宏观水域、林地）时，难以在统一的特征表征中兼顾局部纹理与全局语义。与此同时，标准的方形感受野在提取诸如机场跑道、长距离桥梁等具有长条状几何特征的目标时，容易引入不必要的侧向背景信息，导致特征表示的精细度受限。此外，多尺度特征在分层聚合过程中，若缺乏针对性的通道重校准，关键判别信息极易被异构特征流稀释。

针对上述多尺度突变与目标非对称几何特征带来的挑战，本章在第三章的基础上提出了一种分层非对称感知哈希网络(Asymmetric Pooling-based Triple-Hierarchical Network, AP-THNet)。本章的核心设计理念在于打破传统网络固定且对称感受野的局限，构建一种渐进式的尺度-几何双重感知结构。该网络旨在通过分层架构自下而上地捕捉从底层细节到高层语义的多尺度表征，并创新性地利用层次化非对称感知模块精准锚定特定比例的地物目标。在此基础上，通过专用的自适应重校准融合机制对聚合后的多尺度特征流进行提纯，以确保在最终的高维特征离散化映射过程中保留高保真的语义判别性。

围绕上述核心理念，本章的具体研究工作与技术创新严格沿着分层提取-非对称增强-自适应融合的脉络展开。首先，针对遥感地物尺度悬殊的难题，本章构建了由底向上的层级多尺度感知架构，利用特征金字塔渐进式地融合局部微观细节与宏观全局语义。其次，针对桥梁、跑道等目标显著的非对称分布特性，设计了层次化非对称感知(HAP)机制，通过水平与垂直方向的带状池化操作，在增强特定形态目标感知精度的同时，有效抑制了传统方形算子容易引入的侧向背景噪声。进而，结合RSA重校准融合(RSA-Fusion)模块对跨尺度金字塔融合后的特征进行动态提纯，通过显式建模通道间的自适应依赖关系，解决了关键判别信息在特征流转中易被稀释的痛点，进一步强化了哈希表示的紧凑性。最后，在UCMD、AID及NWPU-RESISC45三大基准数据集上开展了广泛的定量与定性实验，验证了AP-THNet在处理复杂多尺度遥感场景时的优势及其各核心模块的有效性。



## 4.2 算法框架

针对遥感图像中目标尺度跨度悬殊、几何形态高度非对称等导致的特征提取与语义对齐难题，本章提出了一种全新的分层非对称感知深度哈希网络（AP-THNet）。该网络突破了传统单一尺度与固定方形感受野的局限，致力于在复杂的背景干扰下，为多尺度与不规则目标提供高保真的特征描述。如图 4-1 所示，AP-THNet 的整体架构设计严格遵循多尺度提取，非对称增强，自适应融合，细粒度量化的递进式处理逻辑。整个前向传播链路主要由以下四个协同工作的核心模块构成：

（1）分层骨干网络模块（Hierarchical Backbone）：作为模型的前端感知基础，该模块负责对输入的原始遥感影像进行逐层递进的特征提取。网络在不同的深度阶段输出具有不同空间分辨率与语义层级的多尺度基础特征图（Original Multi-Scale Features），从而同时兼顾底层的高频局部纹理与高层的低频全局语义。

（2）层次化非对称感知模块（Hierarchical Asymmetric Perception, HAP）：针对遥感地物的非对称几何特性（如细长的跑道、桥梁），本网络在每一个特征层级后并联嵌入了 HAP 模块。该模块摒弃了传统的方形卷积核，创新性地采用长条形感受野对特征进行定向增强，在精准捕捉特定比例目标的同时，有效剥离了侧向冗余背景，输出提纯后的非对称增强特征（HAP-Enhanced Features）。

（3）特征融合与 RSA 重校准模块（Feature Fusion & RSA-Fusion）：为了防止深层高维映射过程中的信息稀释，网络首先通过特征金字塔路径将不同层级的增强特征进行自顶向下的逐元素相加融合。随后，融合后的复合特征被送入 RSA-Fusion 模块。该模块利用全局池化与全连接逻辑动态提取通道级自适应权重，通过通道乘法对多尺度特征流进行动态挤压与重校准，彻底激活关键判别通道。

（4）哈希编码与优化模块（Hash Projection & Fine-grained Optimization）：经过深度融合与通道校准后的高信噪比特征，最终通过全连接层被投影至紧凑的汉明空间。在细粒度度量学习与损失函数的协同优化下，网络强制不同类别的高维特征在离散二进制空间中形成高类内紧凑性与高类间分离度的簇状分布，从而完成最终的高效检索任务。




图 4-1 AP-THNet 算法框架图

#### 4.2.1 分层骨干网络模块

遥感图像的显著特征之一是地物尺度跨度极大。例如，同一幅图像中可能同时包含微小的单体车辆（仅占几个像素）与宏观的连片水域或机场（占据图像大半部分）。为了在统一的框架内兼顾对极端尺度变化的感知，AP-THNet 首当其冲的设计便是构建一个特征金字塔式的层级多尺度骨干网络（Hierarchical Backbone）。该模块不仅是整个前向传播的物理起点，更是后续非对称感知与特征融合的基石。

给定一张输入的遥感图像  $I \in \mathbb{R}^{H \times W \times 3}$ （其中  $H$  和  $W$  分别为图像的高度与宽度），本研究采用去除了全连接分类头的基础深度卷积网络（如 ResNet-50）作为骨干特征提取器。与传统哈希方法仅利用最后一层深层特征不同，本网络通过截取不同深度阶段（Stages）的输出，显式地构建了包含四个层级的多尺度基础特征集合。

具体而言，图像  $I$  经过骨干网络的前向传播，在四个连续的残差阶段提取出层次化的特征图集  $F_{orig} = \{f_{C_2}, f_{C_3}, f_{C_4}, f_{C_5}\}$ 。其数学推导可表示为：

$$f_{C_i} = \Phi_i(I), \quad i \in \{2, 3, 4, 5\} \quad (4-1)$$

其中， $\Phi_i(\cdot)$  表示骨干网络第  $i$  个阶段的非线性映射函数。这四个层级的特征图在空间分辨率与通道维度上呈现严格的递进关系：

浅层特征 ( $f_{C_2}, f_{C_3}$ )：其空间分辨率较高（通常为原图的 1/4 与 1/8），感受野较小。此类特征保留了丰富的空间几何细节与高频纹理信息，是定位微小目标与精确描绘非对称地物

（如细长跑道）边缘轮廓的关键。

深层特征( $f_{c_4}, f_{c_5}$ ): 其经过了多次下采样, 空间分辨率较低(通常为原图的 1/16 与 1/32), 但通道数翻倍, 且感受野覆盖了极大的图像区域。此类特征内含了高度抽象的低频全局语义, 能够有效地把握场景的整体拓扑结构与环境上下文。

通过上述层级感知架构, AP-THNet 将单一分辨率的输入图像转化为包含丰富多尺度表征的特征组  $\{f_{c_2}, f_{c_3}, f_{c_4}, f_{c_5}\}$ 。这些原生的多尺度基础特征并没有被直接用于哈希映射, 而是作为独立的输入流, 分别被平推馈入后续的 HAP 模块, 以接受进一步的非对称几何提纯与干扰剥离。

#### 4.2.2 层次化非对称感知模块

针对遥感影像中目标尺度跨度大、几何形状显著非对称（如机场跑道、长距离桥梁、细长型河流）所导致的特征感知不精准问题, 本章设计了层次化非对称感知模块（Hierarchical Asymmetric Perception, HAP）。如整体架构图中的绿色模块所示, HAP 模块的核心逻辑并非简单的特征通道叠加, 而是一个深度的几何加权空间注意力编码器, 旨在通过非对称的感受野动态锚定目标的几何骨干特征。




图 4-2 HAP 模块结构图

HAP 模块并行嵌于特征金字塔的每一层特征流中。具体而言, 对于输入的第 1 层基础特征图  $X \in \mathbb{R}^{H \times W \times C}$ , 模块将其拆分为上下两个并行分支进行处理, 以从不同维度捕捉目标的长程几何依赖关系:

(1) 几何先验提取支路（上分支）：针对遥感目标显著的非对称几何分布，该支路摒弃了传统的方形池化窗，引入了非对称平均池化（Asymmetric Average Pooling）算子来显式建模目标的骨架形态。该过程包含两个正交的感知路径：

水平感知路径(Horizontal Sensitivity Branch)：沿着特征图的宽度（ $W$ ）维度进行一维全局压缩，提取沿高度方向分布的带状特征  $X_h \in \mathbb{R}^{H \times 1 \times C}$ 。

垂直感知路径(Vertical Sensitivity Branch)：沿着特征图的高度（ $H$ ）维度进行一维全局压缩，提取沿宽度方向延伸的带状特征  $X_v \in \mathbb{R}^{1 \times W \times C}$ 。

这种非对称的物理压缩方式能够极其敏锐地捕获条状地物（如跑道），同时将正交方向上的无关背景噪声直接剔除。随后，这两个路径提取的非对称几何信息通过特征聚合（Feature Aggregation）与多层感知机（Geometric MLP）进行深度融合与维度变换，生成一个专门反映地物空间轮廓特征的几何键矩阵（Geometric Key,  $K_{geom} \in \mathbb{R}^{HW \times d_k}$ ）。

(2) 注意力投影支路（下分支）：与此同时，下分支负责对原始输入特征  $X$  进行线性空间投影。通过两个独立的线性映射矩阵  $W_q$  和  $W_v$ ，生成用于寻址的查询矩阵（Query,  $Q \in \mathbb{R}^{HW \times d_k}$ ）与包含丰富语义的值矩阵（Value,  $V \in \mathbb{R}^{HW \times C}$ ）。

(3) HAP 注意力核心计算（HAP Attention Core）：在注意力计算核心区，本模块的创新之处在于：直接利用提取到的几何先验  $K_{geom}$  作为自注意力机制的键，去指导全局特征的查询与聚合。具体而言，模块首先计算查询矩阵  $Q$  与几何键矩阵  $K_{geom}$  的点积相关性，并进行缩放与 Softmax 归一化，生成具有形状感知能力的非对称空间注意力权重矩阵（Asymmetric Attention Weights,  $A_{asym} \in \mathbb{R}^{HW \times HW}$ ）：

$$A_{asym} = \text{Softmax} \left( \frac{QK_{geom}^T}{\sqrt{d_k}} \right) \quad (4-2)$$

该权重矩阵  $A_{asym}$  精确地刻画了图像中每一个像素点与长条状几何结构之间的依赖关系。随后，利用该非对称权重矩阵对值矩阵  $V$  进行加权聚合，得到注意力输出：

$$Y_{attn} = A_{asym} V \quad (4-3)$$

最终，HAP 模块的输出特征由注意力输出与原始输入通过残差连接（Residual Connection）叠加生成：

$$F_{out}^{HAP} = X + Y_{attn} \quad (4-4)$$

这种从底层物理几何结构出发，到深度特征加权感知的非对称注意力逻辑，赋予了网络极强的抗干扰能力。利用几何先验充当 Key，强制 Query 去匹配具有特定形状轮廓的区域，从而在强化细长地物特征响应的同时，极其有效地剥离了侧向冗余背景的异质干扰，显著优于传统的方形注意力算子。

#### 4.2.3 特征融合与 RSA 重校准模块

在遥感影像中，地物目标的语义信息往往散落在骨干网络的不同层级中：浅层特征（如 C2、C3）富含细粒度的几何纹理，而深层特征（如 C4、C5）则承载了宏观的类别属性。为了实现全尺度范围内的语义覆盖，本章设计了特征融合模块，旨在构建一套跨层级的信息交互路径。

如图 4-1 左侧及中部所示，该模块的运作逻辑主要包含以下两个阶段：

##### （1）基于特征金字塔的渐进式路径

为了缓解深度网络中底层信息的丢失问题，本章构建了一条由底向上的特征金字塔路径。在该路径中，来自骨干网络 ResNet-50 不同阶段的特征映射首先经过 4.2.1 节所述的 HAP 模块进行空间感知增强。随后，通过跳跃连接机制，将低层级的高分辨率特征与经过上采样后的高层级语义特征进行对齐。这种渐进式的融合方式确保了模型在保持高层语义判别力的同时，能够回溯并利用底层的精细结构信息，为后续处理提供多维度的原始素材。

##### （2）多尺度特征级联与语义聚合

在完成各层级的初步对齐后，特征融合模块执行核心的聚合操作。模块将经过 HAP 增强后的各尺度特征图  $f_i^{HAP}$  在通道维度进行级联：

$$F_{fuse} = [f_{C2}^{HAP}, f_{C3}^{HAP}, f_{C4}^{HAP}, f_{C5}^{HAP}] \quad (4-5)$$

通过这种级联方式，跨尺度的特征响应往往被通过线性变换强制投影至共享的语义表示空间。与简单的逐元素相加相比，级联操作能够最大限度地保留各尺度特征的独立性，避免了不同频率信息在融合初期的相互抵消，从而为下一阶段 RSA 模块的通道筛选提供了最完整的语义底座。

该模块的意义在于，它打破了骨干网络单一级别特征的局限性，实现了局部细节与全局语境的深度握手。这种全层级的融合策略，使得最终生成的特征流  $F_{fuse}$  不仅能够识别巨

大的工业园区，也能精准定位其中的细小油罐或车辆。这种鲁棒的特征聚合能力，是提升遥感检索系统在海量异质数据下查全率的根本保障。

如果说上一节中的 HAP 模块通过空间注意力缓解了目标形状非对称带来的感知偏差，那么本节的 RSA 重校准模块（RSA-Fusion Module）则旨在通过通道注意力机制，解决遥感影像中剧烈的尺度波动问题。如图 4-3 所示，该模块部署于金字塔特征融合之后，通过显式建模不同尺度特征通道间的非线性依赖关系，实现对融合特征的自适应动态重校准。




图 4-3 RSA 重校准模块图

值得强调的是，虽然 RSA 模块在底层数学算子上借鉴了经典的 Squeeze-and-Excitation(SE)范式，但其核心创新力与物理意义在于其独特的部署位置与尺度选择属性。传统的通道注意力多应用于单一尺度的局部卷积层内；而本文的 RSA 模块则直接作用于融合了  $C_2$  至  $C_5$  四个阶段的金字塔复合特征  $F_{fused} \in \mathbb{R}^{H \times W \times C}$  之上。由于该特征图的各个通道隐式地表征了从高频微观细节到低频宏观语义的异构信息，RSA 模块实质上跨越了常规的通道加权，完成了一次基于全局上下文的自适应跨尺度融合（Adaptive Cross-Scale Fusion）。其具体的精细化处理逻辑如下：

（1）全局尺度环境压缩（Global Scale Squeeze）：为了使网络具备全局尺度感知能力，RSA 模块首先利用全局平均池化（GAP）将空间维度的信息极致压缩：

$$Z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W F_{fused}(i, j, c) \quad (4-6)$$

这一步将每个通道内所有的空间响应聚合为一个全局描述向量  $\mathbf{Z} \in \mathbb{R}^C$ ，精准捕获了当前影像中大大小小地物的宏观统计分布。

(2) 跨尺度依赖性建模 (Cross-Scale Excitation): 为了实现多尺度的自适应选择, 模块构建了一个具有瓶颈结构的双层全连接网络, 其数学转换过程为:

$$\omega = \sigma(W_2 \delta(W_1 Z)) \quad (4-7)$$

其中,  $\delta$  为 ReLU 激活函数,  $\sigma$  为 Sigmoid 归一化函数。 $W_1$  与  $W_2$  的降维与升维过程, 本质上是在提取不同感受野大小 ( $C_2 \sim C_5$ ) 特征流之间的非线性竞争与协同关系。该过程最终输出一组尺度自适应通道权重 (Scale-Adaptive Channel Weights,  $\omega \in \mathbb{R}^C$ )。

(3) 尺度权重分配与特征重标定 (Rescale): 这组权重  $\omega$  充当了智能尺度路由器的角色: 当输入影像中主导大尺度宏观地物 (如大片森林) 时, 网络会自动分配更高的权重给携带  $C_5$  语义的通道集; 反之, 当目标为细小且密集的车辆时, 则自动拉升携带  $C_2$  高分辨率细节的通道增益。最后, 通过逐通道相乘 ( $\otimes$ ):

$$F_{refined} = \omega \otimes F_{fused} \quad (4-8)$$

输出的细化自适应特征 (Refined Scale-Adaptive Features,  $F_{refined}$ ) 打破了多尺度直接相加带来的特征稀释与语义中和困境。如图 4-3 右侧所示, 提纯后的高信噪比特征直接送入  $\text{sign}(\cdot)$  引导的二进制编码映射 (Binary Code Mapping) 阶段, 确保了最终生成的哈希码在面对复杂尺度突变时具备极高的判别力。

## 4.2.4 哈希编码与优化模块

### 4.2.4.1 哈希空间解码器

哈希空间解码器的核心任务是构建一个从高维连续特征空间到低维离散汉明空间的映射函数。在接收到 RSA 模块输出的细化自适应特征  $F_{refined}$  后, 为了在保持语义信息的同时极致压缩数据冗余, 本模块设计了一个精细的三阶段变换流水线, 通过连续映射、空间规范化和离散量化生成高质量的二值哈希码。

(1) 连续哈希映射阶段: 经过自适应重校准的特征往往仍具有较高的维度与复杂的分布。为了将其压缩至目标哈希码长度  $K$ , 本模块首先通过全局池化将  $F_{refined}$  展平, 随后引入哈希线性投影层。该过程利用可学习的权重矩阵  $W_h$  和偏置  $b_h$  进行维度转换, 并采用双曲正切函数 ( $\tanh$ ) 进行非线性激活:



$$\mathbf{v} = \tanh(\mathbf{W}_h F_{refined}^{pool} + \mathbf{b}_h) \quad (4-9)$$

引入  $\tanh$  激活函数具有双重意义：首先，它将映射后的连续特征值  $\mathbf{v}$  严格限制在  $(-1,1)$  区间内，在数学形式上逼近目标二值空间  $\{-1,1\}^K$ ；其次，其连续可微的特性为深度神经网络的端到端梯度回传提供了基础。

(2) 球面归一化阶段：由于深度特征的模长极易受到样本复杂度、背景噪声及光照变化的影响，直接对特征向量进行量化会导致语义方向的偏移与信息的丢失。为了增强哈希码的判别力并与基于余弦相似度的对比学习框架保持几何一致性，本文对特征  $\mathbf{v}$  执行了球面归一化（Spherical Normalization）：

$$\mathbf{v} = \frac{\mathbf{v}}{\|\mathbf{v}\|_2} \quad (4-10)$$

通过该操作，模型消除了特征绝对尺度的干扰，将所有样本投影至统一的单位超球面上。在此空间内，样本间的欧氏距离等价于角距离，迫使网络专注于学习更加纯粹的语义方向分布，这极大地利于在离散汉明空间中维持原始的拓扑流形。

(3) 量化与推理阶段：在完成空间映射与归一化后，最终需要将连续特征转化为离散的二值哈希码  $\mathbf{b} \in \{-1,1\}^K$ 。这一过程由符号函数（ $\text{sgn}$ ）严格执行：

$$\mathbf{b} = \text{sgn}(\mathbf{v}) \quad (4-11)$$

然而， $\text{sgn}$  函数在零点处的导数趋于无穷，在其他位置导数为零。这种离散跃变会导致网络在反向传播时出现梯度消失，使得优化过程完全停滞。为此，本文采取了训练与推理分离的连续松弛策略：

训练阶段：绕过硬量化的  $\text{sgn}$  函数，直接利用超球面上的连续特征  $\mathbf{v}$  参与损失函数的计算与梯度回传，保证端到端优化的平滑性。

推理阶段：网络参数冻结后，直接应用  $\text{sgn}$  函数对查询图像的特征生成离散的二进制代码，从而支撑起极低存储开销与位运算级别的高速相似度检索。

#### 4.2.4.2 损失函数设计

为了引导 AP-THNet 生成兼具高判别性、紧凑性且分布均匀的哈希码，本文摒弃了单一的监督信号，设计了一个多准则联合优化目标函数。该函数由量化损失、修正圆损失和

中心聚类损失三部分协同驱动，从不同维度对汉明空间的表示学习进行约束。

(1) 量化损失：量化损失 $\mathcal{L}_{quant}$ 是哈希学习中的核心组成部分，旨在最小化连续深度特征与离散二值码之间的转换误差。由于直接优化离散约束具有非确定性多项式难题（NP-hard）特性，本文通过连续松弛技术构建如下目标：

$$\mathcal{L}_{quant} = \|\mathbf{B} - \mathbf{F}\|_F^2 + \lambda \|\mathbf{B}^T \mathbf{B} - \mathbf{I}\|_F^2 \quad (4-12)$$

其中，第一项为 Frobenius 范数下的残差约束，强制连续特征 $\mathbf{F}$ 逼近其二值化目标 $\mathbf{B}$ ；第二项为平衡约束，其物理意义是使哈希码在每一位上生成的+1和-1数量趋于相等。通过迫使自相关矩阵 $\mathbf{B}^T \mathbf{B}$ 接近单位矩阵 $\mathbf{I}$ ，可以最大限度地提高哈希码的信息熵，避免出现所有特征收敛至同一无效编码的退化解。

(2) 修正圆损失：为了在哈希空间中实现更强的语义判别力，本文引入了修正圆损失 $\mathcal{L}_{cc}$ 。传统的对比损失往往对所有样本采用统一的边界（Margin），这忽视了不同类别内部分布的异质性。修正圆损失通过自适应调整正负样本对的权重，定义如下：

$$\mathcal{L}_{cc} = \frac{1}{N} \sum_{i=1}^N \left[ -\log \frac{e^{s(\alpha_p - \|\mathbf{f}_i - \mathbf{w}_{y_i}\|^2)}}{e^{s(\alpha_p - \|\mathbf{f}_i - \mathbf{w}_{y_i}\|^2)} + \sum_{j \neq y_i} e^{s(\alpha_n - \|\mathbf{f}_i - \mathbf{w}_j\|^2)}} \right] \quad (4-13)$$

其中， $\mathbf{w}_j$ 代表第 $j$ 类的特征中心，通过动量更新机制进行实时维护。该损失的核心创新在于修正项 $\alpha_p$ 和 $\alpha_n$ 的引入：

$$\alpha_p = \max(0, \bar{d}_p - m_p) \quad (4-14)$$

$$\alpha_n = \min(\pi, \bar{d}_n + m_n) \quad (4-15)$$

通过计算当前批次内平均类内距离 $\bar{d}_p$ 和类间距离 $\bar{d}_n$ ，算法能够动态地纠正分布偏差。当类内分布较散时，自动增大压缩力度；当类间界限模糊时，自动强化排斥效应。

(3) 中心聚类损失：为了进一步增强二值空间中特征的内聚性，本文提出了中心聚类损失 $\mathcal{L}_{cl}$ 。该损失直接在哈希投影后的空间内操作，显式地约束样本向其所属类别的二值中心 $\mathbf{c}_j \in \{-1, +1\}^d$ 聚拢：

$$\mathcal{L}_{cl} = \frac{1}{N} \sum_{i=1}^N \|\mathbf{b}_i - \mathbf{c}_{y_i}\|^2 + \eta \sum_{j=1}^C \|\mathbf{c}_j^T \mathbf{c}_j - d\|^2 \quad (4-16)$$

第一项通过最小化样本与类别中心的欧氏距离，消除了量化过程中的杂散分布；第二项作为正则项，确保学习到的二值中心保持单位长度，充分利用编码空间的边际区域。这

种类中心锚定机制显著提升了大规模检索时的抗噪能力。

本文最终的总体损失函数定义为上述三者的加权集成：

$$\mathcal{L}_{total} = \mathcal{L}_q + \lambda_1 \mathcal{L}_{CC} + \lambda_2 \mathcal{L}_{cl} \quad (4-17)$$

其中,  $\lambda_1$  和  $\lambda_2$  为平衡权重系数。在训练过程中, 本文配合退火策略 (Annealing Strategy) 动态调整量化强度, 使得模型在初期侧重于学习鲁棒的语义特征, 在后期侧重于严格的二值化约束, 最终生成高质量的判别性哈希码。

### 4.3 实验与分析

#### 4.3.1 实验设置

为了确保本章所提出的 AP-THNet 算法与第 3 章 (FDG-JA 模型) 在性能评价上的公平性与可比性, 本实验在基础设定上保持一致。

(1) 本章在数据集的选取与划分、评价指标体系的构建, 以及对比基线算法的设定上, 均与第 3 章保持一致。具体而言:

数据集: 实验依然在 UCMD、AID 和 NWPU-RESISC45 三大基准数据集上进行, 均采用 80% 作为训练集, 20% 作为查询集的标准协议。

评价指标: 沿用平均检索精度 (mAP)、截断查准率/查全率 ( $P@K$ ,  $Recall@K$ ) 以及 P-R 曲线进行多维度量化评估。

对比方法: 选取包括 CIDH<sup>[89]</sup>、FDG-JA、DGSSH、SCFR 等在内的 9 种主流通用与遥感专用深度哈希算法作为对比基线。以上基础设置的详细定义与参数介绍, 请参阅本文第 3.3.1 与 3.3.2 节。

(2) 模型框架与骨干网络本章提出的 AP-THNet 模型基于 PyTorch 2.0 深度学习框架进行端到端的开发与实现。为了与前置章节保持架构与算力上的连贯性, 模型继续采用在 ImageNet 数据集上预训练的 ResNet-50 作为层级多尺度骨干特征提取网络。

(3) 训练策略与超参数配置在模型训练的参数优化策略上, 本章针对 AP-THNet 的分层架构特点, 设计了一种差分学习率管理机制:

对于加载了预训练权重的骨干网络层, 采用较小的学习率进行微调, 以防止在训练初期破坏已学到的底层通用视觉特征。

对于本章新设计的核心组件 (包括 HAP 层次化非对称感知模块、RSA 尺度自适应重校准模块以及哈希投影解码层), 则采用较大的初始学习率从头训练, 以加速网络对特定遥

感地物几何与尺度特征的收敛。模型统一采用 Adam 优化器进行参数更新，联合损失函数中的各项平衡权重及所有训练超参数均通过验证集上的网格搜索确定。具体的网络超参数实验配置如表 4-1 所示。

表 4-1 模型训练核心超参数配置

| 类别   | 实验参数项             | 配置细节                      |
|------|-------------------|---------------------------|
| 优化策略 | 优化器 (Optimizer)   | Adam                      |
|      | 学习率调度             | 余弦退火策略 (Cosine Annealing) |
|      | 初始学习率 (微调)        | $1 \times 10^{-5}$        |
|      | 初始学习率 (自研模块)      | $1 \times 10^{-4}$        |
| 训练配置 | 最小学习率衰减           | 初始值的 0.01 倍               |
|      | 批次大小 (Batch Size) | 64                        |
|      | 训练轮数 (Max Epoch)  | 100                       |
|      | 图像输入尺寸            | 224×224 像素                |
|      | 缩放系数 $\beta$      | 初始 1.0，每轮递增 0.1           |

4.3.2 消融实验

为了定量分析 AP-THNet 各核心组成模块对整体检索性能的独立贡献，以及不同模块组合之间的协同效应，本节设计了如表 4-2 所示的六种组件配置方案（M-1 至 M-6），并在 UCMD、AID 与 NWPU-RESISC45 三个数据集上进行了系统性的消融实验。

表 4-2 不同消融配置的模块组成

| Component      | M-1 | M-2 | M-3 | M-4 | M-5 | M-6 |
|----------------|-----|-----|-----|-----|-----|-----|
| Cluster Loss   | ✗   | ✓   | ✓   | ✓   | ✓   | ✓   |
| Circle Loss    | ✗   | ✗   | ✓   | ✓   | ✓   | ✓   |
| HAP Block      | ✗   | ✗   | ✗   | ✓   | ✗   | ✓   |
| RSA Block      | ✗   | ✗   | ✗   | ✗   | ✓   | ✓   |
| Feature Fusion | ✗   | ✗   | ✗   | ✗   | ✓   | ✓   |

为清晰剥离各模块的独立增益与协同效应，本节基于正交控制变量原则设计了六阶递进的消融配置。实验首先以仅含骨干网络与基础量化约束的 M-1 作为评估绝对收益的性能锚点；随后通过 M-2（引入中心聚类损失）与 M-3（追加修正圆损失）的逐级叠加，验证了双重度量约束在强化类内紧凑性与动态调整类间排斥边界上的协同底座作用。在确立最

优损失基线（M-3）后，实验展开两个平行的结构消融分支：M-4 独立接入 HAP 模块以验证层次化非对称感受野对不规则几何目标的捕获能力，而 M-5 则仅接入特征融合与 RSA 模块以验证跨尺度通道校准在应对地物尺度突变时的有效性。最终，M-6 汇聚全部核心组件构成完整的 AP-THNet，旨在验证尺度-几何双重感知架构与度量损失在端到端训练下所激发的协同增效潜能。

表 4-3 不同消融配置在不同数据集、不同哈希码长度下的 mAP 对比（%）

| Methods    | UCMD         |              |              |              | AID          |              |              |              | NWPU-RESISC45 |              |              |              |
|------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|---------------|--------------|--------------|--------------|
|            | 32bit        | 64bit        | 128bit       | 256bit       | 32bit        | 64bit        | 128bit       | 256bit       | 32bit         | 64bit        | 128bit       | 256bit       |
| <b>M-1</b> | 96.15        | 96.75        | 96.83        | 96.93        | 92.17        | 92.85        | 93.17        | 93.44        | 89.15         | 89.65        | 90.17        | 90.37        |
| <b>M-2</b> | 96.82        | 97.24        | 97.51        | 97.85        | 93.34        | 93.93        | 94.13        | 94.48        | 90.17         | 90.85        | 91.09        | 91.39        |
| <b>M-3</b> | 97.63        | 97.88        | 98.11        | 98.34        | 94.82        | 95.07        | 95.29        | 95.53        | 91.39         | 92.09        | 92.57        | 92.90        |
| <b>M-4</b> | 98.45        | 98.65        | 98.79        | 98.84        | 96.29        | 96.82        | 96.99        | 97.13        | 93.48         | 94.11        | 94.48        | 94.79        |
| <b>M-5</b> | 98.24        | 98.58        | 98.76        | 98.87        | 96.17        | 96.91        | 97.14        | 97.26        | 93.89         | 94.32        | 94.55        | 94.86        |
| <b>M-6</b> | <b>99.12</b> | <b>99.41</b> | <b>99.78</b> | <b>99.54</b> | <b>97.33</b> | <b>97.62</b> | <b>97.97</b> | <b>97.98</b> | <b>96.36</b>  | <b>96.65</b> | <b>97.08</b> | <b>97.05</b> |

根据表 4-3 所示的实验结果，六种不同配置在三个基准数据集上呈现出性能递进趋势，充分证明了 AP-THNet 各模块的独立贡献与协同增效作用。具体深入分析如下：

（1）双重量度损失的阶梯式增益（M-1 vs. M-2 vs. M-3） 度量损失的引入对模型基础表征能力的提升起到了作用。以难度最大的 NWPU-RESISC45 数据集（32bit）为例，仅包含基础量化损失的基线 M-1 取得了 89.15% 的 mAP。引入中心聚类损失（M-2）后，性能提升至 90.17%，这表明显式的类中心锚定机制有效消除了离散空间的杂散分布。在此基础上进一步叠加修正圆损失（M-3）后，mAP 跃升至 91.39%。这一阶梯式的涨点轨迹有力证实了：Cluster Loss 与 Circle Loss 具有极强的互补性。前者约束类内特征绝对紧凑，后者动态拉大类间排斥边界，两者协同构筑了稳固的哈希特征底座。

（2）结构模块的独立正交贡献（M-4, M-5 vs. M-3）在最优损失基线（M-3）的基础上，空间与通道维度的架构创新均展现出了显著的独立增益。

非对称空间感知增益（M-4）：仅接入 HAP 模块后，M-4 在各数据集上均实现了稳步提升。例如在 UCMD 32bit 下，M-4（98.45%）较 M-3（97.63%）提升了约 0.8%。这证明了 HAP 模块特有的长条形感受野能够有效剥离侧向背景，精准捕获遥感影像中的不规则几何轮廓。

跨尺度通道校准增益（M-5）：仅接入 Feature Fusion 与 RSA 模块后，M-5 在尺度变化

剧烈的 AID 数据集 128bit 下达到了 97.14%，显著优于 M-3 的 95.29%。这直观反映了金字塔级联与自适应通道选择机制在缓解地物尺度突变、抑制特征稀释方面的卓越效能。

（3）全链路架构的完美协同效应（M-6 vs. All）M-6 作为本章提出的完整 AP-THNet 模型，将三大结构模块与双重度量损失进行了端到端联合优化。实验数据表明，M-6 在所有数据集与码长设置下均取得了压倒性的最优表现。值得注意的是，在背景干扰最强的 NWPU 数据集 32bit 设置下，M-6 达到了 96.36%的检索精度，相比于基础网络 M-1 实现了 +7.21%的增长，且明显高于任何单一结构强化的变体（M-4, M-5）。这一性能呈现，验证了本章尺度-几何双重感知理念的前瞻性：只有将物理层面的全链路特征提纯与数学层面的严密离散约束深度结合，才能在复杂海量的遥感检索任务中表现较好的性能。

4.3.3 算法对比分析

为全面评估 AP-THNet 的检索性能，本节在 UCMD、AID 与 NWPU-RESISC45 三个遥感图像基准数据集上，将所提方法与 CIDH<sup>[89]</sup>、FD-GJA、DGSSH[72]、SCFR[58]、FAH[21]、AHCL[73]、CSQ[69]、IDHN[53]、Greedy[54]共九种代表性深度哈希方法进行系统对比，哈希码长度分别设置为 32、64、128、256 位，对比结果如表 4-4 所示。

表 4-4 不同方法在不同数据集、不同哈希码长度下的 mAP 对比（%）

| Methods  | UCMD  |       |        |        | AID   |       |        |        | NWPU-RESISC45 |       |        |        |
|----------|-------|-------|--------|--------|-------|-------|--------|--------|---------------|-------|--------|--------|
|          | 32bit | 64bit | 128bit | 256bit | 32bit | 64bit | 128bit | 256bit | 32bit         | 64bit | 128bit | 256bit |
| AP-THNet | 99.12 | 99.41 | 99.78  | 99.54  | 97.39 | 97.62 | 97.97  | 97.98  | 96.36         | 96.65 | 97.08  | 97.05  |
| CIDH     | 98.95 | 98.82 | 98.86  | 98.88  | 96.88 | 96.91 | 96.41  | 96.63  | 94.15         | 94.26 | 94.96  | 94.77  |
| FDG-JA   | 98.63 | 98.75 | 98.81  | 99.04  | 96.18 | 96.73 | 96.79  | 97.25  | 94.18         | 94.34 | 94.55  | 94.05  |
| DGSSH    | 98.21 | 98.6  | 98.58  | 98.67  | 95.31 | 96.61 | 96.74  | 96.77  | 92.31         | 93.45 | 93.42  | 94.75  |
| SCFR     | 97.65 | 97.95 | 98.03  | 98.14  | 93.79 | 94.42 | 94.59  | 94.53  | 90.48         | 91.11 | 91.78  | 91.79  |
| FAH      | 93.73 | 95.87 | 97.07  | 97.06  | 92.01 | 91.99 | 92.71  | 93.24  | 89.48         | 89.83 | 90.77  | 90.68  |
| AHCL     | 95.93 | 96.51 | 96.81  | 97.14  | 92.46 | 92.75 | 93.48  | 93.54  | 86.51         | 90.13 | 91.86  | 93.88  |
| CSQ      | 97.64 | 97.84 | 97.76  | 97.62  | 92.99 | 93.42 | 93.34  | 93.11  | 89.28         | 89.6  | 89.33  | 89.37  |
| IDHN     | 93.27 | 93.59 | 94.83  | 95.04  | 91.91 | 92.56 | 92.63  | 92.79  | 88.78         | 87.99 | 88.28  | 88.48  |
| Greedy   | 96.16 | 95.62 | 93.75  | 93.28  | 92.39 | 93.24 | 93.73  | 94.18  | 89.53         | 90.59 | 90.83  | 91.19  |

为验证本章所提模型的有效性，表 4-4 列出了 AP-THNet 与 9 种主流深度哈希方法在三个遥感数据集、四种哈希码长度下的平均检索精度（mAP）对比结果。综合实验数据，可得出以下结论：

(1) 整体检索性能对比在不同数据集与哈希码长度的交叉实验配置中, AP-THNet 整体取得了最优的检索表现。在场景相对简单的 UCMD 数据集上, 该模型在各码长下均保持了极高的精度水平 (最高达 99.78%); 在数据规模更大、背景更复杂的 NWPU-RESISC45 数据集上, AP-THNet 依然取得了 96.36%~97.08% 的 mAP 值。这表明所提的分层非对称感知架构在不同复杂度的遥感场景下均具备良好的特征提取与检索能力。

(2) 对前序章节模型的改进与提升作为本文研究的递进, AP-THNet 较好地弥补了第 3 章 FDG-JA 模型的局限性。对比表 4-4 数据可知, 虽然 FDG-JA 的性能已优于多数对比基线, 但 AP-THNet 在各项指标上均实现了进一步的提升。特别是在尺度跨度较大的 NWPU-RESISC45 数据集 32 位设置下, AP-THNet (96.36%) 较 FDG-JA (94.18%) 提升了 2.18 个百分点。这客观验证了: 引入非对称空间感知与跨尺度特征融合机制, 能够比单一的频域解耦捕获更加丰富的地物判别信息。

(3) 在复杂数据集上的鲁棒性分析横向对比其他外部主流方法 (如 DGSSH、AHCL、SCFR), AP-THNet 的性能优势随着数据集复杂度的增加而更加明显。在 UCMD 数据集上, AP-THNet 领先次优方法 (CIDH) 约 0.17~0.92 个百分点; 而在类别最庞杂的 NWPU-RESISC45 数据集上, 这一领先幅度扩大至 2 个百分点。相对而言, 部分早期方法 (如 IDHN) 在复杂数据集的短码长下性能下降较多, 表现出一定的局限性。这表明, AP-THNet 具备较强的抗背景干扰能力, 在处理大规模复杂遥感图像检索任务时具有更高的鲁棒性。

(4) 哈希码长度对性能的影响趋势纵向观察哈希码长度的变化规律可以发现, 多数对比方法的性能普遍随码长的增加而提升, 但在超过 128 位后增益趋于平缓甚至略有下降, 这主要是由于过长的编码可能引入额外的冗余信息。在此趋势下, AP-THNet 在 128 位与 256 位之间保持了较小的性能波动 (如在 AID 数据集中为 97.97% 与 97.98%)。这说明所提的度量损失函数能够较好地利用高维汉明空间, 使模型对哈希码长度的选择表现出一定的稳定性。

为了更直观地展示各算法在连续检索过程中的综合性能评估, 图 4-4、图 4-5 与图 4-6 分别给出了 12 种对比算法在 UCMD、AID 和 NWPU-RESISC45 三个基准数据集上 (以 128-bit 为例) 的 Recall@K 曲线、Precision@K 曲线以及 P-R (查准率-查全率) 曲线对比结果。从图中可以清晰地观察到, 本文提出的 AP-THNet 在所有评价维度上均展现出了领先优势。






图 4-4 AP-THNet 在 UCMD 检索性能曲线




图 4-5 AP-THNet 在 AID 检索性能曲线




图 4-6 AP-THNet 在 NWPU-RESISC45 检索性能曲线

(1) Recall@K 与查全效率 Recall@K 曲线（左侧子图）反映了模型在有限返回样本中找回所有相关目标的能力。在三个数据集中，AP-THNet 均呈现出最陡峭的上升趋势与最快的收敛速度。例如在 UCMD 数据集上，本文方法在 Top-100 附近即率先逼近 1.0 的召回上限。这一现象直观地印证了特征融合与 RSA 重校准模块的有效性：通过金字塔多尺度级联与通道提纯，模型最大程度地保留了底层高频细节与高层宏观语义，使得系统即使面对大尺度跨度的异质目标，也能做到不漏检，展现出较高的检索效率。

(2) Precision@K 与局部排序精度 Precision@K 曲线（中间子图）衡量了系统在返回

前  $K$  个结果时的排位准确性。无论是在场景相对简单的 UCMD，还是在类内差异极大的 AID 数据集上，AP-THNet 在各个检索深度  $K$  下均维持了最高的准确率水平。尤其是在  $K$  值较小（如 Top-50）的初始检索阶段，本文方法几乎实现了零误判。这主要归功于 HAP 层次化非对称感知模块的引入：该模块利用长条形感受野精准锚定了不规则地物（如细长河流、跑道）的几何骨干，抑制了侧向无关背景像素的激活，从而在相似度排序时，将真正具有高语义相关性的样本推向了检索序列的最前端。

(3) P-R 曲线是衡量检索系统综合性能最核心的指标。在三个数据集的 P-R 曲线图（右侧子图）中，AP-THNet 的红色曲线始终处于最外侧，最贴近坐标系的右上角，拥有最大的曲线下面积（AUC）。特别是在类别最庞杂、背景干扰最强的 NWPU-RESISC45 数据集中，当召回率（Recall）逼近 1.0 的极限水平时，多数基线算法（如 IDHN）的查准率出现了断崖式下跌，而 AP-THNet 依然能维持在一个极高的准确率平台。这有力地证明了：本章所提出的尺度-几何双重感知架构，成功克服了遥感图像中尺度突变与背景冗余带来的语义混淆，确保了哈希码在极高维特征空间中的纯净度与判别力。

#### 4.3.4 超参数分析

在多准则联合优化目标中，平衡系数  $\lambda_1$  与  $\lambda_2$  分别控制着类间判别损失与类内紧凑损失对总体梯度的相对贡献权重。为系统评估 AP-THNet 对这两个超参数的敏感程度，并在不同数据集上搜索最优参数空间，本节对  $\lambda_1$  和  $\lambda_2$  的取值范围进行了二维网格搜索，并绘制了如图 4-7 所示的 mAP 响应三维曲面。




图 4-7 不同数据集上互补损失函数超参数  $\lambda_1$ 、 $\lambda_2$  的敏感性分析

##### (1) 小型简单场景下的参数响应（UCMD 数据集）

如图 4-7 (a)所示，在场景相对简单、数据规模较小的 UCMD 数据集上，mAP 响应曲

面呈现出较为陡峭的峰值特征。最优参数组合锁定在  $\lambda_1 = 22, \lambda_2 = 6$ ，对应峰值 mAP 达 0.9980。观察曲面走势可知，当  $\lambda_2 = 0$ （即退化为仅使用类间判别损失）时，模型性能出现明显下滑。这证明了：在小规模数据集中，由于样本多样性有限，必须施加强有力的类内紧凑约束（ $\lambda_2 > 0$ ）来强制同类特征聚集，才能避免过拟合，形成具有良好泛化性的哈希空间。

#### （2）大型复杂场景下的参数响应（AID 与 NWPU-RESISC45 数据集）

与 UCMD 显著不同，在规模更大、类别更复杂的 AID 与 NWPU-RESISC45 数据集上如图 4-7(b), (c)所示，超参数的响应曲面呈现出高度一致的规律，最优参数组合均出现在  $\lambda_1 = 28, \lambda_2 = 0$  处，且曲面在  $\lambda_1$  轴方向上（100~300 区间）表现出极强的平缓鲁棒性。 $\lambda_2$  的最优取值趋近于 0，这一现象与复杂数据集本身的拓扑结构密切相关。AID 与 NWPU 数据集不仅类别繁多（分别为 30 类和 45 类），且每类包含极大的跨尺度与视角变化，导致类内样本的自然分布呈现出高度的多样性。在这种极端异质化的场景下，若过度施加刚性的类内紧凑约束（增大  $\lambda_2$ ），反而会强行消除类内特征的自然多样性，压缩模型的表达上限。因此，在海量复杂场景中，网络更倾向于依赖适度的类间排斥（ $\lambda_1 = 28$ ）来划分决策边界，而非苛求类内的绝对聚集。

综合上述分析可知，AP-THNet 对超参数的依赖具有显著的数据规模驱动特性：在小数据上需要排斥与聚集双管齐下；而在大数据上则应遵循重排斥、轻聚集的松弛策略。此外，三个数据集的响应曲面在最优解附近均存在宽阔的高值平坦区，表明所提模型对参数微小扰动不敏感，在实际部署中无需严苛调参即可保持优异的检索性能。

### 4.3.5 特征可视化分析

为了直观揭示 AP-THNet 卓越检索性能的潜在视觉机理，本节利用 t-SNE (t-Distributed Stochastic Neighbor Embedding) 算法，将提取到的高维特征降维至二维平面进行可视化。图 4-8 综合展示了 UCMD、AID 与 NWPU-RESISC45 三个基准数据集在骨干网络初始提取 (Original Distribution) 与 AP-THNet 最终优化 (Learned Distribution) 后的特征分布演变过程。




图 4-8 训练前后特征分布对比图

从横向对比可以清晰地观察到，在原始特征空间中（如各组上图所示），由于遥感影像固有的高异质性与复杂的背景干扰，不同类别的样本点呈现出高度混叠的弥散状态，类间边界极度模糊。然而，经过 AP-THNet 的端到端联合优化后（如各组下图所示），特征空间实现了显著的拓扑重构：各场景类别的样本点在二维流形上呈现出极高的内聚性与外斥性，几乎消除了语义交叉现象。

这一显著的聚类演变，印证了本章理论设计的有效性：一方面，HAP 与 RSA 模块组成的尺度-几何双重感知架构精准剥离了冗余的背景噪声，提取了高纯度的判别性特征；另一方面，修正圆损失（Circle Loss）与中心聚类损失（Cluster Loss）的协同优化在度量空间中发挥了关键作用——前者强力推开了不同类别之间的决策边界，后者强制同类样本向专属的二值中心极度收敛。正是这种从特征感知到度量约束的全链路协同，赋予了 AP-THNet 在面对 NWPU-RESISC45 等包含 45 类复杂异质地物的极端场景时，依然能够生成具备极高语义保真度的哈希编码，从而确立了其在大规模检索任务中的领先优势。

为了从神经网络的视觉感知机理层面直观证明 AP-THNet 的优越性，本节采用梯度加权类激活映射（Grad-CAM）技术，对提取到的深层特征进行了空间注意力热力图可视化。如图 4-9 所示，实验选取了三大数据集中涵盖停车场、河流弯道、飞机与工业储罐等多尺度、非对称典型场景，将本文提出的 AP-THNet 与传统 CNN、纯视觉 Transformer (ViT) 以及 Swin Transformer 进行了横向视觉对比。






图 4-9 不同机制在三个数据集下的热力图可视化对比

（1）基线模型感知局限性分析：观察图 4-9 中的前三行基线模型响应可以发现，现有架构在处理复杂遥感场景时普遍存在感知盲区：CNN 注意力受限于局部方形感受野，其热力图多呈碎片化分布，仅能捕捉道路边缘或建筑轮廓等局部高频细节，缺乏全局连续性；ViT 的 Token 级注意力虽然具备了全局视野，但受固定的图块切分（Patch-based）机制影响，不仅呈现出明显的块状伪影，还对无语义的背景区域产生了大量错误响应（如图中飞机场场景的周边草地）；Swin 窗口注意力一定程度上平滑了特征，但在处理极端多尺度的储罐或细长河流时，仍存在响应过度扩散、边界聚焦不准的现象。

（2）AP-THNet 感知优越性分析：相比之下，AP-THNet 的响应在所有测试场景中均展现出了较好的精准度、连续性与强烈的抗干扰能力，印证了本章理论架构设计的正确性：

非对称几何结构的精准锚定（对应 HAP 模块）：在面临 AID 的河流弯道与 NWPU 的线性停机坪等极其不规则的地物时，AP-THNet 展现出了强大的形态追踪能力。得益于 HAP 模块的长条形非对称感受野，模型能够沿着地物的自然延伸方向形成连续、完整的红色高响应带，克服了 CNN 的断裂感与 ViT 的块状伪影，实现了将侧向的无关背景剥离。

极端多尺度目标的自适应覆盖（对应 RSA 模块）：在面临 UCMD 密集的微小车辆或 NWPU 巨大的工业储罐时，RSA 模块的跨尺度通道提纯机制发挥了决定性作用。AP-THNet 既能精准定位微小的单体目标区域，又能自适应放大感受野以覆盖大面积的宏观工业轮廓，没有出现基线模型中顾此失彼或响应弥散的现象。

高纯度的语义聚焦与背景抑制：在复杂场景下，AP-THNet 的红色最高响应区域始终与真实地物语义边界达到像素级的高度吻合。这种强聚焦和强抑制的特征感知机制，从视觉机理的底层逻辑上解释了：为什么 AP-THNet 能够生成极具判别力的哈希编码，并在定

量检索实验中取得超越 SOTA 算法的精度。

#### 4.3.6 检索结果可视化

为了最直观地呈现本章 AP-THNet 算法在真实遥感场景下的特征对齐与检索能力，本节在 UCMD、AID 和 NWPU-RESISC45 三个数据集上分别进行了 Top-10 检索结果的可视化对比实验。绿色边框代表检索样本与查询图像 (Query) 属于同一语义类别，红色边框则代表误检。





















| Query                                                                               | Retrieval Results                                                                   |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                      |                                                                                       |                                                                                       |                                                                                       |                          |
|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|--------------------------|
|  |    |    |    |    |    |    |    |    |    |    | AP-THNet<br>P@50<br>100% |
|                                                                                     |   |   |   |   |   |   |   |   |   |   | CIDH<br>P@50<br>92%      |
|                                                                                     |  |  |  |  |  |  |  |  |  |  | FDG-JA<br>P@50<br>100%   |
|                                                                                     |  |  |  |  |  |  |  |  |  |  | DGSSH<br>P@50<br>22%     |
|                                                                                     |  |  |  |  |  |  |  |  |  |  | SCFR<br>P@50<br>96%      |
|                                                                                     |  |  |  |  |  |  |  |  |  |  | FAH<br>P@50<br>22%       |
|                                                                                     |  |  |  |  |  |  |  |  |  |  | AHCL<br>P@50<br>76%      |
|                                                                                     |  |  |  |  |  |  |  |  |  |  | CSQ<br>P@50<br>62%       |
|                                                                                     |  |  |  |  |  |  |  |  |  |  | IDHN<br>P@50<br>66%      |
|                                                                                     |  |  |  |  |  |  |  |  |  |  | Greedy<br>P@50<br>54%    |

图 4-10 AP-THNet 在 UCMD 检索效果

如图 4-10 所示，在给定一张纹理细节极其复杂的密集住宅区作为查询图像时，本文的 AP-THNet 在前 10 位检索结果中实现了完美的 100% 准确匹配，且 P@50 指标达到了 100%。相比之下，传统的哈希算法（如 FAH，P@50 仅为 22%）在此场景下遭遇了严重的感知钝化，其返回结果中掺杂了大量视觉纹理相似但类别完全不同的干扰图像。这直观证明了 AP-THNet 能够有效抵抗同质化纹理的干扰，生成具有高纯度的二进制编码。

针对类内差异更大、尺度变化更剧烈的 AID 数据集，图 4-11 展示了以公园为查询样



本的检索表现。该场景中不仅包含大面积的植被背景，还散落着极度微小的人工建筑。在此极端尺度波动下，AP-THNet 依然保持了前 10 位全绿的统治级表现（P@100 达 100%）。反观其他主流算法，即便是表现较好的 SCRF，其检索序列中也混入了部分误检样本；而 CSQ 等早期方法更是出现了大量的误检样本。这印证了本章引入的 RSA 特征融合与跨尺度自适应校准机制的效能，确保了模型在大尺度宏观背景下依然不会漏检微观关键特征。

| Query                                                                                     | Retrieval Results                                                                   |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                      |                                                                                       |                                                                                       |                                                                                       |                           |
|-------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------|
| <br>AID |    |    |    |    |    |    |    |    |    |    | AP-THNet<br>P@100<br>100% |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | CIDH<br>P@100<br>68%      |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | FDG-JA<br>P@100<br>98%    |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | DGSSH<br>P@100<br>99%     |
|                                                                                           |   |   |   |   |   |   |   |   |   |   | SCFR<br>P@100<br>99%      |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | FAH<br>P@100<br>99%       |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | AHCL<br>P@100<br>81%      |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | CSQ<br>P@100<br>74%       |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | IDHN<br>P@100<br>79%      |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | Greedy<br>P@100<br>39%    |

图 4-11 AP-THNet 在 AID 检索效果

图 4-12 展示了在类别最庞杂的 NWPU-RESISC45 数据集上，针对不规则住宅街区的检索结果。该场景地物排列极不规则，且伴有强烈的线性道路干扰。AP-THNet 凭借 HAP 模块的非对称空间感知能力，精准锁定了不规则地物的几何骨架，再次实现了 Top-10 的完美检索（P@100 达 100%）。而 IDHN（4%）与 Greedy（2%）等方法则频繁将该场景误检为高速公路或工业区。



| Query                                                                                     | Retrieval Results                                                                   |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                      |                                                                                       |                                                                                       |                                                                                       |                           |
|-------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------|
| <br>NWPU |    |    |    |    |    |    |    |    |    |    | AP-THNet<br>P@100<br>100% |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | CIDH<br>P@100<br>92%      |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | FDG-JA<br>P@100<br>31%    |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | DGSSH<br>P@100<br>96%     |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | SCFR<br>P@100<br>91%      |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | FAH<br>P@100<br>99%       |
|                                                                                           |    |    |    |    |    |    |    |    |    |    | AHCL<br>P@100<br>8%       |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | CSQ<br>P@100<br>49%       |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | IDHN<br>P@100<br>4%       |
|                                                                                           |  |  |  |  |  |  |  |  |  |  | Greedy<br>P@100<br>2%     |

图 4-12 AP-THNet 在 NWPU-RESISC45 检索效果

值得指出的是，本章的 AP-THNet 算法突破了第 3 章 FDG-JA 模型的性能瓶颈。回顾第 3 章的检索可视化可知，FDG-JA 虽然通过频域解耦有效剥离了同质化背景噪声，但在处理诸如本节图 4-11（AID 跨尺度目标）与图 4-12（NWPU 狭长不规则街区）等场景时，偶尔会因单一感受野的局限性而产生语义偏移。而本章的 AP-THNet 通过 HAP 非对称空间感知与 RSA 金字塔通道重校准的双重加持，克服了地物尺度突变与几何非对称带来的感知盲区。它不仅优于现有的 SOTA 基线算法，更实现了对前序研究的优化，在视觉和量化层面上达成了哈希检索闭环。

#### 4.4 本章小结

本章针对遥感图像中地物目标尺度跨度剧烈、几何形态高度非对称等导致特征感知受限与语义对齐偏差的痛点问题，在上一章特征解耦研究的基础上实现了逻辑递进，提出了一种基于分层非对称感知与尺度自适应融合的深度哈希检索方法（AP-THNet）。

首先，本章构建了由底向上的层级感知架构，并创新性地设计了层次化非对称感知模

块（HAP）。该模块利用长条形感受野精准锚定了不规则地物的几何骨架，有效剥离了侧向背景噪声。其次，设计了金字塔特征融合与 RSA 重校准模块，通过显式建模多尺度通道间的非线性依赖关系，实现了对跨尺度异质特征的自适应提纯与动态选择。最后，在哈希空间解码阶段，引入了修正圆损失与中心聚类损失的双重度量优化机制，在增强类内特征紧凑性的同时，动态拉大了类间排斥边界，确保了连续空间到离散汉明空间映射的高语义保真度。最后，在 UCMD、AID 和 NWPU-RESISC45 三大基准数据集上开展了系统的定量对比与定性可视化实验。实验结果一致表明：AP-THNet 不仅在各项检索指标上优于第三章的方法和现有的 9 种主流深度哈希算法，同时消融实验与特征可视化分析（Grad-CAM 与 t-SNE）证实了尺度-几何双重感知架构在应对复杂遥感海量数据时，具备优秀的特征表达能力与抗干扰鲁棒性。

## 5 总结与展望

### 5.1 总结

近年来，随着空天对地观测技术的飞速发展，遥感图像在资源调查、环境监测及城市治理等领域展现出巨大的应用潜力。海量遥感数据的爆发式增长，虽然为地表精确感知提供了丰富素材，但也对信息的快速检索与高效利用提出了严峻挑战。由于遥感图像具有视角独特、背景高度复杂、目标尺度跨度剧烈等特性，其在语义表达上呈现出极强的空间异质性，传统的检索技术难以在兼顾效率的同时精准捕获核心语义。在此背景下，深度哈希技术因其卓越的存储效率与检索性能，逐渐成为遥感图像处理领域的研究热点。然而，如何在杂乱背景中剥离冗余噪声、在剧烈的尺度波动中提取稳健特征，仍是制约检索精度进一步提升的技术瓶颈。本文紧密围绕上述关键科学问题，开展了以下三项核心研究工作：

(1) 提出了基于特征解耦引导的联合注意力遥感深度哈希检索方法 (FDG-JA)。针对遥感图像中同质化背景面积大、核心目标尺度小，导致传统网络在特征提取时容易产生冗余响应的问题，本文从物理底层逻辑出发，引入了频域解耦骨干网络。通过离散小波变换将图像分解为高、低频子带，在底层初步实现了背景与目标的分离。在此基础上，设计了特征解耦门控 (FDG) 模块，通过生成纯净的先验信号引导通道与空间双向注意力机制，实现了对深层判别性语义区域的精准聚光。实验证明，该方法有效打破了背景噪声淹没核心目标的僵局，在提高特征提取纯度的同时，显著缓解了量化过程中的语义漂移。

(2) 提出了基于分层非对称感知与尺度自适应融合的深度哈希检索网络 (AP-THNet)。针对遥感地物目标尺度变化剧烈、几何分布非对称，以及跨层级特征融合易产生信息失真的难题，本文在频域解耦的基础上实现了逻辑递进。首先，创新性地设计了层次化非对称感知模块 (HAP)，通过水平与垂直方向的带状池化操作，精准捕获了跑道、河流等不规则目标的几何特征，剥离了侧向冗余背景。其次，引入了尺度自适应特征融合机制 (RSA)，动态重校准了金字塔各层级特征的通道权重，实现了微观细节与宏观语义的协同补全。此外，在哈希空间解码阶段，引入了修正圆损失与中心聚类损失的双重度量优化机制，动态拉大了类间排斥边界并强化了类内紧凑性。该架构提升了模型对尺度与形态畸变的适应度。

(3) 开展了全面的系统测试与多维度实验验证。本文在 UCMD、AID 和 NWPU-RESISC45 三大主流遥感图像基准数据集上进行了广泛的实验验证。定量结果显示，本文提出的 FDG-JA 与 AP-THNet 模型在 32-bit 到 256-bit 的各个哈希编码阶段，其 mAP 指标

均显著优于现有的前沿对比方法。尤其在 AP-THNet 模型的高维编码下, AID 和 NWPU 数据集的 mAP 分别达到了 97.98%和 97.08%, 展现了极其统治级的特征建模能力。同时, 结合 t-SNE 特征分布可视化与 Grad-CAM 注意力热力图分析, 从数学度量与视觉机理双重层面, 证明了本文算法在处理大规模、高动态范围遥感图像检索任务中的优势与强鲁棒性。

## 5.2 展望

尽管本文构建的基于特征解耦引导与分层非对称感知的深度哈希框架, 在复杂遥感场景下的特征纯化与尺度自适应方面展现出显著优势, 并有效提升了检索精度, 但立足于人工智能技术的快速迭代周期与对地观测任务日益增长的实战需求, 本研究在模型泛化边界、跨模态语义交互深度以及算法在受限环境下的部署灵活性等方面仍存在进一步优化的空间。为了持续推动遥感大数据检索向智能化、精准化与工程化方向迈进, 后续工作将聚焦于以下两个维度进行纵深探索:

(1) 引入视觉大模型先验以增强语义泛化能力。当前以 SAM、DINOv2 为代表的视觉底座大模型在特征表达的普适性上展现出巨大潜力。未来研究可尝试将大模型的全场景认知能力与本文提出的特征解耦机制相结合, 通过知识蒸馏或适配器微调(Adapter Tuning)技术, 进一步提升模型在极端复杂、长尾分布遥感场景下的语义建模精度。

(2) 探索多源跨模态遥感图像哈希检索技术。本文目前主要聚焦于以图搜图的同构检索模式, 而实际应用中用户往往倾向于利用自然语言进行检索。未来可考虑构建基于图文对齐(如 CLIP 架构)的跨模态哈希框架, 研究如何将文本语义与遥感图像的物理频率特征进行深度融合, 从而实现更加灵活、直观的多模态交互式检索, 提升系统的实用价值。

## 参考文献

- [1] Ecosystem C D S. Copernicus Data Space Ecosystem| Europe's Eyes on Earth[EB/OL].(2024).
- [2] Wang L, Yan J, Ma Y. Cloud computing in remote sensing[M]. Chapman and Hall/CRC, 2019.
- [3] Ustin S L, Middleton E M P. Current and near-term earth-observing environmental satellites, their missions, characteristics, instruments, and applications[J]. Sensors, 2024, 24(11): 3488.
- [4] Zhou W, Guan H, Li Z, et al. Remote sensing image retrieval in the past decade: Achievements, challenges, and future directions[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 1447-1473.
- [5] Ahmadzadeh A, Adhyapak R, Iraj A, et al. A guide for manual annotation of scientific imagery: How to prepare for large projects[J]. arXiv preprint arXiv:2508.14801, 2025.
- [6] Ugale P, Railkar P. Deep Learning Based Remote Sensing Image Annotation Based on Semantic and Contextual Information[J]. Mathematical Modelling of Engineering Problems, 2025, 12(10).
- [7] Dubey S R. A decade survey of content based image retrieval using deep learning[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(5): 2687-2704.
- [8] Sukhia K N, Riaz M M, Ghafoor A, et al. Content-based remote sensing image retrieval using multi-scale local ternary pattern[J]. Digital Signal Processing, 2020, 104: 102765.
- [9] Zhang C, Liu J. Content based deep learning image retrieval: A survey[C]//Proceedings of the 2023 9th international conference on communication and information processing. 2023: 158-163.
- [10] Zhu X X, Tuia D, Mou L, et al. Deep learning in remote sensing: A comprehensive review and list of resources[J]. IEEE geoscience and remote sensing magazine, 2017, 5(4): 8-36.
- [11] Chen X, Qin Q, Hou J, et al. Deep neighbor-aware hashing with global-local representation for multi-label remote sensing image retrieval[J]. Signal Processing: Image Communication, 2026: 117537.
- [12] Liu P, Liu Z, Shan X, et al. Deep hash remote-sensing image retrieval assisted by semantic cues[J]. Remote Sensing, 2022, 14(24): 6358.
- [13] Tang X, Yang Y, Ma J, et al. Meta-hashing for remote sensing image retrieval[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-19.
- [14] Li Y, Zhang Y, Huang X, et al. Large-scale remote sensing image retrieval by deep hashing neural networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 56(2): 950-965.
- [15] Cai Z, Pan Y, Jin W. Proxy-based rotation invariant deep metric learning for remote sensing image

- p retrieval[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 7759-7772.
- [16] Qi K, Yang C, Hu C, et al. Rotation invariance regularization for remote sensing image scene classification with convolutional neural networks[J]. Remote Sensing, 2021, 13(4): 569.
- [17] Mahdianpari M, Salehi B, Rezaee M, et al. Very deep convolutional neural networks for complex land cover mapping using multispectral remote sensing imagery[J]. Remote Sensing, 2018, 10(7): 1119.
- [18] Rana S, Gerbino S, Carillo P. Study of spectral overlap and heterogeneity in agriculture based on soft classification techniques[J]. MethodsX, 2025, 14: 103114.
- [19] Liao Y, Hu Z, Jin F, et al. MSSA: A Multi-Scale Semantic-Aware Method for Remote Sensing Image-Text Retrieval[J]. Remote Sensing, 2025, 17(19): 3341.
- [20] Chu J, Li L, Xiao X. Remote sensing image retrieval by multi-scale attention-based CNN and product quantization[C]//2021 40th Chinese Control Conference (CCC). IEEE, 2021: 8292-8297.
- [21] Barz B, Denzler J. Content-based image retrieval and the semantic gap in the deep learning era[C]//International Conference on Pattern Recognition. Cham: Springer International Publishing, 2021: 245-260.
- [22] Liu Y, Zhang D, Lu G, et al. A survey of content-based image retrieval with high-level semantics[J]. Pattern recognition, 2007, 40(1): 262-282.
- [23] Wang M, Guo J, Song B, et al. Graph-based hierarchical semantic consistency network for remote sensing image-text retrieval[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2025.
- [24] Alegavi S, Sedamkar R. Optimizing remote sensing image retrieval through a hybrid methodology[J]. Journal of Imaging, 2025, 11(6): 179.
- [25] Swain M J, Ballard D H. Color indexing. Int[J]. Journal of Computer Vision, 7(1): 11.
- [26] Hadid M H, Hussein Q M, Al-Qaysi Z T, et al. An Overview of Content-Based Image Retrieval Methods And Techniques[J]. Iraqi Journal For Computer Science and Mathematics, 2023, 4(3): 6.
- [27] Stricker M A, Orengo M. Similarity of color images[C]//Storage and retrieval for image and video databases III. SPiE, 1995, 2420: 381-392.
- [28] Huang J, Kumar S R, Mitra M, et al. Image indexing using color correlograms[C]//Proceedings of IEEE computer society conference on Computer Vision and Pattern Recognition. IEEE, 1997: 762-768.



- [29] dos Santos J A, Penatti O A B, Torres R S. Evaluating the potential of texture and color descriptors for remote sensing image retrieval and classification[C]//International conference on computer vision theory and applications. SCITEPRESS, 2010, 2: 203-208.
- [30] Haralick R M, Shanmugam K, Dinstein I H. Textural features for image classification[J]. IEEE Transactions on systems, man, and cybernetics, 2007 (6): 610-621.
- [31] Daugman J G. Two-dimensional spectral analysis of cortical receptive field profiles[J]. Vision research, 1980, 20(10): 847-856.
- [32] Newsam S D, Kamath C. Retrieval using texture features in high-resolution multispectral satellite imagery[C]//Data Mining and Knowledge Discovery: Theory, Tools, and Technology VI. SPIE, 2004, 5433: 21-32.
- [33] Ojala T, Pietikäinen M, Harwood D. A comparative study of texture measures with classification based on featured distributions[J]. Pattern recognition, 1996, 29(1): 51-59.
- [34] Tekeste I, Demir B. Advanced local binary patterns for remote sensing image retrieval[C]//IGARSS 2018-2018 IEEE International Geoscience and Remote Sensing Symposium. IEEE, 2018: 6855-6858.
- [35] Zeying L A N, Yang L I U. Classification of land-use based on remote sensing image texture features with multi-scales and cardinal direction inspired by domain knowledge[J]. Acta Geodaetica et Cartographica Sinica, 2016, 45(8): 973.
- [36] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05). Ieee, 2005, 1: 886-893.
- [37] Vharkte M N, Musande V B. A novel method for retrieval of remote sensing image using wavelet transform and HOG[C]//International Conference on Intelligent Systems Design and Applications. Cham: Springer International Publishing, 2018: 540-549.
- [38] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60(2): 91-110.
- [39] Newsam S, Yang Y. Comparing global and interest point descriptors for similarity retrieval in remote sensed imagery[C]//Proceedings of the 15th annual ACM international symposium on Advances in geographic information systems. 2007: 1-8.
- [40] Yue J, Li Z, Liu L, et al. Content-based image retrieval using color and texture fused features[J]. Mathematical and Computer Modelling, 2011, 54(3-4): 1121-1127.

- [41] Kusumaningrum R, Arymurthy A M. Color and texture feature for remote sensing-image retrieval system: a comparative study[J]. International Journal of Computer Science Issues (IJCSI), 2011, 8(5): 125.
- [42] Newsam S, Wang L, Bhagavathy S, et al. Using texture to analyze and manage large collections of remote sensed image and video data[J]. Applied optics, 2004, 43(2): 210-217.
- [43] Soni P, Singh M, Sharma P, et al. Multifeature Fusion for Enhanced Content-Based Image Retrieval Across Diverse Data Types[J]. Journal of Electrical and Computer Engineering, 2025, 2025(1): 3889925.
- [44] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [45] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [46] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [47] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [48] Tong X Y, Xia G S, Hu F, et al. Exploiting deep features for remote sensing image retrieval: A systematic investigation[J]. IEEE Transactions on Big Data, 2019, 6(3): 507-521.
- [49] Deepan P, Sudha L R. Remote sensing image scene classification using dilated convolutional neural networks[J]. International Journal, 2020, 8(7).
- [50] Zhang X. A survey on deep hashing for image retrieval[J]. arXiv preprint arXiv:2006.05627, 2020.
- [51] Zhu H, Long M, Wang J, et al. Deep hashing network for efficient similarity retrieval[C]//Proceedings of the AAAI conference on Artificial Intelligence. 2016, 30(1).
- [52] Li W J, Wang S, Kang W C. Feature learning based deep supervised hashing with pairwise labels[J]. arXiv preprint arXiv:1511.03855, 2015.
- [53] Zhang Z, Zou Q, Lin Y, et al. Improved deep hashing with soft pairwise similarity for multi-label image retrieval[J]. IEEE Transactions on Multimedia, 2019, 22(2): 540-553.
- [54] Su S, Zhang C, Han K, et al. Greedy hash: Towards fast optimization for accurate hash coding in cnn[J]. Advances in neural information processing systems, 2018, 31.
- [55] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.

- [56] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [57] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [58] Huang M, Dong L, Dong W, et al. Supervised contrastive learning based on fusion of global and local features for remote sensing image retrieval[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-13.
- [59] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [60] Li R, Wang L, Zhang C, et al. A2-FPN for semantic segmentation of fine-resolution remotely sensed images[J]. International journal of remote sensing, 2022, 43(3): 1131-1155.
- [61] Wang K, He D, Sun Q, et al. A novel network for semantic segmentation of landslide areas in remote sensing images with multi-branch and multi-scale fusion[J]. Applied Soft Computing, 2024, 158: 111542.
- [62] Liu C, Ma J, Tang X, et al. Deep hash learning for remote sensing image retrieval[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(4): 3420-3443.
- [63] Li Y, Ma J, Zhang Y. Image retrieval from remote sensing big data: A survey[J]. Information Fusion, 2021, 67: 94-115.
- [64] Han L, Paoletti M E, Tao X, et al. Hash-based remote sensing image retrieval[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-23.
- [65] Gionis A, Indyk P, Motwani R. Similarity search in high dimensions via hashing[C]//Vldb. 1999, 99(6): 518-529.
- [66] Gong Y, Lazebnik S, Gordo A, et al. Iterative quantization: A procrustean approach to learning binary codes for large-scale image retrieval[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 35(12): 2916-2929.
- [67] Shen F, Shen C, Liu W, et al. Supervised discrete hashing[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 37-45.
- [68] Cao Z, Long M, Wang J, et al. Hashnet: Deep learning to hash by continuation[C]//Proceedings of the IEEE international conference on computer vision. 2017: 5608-5617.
- [69] Yuan L, Wang T, Zhang X, et al. Central similarity quantization for efficient image and video

- retrieval[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 3083-3092.
- [70] Li Y, Zhu Z, Yu J G, et al. Learning deep cross-modal embedding networks for zero-shot remote sensing image scene classification[J]. IEEE transactions on geoscience and remote sensing, 2021, 59(12): 10590-10603.
- [71] Tan X, Zou Y, Guo Z, et al. Deep contrastive self-supervised hashing for remote sensing image retrieval[J]. Remote Sensing, 2022, 14(15): 3643.
- [72] Zhou H, Qin Q, Hou J, et al. Deep global semantic structure-preserving hashing via corrective triplet loss for remote sensing image retrieval[J]. Expert Systems with Applications, 2024, 238: 122105.
- [73] Liu C, Ma J, Tang X, et al. Adversarial hash-code learning for remote sensing image retrieval[C]//IGARSS 2019-2019 IEEE International Geoscience and Remote Sensing Symposium. IEEE, 2019: 4324-4327.
- [74] Hou Z, Yan H, Zhang L, et al. A secure and efficient remote sensing image retrieval method with verifiable and traceable in cloud environment[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025.
- [75] Zhao D, Chen Y, Xiong S. Multiscale context deep hashing for remote sensing image retrieval[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 7163-7172.
- [76] Liu X, Chen X, Zhu G. Deep Relevance Hashing for Remote Sensing Image Retrieval[J]. Sensors, 2025, 25(20): 6379.
- [77] Srivastava D, Singh S S, Rajitha B, et al. Content-based image retrieval: A survey on local and global features selection, extraction, representation, and evaluation parameters[J]. IEEE Access, 2023, 11: 95410-95431.
- [78] Prajapati N, Patel N. A Review on Recent Trends on Content-based Image Retrieval for Remote Sensing Images[J].
- [79] Anand A, Singh K, Saxena A. A detailed survey on content based image retrieval (cbir)[J]. 2024.
- [80] Zhao M, Xu D, Gao T. From cognition to computation: A comparative review of human attention and transformer architectures[J]. arXiv preprint arXiv:2407.01548, 2024.
- [81] Zhu X, Cheng D, Zhang Z, et al. An empirical study of spatial attention mechanisms in deep networks[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 6688-6697.
- [82] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [83] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions[J]. arXiv preprint arXiv:1511.07122, 2015.

- [84] Yin A, Ren C, Yan Z, et al. C2S-RoadNet: road extraction model with depth-wise separable convolution and self-attention[J]. Remote Sensing, 2023, 15(18): 4531.
- [85] Khosla P, Teterwak P, Wang C, et al. Supervised contrastive learning[J]. Advances in neural information processing systems, 2020, 33: 18661-18673.
- [86] Hadsell R, Chopra S, LeCun Y. Dimensionality reduction by learning an invariant mapping[C]//2006 IEEE computer society conference on computer vision and pattern recognition (CVPR'06). IEEE, 2006, 2: 1735-1742.
- [87] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and clustering[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 815-823.
- [88] Rusak E, Reizinger P, Juhos A, et al. Infonce: Identifying the gap between theory and practice[J]. arXiv preprint arXiv:2407.00143, 2024.
- [89] Wang W, Guo Z, Cui Z, et al. Centripetal intensive deep hashing for remote sensing image retrieval[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2025.
- [90] Yang Y, Newsam S. Bag-of-visual-words and spatial extensions for land-use classification[C]//Proceedings of the 18th SIGSPATIAL international conference on advances in geographic information systems. 2010: 270-279.
- [91] Xia G S, Hu J, Hu F, et al. AID: A benchmark data set for performance evaluation of aerial scene classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(7): 3965-3981.
- [92] Cheng G, Han J, Lu X. Remote sensing image scene classification: Benchmark and state of the art[J]. Proceedings of the IEEE, 2017, 105(10): 1865-1883.

## 致谢

三载沉潜，终赴新程，硕士求学之路于笔墨间落下圆满句点。回望来路，满心感恩与眷恋，我以最赤诚之心，向所有给予我温暖与力量的人，致以最深切的谢意。

首先我要感谢我的导师牛云云教授。论文从选题淬炼、框架搭建，到实证研究、文稿打磨，每一个环节都浸润着导师的心血与智慧。导师严谨的治学态度、深邃的学术见地，让我学会沉心治学、坚守初心。导师亦师亦友，学术上倾囊相授、循循善诱，思想上关怀备至、指点迷津，其言传身教，成为我为人治学的榜样。师恩如灯，这份教诲与期许，终将作为我前行的力量，激励我脚踏实地、笃行致远。

其次特别感谢我的同门曾燕、杜松芝、范帅尧、付国宁，师兄朱国栋、阮龙、张小豪、徐泽彦和师弟师妹们，三年时间里大家共解科研困惑，共庆每一次微小进步，也共渡每一段迷茫时光。你们在科研和工作中给予了我无私帮助，无数的经验分享让我少走了许多弯路。我们一起讨论问题、分享资料、互相鼓励，在无数个挑灯夜战的夜晚，是你们的陪伴让枯燥的科研生活变得温暖而有力量。

同时要感谢贾广畅、李浩天、韩品慧、陈心怡、胡科扬、彭嘉以及所有的好朋友。我们一同共度朝夕、共享欢喜，在并肩同行的时光里留存无数快乐瞬间，那些相伴的点滴温暖，始终滋养着我坚守心中热爱、永葆勇往直前的勇气，更成为我奔赴未来的底气，照亮我前行的每一步，让我带着这份热爱与勇气，奔赴下一段成长之路。

最后要感谢我的父母，是你们用无私的爱为我撑起一片自由成长的天空。每当我遇到挫折想要放弃时，是你们在电话那头温柔的鼓励让我重拾信心；是你们默默承担生活的重担，让我能心无旁骛地完成学业。你们的理解与支持，是我最坚强的后盾，也是我不断前行的动力源泉。

纸短情长，致谢相逢。谨以此致谢，敬赠所有爱我与我爱的人，敬赠这段全力以赴、温暖向阳的青春时光！



## 附录

### 一、个人信息：

王鹏程，男，2000 年 4 月出生，河南洛阳人，中共党员。2018 年 9 月——2022 年 6 月于广西大学计算机与电子信息学院攻读学士学位，专业为计算机科学与技术；2023 年 9 月——2026 年 6 月于中国地质大学（北京）人工智能学院攻读硕士学位，专业为计算机技术，研究方向为遥感图像检索、强化学习。

### 二、教育背景：

2023.09-2026.06 ： 中国地质大学(北京)

2018.09-2022.06 ： 广西大学

### 三、科研成果：

非第一作者（1 篇）

1) Zhu G, Du S, **Pengcheng Wang**. Dynamic graph convolutional recurrent network with spatiotemporal category information embedding for traffic flow prediction[J]. IEEE Internet of Things Journal, 2024, 11(24): 39473-39486.

计算机软件著作权（2 项）

1) 交通路况智能分析运维系统 V1.0

2) 强化学习成效评估系统 V1.0