

分类号

密级

中国地质大学（北京）
专业硕士学位论文

基于多模态学习的药物分子性质预测研究

研究生 范帅尧 学号 2104230025

专业学位类别 电子信息 专业 计算机技术

校内导师 牛云云 产业导师

学习方式 全日制

2026 年 5 月

**A Dissertation Submitted to
China University of Geosciences for Master of Professional
Degree**

**A Multimodal Learning Approach to Drug Molecule
Property Prediction**

Master Candidate: Shuaiyao Fan

**Professional Degree: Master of Electronic and
Information**

Dissertation Supervisor: Prof. Yunyun Niu

Associate Supervisor:

China University of Geosciences (Beijing)

声 明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国地质大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签 名：_____日 期：_____

关于论文使用授权的说明

本人完全了解中国地质大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。**延期公开的论文在到期公开后应遵守此规定。**

签 名：_____导师签名：_____日 期：_____

摘要

面向性质预测的分子表征学习旨在通过深度学习技术，将分子复杂的结构与特征信息投影成一个高维的数学表示，进而利用这些特征表示来精准的预测分子的各项生化性质，最终从海量候选药物中高效筛选出具备成药潜力的目标分子。医药领域虽已积累了海量的分子数据，但这些数据往往充斥着严重的噪声且标注质量参差不齐，同时，传统计算方法在处理大规模分子数据时面临着极高的计算复杂度。近年来，深度学习技术在数据表征领域的飞速发展，为分子信息建模提供了数据驱动的新范式。然而，如何有效利用分子的多模态数据，在深度学习框架下构建全面且鲁棒的分子特征表示，并以此实现生化性质的高精度预测，已成为当前该领域亟待解决的核心问题。

为解决上述提出的问题，本文基于分子可以表示为多种模态的特性，提出两种创新性方法：

(1) 基于思维链增强与消息传递的分子性质预测方法。针对大语言模型在预测复杂生化性质时缺乏药理逻辑支撑的“黑盒”问题，以及传统图神经网络拓扑感知受限与“信息回流”的缺陷，本方法提出了一种端到端的双塔预测框架。在文本端，引入 LLaMA-3.1 大语言模型与低秩自适应技术，结合思维链提示工程，引导模型自发生成显式逻辑推理文本，将推理过程变为人类可解释的分析文本；在图结构端，采用交互式图神经网络构建原子与化学键的“通信核”，强制实现深层动态交互。在 TDC 平台的多个 ADMET 基准数据集上的实验表明，该方法不仅取得了较优结果，且通过可视化的推理路径为分子安全性评估提供了提供了解释线索。

(2) 基于知识增强与图对齐的多模态分子性质预测框架。针对公共医学文本噪声冗余及分子的多源数据联合优化易引发梯度冲突的问题，该框架构建了包含分子图、序列、指纹及自然语言的四个维度的表征体系。在数据层面，创新性地设计了知识重写流水线，利用大语言模型剔除原始文本中的冗余噪声，并显式注入由 RDKit 工具计算的多项分子理化指标，提升了文本模态的知识密度与约束力。在模型对齐层面，确立以分子图为核心的语义锚点，并引入基于同方差不确定性的自适应加权机制。在 MoleculeNet 的 9 个基准数据集上的系统评估表明，该框架在预测精度上综合表现较好，表明图中心对齐与知识增强可能对性能提升具有积极作用。

关键词：分子性质预测，多模态融合，思维链，对比学习

Abstract

Molecular representation learning for property prediction aims to project the complex structural and feature information of molecules into high-dimensional mathematical representations using deep learning techniques. This approach facilitates the accurate prediction of biochemical properties, thereby enabling the efficient screening of drug candidates with therapeutic potential from massive chemical spaces. Although the pharmaceutical field has accumulated vast amounts of molecular data, these datasets are frequently plagued by significant noise and inconsistent annotation quality. Furthermore, traditional computational methods struggle with high complexity when processing large-scale molecular data. While the rapid advancement of deep learning in data representation has provided a new data-driven paradigm for molecular modeling, the challenge remains on how to effectively utilize multimodal molecular data to construct comprehensive, robust representations for high-precision property prediction. To address these challenges, this paper proposes two innovative methods based on the multimodal nature of molecules:

(1) A Chain-of-Thought Enhanced and Message-Passing Molecular Property Prediction Method. Addressing the "black-box" nature of large language models (LLMs) that lack pharmacological reasoning in biochemical prediction, as well as the limitations of traditional graph neural networks (GNNs) in topological perception and "information oversmoothing," this method presents an end-to-end dual-tower framework. On the textual side, we incorporate the LLaMA-3.1 model with Low-Rank Adaptation (LoRA) and chain-of-thought prompting to guide the model in generating explicit, human-interpretable logical reasoning. On the graph side, an interactive GNN is employed to build a "communication core" for atoms and bonds, forcing deep dynamic interactions. Experimental results on multiple ADMET benchmarks within the Therapeutics Data Commons (TDC) demonstrate that this method significantly improves prediction accuracy and provides robust interpretability for molecular safety assessment through visual reasoning paths.

(2) A Knowledge-Enhanced and Graph-Aligned Multimodal Molecular Property Prediction Framework. To mitigate noise in public medical texts and gradient conflicts arising from multi-source data optimization, this framework constructs a representation system covering four

dimensions: molecular graphs, sequences, fingerprints, and natural language. At the data level, we design an innovative knowledge-rewriting pipeline that utilizes LLMs to prune redundant noise from raw text and explicitly inject physicochemical indices calculated via RDKit, thereby enhancing the knowledge density and constraints of the textual modality. At the model alignment level, we establish the molecular graph as the semantic anchor and introduce an adaptive weighting mechanism based on homoscedastic uncertainty. Systematic evaluations on nine MoleculeNet benchmarks show that this framework achieves competitive overall performance, suggesting that graph-centered alignment and knowledge enhancement can positively contribute to multimodal molecular property prediction.

Key words: Molecular Property Prediction, Multimodal Learning, Chain-of-Thought, Contrastive Learning

目 录

摘要.....	1
ABSTRACT	2
1 引言	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于单模态的分子预测方法	2
1.2.2 基于多模态的分子预测方法	3
1.3 当前研究不足	4
1.4 研究内容以及论文结构	5
1.4.1 研究内容	5
1.4.2 文章架构	6
2 相关理论基础.....	8
2.1 数据表征方法	8
2.1.1 SMILES.....	8
2.1.2 二维拓扑图.....	8
2.1.3 分子指纹.....	9
2.1.4 文本语义.....	9
2.2 图神经网络	10
2.2.1 消息传递机制	10
2.2.2 图卷积网络	11
2.2.3 基于注意力机制的图神经网络	12
2.3 大语言模型与提示词工程	13
2.3.1 Transformer 架构	13
2.3.2 LoRA 技术.....	15
2.3.3 思维链.....	16
2.4 本章小结	17
3 基于思维链增强与消息传递的分子性质预测方法.....	18
3.1 模型设计与描述	18

3.1.1 CoT-CMP 架构概述	18
3.1.2 思维链增强的文本编码器	20
3.1.3 分子图编码器	21
3.1.4 融合与预测模块	22
3.2 实验设计	22
3.2.1 数据集	22
3.2.2 划分方式	25
3.2.3 实验设置	26
3.2.4 评价指标	26
3.2.5 对比模型	27
3.3 实验及结果分析	28
3.3.1 对比实验	28
3.3.2 消融实验	30
3.3.3 可视化分析	31
3.3.4 参数敏感实验	32
3.4 本章小结	33
4 基于知识增强与图对齐的分子性质预测方法	35
4.1 模型设计与描述	35
4.1.1 KGAMA 框架概述	35
4.1.2 图编码器	36
4.1.3 指纹编码器	36
4.1.4 序列编码器	37
4.1.5 文本编码器	38
4.1.6 融合与预测	38
4.2 实验设计	38
4.2.1 预训练数据	38
4.2.2 下游数据集	41
4.2.3 实验设置	43
4.2.4 评价指标	44

4.2.5 损失函数	45
4.2.6 对比模型	46
4.3 实验及结果分析	48
4.3.1 对比实验	48
4.3.2 消融实验	50
4.3.3 可视化分析	53
4.3.4 参数敏感实验	54
4.4 本章小结	55
5 总结与展望	57
5.1 工作总结	57
5.2 工作展望	58
参考文献	59

1 引言

1.1 研究背景及意义

现代创新药物的研发是一个高度复杂、多学科交叉、系统性且极具风险的庞大科学工程。其绵长的生命周期通常横跨数十年的时间，研发的成本也通常会达到数亿美元。整个研发流程可划分为五个关键阶段：第一阶段为药物发现与开发，这一阶段是基于一种特定的疾病或者病症，研究人员通过多种寻找潜在候选药物的策略从百万量级的化合物库中遴选出具有关键作用的目标分子。第二阶段为临床前研究，这一阶段是初始发现阶段与人体测试之间的重要桥梁。通过体外细胞实验与体内动物模型对候选分子的安全性、毒性及药代动力学特性进行系统评估；第三阶段为临床研究，候选药物依次经历多期的临床试验，在不同规模的人群中逐步验证其安全性与有效性；第四阶段为监管审批，药物开发商向监管机构提交新药申请，由专家团队对全部临床数据进行严格审查；第五阶段为上市后安全监控，已获批药物在真实世界的大规模使用中持续接受不良事件监测与长期安全性评估。上述五个阶段环环相扣、层层递进，这一严苛而漫长的研发流程迫切需要更高效的技术手段介入，以加速候选分子的早期筛选与优化过程，降低研发成本与失败风险。

分子性质预测在药物研发的早期阶段扮演着至关重要的角色。其目的是匹配目标分子相应的生化性质。通过在实验验证之前对候选分子的关键性质进行快速评估，研究人员得以从百万量级的化合物库中迅速剔除不符合要求的分子，将候选范围大幅压缩至数百个具有成药潜力的先导化合物，从而在源头上规避大量无效的实验资源消耗。

然而，传统获取分子性质的手段面临着难以逾越的效率与成本瓶颈。长期以来，分子理化性质任务高度依赖于湿实验。尽管实验方法具有极高的数据可靠性，但其实施成本高昂，且操作流程复杂耗时。面对庞大的潜在化学成药空间，传统的湿实验显然无法满足现代医药工业的大规模高通量筛选需求。另一方面，以量子力学计算和分子动力学模拟为代表的理论计算方法，虽能从微观原子层面解析分子的电子结构与构象动力学行为，但其对计算资源的极高消耗以及时间尺度的严苛限制，使其难以被广泛应用于复杂生物大分子体系的快速评估。

近年来，随着计算能力的飞跃与医药大数据的积累，计算机辅助方法特别是深度学习技术与人工智能技术的突起，为药物研发带来了前所未有的范式变革。深度学习凭借其强大的数据处理与非线性模式挖掘能力，能够在极短的时间内高效处理海量的分子数据。通

过构建多层神经网络结构，模型能够自动学习数据的高维特征表示，从而实现对复杂“分子结构—生化性质”映射关系的精准建模与预测。从基于一维序列的 Transformer 到基于二维拓扑的图神经网络，深度学习技术正推动新药发现由传统的经验驱动全面转向数据驱动。这一前沿技术的加持，不仅打破了传统实验与理论计算的效率壁垒，更为精准预测分子药代动力学特性、大幅提升药物研发的成功率提供了革命性的智能辅助方案。

1.2 国内外研究现状

在药物发现早期，准确预测分子的物理化学性质与药代动力学特性是加速目标分子筛选任务的核心。随着医药大数据的积累与计算机算力的爆发，计算机辅助分子性质预测经历了从传统机器学习到深度学习的范式跃迁。目前，国内外学术界在该领域的研究明显展现出两条主要的核心技术主线：基于单模态的分子表示方法与基于多模态的分子表示方法来对分子性质进行预测。

1.2.1 基于单模态的分子预测方法

单模态方法是指依赖单一的数据形式，例如典型的一维数据 SMILES 序列，二维数据分子拓扑图、三维数据分子的坐标等，来进行分子表征的构建，进而预测分子性质。

由于分子可以天然地被表示为由原子和化学键构成的非欧几里得图结构，因此图神经网络在分子单模态表征中成为了主流的工具。例如 FragNet^[1]将分子拆解为片段，通过构建多层次图表示在图神经网络中显示建模分子片段和整体的关系，从而提升性质预测的精度与可解释性。GA-GNN^[2]用几何代数作为底层数学工具，把向量、平面、旋转等几何对象统一表示，嵌入 GNN 中，增强对空间结构的建模。Add-GNN^[3]在 GNN 中引入可加性注意力，针对不同尺度的邻域信息，例如近邻和远邻，给予不同权重，实现更细粒度的图读出。CD-MVGNN^[4]它打破了传统模型单一视角的局限，将原子和化学键视为同等重要，构建了双轨并行的多视图架构。通过交叉依赖消息传递机制，使得节点与边在每一步信息聚合时，都能实时交互并利用对方的最新状态，从而高效、精准地捕捉分子的底层拓扑特征。KA-GNN^[5]抛弃了传统 GNN 中用于拟合数据的多层感知机（MLP），转而基于数学上的 Kolmogorov - Arnold 表示定理，将预测分子性质的复杂高维函数，拆解为多个一维的基础组合函数。

除图结构外，化学分子还可以通过标准化的编码规则转换为一维序列或特征向量，最典型的代表为 SMILES 字符串与分子指纹。这类一维模态天然契合自然语言处理（NLP）

领域的底层架构，能够直接借助 Transformer 等模型开展大规模自监督预训练，在计算效率与特征表征上展现出独特优势。例如 SMILES-BERT^[6]将 Transformer 架构引入分子表征学习。它通过在大规模无标签 SMILES 数据上进行掩码语言建模预训练。SMILES-GRPO 提出基团感知掩码，强制模型一次性遮盖或预测整个功能基团。MFBERT^[7]直接将扩展连通性指纹等一维向量作为输入 Token 喂给 Transformer 进行掩码预训练，成功实现了离散化学特征与深度注意力机制的融合，其预测精度依然能够持平复杂的 GNN 或者深层的 Transformer 模型。

1.2.2 基于多模态的分子预测方法

与仅依赖单一结构模态（图或序列）的模型相比，多模态分子预测方法通过联合利用分子图、三维构象、SMILES 序列、文本描述以及光谱等多通道信息，更全面地表征分子的结构-性质关系。

其中，一维分子序列和二维分子图相融合是常用的方法之一。例如 AMCFNet^[8]提出了一种自适应多模式对比融合网络，从 SMILES 序列与图结构表示之间的交互和共识中自适应地提取互补特征。MMCL^[9]框架通过 BRICS 算法显式地将功能基团建模为层级图中的特殊节点，并结合双向门控循环单元处理序列信息，实现了图结构语义与序列语义的深层对齐。MolGramTreeNet^[10]引入了上下文无关文法解析技术，将 SMILES 序列转化为具有层级语义的分子语法树，并结合图卷积网络对 2D 分子图进行并行编码。该模型通过通道拼接将层次化语法特征与拓扑结构特征深度融合，相较于常见的交叉注意力融合机制这种通道拼接技术展现出了更高的性能。GSST^[11]通过引入可学习的软 token 概念，将图拓扑特征映射至序列空间，并利用 G2S-Former 模块实现了多模态信息的深度对齐与融合，有效弥补了单一模态在分子表征中的语义缺失。MolPROP^[12]通过将预训练的大语言模型 ChemBERTa-2 与图神经网络相结合，证实了多模态融合在回归类性质预测任务中的协同增效作用，并提出了一种基于重原子匹配的特征映射策略。MDFCL^[13]通过基于主链与侧链的自适应增强策略，构建了包含多种增强实例的图对比学习体系，通过在图模态与序列模态间实施分层对比损失，实现了双模态的语义一致性建模。

将分子结构与自然语言描述文本对齐，可以利用文本中蕴含的药理、用途等高层语义知识来增强分子的表示。例如 MoleculeSTM^[14]，它是该方向极具开创性的基础模型之一。它通过构建包含超过 28 万对“结构-文本”的 PubChemSTM 数据集，利用跨模态对比学习将分子表示与自然语言映射到了统一的潜空间。Wang 等人构建的 MolTextNet^[15]将高质量

的“分子-文本”配对样本扩充至约两百万条，为训练更大规模的跨模态编码器提供了数据底座。ProtoMol^[16]该模型通过引入层级式双向交叉注意力机制与统一的语义原型空间，实现了分子图结构与文本描述在多层级上的精细化对齐，解决了多模态分子模型在层级语义捕捉与模态对齐方面的不足。TRIDENT^[17]进一步将三种模态：SMILES 序列、自然语言描述及分层功能注释统一到一个三模态表示框架中，提出体积化全局对齐目标和局部对应任务。MolPrompt^[18]通过将分子的物理化学描述符转化为可学习的语义提示，将其嵌入到图结构的表征信息中，实现了图模态与文本描述的深度语义对齐。

利用分子的三维结构信息结合可以弥补分子平面拓扑与真实物理空间结构之间的信息鸿沟。例如 GraphMVP^[19]，它利用分子的二维和三维模态，通过自适应地整合 2D 和 3D 图的信息，学习具有丰富空间语义的分子表征。随后，Uni-Mol^[20]作为一项里程碑式的工作，提出了通用的 3D 分子表征学习框架，该模型是首个能够直接输入 3D 原子坐标进行预训练的大规模模型。MolInterAct^[21]工作专注于 2D 与 3D 构象的深度交互，通过设计原子级与分子级的“交互层”，在多层网络堆叠中逐步对齐 2D 和 3D 空间信息。ECMMR^[22]框架通过 BRICS 算法显式地提取并编码分子功能片段，并利用超图结构捕捉原子间的复杂高阶关系。此外，该框架还引入了耦合先验优化策略，通过对比学习与生成式重建任务的协同，实现了图模态与 3D 几何模态的动态对齐。

双模态或者特定视角的对齐策略虽在一定程度上弥补了单模态的缺陷，但是分子的化学特性是多维度的综合表现，将分子的多模态数据进行融合是该领域一个前沿的方向。例如 Uni-Poly^[23]创新性地 将 SMILES、2D 图、3D 构象及分子指纹与领域文本描述进行了统一融合，通过多模态注意力池化机制有效提升了聚合物物化性质预测的综合性能。MuMo^[24]将分子 2D 的拓扑信息和 3D 的几何信息统一，作为稳定的结构先验，然后引入渐进式注入机制进行融合，并且采用了 Manba 作为骨干网络来进行计算。MoLA^[25]采用跨层注意力融合机制自适应地构建多通道相关图，让不同模态在不同网络深度的贡献进行自动的调整，并创新性地 将树突神经元模块引入指纹处理分支，实现了非线性交互特征的有效捕捉。MMFRL^[26]系统比较了早期、中期和晚期三种特征融合策略，并在多模态表示之上引入分子间关系学习模块，显式建模分子间的相似性与作用机制。DMMF^[27]通过引入模态内门控与模态间注意力机制，不仅要预测分子的性质还要完成模态之间的重构，实现了样本级的自适应权重分配。

1.3 当前研究不足

尽管以深度学习为代表的单模态与多模态表征技术在分子性质预测任务上取得了长足的进步，但面对高度复杂且容错率极低的真实药物发现场景，当前研究仍存在以下难以逾越的局限性：

单模态拓扑感知受限与信息回流瓶颈：传统的图神经网络主要依赖于局部节点的无向聚合机制，严重忽视了化学键在电子效应传递中的动态交互作用。这种机制在多层迭代时极易产生信息冗余与信息回流，导致模型难以精准感知多环系统或长碳链分子中的复杂立体空间依赖。

大模型直接推理的黑盒态与文本幻觉：虽然大语言模型（LLMs）展现出了跨模态理解的潜力，但在面对如跨膜吸收、毒理副作用等复杂的药代动力学（ADMET）评估时，现有方法多要求模型进行缺乏中间逻辑支撑的直接端到端映射。这不仅极易导致模型产生无事实依据的幻觉，更使得预测过程呈现出完全不可解释的黑盒特性，难以满足制药工业的逻辑审计要求。

多模态融合面临的文本噪声与梯度冲突：现有的多模态对齐策略严重受制于公共医学数据库，如 PubChem 数据库中文本质量的参差不齐。原始分子描述通常充斥着冗余的行政历史轶事，且缺乏关键定量理化指标的约束。在进行粗粒度的跨模态对比学习时，这种多源数据的语义鸿沟极易引发模态间的梯度冲突与负迁移，导致特征对齐失败。

1.4 研究内容以及论文结构

1.4.1 研究内容

针对上述分子性质预测研究中存在的拓扑感知局限、黑盒预测痛点以及多模态对齐中的梯度冲突等问题，本文深入探究了基于大语言模型推理、知识增强与图网络深度交互的解决方案。本文的主要研究内容包括如下：

(1) 将大语言模型领域的思维链推理技术于交互式消息传递图神经网络相结合，本文提出了一种端到端的双塔预测框架。在文本端，利用大语言模型与思维链技术，引导模型自发生成包含结构识别到理化属性分析，再到性质推导的显式逻辑推理文本，增强了模型决策过程的可解释性表达能力；在图结构端，构建基于通信核的交互式图神经网络，强制原子与化学键进行动态深度交互，精准捕获分子的立体电子效应。最终通过交叉注意力机制，实现宏观药理语义与微观拓扑结构的自适应融合。

(2) 将多模态知识增强技术与交叉注意力相结合，本文提出了一种以图表征为核心、

多模态知识增强的分子预测架构（KGAMA）。该框架构建了包含图、序列、指纹及自然语言的四维表征体系，并创新性地设计了大语言模型知识重写流水线，显式注入定量理化指标以过滤文本噪声。在模型对齐阶段，摒弃全排列对齐策略，引入基于同方差不确定性的自适应加权机制，使模型能够自动平衡各模态的噪声水平，实现跨模态特征在统一高维语义空间的稳健对齐。

1.4.2 文章架构

本小节将介绍本文的整体结构，本文分为五个大章节，以下是各个章节的详细介绍。

第一章为绪论。本章系统阐述了分子性质预测在现代药物研发早期的高效虚拟筛选中的研究背景及其至关重要的科学意义，详细综述了单模态深度学习与多模态表征技术在该领域的应用现状，并深入分析了现有方法在拓扑特征提取局限、大语言模型“黑盒”化以及多模态融合语义冲突等方面所面临的挑战。最后，概述了本文针对这些痛点提出的多模态知识增强与思维链推理的创新性解决策略。

第二章介绍了本研究相关的理论基础。本章系统梳理了本文构建模型所依赖的底层数学原理与算法基石。首先，详细阐述了涵盖一维 SMILES 序列、二维拓扑图、分子指纹及自然语言文本的多维数据表征方法。其次，深入剖析了图空间域的特征提取算法，包括图卷积网络、图注意力网络及消息传递机制等。最后，重点介绍了大语言模型领域的 Transformer 架构、低秩自适应（LoRA）微调技术与思维链（CoT）推理机制，并界定了跨模态特征对齐与融合的通用范式，为后续核心章节的模型设计提供了严密的理论支撑。

第三章介绍了基于思维链增强与消息传递的分子性质预测方法。本章针对现有模型在大语言模型预测时的不可解释性的黑盒问题以及传统图网络拓扑感知的局限，提出了一种端到端的双塔预测框架（CoT-CMP）。详细介绍了大模型引导的显式药理逻辑文本生成机制与基于通信核的交互式图特征提取机制，并全面呈现了该模型在 TDC 平台多个 ADMET 基准数据集上的实验设置、对比结果、消融实验与可视化讨论。

第四章介绍了基于知识增强与图对齐的分子性质预测方法。本章指出了公共医学文本噪声冗余及多源异构数据直接对齐易引发梯度冲突的不足，提出了一种以图表征为核心的四维多模态分子预测架构（KGAMA）。接着详细介绍了大语言模型知识重写流水线的设计逻辑，以及基于同方差不确定性的自适应加权机制在对比学习中的应用，并系统展示了该框架在 MoleculeNet 基准数据集上的实验设置、性能对比、消融分析与注意力权重特征的可视化结果。

第五章对全文内容进行了系统性的总结与展望。本章对全文的核心研究内容与两项多模态预测框架的创新性成果进行了高度概括，客观分析了当前研究工作中存在的局限性，并从引入三维几何构象、构建亿级规模多模态基础模型以及干湿实验闭环验证等维度，对未来分子性质预测领域的发展方向进行了科学的展望。

2 相关理论基础

2.1 数据表征方法

2.1.1 SMILES

简化分子线性输入规范(Simplified Molecular Input Line Entry System, SMILES)是将分子的二维或三维结构信息降维为一维字符串序列的最常用方法之一。SMILES 通过对分子图进行深度优先遍历(Depth-First Search, DFS)生成线性字符串。其编码遵循严格的化学语法规则：节点(原子)由标准元素符号(如 H、C、S)表示；边(化学键)由特定字符(如 “=” 表示双键，“#” 表示三键)标定；分支结构通过括号 “()” 进行嵌套声明；环状结构则通过在开环和闭环原子处标记相同数字来实现断键重连。使用 SMILES 生成的序列具有天然紧凑性，且高度契合自然语言处理(NLP)领域的序列模型。通过特定分词算法，可将 SMILES 字符串映射至高维向量空间，进而利用神经网络算法对其进行特征提取。

2.1.2 二维拓扑图

分子的拓扑结构表示了分子中原子之间的连接方式，且拓扑结构可以用拓扑图来表示，其中可以将原子抽象为节点，化学键抽象为边。通过拓扑图可以更加直观地表示分子的原子连接关系与局部结构特征。

在图表征中， V 表示节点（原子）集合， E 表示边（化学键）集合。为了在图神经网络中进行消息传递，需要为节点和边分别构建初始特征矩阵：节点特征矩阵可表示为公式(2-1)：

$$X_v \in \mathbb{R}^{|V| \times d_v} \quad (2-1)$$

其中， $|V|$ 为原子总数， d_v 为原子特征维度。常见的原子特征包括原子序数、电负性、杂化轨道类型、隐式氢原子数量、形式电荷及是否具有手性等。

边特征矩阵如公式(2-2)所示：

$$X_e \in \mathbb{R}^{|E| \times d_e} \quad (2-2)$$

其中， $|E|$ 为化学键总数， d_e 为边特征维度。常见的边特征包括化学键类型，如单键、双键、三键、芳香键，是否处于共轭体系以及是否属于环结构等。二维拓扑图表征完整保留了分子的骨架连接性与图同构不变性，能够有效捕捉局部化学环境中的原子交互模式及远端原子间的拓扑依赖关系，是分子图神经网络建模的核心输入数据结构。

2.1.3 分子指纹

分子指纹（Molecular Fingerprints）是一种将分子的局部子结构、拓扑路径或特定官能团编码为固定长度特征向量的表征方法。其本质通常是一个固定长度的二进制位数组，其中每一位代表特定的分子特征是否存在。基于“结构相似性原理”，指纹的相似性通常预示着分子间具有相似的理化性质或生物活性。

根据编码策略的不同，分子指纹又可分为多种类型，常见的类型有：基于拓扑路径的指纹、基于原圆形领域的指纹、基于专家规则的指纹等。分子指纹将结构各异、大小不一的分子转化为维度统一的数值向量，从而使其能够作为标准化输入，高效地应用于各类机器学习模型。

2.1.4 文本语义

纯粹的序列或拓扑图表征往往局限于微观的化学结构层次，难以直接映射到宏观的药代动力学特性与生物学靶点机制。自然语言与理化知识表征通过引入外部专家经验与客观计算指标，为模型提供高阶语义信息。

该表征主要分为两部分：

定量理化属性：利用化学信息学工具（如 RDKit）依据分子的 2D 结构计算客观存在的物理化学指标。核心参数包括脂水分配系数（LogP）、拓扑极性表面积（TPSA）、精确分子量（Exact MW）以及可旋转键数量等。这些连续的数值变量对分子的透膜性与溶解度具有决定性的指示作用。

定性语义文本：利用结构化的医学数据库记录或大语言模型生成的逻辑推理文本，将分子的靶点结合倾向、潜在毒性机制及官能团作用以自然语言的形式进行编码。通过预训练语言模型的语义投影，该表征能够有效弥合“微观图结构”与“宏观生物活性”之间的语义鸿沟。



中文名	阿司匹林	SMILES	<chem>CC(=O)OC1=CC=CC=C1C(=O)O</chem>
二维拓扑图		分子指纹	
文本	This molecule is acetylsalicylic acid, a widely utilized non-steroidal anti-inflammatory drug, non-narcotic analgesic, antipyretic, and platelet aggregation inhibitor. Appearing as an odorless white crystalline powder with a slightly bitter taste, it is structurally a benzoic acid derivative in which the phenolic hydroxyl hydrogen has been replaced by an acetoxy group. The compound features a simple architecture consisting of a single aromatic benzene ring, an ester linkage, and two rotatable bonds. With a low molecular weight of 180.16g/mol, it is a highly compact molecule. Its moderate lipophilicity, reflected by a LogP of 1.31, alongside a topological polar surface area of 63.6 Å², provides an optimal balance of aqueous solubility and cellular membrane permeability. Additionally, its capacity to form intermolecular interactions through one hydrogen bond donor and three hydrogen bond acceptors facilitates efficient absorption, ensuring high oral bioavailability.		

图 2-1 阿司匹林的多模态化学表征

2.2 图神经网络

分子结构本质上是由原子与共价键构成的非欧几里得空间数据，传统的卷积神经网络（CNN）与循环神经网络（RNN）无法直接处理此类不规则的拓扑连接。图神经网络（Graph Neural Networks, GNN）通过在节点（原子）及其拓扑邻域之间执行特征聚合与非线性变换，成为了当前分子图表示学习的标准范式。本节将系统梳理图卷积、图注意力机制、消息传递框架以及图 Transformer 的核心理论。

2.2.1 消息传递机制

消息传递神经网络（Message Passing Neural Network, MPNN）是空间域图神经网络的通用数学框架。该框架从图的本质出发，其认为在网络拓扑中想要得到节点信息，最直接的方式就是通过相邻的节点相互传递特征信息来更新节点的表示。MPNN 的消息传递机制如图 2-2，具体来说是将每一层神经网络的操作分为了三个步骤：

第一步：消息构造。假设需要更新节点 v 的特征信息，需要观察该节点的邻居节点集合 $\mathcal{N}(v)$ 中的每一个节点，并且结合它们之间的边特征 e_{vu} ，为每条邻居关系构造一条专属信息：

$$m_{vu} = \text{Message}(h_v, h_u, e_{vu}) \quad (2-3)$$

第二步：消息聚合。节点 v 将所有来自邻居节点的信息通过一个置换不变性的函数进行聚合，最终得到一个聚合表示：

$$m_v = \text{Aggregate}(m_{vu} | u \in \mathcal{N}(v)) \quad (2-4)$$

第三步：状态更新。节点 v 根据自己当前的隐藏 h_v 和汇聚到邻居的信息 m_v 为输入，经过一个可学习的神经网络来更新自身的状态，进而得到新的状态 h_v^{new} ：

$$h_v^{\text{new}} = \text{Update}(h_v, m_v) \quad (2-5)$$

在每一轮的消息传递的过程中，图中所有的节点都同步执行以上三个步骤，在经过 K 层迭代之后，每一个节点的表示都将融合其 K 阶邻域之内的所有的节点特征与结构信息，从而实现对图结构的层次化感知。




图 2-2 消息传递机制示意图

2.2.2 图卷积网络

图卷积网络是由 Thomas 等人在 2017 年的论文《Semi-Supervised Classification with Graph Convolutional Networks》中首次提出，图卷积网络的核心在于一个节点的特征，是由它自身和其邻居共同决定。通过层层传递，结构相似、连通紧密的节点，他们的特征就会越来越相似。

设 $H^{(l)} \in \mathbb{R}^{V \times d}$ 为第 l 层的节点特征矩阵， A 为图的邻接矩阵，GCN 每层的特征更新公式可以表示为公式(2-6)：

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right) \quad (2-6)$$

其中， $\tilde{A} = A + I$ 是为添加了自环的邻接矩阵，以保留节点自身的特征信息； $\tilde{D}$ 为 $\tilde{A}$ 的度矩阵，其对角线元素即为 $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$ ； $W^{(l)}$ 为第 l 层的可学习的权重矩阵； $\sigma(\cdot)$ 为非线性

激活函数，如 ReLU；对称归一化项 $\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}$ 对邻接矩阵做归一化处理，缓解高度节点在聚合的过程中堆特征值的影响。GNN 通过堆叠多层的卷积操作实现了对多邻域节点信息的逐层传递，这样的操作在经过 K 层的堆叠之后，每一个节点都将融合其 K 阶邻域内所有节点的结构与特征信息。

2.2.3 基于注意力机制的图神经网络

2017 年 Transformer 凭借自注意力机制在序列建模领域取得了突破性进展。受其启发，Veličković 等人在 2018 年将注意力机制引入图领域，提出了图注意力网络（Graph Attention Network, GAT），其核心为在节点间的信息交互中引入动态注意力机制，进而解决图卷积网络权重固定的痛点。如公式(2-7)所示，对于中心节点 i 及其邻居节点 j ，GAT 首先通过一个可以共享的注意力函数计算两者之间的注意力分数：

$$e_{ij} = \text{LeakyReLU}\left(\bar{a}^T \left[Wh_i \parallel Wh_j\right]\right) \quad (2-7)$$

其中， W 为共享的线性变换矩阵， $\bar{a}$ 为可学习的注意力权重向量， $\parallel$ 符号表示拼接操作。随后使用归一化函数 Softmax 对节点 i 邻域内的所有注意力分数进行归一化操作，得到最终的注意力权重，如公式(2-8)所示：

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in N(i)} \exp(e_{ik})} \quad (2-8)$$

最终，节点 i 的特征通过对邻居特征的加权求和进行更新，如公式(2-9)所示：

$$h_i^{(l+1)} = \sigma \left(\sum_{j \in N(i)} \alpha_{ij} Wh_j^{(l)} \right) \quad (2-9)$$

然而，GAT 的注意力计算仍局限于一阶邻居范围内，本质上仍属于局部聚合范式，难以直接建模分子中远端原子之间的长程依赖关系。为突破这一局部感受野的限制，研究者将 Transformer 的全局自注意力机制引入图结构建模，形成了图 Transformer 架构。以 Graphormer 为代表的图 Transformer 模型将分子中所有节点两两之间的联系一并纳入注意力计算范围之内，实现了真正意义上的全局建模。标准的 Transformer 架构适用于处理无序的序列，无法感知图的拓扑结构，所以必须显式的引入图的几何结构与拓扑信息。Graphormer 设计了三种互补的结构编码机制：其一为中心性编码（Centrality Encoding），利用节点的入度与出度为每个原子引入可学习的偏置向量，以量化其在分子图中的拓扑重

要性；其二为空间编码（Spatial Encoding），将节点对之间的最短路径距离映射为注意力矩阵中的标量偏置，显式刻画原子间的物理隔离程度；其三为边缘编码（Edge Encoding），提取节点对最短路径上所有边特征的加权均值，将化学键属性直接注入注意力权重的计算过程。三种结构编码协同作用，使图 Transformer 能够在全局注意力框架下同时感知局部化学键属性与全局拓扑距离，将分子的多尺度结构信息映射至统一的高维表示空间。

2.3 大语言模型与提示词工程

在分子性质预测任务中，纯粹的结构表征往往局限于微观拓扑，难以直接映射到宏观的复杂药代动力学特性。大语言模型（Large Language Models, LLMs）通过在海量语料上进行无监督预训练，内部隐式地压缩了丰富的跨学科知识。本节将系统阐述大语言模型的底层架构、参数高效微调机制以及激发模型推理能力的思维链技术。

2.3.1 Transformer 架构

Vaswani 等人在 2017 年的论文《Attention Is All You Need》中首次提出了 Transformer 架构。该架构的核心是通过自注意力机制（Self-Attention）来建立输入序列内部的全局依赖关系，如图 2-3 所示。相比于传统循环神经网络的递归计算与卷积神经网络的局部感受野范式，Transformer 在处理序列数据时的性能得到了极大的提升。Transformer 由编码器和解码器两部分组成，每一部分均由多层结构堆叠而成，而每一层又包含多个功能不同的子模块。其中最核心的子模块为多头注意力机制。

Transformer 架构采用了缩放点积注意力机制（Scaled Dot-Product Attention）作为最基本的计算单元。在给定输入序列的特征矩阵 X 的情况下，模型通过初始化三个可学习的参数矩阵 W_Q 、 W_K 、 W_V ，将其分别投影为查询矩阵 Q （Query）、键矩阵 K （Key）和值矩阵 V （Value）。通过这三个矩阵，可得注意力权重的计算公式：

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \quad (2-10)$$

其中，矩阵乘法 $QK^\top$ 计算序列中任意两个特征元素之间的内积相似度；除以缩放因子 $\sqrt{d_k}$ 是为了防止特征维度较高时内积数值过大，导致梯度不稳定进而难以计算；Softmax 操作将相似度矩阵转化为归一化的概率分布，并与值矩阵 V 进行加权求和，以此实现全局信息的动态提取。

为了使模型能够同时从多个不同的特征子空间中捕捉信息，Vaswani 等人将 Transformer 中的自注意力机制进一步扩展为多头注意力机制，如公式(2-11)。模型将 W_Q 、 W_K 、 W_V 并行投影至 h 个低维特征子空间，在每个子空间中分别进行缩放点积注意力计算，随后将各个头的输出拼接，并经过一次线性变换还原维度：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (2-11)$$

$$\text{head}_i = \text{Attention}(Q W_Q^{(i)}, K W_K^{(i)}, V W_V^{(i)}) \quad (2-12)$$

其中， $W_Q^{(i)}$ 、 $W_K^{(i)}$ 、 $W_V^{(i)}$ 是索引为 i 的注意力头的投影矩阵， $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ 为输出投影矩阵。多头注意力机制显著提升了模型的特征表达能力，使其能够更好地捕获复杂的语法结构与深层语义。

在多头注意力层之后，Transformer 对序列中的每个位置独立应用了一个全连接的前馈神经网络（Position-wise Feed-Forward Network, FFN），以引入必要的非线性变换。该网络通常包含两层线性映射与一个 ReLU 激活函数，如公式(2-13)：

$$\text{FFN}(x) = \max(0, x W_1 + b_1) W_2 + b_2 \quad (2-13)$$

其中 W_1 用于将特征维度从 d_{model} 扩展至更高的维度，而 W_2 则将其映射回原始维度 d_{model} ，两次线性变换共同实现对每个位置特征的非线性变换。




图 2-3 Transformer 架构

2.3.2 LoRA 技术

低秩自适应（Low-Rank Adaptation, LoRA）是由 Edward J. Hu 等人于 2021 年在论文《LoRA: Low-Rank Adaptation of Large Language Models》中提出的一种参数高效的轻量化微调方法。其核心动机在于解决当前大语言模型预训练面临的算力瓶颈：随着大语言模型参数规模呈指数级增长，面向下游特定领域任务进行全参数微调的计算成本与硬件门槛极高。此外，在样本量有限的垂直领域数据上更新全部预训练权重，极易引发“灾难性遗忘”，导致模型丧失其在预训练阶段所习得的泛化知识。LoRA 的理论依据建立在深度学习模型的“内在秩”假设之上。即尽管预训练模型包含海量参数，但其在适配特定下游任务时，并非所有的参数都需要调整，真正对下游任务有效的权重实际上只存在于一个极低维度的子空间中。基于此假设，LoRA 提出了一种旁路更新机制：通过向模型的部分网络层添加额外的可训练低秩矩阵，来实现模型在特定任务上的微调，同时保持原有模型的全部参数处于冻结状态。

LoRA 的工作机制可分为两部分：微调和推理。在模型训练过程中，LoRA 保持模型原始的预训练参数矩阵 $W \in \mathbb{R}^{d \times d}$ 处于完全冻结状态，使其不参与任何梯度更新。与此同时，在原始矩阵旁引入两个较小的可训练参数矩阵 $A \in \mathbb{R}^{r \times d}$ 和 $B \in \mathbb{R}^{d \times r}$ ，其中 r 为极小的本征秩超参数。模型将这两个低秩矩阵的乘积 $\Delta W = B \cdot A$ 作为对原参数矩阵 W 的附加调整项，使

得整体等效权重演变为：

$$\hat{W} = W + \Delta W = W + B \cdot A \quad (2-14)$$

在反向传播的过程中，优化器仅对矩阵 A 和 B 的参数进行梯度计算与更新，原始权重 W 始终保持不变，从而在极大降低显存开销的同时实现了特定任务的参数适配。

在模型部署与实际计算时，LoRA 模块可以无缝叠加到原始权重中，不引入任何额外的计算延迟。当输入张量 x 经过该线性层时，不再仅仅与原始权重 W 相乘，而是使用带有LoRA 调整项的融合权重。模型的正向传播行为等效为：

$$x \cdot \hat{W} = x \cdot (W + B \cdot A) \quad (2-15)$$

由于 $\Delta W = B \cdot A$ 是来自 LoRA 模块的补充权重，可在部署前静态预计算并直接叠加至 W 中，推理时的实际计算量与原始模型完全一致，兼顾了参数效率与推理性能。

2.3.3 思维链

大语言模型通过在海量的文本数据上进行无监督训练，构建了蕴含丰富世界知识的高维语义表示空间。为将模型中潜藏的广义知识精确的迁移至特定的下游任务，提示词工程成为一种核心的技术，其通过将具体任务构建为自然语言指令，使目标任务在输入形式上对齐模型预训练阶段的自回归目标。2022 年，Wei 等人在论文《Chain-of-Thought Prompting Elicits Reasoning in Large Language Models》中首次提出思维链（Chain-of-Thought, CoT）技术。思维链的核心在于通过引导大语言模型将复杂的问题逐步分解成一系列可求解的简单的子问题，并依次生成每个子步骤的推理过程，可以显著提升模型在复杂推理任务上的性能表现。这些介于输入与最终答案之间的中间推理步骤被定义为思维链。

CoT 技术的出现具有深刻的现实动机，研究人员观察到尽管大语言模型在参数规模扩展后展现出强大的知识存储能力，但是在面对数学推理、逻辑判断等需要多步骤因果推断的问题的复杂任务时，模型往往倾向于直接输出答案而跳过中间推导过程，这导致模型的正确率大幅下降。这是由于传统的提示词要求模型执行从输入到输出的直接映射，也就是 $\langle \text{input} \rightarrow \text{output} \rangle$ ，将复杂的多步推理过度压缩为单次前向传播，超出了模型在有限计算步骤内的推理能力边界。而 CoT 技术改变了这一映射方式，将推理流程拓展为 $\langle \text{input} \rightarrow \text{reasoning chain} \rightarrow \text{output} \rangle$ ，即模型在给出答案之前，显示地要求完整生成中间的推理链条。在数学表示上，CoT 将原本的条件概率建模 $P(Y|X)$ 扩展为联合概率分布

$$P(Y, Z | X) = P(Z | X) \cdot P(Y | X, Z) \quad (2-16)$$

其中， X 为任务输入， $Z = z_1, z_2, \dots, z_m$ 为由 m 个逻辑节点组成的中间推理路径， Y 为最终输出。该分解表明，模型首先基于输入 X 生成推理路径 Z ，再在 X 与 Z 的双重条件约束下推导最终结果 Y 。

2.4 本章小结

本章系统梳理了多模态分子性质预测的核心理论基础，为后续的模型构建确立了严谨的数学框架与算法支撑。首先，明确了涵盖一维序列、二维拓扑、分子指纹与自然语言的多维数据表征方法，确立了模型的多源异构输入基准。其次，深入剖析了特征提取的底层逻辑：在图空间域，系统推导了消息传递神经网络（涵盖 GCN 与 GAT 变体）及图 Transformer 的拓扑聚合机制；在文本语义域，详细阐释了 Transformer 自注意力架构、LoRA 轻量化微调策略，以及激发大模型复杂因果推理的思维链（CoT）理论。最后，界定了基于交叉注意力的特征动态融合与基于对比学习的跨模态空间对齐范式。综上所述，本章所构建的完整理论体系，直接为后文第三章与第四章中复杂网络架构的设计、目标函数的推导及多模态协同机制的实现奠定了坚实的基石。

3 基于思维链增强与消息传递的分子性质预测方法

在现代创新药物研发的早期阶段，精准评估候选分子的吸收、分布、代谢、排泄与毒性（ADMET）等生化性质，对于降低研发成本与规避后期临床风险具有至关重要的意义。近年来，随着计算化学与人工智能技术的深度交叉，基于深度学习的分子表征技术极大地加速了药物分子筛选的进程。模型通过自动学习大量的化合物分子高维空间与序列特征，实现了从分子结构映射到药理性质的建模，推动了药物发现流程从传统经验试错向数据驱动预测的演变进程。

面对高度复杂且容错率极低的真实药物筛选场景，现有的预测范式仍面临两项严峻的理论与技术瓶颈。一方面，在微观拓扑感知上，传统的图神经网络大多依赖于局部节点的无向聚合机制，严重忽视了化学键在消息传递中的动态交互作用，这种机制在多层迭代时极易引发信息冗余与信息回流，导致模型难以精准感知多环结构或长碳链分子中的复杂空间依赖。另一方面，在宏观性质预测上，大语言模型虽然展现出了强大的高维知识表征潜力，但现有的预测方法多要求模型进行缺乏中间逻辑支撑的端到端直接映射。这不仅容易引发无事实依据的幻觉，更使得预测过程呈现出难以解释的黑盒特性，难以满足现代制药工业对人工智能预测结果进行检验的严格要求。

为了应对上述挑战，本章提出了一种基于思维链增强与通信式图交互的分子性质预测模型（Chain-of-Thought enabled Communicative Message Passing framework, CoT-CMP）。该方法创新性地构建了双塔融合架构：在文本编码端，引入 LLaMA-3.1 大语言模型与低秩自适应（LoRA）轻量化微调技术，并结合思维链（CoT）提示工程，引导模型自发生成包含微观结构识别、理化属性分析和目标性质推导的显式逻辑推理文本，增强了模型决策过程的可解释性表达能力；在分子图编码端，采用交互式图神经网络（CMPNN）构建原子与化学键的“通信核”，强制特征在传递前进行深层动态交互，克服了传统无向图的信息回流弊端，精准捕获了分子的立体电子效应。最终，本框架通过交叉注意力机制，以结构更稳定的分子图拓扑特征为查询锚点，动态检索并自适应融合文本推理空间中的高价值药理逻辑，从而实现对复杂 ADMET 性质的高精度、高可解释性预测。

3.1 模型设计与描述

3.1.1 CoT-CMP 架构概述

针对 ADMET（吸收、分布、代谢、排泄、毒性）分子性质预测任务中存在的结构特

征与语义逻辑难以对齐的挑战，本章提出了一种全新的端到端预测框架——基于思维链增强与通信式图交互的分子性质预测模型（Chain-of-Thought enabled Communicative Message Passing framework, CoT-CMP）。该框架创新的将思维链引入大语言模型来进行药物分子的文本描述的生成，并核心设计双塔模型：一方面利用大语言模型显式的逻辑推理能力来弥补传统模型的不可解释性；另一方面利用改进的通信式图神经网络来捕捉分子内部深层的原子和键之间的动态交互。

具体而言，采用具有针对性的下游任务直接微调策略，以适应 ADMET 数据集样本量少但领域特异性极强的特点。如图 3-1 所示，模型的整体拓扑结构由三条核心处理链路耦合而成：首先是基于思维链的大语言模型文本编码链路，该模块利用 LLaMA-3.1-8B 强大的广义知识库与逻辑推理能力，通过提示词工程将分子的 SMILES 序列转化为蕴含丰富药理规则的显式推理文本，并通过低秩自适应（LoRA）技术高效提取高维语义特征。

其次是交互式图编码链路，该模块引入了先进的 CMPNN(Communicative Message Passing Neural Network)架构。为了突破传统图神经网络（如 MPNN）中存在的信息回流问题以及忽视化学键独立语义的局限，CMPNN 创新性地构建了原子与化学键之间的“通信核”。在有向消息传递的过程中，模型强制原子特征与化学键特征进行深度交互，使得化学键不再是静态的连接边，而是参与特征演化的动态实体，从而精准捕捉分子内部的电子效应与构效关系。

最后是多模态交叉注意力融合链路，该模块以结构信息更为稳定的图表征作为查询锚点（Anchor），通过交叉注意力机制动态聚合文本推理特征，最终通过多层感知机实现对分子 ADMET 性质的高精度预测。这种设计不仅赋予了模型强大的预测能力，更通过思维链的生成与关键子结构的交互，显著提升了模型决策过程的可解释性。




图 3-1 CoT-CMP 架构图

3.1.2 思维链增强的文本编码器

在药物分子性质预测中，传统的文本编码方式往往仅将 SMILES 字符串视为无语义的符号序列，难以挖掘其中隐含的构效关系逻辑。为了解决这一问题，本研究引入了思维链（Chain-of-Thought, CoT）技术，旨在模拟药物化学家在分析分子时的逐步推理过程，以便使模型能够生成更具逻辑性的推理文本，并为结果解释提供依据。文本编码器的首要任务是构建高质量的提示词工程。本架构不再直接要求模型输出预测结果，而是设计了一种包含“分子描述+任务指令+推理引导”的复合提示模板。具体来说，输入的 SMILES 序列首先被转化为自然语言描述，并结合“Let's think step by step”的引导指令输入至大语言模型中，详细的提示词模板如表 3-1 所示。这一过程能够激发大模型内部潜藏的化学知识，使其自发地从分子量、氢键供受体数量、旋转键数等理化性质出发，逐步推导其对特定 ADMET 性质的影响，最终生成一段逻辑严密的推理文本。

在模型选择上，本文选用了具有 80 亿参数的 LLaMA-3.1 模型作为文本编码的主干网络。鉴于全参数微调大模型对计算资源的需求极高且容易在小样本的 ADMET 数据集上发生过拟合，本文采用了低秩自适应（LoRA）微调策略。LoRA 技术通过在预训练模型的每一层注入可训练的低秩分解矩阵，在保持预训练权重冻结的前提下，仅更新极少量的附加参数。这种方法不仅大幅降低了显存开销，更重要的是，它允许模型在保留通用化学知识的同时，能够快速适配下游特定的分子性质预测任务。在实现上，本文首先基于提示模板生成包含显式推理步骤的文本，再将生成文本与原始分子描述一并输入文本编码器，提取其最终隐藏层表示作为文本语义特征。

表 3-1 提示词模板

System Instruction	You are an expert medicinal chemist and toxicologist. Your task is to analyze the molecular structure and predict its property in a specific biochemical task.
Input Context	Here is the information of a specific drug molecule: SMILES: {smiles} Physicochemical Properties: {properties}
Task	Let's think step by step. Determine whether this molecule is likely to exhibit the target property in the {dataset_task} task. Please reason explicitly in the following three stages: 1. Key Substructure Identification: Identify the major functional groups, ring systems, and core scaffold. 2. Physicochemical and Toxicological Interpretation: Explain how the identified substructures and the provided physicochemical properties may contribute to the target property. 3. Final Property Deduction: Provide one concise sentence summarizing whether the molecule is likely to exhibit the target property.
Output Format	[Key Substructure Identification] ... [Physicochemical and Toxicological Interpretation] ... [Final Property Deduction] ...

3.1.3 分子图编码器

尽管大语言模型在宏观的药理规则推理上具有优势，但其对微观分子拓扑结构的感知能力存在天然缺陷。为了弥补这一短板并精准捕捉原子间的化学键合作用与电子效应，本文采用了交互式消息传递图神经网络（Communicative Message Passing Neural Network, CMPNN）作为图编码器。同样的，本文的图编码器将分子表示为 $G = (V, E)$ ，其中 $v \in V$ 表示分子中的原子节点， $e_{uv} \in E$ 表示原子 u 与原子 v 之间的化学键。相比于只更新节点特征

的 MPNN 模型和只更新边特征的 DMPNN 模型, CMPNN 模型同时对节点特征和边特征进行更新, 并使用一个被称为通信核的特殊模块来进行操作。该模块打破了传统方法中化学键特征仅作为辅助输入的惯例, 强制原子特征与化学键特征在传递前进行深度的交互操作。在每一次迭代中, 原子节点的特征向量会与相连化学键的特征向量进行非线性融合, 生成增强的消息向量。最终, 经过多次更新的有向边特征被映射回原子节点, 并通过一个基于门控机制的读出层聚合成图级别的全局表征向量。这一向量高度浓缩了分子的拓扑连接与立体电子特征, 将作为后续与文本模态融合过程中的结构锚点, 引导文本模态的推理逻辑与之对齐。

3.1.4 融合与预测模块

在获取了包含显式推理逻辑的文本表征与包含深层拓扑结构的图表征后, 如何将这两股异构信息进行有效融合是决定预测性能的关键。简单的特征拼接往往忽略了不同模态特征之间的语义鸿沟, 难以实现深度的信息交互。因此, 本研究设计了一个基于交叉注意力机制的融合模块。在该模块中, 本研究选取物理意义更为明确、结构更为稳定的图表征向量作为查询向量, 而将包含丰富语义推理信息的文本表征向量作为键向量和值向量。

通过这种设计, 模型能够以分子的拓扑结构为索引, 在文本推理空间中动态检索与之匹配的药理逻辑描述。交叉注意力机制会计算图特征与文本特征之间的相关性分数, 并据此对文本信息进行加权聚合。这意味着, 对于某些依赖特定官能团的性质(如毒性), 模型会更加关注图结构中对应的子结构特征; 而对于某些依赖整体理化性质的属性(如溶解度), 模型则会从文本模态中提取更多的推理信息。经过交叉注意力融合后的特征向量, 不仅保留了分子的结构骨架, 还融入了专家的推理逻辑。最后, 该融合向量被输入至一个由多层全连接网络构成的预测头中。针对 ADMET 数据集中的不同任务类型, 预测头分别输出分类任务的概率值或回归任务的实数值, 从而实现端到端的分子性质预测。

3.2 实验设计

3.2.1 数据集

本研究中采用来自 TDC 平台中的 ADMET Benchmark Group^[28]作为实验基准。TDC 是目前研发发现领域最为权威的数据集之一, 其提供的 ADMET 数据集基准组, 涵盖了药物的吸收、分布、代谢、排泄和毒性等关键指标。在本章节将会在 ADMET 基准组上对 CoT-CMP 框架进行微调。数据集的基本介绍如表 3-2 所示。

表 3-2 ADMET 基准数据集

任务分类	数据集	分子数量	任务类型	评价指标	划分方式
吸收	Caco2	906	回归	MAE	Scaffold
	HIA	578	分类	AUROC	Scaffold
	Pgp	1212	分类	AUROC	Scaffold
	Bioav	640	分类	AUROC	Scaffold
	Lipo	4200	回归	MAE	Scaffold
	AqSol	9982	回归	MAE	Scaffold
分布	BBB	1975	分类	AUROC	Scaffold
	PPBR	1797	回归	MAE	Scaffold
	VDss	1130	回归	Spearman	Scaffold
代谢	CYP2C9 Inhibition	12092	分类	AUPRC	Scaffold
	CYP2D6 Inhibition	13130	分类	AUPRC	Scaffold
	CYP3A4 Inhibition	12328	分类	AUPRC	Scaffold
	CYP2C9 Substrate	666	分类	AUPRC	Scaffold
	CYP2D6 Substrate	664	分类	AUPRC	Scaffold
	CYP3A4 Substrate	667	分类	AUPRC	Scaffold
排泄	Half life	667	回归	Spearman	Scaffold
	CL-Hepa	1020	回归	Spearman	Scaffold
	CL-Micro	1102	回归	Spearman	Scaffold
毒性	LD50	7385	回归	MAE	Scaffold
	hERG	648	分类	AUROC	Scaffold
	Ames	7255	分类	AUROC	Scaffold
	DILI	475	分类	AUROC	Scaffold

1. 吸收

Caco-2: 衡量药物在人结肠癌细胞系中的渗透系数，是模拟人体肠道吸收能力的体外黄金标准，用于精准预测口服药物的吸收效率。

HIA: 量化药物经由肠道上皮细胞进入血液循环的比例，是评估口服药物能否被人体有效吸收的核心前置指标。

Pgp: 预测分子是否为 P-糖蛋白的底物或抑制剂。该蛋白能将药物泵出细胞，直接影响药物的吸收效率与多药耐药性产生。

Bioav: 预测药物进入体循环的比例，反映了吸收过程和肝脏首过效应的综合结果，是

决定临床给药剂量的重要参数。

Lipo: 记录分子的辛醇-水分配系数 (LogD)，用于评估药物的亲脂性。该性质直接决定了药物穿透细胞膜及生物屏障的能力。

2. 分布

BBB: 判断分子能否穿透血脑屏障进入中枢神经系统。这对开发脑部疾病药物至关重要，同时也用于规避非脑部药物的中枢副作用。

PPBR: 预测药物与血浆蛋白的结合率。结合率过高会限制血液中游离药物的浓度，进而影响药效发挥与向组织的分布。

VDss: 衡量药物在体内的理论稳态分布容积，反映药物在组织与血浆间的分布倾向，是指导临床给药间隔设计的关键参数。

3. 代谢

CYP2C9 Inhibition: 预测分子是否抑制 CYP2C9 酶。该酶代谢约 15% 的临床药物，其抑制作用会导致底物药物血药浓度异常升高，引发严重出血等不良反应。

CYP2D6 Inhibition: 预测分子对 CYP2D6 酶的抑制潜力。该酶涉及约 25% 药物的代谢，其抑制可能导致显著的药物相互作用，影响联合用药的安全性。

CYP3A4 Inhibition: 判断分子是否抑制人体含量最丰富的 CYP3A4 酶。由于该酶代谢近半数临床药物，其强抑制剂极易引发灾难性的药物蓄积中毒，是 DDI 筛查的重中之重。

CYP2C9 Substrate: 预测分子是否为 CYP2C9 酶的底物。识别该代谢途径有助于预测药物在不同基因型人群中的清除速率差异，对优化酸性药物的药代动力学至关重要。

CYP2D6 Substrate: 判断分子是否主要通过 CYP2D6 途径清除。该酶存在显著的遗传多态性，确定其底物属性对于预测药物在“快/慢代谢者”体内的暴露量差异具有指导意义。

CYP3A4 Substrate: 预测分子是否被 CYP3A4 酶代谢。作为肝脏首过效应的主要执行者，确认底物属性有助于评估药物的口服生物利用度及受代谢诱导剂影响的敏感性。

4. 排泄

Half Life: 预测药物在体内的消除半衰期，即血药浓度降低一半所需时间。它是描述药物在体内驻留时长的核心药代动力学参数。

CL-Hepa: 测量药物在肝细胞中的清除率，反映肝脏整体对药物的代谢清除能力，是评估药物肝脏代谢稳定性的体外模型。

CL-Micro: 测量药物在肝微粒体中的内在清除率，主要反映 I 相代谢酶对药物的降解

速率。

5. 毒性

LD50: 记录导致 50%实验动物死亡的致死剂量，用于评估化合物的急性毒性水平，是药物安全性评价中不可逾越的基础红线。

hERG: 预测分子对钾离子通道的阻滞作用。该通道阻塞会导致长 QT 综合征等致死性心律失常，是心脏毒性评估中较为关键的指标。

Ames: 基于细菌回复突变实验判断分子是否具有致突变性，用于早期筛查潜在的致癌风险与遗传毒性，是临床前必做的安评项目。

DILI: 预测药物诱导的肝损伤风险。这是导致药物临床试验失败主要原因之一，该数据集用来预测分子是否会诱导肝损伤。

3.2.2 划分方式

为了更直观地揭示不同数据划分策略对模型泛化评估的影响，本研究选取了 PPBR_AZ（血浆蛋白结合率）数据集作为典型案例，利用 t-SNE 降维技术将高维分子特征映射至二维平面，并采用六边形热力图对化学空间的分布密度进行了可视化对比。如图 3-2 所示，图中每个六边形单元的颜色映射了该区域内测试集样本的占比：深绿色代表该区域完全由训练集样本占据，而红色则代表该区域完全由测试集样本占据。

如图 3-2 左侧所示，在随机划分（Random Split）策略下，热力图呈现出均匀的深绿色基调，且测试集样本（浅色/红色点）呈散点状随机分布于训练集样本的包围之中。这种“均匀混合”现象表明，训练集与测试集在化学空间中共享了大量相似的分子骨架结构，模型在测试集上的预测本质上是一种插值过程，极易因记忆相似结构而导致性能评估的虚高。

相比之下，图 3-2 右侧的骨架划分（Scaffold Split）展现出了截然不同的分布模式。热力图呈现出显著的区域分化特征：部分化学空间区域呈现深绿色（训练集集中区），而部分区域则呈现鲜明的红色或橙色（测试集集中区）。这种“斑块状”分布直观地说明了训练集与测试集占据了互不重叠的化学空间区域，二者之间存在显著的结构鸿沟。这种划分方式迫使模型必须跨越已知的骨架簇，对位于全新化学空间区域的分子进行外推预测。

该可视化结果表明，骨架划分能够在一定程度上减少训练集与测试集之间的骨架重叠，从而比随机划分更严格地评估模型的结构泛化能力。因此，本文后续实验采用骨架划分策略，以提高泛化评估的严格性。




图 3-2 随机划分与骨架划分在 PPBR_AZ 数据集上分布的对比

3.2.3 实验设置

为了确保实验结果的可复现性与公平性，此小结将介绍本实验中各个环节所用到的实验设置和相关参数设置，具体如下：

本实验所用到的计算设备是一张 NVIDIA GeForce RTX 4090 的显卡，其拥有 24GB 的显存，用来对模型推理和梯度计算。操作系统为 Ubuntu 24.04 LTS，配合一张 Intel Core i7-12700KF CPU 和 64GB 的内存。在软件方面主要是基于 PyTorch 2.4.1 深度学习框架构建，图神经网络组件依赖于 PyG (PyTorch Geometric) 2.7.0 库，化学分子处理与理化指标计算则统一采用 RDKit 2025.9.3 工具包。

对于模型架构中的参数来说，本实验选用了 LLaMA-3.1-8B-Instruct 作为文本模态的主干网络，其输入序列的最大长度为 512 个 Token。对于 LoRA 的核心参数设定为：秩 $r=16$ ，缩放系数为 32，Dropout 为 0.05。对于图编码采用三层的 CMPNN 网络，其隐藏层统一设置为 300。

关于模型训练过程中的相关参数，例如学习率设置为 1×10^{-5} ，批次大小设置为 32，最大训练轮次设置为 200 轮，且引入早停机制，当损失连续 15 个 Epoch 未出现下降的时候自动终止训练。

3.2.4 评价指标

ADMET 基准数据组涵盖了分类和回归两类任务，针对不同的任务类型采用不同的评价指标。其在分类任务中使用了 AUROC 和 AUPRC 作为评价标准，在回归任务中使用了 MAE 和 Spearman 作为评价标准。各个指标的具体介绍如下：

AUROC：全称为接收者操作特征曲线下面积（Area Under the Receiver Operating Characteristic Curve），适用于二分类任务，评估模型对正负样本的排序能力。具体来说 ROC 是以假阳性率(FPR)为横坐标，真阳性率(TPR,即召回率)为纵坐标绘制的一条曲线。而 AUROC 就是这条 ROC 曲线下方的积分的面积。

$$TPR = \frac{TP}{TP + FN} \quad (3-1)$$

$$FPR = \frac{FP}{FP + TN} \quad (3-2)$$

$$AUROC = \int_0^1 TPR(FPR)d(FPR) \quad (3-3)$$

AUPRC：全称为精确率-召回率曲线下面积（Area Under the Precision-Recall Curve），适用于数据分布极度不平衡的二分类任务。PR 曲线是以召回率，即 TPR 为横坐标，精确率(Precision)为纵坐标绘制的曲线。而 AUPRC 就是 PR 曲线下方的面积。

$$Precision = \frac{TP}{TP + FP} \quad (3-4)$$

$$Recall = \frac{TP}{TP + FN} \quad (3-5)$$

$$AUPRC = \int_0^1 Precision(Recall)d(Recall) \quad (3-6)$$

MAE：全称为平均绝对误差（Mean Absolute Error），适用于回归任务，用于衡量模型预测值与真实值之间偏差的平均水平。假设样本的总数为 n ， y_i 是第 i 个样本的真实值， $\hat{y}_i$ 是第 i 个样本的预测值，则平均绝对误差定义为：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3-7)$$

Spearman：全称为斯皮尔曼等级相关系数（Spearman's Rank Correlation Coefficient），与 MAE 不同的是 Spearman 关注排序能力即预测值的相对大小关系是否正确。一个模型可能 MAE 较大但 Spearman 系数很高，这说明虽然预测的绝对数值不够精确，但能够正确区分样本之间的相对高低。在药物筛选的实际应用中，通常需要从大量候选分子中筛选出性质最优的一批分子，此时排序的准确性往往比绝对数值的精度更具实际价值，因此 Spearman 系数在 ADMET 基准评估中具有重要意义。

3.2.5 对比模型

为了客观评估 CoT-CMP 框架在 ADMET 预测任务中的性能优势，本文从 ADMET 基

准组的官方排行榜中选取了四个基准模型。该排行榜旨在为各个数据集提供标准化的性能评估。各个基准模型的介绍如下：

GCN^[29]：图卷积神经网络是最经典也是应用最广泛的神经网络基线模型之一。该模型将分子视为图，原子视为节点，化学键视为边，通过局部领域内的消息传递机制来更新节点的特征信息。每一个原子都聚合了一阶邻居原子的特征信息，通过卷积操作来获取分子之间局部拓扑结构，最终通过读出函数得到分子级别的嵌入。

AttentiveFP^[30]：是基于注意力机制的经典图神经网络，旨在解决传统 GCN 在处理长程依赖时的局限性。该模型首次通过在原子级别和分子级别引入图注意力网络，能够动态学习不同邻居节点对中心原子的贡献权重。先对原子邻域做注意力加权聚合，再对全局分子做超图级别的注意力读出。该模型能够捕捉长程依赖，在多个分子性质预测任务上表现优异，是图神经网络中较强的基线模型。

NeuralFP^[31]：神经图指纹模型是一种将深度学习应用于分子表征的开创性工作之一，通过对传统的 Morgan 指纹进行神经网络的泛化，将固定的哈希操作替换为可学习的神经网络，允许网络在端到端的训练过程中自主学习最优的特征提取方式。它通过图池化操作，将节点级别的特征平滑地聚合为整个分子的连续型向量表示。

CNN^[32]：卷积神经网络是一种基于卷积操作的网络模型，在分子预测任务中通常将 SMILES 视为序列输入，利用一维卷积网络提取局部子结构特征。

3.3 实验及结果分析

3.3.1 对比实验

为了验证 CoT-CMP 模型在药物分子预测任务上的性能，本章节在 ADMET 基准组上的 22 个数据集进行了实验，实验过程中所有的基线模型和 CoT-CMP 保持一致的划分方式。为了保证实验数据的可靠性，实验采用了不同的随机数进行了多次实验。试验结果中最好的数据由黑体标出，次优的结果由下划线标出。各个模型的实验结果数据如表 3-3。

由实验数据结果可得知 CoT-CMP 在 17 个评测集上获取了最优的结果，在 5 个评测集上获取了次优的结果。值得注意的是在本次实验包含的 4 项毒性预测任务（LD50, hERG, Ames, DILI）中，CoT-CMP 实现了全面领先。无论是针对心脏毒性的 hERG 抑制预测，致突变性的 Ames 测试，还是药物性肝损伤，CoT-CMP 均展现出了最高的预测精度，将准确率分别提升至 0.855、0.838、0.891。这一结果表明，模型在毒性相关任务上

具有较好的判别能力，可为高通量虚拟筛选中的早期风险评估提供参考。另外在 VDss 数据集中，和最佳的模型 GCN 相比，CoT-CMP 模型性能提高了 7% 左右，在 Half life 数据集上性能提高了 10% 左右。在 CYP2D6 Inhibition、CYP3A4 Inhibition、CYP2C9 Substrate 和 CYP2D6 Substrate 等代谢相关的数据集上，CoT-CMP 模型表现出了优异的性能。

表 3-3 COT-CMP 在 ADMET 基准组上的对比实验结果

数据集	GCN	AttentiveFP	NeuralFP	CNN	CoT-CMP
Caco2(↓)	0.599 _(0.104)	<u>0.401</u> _(0.032)	0.530 _(0.102)	0.446 _(0.036)	0.387 _(0.361)
HIA(↑)	0.936 _(0.024)	<u>0.974</u> _(0.007)	0.943 _(0.014)	0.869 _(0.026)	0.982 _(0.012)
Pgp(↑)	0.895 _(0.021)	0.892 _(0.012)	0.902 _(0.020)	<u>0.908</u> _(0.012)	0.912 _(0.020)
Bioav(↑)	0.566 _(0.115)	0.628 _(0.035)	0.632 _(0.036)	0.613 _(0.013)	<u>0.630</u> _(0.026)
Lipo(↓)	0.541 _(0.011)	0.572 _(0.007)	<u>0.536</u> _(0.023)	0.743 _(0.020)	0.510 _(0.035)
AqSol(↓)	0.907 _(0.020)	<u>0.776</u> _(0.008)	0.947 _(0.009)	1.023 _(0.023)	0.742 _(0.046)
BBB(↑)	0.842 _(0.016)	0.855 _(0.011)	0.836 _(0.009)	0.781 _(0.030)	<u>0.850</u> _(0.019)
PPBR(↓)	10.194 _(0.373)	9.373 _(0.335)	<u>9.292</u> _(0.384)	11.106 _(0.358)	8.892 _(0.212)
VDss(↑)	<u>0.457</u> _(0.050)	0.241 _(0.145)	0.258 _(0.162)	0.226 _(0.114)	0.521 _(0.151)
CYP2C9 Inhibition(↑)	0.735 _(0.004)	0.749 _(0.004)	0.739 _(0.010)	0.713 _(0.006)	<u>0.745</u> _(0.023)
CYP2D6 Inhibition(↑)	0.616 _(0.020)	<u>0.646</u> _(0.014)	0.627 _(0.009)	0.544 _(0.053)	0.650 _(0.010)
CYP3A4 Inhibition(↑)	0.840 _(0.010)	<u>0.851</u> _(0.006)	0.849 _(0.004)	0.821 _(0.003)	0.855 _(0.004)
CYP2C9 Substrate(↑)	0.344 _(0.051)	<u>0.375</u> _(0.032)	0.359 _(0.059)	0.367 _(0.059)	0.380 _(0.051)
CYP2D6 Substrate(↑)	<u>0.617</u> _(0.039)	0.574 _(0.030)	0.572 _(0.062)	0.485 _(0.037)	0.621 _(0.029)
CYP3A4 Substrate(↑)	0.590 _(0.023)	0.576 _(0.025)	0.578 _(0.020)	0.662 _(0.031)	<u>0.622</u> _(0.035)
Half life(↑)	<u>0.239</u> _(0.100)	0.085 _(0.068)	0.177 _(0.165)	0.038 _(0.138)	0.337 _(0.175)
CL-Hepa(↑)	0.366 _(0.063)	0.289 _(0.022)	0.401 _(0.037)	0.235 _(0.021)	<u>0.382</u> _(0.022)
CL-Micro(↑)	<u>0.532</u> _(0.033)	0.365 _(0.055)	0.529 _(0.015)	0.252 _(0.116)	0.550 _(0.027)
LD50(↓)	<u>0.649</u> _(0.026)	0.678 _(0.012)	0.667 _(0.020)	0.675 _(0.011)	0.601 _(0.028)
hERG(↑)	0.738 _(0.038)	<u>0.825</u> _(0.007)	0.722 _(0.034)	0.754 _(0.037)	0.855 _(0.035)
Ames(↑)	0.818 _(0.010)	0.814 _(0.008)	<u>0.832</u> _(0.006)	0.776 _(0.015)	0.838 _(0.017)
DILI(↑)	0.859 _(0.033)	<u>0.886</u> _(0.015)	0.851 _(0.026)	0.792 _(0.016)	0.891 _(0.020)

通过横向对比也可以发现，基于一维序列的 CNN 模型在绝大多数任务上表现平平，这验证了保留分子的二维或三维空间拓扑结构对于准确预测 ADMET 属性至关重要。另一方面，与同为图神经网络的 AttentiveFP 和 NeuralFP 相比，CoT-CMP 依然能够在大部分任

务中胜出。这说明本模型采用的 CoT 增强文本描述和交叉注意力融合的策略，相比于 AttentiveFP 简单的注意力机制，能够更有效地聚合长程依赖信息和捕获局部官能团的特征，从而在复杂的 ADMET 任务中获得了更加丰富和鲁棒的分子表征。

3.3.2 消融实验

为系统性地研究 CoT-CMP 框架中各核心模块的独立贡献与协同效应，特别是探究大语言模型内部机制以及多模态融合方式对 ADMET 最终预测性能的影响，本节在统一的实验配置环境下，设计了五种渐进式的消融变体进行对比分析。

本研究以完整的 CoT-CMP 模型为基准上限，向下拆分架构模块或优化策略，各个变体的具体定义如下：

w/o Text: 完全移除大语言模型及其对应的文本编码链路，仅保留 CMPNN 图编码器提取分子的二维拓扑特征，并通过全连接层直接输出预测结果。

w/o LoRA : 保留双塔架构与融合模块，但在训练过程中完全冻结 LLaMA-3.1 的所有预训练权重，不使用低秩自适应微调，仅将大模型作为静态的特征提取器。

w/o CoT : 保留所有的模型权重微调与双塔架构，但对提示词进行修改。具体而言，仅对文本提示模板进行调整，即删除原模板中用于触发分步推理的显式引导语，如 “Let’s think step by step”，只输入分子的 SMILES 序列和原始理化性质描述文本，进行性质的预测文本生成。

w/o Cross-Attn: 保留完整的图文特征提取链路，但在多模态对齐阶段，移除动态交叉注意力模块，转而采用简单的特征拼接方式将图向量与文本向量拼接。

表 3-4 CoT-CMP 在 ADMET 基准组上部分分类任务消融实验结果

Model	Pgp	BBB	CYP2D6 Inhibition	Ames
w/o Text	0.835 _(0.018)	0.803 _(0.016)	0.597 _(0.037)	0.805 _(0.017)
w/o CoT	0.805 _(0.024)	0.791 _(0.032)	0.593 _(0.027)	0.795 _(0.022)
w/o LoRA	0.775 _(0.012)	0.740 _(0.010)	0.566 _(0.029)	0.748 _(0.015)
w/o Cross-Attn	0.872 _(0.015)	0.825 _(0.021)	0.638 _(0.023)	0.820 _(0.019)
CoT-CMP	0.912_(0.020)	0.850_(0.019)	0.650_(0.010)	0.838_(0.017)

本文在 Pgp、BBB、CYP2D6 Inhibition 和 Ames 四个分类数据集上进行了消融实验，结果如表 3-4 所示，从整体来看，CoT-CMP 在这四个分类数据集上均取得了最优的结果，

表明本文提出的文本增强、CoT 提示模块、LoRA 微调策略以及跨模态交叉注意力等模块均能够有效提升模型的性能,且各模块之间存在明显的协同增益。具体来看,w/o LoRA 的性能整体最弱,在 Pgp、BBB、CYP2D6 Inhibition 和 Ames 上的结果分别仅为 0.775、0.740、0.566 和 0.748,相较完整模型分别下降了 0.137、0.110、0.084 和 0.090。这说明参数高效微调机制对大模型适应分子性质预测任务具有重要作用,若缺少有效的任务适配,文本的语义建模能力将明显降低。

表 3-5 CoT-CMP 在 ADMET 基准组上部分回归任务消融实验结果

Model	Caco2	AqSol	PPBR	LD50
w/o Text	0.521 _(0.045)	0.935 _(0.052)	10.954 _(0.345)	0.705 _(0.035)
w/o CoT	0.485 _(0.038)	0.882 _(0.048)	10.320 _(0.285)	0.682 _(0.030)
w/o LoRA	0.442 _(0.033)	0.824 _(0.051)	9.765 _(0.260)	0.655 _(0.025)
w/o Cross-Attn	0.415 _(0.028)	0.778 _(0.041)	9.245 _(0.235)	0.624 _(0.031)
CoT-CMP	0.387_(0.361)	0.742_(0.046)	8.892_(0.212)	0.601_(0.028)

在回归数据集中,本文选取了 Caco2、AqSol、PPBR 和 LD50 四个数据集做消融实验,结果如表 3-5 所示。本文提出的 CoT-CMP 模型仍然在四个数据集上取得了最优的性能,这表明各个模块之间的协同同样能够在连续值性质预测任务中有效降低误差。其中,w/o Text 在四个任务上的 MAE 最高,说明若完全移除文本模态,模型对分子性质连续值的拟合能力将受到明显削弱。这一结果表明,文本信息在回归任务中同样发挥了重要补充作用,尤其对于需要综合理化属性与语义知识的任务更为关键。w/o CoT 相比 w/o Text 有一定改善,但仍明显劣于完整模型。这说明即使保留文本输入,如果缺少显式的思维链引导,模型所构建的文本表征仍然不够充分,难以最大化发挥文本模态最大作用。w/o LoRA 虽然较 w/o Text 和 w/o CoT 已有明显改善,但仍全面落后于完整模型。另一方面,w/o Cross-Attn 是所有消融版本中最接近完整模型的设置,但依旧高于 CoT-CMP,说明仅依赖简单的模态组合仍不足以充分建模图结构与文本语义之间的对应关系,而跨模态交叉注意力机制能够进一步提升异构信息融合的有效性。

3.3.3 可视化分析

为进一步验证 CoT-CMP 模型在可解释性,本文选取 TDC 的毒性预测任务 DILI 数据集中的氯磺丙脲(chlorpropamide)作为典型案例进行可视化分析。该分子的 SMILES 为

CCCNC(=O)NS(=O)(=O)c1ccc(Cl)cc1, 在数据集中对应的标签为 1, 表示该样本具有药物性肝损伤风险。本文从分子结构和文本语义两个方面对模型的判别依据进行了可视化, 如图 3-3 所示。左侧给出了氯磺丙脲的二维分子结构, 右侧展示了模型在图模态上的注意力热力分布。可以观察到, 模型的高响应区域主要集中在对氯苯基-磺酰脲主骨架, 尤其是磺酰基、相邻脲基连接区以及芳香环邻近区域表现出较高的注意力。在文本模态方面, 图 3-3 下方详细展示了大模型生成的结构化分析文本及其热力词可视化结果。其中对于一些分子结构的词语模型表现出较高的关注, 例如 p-chlorobenzenesulfonyl、N-sulfonylurea scaffold、chlorophenyl ring 等, 还有对于毒理判断直接相关的关键词, 例如 hepatotoxicity、drug-induced liver injury 等词语也是表现出较高的关注度。上述可视化结果表明, 模型在该样本上关注的结构区域和文本关键词与已知毒性相关化学直觉具有一定一致性, 从而为理解模型预测依据提供了辅助线索。




图 3-3 氯磺丙脲在 DILI 任务中的双模态可视化分析结果

3.3.4 参数敏感实验

在图神经网络的架构设计中, 消息传递的层数是决定模型感受视野的大小和特征提取

质量的关键超参数之一。为了进一步探究 CMPNN 图编码器的层数对于模型最终性能的影响，本节从吸收、分布、代谢、毒性相关任务中各选了一个数据集，覆盖了分类任务和回归任务，进行图编码器层数的参数敏感性实验，结果如图 3-4 所示。

根据结果可知，随着图编码器的层数加深，性能曲线呈现出倒 U 型。当层数为 1 到 2 层的时候，模型的表现较低，这是由于浅层网络不足以捕捉分子全局的特征信息。在层数达到 3 层的时候，模型性能达到峰值。这是由于大多数分子都是小分子，因此三层图网络已经可以很好的捕捉到全局的信息。在层数达到 4 到 5 层的时候，模型的性能明显开始下降，这是由于过深的网络对于小分子结构来说会极容易出现过拟合现象。因此，为了在全局感受野与特征区分度之间取得最佳平衡，本研究在核心实验中，均将 CMPNN 的层数设置为 3 层。




图 3-4 CMPNN 模型层数对分类任务性能的影响

3.4 本章小结

本章针对药物分子 ADMET 性质预测任务中微观结构特征与宏观药理语义逻辑难以有效对齐的问题，提出了 CoT-CMP 双塔预测框架。该框架结合思维链增强的文本编码、CMPNN 图结构建模与交叉注意力融合，实现了图文信息的联合预测。在 TDC 多个 ADMET 基准上的实验结果表明，该方法在多数任务上取得了较优表现，消融实验也验证了文本增强、LoRA 微调和跨模态融合模块的有效性。

在模型架构设计方面，本章详细阐述了 CoT-CMP 框架的三大核心组件。在文本编码端，模型引入了 LLaMA-3.1 大语言模型，结合思维链(CoT)提示工程与低秩自适应(LoRA)

微调技术，将分子的线性序列转化为包含显式理化分析与药效推导的逻辑文本表征，显著提升了预测过程的可解释性。在图编码端，模型采用了交互式消息传递图神经网络（CMPNN）。通过构建基于有向边的消息传递机制与引入通信核模块，该网络有效克服了传统图模型中的信息回流弊端，实现了原子与化学键特征的动态深度交互，从而精准捕获了复杂的分子全局拓扑依赖。在多模态融合端，模型部署了交叉注意力机制，以分子结构特征为查询锚点，动态聚合文本推理空间中的高价值语义信号。

在实验设计方面，本章明确了模型评估的基准体系。实验选取了 Therapeutics Data Commons (TDC) 平台中涵盖吸收、分布、代谢、排泄与毒性五个维度的多项核心数据集。为真实反映模型在未知化学空间中的泛化性能，本章论证并确立了基于骨架划分的严格评估策略，并详细规定了包含 AUROC、AUPRC、MAE 及 Spearman 相关系数在内的多维评价指标体系，同时选取了 AttentiveFP、NeuralFP、CNN 及 GCN 四种具有代表性的模型作为对比基线。本章的理论架构搭建与严密的实验流程设计，为后续验证 CoT-CMP 模型在复杂药物分子性质预测任务中的优越性奠定了坚实基础。

4 基于知识增强与图对齐的分子性质预测方法

随着深度学习技术的飞速发展，数据驱动分子表征学习在创新药物发现与候选分子早期成药性评估中展现出了巨大的应用潜力。为缓解高精度分子生化性质标签严重稀缺的困境，研究人员广泛采用“无监督预训练-下游微调”的范式，极大提升了模型对未知化学空间的探索能力。然而，分子的理化性质与生物活性是多尺度空间结构与复杂药理规律的综合体现。传统的单一模态（如纯拓扑图或纯一维序列）存在固有的特征盲区，难以全面捕捉分子的全局信息。因此，融合多源异构数据的多模态表征学习逐渐成为该领域突破性能上限的关键路径。

尽管多模态融合前景广阔，但现有的跨模态预训练框架仍面临两项亟待突破的瓶颈。首先是语义鸿沟与数据噪声问题：公共医学数据库中的原始分子文本通常充斥着历史轶事等非结构化冗余信息，描述长度呈现极端的分布不均，且严重缺乏如脂水分配系数、极性表面积等关键定量理化指标的显式约束。其次是多模态对齐的梯度冲突问题：传统的跨模态对比学习多采用简单的全排列对齐策略，这种机械的对齐方式在面对包含图、序列、指纹及文本等多源异构数据时，极易因各模态信息熵与噪声水平的巨大差异，引发剧烈的模态间梯度冲突，最终导致模型出现特征提取坍塌或严重的负迁移现象。

为了应对上述挑战，本章提出了一种基于知识增强与图对齐的多模态分子性质预测框架（Knowledge-enhanced Graph Anchor Multimodal Alignment, KGAMA）。该框架构建了包含分子图、序列、指纹及自然语言的四维全景表征体系，并实现了两大核心创新：在数据构建端，创新性地引入了大语言模型驱动的知识重写流水线，将客观计算的定量物理化学属性无缝编织入去噪后的专家文本中，大幅提升了文本模态的知识密度与语义约束力；在多模态对齐端，摒弃了高复杂度的全排列对齐策略，确立了以分子图为核心的“语义锚点”，并引入了基于同方差不确定性的自适应加权对比学习机制，使得模型能够自主评估并动态平衡各模态的噪声水平。通过微观拓扑结构与宏观药理语义的稳健对齐，本框架旨在提升模型在下游复杂分子性质预测任务中的综合表现。

4.1 模型设计与描述

4.1.1 0KGAMA 框架概述

本章节提出了一个基于图表征为核心、多模态知识增强的分子预测架构，该框架的核心在于突破多源异构数据的语义壁垒，构建一个能够将多个通道的数据对齐到一个统一的

高维空间，进而进行分子的表征。本文框架采用预训练-微调范式，在预训练阶段，引入以图为中心的对比学习策略，驱动各个模态在潜在空间内完成语义锚定对齐；而在面向特定下游任务的微调阶段，则使用交叉注意力模块与多层感知机，实现对任务敏感特征的动态捕捉与灵活预测。

该模型的详细架构如图 4-1 所示，其总体结构可清晰划分为三大核心组件：多模态专属编码器：用于提取异构特征，统一嵌入空间映射模块：用于维度对齐，以及基于交叉注意力机制的融合模块：用于特征交互与预测。




图 4-1 KGAMA 模型架构

4.1.2 图编码器

图编码器构成了本框架的语义核心（Anchor）。本研究使用 Graphormer 架构，旨在从拓扑连接与几何空间两个维度对分子图进行深度解构。区别于传统图神经网络受限于局部感受野的缺陷，Graphormer 引入了三位一体的编码策略：中心性编码用于量化原子的节点重要度，空间编码负责记录原子间的最短路径距离，而边缘编码则精确描述化学键类型。经由多层 Graphormer Layer 的迭代处理，模型输出具备高度结构保真度的图表征向量 F_g ，该向量在预训练阶段充当了其他模态对齐的“语义锚点”。

4.1.3 指纹编码器

分子指纹作为一种将分子局部子结构转化为二进制代码的数字化表征手段，其核心机

制在于依据既定规则判定分子特定结构是否存在，如表 4-1 所示。基于编码策略之差异，现有指纹技术主要涵盖 AtomPairs、MACCS 及 Morgan 三类。表 4-1 详尽列示了各指纹所能承载的信息维度。

表 4-1 三种典型分子指纹特征的比较分析

指纹类型	结构信息	功能信息	拓扑信息
AtomPairs	√		√
MACCS	√	√	
Morgan	√		√

AtomPairs 指纹侧重于提取分子内全部非氢原子对的拓扑特征，该方法依照原子类型及原子间最短路径距离实施编码，进而有效捕捉分子内部空间关联与结构属性，尤为适宜表征分散官能团与整体构型间之关系。MACCS 指纹则建立于 166 个结构密钥基础之上形成二进制序列，每一密钥均指向特定分子子结构或化学特性；若分子具备密钥定义之结构，对应位赋值为 1，反之则置 0。本研究中，Morgan 算法参数设定为半径 2，比特数 2048。

前述三种指纹凭借相异编码策略，实现了对分子结构信息的多维覆盖，有效规避了单一类型之局限。综合利用三者有助于构建更为精细的分子特征图谱，赋予模型训练强劲输入支撑。实验将三种指纹拼接并导入分子指纹编码器，借助包含激活函数的多层感知机（MLP）习得非线性映射关系，将其投影至统一向量空间。具体运算流程如下：

$$\text{Output} = \sigma(W \cdot [A(x), B(x), C(x)] + b) \quad (4-1)$$

其中 $A(x)$ 代表 AtomPairs 指纹， $B(x)$ 指代 MACCS 指纹， $C(x)$ 为 Morgan 指纹； σ 表示 ReLU 激活函数， W 与 b 分别对应权重矩阵及偏置向量。

4.1.4 序列编码器

SMILES 字符串虽以线性文本形式存在，其本质却蕴含着复杂的化学拓扑逻辑与层次化结构。鉴于此，本文摒弃了传统的循环神经网络（RNN）方案，转而采用 RoBERTa 变体 Transformer 架构作为序列特征提取引擎。相较于 RNN 易受梯度消失困扰的固有缺陷，该架构凭借全局自注意力机制，具备跨越线性序列距离、直接锁定远端原子关联的能力。输入流处理：原始 SMILES 序列经由分词器离散化为 Token 流后，于序列首部植入全局表征符[CLS]，以此作为整个分子序列信息的聚合锚点。长程依赖建模：如图 4-1 所示，借助多头注意力层，模型能够穿透线性的字符间隔，精准捕捉支链末端或大环闭合点间的空间

语义一致性。特征投影：最终层输出的[CLS]隐状态向量被提取为序列全局表征 F_s ，随后经由全连接层映射至与图特征 F_g 等维的语义空间，为后续的跨模态对齐奠定维度基础。

4.1.5 文本编码器

该模块实现了本文核心创新点之一：知识增强重写。针对原始数据库文本可能存在的噪声干扰与信息冗余，本文设计了如下处理链路：

1.知识注入：利用 PubChem API 获取原始描述，并融合由 RDKit 计算得出的 11 项关键理化指标，如 LogP、TPSA 等。

2.知识重写：利用大语言模型充当领域专家，将定量的理化数值与定性的文本描述有机融合，生成逻辑严密、去噪后的高质量文本。

3.语义编码：重写后的文本被送入预训练 SciBERT 编码器。得益于其在海量科学文献上的预训练先验，SciBERT 能够敏锐捕捉分子描述中的专业术语语义，最终输出高密度的文本特征向量 F_t 。

具体的构建流程见实验设计预训练数据章节。

4.1.6 融合与预测

在下游任务微调阶段，模型通过交叉注意力机制实现多模态信息的自适应融合。动态加权融合机制允许模型根据不同性质预测任务的需求，自动学习不同模态特征 (F_g, F_s, F_f, F_t) 的重要性权重 W_m 。性质预测：融合后的全景分子表征被输入至由多层全连接网络构成的预测头（MLP Head），最终输出分子的理化性质或生物活性预测值 Y_{pred} 。

4.2 实验设计

4.2.1 预训练数据

为了克服现有分子文本数据集中存在的描述稀疏、噪声干扰大以及缺乏定量理化信息的问题，本文设计了一套包含“数据清洗—知识检索—属性计算—大模型重写”的自动化数据构建流水线。该流程旨在构建一个兼具高质量化学结构与高密度语义信息的分子—文本数据集，并使用 RDKit 工具生成其他模态的数据，用于多模态预训练。具体构建流程如下：

第一步，分子结构获取与标准化。本文选取 PubChem 数据库作为原始数据来源，随机抽取了约 30 万个药物分子 SMILES 序列。鉴于原始数据中存在异构体冗余及书写不规范

等问题，本文使用 RDKit 工具包对所有 SMILES 进行了规范化处理，并去除了重复项等无法通过 RDKit 解析的异常分子，并通过分子的唯一标识符 InChIKey，去掉了与下游数据集重叠的分子。经过严格筛选，最终保留了约 22 万个具有高度代表性的独立分子结构，构成了预训练数据集的骨架。

第二步，基于 API 的专家知识检索。针对筛选出的分子，本文利用 PubChem 提供的 PUG View API 接口进行批量检索，重点提取 JSON 数据中“Names and Identifiers”及“Record Description”字段下的描述性文本。该部分数据通常包含分子的通用名称、药理作用机制及历史背景等专家知识。然而，直接将 API 检索的原始文本用于训练存在显著的质量问题，主要集中在以下两个方面：

噪声冗余与文本过长：部分知名药物分子的记录中包含了大量非结构化的冗余信息。例如，在检索阿司匹林（Aspirin）时，返回的原始文本不仅长达数千词，还夹杂着 1853 法国化学家提取相关化学物等历史轶事、过期的专利号引用等。这些与分子构效关系无关的噪声数据会显著稀释核心语义，增加模型训练的显存开销并导致注意力分散。

描述稀疏与语义缺失：相反，部分分子的原始检索文本虽然看似完整，实则存在严重的语义冗余与信息混杂问题。例如，在检索阿克罗宁（Acronycine）时，原始文本将来源于不同数据库的片段化描述直接拼接，导致分子名称在“Acronycine”与“Acronine”之间不一致，同一分子的分子量信息与药理描述散落于多个独立语句之中，且夹杂着“(NTP, 1992)”、“(NCI04)”等数据来源标注符号。此类结构混乱的文本缺乏对分子功能与构效关系的系统性整合，导致模型在对比学习中难以提取一致的语义信号，从而引发模态对齐偏差。

上述“长尾分布”现象证明，仅依赖原始检索文本难以构建高质量的对齐空间，必须进一步对文本进行去噪压缩与语义补全。

第三步，理化性质计算与上下文构建：为了弥补文本模态在定量信息上的缺失，本文利用 RDKit 计算了每个分子的 11 项关键理化性质，具体的理化性质见表 4-2。这些理化指标被格式化为结构化的文本上下文，作为后续大模型生成的“事实锚点”，确保生成的文本描述在物理化学属性上不仅定性准确，而且定量精确。

表 4-2 分子理化性质指标及其含义

属性名称	英文标识	含义描述
平均分子量	MolWt	分子的平均相对质量

精确分子量	ExactMolWt	基于同位素质量计算的精确分子质量
脂水分配系数	LogP	衡量分子亲脂性的关键参数
拓扑极性表面积	TPSA	分子表面极性原子的总面积
重原子数	Heavy_Atoms	分子中非氢原子的总数量
氢键供体数	H_Bond_Donors	分子中能提供质子的基团数量
氢键受体数	H_Bond_Acceptors	分子中能接受质子的原子数量
可旋转键数	Rotatable_Bonds	单键旋转自由度的度量
环数量	Ring_Count	分子中环状结构的总数
芳香环数量	Aromatic_Rings	具有芳香性的环结构数量
手性中心数	Stereocenters	分子中立体异构中心的数量

第四步，基于大模型的知识清洗与重写：本文引入大语言模型（LLM）作为文本生成代理，通过精心设计的提示词工程执行“清洗+融合”任务。具体而言，本方法将 API 检索到的粗糙文本与 RDKit 计算的理化性质共同输入模型，要求模型去除原始文本中的噪声，并将理化指标自然地融入对分子的描述中。最终生成的文本呈现为“专家知识+理化属性”的混合描述形式，既保留了 PubChem 中的药理语义，又增强了对分子结构—性质关系的显式表达。

提示词的设计遵循以下三个核心原则：

角色定义与任务约束：明确指示模型扮演“资深药物化学家”的角色，并规定输出必须使用客观、学术的陈述语气，严禁使用第一人称或情感色彩词汇。

上下文注入：将检索到的原始文本与计算所得的理化性质列表作为两个独立的上下文块输入，强制模型在重写时必须参考这两部分信息。

负面约束：显式列出需要过滤的噪声类型（如专利号、历史轶事、商业名称），防止模型产生“幻觉”或保留冗余信息。

第五步，多模态输入视图构建：为了构建全方位的分子表征空间，除上述增强后的文本模态外，本文进一步基于清洗后的 SMILES 序列，利用 RDKit 工具包生成了分子的 2D 拓扑图结构与分子指纹，形成了图、序列、指纹、文本四位一体的多模态输入数据。

通过上述流程，本文成功构建了一个包含约 22 万个高质量多模态预训练数据集，为后续的多模态对比学习提供了坚实的数据基础。如图 4-2 展示了一个药物分子直接搜索到的数据和重写后的对比。



SMILES	<chem>CC(=O)OC1=CC=CC=C1C(=O)O</chem>	<chem>CC(=O)OC1=CC=CC=C1C(=O)O</chem>
2D Structure		
检索数据	Aspirin can cause developmental toxicity and female reproductive toxicity according to an independent committee of scientific and health experts. Acetylsalicylic acid appears as odorless white crystals or crystalline powder with a slightly bitter taste. (NTP, 1992) In 1853, a French chemist named Charles Frederic Gerhardt neutralized salicylic acid by buffering it with sodium (sodium salicylate) and acetyl chloride, creating acetosalicylic anhydride. Gerhardt's product worked, but he had no desire to market it and abandoned his discovery. In 1897, researcher Arthur Eichengrun and Felix Hoffmann, a research assistant at Friedrich Bayer & Co. in Germany, derivatized one of the hydroxyl functional groups in salicylic acid with an acetyl group (forming the acetyl ester), which greatly reduced the negative effects. This was the first synthetic drug, not a copy of something that existed in nature, and the start of the pharmaceuticals industry. Aspirin acts as an inhibitor of cyclooxygenase which results in the inhibition of the biosynthesis of prostaglandins. Aspirin also inhibits platelet aggregation and is used in the prevention of arterial and venous thrombosis. (From Martindale, The Extra Pharmacopoeia, 30th ed, p5). The prototypical analgesic used in the treatment of mild to moderate pain. It has anti-inflammatory and antipyretic properties and acts as an inhibitor of cyclooxygenase which results in the inhibition of the biosynthesis of prostaglandins. Aspirin also inhibits platelet aggregation and is used in the prevention of arterial and venous thrombosis. (From Martindale, The Extra Pharmacopoeia, 30th ed, p5) See also: Acetaminophen; Aspirin; Caffeine (component of); Aspirin; Omeprazole (component of); Aspirin; caffeine; orphenadrine citrate (component of)	Acronychnine is a yellow powder. (NTP, 1992) Acronychnine is an alkaloid antineoplastic agent isolated from <i>Acronychia baueri</i>. It has a role as a metabolite and an antineoplastic agent. It is an alkaloid and a member of acridone derivatives. Acronine is a small molecule drug. Acronine has a monoisotopic molecular weight of 321.14 Da. Acronine has been reported in <i>Sarcomelicope argyrophylla</i>, <i>Swinglea glutinosa</i>, and <i>Sarcomelicope simplicifolia</i> with data available. Acronine is a natural alkaloid with an acridine structure isolated from the bark of the plant <i>Acronychia baueri</i> (Australian scrub ash) with antineoplastic properties. Acronychnine appears to alkylate DNA and interfere with DNA replication. (NCI04) A pyrano-acridone alkaloid found in RUTACEAE plants.
知识重写	This molecule is acetylsalicylic acid, commonly known as aspirin, a prototypically non-steroidal anti-inflammatory drug and platelet aggregation inhibitor. Appearing as an odorless white crystalline powder, it exerts its analgesic, antipyretic, and anti-inflammatory effects by non-selectively inhibiting cyclooxygenase (COX-1 and COX-2) enzymes. It achieves this by acetylating serine residues within the enzyme, fundamentally decreasing prostaglandin production. Clinically, it is extensively used to manage pain and fever, and to prevent arterial and venous thrombosis such as strokes and myocardial infarctions, though it carries risks of liver toxicity at high doses and Reye syndrome in susceptible children. Structurally, it is a benzoic acid derivative where the phenolic hydroxyl group is replaced by an acetoxy group, featuring a single aromatic benzene ring and an ester linkage. With a low molecular weight of 180.16 g/mol and a compact framework of just 13 heavy atoms, it is a relatively small molecule, facilitating rapid systemic distribution. Its moderate lipophilicity, reflected by a LogP of 1.31, combined with a topological polar surface area (TPSA) of 63.6 Å², ensures excellent oral bioavailability and efficient cellular membrane permeability. These favorable pharmacokinetic traits are further supported by a balanced hydrogen bonding profile consisting of one hydrogen bond donor and three hydrogen bond acceptors. Additionally, the molecule possesses two rotatable bonds, providing just enough conformational flexibility to effectively bind and inhibit its target cyclooxygenase enzymes.	This molecule is acronychnine (also known as acronine), a natural pyrano-acridone alkaloid isolated from plants in the Rutaceae family, notably the bark of <i>Acronychia baueri</i>. Appearing as a yellow powder, it functions as an antineoplastic agent that alkylates DNA and interferes with DNA replication. Structurally, it is a highly rigid acridone derivative consisting of four fused rings—three of which are aromatic—alongside ether linkages and a complete absence of stereocenters. With a molecular weight of 321.38 g/mol and 24 heavy atoms, it is a moderately sized small molecule. Its highly lipophilic nature, reflected by a LogP of 3.88, alongside a relatively low topological polar surface area (TPSA) of 40.46 Å², suggests excellent cell membrane permeability, a crucial trait allowing it to efficiently traverse lipid bilayers to reach intracellular DNA targets. This conformational stability is further reinforced by having only a single rotatable bond. The molecule's interaction profile is strictly acceptor-based; it lacks hydrogen bond donors entirely but features four hydrogen bond acceptors. This specific hydrogen bonding arrangement, combined with its hydrophobic aromatic core, heavily influences its membrane transport kinetics and its mechanism of intercalating or alkylating DNA, ultimately facilitating its potent antineoplastic activity.

图 4-2 药物分子原始检索文本与重写文本的对比示例

4.2.2 下游数据集

为评估本文预训练模型在下游分子性质预测任务中的泛化能力和迁移能力，本文选取了 MoleculeNet^[33]数据集中 9 个具有代表性的数据集进行效果评估。MoleculeNet 由 Wu 等于 2018 年提出，通过提供统一的数据划分策略、评价指标及实验协议，解决了过往研究中因基准不一致导致模型性能难以横向比较的问题。本文选用的数据集涵盖了生物物理学、生理学及物理化学等多个领域，包含 6 个分类任务与 3 个回归任务。具体的数据集统计信息及划分方式如表 4-3 所示。

表 4-3 MolecuNet 基准组基本信息

数据集	任务类型	分子数	种类	评价指标	划分方式
BACE	分类	1513	生物物理学	AUC	骨架划分
BBBP	分类	2050	生理学	AUC	骨架划分
ClinTox	分类	1484	生理学	AUC	骨架划分
Tox21	分类	7831	生理学	AUC	骨架划分
ToxCast	分类	8597	生理学	AUC	骨架划分
Sider	分类	1427	生理学	AUC	骨架划分
FreeSolv	回归	642	物理化学	RMSE	骨架划分
ESOL	回归	1128	物理化学	RMSE	骨架划分
Lipo	回归	4200	物理化学	RMSE	骨架划分

BACE: 判断分子是否为 β -分泌酶 1 的抑制剂——BACE1 过度激活会导致大脑中异常淀粉样蛋白沉积，是阿尔茨海默病的关键致病因素，该任务用于筛选潜在的抗阿尔茨海默病药物。

BBBP: 判断分子能否穿透血脑屏障——血脑屏障是中枢神经系统的保护屏障，若开发治疗阿尔茨海默病、帕金森病等脑部疾病的药物，需分子具备穿透该屏障的能力。

ClinTox: 判断分子在临床实验阶段是否存在毒性，如肝毒性、心脏毒性——临床阶段是药物研发的关键环节，该任务可筛选出临床风险低的分子，降低研发失败率。

Tox21: 判断分子对 21 种毒性相关生物靶点的活——这些靶点与细胞毒性、遗传毒性等密切相关，该任务可全面评估分子的多维度毒性，是药物安全性评估的核心任务之一。

ToxCast: 判断分子是否具有致癌性、致突变性等长期毒性——长期毒性是药物上市前的重要评估指标，该任务可提前识别分子的潜在长期风险。

SIDER: 判断分子是否具有已知的副作用——SIDER 数据库收录了药物已报道的副作用信息，该任务可提前评估分子的安全性风险，避免后续临床实验中因严重副作用终止研发。

ESOL: 预测分子的水溶性——水溶性直接影响药物的口服吸收、生物利用度，水溶性过低的药物可能无法被人体有效吸收，该任务可指导优化分子结构以提升水溶性。

FreeSolv: 预测分子在水中的溶剂化自由能——溶剂化自由能反映分子与水的相互作用强度，与药物的溶解度、稳定性密切相关，该任务为分子的溶剂选择、剂型设计提供依

据。

Lipo: 预测分子的脂溶性——脂溶性影响药物的跨膜吸收、组织分布，脂溶性过高或过低都会影响药效，该任务可优化分子的脂溶性以平衡吸收与分布。

如图 4-3 所示，本文对 6 个分类数据集和 3 个回归数据集进行了可视化展示。分类任务通过柱状图展示已标注样本的正负类别分布，结果表明不同数据集的类别平衡性差异明显：BACE 和 Sider 相对均衡，而 Tox21、ClinTox、ToxCast 以及 BBBP 存在不同程度的类别不平衡。回归任务通过直方图和密度曲线展示标签值分布，结果显示 FreeSolv、ESOL 和 Lipo 在取值范围、集中区域及分布形态上均存在显著差异。对于多任务数据集，缺失标签仅表示该任务未标注，因此未作为独立类别参与可视化统计。




图 4-3 各数据集标签分布的可视化结果

4.2.3 实验设置

1. 实验环境

本文实验均在 Linux 操作系统上进行实验，各个类别的详细信息如图所示。

表 4-4 实验软硬件环境配置详情

类别	组件/库	版本/规格
系统	OS	Ubuntu 24.04.1 LTS
	CUDA	12.2
硬件	GPU	NVIDIA GeForce RTX 4090 (24GB)
	CPU	Intel Core i7-12700KF
	RAM	64G
软件	Python	3.10.19
	PyTorch	2.4.1+cu121
	Geometric	2.7.0
	RDKit	2025.9.3

2. 参数设置

预训练参数设置：优化器：采用 AdamW 优化器，以解耦权重衰减（Weight Decay）策略提升模型泛化性，权重衰减系数设为 1×10^{-4} 。学习率调度：采用带有线性预热的余弦退火策略。初始学习率设为 2×10^{-4} ，预热步数占总步数的 6%，随后逐渐衰减至 1×10^{-6} 。为了保证对比学习中负样本的数量充足，将批次大小设为 256。模型共训练 100 个 Epoch，并在验证集 loss 不再下降时实施早停。对比损失参数：基于参数敏感性实验结果，NT-Xent 损失函数中的温度系数 τ 固定为 0.1。自适应加权损失中的可学习噪声参数 σ_m 初始化为 1.0，并随训练过程自动更新。模型架构参数：Graphormer 编码器包含 6 层 Transformer 层，隐藏层维度设为 256，多头注意力头数设为 8。

微调参数设置：在下游任务阶段，将预训练好的 KGAMA 编码器迁移至 MoleculeNet 的 9 个基准数据集上。为了适应不同规模的数据集，微调策略进行了如下调整：为了保留预训练特征的先验知识，微调阶段采用较小的学习率，设定为 5×10^{-5} 。批次大小设为 32，以适应小样本数据的梯度更新频率。在预测头中引入 Dropout 层，丢弃率设为 0.1，以防止在小数据集上过拟合。训练周期为 100 个 Epoch，同样配合早停机制，Patience 参数设置为 5。

4.2.4 评价指标

本研究根据具体任务特性的不同，实施了差异化的效能评测策略。针对分类问题，模

型对类别的区分效能主要依赖受试者工作特征曲线下面积（AUROC）进行考量。AUROC能够量化模型在真假阳性率权衡过程中的表现，其得分位于 0.5 到 1 的闭区间内，分数越高象征着模型拥有更优异的判别力。而在回归分析中，核心关注点转向均方根误差（RMSE），该指标用于刻画预测精度。通过对预测值与实测值之差进行平方、取均值后再开方，RMSE实现了对误差的标准化度量，具体公式如(4-2)所示；由于其单位与目标变量保持一致，较小的 RMSE 值直接映射出模型预测结果与真实数据之间极高的匹配吻合度。

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4-2)$$

4.2.5 损失函数

在将分子的多模态特征映射到同一的向量空间之后，模型的核心任务是通过对比学习来实现跨模态的语义对齐。本文设计了一种改进的以图为中心的双向 NT-Xent 对比损失，并引入基于同方差不确定性的自适应加权机制，以实现多任务场景下的稳健优化。

对比学习通过在表征空间中拉近正样本对、推远负样本对来学习具有判别性的特征表示。目前最主流的目标函数是归一化温度缩放交叉熵损失（Normalized Temperature-scaled Cross Entropy Loss, NT-Xent）。对于给定的样本对(i, j)，其标准的 NT-Xent 损失定义如下：

$$l_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j) / \tau)}{\sum_{k=1}^{2B} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k) / \tau)} \quad (4-3)$$

其中， z_i, z_j 为归一化后的特征向量，sim 表示余弦相似度， τ 为温度系数， B 为批次大小，分母项包含了批次内所有的负样本。然而，经典的 NT-Xent 通常基于双视图设定，如 CLIP 中的图像 - 文本。当扩展至本文的四模态场景（Graph, SMILES, Fingerprint, Text）时，若采用全排列的两两对齐策略，将面临计算开销随模态数量呈平方级增长，噪声传播与训练不稳定性等问题。在分子表征学习中，分子图直接刻画了原子间的连接拓扑，被认为是最具“物理真实性”和“结构稳定性”的主模态；相比之下，SMILES 序列、分子指纹及文本描述均可视为该核心结构的辅助视图。

基于此，本文采用 Graph-centered 对齐范式：仅计算分子图与其辅模态间的对齐损失，而不进行辅模态间的冗余对齐。设第*i*个分子样本在模态 $m \in \{S, F, T\}$ 下的表示为 $z_i^{(m)}$ ，Graph 模态表示为 $z_i^{(G)}$ 。为了确保对齐的对称性，本文定义双向对比损失 $L_{G,m}$ 为：

$$L_{G,m} = \frac{1}{2}(L_{G \rightarrow m} + L_{m \rightarrow G}) \quad (4-4)$$

其中，从 Graph 到模态 m 的单向对比损失定义为：

$$L_{G \rightarrow m} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{sim}(z_i^{(G)}, z_i^{(m)}) / \tau)}{\sum_{k=1}^B \exp(\text{sim}(z_i^{(G)}, z_k^{(m)}) / \tau)} \quad (4-5)$$

在联合优化三个对齐任务 ($G \leftrightarrow S$, $G \leftrightarrow F$, $G \leftrightarrow T$) 时，由于各模态的信息熵与噪声水平存在显著差异，采用静态等权重加权（如 1:1:1）往往难以达到最优收敛状态。特别是文本描述模态，由于 LLM 生成的自然语言具有更强的语义抽象性，其损失函数的量级与梯度方向可能与其他模态产生剧烈冲突。为此，本文借鉴同方差不确定性理论，通过为每个对齐任务引入可学习的噪声参数 σ_m ，构建自适应加权损失函数：

$$L_{total} = \sum_{m \in \{S, F, T\}} \left(\frac{1}{2\sigma_m^2} L_{G,m} + \log \sigma_m \right) \quad (4-6)$$

其中， $\frac{1}{2\sigma_m^2}$ 为动态权重，当某一模态对齐任务表现出较高的不确定性或存在较大噪声

时，模型会自动增大 σ_m 以降低该任务对总梯度的贡献。

正则化约束： $\log \sigma_m$ 项作为正则化因子，防止 σ_m 无限增大导致权重坍塌，使模型在降低噪声影响与维持任务增益之间寻找一个平衡。

通过这种方式，模型能够在预训练过程中自主识别各模态的可靠性，优先学习确定性较强的结构关联，例如图模态和 SMILES 模态，并平滑处理复杂语义对齐，例如图模态和文本模态，从而显著提升了多模态表征的稳健性与收敛效率。

4.2.6 对比模型

Mol2Vec^[34]：受 NLP 中的 Word2Vec 启发，该方法将分子结构拆分为若干子结构并将其视为词语。通过在大量分子数据上运行 Skip-gram 算法进行无监督训练，学习子结构的向量表示，最终通过聚合这些向量获得分子的整体表示。

N-Gram^[35]：一种基于分子拓扑特征的方法，将分子表示为由连续 N 个化学键组成的路径集合。它不需要预先定义复杂的化学特征，具有良好的通用性和灵活性，能够从结构角度有效刻画分子的局部环境。

GIN^[36]: 一种极具表达能力的图深度学习模型。其理论基础在于能够达到 Weisfeiler-Lehman 图同构测试的辨别能力上限, 通过对节点及其邻居特征的强有力聚合, 有效区分不同的分子图结构。

AttentiveFP^[30]: 是一种引入注意力机制的图神经网络模型。该方法通过注意力权重动态调整邻居节点在信息聚合过程中的重要性, 使模型能够自动关注对分子性质预测更为关键的原子和化学键, 从而提升模型的表达能力和预测性能。

MPNN^[37]: 一种通用的框架, 核心在于将化学键（边）的信息纳入节点表示学习的过程中, 通过多轮信息传递更新原子特征。

DMPNN^[38]: MPNN 的改进版本。它采用了定向信息传递机制, 防止信息在传递过程中出现“回流”现象。同时结合了动态池化机制, 根据具体任务自适应地聚合关键特征。

CMPNN^[39]: 这是对传统消息传递神经网络 MPNN 的重要改进。它通过在原子和化学键之间引入显式的“通信”机制, 增强了模型对局部和全局信息的捕捉能力。

GROVER^[40]: 目前的先进模型之一。它结合了图卷积网络和 Transformer 的自注意力机制, 能够同时提取分子的结构特征和属性特征。通过大规模梯度累积策略和精心设计的自监督任务, 在大规模数据集上展现了极强的特征提取能力。

SchNet^[41]: 专门面向量子化学建模的深度学习方法。不同于传统的二维图模型, SchNet 重点建模原子的三维空间位置。它通过连续滤波卷积作用于原子间的欧几里得距离, 从而模拟分子的电子结构和量子动力学相互作用, 无需人工设计特征即可自动学习分子的电子特性。

GraphMVP^[42]: 一种先进的图自监督学习模型, 旨在通过对分子的 2D 拓扑图和 3D 几何构象进行多视图对齐来学习表征。它通过对比学习拉近同一分子的二维和三维表示, 使模型具备对分子空间构象的感知能力。

MoleculeSTM^[43]: 这是一种基于语言模型的多模态分子预训练框架。它利用化学文本描述与分子结构之间的配对关系进行预训练, 旨在将分子的化学结构映射至与其语义功能一致的向量空间。

MoMu^[44]: 该模型专注于跨模态的图-文本对齐学习。它通过构建大规模的分子图与对应的化学描述文本对, 利用对比学习目标函数使模型能够同时从视觉（图结构）和语义（文本）两个维度理解分子性质。

KV-PLM^[45]: 一种知识增强的预训练语言模型。它尝试在预训练过程中显式注入分子

的理化性质知识或专家规则，以缩短分子的结构信息与下游性质预测任务之间的语义鸿沟。

4.3 实验及结果分析

4.3.1 对比实验

针对 MoleculeNet 涵盖的 9 个分子性质预测基准数据集，本研究开展了多维度的系统性评估。在数据处理层面，全部遵循 MoleculeNet 推荐的标准化协议，即采用骨架分割策略，将样本集按 8:1:1 的比例严格划分为训练集、验证集与测试集，以评估模型在非同源分子结构上的泛化能力。为消除随机性干扰，所有实验均在不同随机种子下重复进行多轮，最终得到各项指标的均值及其标准差。最终结果如表 4-5 所示。

表 4-5 KGAMA 在 MoleculeNet 分类任务上对比实验结果

Datasets	BACE	BBBP	ClinTox	Tox21	ToxCast	SIDER
#Molecules	1513	2039	1478	7831	8575	1472
#Tasks	1	1	2	12	617	27
AttentiveFP	0.863 _(0.150)	0.908 _(0.050)	0.933 _(0.020)	0.807 _(0.021)	0.637 _(0.103)	0.605 _(0.061)
Mol2Vec	0.802 _(0.008)	0.826 _(0.027)	0.750 _(0.127)	0.754 _(0.101)	0.614 _(0.031)	0.592 _(0.003)
GROVER	0.810 _(0.044)	0.695 _(0.185)	0.762 _(0.013)	0.735 _(0.027)	0.653 _(0.005)	0.614 _(0.017)
GraphMVP	0.812 _(0.009)	0.724 _(0.016)	0.791 _(0.028)	0.759 _(0.005)	0.631 _(0.114)	0.639 _(0.012)
MPNN	0.815 _(0.043)	0.913 _(0.042)	0.879 _(0.054)	0.808 _(0.024)	0.691 _(0.018)	0.595 _(0.031)
DMPNN	0.823 _(0.038)	0.919 _(0.048)	0.897 _(0.041)	0.759 _(0.034)	0.655 _(0.101)	0.570 _(0.031)
CMPNN	<u>0.869_(0.002)</u>	<u>0.927_(0.002)</u>	0.901 _(0.012)	<u>0.837_(0.016)</u>	<u>0.709_(0.002)</u>	0.617 _(0.003)
GIN	0.845 _(0.021)	0.894 _(0.019)	0.869 _(0.034)	0.811 _(0.002)	0.703 _(0.004)	0.591 _(0.016)
SchNet	0.751 _(0.033)	0.847 _(0.025)	0.717 _(0.041)	0.767 _(0.023)	0.679 _(0.021)	0.545 _(0.038)
N-Gram	0.779 _(0.031)	0.912 _(0.004)	0.855 _(0.013)	0.761 _(0.130)	0.659 _(0.133)	<u>0.662_(0.009)</u>
MoleculeSTM	0.808 _(0.002)	0.712 _(0.019)	<u>0.925_(0.011)</u>	0.769 _(0.005)	0.651 _(0.014)	0.610 _(0.008)
MoMu	0.767 _(0.014)	0.705 _(0.020)	0.799 _(0.041)	0.756 _(0.003)	0.634 _(0.011)	0.605 _(0.009)
KV-PLM	0.785 _(0.027)	0.731 _(0.054)	0.892 _(0.073)	0.725 _(0.102)	0.550 _(0.065)	0.598 _(0.056)
KGAMA	0.872_(0.006)	0.930_(0.002)	0.939_(0.012)	0.841_(0.005)	0.712_(0.011)	0.669_(0.004)

在 BACE 与 BBBP 数据集上，KGAMA 模型显著超越了经典的图神经网络模型 GIN、AttentiveFP，其中在 BACE 数据集上分别提高了 3.2 和 1.04 个百分点，在 BBBP 数据集上分别提高了 4.03 和 2.42 个百分点。相比于次优的 CMPNN 模型来说，KGAMA 在这两个数据集上均提高了 0.3 个百分点。这种优势主要是 KGAMA 使用了 Graphormer 编码器，其

能够对分子全局的拓扑结构进行捕捉，相比于传统的图神经网络能够捕捉更加远程的原子依赖关系。在 ClinTox 与 SIDER 等涉及复杂药理毒理机制的数据集上，KGAMA 模型相比与 MoleculeSTM 这种采用文本对齐的模型来说，KGAMA 也展现了较为显著的优势，性能分别提高了 1.4 和 5.9 个百分点。这个结果证明了本研究设计的知识重写模块的有效性。这也说明了在构建分子文本语义表征时，使用高密度、去噪声的高质量文本，是提升下游预测任务性能的重要条件之一。在 Tox21 与 ToxCast 这种包含了数百个子任务的数据集上，KGAMA 依然可以保持一定的性能优势，相较于次优模型，最终在结果上分别提高了 0.03 和 0.04 个百分点。这一结果验证了本框架引入的基于同方差不确定性的自适应加权机制，能够有效平衡不同任务与模态间的噪声，确保了模型在极端复杂场景下的泛化上限。

表 4-6 KGAMA 在 MoleculeNet 回归任务上对比实验结果

Datasets	ESOL	FreeSolv	Lipo
# Molecules	1128	642	4200
# Tasks	1	1	1
AttentiveFP	0.877 _(0.060)	2.073 _(0.220)	0.721 _(0.030)
Mol2Vec	0.995 _(0.032)	2.021 _(0.154)	0.803 _(0.021)
GROVER	0.921 _(0.087)	2.026 _(0.127)	0.676 _(0.022)
GraphMVP	1.029 _(0.033)	1.893 _(0.063)	0.681 _(0.002)
MPNN	1.167 _(0.430)	2.185 _(0.952)	0.672 _(0.051)
DMPNN	0.972 _(0.097)	2.170 _(0.536)	0.662 _(0.051)
CMPNN	<u>0.845_(0.039)</u>	1.833 _(0.581)	<u>0.658_(0.029)</u>
GIN	0.885 _(0.051)	<u>1.619_(0.202)</u>	0.659 _(0.085)
SchNet	1.045 _(0.064)	3.215 _(0.355)	0.909 _(0.098)
N-Gram	1.074 _(0.112)	2.688 _(0.251)	0.812 _(0.031)
MoleculeSTM	-	-	-
MoMu	-	-	-
KV-PLM	1.124 _(0.251)	2.124 _(0.429)	0.902 _(0.047)
KGAMA	0.831_(0.024)	1.512_(0.233)	0.655_(0.006)

表 4-6 进一步展示了模型在 ESOL、FreeSolv 和 Lipo 三个回归任务上的均方根误差表现，即 RMSE 数值越低越好。在水溶性预测任务 ESOL 中，KGAMA 取得了 0.831 的极低误差，显著优于 CMPNN 的 0.845 与 AttentiveFP 的 0.877。这表明模型不仅在离散的分类空间中表现优异，在连续的物理化学性质空间中同样具备精准的回归能力。特别是在

FreeSolv 溶剂化自由能任务上，模型将 RMSE 降至 1.512，相比于次优的基线模型 GIN 的 1.619 提升了近 6%，充分体现了多模态特征融合在刻画分子能量状态方面的优势。值得注意的是，在 Lipo 亲脂性数据集上，KGAMA 达到了 0.655 的 SOTA 水平。结合可视化分析可知，这一优异表现很大程度上源于分子指纹模态的引入。分子的亲脂性与分子中的特定官能团数量呈线性相关，而基于统计计数的指纹特征正好能比较精确捕捉此类信息。

综上所述，无论是面向离散的生物活性分类，还是连续的理化性质回归，KGAMA 均凭借其图中心对比学习+多模态知识增强的复合架构，展现出了优异的综合性能。

4.3.2 消融实验

为系统解构不同输入模态及融合机制对模型最终预测能力的边际贡献，本文基于所提出的 KGAMA 框架，构建了五种递进式的消融变体。所有变体均在统一的实验配置下进行训练与评测，旨在定量分析各模态信息的有效性及交叉注意力模块的核心价值。

本文以分子图作为核心语义锚点，逐步引入其他辅助模态，具体变体定义如下：

w/o ALL：基准模型，仅保留图编码器分支，采用 Graphormer 提取分子拓扑特征，作为下游任务的单一输入源，用于评估纯结构视角的预测基线。

w/o STC：结构增强。在图编码器的基础上引入分子指纹模态，旨在补充图神经网络可能遗漏的全局子结构统计信息。

w/o TC：序列增强，进一步融合 SMILES 序列模态，利用 Transformer 捕获分子的线性化学语法与长程依赖。

w/o C：静态融合，采用完整的四模态输入，但通过简单的特征拼接方式进行融合，用于评估多模态信息的原始叠加效应。

KGAMA：完整模型，本文提出的最终形态，即在四模态基础上引入交叉注意力机制，实现特征的动态自适应融合。

表 4-7 KGAMA 在 MoleculeNet 基准组上分类任务消融实验结果

Datasets	BACE	BBBP	ClinTox	Tox21	ToxCast	SIDER
w/o All	0.825 _(0.150)	0.898 _(0.050)	0.805 _(0.020)	0.771 _(0.021)	0.695 _(0.103)	0.638 _(0.061)
w/o STC	0.842 _(0.008)	0.912 _(0.027)	0.845 _(0.127)	0.795 _(0.101)	0.701 _(0.031)	0.645 _(0.003)
w/o TC	0.855 _(0.044)	0.915 _(0.185)	0.885 _(0.013)	0.822 _(0.027)	0.706 _(0.005)	0.655 _(0.017)
w/o C	0.862 _(0.009)	0.922 _(0.016)	0.915 _(0.028)	0.835 _(0.005)	0.709 _(0.114)	0.661 _(0.012)
KGAMA	0.870 _(0.043)	0.930 _(0.042)	0.939 _(0.054)	0.841 _(0.024)	0.712 _(0.018)	0.669 _(0.031)




图 4-4 KGAMA 在 MoleculeNet 基准组上分类任务消融实验结果

五种变体模型在 MoleculeNet 六个分类数据集的消融实验结果如表 4-5、图 4-4 所示，从整体来看，KGAMA 模型在六个数据集上均取得了最优的成绩，这一结果表明了本文提出的各个模块均能够对模型的性能产生积极的作用，且多模态数据的多视角互补使得模型可以在预测任务中取得较好的成绩。进一步来看，随着各个单模块的加入，性能逐步的递增，但是各个模块的贡献程度也存在差异。其中，w/o STC 变体由于加入了分子指纹，相比于 w/o ALL 变体性能得到了显著的提升。其中在 ClinTox 任务上 AUROC 从 0.805 大幅提升至 0.845。w/o C 是各消融变体模型中最接近完整模型的配置，但在六个数据集上仍全部落后于 KGAMA，例如在 ClinTox 上从 0.915 提升到 0.939，在 BBBP 上从 0.922 提升到 0.930，在 SIDER 上从 0.661 提升到 0.669。这进一步说明，即使某些模块单独移除后性能下降相对有限，但其与其他模块联合时仍能带来稳定增益。

表 4-8 KGAMA 在 MoleculeNet 基准组上回归任务消融实验结果

Datasets	ESOL	FreeSolv	Lipo
w/o All	2.102 _(0.060)	1.521 _(0.220)	1.244 _(0.030)
w/o STC	1.855 _(0.032)	1.476 _(0.154)	0.966 _(0.021)
w/o TC	1.805 _(0.087)	1.226 _(0.127)	0.853 _(0.022)
w/o C	1.725 _(0.033)	1.001 _(0.063)	0.789 _(0.002)
KGAMA	1.512_(0.024)	0.831_(0.233)	0.656_(0.006)




图 4-5 KGAMA 在 MoleculeNet 基准组上回归任务消融实验结果

为了验证在回归数据集上 KGAMA 的有效性,本文也在 MoleculeNet 基准组上的 ESOL、FreeSolv 和 Lipophilicity 三个数据集上进行了消融实验。实验结果如表 4-6 和图 4-5 所示。从整体来看,KGAMA 在三个数据集上均取得了最低的 RMSE,分别为 1.512、0.831 和 0.656,高于所有的消融变体模型。随着模块的逐步加入,模型的性能也是逐步的提高,当全部模块被移除的时候,性能最差,如在 ESOL 数据集上 w/o All 的 RMSE 是 2.102,相比完整模型的 1.512 高出 0.590。w/o STC 相较于完整模型仍存在较明显差距,在 ESOL、FreeSolv 和 Lipo 三个数据集上的 RMSE 分别为 1.855、1.476 和 0.966。这说明移除该模块后,模型对分子性质的连续值建模能力受到明显影响。相比之下, w/o TC 的结果有所改善, RMSE 分别下降到 1.805、1.226 和 0.853,表明该部分模块的引入在特征表征与信息交互中发挥了重要作用。

对比引入完整四模态输入但采用静态拼接的 w/o C 与本文提出的完整模型 KGAMA,可以清晰观察到交叉注意力机制的决定性作用。在 FreeSolv 任务上,KGAMA 的 RMSE 从 1.725 进一步降低至 1.512。上述差距说明简单的特征拼接方法本质上默认分子各模态数据对所有任务具有同等重要性,无法有效处理多模态间的语义冲突与信息冗余。相比之下,交叉注意力机制能够根据具体预测任务的性质动态调配模态贡献权重,在 ClinTox 任务中,该任务对专家文本知识高度依赖,完整模型能够自适应地识别这一特性并给予文本模态更大的权重,从而提取隐含在文本信息中的毒理学因果关联,实现多模态信息的深度协同而非简单叠加。

进一步地,本研究绘制了九个数据集的预测值和实验值之间的相关性散点图,如图 4-6 所示,可以清楚的看到 KGAMA 的回归曲线结果比其变体更加接近标准灰色基线,进一步

证明了我们架构中各个模块的重要性。




图 4-6 KGAMA 及其变体散点结果

4.3.3 可视化分析

为了进一步解释不同模态对特定分子性质预测任务的贡献，本文分析了 KGAMA 模型学习的注意力权重矩阵，如图 4-7 图 4-7 所示。图中横轴代表不同的分子性质预测任务，纵轴代表四种输入模态，颜色的深浅直观反映了该模态在特定任务中的重要性贡献度，即权重值越大，颜色越深。根据权重图可以得出在物理性质任务中的结构模态起主导效应，具体的说在预测分子的物理化学性质时，模型表现出对拓扑结构的高度依赖。在 FreeSolv 和 ESOL 任务中，Graph 模态的权重分别高达 0.40 和 0.39，显著高于其他模态。这与化学

直觉高度一致。分子的溶解能力和能量状态主要由其分子骨架的拓扑连接及原子间的空间排布决定。本文所使用的 Graphormer 图神经网络提取的显式结构特征在此类任务中提供了核心的判别依据，起到了语义锚点的作用。值得注意的是，在 Lipo 任务中，Fingerprint 获得了最高的权重 0.38，甚至超过了 Graph。这是因为亲脂性与分子中特定的疏水/亲水官能团数量呈强线性相关，而基于统计计数的分子指纹恰好擅长捕获此类特征。

另一方面权重图中也体现了知识增强在生物药理任务中的突破，与物理任务形成鲜明对比的是，在涉及复杂生物相互作用的任務中，模型自动学会了依赖专家知识。在 Sider、ClinTox 和 Tox21 任务中，文本模态的权重出现了显著跃升，分别为 0.38、0.36 和 0.32。这是因为副作用和毒性往往难以仅从分子结构中直接推断，但通常在文献或专家描述中有明确的记录。此时，经过 LLM 重写并注入了 11 项理化性质的文本模态成为了关键的信息源。模型给予文本模态高权重，证明了本研究提出的知识增强策略成功地将非结构化的药理知识转化为了可被模型利用的特征，弥补了单结构视角的盲区。

最后模态权重图体现了序列模态的稳健补充作用，SMILES 模态在所有 9 个任务中的权重分布呈现出高度的稳定性，维持在 0.18-0.24 的区间内。作为分子的线性化表征，SMILES 虽然在某些特定任务上不如 Graph 直观或 Text 深刻，但它提供了一种独特的序列视角，能够捕获图网络可能遗漏的长程依赖信息。这种平稳输出的特性使其成为了多模态融合中的稳定器，确保模型在任何任务中都不会因单一模态的缺失或噪声而失效。




图 4-7 不同分子模态在各下游任务中的注意力权重分布

4.3.4 参数敏感实验

为了验证模型在不同超参数设置下的鲁棒性，并探究核心的超参数对对比学习性能的影响，本小节选取了对比损失函数中的温度系数 τ 进行敏感性实验。实验在 ClinTox 和 BBBP

两个代表性数据集上进行，其他训练参数保持不变。温度系数 τ 在 NT-Xent 损失函数中起着调节负样本梯度的关键作用。图 4-8 展示了模型性能随 τ 值的变化曲线，图中展示了五种不同的温度系数，分别是 0.05、0.1、0.2、0.5、1.0。从图中可以观察到明显的“倒 U 型”趋势，具体分析如下：过小的 $\tau(0.05)$ ：当温度系数过小时，Softmax 分布变得极度尖锐，模型过度关注少量极其困难的负样本。这虽然能提供强梯度的监督信号，但容易引入潜在的假阴性样本噪声，导致优化过程不稳定，模型性能出现显著下降（ClinToxAUROC 降至 0.89 左右）。过大的 $\tau(0.5-1.0)$ ：随着温度系数增大，分布趋于平滑，模型对不同负样本的区分能力减弱。当 $\tau = 1.0$ 时，模型实际上是在同等程度地惩罚所有非匹配样本，失去了挖掘难样本的能力，导致特征空间的判别性降低，性能随之衰减。最优区间(0.1-0.2)：实验结果表明，当 τ 设定在 0.1 至 0.2 之间时，模型取得了最佳的预测性能。在此区间内，模型在挖掘难样本与保持训练稳定性之间达到了平衡，能够学习到既具有区分度又具备泛化能力的分子表征。因此，本研究在所有后续实验中均将 τ 默认设置为 0.1。




图 4-8 温度系数 τ 对模型预测性能的影响

4.4 本章小结

本章系统阐述了一种基于图对齐与知识增强的多模态分子性质预测框架。针对现有方法在异构数据融合及语义鸿沟跨越方面的局限性，本章首先构建了包含图、序列、指纹及文本的四维模态表征体系。特别是在文本模态处理上，创新性地设计了“知识重写流水线”，

利用大语言模型将非结构化的药理描述与定量的理化性质有机融合，为模型注入了高密度的专家先验知识。在模型训练层面，提出了以分子图为核心的对比学习预训练策略，并引入基于同方差不确定性的动态加权机制，有效解决了多任务场景下的模态噪声干扰与梯度冲突问题。

为了全面验证所提方法的有效性，本章在 MoleculeNet 的 9 个基准数据集上开展了多维度的实证研究。对比实验结果表明，该模型在 BACE、ClinTox 等分类任务及 FreeSolv 等回归任务上均取得了优于当前主流基准（如 CMPNN、MoleculeSTM）的预测性能。随后的消融实验定量解析了各输入模态的边际贡献，证实了交叉注意力机制在特征融合阶段优于简单拼接策略。最后，参数敏感性分析验证了模型核心超参数的鲁棒性。

综上所述，本章提出的方法不仅在预测精度上刷新了多项记录，更在模型的可解释性与泛化能力上取得了显著突破，为后续的药物分子筛选与优化提供了可靠的计算工具。

5 总结与展望

5.1 工作总结

分子性质预测旨在建立分子结构到理化属性再到生物活性的高维映射关系，是现代药物发现中跨越庞大化学空间、实现高效虚拟筛选的核心技术瓶颈。近年来，基于深度学习的分子表征技术虽显著加速了性质预测的进程，但由于分子性质是复杂量子物理与宏观药理规律的综合体现，现有预测模型仍面临严重的理论与性能瓶颈：一方面，单一模态难以全面捕捉分子的多尺度立体特征，且传统图神经网络受限于局部聚合机制，存在严重的“信息回流”与长程拓扑依赖捕捉困难；另一方面，纯数据驱动的预测模型高度依赖统计相关性，在面对复杂的 ADMET 评估时往往陷入缺乏药理学依据的黑盒状态。此外，尽管多模态融合被认为是完善分子表征的有效途径，但现有的预测框架严重受制于医学数据库文本噪声大、描述稀疏以及缺乏定量指标约束的痛点，在进行多源异构数据联合优化时极易引发模态间的梯度冲突与负迁移。

第一，针对大模型预测的黑盒问题与图网络拓扑感知的局限，提出了一种基于思维链增强与通信式图交互的分子性质预测框架（CoT-CMP）。

本工作在文本特征提取端引入了 LLaMA-3.1 大语言模型，结合低秩自适应（LoRA）微调与思维链（CoT）技术，摒弃了传统的端到端直接映射。通过精心设计的提示词工程，引导模型自发生成包含“理化属性分析—靶点结合评估—宏观性质推导”的显式逻辑推理文本，将隐式的决策过程外化为人类可读的药理分析，赋予了模型高度的可解释性。在图结构端，本工作采用了交互式图神经网络（CMPNN），构建了原子与化学键的“通信核”，强制实现深度的动态交互，从根本上克服了传统无向图信息回流的弊端，精准捕获了分子的立体电子效应。最后，通过交叉注意力机制，以分子结构拓扑为查询锚点，动态检索并自适应融合文本推理空间中的关键药理逻辑。在 TDC 平台的多个 ADMET 基准数据集上的实验表明，该框架在多项分类与回归任务上均显著超越了主流基线模型，有效的增强了模型决策过程的可解释性表达能力

第二，针对公共医学文本噪声冗余及多模态对齐中的梯度冲突问题，提出了一种基于知识增强与图对齐的分子性质预测框架（KGAMA）。

本工作突破了双模态的局限，构建了包含分子图、SMILES 序列、分子指纹及自然语言的四维全景表征体系。在数据层面，创新性地设计了知识重写流水线，利用大语言模型

剔除原始 PubChem 文本中的无用噪声与冗余轶事，并显式注入由 RDKit 计算的 11 项关键物理化学指标，极大提升了文本模态的知识密度与定量约束力。在预训练模型对齐层面，本工作摒弃了计算复杂度高且易导致负迁移的全排列对齐策略，确立了以分子图为核心的语义锚点，并引入了基于同方差不确定性的自适应加权机制。该机制使模型能够自动识别并平衡各模态的噪声水平，实现了跨模态特征在统一高维语义空间中的稳健对齐。在 MoleculeNet 的 9 个基准数据集上的系统评估表明，该框架不仅在预测精度上取得了卓越表现，更通过消融实验与注意力权重热图，深刻揭示了“图中心对比学习+多模态知识增强”在刻画复杂分子构效关系中的核心机理与巨大潜力。

5.2 工作展望

本文在基于多模态学习、思维链推理与知识增强的分子性质预测方面取得了显著的阶段性成果，有效增强了模型决策过程的可解释性表达能力与多模态数据进行对齐的梯度冲突，但受限于目前的计算资源及现有数据维度的瓶颈，本研究仍存在一定的局限性。为了进一步推动人工智能驱动的药物发现走向成熟，未来的研究工作可以从以下几个关键维度进行深入探索与拓展：

1. 引入三维几何构象与等变神经网络

本文当前的分子图表征与特征融合主要依赖于分子的二维拓扑结构与一维序列。然而，在真实的物理化学环境与人体生理环境中，分子的宏观理化性质及微观生物活性高度依赖其三维空间构象与立体异构性。未来的研究可考虑引入分子的三维坐标、键角、二面角等深层几何信息，并结合 SE(3)等变图神经网络或 3DGraphormer 架构。通过构建涵盖“1D 序列-2D 拓扑-3D 构象-自然语言”的全维度表征体系，有望进一步突破模型在分子性质预测任务上的性能瓶颈。

2. 构建亿级规模的分子多模态基础模型

本文在 KGAMA 框架中构建了约 22 万量级的高质量多模态预训练数据集，虽然充分验证了“大语言模型知识重写”与“图中心对比学习”的有效性，但相较于真实世界中数以百亿计的潜在成药空间，当前的数据规模仍显单薄。未来的工作可借助更强大的分布式算力集群，将预训练多模态语料库的规模扩展至千万甚至亿级别。同时，随着多模态大模型底座的不断进化，未来可探索将图编码器与大语言模型进行底层参数级别的深度融合，打造具有零样本泛化能力的分子科学通用基础模型，以应对更加极端的小样本罕见病药物研发场景。

参考文献

- [1] Panapitiya, G., Gao, P., Maupin, C.M., et al. FragNet: A Graph Neural Network for Molecular Property Prediction with Four Levels of Interpretability[J]. *Journal of the American Chemical Society*, 2026, 148(9): 9930-9950.
- [2] Petersen, K.H., Schmidt, M.N. Design and Evaluation of a Geometric Algebra-Based Graph Neural Network for Molecular Property Prediction[A]. *Proceedings of the 7th Northern Lights Deep Learning Conference (NLDL)*[C]. PMLR, 2026: 328-344.
- [3] Zhou, R., Zhang, Y., He, K., et al. Add-GNN: A Dual-Representation Fusion Molecular Property Prediction Based on Graph Neural Networks with Additive Attention[J]. *Symmetry, Multidisciplinary Digital Publishing Institute*, 2025, 17(6).
- [4] Ma, H., Bian, Y., Rong, Y., et al. Cross-dependent graph neural networks for molecular property prediction[J]. *Bioinformatics*, 2022, 38: 2003-2009.
- [5] Li, L., Zhang, Y., Wang, G., et al. Kolmogorov–Arnold graph neural networks for molecular property prediction[J]. *Nature Machine Intelligence*, Nature Publishing Group, 2025, 7(8): 1346-1354.
- [6] Wang, S., Guo, Y., Wang, Y., et al. SMILES-BERT: Large Scale Unsupervised Pre-Training for Molecular Property Prediction[A]. *Proceedings of the 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics*[C]. New York, NY, USA: Association for Computing Machinery, 2019: 429-436.
- [7] Abdel-Aty, H., Gould, I.R. Large-Scale Distributed Training of Transformers for Chemical Fingerprinting[J]. *Journal of Chemical Information and Modeling*, American Chemical Society, 2022, 62(20): 4852-4862.
- [8] Tang, W., Li, M., Zhan, Y., et al. Adaptively multi-modal contrastive fusion network for molecular properties prediction[J]. *Engineering Applications of Artificial Intelligence*, 2025, 152: 110782.
- [9] Gao, M., Zhu, F. MMCL: A Multi-modal Contrastive Learning Framework for Molecular Property Prediction[J]. *IEEE Transactions on Computational Biology and Bioinformatics*, 2026: 1-14.
- [10] Zhang, Y., Liu, W., Zhao, H., et al. MolGramTreeNet: A multimodal molecular property prediction model via grammar tree-constrained molecular representation[J]. *iScience*, 2026, 29(3): 114928.
- [11] Zhou, J., Zhao, Q., Shu, P., et al. GSST: Multimodal Graph-SMILES Fusion with Soft SMILES Tokens for Molecular Property Prediction[J]. *IEEE Journal of Biomedical and Health Informatics*, 2025: 1-12.

- [12] Rollins, Z.A., Cheng, A.C., Metwally, E. MolPROP: Molecular Property prediction with multimodal language and graph fusion[J]. *Journal of Cheminformatics*, 2024, 16(1): 56.
- [13] Gong, X., Liu, M., Liu, Q., et al. MDFCL: Multimodal data fusion-based graph contrastive learning framework for molecular property prediction[J]. *Pattern Recognition*, 2025, 163: 111463.
- [14] Liu, S., Nie, W., Wang, C., et al. Multi-modal molecule structure–text model for text-based retrieval and editing[J]. *Nature Machine Intelligence*, Nature Publishing Group, 2023, 5(12): 1447-1457.
- [15] Zhu, Y., Liu, G., Inae, E., et al. MolTextNet: A Two-Million Molecule-Text Dataset for Multimodal Molecular Learning[J].2025.
- [16] Wang, Y., Zhang, K., Huang, J., et al. ProtoMol: enhancing molecular property prediction via prototype-guided multimodal learning[J]. *Briefings in Bioinformatics*, 2025, 26(6): bbaf629.
- [17] TRIDENT: Tri-Modal Molecular Representation Learning with Taxonomic Annotations and Local Correspondence[A].2025.
- [18] Li, Y., Liu, C., Gao, X., et al. MolPrompt: improving multi-modal molecular pre-training with knowledge prompts[J]. *Bioinformatics*, 2025, 41(9): btaf466.
- [19] Liu, S., Wang, H., Liu, W., et al. Pre-training Molecular Graph Representation with 3D Geometry[A].2021.
- [20] Zhou, G., Gao, Z., Ding, Q., et al. Uni-Mol: A Universal 3D Molecular Representation Learning Framework[A].2022.
- [21] Sun, M., Ai, C., Zhang, D., et al. MolInterAct: Multiscale Cross-Modal Interaction for Robust Molecular Representation Learning[A]. 2025 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)[C]. 2025: 1215-1220.
- [22] Lin, J., Wang, G., Li, S., et al. Effective and compact multimodal molecular representation optimization with molecular fragments enhancement[J]. *Expert Systems with Applications*, 2026, 318: 131997.
- [23] Huang, Q., Li, Y., Zhu, L., et al. Unified multimodal multidomain polymer representation for property prediction[J]. *npj Computational Materials*, Nature Publishing Group, 2025, 11(1): 153.
- [24] Jing, Z., Sun, Y., Li, Y.Y., et al. Structure-Aware Fusion with Progressive Injection for Multimodal Molecular Representation Learning[A].2025.
- [25] Li, J., Zhang, Z., Lei, Z., et al. MoLA: Molecular multimodal layerwise adaptive network for molecular property prediction[J]. *Knowledge-Based Systems*, 2026, 338: 115563.

- [26] Zhou, Z., Li, Y., Hong, P., et al. Multimodal fusion with relational learning for molecular property prediction[J]. Communications Chemistry, Nature Publishing Group, 2025, 8(1): 200.
- [27] Priyadarsini, I., Takeda, S., Hamada, L., et al. Learning Resilient Molecular Representations with Dynamic Multi-Modal Fusion[A].2025.
- [28] Huang, K., Fu, T., Gao, W., et al. Therapeutics Data Commons: Machine Learning Datasets and Tasks for Drug Discovery and Development[A].2021.
- [29] Li, Y., Wan, Y., Liu, X. Semi-supervised Learning with Graph Convolutional Networks Based on Hypergraph[J]. Neural Processing Letters, 2022, 54(4): 2629-2644.
- [30] Xiong, Z., Wang, D., Liu, X., et al. Pushing the Boundaries of Molecular Representation for Drug Discovery with the Graph Attention Mechanism[J]. Journal of Medicinal Chemistry, 2020, 63(16): 8749-8760.
- [31] Duvenaud, D.K., Maclaurin, D., Iparraguirre, J., et al. Convolutional Networks on Graphs for Learning Molecular Fingerprints[A]. Advances in Neural Information Processing Systems[C]. Curran Associates, Inc., 2015, 28.
- [32] Hirohara, M., Saito, Y., Koda, Y., et al. Convolutional neural network based on SMILES representation of compounds for detecting chemical motif[J]. BMC Bioinformatics, 2018, 19(19): 526.
- [33] Wu, Z., Ramsundar, B., Feinberg, E.N., et al. MoleculeNet: a benchmark for molecular machine learning[J]. Chemical Science, The Royal Society of Chemistry, 2018, 9(2): 513-530.
- [34] Jaeger, S., Fulle, S., Turk, S. Mol2vec: Unsupervised Machine Learning Approach with Chemical Intuition[J]. Journal of Chemical Information and Modeling, American Chemical Society, 2018, 58(1): 27-35.
- [35] Liu, S., Demirel, M.F., Liang, Y. N-Gram Graph: Simple Unsupervised Representation for Graphs, with Applications to Molecules[A]. Advances in Neural Information Processing Systems[C]. Curran Associates, Inc., 2019, 32.
- [36] Xu*, K., Hu*, W., Leskovec, J., et al. How Powerful are Graph Neural Networks?[A].2018.
- [37] Gilmer, J., Schoenholz, S.S., Riley, P.F., et al. Neural message passing for Quantum chemistry[A]. Proceedings of the 34th International Conference on Machine Learning - Volume 70[C]. Sydney, NSW, Australia: JMLR.org, 2017: 1263-1272.
- [38] Correction to Analyzing Learned Molecular Representations for Property Prediction[J]. Journal of Chemical Information and Modeling, 2019.
- [39] Song, Y., Zheng, S., Niu, Z., et al. Communicative Representation Learning on Attributed Molecular

Graphs[A].2020, 3: 2831-2838.

[40] Rong, Y., Bian, Y., Xu, T., et al. Self-Supervised Graph Transformer on Large-Scale Molecular Data[J]. arXiv: Biomolecules, 2020.

[41] Schütt, K., Kindermans, P.J., Felix, H.E.S., et al. SchNet: A continuous-filter convolutional neural network for modeling quantum interactions[A].2017.

[42] Liu, S., Wang, H., Liu, W., et al. Pre-training Molecular Graph Representation with 3D Geometry[J]. ArXiv, 2021.

[43] Liu, S., Nie, W., Wang, C., et al. Multi-modal molecule structure–text model for text-based retrieval and editing[J]. Nature Machine Intelligence, Nature Publishing Group, 2023, 5(12): 1447-1457.

[44] Su, B., Du, D., Yang, Z., et al. A Molecular Multimodal Foundation Model Associating Molecule Graphs with Natural Language[J].arXiv, 2022.

[45] Zeng, Z., Yao, Y., Liu, Z., et al. A deep-learning system bridging molecule structure and biomedical text with comprehension comparable to human professionals[J]. Nature Communications, Nature Publishing Group, 2022, 13(1): 862.

