

用于基于文本的检索和编辑的多模态分子结构文本模型

Shengchao Liu^{1,2}, Weili Nie³, Chengpeng Wang⁴, Jiarui Lu^{1,2}, Zhuoran Qiao⁵, Ling Liu⁶, Jian Tang^{*1,7}, Chaowei Xiao^{*3,8}, and Animashree Anandkumar^{*3,5}

1 米拉-魁北克人工智能研究所, 蒙特利尔, QC H2S 3H1, 加拿大2 蒙特利尔大学, 蒙特利尔, QC H3T 1J4, 加拿大3 NVIDIA 研究中心, 圣克拉拉, CA 95051, 美国4 伊利诺伊大学香槟分校, 香槟, IL 61801, 美国5 加州理工学院, 帕萨迪纳, CA 91125, 美国6 普林斯顿大学, 普林斯顿, 新泽西州 08544, 美国7 HEC 蒙特利尔, 蒙特利尔, QC H3T 2A7, 加拿大8 亚利桑那州立大学, 坦佩, AZ 85281, 美国

ABSTRACT

人工智能在药物发现中的应用越来越多。然而, 现有的研究使用机器学习主要利用分子的化学结构, 而忽略了化学中可用的大量文本知识。结合文本知识使我们能够实现新的药物设计目标, 适应基于文本的指令并预测复杂的生物活动。在这里, 我们提出了一种多模态分子结构文本模型 MoleculeSTM, 通过对比学习策略共同学习分子的化学结构和文本描述。为了训练 MoleculeSTM, 我们构建了一个大型多模态数据集, 即 PubChemSTM, 其中包含超过 280,000 个化学结构-文本对。为了证明 MoleculeSTM 的有效性和实用性, 我们设计了两个基于文本指令的具有挑战性的零样本任务, 包括结构文本检索和分子编辑。MoleculeSTM 有两个主要特性: 开放词汇和通过自然语言进行组合。在实验中, MoleculeSTM 获得了跨各种基准的新生化概念的最先进的泛化能力。

人工智能 (AI) 的最新进展有望为药物发现带来变革[1]。人工智能方法已被用来增强和加速当前的计算管道[2,3,4], 包括但不限于虚拟筛选[5,6]、代谢特性预测[7,8,9]以及有针对性的化学结构生成和编辑[10,11,12,13]。现有的机器学习 (ML) 方法主要集中在通过一维描述[14]、二维分子图[7, 15, 8], 或三维几何结构[16, 17, 18]。他们还使用监督信号, 例如毒性标签、量子力学特性和结合亲和力测量。然而, 这种监督设置需要对预先确定的标签类别进行昂贵的注释, 阻碍了对看不见的类别和任务的应用[19]。为了克服这个问题, 人们提出了对大型数据库[20]进行无监督预训练, 其主要优点是能够通过重建掩码拓扑[21]或几何[22]子结构来学习化学结构, 而无需监督注释。与监督设置相比, 尽管这种预训练模型[21, 22]已被证明通过对一些标记示例进行微调可以更有效地泛化到各种下游任务, 但在没有此类标记示例或微调的情况下泛化未见过的类别和任务 (即机器学习中所谓的零样本设置[23]) 仍然是一个公开的挑战。此外, 现有的分子预训练方法大多只包含化学结构, 而对多模态表示的探索较少。我们拥有大量人类可理解且易于访问的文本数据。现在, 它被用于图像和视频的大规模多模态模型 [24,25,26,27]。自然语言界面是一种实现开放词汇和任务描述的直观方式。预训练的多模态模型可以很好地推广到新的类别和任务, 即使在零样本设置中也是如此 [24,25,26,27]。它们还使智能体能够交互式地学习解决新任务并探索新环境 [28, 29]。我们相信, 通过结合文献中可用的大量文本知识, 也可以在分子模型中获得类似的功能。之前的工作[30]已尝试利用文本知识来学习分子表示。然而, 它仅支持使用一维描述 (简化的分子输入行输入系统或 SMILES) 进行建模, 并在小规模数据集 (10K 结构文本对) 上学习化学结构和文本描述。此外, 它将两种模式统一到一个语言建模框架中, 并需要对齐的数据 (即每个样本的化学结构和文本) 进行训练。




图 1. 预训练和下游任务的流程。(a) MoleculeSTM 预训练有两个分支：化学结构（绿色）和文本描述（粉色）。(b) 结构文本检索下游任务。(c) 基于文本的分子编辑下游任务。(d) 分子特性预测下游任务。

因此，它无法采用现有强大的预训练模型，并且对齐数据的可用性极其有限。我们的方法：我们设计了一个用于分子理解的多模态基础模型，其中包含分子结构信息和文本知识。我们使用基于文本的指令演示了对新药物设计目标的零样本泛化，以及对新的复杂生物活性的预测，而无需标记示例或微调。我们提出了 MoleculeSTM，由两个分支组成：化学结构分支和文本描述分支，分别处理分子的内部结构和外部领域知识。这种解开的设计使 MoleculeSTM 能够与单独训练每种模态的强大现有模型集成，即分子结构模型 [11, 31] 和科学语言模型 [32]。给定这些预训练模型，MoleculeSTM 通过对比学习范式连接了两个分支 [31, 33]。为了将这两个分支与 MoleculeSTM 对齐，我们从 Pub-Chem [34] 构建了一个名为 PubChemSTM 的结构文本数据集，这是迄今为止社区中最大的多模态数据集（比现有数据集 [30] 大 28 倍）。在 PubChemSTM 中，每个化学结构都配有文字描述，相应地说明了化学和物理特性或高级生物活性。由于 MoleculeSTM 是在大规模结构文本对数据集上进行训练的，并且此类文本数据包含开放式化学信息，因此它可以以零镜头方式推广到各种下游任务。为了展示引入语言模态的优势，我们设计了两个具有挑战性的下游任务：结构文本检索任务和基于文本的分子编辑任务，并以零镜头方式将预训练的 MoleculeSTM 应用于它们。通过研究这些任务，我们总结了 MoleculeSTM 的两个主要属性：开放词汇和组合性。(1) 开放词汇意味着我们提出的 MoleculeSTM 不限于一组固定的预定义分子相关文本描述，并且可以支持利用所描述的未绑定词汇表探索广泛的生化概念。

通过自然语言。在药物发现流程中，这样的属性可用于先导优化任务中基于文本的分子编辑和药物再利用任务中的新型疾病-药物关系提取。(2)组合性意味着我们可以通过将一个复杂的概念分解为几个简单的概念来表达它。这可以应用于基于文本的多目标先导优化任务[35]，其目标是生成同时满足多个属性的分子。根据经验，与最先进的方法相比，MoleculeSTM 在 6 个零样本检索任务（准确率高出 50%）和 20 个零样本基于文本的编辑任务（命中率高出 40%）上达到了最佳性能。此外，对于分子编辑任务，目视检查表明 MoleculeSTM 可以成功检测文本描述中隐含的关键结构。此外，我们还探讨了 MoleculeSTM 是否可以通过微调来提高标准分子特性预测基准 [9] 的性能。我们的结果表明，MoleculeSTM 可以在八个属性预测任务的九个基线中实现最佳整体性能。


Results

概述和预备知识在本节中，我们首先概述 MoleculeSTM。然后，我们介绍如何预训练 MoleculeSTM 并将预训练的 MoleculeSTM 应用于三类下游任务（图 1）。概述。MoleculeSTM 由两个分支组成：化学结构分支和文本描述分支（ x_{xxc} 和 x_{xxt} ）。化学结构分支说明了分子中原子的排列。我们考虑两种类型的编码器 f_c ：SMILES 字符串上的 Transformer [36] 和 2D 分子图上的 GNN [7,8,15]。文本描述分支提供了分子功能的高级描述，我们使用最近工作[37]中的语言模型作为编码器 f_t 。预训练。在这个设计中，MoleculeSTM 的目标是通过对比学习，使用两个投影仪（ p_c 和 p_t ）将从两个分支提取的表示映射到联合空间 [31, 33]。对比学习的基本思想是减少同一分子的化学结构和文本描述对之间的表示距离，增加不同分子的化学结构和文本描述对之间的表示距离。具体来说，我们使用预训练的单模态检查点 [11,31,32] 初始化这两个分支编码器，然后对收集的数据集 PubChemSTM 执行端到端对比预训练。特别是对于 PubChemSTM，它是根据 PubChem [34] 构建的。我们使用文本描述字段提取分子，从而生成 281K 化学结构和文本对。更多详细信息请参见补充 A.1。

下游任务设计的两个原则我们想强调的是，对于这些下游任务，预训练的 MoleculeSTM 中的语言模型揭示了分子建模和药物发现的某些吸引人的属性。我们总结了下面两个要点。开放词汇。语言本质上是开放词汇和自由形式[38]。大语言模型已经在各种艺术相关应用中证明了它的泛化能力 [24,25,26]，我们发现它还可以为药物发现任务提供有前景和富有洞察力的观察结果。在这种情况下，我们的方法不限于一组固定的预定义分子相关注释，而是可以支持使用未绑定词汇来探索新的生化概念。一个例子是药物的再利用。假设我们有一个新疾病或蛋白质目标功能的文字描述。这样的话，我们就可以利用 MoleculeSTM 获得它与所有现有药物的相似度，并检索出排名最高的药物，可以用于后期的临床试验等阶段。另一个例子是基于文本的潜在客户优化。我们用自然语言来描述一个全新的属性，优化后可以体现在生成的分子中的组合性。另一个属性是组合性。在自然语言中，复杂的概念可以通过将其分解为简单的概念来表达。这对于某些特定领域的任务至关重要，例如多目标先导优化[35]，我们需要同时生成具有多种所需特性的分子。现有的解决方案是 (1) 为每个所需属性学习一个分类器并在大型候选池上进行过滤 [10] 或 (2) 优化检索数据库以修改分子以实现多目标 [12]。主要限制是成功率很大程度上取决于用于训练分类器或检索数据库的标记数据的可用性。而通过 MoleculeSTM 中的语言模型，我们提供了另一种解决方案。我们首先制作一个自然文本，称为文本提示，作为任务描述。文本提示可以是多目标的，由每个属性的描述组成（例如，“分子可溶于水且具有高渗透性”）。借助化学结构和文本描述之间预先训练的联合空间，MoleculeSTM 可以将分子属性组合问题转化为语言组合问题，使用语言模型更容易处理。

下游：零样本结构文本检索实验。对于零样本检索，我们从 DrugBank [39] 构建了三个数据集。DrugBank 是迄今为止最全面的类药物分子数据库。这里我们提取了 DrugBank 中的三个字段：描述字段、药效学字段和解剖治疗化学（ATC）字段。这些字段说明了化学性质和药物对目标生物体的作用。那么检索任务可以看作是一个 T 选一多项选择问题，其中

(a) Structure-text Retrieval Results



(b) Drug Re-purposing Case Studies from DrugBank-ATC




图 2. 零样本结构文本检索的结果。(a) 三个 DrugBank 数据集上的零样本结构文本检索的准确性。(b) DrugBank-ATC 检索的四个案例研究。HMG-CoA 是 β -羟基 β -甲基戊二酰-CoA。

T 是选择的数量。具体来说，我们有两种设置：(1) 给定化学结构以检索文本描述；(2) 给定文本描述以检索化学结构。检索准确率作为评价指标的基线。我们首先考虑使用预训练的单模态编码器的两个基线[11,31,32]。(1) 冻结是我们对两个分支和两个随机初始化的投影仪采用预训练的编码器。(2) 相似性是我们仅从单个分支中获取相似性。例如，在第一个设置中，当给定化学结构时，我们从 PubChemSTM 中检索最相似的化学结构，然后将 PubChemSTM 中相应的配对文本表示作为代理表示。基于此，我们可以计算代理表示和 T 个请求文本表示之间的相似度得分。(3) 我们进一步考虑第三个基线，即基于 SMILES-文本对的用于知识丰富和多功能机器阅读的预训练语言模型 (KV-PLM) [30]。结果。零样本检索结果如图2 (a) 所示。首先，我们观察到两种设置之间所有算法的准确性都非常相似。然后，正如预期的那样，我们观察到由于随机初始化的投影仪，基线《冰雪奇缘》的表现并不比随机猜测更好。相似性基线比机会性能好一些，验证了预训练的单模态确实学习了语义信息，但不能在模态之间很好地泛化。另一方面，KV-PLM 从 SMILES-文本对中学习语义上有意义的信息，因此在三个数据集上实现了更高的准确性。对于 MoleculeSTM，GNN 的图形表示在描述和药效学方面比 Transformer 模型的 SMILES 表示具有更高的准确性；然而，它们在三个数据集和两个设置上都远远优于所有其他方法。例如，与 T = 20 的最佳基线相比，准确率提高了大约 50%、40% 和 15%。如此大的改进差距验证了




图 3.基于文本的零样本分子编辑的管道。(a) 空间对齐步骤对齐预训练分子生成模型的表示空间和 MoleculeSTM 的表示空间。(b) 潜在优化步骤学习一种类似于输入分子和文本描述的潜在表示。

表明MoleculeSTM可以在理解和桥接分子的两模式方面发挥更好的作用。药物再利用分析案例研究。在图2(b)中，我们进一步展示了关于ATC检索质量的四个案例研究。具体来说，考虑到分子的化学结构，我们从 600 个中选取 10 个最相似的 ATC 标签。据观察，MoleculeSTM 可以检索排名较高的真实 ATC 标签。

下游：基于文本的零样本分子编辑实验。对于分子编辑，我们从 ZINC [20] 中随机采样 200 个分子，并以文本提示作为输入。涵盖了四类文本提示：（1）单目标编辑是使用单一药物相关属性进行编辑的文本提示，例如“具有高溶解度的分子”和“更像药物的分子”。（2）多目标（组合性）编辑是同时应用多个属性的文本提示，例如“高溶解度和高渗透性的分子”。（3）基于结合亲和力的编辑是分析描述的文本提示，其中每个分析对应一个结合亲和力任务。一个具体的例子是 ChEMBL 1613777 [40]，提示为“该分子在酶蛋白的抑制剂和底物的测定中被测试为阳性。它使用分子氧将一个氧原子插入底物中，并将第二个氧原子还原为水分子。”。输出分子应具有更高的结合亲和力分数。（4）药物相关性编辑是使分子结构与某些常见药物相似的文字提示，例如“这个分子看起来像青霉素”。我们期望输出分子比输入药物与目标药物更相似。更详细的文本提示描述，请查看补充D。评价为满意的命中率，如果输出和输入之间的度量差值超过阈值 Δ ，则为命中。 Δ 值是特定于任务的，我们考虑两种典型情况： $\Delta = 0$ 表示宽松条件， $\Delta > 0$ 是严格条件，具有较大的积极影响。我们在图 3 中提供了算法管道，更多详细信息可以在方法部分的基线中找到。我们考虑四个基线。前三个基线 [13] 修改输入分子的表示，然后解码到分子空间。随机是我们采用随机噪声作为对输入分子表示的扰动。PCA 是我们以特征向量作为潜在方向，使用主成分分析（PCA）分解输入分子的潜在表示后获得特征向量。High Variance 是我们取方差最高的潜在表征维度，对其应用 one-hot 编码作为语义方向进行编辑。此外，我们还考虑了直接修改分子空间的基线，即遗传搜索（GS）。它是图遗传算法的变体 [41]，不同之处在于 GS 进行随机搜索，而不是通过奖励函数进行引导搜索，因为在零样本设置下没有可用的检索数据库。结果。首先，我们在图 4 中提供了四种编辑任务类型的 20 个编辑任务的定量结果。实验结果表明，MoleculeSTM 的令人满意的命中率是所有 20 个任务中最好的。它验证了，对于 SMILES 和分子图编码器，MoleculeSTM 能够更好地理解自然语言的语义，以探索具有所需属性的输出分子。接下来，我们仔细检查图 5 中输出分子的质量，详细分析如下：单目标分子编辑的可视化分析。我们使用单目标属性直观地分析输入和输出分子之间的差异。典型的修饰是添加、去除和替换分子的官能团或核心。例如，图 5 (a) 和 (b) 显示了对同一分子前导的两个不同编辑




图 4. 零次基于文本的分子编辑的可视化结果。四种基于文本的编辑任务的命中率令人满意 (%) : 8个单目标、4个多目标、4个基于ChEMBL结合亲和力的编辑任务(预训练的随机森林作为评估器, 详细的文本提示在补充D中)和4个药物相关性编辑任务。对于所有可视化结果, 令人满意的阈值 (Delta) 均为 0。每个任务运行三个随机种子, 每个误差条的长度代表标准差。

根据文字提示, 溶解度会向相反方向变化。将吡啶替换为吡嗪核心可提高溶解度, 而插入苯键则产生不溶性分子。在图 5 (c) 和 (d) 中, 将酰胺键改为烷基胺和尿素分别会导致编辑分子的渗透性更高和更低。最后, 图5(e)和(f)在分子的确切位置添加了一个丁基醚和一个伯胺, 分别带来了更多的氢键受体和供体。多目标分子编辑的可视化分析。我们进一步分析多目标(组合)属性编辑。当向分子中引入极性基团并去除亲脂性烃(例如用酰胺或伯胺取代图 5 (g) 中的甲基或苯基)时, 水溶性提高和渗透性降低是一致的。然而, 如果极性官能团与疏水性组分一起被去除或数量减少, 则可以获得更高的溶解度和渗透性。例如, 图5(h)中, 左侧的酰胺键和苯键均被去除, 右侧的[1,2]恶唑并[5,4-b]吡啶取代基被极性表面较小的水溶性咪唑取代。专利药物分子邻域搜索案例研究。在药物发现中, 改善先导分子的类药特性对于寻找候选药物至关重要[35]。在此, 我们演示了两个示例, 通过根据文本提示解决专利类似物的特性缺陷, 从其专利类似物生成批准的药物。图 5 (i) 从其氨基取代衍生物生成塞来昔布 [42], 其中氨基的去除使分子具有更大的肠道渗透性, 从而导致更高的生物利用度 [43]。在图5 (j) 中, 三甲氧基苯部分, 一种已知会经历氧化相I代谢的富电子芳烃[44], 通过调用代谢稳定的分子而被多奈哌齐中的二甲氧基芳烃取代。总之, 我们对四种类型和20个基于文本的分子编辑任务进行了丰富的实验, 其中令人满意的结果




图 5. 基于文本的分子编辑的可视化分析。溶解度编辑 (a,b)、渗透性编辑 (c,d)、受体和

供体编辑 (e,f)、溶解度和渗透性编辑 (g,h) 以及专利数据的邻域搜索 (i,j)。粉色和蓝色区域标记了编辑前后的官能团，我们列出了化学文摘服务 (CAS) 注册号。(k) 可视化基于结合亲和力的编辑，红色虚线标记了潜在的结合。

MoleculeSTM 的命中率优于基线方法。此外，我们的编辑结果可以匹配基于化学领域知识的预期结果。定量和定性结果都表明 MoleculeSTM 可以学习对领域应用有用的语义上有意义的信息，这鼓励我们在未来使用 MoleculeSTM 探索更具挑战性的任务。

下游：分子特性预测实验。MoleculeSTM 的优势之一是预训练的化学结构表示与外部领域知识共享信息，这种隐式偏差可能有利于性质预测任务。与之前的分子预训练工作类似 [21, 31]，我们采用 MoleculeNet 基准 [9]。它包含八个单模态二元分类数据集，用于评估预训练分子表示方法的表达能力。评价

	method	BBBP $\uparrow$	Tox21 $\uparrow$	ToxCast $\uparrow$	Sider $\uparrow$	ClinTox $\uparrow$	MUV $\uparrow$	HIV $\uparrow$	Bace $\uparrow$	Avg $\uparrow$
SMILES	– (random initialized)	66.54 $\pm$ 0.95	71.18 $\pm$ 0.67	61.16 $\pm$ 1.15	58.31 $\pm$ 0.78	88.11 $\pm$ 0.70	62.74 $\pm$ 1.57	70.32 $\pm$ 1.51	80.02 $\pm$ 1.66	69.80
	MegaMolBART	68.89 $\pm$ 0.17	73.89 $\pm$ 0.67	63.32 $\pm$ 0.79	59.52 $\pm$ 1.79	78.12 $\pm$ 4.62	61.51 $\pm$ 2.75	71.04 $\pm$ 1.70	82.46$\pm$0.84	69.84
	KV-PLM	70.50 $\pm$ 0.54	72.12 $\pm$ 1.02	55.03 $\pm$ 1.65	59.83 $\pm$ 0.56	89.17$\pm$2.73	54.63 $\pm$ 4.81	65.40 $\pm$ 1.69	78.50 $\pm$ 2.73	68.15
	MoleculeSTM	70.75$\pm$1.90	75.71$\pm$0.89	65.17$\pm$0.37	63.70$\pm$0.81	86.60 $\pm$ 2.28	65.69$\pm$1.46	77.02$\pm$0.44	81.99 $\pm$ 0.41	73.33
Graph	– (random initialized)	63.90 $\pm$ 2.25	75.06 $\pm$ 0.24	64.64 $\pm$ 0.76	56.63 $\pm$ 2.26	79.86 $\pm$ 7.23	70.43 $\pm$ 1.83	76.23 $\pm$ 0.80	73.14 $\pm$ 5.28	69.99
	AttrMask	67.79 $\pm$ 2.60	75.00 $\pm$ 0.20	63.57 $\pm$ 0.81	58.05 $\pm$ 1.17	75.44 $\pm$ 8.75	73.76 $\pm$ 1.22	75.44 $\pm$ 0.45	80.28 $\pm$ 0.04	71.17
	ContextPred	63.13 $\pm$ 3.48	74.29 $\pm$ 0.23	61.58 $\pm$ 0.50	60.26 $\pm$ 0.77	80.34 $\pm$ 3.79	71.36 $\pm$ 1.44	70.67 $\pm$ 3.56	78.75 $\pm$ 0.35	70.05
	InfoGraph	64.84 $\pm$ 0.55	76.24 $\pm$ 0.37	62.68 $\pm$ 0.65	59.15 $\pm$ 0.63	76.51 $\pm$ 7.83	72.97 $\pm$ 3.61	70.20 $\pm$ 2.41	77.64 $\pm$ 2.04	70.03
	MolCLR	67.79 $\pm$ 0.52	75.55 $\pm$ 0.43	64.58 $\pm$ 0.07	58.66 $\pm$ 0.12	84.22 $\pm$ 1.47	72.76 $\pm$ 0.73	75.88 $\pm$ 0.24	71.14 $\pm$ 1.21	71.32
	GraphMVP	68.11 $\pm$ 1.36	77.06$\pm$0.35	65.11$\pm$0.27	60.64 $\pm$ 0.13	84.46 $\pm$ 3.10	74.38$\pm$2.00	77.74$\pm$2.51	80.48 $\pm$ 2.68	73.50
	MoleculeSTM	69.98$\pm$0.52	76.91 $\pm$ 0.51	65.05 $\pm$ 0.39	60.96$\pm$1.05	92.53$\pm$1.07	73.40 $\pm$ 2.90	76.93 $\pm$ 1.84	80.77$\pm$1.34	74.57

Table 1. Results on eight MoleculeNet binary classification tasks. Mean and standard deviation of test ROC-AUC on three random seeds are reported.

指标是受试者工作特征曲线下的面积 (ROC-AUC) [45]。基线。我们考虑两种类型的化学结构：SMILES 字符串和分子图。对于 SMILESstring，我们采用三个基线：随机初始化的模型和两个预训练的语言模型（MegaMolBART [11] 和 KV-PLM [30]）。对于分子图，除了随机初始化之外，我们还考虑了五种基于预训练的方法作为基线：AttrMasking [21]、ContextPred [21]、InfoGraph [46]、MolCLR [47] 和 GraphMVP [8]。结果。如表 1 所示，我们首先观察到与随机初始化的方法相比，基于预训练的方法提高了整体分类精度。与三个基线相比，SMILES 字符串上的 MoleculeSTM 在八项任务中的六项上取得了一致的改进。分子图上的 MoleculeSTM 在八项任务中的四项上表现最好，同时它在其他四项任务中的表现与最佳基线相当。在这两种情况下，MoleculeSTM 的整体性能（即对所有八个任务取平均值）是所有方法中最好的。

Discussion

在这项工作中，我们提出了一个多模态模型 MoleculeSTM，以说明结合文本描述进行分子表示学习的有效性。在两项新提出的零样本任务和一项标准属性预测基准上，我们证实与现有方法相比，MoleculeSTM 的性能持续提高。此外，我们观察到 MoleculeSTM 可以检索新的药物-靶点关系并成功修改分子子结构以获得所需的特性。这些功能可能会加速各种下游药物发现实践，例如重新利用和多目标先导优化。此外，此类下游任务的结果与化学专家的反馈一致，反映了 MoleculeSTM 的领域知识探索能力。这项工作的一个限制是数据不足。尽管 PubChemSTM 比现有作品中使用的数据集大 28 倍，但它可以进一步改进，并且将来可能需要整个社区的支持。这项工作的第二个瓶颈是化学结构模型的表达能力，包括 SMILES 编码器、GNN 编码器和基于 SMILES 的分子生成模型。更具表现力的架构的开发与这项工作垂直，并且可以切实地适应我们的多模式预训练框架。对于未来的方向，我们希望将 MoleculeSTM 从化学信息学扩展到具有更丰富文本信息的生物信息学任务。这使我们能够考虑基于结构的药物设计问题，例如蛋白质-配体结合和片段设计。此外，3D 几何信息对于小分子和聚合物变得更加重要，因此可以合并到我们的基础模型中。最后但并非最不重要的是，文本描述的标记化可能需要额外的努力。某些任务拥有丰富的术语（例如 DrugBank-ATC 中的 ATC 代码），整体性能会受到相应影响。对于这样的根本性问题，应该认真对待。

Methods

本节简要描述预训练和下游任务中的某些模块。详细的规范，例如数据集构造、模型架构和超参数，可以在补充 A 中找到。

MoleculeSTM 预训练数据集构建。对于结构文本预训练，我们考虑 PubChem 数据库 [34] 作为数据源。PubChem 包含 112M 个分子，是最大的分子公共数据库之一。PubChem 数据库有很多字段，之前的工作[30]使用同义词字段与学术论文语料库[48]进行匹配，得到具有 10K 结构-文本对的数据集。同时，PubChem 数据库还有另一个字段“string”，更加全面、通用。

分子注释。我们利用这个字段构建了一个名为 PubChemSTM 的大型数据集，由 250K 分子和 281K 结构文本对组成。此外，尽管 PubChemSTM 是最大的带有文本描述的数据集，但与其他领域的同行相比，其数据集大小相对较小（例如，视觉语言领域的 400M [24]）。为了缓解这种数据不足的问题，我们采用现有检查点的预训练模型，然后进行端到端预训练，如下所述。化学结构分支 f_c 。这项工作考虑了两种类型的化学结构：SMILES 字符串将分子视为序列，而 2D 分子图分别将原子和键视为节点和边。然后，基于化学结构，我们应用深度学习编码器 f_c 来获取潜在向量作为分子表示。具体来说，对于 SMILES 字符串，我们采用来自 MegaMolBART [11] 的编码器，该编码器在 ZINC 数据库 [49] 的 500M 分子上进行了预训练。对于分子图，我们采用 Graph-MVP 预训练 [31] 来预训练图同构网络 (GIN) [15]。GraphMVP 正在对来自 GEOM 数据集 [50] 的 250K 构象进行 2D 拓扑和 3D 几何之间的多视图预训练。因此，尽管我们没有明确利用 3D 几何形状，但最先进的预训练 GIN 模型可以隐式编码此类信息。文本描述分支 f_t 。文本描述分支提供了分子功能的高级描述。我们可以将这个分支视为加强分子表示的领域知识。这种领域知识是以自然语言的形式存在的，我们使用 BERT 模型 [37] 作为文本编码器 f_t 。我们进一步调整了预训练的 SciBERT [32]，它是根据化学和生物领域的文本数据进行预训练的。对比预训练。对于 MoleculeSTM 预训练，我们采用对比学习策略，例如 EBM-NCE [31] 和 InfoNCE [33]。EBM-NCE 和 InfoNCE 对齐同一分子的结构文本对，并同时对比不同分子的结构文本对。我们认为对比预训练方法的选择是一个重要的超参数。EBM-NCE 和 InfoNCE 的目标是

$$\begin{aligned}\mathcal{L}_{\text{EBM-NCE}} &= -\frac{1}{2} \left(\mathbb{E}_{\mathbf{x}_c, \mathbf{x}_t} [\log \sigma(E(\mathbf{x}_c, \mathbf{x}_t))] + \mathbb{E}_{\mathbf{x}_c, \mathbf{x}_t'} [\log (1 - \sigma(E(\mathbf{x}_c, \mathbf{x}_t')))] + \mathbb{E}_{\mathbf{x}_c, \mathbf{x}_t} [\log \sigma(E(\mathbf{x}_c, \mathbf{x}_t))] + \mathbb{E}_{\mathbf{x}_c', \mathbf{x}_t} [\log (1 - \sigma(E(\mathbf{x}_c', \mathbf{x}_t)))] \right), \\ \mathcal{L}_{\text{InfoNCE}} &= -\frac{1}{2} \mathbb{E}_{\mathbf{x}_c, \mathbf{x}_t} \left[\log \frac{\exp(E(\mathbf{x}_c, \mathbf{x}_t))}{\exp(E(\mathbf{x}_c, \mathbf{x}_t)) + \sum_{\mathbf{x}_t'} \exp(E(\mathbf{x}_c, \mathbf{x}_t'))} + \log \frac{\exp(E(\mathbf{x}_c, \mathbf{x}_t))}{\exp(E(\mathbf{x}_c, \mathbf{x}_t)) + \sum_{\mathbf{x}_c'} \exp(E(\mathbf{x}_c', \mathbf{x}_t))} \right],\end{aligned}\quad (1)$$

其中 σ 是 sigmoid 激活函数， $\mathbf{x} \times \mathbf{x}_c$ 和 $\mathbf{x} \times \mathbf{x}_t$ 形成每个分子的结构文本对， $\mathbf{x} \times \mathbf{x}_c'$ 和 $\mathbf{x} \times \mathbf{x}_t'$ 是从噪声分布中随机采样的负样本，我们使用经验数据分布。 $E(\cdot)$ 是具有灵活公式的能量函数，我们使用联合学习空间上的点积，即 $E(\mathbf{x} \times \mathbf{x}_c, \mathbf{x} \times \mathbf{x}_t) = \langle p_c \circ f_c(\mathbf{x} \times \mathbf{x}_c), p_t \circ f_t(\mathbf{x} \times \mathbf{x}_t) \rangle$ ，其中 $\circ$ 是函数复合。

下游：零样本结构文本检索给定一个化学结构和 T 个文本描述，检索任务是根据在联合表示空间上计算的分数的选择与化学结构相似度最高的文本描述（反之亦然）。这对于特定的药物发现任务很有吸引力，例如药物重新利用或适应症扩展 [30, 51]。我们强调，预训练模型用于零样本设置中的检索，即无需针对该检索任务进行模型优化。现有的工作 [52] 已经见证了仅利用化学结构是不够的潜在问题，而 MoleculeSTM 通过采用文本描述并利用分子的高级功能，实现了一种新颖的视角。在这种零样本任务设置中，所有编码器 (f_c , f_t) 和投影仪 (p_c , p_t) 都是从 MoleculeSTM 进行预训练的，并在此下游任务中保持冻结。设置 (1) 的检索任务的示例是

$$\text{Retrieval}(\mathbf{x}_c) = \arg \max_{\tilde{\mathbf{x}}_t} \left\{ \langle p_c \circ f_c(\mathbf{x}_c), p_t \circ f_t(\tilde{\mathbf{x}}_t) \rangle \mid \tilde{\mathbf{x}}_t \in T \text{ textual descriptions} \right\}.\quad (2)$$

下游：基于零次文本的分子编辑分子编辑任务的目标是修改分子的化学结构，例如官能团变化 [53] 和支架跳跃 [54, 55]。传统的分子编辑方法高度依赖领域专家，并且可能存在主观或偏见 [56, 57]。机器学习方法提供了解决这个问题的替代策略。给定固定的预训练分子生成模型（编码器 f_g 和解码器 h_g ），机器学习编辑方法在潜在表示（或潜在代码）空间上学习语义上有意义的方向。然后，解码器 h_g 通过沿该方向移动来生成具有所需属性的输出分子。在 MoleculeSTM 中，利用预训练的联合表示空间，我们可以通过以零样本的方式注入文本描述来完成此任务。如图 3 (a, b) 所示，我们需要两个阶段。第一阶段是空间对齐，我们训练适配器模块将生成模型的表示空间与 MoleculeSTM 的联合表示空间对齐。第二阶段是潜在优化，我们使用两个相似度直接学习潜在代码

分数作为目标函数。最后，解码优化的潜在代码可以得到输出分子。请注意，在此编辑过程中，MoleculeSTM (f_c, p_c, f_t, p_t) 和预训练的分子生成模型 (f_g, h_g) 都被冻结。第 1 阶段：空间对齐。在这个阶段，目标是学习一个适配器模块，将生成模型的表示空间与 MoleculeSTM 的联合表示空间对齐。遵循高斯分布，目标函数为

$$\mathcal{L} = \|m_{g2f} \circ f_g(\mathbf{x}_c) - p_c \circ f_c(\mathbf{x}_c)\|^2, \quad (3)$$

其中 $\circ$ 是函数组合函数， m_{g2f} 是为对齐两个潜在空间而优化的适配器模块。阶段 2：潜在优化。在此阶段，给定输入分子 $\mathbf{x}_{c,in}$ 和文本提示 $\mathbf{x}_{t}$ ，目标是直接优化潜在代码 w 。最优的 w 应同时接近 $\mathbf{x}_{c,in}$ 和 $\mathbf{x}_{t}$ 的表示，如下所示：

$$w = \arg \min_{w \in \mathcal{W}} \left(-\mathcal{L}_{\text{cosine-sim}}(m_{g2f}(w), p_t \circ f_t(\mathbf{x}_t)) + \lambda \cdot \mathcal{L}_2(w, f_g(\mathbf{x}_{c,in})) \right), \quad (4)$$

其中 $\mathcal{W}$ 是潜在代码空间， $\mathcal{L}_{\text{cosine-sim}}$ 是余弦相似度， $\mathcal{L}_2$ 是 L_2 距离， λ 是平衡这两个相似项的系数。最后，在我们优化潜在代码 w 之后，我们将使用预训练生成模型中的解码器进行解码，以获得输出分子： $\mathbf{x}_{c,out} = h_g(w)$ 。评估。评价指标是满意的命中率。假设我们有一个输入分子 $\mathbf{x}_{c,in}$ 和一个文本提示 $\mathbf{x}_{t}$ ，编辑算法将生成一个输出分子 $\mathbf{x}_{c,out}$ 。然后我们用命中率来衡量输出分子是否能够满足文本提示中所示的条件。

$$\text{hit}(\mathbf{x}_{c,in}, \mathbf{x}_t) = \begin{cases} 1, & \exists \lambda, \text{ s.t. } \mathbf{x}_{c,out} = h_g(w; \lambda) \wedge \text{satisfy}(\mathbf{x}_{c,in}, \mathbf{x}_{c,out}, \mathbf{x}_t), \\ 0, & \text{otherwise} \end{cases}, \quad \text{hit}(t) = \frac{\sum_{i=1}^N \text{hit}(\mathbf{x}_{c,in}^i, \mathbf{x}_t)}{N}, \quad (5)$$

其中 N 是编辑输出的总数， $\text{satisfy}(\cdot)$ 是满足条件。它是特定于任务的，我们在下面列出了五个关键点。（1）对于基于单目标属性的编辑，我们使用分配系数的对数（LogP）、药物相似度的定量估计（QED）和拓扑极表面积（tPSA）作为代理来分别测量分子溶解度[58]、药物相似度[59]和渗透性[60]。明确计算氢键受体（HBA）和氢键供体（HBD）的数量。一旦输入分子和输出分子之间的测量差异高于某个阈值 Δ ，则命中成功。（2）对于基于多目标属性的编辑，我们输入描述多个属性组成的文本提示。 Δ 由每个单独属性的阈值组成，成功的命中需要同时满足所有属性。

（3）对于基于结合亲和力的编辑，我们采用 ChEMBL 的真实数据来训练二元分类器并测试输出分子是否比输入分子具有更高的置信度，并且 Δ 固定为 0。（4）对于药物相关性编辑，我们使用 Tanimoto 相似性来量化结构相似性[61]。如果输出分子和目标药物之间的相似度得分比输入分子和目标药物之间的相似度高出阈值 Δ ，则它将被击中。（5）此外，满意阈值 Δ 的选择也是针对特定任务的，值越高，满足条件越严格。阈值的详细信息可以在补充 D 中找到。

下游：分子特性预测对于建模，我们采用预训练的编码器 f_c 并添加预测头 h_c 来预测分类值或标量值分子特性，例如结合亲和力或毒性。 f_c 和 h_c 都经过优化以适应目标属性，即以微调方式 [21, 31]。

数据可用性

所有数据集均在此 Hugging Face 链接中提供。特别是在 PubChemSTM 的发布过程中，我们遇到了关于文本数据许可的巨大挑战。正如 PubChem 小组所证实的那样，对这些数据进行研究并不违反他们的许可；然而，PubChem 不拥有文本数据的许可证，因此需要对 PubChemSTM 中 280 个结构文本对中的每一个的许可证进行广泛的评估。这阻碍了 PubChemSTM 的发布。尽管如此，我们 (1) 在补充 A.1 中描述了详细的预处理步骤，(2) 在 PubChemSTM 中提供了带有 CID 文件的分子，(3) 还提供了详细的预处理脚本。通过利用这些脚本，用户可以轻松重建 PubChemSTM 数据集。

代码可用性

源代码可以在此 GitHub 存储库和 Zenodo [62] 中找到。此处提供了预训练和三个下游任务的脚本。此 Hugging Face 链接提供了预训练模型的检查点。除了迄今为止描述的方法之外，为了帮助用户尝试我们的 MoleculeSTM 模型，此版本还包括笔记本中的演示。此外，用户可以通过检查数据集文件夹来自定义自己的数据集。

Acknowledgements

这项工作是刘胜超在 NVIDIA Research 实习期间完成的。作者要感谢 Michelle Lynn Gill、Abe Stern 以及来自 NVIDIA 的 AIAI 和 Clara 团队的其他团队成员的富有洞察力的评论。作者还要感谢 PubChem 的 Teresa Dierks、Evan Bolton、Paul Thiessen 等人的善意帮助，确认了 PubChem 许可证。

作者贡献声明

S.L.、W.N.、C.W.、Z.Q.、C.X. 和 A.A. 构思并设计了实验。S.L. 进行了实验。S.L. 和 C.W. 分析了数据。S.L.、C.W. 和 J.L. 贡献了分析工具。S.L.、W.N.、C.W.、J.L.、Z.Q.、L.L.、J.T.、C.X. 和 A.A. 撰写了这篇论文。J.T.、C.X. 和 A.A. 为该项目的咨询做出了同样的贡献。

Competing Interests Statement

作者声明没有竞争利益。

References

- [1] 托马斯·沙利文。 “一条艰难的路：一款新药的研发成本达26亿美元，进入临床开发的药物批准率不足12%”。见：政策与医学（2019）。
- [2] 阿塔纳斯·帕特罗诺夫、科斯塔斯·帕帕多普洛斯和奥拉·恩奎斯特。 “人工智能影响了药物发现吗？” 见：药物设计中的人工智能。施普林格，2022 年，第 153–176 页。
- [3] Madura KP Jayatunga, Wen Xie, Ludwig Ruder, Ulrik Schulze, and Christoph Meier. “AI in small-molecule drug discovery: A coming wave”. In: *Nat. Rev. Drug Discov* 21 (2022), pp. 175–176.
- [4] 约翰·跳跃者、理查德·埃文斯、亚历山大·普里策尔、蒂姆·格林、迈克尔·菲格诺夫、奥拉夫·罗尼伯格、凯瑟琳·图尼亚苏瓦纳库、拉斯贝茨、奥古斯丁·齐德克、安娜·波塔彭科、亚历克斯·布里奇兰、克莱门斯·迈耶、西蒙·A·科尔、安德鲁·J·巴拉德、安德鲁·考伊、贝尔纳迪诺·罗梅拉-帕雷德斯、斯坦尼斯拉夫·尼科洛夫、Rishub Jain、Jonas Adler、Trevor Back、Stig Petersen、David Reiman、Ellen Clancy、Michal Zielinski、Martin Steinegger、Michalina Pacholska、Tamas Berghammer、Sebastian Bodenstein、David Silver、Oriol Vinyals、Andrew W. Senior、Koray Kavukcuoglu、Pushmeet Kohli 和 Demis Hassabis。 “使用 AlphaFold 进行高精度蛋白质结构预测”。见：《自然》596.7873 (2021)，第 583–589 页。
- [5] 塞巴斯蒂安·G·罗勒和克努特·鲍曼。 “基于 PubChemBioactivity 数据的虚拟筛选的最大无偏验证 (MUV) 数据集”。见：《化学信息与建模杂志》49.2 (2009)。 PMID: 19161251, 第 169–184 页。 DOI: 10.1021/ci8002649。 电子打印: <https://doi.org/10.1021/ci8002649>。 网址: <https://doi.org/10.1021/ci8002649>。
- [6] 刘胜超、Moayad Alnammi、Spencer S Ericksen、Andrew F Voter、Gene E Ananiev、James L Keck、F Michael Hoffmann、Scott A Wildman 和 Anthony Gitter。 “前瞻性虚拟筛选的实用模型选择”。见：化学信息和建模杂志 59.1 (2018)，第 282–293 页。
- [7] David K Duvenaud、Dougal Maclaurin、Jorge Iparraguirre、Rafael Bombarell、Timothy Hirzel、Alán Aspuru-Guzik 和 Ryan P Adams。 “用于学习分子指纹的图上的卷积网络”。见：神经信息处理系统的进展28 (2015)。
- [8] 刘胜超，Mehmet F Demirel，梁英玉。 “N-Gram 图：图的简单无监督表示，及其在分子中的应用”。见：神经信息处理系统的进展 32 (2019)。
- [9] Zhuhenqin Wu、Bharath Ramsundar、Evan N Feinberg、Joseph Gomes、Caleb Geniesse、Aneesh S Pappu、Karl Leswing 和 Vijay Pande。 “MoleculeNet: 分子机器学习的基准”。见：化学科学 9.2 (2018)，第 513–530 页。
- [10] 金文功，Regina Barzilay，Tommi Jaakkola。 “使用结构基序分层生成分子图”。见：机器学习国际会议。 PMLR。 2020 年，第 4839–4848 页。
- [11] Ross Irwin、Spyridon Dimitriadis、Jiazhen He 和 Esben Jannik Bjerrum。 “Chemformer: 用于计算化学的预训练变压器”。见：机器学习：科学与技术 3.1 (2022)，第 14 页。 015022。
- [12] Zichao Wang, Weili Nie, Zhuoran Qiao, Chaowei Xiao, Richard Baraniuk, and Anima Anandkumar. “Retrieval-based Controllable Molecule Generation”. In: *arXiv preprint arXiv:2208.11126* (2022).
- [13] 刘胜超，王成鹏，聂伟丽，王汉辰，陆家瑞，周博雷，唐健。 “GraphCG: 图中可操纵因素的无监督发现”。见：NeurIPS 2022 研讨会：图学习的新前沿。 2022。 网址: https://openreview.net/forum?id=BhR44NzeK_1。
- [14] Mario Krenn、Florian Häse、AkshatKumar Nigam、Pascal Friederich 和 Alan Aspuru-Guzik。 “自引用嵌入字符串 (SELFIES) : 100% 稳健的分子字符串表示”。见：机器学习：科学与技术 1.4 (2020)，第 14 页。 045024。

- [15] 徐克雨露, 胡伟华, Jure Leskovec, Stefanie Jegelka. “图神经网络有多强大?” 见: arXiv preprint arXiv:1810.00826 (2018).
- [16] Kristof T Schütt, Huziel E Sauceda, P-J Kindermans, Alexandre Tkatchenko 和 K-R Müller. “SchNet——分子和材料的深度学习架构”。见: 《化学物理杂志》148.24 (2018), 第 14 页。241722。
- [17] 维克多·加西亚·萨托拉斯, 埃米尔·胡格布姆和马克斯·威灵。 “E(n) 等变图神经网络”。见: arXiv preprint arXiv:2102.09844 (2021)。
- [18] 肯尼思·阿茨, 弗朗西斯卡·格里索尼和吉斯伯特·施奈德。 “分子表示的几何深度学习”。见: Nature Machine Intelligence 3.12 (2021), 第 1023–1032 页。
- [19] 季远峰, 张璐, 吴嘉祥, 吴秉哲, 黄龙凯, 徐婷阳, 容宇, 李兰清, 任杰, 薛丁, 等。 “DrugOOD: 分布外 (OOD) 数据集馆长和人工智能辅助药物发现的基准——关注带有噪声注释的亲和力预测问题”。见: arXiv 预印本 arXiv:2201.09637 (2022)。
- [20] 约翰·J·欧文, 蒂格·斯特林, 迈克尔·M·迈辛格, 艾琳·S·博尔斯塔和瑞安·G·科尔曼。 “ZINC: 发现生物学化学的免费工具”。见: 《化学信息与建模杂志》52.7 (2012), 第 1757–1768 页。
- [21] Weihua Hu, Bowen Liu, Joseph Gomes, Marinka Zitnik, Percy Liang, Vijay Pande, and Jure Leskovec. “Strategies for pre-training graph neural networks”. In: *International Conference on Learning Representations, ICLR*. 2020.
- [22] Shengchao Liu, Hongyu Guo, and Jian Tang. “Molecular geometry pretraining with se (3)-invariant denoising distance matching”. In: *arXiv preprint arXiv:2206.13602* (2022).
- [23] Hugo Larochelle, Dumitru Erhan, and Yoshua Bengio. “Zero-data learning of new tasks.” In: *AAAI*. Vol. 1. 2. 2008, p. 3.
- [24] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark 等。 “从自然语言监督中学习可转移的视觉模型”。见: 国际机器学习会议。PMLR. 2021 年, 第 8748–8763 页。
- [25] Alex Nichol, Prafulla Dhariwal, Aditya Ramesh, Pranav Shyam, Pamela Mishkin, Bob McGrew, Ilya Sutskever 和 Mark Chen. “Glide: 使用文本引导扩散模型生成和编辑逼真的图像”。见: arXiv 预印本 arXiv: 2112.10741(2021)。
- [26] Aditya Ramesh, Prafulla Dhariwal, Alex Nichol, Casey Chu, and Mark Chen. “Hierarchical text-conditional image generation with clip latents”. In: *arXiv preprint arXiv:2204.06125* (2022).
- [27] 或者 Patashnik, Zongze Wu, Eli Shechtman, Daniel Cohen-Or 和 Dani Lischinski. “Styleclip: 文本驱动的 styleganimagery 操作”。见: IEEE/CVF 国际计算机视觉会议论文集。2021 年, 第 2085–2094 页。
- [28] Shuang Li, Xavier Puig, Yilun Du, Clinton Wang, Ekin Akyurek, Antonio Torralba, Jacob Andreas, and Igor Mordatch. “Pre-trained language models for interactive decision-making”. In: *arXiv preprint arXiv:2202.01771* (2022).
- [29] Linxi Fan, Guanzhi Wang, Yunfan Jiang, Ajay Mandlekar, Yuncong Yang, Haoyi Zhu, Andrew Tang, De-An Huang, Yuke Zhu, and Anima Anandkumar. “Minedojo: Building open-ended embodied agents with internet-scale knowledge”. In: *arXiv preprint arXiv:2206.08853* (2022).
- [30] 曾珍妮, 姚媛, 刘志远, 孙茂松。 “一个连接分子结构和生物医学文本的深度学习系统, 其理解力可与人类专业人员相媲美”。见: 《自然通讯》13.1 (2022), 第 1-11 页。
- [31] 刘胜超, 王汉辰, 刘维扬, Joan Lasenby, 郭宏宇, 唐健。 “用 3D 几何预训练分子图表示”。见: 国际学习代表会议。2022。网址: <https://openreview.net/forum?id=xQe1pOKPam>。
- [32] 伊兹·贝尔塔吉 (Iz Beltagy), 凯尔·罗 (Kyle Lo) 和阿曼·科汉 (Arman Cohan)。 “SciBERT: 科学文本的预训练语言模型”。在: EMNLP. 2019.eprint: arXiv: 1903.10676。
- [33] Aaron van den Oord, Yazhe Li 和 Oriol Vinyals。 “具有对比预测编码的表示学习”。见: arXiv preprint arXiv:1807.03748 (2018)。
- [34] Sunghwan Kim, Jie Chen, Tiejun Cheng, Asta Gindulyte, Jia He, Siqian He, Qingliang Li, Benjamin A Shoemaker, Paul A Thiessen, Bo Yu, 等。 “2021 年的 PubChem: 新的数据内容和改进的网络界面”。见: 核酸研究 49.D1 (2021), 第 D1388–D1395 页。
- [35] 詹姆斯·P·休斯, 斯蒂芬·里斯, S·巴雷特·卡林吉安和凯伦·L·菲尔波特。 “早期药物发现的原则”。见: 英国药理学杂志 162.6 (2011), 第 1239–1249 页。
- [36] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser 和 Illia Polosukhin。 “注意力就是您所需要的”。见: 神经信息处理系统的进展 30 (2017)。
- [37] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. “Bert: Pre-training of deep bidirectional transformers for language understanding”. In: *arXiv preprint arXiv:1810.04805* (2018).
- [38] 顾秀野, 林宗义, 郭伟成, 崔寅。 “通过视觉和语言知识蒸馏进行开放词汇对象检测”。见: arXiv 预印本 arXiv: 2104.13921 (2021)。

- [39] David S Wishart, Yannick D Feunang, An CGuo, Elvis J Lo, Ana Marcu, Jason R Grant, Tanvir Sajed, Daniel Johnson, Carin Li, Zinat Sayeeda 等。“DrugBank 5.0: 2018 年 DrugBank 数据库的重大更新”。见: 核酸研究 46.D1 (2018), 第 46 页。D1074–D1082。
- [40] 大卫·门德斯、安娜·高尔顿、帕特里夏·本托、乔恩·钱伯斯、玛琳·德·维吉、埃洛伊·费利克斯、玛丽亚·保拉·马加里尼奥斯、胡安·FMosquera、普鲁登斯·穆托沃、米哈乌·诺沃特卡、玛丽亚·戈迪略·马拉尼翁、菲奥娜·亨特、劳拉·洪科、格蕾丝·穆根巴特、米拉格罗斯·罗德里格斯·洛佩兹、弗朗西斯·阿特金森、尼古拉斯·Bosc、Chris J Radoux、Aldo Segura-Cabrera、Anne Hersey 和 Andrew R Leach。“ChEMBL: 走向生物测定数据的直接沉积”。见: 《核酸研究》47.D1 (2018 年 11 月), 第 D930–D940 页。ISSN: 0305-1048。DOI: 10.1093/nar/gky1075。电子打印: <https://academic.oup.com/nar/article-pdf/47/D1/D930/27437436/gky1075.pdf>。网址: <https://doi.org/10.1093/nar/gky1075>。
- [41] 简·H·詹森。“基于图的遗传算法和生成模型/蒙特卡罗树搜索探索化学空间”。见: 化学科学 10.12 (2019), 第 3567–3572 页。
- [42] 约翰·J·塔利、托马斯·D·潘宁、保罗·W·柯林斯、唐纳德·J·罗吉尔、詹姆斯·W·马莱查、朱莉·M·宫代、斯蒂芬·R·伯滕肖、伊什·K·卡纳、马修·J·格拉内托、罗兰·S·罗杰斯等人。用于治疗炎症的取代吡唑基苯磺酰胺。美国专利 5,760,068。1998 年 6 月。
- [43] 大卫·达尔格伦和汉斯·莱纳纳斯。“肠道渗透性和药物吸收: 预测实验、计算和体内方法”。见: 药剂学 11.8 (2019)。国际标准刊号: 1999-4923。DOI: 10.3390/药剂学11080411。网址: <https://www.mdpi.com/1999-4923/11/8/411>。
- [44] 戈登·古洛夫、让·伦森、西德尼·乌登弗兰德、约翰·W·达利、唐纳德·M·杰里纳和伯恩哈德·维特科普。“羟基化诱导的迁移: NIH 转变: 最近的实验揭示了芳香族化合物酶促羟基化的意外且普遍的结果。”见: 《科学》157.3796 (1967), 第 1524–1530 页。
- [45] 安德鲁·P·布拉德利。“ROC 曲线下面积在机器学习算法评估中的使用”。见: Pattern recognize30.7 (1997), 第 1145–1159 页。
- [46] 孙帆云, Jordan Hoffmann, Vikas Verma, 唐健。“信息图: 通过互信息最大化进行无监督和半监督图级表示学习”。见: 国际学习表征会议, ICLR. 2020。
- [47] Yuyang Wang, Jianren Wang, Zhonglin Cao, and Amir Barati Farimani。“Molclr: Molecular contrastive learning of representations via graph neural networks”。In: *arXiv preprint arXiv:2102.10056* (2021)。
- [48] 凯尔·洛、露西·王、马克·诺伊曼、罗德尼·金尼和丹·S·韦尔德。“S2ORC: 语义学者开放研究语料库”。见: arXiv 预印本 arXiv:1911.02782 (2019)。
- [49] 蒂格·斯特林和约翰·J·欧文。“ZINC 15——适合每个人的配体发现”。见: 化学信息与建模杂志 55.11(2015), 第 2324–2337 页。
- [50] 西蒙·阿克塞尔罗德和拉斐尔·戈麦斯·邦巴雷利。“GEOM, 用于属性预测和分子生成的能量注释分子构象”。见: 科学数据 9.1 (2022), 第 1-14 页。
- [51] 索拉布·阿加瓦尔。“癌症靶向治疗”。在: 自然评论。药物发现 9.6 (2010), p. 427。
- [53] 彼得·埃特尔、伊娃·阿尔特曼和杰弗里·M·麦肯纳。“生物活性分子中最常见的官能团以及它们的受欢迎程度如何随着时间的推移而演变”。见: 《药物化学杂志》63.15 (2020), 第 8408–8418 页。
- [54] 汉斯·约阿希姆·伯姆、亚历山大·弗洛尔和马丁·斯塔尔。“脚手架跳跃”。载于: 当今的药物发现: 技术 1.3 (2004), 第 14 页。217–224。
- [55] 叶胡, Dagmar Stumpfe, Jurgen Bajorath。“支架跳跃的最新进展: 微观视角”。见: 《药物化学杂志》60.4 (2017), 第 1238–1246 页。
- [56] 于尔根·德鲁斯。“药物发现: 历史视角”。见: 《科学》287.5460 (2000), 第 1960–1964 页。
- [57] 洛朗·戈麦斯。“药物化学决策: 我们直觉的力量”。见: ACS 药物化学快报 9.10 (2018), 第 956–958 页。
- [58] Albert Leo, Corwin Hansch, and David Elkins。“Partition coefficients and their uses”。In: *Chemical Reviews* 71.6 (1971), pp. 525–616. DOI: 10.1021/cr60274a001. eprint: <https://doi.org/10.1021/cr60274a001>. URL: <https://doi.org/10.1021/cr60274a001>。
- [59] G Richard Bickerton, Gaia V Paolini, Jérémy Besnard, Sorel Muresan 和 Andrew L Hopkins。“量化药物的化学美”。见: 《自然化学》4.2 (2012), 第 90-98 页。
- [60] 彼得·埃特尔、伯恩哈德·罗德和保罗·塞尔泽。“作为基于片段的贡献之和的分子极性表面积的快速计算及其在药物转运特性预测中的应用”。见: 《药物化学杂志》43.20 (2000). PMID: 11020286, 第 3714–3717 页。DOI: 10.1021/jm000942e。电子打印: <https://doi.org/10.1021/jm000942e>。网址: <https://doi.org/10.1021/jm000942e>。

[61]达科·布蒂娜。“基于 Daylight 指纹和 Tanimoto 相似度的无监督数据库聚类：一种快速、自动化的聚类小型和大型数据集的方法”。见：《化学信息与计算机科学杂志》39.4 (1999)，第 747–750 页。DOI: 10.1021/ci9803381。电子打印：https://doi.org/10.1021/ci9803381。网址：https://doi.org/10.1021/ci9803381。

[62] Shengchao Liu, Weili Nie, Chengpeng Wang, Jiarui Lu, Zhuoran Qiao, Ling Liu, Jian Tang, Chaowei Xiao, and Anima Anandkumar. “Multi-modal Molecule Structure-text Model for Text-based Editing and Retrieval”. In: (Aug. 2023). DOI: [10.5281/zenodo.8303265](https://doi.org/10.5281/zenodo.8303265).

ReadPaper.com

A.1 PubChemSTM 构建我们构建了一个名为 PubChemSTM 的化学结构-文本对数据集，该数据集是从 PubChem 数据库中提取的[1]。下面我们解释数据集构建的关键步骤。1. 我们使用 PUG View（一种 REST 风格的 Web 服务）来下载分子的文本描述。它总共有290页，每页都以XML格式下载。作为参考，可以在此处找到示例页面（第一页）。XML 数据中有一个“字符串”字段，我们将其视为分子的文本描述。构建完成后，我们拥有 250K 个分子（具有唯一的 PubChem ID）和 281K 个化学结构-文本对。请注意，每个分子可以有来自不同资源的多个注释。· 大多数分子注释以通用名称或国际纯粹与应用化学联合会 (IUPAC) 名称开头。我们可以使用原始描述（使用通用名称或IUPAC名称）或将其替换为文本模板（例如，“这个分子是...”）。· 因此，我们构建了两个版本的PubChemSTM数据集，PubChemSTM-raw和PubChemSTM-extracted，分别对应于使用原始注释或用文本提示替换分子名称。除了分子名称外，这两个版本的 PubChemSTM 共享分子。2. 我们从 PubChem FTP 服务下载 326 个 SDF 文件。每个SDF文件包含一批分子的结构信息（例如 SMILES字符串和分子图）。3. 我们使用 PubChemID 匹配前两个步骤中每个分子的注释和化学结构，并且第一步中的大多数分子都包含 SDF 文件中相应的化学结构。具体来说，只有 12个分子未能从SDF文件中找到有效的SMILES，我们忽略这些分子。4. 最终，遵循上述三个步骤将得到一个包含 281K 对和 250K 个独特分子的结构文本对数据集。请注意，PubChem 数据库 [1] 在线更新频繁，上述数字收集于 2022 年 3 月。

预处理详细信息 PubChem 数据库中有一个名为“名称”的字段，其中包括每个分子的通用名称或 IUPAC 名称。请注意，IUPAC 上的标记化并非易事。因此我们进行了两个版本来测试其效果，即 PubChemSTM-raw和PubChemSTM-extracted。我们发现 PubChemSTM-raw 中存在多种文本描述模式，这些模式被进一步用来提取更清晰版本的分子描述，如 PubChem-extract 中一样。详细说明如下：· 最常见的模式是分子注释以“XXX（名称）是/是/是/是/出现/发生/代表/属于/退出...”开头。我们手动提取它以获得大部分分子名称，并将其替换为“This molecular ...”或“These molecular ...”。· 额外的单词“Pure”。一些分子注释以“Pure xxx ...”开头，我们删除了“Pure”一词。· 拼写错误。例如，“Mercurycombines ...”应该是“Mercury Combines ...”。

数据集示例 我们在表 2 中提供了 PubChemSTM-raw 和 PubChemSTM-extracted 的四个示例。

可重复性 由于 PubChem 数据库 [1] 经常在线更新，因此我们提供了本工作中使用的所有预处理数据集，以实现可重复性。另外，还提供了上述步骤的源代码以供将来使用。

比较 如前所述，我们采用预训练的 SciBERT 模型 [2] 并继续在 PubChemSTM 上进行训练。SciBERT 是专门为科学发现而训练的 aBERT 模型。它从 Semantic Scholar [3] 中随机抽取了 114 万篇论文，其中大约 18% 的论文来自计算机科学领域，82% 的论文来自广泛的生物医学领域。其语料库有3.17B个token，词汇量为31K。此外，SciBERT 接受了整篇论文的训练，而不仅仅是摘要。一个潜在的问题是词汇从 Semantic Scholar 到 PubChemSTM 的转变。尽管我们在这项工作中采用了 SciBERT 的预训练检查点（连同其词汇表），但我们仍然希望仔细检查文本数据的词汇表。在表 3 中，我们列出了 PubChemSTM-raw 和 PubChemSTM-extract 的词汇表大小，采用三种标记化方法：使用空格、spaCy [4] 和 SciBERT 标记化器。我们可以观察到，与使用空格和 spaCy 的相比，使用 SciBERT 分词器的 PubChemSTM-raw 和 PubChemSTM-extract 之间的差异非常小。因此，我们想说词汇也是一个重要因素，SciBERT分词器已经表现出了相当稳定的分词效果。未来需要更全面的分词和词汇来推动这一研究路线，即为药物发现提供大语言模型。但这超出了本文的范围，需要整个社区的努力。

A.2 架构细节 我们有两个分支，化学结构分支 f_c 和文本描述分支 f_t。

表 2. PubChemSTM 上的示例。这里对于化学结构，我们只列出 SMILES 字符串，因为 2D 拓扑图可以是使用 RDKit 包获得。

PubChemSTM-raw	PubChemSTM-extracted
SMILES: <chem>c1ccccc1</chem>	
Benzene is a colorless liquid with a sweet odor. It evaporates into the air very quickly and dissolves slightly in water.	<i>This molecule is</i> a colorless liquid with a sweet odor. It evaporates into the air very quickly and dissolves slightly in water.
SMILES: <chem>Oc1ccccc1</chem>	
Phenol is both a manufactured chemical and a natural substance. It is a colorless-to-white solid when pure.	<i>This molecule is</i> both a manufactured chemical and a natural substance. It is a colorless-to-white solid when pure.
SMILES: <chem>CC(=O)Oc1ccccc1C(=O)O</chem>	
Acetylsalicylic acid appears as odorless white crystals or crystalline powder with a slightly bitter taste.	<i>This molecule appears</i> as odorless white crystals or crystalline powder with a slightly bitter taste.
SMILES: <chem>CC1(C)SC2C(NC(=O)Cc3ccccc3)C(=O)N2C1C(=O)O</chem>	
Benzylpenicillin is a penicillin in which the substituent at position 6 of the penam ring is a phenylacetamido group. It has a role as an antibacterial drug, an epitope and a drug allergen.	<i>This molecule is</i> a penicillin in which the substituent at position 6 of the penam ring is a phenylacetamido group. It has a role as an antibacterial drug, an epitope, and a drug allergen.

Table 3. The vocabulary comparison.

Data Source	Tokenization Method	size of vocabulary	overlap with SciBERT
Semantic Scholar (used in SciBERT)	SciBERT tokenizer	31,090	-
PubChemSTM-raw	white space	315,704	7,635
	spaCy	114,976	719
	SciBERT tokenizer	18,320	18,320
PubChemSTM-extract	white space	100,877	7,562
	spaCy	27,519	691
	SciBERT tokenizer	17,442	17,442

化学结构分支 f_c 这项工作考虑了两种类型的化学结构：SMILES 字符串将分子视为序列，而 2D 分子图分别将原子和键视为节点和边。然后基于化学结构，我们应用深度学习编码器 f_c 来获得潜在向量作为分子表示。具体来说，对于 SMILES 字符串，我们采用 MegaMolBART [5] 的编码器，该编码器在 ZINC 数据库 [6] 的 500M 分子上进行预训练。对于分子图，我们使用 GraphMVP 预训练 [8] 采用预训练的图同构网络 (GIN) [7]。GraphMVP 正在对来自 GEOM 数据集的 250K 构象进行 2D 拓扑和 3D 几何之间的多视图预训练[9]。因此，尽管我们没有明确利用 3D 几何形状，但最先进的预训练 GIN 模型可以隐式编码此类信息。

文本描述分支 文本描述分支提供了分子功能的高级描述。我们可以将此分支视为领域知识来加强分子表示。这些领域知识以自然语言的形式存在，我们使用 BERT 模型[10]作为文本编码器 f_t 。我们进一步调整了预训练的 SciBERT [2]，它是根据化学和生物领域的文本数据进行预训练的。

表 4. 型号规格。每个模型中的#个参数。

Branch	Model	# parameters
Chemical structure	MegaMolBART	10,010,635
	GIN	1,885,206
Textual description	SciBERT	109,918,464

A.3 预训练细节预训练目标 对于 MoleculeSTM 预训练，我们应用对比学习。更具体地说，我们选择 EBM-NCE [8] 和 InfoNCE [11] 之一。两者本质上都在做同样的事情，但 EBM-NCE 被发现更

对于图形数据有效 [8, 12]。EBM-NCE 的目标是：

$$\mathcal{L} = -\frac{1}{2} \left(\mathbb{E}_{\mathbf{x}_c, \mathbf{x}_t} [\log \sigma(E(\mathbf{x}_c, \mathbf{x}_t))] + \mathbb{E}_{\mathbf{x}_c, \mathbf{x}_t'} [\log(1 - \sigma(E(\mathbf{x}_c, \mathbf{x}_t')))] \right) - \frac{1}{2} \left(\mathbb{E}_{\mathbf{x}_c, \mathbf{x}_t} [\log \sigma(E(\mathbf{x}_c, \mathbf{x}_t))] + \mathbb{E}_{\mathbf{x}_c', \mathbf{x}_t} [\log(1 - \sigma(E(\mathbf{x}_c', \mathbf{x}_t)))] \right), \quad (6)$$

其中 $\mathbf{x} \times \mathbf{x} \times \mathbf{c}$ 和 $\mathbf{x} \times \mathbf{x} \times \mathbf{t}$ 形成每个分子的结构文本对，并且 $\mathbf{x} \times \mathbf{x} \times \mathbf{c}'$ 和 $\mathbf{x} \times \mathbf{x} \times \mathbf{t}'$ 是从噪声分布中随机采样的负样本，我们使用经验数据分布。 $E(\cdot)$ 是具有灵活公式的能量函数，我们使用联合学习空间上的点积，即 $E(\mathbf{x} \times \mathbf{x} \times \mathbf{c}, \mathbf{x} \times \mathbf{x} \times \mathbf{t}) = \langle \mathbf{p}_c \circ \mathbf{f}_c(\mathbf{x} \times \mathbf{x} \times \mathbf{c}), \mathbf{p}_t \circ \mathbf{f}_t(\mathbf{x} \times \mathbf{x} \times \mathbf{t}) \rangle$ 。同样，我们的 InfoNCE 目标是：

$$\mathcal{L} = -\frac{1}{2} \mathbb{E} \left[\log \frac{\exp(E(\mathbf{x}_c, \mathbf{x}_t))}{\exp(E(\mathbf{x}_c, \mathbf{x}_t)) + \sum_{\mathbf{x}_t'} \exp(E(\mathbf{x}_c, \mathbf{x}_t'))} + \log \frac{\exp(E(\mathbf{x}_c, \mathbf{x}_t))}{\exp(E(\mathbf{x}_c, \mathbf{x}_t)) + \sum_{\mathbf{x}_c'} \exp(E(\mathbf{x}_c', \mathbf{x}_t))} \right]. \quad (7)$$

超参数 我们列出了用于 MoleculeSTM 预训练的关键超参数，分别以 SMILES 字符串和 2D 分子图作为输入。

Table 5. Hyperparameter specifications for MoleculeSTM pretraining.

Input	Hyperparameter	Value
SMILES string	epochs	{32}
	learning rate for text branch	{1e-4}
	learning rate for chemical structure branch	{1e-5, 3e-5}
	objective function	{ EBM-NCE, InfoNCE }
2D molecular graph	epochs	{32}
	learning rate for text branch	{1e-4}
	learning rate for chemical structure branch	{1e-5, 3e-5}
	objective function	{ EBM-NCE, InfoNCE }

运行时间 我们列出了 MoleculeSTM 的运行时间，分别以 SMILES 字符串和 2D 分子图作为输入。

Table 6. Running time for MoleculeSTM pretraining.

Input	Running Time
SMILES string	44min / epoch
2D molecular graph	42min / epoch

B 下游任务的设计原则

在本节中，我们讨论设计下游任务时的关键原则。

适用评估视觉语言领域的基础模型与我们的MoleculeSTM最大的区别之一可以体现在评估上。大多数视觉和语言任务可以被视为艺术问题，即不存在适用于评估的标准且精确的解决方案。例如，我们可以检测图像是否是“骑马的宇航员”或“熊猫制作拿铁艺术”[13]，但仅在视觉上而不是在计算上，这阻碍了大规模评估。药物发现的情况并非如此，因为它是一项科学任务，可以在体外或计算机中准确评估结果（例如，编辑任务中输出分子的特性）。此后，物理实验通常昂贵且持久，因此在这项工作中，我们希望重点关注计算上可行的评估任务。

模糊匹配 特别对于分子编辑任务，文本提示应遵循“模糊匹配”标准，因为可能存在多个输出分子。这与“精确匹配”相矛盾，“精确匹配”中输出分子是确定性的。例如，对于官能团的变化，我们可以输入“将环中的第三个氮原子改为氧原子”之类的提示。这个提示非常明确，并有精确的解决方案，并且存在基于规则的化学工具来完美地处理这个问题。因此，基于文本的编辑无法在这个赛道上展现出它的优势。相反，基于文本的编辑可以通过在潜在空间中在语义上有意义的方向上徘徊，在模糊匹配设置中提供更多好处。这也反映了我们一直关注的语言模型的开放词汇属性。

C.1 数据集构建 DrugBank 数据库 [14] 有许多对于探索药物发现任务可能很有趣的领域。这里我们为零次检索任务提取每种小分子药物的三个字段：描述字段、药效学字段和解剖治疗化学（ATC）字段，详细信息如下：· DrugBank-描述。描述字段对药物的化学性质、历史和监管状态进行了高级审查。· DrugBank-药效学。这说明了药物如何改变或影响其所用的生物体。该字段可能包括体内所需和不需要的影响（也称为副作用）。· DrugBank-ATC。解剖治疗化学品（ATC）是一个分类系统，根据分子作用的器官或系统及其治疗、药理学和化学特性将分子分为不同的组。我们列出数据集构建的关键步骤如下：1. 我们从网站下载完整的 DrugBank 数据库（XML 格式）和小型化学结构文件（SDF 格式）。2. 我们解析 XML 文件，并提取包含三个字段的数据：描述、药效学和 ATC。3. 我们将提取的文件映射到 SDF 文件中的化学结构。对于 DrugBank-Description 和 DrugBank-Pharmacodynamics 数据集，我们排除了 PubChemSTM 中显示的分子，并使用 canonicalSMILES 进行过滤。同时，对于 DrugBank-ATC，我们排除同时满足以下两个标准的分子：· 化学结构过滤 如果具有相同规范 SMILES 的分子已出现在 PubChemSTM 中；· 文本数据过滤 我们首先需要定义两个文本数据之间的相似性，如方程（8），其中文本 DrugBank 和文本 PubChemSTM 分别是来自 DrugBank 和 PubChemSTM 的同一分子的文本数据， $\text{len}()$ 是长度文本数据的编辑距离， $\text{Levenshtein}()$ 是两个文本数据之间的编辑距离。因此，第二个条件是：如果 DrugBank 文本和 PubChemSTM 文本之间的相似度高某个阈值（例如 0.6）。另一个细节是，对于 DrugBank-ATC，每个小分子存在多个 ATC 字段（文本 DrugBank）。在 PubChemSTM 中，每个分子还存在多个文本描述（文本 PubChemSTM）。因此，在文本数据过滤步骤中，对于 DrugBank 和 PubChemSTM 之间的每个共享分子，我们计算所有文本 DrugBank - 文本 PubChemSTM 对的相似度，如果存在相似度高于阈值 0.6.4 的一对，则排除该分子。一些基本的数据集统计数据可以在表 7 中找到。请注意，ATC 有很多级别，我们在这项工作中使用级别 5 进行检索。

$$\frac{\text{Levenshtein}(\text{textDrugBank}, \text{textPubChemSTM})}{\text{len}(\text{textDrugBank})} \quad (8)$$

表7. DrugBank中三个字段的统计信息。上面已经说明了过滤步骤。

Field	# structure-text pairs molecule not in PubChemSTM	# structure-text pairs molecule shared in PubChemSTM but text similarity below 0.6	total
DrugBank-Description	1,154	—	1,154
DrugBank-Pharmacodynamics	1,005	—	1,005
DrugBank-ATC	1,507	1,500	3,007

C.2 实验为了实验，我们在正文中引入了三个基线。作为概念验证，我们执行另一个称为随机的基线。对于随机，两个编码器（f c 和 f t）都是随机初始化的。三个数据集的零样本检索结果如表8至表10所示。

表 8. DrugBank-Description T-选一检索的准确性 (%)。

	T	Given Chemical Structure			Given Text		
		4	10	20	4	10	20
SMILES	Random	24.59 $\pm$ 1.14	10.12 $\pm$ 1.38	4.97 $\pm$ 0.42	24.54 $\pm$ 0.97	9.97 $\pm$ 0.81	5.09 $\pm$ 0.37
	Frozen	25.07 $\pm$ 1.24	10.22 $\pm$ 1.19	5.12 $\pm$ 0.65	24.69 $\pm$ 1.87	10.20 $\pm$ 1.38	5.37 $\pm$ 1.15
	Similarity	36.35 $\pm$ 0.59	23.22 $\pm$ 0.58	16.40 $\pm$ 0.59	22.74 $\pm$ 0.24	10.31 $\pm$ 0.24	5.34 $\pm$ 0.24
	KV-PLM	73.80 $\pm$ 0.00	53.96 $\pm$ 0.29	40.07 $\pm$ 0.38	72.86 $\pm$ 0.00	52.55 $\pm$ 0.29	40.33 $\pm$ 0.00
	MoleculeSTM	97.50 $\pm$ 0.46	94.18 $\pm$ 0.46	91.12 $\pm$ 0.46	98.21 $\pm$ 0.00	94.54 $\pm$ 0.37	91.97 $\pm$ 0.46
Graph	Random	25.78 $\pm$ 1.43	10.71 $\pm$ 0.97	4.83 $\pm$ 1.00	24.98 $\pm$ 0.32	10.20 $\pm$ 0.40	4.80 $\pm$ 0.21
	Frozen	24.01 $\pm$ 1.34	9.39 $\pm$ 0.92	4.85 $\pm$ 0.52	24.00 $\pm$ 1.66	9.91 $\pm$ 0.71	5.07 $\pm$ 0.75
	Similarity	30.03 $\pm$ 0.38	13.63 $\pm$ 0.27	7.07 $\pm$ 0.10	24.81 $\pm$ 0.27	10.22 $\pm$ 0.24	4.74 $\pm$ 0.24
	MoleculeSTM	99.15 $\pm$ 0.00	97.19 $\pm$ 0.00	95.66 $\pm$ 0.00	99.05 $\pm$ 0.37	97.50 $\pm$ 0.46	95.71 $\pm$ 0.46

表 9. DrugBank-药效学 T 选择一检索的准确性 (%)。

	T	Given Chemical Structure			Given Text		
		4	10	20	4	10	20
SMILES	Random	24.49 $\pm$ 0.68	9.73 $\pm$ 0.34	5.14 $\pm$ 0.57	25.61 $\pm$ 0.62	10.10 $\pm$ 0.91	5.07 $\pm$ 0.69
	Frozen	25.47 $\pm$ 1.12	10.55 $\pm$ 0.75	5.48 $\pm$ 0.70	25.34 $\pm$ 0.41	9.86 $\pm$ 0.44	4.84 $\pm$ 0.26
	Similarity	27.85 $\pm$ 0.03	10.75 $\pm$ 0.02	5.67 $\pm$ 0.01	24.58 $\pm$ 0.03	11.25 $\pm$ 0.03	5.29 $\pm$ 0.02
	KV-PLM	68.38 $\pm$ 0.03	47.59 $\pm$ 0.03	36.54 $\pm$ 0.03	67.68 $\pm$ 0.03	48.00 $\pm$ 0.02	34.66 $\pm$ 0.02
	MoleculeSTM	88.07 $\pm$ 0.01	81.70 $\pm$ 0.02	75.94 $\pm$ 0.02	88.46 $\pm$ 0.01	81.01 $\pm$ 0.02	74.64 $\pm$ 0.03
Graph	Random	26.00 $\pm$ 0.37	9.65 $\pm$ 0.88	4.95 $\pm$ 0.36	25.11 $\pm$ 0.63	9.99 $\pm$ 0.62	4.82 $\pm$ 0.54
	Frozen	25.49 $\pm$ 1.82	10.19 $\pm$ 1.47	4.74 $\pm$ 0.56	25.55 $\pm$ 0.45	10.15 $\pm$ 0.77	4.88 $\pm$ 0.55
	Similarity	25.33 $\pm$ 0.27	9.89 $\pm$ 0.52	4.61 $\pm$ 0.08	25.28 $\pm$ 0.03	10.64 $\pm$ 0.02	5.47 $\pm$ 0.02
	MoleculeSTM	92.14 $\pm$ 0.02	86.27 $\pm$ 0.02	81.08 $\pm$ 0.05	91.44 $\pm$ 0.02	86.76 $\pm$ 0.03	81.68 $\pm$ 0.03

Table 10. Accuracy (%) of molecule-ATC T-choose-one retrieval.

	T	Given Chemical Structure			Given Text		
		4	10	20	4	10	20
SMILES	Random	25.03 $\pm$ 0.33	9.83 $\pm$ 0.19	4.80 $\pm$ 0.22	25.44 $\pm$ 1.21	10.03 $\pm$ 0.94	5.11 $\pm$ 0.79
	Frozen	25.05 $\pm$ 0.94	10.17 $\pm$ 0.63	4.99 $\pm$ 0.54	25.35 $\pm$ 0.78	10.32 $\pm$ 0.44	5.22 $\pm$ 0.34
	Similarity	30.03 $\pm$ 0.00	13.35 $\pm$ 0.02	7.53 $\pm$ 0.02	26.74 $\pm$ 0.03	11.01 $\pm$ 0.00	5.62 $\pm$ 0.00
	KV-PLM	60.94 $\pm$ 0.00	42.35 $\pm$ 0.00	30.32 $\pm$ 0.00	60.67 $\pm$ 0.00	40.19 $\pm$ 0.00	29.02 $\pm$ 0.00
	MoleculeSTM	70.84 $\pm$ 0.07	56.75 $\pm$ 0.05	46.12 $\pm$ 0.07	73.07 $\pm$ 0.03	58.19 $\pm$ 0.03	48.97 $\pm$ 0.06
Graph	Random	24.48 $\pm$ 0.66	9.97 $\pm$ 0.25	4.81 $\pm$ 0.34	25.48 $\pm$ 0.59	10.40 $\pm$ 0.37	5.38 $\pm$ 0.30
	Frozen	24.19 $\pm$ 0.77	10.24 $\pm$ 0.71	4.87 $\pm$ 0.47	24.95 $\pm$ 1.52	10.07 $\pm$ 0.80	5.06 $\pm$ 0.36
	Similarity	29.46 $\pm$ 0.00	12.34 $\pm$ 0.00	6.52 $\pm$ 0.00	25.78 $\pm$ 1.53	10.23 $\pm$ 0.70	5.06 $\pm$ 0.67
	MoleculeSTM	69.33 $\pm$ 0.03	54.83 $\pm$ 0.04	44.13 $\pm$ 0.05	71.81 $\pm$ 0.05	58.34 $\pm$ 0.07	47.58 $\pm$ 0.05

C.3 消融研究：固定预训练编码器在主体部分，我们采用预训练的单模态检查点进行预训练，即 f c 的 GraphMVP 和 MegaMolBART，以及 f t 的 SciBERT。然后对于 MoleculeSTM 预训练，我们使用对比学习并更新所有模型参数。在这里，我们通过仅优化两个分支（pc, pt）的联合空间的投影层来进行消融研究，同时保持两个编码器（fc, ft）固定。三个数据集的结果如表 11 至表 13 所示。

Table 11. Accuracy (%) of DrugBank-Description *T*-choose-one retrieval.

T		Given Chemical Structure			Given Text		
		4	10	20	4	10	20
SMILES	Random	24.59 ± 1.14	10.12 ± 1.38	4.97 ± 0.42	24.54 ± 0.97	9.97 ± 0.81	5.09 ± 0.37
	Frozen	25.07 ± 1.24	10.22 ± 1.19	5.12 ± 0.65	24.69 ± 1.87	10.20 ± 1.38	5.37 ± 1.15
	Similarity	36.35 ± 0.59	23.22 ± 0.58	16.40 ± 0.59	22.74 ± 0.24	10.31 ± 0.24	5.34 ± 0.24
	MoleculeSTM	47.64 ± 0.40	29.21 ± 0.47	19.69 ± 0.47	52.60 ± 0.46	32.24 ± 0.37	21.45 ± 0.37
Graph	Random	25.78 ± 1.43	10.71 ± 0.97	4.83 ± 1.00	24.98 ± 0.32	10.20 ± 0.40	4.80 ± 0.21
	Frozen	24.01 ± 1.34	9.39 ± 0.92	4.85 ± 0.52	24.00 ± 1.66	9.91 ± 0.71	5.07 ± 0.75
	Similarity	30.03 ± 0.38	13.63 ± 0.27	7.07 ± 0.10	24.81 ± 0.27	10.22 ± 0.24	4.74 ± 0.24
	MoleculeSTM	51.28 ± 0.00	31.99 ± 0.41	20.71 ± 0.47	55.27 ± 0.00	33.08 ± 0.00	21.77 ± 0.00

表 12. DrugBank-药效学 *T*-选择一检索的准确性 (%)。

T		Given Chemical Structure			Given Text		
		4	10	20	4	10	20
SMILES	Random	24.49 ± 0.68	9.73 ± 0.34	5.14 ± 0.57	25.61 ± 0.62	10.10 ± 0.91	5.07 ± 0.69
	Frozen	25.47 ± 1.12	10.55 ± 0.75	5.48 ± 0.70	25.34 ± 0.41	9.86 ± 0.44	4.84 ± 0.26
	Similarity	27.85 ± 0.03	10.75 ± 0.02	5.67 ± 0.01	24.58 ± 0.03	11.25 ± 0.03	5.29 ± 0.02
	MoleculeSTM	46.43 ± 0.00	27.42 ± 0.47	18.24 ± 0.47	52.53 ± 0.41	30.53 ± 0.00	19.98 ± 0.00
Graph	Random	26.00 ± 0.37	9.65 ± 0.88	4.95 ± 0.36	25.11 ± 0.63	9.99 ± 0.62	4.82 ± 0.54
	Frozen	25.49 ± 1.82	10.19 ± 1.47	4.74 ± 0.56	25.55 ± 0.45	10.15 ± 0.77	4.88 ± 0.55
	Similarity	25.33 ± 0.27	9.89 ± 0.52	4.61 ± 0.08	25.28 ± 0.03	10.64 ± 0.02	5.47 ± 0.02
	MoleculeSTM	46.29 ± 0.03	27.18 ± 0.02	17.73 ± 0.02	50.95 ± 0.04	31.65 ± 0.03	23.00 ± 0.03

表 13. DrugBank-ATC *T* 选择一检索的准确度 (%)。

T		Given Chemical Structure			Given Text		
		4	10	20	4	10	20
SMILES	Random	25.03 ± 0.33	9.83 ± 0.19	4.80 ± 0.22	25.44 ± 1.21	10.03 ± 0.94	5.11 ± 0.79
	Frozen	25.05 ± 0.94	10.17 ± 0.63	4.99 ± 0.54	25.35 ± 0.78	10.32 ± 0.44	5.22 ± 0.34
	Similarity	30.03 ± 0.00	13.35 ± 0.02	7.53 ± 0.02	26.74 ± 0.03	11.01 ± 0.00	5.62 ± 0.00
	MoleculeSTM	43.41 ± 0.12	25.66 ± 0.06	15.69 ± 0.06	48.75 ± 0.11	29.44 ± 0.06	19.75 ± 0.03
Graph	Random	24.48 ± 0.66	9.97 ± 0.25	4.81 ± 0.34	25.48 ± 0.59	10.40 ± 0.37	5.38 ± 0.30
	Frozen	24.19 ± 0.77	10.24 ± 0.71	4.87 ± 0.47	24.95 ± 1.52	10.07 ± 0.80	5.06 ± 0.36
	Similarity	29.46 ± 0.00	12.34 ± 0.00	6.52 ± 0.00	25.78 ± 1.53	10.23 ± 0.70	5.06 ± 0.67
	MoleculeSTM	42.53 ± 0.07	24.34 ± 0.00	14.78 ± 0.03	48.91 ± 0.03	28.77 ± 0.07	19.28 ± 0.07

分子编辑或可控分子生成是指基于给定的、预先训练的分子生成模型来改变分子的结构。在这项工作中，借助 MoleculeSTM 中的大型语言模型，我们能够进行基于文本的零样本分子编辑。首先，我们想列出两个关键挑战，比较视觉域和分子域之间的编辑任务，如下：

- 主干生成模型。对于视觉领域，基于StyleGAN [15]（一种良好解缠结的骨干模型）的图像可控生成是相当可行的。然而，这对于深层分子生成模型来说并非易事。最近的工作 GraphCG[16]探索了基于图的可控分子生成方法的解缠结特性，结论是，尽管主干生成模型没有完全解缠结，但仍然存在对分子图或点云等高度结构化数据进行可控生成的方法。同时，开发一种新颖的解缠结分子生成模型超出了本工作的范围，因为MoleculeSTM 的编辑解决方案与模型无关，并且可以轻松推广到未来的模型。
- 评估。图像可控生成是一个艺术问题，即它是主观的并且可以有多个（甚至无限多个）答案。相反，可控分子的产生是一个科学问题，即它是客观的并且只有少数答案。这已在附录 B 中讨论。

D.1 实验设置实现细节由于大多数模块都是固定的，我们只需要学习适配器模块和优化后的潜在代码 w 。两个关键的超参数是学习率 $\{1e-2, 1e-3\}$ 和 $\lambda \in \{1e1, 1e0, 1e-1, 1e-2, 1e-3\}$ 。作为公平比较，对于基线，我们采用 $w = w_{in} + \alpha \cdot D$ 的形式，其中 D 是使用随机、PCA 和方差获得的，并且 $\lambda \in \{1.0, 1.5, 2.0, 2.5, 3.0\}$ 。对于GS，我们对每个输入分子重复随机采样五次。接下来，我们将对四种类型的编辑任务以及三个案例研究进行零样本基于文本的分子编辑，如下所述：

- 附录D.2 中的单目标分子编辑（八个任务）。
- 附录D.3 中的多目标分子编辑（六个任务）。
- 附录D.4 中的基于结合亲和力的分子编辑（六个任务）。
- 附录D.5 中的药物相关性编辑（四个任务）。
- 附录D.6中专利药物分子的邻域搜索（三个案例研究）。

由于页数限制，我们在正文中仅展示了四个多目标和四个基于结合亲和力的编辑任务。这里我们展示了更全面的结果。我们要提到的是，对于单目标和多目标编辑，我们从 ZINC 中随机选择 200 个分子作为输入分子。这 200 个输入分子均未出现在 PubChemSTM 中。此外，随机选择过程确保了这 200 个分子的属性分布与整个数据集保持一致。下面（图 6 和图 7）示出了分子特性的三个示例：LogP（测量水溶性）、tPSA（测量渗透性）和分子量。




Figure 6. Three property distributions on 200 randomly sampled molecules for editing.




Figure 7. Three property distributions on 250K molecules from ZINC250K.

D.2 单目标分子编辑我们首先考虑分子编辑的八个单目标属性。如方法部分所示，满意度函数和阈值 Delta 的定义具体基于每个任务，如下：

- 我们使用LogP 来评估溶解度和不溶解度。我们取0和0.5作为不同的阈值。
- 我们使用QED来评估药物相似性。我们取0和0.1作为不同的阈值。
- 我们使用tPSA来评估高渗透率和低渗透率。我们取0和10作为不同的阈值。
- 对于氢键受体（HBA）和氢键供体（HBD），我们可以直接在分子中计数，我们使用0和1作为不同的阈值。对于 Delta，它是只有高于它才能被视为命中的阈值。因此 Delta 越大意味着编辑标准越严格。下面我们展示了8个单目标性质分子编辑结果的定量和定性结果。

表 14. 八个单目标分子编辑的结果。输入是从 ZINC 中随机采样的 200 个分子，

评估是属性变化的命中率。潜在的优化是使用 MoleculeSTM 进行基于文本的分子编辑，分别使用 SMILES 字符串和分子图。

	Δ	baseline				latent optimization	
		Random	PCA	High Variance	GS-Mutate	SMILES	Graph
This molecule is <i>soluble in water</i> .	0	35.33 $\pm$ 1.31	33.80 $\pm$ 3.63	33.52 $\pm$ 3.75	52.00 $\pm$ 0.41	61.87 $\pm$ 2.67	67.86 $\pm$ 3.46
	0.5	11.04 $\pm$ 2.40	10.66 $\pm$ 3.24	10.86 $\pm$ 2.56	14.67 $\pm$ 0.62	49.02 $\pm$ 1.84	54.44 $\pm$ 3.99
This molecule is <i>insoluble in water</i> .	0	43.36 $\pm$ 3.06	39.36 $\pm$ 2.55	42.89 $\pm$ 2.36	47.50 $\pm$ 0.41	52.71 $\pm$ 1.67	64.79 $\pm$ 2.76
	0.5	19.75 $\pm$ 1.56	15.12 $\pm$ 2.93	18.22 $\pm$ 0.33	12.50 $\pm$ 0.82	30.47 $\pm$ 3.26	47.09 $\pm$ 3.42
This molecule is <i>like a drug</i> .	0	38.06 $\pm$ 2.57	33.99 $\pm$ 3.72	36.20 $\pm$ 4.34	28.00 $\pm$ 0.71	36.52 $\pm$ 2.46	39.97 $\pm$ 4.32
	0.1	5.27 $\pm$ 0.24	3.97 $\pm$ 0.10	4.44 $\pm$ 0.58	6.33 $\pm$ 2.09	8.81 $\pm$ 0.82	14.06 $\pm$ 3.18
This molecule is <i>not like a drug</i> .	0	36.96 $\pm$ 2.25	35.17 $\pm$ 2.61	39.99 $\pm$ 0.57	71.33 $\pm$ 0.85	58.59 $\pm$ 1.01	77.62 $\pm$ 2.80
	0.1	6.16 $\pm$ 1.87	5.26 $\pm$ 0.95	7.56 $\pm$ 0.29	27.67 $\pm$ 3.79	37.56 $\pm$ 1.76	54.22 $\pm$ 3.12
This molecule has <i>high permeability</i> .	0	25.23 $\pm$ 2.13	21.36 $\pm$ 0.79	21.98 $\pm$ 3.77	22.00 $\pm$ 0.82	57.74 $\pm$ 0.60	59.84 $\pm$ 0.78
	10	17.41 $\pm$ 1.43	14.52 $\pm$ 0.80	14.66 $\pm$ 2.13	6.17 $\pm$ 0.62	47.51 $\pm$ 1.88	50.42 $\pm$ 2.73
This molecule has <i>low permeability</i> .	0	16.79 $\pm$ 2.54	15.48 $\pm$ 2.40	17.10 $\pm$ 1.14	28.83 $\pm$ 1.25	34.13 $\pm$ 0.59	31.76 $\pm$ 0.97
	10	11.02 $\pm$ 0.71	10.62 $\pm$ 1.86	12.01 $\pm$ 1.01	15.17 $\pm$ 1.03	26.48 $\pm$ 0.97	19.76 $\pm$ 1.31
This molecule has <i>more hydrogen bond acceptors</i> .	0	12.64 $\pm$ 1.64	10.85 $\pm$ 2.29	11.78 $\pm$ 0.15	21.17 $\pm$ 3.09	54.01 $\pm$ 5.26	37.35 $\pm$ 0.79
	1	0.69 $\pm$ 0.01	0.90 $\pm$ 0.84	0.67 $\pm$ 0.01	1.83 $\pm$ 0.47	27.33 $\pm$ 2.62	16.13 $\pm$ 2.87
This molecule has <i>more hydrogen bond donors</i> .	0	2.97 $\pm$ 0.61	3.97 $\pm$ 0.55	6.23 $\pm$ 0.66	19.50 $\pm$ 2.86	28.55 $\pm$ 0.76	60.97 $\pm$ 5.09
	1	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	1.33 $\pm$ 0.24	7.69 $\pm$ 0.56	32.35 $\pm$ 2.57

表 15. 基于文本的溶解度编辑可视化，通过辛醇-水分配系数 (LogP) 的对数测量

分子。一般来说，LogP 较小的分子更易溶于水。为了生成可溶于水的分子，我们可以添加极性成分（例如氧和氮），去除疏水部分（例如苯和环己烷），或用输入分子中的极性官能团替换疏水基团。为了生成不溶于水的分子，我们可以对输入分子进行相反的修改。粉色和蓝色区域分别突出显示输入和输出分子中的修改结构。













Text Prompt: This molecule is <i>soluble in water</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
 LogP: 3.66	 LogP: 3.05	 LogP: 3.72	 LogP: 2.56	 LogP: 4.25	 LogP: 2.76
Text Prompt: This molecule is <i>insoluble in water</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
 LogP: 3.66	 LogP: 5.03	 LogP: -0.36	 LogP: 0.72	 LogP: 2.37	 LogP: 4.41

表 16. 基于文本的渗透性编辑可视化，通过分子的拓扑极性表面积 (tPSA) 进行测量。

一般来说，tPSA 较小的分子渗透性更强。为了生成具有高渗透性的分子，我们可以从输入分子中去除具有高极性的官能团或杂环，例如酰胺、磺酰胺、脲、硝基和含氮芳烃。为了生成低渗透性的分子，我们可以对输入分子进行相反的修改。粉色和蓝色区域分别突出显示输入和输出分子中的修改结构。

























Text Prompt: This molecule has <i>high permeability</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
tPSA: 104	tPSA: 87	tPSA: 96	tPSA: 68	tPSA: 76	tPSA: 20
Text Prompt: This molecule has <i>low permeability</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
tPSA: 104	tPSA: 116	tPSA: 42	tPSA: 67	tPSA: 20	tPSA: 46

表 17. 氢键受体 (HBA) 和氢键供体 (HBD) 基于文本的编辑的可视化。用于生成

对于具有更多 HBA 的分子，我们可以在输入分子中添加杂原子，例如氧、氮和硫，或用含杂原子的结构基序替换现有基团。为了生成含有更多 HBD 的分子，我们可以添加带有氢的杂原子，例如胺等官能团和吡咯等杂环。粉色和蓝色区域分别突出显示输入和输出分子中的修改结构。

Text Prompt: This molecule has <i>more hydrogen bond acceptors</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
HBA: 6	HBA: 7	HBA: 5	HBA: 6	HBA: 3	HBA: 5
Text Prompt: This molecule has <i>more hydrogen bond donors</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
HBD: 2	HBD: 3	HBD: 2	HBD: 3	HBD: 1	HBD: 2

D.3 多目标分子编辑 然后我们考虑分子编辑的六个多目标属性。如方法部分所示，满意度函数和阈值 Delta 的定义具体基于每个任务。首先，对于每个单目标，我们遵循附录D.2中的评估指标，包括溶解度、渗透性以及HBA和HBD的数量。然后，对于多目标评估，我们考虑两种情况：· 具有宽松阈值的简单情况，例如溶解度和渗透率同时为阈值 0 和 0。· 具有严格阈值的挑战性情况，例如溶解度和 HBA/HBD 同时为阈值 0.5 和 1，以及溶解度和渗透性同时为阈值 0.5 和 10。那么成功的命中需要同时满足这两个条件。下面我们展示了六个多目标特性分子编辑结果的定量和定性结果。

表 18. 六种多目标分子编辑的结果。输入是从 ZINC 中随机采样的 200 个分子，评估

是属性变化的命中率。潜在的优化是使用 MoleculeSTM 进行基于文本的分子编辑，分别使用 SMILES 字符串和分子图。

	Δ	baseline				latent optimization	
		Random	PCA	High Variance	GS-Mutate	SMILES	Graph
This molecule is <i>soluble in water</i> and has <i>more hydrogen bond acceptors</i> .	0 – 0	9.88 $\pm$ 1.03	8.64 $\pm$ 2.06	9.09 $\pm$ 1.25	14.00 $\pm$ 2.48	27.87 $\pm$ 3.86	27.43 $\pm$ 3.41
	0.5 – 1	0.23 $\pm$ 0.33	0.45 $\pm$ 0.64	0.22 $\pm$ 0.31	0.67 $\pm$ 0.62	8.80 $\pm$ 0.04	11.10 $\pm$ 1.80
This molecule is <i>insoluble in water</i> and has <i>more hydrogen bond acceptors</i> .	0 – 0	2.99 $\pm$ 0.38	2.00 $\pm$ 0.58	2.45 $\pm$ 0.67	7.17 $\pm$ 0.85	8.55 $\pm$ 2.75	8.21 $\pm$ 0.81
	0.5 – 1	0.45 $\pm$ 0.32	0.00 $\pm$ 0.00	0.22 $\pm$ 0.31	0.17 $\pm$ 0.24	2.93 $\pm$ 0.30	0.00 $\pm$ 0.00
This molecule is <i>soluble in water</i> and has <i>more hydrogen bond donors</i> .	0 – 0	2.28 $\pm$ 1.15	2.23 $\pm$ 1.16	4.44 $\pm$ 0.58	13.83 $\pm$ 2.95	33.51 $\pm$ 4.08	49.23 $\pm$ 1.71
	0.5 – 1	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	9.98 $\pm$ 1.03	23.94 $\pm$ 1.09
This molecule is <i>insoluble in water</i> and has <i>more hydrogen bond donors</i> .	0 – 0	0.69 $\pm$ 0.58	1.96 $\pm$ 0.87	1.79 $\pm$ 0.66	5.67 $\pm$ 0.62	17.03 $\pm$ 2.75	14.42 $\pm$ 3.43
	0.5 – 1	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	2.59 $\pm$ 1.14	3.84 $\pm$ 0.71
This molecule is <i>soluble in water</i> and has <i>high permeability</i> .	0 – 0	5.06 $\pm$ 1.21	3.53 $\pm$ 0.38	4.88 $\pm$ 2.21	8.17 $\pm$ 1.03	35.69 $\pm$ 3.19	39.74 $\pm$ 2.26
	0.5 – 10	1.16 $\pm$ 0.68	0.67 $\pm$ 0.55	0.66 $\pm$ 0.54	0.00 $\pm$ 0.00	19.15 $\pm$ 0.73	22.66 $\pm$ 1.90
This molecule is <i>soluble in water</i> and has <i>low permeability</i> .	0 – 0	12.17 $\pm$ 1.05	10.43 $\pm$ 2.88	13.08 $\pm$ 2.28	19.83 $\pm$ 2.46	44.35 $\pm$ 0.68	30.87 $\pm$ 0.62
	0.5 – 10	6.20 $\pm$ 0.64	6.23 $\pm$ 2.31	6.67 $\pm$ 0.53	4.83 $\pm$ 0.85	28.67 $\pm$ 2.22	20.06 $\pm$ 1.26

表 19. 基于文本的多目标（组合性）属性编辑的可视化：溶解度和氢键供体（HBD）、

通过 LogP 和分子的 HBD 数量来测量。具有更多 HBD 的分子也可能溶于水，例如用极性基团或输入分子中含有氢杂原子的环（醇、氮杂吡啶、羧酸等）取代疏水基团（苯、噻吩、溴化物等）。尽管如此，我们可以在输入分子中添加HBD，同时降低其溶解度，例如用输入分子中亲水性较低的HBD（吡啶、硫醇等）替换高极性结构基序（酰胺、内酯等）。粉色和蓝色区域分别突出显示输入和输出分子中的修饰结构。

























Text Prompt: This molecule is <i>soluble in water</i> and has <i>more hydrogen bond donors</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
LogP: 4.67, HBD: 1	LogP: 2.29, HBD: 2	LogP: 2.15, HBD: 1	LogP: 1.41, HBD: 2	LogP: 1.79, HBD: 1	LogP: 0.43, HBD: 3
Text Prompt: This molecule is <i>insoluble in water</i> and has <i>more hydrogen bond donors</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
LogP: 1.56, HBD: 1	LogP: 2.42, HBD: 2	LogP: 3.26, HBD: 1	LogP: 3.64, HBD: 2	LogP: 3.10, HBD: 2	LogP: 5.00, HBD: 3

表 20. 基于文本的编辑对多目标（组合性）属性的可视化：溶解度和渗透性，通过测量

分子的 LogP 和 tPSA。具有低渗透性的分子也可能溶于水，例如针对输入分子添加极性官能团（例如酰胺、胺）和去除碳氢化合物（例如甲基、苯基）。然而，我们可以增加分子的溶解度和渗透性，例如同时去除碳氢化合物和极性部分或减小输入分子中杂环的大小（例如，[1,2]恶唑并[5,4-b]吡啶到咪唑）。粉色和蓝色区域分别突出显示输入和输出分子中的修改结构。

Text Prompt: This molecule is <i>soluble in water</i> and has <i>low permeability</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
LogP: 0.55, tPSA: 71	LogP: -0.34, tPSA: 100	LogP: 2.70, tPSA: 71	LogP: 2.39, tPSA: 82	LogP: 3.70, tPSA: 93	LogP: 1.62, tPSA: 119

Text Prompt: This molecule is <i>soluble in water</i> and has <i>high permeability</i> .					
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
LogP: 4.46, tPSA: 76	LogP: 3.21, tPSA: 47	LogP: 2.51, tPSA: 84	LogP: 1.82, tPSA: 55	LogP: 3.50, tPSA: 68	LogP: 2.38, tPSA: 58

D.4 基于结合亲和力的分子编辑我们进一步在结合亲和力测定中应用基于文本的编辑。具体来说，我们从 ChEMBL [17] 中获取了六个结合亲和力任务。每个测定都有文字描述，如表 21 所列。

Table 21. ChEMBL assay descriptions.

ChEMBL ID	Assay Description
1613777	This molecule is tested positive in an assay that are inhibitors and substrates of an enzyme protein. It uses molecular oxygen inserting one oxygen atom into a substrate and reducing the second into a water molecule.
1613797	This molecule is tested positive in an assay for Anthrax Lethal, which acts as a protease that cleaves the N-terminal of most dual specificity mitogen-activated protein kinase kinases.
2114713	This molecule is tested positive in an assay for Activators of ClpP, which cleaves peptides in various proteins in a process that requires ATP hydrolysis and has a limited peptidase activity in the absence of ATP-binding subunits.
1613838	This molecule is tested positive in an assay for activators involved in the transport of proteins between the endosomes and the trans Golgi network.
1614236	This molecule is an inhibitor of a protein that prevents the establishment of the cellular antiviral state by inhibiting ubiquitination that triggers antiviral transduction signal and inhibits post-transcriptional processing of cellular pre-mRNA.
1613903	This molecule is tested positive in the high throughput screening assay to identify inhibitors of the SARS coronavirus 3C-like Protease, which cleaves the C-terminus of replicase polypeptide at 11 sites.

为了进行评估，我们遵循方法部分。回想一下，每个结合亲和力测定可以对应于带有阳性和阴性标记的分子。因此，我们可以在这些数据点上训练分类器，这里的满足标准是输出分子是否比输入分子具有更高的置信度，其中使用每个任务的分类器来预测置信度。该管道如图 8 所示。




图 8. 基于结合亲和力的分子编辑流程。输入分子从ZINC中随机采样，文字提示是测定描述。为了进行评估，每个测定的小分子用于训练二元分类器，并考虑两种类型的模型（随机森林和逻辑回归）。


命中率结果如表 22 所示。请注意，为了更好地证明我们结果的有效性，我们为每个分析训练了两个分类器：随机森林 (RF) 和逻辑回归 (LR)，并以指纹作为特征化。Delta 为 0。

表 22. 六种 ChEMBL 测定编辑的结果。每个 ChEMBL 测定都是一个二元任务，我们训练一个分类器来获得每个分子（输入和输出分子）的置信度得分。输入是从ZINC中随机采样的200个分子，评估是置信度变化的命中率。潜在的优化是使用 MoleculeSTM 进行基于文本的分子编辑，分别使用 SMILES 字符串和分子图。


ChEMBL ID		baseline				latent optimization	
		Random	PCA	High Variance	GS-Mutate	SMILES	Graph
1613777	RF	44.99 $\pm$ 2.08	44.49 $\pm$ 1.22	44.45 $\pm$ 1.01	39.17 $\pm$ 3.66	48.70 $\pm$ 2.06	44.53 $\pm$ 1.60
	LR	47.34 $\pm$ 5.53	49.13 $\pm$ 0.86	49.69 $\pm$ 6.75	51.50 $\pm$ 2.86	54.09 $\pm$ 1.94	50.55 $\pm$ 3.14
1613797	RF	44.76 $\pm$ 2.18	46.25 $\pm$ 0.97	46.92 $\pm$ 3.34	46.67 $\pm$ 1.55	55.03 $\pm$ 2.23	49.03 $\pm$ 0.03
	LR	48.40 $\pm$ 3.71	49.92 $\pm$ 4.31	48.67 $\pm$ 1.64	49.17 $\pm$ 3.01	57.98 $\pm$ 3.34	54.95 $\pm$ 3.74
2114713	RF	39.87 $\pm$ 2.32	42.91 $\pm$ 2.64	42.19 $\pm$ 3.68	41.33 $\pm$ 1.25	49.20 $\pm$ 2.11	60.93 $\pm$ 2.53
	LR	51.39 $\pm$ 1.15	52.62 $\pm$ 1.64	52.24 $\pm$ 1.07	50.50 $\pm$ 1.47	56.93 $\pm$ 3.67	58.77 $\pm$ 2.41
1613838	RF	44.49 $\pm$ 1.48	44.71 $\pm$ 1.80	45.30 $\pm$ 2.47	36.00 $\pm$ 2.68	43.94 $\pm$ 3.75	49.13 $\pm$ 2.52
	LR	50.22 $\pm$ 4.23	49.73 $\pm$ 2.33	44.69 $\pm$ 2.41	41.33 $\pm$ 3.17	47.50 $\pm$ 2.28	56.13 $\pm$ 1.50
1614236	RF	41.33 $\pm$ 3.59	42.28 $\pm$ 1.91	42.85 $\pm$ 2.88	45.33 $\pm$ 1.65	57.90 $\pm$ 2.39	35.71 $\pm$ 4.19
	LR	46.57 $\pm$ 0.51	49.34 $\pm$ 1.80	50.62 $\pm$ 3.86	56.00 $\pm$ 1.08	65.78 $\pm$ 5.67	46.36 $\pm$ 2.53
1613903	RF	44.28 $\pm$ 0.77	43.83 $\pm$ 2.65	42.00 $\pm$ 3.19	46.17 $\pm$ 0.85	56.82 $\pm$ 3.96	58.70 $\pm$ 1.43
	LR	53.94 $\pm$ 3.30	48.63 $\pm$ 4.49	56.19 $\pm$ 2.51	56.33 $\pm$ 0.94	58.31 $\pm$ 2.98	64.64 $\pm$ 5.23

然后我们添加对接以实现图 9 中的可视化。我们选择具有可用 PDB 结构的 ChEMBL 1613777。具体来说，我们首先使用 MoleculeSTM 提取输出分子，其置信度（RF 和 LR）高于使用基线生成的分子。然后我们运行分子对接软件来获取结果。下面列出了对接设置的详细信息。· 我们使用 RDKit [19] 中提供的 Merck 分子力场 (MMFF) [18] 为每个分子嵌入（生成）3D 构象异构体。MMFF 的介电常数设置为 80，优化的最大迭代次数为 1000，每个分子的最多 5 个构象异构体用于进一步分析。· 对于结合靶标，我们考虑检测 P450 (CYP) 2C19 [20] (ChEMBL id: 1613777) 并选择蛋白质数据库 (PDB) 中可用的相应晶体结构 (PDB id: 4GQS)。进一步，我们取 A 链进行对接运行。随后进行结合，结合口袋与 PDB 复合物晶体结构中的原始配体对齐：中心设置为 (-81.48, 16.55, -41.6)，盒子设置为 (20.0, 23.0, 25.0)。· 然后我们进行预处理步骤以补充氢原子并添加部分电荷。我们使用 meeko v0.3.3 来处理小分子，使用 AutoDock 柔性受体 (ADFR) 套件 v1.2 来处理蛋白质。· 对于对接，我们使用 AutoDock Vina v1.2.3 [21]。每个分子构象异构体都以 32 的穷举度进行对接，并挑选具有最佳（最低）对接分数的姿势并用于可视化。为了可视化，我们使用 UCSF Chimera。


(a) Set 1, input molecule (SMILES): Cc1cc(F)cc(C(=O)Oc2cccc(C(N)=O)c2)c1



Input Molecule
(docking score: -9.055)




Output Molecule with GS
(docking score: -8.843)




Output Molecule with MoleculeSTM
(docking score: -10.35)


(b) Set 2, input molecule (SMILES): COC(=O)[C@@H]1CN(Cc2cnc(C3CC3)s2)C[C@@H](C)O1



Input Molecule
(docking score: -7.441)



Output Molecule with GS
(docking score: -7.747)



Output Molecule with MoleculeSTM
(docking score: -11.363)

图 9. 用于基于结合亲和力的分子编辑的两组对接可视化。文本提示来自 ChEMBL 1613777 (“This

检测结果呈阳性的分子是酶蛋白的抑制剂和底物。它使用分子氧将一个氧原子插入底物，并将第二个氧原子还原为水分子。”)。为了可视化，显示了 GS 和 MoleculeSTM 的输入分子和输出分子。观察到 MoleculeSTM 可以生成对接分数最低的分子（氢键最多，并以红色虚线标记）。在组 1 (a) 中，输出分子共享相同的分子支架。在组 2 (b) 中，输出分子的主题使用 MoleculeSTM 也发生了变化。

D.5 药物相关性编辑作为概念验证，我们进一步对常见药物编辑进行了四个编辑任务。这里使用的文本提示是为了使输入分子看起来像现有的药物，例如，“这个分子看起来像青霉素”。在方法部分之后，所使用的满足函数是Tanimoto相似度，并且阈值 Delta 取值0和0.05。

表 23. 四种常见药物分子编辑的结果。输入是从 ZINC 中随机采样的 200 个分子，评估







是谷本与普通药物相似度增加的命中率。潜在的优化是使用 MoleculeSTM 进行基于文本的分子编辑，分别使用 SMILES 字符串和分子图。

	Δ	baseline				latent optimization	
		Random	PCA	High Variance	GS-Mutate	SMILES	Graph
This molecule looks like Penicillin.	0	43.61 $\pm$ 2.23	46.51 $\pm$ 3.02	44.42 $\pm$ 3.56	28.67 $\pm$ 0.94	58.13 $\pm$ 0.97	50.91 $\pm$ 2.80
	0.05	0.69 $\pm$ 0.55	0.23 $\pm$ 0.32	0.89 $\pm$ 0.30	0.67 $\pm$ 0.62	11.01 $\pm$ 0.58	3.64 $\pm$ 0.57
This molecule looks like Aspirin.	0	43.82 $\pm$ 1.41	43.12 $\pm$ 5.35	44.63 $\pm$ 3.33	25.00 $\pm$ 2.16	40.13 $\pm$ 1.33	54.05 $\pm$ 3.58
	0.05	2.99 $\pm$ 0.38	3.08 $\pm$ 0.82	2.45 $\pm$ 0.33	0.33 $\pm$ 0.47	4.28 $\pm$ 1.22	10.84 $\pm$ 1.26
This molecule looks like Caffeine.	0	42.71 $\pm$ 3.16	40.33 $\pm$ 0.71	40.64 $\pm$ 3.89	26.17 $\pm$ 1.31	46.08 $\pm$ 3.81	51.01 $\pm$ 1.22
	0.05	0.69 $\pm$ 0.01	0.23 $\pm$ 0.32	0.44 $\pm$ 0.31	0.33 $\pm$ 0.24	1.61 $\pm$ 0.67	0.61 $\pm$ 0.01
This molecule looks like Dopamine.	0	42.00 $\pm$ 3.08	42.50 $\pm$ 2.12	41.33 $\pm$ 2.86	30.50 $\pm$ 1.63	47.00 $\pm$ 4.11	55.50 $\pm$ 2.73
	0.05	0.00 $\pm$ 0.00	0.44 $\pm$ 0.31	0.22 $\pm$ 0.31	0.83 $\pm$ 0.24	2.30 $\pm$ 0.44	6.24 $\pm$ 0.56

D.6 邻域搜索专利药物分子的案例研究为了演示基于文本的分子编辑的实用性，我们展示了三个从类似物生成批准药物的案例研究。先导化合物优化是药物发现的关键阶段，其中基于先导分子制备密切相关的化合物，旨在提高其功效和 DMPK（药物代谢和药代动力学）特性，并最终确定候选药物 [22]。因此，要求具有更大类似物特性的文本提示将为改善先导分子的缺陷和加速药物发现研究提供信息。具体来说，输入分子是每个已批准药物分子的专利类似物，并且输入文本提示是单目标的，如附录 D.2 中的那样。这里的目标是检查是否能够成功生成已批准的药物作为输出分子，其结构变化与文本提示中反映的性能改进一致。例如，在表24(a)中，通过将咪唑取代基替换为甲氧基，成功地从类似物生成厄洛替尼[23]。这一变化反映了 tPSA 从 83 下降到 75，与指示渗透性更高的文本提示一致。表24 (b)从其氨基取代的衍生物[24]生成塞来昔布，其中氨基的去除使分子具有更大的肠渗透性，从而导致更高的生物利用度。生物利用度是药物分子到达体循环的分数，是口服药物吸收的关键因素[25]。最后，表 24 (c) 说明了分子中潜在的代谢负担可以通过基于文本的编辑来解决。一篇呼吁代谢稳定分子的文章成功地将多奈哌齐中的三甲氧基芳烃转变为二甲氧基芳烃[26]，其中前者代表已知会经历氧化相 I 代谢的富含电子的芳香族化合物[27]。

表 24. 对药物类似物进行三个单目标分子编辑的可视化，根据文本提示生成批准的药物。

粉色和蓝色区域分别突出显示输入和输出分子中的修改结构。

(a) Prompt: This molecule has high permeability.		(b) Prompt: This molecule has high bioavailability.		(c) Prompt: This molecule is metabolically stable.	
Input Molecule	Output Molecule	Input Molecule	Output Molecule	Input Molecule	Output Molecule
					
CAS: 183320-43-6	Tarceva (Erlotinib)	CAS: 170570-28-2	Celebrex (Celecoxib)	CAS: 120013-52-7	Aricept (Donepezil)

在本节中，我们回顾了 MoleculeNet 和分子基准测试工作中用于分子特性预测下游任务的两类主要数据集 [28, 29]。

分子特性：药理学血脑屏障穿透 (BBBP) [30]数据集测量分子是否会穿透中枢神经系统。所有三个毒性相关数据集 Tox21 [31]、ToxCast [28] 和 ClinTox [32] 都与分子化合物的毒性有关。副作用资源 (SIDER) [33]数据集将药物不良反应存储在上市药物数据库中。

分子特性：生物物理学最大无偏验证 (MUV) [34] 是 PCBA 的另一个子数据库，是通过应用精炼的最近邻分析获得的。HIV来自药物治疗计划 (DTP) AIDS AntiviralScreen[35]，其目的是预测HIV复制的抑制情况。BACE 测量一组 β -分泌酶 1 (BACE-1) 抑制剂的结合结果，并收集在 MoleculeNet [28] 中。

Table 25. Summary for the molecule chemical datasets.

Dataset	Task	# Tasks	# Molecules
BBBP	Classification	1	2,039
Tox21	Classification	12	7,831
ToxCast	Classification	617	8,576
Sider	Classification	27	1,427
ClinTox	Classification	2	1,478
MUV	Classification	17	93,087
HIV	Classification	1	41,127
Bace	Classification	1	1,513

对于数据分割，我们采用脚手架分割[28]。Scaffold衡量的是分子的骨架结构，而scaffoldsplitting意味着我们将具有更常见的scaffold的分子放入训练中，其余的放入验证和测试中，以模拟分布外 (OOD) 设置。OOD 设置在实际场景中更常见，因此更适合测试预训练的分子表示能力。

实现细节 对于 SMILES 字符串，我们使用 MegaMolBART [5] 作为骨干 Transformer 模型。对于分子图，我们使用相同的主干 GIN 模型，并且使用丰富的特征（如 GraphMVP [8] 中用于回归任务的那样）。我们在下面列出了主要的超参数。

表 26. 分子特性预测的超参数规范。

	Hyperparameter	Value
Pretraining Baseline	epochs	{100}
	learning rate	{1e-3}
	weight decay	{0}
Downstream	epochs	{100}
	learning rate	{1e-3, 5e-4}
	weight decay	{0}

骨干模型的选择。我们想要澄清的是，MoleculeSTM 与每种模态的主干编码器（例如分子表示模型）无关。· 对于主干模型，我们使用 GIN 模型作为固定的 2D GNN 主干编码器。换句话说，MoleculeSTM 的性能受到 2D 主干模型的限制。· 在分子预训练研究领域（例如 AttrMask [36]、MolCLR [37]、GraphMVP [8]、MoleculeSDE [38]），所有这些工作都采用 GIN 作为 2D 主干模型，作为控制来测试各种预训练算法的有效性。这与我们提出的 MoleculeSTM 的情况类似。· 未来，我们希望探索更先进的分子 GNN 模型。

补充参考文献

- [1] Sunghwan Kim, Jie Chen, Tiejun Cheng, Asta Gindulyte, Jia He, Siqian He, Qingliang Li, Benjamin A Shoemaker, Paul A Thiessen, Bo Yu, et al. "PubChem in 2021: new data content and improved web interfaces". In: *Nucleic acids research* 49.D1 (2021), pp. D1388–D1395.
- [2] Iz Beltagy, Kyle Lo, and Arman Cohan. "SciBERT: Pretrained Language Model for Scientific Text". In: *EMNLP*. 2019. eprint: [arXiv:1903.10676](https://arxiv.org/abs/1903.10676).
- [3] Waleed Ammar, Dirk Groeneveld, Chandra Bhagavatula, Iz Beltagy, Miles Crawford, Doug Downey, Jason Dunkelberger, Ahmed Elgohary, Sergey Feldman, Vu Ha, et al. "Construction of the literature graph in semantic scholar". In: *arXiv preprint arXiv:1805.02262* (2018).
- [4] M Honnibal, I Montani 和 S Van Landeghem. "博伊德"。见: A. spaCy: Python 中工业级自然语言处理 (2020)。
- [5] Ross Irwin, Spyridon Dimitriadis, Jiazhen He, and Esben Jannik Bjerrum. "Chemformer: a pre-trained transformer for computational chemistry". In: *Machine Learning: Science and Technology* 3.1 (2022), p. 015022.
- [6] Teague Sterling and John J Irwin. "ZINC 15—ligand discovery for everyone". In: *Journal of chemical information and modeling* 55.11 (2015), pp. 2324–2337.
- [7] Keyulu Xu, Weihua Hu, Jure Leskovec, and Stefanie Jegelka. "How powerful are graph neural networks?" In: *arXiv preprint arXiv:1810.00826* (2018).
- [8] Shengchao Liu, Hanchen Wang, Weiyang Liu, Joan Lasenby, Hongyu Guo, and Jian Tang. "Pre-training Molecular Graph Representation with 3D Geometry". In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=xQUelpOKPam>.
- [9] Simon Axelrod and Rafael Gomez-Bombarelli. "GEOM, energy-annotated molecular conformations for property prediction and molecular generation". In: *Scientific Data* 9.1 (2022), pp. 1–14.
- [10] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. "Bert: Pre-training of deep bidirectional transformers for language understanding". In: *arXiv preprint arXiv:1810.04805* (2018).
- [11] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. "Representation learning with contrastive predictive coding". In: *arXiv preprint arXiv:1807.03748* (2018).
- [12] Kaveh Hassani and Amir Hosein Khasahmadi. "Contrastive multi-view representation learning on graphs". In: *International Conference on Machine Learning*. PMLR. 2020, pp. 4116–4126.
- [13] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S Sara Mahdavi, Rapha Gontijo Lopes, et al. "Photorealistic Text-to-Image Diffusion Models with Deep Language Understanding". In: *arXiv preprint arXiv:2205.11487* (2022).
- [14] David S Wishart, Yannick D Feunang, An C Guo, Elvis J Lo, Ana Marcu, Jason R Grant, Tanvir Sajed, Daniel Johnson, Carin Li, Zinat Sayeeda, et al. "DrugBank 5.0: a major update to the DrugBank database for 2018". In: *Nucleic acids research* 46.D1 (2018), pp. D1074–D1082.
- [15] Tero Karras, Samuli Laine, and Timo Aila. "A style-based generator architecture for generative adversarial networks". In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2019, pp. 4401–4410.
- [16] Shengchao Liu, Chengpeng Wang, Weili Nie, Hanchen Wang, Jiarui Lu, Bolei Zhou, and Jian Tang. "GraphCG: Unsupervised Discovery of Steerable Factors in Graphs". In: *NeurIPS 2022 Workshop: New Frontiers in Graph Learning*. 2022. URL: https://openreview.net/forum?id=BhR44NzeK_1.
- [17] 大卫·门德斯、安娜·高尔顿、帕特里夏·本托、乔恩·钱伯斯、玛琳·德·维吉、埃洛伊·费利克斯、玛丽亚·保拉·马加里尼奥斯、胡安·F Mosquera、普鲁登斯·穆托沃、米哈乌·诺沃特卡、玛丽亚·戈迪略-马拉尼翁、菲奥娜·亨特、劳拉·洪科、格蕾丝·穆根巴特、米拉格罗斯·罗德里格斯·洛佩兹、弗朗西斯·阿特金森、尼古拉斯·Bosc、Chris J Radoux、Aldo Segura-Cabrera、Anne Hersey 和 Andrew R Leach. "ChEMBL: 走向生物测定数据的直接沉积"。见: 《核酸研究》47.D1 (2018 年 11 月), 第 D930–D940 页。ISSN: 0305-1048. DOI: 10.1093/nar/gky1075. 电子打印: <https://academic.oup.com/nar/article-pdf/47/D1/D930/27437436/gky1075.pdf>. 网址: <https://doi.org/10.1093/nar/gky1075>.
- [18] 托马斯·A·哈尔格伦. "默克分子力场. I. MMFF94 的基础、形式、范围、参数化和性能"。见: 计算化学杂志 17.5-6 (1996), 第 490-519 页。
- [19] Greg Landrum et al. *RDKit: A software suite for cheminformatics, computational chemistry, and predictive modeling*. 2013.
- [20] R Leila Reynald, Stefaan Sansen, C David Stout, and Eric F Johnson. "Structural Characterization of Human Cytochrome P450 2C19: ACTIVE SITE DIFFERENCES BETWEEN P450s 2C8, 2C9, AND 2C19". In: *Journal of Biological Chemistry* 287.53 (2012), pp. 44581–44591.
- [21] Oleg Trott and Arthur J Olson. "AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading". In: *Journal of computational chemistry* 31.2 (2010), pp. 455–461.

- [22] James P Hughes, Stephen Rees, S Barrett Kalindjian, and Karen L Philpott. “Principles of early drug discovery”. In: *British journal of pharmacology* 162.6 (2011), pp. 1239–1249.
- [23] Rodney Caughren Schnur and Lee Daniel Arnold. *Alkynyl and azido-substituted 4-anilinoquinazolines*. US Patent 5,747,498. May 1998.
- [24] John J Talley, Thomas D Penning, Paul W Collins, Donald J Rogier Jr, James W Malecha, Julie M Miyashiro, Stephen R Bertenshaw, Ish K Khanna, Matthew J Graneto, Roland S Rogers, et al. *Substituted pyrazolyl benzenesulfonamides for the treatment of inflammation*. US Patent 5,760,068. June 1998.
- [25] David Dahlgren and Hans Lennernäs. “Intestinal Permeability and Drug Absorption: Predictive Experimental, Computational and In Vivo Approaches”. In: *Pharmaceutics* 11.8 (2019). ISSN: 1999-4923. DOI: [10.3390/pharmaceutics11080411](https://doi.org/10.3390/pharmaceutics11080411). URL: <https://www.mdpi.com/1999-4923/11/8/411>.
- [26] Hachiro Sugimoto, Youichi Iimura, Yoshiharu Yamanishi, and Kiyomi Yamatsu. “Synthesis and Structure-Activity Relationships of Acetylcholinesterase Inhibitors: 1-Benzyl-4-[(5,6-dimethoxy-1-oxoindan-2-yl)methyl]piperidine Hydrochloride and Related Compounds”. In: *Journal of Medicinal Chemistry* 38.24 (1995). PMID: 7490731, pp. 4821–4829. DOI: [10.1021/jm00024a009](https://doi.org/10.1021/jm00024a009). eprint: <https://doi.org/10.1021/jm00024a009>. URL: <https://doi.org/10.1021/jm00024a009>.
- [27] Gordon Guroff, Jean Renson, Sidney Udenfriend, John W Daly, Donald M Jerina, and Bernhard Witkop. “Hydroxylation-Induced Migration: The NIH Shift: Recent experiments reveal an unexpected and general result of enzymatic hydroxylation of aromatic compounds.” In: *Science* 157.3796 (1967), pp. 1524–1530.
- [28] Zhenqin Wu, Bharath Ramsundar, Evan N Feinberg, Joseph Gomes, Caleb Geniesse, Aneesh S Pappu, Karl Leswing, and Vijay Pande. “MoleculeNet: a benchmark for molecular machine learning”. In: *Chemical science* 9.2 (2018), pp. 513–530.
- [29] Hanchen Wang, Jean Kaddour, Shengchao Liu, Jian Tang, Matt Kusner, Joan Lasenby, and Qi Liu. *Evaluating Self-Supervised Learning for Molecular Graph Embeddings*. 2022. URL: <https://openreview.net/forum?id=ctX2eXYIW3>.
- [30] Ines Filipa Martins, Ana L Teixeira, Luis Pinheiro, and Andre O Falcao. “A Bayesian approach to in silico blood-brain barrier penetration modeling”. In: *Journal of chemical information and modeling* 52.6 (2012), pp. 1686–1697.
- [31] Tox21 Data Challenge. “Tox21 Data Challenge 2014”. In: <https://tripod.nih.gov/tox21/challenge/> (2014).
- [32] Kaitlyn M Gayvert, Neel S Madhukar, and Olivier Elemento. “A data-driven approach to predicting successes and failures of clinical trials”. In: *Cell chemical biology* 23.10 (2016), pp. 1294–1301.
- [33] Michael Kuhn, Ivica Letunic, Lars Juhl Jensen, and Peer Bork. “The SIDER database of drugs and side effects”. In: *Nucleic acids research* 44.D1 (2015), pp. D1075–D1079.
- [34] Sebastian G. Rohrer and Knut Baumann. “Maximum Unbiased Validation (MUV) Data Sets for Virtual Screening Based on PubChem Bioactivity Data”. In: *Journal of Chemical Information and Modeling* 49.2 (2009). PMID: 19161251, pp. 169–184. DOI: [10.1021/ci8002649](https://doi.org/10.1021/ci8002649). eprint: <https://doi.org/10.1021/ci8002649>. URL: <https://doi.org/10.1021/ci8002649>.
- [35] Daniel Zaharevitz. *Aids antiviral screen data*. 2015.
- [36] Weihua Hu, Bowen Liu, Joseph Gomes, Marinka Zitnik, Percy Liang, Vijay Pande, and Jure Leskovec. “Strategies for pre-training graph neural networks”. In: *International Conference on Learning Representations, ICLR*. 2020.
- [37] Yuyang Wang, Jianren Wang, Zhonglin Cao, and Amir Barati Farimani. “Molclr: Molecular contrastive learning of representations via graph neural networks”. In: *arXiv preprint arXiv:2102.10056* (2021).
- [38] Shengchao Liu, Weitao Du, Zhi-Ming Ma, Hongyu Guo, and Jian Tang. “A group symmetric stochastic differential equation model for molecule multi-modal pretraining”. In: *International Conference on Machine Learning*. PMLR. 2023, pp. 21497–21526.