

分 类 号: TP183
论文编号: 2022024801

密级: 公开

贵 州 大 学
2025 届硕士研究生学位论文

基于图 Transformer 的分子性质预测方法研究

学科专业: 电子信息
研究方向: 大数据技术与工程
导 师: 陆见光
研 究 生: 张绍光

中国 ▪ 贵州 ▪ 贵阳
2025 年 05 月

硕士学位论文答辩委员会名单

基于图 Transformer 的分子性质预测方法研究

答辩人：张绍光

答辩委员会委员：

贵州财经大学教授：_____邓明森_____（主席）

贵州大学教授：_____唐向红_____

贵州大学副教授：_____杨静_____

贵州大学副教授：_____王崎_____

贵州大学副教授：_____王阳_____

答辩秘书：李清荷 助理实验师

答辩时间：2025 年 05 月 27 日

答辩地点：贵州大学崇厚楼 812

摘要

药物研发作为医药领域发展的核心驱动力，在现代医学发展和人们健康意识提升的背景下，其重要性愈发凸显。然而，当药物研发不仅难度攀升，成本也持续增加。提高分子性质预测能力对药物研发意义重大，能够助力科研人员快速筛选与设计具备潜在活性的药物分子，从而有效降低研发成本、缩短研发周期。

在分子性质预测领域，基于 Transformer 的分子性质预测方法虽有所应用，但暴露出一系列问题。一方面，标准 Transformer 架构主要适用于序列数据，难以有效提取分子中的深度空间结构信息；另一方面，多数现有方法都基于传统空域离散型编码，导致现有模型难以有效捕捉不同化学键对应的特征值之间的相互关系。针对上述现有方法的一些不足，本文在深度空间信息提取方法和图特征的相互关系方法上进行了研究，并提出基于空间结构信息提取图 Transformer 的分子性质预测模型（Spatial Structure Information Extraction Graph Transformer, SSET）与基于双域融合图 Transformer 的分子性质预测模型（Dual-Domain Fusion Graph Transformer Model Using Rapid Attention Methods, DRAM），旨在提升分子性质预测的准确性与效率。本文的主要贡献如下：

（1）本文提出 SSET 模型，SSET 由边缘特征融合子图空间结构提取器模块（ETSE）和位置信息编码图 Transformer 模块（PEGT）组成。ETSE 模块通过边特征融合和最具价值子图（Mv-subgraph）表示学习完成空间结构信息提取。边特征融合丰富了节点表示，提供了关于图结构更全面的信息。Mv-subgraph 表示提高了模型识别和表示局部结构的能力。同时，模型引入 PEGT 模块来补充位置信息。与传统的图 Transformer 相比，PEGT 增强了结构感知能力，使模型能够更准确地捕获分子图节点之间的关系。此外，PEGT 增强了上下文理解，帮助模型分析图结构中每个节点的位置和上下文。

（2）为进一步提升分子性质预测精度，本文在空间结构信息提取的基础上，创新性地引入谱域，并提出 DRAM 模型。模型主要分为两个模块：一个以谱域编码为基础的注意力模块（FASE）以及一个结合全局信息和局部结构信息的快速注意力模块（ALGI）。谱域注意力模块从一个新的角度探索了分子图的特征信息，并且通过一个新的谱域编码维持了分子置换等变性的同时捕捉到分子特征之间的相互关系。而空域层面的注意力机制则保留捕获分子间的长程依赖性，同时避免过度平滑或过度挤压的问题的优势。模型可以提供更适应不同频率范围和尺度的特征表示，从而提高适应性、泛化能力和性能。此外，本文在多个数据集上对 SSET 和 DRAM 模型进行了验

证。实验结果表明，这两个模型有效解决了现有分子图性质预测方法的关键问题，在预测准确性、适应性和泛化能力等方面都取得了很好的效果。

综上所述，本研究为药物研发及相关领域提供了更高效、准确的分子性质预测方法，进一步推动药物研发的发展进程。

关键词：深度学习；图神经网络；图 Transformer；药物研发；分子性质预测

ABSTRACT

Drug research and development, as the core driving force in the development of the pharmaceutical field, has become increasingly significant against the backdrop of the advancement of modern medicine and the enhancement of people's health awareness. However, currently, drug research and development not only faces increasing difficulties but also incurs continuously rising costs. Precise prediction of molecular properties is of great significance for drug research and development, as it can assist researchers in quickly screening and designing drug molecules with potential activity, thereby effectively reducing research and development costs and shortening the research and development cycle.

In the field of molecular property prediction, although molecular property prediction methods based on Transformer have been applied, a series of problems have emerged. On the one hand, the standard Transformer architecture is mainly suitable for sequential data and has difficulty in effectively extracting the deep spatial structure information within molecules. On the other hand, most existing methods are based on traditional discrete encoding in the spatial domain, which makes it difficult for existing models to effectively capture the interrelationships between the characteristic values corresponding to different chemical bonds. In response to some of the deficiencies of the existing methods mentioned above, this paper conducts research on the method of extracting deep spatial information and the method of interrelationships of graph features, and proposes a molecular property prediction model (Spatial Structure Information Extraction Graph Transformer , SSET) based on graph Transformer for spatial structure information extraction and a molecular property prediction model (Dual-Domain Fusion Graph Transformer Model Using Rapid Attention Methods , DRAM) based on dual-domain fusion graph Transformer, aiming to improve the accuracy and efficiency of molecular property prediction. The main contributions of this paper are as follows:

(1) This paper proposes the SSET model, which is composed of the Edge Feature Fusion Subgraph Spatial Structure Extractor module (ETSE) and the Position Information Encoding Graph Transformer module (PEGT). The ETSE module completes the extraction of spatial structure information through edge feature fusion and the representation learning of the Most Valuable Subgraph (Mv-subgraph). Edge feature fusion enriches the node representation and provides more comprehensive information about the graph structure. The

Mv-subgraph representation improves the model's ability to recognize and represent local structures. At the same time, the model introduces the PEGT module to supplement the position information. Compared with traditional graph Transformers, PEGT enhances the structural perception ability, enabling the model to more accurately capture the relationships between nodes in the molecular graph. In addition, PEGT enhances the understanding of the context, helping the model analyze the position and context of each node in the graph structure.

(2) To further improve the accuracy of molecular property prediction, based on the extraction of spatial structure information, this paper innovatively introduces the spectral domain and proposes the DRAM model. The model is mainly divided into two modules: an attention module (FASE) based on spectral domain encoding and a fast attention module (ALGI) that combines global information and local structure information. The spectral domain attention module explores the feature information of the molecular graph from a new perspective, and through a new spectral domain encoding, it maintains the molecular permutation equivariance while capturing the interrelationships between molecular features. The attention mechanism at the spatial domain level retains the advantage of capturing the long-range dependencies between molecules while avoiding the problems of over-smoothing or over-squeezing. The model can provide feature representations that are more adaptable to different frequency ranges and scales, thereby improving adaptability, generalization ability, and performance. In addition, this paper validates the SSET and DRAM models on multiple datasets. Experimental results show that these two models effectively address the key issues of existing molecular graph property prediction methods, and have achieved good results in terms of prediction accuracy, adaptability, and generalization ability.

In conclusion, this study provides a more efficient and accurate method for predicting molecular properties for drug research and development and related fields, further promoting the development process of drug research and development.

Key words: Deep learning, graph neural network, graph transformer, drug research and development, molecular property prediction.

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 早期分子性质预测模型.....	2
1.2.2 基于深度学习的预测模型.....	3
1.3 主要研究内容.....	5
1.4 论文组织结构.....	7
1.5 本章小结.....	8
第 2 章 相关理论基础	9
2.1 分子图特性.....	9
2.2 分子图的子图.....	10
2.3 图卷积神经网络.....	11
2.4 图 Transformer.....	13
2.5 图神经网络组件.....	15
2.5.1 激活函数.....	15
2.5.2 损失函数.....	17
2.5.3 优化算法.....	18
2.5.4 Dropout	19
2.5.5 全连接层.....	19
2.6 本章小结.....	20
第 3 章 基于深度空间结构信息提取图 Transformer 的分子性质预测模型	23
3.1 引言.....	23
3.2 模型框架.....	23
3.3 子图空间结构提取.....	24
3.3.1 边特征融合.....	25
3.3.2 节点遴选.....	26
3.3.3 空间结构信息提取.....	27
3.4 位置信息编码图 Transformer.....	28
3.5 实验分析.....	30
3.5.1 数据集介绍.....	30
3.5.2 实验设置.....	32
3.5.3 实验评价指标.....	34
3.5.4 实验性能比较.....	35

3.5.5 消融实验.....	36
3.6 本章小结.....	38
第4章 基于双域融合图 Transformer 的分子性质预测模型	41
4.1 引言.....	41
4.2 模型框架.....	41
4.3 分子图谱域空间信息提取	42
4.3.1 特征值和特征向量计算.....	43
4.3.2 融合谱域编码的快速注意力.....	43
4.4 分子图局部信息和全局信息整合	44
4.4.1 原子和化学键信息嵌入.....	45
4.4.2 局部信息和全局信息提取模块.....	46
4.4.3 图拉普拉斯滤波.....	46
4.5 实验分析.....	47
4.5.1 数据集介绍.....	47
4.5.2 实验设置.....	48
4.5.3 实验评价指标.....	50
4.5.4 实验性能比较.....	50
4.5.5 消融实验.....	52
4.6 本章小结.....	53
第5章 总结与展望	55
5.1 总结.....	55
5.2 展望.....	56
参考文献.....	57

第1章 绪论

1.1 研究背景及意义

随着现代医学的快速发展与人们对健康需求的不断提升，药物研发成为了医药领域持续进步的核心驱动力^[1]。然而，当下药物研发面临着诸多严峻挑战，研发难度与日俱增，成本不断攀升^[2]。新药研发成本逐年急剧增加^[3-4]，有相关调查^[5]表示 10 家制药公司 68 种新药研发成本，估算平均自付 4.03 亿美元，资本化后 8.02 亿美元，成本年增 7.4%。在药物研发过程中，药物分子的活性、毒性、药代动力学等性质若不能被准确认知，就会导致大量的研发资源浪费在无效或有害的分子上^[6]。比如，许多药物在临床试验后期才因毒性问题被终止研发，前期投入的巨额资金和时间付诸东流。药物分子性质的不确定性带来了研发周期漫长的问题^[7]，这使得许多患者无法及时获得有效的治疗药物。同时，高昂的研发成本也直接导致新药价格居高不下，普通患者难以承受^[8-11]。此外，研发失败的风险也阻碍了医药企业的创新积极性，影响整个行业的发展活力。




图 1-1 新药研发流程图

早期药物研发依赖实验试错与经验设计，虽推动行业发展，却在面对复杂疾病时效率低、成本高^[12]。随着科技发展，人工智能等技术为新药研发带来突破契机^[13-17]。其中，分子性质预测凭借对药物分子关键性质的提前洞察，成为药物研发革新的重要力量。与传统研发方式相比，它能更高效地筛选分子、规避风险、优化结构。分子性质预测是药物研发过程中的关键环节^[18]，它通过整合大量的化学、生物学数据，运用先进的计算模型和算法，对药物分子的各种性质，如活性、毒性、药代动力学性质等进行预测^[19]。分子性质预测能够助力药物研发团队提前规划研发路径，做出科学合理的决策。在药物研发的早期阶段，分子性质预测可以帮助筛选出最具潜力的药物分子，大幅缩短研发周期^[20]。例如，通过预测分子与靶点的结合活性，能够快速判断哪

些分子更有可能成为有效的药物，避免在无效分子上耗费过多时间和资源。同时，预测分子的毒性，有助于提前规避潜在的安全风险，减少临床试验阶段因毒性问题导致的研发失败，从而降低研发成本。此外，对于药物的优化阶段，分子性质预测可以为药物结构的改进提供方向。通过预测不同结构修饰对分子性质的影响，研发人员能够有针对性地设计和合成新的药物分子，提高药物的疗效和安全性。这不仅有助于加速新药的上市进程，还能为患者提供更有效、更安全的治疗药物，提升医疗服务水平。然而，实现有效的分子性质预测并非轻而易举，面临着诸多挑战^[21]。首先，药物研发涉及的数据来源广泛，包括高通量实验数据、临床数据等，数据量庞大且质量参差不齐，如何有效整合和处理这些数据是一大难题^[22]。其次，分子性质与药物活性、毒性等之间的关系复杂，存在多种相互作用机制，这要求预测模型能够精准捕捉这些复杂的关联。再者，不同疾病靶点和药物作用机制各异，预测模型需要具备强大的泛化能力，才能适应多样化的药物研发场景。

综上所述，在竞争激烈的药物研发领域，分子性质预测发挥着不可或缺的作用，它在加速新药研发、提高研发成功率、保障药物安全性等方面具有重大价值^[23]。同时，鉴于药物研发数据和分子性质关系的复杂性，实现更有效的分子性质预测仍是一项极具挑战性的任务，需要科研人员不断探索创新^[24]。

1.2 国内外研究现状

目前，学术界针对分子性质预测问题开展了广泛而深入的研究，提出了一系列富有创新性的预测方法，为药物研发及相关领域的发展提供了有力支撑。本节将从统计学预测模型、传统机器学习预测模型、深度学习预测模型三个维度展开。当下，深度学习技术发展迅猛，在分子性质预测领域，基于深度学习的方法展现出了卓越的适用性，应用也愈发广泛。因此，重点将会放在深度学习预测模型的分析与介绍上。

1.2.1 早期分子性质预测模型

早期的分子性质预测多依赖基于统计学的方法，例如定量构效关系（QSAR）模型^[25]。这类模型通过分析分子的结构特征与性质之间的统计关系来进行预测。研究人员收集大量已知分子结构及其对应性质的数据，运用多元线性回归、主成分分析等统计手段，构建起结构性质关系模型。QSAR 模型在早期药物研发中发挥了重要作用，能够快速对一些简单分子的活性、毒性等性质进行初步评估^[26]。然而，该模型对复杂分子体系的适应性较差，难以准确描述分子间复杂的相互作用，预测精度在面对结构复杂的药物分子时存在较大局限^[27]。

随着机器学习技术的兴起，基于传统机器学习的分子性质预测模型逐渐崭露头

角。支持向量机 (SVM)^[28]、随机森林算法^[29]被广泛应用于分子性质预测领域。这些模型通过对分子结构特征进行编码, 将其转化为机器学习算法能够处理的特征向量, 进而进行训练和预测。例如, SVM 模型能够在高维空间中寻找最优分类超平面, 对分子的活性类别进行有效预测^[30]; 随机森林则通过构建多个决策树并综合其预测结果, 提高了预测的稳定性和准确性。相较于基于统计学的模型, 传统机器学习模型在处理复杂数据和非线性关系方面表现更优, 能在一定程度上提升分子性质预测的精度。但它们对于大规模、高维度数据的处理能力有限, 且特征工程依赖人工经验, 难以充分挖掘数据中的潜在信息^[31]。

1.2.2 基于深度学习的预测模型

近年来, 深度学习现在已经成为分子预测的主流方法, 大致可分为二类: 基于图神经网络 (GNN) 的分子预测方法和基于图 Transformer 的分子预测方法。

(1) 基于图神经网络 (GNN) 的分子性质预测方法

首先介绍基于 GNN 的分子预测方法。GNN 分子预测方法通过定义卷积等操作, 聚合学习节点邻居信息, 能全面捕获分子图结构特征, 用于预测分子性质。Kipf^[32]使用图卷积网络 (GCN) 方法通过在图上定义卷积操作, 有效地聚合和学习了节点的邻居信息。通过聚合和学习邻居节点的信息, GCN 可以学习图中节点的有用表示。这一创新为基于 GNN 的图表示学习的发展奠定了基础。同年, Defferrard^[33]通过在图的谱域中进行快速局部滤波来处理图数据。这种方法保留了谱方法的理论优势, 提高了计算效率, 使 GCN 够有效地应用于大规模图数据的处理。2017 年, Hamilton^[34]提出了一种新的归纳式图表示学习方法 GraphSAGE。与先前的直推式方法不同, GraphSAGE 可以在未见过的节点上生成嵌入, 这对于大规模图尤为重要。为了更有效地捕获节点之间的复杂关系, GAT^[35]将 GNN 与注意力机制相结合。2018 年, Veli^[36]设计了一种无监督的图表示学习方法。该方法通过最大化图中局部节点表示与全局图表示之间的互信息, 有效地学习了丰富且具有判别性的图嵌入。同样在 2018 年, 为了增强 GNN 在解决图同构问题方面的性能, Xu^[37]提出了 GIN 模型, 该模型在节点表示学习中考虑了图同构。这种机制允许节点根据其邻居节点的重要性动态分配不同的权重。同年, CGCNN^[38]第一个利用 GNN 完成分子图表示学习的模型。它通过构建晶体材料的图形表示来准确预测材料性质。此外, 它通过考虑原子之间的连接及其化学环境来学习材料性质, 使预测不仅准确, 而且具有可解释性。2019 年, Yao^[39]创新性地 将 GCN 应用于文本分类任务。该模型通过将文本数据表示为图结构, 有效地捕获和利用了单词之间的复杂关系。同年, DGCNN^[40]通过构建和更新点云数据的动态图结构, 高效地学习了三维点云的深层特征。2020 年, Liu^[41]提出了一种由统一 GCN 和多个子网络组成的混合 GCN, 通过自动学习药物原子和键之间拓扑结构的潜在表示

来预测癌症药物反应。2022 年, DualGCN^[42]通过图卷积网络对药物化学结构和生物样本组织学数据进行编码, 实现了无需大规模单核苷酸变异数据的癌症药物反应预测, 显著优于现有方法。2023 年, DeepDrug^[43]利用残差 GCN 和卷积网络来学习药物和蛋白质的基于结构和序列的表示, 实现了对药物-药物和药物-靶点相互作用的高效预测, 并在新冠药物重新定位方面显示出潜力。2024 年, DeepAEG^[44], 一种多源异构图卷积神经网络, 将药物和基因多组学数据的先进特征提取与序列重组和边特征相结合, 以预测癌细胞系中的 IC50 敏感性值。同年, 随海燕等人^[45]针对分子性质预测中图神经网络难以处理大规模分子图及信息传播的局限构建 GAGCN 模型, 模型借助图神经网络对分子图进行表示学习, 捕捉结构特征, 运用门控循环单元对分子序列建模, 借门控机制自适应处理序列信息, 通过注意力机制自适应学习不同特征权重, 融合图神经网络和门控循环单元, 充分整合分子结构与序列信息。2025 年, 林艳梅^[46]等人提出 DMMPP 模型融合多视角、多层次分子特征, 借助全连接神经网络、混合图神经网络和 VGG 网络, 分别学习分子指纹、2D 分子图、分子图像特征, 经降维、拼接融合特征后, 输入预测模块实现分子性质预测。

尽管基于 GNN 的分子性质预测可以通过研究节点及其邻居提取丰富的特征, 但 these 方法仍然面临一些限制。这些限制包括 GNN 的表达能力有限^[45]以及过平滑^[48]和过压缩^[49]现象限制了模型的分子性质预测能力。为了解决这些问题, 许多研究人员开始研究将图与 Transformer 相结合。基于 Transformer 的图表示学习方法可以通过其独特的自注意力机制和分层结构解决基于 GNN 的方法所遇到的过平滑和过压缩问题。自注意力机制允许模型在计算节点表示时考虑图中任何其他节点的信息, 从而有效地处理长期依赖问题。此外, 与 GNN 采用的局部聚合机制不同, Transformer 的多层结构实现了全局信息集成。这一特性有助于缓解过平滑现象, 即在多层处理后不同节点的特征表示趋于收敛。借助 Transformer 独特的优势模型的分子性质预测的能力得到进一步提高。

(2) 基于图 Transformer 的分子性质预测方法

Transformer 模型最初由 Vaswani^[50]于 2017 年提出, 用于机器翻译等自然语言处理任务。Transformer 的自注意力机制可以在输入序列中创建全局依赖关系, 以更好地捕获上下文信息。同年, Veli^[35]在 GAT 模型中尝试将自注意力用于复杂的图数据。虽然它不是一个纯粹的 Transformer 模型, 但为随后 Transformer 在图数据中的应用奠定了基础。随后, 研究人员尝试对 Transformer 进行修改, 使其能够处理非序列化的图数据。2020 年, Dwivedi^[51]将一种新的基于 Transformer 的方法引入到图表示学习领域, 揭示了其在自然语言处理之外的应用可能性。同年, Cai^[52]将图 Transformer 模型应用于图到序列学习领域。这种新方法不仅提高了全局图结构建模的效率, 而且在几个实际应用中表现出优越的性能。随后, GROVER^[53]在节点、边和图级别设计了自监

督任务。这些任务使模型能够从大量未标记的分子数据中学习丰富的结构和语义信息。GROVER 的引入代表了自监督学习和分子数据分析领域的重要进展，特别是在资源受限的环境中。2021 年，Ying^[54]提出的 Graphormer 结合了图结构信息和 Transformer 模型的优点。这项工作验证了 Transformer 在图表示学习应用中的有效性和适用性。同年，一种新颖的基于自注意力的 GNN 架构 SAN^[55]有效地学习和维护了图中节点之间的关系。这种方法通过自注意力机制全面考虑了图中所有节点的信息，强调了关系维护的重要性。2022 年，Li^[56]聚焦分子性质预测，指出当前自监督学习在该领域的两大问题：预训练任务定义不明与模型能力受限，并提出知识引导的图 Transformer 预训练框架 KPGT，设计 LiGhT 模型引入知识引导预训练策略。2023 年，PharmHGT^[57]针对现有基于原子的分子图表示无法充分利用药效团信息的问题，提出药效团约束的异构图 Transformer，通过设计药效团约束多视图分子表示图，让模型有效提取功能子结构和化学反应中的关键化学信息，实现更具信息量的分子表征。2024 年，KnoMol^[58]将化学专家知识融入模型，模拟药物化学家分析方法，并借助多视角注意力机制，精确表征环状系统，不仅有效解决数据稀缺难题，还在识别新 HER2 抑制剂的实际应用中，展现出显著价值，为知识嵌入 Transformer 领域提供新思路。2025 年，SGNN-T^[59]模型分子的全局、局部信息，与三维空间结构深度融合，其中 GGFF 模块通过纳入键角信息，有效弥补了常规网络空间信息的缺失，TSGFE 模块则将坐标和中心度等关键特征融入 Transformer，进一步增强了模型对分子几何特征的表达能力，进而实现对分子全局与局部信息的协同编码。

总的来说，基于图 Transformer 的方法还能更好地处理大规模、高维度的分子数据，在处理复杂分子体系时，其强大的并行计算能力可以加速模型训练和预测过程，提高计算效率。然而现有的基于图 Transformer 的方法还面临着一些难题，例如深度空间结构信息提取能力不足以及无法有效捕捉分子特征之间的相互关系。

1.3 主要研究内容

由国内外研究现状可知，目前利用深度学习完成分子性质是主要解决方案。然而现有的方法完成分子性质预测方法时，对于分子深度空间结构信息提取和捕捉分子特征之间的相互关系的能力不足，进而导致分子预测性能受到限制。要解决的具体问题和应对方案等细节将在下文具体研究内容中阐述。为便于理解本文研究思路，下面首先整体介绍本文大致研究内容。

本文大致研究内容为：首先，针对现有方法对深度空间结构信息提取不完善的问题，本文对空间结构信息的有效提取进行了研究和探讨，并提出一种基于深度空间信息提取 Transformer 的子图表示分子预测模型（SSET）。随后为了进一步提升分子性质

预测的准确性，本文在提取空间结构信息的基础上引入谱域空间来解决不能有效捕捉分子特征的相互关系的问题，并且提出了一个基于快速注意力融合谱域和空域的双域融合图 Transformer 的分子性质预测模型（DRAM）。

（1）关于深度空间结构信息提取的方法研究

目前基于 Transformer 的分子性质预测模型无法捕获深度空间结构信息。存在这种缺陷是因为标准 Transformer 架构主要用于处理序列数据，其中元素之间的关系通常由它们在序列中的位置定义。此外，大多数基于 Transformer 的模型基于全图完成图预测任务。这导致了计算复杂度高、内存需求大以及局部特征细节丢失的问题。分子中的一些官能团或活性位点对化学性质和生物活性的影响相当大，基于 Transformer 的模型无法捕获这种结构信息，因此在分子性质预测中难以取得良好的结果。为了解决上述问题，本文对于深度空间结构信息提取的方法进行研究，并设计了一种基于深度空间结构信息提取图 Transformer 的分子性质预测模型（SSET）。SSET 由边缘特征融合子图空间结构提取器（ETSE）模块和位置信息编码图 Transformer（PEGT）模块组成。ETSE 模块通过边特征融合和最具价值子图（Mv-subgraph）表示学习完成空间结构信息提取。边特征融合丰富了节点表示，提供了关于图结构更全面的信息。Mv-subgraph 表示提高了模型识别和表示局部结构的能力。然后，本文引入 PEGT 模块来补充位置信息。与传统的图 Transformer 相比，PEGT 增强了结构感知能力，使模型能够更准确地捕获图中节点之间的关系。此外，PEGT 增强了上下文理解，帮助模型分析图结构中每个节点的位置和上下文。模型拟在四个数据集上验证 SSET 在分子性质预测上面的表现。

（2）关于图特征的相互关系捕获方法研究

传统方法由于没有深入挖掘谱域层面的信息，导致对于图特征之间的相互关系捕获能力较弱。为此，本文对于图特征相互关系捕获方法进行了研究，并提出基于双域融合图 Transformer 的分子性质预测方法（DRAM）。DRAM 模型通过新编码方案，能够将分子特征转化为谱域中的独特表示，让模型可以敏锐地捕捉到分子特征间的细微关联，推动模型对于分子特征之间关联的捕捉。在架构层面，DRAM 构建了从谱域和空域两个层次捕捉特征信息的 Fast Attention 架构。该架构整合了谱域的深度分析与空域的直观视角，实现了对分子特征的全面理解。模型主要由两大核心模块组成：谱域注意力模块 FASE 和快速注意力模块 ALGI。谱域注意力模块 FASE 以新编码方案为基础，从全新的视角深入探索谱域空间内分子图特征的相互关系。它通过创新的编码策略，确保在处理分子结构变化时维持置换等变性，这意味着无论分子以何种形式排列，模型都能准确识别其关键特征，极大提升了模型对复杂多变分子结构的适应性。快速注意力模块 ALGI 则结合了全局信息和局部结构，在空域层面发挥关键作用。该模块不仅能够有效保留捕获分子间的长程依赖性，避免了因忽视分子间远距离

相互作用而导致的信息缺失，还通过独特的设计，规避了过度平滑或过度挤压问题，这保证了模型在捕捉分子间复杂关系时，不会丢失关键细节，使得模型在分析大分子体系时，依然能够保持较高的准确性。得益于独特的架构和模块设计，DRAM 模型可以生成更适应不同频率范围和尺度的特征表示。无论是处理高频的局部特征，还是低频的全局特征，模型都能游刃有余。这种卓越的适应性显著提升了模型的泛化能力，使其在面对不同类型的分子数据集时，都能表现出优异的性能。DRAM 模型拟在六个具有代表性的数据集上实验。

1.4 论文组织结构

本文共有五章，如图 1-2 所示。各章节的具体内容如下：

第一章：开篇点明分子性质预测的研究背景，深入剖析其研究意义，随后全面梳理国内外在该领域的研究进展。在此基础上，详细阐释本文的核心研究内容，以及论文的整体结构安排。

第二章：首先对分子图的特性展开介绍，让读者对其有清晰认知。接着，阐述与本研究模型紧密相关的深度学习技术，这些技术为后续章节的深入研究筑牢理论根基。

第三章：引言部分率先阐明提出本章分子性质预测模型的出发点。紧接着，对基于深度空间结构信息提取 Transformer 分子性质预测模型（SSET）展开详细介绍。在模型构建完成后，将 SSET 模型与基线模型的预测结果进行对比，通过实验数据验证 SSET 在分子性质预测方面的有效性。此外，为了进一步探究 SSET 模型的性能，还从消融实验、可视化实验、超参数实验多个维度进行分析。

第四章：引言中说明提出本章模型的目的。随后，介绍基于双域融合图 Transformer 的分子性质预测模型（DRAM），对其整体架构与具体设计细节进行解读。通过对比 DRAM 模型和基线模型的预测结果，验证了 DRAM 模型在分子性质预测上更具优势。并通过消融实验和超参数实验对 DRAM 模型进行全面且深入的研究。

第五章：首先对研究过程中的关键工作进行汇总，清晰梳理了研究成果，点明本研究在相关领域所做贡献。之后，针对研究中的薄弱环节展开反思，基于现有不足，对后续研究方向进行前瞻性思考。




图 1-2 本文组织结构图

1.5 本章小结

本章聚焦分子性质预测。在研究背景及意义方面，药物研发面临高成本、低成功率困境，分子性质预测可助力筛选药物分子、降低成本。研究现状上，回顾了基于统计学、传统机器学习、深度学习的预测模型，重点介绍深度学习模型。主要研究内容为提出 SSET 和 DRAM 分子预测模型，以解决现有方法对于分子深度空间结构信息提取和捕捉分子特征之间的相互关系的能力不足的问题。论文共五章，后续章节将介绍相关理论、详细阐述模型并分析结果，最后总结工作、展望未来。

第2章 相关理论基础

目前,人工智能技术已成为药物研发领域的关键驱动力,并在诸多环节展现出巨大潜力。作为人工智能的核心技术,深度学习因其强大的数据分析和模式识别能力,被广泛应用于药物研发过程。在分子性质预测这一重要研究方向上,图深度学习模型,如图卷积神经网络(Graph Convolutional Neural Network, GCN)^[32]逐步成为主流手段。尤其是图 Transformer(Graph Transformer)^[35]的出现,为分子性质预测带来了新的突破。通过捕捉分子图中原子间的复杂关系以及整合多维度信息,图 Transformer 能够更精准地预测药物分子的各类性质,在分子性质预测任务中表现优异。为给后续研究筑牢根基,本章将按序剖析上述理论与技术要点,结尾处对本章内容加以归纳总结。

2.1 分子图特性

(1) 分子图的基本构成

分子图是基于化学分子结构的图形化表示方式,其中每个节点代表一个原子,每个原子具有一组物理化学属性,例如原子类型、原子电荷、价电子数等。这些属性决定了原子的化学反应性和与其他原子之间的结合方式。边表示分子中原子之间的化学键,包括单键、双键、三键和芳香键等。每条边除了表示原子间的连接,还可以有权重,表示化学键的强度或其他性质。如图 2-1 分别展示的就是乙醛和乙烯醇的分子结构,二者具有相同的分子式: C_2H_4O 。乙醛和乙烯醇是构造异构体,这意味着它们具有相同的分子式但分子结构不同。由于它们的分子结构不同,它们在化学性质上表现出显著差异。




图 2-1 分子图结构示意图

（2）分子图的拓扑结构特性

分子图的拓扑结构反映了分子内部原子与原子之间的连接关系，这一结构具有以下特性：

非欧几里得结构：分子图通常是一个非欧几里得的图，意味着节点之间的距离和连通性无法用简单的欧几里得几何描述。这使得传统的深度学习方法，尤其是卷积神经网络，在处理分子图时遇到了挑战，因为这些方法依赖于规则网格数据。

局部与全局信息的互相依赖：在分子图中，原子间的局部联系往往决定了化学反应性、物理性质等局部特性；而分子整体的化学性质则依赖于原子间更复杂的全局联系。因此，在分子图学习中，既需要捕捉局部的信息，又需要能够处理图结构的全局性质。

（3）分子图的异构性和多样性

分子图不仅具有结构上的多样性，还在化学属性上表现出明显的异构性，这使得分子图的学习任务变得更加复杂：

异构性：在分子图中，不同原子和化学键的类型多样化。不同的原子（如碳、氮、氧等）具有不同的化学属性，这使得图的节点特征在类型和数值上呈现多样性。同样，化学键的类型（如单键、双键、三键）和它们的键长、键能等属性也为分子图提供了丰富的信息。

图的拓扑异质性：分子图的拓扑结构并不是单一的。每种分子在其类别和形态上都有不同的拓扑形式，例如链状分子、环状分子或支链分子等，这些不同的拓扑结构使得图的学习任务更加复杂，需要适应多种不同的图形。

2.2 分子图的子图

在分子性质预测这一任务中，子图作为分子图的重要组成部分，发挥着不可忽视的作用。子图的合理利用能够为分子性质预测提供更深入、更精准的信息，帮助模型更好地理解分子的内在特性。

（1）子图用于提取关键分子特征

分子的性质往往由其特定的结构片段所决定，而子图恰好能够捕捉这些关键的结构信息。例如，在药物分子中，某些特定的官能团子图可能与药物的活性、选择性等性质密切相关。通过识别和提取这些具有关键作用的子图特征，图深度学习模型（如 GCN 和图 Transformer）能够更准确地学习分子的结构与性质之间的关系。

（2）子图增强模型对复杂分子的处理能力

对于结构复杂的分子，直接对整个分子图进行处理可能会导致模型难以捕捉到重要的信息。而将分子图分解为多个子图进行分析，可以降低模型的处理难度，同时提

高模型对复杂结构的理解能力。子图可以反映分子中局部的结构特征和相互作用，这些信息对于分子性质预测至关重要。例如，在预测具有大分子量和复杂拓扑结构的生物分子性质时，利用子图可以更清晰地分析分子中不同区域的功能和相互作用，从而提升模型的预测准确性。

（3）基于子图的分子性质预测方法

目前，已经有一些基于子图的方法应用于分子性质预测任务。例如，子图挖掘算法可以从分子图中自动提取具有代表性的子图模式，然后将这些子图特征输入到预测模型中进行性质预测。另外，一些研究还尝试将子图与注意力机制相结合，让模型更加关注对分子性质有重要影响的子图部分，进一步提高预测的准确性。这些方法为分子性质预测提供了新的思路和途径，推动了该领域的发展。

2.3 图卷积神经网络

（1）图卷积神经网络的基本概念

如图 2-2 所示，图卷积神经网络（GCN）是一类专门用于处理图结构数据的深度学习模型。图数据具有节点和边的特征，每个节点代表一个实体，每条边则表示实体之间的关系。在图卷积网络中，每个节点的特征信息是通过聚合其邻居节点的信息来更新的，类似于传统卷积神经网络（CNN）中的卷积操作，但 GCN 处理的是图结构数据，而不是规则网格数据。

GCN 的核心概念在于节点特征的更新是通过图的邻接关系来完成的。具体来说，GCN 通过图的邻接矩阵与节点的特征矩阵进行乘积操作，将邻接信息传递给节点。图卷积操作的公式通常可以写作：

$$H(l+1) = \sigma(\hat{A}H^{(l)}W^{(l)}) \quad (2-1)$$

其中， $H^{(l)}$ 是第 l 层节点特征矩阵， $\hat{A}$ 是标准化后的邻接矩阵， $W^{(l)}$ 是当前层的权重矩阵， σ 是激活函数。通过多层图卷积的堆叠，GCN 能够逐步整合邻域的信息，捕捉更复杂的图结构特征。




图 2-2 图卷积神经网络简化结构示意图

（2）图卷积神经网络的层次结构

GCN 通常由多个卷积层堆叠而成，每一层都会通过聚合节点邻居的特征来更新节点的表示。具体而言，GCN 的每一层可以看作是在图中进行信息传播和聚合操作，将每个节点的特征更新为其邻域节点特征的加权和。随着 GCN 层数的增加，网络能够捕捉到越来越大的邻域信息，从而提升模型的表达能力。

在 GCN 的层次结构中，信息的传播是逐层进行的。每一层不仅依赖于邻接矩阵来传播节点信息，还包括了激活函数和权重矩阵的学习。通常，GCN 网络的前几层能够聚焦于局部邻域的信息，这对于捕捉原子间直接的化学键信息非常重要。随着层数的增加，网络能够逐渐整合更大范围的图结构信息，捕捉全局特征。因此，GCN 的层数设计在一定程度上影响了模型的能力。但是目前 GCN 存在层数太少可能导致模型无法学习到足够的全局信息，而层数过多则可能导致过拟合，且计算成本过高的问题。除了卷积操作外，GCN 在层与层之间也有信息传递的机制。具体来说，GCN 通过节点间的邻接关系来传递信息，使得每个节点的特征逐渐被更新和精炼。这种信息传递不仅能捕捉到局部信息，也能通过多层聚合的方式，捕捉到图的全局结构特征，具有较强的表达能力。

（3）GCN 在分子图学习中的应用

在分子图学习中，GCN 展现出了强大的应用潜力。分子图通常由原子节点和化学键边构成，GCN 能够通过图卷积操作提取分子的结构信息，从而进行各种性质的预

测。对于分子图，GCN通过处理原子间的化学键和原子属性，能够捕捉分子局部的结构信息。在多层GCN的模型中，每一层都可以根据原子和化学键之间的关系，不断更新节点的特征表示，从而形成分子的全局表征。通过这种方式，GCN能够结合分子的局部信息和全局信息，从而为分子性质的预测提供强有力的支持。

2.4 图 Transformer

图 Transformer (Graph Transformer) 结合了图结构数据的特性与 Transformer 架构，在处理图数据相关任务中具有强大的能力。以下按照步骤详细介绍图 Transformer 及其相关公式：

(1) 节点嵌入初始化

给定一个图 $G = (V, E)$ ，其中 V 是节点集合， E 是边的集合。对于图中的每个节点 $v_i \in V$ ，首先为其分配一个初始的特征向量，即节点嵌入 $h_i^{(0)}$ ，该向量表示节点 v_i 的初始特征信息，后续的计算将基于此展开，如图 2-3 所示。




图 2-3 图 Transformer 计算流程简化架构示意图

(2) 计算查询、键和值向量

对于每一层 l 的每个节点 v_i ，可以通过线性变换来计算其对应的查询向量 q_i 、键向量 k_i 和值向量 v_i 。计算公式如下：

$$q_i = W_q^{(l)} h_i^{(l-1)} \quad (2-2)$$

$$k_i = W_k^{(l)} h_i^{(l-1)} \quad (2-3)$$

$$v_i = W_v^{(l)} h_i^{(l-1)} \quad (2-4)$$

其中, $W_q^{(l)}$ 、 $W_k^{(l)}$ 和 $W_v^{(l)}$ 是第 l 层可学习的权重矩阵, $h_i^{(l-1)}$ 是上一层节点 v_i 的特征向量。

(3) 注意力权重计算

接下来计算节点 v_i 与其他节点 v_j 之间的注意力权重 α_{ij} 。通过计算查询向量 q_i 与键向量 k_j 的相似度, 并经过缩放和归一化操作得到注意力权重。具体公式为:

$$\alpha_{ij} = \frac{\exp\left(\frac{q_i^T k_j}{\sqrt{d_k^{(l)}}}\right)}{\sum_{v_k \in \mathcal{N}(v_i)} \exp\left(\frac{q_i^T k_k}{\sqrt{d_k^{(l)}}}\right)} \quad (2-5)$$

其中, $d_k^{(l)}$ 是第 l 层键向量的维度, $\mathcal{N}(v_i)$ 表示节点 v_i 的邻居节点集合。

(4) 多头自注意力计算

为了捕捉不同方面的信息, 图 Transformer 通常使用多头自注意力机制, 机制架构如图 2-4 所示。假设有 h 个注意力头, 对于每个头 $s = 1, 2, \dots, h$, 分别按照上述步骤计算注意力权重和聚合邻居节点的值向量。第 s 个注意力头的输出 head_s 为:

$$\text{head}_s = \sum_{v_j \in \mathcal{N}(v_i)} \alpha_{ij}^s v_j^s \quad (2-6)$$

其中, α_{ij}^s 是第 s 个注意力头中节点 v_i 与 v_j 之间的注意力权重, v_j^s 是第 s 个注意力头中节点 v_j 的值向量。

然后将 h 个注意力头的输出进行拼接, 并通过一个线性变换得到节点 v_i 在多头自注意力机制后的特征向量 $h_i^{(l)'} :$

$$h_i^{(l)'} = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h) W^O \quad (2-7)$$

其中, W^O 是可学习的权重矩阵。

(5) 前馈神经网络处理

将多头自注意力机制的输出 $h_i^{(l)'}$ 送入前馈神经网络 (FFN) 进行进一步的特征变换。前馈神经网络通常由两个线性层和一个激活函数组成, 公式如下:

$$h_i^{(l)} = \text{FFN}(h_i^{(l)'}) = \sigma(W_2^{(l)} \text{ReLU}(W_1^{(l)} h_i^{(l)'} + b_1^{(l)}) + b_2^{(l)}) \quad (2-8)$$

其中, $W_1^{(l)}$ 和 $W_2^{(l)}$ 是第 l 层前馈神经网络的可学习权重矩阵, $b_1^{(l)}$ 和 $b_2^{(l)}$ 是对应的偏置向量, ReLU 是线性整流单元激活函数, σ 通常是一个非线性激活函数, 如 Sigmoid 或 GELU。




图 2-4 多头自注意力机制示意图

经过上述步骤，图 Transformer 能够逐步更新节点的特征表示，从而有效地捕捉图中节点之间的关系和结构信息，在图的表示学习、节点分类、图分类等众多任务中发挥重要作用。

2.5 图神经网络组件

图神经网络的设计由多个重要组件构成，这些组件在深度学习中扮演着至关重要的角色，尤其是在图神经网络和图 Transformer 的应用中。这些组件不仅影响网络的训练效率，还直接影响模型对图数据的处理能力和最终的预测效果。以下是神经网络中的一些关键组件，它们在图数据处理任务中各自发挥着独特作用。

2.5.1 激活函数

激活函数在神经网络中具有非常重要的作用，它们不仅为网络引入了非线性特性，使得神经网络能够学习到复杂的模式，还决定了网络在训练过程中如何调整参数。尤其是在图神经网络（GNN）和图 Transformer 等模型中，激活函数的选择直接影响模型的表现。

常见的激活函数如图 2-5 所示包括 ReLU、Leaky ReLU、Sigmoid 和 Tanh 等，每种激活函数都有其独特的特点和适用场景。




图 2-5 常见激活函数曲线示意图

ReLU（修正线性单元）是最为常见的激活函数之一。其数学表达式为：

$$f(x) = \max(0, x) \quad (2-9)$$

ReLU 的主要优点是计算简单且能够避免梯度消失问题，因此在深度神经网络中广泛应用。ReLU 在正输入值时能够保留原始信息，而对于负输入则输出 0，这使得网络能够快速捕捉到正向信号。然而，ReLU 也有一些缺点，最突出的就是它可能导致“死神经元”现象，即一些神经元在训练过程中因一直输出 0 而无法更新。为了缓解这一问题，Leaky ReLU 作为 ReLU 的改进版本应运而生。Leaky ReLU 的公式为：

$$f(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases} \quad (2-10)$$

其中， α 通常取 0.01。通过允许负输入值以较小的比例传递信息，Leaky ReLU 能够减少“死神经元”问题，确保网络在训练过程中的信息流动更加平稳。

与 ReLU 和 Leaky ReLU 不同，Sigmoid 函数将输入值映射到 0 到 1 之间，通常用于二分类任务。其数学表达式为：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-11)$$

Sigmoid 的输出范围 (0, 1) 使得它特别适合用于表示概率，尤其是在需要输出概率值的任务中，如二元分类任务。尽管 Sigmoid 具有良好的概率解释性，但它也有

一个明显的缺点，即梯度消失问题。尤其是在网络的深层中，Sigmoid 的梯度非常小，导致在反向传播过程中梯度逐渐减小，影响网络的训练效率。

Tanh（双曲正切）函数是 Sigmoid 的一个变种，它将输入值映射到-1 到 1 之间。其公式为：

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-12)$$

Tanh 的输出范围比 Sigmoid 更广（-1 到 1），可以更好地避免梯度消失的问题，因为它的输出值不会集中在 0 附近，增加了梯度更新的稳定性。然而，尽管 Tanh 相比于 Sigmoid 在某些情况下表现更好，但在深层网络中，梯度消失问题依然可能存在，尤其是在输入值过大或过小时，梯度会变得极小，影响模型的学习能力。

在图神经网络和图 Transformer 的设计中，激活函数的选择直接影响到模型的性能。ReLU 由于其计算效率高、避免梯度消失的问题，通常在图神经网络中成为首选。它能够帮助模型快速捕捉节点间的非线性关系，尤其在分子图性质预测等任务中非常有效。而 Leaky ReLU 则由于其避免死神经元的特性，适合用于那些需要捕捉更复杂特征的任务。Sigmoid 和 Tanh 则更多地用于输出层或者某些特定的任务中。

激活函数作为神经网络架构中的关键非线性模块，其设计与选择深度影响着网络训练过程中的信息传递机制与学习效能。在神经网络前向传播阶段，激活函数通过引入非线性变换，打破线性模型的表达瓶颈，使得网络能够学习数据中复杂的非线性映射关系。在反向传播过程中，激活函数的导数特性直接决定梯度的传播路径与强度，合适的激活函数可有效避免梯度消失或梯度爆炸问题，保障参数更新的稳定性与收敛效率。

总体而言，激活函数的选择决定了神经网络在训练过程中的信息流动和学习效率。通过合理的激活函数设计，神经网络能够更好地理解图结构中的特征，尤其是在分子图性质预测任务中，合理选择激活函数可以显著提升模型的性能。

2.5.2 损失函数

损失函数作为神经网络训练过程中的核心要素，在优化模型参数、引导学习方向中发挥着至关重要的作用。它通过量化模型预测结果与真实值之间的差异，将抽象的优化目标转化为可计算的数值标量，为梯度下降、随机梯度下降及其变体等优化算法提供明确的优化方向。不同类型的损失函数基于各自独特的数学特性与设计逻辑，对模型训练的动态过程产生差异化影响。在图任务中，常用的损失函数如图 2-6 所示包括均方误差（MSE）、交叉熵损失（Cross-Entropy）。




图 2-6 常见损失函数曲线示意图

对于回归任务，均方误差（MSE）是最常见的损失函数，它通过计算预测值与真实值之间的差异的平方和，来量化模型的误差。交叉熵损失则广泛用于分类任务中，尤其是在处理分子图的分类任务时，交叉熵能够有效度量不同类别之间的距离，从而优化分类性能。

对于分子图性质预测任务，损失函数的选择至关重要。适当的损失函数不仅能够帮助网络从数据中学习到的关键的特征，还能确保在高维数据中进行有效的优化。因此，针对具体任务选择合适的损失函数是训练成功的关键因素之一。

2.5.3 优化算法

优化算法是神经网络训练过程中不可或缺的一部分。它的作用是调整网络的权重参数，以最小化损失函数的值。常见的优化算法有随机梯度下降（SGD）、动量优化（Momentum）、Adam 等。在处理大规模图数据时，优化算法的效率和稳定性显得尤为重要。

（1）随机梯度下降（SGD）：

作为最基础的算法，SGD 每次从训练数据中随机抽取一个样本，基于该样本计算的梯度来更新权重。这种做法大幅降低计算量，使算法更易于实现。但由于更新方向依赖单个样本，会导致训练过程出现波动，难以快速收敛到最优解。不过，也正是因为这种随机性，SGD 有机会跳出局部最优，找到全局最优解。

（2）动量优化（Momentum）：

动量优化引入物理学中的动量概念，模拟物体运动的惯性。在更新权重时，算法

不仅考虑当前样本的梯度，还结合上一次的更新方向，使权重更新更具连贯性。这一特性有效减少了梯度更新时的震荡，加快了收敛速度，特别适用于处理损失函数呈沟壑状的情况。

（3）Adam:

将动量算法和自适应梯度算法的优势集于一身。一方面，它利用动量来加速收敛，另一方面，又能为每个参数分配自适应学习率，从而避免梯度消失和梯度爆炸的问题。该算法在复杂的深度学习模型训练中，展现出强大的适应性，不仅训练过程稳定，收敛速度也非常快，因此在图像识别、语音识别和自然语言处理等多个领域得到广泛应用。

2.5.4 Dropout

Dropout 是一种常见的正则化方法，旨在防止神经网络的过拟合。它的基本思想是在训练过程中随机“丢弃”一定比例的神经元，这样可以避免网络过度依赖某些特定的神经元，增强模型的泛化能力。在图神经网络中，Dropout 不仅在卷积层之后应用，也可用于自注意力机制和其他网络层。Dropout 的使用有效地减少了网络在学习过程中对特定路径的过度依赖，确保了模型能够学习到更加稳定和鲁棒的特征表示。在训练图模型时，尤其是在面对大规模图数据时，Dropout 能够显著提高模型的抗噪声能力，并使得最终的预测更加可靠。

2.5.5 全连接层

（1）基本概念

全连接层（Fully Connected Layer）是神经网络中最基础的层结构之一。示意图如图 2-7 所示。在全连接层里，每一个神经元都和上一层的所有神经元相连接。这意味着该层的每个神经元的输入，是上一层所有神经元输出的加权和，再加上一个偏置项。可以用以下公式来表达：

$$y_j = \sum_{i=1}^n w_{ij} x_i + b_j \quad (2-13)$$

其中, x_i 代表上一层第 i 个神经元的输出, w_{ij} 是连接上一层第 i 个神经元与当前层第 j 个神经元的权重, b_j 是当前层第 j 个神经元的偏置, y_j 是当前层第 j 个神经元的输出, n 是上一层神经元的数量。




图 2-7 全连接层示意图

(2) 在图神经网络中的工作机制

在图神经网络里, 全连接层一般处于网络的后端。前面的图卷积层或者自注意力机制层会对图结构数据进行特征提取与转换, 获取节点或者图的特征表示。而全连接层的作用就是进一步处理和融合这些不同层次、不同来源的特征信息。例如, 在分子性质预测任务中, 图卷积层能够根据分子图的邻接关系对原子节点的特征进行聚合和更新, 从而捕捉分子的局部结构特征。全连接层则会接收这些经过处理的节点特征, 通过一系列的线性变换和非线性激活, 把它们整合为一个固定长度的特征向量, 这个向量就代表了整个分子的特征。之后, 再把这个特征向量输入到输出层, 对分子的性质进行预测。

2.6 本章小结

本章主要阐述了图相关理论基础。首先介绍了分子图以及相关的子图内容, 点明其结构特性对于分子图性质预测的重要性。接着介绍了图卷积神经网络与图 Transformer 这两类重要模型, 说明它们在处理图数据的特点和作用。最后阐述图神经

网络包含的多种组件，各组件协同工作，在模型运行中发挥作用，为后续深入研究图数据处理及相关应用奠定基础。

第3章 基于深度空间结构信息提取图 Transformer 的分子性质预测模型

3.1 引言

在药物研发领域，分子的结构与功能关联研究是核心命题，而空间结构作为连接微观原子排布与宏观性质的关键维度，起到一个非常重要的作用。例如，分子的立体构象和空间排列会影响其反应性、相互作用以及药物活性。此外，分子的拓扑结构会影响其化学性质和反应性，化学键的类型和长度能决定分子的稳定性和功能。然而，现有的图 Transformer 主要关注节点之间的相互作用和关系，却不考虑节点在空间中的具体位置以及空间结构信息。因此，它可能无法直接捕捉分子的立体构象和空间排列。这种能力的缺失在处理分子异构体或具有空间特征的分子时会限制模型分子性质预测能力。

为解决上述问题，本章基于深度空间结构信息提取 Transformer 设计了一个名为 SSET 的分子性质预测模型。SSET 模型由边缘特征融合子图空间结构提取器（ETSE）模块和位置信息编码图 Transformer（PEGT）模块组成。ETSE 模块通过边缘特征融合和最具有价值子图表示来完成空间结构信息的提取。边缘特征融合丰富了节点的表示，提供了关于图结构更全面的信息。Mv-subgraph 的表示学习提高了模型识别和表示局部结构的能力。PEGT 模块负责补充分子节点位置信息方面的工作。与传统图 Transformer 相比，PEGT 增强了结构感知能力，使模型能够更准确地捕捉图中节点之间的关系。此外，PEGT 增强了上下文理解，帮助模型分析整个图结构中每个节点的位置和上下文信息。此外，SSET 模型通过使用子图减轻了高计算复杂度带来的负担。在真实数据集上进行的实验表明，基于图 Transformer 构建的 SSET 模型极大地改进了分子性质预测能力。

3.2 模型框架

本节首先从宏观上介绍 SSET 的整体架构。随后，分别介绍 SSET 包含的两个子模块 ETSE 和 PEGT。子模块 ETSE 中介绍边特征融合、节点遴选以及子图空间信息提取。在子模块 PEGT 中介绍结合编码信息嵌入的图 Transformer。

如图 3-1 所示, 该模型图分为两部分, 蓝色线条内的边缘特征融合子图空间结构提取器 (ETSE) 模块以及线条之外的位置信息编码图 Transformer (PEGT) 模块。对于 ETSE 模块, 首先, 最具价值子图 (Mv-subgraph) 通过简单图卷积 (SGC) 进行处理, 并且通过叠加权重对分子特征进行嵌入, 以获得带有分子子空间结构信息的特征表示 X_S 。其次, 分子边缘特征 E 基于主成分分析融合 (PF) 算法进行方法处理, 并通过多层感知机 (MLP) 进行特征处理, 从而得到分子化学键的特征表示 $E^{(1)}$ 。对于 PEGT 模块, 首先将 A 通过奇异值分解位置信息编码 (SVD PE) 方法进行处理, 以获得位置信息编码 P 。将 P 与分子节点特征进行叠加, 从而得到携带位置信息的分子特征表示 X_P 。对于这两个模块的整合过程, 首先将 X_S 通过线性层进行处理, 以完成维度变换, 使其成为 Transformer 编码器中的查询 Q 和键 K 。然后, 将从 PEGT 模块获得的 $E^{(1)}$ 和 X_P 通过消息传递神经网络 (MPNN) 进行处理, 以获得嵌入了化学键信息和原子位置信息的特征表示 X_E , 将其作为 Transformer 编码器中的值 V 。最后, 通过 Transformer 编码器和输出层的处理来完成分子性质预测。




图 3-1 SSET 模型的架构图

3.3 子图空间结构提取

分子的化学性质往往与其局部结构特征密切相关。利用子图来完成分子图表示能够凸显这些局部特征, 比如官能团、环结构或者特定化学键。而且, 它还能构建模型以理解整个分子提供关键信息。因此, 子图是提取分子空间结构信息的重要工具, 在理解分子组成方面起着至关重要的作用。基于上述分析, 本章设计了边缘特征融合子图空间结构提取器 (ETSE) 模块, 旨在通过边缘特征融合以及最具有价值子图表示的处理来生成包含空间结构信息的图向量表示。在接下来的讨论中, 本章将整个分

子图记为 $G = (V, X, E)$ ，其中节点 $u \in V$ 的节点属性用 $X_u \in X \subset R^d$ 来表示，对于一个含有 n 个节点的图，所有节点的节点属性都存储在 $X \in R^{n \times d}$ 中。

3.3.1 边特征融合

分子图的边缘特征为分子中原子间的相互作用、连接性、拓扑结构以及空间信息提供了重要内容。这些信息对于理解分子结构、性质及行为十分关键。因此，本章引入了一个基于主成分分析融合（PF）算法的边缘特征信息融合模块来完成此项工作。在这个融合工作中，数据首先需要进行归一化处理。对于输入的原始图 G ，每张图代表一个分子，节点代表原子，而边代表化学键。图 G 的边缘特征信息记为 $E \in R^{e \times m}$ 。利用边缘特征矩阵 E ，可以按如下方式计算协方差矩阵 C ：

$$C = \frac{1}{e-1} \left(E - \frac{1}{e} \sum_{i=1}^e E_i \right)^T \left(E - \frac{1}{e} \sum_{i=1}^e E_i \right) \quad (3-1)$$

然后，对协方差矩阵 C 进行特征值分解，以获取特征值以及相应的特征向量 v 。选取前 r 个特征向量作为主成分。接着，将原始边缘特征矩阵 E 投影到所选的主成分上，从而得到降维后的特征矩阵 $E^{(0)}$ 。这一过程由以下公式描述：

$$Cv = \lambda v, E^{(0)} = \left(E - \frac{1}{e} \sum_{i=1}^e E_i \right) \xi_r, \text{ where } \xi_r = [v_1 \ v_2 \ \cdots \ v_r] \quad (3-2)$$

上述等式中的 ξ_r 是包含前 r 个特征向量的矩阵。最后，通过将矩阵 $E^{(0)}$ 的各行相加进行聚合，并利用全连接层完成维度变换，便可得到一个新的边缘特征向量表示 $E^{(1)}$ ：

$$E_i^{(1)} = MLP \left\{ \sum_{j=1}^r E_{ij}^{(0)} \right\} \quad (3-3)$$

在这项基于主成分分析融合（PF）算法的边缘特征融合工作中，本章首先将高维的分子图数据转换为一种低维表示形式，这种形式保留了数据中的主要信息。这一操作降低了数据的复杂度以及计算负担。同时，通过找出数据中的主成分，可以提取出分子图中最具代表性的特征。这些主成分在分子结构、分子功能以及分子间相互作用方面都起着重要作用。因此，保留下来的主成分能够帮助模型聚焦于最相关的那些特征。此外，分子的全局特征对于描述整体分子结构和功能而言至关重要。出于这个原因，模型通过聚和操作来捕捉分子图的整体特征，以便更好地理解和分析分子的性质。

3.3.2 节点遴选

通过选取特定的原子或残基作为子图的节点，能够聚焦于分子内的某个特定区域，以便更好地明晰该区域的空间结构。为此，模型设计了一种介数中心性页面排名（BCPR）算法，并利用它对分子图中节点的重要性进行排序。本节将引入最具有价值图节点（Mv-node）的概念。对于一个具有 n 个节点的分子图 $G = (V, X, E)$ ，节点 $u \in V$ 的介数中心性值（BCV）定义为：

$$BCV(u) = \sum_{s \neq u \neq t} \frac{\sigma_{st}(u)}{\sigma_{st}} \quad (3-4)$$

在上式中， σ_{st} 表示从节点 s 到节点 t 的最短路径的数量，而 $\sigma_{st}(u)$ 表示在从节点 s 到节点 t 的最短路径中经过节点 u 的数量。第 i 个节点的初始中心性页面排名值（CPRV）可通过介数中心性值（BCV）来获得。其计算公式如下：

$$CPRV_{\text{initial}}(i) = \frac{BCV(i)}{\sum_{i=1}^n BCV(i)} \quad (3-5)$$

然后，中心性页面排名值（CPRV）可通过以下等式完成迭代：

$$CPRV(u) = (1 - \psi) + \psi \sum_{s \in In(u)} \frac{CPRV(s)}{Out(s)} \quad (3-6)$$

其中， $In(u)$ 表示指向节点 u 的节点集合， $Out(s)$ 表示节点 s 的出度， ψ 是一个介于 0 和 1 之间的阻尼因子。最后，在中心性页面排名值（CPRV）经过多次迭代稳定之后，根据该值筛选出排名靠前的 N 个最具有价值图节点（Mv-node）：

$$\text{Mv-nodes} = \text{TopValue}(CPRV(\text{Graph}), N) \quad (3-7)$$

在最具有价值图节点（Mv-node）筛选过程中，首先需要计算每个节点的介数中心性值（BCV），该值能够反映节点在分子结构、功能以及相互作用中所起的关键作用。然后，通过介数中心性-页面排名（BCPR）算法对介数中心性值（BCV）做进一步处理，以得到中心性页面排名值（CPRV），该值会通过不断迭代而趋于稳定。最后，利用图中各节点的 CPRV 筛选出排名靠前的 N 个 Mv-node。从理论上讲，BCPR 算法是依据分子图的连通性和传递性原理来筛选 Mv-node 的。具体而言，分子中的节点之间存在着复杂的连通关系，这种关系反映了分子内部的结构以及相互作用情况。传递性原理指的是，与重要节点相连接的节点也具备一定的重要性。基于这两项原理，BCPR 算法通过不断迭代逐步收敛，从而获得稳定的 CPRV。CPRV 较高的节点也被视作更为重要的节点。筛选出最具有价值图节点（Mv-node）能够使生成的子图降低后续模型计算的时空复杂度。这样的筛选方式还能凸显出重要节点以及它们之间

的连通关系，从而使模型能够更好地理解分子的关键特征以及空间结构信息。

3.3.3 空间结构信息提取

BCPR 算法能够获取分子图的最具有价值图节点 (Mv-node)，接下来需要考虑利用这些最具有价值图节点构建最具有价值子图 (Mv-subgraph) 以及提取空间结构信息。利用 k 跳算法提取子图，能够有效捕捉一个节点与其 k 跳邻域节点之间的关系。通过选择合适的 k 值，可以控制子图的大小，使子图包含该节点的局部邻域信息。这一特性有助于在分析图数据时聚焦于节点的局部结构，且不受整个图规模的影响。基于上述分析，本章选择采用 k 跳算法来生成 Mv-subgraph。首先运用 k 跳算法完成子图 G_k 的提取工作。随后，需要对生成的子图表示 G_k 提取其空间结构信息。提取子图空间结构信息的方法有很多，比如传统的图卷积神经网络、图注意力网络以及图自编码器等。然而，上述方法在提取空间结构信息时相关的时空复杂度，可能会阻碍整个模型应用于更大规模的数据集。与之相比，简单图卷积 (SGCConv) [60] 通过多次迭代来累积邻域节点的特征，以此提取更丰富的图结构信息。与传统的图卷积操作相比，SGCConv 省略了非线性变换，这使得计算效率更高。该方法可表示为：

$$S = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} \quad (3-8)$$

其中， S 表示添加了自环的正则化邻接矩阵， $\tilde{A}$ 是在 A 的基础上添加了自环的矩阵，而 $\tilde{D}$ 是 $\tilde{A}$ 度矩阵。

$$X_M = S^l X Y, \text{ where } Y = Y^{(1)} Y^{(2)} Y^{(3)} \dots Y^{(l)} \quad (3-9)$$

其中， S 矩阵的多次乘积被合并为 S 的 l 次幂，即 S^l 。而 $Y^{(l)}$ 是与每一层相关联的权重矩阵，并且 Y 会将权重重新参数化为单个矩阵， X_M 表示一种提取子空间结构信息的特征表示。

本节基于 k 跳算法和简单图卷积 (SGCConv) 算法设计了整个空间结构信息提取模块。通过 k 跳算法生成的最具有价值子图 (Mv-subgraph) 能够有效地捕捉节点与其 k 跳邻域节点之间的关系。通过选择合适的 k 值，可以对该子图的大小进行控制，使子图包含节点的局部邻域信息。此外，Mv-subgraph 能够突出分子结构中最重要的一部分，让关键区域的空间结构和功能特性更加清晰明了，而不会被整个分子结构的复杂性所掩盖。与处理整个分子图相比，Mv-subgraph 显著减少了节点和边的数量，降低了计算复杂度和资源消耗，在处理大型或复杂分子时能够更快地得出结果。然后，在提取空间结构信息时，SGCConv 通过对邻接矩阵的乘法运算进行多次迭代来累积节点的邻域信息。这一操作有助于保留节点的局部结构特征，从而能更好地理解节点的功能及相互作用。而且，由于使用的是子图而非全图，这种处理方式在处理大规模图

数据时成为了一种有效的方法。

3.4 位置信息编码图 Transformer

传统图神经网络通常通过聚合局部邻域节点来更新节点表示，图 Transformer 引入了一种自注意力机制，该机制允许每一层中所有节点进行全局信息交互。这使得图 Transformer 能够更好地捕捉节点之间的全局依赖关系，并改进模型表示效果。然而，以往的图 Transformer 主要关注分子节点之间的相互作用，却忽略了原子的位置信息。因此，它无法直接捕捉分子的空间排列情况。为此，本章基于奇异值分解（SVD）^[61]编码设计了一个位置信息编码图 Transformer（PEGT）模块来解决这一问题。对于一个具有 n 个节点的分子图 G ，其中 $A \in R^{n \times n}$ 表示其邻接矩阵。通过奇异值分解（SVD）编码，邻接矩阵 A 可分解为如下形式：

$$A = O \Sigma H^T, \text{ where } \Sigma = \text{diag}(\sigma_1, \sigma_2, \sigma_3, \dots, \sigma_n) \quad (3-10)$$

其中， $O \in R^{n \times n}$ 是左奇异矩阵， $H \in R^{n \times n}$ 是右奇异矩阵，且它们都是正交矩阵。 $\Sigma \in R^{n \times n}$ 是矩阵 A 的奇异值矩阵，奇异值 σ 按如下顺序排列： $\sigma_1 \geq \sigma_2 \geq \sigma_3 \geq \dots \geq \sigma_n = 0$ 。与较小奇异值相对应的特征向量往往捕捉的是数据中的微小波动或噪声，而非主要的结构信息。通过保留较大的奇异值及其对应的向量，能够更好地捕捉数据的主要结构特征，从而提高模型的稳定性和泛化能力。基于此原因，本章设计了一个动态参数 ρ ，以便依据截断奇异值分解^[62]对编码进行截断。因此，公式（3-10）被重写成了一种新的形式。

$$A \approx \hat{O} \Sigma_\rho \hat{H}^T = (\hat{O} \Sigma_\rho^{1/2}) \cdot (\hat{H} \Sigma_\rho^{1/2})^T, \text{ where } \rho = \min \left\{ k : \frac{\sum_{i=1}^k \sigma_i}{\sum_{j=1}^N \sigma_j} \geq \tau \right\} \quad (3-11)$$

其中 $\hat{O}$ 、 $\hat{H}$ 分别是截去前 ρ 列后的左奇异矩阵和右奇异矩阵， Σ_ρ 是对应于前 ρ 个奇异值的对角矩阵， k 表示被截断的奇异值的数量， τ 表示保留了多少信息，将该值设为 0.9。

公式（3-11）中的 $\hat{O} \Sigma_\rho^{1/2}$ 和 $(\hat{H} \Sigma_\rho^{1/2})^T$ 分别表示为 P_l 和 P_r 。下一步是将 P_l 和 P_r 进行拼接以获得位置编码矩阵 P_s 。此外，对左右奇异值向量的符号进行随机反转，以保证模型的泛化能力。然后， P_s 矩阵需要一个嵌入层来完成维度转换，以便进行下一步操作以及特征向量的融合。最终，分子图中节点的位置信息得以被捕捉。总而言之，位置信息编码图 Transformer 的自注意力机制可表述如下：

$$P = PEE\{P^S\}, \text{ where } P^S = SR(P^l \parallel P^r) \quad (3-12)$$

其中, PEE 表示位置编码嵌入, SR 表示符号反转, $\parallel$ 表示按列拼接, P 表示分子图的位置编码。

$$PI = W_V X_E + B_V, \text{ where } X_E = EFF\{P + X^{(0)}\} \quad (3-13)$$

其中, W_V 、 B_V 分别代表输入 V 的权重矩阵和偏置矩阵, EFF 表示边特征融合, $X^{(0)}$ 表示经过原子嵌入处理后所获得的新的分子节点特征表示。

$$Attn = \text{softmax} \left(\frac{(W_Q X_s + B_Q)(W_K X_s + B_K)^T}{\sqrt{d_k}} \right) \cdot PI \quad (3-14)$$

其中, W_Q 、 W_K 分别代表输入 Q 和输入 K 的权重矩阵, B_Q 和 B_K 则分别代表它们的偏置矩阵, d_k 是缩放因子。经过多头注意力机制、前馈神经网络、层归一化等一系列迭代操作后, 注意力 ($Attn$) 会由输出层进行处理来进行分子性质预测。

总体而言, 本章设计了如图 3-2 所示的位置信息编码图 Transformer。利用 SVD 编码构建的分子图 Transformer 能有效地进行降维以提取关键特征, 增强了模型的表征能力和预测性能。




图 3-2 PEGT 模块的架构图

3.5 实验分析

在本节中，使用四个中大型基准数据集来评估 SSET 模型在分子性质预测方面的性能。此外，还对 SSET 模型架构的不同组成部分进行了分析，以确定性能提升的驱动因素。表 3-1 介绍了四个数据集的详细信息。

表 3-1 四个数据集的详细信息

数据集	图数量	平均节点数	平均边数	任务	评价指标
ZINC	12,000	23.2	49.8	回归	MAE
MolHIV	14,000	117.5	4749.2	分类	ACC
PATTERN	41,127	25.5	27.5	分类	AUROC
MolPCBA	437,929	26.0	28.1	分类	AP

3.5.1 数据集介绍

ZINC^[63]数据集在计算化学和药物研发领域占据着重要地位，它提供了全面的结构信息集合。该数据集涵盖了多种多样的化合物，包括类药样本以及适用于药物设计的实体。ZINC 数据集中的详细结构及其相关属性为药物设计、虚拟筛选以及机器学习模型的训练提供了宝贵的基础。具体而言，该数据集被用于图回归任务，重点是预测分子图的受限溶解性属性。

PATTERN^[64]数据集代表了一项通过随机块模型创建的节点分类任务，该任务通常应用于社交网络社区建模。通过调节社区内和社区外的连接来控制任务难度。PATTERN 数据集主要旨在评估识别特定预定义子图这一核心的图任务。设计该数据集的目的是为了挑战并评估图神经网络（GNN）的性能，尤其是评估它们基于图中存在的结构和关系信息来识别并分类节点的能力。

MolHIV^[65]数据集是抑制艾滋病毒复制研究的基础。该数据集中的每个图都代表一个独特的分子，其中原子为节点，化学键为边。节点特征包含一个 9 维向量，涵盖了原子序数、手性、形式电荷以及成环情况等信息。边特征跨越 3 个维度，囊括了化学键类型、立体化学以及表明共轭情况的其他特征等信息。该数据集的主要目标是准确预测二元标签，以表明给定分子是否对艾滋病毒复制有抑制作用。

MolPCBA^[65]数据集是药物研发和化学信息学研究的关键资源。它包含众多化合物详尽的结构及生物活性数据，被广泛用于训练和评估用于预测分子特性及生物活性的机器学习模型。MolPCBA 数据集为数以万计的分子提供了简化分子线性输入规范（SMILES）表示以及多种生物活性检测结果，包括对各类靶点的抑制活性和结合亲

和力等。这些数据有助于加快药物研发进程，并提高分子特性预测的准确性。

本章将 SSET 模型与以下经典的图神经网络（GNN）方法进行比较：图卷积网络（GCN）^[32]、图同构网络（GIN）^[37]、图注意力网络（GAT）^[35]、有向图网络（DGN）^[66]、图子结构网络（GSN）^[67]、主邻域聚合网络（PNA）^[68]、图采样与聚合网络（GraphSAGE）^[34]、各向同性高效图卷积网络（EGC-M）^[69]、药物反应预测网络（GPDRP）^[70]、细胞通讯预测网络（CCP）^[71]。此外，SSET 还与几种近期在图上应用的 Transformer 模型进行比较，例如图 Transformer（Graph Transformer）^[52]、分层路径感知图 Transformer（GTSP-HP）^[72]、通用图 Transformer（GGFormer）^[73]、频谱注意力网络（SAN）^[55]、图 Transformer（Graphormer）^[54]、基于自监督的图表示学习框架（Grover）^[53]、药物异构图 Transformer（PharmHGT）^[57]、基于图 Transformer 神经网络的药物-靶点相互作用模型（GraphormerDTI）^[74]。

图卷积网络（GCN）：图卷积网络（GCN）是一种深度学习模型，专门用于提取和理解图结构数据中的模式。

图同构网络（GIN）：图同构网络（GIN）是一种专为图结构数据定制的神经网络架构，尤其侧重于捕捉和处理图同构问题。

图注意力网络（GAT）：图注意力网络（GAT）是为图结构数据开发的一种神经网络架构。它运用注意力机制使节点能够有选择性地聚合来自相邻节点的信息。有向图网络（DGN）：

有向图网络（DGN）引入了一种以无监督方式将方向嵌入到图网络中的机制，有助于更准确地表示各种物理或生物学问题中的各向异性特征。

图子结构网络（GSN）：图子结构网络（GSN）利用基于子结构编码的拓扑感知消息传递机制。它保留了标准图神经网络（GNN）的关键特性，并且在区分具有挑战性的图同构实例方面表现出色。

主邻域聚合网络（PNA）：主邻域聚合网络（PNA）提出了一种新颖的架构，它将多个聚合器与度缩放器相结合。它将这一理论框架扩展到包含连续特征，这些连续特征在现实世界的输入领域以及图神经网络（GNN）的隐藏层中十分常见。

图采样与聚合网络（GraphSAGE）：采样与聚合（GraphSAGE）是一个通用的归纳框架，它利用节点特征信息有效地生成节点嵌入表示。

各向同性高效图卷积网络（EGC-M）：各向同性图神经网络——高效图卷积（EGC）通过采用空间变化自适应滤波器，始终优于类似的各向异性模型，包括流行的图注意力网络（GAT）或主邻域聚合网络（PNA）等架构。

药物反应预测网络（GPDRP）：药物反应预测网络（GPDRP）提出了一种新方法，它将药物分子图谱与细胞基因通路活性评分相结合，显著提高了药物反应预测的准确性。

图 Transformer: 图 Transformer 引入了显式关系编码, 使得远距离节点之间能够直接通信, 并为全局图结构建模提供了一种有效的方法。

频谱注意力网络 (SAN): 频谱注意力网络 (SAN) 利用学习到的位置编码 (LPE) 来充分利用拉普拉斯频谱, 以学习给定图中每个节点的位置。

图 Transformer (Graphormer): 图 Transformer (Graphormer) 建立在标准 Transformer 的基础上, 采用全局自注意力作为聚合机制, 允许节点之间进行无约束的长距离动态交互。

基于自监督的图表示学习框架 (Grover): 基于自监督的图表示学习框架 (Grover) 提出了一种自监督图表示学习框架, 通过在节点、边和图层面开展自监督任务, 从无标记的分子数据中学习结构和语义信息, 它将消息传递网络与 Transformer 相结合, 以实现更强的分子编码能力。

基于图卷积网络 (GCN) 的方法通常由于其局部邻域聚合的特性, 往往只能捕捉相对较近节点之间的相互作用。然而, SSET (结构增强自注意力图 Transformer) 模型能够通过自注意力机制在全局范围内动态地权衡不同节点之间的关系。因此, SSET 模型能够更好地捕捉远距离原子之间的相互作用力, 进而提高分子图表示的准确性。通过结合端到端结构增强 (ETSE) 模块和位置编码引导图 Transformer (PEGT) 模块, SSET 模型充分利用了分子结构信息、位置信息以及化学键信息, 这极大地提升了捕捉分子远距离相互作用的能力以及分子性质预测的准确性。与现有方法相比, SSET 在多个方面具有显著优势。例如, 尽管图 Transformer (Graphormer) 使用了全局自注意力机制, 但它缺乏对局部子图特征的深入挖掘, 导致其在细粒度的远距离相互作用捕捉方面有所不足。相比之下, SSET 通过结合稀疏图卷积 (SGC) 和全局自注意力机制, 能在更细粒度的层面上捕捉远距离原子之间的相互作用。此外, 基于自监督的图表示学习框架 (Grover) 侧重于结构和语义信息的学习, 但忽略了对位置信息的综合利用。而 SSET 通过奇异值分解位置编码 (SVD PE) 方法以及位置信息编码, 能够提供对分子特征更全面的表示。总而言之, SSET 在分子特征提取和分子性质预测能力方面显著优于现有的基于 Transformer 的方法。

3.5.2 实验设置

本章使用的所有四个数据集均可从官方网站下载。所有实验均在英伟达 A-10 GPU 上进行。SSET 模型所使用的基本参数详情可在表 3-2 中找到。此外, 有两个超参数, 即 M 和 K , 它们对模型有着重大影响, 下面将分别进行讨论。参数 M 代表 Mv-node 的数量, 参数 K 代表 Mv-subgraph 生成的规模。以 MolHIV 数据集为例, 可以首先确定 K 的大小。根据经验法则, 对于 K 参数, 可以先选择 2 或 3 作为初始值。因为在大多数图结构中, 一个节点的二阶和三阶邻居通常包含了大部分重要信息。经

过后续实验发现,当 K 为 1 或 4 时,模型效果欠佳。从理论上讲,将 K 参数设置得过小,可能会导致模型无法捕捉节点之间的远距离关系,使得模型在处理复杂任务时缺乏全局信息;而将 K 参数设置得过大,则会导致图结构扩张,这会增加计算量和存储需求。因此,当 K 设为 1 或 4 时,模型表现较差。此外对于 M 参数来说, M 过大可能会引入过多的噪声和冗余信息,使得模型难以捕捉节点之间有效的关系; M 过小可能会导致子图之间差异过大,使得模型难以从有限的样本中学习到稳健的特征表示。因此,根据经验法则,首先为 M 选择 5 到 10 的初始值区间。随后,可以将 K 固定为 2 或 3,通过实验在 MolHIV 数据集中探索最合适的值。如图 3-3c 所示,可以观察到在 MolHIV 数据集中将 K 设为 3 时的模型效果要好得多。当 K 设为 3 时,随着参数 M 从 5 变化到 8,模型性能逐渐提升。然而,当 M 参数超过 8 时,性能会急剧下降。所以得到了最佳的参数值组合,即 $M = 8$ 且 $K = 3$,具体实验结果如图 3-3 所示。

表 3-2 SSET 在不同数据集上的超参数

超参数	ZINC	PATTERN	MolHIV	MolPCBA
Layer	4	8	8	8
Heads	8	8	8	8
Hidden	128	64	64	64
Global pooling	mean	mean	mean	mean
Epoch	2000	200	100	50
Warmup	50	10	5	5
Batch size	32	64	64	32
Learning rate	1e-3	3e-4	1e-4	1e-3
Dropout	0.2	0.2	0.25	0.3
Weight decay	1e-5	1e-4	1e-4	1e-5




图 3-3 SSET 模型参数实验折线图

3.5.3 实验评价指标

对于 ZINC 数据集，使用平均绝对误差（MAE）作为评估指标。平均绝对误差（MAE）是一种常用的回归模型评估指标，用于衡量预测值与真实值之间的平均绝对误差。其计算方式如下：

$$MAE = (1/n) * \sum |\hat{y} - y| \quad (3-15)$$

其中， $\sum$ 表示求和运算， n 表示样本数量， i 是样本序号， $\hat{y}$ 是预测值， y 是真实值。对于 PATTERN 数据集，使用准确率（ACC）作为评估指标。ACC 是一种常用的分类模型评估指标，用于衡量模型正确分类的所有样本所占的比例。具体而言，首先计算预测值 $\hat{y}$ 与真实值 y 的混淆矩阵 CF ：

$$CF_{ij} = \sum_{n=1}^N 1(y_n = i \text{ and } \hat{y}_n = j) \quad (3-16)$$

其中， N 是样本的总数， y_n 是第 n 个样本的真实标签， $\hat{y}_n$ 是第 n 个样本的预测标签， $1(\cdot)$ 是指示函数，当条件为真时取值为 1，否则取值为 0。

$$ACC = \frac{\sum_{i=1}^k CF_{ii}}{\sum_{i=1}^k \sum_{j=1}^k CF_{ij}} \quad (3-17)$$

其中, CF_{ii} 是混淆矩阵的对角元素, $\sum_{i=1}^k CF_{ii}$ 表示类别 i 中正确分类的数量, $\sum_{i=1}^k \sum_{j=1}^k CF_{ij}$ 是混淆矩阵所有元素之和, 代表样本的总数, k 是类别总数。

对于 MolHIV 数据集, 使用特征曲线下面积 (AUROC) 作为评估指标。AUROC 是一种常用的分类模型评估指标, 用于衡量二分类模型的性能。AUROC 表示 ROC 曲线下的面积, 可通过对 ROC 曲线下的面积进行数值积分得到。AUROC 的计算公式可表示为:

$$AUROC(y, \hat{y}) = \int_0^1 TPR(FPR) dFPR \quad (3-18)$$

其中, $\hat{y}$ 是预测值, y 是真实值, 真阳性率 (TPR) 表示真正例的比率, 假阳性率 (FPR) 表示假正例的比率。对于 MolPCBA 数据集, 使用平均精度 (AP) 作为评估指标。平均精度 (AP) 结合了精确率和召回率, 通过计算不同阈值下精确率-召回率曲线下的面积来衡量模型的整体性能。平均精度 (AP) 的计算公式可表示为:

$$AP = \frac{1}{m} \sum_{i=1}^m \sum_n (R_{n,i} - R_{n-1,i}) P_{n,i} \quad (3-19)$$

其中, m 是标签的数量, $R_{n,i}$ 和 $P_{n,i}$ 分别是在第 n 个点处第 i 类的召回率和精确率。

3.5.4 实验性能比较

本章与一些基准方法进行了对比, 对比结果展示在表 3-3 中。从实验结果来看, 很明显, 相较于基于图神经网络 (GNN) 的表示学习方法, 本章所提出的结构增强自注意力图 Transformer (SSET) 模型在图表示学习能力方面更胜一筹。而且, 与近年来应用于图数据的 Transformer 模型相比, SSET 模型也有所改进。此外, 在提升性能的同时还在一定程度上降低了存储和计算成本。这种成本的降低使得 SSET 模型能够应用于规模更大的图数据集。对于处理图数据的传统方法, 例如图同构网络 (GIN)、图卷积网络 (GCN) 等, 当这类方法处理图数据时, 节点的表示通常是通过迭代聚合相邻节点的信息来获得的。在这个过程中, 一些重要信息可能会丢失或者变得模糊不清, 尤其是当图中存在长距离依赖关系时更是如此。相比之下, SSET 模型能够通过每个节点上执行自注意力计算, 同时考虑图中所有节点之间的关系。这种全局信息聚合方式使得节点能够更好地捕捉长距离依赖关系, 进而使模型取得更好的效果。对于近期将 Transformer 方法应用于图数据集的情况, 如 Graph Transformer、Graphormer 等方法, 这类方法引入了多头注意力机制, 通过使用多个注意力头并行计算节点之间

的关系权重。多头机制能够提供更强的表达能力，使模型能够更好地处理不同尺度以及不同类型的依赖关系。然而，这类方法主要侧重于节点之间的相互作用和关系，却没有考虑节点在空间中的具体位置以及空间结构信息。因此，它可能无法直接捕捉分子的立体构象和空间排列情况。这一缺陷限制了模型在处理分子的立体异构体或者具有空间特征的分子时的性能表现。SSET 模型通过融入端到端结构增强（ETSE）模块解决了上述问题，该模块旨在从分子中提取空间结构信息。同时，引入了位置编码引导图 Transformer（PEGT）模块，以解决传统方法由于缺乏位置信息而无法区分处于不同位置但具有相同特征的节点这一问题。因此，SSET 模型在不同的数据集上都有着稳健的性能表现。

表 3-3 SSET 模型和基线模型在不同数据集上的实验结果

Model type	Method	ZINC	PATTERN	MolHIV	MolPCBA
GNN-based	GIN	0.562	85.590	75.58	0.2682
	GCN	0.367	85.498	75.99	0.2385
	GAT	0.384	78.271	75.82	-
	EGC-M	0.281	-	78.18	-
	DGN	0.219	86.680	79.70	0.2885
	PNA	0.142	86.567	79.05	0.2838
	CCP	-	-	79.59	0.2530
	GSN	0.101	-	77.99	-
	GTSP-HP	-	-	77.82	0.2756
Transformer-based	GGFormer	0.230	85.22	-	-
	Graph transformer	0.226	84.808	-	-
	SAN	0.139	86.581	77.85	0.2756
	Graphormer	0.122	86.650	76.40	0.2643
Ours	SSET	0.092	86.732	79.97	0.2934

3.5.5 消融实验

在本节中，构建了三个消融实验： $SSET_{EPK}$ 、 $SSET_{TSE}$ 和 $SSET_{PEGT}$ 。在 $SSET_{EPK}$ 模块中，移除了边特征融合以及 Mv -subgraph 生成部分，而是使用原始图来进行简单的

结构提取。在 $SSET_{TSE}$ 模块中，去除了提取结构信息的功能，仅完成边特征信息与基础图信息的融合。在 $SSET_{PEGT}$ 模块中，移除了位置信息编码器，通过基础的图 Transformer 来完成图表示学习。消融实验的结果展示在图 3-4 中。




图 3-4 SSET 模型消融实验结果图

基于对实验结果的分析，以 ZINC 数据集为例，很明显，与 SSET 模型相比， $SSET_{EPK}$ 模块的性能出现了一定程度的下降。之所以会得到这样的结果，是因为分子图的边特征包含诸如原子连接性和化学键类型等关键信息。忽略这些信息会导致模型无法准确捕捉分子间的相互作用。此外，由于某些分子具有独特的局部结构， $SSET_{EPK}$ 模块在利用原始分子图进行结构信息提取时，可能无法捕捉到这些特定的结构细节。而且，原始图包含大量冗余信息，这降低了模型的效率和准确性。摒弃了空间结构信息提取器的 $SSET_{TSE}$ 模块，与 SSET 模块相比，在性能上存在显著差距。这是因为分子的立体构象和空间排列情况会影响其化学反应活性、相互作用以及药物活性等化学性质。然而， $SSET_{TSE}$ 无法捕捉这类结构信息，这就导致模型对分子图的特性预测不准确，从而使其性能大幅降低。从实验结果可以看出，与 SSET 相比， $SSET_{PEGT}$ 模块的性能出现了部分下降。这归因于分子图中位置信息的重要性，它有助于识别分子内的活性位点、结合位点以及催化位点等功能区域。通过分析位置信息，可以确定与特定功能相关的原子或它们的相互作用模式。然而，基础的 Transformer

并不具备获取分子图位置信息的能力。总而言之，基于上述分析可以了解到 SSET 模型中各个模块所承担的功能以及它们对整个模型的独特贡献。由于使用了重要的模块，SSET 模型相较于传统的图神经网络（GNN）模型和 Transformer 模型，性能有所提升。此外，利用 SSET 模型和基础 Transformer 模型在 MUTAG^[75]数据集上的结果，对模型的注意力进行了可视化，如图 3-5 所示。从图 3-5 中的注意力分布情况可以看出，SSET 模型能够识别出硝基（NO₂）官能团，它属于一种会引发致突变性的化学官能团。基础 Transformer 也会关注这个官能团，但它还会将注意力分散到一些不重要的原子上，这可能会导致模型出现误分类的情况。SSET 模型会通过仅聚焦于重要的原子和官能团来改善这一状况。




图 3-5 SSET 模型与普通注意力效果可视化对比图

3.6 本章小结

在本章中，提出了一种名为 SSET 的分子性质预测模型，它基于位置信息编码图 Transformer。SSET 模型包含空间结构信息提取模块（ETSE）以及基于 Transformer 的位置编码引导图 Transformer 模块（PEGT）。ETSE 模块通过边特征融合以及 Mv-

subgraph 生成来提取空间结构信息。边特征融合丰富了节点表示，并且提供了关于图结构更为全面的信息。Mv-subgraph 的生成使模型能够聚焦于图的关键部分，进而提升对局部结构信息的提取能力。PEGT 是一个基于图 Transformer 的模块，通过位置信息编码解决了先前基于 Transformer 的模型所存在位置信息提取能力不足的局限。针对基于传统神经网络以及近期基于 Transformer 的图表示模型设计了对比实验。这些实验表明，SSET 模型增强了提取空间结构信息的能力，从而提高了分子图性质预测能力。然而 SSET 还存在一些不足，例如 Transformer 架构不够精简，不能有效捕捉分子特征之间的相互关系，这一定程度上限制了模型的分子性质预测能力。

第4章 基于双域融合图 Transformer 的分子性质预测模型

4.1 引言

在药物研发领域，对分子性质进行精准有效的预测，不仅能极大地加速科研进程，显著降低研发成本，更是推动新药从实验室走向临床的关键力量。过往研究中，多种分子性质预测模型不断涌现。上一章提出的 SSET 模型凭借独特的技术路径，在预测分子性质的关键问题上，为学界和产业界提供了极具价值的新思路。但现有模型仍存在一定优化空间，为进一步提升模型性能，强化对分子特征的表达，增强信息捕捉的全面性，本章构建了全新的 DRAM 模型。

DRAM 模型是在 SSET 基础上进行优化，它创新性地引入谱域空间，构建全新编码方案，从谱域层面刻画分子特征间的相互关联信息，并维持分子的置换等变性，打破了以往空域离散型编码的局限，开辟了一条全新的研究路径。基于此，DRAM 模型构建了谱域和空域层次捕捉特征信息的 Fast Attention 架构。其中，基于新谱域编码的注意力模块，能从全新视角挖掘谱域空间内分子图的特征，确保模型在不同排列组合下的稳定性；结合全局信息与局部结构的简化注意力模块，既保留了捕获分子长程依赖性的优势，又规避了过度平滑或挤压问题，显著提升了模型对分子性质的刻画能力。经六个具有代表性的数据集验证，DRAM 模型展现出出色的适应性、泛化能力和卓越性能，为分子性质预测领域提供了全新的解决方案。

本章将深入剖析 DRAM 模型的设计理念、架构组成、核心模块及实验验证过程，力求全方位呈现该模型在分子性质预测领域的创新性与应用价值。

4.2 模型框架

本节首先对 DRAM 模型展开系统性介绍，对 DRAM 整体架构进行总览。随后，深入到模型内部，对 DRAM 所包含的两个核心子模块——FASE 和 ALGI 展开阐述。子模块 FASE 创新性地将谱域编码和快速注意力模块相结合。谱域编码打破传统编码局限，从全新谱域维度描述分子特征，快速注意力模块基于谱域编码，挖掘分子特征信息之间的相互关系。而子模块 ALGI，通过精妙的设计，实现局部信息和全局信息的有机聚合，精准捕捉分子的长程依赖关系。最后，聚焦两个子模块的融合环节，解析如何通过模块间的协同运作，让 DRAM 发挥出更强大的性能，实现对分子性质的高效预测。

如图 4-1 所示，该模型图分为两部分，上半部分是包含谱域滤波的快速注意力模块（FASE）模块，下半部分是全局信息和局部信息整合（ALGI）模块。对于 FASE 模块，首先，输入图经过简单处理后计算特征值以及特征向量，并且进一步进行谱域编码得到谱域编码矩阵。矩阵经过处理得到注意力模块所需要的 Q, K, V 。进一步经过快速注意力模块计算得到输出 $output$ 。对于 ALGI 模块，首先经过简单处理的节点和边特征得到 $X_{(0)}$ 和 $E_{(0)}$ ，分别通过编码器得到节点特征和边特征矩阵。然后通过快速注意力模块和局部结构信息提取模块完成局部信息和全局信息的聚合得到 $X_{(2)}$ 。最后 $output$ 经过处理得到 $base$ 和 $X_{(2)}$ 进行拉普拉斯卷积和图池化，最后完成分子性质的预测和分析。




图 4-1 DRAM 的模型架构图

4.3 分子图谱域空间信息提取

在深入研究分子结构与性质的关联过程中，我们意识到传统方法在挖掘分子图特征之间的相互关系中存在一定的局限性。鉴于此，本章构建了一个谱域注意力模块。该模块独辟蹊径，从一个新的角度探索了谱域空间内分子图的特征信息。它突破了以往仅聚焦于空间域分析的固有模式，将目光投向谱域空间，通过对分子图在谱域中的特性进行深度剖析，有望揭示出那些在常规分析中被忽视的关键信息，为进一步理解分子的内在机制以及其相关性质提供全新的思路与有力的工具。在本章的讨论中，仍

然沿用第三章的设定，将整个分子图记为 $G = (V, X, E)$ ，其中节点 $u \in V$ 的节点属性用 $X_u \in X \subset R^d$ 来表示，对于一个含有 n 个节点的图，所有节点的节点属性都存储在 $X \in R^{n \times d}$ 中。

4.3.1 特征值和特征向量计算

在完成分子图谱域空间信息提取前，进行特征值和特征向量计算具有重要意义。为此首先需要计算分子图的特征值和特征向量。在图论中，对于图 $G = (V, E)$ ，其中 $V = \{v_1, v_2, \dots, v_n\}$ 是顶点集， $|V| = n$ 为顶点个数， E 是边集。首先定义邻接矩阵 $A = (a_{ij})$ ，它是一个 $n \times n$ 的矩阵，当 $(v_i, v_j) \in E$ 时， $a_{ij} = 1$ ，否则 $a_{ij} = 0$ 。然后有度矩阵 $D = (d_{ij})$ ，它是 $n \times n$ 的对角矩阵，其中 d_{ii} 表示顶点 v_i 的度，即 $d_{ii} = \sum_{j=1}^n a_{ij}$ ，且 $i \neq j$ 时， $d_{ij} = 0$ 。而拉普拉斯矩阵 L 则定义为度矩阵 D 与邻接矩阵 A 的差，即 $L = D - A$ ，其元素 l_{ij} 满足：当 $i = j$ 时， $l_{ij} = d_{ii}$ ；当 $i \neq j$ 时， $l_{ij} = -a_{ij}$ 。特征值和特征向量的计算工作能够实现数据降维与信息浓缩，将高维复杂的原始数据转化为少数几个代表分子主要特征的变量，减少无关信息干扰。识别对分子性质有关键影响的振动模式。同时，还能为后续机器学习和深度学习模型提供标准化输入。

4.3.2 融合谱域编码的快速注意力

常规的位置编码方案，编码记录了分子图的位置信息，导致模型可能会将不同输入顺序的相同分子图认定为不同的分子。相较于以往的空域离散型编码方案，谱域编码仅取决于原子间的连接关系，而不依赖原子的排列顺序，维持了分子图的置换等变性。这为分子性质预测提供了更稳定、准确的编码方案，确保模型可以专注于分子的实际拓扑结构和化学性质，而不受输入顺序的干扰。谱域编码设计可由如下公式表示：

$$\rho(\lambda, 2i) = w_G \cdot e^{-\frac{(\lambda-\mu)^2}{2\sigma^2}} + w_H \cdot \sin\left(\frac{c\lambda}{10000^{\frac{2i}{d}}}\right) \quad (4-1)$$

$$\rho(\lambda, 2i+1) = w_G \cdot e^{-\frac{(\lambda-\mu)^2}{2\sigma^2}} + w_H \cdot \cos\left(\frac{c\lambda}{10000^{\frac{(2i+1)}{d}}}\right) \quad (4-2)$$

其中 λ 是拉普拉斯矩阵的特征值， w_G 和 w_H 分别代表高斯部分和正弦余弦部分权重，常量 c 调整输入幅度，10000 是一个常数，用于控制编码的周期和频率， d 表示编码向量维度。下一步两部分编码和特征值的拼接得到最终携带有谱域特征的分子图表示

E 。为了使该模型能够应用到更大的分子数据集上，本章改造了注意力机制使其具有线性复杂度。具有线性复杂度的注意力公式可由以下过程表述。首先进行输入正则化：

$$qs_{norm} = \frac{qs}{\|qs\|_2}, ks_{norm} = \frac{ks}{\|ks\|_2} \quad (4-3)$$

上述公式通过使用 L_2 范数实现归一化处理，分子为原始张量，分母为其 L_2 范数。下一步进行注意力分数计算，具体过程可表述为：

$$attn_output_{n,h,d} = \frac{\sum_m \left(qs_{norm,n,h,m} \cdot \sum_l (ks_{norm,l,h,m} \cdot vs_{l,h,d}) \right) + N \cdot vs_{n,h,d}}{\sum_m \left(qs_{norm,n,h,m} \cdot \sum_l ks_{norm,l,h,m} \right) + N} \quad (4-4)$$

其中分子部分包含两层求和，先对 l 维度上 ks_{norm} 和 vs 的乘积求和，再与 qs_{norm} 在 m 维度上的乘积求和，最后加上 $N \cdot vs_{n,h,d}$ 作为修正项。分母部分首先对 l 维度上的 ks_{norm} 求和，再与 qs_{norm} 在 m 维度上的乘积求和，最后加上 N 作为修正项。

FASE 模块可依据图的整体谱特性与结构特征，灵活调整注意力。即使图结构存在噪声，或发生微小变化，它也能凭借更稳定的结构信息，精准分配注意力，有效提升对噪声及结构变化的鲁棒性，进而在含有噪声的数据中，依然保持出色性能。FASE 在挖掘结构信息时更高效，能精准提取关键特征，实现更优的特征表示。在处理局部与全局信息时，做到了有机结合、协同处理。面对复杂多变的图结构，该机制展现出极强的适应性，能快速调整策略。同时，其鲁棒性使其无惧噪声干扰，确保数据处理的稳定性。而且，这种机制具备良好的可解释性，为研究人员理解模型决策过程提供了便利。相比普通编码的注意力机制，融合谱域编码的注意力机制，能更高效地处理复杂图结构数据以及捕捉分子特征之间的相互关系，为图学习与深度学习领域的各类任务，提供了更为强大的工具，助力相关研究与应用取得更好的进展。

4.4 分子图局部信息和全局信息整合

ALGI 模块的分子图局部信息和全局信息整合具有重要意义。首先，从化学性质预测的角度来看，分子的化学性质是由局部结构和全局结构共同决定的，像分子中局部的官能团、化学键等局部信息以及分子整体的拓扑结构、大小和形状等全局信息都起着关键作用。通过整合二者，能够更全面的考量影响分子性质的诸多因素，进而显著提升分子性质预测的精准度，比如在预测分子溶解性时，既考虑局部亲水或疏水官能团信息，又兼顾分子整体大小和形状，避免了单一考虑局部信息的片面性。其次，对于分子的反应性理解也十分重要，分子的反应性既受局部活性位点影响，又受整体

结构如空间位阻等全局因素的制约，这种整合有助于深入理解分子在化学反应中的行为，为化学反应路径的设计和优化提供更准确的依据。

4.4.1 原子和化学键信息嵌入

对于分子图 $G=(V,E)$ ，其中 V 表示节点集合（原子）， E 表示边集合（化学键）。设 X 为初始节点特征矩阵，其中 X_i 是节点 i 的初始特征向量，包含了原子的多种信息，例如原子类型、原子电荷、杂化状态等。 A 为图 G 的邻接矩阵， A_{ij} 表示节点 i 和节点 j 之间是否存在边（化学键）， I 为单位矩阵， $\tilde{A}=A+I$ 表示添加了自环的邻接矩阵， $\tilde{D}$ 是 $\tilde{A}$ 的度矩阵，其对角元素为 $\tilde{D}_{ii}=\sum_j \tilde{A}_{ij}$ 。首先对于节点嵌入，在 GCN 的第 k 层更新节点特征矩阵 $H^{(k)}$ 的公式如下：

$$H^{(k)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(k-1)} W^{(k)} \right) \quad (4-5)$$

其中： $H^{(0)}=X$ 表示初始节点特征矩阵。 $W^{(k)}$ 是第 k 层的可训练权重矩阵，其作用是将节点特征映射到不同的空间维度。 σ 是激活函数，可使用 ReLU 函数，即 $\sigma(x) = \max(0, x)$ 。

对于节点 i 在第 k 层的特征更新公式可进一步展开为：

$$h_i^{(k)} = \sigma \left(\sum_{j \in N(i) \cup \{i\}} \frac{1}{\sqrt{\tilde{d}_i \tilde{d}_j}} \cdot h_j^{(k-1)} W^{(k)} \right) \quad (4-6)$$

其中， $N(i)$ 是节点 i 的邻居节点集合， $\tilde{d}_i = \sum_j \tilde{A}_{ij}$ 和 $\tilde{d}_j = \sum_i \tilde{A}_{ij}$ 是考虑自环后的节点 i 和节点 j 的度。对于边（化学键）的嵌入可以基于节点的嵌入信息来构建。对于边 (i,j) ，可以使用以下拼接操作生成其嵌入：

$$e_{ij} = \text{concat}(h_i^{(k)}, h_j^{(k)}) \quad (4-7)$$

其中 $h_i^{(k)}$ 和 $h_j^{(k)}$ 是节点 i 和节点 j 在第 k 层的嵌入向量，concat 表示拼接操作。

在分子图的节点嵌入过程中，首先将每个原子的化学信息编码为初始特征向量 X_i 形成初始节点特征矩阵 X 。在 GCN 的每一层 k ，通过邻接矩阵和度矩阵对邻居节点的信息进行归一化和聚合操作，即通过 $\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$ 实现。这个操作考虑了节点的度信息，确保信息聚合的权重是根据邻居节点的度进行调整的。然后将处理后的信息与上一层的节点特征矩阵 $H^{(k-1)}$ 相乘，再乘以可训练的权重矩阵 $W^{(k)}$ 进行线性变换，最后使用激活函数 σ 得到更新后的节点特征矩阵 $H^{(k)}$ 。对于节点 i ，其特征更新是对邻居

节点 j 的特征 $h_j^{(k-1)}$ 进行加权求和，加权系数为 $\frac{1}{\sqrt{\tilde{d}_i \tilde{d}_j}}$ ，这体现了信息在分子图中的

传播过程，使节点能够融合其邻居节点的信息，经过多层 GCN 层后可以捕捉到更广泛的局部和全局的结构信息。

对于边的嵌入，由于化学键连接着两个原子，其嵌入可以通过节点的嵌入信息来表示。通过拼接、求和或元素乘法等操作，可以将边的特征表示为边嵌入 e_{ij} 。这些操作将边的信息与连接的两个节点的性质联系起来，如键的类型、键长、键能等可能与连接的原子性质相关的信息，从而将化学键的信息也融入到嵌入表示中。

通过这种节点和边嵌入的方式，可以将分子图中的原子和化学键信息有效地嵌入到低维向量空间，既反映了原子的局部化学环境（通过节点嵌入），又体现了化学键所连接的原子的性质（通过边嵌入），为后续分子性质预测、化学反应预测等任务提供有效的特征表示。这种嵌入方式充分利用了图卷积网络的信息传播能力，将分子图的结构信息转化为适合计算机处理和机器学习算法的低维向量表示，有助于深入理解分子的结构性质关系，提高了分子性质预测的准确性，为药物研发等领域的研究和应用提供了有力支持。

4.4.2 局部信息和全局信息提取模块

局部信息和全局信息整合在处理图结构数据时具有重要意义。首先，它有助于对分子图等结构形成更全面的理解，将宏观的整体拓扑结构和微观的局部化学键、官能团信息相结合，可完善结构表征并适应不同规模的图。其次，能提升化学性质预测的准确性，综合考虑影响分子化学性质和反应性的局部环境及整体特性，如溶解性、反应性和活性的预测。再者，增强了模型的特征表示能力，丰富特征空间，提高泛化能力，避免单一信息带来的局限性。为此本章设计了一个局部信息和全局信息提取模块。首先局部信息提取模块使用的是 GCNconv 可由以下公式表述：然后全局信息的提取使用的是上述设计的线性注意力机制，这里不再赘述。最后对全局特征和局部特征进行叠加，得到一个具有局部信息和全局信息的分子图的特征表示。

4.4.3 图拉普拉斯滤波

在完成图特征表示后还需要进行图拉普拉斯滤波，目的在于平滑和去噪、特征提取和降维以及图信号增强和突出局部结构。有助于进一步更好的完成图预测。对于图 $G = (V, E)$ ，其邻接矩阵为 A ，度矩阵为 D ，拉普拉斯矩阵 $L = D - A$ ，图信号 x 为 n 维向量，常用的图拉普拉斯滤波公式为 $y = (I - \alpha L)x$ ，可进一步展开为：

$$y_i = (1 - \alpha l_{ii})x_i - \alpha \sum_{j \in N(i)} l_{ij}x_j \quad (4-8)$$

其中 I 是 $n \times n$ 单位矩阵, α 是滤波参数, y 是滤波后的图信号, $N(i)$ 是节点 i 的邻居节点集合。

图数据常含噪声, 会干扰后续分析与建模, 而图拉普拉斯滤波凭借其数学原理, 能有效识别和去除噪声, 让图数据更纯净可靠, 为分类、预测等任务打好基础。现实中图数据维度高且有大量冗余信息。图拉普拉斯滤波可以捕捉关键特征, 将高维数据投影到低维空间, 在保留关键信息的同时降低维度, 既减轻计算负担, 又避免维度灾难导致的模型性能下降, 提高数据处理效率。图的局部结构蕴含关键信息, 图拉普拉斯滤波通过特定变换操作增强这些信息, 让模型更关注局部细节, 提升对局部特征的捕捉能力, 从而更精准地挖掘和理解图数据。总之, 图拉普拉斯滤波在平滑去噪、特征提取与降维、增强图信号突出局部结构等方面发挥重要作用, 全面提升图数据质量与可用性, 有力支持分子性质预测, 使模型在各类图相关任务中表现更出色。

4.5 实验分析

除开第三章实验分析中使用的数据集外, 本节还添加了三个新的数据集来验证 DRAM 模型的有效性。除此之外, 本节还对 DRAM 模型架构的不同组成部分进行了分析, 以确定性能提升的驱动因素。

4.5.1 数据集介绍

PCQM4Mv2^[76]数据集由斯坦福大学的 Open Graph Benchmark (OGB) 项目构建, 专门面向分子性质预测任务。其任务是根据二维分子图预测密度泛函理论 (DFT) 计算的分子最高占据分子轨道 (HOMO)-最低未占据分子轨道 (LUMO) 能隙, 这是分子最实际相关的量子化学性质之一, 与反应性、光激发和电荷传输有关。分子图中每个节点有 9 维特征, 如原子序数、手性等; 每条边有 3 维特征, 如键类型、键立体化学等。

ESOL^[77]数据集是一个在化学领域用于研究化合物相关性质的重要数据集。它主要聚焦于有机化合物水溶性 (Water Solubility) 这一关键特性。该数据集包含了大量不同种类的有机化合物样本, 这些样本来源广泛且具有一定的代表性。研究人员通过各种实验手段收集并整理了这些化合物的相关数据, 旨在建立一个能够准确预测有机化合物水溶性的模型。在 ESOL 数据集中, 每个化合物都有其对应的水溶性数值, 这一数值是衡量化合物在水中溶解能力的重要指标。同时, 数据集中还包含了许多与化合物结构相关的描述符, 这些描述符从不同角度刻画了化合物的结构特征, 比如分子的大小、形状、原子组成以及化学键的类型等信息。

除了将 DRAM 模型与第三章列举的经典的图神经网络 (GNN) 方法进行比较

外，还与一些近期提出方法进行对比：

Edge-augmented Graph Transformer (EGT)^[78]：EGT 是 Transformer 神经网络架构的衍生，聚焦通用图学习。它创新性搭建边通道，作为处理成对结构信息的专属路径，这让模型能够直接接纳各类形式的结构信息，为实现图结构数据的高效学习创造了条件。

Tokenized Graph Transformer (TokenGT)^[80]：TokenGT 是一种简单且有效的图学习方法，旨在展示标准 Transformer 在没有图特定修改的情况下也能在图学习任务中取得良好结果。该方法将图中的节点和边视为独立的令牌，并通过令牌嵌入将它们输入到 Transformer 中。

A general, powerful, scalable graphTransformer (GPS)^[80]：GPS 是一种图表示学习模型，旨在通过高效的设计处理图结构数据并实现最先进的性能。该方法通过解耦局部边聚合机制与全局注意力机制，确保计算复杂度为 $O(N + E)$ ，适用于大规模图数据。GPS 的核心由三部分组成：位置/结构编码、局部消息传递机制和全局注意力机制。该架构在多个基准任务上表现出色，展示了其在图学习中的可扩展性和高效性。

Graph Propagation Transformer (GPTrans)^[81]：GPTrans 是一种用于图表示学习的创新型 Transformer 架构。该方法的核心思想是充分考虑图中节点和边之间的信息传播，在 Transformer 块中构建注意力模块时，显式地传递信息。具体来说，提出了一种图传播注意力（Graph Propagation Attention, GPA），该机制通过三种方式传递信息：节点到节点、节点到边、以及边到节点完成图结构数据的学习。

表 4-1 ESOL, PCQM4Mv2 数据集的详细信息

数据集	图数量	平均节点数	平均边数	任务	评价指标
ESOL	1,128	38.7	40.5	回归	RMSE
PCQM4Mv2	300,000	24.2	26.7	回归	MAE

4.5.2 实验设置

使用的所有数据集均可从官方网站下载。所有实验均在英伟达 A-10 GPU 上进行。DRAM 模型所使用的基本参数详情可在表 4-2 中找到。此外，谱域编码中有两个很重要的参数 w_G 和 w_H ，这里由于 w_G 和 w_H 表示不同部分的权重，两个参数之和为 1，所以只需讨论 w_G 的参数设置即可，首先调试好其他基本参数值，然后开始调试 w_G ，观察不同 w_G 对于实验结果的影响。当 $w_G = 0.1$ 时，高斯部分对整体编码的贡献显著降低，使得位置编码更侧重于正弦和余弦函数所代表的周期性信息，丢失了一些重要的局部平滑特征。而随着 w_G 的增大，高斯部分在位置编码中占据主导地位，正弦和余弦函数所代表的周期性信息会被显著削弱。分子结构中的一些周期性特征无

法在编码中得到有效体现，导致编码失去了对这些重要特征的表达能力。通过实验最终确定 $w_G = 0.2$ ，即 $w_H = 0.8$ 实验结果如图 4-2。

表 4-2 DRAM 模型在不同数据集上的参数信息

超参数	ZINC	PATTERN	MOLHIV	MolPCBA	ESOL	PCQM4Mv2
Layer	8	8	8	8	8	8
Heads	8	8	8	8	8	8
Hidden	64	64	64	64	64	32
Global pooling	Mean	Mean	Mean	Mean	Mean	Mean
Epoch	2000	200	100	50	200	100
Warmup	50	10	5	5	50	5
Batch size	64	64	64	32	64	32
Learning rate	1e-3	2e-3	1e-4	1e-3	1e-1	1e-1
Dropout	0.2	0.2	0.25	0.3	0.2	0.25
Weight decay	1e-5	1e-4	1e-4	1e-5	1e-4	1e-4




图 4-2 DRAM 模型的参数实验图

4.5.3 实验评价指标

对于新添加的两个数据集，PCQM4Mv2 数据集使用的是 MAE 评价指标，在第三章中已经做过介绍。对于 ESOL 数据集使用 RMSE 作为评价指标，以下仅对 RMSE 评价指标做介绍。

RMSE 即均方根误差 (Root Mean Squared Error)，是一种在数据预测和评估模型性能时广泛使用的重要指标。从定义上来说，RMSE 用于衡量预测值与真实值之间的偏差程度。它的计算过程是先求出每个预测值与真实值差值的平方，然后对这些平方值求平均数，最后再取平方根。可用如下公式表示：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4-9)$$

其中 n 是样本数量， y_i 是第 i 个样本的真实值， $\hat{y}_i$ 是第 i 个样本的预测值。在 ESOL 数据集研究中，当科研人员运用机器学习算法构建预测有机化合物水溶性的模型时，RMSE 能发挥重要作用。如果 RMSE 的值较小，说明模型预测的水溶性数值与通过实验测量得到的真实水溶性数值之间的偏差较小，也就意味着模型的预测准确性较高；反之，若 RMSE 值较大，则表明模型预测结果与真实值偏差较大，模型的准确性有待提高。RMSE 能直观地反映出模型在预测化合物水溶性方面的精确程度，帮助研究人员评估模型的优劣，进而对模型进行优化和改进。

4.5.4 实验性能比较

为了验证 DRAM 模型的有效性，我们把 DRAM 与一些基准方法在六个数据集中进行了对比，对比结果展示在表格 4-3, 4-4 中。从实验结果来看，DRAM 模型在分子性质预测领域展现出卓越实验效果，显著优于普通 GNN 以及其他基于 Transformer 的模型以及 SSET 模型。与普通 GNN 相比，DRAM 模型在编码方案上实现了重大突破。普通 GNN 多聚焦空域，采用离散型编码，难以连续描述分子内部复杂相互作用，如在分子轨道能量分布描述上存在局限。而 DRAM 引入谱域空间信息提取，其独特的谱域编码能细腻呈现连续特征，为特征分析提供更丰富精准的数据基础。在信息捕捉方面，普通 GNN 依赖相邻节点迭代聚合，面对长距离依赖信息易丢失，DRAM 的谱域注意力模块则能从全新视角探索谱域空间特征，且维持置换等变性，全面捕捉分子信息。相较于其他基于 Transformer 的模型，DRAM 模型在谱域信息利用上更胜一筹。其他 Transformer 模型虽有多头注意力机制，但常忽视谱域深层价值。DRAM 的 FASE 模块通过谱域滤波突出与空间结构相关的频谱特征，有效解决处理复杂空间特征分子时性能不佳的问题。同时，多数 Transformer 模型忽略节点空间位置与结构信息，DRAM 的 ALGI 模块能融入特定结构信息提取模块，在处理空间特征分

子数据时实验效果远超同类。和 SSET 模型相比, DRAM 在谱域信息提取上深度与广度更佳。SSET 虽有改进, 但 DRAM 全新编码方案能更深入全面地描述分子内部复杂相互作用, 在不同频率和尺度下提供更适配的特征表示, 提升模型适应性与泛化能力。总体而言, DRAM 模型凭借在编码方案、信息处理及模块设计等多方面的优化与创新, 在六个数据集上都取得了不错的效果。

表 4-3 DRAM 与基线方法在 ZINC, PATTERN, MolHIV 数据集上的对比

Model type	Method	ZINC(↓)	PATTERN(↑)	MolHIV(↑)
GNN-based	GIN	0.562	85.590	75.58
	GCN	0.367	85.498	75.99
	GAT	0.384	78.271	75.82
	EGC-M	0.281	-	78.18
	DGN	0.219	86.680	79.70
	PNA	0.142	86.567	79.05
	CCP	-	-	79.59
	GSN	0.101	-	77.99
	GTSP-HP	-	-	77.82
	GGFormer	0.230	85.22	-
Transformer-based	Graph transformer	0.226	84.808	-
	SAN	0.139	86.581	77.85
	Graphormer	0.122	86.650	76.40
	SSET	0.092	86.732	79.97
	GPTrans-Nano	0.077	86.731	-
	GPS	0.070	86.685	78.80
Ours	DRAM	0.061	87.171	80.38

表 4-4 DRAM 与基线方法在 MolPCBA, ESOL, PCQM4Mv2 数据集上的对比

Model type	Method	MolPCBA(↑)	ESOL(↓)	PCQM4Mv2(↓)
GNN-based	GIN	0.2682	0.509	0.1195
	GCN	0.2385	0.520	0.1379
	DGN	0.2885	-	-
	PNA	0.2838	-	-
	CCP	0.2530	0.493	-
	EGT	0.2961	-	0.0857
	SAN	0.2756	-	-
Transformer-based	Graphormer	0.2643	0.618	0.0864
	GPS	0.2907	0.613	0.0858
	SSET	0.2934	-	-
	TokenGT	-	0.667	0.0910
Ours	DRAM	0.3006	0.452	0.0812

4.5.5 消融实验

为了探索 DRAM 模型中的各个组成部分对于模型的贡献, 本节构建了三个消融实验分别为 DRAM_{SDC} , DRAM_{SDA} , $\text{DRAM}_{\text{ALGI}}$ 。三个实验方案分别为移除全新谱域编码方案、停用谱域注意力模块以及停用局部信息和全局信息整合模块, 如图 4-3 可以清晰地看到, 在所有实验场景下, 原始 DRAM 模型均展现出更优的性能。这一结果有力地证明了 DRAM 模型设计的科学性与创新性, 各关键组成部分对模型性能提升具有不可或缺的作用。

移除全新谱域编码方案 DRAM_{SDC} 的实验中, 修改后的模型无法从谱域层面有效描述连续特征信息, 表现远不及原始 DRAM 模型。这表明全新谱域编码方案是 DRAM 模型从谱域层面捕捉特征信息的关键, 它打破了传统空域离散型编码的局限, 为模型提供了更丰富、连续的特征描述, 极大地增强了模型对分子复杂谱域特征的处理能力, 进而提升了模型的整体性能。

移除谱域注意力模块 DRAM_{SDA} 的实验结果显示, 修改后的模型性能下降明显。该模型在面对分子结构发生旋转、平移等变换时, 无法利用新编码维持置换等变性, 无法准确识别分子特征, 性能显著降低。这充分说明谱域注意力模块对于模型在谱域

层面的特征提取以及应对分子结构变化起着至关重要的作用。它基于全新谱域编码方案，能够深入探索谱域空间内分子图的特征信息，使模型在复杂的分子结构变化场景下仍能准确识别和分析分子特征，是保障模型在谱域层面性能的核心组件。

移除局部信息和全局信息整合模块 $\text{DRAM}_{\text{ALGI}}$ 的实验结果显示，修改后的模型无法有效整合分子图的局部与全局信息，性能下降。在处理大型复杂分子体系时该模型难以捕捉分子间长程依赖性，预测准确率显著降低。这凸显了局部信息和全局信息整合模块在 DRAM 模型中的关键价值。它在空域层面精准协调，将分子的局部细节与全局特征有机结合，确保模型能够准确把握分子间长程相互作用，极大提升了模型处理复杂分子体系的性能。

综上所述，原始 DRAM 模型凭借全新谱域编码方案、谱域注意力模块以及局部信息和全局信息整合模块的协同作用，在从谱域和空域层面捕捉特征信息、应对分子结构变化以及处理复杂分子体系等方面表现良好，有效的提升了分子性质预测能力。




图 4-3 DRAM 模型消融实验结果图

4.6 本章小结

在本章中，首先介绍了 DRAM 模型，其采用全新谱域编码方案，构建了能从谱域和空域捕捉特征的 Fast Attention 架构。模型包含谱域注意力模块，可探索谱域特征来捕捉分子特征之间的相互关系并维持置换等变性。此外局部和全局信息整合模块，

能保留长程依赖并避免过度平滑。本章将 DRAM 与传统 GNN 及其他基于 Transformer 的模型进行对比，实验显示 DRAM 在分子性质预测任务上表现更优。此外，通过三个消融实验，明确了全新谱域编码方案对获取复杂谱域特征、谱域注意力模块对处理分子结构变化、局部和全局信息整合模块对捕捉长程依赖的关键作用。综上，DRAM 模型设计科学创新，各部分协同提升了其在谱域和空域特征捕捉及处理复杂分子体系的能力，为模型优化及在分子性质预测等领域应用提供了有力支撑。

第 5 章 总结与展望

5.1 总结

在当前的研究进程中，基于 Transformer 的分子性质预测在捕获深度空间结构信息方面以及特征信息之间的相互关系提取上存在不足。由于 Transformer 架构起初主要面向序列数据处理，在这种模式下，元素间关系由序列位置定义。而在分子性质预测领域，大多数基于 Transformer 的方法基于全图来完成分子性质预测任务。这一做法带来诸多弊端，首先是计算复杂度急剧攀升，随着图规模扩大，计算量呈指数级增长；其次，内存需求大幅增加，对硬件资源提出了极高要求；更为关键的是，在处理过程中，局部特征细节容易丢失，致使模型在分子图分析这类对局部特征高度依赖的任务中，难以收获理想成果。为有效攻克这些难题，本文提出了 SSET 和 DRAM 两大模型。本文具体的主要贡献和成果如下：

（1）提出基于深度空间结构信息提取 Transformer 的分子预测模型 SSET，它由两个核心模块组成，即 ETSE 模块和 PEGT 模块。ETSE 模块在空间结构信息提取方面发挥着关键作用，其通过边特征融合和 Mv-subgraph 表示来实现这一目标。边特征融合操作极大地丰富了节点表示，为图结构信息的描述提供了更为全面的视角，使得节点不再孤立，而是与周边环境紧密关联。Mv-subgraph 表示则显著提升了模型对局部结构的识别与表示能力，让模型能够精准聚焦于分子图中的关键局部区域，进而生成更具判别性和泛化性的图表示。而 PEGT 模块主要负责补充位置信息，与传统图 Transformer 相比，它显著增强了结构感知能力，使得模型对图中节点间关系的捕获更加准确。同时，该模块还极大地提升了上下文理解能力，模型深入剖析图结构中每个节点所处的位置和上下文环境，从而更精准地把握图的整体特性。

（2）在 SSET 基础上进一步提高分子性质预测精度，提出基于快速注意力融合谱域和空域的分子性质预测 DRAM 模型。该模型引入了谱域空间，并构建了全新的编码方案，从谱域层面来描述分子特征之间的相互信息并且维持了分子的置换等变性。与以往广泛采用的空域离散型编码方案相比，这种新编码方案开辟了一条全新的研究路径。基于此，模型构建了从谱域和空域两个层次捕捉特征信息的 Fast Attention 架构。其中，以新的谱域编码方案为基础的注意力模块，从全新角度深入探索谱域空间内分子图的特征信息，并且通过巧妙设计维持了置换等变性，确保模型在不同排列组合下的稳定性。结合全局信息和局部结构的简化注意力模块，不仅保留了捕获分子间长程依赖性的优势，还成功避免了过度平滑或挤压问题，有效提升了模型对分子性质

的刻画能力。在六个具有代表性的数据集上开展的实验结果充分表明，DRAM 模型展现出良好的适应性、泛化能力以及优秀的性能，为分子性质预测领域带来了一个新的解决方案。

本文通过构建 SSET 和 DRAM 两大模型，为分子性质预测任务提供了具有空间结构信息提取和特征信息相互捕获的方法。此外，该研究能够提高分子性质预测准确性，进而提高药物研发的效率和成功率，降低研发成本和风险，为开发出更有效、更安全的药物提供有力支持。

5.2 展望

本文针对分子性质预测任务提出 SSET 和 DRAM 两种模型，并在真实数据集上验证了其有效性。然而，本研究工作仍存在若干有待完善与改进之处，后续可从以下维度开展更为深入的研究。

（1）在模型普适性拓展方面，当前实验仅在有限数量的数据集上开展，后续可将模型应用于更多不同类型、规模更大且来源更为广泛的数据集，涵盖不同药物类型、疾病靶点相关的分子数据等，全面检验模型在复杂多变现实场景中的性能表现，进一步提升模型的普适性与通用性。

（2）在模型性能优化层面，尽管 SSET 和 DRAM 已取得一定成果，但仍具备提升空间。可深入探究模型内部参数的优化调整策略，采用更为先进的超参数优化算法，如贝叶斯优化、遗传算法等，精准寻优，挖掘模型的最大潜力。同时，探索引入更多先进技术，如将强化学习与现有模型相结合，动态调整模型决策过程，增强模型在复杂环境下的自主学习与决策能力，持续提升模型对分子性质预测的准确性与效率。

（3）在模型解释性增强方面，随着深度学习模型复杂度的不断增加，理解模型决策过程的重要性日益凸显。后续研究可尝试将模型在处理分子图数据时的关键步骤、特征提取过程、注意力分布等信息直观呈现，助力研究人员深入了解模型行为，增强对模型预测结果的信任度，为进一步优化模型提供有力支撑。

参考文献

- [1] 谢周令, 张茹, 王琴, 廖晨钟. 融入结构可视化与创新药物案例的配位化学教学[J]. 大学化学, 2023, 38(12): 38-44.
- [2] Bano I, Butt U D, Mohsan S A H. New challenges in drug discovery[M]//Novel Platforms for Drug Delivery Applications. Woodhead Publishing, 2023: 619-643.
- [3] 王庆华, 黄润青, 李璠, 刘国恩. 新药研发成本的系统性综述[J]. 中国新药杂志, 2020, 29(06): 601-608.
- [4] 丁晓峰. 开发一种新药平均成本已达 26 亿美元[J]. 科学大观园, 2018, (15): 30-31.
- [5] DiMasi J A, Hansen R W, Grabowski H G. The price of innovation: new estimates of drug development costs[J]. Journal of health economics, 2003, 22(2): 151-185.
- [6] 林志吟. 十年时间、十亿美元: AI 能否颠覆新药研发规律[N]. 第一财经日报, 2025-03-24(A10).
- [7] Schuhmacher A, Hinder M, und Stein A S, et al. Analysis of pharma R&D productivity—a new perspective needed[J]. Drug Discovery Today, 2023, 28(10): 103726.
- [8] 王庆华, 黄润青, 李璠, 刘国恩. 新药研发成本的系统性综述[J]. 中国新药杂志, 2020, 29(06): 601-608.
- [9] 陈珂玲, 曾顺泽, 许鹏超, 余艳, 冯慧玲, 李园. 高成本驱动下的 CAR-T 工艺发展趋势[J]. 中国生物工程杂志, 2024, 44(07): 49-57. DOI:10.13523/j.cb.2312027.
- [10] 翟丹婷. 药品制造企业成本管理的难点及对策[J]. 中国市场, 2025, (06): 111-114. DOI:10.13939/j.cnki.zgsc.2025.06.028.
- [11] 邵群轶. 新质生产力驱动下医药行业研发支出策略的优化路径研究[J]. 环渤海经济瞭望, 2025, (02): 28-31. DOI:10.16457/j.cnki.hbhjllw.2025.02.048.
- [12] 吴伟洁, 耿利军, 肖剑龙, 黄阎妹, 陆瑶, 赵海璐. 动物实验对药物研发重要吗?[J]. 医学争鸣, 2018, 9(06): 60-63. DOI:10.13276/j.issn.1674-8913.2018.06.017.
- [13] Zhang, K., Yang, X., Wang, Y., Yu, Y., Huang, N., Li, G., ... & Yang, S. Artificial intelligence in drug development[J]. Nature Medicine, 2025: 1-15.
- [14] Tiwari, P. C., Pal, R., Chaudhary, M. J., & Nath, R. Artificial intelligence revolutionizing drug development: Exploring opportunities and challenges[J]. Drug Development Research, 2023, 84(8): 1652-1663.
- [15] 张学博, 马征远, 袁银池, 李丹丹. 人工智能驱动下的制药产业变革[J]. 竞争情报, 2024, 20(05): 28-36. DOI:10.19442/j.cnki.ci.2024.05.006.

- [16] Patel V, Shah M. Artificial intelligence and machine learning in drug discovery and development[J]. *Intelligent Medicine*, 2022, 2(3): 134-140.
- [17] 杨双萌, 于江, 侯文彬, 赵倩, 李祎亮. 人工智能算法用于药物研发的研究进展[J]. *现代药物与临床*, 2023, 38(12): 3150-3160.
- [18] Askr, H., Elgeldawi, E., Aboul Ella, H., Elshaier, Y. A., Gomaa, M. M., & Hassanien, A. E.. Deep learning in drug discovery: an integrative review and future challenges[J]. *Artificial Intelligence Review*, 2023, 56(7): 5975-6037.
- [19] Li Z, Jiang M, Wang S, et al. Deep learning methods for molecular representation and property prediction[J]. *Drug Discovery Today*, 2022, 27(12): 103373.
- [20] 孙一舟, 汤缪灵, 张硕卿, 洪鑫. 数据驱动的有机分子理化性质预测[J]. *科学通报*, 2025, 70(Z1): 492-507.
- [21] Xia, J., Zhang, L., Zhu, X., Liu, Y., Gao, Z., Hu, B., ... & Li, S. Z. Understanding the limitations of deep models for molecular property prediction: Insights and solutions[J]. *Advances in Neural Information Processing Systems*, 2023, 36: 64774-64792.
- [22] Ståhl, N., Falkman, G., Karlsson, A., Mathiason, G., & Boström, J. Deep convolutional neural networks for the prediction of molecular properties: challenges and opportunities connected to the data[J]. *Journal of Integrative Bioinformatics*, 2019, 16(1): 20180065.
- [23] Shen J, Nicolaou C A. Molecular property prediction: recent trends in the era of artificial intelligence[J]. *Drug Discovery Today: Technologies*, 2019, 32: 29-36.
- [24] Xia, J., Zhang, L., Zhu, X., Liu, Y., Gao, Z., Hu, B., ... & Li, S. Z. Understanding the limitations of deep models for molecular property prediction: Insights and solutions[J]. *Advances in Neural Information Processing Systems*, 2023, 36: 64774-64792.
- [25] Tropsha A. Best practices for QSAR model development, validation, and exploitation[J]. *Molecular informatics*, 2010, 29(6-7): 476-488.
- [26] Patel, H. M., Noolvi, M. N., Sharma, P., Jaiswal, V., Bansal, S., Lohan, S., ... & Bhardwaj, V. Quantitative structure–activity relationship (QSAR) studies as strategic approach in drug discovery[J]. *Medicinal chemistry research*, 2014, 23: 4991-5007.
- [27] Mak K K, Pichika M R. Artificial intelligence in drug development: present status and future prospects[J]. *Drug discovery today*, 2019, 24(3): 773-780.
- [28] Cortes C, Vapnik V. Support-vector networks[J]. *Machine learning*, 1995, 20: 273-297.
- [29] Breiman L. Random forests[J]. *Machine learning*, 2001, 45: 5-32.
- [30] Heikamp K, Bajorath J. Support vector machines for drug discovery[J]. *Expert opinion on drug discovery*, 2014, 9(1): 93-104.

- [31] Hansen, K., Biegler, F., Ramakrishnan, R., Pronobis, W., Von Lilienfeld, O. A., Muller, K. R., & Tkatchenko, A. Machine learning predictions of molecular properties: Accurate many-body potentials and nonlocality in chemical space[J]. The journal of physical chemistry letters, 2015, 6(12): 2326-2331.
- [32] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.
- [33] Defferrard M, Bresson X, Vandergheynst P. Convolutional neural networks on graphs with fast localized spectral filtering[J]. Advances in neural information processing systems, 2016, 29.
- [34] Hamilton W, Ying Z, Leskovec J. Inductive representation learning on large graphs[J]. Advances in neural information processing systems, 2017, 30.
- [35] Veličković, P., Cucurull, G., Casanova, A., Romero, A., Lio, P., & Bengio, Y. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017.
- [36] Veličković, P., Fedus, W., Hamilton, W. L., Liò, P., Bengio, Y., & Hjelm, R. D. Deep graph infomax [J]. arXiv preprint arXiv:1809.10341, 2018.
- [37] Xu, K., Hu, W., Leskovec, J., & Jegelka, S. How powerful are graph neural networks?[J]. arXiv preprint arXiv:1810.00826, 2018.
- [38] Xie T, Grossman J C. Crystal graph convolutional neural networks for an accurate and interpretable prediction of material properties[J]. Physical review letters, 2018, 120(14): 145301.
- [39] Yao L, Mao C, Luo Y. Graph convolutional networks for text classification[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 7370-7377.
- [40] Wang, Y., Sun, Y., Liu, Z., Sarma, S. E., Bronstein, M. M., & Solomon, J. M. Dynamic graph cnn for learning on point clouds[J]. ACM Transactions on Graphics (tog), 2019, 38(5): 1-12.
- [41] Liu, Q., Hu, Z., Jiang, R., & Zhou, M. DeepCDR: a hybrid graph convolutional network for predicting cancer drug response[J]. Bioinformatics, 2020, 36(Supplement_2): i911-i918.
- [42] Ma, T., Liu, Q., Li, H., Zhou, M., Jiang, R., & Zhang, X. DualGCN: a dual graph convolutional network model to predict cancer drug response[J]. BMC bioinformatics, 2022, 23(Suppl 4): 129.
- [43] Yin, Q., Fan, R., Cao, X., Liu, Q., Jiang, R., & Zeng, W. DeepDrug: a general graph-based deep learning framework for drug-drug interactions and drug-target interactions prediction[J]. Quantitative Biology, 2023, 11(3): 260-274.
- [44] Lao, C., Zheng, P., Chen, H., Liu, Q., An, F., & Li, Z. DeepAEG: a model for predicting cancer drug response based on data enhancement and edge-collaborative update strategies[J]. BMC bioinformatics, 2024, 25(1): 105.

- [45] 随海燕, 袁洪波, 周焕笛, 赵欢, 霍静倩 & 程曼. 融合图神经网络、门控循环单元与注意力机制的分子性质预测方法 [J]. 河北农业大学学报, 2024, 47 (06): 40-46+61. DOI:10.13320/j.cnki.jauh.2024.0084.
- [46] 林艳梅, 陈楠, 周宏亮 & 彭昱忠. 一种基于深度学习多模态融合的分子性质预测方法[J]. 南宁师范大学学报(自然科学版), 2025, 42(02): 62-69. DOI:10.16601/j.cnki.issn2096-7330.2025.02.009.
- [47] Morris, C., Ritzert, M., Fey, M., Hamilton, W. L., Lenssen, J. E., Rattan, G., & Grohe, M. Weisfeiler and leman go neural: Higher-order graph neural networks[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 4602-4609.
- [48] Chen, D., Lin, Y., Li, W., Li, P., Zhou, J., & Sun, X. Measuring and relieving the over-smoothing problem for graph neural networks from the topological view[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(04): 3438-3445.
- [49] Alon U, Yahav E. On the bottleneck of graph neural networks and its practical implications[J]. arXiv preprint arXiv:2006.05205, 2020.
- [50] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [51] Dwivedi V P, Bresson X. A generalization of transformer networks to graphs[J]. arXiv preprint arXiv:2012.09699, 2020.
- [52] Cai D, Lam W. Graph transformer for graph-to-sequence learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(05): 7464-7471.
- [53] Rong, Y., Bian, Y., Xu, T., Xie, W., Wei, Y., Huang, W., & Huang, J. Self-supervised graph transformer on large-scale molecular data[J]. Advances in neural information processing systems, 2020, 33: 12559-12571.
- [54] Ying, C., Cai, T., Luo, S., Zheng, S., Ke, G., He, D., ... & Liu, T. Y. Do transformers really perform badly for graph representation?[J]. Advances in neural information processing systems, 2021, 34: 28877-28888.
- [55] Kreuzer, D., Beaini, D., Hamilton, W., Létourneau, V., & Tossou, P. Rethinking graph transformers with spectral attention[J]. Advances in Neural Information Processing Systems, 2021, 34: 21618-21629.
- [56] Li H, Zhao D, Zeng J. KPGT: knowledge-guided pre-training of graph transformer for molecular property prediction[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022: 857-867.
- [57] Jiang, Y., Jin, S., Jin, X., Xiao, X., Wu, W., Liu, X., ... & Niu, Z. Pharmacophoric-constrained heterogeneous graph transformer model for molecular property prediction[J]. Communications Chemistry, 2023, 6(1): 60.

- [58] Gao, J., Shen, Z., Lu, Y., Shen, L., Zhou, B., Xu, D., ... & Dong, X. KnoMol: A Knowledge-Enhanced Graph Transformer for Molecular Property Prediction[J]. *Journal of Chemical Information and Modeling*, 2024, 64(19): 7337-7348.
- [59] Zhang, T., Xia, C., Yang, H., Guo, X., Zheng, H., & Wulamu, A. SGNN-T: Space graph neural network coupled transformer for molecular property prediction[J]. *Computational Materials Science*, 2025, 246: 113358.
- [60] Wu, F., Souza, A., Zhang, T., Fifty, C., Yu, T., & Weinberger, K. Simplifying graph convolutional networks[C]//International conference on machine learning. Pmlr, 2019: 6861-6871.
- [61] Zhou, B., Liu, X., Liu, Y., Huang, Y., Lio, P., & Wang, Y. Spectral transform forms scalable transformer[J]. *arXiv preprint arXiv:2111.07602*, 2021.
- [62] Hansen P C. The truncated SVD as a method for regularization[J]. *BIT Numerical Mathematics*, 1987, 27: 534-553.
- [63] Irwin, J. J., Sterling, T., Mysinger, M. M., Bolstad, E. S., & Coleman, R. G. ZINC: a free tool to discover chemistry for biology[J]. *Journal of chemical information and modeling*, 2012, 52(7): 1757-1768.
- [64] Dwivedi, V. P., Joshi, C. K., Luu, A. T., Laurent, T., Bengio, Y., & Bresson, X. Benchmarking graph neural networks[J]. *Journal of Machine Learning Research*, 2023, 24(43): 1-48.
- [65] Hu, W., Fey, M., Zitnik, M., Dong, Y., Ren, H., Liu, B., ... & Leskovec, J. Open graph benchmark: Datasets for machine learning on graphs[J]. *Advances in neural information processing systems*, 2020, 33: 22118-22133.
- [66] Beaini, D., Passaro, S., Létourneau, V., Hamilton, W., Corso, G., & Liò, P. Directional graph networks[C]//International Conference on Machine Learning. PMLR, 2021: 748-758.
- [67] Bouritsas, G., Frasca, F., Zafeiriou, S., & Bronstein, M. M. Improving graph neural network expressivity via subgraph isomorphism counting[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022, 45(1): 657-668.
- [68] Corso, G., Cavalleri, L., Beaini, D., Liò, P., & Veličković, P. Principal neighbourhood aggregation for graph nets[J]. *Advances in neural information processing systems*, 2020, 33: 13260-13271.
- [69] Tailor, S. A., Opolka, F. L., Lio, P., & Lane, N. Dal. Do we need anisotropic graph neural networks? [J]. *arXiv preprint arXiv:2104.01481*, 2021.
- [70] Yang Y, Li P. GPDRP: a multimodal framework for drug response prediction with graph transformer [J]. *BMC bioinformatics*, 2023, 24(1): 484.
- [71] Zhu, P., Li, J., Dong, Z., Hu, Q., Wang, X., & Wang, Q. CCP-GNN: competitive covariance pooling for improving graph neural networks[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2024.

- [72] Zhou, S., Guo, D., Li, J., Yang, X., & Wang, M. Exploring sparse spatial relation in graph inference for text-based VQA[J]. IEEE Transactions on Image Processing, 2023, 32: 5060-5074.
- [73] Kong, L., Ojha, V., Gao, R., Suganthan, P. N., & Snášel, V. Low-rank and global-representation-key-based attention for graph transformer[J]. Information Sciences, 2023, 642: 119108.
- [74] Gao, M., Zhang, D., Chen, Y., Zhang, Y., Wang, Z., Wang, X., ... & Song, J. Graphormerdti: a graph transformer-based approach for drug-target interaction prediction[J]. Computers in Biology and Medicine, 2024, 173: 108339.
- [75] Morris, C., Kriege, N. M., Bause, F., Kersting, K., Mutzel, P., & Neumann, M. TUDataset: A collection of benchmark datasets for learning with graphs[J]. arXiv preprint arXiv:2007.08663, 2020.
- [76] Hu, W., Fey, M., Ren, H., Nakata, M., Dong, Y., & Leskovec, J. Ogb-lsc: A large-scale challenge for machine learning on graphs[J]. arXiv preprint arXiv:2103.09430, 2021.
- [77] Wu, Z., Ramsundar, B., Feinberg, E. N., Gomes, J., Geniesse, C., Pappu, A. S., ... & Pande, V. MoleculeNet: a benchmark for molecular machine learning[J]. Chemical science, 2018, 9(2): 513-530.
- [78] Hussain M S, Zaki M J, Subramanian D. Edge-augmented graph transformers: Global self-attention is enough for graphs[J]. arXiv preprint arXiv:2108.03348, 2021, 3.
- [79] Kim, J., Nguyen, D., Min, S., Cho, S., Lee, M., Lee, H., & Hong, S. Pure transformers are powerful graph learners[J]. Advances in Neural Information Processing Systems, 2022, 35: 14582-14595.
- [80] Rampásek, L., Galkin, M., Dwivedi, V. P., Luu, A. T., Wolf, G., & Beaini, D. Recipe for a general, powerful, scalable graph transformer[J]. Advances in Neural Information Processing Systems, 2022, 35: 14501-14515.
- [81] Chen, Z., Tan, H., Wang, T., Shen, T., Lu, T., Peng, Q., ... & Qi, Y. Graph propagation transformer for graph representation learning[J]. arXiv preprint arXiv:2305.11424, 2023.

图 版

图 1-1 新药研发流程图.....	1
图 1-2 本文组织结构图.....	8
图 2-1 分子图结构示意图.....	9
图 2-2 图卷积神经网络简化结构示意图.....	12
图 2-3 图 Transformer 计算流程简化架构示意图.....	13
图 2-4 多头自注意力机制示意图.....	15
图 2-5 常见激活函数曲线示意图.....	16
图 2-6 常见损失函数曲线示意图.....	18
图 2-7 全连接层示意图.....	20
图 3-1 SSET 模型的架构图	24
图 3-2 PEGT 模块的架构图.....	29
图 3-3 SSET 模型参数实验折线图	34
图 3-4 SSET 模型消融实验结果图	37
图 3-5 SSET 模型与普通注意力效果可视化对比图	38
图 4-1 DRAM 的模型架构图.....	42
图 4-2 DRAM 模型参数实验图.....	49
图 4-3 DRAM 模型消融实验结果图.....	53

表 版

表 3-1 四个数据集的详细信息.....	30
表 3-2 SSET 在不同数据集上的超参数	33
表 3-3 SSET 模型和基线模型在不同数据集上的实验结果	36
表 4-1 ESOL, PCQM4Mv2 数据集的详细信息.....	48
表 4-2 DRAM 模型在不同数据集上的参数信息.....	49
表 4-3 DRAM 与基线方法在 ZINC, PATTERN, MolHIV 数据集上的对比.....	51
表 4-4 DRAM 与基线方法在 MolPCBA, ESOL, PCQM4Mv2 数据集上的对比.....	52