

硕士学位论文

基于多模态的分子性质预测研究

The Research on Molecular Property Prediction Based on
Multi-modality

作者姓名：_____王天翔_____

学号：_____32109205_____

指导教师：林晓惠 刘心昱（企业导师）

学科、专业：_____计算机技术_____

答辩日期：_____2024.5.24_____

大连理工大学

Dalian University of Technology

摘 要

在药物研发、量子力学等领域中，分子性质预测工作一直是一个重要的研究课题。然而，由于实验付出的金钱和时间成本高昂，获取到所需性质的分子是非常困难的。因此，通过模拟的方式采用计算机技术预测生成的分子是否具有某种特定性质就成为了一种良好的选择。为了提高分子性质预测的性能，本文研究了基于多模态的分子性质预测算法，具体研究内容如下：

1. 提出了基于多模态的对比学习分子性质预测算法 MMCLR (Multi-Modal Contrastive Learning of Representation for molecular property prediction)。算法利用三种不同模态的分子表示进行相互对比，针对分子性质预测对比学习工作中仅考虑分子结构相似性而缺失了化学相似性的问题，在损失函数中融合了模态间的空间联合度和分子间的化学相似性，为对比学习的训练过程添加了化学信息。MMCLR 首先通过有监督对比学习方式预训练，然后在下游的分子性质预测任务上进行微调。

2. 提出了基于多模态的细粒度自注意力分子性质预测算法 MMFG (Multi-Modal Fine-Grained self-attention algorithm for molecular property prediction)。相比于粗粒度从整个模态的维度上进行训练，细粒度方式能够获取到不同模态内部各个要素相互之间的关系。在分子研究领域，这体现为不同模态内表示同样化学意义的要素应该表现为相近的隐藏表示。因此，本算法针对粗粒度训练方式的不足，使用各个模态的细粒度要素进行自注意力计算，并添加对比学习引导，结合所有要素的信息获取分子的整体表示，进行分子性质预测。

3. 实现了分子性质预测系统，该系统集成了 MMCLR、MMFG、基线模型等分子性质预测方法，能够调整多种模型参数，实时反馈模型训练进度，呈现训练结果，方便相关研究人员评价并选择合适的分子性质预测方法。

本文提出的两种算法均基于多模态的思想，通过结合分子的多种结构表示训练高性能的分子性质预测模型。其中 MMCLR 通过对比学习方式，考虑了模态间的空间联合度和分子间的化学相似性，从而提高了训练得到的分子表示的有效性；MMFG 使用了细粒度方式，为各模态的内部要素建立关系，通过自注意力机制训练分子表示，有效提高了分子性质预测的性能。由于细粒度方式能够学习到更丰富的分子结构信息，因此在分子性质预测工作上表现更好，但这个过程需要借助粗粒度对比学习表示作为引导。本文在多个数据集上进行了对比、消融实验，验证了两个算法的有效性。

关键词：分子性质预测；多模态；对比学习；细粒度

ABSTRACT

In fields such as drug discovery and quantum mechanics, predicting molecular properties has been a crucial research topic. However, due to the high costs in terms of money and time associated with experiments, obtaining molecules with the desired properties can be challenging. Therefore, the use of computer technology to simulate and predict whether generated molecules possess certain specific properties has become a favorable choice. To enhance the performance of molecular property prediction, this study investigates multi-modality-based algorithms for molecular property prediction. The specific research contributions are as follows:

1. This thesis proposes the algorithm MMCLR (Multi-Modal Contrastive Learning of Representation for molecular property prediction). The algorithm leverages three different modalities of molecular representations for mutual contrast, aims the problem of only considering structural similarity and lacking chemical similarity in the contrastive learning for molecular property prediction, integrates the spatial coherence between modalities and chemical similarity between molecules in the loss function, incorporates chemical information in the process of contrastive learning. MMCLR is pre-trained using supervised contrastive learning firstly and then fine-tuned on downstream molecular property prediction tasks.

2. This thesis proposes the algorithm MMFG (Multi-Modal Fine-Grained self-attention algorithm for molecular property prediction). Compared to coarse-grained training across the entire modality dimensions, fine-grained approaches capture relationships among various elements within each modality. In molecule research field, it means the elements with same chemical significance represented in different modalities should be expressed as similar hidden representation. Therefore, the algorithm aims the disadvantage of coarse-grained training method, uses self-attention calculations on internal elements of each modality and contrastive learning-guidance, then combines information from all elements, and obtains an overall representation of the molecule for molecular property prediction.

3. This thesis implements a molecular property prediction algorithm system, which integrates molecular property prediction algorithms including the methods MMCLR, MMFG, and baseline models. It can adjust model parameters, feedback on real-time model training progress, and present training results, facilitate relevant researchers to evaluate and select appropriate molecular property prediction methods.

Both algorithms proposed in this study are based on the multi-modal concept, combining multiple structural representations of molecules to train high-quality models for molecular property prediction. MMCLR employs a contrastive learning approach, considering spatial coherence between modalities and chemical similarity between molecules, enhancing the

effectiveness of the trained molecular representations. MMFG uses a fine-grained approach to establish relationships among internal elements of each modality, and trains molecular representations through self-attention mechanisms to effectively improve the performance of molecular property prediction. Due to the ability of fine-grained methods to learn richer molecular structural information, it performs better in predicting molecular properties. However, this process requires the guidance of coarse-grained contrastive learning representations. Comparison and ablation experiments on multiple datasets validate the effectiveness of the two algorithms presented in this study.

Key Words: Molecular Property Prediction; Multi-modality; Contrastive Learning; Fine-Grained

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外相关研究工作进展	2
1.3 论文研究思路及目标.....	4
2 相关技术.....	7
2.1 分子表示.....	7
2.2 自然语言处理.....	9
2.2.1 循环神经网络.....	9
2.2.2 卷积神经网络.....	9
2.2.3 Transformer 模型	10
2.3 图神经网络.....	11
2.3.1 图卷积网络.....	12
2.3.2 图注意力网络.....	12
2.3.3 图同构网络.....	12
2.4 本文涉及到的几个分子表示编码器	13
2.4.1 Transformer-CNN	13
2.4.2 Attentive FP.....	13
2.4.3 DimeNet 与 DimeNet++.....	14
2.5 对比学习技术.....	15
2.6 多模态.....	16
2.7 本章小结.....	17
3 基于多模态的对比学习分子性质预测算法	18
3.1 MMCLR 算法.....	18
3.1.1 MMCLR 算法的整体流程.....	18
3.1.2 MMCLR 中用到的分子表示.....	19
3.1.3 对比损失函数.....	21
3.1.4 空间联合度.....	24
3.1.5 化学相似性.....	25
3.2 实验.....	26
3.2.1 数据集.....	26
3.2.2 基线方法.....	27
3.2.3 实验设置.....	27
3.2.4 性能评估.....	29
3.2.5 模态消融实验.....	30

3.2.6 空间联合度分析	32
3.2.7 化学相似性分析	35
3.3 本章小结	36
4 基于多模态细粒度的自注意力分子性质预测算法	37
4.1 MMFG 算法	37
4.1.1 MMFG 算法的整体流程	37
4.1.2 细粒度自注意力	38
4.1.3 对比学习表示引导	40
4.1.4 细粒度张量化	41
4.2 实验	44
4.2.1 数据集、基线与实验细节设置	44
4.2.2 性能评估	45
4.2.3 细粒度方法与粗粒度方法的比较	46
4.2.4 消融实验	47
4.3 本章小结	50
5 分子性质预测系统	51
5.1 引言	51
5.2 数据集和训练模型选择	52
5.3 重要参数设置与自检系统	53
5.4 训练过程与结果展示	55
5.5 本章小结	56
6 结论与展望	57
6.1 结论	57
6.2 创新点	58
6.3 展望	58
参考文献	61

图目录

图 3.1 MMCLR 的整体框架	19
图 3.2 分类和回归任务化学相似性示意图	23
图 3.3 空间联合度示意图	24
图 3.4 不同空间联合度对模型性能的影响（回归）	33
图 3.5 不同空间联合度对模型性能的影响（分类）	33
图 3.6 空间联合度的应用对模型性能的影响（回归）	34
图 3.7 空间联合度的应用对模型性能的影响（分类）	34
图 3.8 化学相似性的应用对模型性能的影响（回归）	35
图 3.9 化学相似性的应用对模型性能的影响（分类）	35
图 4.1 MMFG 的整体框架	37
图 4.2 多模态细粒度示意图	39
图 4.3 MMFG 的细粒度实现示意图	40
图 4.4 粗粒度池化方式的张量拼接	42
图 4.5 不同模态编码得到的细粒度表示	43
图 4.6 细粒度张量化示意图	44
图 4.7 消融实验示意图	49
图 5.1 分子性质预测系统界面	51
图 5.2 数据集加载示意图	52
图 5.3 数据集样例	52
图 5.4 训练模型选择示意图	53
图 5.5 主要参数设置	54
图 5.6 系统自检功能实现	54
图 5.7 训练过程	55
图 5.8 测试集预测结果	56

表目录

表 3.1 二维分子图的节点特征和边特征	20
表 3.2 数据集	27
表 3.3 参数设置和调优范围	28
表 3.4 MMCLR 与深度学习基线的性能对比	29
表 3.5 MMCLR 与分子性质预测基线的性能对比	30
表 3.6 MMCLR 与单模态的性能对比	31
表 3.7 MMCLR 与双模态的性能对比	31
表 3.8 MMCLR 与直接训练的性能对比	32
表 4.1 MMFG 与深度学习基线的性能对比	45
表 4.2 MMFG 与分子性质预测基线的性能对比	46
表 4.3 MMFG 与粗粒度方法的性能对比	47
表 4.4 自注意力机制与最大池化的性能对比	48
表 4.5 自注意力模块中缺少各组分情况下的性能对比	49

主要符号表

符 号	代表意义	单位或定义
英文字母		
G^{2d}	二维分子图	\
V	顶点集（原子集）	\
E^{2d}	二维分子图的边集（化学键集）	\
G^{3d}	三维空间表示	\
C	原子的空间位置集合	\
c_v	顶点 v 的空间位置	\
e_{uv}	顶点 u 和顶点 v 的连边	\
d_θ	空间位置距离的截断阈值	\
$O(\cdot)$	时间复杂度	\
希腊字母		
λ	空间联合度	\
缩写		
MPP	分子性质预测	
MLP	多层感知机	
RNN	循环神经网络	
CNN	卷积神经网络	
BERT	Transformer 结构的双向编码器表示	
pKa	药物的解离常数	
MD	分子描述符	
FP	指纹	
SMILES	简化分子输入线记录规范	

1 绪论

1.1 研究背景与意义

医学一直是人类文明的一根重要支柱，为保护人类健康、挽救人类生命做出了重要贡献。在医学的世界中，药物使用是必不可少的一环。在准确地判断出患者的病情后，使用有效的、适量的药物，能治愈患者的疾病，恢复患者的健康。随着社会的发展，更多种疾病被发现，也会有新的疾病出现，因此社会对药物的需求也不断增长，对药物的使用也是一个与时俱进的过程。面对新疾病带来的挑战，如果旧有药物失去了作用或效果不佳，那势必会要求药企研发并生产新型药物来应对新出现的或以前未发现、未解决的疾病。

药物研发的过程非常复杂，包括确认药物靶点、筛选先导化合物、建立检测方法、药理学研究、毒理学实验、药剂学研究、动物实验、一期临床试验、二期临床试验、三期临床试验等¹，其中每个过程都需要大量的人力和资金投入，并且需要短则几个月、长则三四年的实验时间。因此，药物研发成本高、同时也存在巨大风险。在过去，药物研发界有一个“双十”的说法，即研发一款新型药物需要十年的时间、耗资十亿美元。事实上，因为医学发展而对药物产生的更加精细化、特异化的需求，现在一款新型药物的研发需要投入的成本甚至已经超过了这两个数字²。

尽管目前生物技术的迅速进展在一定程度上帮助和促进了药物研发，但药物开发仍旧存在许多困难，周期长、投入大、耗费资源多等问题依然存在。在药物发现的过程中使用人工智能方法，特别是分子性质预测方法，可以有效地减轻对耗时费力的实验的过度依赖。例如，严重的毒性可能会导致临床试验失败或批准的药物退出市场^[1]，这会为生产药物的厂家带来难以估量的损失。为了避免出现这种情况，在药物研发的过程中对预计要生产的药物进行毒性的预测，从而排除带有毒性的分子。因此，分子性质预测工作成为了医疗保健和药物发现等研究中的重要一环^[2]。如果能够准确地预测分子的性质，可以提高药物研发的效率，减少试错成本，缩短研发周期；分子性质预测还可以帮助科学家们快速筛选出具有潜在药效的化合物，为新药物的研发和设计提供有力的支持。生产药物之前可以首先预测生成的药物分子是否带有能够促进治疗效果的性质，然后对这些分子进行筛选，保留可能会带来良好治疗效果的药物分子，排除治疗效果可能不佳的分子。

¹ <https://zhuanlan.zhihu.com/p/137765451>

² <https://zhuanlan.zhihu.com/p/588006986>

此外，分子性质预测还是许多科学研究领域中的一项重要任务，包括量子力学、物理化学、生物物理学和生理学等^[3]。例如，量子力学（Quantum Mechanical, QM）既是研究分子结构与性质的一个重要方法，也是分子性质预测中的一项重要任务。如果能够清楚生物学或化学对象中分子的各级结构，就可以用这些信息来研究与分子结构关系密切的分子活性，或者它们之间的相互作用。使用量子力学方法进行计算，能够解释分子的量子结构与其生物活性的关系，也能对研究药物分子和对应受体的相互之间的作用提供帮助，为要设计出的药物是否合理提供理论上的依据。

计算机辅助方法能够基于分子结构和化学组成等信息更便利、更精确地预测分子性质。随着计算机技术的不断进步，尤其是人工智能技术的快速发展，越来越多的研究者开始使用人工智能技术进行分子性质预测。使用计算机辅助方法，能够帮助科学家们快速准确地预测化合物的性质。

1.2 国内外相关研究工作进展

分子性质预测（Molecular Property Prediction, MPP）任务的开端可以追溯到上世纪初期的化学领域。最早的分子性质预测工作采用非计算机方法，通常基于实验数据的经验关系，如熔沸点、密度、分子量等物理性质，通过建模这些物理性质与化学结构间的关系进行分子性质预测。50年代至60年代，随着分子结构研究的不断深入，基于计算机的方法开始崭露头角。一些经典理论为计算分子结构和性质提供了数学模型，包括休克尔规则、密度泛函理论¹等，这些理论为分子性质预测工作奠定了坚实的基础。上世纪70年代至80年代，随着计算机硬件的发展，计算机性能也不断提高，借助计算机的分子性质预测方法更加广泛，如分子动力学模拟、分子轨道理论、半经验方法等，这些方法借助计算机技术进行模拟，可以得到分子的光谱、电子结构、振动频率等更加精确的性质²。随着21世纪科技的蓬勃发展，计算机的性能已经远远超出上世纪的水平，并且随着机器学习等人工智能技术的兴起，计算机方法在分子性质预测任务中的应用越来越深入，其发展推动了分子性质预测等工作不断前进，特别是在药物研发、材料设计等领域，基于计算机的分子性质预测方法已不可或缺。

近年来，随着深度学习的不断发展，分子性质预测工作中的深度学习方法开始展现优势。例如，Lashkarblooki等人使用多层感知机（Multi-Layer Perceptron, MLP）预测含离子液体的混合物的三元粘度^[4]；Nazarova等人利用优化的循环神经网络（Recurrent Neural Network, RNN）进行聚合物介电性的预测^[5]；Wallach等人设计的AtomNet^[6]被

¹ https://www.mindsponge.cn/mindsponge/docs/zh-CN/master/user/property_prediction.html

² <https://zhuanlan.zhihu.com/p/350746076>

用于药物发现领域，利用卷积神经网络来预测小分子的生理活性。

人工智能技术的发展也让分子性质预测工作的建模方式有了更多的选择。Wu 等人使用双向长短期记忆 (Long Short Term Memory, LSTM) 循环神经网络和注意力机制进行多种分子性质的预测^[7]；Wang 等人同时使用序列和图两种表示在多个数据集上进行分子性质预测^[8]；Swanson 使用有向消息传递网络 (Directed Message Passing Neural Network, D-MPNN) 进行数据分析来完成分子性质预测工作^[9]；Duvenaud 等人使用图卷积网络 (Graph Convolutional Network, GCN) 作为特征提取方式进行分子性质预测^[10]；Hu 等人则比较了包括图卷积网络、图注意力网络 (Graph Attention Network, GAT)、图同构网络 (Graph Isomorphism Network, GIN) 等多种图神经网络在分子性质预测工作上的表现^[11]。

此外，还有一些广义上的图神经网络也可用作分子性质预测工作。例如，Kearnes 等人使用 Weave 图卷积模型^[12]来获得分子表示；Gilmer 等人设计了消息传递网络 (Message Passing Neural Network, MPNN)^[13]来预测分子的量子性质；Xiong 等人设计了 Attentive FP 模型^[14]用于药物发现工作。此外，为了将三维几何信息引入分子性质预测任务，许多工作为三维空间表示专门设计了相应的图神经网络。Schütt 等人设计了 SchNet 模型^[15]，提出了连续滤波卷积层的概念，使图神经网络适用于分子动力学模拟；Gasteiger 等人分别设计了 DimeNet 模型^[16]和 DimeNet++模型^[17]模型，使用方向消息传递的方式充分利用了分子中的方向性信息；Coors 等人提出了一种通用的 3D 图网络框架 SphereNet^[18]，充分利用了分子中的空间位置信息。预训练模型在自然语言处理工作中取得了巨大成功。其思想是，通过未标记样本学习样本的通用表示，使模型学习到与标签无关、只与样本分布有关的领域知识。受此影响，在分子性质预测工作中也产生了大量通过预训练方式提高模型性能的工作。类似于自然语言处理领域的 BERT 模型^[19]，研究人员设计了一些用于分子性质预测的掩蔽语言模型 (Masked Language Model, MLM) 预训练方式，包括 ChemBERTa^[20]、SMILES-BERT^[21]、MolFormer^[22]、Mole-BERT^[23]等。还有一些工作使用了类似 GPT 模型的自回归预训练思想，包括 MolGPT^[24]、GPT-GNN^[25]、MGSSL^[26]等。

除了常见的 MLM 和自回归预训练方法之外，也存在其它预训练方法训练分子性质预测模型。GROVER 模型^[27]使用预测掩蔽的子图的方式来捕捉分子图中的上下文信息；MPG 模型^[28]将每个分子切分为两部分，随机打乱并重组，然后预测重组后的分子是否恰好一个原样本；InfoGraph^[29]通过最大化图级表示和不同尺度（如节点、边、三角形）的子结构表示之间的互信息来学习分子的图级表示；GEM^[30]导入了分子几何信息，通过键长预测、键角预测和原子距离矩阵预测进行预训练；SMILES-Transformer^[31]基于

Transformer 的编码器-解码器网络,通过重构 SMILES 字符串来学习分子表示;Uni-Mol^[32]通过在 3D 分子几何的原子坐标中添加噪声并预测这些噪声,该方法证明这项预训练目标能够学习到分子力场的相关知识。

近来,在众多的预训练方法中,对比学习方法在分子性质预测的研究中日益受到关注。对比学习是一种自监督预训练方式,它为每个样本生成多种表示,再通过最大化同一样本不同表示的相似性、最小化不同样本表示的相似性来达到让样本在空间中按相似度分布的效果,从而为模型导入与样本有关、与标签无关的内在知识。在 SimCLR^[33]提出对比学习的概念之后,这种预训练方式很快被引入分子性质预测领域,因为相比于图像和文本,分子有着更多种表示形态,因此在对比方式上存在更多可能。GraphCL^[34]、JOAO^[35]、MolCLR^[36]等工作使用二维分子图及其变种进行对比学习;DMP^[37]、SMICLR^[38]使用字符串和分子图产生分子表示进行对比学习;GraphMVP^[39]、3D Infomax^[40]、GeomGCL^[41]则使用二维分子图和三维空间表示进行对比学习;3DGCL^[42]使用不同的三维分子构象进行对比学习;MM-Deacon^[43]使用 SMILES 和 IUPAC 分别获得表示进行对比学习;KCL^[44]通过二维分子图和知识图进行对比学习等。

我国研究人员也积极参与了分子性质预测的研究。国防科技大学等单位联合设计了 MG-BERT 模型^[45]。类似 BERT 模型中的掩蔽语言建模(Mask Language Modeling, MLM)的方式,他们提出了一种自监督预训练策略:掩蔽原子预测(Masked Atoms Prediction),并使用大量无标记数据进行预训练,充分挖掘分子上下文信息;然后将预训练好的模型投入下游任务的微调;其在 11 个 ADMET 分子性质预测数据集上的性能都优于其它方法。西湖大学李子青教授团队设计了 Mole-BERT 模型^[23]用来进行分子属性预测。该方法采用 VQ-VAE 变体的编码器作为上下文感知标记器,将原子编码为有意义的离散值,可以扩大原子词汇量,缓解主要原子(如碳)和稀有原子(如磷)之间的数量差异。此外,该方法提出了三重掩蔽对比学习(Triplet Masked Contrastive Learning, TMCL)来建模分子间的异质语义相似性。谢良旭等人设计了基于融合神经网络模型^[46],用以提高对药物分子 pKa 的预测能力。

1.3 论文研究思路及目标

本文利用分子的一维、二维和三维视角的分子结构,采用三种不同模态的分子表示,通过对比学习预训练的方式使模型学习与标签无关的先验知识,并分别从不同的粒度提取分子的化学信息,以获得性能更好的分子表示进行下游的分子性质预测任务。

在第三章中,本文构建基于多模态对比学习的分子性质预测算法 MMCLR (Multi-Modal Contrastive Learning Representation for molecular property prediction)。首先将分子

的 SMILES 字符串表示处理为二维分子图和三维空间表示，然后分别将不含标签的 SMILES、二维分子图、三维空间表示这三种分子结构表示送入不同的编码器，获得该分子在三种编码器中获得的隐藏表示；之后使用对比学习的方式进行预训练，对三种分子结构表示进行相互对比，通过损失函数的约束使模型能够学习到与分子结构相关的先验知识；最后建立与预训练模型具有相同编码器结构的微调模型，将对比学习过程学习到的模型参数迁移到下游的微调模型作为初始化参数，获得三种结构表示后将三种表示进行联合并使用多层感知机处理，得到分子的最终表示，从而进行分子性质预测。本文在对比学习常用的损失函数上加入了空间联合度的概念，通过模态间的空间联合度为对比学习过程中各模态间的关系进行更细致的区分；此外，本文借助有监督对比学习的思想，计算了预测任务标签的差异作为化学相似性，通过在损失函数中添加化学相似性来提高模型对结构相似分子的预测能力。上述工作能够使模型学习到与标签值无关的分子结构信息，并且能够借助具体的预测任务的化学信息对分子结构信息中的误差知识进行约束，从而为下游的分子性质预测提供帮助。相关的实验结果证明了 MMCLR 的有效性。

在第四章中，本文提出基于多模态的细粒度自注意力分子性质预测算法 MMFG (Multi-Modal Fine-Grained self-attention algorithm for molecular property prediction)。该算法也借助预训练算法，通过对比学习的方式引入先验知识，但在编码器的输出上进行了细粒度的设计：不再从每个编码器中获得分子的整体表示，而直接获得字符级或原子级的细粒度隐藏表示，建立多模态间各要素的细粒度交互关系，通过自注意力机制使字符级或原子级表示学习到其它模态内化学意义上相近的要素的内部知识，从而在细粒度级别上为分子的整体表示提供信息。此外，将样本导入对比学习预训练获得的模型获得其初级分子表示，然后加入自注意力模块与其它细粒度表示，共同参与自注意力计算。相关的对比和消融实验结果证明了 MMFG 的有效性。

在第五章中，本文设计了分子性质预测系统，实现了简单的交互式 UI，集成包括本文提出的两种算法、基线模型等分子性质预测方法，可以导入新的分子性质预测数据集或使用提供的数据集；对于本文实现的两种算法，可以详细调整模型参数；对于其它的基线方法，可以调整模型的主要参数用于对比实验。本系统可以并且实时反馈模型的训练进度，最后输出测试集的预测结果。

本文的组织结构如下：

第一章：介绍了分子性质预测工作的研究背景和研究意义；阐述了分子性质预测在药物研发等领域起到的重要作用；说明了分子性质预测研究的必要性；回顾了分子性质预测的研究历史；整理了该领域国内外的研究现状；简单描述了本文所做的主要工作并

解释其原理和优越性。

第二章：简单介绍了与分子性质预测和多模态工作有关的相关技术；阐述了分子表示在分子性质预测中的重要作用，整理了处理这些分子表示的一些经典的神经网络模型和分子性质预测模型，涵盖自然语言处理、图神经网络、对比学习预训练等领域的相应方法；介绍了用于本文多模态部分的编码器模型、对比学习技术和多模态技术在分子性质预测领域的应用。

第三章：对 MMCLR 的整体流程进行了介绍；描述了多模态对比学习的过程和原理，设计了适用于多模态的损失函数，并融合了模态间的空间联合度和分子间的化学相似性；整理了实验的各方面设置并列出了 MMCLR 与各基线对比的实验结果，进行了消融实验验证了多模态与单模态相比的优势，阐述了模态间的空间联合度和分子的化学相似性的研究意义，设计了消融实验分析了空间联合度和化学相似性对模型性能的影响。

第四章：对 MMFG 算法的整体流程进行了介绍；描述了细粒度自注意力机制设计的优势、化学意义和主要流程；整理了实验的各方面设置并列出了 MMFG 算法与各基线对比的实验结果，进行了细粒度和粗粒度的对比实验，以及其它消融实验证明细粒度自注意力机制中各模块的有效性，包括是否使用对比学习引导、使用最大池化和卷积池化对 MMFG 算法产生的影响等。

第五章：对分子性质预测系统进行介绍，包括 UI 设计、算法的选择、数据集的加载、模型和训练过程的参数设置、训练实时反馈和最终测试结果的输出等。

结论与展望部分对算法的整体流程进行了整理与总结，分析了本文提出的两种算法与其它分子性质预测方法相比的优势与特点与两种算法间的相互关系。

2 相关技术

本章介绍了一些分子性质预测领域内的常见算法与重要概念。首先，引入了分子表示的概念，并介绍了常用的分子性质预测表示和各自的特点；介绍了图神经网络领域和自然语言处理的一些重要神经网络；介绍了一些在后文中被用作编码器的分子性质预测模型；最后介绍了对比学习技术和多模态的概念，以及这些技术在分子性质预测领域的应用。

2.1 分子表示

在化学计量学中，传统的分子性质预测方式是构建特征工程，即利用专家知识针对样本分子数据集建立特征，这种特征通常用来描述分子的某种化学性质或描述分子是否具有某种子结构，对应的特征集被称为分子描述符（Molecule Descriptors）或分子指纹（Molecule Fingerprints）。特征工程构建完成后，使用机器学习方法对得到的特征进行处理，预测分子性质，常用的机器学习方法包括支持向量机（Support Vector Machine, SVM）^[47]、随机森林（Random Forest, RF）^[48]、极端梯度增强（Extreme Gradient Boosting, XGBoost）^[49]、决策树（Decision Tree, DT）^[50]等。

这种构建特征工程的方式不仅非常依赖专家知识，并且获取有代表性的特征的过程需要耗费大量的时间和资源，而且选取的描述符会对模型施加较强的预设先验，使模型产生偏差^[51]，因此这种方法有很大的局限性。近年来，深度学习蓬勃发展，并在自然语言处理、计算机视觉等领域取得了令人瞩目的进步。由于深度学习使用的网络模型普适性强、搭建相对容易、能够处理各种形式的数据输入而不需要复杂的特征工程，并且能够取得良好的性能表现，已经逐渐被业界重视起来。

在分子性质预测领域，深度学习方法也越来越受到研究人员的青睐。由于深度学习针对不同形式的数据表示有不同的处理方式（例如循环神经网络（Recurrent Neural Network, RNN）^[52]被用来处理文本数据、卷积神经网络（Convolutional Neural Network, CNN）^[53]主要被用来处理图像数据等），因此可以针对包含更多分子信息、对分子区分度更好的分子表示设计特定的深度神经网络，从而避免使用利用专家知识得到的分子特征，因为通过复杂的特征工程获取这些特征会带来许多资源消耗，而且分子特征只能使用分子的某些属性来表示某一个分子，表示的特异性相对较差。除了上文提到的分子描述符和分子指纹，常见的分子表示形式还包括字符串表示、二维分子图表示、三维空间表示等。

字符串表示有三种常见形式：简化分子输入线记录规范（Simplified Molecular Input

Line Entry System, SMILES)^[54,55]、SMILES 任意目标规范 (SMiles ARbitrary Target Specification, SMRATS)、IUPAC 国际化学标识符 (The IUPAC International Chemical Identifier, InChI)^[56]。SMILES 在表示多样性上又分为通用型 (generic, 也称非规范型 (non-canonical)) 与规范型 (canonical) 两种。其中, 规范型 SMILES 在生成的过程中保证原子和化学键排列有序, 能够实现分子和 SMILES 的一对一映射, 并且表示形式比较简洁, 因此被广泛用作分子的字符串表示形式。

使用字符串形式表示分子十分简洁, 但同样也存在一些问题, 比如字符串表示法无法同时保证表示的唯一性、分子的手性和同位素属性等。更重要的是, 字符串形式只有原子和化学键的基础信息以及它们的连接关系, 原子和化学键中蕴含的其它信息被忽略了。分子的二维分子图表示可以一定程度上解决该问题。分子图中的“图”并不是指一张图片, 而是一种图数据结构。二维分子图通常被表示为 $G^{2d} = \{V, E^{2d}\}$, 其中 V 表示分子中包含的原子集合, 在图中原子表示为节点; E^{2d} 表示分子的化学键集合, 在图中表示为各边。图中的每个节点和每条边又包含了各自的特征信息, 并且图中记录了各节点和边之间的结构信息。这种表示方式的优越性在于, 在保留了原子和化学键的结构关系的同时为每个原子和每条化学键赋予独特的特征信息 (如原子的杂化性、化学键的共轭性等), 从而能够在一定程度上区分同一个分子中相同的原子或化学键。

二维分子图能够保留分子中各原子和化学键的信息, 但这种表示形式依然存在问题: 它并没有包含分子的空间结构。事实上, 二维分子图只能够表示分子的平面信息, 而某些分子中原子的不同空间位置会影响分子的性质, 比如分子的手性信息。此外, 不同空间位置的原子之间产生的分子内作用力也会对分子性质产生影响, 尤其是在量子力学领域, 这种效应更为明显。在这种情况下, 通过分子的三维空间表示对分子的空间信息进行补充成为一种良好的选择, 它能够在生成的过程中获取原子的空间位置。分子的三维空间表示通常被记为 $G^{3d} = \{V, C, E^{3d}\}$, 其中 V 表示分子的原子集, 在图中原子表示为节点; C 表示原子的空间位置集合, 对于每个 $v \in V$, 有 $c_v = (x_v, y_v, z_v) \in C$, 其中 (x_v, y_v, z_v) 为原子 v 的三维空间位置; E^{3d} 不再表示化学键集合, 而是在三维空间中距离小于阈值的原子对, 即 $E^{3d} = \{e_{uv} | \text{dist}(c_u, c_v) < d_\theta\}$, 其中 c_u, c_v 分别表示原子 u 和原子 v 的三维空间位置, $\text{dist}(c_u, c_v)$ 表示 c_u, c_v 在三维空间中的距离, d_θ 表示空间位置距离的截断阈值。

除了上述常见的方式之外, 还有一些其它的分子表示形式, 例如将分子表示为基于像素的二维光栅化图像, 或以三维分子网格的形式来表示分子等。但这些方法局限性较大, 因此没有被广泛使用。

分子表示有多种形式, 并且每种形式分别有自己的优势和特点, 因此本文考虑使用更多的方式来处理不同表示形式的分子, 而深度学习技术面向多种形式输入的特点为本

文提供了便利。更准确地来说,本文在处理不同的分子表示时通常会选择不同的神经网络模型。

2.2 自然语言处理

对于字符串形式的输入,本文选择使用自然语言处理(Natural Language Processing, NLP)领域的相关技术进行深度网络模型的搭建。自然语言处理工作涵盖范围较广,形式上可以分为序列分类、成对序列分类、单词标记、序列到序列等任务^[57],具体应用上则包含了机器翻译、文本摘要、文本分类、文本校对、信息抽取、语音合成、语音识别、自然语言理解和自然语言生成等众多研究领域。由于本文所研究的分子性质预测工作实际上是回归和分类问题,因此这里仅介绍文本分类(也可用作回归)的相关技术。

2.2.1 循环神经网络

循环神经网络(Recurrent Neural Network, RNN)是自然语言处理领域最经典的算法之一。1986年,Elman等人提出了最初的循环神经网络^[52],用以处理序列数据。RNN的独特之处在于,处理序列当中的每个数据点位生成隐藏表示的同时接收上一个点位的表示,然后将目前点位的表示传递给下一个单元,如此不断迭代。这种方式使得每个单元输出的隐藏表示都包含了之前所有数据的信息,因此模型在不断收集序列中每个点位的的信息的同时,还能够收集包含之前所有点位信息的信息集合。

循环神经网络能够有效地处理序列化数据,但它只能够处理较接近的上下文,随着序列读取的不断深入,RNN单元对序列前段的注意力会迅速下降。1997年,Hochreiter等人提出了长短时记忆网络(Long Short-Term Memory, LSTM)^[58],该模型使用LSTM单元来替换标准RNN中的节点,使用输入门(Input Gate)、输出门(Output Gate)和遗忘门(Forget Gate)来控制序列信息的传输,从而让上下文信息能够在较大范围内进行保存和传输,这种方式能够解决传统RNN中普遍存在的长期依赖问题和梯度消失或梯度爆炸问题。2014年,Chung等人提出了门控循环单元(Gate Recurrent Unit, GRU)^[59],为LSTM引入了更新门(Update Gate)和重置门(Reset Gate),在与LSTM性能相近的条件下减少了运算时间。

2.2.2 卷积神经网络

卷积神经网络(Convolutional Neural Network, CNN)是深度学习的代表算法之一,常被用于处理以多阵列(array)形式的数据,包括一维形式的信号、语言、序列等,二维形式的图像或音频频谱图,三维形式的视频、体积图像等。1998年,Yann LeCun等人提出了LeNet-5模型^[60],首次在神经网络中使用BP算法进行训练,形成了现代卷积

神经网络的雏形。2012 年, Krizhevsky 等人提出了 AlexNet^[61], 为卷积神经网络引入了深层结构和 dropout 方法, 在 ImageNet 图像识别大赛中一举夺魁并大幅刷新最优性能, 颠覆了计算机视觉领域。从此之后, 卷积神经网络蓬勃发展并被广泛应用于各个计算机领域, 在很多研究问题上效果显著。

卷积神经网络利用自然信号的特性形成了四个关键的思想: 局部连接、共享权重、池化和多层的使用^[62]。卷积神经网络的架构通常分为输入层、卷积层、激活层、池化层和全连接层等。其中卷积层是卷积神经网络的核心要素, 通过对感受野(Receptive Field)内的数据进行卷积达到局部连接的效果, 再不断滑动卷积核来处理其它输入, 并且使用卷积核共享权重, 这能够保证模型在不同空间位置以相同的方式收集信息, 从而使模型能够提取出在输入各处的共性特征。

虽然卷积神经网络更广泛的用途在于计算机视觉领域, 但也能够解决一部分自然语言处理的问题。例如, 2014 年 Kim 提出了 TextCNN 模型^[63], 该方法使用 word2vec 或 GLOVE 预训练好的词嵌入(Word Embedding)来对词汇进行编码, 从而将每个词汇映射成一个向量表示, 相应地, 每个句子也就被映射成了一系列的向量表示; 然后再使用卷积神经网络来处理编码后的句子, 将获得的输出用于文本分类。TextCNN 在当时取得了优异的性能, 并成为自然语言处理领域的经典之作。

2.2.3 Transformer 模型

Google 人工智能研究团队于 2017 年提出了 Transformer 模型^[64], 起初被用来解决机器翻译问题。该模型没有使用循环神经网络式的逐元素读取或卷积神经网络的窗口式遍历方式来处理序列数据, 而是采用了注意力机制进行信息交互。

Transformer 模型分为编码器和解码器两个部分。句子输入首先被模型按单词编码为一系列嵌入向量; 由于直接对每个单词进行嵌入处理的过程没有包含序列的顺序信息, 因此在每个嵌入向量中加入对应单词的位置信息。在编码器中包含多个相同的注意力层, 其中每个注意力层又分为两个子层: 多头注意力子层和前馈子层。在多头注意力子层中, 模型将输入的句子表示的向量集合当作三个矩阵 query、key、value, 分别与三个可学习权重矩阵 W^Q 、 W^K 、 W^V 相乘, 得到三个新的矩阵 Q 、 K 、 V , 再获得句子的表示向量

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.1)$$

其中 d_k 为矩阵 K 的维度。通过这个过程, 权重矩阵能够学习到输入的单词两两之间的关系, 也就是所谓的“注意力机制”。为了使模型学习到更丰富的信息, 将上述过程扩展多个通道, 形成多头注意力机制。在前馈子层中, 使用位置前馈网络(Position-wise Feed-

Forward Networks) 对每个词向量进行处理。两个子层最后都使用残差连接 (Residual Connection) 和层归一化 (Layer Normalization) 优化获得的表示。编码器将上述过程重复多次。

解码器部分和编码器部分类似, 但有一些不同。解码器每次输出一个词汇的概率分布, 而输入需要用到之前解码器的输出, 然后将输入首先使用掩蔽 (masked) 机制进行自注意力运算, 掩蔽机制的作用是保证模型不会看到当前词汇位置之后的词汇; 将掩蔽注意力部分的输出作为多头注意力的value, 编码器的输出则作为query和key, 之后的部分则与编码器相同。上述过程同样重复多次, 最后通过线性层和softmax获得新一个输出词汇的概率分布。

Transformer 模型由于其优越的性能和较小的时间开销, 一跃成为近年来最受欢迎的基础模型架构。大量大数据模型使用 Transformer 作为基本单元, 并在包括自然语言处理、计算机视觉等众多领域取得了卓越的成就。

2.3 图神经网络

对于分子来说, 图 (Graph) 是一种更直接的结构, 可以存储和表示分子中的大多数结构信息^[2], 而分子的结构信息是影响分子性质的重要一环。一个分子可以被表示成一个二维分子图 $G^{2d} = \{V, E^{2d}\}$, 其原子集被表示成图中的节点集 V , 化学键集合被表示成图中的边集 E^{2d} 。原子的属性和化学键的属性在图中被表示为节点和边的特征。在使用图来表示分子后, 就可以使用图神经网络进行分子性质预测。图神经网络 (Graph Neural Network, GNN) 的概念来自于 Scarselli 等人提出的神经网络模型^[65], 现在提到图神经网络通常泛指能够处理图结构的一系列神经网络。根据 Wu 等人的分类^[66], 图神经网络可以分为卷积图神经网络 (Convolutional Graph Neural Networks, ConvGNNs) (事实上, 卷积图神经网络通常也被叫做图卷积网络, 但为了和狭义上的图卷积网络^[67]进行区分, 在这里使用前者的表述)、循环图神经网络 (Recurrent Graph Neural Networks, RecGNNs)、图自编码器 (Graph AutoEncoders, GAEs)、时空图神经网络 (Spatial-temporal Graph Neural Networks, STGNNs) 等, 其中最常见、使用最广泛的一类是卷积图神经网络。

图神经网络和卷积图神经网络的关系有些类似于深度神经网络和卷积神经网络的关系。卷积图神经网络将卷积运算从图像等传统数据推广到了图数据, 核心思想是学习一个函数映射 $f(\cdot)$, 通过该映射使图中的节点可以聚合自身的特征和邻居节点的特征, 从而生成新的节点表示。卷积图神经网络又可以分为两大类: 基于谱域的卷积图神经网络 (Spectral-based ConvGNN) 和基于空域的卷积图神经网络 (Spatial-based ConvGNN)。基于谱域的方法从图信号处理的角度引入滤波器来定义图卷积, 其中图卷积操作被解释

为从图信号中去除噪声。基于空域的方法将图卷积表示为从邻域聚合特征信息，当图卷积网络的算法在节点层次运行时，图池化模块可以与图卷积层交错，将图表达为高级子结构。基于谱域的卷积图神经网络包括图卷积网络，基于空域的图神经网络包括图注意力网络、图同构网络、消息传递网络等。

2.3.1 图卷积网络

基于谱域的卷积图神经网络存在几个限制：首先，对图的任何扰动都会导致特征基的变化；其次，学习的滤波器是域相关的，这意味着它们不能应用于具有不同结构的图；第三，拉普拉斯矩阵的特征分解需要 $O(n^3)$ 的计算复杂度，其中 n 为图中的节点数。而 Kipf 等人设计的图卷积网络（Graph Convolutional Network, GCN）^[67]通过近似和简化，将计算复杂度降低到 $O(m)$ ，其中 m 为边的数量。

GCN 也是一种深度神经网络。设图的邻接矩阵为 A ，则 GCN 在层与层之间的传播方式可以表示为

$$f(H^{(l)}, A) = \sigma \left(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right) \quad (2.2)$$

其中： $\hat{A} = A + I$ ， I 为单位矩阵； $\hat{D}$ 为 $\hat{A}$ 的度矩阵； $H^{(l)}$ 为每一层 l 的特征矩阵， $H^{(0)}$ 为初始特征矩阵； σ 为非线性激活函数。

2.3.2 图注意力网络

GCN 的出现弥补了谱域方法和空域方法的差距，从而推动了空域方法快速发展。空域方法因为其效率高、灵活性高、普适性强的特点，受到了业界学者的青睐。图注意力网络（Graph Attention Network, GAT）^[68]是基于空域的卷积图神经网络中的代表性方法，它引入了注意力机制，在为每个节点计算来自邻居节点的信息时添加了权重。其核心思想可以表示为

$$\alpha_{ij} = \text{softmax}(\sigma(\vec{a}^T [W\vec{h}_i || W\vec{h}_j])) \quad (2.3)$$

其中 α_{ij} 为表示节点 i 和节点 j 之间的注意力系数， $\vec{h}_i$ 、 $\vec{h}_j$ 分别为节点 i 、节点 j 的节点特征， $\vec{a}$ 为可学习的注意力映射， W 为可学习的权重矩阵， σ 为激活函数。获得上述权重后，再使用经过加权的邻居节点特征来更新节点特征。

2.3.3 图同构网络

图同构网络（Graph Isomorphism Network, GIN）^[69]证明基于聚合的图神经网络的表征能力上限为 Weisfeiler-Lehman 图同构测试。达到这一上限需要聚合函数和读出函数是单射的，该方法使用神经网络来参数化聚合函数，具体表现形式为

$$\mathbf{h}_v^{(k)} = MLP^{(k)}((1 + \epsilon^{(k)}) \cdot \mathbf{h}_v^{(k-1)} + \sum_{u \in N(v)} \mathbf{h}_u^{(k-1)}) \quad (2.4)$$

其中 k 为迭代轮数, $\mathbf{h}_v^{(k)}$ 、 $\mathbf{h}_u^{(k)}$ 为第 k 次迭代节点 v 、节点 u 的隐藏表示、 $N(v)$ 为 v 的邻居节点, ϵ 为可学习参数, MLP 为多层感知机。经过多轮迭代后, 最后使用串联的方式获得图级表示。

2.4 本文涉及到的几个分子表示编码器

本文使用了多模态用以解决分子性质预测问题。具体到模型而言, 本文将各种不同的分子表示视为分子的不同模态, 针对不同模态(包括字符串表示 SMILES、二维分子图表示和三维空间表示), 使用了对应的神经网络来进行处理。因此在介绍本文使用的对比学习框架之前, 本文首先介绍用以处理各种分子表示形式的网络模型。

2.4.1 Transformer-CNN

对于分子的 SMILES 形式, 本文使用了 Karpov 等人提出的 Transformer-CNN 模型^[70]进行处理, 该模型能够有效地处理字符串形式的分子。该方法在预测分子性质之前首先进行了 SMILES 规范化预训练: 选取 ChEMBL 数据库中 SMILES 长度小于等于 110 的分子, 这些分子的 SMILES 表示是规范化的; 使用数据增强将这些分子扩充了 10 倍, 扩充得到的 SMILES 都是原分子的非规范化表示; 建立 Transformer 模型将所有规范化与非规范化的 SMILES 通过网络的学习统一“翻译”为分子对应的规范化 SMILES, 训练完成后将 Transformer 编码器中的模型参数迁移到预测模型上, 这些模型参数中保留了含有 SMILES 编码信息的先验知识, 能够帮助之后的分子性质预测任务。

用于分子性质预测的 Transformer-CNN 模型分为两部分: Transformer 编码器和 TextCNN 卷积块。首先将长度为 n 的 SMILES 形式的分子进行 one-hot 编码, 获得该分子的矩阵表示(大小为 $n \times s$, 其中 s 为 SMILES 字符集的大小); 将该矩阵输入到 Transformer 的 embedding 层进行稠密化并添加位置信息, 经过三个 Transformer 自注意力块后获得该分子的嵌入表示(维度为 $n \times h$, 其中 h 为每个字符隐藏表示的大小); 最后将获得的嵌入表示视为文本输入进多通道的 TextCNN, 得到该分子的向量表示后进行分子性质预测。

2.4.2 Attentive FP

对于分子的二维分子图形式, Xiong 等人提出了 Attentive FP(这里的 FP 是 FingerPrint 的缩写, 即指纹, 借用了分子指纹的概念, 但分子指纹的特征通常表示用来表示分子的某个子结构的有无, 此处所指的概念更宽泛, 它表示该模型提取出的特征能够体现分子的某些性质)模型^[14]。Attentive FP 是一种用于分子性质预测的图神经网络,

通过将节点信息从附近的节点传播到更远处的节点来表征原子局部环境，而且还通过应用图注意机制来考虑分子内的非局部效应。

具体而言，该方法使用了类似于 GAT（见章节 2.3.2）中的注意力机制，通过关注目标节点的邻居节点和局部环境来获得目标节点的上下文向量。该过程 M 可分为三个步骤：对齐，加权和上下文聚合，对应的公式分别为

$$\mathbf{e}_{vu} = \text{leaky_relu}(\mathbf{W} \cdot [\mathbf{h}_v, \mathbf{h}_u]) \quad (2.5)$$

$$a_{vu} = \text{softmax}(\mathbf{e}_{vu}) = \frac{\exp(\mathbf{e}_{vu})}{\sum_{u \in N(v)} \exp(\mathbf{e}_{vu})} \quad (2.6)$$

$$\mathbf{C}_v = \text{elu}(\sum_{u \in N(v)} a_{vu} \cdot \mathbf{W} \cdot \mathbf{h}_u) \quad (2.7)$$

其中 v 是目标节点， $\mathbf{h}_v$ 是节点 v 的状态向量， $N(v)$ 表示节点 v 的所有邻居节点集合， $\mathbf{h}_u$ 是节点 v 的邻居节点 u 的状态向量， leaky_relu 和 elu 是非线性激活函数。注意力计算过程 M 在对齐操作期间，将目标节点的状态向量 $\mathbf{h}_v$ 和邻居节点的状态向量 $\mathbf{h}_u$ 连接起来，然后通过可训练权重矩阵 $\mathbf{W}$ 进行线性变换，得到每组目标-邻居节点对的对齐向量 $\mathbf{e}_{vu}$ ；在加权操作中， $\mathbf{e}_{vu}$ 在相邻节点上通过 softmax 函数进行归一化，并获得相邻节点 u 对目标节点 v 的权重 a_{vu} ；最后进行上下文操作，对相邻节点的状态向量 $\mathbf{h}_u$ 进行线性变换，再进行加权和非线性激活映射，获得最终的目标节点 v 的上下文向量 $\mathbf{C}_v$ 。

Attentive FP 在每一轮都进行上述注意力计算，并使用图神经网络对分子表示进行迭代更新，迭代更新的过程分为两个步骤：消息传递和读出：

$$\mathbf{C}_v^{k-1} = \sum_{u \in N(v)} M^{k-1}(\mathbf{h}_v^{k-1}, \mathbf{h}_u^{k-1}) \quad (2.8)$$

$$\mathbf{h}_v^k = \text{GRU}^{k-1}(\mathbf{C}_v^{k-1}, \mathbf{h}_v^{k-1}) \quad (2.9)$$

其中 $\mathbf{h}_v^k$ 是 k 次迭代之后目标节点 v 的状态向量。在消息传递阶段，目标节点通过应用图注意力机制 M^{k-1} 来聚合邻居节点的信息，该机制被称为迭代 $k-1$ 时的消息函数；在读出阶段， GRU^{k-1} （门控循环单元，见章节 2.2.1）获取目标节点上一轮迭代的状态向量 $\mathbf{h}_v^{k-1}$ 和上下文消息 $\mathbf{C}_v^{k-1}$ ，并将节点的向量表示更新为当前状态 $\mathbf{h}_v^k$ ，该过程被称为迭代 $k-1$ 时的更新函数。

2.4.3 DimeNet 与 DimeNet++

DimeNet^[16]是 Gasteiger 等人提出的图神经网络模型。它在两个方面改进了常规 GNN：(1) 常规 GNN 通过嵌入 $\mathbf{h}_i$ 来表示每个原子 i ，并且通过消息传递在 l 次迭代中更新这些原子的嵌入表示，而 DimeNet 则是嵌入并更新原子之间的消息 $\mathbf{m}_{ji}$ ，这使该模型能够考虑方向信息（通过键角 $\alpha_{(k,j,i)}$ ）和原子间距离 d_{ji} ；(2) DimeNet 使用球形 2D 傅里叶-贝塞尔

准则 (Fourier-Bessel basis) 来将原子间距离和键角嵌入到一起,

$$\mathbf{m}_{ji}^{(l+1)} = f_{\text{update}} \left(\mathbf{m}_{ji}^{(l)}, \sum_{k \in N_j \setminus i} f_{\text{int}} \left(\mathbf{m}_{kj}^{(l)}, \mathbf{e}_{\text{RBF}}^{(ji)}, \mathbf{a}_{\text{SBF}}^{(kj,ji)} \right) \right) \quad (2.10)$$

其中 f_{update} 表示更新函数, f_{int} 表示交互函数, $\mathbf{e}_{\text{RBF}}^{(ji)}$ 是 d_{ji} 的径向基函数 (radial basis function, RBF) 表示, $\mathbf{a}_{\text{SBF}}^{(kj,ji)}$ 是 d_{kj} 和 $\alpha_{(kj,ji)}$ 的球形基函数 (spherical basis function, SBF) 表示。

Gasteiger 等人在 DimeNet 的基础上又提出了 DimeNet++^[17]。由于 DimeNet 分别嵌入每个交互对, 并且每个键角都需要嵌入一个三元组表示, 因此产生了组合爆炸的现象, 导致网络训练速度非常缓慢。DimeNet++ 将有向消息传递块中使用的双线性层替换为更简单的阿达玛积, 并且对模型进行了一定程度的缩减, 从而在性能几乎没有损失的条件将运算速度提高了 8 倍。

2.5 对比学习技术

对比学习 (Contrastive Learning) 是一种机器学习中常用的自监督学习方法, 其目标是通过学习数据中不同样本之间的差异来学习有意义的表示。对比学习的起源可以追溯到早期的聚类算法和相似性学习。然而, 现代对比学习的兴起主要归功于深度学习的发展, 尤其是在计算机视觉领域, 对比学习得到了广泛的应用。Chen 等人在 2020 年提出的 SimCLR^[71] 让对比学习技术在业内受到了非常多的关注, 从此对比学习开始作为一种有效的预训练手段被计算机领域内的各种任务所接受。对于对比学习技术在分子性质预测工作中的应用, 可见本文第 1.2 节, 这里不再赘述。

对比学习作为一种自监督学习方法, 主要用于学习数据中的表示, 其核心思想是让相似样本的表示相互靠近, 有差异的样本的表示相互远离, 帮助模型学习到更具区分性和有意义的特征表示。在具体的实现上, 对比学习需要每个样本具有两个表示方法, 最大化同一样本对应的两个表示方式的相似性, 最小化其它样本表示之间的相似性。但这需要借助数据增强或多模态的方法, 为每个样本建立两种表达方式进行对比学习。传统的对比学习通常采用两种形式: 使用两种分子表示进行相互对比^[38,40,41]; 使用同一种表示形式但令其表示内容上存在差异 (采用数据增强等方式)^[36,42], 从而能够进行对比学习。这两种方式的共同点, 是采用双通道或双模态 (事实上双模态本身也是双通道, 但由于使用的两种表示方式来自于不同模态, 因此在这里加以区分) 的方式, 在两者之间做对比。

需要特别介绍的是 Khosla 等人提出的有监督对比学习 (Supervised Contrastive Learning) 方法^[72]。自监督对比学习关注于每个个体样本之间的差异, 目的是让同一个

样本的两种表示更趋近，不同样本的表示相互远离，其对比依据为“是否来自于同一个样本”；有监督对比学习与自监督对比学习不同的是，其并不从“是否来自于同一个样本”来判断表示之间的趋向性，而是着眼于“是否来自于同一个类”。有监督对比学习的中心思想为，来自于同一类的样本在隐藏表示上应当相互趋近，来自于不同类的样本在隐藏表示上应当相互远离，这是非常好理解的，因为来自于同一个类的样本自然应该比不同类的样本更加相似。

2.6 多模态

多模态 (Multi-modality) 通常指涉及多个感官模态或信息来源的情境或系统。常见的多模态方法通常会使用样本的图像、自然语言、视频、语音等表示。在计算机科学和人工智能领域，多模态通常涉及融合和处理来自不同感官或数据源的信息，以更全面地理解和处理信息。近年来，随着预训练方法的发展和计算硬件的进步，大数据、大模型成为了人工智能的重要发展方向，而在大数据和大模型的帮助下，建立模态之间的数据映射关系变得更加容易。在多模态技术的帮助下，产生了一批以 Midjourney、Sora 等工具为代表的新式人工智能产品，这些工具都可以通过多模态交互的方式生产人类需要的文化内容。

化合物分子具有多种多样、特点各异的计算机表示形式，包括字符串、二维分子图、三维空间表示、分子描述符、分子指纹、分子图像等，并且每一种表示形式实际上也有多种表达方法，比如用字符串来表示分子就可以使用 SMILES 字符串、SMRATS (SMiles ARbitrary Target Specification, SMILES 二进制目标规范，是 SMILES 字符串的一种变体) 字符串和 IUPAC 字符串 (由国际纯粹与应用化学联合会 International Union of Pure and Applied Chemistry 规定的系统命名化学物质的命名法) 等。自然而然地，这些表示形式可以被视为分子的多种模态。在分子性质预测领域，多模态也是一种重要的研究手段。由于各种模态的结构特点不同，因此我们可以借鉴多模态领域的研究经验，用各种方式对不同模态的信息进行组合，从多种角度提取到分子的结构信息，为分子性质预测提供更多帮助。

多模态方法已经在分子性质预测领域中得到了应用。Zeng 等人提出了 KV-PLM 方法^[73]，将包含分子结构信息的 SMILES 字符串直接插入到知识文本中相应化学实体名的后面，之后利用类似于 BERT 中的掩蔽语言模型进行无监督的预训练，即随机掩盖文本中的一些词，让模型去预测还原出这些词，以此来学习到词汇的语境特征，为下游的分子性质预测等任务提供先验知识。Zhu 等人提出了 MEMO (MolEcular pretraining framework with Multiview cOntrastive learning) 框架^[74]，利用二维分子图、三维空间表示、

SMILES 字符串和分子指纹等多种分子表示进行对比学习预训练，利用注意力机制获得分子的集合表示。Zhang 等人提出了 PremuNet^[75]，从多个分子视图提取全面的分子信息，利用 Transformer-GNN 提取 SMILES 和二维图信息，利用融合网络提取三维几何信息，并使用了自编码器重建、原子特征掩蔽、构象重建等预训练任务为模型导入先验知识。华为云计算技术健康智能实验室发布了华为盘古药物分子大模型^[76]，该模型通过药物分子的图结构表示和 SMILES 字符串两种分子模态，通过自编码器建立自监督预训练大模型。该模型能够应用于多种下游分子任务，包括分子性质预测、分子虚拟库生成和分子优化等。此外，对比学习与多模态在概念上有交叉之处，因此对于前文提到过的多模态对比学习研究此处省略。

2.7 本章小结

本章介绍了一些分子性质预测领域内重要的概念和常见的算法。首先，列举了分子性质预测领域中一些常用的分子表示，包括 SMILES 字符串表示、二维分子图表示和三维空间表示等，并说明了这些表示各自的特点；由于本文的多模态方法使用了自然语言处理和图神经网络领域的相关技术，因此介绍了自然语言处理和图神经网络领域的一些经典的神经网络，包括循环神经网络、卷积神经网络、Transformer 模型、图卷积网络、图注意力网络、图同构网络等；此外简单介绍了 Transformer-CNN、Attentive FP、DimeNet++ 等分子性质预测方法，这几个方法在本文第三章和第四章被用作分子 SMILES、二维分子图和三维空间表示的编码器；最后介绍了对比学习技术和多模态的概念和在分子性质预测领域的发展现状。

3 基于多模态的对比学习分子性质预测算法

在这一章中，本文提出了 MMCLR (Multi-Modal Contrastive Learning of Representation for molecular property prediction) 对比学习分子性质预测框架并对其性能进行了实验分析。

由于分子的各种表示模态在结构表达上都有各自的特点(见本文 2.1 节)，因此 MMCLR 算法利用了分子的多种表示模态，包括 SMILES 字符串表示、二维分子图表示和三维空间表示，通过注入多种结构不同的分子信息来结合多种分子的结构信息；为了更深入地探究各模态表示空间之间的关系，MMCLR 引入了空间联合度的概念，通过对各模态进行加权来构建更精确的联合表示空间；为了弥补对比学习仅考虑分子结构而忽略了分子性质可能造成的“活性悬崖”问题，MMCLR 引入了化学相似性的概念，通过在化学性质角度对样本距离进行衡量来构筑更准确的样本表示。

3.1 MMCLR 算法

3.1.1 MMCLR 算法的整体流程

MMCLR 算法的整体流程如图 3.1 所示，包括对比学习预训练和下游任务微调两部分。

如图 3.1(a)所示，首先从数据集中读取分子的 SMILES 表示，然后通过 RDKit Python 库从 SMILES 表示获得对应分子的二维分子图表示和三维空间表示；再对 SMILES 表示、二维分子图表示和三维空间表示进行编码，获得分子的三种模态的隐藏表示；利用对比学习技术，使同一个分子在多种模态中的表示差异趋于最小、不同分子之间的表示差异趋向最大，通过预训练的方式为模型注入先验知识。设计了新的对比损失函数，融合了模态间的空间联合度和分子的化学相似性，使模型学习到模型间的交互关系和数据集特异性的化学信息。然后将对比学习训练好的预训练模型参数迁移到微调模型上，进行回归或分类任务的预测，如图 3.1(b)所示。

MMCLR 框架的特点在于，能够使用包括分子 SMILES、二维分子图和三维空间表示等多种分子表示，利用分子的多种模态学习到不同角度的分子结构信息，并且利用空间联合度在对比学习中对模态之间加以区分，更深度地挖掘分子信息；通过在损失函数中加入化学相似度的方式，利用与数据集标签有关的化学信息丰富对比学习过程，弥补对比学习过程中仅考虑分子结构的不足。




图 3.1 MMCLR 的整体框架
Fig. 3.1 The framework of MMCLR

3.1.2 MMCLR 中用到的分子表示

由于字符串表示占用空间小、表示规范且利于传输，因此分子数据集中通常会使用 SMILES 字符串来表示分子。MMCLR 首先从数据集中获取每个分子的 SMILES 表示，使用 RDKit Python 库将 SMILES 字符串分别转化为对应分子的二维分子图和三维空间表示。针对分子的 SMILES、二维分子图和三维空间表示分别采用处理字符串的 Transformer-CNN 编码器、处理二维分子图的 Attentive FP 编码器和处理三维空间表示的 DimeNet++ 编码器进行分析，得到三个编码器输出的隐藏表示，在预训练阶段将三种表示进行对比学习，在微调阶段将三个表示联合起来作为分子的整体隐藏表示，预测分子性质。

二维分子图采用图结构来表示分子，每个二维分子图都是由一系列相互连接的节点和边构成的，其中节点代表了分子的原子，而边代表了分子的化学键；每个节点和每条边各自具有自己的特征，从化学意义上来说，节点特征和边特征分别代表了分子的原子特征和化学键特征。所有节点特征和所有边特征的维数都是一样的，其代表的化学意义见表 3.1，所有特征使用 one-hot 进行编码。

表 3.1 二维分子图的节点特征和边特征
Tab. 3.1 The node features and bond features of 2D molecule graph

	特征	特征范围/类别	one-hot 位数
原子特征	原子类型	[H,He,Li,Be,B,·····]	132
	杂化方式	[s,sp,sp ² ,sp ³ ,sp ³ d,sp ³ d ²]	6
	手性类型	[R,S]	2
	手性中心	Boolean	1
	logP 贡献	Float	1
	摩尔折射率贡献	Float	1
	度	[0,1,2,3,4,5]	6
	形式电荷	Integer	1
	Gasteiger 电荷	Float	1
	是否为芳香性?	Boolean	1
	是否为氢受体?	Boolean	1
	是否为氢供体?	Boolean	1
	是否为异质?	Boolean	1
	是否在长为 n 的环内?	[0,3,4,5,6,7,8,9,10]	9
	Labute ASA 贡献	Float	1
	原子质量	Float	1
	氢原子个数	[0,1,2,3,4]	5
	自由基电子	[0,1,2]	3
	原子价	[0,1,2,3,4,5,6]	7
	TPSA 贡献	Float	1
边特征	边类型	[Single,Double,Triple,Aromatic]	4
	立体异构方式	[StereoNone,StereoZ,StereoE,StereoAny]	4
	是否共轭?	Boolean	1
	是否可旋转?	Boolean	1
	是否在环内?	Boolean	1

三维空间表示中的原子坐标采用 ETKDG 算法^[77]生成。要指出的是,虽然许多研究者会使用 MMFF 力场^[78]对生成的坐标进行优化,但 RDKit 库中 MMFF 力场的原子类型编码采用了自身的芳香性模型,因此优化后分子原本的芳香属性会改变,所以本文没有采用这种方式。

对于同一个分子而言,这三种隐藏表示中都蕴含了该分子原子属性、分子结构等的信息,并且由于三种输入的分子表示形式是不同的,三种隐藏表示中的信息也分别从不同角度体现了分子的结构。比如 SMILES 中的信息更加简洁,因此一维通路学习到的信息更偏向于分子的主干;二维分子图中包含了分子的拓扑结构、原子特征和化学键特征,因此二维通路能够学习到分子的结构信息和化学信息;三维空间表示中包含了分子中所有原子在空间中的三维坐标,因此三维通路对分子手性、原子间作用力等信息更为侧重。

3.1.3 对比损失函数

得到分子在三种模态下的隐藏表示后,本文设计了适用于三路对比学习的对比损失函数,并且为了挖掘多模态分子表示空间的内部信息和利用不同分子间的化学信息差异,MMCLR 在对比损失函数中添加了空间联合度和化学相似性的度量。

在以往的研究中,对比学习过程通常是在双通道或双模态上进行的,因此对比学习的损失只适用于双通道,通常会使用正规化温标交叉熵 (the Normalized Temperature-scaled CROSS ENTropy loss, NT-Xent)^[33]作为对比学习的损失函数:

$$l_{i,i'} = -\log \frac{\exp(\text{sim}(z_i, z_{i'})/\tau)}{\sum_{j=1, j \neq i}^{2N} \exp\{\text{sim}((z_i, z_j)/\tau)\}} \quad (3.1)$$

其中 z_i 、 $z_{i'}$ 表示同一个分子 i 的两种不同表示, z_j 表示同一个 mini-batch 中除 z_i 之外的其它的分子隐藏表示, N 为 mini-batch 的大小, τ 表示温标系数。因为两路对比学习中一个 mini-batch 中每个分子都有两个表示,所以一共有 $2N$ 个隐藏表示。而 mini-batch 的总损失为

$$l_{\text{mini-batch}} = \sum_{i=1}^N (l_{i,i'} + l_{i',i}) \quad (3.2)$$

但由于 NT-Xent 只适用于两路对比学习,而本章的工作建立在多模态的基础上,因此本章在该损失的基础上,提出三路对比化学损失 (Triplet Contrastive Chemical Loss) 函数。

三路对比化学损失从多模态的角度出发,将传统的两路对比损失扩展到三种模态,从而使损失函数能够约束更多种模态的分子表示;并且本文在损失函数中添加了空间联合度和化学相似性的概念:空间联合度的提出是为了优化多模态分子表示的联合表达效果,而加入化学相似性则是为了弥补对比学习概念中只考虑分子结构而缺失了化学意义的不足。

首先定义样本集 $X = \{x_i | i = 1, 2, \dots, N\}$, 其中 x_i 为样本,共 N 个样本;模态集 $M = \{m_\alpha | \alpha = \text{I}, \text{II}, \text{III}\}$, 共三种模态,分别代表了一维 SMILES 表示、二维分子图表示和三

维空间表示。

本文采用余弦相似性定义分子的两种隐藏表示的相似性。分子 x_i 在模态 m_α 下与分子 x_j 在模态 m_β 下的相似性计算如公式(3.3)所示:

$$\text{sim}(x_i^{m_\alpha}, x_j^{m_\beta}) = \exp(\cos(z_{x_i}^{m_\alpha}, z_{x_j}^{m_\beta})/\tau) \quad (3.3)$$

其中 $\text{sim}(x_i^{m_\alpha}, x_j^{m_\beta})$ 表示分子 x_i 在模态 m_α 下与分子 x_j 在模态 m_β 下的相似性, $i, j \in \{1, 2, \dots, N\}$, $\alpha, \beta \in \{I, II, III\}$, $z_{x_i}^{m_\alpha}$ 、 $z_{x_j}^{m_\beta}$ 分别表示分子 x_i 在模态 m_α 下的隐藏表示和分子 x_j 在模态 m_β 下的隐藏表示; $\cos(z_{x_i}^{m_\alpha}, z_{x_j}^{m_\beta})$ 表示 $z_{x_i}^{m_\alpha}$ 与 $z_{x_j}^{m_\beta}$ 的余弦相似性, 即分子 x_i 在模态 m_α 下的隐藏表示和分子 x_j 在模态 m_β 下的余弦相似性, $\exp()$ 为指数函数, τ 为温标系数。

接下来构建三路对比化学损失函数, 其中分为四部分计算: 同分子在不同模态下的相似性 S_1 、不同分子在同模态下的相似性 S_2 、不同分子在不同模态下的相似性 S_3 、所有分子在所有模态下的化学相似性 S_4 :

(1) 计算分子 x_i 在模态 m_α 下的隐藏表示与该分子在其他模态下的隐藏表示的相似性 $S_1(x_i^{m_\alpha})$, 如公式(3.4)所示, 其中 $i \in \{1, 2, \dots, N\}$, $\alpha \in \{I, II, III\}$, 下同:

$$S_1(x_i^{m_\alpha}) = \sum_{m \in M, m \neq m_\alpha} \text{sim}(x_i^{m_\alpha}, x_i^m) \quad (3.4)$$

(2) 计算分子 x_i 在模态 m_α 下的隐藏表示与其他分子在模态 m_α 下的隐藏表示的相似性 $S_2(x_i^{m_\alpha})$, 如公式(3.5)所示:

$$S_2(x_i^{m_\alpha}) = \sum_{x \in X, x \neq x_i} \text{sim}(x_i^{m_\alpha}, x^{m_\alpha}) \quad (3.5)$$

(3) 计算分子 x_i 在模态 m_α 下的隐藏表示与其他分子在其他模态下的隐藏表示的相似性 $S_3(x_i^{m_\alpha})$, 如公式(3.6)所示:

$$S_3(x_i^{m_\alpha}) = \sum_{m \in M, m \neq m_\alpha} \sum_{x \in X, x \neq x_i} \text{sim}(x_i^{m_\alpha}, x^m) \quad (3.6)$$

以上三个公式计算的是分子隐藏表示间的相似性, 这些相似性更多着眼于分子结构, 而非分子的化学性质。接下来计算与分子 x_i 的化学相似性相近的分子的全模态相似性 $S_4(x_i^{m_\alpha})$ 。首先计算分子 x_i 和 x_j 的类标相似性 $\text{sim}_{lab}(x_i, x_j)$ 作为其化学相似性。由于分类任务和回归任务的标签有差异, 因此我们对回归和分类任务的化学相似性分别定义。对于分类任务, 化学相似性 $\text{sim}_{lab}(x_i, x_j)_{cls}$ 定义如公式(3.7)所示, 示意图如图 3.2(a):

$$sim_{lab}(x_i, x_j)_{cls} = \begin{cases} 1, & i == j \\ 0.5, & i \neq j \text{ 且 } i, j \text{ 类标相同} \\ 0, & \text{其它} \end{cases} \quad (3.7)$$

对于回归任务，先对训练集的标签进行归一化，求其标签距离 $dist(x_i, x_j) = abs(lab_{x_i} - lab_{x_j})$ ， $abs()$ 为绝对值函数， lab_{x_i} 、 lab_{x_j} 分别为分子 x_i 和 x_j 经过归一化后的标签；然后求分子的回归标签之间的相似性 $sim_{lab}(x_i, x_j)_{reg}$ ，如公式(3.8)所示，示意图见图 3.2(b)：

$$sim_{lab}(x_i, x_j)_{reg} = \begin{cases} 1, & i == j \\ 1 - dist(x_i, x_j), & i \neq j \text{ 且 } dist(x_i, x_j) \leq 0.4 \\ 0, & dist(x_i, x_j) > 0.4 \end{cases} \quad (3.8)$$




图 3.2 分类和回归任务化学相似性示意图

Fig. 3.2 The diagram of chemical similarity for classification and regression tasks

(4) 计算分子 x_i 在模态 m_α 下的隐藏表示与所有分子全模态的隐藏表示的化学相似性 $S_4(x_i^{m_\alpha})$ ，如公式(3.9)所示：

$$S_4(x_i^{m_\alpha}) = \frac{1}{|P(i)|} \sum_{m \in M} \sum_{x \in X} sim(x_i^{m_\alpha}, x^m) * sim_{lab}(x_i, x) \quad (3.9)$$

其中对于分类任务， $P(x_i)$ 为与 x_i 分子类标相同的分子集；对于回归任务， $P(x_i)$ 为与 x_i 分子回归标签相近的分子集， $P(x_i) = \{x | sim_{lab}(x_i, x) > 0\}$ 。

计算分子 x_i 在模态 m_α 下的三路对比化学损失 $l_{x_i}^{m_\alpha}$ ，公式(3.10)如下：

$$l_{x_i}^{m_\alpha} = -\log \frac{S_1(x_i^{m_\alpha}) + S_4(x_i^{m_\alpha})}{(1-\lambda)S_2(x_i^{m_\alpha}) + \lambda S_3(x_i^{m_\alpha})} \quad (3.10)$$

其中 λ 为模态之间的空间联合度，见图 3.3。




图 3.3 空间联合度示意图

Fig. 3.3 The diagram of spatial coherence

最终，对于一个 mini-batch，其总损失为

$$L = \sum_{m \in M} \sum_{x \in X} l_x^m \quad (3.11)$$

3.1.4 空间联合度

这里需要特别解释空间联合度 λ 在损失函数中的作用。根据 Du 等人的研究^[79]，在使用多模态的训练过程中有可能会产生单模态训练不足的问题，这对于最终的训练效果是有影响的。传统的对比学习损失函数通常不对同模态和另一模态（或同通道与另一通道。这里要注意的是，多模态一定会使用多通道，但多通道不一定是多模态）进行权重上的区别，但事实上这一点对模型最终的性能是有影响的。其原因在于，对比学习在不同模态之间进行对比，其目的是让模型学习到的隐藏表示在空间内按分子相似性分布，相似的分子互相靠近，不相似的分子彼此远离。如果在单通道中使用对比学习（某些对比学习方法会在双通道之间共享网络权重，实际上相当于学习了一个通道），那梯度的反向

传播只会在一个通道中进行，分布也只有一个；但对于多通道形式的模型而言，每个通道都能单独（而不是独立）地学习出一个分布，但这个分布是与其他通道的分布相关的，其相关性被对比学习的损失函数约束。

对比学习预训练的目标是让同一样本不同模态之间的相似度 S_1 （见公式(3.4)）最大，让不同样本同一模态之间的相似度 S_2 （见公式(3.5)）和不同样本不同模态之间的相似度 S_3 （见公式(3.6)）最小。由于 S_1 和 S_3 两部分是跨模态的，这会让不同模态中相似的样本趋近，不相似的样本彼此远离。因此，随着模型的不断迭代，这两者的存在会使不同模态获得的分布趋于相似，模型最后训练出来的三种表示事实上来自于类似的分布。这种方式会帮助模型构筑更完善的样本空间，但同样会带来一个问题：由于模态之间的内部知识各异，最后得到的分布虽然会集合各个模态的知识，但也同样会淡化彼此的信息。于是本文尝试提高或降低每个模态的样本空间之间的联合度：当联合度提高时，模态之间的分布相似性会提升，使分子的分布更加准确，但这可能会造成模型学习时更加注重模态之间的联系，造成每个模态的学习效果不足；当联合度降低时，可能会在一定程度上造成模态之间的分布近似度下降导致损失样本空间的精度，但通过损失函数中的 S_2 项使模型更加侧重于得到每个模态内部的样本分布，而如果各个模态都能够很好地对分子进行区分，那它们的联合表示也应该能够很好地区分分子。因此，本方法在损失函数上对同模态和不同模态加以区分，探究空间联合度对于对比学习效果的影响。

3.1.5 化学相似性

此外，本方法在设计对比学习损失函数的时候考虑了化学相似性。传统的含有对比学习预训练阶段的分子性质预测方法通常只比较分子相似性，即基于分子自身的结构表示进行对比，例如使用字符串表示和二维分子图表示对比、二维分子图与其增强图进行对比、二维分子图和三维空间表示对比等等。但这些方法的对比策略都着眼于分子本身的结构某种表示形式或其衍生体，其默认的理论基础是结构相似的分子在化学性质上也相近。但实际上，存在结构相似的分子在化学性质的表现上是截然不同的。

在化合物分子研究领域存在一种“活性悬崖”的说法^[80]，是指化合物中微小结构变化导致生物活性或药物活性的显著变化。这种变化可以是正向的（增加活性）或负向的（减弱活性），而这种变化发生在了非常相似的化学结构之间。活性悬崖的理解对于药物设计和优化非常重要，因为它有助于确定药物分子中哪些结构要素是关键的。举例说明，左旋布洛芬和右旋布洛芬是布洛芬的两种对映异构体，仅有手性不同，但左旋布洛芬对 COX-2 几乎没有活性，而右旋布洛芬却对 COX 有确切的抑制作用。有研究表明右

旋布洛芬的活性是左旋布洛芬的 160 倍，是消旋体的 1.6 倍¹。这个例子显示了分子的活性悬崖，即微小的结构差异可以在药物活性上产生显著的影响。

为了避免出现只考虑分子相似性导致活性悬崖等问题影响模型性能的情况，本方法在分子相似性之外又考虑了分子的化学相似性。分子相似性主要关注化合物的结构特征（如共享的亚结构、环体系、拓扑结构、分子手性等）及其表征，而化学相似性主要基于化合物的物理化学特征（如溶解度、沸点、logP、分子量、电子密度、偶极矩等）。事实上，由于每一个具体的分子性质预测任务都是不同的（例如 FreeSolv 数据集的标签为分子的水化作用自由能，ESOL 数据集的标签为水溶解度等），如果仅以一种或一系列物理化学特征来衡量分子之间的化学相似性可能会出现与标签无关甚至负相关或信息泄露的问题。但对每一个数据集而言，其标签自身的相似度一定表示了分子在该数据集上的与标签相关的化学相似性。因此，本方法采用了有监督对比学习的方法，使用数据集（训练集）自身标签作为化学相似性进行监督对比，对每个数据集进行特异性的化学相似性比较，旨在使用化学相似性为对比学习预训练过程增加更多信息，从而缓解分子的活性悬崖问题。

3.2 实验

为了说明 MMCLR 的有效性，本节在分类和回归两类分子性质预测问题上分别和经典的深度学习模型与先进的分子性质预测模型进行了性能比较，包括 GRU、GCN、GAT、GIN、SchNet、GPT-GNN、GraphCL、InfoGraph、GROVER、GraphMVP、MolCLR，这些模型的特点见第 3.3.2 节。此外，为了证明本文提出的空间联合度和化学相似性的有效性，以及分子的多模态在 MMCLR 中起到的作用，本文分别对空间联合度和化学相似性进行了消融实验，并且对 MMCLR 中的各模态单独提取和两两提取的性能效果分别进行验证预测。

3.2.1 数据集

本文使用了分子性质预测工作中 9 个常见的数据集^[3]（6 个分类问题、3 个回归问题）对 MMCLR 和测试的基线模型进行评价。数据集的详细信息见表 3.2，其中由于存在无效 SMILES、一部分 SMILES 无法转化为有效的二维分子图或三维空间表示等问题，因此本文对数据集进行了裁剪，在表中最后一列中展示了裁剪前和裁剪后的化合物数量。所有的方法都是在裁剪后的数据集上进行训练、验证和测试的。

¹ https://m.baidu.com/bh/m/detail/ar_3801631534053646497

表 3.2 数据集
Tab. 3.2 Datasets

数据集	数据类型	任务	化合物数量→筛选后数量
FreeSolv	物理化学	回归	642→598
ESOL	物理化学	回归	1128→1105
Lipophilicity	物理化学	回归	4200→4186
BACE	生物物理学	分类	1513→1513
BBBP	生理学	分类	2039→1882
ClinTox	生理学	分类	1478→1354
SIDER	生理学	分类	1427→1209
Tox21	生理学	分类	7831→6859
ToxCast	生理学	分类	8575→6267

3.2.2 基线方法

本文将 MMCLR 模型与经典的深度学习模型、分子性质预测模型和预训练模型进行了比较,并且考虑到分子的多模态的特点,使用了不同类型的基线模型用以处理不同的分子表示。

对于字符串表示,本文使用经典的 NLP 模型 GRU^[59]进行处理;对于二维分子图,本文使用图神经网络进行处理,包括图卷积网络 GCN^[10]、图注意网络 GAT^[68]和图同构网络 GIN^[69];对于三维空间表示,本文使用经典的分子性质预测模型 SchNet^[15]。本文还对比了一些分子性质预测领域最先进且具有代表性的模型,包括自回归预训练模型 GPT-GNN^[25]、使用二维分子图进行对比的对比学习模型 GraphCL^[34]、通过最大化图级表示和子结构表示之间的互信息来学习表示的分子性质预测模型 InfoGraph^[29]、使用预测掩蔽的子图的方式来捕捉分子图中的上下文信息的分子性质预测模型 GROVER^[27]、使用二维分子图和三维空间表示进行对比学习的预训练模型 GraphMVP^[39]以及使用二维分子图的图增强表示进行对比的对比学习模型 MolCLR^[36]。基线模型的一些具体细节见本文第二章。

3.2.3 实验设置

本文对数据集采用了 scaffold 碳骨架切分方式,该方式对训练集、验证集和测试集的切分基于不同的碳链结构,是分子性质预测工作中的一种常用的切分方式,更符合分子性质预测工作中真实情形。

对所有的模型都进行了 10 次重复验证,每次重新设置随机种子并重置模型参数。

在对比学习模型和对比学习模型的微调阶段，本文将数据集划分为训练集、验证集和测试集，三者的比率为 8:1:1。对于一部分预训练基线，由于原文提供了预训练模型，因此本文直接加载了这些模型的预训练模型。

此外，本文也进行了不使用对比学习、直接使用有监督方法进行预测的比较实验以及一些关键参数的消融实验，包括空间联合度、化学相似性等，以及对三种模态单独训练和两两联合训练的比较实验。

在模型训练的过程中，对比学习训练轮数为 500，微调训练轮数设置为 300，在训练过程中使用了 early stopping 技术，early stopping 轮数设置为 30。所有分子的 SMILES 都来自公开数据集，二维分子图和三维空间表示则通过 SMILES 计算而来，计算工具为 Python RDKit 库。本文的模型使用 Adam 优化器进行训练，并使用 ReduceLROnPlateau 学习率衰减策略。对比学习损失中的温标系数 $\tau=0.05$ 。其它的主要参数的选择和调优范围见表 3.3。

表 3.3 参数设置和调优范围
Tab. 3.3 Hyper-parameters setting and finetune range

	超参数	取值/范围
基础参数	holdout 次数	10
	激活函数	ReLU
	每种模态的隐藏表示大小	64
	学习率衰减比率	0.9
	学习率衰减等待轮数	10
	最小学习率	0.0005
对比学习	batch size	32
	温标系数 τ	0.05
	空间联合度 λ	[0,0.25,0.5,0.75,1]
	学习轮数	500
	学习率	0.001
微调	MLP 维度	64
	batch size	[16,32,64,128]
	学习轮数	500
	早停轮数	30
	学习率	[0.001, 0.0001]

MMCLR 算法与所有的模型都使用 python 语言和 pytorch 深度学习框架进行实现, 部分基线模型使用了对应文章作者在 github 上或其它位置提供的源代码。所有模型在 Windows 环境下运行, 在 RTX 3060 GPU 上进行训练。使用的 python 版本为 3.10.4, pytorch 版本为 1.12.1, RDKit 版本为 2022.03.5, torch-geometric 库版本为 2.1.0, cuda 版本为 11.7。

3.2.4 性能评估

本文提出的模型 MMCLR 和所有基线模型的性能对比见表 3.4 和表 3.5。表 3.4 中为 MMCLR 与深度学习基线的性能对比, 表 3.5 中为 MMCLR 与分子性质预测基线的性能对比。对于回归问题, 使用均方根误差 (Root Mean Square Error, RMSE) 作为评价指标, 值越低性能越优; 对于分类问题, 使用 ROC-AUC (Receiver Operating Characteristic curve-Area Under the Curve, ROC 曲线下区域) 面积作为评价指标, 值越高性能越优。表中加粗指标值表示同一数据集下性能取得最佳, 加下划线指标值表示同一数据集下性能次优。右下角的加括号小字为标准差。赢/平/负表示该列方法与 MMCLR 相比性能胜出/持平/较差的比较结果。数据集中的 Lipo. 为数据集 Lipophilicity 的缩写, 下同。

表 3.4 MMCLR 与深度学习基线的性能对比

Tab. 3.4 The performances comparison between MMCLR and deep learning baselines							
数据集		MMCLR	GRU	GAT	GIN	GCN	SchNet
FreeSolv	回归 ↓ (RMSE)	1.60 _(0.11)	2.40 _(0.15)	<u>2.37</u> _(0.10)	2.89 _(0.14)	2.97 _(0.07)	3.41 _(0.45)
ESOL		0.91 _(0.07)	1.11 _(0.09)	1.39 _(0.03)	1.57 _(0.06)	1.53 _(0.01)	<u>1.05</u> _(0.05)
Lipo.		0.74 _(0.03)	0.86 _(0.02)	0.84 _(0.02)	<u>0.82</u> _(0.01)	0.88 _(0.01)	0.92 _(0.01)
BACE	分类 ↑ (ROC-AUC)	0.87 _(0.01)	0.55 _(0.05)	0.73 _(0.04)	<u>0.78</u> _(0.01)	0.73 _(0.02)	0.77 _(0.05)
BBBP		0.73 _(0.02)	0.58 _(0.06)	<u>0.67</u> _(0.02)	0.65 _(0.00)	0.61 _(0.01)	0.61 _(0.03)
ClinTox		1.00 _(0.00)	<u>0.99</u> _(0.00)	0.91 _(0.03)	0.92 _(0.01)	0.94 _(0.01)	0.67 _(0.03)
SIDER		0.63 _(0.02)	0.51 _(0.03)	0.60 _(0.03)	0.60 _(0.01)	0.61 _(0.02)	<u>0.62</u> _(0.02)
Tox21		0.73 _(0.02)	0.73 _(0.04)	0.70 _(0.01)	0.72 _(0.02)	0.73 _(0.01)	0.69 _(0.01)
ToxCast		0.87 _(0.02)	0.54 _(0.02)	<u>0.83</u> _(0.01)	0.72 _(0.03)	0.81 _(0.04)	0.76 _(0.10)
赢/平/负			0/1/8	0/0/9	0/0/9	0/1/8	0/0/9

表 3.5 MMCLR 与分子性质预测基线的性能对比

Tab. 3.5 The performances comparison between MMFG and molecular property prediction baselines

数据集		MMCLR	G-GNN	GraphCL	InfoGraph	GROVER	GraphMVP	MolCLR
FreeSolv		1.60 _(0.11)	2.87 _(0.05)	3.29 _(0.16)	3.40 _(0.16)	3.32 _(0.15)	2.55 _(0.14)	<u>2.48</u> _(0.28)
ESOL	回归 ↓ (RMSE)	0.91 _(0.07)	<u>1.32</u> _(0.04)	1.52 _(0.08)	1.46 _(0.09)	1.37 _(0.05)	<u>1.32</u> _(0.05)	1.46 _(0.08)
Lipo.		0.74 _(0.03)	0.82 _(0.01)	0.79 _(0.02)	0.78 _(0.02)	0.78 _(0.02)	<u>0.76</u> _(0.01)	0.82 _(0.01)
BACE		0.87 _(0.01)	0.74 _(0.02)	0.71 _(0.03)	0.75 _(0.02)	0.79 _(0.03)	<u>0.81</u> _(0.02)	0.75 _(0.03)
BBBP		<u>0.73</u> _(0.02)	0.68 _(0.01)	0.71 _(0.02)	<u>0.73</u> _(0.02)	0.70 _(0.04)	0.74 _(0.02)	0.65 _(0.02)
ClinTox	分类 ↑ (ROC-AUC)	1.00 _(0.00)	0.64 _(0.03)	<u>0.75</u> _(0.04)	0.71 _(0.05)	0.69 _(0.03)	<u>0.75</u> _(0.03)	0.72 _(0.07)
SIDER		0.63 _(0.02)	0.57 _(0.02)	0.55 _(0.02)	0.55 _(0.02)	0.57 _(0.03)	0.61 _(0.02)	<u>0.62</u> _(0.02)
Tox21		0.73 _(0.02)	0.77 _(0.16)	0.68 _(0.03)	0.71 _(0.03)	0.69 _(0.03)	0.70 _(0.03)	<u>0.75</u> _(0.03)
ToxCast		0.87 _(0.02)	0.61 _(0.05)	0.39 _(0.12)	0.60 _(0.12)	0.58 _(0.15)	0.60 _(0.18)	<u>0.74</u> _(0.09)
赢/平/负			1/0/8	0/0/9	0/0/9	0/0/9	1/0/8	0/0/9

很明显，MMCLR 取得了最好的性能，与常见的深度学习模型相比，在 9 个数据集上都取得了最优性能；与分子性质预测模型基线相比，在 9 个数据集中的 7 个上取得了最佳性能，相比于表 3.4 和表 3.5 中的基线模型中的最佳模型，本文的模型在性能上平均提升了 6.3%。与基线模型相比，本文的模型使用了更多的分子表示，从而能够学习到更丰富的分子信息，而基线模型只涉及一种或两种模态，因此能够学习到的信息相比 MMCLR 更少。此外，由于本文使用了对比学习进行预训练，并在损失函数中添加了空间联合度和化学相似性的衡量，因此 MMCLR 能够学习到来自于分子结构内部和化学属性两方面的先验知识，这为本文的监督学习过程提供了帮助。

3.2.5 模态消融实验

为了说明多模态学习对模型训练的帮助，本文进行了一系列消融实验。

首先，本文测试了三种模态中每一种模态各自独立使用进行分子性质预测的性能，测试结果见表 3.6。表中结果显示，三种模态同时使用提升了预测性能，在 9 个数据集上的 8 个都取得了最优的结果，平均性能提升达到了 4.6%。该实验表明，更多形式的分子表示对分子性质预测的训练是有益的，因为多种分子表示中蕴含的分子信息有差异，同时使用多模态能够使得模型学习到多角度的分子信息。

表 3.6 MMCLR 与单模态的性能对比

Tab. 3.6 The performances comparison between MMCLR and one-modal models

数据集		MMCLR	Transformer-CNN	Attentive FP	DimeNet++
FreeSolv	回归 ↓ (RMSE)	1.60 _(0.11)	2.47 _(0.07)	<u>1.95</u> _(0.16)	2.09 _(0.31)
ESOL		0.91 _(0.07)	1.26 _(0.04)	<u>0.92</u> _(0.04)	0.98 _(0.04)
Lipo.		0.74 _(0.03)	0.86 _(0.02)	<u>0.77</u> _(0.01)	0.81 _(0.03)
BACE	分类 ↑ (ROC-AUC)	0.87 _(0.01)	<u>0.85</u> _(0.05)	0.81 _(0.02)	0.71 _(0.07)
BBBP		0.73 _(0.02)	<u>0.72</u> _(0.01)	<u>0.72</u> _(0.03)	0.57 _(0.03)
ClinTox		1.00 _(0.00)	1.00 _(0.00)	0.91 _(0.01)	0.58 _(0.03)
SIDER		<u>0.63</u> _(0.02)	0.60 _(0.01)	0.64 _(0.02)	0.62 _(0.03)
Tox21		0.73 _(0.02)	0.68 _(0.03)	<u>0.70</u> _(0.01)	0.69 _(0.02)
ToxCast		0.87 _(0.02)	<u>0.78</u> _(0.06)	0.65 _(0.13)	0.73 _(0.09)
赢/平/负		0/1/8		1/0/8	0/0/9

此外, 本文还对三种模态中的每两种组合建立对比学习模型, 结果见表 3.7。表中结果显示, 三种模态同时使用仍然具有性能优越性, 并且使用两种模态进行预测与单模态方法相比具有明显的性能提升, 说明多种分子表示的确能够学习到更全面的分子信息, 同时也说明三种结构信息对分子性质预测都有帮助。

表 3.7 MMCLR 与双模态的性能对比

Tab. 3.7 The performances comparison between MMCLR and two-modal models

数据集		MMCLR	Tf-CNN & Att. FP	Tf-CNN & DmNt++	Att. FP & DmNet++
FreeSolv	回归 ↓ (RMSE)	1.60 _(0.11)	1.87 _(0.09)	1.93 _(0.18)	<u>1.81</u> _(0.17)
ESOL		0.91 _(0.07)	0.98 _(0.03)	0.91 _(0.03)	0.91 _(0.04)
Lipo.		0.74 _(0.03)	0.80 _(0.01)	<u>0.76</u> _(0.02)	<u>0.76</u> _(0.03)
BACE	分类 ↑ (ROC-AUC)	0.87 _(0.01)	0.85 _(0.01)	<u>0.86</u> _(0.02)	0.84 _(0.02)
BBBP		0.73 _(0.02)	0.73 _(0.01)	0.71 _(0.02)	0.71 _(0.03)
ClinTox		1.00 _(0.00)	1.00 _(0.00)	1.00 _(0.00)	0.88 _(0.03)
SIDER		0.63 _(0.02)	0.60 _(0.03)	0.61 _(0.03)	0.63 _(0.02)
Tox21		0.73 _(0.02)	0.69 _(0.04)	0.73 _(0.03)	0.69 _(0.04)
ToxCast		0.87 _(0.02)	<u>0.81</u> _(0.04)	<u>0.81</u> _(0.04)	0.77 _(0.13)
赢/平/负			0/2/7	0/3/6	0/2/7

为了证明对比学习预训练策略的有效性，本文比较了使用对比学习预训练和不使用预训练，直接将分子表示输入进三路神经网络、获得隐藏表示并拼接、直接进行预测的模型性能，测试结果见表 3.8。表中结果显示，使用对比学习的确能够提升模型的训练效果，平均性能提升了 1.8%。该实验结果证明了对比学习预训练策略的有效性，说明为模型注入与分子结构和化学信息有关的先验知识能够帮助模型进行学习。

表 3.8 MMCLR 与直接训练的性能对比

Tab. 3.8 The performances comparison between MMCLR and training directly

数据集		MMCLR	直接训练
FreeSolv	回归 ↓ (RMSE)	1.60 _(0.11)	1.80 _(0.18)
ESOL		0.91 _(0.07)	0.88 _(0.05)
Lipo.		0.74 _(0.03)	0.77 _(0.06)
BACE	分类 ↑ (ROC-AUC)	0.87 _(0.01)	0.85 _(0.01)
BBBP		0.73 _(0.02)	0.72 _(0.01)
ClinTox		1.00 _(0.00)	1.00 _(0.00)
SIDER		0.63 _(0.02)	0.61 _(0.02)
Tox21		0.73 _(0.02)	0.69 _(0.04)
ToxCast		0.87 _(0.02)	0.79 _(0.03)
赢/平/负			0/1/8

3.2.6 空间联合度分析

为了证明空间联合度能够帮助模型更好地从多种分子模态中学习信息，本文进行了消融实验：在不考虑化学相似性的情况下，通过比较不同空间联合度 λ 下训练的对比学习模型的性能来确定空间联合度对分子性质预测效果的影响。该消融实验的结果如图 3.4 和图 3.5 所示，图中横坐标为空间联合度，分数据集显示；纵坐标为同一数据集下该空间联合度与性能表现最佳的空间联合度的测试评价指标（回归问题的评价指标是 RMSE，值越低性能越优；分类问题的评价指标是 ROC-AUC，值越高性能越优）的比值。在图 3.4 中，每个数据集下表现最优的空间联合度下测得的 RMSE 标定为 100%，其它表现较差的空间联合度下测得的 RMSE 大于 100%；在图 3.5 中，每个数据集下表现最优的空间联合度下测得的 ROC-AUC 标定为 100%，其它表现较差的空间联合度下测得的 RMSE 小于 100%：




图 3.4 不同空间联合度对模型性能的影响（回归）

Fig. 3.4 The effect of different spatial coherence to the model performance (regression)




图 3.5 不同空间联合度对模型性能的影响（分类）

Fig. 3.5 The effect of different spatial coherence to the model performance (classification)

从图 3.4 和图 3.5 中可以看出，各数据集对空间联合度的敏感性有差异。在分类问题中，空间联合度较大，即重视模态间联系时训练效果较好，说明分类问题更重视模态之间的联合对比学习；在回归问题中该趋势不明显，当空间联合度趋向于 0.5，即平等地对待同模态和跨模态样本表示时模型表现更好，这一点在分类问题当中恰恰相反。

为了证明空间联合度在对比学习方法中的有效性，本方法进行了使用对比学习但不考虑空间联合度（即空间联合度为 0.5）、使用对比学习考虑空间联合度之间的比较。消

融实验的结果如图 3.6 和图 3.7（图 3.6 中为回归数据集，使用的评价指标为 RMSE，值越低性能越优，图 3.7 中六个数据集为分类数据集，使用的评价指标为 ROC-AUC，值越高性能越优，下同）：




图 3.6 空间联合度的应用对模型性能的影响（回归）

Fig. 3.6 Model performance with or without spatial coherence(regression)




图 3.7 空间联合度的应用对模型性能的影响（分类）

Fig. 3.7 Model performance with or without spatial coherence(classification)

从图 3.6 和图 3.7 可以看出，考虑空间联合度后模型性能在 9 个数据集上的 8 个有了明显的性能提升，平均性能提升达到 4.7%。说明考虑空间联合度对于对比学习过程是有帮助的。通过调整空间联合度对不同模型模态之间的分布进行约束，使得到的分子表示更能代表分子本身的特征，最终学习得到的模型性能更好。

3.2.7 化学相似性分析

为了证明加入化学相似性在分子性质预测工作中的有效性,本文对比了使用化学相似性 (Chemical Similarity) 与不使用化学相似性两种情况下对比学习的性能,消融实验的结果如图 3.8 和图 3.9 所示:




图 3.8 化学相似性的应用对模型性能的影响 (回归)

Fig. 3.8 Model performance with or without chemical similarity(regression)




图 3.9 化学相似性的应用对模型性能的影响 (分类)

Fig. 3.9 Model performance with or without chemical similarity(classification)

从图 3.8 和图 3.9 中可以看出,使用化学相似性后对比学习在大部分数据集上性能有提升,在 9 个数据集上的 8 个表现更好,说明使用化学相似性能够为分子性质预测提供更多信息,在一定程度上缓解分子的活性悬崖问题,从而帮助模型学习到更多先验知识。

3.3 本章小结

本章提出了基于多模态的对比学习分子性质预测算法 MMCLR (Multi-Modal Contrastive Learning of Representation for molecular property prediction, 用于分子性质预测的多模态对比学习表示)。MMCLR 算法利用了多模态的思想, 选取了三种经典且有效的分子结构表示, 使用对比学习技术进行预训练, 为模型训练提供与分子结构有关的先验知识。此外, 本章在对比学习的损失函数中加入了模态的空间联合度的设计, 对模态之间的关系进行了研究; 并且借助有监督对比学习的思想, 将分子的化学相似性加入对比学习损失函数部分, 从分子本身的性质出发进行先验知识的导入, 提供了分子结构之外的新的角度, 缓解了分子的活性悬崖问题。本章工作与多种分子性质预测方法和经典的深度学习方法相比, 在 9 个数据集上的 7 个都取得了最优的性能, 证明了 MMCLR 算法的优越性。本章还通过消融实验进一步验证了空间联合度和化学相似性两部分分别对模型性能的影响。

4 基于多模态细粒度的自注意力分子性质预测算法

在第三章中,本文提出了基于多模态的对比学习分子性质预测算法 MMCLR,该算法结合多种分子表示,使用对比学习预训练为模型导入与分子结构有关的先验知识,并通过模态间的空间联合度考虑多种模态之间的交互关系,通过分子间的化学相似性缓解分子的活性悬崖问题。但这种方法在建立分子的隐藏表示时是粗粒度的,即对于一个分子的每种模态都建立一个整体的隐藏表示,可能会忽略分子的多种模态间的细粒度的交互关系。针对这个问题,本章继续开展研究,提出了基于多模态的细粒度自注意力分子性质预测算法 MMFG (Multi-Modal Fine-Grained self-attention algorithm for molecular property prediction)。

4.1 MMFG 算法

4.1.1 MMFG 算法的整体流程

MMFG 算法也借助了预训练思想。首先采用对比学习预训练方式为模型注入先验知识,然后在预测模型上进行分子性质预测,方法的整体框架见图 4.1。




图 4.1 MMFG 的整体框架

Fig. 4.1 The framework of MMFG

图 4.1 中左侧所示是对比学习预训练部分，采用本文第三章的对比学习策略（见第 3.2 节）。但 MMFG 算法在具体实现上与第三章的 MMCLR 算法不同：MMCLR 算法使用预训练-迁移模式，首先在预训练模型上进行训练，然后将预训练模型参数迁移到下游的微调模型上；MMFG 算法则是首先进行模型预训练，但不进行模型参数的迁移，而是先将样本输入进预训练好的模型获得每个样本的初始分子表示，再将其导入到下一阶段的细粒度自注意力部分，作为自注意力计算的引导向量。

图 4.1 中右侧为 MMFG 的训练部分。在传统的粗粒度方式中，每种模态输入进对应的编码器后会直接进行池化，然后获得每个模态对应的隐藏表示，收集这些表示后进行下一步的操作；而在 MMFG 细粒度算法中，同样将样本的三种模态分别输入对应的编码器，但不在每种模态的模型内部直接进行池化操作，而是获得三种模态的细粒度表示后将它们收集起来，统一放入细粒度自注意力模块中作为样本的细粒度表示序列，再将预训练阶段获得的初级分子表示放到细粒度表示序列的起始位置一起加入自注意力计算。经过自注意力学习后，各模态的细粒度表示之间能够相互学习，从初级分子表示和细粒度表示获得最终分子表示，再将该表示输入多层感知机进行分类或回归，完成具体的下游具体的分子性质预测任务。

4.1.2 细粒度自注意力

在多模态研究领域，细粒度是一种常见的研究方法。其相比于粗粒度的优势在于，能够更细致地对每种模态间内部要素之间的关系进行分析，而不仅仅是只把目光放在模态与模态间的关系。

以图像和文本的多模态为例，对于“在蓝天和白云下，一只狗站在雪地上”的这样一个样本，其文本模态为引号内的这句话，其图像模态为描述了这句话的图片表示（见图 4.2）。如果以粗粒度的方式来学习，模型会更关注于整张图片和这句文本之间的映射关系，从而使模型能够将该图片与其他文本、该文本与其他图片区分开来，学习到的内部信息都是隐藏的，如果没有合适的训练模型，很难从大量数据中提取到有效的信息。而以细粒度的方式学习，模型则会关注于图片中的子块与句子中的词汇的对应关系，例如图 4.2 中以红色圆圈标识的三个子块对应了句子中的“白云”、以黄色圆圈标识的两个子块对应了句子中的“狗”，而同时以红色圆圈和青色圆圈标识的子块也同时对应了“白云”和“蓝天”。细粒度方式希望能够通过学习模态内部要素之间的关系（在图 4.2 中为图像的子块和句子的字符），使模型获得模态子要素级别的经验，这样模型下一次再遇到“蓝天”、“白云”、“狗”、“雪地”的词汇时能够分辨出其对应的图像，反之也是一样的。




图 4.2 多模态细粒度示意图

Fig. 4.2 The diagram of multi-modal fine-grain

而对于分子性质预测工作，细粒度方式考虑模态内部分子表示的各要素之间的对应关系。本文采用的三种分子表示分别为 SMILES 字符串表示、二维分子图表示和三维空间表示。在 SMILES 字符串中，字符类型主要包括分子中的原子、特殊的化学键和一些标点符号，经过编码器处理后将所有的字符处理为隐藏表示；二维分子图以原子特征矩阵、邻接矩阵和键特征矩阵的形式表示，经过编码器处理后表示为一系列的隐藏表示，每个表示代表一个原子，隐藏表示向量的数量就是分子中原子的数量；三维空间表示的输入是原子的坐标矩阵，输出则和二维分子图类似，都是输出一系列原子的隐藏表示向量。

很明显，在字符串、二维分子图和三维空间表示经过细粒度编码后都包含了所有原子的隐藏表示，因此如果将三种模态的细粒度表示放在一起学习，则训练模型应该学习到它们之间的对应关系，即同一个原子在三种模态中的细粒度表示应该更相似，因为它们在化学意义上是相同的。因此，本文在使用自注意力机制对这些表示进行处理，将三种模态的细粒度表示放入同一个自注意力模块中，模型经过充分学习，对于分子中每一

个原子而言，其在三种模态中的表示应该更相似，即彼此获得更高的注意力权重（见图 4.3）。




图 4.3 MMFG 的细粒度实现示意图

Fig. 4.3 The diagram of fine-grained implementation in MMFG

如果将对比学习表示引导和细粒度表示集合起来的矩阵记为 $\mathbf{X}$ ，令

$$\begin{cases} \mathbf{Q} = \mathbf{X}\mathbf{W}^Q \\ \mathbf{K} = \mathbf{X}\mathbf{W}^K, \\ \mathbf{V} = \mathbf{X}\mathbf{W}^V \end{cases} \quad (4.1)$$

其中 $\mathbf{W}^Q$ 、 $\mathbf{W}^K$ 、 $\mathbf{W}^V$ 为权重矩阵，则最终的输出结果为

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}, \quad (4.2)$$

其中 d_k 为 $\mathbf{X}$ 的向量数。

4.1.3 对比学习表示引导

自注意力机制因为 Transformer 模型的提出而受到关注，是本章提出的 MMFG 方法的一个重要组成模块。

Transformer 模型在被提出时是用于完成机器翻译任务的，它的一个特点是输入和输出等长，即序列有多少个元素，输入和输出就有多少个对应的向量表示。以 Transformer 模型为基础的 BERT 模型的基本结构来自于注意力模块，但它并不只关心机器翻译任务，它也可以用于解决分类任务，因此需要获得一个序列的隐藏表示来进行分类。但一个变长的序列是无法使用多层感知机处理的，因此 BERT 中使用了一个巧妙的设计，即在序

列起始位置添加一个虚拟的[cls]词根，将其视为序列的一部分，让这个词根也加入自注意力计算，最后提取这个[cls]词根的隐藏表示作为整个序列的隐藏表示，利用该隐藏表示完成分类任务（以下简称 BERT 分类模式）。

相比于最大池化或平均池化方式，BERT 分类模式能够收集更多词根信息，但它有一个问题：输入的[cls]词根经过嵌入层的处理，获得的初始隐藏表示是相同的，换句话说，每个样本输入的初始表示都是相同的。在 BERT 模型中这个问题没有显现的原因是，BERT 是一个规模较大的计算模型，其使用的数据量也非常庞大，即使样本的初始表示相同，经过多层的注意力模块处理后每个样本也能从模型中得到充分的学习，最后获得区分度较强的隐藏表示。而对于分子性质预测任务来说，数据集规模仅在几百到几千，如果使用多层注意力模块，很容易让模型出现过拟合问题，因此在模型设置中通常只会使用层数较少的注意力模块，但由于所有样本的初始表示都来自于[cls]标记的嵌入向量，因此初始表示相同，过少的注意力模块又无法让样本得到充分学习，最后获得的最终表示区分度就会很差。

因此，本章基于 BERT 分类模式和分子性质预测任务本身的特点，设计了如下的实现方式：针对样本添加的[cls]词根因为模型深度较小导致区分度较低，本文使用对比学习隐藏表示作为样本的“[cls]词根”——这里的“[cls]词根”不再用于分类，其出现在[cls]词根通常会出现的位置上，是将对对比学习隐藏表示添加在样本的多模态细粒度表示中，为获取分子的最终表示注入先验信息，通过自注意力机制，样本的细粒度表示能够学习到对比学习隐藏表示中的化学先验知识，提高模型的预测性能（这一点在第 4.3.3 节的比较实验中能够印证）。这个对比学习隐藏表示不再用于预测，而是为细粒度表示提供一个先验知识的引导，帮助模型获得更准确的多模态细粒度表示。在自注意力计算后，使用卷积计算，将分子的多模态细粒度表示通过卷积的方式池化为一个整体的分子表示向量。

本章 MMFG 方法，将对对比学习预训练部分视为一个编码器，将分子结构输入后编码为对应的分子表示，而这个表示被放在了下游的细粒度自注意力模块，作为多模态细粒度表示的先验引导。

4.1.4 细粒度张量化

在深度学习方法中，由于模型参数多、数据集规模大，如果将样本逐一送入大模型深度神经网络进行训练，会严重拖慢训练的速度。因此，数据通常都是以 batch 的形式进行训练的，即将一组样本放入同一个 batch 中，让样本之间的特征对齐，然后对样本进行归一化，统一不同维度数据的量纲和量纲单位，再将处理好的 batch 放入模型中进行训练。这样做的好处是，输出的 batch 以张量的形式存在，模型在学习时可以以矩阵

乘法的方式进行计算，大大加快了训练的速度。但实际上，输入的样本和模型的输出通常在表示形式上都是存在差异的，输入的原始样本是经过了编码器编码和模型的处理才获得了最后的输出，而这个输出通常都是以向量表示的形式存在。因此，输入的 **batch** 和输出的 **batch** 在组织形式上经常是有不同的。例如，如果输入的 **batch** 中的每个样本是字符串，通常会被对齐、填充；输入的 **batch** 中的每个样本是数值特征集合，则会进行特征对齐。处理好之后，再把这些处理好的 **batch** 当作张量进行处理；而输出的 **batch** 通常是隐藏表示张量。从输入到输出的过程，既是编码和处理的过程，也是数据组织形式从松散变向紧密的过程。

在多模态分子性质预测的研究中，对于粗粒度方式而言，样本的每个模态经过编码器处理后获得分子在每个模态中的表示，以 **batch** 的形式处理则会获得整体表示的 **batch** 张量。如果要將多模态的表示集合起来，只需要将三种模态的表示按特征拼接即可（见图 4.4）。




图 4.4 粗粒度池化方式的张量拼接

Fig. 4.4 Tensor concatenation of coarse-grained pooling

而对于细粒度方式，每个模态的分子表示经过编码器处理后得到的不是分子级的整体表示，而是字符级或原子级的细粒度表示。事实上，细粒度和粗粒度在池化之前的处理方式基本相同，粗粒度的处理就是在细粒度计算的基础上，每个编码器加上了各自的池化方式，即将每个模态的细粒度表示在编码器内部直接池化为一个整体的分子表示，

而细粒度处理则对所有模态的细粒度表示进行统一池化，而不是在每个编码器内部进行池化。

然而，这个池化方式对于每个模态来说是不一样的（见图 4.5）。因为对于细粒度表示而言，每个样本的长度是不一样的，因此不能以完整的张量来表示一个 batch 内的所有样本，同时又保证这个张量在不同的 batch 上长度统一；并且对于每种模态来说，更适合它们的编码方式也是不同的，因此对于不同的模态，通常会采用不同的池化方式。

对于字符串表示，通常将样本堆叠起来以三维张量的方式进行处理，三维分别为 batch 内样本、样本内字符表示和字符表示里的特征；对于长度不等的样本，以最长的样本为基准进行对齐，长度不够的样本在字符序列最后补充 0 向量（图 4.5 中灰色向量部分），池化时对每个样本进行最大或平均池化，再获得各自的粗粒度表示。

对于二维分子图和三维空间表示，通常以图神经网络或消息传递网络的方式进行编码，编码后得到的细粒度张量是在节点表示的方向上进行堆叠的，即获得的细粒度表示是一个二维张量，二维分别为所有样本的节点表示、每个节点里的特征。通常，二维分子图和三维空间表示会附带一个标记向量，这个向量记录了 batch 的细粒度表示中每个向量应该归属于哪个样本（图中以虚线的方式隔开），在池化时就可以依据这个标记向量进行池化，从而反向获得每个样本最终的粗粒度表示。




图 4.5 不同模态编码得到的细粒度表示

Fig. 4.5 Fine-Grained representation obtained by encoding from different modality

如果想要获得多模态细粒度表示，就需要将三种模态的细粒度表示集合到一起，获得每个样本统一的细粒度表示；而由于每个样本的字符串表示和二维与三维的细粒度表示长度不同，因此本文选择了将二维细粒度表示和三维细粒度表示按照标记向量进行拆分的方式，将二者拼接到字符串细粒度表示的后面，再加上首位的虚拟节点（虚拟字符）

获得每个样本的整体细粒度表示，对齐后长度不足的样本整体细粒度表示的最后补充 0 向量（见图 4.6）。

由于拼接后的细粒度表示里包含了虚拟节点、一维细粒度表示、二维细粒度表示、三维细粒度表示和填充字符，因此已经不完全是字符向量，但在技术上可以视作一整串字符，因此将其记为广义字符。而由于使用注意力模块进行细粒度表示的处理，本文依据 Transformer 模型的经验，使用 Layer Normalization 方式对张量进行标准化，因此不用考虑特征对齐的问题。

Layer Normalization 与常规的 Batch Normalization 不同，Batch Normalization 是从 batch 的维度去做标准化，也就是说，Batch Normalization 是在针对不同样本的同一特征做操作；Layer Normalization 是在隐藏表示的维度上去做标准化，即针对单个样本的不同特征做操作。因此 Layer Normalization 最大的好处是超脱样本中特征数的限制。具体而言，Batch Normalization 就是在每个特征的维度上统计所有样本的值，然后计算特征在所有样本上的均值和方差；Layer Normalization 就是在每个样本上统计所有特征的值，计算样本中所有特征的均值和方差。所以 Batch Normalization 在每个特征维度上的分布是稳定的，而 Layer Normalization 在每个样本上的分布是稳定的。




图 4.6 细粒度张量化示意图

Fig. 4.6 The diagram of fine-grained tensor quantization

4.2 实验

4.2.1 数据集、基线与实验细节设置

为了说明 MMFG 算法的有效性，本节在分类和预测两类分子性质预测问题上将本

文提出的 MMFG 算法与基线模型、第三章工作进行了比较，并设计了对比实验。由于本章工作与第三章工作均为分子性质预测，因此本章的数据集选取和实验细节的设置与第三章的设置（见第 3.3 节）相同，在此不进行赘述。选取的比较方法与第三章实验部分的比较方法相同，同时增加了本章的 MMFG 算法与第三章工作 MMCLR 的对比。此外，为了证明细粒度计算、自注意力模块、对比学习引导和卷积操作在 MMFG 算法中的作用，本文对这些部分进行了消融和对比实验。

4.2.2 性能评估

为了证明 MMFG 算法的有效性，本节对 MMFG 算法的性能进行了实验分析，并与一些经典的深度学习模型和最先进的分子性质预测模型进行了性能比较，其中包括本文第三章的 MMCLR 算法以及其它的基线方法，基线方法在第 3.3.2 中已经介绍过了，这里不再赘述。实验结果见表 4.1 和表 4.2，表中回归问题的评价指标为 RMSE，值越小性能越优；分类问题的评价指标为 ROC-AUC，值越大性能越优。表中粗体为同数据集下性能最优的方法的性能评价，加下划线为性能次优的方法的性能评价，括号内为测试结果的标准差，赢/平/负为对应方法在 9 个数据集上与 MMFG 相比性能胜出/持平/较差的数量。

表 4.1 MMFG 与深度学习基线的性能对比

Tab. 4.1 The performances comparison between MMFG and deep learning baselines							
数据集		MMFG	GRU	GAT	GIN	GCN	SchNet
FreeSolv	回归 ↓ (RMSE)	1.68_(0.04)	2.40 _(0.15)	<u>2.37_(0.10)</u>	2.89 _(0.14)	2.97 _(0.07)	3.41 _(0.45)
ESOL		0.89_(0.03)	1.11 _(0.09)	1.39 _(0.03)	1.57 _(0.06)	1.53 _(0.01)	<u>1.05_(0.05)</u>
Lipo.		0.74_(0.02)	0.86 _(0.02)	0.84 _(0.02)	<u>0.82_(0.01)</u>	0.88 _(0.01)	0.92 _(0.01)
BACE	分类 ↑ (ROC-AUC)	0.88_(0.01)	0.55 _(0.05)	0.73 _(0.04)	<u>0.78_(0.01)</u>	0.73 _(0.02)	0.77 _(0.05)
BBBP		0.74_(0.01)	0.58 _(0.06)	<u>0.67_(0.02)</u>	0.65 _(0.00)	0.61 _(0.01)	0.61 _(0.03)
ClinTox		1.00_(0.00)	<u>0.99_(0.00)</u>	0.91 _(0.03)	0.92 _(0.01)	0.94 _(0.01)	0.67 _(0.03)
SIDER		0.65_(0.02)	0.51 _(0.03)	0.60 _(0.03)	0.60 _(0.01)	0.61 _(0.02)	<u>0.62_(0.02)</u>
Tox21		0.76_(0.03)	<u>0.73_(0.04)</u>	0.70 _(0.01)	0.72 _(0.02)	<u>0.73_(0.01)</u>	0.69 _(0.01)
ToxCast		0.85_(0.05)	0.54 _(0.02)	<u>0.83_(0.01)</u>	0.72 _(0.03)	0.81 _(0.04)	0.76 _(0.10)
赢/平/负			0/0/9	0/0/9	0/0/9	0/0/9	0/0/9

表 4.2 MMFG 与分子性质预测基线的性能对比

Tab. 4.2 The performances comparison between MMFG and molecular property prediction baselines

数据集		MMFG	GraphCL	InfoGraph	GROVER	GraphMVP	MolCLR	MMCLR
FreeSolv		<u>1.68</u> _(0.04)	3.29 _(0.16)	3.40 _(0.16)	3.32 _(0.15)	2.55 _(0.14)	2.48 _(0.28)	1.60 _(0.11)
ESOL	回归 ↓ (RMSE)	0.89 _(0.03)	1.52 _(0.08)	1.46 _(0.09)	1.37 _(0.05)	1.32 _(0.05)	1.46 _(0.08)	<u>0.91</u> _(0.07)
Lipo.		0.74 _(0.02)	0.79 _(0.02)	0.78 _(0.02)	0.78 _(0.02)	0.76 _(0.01)	0.82 _(0.01)	0.74 _(0.03)
BACE		0.88 _(0.01)	0.71 _(0.03)	0.75 _(0.02)	0.79 _(0.03)	0.81 _(0.02)	0.75 _(0.03)	<u>0.87</u> _(0.01)
BBBP		0.74 _(0.01)	0.71 _(0.02)	0.73 _(0.02)	0.70 _(0.04)	0.74 _(0.02)	0.65 _(0.02)	0.73 _(0.02)
ClinTox	分类 ↑ (ROC-AUC)	1.00 _(0.00)	0.75 _(0.04)	0.71 _(0.05)	0.69 _(0.03)	0.75 _(0.03)	0.72 _(0.07)	1.00 _(0.00)
SIDER		0.65 _(0.02)	0.55 _(0.02)	0.55 _(0.02)	0.57 _(0.03)	0.61 _(0.02)	0.62 _(0.02)	<u>0.63</u> _(0.02)
Tox21		0.76 _(0.03)	0.68 _(0.03)	0.71 _(0.03)	0.69 _(0.03)	0.70 _(0.03)	<u>0.75</u> _(0.03)	0.73 _(0.02)
ToxCast		<u>0.85</u> _(0.05)	0.39 _(0.12)	0.60 _(0.12)	0.58 _(0.15)	0.60 _(0.18)	0.74 _(0.09)	0.87 _(0.02)
赢/平/负			0/0/9	0/0/9	0/0/9	0/1/8	0/0/9	2/2/5

表 4.1 为 MMFG 算法与深度学习基线方法的性能对比，表 4.2 为 MMFG 算法与分子性质预测基线方法的性能对比。表 4.1 和表 4.2 的实验结果表明，MMFG 在 9 个分子性质预测数据集上都表现出色；与 5 个深度学习模型相比，MMFG 算法在 9 个数据集上都取得了最优性能；与 6 个分子性质预测基线模型相比，MMFG 算法在 7 个数据集上取得了最优性能，在两个数据集上取得了次优性能，并且在大部分数据集上与本文第三章工作 MMCLR 相比表现出色，MMFG 算法的性能与 MMCLR 相比在 5 个数据集上性能更优，两个数据集上性能持平，说明了 MMFG 算法的有效性。

4.2.3 细粒度方法与粗粒度方法的比较

为了证明细粒度方式相比于粗粒度方式的优越性，本节将 MMFG 算法的性能与粗粒度方式（与细粒度方式使用相同的编码器，但每个编码器输出一个整体的向量表示，最终的分子表示为三种编码器的联合表示，使用该联合表示进行分子性质预测的方法，表中记为 Multi-Modal Coarse-Grained model, MMCG）的性能进行了比较，比较结果见表 4.3：

表 4.3 MMFG 与粗粒度方法的性能对比

Tab. 4.3 The performances comparison between MMFG and coarse-grained model

数据集		MMFG	MMCG
FreeSolv		1.68 _(0.04)	1.80 _(0.18)
ESOL	回归 ↓ (RMSE)	0.89 _(0.03)	0.88 _(0.05)
Lipo.		0.74 _(0.02)	0.77 _(0.06)
BACE		0.88 _(0.01)	0.85 _(0.01)
BBBP		0.74 _(0.01)	0.72 _(0.01)
ClinTox	分类 ↑	1.00 _(0.00)	1.00 _(0.00)
SIDER	(ROC-AUC)	0.65 _(0.02)	0.61 _(0.02)
Tox21		0.76 _(0.03)	0.69 _(0.04)
ToxCast		0.85 _(0.05)	0.79 _(0.03)
赢/平/负			1/1/7

通过实验结果可以看出，MMFG 算法在 9 个数据集的 7 个上效果好于粗粒度算法 MMCG，在一个数据集上性能与粗粒度算法持平，仅在 ESOL 数据集上性能略逊于 MMCG 算法。表 4.3 的实验结果说明细粒度方式能够为分子性质预测模型带来更多信息，通过细粒度的方式，模型能够学习到多模态细粒度表示之间的关系，加强模型细粒度之间的交互，表明该方式在分子性质预测工作上具有优越性。

4.2.4 消融实验

为了说明 MMFG 算法中各部分机制的作用，本节设计了一系列消融实验，包括注意力机制与最大池化方式的对比、使用卷积操作和直接使用 BERT 模式分类或回归对注意力机制效果的影响、是否添加对比学习引导对注意力机制操作的影响，具体内容见图 4.7。

首先，为了证明自注意力机制对 MMFG 算法的帮助，本节将图中的细粒度自注意力机制替换为最大池化方式，与使用自注意力机制的算法进行了性能比较，结果如表 4.4 所示：

表 4.4 自注意力机制与最大池化的性能对比
Tab. 4.4 The performances comparison between self-attention mechanism and max-pooling

数据集		自注意力	最大池化
FreeSolv		1.68_(0.04)	2.36 _(0.06)
ESOL	回归 ↓ (RMSE)	0.89_(0.03)	1.46 _(0.05)
Lipo.		0.74_(0.02)	0.87 _(0.02)
BACE		0.88_(0.01)	0.65 _(0.03)
BBBP		0.74_(0.01)	0.66 _(0.01)
ClinTox	分类 ↑	1.00_(0.00)	0.87 _(0.02)
SIDER	(ROC-AUC)	0.65_(0.02)	0.51 _(0.03)
Tox21		0.76_(0.03)	0.70 _(0.04)
ToxCast		0.85_(0.05)	0.41 _(0.05)
赢/平/负			0/0/9

通过表 4.4 结果能够看出，使用自注意力机制相比于最大池化方式，在 9 个数据集上性能都更好，说明自注意力机制对分子细粒度表示的池化过程有帮助，自注意力方式能够学习到不同模态的细粒度表示之间的关系，并对这些细粒度表示进行优化，从而提高模型的性能。

此外，为了证明对比学习表示引导和卷积计算在 MMFG 算法中的作用，本节设计了以下消融实验：

(1) 将对比学习表示引导（图 4.7 中①部分）和多模态细粒度表示（图 4.7 中②部分）放在一起使用自注意力机制，最后使用卷积（图 4.7 中③部分）集合为最终分子表示（即完整的 MMFG 算法）；

(2) 不使用卷积计算，在自注意力计算后使用对比学习引导作为分子表示进行分类或回归，从而确定卷积计算在细粒度算法中的作用（第 4.2.3 节中介绍的 BERT 模式分类方法），即只使用图 4.7 中的①和②部分；

(3) 不使用对比学习表示引导，只使用三种模态的细粒度表示进行卷积计算获得分子表示，从而确定对比学习表示引导在细粒度算法中的作用，即只使用图 4.7 中的②和③部分。




图 4.7 消融实验示意图

Fig. 4.7 The diagram of ablation experiments

消融实验的结果如表 4.5 所示：

表 4.5 自注意力模块中缺少各组分情况下的性能对比

Tab. 4.5 The performances comparison in the absence of each component in the self-attention module

数据集		MMFG	无卷积 (①+②)	无对比学习引导 (②+③)
FreeSolv		1.68 _(0.04)	2.42 _(0.16)	<u>1.82</u> _(0.13)
ESOL	回归 ↓ (RMSE)	0.89 _(0.03)	1.04 _(0.06)	<u>0.97</u> _(0.08)
Lipo.		0.74 _(0.02)	0.94 _(0.05)	<u>0.76</u> _(0.03)
BACE		0.88 _(0.01)	0.65 _(0.02)	<u>0.73</u> _(0.05)
BBBP		0.74 _(0.01)	0.70 _(0.03)	<u>0.73</u> _(0.01)
ClinTox	分类 ↑	1.00 _(0.00)	<u>1.00</u> _(0.00)	0.83 _(0.03)
SIDER	(ROC-AUC)	0.65 _(0.02)	0.54 _(0.05)	<u>0.58</u> _(0.02)
Tox21		0.76 _(0.03)	0.68 _(0.05)	<u>0.71</u> _(0.05)
ToxCast		0.85 _(0.05)	<u>0.79</u> _(0.06)	0.75 _(0.05)
赢/平/负			0/0/9	0/0/9

通过上述结果能够看出，在自注意力模块使用卷积进行池化并加入对比学习表示引导两种措施对模型的性能都有提升，实验在 9 个数据集上性能都更好，性能均有较大提升，说明卷积计算和对比学习表示引导对自注意力计算有帮助。对比学习表示引导能够为模型注入先验知识，卷积计算能够更好地整合分子的细粒度表示，从而提高模型的性能。

4.3 本章小结

本章提出了基于多模态的细粒度自注意力分子性质预测算法 MMFG (Multi-Modal Fine-Grained self-attention algorithm for molecular property prediction)。MMFG 算法不同于分子性质预测多模态工作中常用的粗粒度表示方式，在多模态之间使用了细粒度表示方法，并使用自注意力机制让各个模态的细粒度表示进行自注意力计算，且添加了对比学习表示引导为模型注入先验信息，从而提高模型的预测性能，提供了一种良好的分子性质预测方法。本章还阐述了 MMFG 算法中各部分的设计思路，包括细粒度自注意力模块、对比学习表示引导和细粒度张量化等部分。本章为 MMFG 设计了对比实验，将 MMFG 算法与多个基线模型以及本文第三章的 MMCLR 算法进行了性能对比，实验结果表明 MMFG 算法在分子性质预测工作中取得了良好的性能。最后，本章对 MMFG 算法的各部分进行了消融实验，验证了 MMFG 算法中各组分的有效性。

5 分子性质预测系统

5.1 引言

本文设计了一个分子性质预测系统。该系统提供了多种分子性质预测方法，允许调整部分方法参数设置，导入数据，对系统提供的分子性质预测方法进行评价分析，建立分子性质预测模型，方便研究人员选择合适的方法进行分子性质预测。

本系统能够使用交互式 UI 选择各种分子性质预测方法进行预测，系统中实现的分子性质预测方法包括本文第三章方法 MMCLR、第四章方法 MMFG 和基线模型与消融实验等。该系统允许调整学习率、训练轮数、batch size、训练集-验证集-测试集比例等训练参数，并且可视化实时反馈训练进度，呈现训练结果，为研究人员选择分子性质预测方法提供辅助。

分子性质预测算法系统的界面如图 5.1 所示：




图 5.1 分子性质预测系统界面

Fig. 5.1 The interface of molecular property prediction system

该系统分为两个菜单页，分别为主要参数页、详细参数页，在图 5.1 中用红色方框标出。

5.2 数据集和训练模型选择

主要参数页中可以选择本文中使用的 9 个数据集之一（见第 3.3.1 节），这时数据集名、预测任务、csv 文件中的样本表头和标签表头已经提供好；系统也允许加载新的数据集，但需要填写上述信息供系统读取，系统示意图见图 5.2，数据集样例见图 5.3，其中第一列为样本，第二列为回归预测标签。

图 5.2 数据集加载示意图

Fig. 5.2 The diagram of loading dataset

	A	B
1	smiles	expt
2	CN(C)C(=O)c1ccc(cc1)OC	-11.01
3	CS(=O)(=O)Cl	-4.87
4	OC(C)C=C	1.83
5	OCc1cccc1	-5.45
6	OCc1cccc1	-4.21
7	Cc1cc(cc(c1)O)C	-6.27
8	OC(C)C(C)C	2.34
9	OCOC(C)C	-3.92
10	C[C@@H]1CCCC[C@H]1C	1.58
11	OC[C@H](C)C(C)O	-3.88
12	OCc1cccc1	-4.33
13	OCOC(=O)OC	-2.49
14	c1ccc(cc1)S	-2.55
15	OC(=O)C(=O)C(=O)C	-4.78
16	c1ccc2c(c1)OC2	-1.46
17	OCc1cccc1	-2.22
18	c1cc(ccc1)Br	-5.85
19	OCOC(C)C	2.88
20	OC(=O)OCOC(=O)C	-6.34
21	OCOP(=S)(OC)SCSP(=S)(OC)OC	-6.1
22	C1CCCC(C1)O	-5.48

图 5.3 数据集样例

Fig. 5.3 An example of datasets

选择好数据集后，就可以选择的分子性质预测模型了，见图 5.4。图中的模型模态数为训练模型使用的编码器数量，1、2、3 分别代表了单模态、双模态、三模态方法，MPP 为分子性质预测（Molecular Property Prediction）的基线方法。本系统中提供了本文第三章、第四章中提到的方法、消融实验、对比基线等模型，包括单模态方法 GRU、GAT、GCN、GIN、SchNet、Transformer-CNN、Attentive FP、DimeNet++（见图 5.4(a)），双模态方法（Transformer-CNN、Attentive FP、DimeNet++三者之二作为编码器进行联合训练，是 MMCLR 的消融实验，见图 5.4(b)，其中 1d、2d、3d 分别为 Transformer-CNN、Attentive FP、DimeNet++方法），三模态方法 MMCLR（本文第三章算法，见图 5.4(c)）、

MMFG（本文第四章算法）及各种消融实验（见图 5.4(d)），以及分子性质预测工作中具有代表性的方法 AttrMask、GROVER-Contextual、ContextPred、EdgePred、GPT-GNN、GraphCL、InfoGraph、GROVER-Motif、GraphMVP 等（见图 5.4(e)，其中 AM 为 AttrMask 方法、Contextual 为 GROVER-Contextual 方法、CP 为 ContextPred 方法、EP 为 EdgePred 方法、IG 为 InfoGraph 方法、GROVER 为 GROVER-Motif 方法，其它方法与模型名相同）。




图 5.4 训练模型选择示意图

Fig. 5.4 The diagram of choosing training model

5.3 重要参数设置与自检系统

主要参数页的右侧为模型的一些重要参数的设置，包括训练轮数、batch size、学习率、验证次数、训练集比例、验证集比例、测试集比例、投影层的 dropout 比例、是否采取早停策略以及早停轮数、每个模态的隐藏表示大小等。根据选择模型的不同，如果选择的模型中有对比学习预训练部分或注意力模块的话，对比学习参数和注意力参数两部分会分别对应亮起，提供一些参数进行调整。对比学习部分提供温标系数、MMCLR 方法中的空间联合度、化学相似性和回归相似性阈值几个参数，注意力模块提供注意力层数、注意力头数、注意力 dropout 几个参数，见图 5.5。如果不再进行详细调整，则可以直接选择下方的使用默认配置，这时详细参数页的所有参数菜单将熄灭；如果想进行更加精确的调整，可以选择自定义配置，这时详细参数页的所有参数菜单将亮起，此时详细参数页内的菜单提供给用户进行详细的参数设置。

☒ 早停 30 注意力参数

训练轮数 300 注意力层数 1

batch size 16 注意力头数 2

学习率 0.001 注意力dropout 0.0

验证次数 10 投影层dropout 0.0

对比学习参数 每个模态的表示大小 64

遗忘系数 τ 0.01 训练集比例 0.8

空间联合度 λ 0.5 验证集比例 0.1

☒ 化学相似性 测试集比例 0.1

图白相似性阈值 0.4

☒ 使用默认配置

☐ 自定义配置

图 5.5 主要参数设置

Fig. 5.5 Main parameters settings

为了避免信息输入过程出错导致系统崩溃，本系统设计了简单的自检功能，如果输入信息不全或有误，则主界面下方的控制台输出会弹出对应提示信息帮助用户修改问题，见图 5.6。

图 5.6 系统自检功能实现

Fig. 5.6 System self-check function implementation

5.4 训练过程与结果展示

所有参数设置好之后,点击系统主要参数页中左侧的开始训练按钮就可以进行模型训练了。模型在训练的时候,验证次数和训练轮数两个进度条将会随着模型的训练进行实时反馈,从而让用户确定当前的训练进度,并且下方的控制台输出栏会同步输出训练信息,见图 5.7。




图 5.7 训练过程

Fig. 5.7 Training process

训练完成后，测试结果会自动保存在设置好的 excel 文件里，可以到文件管理器中进行查看。点击图 5.7 中右下角的查看结果按钮，这时会弹出模型测试集在训练模型上的预测结果，见图 5.8。每一行的第一串字符为样本的 SMILES 表示，第二个数字为真实标签，第三个数字为预测值。




图 5.8 测试集预测结果

Fig. 5.8 Prediction results of test set

5.5 本章小结

本章设计了一个分子性质预测测试系统，展示了该系统的整体界面，介绍了该系统的主要功能和交互逻辑，包括各种训练模型的选择、分子性质预测数据集的选择、主要参数调整以及其它参数调整、自检系统、进度的实时反馈、控制台输出以及结果显示等部分，为分子性质预测领域的研究人员提供了可视化工具。

6 结论与展望

6.1 结论

在医学领域中, 药物研发一直是一项重要工作, 但药物研发需要非常大的成本投入, 并且耗费大量的时间。在药物研发的过程中使用分子性质预测方法, 能够减少实验成本, 加快研发进度。例如, 可以使用分子性质预测方法对大量分子进行初步筛选, 从而排除有毒分子、筛选出可能具有药性的分子。此外, 分子性质预测在许多科学研究领域也具有重要作用, 如量子力学、物理化学等。本文对分子性质预测方法进行研究, 提出了两种多模态分子性质预测算法, 提高了分子性质预测的精度, 并实现了分子性质预测系统, 辅助研究人员选择合适的分子性质预测方法。

本文第三章提出了一种基于多模态的对比学习分子性质预测方法 MMCLR。MMCLR 框架融合了 SMILES、二维分子图和三维空间表示三种模态的分子信息, 使用对比学习预训练技术为模型注入先验知识, 设计的损失函数中添加了空间联合度概念, 能够使模型学习到模态之间的交互关系, 并利用有监督对比学习的思想, 在损失函数中添加了化学相似性概念, 从而缓解了分子的活性悬崖问题。实验表明, 在 6 个分子性质预测分类数据集和 3 个分子性质预测回归数据集上与 GRU、GAT、GCN、GIN、SchNet 等深度学习模型和 GPT-GNN、GraphCL、InfoGraph、GROVER、GraphMVP、MolCLR 等分子性质预测模型相比取得了更优异的性能。此外, 本章还设计了模态消融实验证明三种模态每一种的有效性, 并比较了三种模态单独预测的性能和每两种模态结合使用的性能, 并设计了消融实验探究空间联合度和化学相似性对 MMCLR 算法的影响。

本文第四章提出了一种基于多模态的细粒度自注意力分子性质预测模型 MMFG。MMFG 也使用了三种模态的分子信息和对比学习技术, 但没有将对对比学习预训练模型参数向下游预测模型进行迁移, 而是将对对比学习获得的分子表示输入到下游预测模型作为引导, 并且对三种模态经过编码后得到的表示进行了细粒度处理, 再使用自注意力机制将细粒度表示和对比学习引导一起训练, 获得最终的分子表示。实验表明, 在 6 个分子性质预测分类数据集和 3 个分子性质预测回归数据集上与 GRU、GAT、GCN、GIN、SchNet 等深度学习模型和 GPT-GNN、GraphCL、InfoGraph、GROVER、GraphMVP、MolCLR 等分子性质预测模型以及第三章工作 MMCLR 方法相比取得了更优异的性能。此外, 本章设计了消融实验证明 MMFG 方法中细粒度处理、对比学习引导和卷积池化等部分对模型性能的影响。

本文第五章设计了分子性质预测系统, 使用 PySide6 建立了交互式 UI 用于分子性

质预测测试。该系统支持的分子性质预测算法包括本文第三章方法 MMCLR、第四章方法 MMFG 和两算法的消融实验和对比实验以及常见的深度学习模型和分子性质预测等基线模型。该系统可以选择导入新的分子性质预测数据集或选择提供的数据，能够调整 MMCLR 和 MMFG 的重要模型参数和其它模型常见的训练参数，并反馈训练过程、输出训练结果。本系统为分子性质预测工作的落地提供了一种解决方案。

本文提出的两种算法均基于多模态分子信息，并使用了对比学习预训练技术，从而获得性能优越的分子性质预测模型。其中 MMCLR 方法通过空间联合度学习到模态空间的交互关系，通过化学相似性利用样本之间的关系优化分子表示；MMFG 方法通过细粒度学习分子中模态间原子表示之间的交互关系，并利用对比学习引导为模型添加先验知识。在第 4.3.2 节中，对比了 MMCLR 方法和 MMFG 方法的性能，在 9 个数据集中，MMFG 在 5 个数据集上性能更好，MMCLR 在 2 个数据集上性能更好，其它两个数据集性能持平，说明在测试的 9 个数据集上，细粒度方法 MMFG 比粗粒度方法 MMCLR 表现更好。MMFG 不仅从对比学习引导中获取了 MMCLR 的信息，并且通过细粒度方式学习到了多模态细粒度表示之间的交互关系，从而学习到了更好的分子表示。另外需要注意的是，粗粒度方式的计算量随模态数的增长是线性的，而细粒度方式的计算量随模态数的增长是平方级的。本文使用了三种常见的分子模态表示，当模态数进一步增加时，细粒度方式可能会遇到计算时间过长的问題，这有待进一步的实验验证。

6.2 创新点

(1) 对分子性质预测工作中对比学习预训练的部分进行了改进，设计了新的三路对比化学损失函数以适应多模态分子输入，通过在损失函数中加入模态间的空间联合度探究多模态分子表示空间的相互关系，并针对传统对比损失只考虑分子结构的问题，在损失函数中添加化学相似性，通过有监督对比学习的思想约束分子表示，使对比损失受到分子化学信息的控制，提高了分子性质预测的精度。

(2) 针对分子性质预测工作中粗粒度方法的不足，提出了细粒度自注意力分子性质预测方法，将多种分子表示模态的细粒度表示集合起来，通过自注意力机制使各模态细粒度表示相互学习，从而使模型学习到细粒度表示之间的对应化学关系，提高分子性质预测模型的性能。

6.3 展望

考虑到化学领域大量的无标签数据，以及分子的多种表达形式，如果能够建立化学大模型，同时利用大量无标签数据和分子的多种模态表达，应该能建立起非常出色的无监督预训练模型，得到精度较高的分子表示，从而直接迁移到包括分子性质预测领域在

内的各种化学任务，为整个计算机化学领域带来福祉。考虑到如今多模态工作在 NLP 领域和 CV 领域的蓬勃发展，以及 ChatGPT、Midjourney 等工作的落地实现，如果建立起效果非常好的化学预训练大模型，可能很多化学工作也可以像 ChatGPT 一样通过简单的命令交互就可以获取到自己需要的分子结构或分子性质，能够极大程度的降低化学作者的工作压力。

参 考 文 献

- [1] Cai C., Wang S., Xu Y., et al. Transfer learning for drug discovery[J]. Journal of Medicinal Chemistry, 2020, 63(16): 8683-8694.
- [2] Li Z., Jiang M., Wang S., et al. Deep learning methods for molecular representation and property prediction[J]. Drug Discovery Today, 2022, 27(12): 103373.
- [3] Wu Z., Ramsundar B., Feinberg E. N., et al. MoleculeNet: a benchmark for molecular machine learning[J]. Chemical Science, 2018, 9(2): 513-530.
- [4] Lashkarblooki M., Hezave A. Z., Al-Ajmi A. M., et al. Viscosity prediction of ternary mixtures containing ILs using multi-layer perceptron artificial neural network[J]. Fluid Phase Equilibria, 2012, 326: 15-20.
- [5] Nazarova A. L., Yang L., Liu K., et al. Dielectric polymer property prediction using recurrent neural networks with optimizations[J]. Journal of Chemical Information and Modeling, 2021, 61(5): 2175-2186.
- [6] Wallach I., Dzamba M., Heifets A.. AtomNet: a deep convolutional neural network for bioactivity prediction in structure-based drug discovery[J]. arXiv preprint, 2015: 1510.02855.
- [7] Wu C. K., Zhang X C., Yang Z. J., et al. Learning to SMILES: ban-based strategies to improve latent representation learning from molecules[J]. Briefings in Bioinformatics, 2021, 22(6): bbab327.
- [8] Wang Z., Liu M., Luo Y., et al. Advanced graph and sequence neural networks for molecular property prediction and drug discovery[J]. Bioinformatics, 2022, 38(9): 2579-2586.
- [9] Swanson K.. Message passing neural networks for molecular property prediction[D]. Massachusetts Institute of Technology, 2019.
- [10] Duvenaud D. K., Maclaurin D., Iparraguirre J., et al. Convolutional networks on graphs for learning molecular fingerprints[C]. Neural Information Processing Systems, Montreal, Quebec, Canada. 2015: 28.
- [11] Hu W., Liu B., Gomes J., et al. Strategies for pre-training graph neural networks[J]. arXiv preprint, 2019: 1905.12265.
- [12] Kearnes S., McCloskey K., Berndl M., et al. Molecular graph convolutions: moving beyond fingerprints[J]. Journal of Computer-aided Molecular Design, 2016, 30: 595-608.
- [13] Gilmer J., Schoenholz S. S., Riley P. F., et al. Neural message passing for quantum chemistry[C]. The 34th International Conference on Machine Learning, Sydney, New South Wales, Australia. 2017: 1263-1272.
- [14] Xiong Z., Wang D., Liu X., et al. Pushing the boundaries of molecular representation for drug discovery with the graph attention mechanism[J]. Journal of Medicinal Chemistry, 2019, 63(16): 8749-8760.
- [15] Schütt K. T., Sauceda H. E., Kindermans P. J., et al. SchNet-a deep learning architecture for molecules and materials[J]. The Journal of Chemical Physics, 2018, 148(24): 241722.
- [16] Gasteiger J., Groß J., Günnemann S. Directional message passing for molecular graphs[J]. arXiv preprint, 2020: 2003.03123.

- [17] Gasteiger J., Giri S., Margraf J. T., et al. Fast and uncertainty-aware directional message passing for non-equilibrium molecules[J]. arXiv preprint, 2020: 2011.14115.
- [18] Coors B., Condurache A. P., Geiger A.. SphereNet: learning spherical representations for detection and classification in omnidirectional images[C]. The 15th European Conference on Computer Vision, Munich, Bavaria, Germany. 2018: 518-533.
- [19] Devlin J., Chang M. W., Lee K., et al. BERT: pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint, 2018: 1810.04805.
- [20] Chithrananda S., Grand G., Ramsundar B.. ChemBERTa: large-scale self-supervised pretraining for molecular property prediction[J]. arXiv preprint, 2020: 2010.09885.
- [21] Wang S., Guo Y., Wang Y., et al. SMILES-BERT: large scale unsupervised pre-training for molecular property prediction[C]. The 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics, New York, New York, United States. 2019: 429-436.
- [22] Ross J., Belgodere B., Chenthamarakshan V., et al. Large-Scale chemical language representations capture molecular structure and properties[J]. Nature Machine Intelligence, 2022, 4(12): 1256-1264.
- [23] Xia J., Zhao C., Hu B., et al. Mole-BERT: rethinking pre-training graph neural networks for molecules[C]. The Eleventh International Conference on Learning Representations, online. 2022.
- [24] Bagal V., Aggarwal R., Vinod P. K., et al. MolGPT: molecular generation using a transformer-decoder model[J]. Journal of Chemical Information and Modeling, 2022, 62(9): 2064-2076.
- [25] Hu Z., Dong Y., Wang K., et al. GPT-GNN: generative pre-training of graph neural networks[C]. The 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, online. 2020: 1857-1867.
- [26] Zhang Z., Liu Q., Wang H., et al. Motif-Based graph self-supervised learning for molecular property prediction[C]. Neural Information Processing Systems, Sydney, New South Wales, Australia. 2021: 15870-15882.
- [27] Rong Y., Bian Y., Xu T., et al. Self-Supervised graph transformer on large-scale molecular data[C]. Neural Information Processing Systems, online. 2020: 12559-12571.
- [28] Li P., Wang J., Qiao Y., et al. An effective self-supervised framework for learning expressive molecular global representations to drug discovery[J]. Briefings in Bioinformatics, 2021, 22(6): bbab109.
- [29] Sun F.-Y., Hoffman J., Verma V., et al. InfoGraph: unsupervised and semi-supervised graph-level representation learning via mutual information maximization[J]. arXiv preprint, 2019: 1908.01000.
- [30] Fang X., Liu L., Lei J., et al. Geometry-Enhanced molecular representation learning for property prediction[J]. Nature Machine Intelligence, 2022, 4(2): 127-134.
- [31] Honda S., Shi S., Ueda H. R.. Smiles-Transformer: pre-trained molecular fingerprint for low data drug discovery[J]. arXiv preprint, 2019: 1911.04738.
- [32] Zhou G., Gao Z., Ding Q., et al. Uni-Mol: a universal 3d molecular representation learning framework[C]. The Twelfth International Conference on Learning Representations, London, Greater London, United Kingdom. 2023.

- [33] Chen T., Kornblith S., Norouzi M., et al. A simple framework for contrastive learning of visual representations[C]. The Thirty-seventh International Conference on Machine Learning, online. 2020: 1597-1607.
- [34] Moren K., Goehringer D.. GraphCL: a framework for execution of data-flow graphs on multi-device platforms[C]. 30th Euromicro International Conference on Parallel, Valladolid, Castile and León, Spain. 2022: 116-121.
- [35] You Y., Chen T. L., Shen Y., et al. Graph contrastive learning automated[C]. The Thirty-eighth International Conference on Machine Learning, online. 2021: 12121-12132.
- [36] Wang Y., Wang J., Cao Z., et al. Molecular contrastive learning of representations via graph neural networks[J]. Nature Machine Intelligence, 2022, 4(3): 279-287.
- [37] Zhu J., Xia Y., Qin T., et al. Dual-view molecule pre-training[C]. The 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, Anchorage, Alaska, United States. 2023: 3615-3627.
- [38] Pinheiro G. A., Da Silva J. L. F., Quiles M. G.. SMICLR: contrastive learning on multiple molecular representations for semisupervised and unsupervised representation learning[J]. Journal of Chemical Information and Modeling, 2022, 62(17): 3948-3960.
- [39] Liu S., Wang H., Liu W., et al. Pre-training molecular graph representation with 3d geometry[J]. arXiv preprint, 2021: 2110.07728.
- [40] Stärk H., Beaini D., Corso G., et al. 3D Infomax improves gnns for molecular property prediction[C]. The Thirty-ninth International Conference on Machine Learning, Tokyo, Tokyo Metropolis, Japan. 2022: 20479-20502.
- [41] Li S., Zhou J., Xu T., et al. GEOMGCL: geometric graph contrastive learning for molecular property prediction[C]. The 36th Annual AAAI Conference on Artificial Intelligence, Vancouver, British Columbia, Canada. 2022, 36(4): 4541-4549.
- [42] Moon K., Im H. J., Kwon S.. 3D graph contrastive learning for molecular property prediction[J]. Bioinformatics, 2023, 39(6): btad371.
- [43] Guo Z., Sharma P., Martinez A., et al. Multilingual molecular representation learning via contrastive pre-training[J]. arXiv preprint, 2021: 2109.08830.
- [44] Fang Y., Zhang Q., Yang H. H., et al. Molecular contrastive learning with chemical element knowledge graph[C]. The 36th Annual AAAI Conference on Artificial Intelligence, Vancouver, British Columbia, Canada. 2022: 3968-3976.
- [45] Zhang X. C., Wu C. K., Yang Z. J., et al. MG-BERT: leveraging unsupervised atomic representation learning for molecular property prediction[J]. Briefings in Bioinformatics, 2021, 22(6): bbab152.
- [46] 谢良旭,李峰,谢建平,et al. 基于融合神经网络模型的药物分子性质预测[J]. 计算机科学, 2021, 48(09): 251-256.
- [47] Cortes C., Vapnik V.. Support-vector networks[J]. Machine Learning, 1995, 20: 273-297.
- [48] Breiman L.. Random forests[J]. Machine Learning, 2001, 45: 5-32.
- [49] Chen T., Guestrin C.. XGBOOST: a scalable tree boosting system[C]. The 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, California, United States. 2016: 785-794.

- [50] Quinlan J. R.. C4.5: programs for machine learning[J]. Machine Learning, 1994, 16: 235-240.
- [51] 陈鑫,刘喜恩,吴及. 药物表示学习研究进展[J]. 清华大学学报(自然科学版), 2020, 60(02): 171-180.
- [52] Elman J. L.. Finding structure in time[J]. Cognitive Science, 1990, 14(2): 179-211.
- [53] Lecun Y., Boser B., Denker J. S., et al. Backpropagation applied to handwritten zip code recognition[J]. Neural Computation, 1989, 1(4): 541-551.
- [54] Weininger D.. SMILES, A chemical language and information system. 1. introduction to methodology and encoding rules[J]. Journal of Chemical Information and Computer Sciences, 1988, 28(1): 31-36.
- [55] Weininger D., Weininger A., Weininger J. L.. SMILES. 2. algorithm for generation of unique smiles notation[J]. Journal of Chemical Information and Computer Sciences, 1989, 29(2): 97-101.
- [56] Heller S. R., McNaught A., Pletnev I., et al. InChI, the iupac international chemical identifier[J]. Journal of Cheminformatics, 2015, 7(1): 1-34.
- [57] Lauriola I., Lavelli A., Aioli F.. An introduction to deep learning in natural language processing: models, techniques, and tools[J]. Neurocomputing, 2022, 470: 443-456.
- [58] Hochreiter S., Graves A.. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [59] Chung J., Gulcehre C., Cho K. H., et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv preprint, 2014: 1412.3555.
- [60] Lecun Y., Bottou L., Bengio Y., et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [61] Krizhevsky A., Sutskever I., Hinton G. E.. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [62] Lecun Y., Bengio Y., Hinton G.. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [63] Kim Y.. Convolutional neural network for sentence classification[C]. The Conference on Empirical Methods in Natural Language Processing, Doha, Ad Dawhah, Qatar. 2014: 1746-1751.
- [64] Vaswani A., Shazeer N., Parmar N., et al. Attention is all you need[C]. Neural Information Processing Systems, Long Beach, California, United States. 2017, 30.
- [65] Scarselli F., Gori M., Tsoi A. C., et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2008, 20(1): 61-80.
- [66] Wu Z., Pan S., Chen F., et al. A comprehensive survey on graph neural networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(1): 4-24.
- [67] Kipf T. N., Welling M.. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint, 2016: 1609.02907.
- [68] Veličković P., Cucurull G., Casanova A., et al. Graph attention networks[J]. arXiv preprint, 2017: 1710.10903.
- [69] Xu K., Hu W., Leskovec J., et al. How powerful are graph neural networks? [J]. arXiv preprint, 2018: 1810.00826.
- [70] Karpov P., Godin G., Tetko I. V.. Transformer-CNN: swiss knife for QSAR modeling and interpretation[J]. Journal of Cheminformatics, 2020, 12(1): 1-12.

- [71] Chen T., Kornblith S., Norouzi M., et al. A simple framework for contrastive learning of visual representations[C]. The 37th International Conference on Machine Learning, PMLR, online. 2020:1597-1607.
- [72] Khosla P., Teterwak P., Wang C., et al. Supervised contrastive learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 18661-18673.
- [73] Zeng Z., Yao Y., Liu Z., et al. A deep-learning system bridging molecule structure and biomedical text with comprehension comparable to human professionals[J]. Nature Communications, 2022, 13(1): 862.
- [74] Zhu Y., Chen D., Du Y., et al. Featurizations matter: a multiview contrastive learning approach to molecular pretraining[C]. ICML 2022 2nd AI for Science Workshop, Tokyo, Tokyo Metropolis, Japan. 2022.
- [75] Zhang H., Wu J., Liu S., et al. A pre-trained multi-representation fusion network for molecular property prediction[J]. Information Fusion, 2024, 103: 102092.
- [76] Lin X., Xu C., Xiong Z., et al. PanGu drug model: learn a molecule like a human[J]. Biorxiv, 2022: a2022.03. 31.485886.
- [77] Riniker S., Landrum G. A.. Better informed distance geometry: using what we know to improve conformation generation[J]. Journal of Chemical Information and Modeling, 2015, 55(12): 2562-2574.
- [78] Halgren T. A.. Merck molecular force field. I. Basis, form, scope, parameterization, and performance of MMFF94[J]. Journal of Computational Chemistry, 1996, 17(5-6): 490-519.
- [79] Du C., Teng J., Li T., et al. On uni-modal feature learning in supervised multi-modal learning[J]. arXiv preprint, 2023: 2305.01233.
- [80] Zhang Z., Zhao B., Xie A., et al. Activity Cliff Prediction: Dataset and Benchmark[J]. arXiv preprint, 2023: 2302.07541.