

学校代码：10730
分类号：

密级：

兰州大学
博士学位论文
(学术学位)

论文题目 (中文)	基于知识引导与数据驱动的分子性质与药物-靶标相互作用预测研究
论文题目 (外文)	Molecular property and drug-target interaction prediction based on knowledge-guided and data-driven
作者姓名	刘硕
学科专业	化学·药物化学生物学
研究方向	人工智能辅助药物发现
教育类型	学历教育
指导教师	刘焕香 教授
合作导师	
论文工作时段	2021 年 9 月至 2025 年 4 月
答辩日期	2025 年 5 月

校址：甘肃省兰州市城关区天水南路 222 号

基于知识引导与数据驱动的分子性质与药物-靶标相互作用预测研究

中文摘要

化合物的分子性质与药物-靶标相互作用预测是药物研发与计算化学领域的重要课题。传统实验方法受限于高成本与低通量，而经典计算方法在大规模分子数据处理中计算复杂度较高，难以满足实际应用需求。近年来，以深度学习为代表的驱动技术为分子信息建模提供了新的范式，有效提升了预测效率。然而，如何在深度学习框架下整合化学领域知识，并利用多模态融合策略提高模型的泛化能力和预测准确性，仍是亟待解决的关键问题。本研究基于“知识引导与数据驱动协同”的核心思想，提出三种创新性的方法：

（1）指纹增强分层图神经网络用于分子性质预测（FH-GNN）

FH-GNN 构建了融合原子级、基序级和分子级信息的分层分子图，并引入分子指纹编码模块，将化学领域的先验知识与从数据中获取的分子结构信息有效结合，同时采用自适应注意力机制动态融合分层分子图表示与指纹特征，生成具有任务自适应性的全面分子表征。该方法既弥补了传统图神经网络在捕捉分子功能信息上的不足，又通过多尺度建模提高了对分子细微结构差异的敏感性。在 MoleculeNet 基准测试的 8 个数据集上的实验结果表明，FH-GNN 在分子性质预测任务中显著优于基线模型，验证了在分子表征方面的卓越性能。同时，通过对模型注意力权重的可视化分析，揭示了分子关键功能基团与其物理化学性质之间的紧密关系，为药物分子的理性设计与优化提供了可解释性的理论支持。

（2）基于领域通用和领域特定特征的药物-靶标相互作用预测框架（E-DIS）

E-DIS 框架利用双分支特征提取架构，同时学习领域通用特征和领域特定特征。领域通用特征提取器在全量训练数据上学习普适性的分子表征，领域特定特征提取器在不同领域训练专家模型，从多种分布中捕获和对齐领域特定信息。该框架能够同时学习药物-靶标对的全局共性和局部特异性特征，突破对单一特征模式的依赖，增强了对新颖药物-靶标对的泛化能力。在多个基准数据集（包括 Davis、KIBA、BindingDB 和 BIOSNAP）上的结果表明，无论在领域内还是跨领域实验设置下，E-DIS 框架均能显著提升药物-靶标相互作用预测模型的性能，其泛化能力明显优于现有的领域自适应方法。此外，通过可视化分析

和消融实验，我们进一步揭示了 E-DIS 在特征学习和多样化特征捕捉方面的优势，为模型的有效性提供了有力的支持。

（3）基于多模态融合的药物-靶标结合亲和力预测模型（MF-Net）

MF-Net 采用多模态输入策略，融合药物-靶标复合物的序列特征、原子图特征和片段图特征，分别从全局背景、局部原子级和高层次功能域交互三个层次捕捉分子信息。通过数据驱动的权重分配机制和对比损失约束，MF-Net 能够自适应调整各模态特征的重要性，生成互补且稳健的分子表征。实验结果表明，MF-Net 在 PDBBind v2016 数据集上的药物-靶标结合亲和力预测任务中显著优于基线模型；在 DUD-E、DEKOIS2.0 及 LIT-PCBA 数据集上的虚拟筛选任务中，展现出卓越的早期筛选能力和鲁棒性。消融实验系统性地验证了多模态特征融合的必要性和可视化分析则深入揭示了不同模态特征对关键药物-靶标相互作用的贡献机制。这些结果验证了 MF-Net 在捕捉药物-靶标复杂交互关系和快速识别活性化合物方面的优势，同时也凸显了高效特征融合策略在提高药物-靶标相互作用预测精度中的关键作用。

综上所述，本研究在理论方法层面、技术实现方面以及应用价值方面均取得了系统性的创新成果。首先，通过融合分子指纹特征、领域特定知识和多模态数据，构建了知识引导与数据驱动协同增强的计算框架。该框架充分发挥了化学领域先验知识与数据分布规律的互补优势，显著提升了模型的表征能力和预测精度。其次，分层分子图建模方法实现了分子多尺度特征的有机融合；双分支架构有效解决了跨领域泛化问题；多模态融合策略攻克了异构数据协同建模的难题。这些创新技术共同推动了复杂分子系统表征方法的进步。最后，在应用价值方面取得了显著成效。本研究提出的 FH-GNN、E-DIS 和 MF-Net 三个核心模型，分别针对分子性质预测、药物-靶标相互作用预测的跨领域泛化和多模态建模等关键问题，不仅为相关研究提供了高效可靠的计算工具，更为智能药物研发体系的构建奠定了坚实的理论基础，展现出广阔的应用前景。

关键词：分子性质预测，药物-靶标相互作用预测，知识引导，数据驱动，多模态融合

MOLECULAR PROPERTY AND DRUG-TARGET INTERACTION PREDICTION BASED ON KNOWLEDGE-GUIDED AND DATA-DRIVEN

Abstract

Molecular property of compounds and drug-target interaction prediction are critical tasks in drug discovery and computational chemistry. Traditional experimental methods are limited by high costs and low throughput, while classical computational methods suffer from high computational complexity in processing large-scale molecular datasets, limiting their practical applicability. In recent years, data-driven techniques, particularly those based on deep learning, have provided a new paradigm for molecular information modeling and have significantly enhanced prediction efficiency. However, how to integrate chemical domain knowledge into deep learning frameworks and leverage multimodal fusion strategies to enhance model generalization and predictive accuracy remains key challenges. Based on the core concept of "knowledge-guided and data-driven synergy," this study proposes three innovative methods:

(1) Fingerprint-enhanced hierarchical molecular graph neural network for molecular property prediction (FH-GNN).

FH-GNN constructs a hierarchical molecular graph that integrates atomic-, motif-, and molecular-level information. It introduces a molecular fingerprint encoding module to effectively combine chemical domain prior knowledge with data-driven molecular structural information. Additionally, an adaptive attention mechanism is employed to dynamically fuse hierarchical molecular graph representations with fingerprint features, generating comprehensive molecular representations with task-adaptive capabilities. This method not only addresses the limitations of traditional graph neural networks in capturing molecular functional information, but also enhances sensitivity to subtle structural differences through multi-scale modeling. Experimental results on eight MoleculeNet benchmark datasets demonstrate that FH-GNN significantly outperforms baseline models in molecular property prediction tasks, validating its superior performance in molecular

representation. Additionally, visualization analysis of attention weights reveals the close relationship between key functional groups and the physicochemical properties, providing interpretable theoretical support for the rational drug design and optimization.

(2) Versatile framework for drug-target interaction prediction by considering domain-generic and domain-specific features (E-DIS).

The E-DIS framework utilizes a dual-branch feature extraction architecture to simultaneously learn domain-generic and domain-specific features. The domain-generic feature extractor captures universal molecular representations from the entire training data, while the domain-specific feature extractor trains expert models on different domains to capture and align domain-specific information from diverse distributions. This framework can simultaneously learn both the global common and local specific features of drug-target pairs, overcoming reliance on single feature patterns and enhancing generalization capability for novel drug-target pairs. Results on multiple benchmark datasets, including Davis, KIBA, BindingDB, and BIOSNAP, show that the E-DIS framework significantly improves the drug-target interaction prediction performance under both in-domain and cross-domain experimental settings, with generalization capabilities clearly outperforming existing domain adaptation methods. Furthermore, visualization analyses and ablation studies further reveal the advantages of E-DIS in feature learning and diverse feature capture, providing strong interpretative support for the model's effectiveness.

(3) Multimodal fusion network for drug-target binding affinity prediction (MF-Net).

MF-Net employs a multimodal input strategy, integrating sequence features, atomic graph features, and fragment graph features of drug - target complexes to capture molecular information at three levels: global context, local atomic-level interactions, and high-level functional domain interactions. MF-Net adaptively adjusts the importance of each modality through data-driven weight allocation mechanism and contrastive loss constraints, generating complementary and robust molecular representations. Experimental results show that MF-Net significantly outperforms baseline models in drug - target binding affinity prediction tasks on the PDBBind v2016 dataset and demonstrates excellent early screening performance and robustness in virtual screening tasks on the DUD-E, DEKOIS2.0, and LIT-PCBA datasets.

Ablation studies systematically validate the necessity of multimodal feature fusion, while visualization analyses further reveal the contribution mechanisms of different modality features to key drug-target interactions. These results confirm the advantages of MF-Net in capturing complex drug – target interaction and rapidly identifying active compounds, while highlighting the crucial role of efficient feature fusion strategies in enhancing prediction accuracy of drug-target interaction prediction.

In summary, this study achieves systematic innovations in theoretical methodology, technical implementation, and practical applications. Firstly, by integrating molecular fingerprint features, domain-specific knowledge, and multimodal data, we constructed a computational framework that synergistically combines knowledge-driven and data-driven approaches. This framework effectively leverages the complementary advantages of chemical domain prior knowledge and data distribution patterns, significantly enhancing the model's representation capability and prediction accuracy. Secondly, the modeling method of hierarchical molecular graph realizes the organic integration of molecular multiscale features, the dual-branch architecture effectively addresses the cross-domain generalization challenges, and the multimodal fusion strategy overcomes the difficulties of heterogeneous data collaborative modeling. These innovative techniques collectively advance molecular representation learning for complex molecular systems. Finally, in terms of practical applications, this study has demonstrated significant value. The three core models proposed—FH-GNN, E-DIS, and MF-Net—tackle key challenges in molecular property prediction, cross-domain generalization in drug-target interaction prediction, and multimodal modeling. These models not only provide efficient and reliable computational tools for related research but also lay a solid theoretical foundation for the development of intelligent drug discovery systems, showcasing broad application prospects.

Keywords: molecular property prediction, drug-target interaction prediction, knowledge-guided, data-driven, multimodal fusion

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 研究现状及挑战.....	3
1.2.1 深度学习在分子性质预测中的研究现状	3
1.2.2 深度学习在药物-靶标相互作用预测中的研究现状	5
1.2.3 存在的挑战和发展趋势.....	7
1.2.4 领域知识整合.....	8
1.2.5 多模态学习.....	9
1.3 主要研究内容.....	10
1.4 本文组织架构.....	11
第二章 相关理论基础	12
2.1 分子性质.....	12
2.2 药物-靶标相互作用	13
2.3 分子表示.....	13
2.4 分子片段.....	15
2.5 机器学习.....	16
2.6 深度学习.....	17
2.7 图神经网络.....	20
2.8 消息传递神经网络.....	22
第三章 指纹增强分层图神经网络用于分子性质预测	24
3.1 研究背景.....	24
3.2 算法运行设置.....	25
3.2.1 数据集.....	25
3.2.2 评价指标.....	26
3.2.3 基线模型.....	26
3.2.4 参数设置.....	27
3.3 方法描述.....	27
3.3.1 FH-GNN 框架概述.....	27
3.3.2 分层分子图表示模块.....	28
3.3.3 分子指纹编码模块.....	31
3.3.4 融合与预测模块.....	32
3.4 结果与讨论.....	33
3.4.1 性能测试结果及分析.....	33
3.4.2 消融实验结果及分析.....	34

3.4.3 可视化分析.....	36
3.4.4 案例及解释性分析.....	37
3.5 本章小结.....	39
第四章 基于领域通用和领域特定特征的药物-靶标相互作用预测...	40
4.1 研究背景.....	40
4.2 算法运行设置.....	41
4.2.1 数据集.....	41
4.2.2 评价指标.....	42
4.2.3 基线模型.....	42
4.2.4 参数设置.....	43
4.3 方法描述.....	44
4.3.1 E-DIS 框架概述	44
4.3.2 领域通用特征提取器.....	45
4.3.3 领域特定特征提取器.....	46
4.4 结果与讨论.....	46
4.4.1 领域内设置下性能测试结果及分析	47
4.4.2 跨领域设置下性能测试结果及分析	52
4.4.3 可视化分析.....	58
4.5 本章小结.....	59
第五章 基于多模态融合的药物-靶标结合亲和力预测.....	61
5.1 研究背景.....	61
5.2 算法运行设置.....	62
5.2.1 数据集.....	62
5.2.2 评价指标.....	62
5.2.3 基线模型.....	63
5.2.4 参数设置.....	64
5.3 方法描述.....	65
5.3.1 MF-Net 框架概述.....	65
5.3.2 多模态输入.....	66
5.3.3 序列特征提取模块.....	68
5.3.4 原子级特征提取模块.....	70
5.3.5 片段级特征提取模块.....	71
5.3.6 融合与预测模块.....	72
5.3.7 损失函数.....	73
5.4 结果与讨论.....	74
5.4.1 结合亲和力预测结果及分析.....	74
5.4.2 消融实验结果及分析.....	75
5.4.3 基于通用结构的虚拟筛选结果及分析	76

5.4.4 基于特定结构的虚拟筛选结果及分析	77
5.4.5 可视化分析	79
5.5 本章小结	80
第六章 结论与展望	81
6.1 本文总结	81
6.2 工作展望	82
参考文献	84
缩略词表	97

第一章 绪论

1.1 研究背景与意义

创新药物的研发是一个复杂而系统的科学工程，涵盖了从分子发现到临床转化的全过程。如图 1-1 所示，该过程主要包含药物发现、临床前研究、临床研究和新药审批上市等关键阶段，通常需要 12-15 年的研发周期和约 18 亿美元的资金投入^[1-4]。在药物发现的初始阶段，研究人员通常基于疾病的病理机制和靶点验证研究确定治疗靶标，继而通过高通量筛选或虚拟筛选获取具有初步活性的苗头化合物。接着，结合结构-活性关系研究对其进行优化，筛选出具有良好活性和成药潜力的先导化合物。最终，基于药效、安全性及药代动力学等关键指标进行综合评估，遴选出可进入临床前研究的候选药物^[5, 6]。据统计，约百万量级的化合物经过层层筛选，最终仅有极少数能够进入后期临床阶段并获得上市许可^[7]，这一严苛的筛选过程主要受限于化合物的安全性、有效性及药代动力学特性等关键因素^[8]。




图 1-1 药物研发流程图

分子性质预测与药物-靶标相互作用预测贯穿于药物研发的各个阶段，在化合物筛选、先导优化和作用机制研究等多个环节发挥着关键作用，能够大幅提升新药发现的效率和成功率^[9-15]。分子性质预测主要针对化合物的物理化学性质、生物活性以及毒性等指标进行定量估计。在药物筛选初期，通过预测化合物的分子属性，可以从庞大的化合物库中快速剔除不符合要求的分子，缩小候选范围，并在先导化合物优化过程中指导结构修改，提升药物的药代动力学性质和安全性。在临床前研究阶段，通过预测化合物的毒性和代谢产物，有助于提前发现潜在的不良反应，从而降低后期临床试验的风险。药物-靶标相互作用预测旨在定量或定性地描述化合物与生物靶标之间的结合行为。基于药物-靶标相互作用预测技术，可以实现对大规模化合物库的高通量虚拟筛选，快速识别

与目标蛋白具有较高结合亲和力的候选分子。该方法尤其适用于药物重定位研究，能够从已获批的药物中发现具有新靶点活性的潜在治疗分子。通过预测和分析药物与靶标之间的相互作用模式，可以揭示药物的作用机制，为优化药物结构和提高选择性提供理论依据。在实验验证前，药物-靶标相互作用预测研究有助于合理安排实验策略，减少盲目试错，提高实验的成功率和效率。分子性质预测与药物-靶标相互作用预测研究不仅能够在早期发现具有高活性和良好安全性的新药候选分子，而且在后期的临床前研究中也能为药物优化和风险评估提供有力支持，从而加速整个药物研发流程，提高新药上市的成功率。

实验方法作为分子性质与药物-靶标相互作用研究的传统手段，具有预测精度高、数据可靠性强的显著优势，能够通过规范的实验操作获得准确的定量结果^[16]。然而，这类方法在实际应用中存在明显的局限性：首先，实施成本较高，需要依赖先进的仪器设备和昂贵的实验耗材；其次，操作流程复杂且耗时，从样品制备到数据分析往往需要数周甚至数月时间；最后，对实验环境要求严格，需要专业的技术人员进行操作和维护。这些因素导致实验方法难以满足大规模、高通量的药物筛选需求^[10]。相比之下，理论计算方法（如量子力学计算和分子动力学模拟）在揭示分子微观机制方面展现出独特的优势^[9, 17]。这类方法能够从原子层面解析分子的电子结构特征和构象动力学行为，为理解分子性质与药物-靶标相互作用的内在机制提供理论依据。然而，理论计算方法同样面临挑战：高精度的量子力学计算需要消耗大量的计算资源，而分子动力学模拟的时间尺度限制使其难以处理复杂的生物大分子体系。这些技术瓶颈限制了传统计算方法在分子性质预测与药物-靶标相互作用研究中的应用。

近年来，随着计算能力的提升与高质量数据的积累，数据驱动的深度学习技术凭借其复杂特征的自适应建模能力，逐渐成为分子性质预测与药物-靶标相互作用预测领域的研究热点^[18-20]。传统实验方法和理论计算方法在应对庞大的分子数据库时往往效率低下，而深度学习技术则能够在极短的时间内高效处理海量的分子数据。凭借其卓越的特征提取与建模能力，深度学习在分子表征^[21, 22]、分子性质预测^[23-26]、分子性质优化^[27]以及药物-靶标相互作用预测^[28-32]等任务中均取得了显著成果。通过构建分子结构与功能特性之间的非线性映射关系，深度学习技术正推动药物研发由传统的经验驱动模式向数据驱动模式转变，为药物研发过程提供了全新的技术支持和决策依据。

1.2 研究现状及挑战

1.2.1 深度学习在分子性质预测中的研究现状

深度学习在分子性质预测中的应用已经取得了显著进展，尤其是在提高预测精度和计算效率方面。传统的分子性质预测方法通常依赖于手工特征提取，处理速度慢且难以捕获分子复杂的结构信息。相比之下，深度学习通过自动学习特征，能够从原始数据中提取出潜在的规律，从而为分子性质预测提供新的方法论和技术路径。通过使用循环神经网络（Recurrent Neural Network, RNN）、卷积神经网络（Convolutional Neural Network, CNN）、图神经网络（Graph Neural Network, GNN）和 Transformer 等不同类型的网络架构，深度学习能够从序列数据、分子图或三维结构中提取有价值的特征，实现对分子理化性质、溶解度、毒性、反应性等多种属性的高效预测。

RNN 擅长处理顺序数据，具有独特的内部记忆功能，常见的 RNN 方法有长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环单元（Gated Recurrent Unit, GRU）。基于 RNN 的深度学习模型在分子性质预测中被广泛应用，特别是在处理一维分子数据时，展现出了良好的性能。Lin 等人^[33]首次将简化分子线性输入系统（Simplified Molecular Input Line Entry System, SMILES）表示转化为样本向量，并通过双向 GRU 进行处理，从而预测分子性质。Wu 等人^[34]采用 LSTM 注意网络，结合多步注意力机制，突出关键序列特征以提高预测性能。Nazarova 等人^[35]同时使用二进制和十进制的 SMILES 表示方法识别化合物结构与介电常数的相关性。Wang 等人^[36]通过 LSTM 网络自动生成分子结构的标签，有效表征分子结构信息和连通性。这些研究展示了基于 RNN 模型在从序列中提取语义信息方面的有效性。然而，RNN 模型在处理长序列时仍面临挑战，特别是对相邻原子的关注可能会阻碍远距离原子间相互作用的捕捉，影响对广泛结构关系的建模能力。

CNN 因其处理网格数据和捕捉局部模式的能力在分子性质预测中得到了广泛应用。基于 CNN 的模型通过不同维度的分子表示（包括一维序列、二维图像以及三维结构）展现了在分子性质预测中的优势。在一维序列处理方面，Hirohara 等人^[37]创新性地将 CNN 应用于 SMILES 数据，实现了对一维分子数据局部模式的有效捕捉。同时，Chen 和 Tseng^[38]指出，SMILES 分子枚举方法能够显著影响 CNN 在溶解度预测等任务中的性能。随着深度学习方法在图像处理领域的成功应用，部分研究开始尝试使用 CNN 提取二维分子图像中的特征。但由于分子图像大小固定而不同分子的尺寸存在差异，Zhang 等人提出了 ABC-Net，通过 CNN 生成热图并将原子和化学键表示为点来预测分子图结构；而

Jiang 等人^[39]则构建了等尺寸的分子持久光谱图像, 并利用 CNN 进行编码以提取有效的分子表征。三维分子网格作为分子结构的直观表示手段, 可用于捕捉分子的三维信息。然而, 由于数据过于稀疏, 直接使用分子在三维网格中的离散化表示会导致 CNN 难以有效提取特征, 从而降低模型性能。为此, Kuzminykh 等人^[40]通过将原子扩展到附近的网格, 并基于波变换进行变换, 从而改进了 CNN 在三维分子网格中的应用; Liu 等人^[41]利用以原子为中心的高斯密度模型, 为不同原子类型设定多通道空间分辨率, 改善了分子的三维表示; 此外, Sunseri 和 Koes^[42]则推动了基于网格的三维分子表示的应用, 生成了与深度学习框架兼容的体系化分子数据, 为分子预测任务提供了更为丰富的三维特征。基于 CNN 的模型在分子性质预测中通过高效提取一维序列、二维图像以及三维结构信息, 成功应用于多种分子特征提取任务, 推动了药物研发和分子性质预测领域的发展。

分子可以直观地表示为图, 其中原子作为节点、化学键作为边缘, 这使得 GNN 成为提取分子特征的理想工具。GNN 能够有效地处理分子图结构, 通过节点和边缘的消息传递, 捕获分子内原子和化学键之间的相互作用。AttentiveFP^[43]通过在不同距离上传播节点信息, 有效表征原子的局部环境, 并通过图注意力机制结合局部和非局部的分子效应, 增强了分子结构的表征。与此类似, Withnall 等人^[44]在现有的消息传递神经网络框架中引入了注意力和边缘记忆方案, 进一步提升了信息提取的效率。此外, Li 等人^[45]提出的三重消息传递机制通过原子-键-原子信息的聚合, 优化了神经网络的隐藏状态, 显著改善了模型对复杂分子结构的处理能力。Zhang 等人^[46]提出的 CoAtGIN 算法通过 k-hop 卷积捕获远程邻居信息, 并采用线性关注来聚合全局图表示, 进一步提升了 GNN 模型在分子性质预测中的表现。为了克服传统 GNN 模型中对单一结构信息的依赖, Song 等人^[47]提出了通信消息传递神经网络, 通过强化节点和边缘之间的消息交互, 改善了分子嵌入的表现。在分子三维结构的处理上, 近年来也有显著的进展。Fuchs 等人^[48]通过引入等变约束, 增强了自我注意力机制对几何信息的处理能力。而 Schutt 等人^[49]则提出了旋转等变的消息传递机制, 通过极化原子相互作用神经网络架构, 使得模型能够有效地处理分子中旋转不变性的问题。总的来说, 基于 GNN 的模型通过不断创新消息传递机制和引入更多的几何与物理信息, 为分子性质预测的研究提供了新的思路和方法, 显著提高了模型的预测精度和解释性。

基于 Transformer 的模型在分子性质预测中的应用也取得了显著的进展。Transformer 架构以其强大的自注意力机制而闻名, 能够有效处理序列数据中的

远程依赖关系，提升了分子数据的处理效率和准确性，尤其是在分子 SMILES 序列和分子图的处理上。Wang 等人^[50]将 Transformer 应用于分子 SMILES 序列的处理，利用其自注意力机制提取分子信息，显著提高了模型对分子上下文关系的理解能力。Wang 等人^[51]进一步提出了结构指纹标记化和规范化图表示两项创新进展，推动了分子数据表示的有效性和复杂模型结构的优化。为了解决 SMILES 表征中的有效性和鲁棒性挑战，Yüksel 等人^[52]采用 SELFIES 分子表征方式学习高质量分子特征，进一步提高了分子数据分析的可靠性。Su 等人^[53]则探索了 SMILES 中绝对位置与相对位置嵌入的差异，并提出 RoFormer 模型，通过有效的线性注意力机制专注于相对位置嵌入，增强了模型对分子序列的处理能力。在分子图表示的研究中，Transformer 的应用同样展现了巨大的潜力。Rong 等人^[54]将消息传递网络与 Transformer 架构结合，从图的节点中提取向量作为查询、键和值，并通过注意力机制融合局部与全局信息，从而提升了分子图的表示能力。Park 等人^[55]引入了图的相对位置编码，解决了线性化问题，有效地编码了图的节点和边缘的交互。Hussain 等人^[56]开发了边缘增强图 Transformer，通过全局自注意力机制及边缘通道捕捉进化结构信息，实现对边缘的直接预测。Yin 和 Zhong^[57]提出了一种交替使用 GNN 和 Transformer 层的方法，这种方法能够有效混合局部和全局信息，进一步丰富了 Transformer 的表示能力。

1.2.2 深度学习在药物-靶标相互作用预测中的研究现状

基于深度学习的药物-靶标相互作用预测方法显著提升了对药物和靶标序列及结构中高级隐藏特征的自动提取能力，从而获得了广泛的应用。基于输入类型可以将深度学习方法分为两大类：基于序列的方法以及基于结构的方法。基于序列的方法处理药物和靶标蛋白质的序列输入，基于结构的方法则将输入表示为图形结构。

基于序列的深度学习方法主要利用药物的 SMILES 字符串和蛋白质的氨基酸序列作为输入，尽管这类方法忽略了分子的拓扑结构信息，但在计算速度上具有显著优势。基于序列的深度学习方法在药物-靶标相互作用预测中不断演进，从最初的 CNN 模型到后来的高阶特征融合、自监督学习和 Transformer 模型。DeepDTA^[58]是最早采用序列输入的深度学习模型之一，它使用两个独立的 CNN 模块分别从蛋白质序列和药物 SMILES 中提取特征，并将二者融合后进行亲和力预测。WideDTA^[59]通过引入药物常见的子结构和蛋白质的保守结构域，在序列表示的基础上进一步构建高阶特征，提升了模型对分子细微结构信息的捕捉能力。为了解决标注数据稀缺和数据不平衡问题，DeepAffinity^[60]和 Co-VAE^[61]

等模型采用了自监督学习和变分自编码器的策略，从无标签数据中学习药物和蛋白质的通用表示，并通过对抗或共正则化机制将这些表示与结合亲和力进行关联。随着 Transformer 架构在自然语言处理中的成功，MT-DTI^[62]、MRBDTA^[63]、DTITR^[64]以及 ELECTRA-DTA^[65]等模型开始引用自注意力机制，通过多头注意力和交叉注意力机制来捕捉序列中长程依赖和局部关键特征，从而提升了预测准确性。基于序列的方法由于易于获取而具有明显优势。这些方法不仅能高效处理序列数据，且对计算资源的要求较低，在利用高级序列特征进行药物-靶标相互作用预测方面表现出良好性能。然而，它们忽略了与靶点和药物相关的其他多模态信息，例如拓扑图和三维结构，而这些结构信息往往包含着对药物-靶标相互作用预测至关重要的特征。

近年来，基于结构的深度学习方法在药物-靶标相互作用预测中取得了显著进展，主要依赖 GNN、三维卷积神经网络（Three-Dimensional Convolutional Neural Network, 3D-CNN）和 Transformer 等技术，从药物分子图、蛋白质结构或药物-靶标复合物的三维数据中提取关键特征。这些方法可大致分为三类：基于分子图和蛋白质接触图的 GNN 方法、基于三维复合物结构的 CNN 方法以及结合 Transformer 与预训练语言模型的方法。大多数模型将药物表示为分子图，蛋白质表示为接触图，并利用 GNN 及其变体自动学习结构特征。DGraphDTA^[66]通过蛋白质结构预测方法生成接触图，结合 GNN 挖掘药物和靶标的结构信息。WGNN-DTA^[67]利用 ESM 模型^[68]构建加权蛋白质图，增强结构表征能力。HiSIF-DTA^[69]不仅使用接触图，还整合蛋白质-蛋白质相互作用网络，引入高阶功能语义。基于三维复合物结构的 CNN 方法则直接将药物-靶标复合物的三维结构转换为体素网格，利用 3D-CNN 提取空间特征。AK-Score^[70]采用多通道 3D-CNN 独立训练，增强结合亲和力预测的鲁棒性。Sfcnn^[71]将复合物转换为三维网格，通过 CNN 学习几何特征。这类方法能直观建模结合位点的空间布局，但对计算资源要求较高，且依赖准确的三维复合物结构数据。近期研究探索了 Transformer 架构在药物-靶标相互作用预测任务中的应用。基于 Transformer 的预测方法通过独特的自注意力机制，能够有效捕捉药物分子与靶标蛋白之间的长程依赖关系。GTAMP-DTA^[72]和 AttentionMGT-DTA^[73]采用图 Transformer 分别学习药物分子图和蛋白质口袋图的结构信息，再通过交叉注意力机制捕捉药物-靶标间的非共价相互作用。STAMP-DPI^[74]结合 BERT 预训练策略获得蛋白质嵌入，利用 Transformer 解码器预测药物-靶标相互作用。HGTDP-DTA^[75]引入动态提示机制，利用 Transformer 为不同药物-靶标对生成定制化特征。这些基于结构的方法能够更好地利用药物和靶标的结构信息，提高药物-靶

标相互作用预测的性能，同时也具有较强的可解释性，帮助深入理解药物-靶标相互作用机制。

1.2.3 存在的挑战和发展趋势

尽管深度学习在分子性质预测和药物-靶标相互作用预测领域已取得显著成果，但其依赖于从数据中自动提取特征，可能会忽略分子中固有的物理化学特性。同时，当前常用的深度学习方法大多依赖单一模态，难以全面捕捉分子复杂的结构信息，容易遗漏关键的化学、物理或生物学特征，导致信息表示不够充分，进而使模型对数据集和超参数设置高度敏感。此外，深度学习模型通常需要大量高质量的训练数据，而标注数据的获取成本高昂且资源有限。更重要的是，由于数据集和任务之间存在较大的差异，深度学习模型在面对新的、未知的药物或靶标时，往往表现出较差的泛化能力，导致预测效果不理想。




图 1-2 分子领域知识示意图

近几年，在分子性质与药物-靶标相互作用预测领域，深度学习技术的发展呈现出两大核心演进方向：其一是领域知识的整合，其二是多模态融合策略的创新设计^[76]。通过将领域知识与多模态数据整合到深度学习模型中，不仅克服了传统单模态方法在表征能力上的局限，而且显著提升了模型对分子复杂结构的捕捉能力和泛化性能，从而有效推动了分子性质预测与药物-靶标相互作用预测在实际药物研发中的应用。图 1-2 展示了分子的领域知识，包括分子性质、

分子信息以及分子片段。分子性质之间的内在关系可以用来提升相应预测任务的性能。例如，偶极矩和各向同性极化率等极性参数直接影响分子间的相互作用，进而决定了分子的溶解度和亲脂性^[77, 78]。同时，将分子信息（如原子坐标、键角和距离矩阵）整合到分子图中，有助于改进模型框架^[79, 80]。此外，分子片段与分子特定功能和生物活性密切相关，化学家倾向于从具有明确化学功能的分子片段（如官能团、药效团等）的角度，阐释分子结构与其理化性质/生物活性之间的关系。化学、物理、生物学等领域的专家知识，能够为模型提供先验信息，弥补纯数据驱动方法对分子中的物理化学特性的忽视。整合领域知识能够帮助模型更好地理解数据内在规律，在数据稀缺的情况下，通过规则、经验和已有的理论来指导模型的学习过程，从而提高模型的鲁棒性和泛化能力。这种知识的引导能够帮助模型从更专业的角度进行特征学习，提高预测的准确性。

针对单一数据模态难以全面捕捉分子复杂结构信息的问题，近年来研究者们开发了结合分子表示学习、多任务学习和集成方法的新策略^[81-84]，以增强模型的表达能力。多模态学习作为一个充满活力的多学科领域，提供了一种整合不同来源数据的通用框架^[85, 86]，通过从序列、图结构和分子指纹或描述符等不同模态中提取关键信息，打破了单一模态的局限性，从而推动了分子性质预测与药物-靶标相互作用研究的深入发展。这种跨模态的学习方式能够从不同的角度对同一问题进行建模，从而提供更全面的分子表征，增强模型的鲁棒性。多模态学习通过引入多种数据源，扩充了有效特征空间，能够有效地减少单一模态可能存在的信息缺失或噪声问题，使得模型在面对复杂任务时更具稳定性和泛化能力。

1.2.4 领域知识整合

在分子性质与药物-靶标相互作用预测领域，领域知识的系统性整合已成为提升模型性能与可解释性的重要策略。利用分子性质之间的内在关系，可以提高相应预测任务的性能。例如，Sun 等人^[87]和 Yang 等人^[88] 利用易于获得的物理性质，显著改善了对化学和生理性质的预测性能。DGraphDTA 模型^[66]通过引入基于 R 基团的附加属性（如极性、分子量、带电性和芳香性等），实现了蛋白质表征方式的拓展。同时，越来越多的研究开始利用分子信息，比如原子和化学键的属性，Zhou 等人^[89]将原子距离矩阵作为位置编码引入 GNN，有效保留了分子的三维空间信息。Liu 等人^[11]突破了传统单跳邻域交互的限制，在分子图中同时编码原子间距、键角与二面角等几何参数。Gao 等人^[90]构建了一个由 GNN 和 Transformer 组成的嵌入单元，平衡原子的邻近和远程相互作用，并更加关注共轭体系、不饱和键、杂原子和分子拓扑结构。

上述方法本质上将预测归因于单个节点、边或节点特征，然而化学家通常习惯于从具有化学意义的分子片段的角度，理解分子结构与性质之间的因果关系。为此，Zang 等人^[91]通过逆转录合成有趣化学子结构（Breaking of Retrosynthetically Interesting Chemical Substructures, BRICS）和附加分解方法对分子图进行分解，构建了基序级图，并设计了自监督学习的基序生成框架，加强模型的表达能力。为了进一步挖掘高阶片段信息，Gao 等人^[92]提出了片段相互作用注意力机制，在聚合邻域信息时同步考虑片段间的协同效应。Wu 等人^[93]则构建原子-基序双层次异构图，利用注意力机制区分不同层级节点的相互作用模式。Jiang 等人^[94]提出多视图分子表示图，通过药效团特征约束功能片段的嵌入空间，充分利用分子片段和药效团特征。

尽管将领域知识整合到分子性质和药物-靶标相互作用预测模型中具有显著优势，但这一过程仍然面临许多挑战。如何构建高效的知识表征机制，将其与数据驱动的深度学习方法有机结合，实现化学领域知识与特征学习之间的动态平衡，仍然是该领域亟待解决的关键技术难题。同时，在此过程中保持模型的灵活性、可扩展性和客观性也是至关重要的。

1.2.5 多模态学习

多模态学习凭借整合异构数据的优势，在分子性质预测和药物-靶标相互作用预测领域展现出独特的应用前景。该方法通过融合分子在不同模态下的表示，构建更全面的分子表征体系，显著提升了模型对分子性质和药物-靶标相互作用预测的能力。当前，多模态学习的技术实现路径主要包括二维信息融合、三维信息整合以及跨模态联合学习等策略。

在二维信息融合方面，Cai 等人^[95]与 Wang 等人^[96]构建了分子图与化学指纹的联合学习框架，通过 GNN 捕获全局拓扑特征，同时利用指纹编码提取官能团等局部化学信息，实现了对分子领域知识与结构特征的协同表征。此外，部分研究者构建了分子图与序列的联合学习模型，比如 MolFM^[97]、GraSeq^[98]和 GIT-Mol^[99]均使用不同的编码器处理 SMILES 字符串与分子图信息，而 Wang 等人^[100]则构建了联合嵌入空间，在保留模态特异性的同时，保持了语义的一致性。同时，也有工作通过融合分子描述符的信息来增强表征能力，Tang 等人^[101]提出的多源编码框架整合了分子描述符、分子指纹、分子图及 SMILES 文本等多维特征，MolMap^[102]则创新性地将分子描述符和分子指纹映射为二维特征矩阵，从而保留了化学特征的拓扑关联性。在三维结构整合方面，Chen 等人^[103]提出代数图辅助双向 Transformer 框架，通过融合 SMILES 序列与代数图表示，实现了立体化学信息的有效建模。Xu 等人^[104]融合了来自蛋白质表面、三维结构和

序列的信息，并使用交叉注意机制在不同模态之间进行特征对齐。在跨模态联合学习方面，Liu 等人^[105]采用知识增强建模方法，创新性地将分子结构与化学文本知识联合嵌入，增强了模型对分子功能的解释能力。同时，Zhang 等人^[106]首次引入分子质谱作为独立模态，其碎片离子信息为分子图提供了互补的化学键断裂特征。这些技术路径共同推动了多模态学习在分子性质和药物-靶标相互作用预测中的应用，为计算药物发现提供了更全面、更精准的信息支撑。

多模态学习方法在分子性质与药物-靶标相互作用预测任务中展现出显著优势，但其应用仍面临诸多挑战与限制。这些挑战主要源于不同模态在数据结构、表达方式及特征分布上的固有差异，直接融合时会导致表征冲突。然而，当前研究多聚焦于浅层特征拼接或静态权重分配策略，未能构建系统化的跨模态整合框架，并且忽略了化学领域知识与多模态特征的协同作用。只有通过精心设计的融合方法，才能最大程度地提高模型的预测准确性、泛化性和实用性。因此，如何设计知识增强的多模态融合策略，成为了当前亟待解决的另一个核心问题。

1.3 主要研究内容

本研究致力于融合领域知识体系与多模态数据表征，构建知识引导与数据驱动协同增强的新型计算框架，通过融合化学家在分子设计中的“因果推理”能力以及深度学习的“关联挖掘”能力，提升模型在分子性质预测和药物-靶标相互作用预测领域的表现。本研究提出了三种创新性的方法：指纹增强的分层图神经网络（Fingerprint-Enhanced Hierarchical Graph Neural Network, FH-GNN）、融合领域通用特征提取器与领域特定特征提取器的框架（Ensembles of Domain-Generic Feature Extractors and Domain-Specific Feature Extractors, E-DIS）以及多模态融合网络（Multimodal Fusion Network, MF-Net）。FH-GNN 通过构建原子、基序和分子三级分层分子图，建立各层次之间的关联，实现了对分子结构的多尺度建模，同时，引入自适应注意力机制，动态融合分层分子图和分子指纹信息，生成更具判别性的分子表示。E-DIS 利用双分支架构同步提取领域通用特征与领域特定特征，通过门控网络实现特征动态加权，构建了一个灵活、可扩展的框架，提升了模型的泛化能力。MF-Net 则通过融合药物-靶标复合物的序列特征、原子图特征和片段图特征，全面捕捉分子全局背景、局部原子级信息和高层次功能域交互的细节。通过数据驱动的权重分配机制和对比损失机制协调各模态的贡献度，提升了特征表示的鲁棒性和判别能力。本研究在知识嵌入、特征融合和架构创新方面实现了系统性突破，显著提升了知识引导

与数据驱动的协同效应，为分子性质预测和药物-靶标相互作用研究提供了更精确、更可靠的计算工具。

1.4 本文组织架构

第一章为绪论。本章系统阐述了分子性质预测与药物-靶标相互作用预测领域的研究背景及其科学意义，详细综述了深度学习在这两个领域中的应用现状，并深入分析了现有方法所面临的挑战以及可能的改进方案。最后，概述了本研究针对这些挑战提出的创新性解决策略。

第二章介绍了本研究相关的理论基础。首先阐述了对分子性质以及药物-靶标相互作用的理解。然后系统梳理了分子表示方法与分子片段类型。最后介绍了机器学习和深度学习的基本概念，并详细介绍了图神经网络和消息传递神经网络的理论基础，为后续章节的内容理解提供支撑。

第三章介绍了针对现有分子性质预测方法在多尺度特征提取与领域知识融合方面的不足，提出的指纹增强分层图神经网络。详细介绍了模型的实验设置、方法描述以及在各个数据集的实验结果与讨论。

第四章介绍了基于领域通用和领域特定特征的药物-靶标相互作用预测研究。本章指出了现有方法在泛化能力方面的不足，接着详细介绍了特征融合框架的实验设置、方法描述以及在领域内和跨领域设置下的实验结果与讨论。

第五章介绍了基于多模态融合的药物-靶标结合亲和力预测研究。本章首先阐述了现有方法在挖掘药物-靶标复合物跨模态交互信息方面的局限性，然后详细介绍了多模态融合网络的实验设置、方法描述以及在亲和力预测和虚拟筛选任务中的实验结果与讨论。

第六章对全文内容进行了系统性的总结，并对未来分子性质预测和药物-靶标相互作用预测领域的发展方向进行了展望。

第二章 相关理论基础

2.1 分子性质

分子性质预测研究作为药物发现与设计领域的核心科学问题之一，不仅揭示了分子的内在结构和组成，还决定了分子在特定环境下的动态行为模式及其相互作用机制。对分子性质的研究跨越了从原子级电子结构到生物体整体效应的多个尺度，为理解分子功能和优化药物性能奠定了坚实基础。在药物研发过程中，准确预测和深入理解分子性质是构建高效药物的前提，这需要融合量子力学、物理化学、药物化学和生理学等多个学科的综合视角。

从量子力学的角度看，分子电子结构特征（如前线轨道能级、电子云分布等）是解析化学反应机理的关键理论依据。例如，电离势的高低直接影响分子参与电子转移反应的能力，进而决定其化学反应活性与代谢稳定性。这些电子特性为理解分子反应机制提供了理论基础，是药物设计中优化分子稳定性和反应活性的重要依据。

物理化学性质描述了分子在物理过程和化学反应中的基本行为特征。物理性质包括溶解度、极性、热稳定性等，这些性质影响分子的状态、混溶性和物理加工过程，直接影响药物的制备、储存和使用过程。例如，溶解度决定药物在生物介质中的分散状态，直接影响其吸收与生物利用度，水溶性差的药物通常需要剂型优化以改善其生物利用度。化学性质指分子在化学反应中的表现，如酸碱性、氧化还原能力、反应活性、稳定性等。这些性质决定了分子如何与其他化合物发生化学反应，是设计合成路线和新材料的重要依据。

药物化学性质关注的是分子在体内的行为模式及其与生物系统的相互作用，主要包括生物利用度、代谢途径、靶向性和毒性等。生物利用度反映了药物被吸收并进入体循环的比例，是评估药物疗效的重要参数；代谢途径描述了药物在体内的转化过程，影响其半衰期和毒性；靶向性决定了药物与特定靶标的结合能力，是药物效力和选择性的关键；毒性评估了药物对器官或细胞的潜在损害，是临床前研究的重要环节。通过在机体水平上评估药物化学性质，可以优化药代动力学参数，指导药物发现、毒理学评估和生物材料设计，从而提高药物的疗效和安全性。

2.2 药物-靶标相互作用

药物-靶标相互作用的特异性与结合亲和力共同决定了药物的效力、选择性以及最终的临床疗效。药物-靶标相互作用描述了药物分子与生物系统中特定蛋白质或受体之间的结合关系，涵盖了分子之间因静电作用、氢键、范德华力以及局部化学反应等非共价作用而形成的各种结合模式。这种相互作用不仅决定了分子在物理化学层面的性质，还为细胞内分子识别、分子通讯及信号传递提供了基本机制。在药物设计中，小分子配体通常与蛋白质上特定的结合位点发生高度特异的非共价相互作用，从而实现对靶标蛋白质功能的精细调控。相互作用的强度、空间匹配程度、电荷分布、疏水性以及氢键的形成能力等因素共同影响着配体与靶标蛋白质结合的亲和性和选择性。其中，药物分子与靶标蛋白结合位点的空间互补性，决定了结合的可能性；药物分子与靶标蛋白之间的电荷分布、氢键形成能力以及疏水性匹配，影响结合的稳定性。药物-靶标间的相互作用并非静态，而是通过构象变化实现动态适配。深入理解这一过程对于揭示药物作用机理、指导药物结构优化以及减少副作用具有重要的理论和实践意义。

药物-靶标结合亲和力则定量描述了药物分子与其靶标蛋白结合的紧密程度，通常通过实验测定的解离常数 (K_d)、抑制常数 (K_i) 或半数最大抑制浓度 (IC_{50}) 来衡量。这些参数反映了药物分子与靶标蛋白之间相互作用的稳固性和强度，是评估药物效力的重要指标。为便于数据处理和模型训练，常对这些实验值进行对数转换，从而使数据分布更加平滑。一般来说，较高的结合亲和力意味着药物分子能够更稳定、有效地与靶标结合，从而发挥理想的生物学效应。药物-靶标亲和力的精确预测是计算机辅助药物设计的核心环节之一，它不仅有助于筛选出高效候选药物，也为进一步指导分子的结构设计，提高药效和安全性提供了有力支持。

2.3 分子表示

分子表示是计算化学与计算机辅助药物设计领域的核心基础，其本质在于将分子的化学结构信息转化为计算机可以处理的数字化表征。由于分子结构蕴含着决定分子性质和药物-靶标相互作用的丰富信息，这一转化过程对于分子性质预测、虚拟筛选以及药物设计等任务具有关键影响。主流的分子表示方法主要分为三大类：分子指纹/描述符、序列表示和图表示。每种方法在信息表征的维度和计算效率上都有其独特优势，需根据具体任务需求选择或设计最合适的表示策略，从而为后续模型预测和分析提供坚实的数据基础。

分子指纹是一种将分子的结构信息编码为二进制字符串的表示方法,通过预先设定的规则判断分子中是否存在特定的结构或化学特征^[107]。根据编码策略的不同,分子指纹主要可分为子结构指纹、拓扑或路径指纹、圆形指纹以及药效团指纹^[108]。其中,子结构指纹基于预定义化学子结构库,将分子表征为二进制向量,每个位置对应特定子结构(如羟基、羧基、苯环等)的存在状态,如MACCS 指纹包含 166 种子结构^[109]。拓扑或路径指纹通过枚举分子中所有原子路径,记录不同路径类型的出现频次,典型代表如 Daylight 指纹。圆形指纹通常以某一原子为中心,在给定的半径内捕捉局部结构信息,从而生成描述该原子及其邻域特征的编码,如拓展连通性指纹(Extended-Connectivity Fingerprint, ECFP)^[110]。药效团指纹则着眼于分子中与生物活性相关的功能基团或立体结构特征,这类指纹不仅考虑了原子及其连接方式,更强调了分子中能够与生物靶点发生相互作用的关键药效团信息。通过对药效团的空间位置、几何排列和化学性质进行编码,药效团指纹能够为药物设计和活性预测提供更具生物学意义的描述。分子描述符是一种将分子化学结构转化为定量数值的表征方法,旨在用数学形式描述分子的各种物理化学特性和结构信息。通过构建描述符,可以将分子的复杂结构抽象为一组数值数据,从而便于计算机进行进一步的数据处理、建模和预测分析。常见的分子描述符包括原子数目、分子量、极性表面积、拓扑指数、几何形状参数以及电子性质等。这些描述符不仅能够反映分子的整体性质,还可以捕捉分子局部结构中的关键信息,如官能团、环结构等。

序列表示因其编码效率高、存储成本低的特点,已成为计算机辅助药物设计中应用最广泛的分子表示方法之一。其中,SMILES 与国际化学标识符(International Chemical Identifier, InChI)作为两大主流技术体系,分别从不同的角度实现了分子结构的标准化编码。SMILES 是最常见的序列表示方法,通过特定语法规则将分子结构转化为紧凑的字符串序列^[111]。针对 SMILES 对立体化学信息的表征能力有限和语法有效性难以保障的缺陷,研究者开发了多个改进版本:规范 SMILES、异构体 SMILES 以及自引用嵌入字符串(Self-Referencing Embedded Strings, SELFIES)等。规范 SMILES 通过标准化原子遍历顺序消除冗余编码,确保每个分子对应唯一的字符串表征^[112]。异构体 SMILES 引入立体化学描述符增强手性中心的表达能力^[113]。SELFIES 采用自引用语法规则,构建 100%有效的健壮性编码系统^[114]。InChI 是由国际纯粹与应用化学联合会主导开发的一种化学标识符,旨在为分子结构提供一种标准化和唯一的数字表示方法^[115]。与 SMILES 不同,InChI 采用层次化结构对分子信息进行编码,便于分子数据库间的检索和信息交换,在科学文献和数据共享中得到

了广泛应用。

图表示法作为分子表征领域的重要突破, 通过将分子的化学结构直接转化为图结构, 实现了对分子拓扑信息的完整编码。其核心范式是将原子映射为图节点, 化学键转化为图边, 从而构建分子结构的数学表征。图表示通过二维邻接矩阵或边列表精确描述原子间的连接关系。其中, 节点特征向量通常包含原子类型、电荷分布、杂化状态、电子构型、芳香性等; 边特征向量通常包含化学键类型、共轭特征、键长等。通过引入三维空间坐标(如笛卡尔坐标或内坐标), 可进一步扩展为三维分子图表示, 显著提升对分子构象的表征能力。图表示作为一种经典且直观的分子表示方法, 能够充分保留分子结构的完整信息, 并通过深度学习技术有效挖掘分子内部的复杂模式, 是当前药物发现和分子建模中不可或缺的重要工具。

2.4 分子片段

分子片段作为构成分子功能的基本单元, 在决定分子功能及其相互作用中起着关键作用。根据化学特性和生物意义的差异, 分子片段通常可划分为官能团、分子基序和药效团三类。

官能团指分子中具有特定反应活性的原子基团, 如羟基和羧基等。这些基团通过电子效应和空间效应调控分子的理化性质, 对分子的化学行为和分子间相互作用具有显著影响。在药物化学中, 官能团工程化改造是优化分子药代动力学参数的主要策略, 例如, 通过引入磺酸基团可以改善分子的溶解性、稳定性和生物活性^[116]。

分子基序是分子中较大的结构单元, 不仅影响分子的整体稳定性和电子特性, 还会改变分子与生物靶标的相互作用, 从而影响其生物活性。常用的分子基序化方法包括 BRICS^[117]、逆转录合成组合分析程序(Retrosynthetic Combinatorial Analysis Procedure, RECAP)^[118]、Murcko 骨架^[119]、增强分子片段化方法(Enhanced Molecular Fragmentation, eMolFragments)^[120]和基于 RDKit 的骨架网络(RDKit Scaffold Network, rdScaffoldNetwork)^[121]等。其中, BRICS 方法基于逆向分析化学反应的断裂规则, 识别出与生物活性或合成可行性密切相关的重要基序; RECAP 方法同样利用预定义的断裂规则, 将分子拆分为若干片段, 重点在于发现具有合成实用性的连接点, 便于后续的片段重组和新化合物设计; Murcko 骨架方法则通过去除侧链和功能基团, 提取出决定分子核心结构的框架; eMolFragments 方法在传统 RECAP 规则的基础上, 结合分子中原子连接方式及局部环境信息, 实现对基序的更细粒度划分; rdScaffoldNetwork 利用

RDKit 工具, 通过系统去除官能团和侧链, 构建出包含多级骨架及其衍生物的网络结构, 从而揭示分子的结构多样性。

药效团是一种更为抽象的分子表征方式, 不仅关注原子及其连接方式, 更强调在特定空间排列中能够与生物靶标发生相互作用的关键功能组。药效团并非指某一特定的官能团或特征结构片段, 而是对分子性质的一种综合性描述, 涵盖了氢键相互作用、疏水中心、电荷中心和芳香环中心等多种特征。这些特征在分子识别中发挥着至关重要的作用: 氢键相互作用是药物-靶标识别的关键因素; 疏水中心通常由连续碳原子构成, 能与靶标的疏水基团形成稳定的疏水核心; 电荷中心能与靶标形成盐桥或强静电作用; 芳香环中心则能通过 $\pi-\pi$ 相互作用参与分子间的结合。药效团描述了对化合物的生物活性至关重要的分子特征框架, 准确识别和理解药效团对于揭示分子相互作用机制、优化先导化合物和开发新药物具有重要意义。

2.5 机器学习

机器学习是一门多学科交叉的研究领域。与传统依赖预设规则的编程方法相比, 机器学习更注重从数据中自动发现规律, 以构建能够适应未知数据的预测模型。机器学习的发展离不开算法和模型不断创新。早期的机器学习算法包括线性模型、决策树与集成方法^[122]、支持向量机 (Support Vector Machine, SVM)^[123]和朴素贝叶斯 (Naive Bayes, NB)^[124]等, 主要侧重于特征工程和统计模型的构建。而近年来, 随着计算能力和大数据技术的提升, 深度学习等基于神经网络的模型逐渐成为研究热点, 这些模型通过多层非线性变换自动从原始数据中提取抽象特征, 在图像识别、自然语言处理、语音识别以及药物设计等领域取得了显著成果。

线性模型通过假设输入特征与输出变量之间存在线性关系来构建预测模型。最基本的线性模型包括线性回归和逻辑回归。线性模型具有计算简单、易于解释和高效训练的优点, 但其表现受限于线性假设, 难以捕捉复杂的非线性关系, 因此在处理高维数据或复杂模式时可能表现不佳。

决策树通过对特征空间进行递归划分来构建树形结构, 其工作原理是通过不断地对数据进行分割, 将样本划分到各个叶节点, 并在叶节点上做出预测。由于决策树结构直观且易于理解, 常被用于分类和回归任务。然而, 单棵决策树往往容易过拟合, 为了解决这一问题, 出现了集成方法, 比如随机森林 (Random Forest, RF)^[125]和梯度提升树 (Gradient Boosting Decision Trees, GBDT)^[126]等, 通过构建多个决策树并将其预测结果进行综合, 不仅显著提高

了预测精度，还增强了模型的鲁棒性和泛化能力。RF 通过对样本和特征进行随机采样生成多棵树，降低了模型的方差；而 GBDT 则通过逐步优化损失函数来不断修正预测误差，具有较强的拟合能力。

SVM 是一种以结构风险最小化为目标的机器学习方法，主要用于分类问题。SVM 试图在特征空间中寻找一个最优超平面，使得不同类别的样本之间的间隔最大化，从而提高模型的泛化性能。对于非线性可分问题，SVM 采用核函数将原始数据映射到高维空间，使得数据在该空间中变得线性可分。

NB 是一类基于贝叶斯定理并假设各特征条件独立的概率模型。该方法通过计算后验概率，选择具有最高概率的类别作为预测结果。NB 具有训练速度快、对小规模数据表现良好和对噪声具有一定鲁棒性的优点，尤其在文本分类、垃圾邮件检测等领域中应用广泛。

总之，这几种传统机器学习方法各有特点：线性模型以计算效率高和解释性强见长；决策树及其集成方法则通过树状结构和组合策略有效捕捉复杂决策边界；SVM 通过最大间隔原则和核技巧应对高维与非线性问题；而 NB 以其概率推断和条件独立假设在部分领域展现出优异性能。不同的方法适用于不同的数据特性和任务需求，为机器学习领域提供了丰富的工具和思路。

2.6 深度学习

深度学习是机器学习的一个分支，通过构建多层次的非线性神经网络，自动提取数据中的高层次抽象特征和隐含表示。传统神经网络通常由输入层、隐藏层和输出层构成，而深度神经网络则通过增加隐藏层的数量，使得模型具有更强的表达能力和建模复杂关系的能力。每一层网络通过权重和偏置参数对输入数据进行线性组合，并经过非线性激活函数处理，逐层提取数据中的特征信息。相比于人工设计的特征，深度特征的代表能力更强、更稳健，从而能在复杂任务中表现出优异的性能。典型的深度学习模型包括全连接神经网络(Fully Connected Neural Networks, FCNN)、CNN^[127]、RNN^[128]、GNN^[129]以及Transformer^[130]。FCNN 适用于静态数据建模，CNN 适合处理具有空间结构的数据，RNN 及其变体擅长捕捉序列信息中的时间依赖性，GNN 则针对图结构数据进行高效建模，而 Transformer 通过自注意力机制在全局范围内捕捉复杂的依赖关系。这些模型各有侧重，为解决不同类型数据的复杂问题提供了有力的技术支持。




图 2-1 全连接神经网络示例

FCNN 是深度学习的基础网络，其主要特点在于信息在网络中单向传递，不存在循环或反馈。图 2-1 展示了一个 FCNN 结构示例。FCNN 通常包括一个输入层、一个或多个隐藏层和一个输出层。输入层负责接收原始数据，并将其转换为适合网络处理的向量。每个输入节点对应原始数据中的一个特征。隐藏层是神经网络中进行特征提取和信息加工的主要部分，通过非线性激活函数对输入信息进行逐层变换和特征抽象，提取数据中的潜在模式。隐藏层的层数和每层神经元的数量直接影响网络的表达能力和复杂度。输出层则将隐藏层的特征映射到具体的任务空间。输出层的节点数通常取决于具体任务，例如分类问题中的类别数量或回归问题中的输出维度。在 FCNN 中，各层之间的连接通常是全连接的，每个神经元都与前一层的所有神经元相连，这种密集连接使得网络能够捕捉到输入数据中复杂的非线性关系。FCNN 作为一种基础而强大的深度学习模型，通过多层非线性变换实现了从低级特征到高级语义的自动抽象，具有较强的表达能力和灵活的适应性。尽管其在处理时序数据和解决梯度消失问题上存在一定局限，但在大多数静态数据建模任务中，FCNN 依然展现出优异的性能，并为各类复杂模型的发展奠定了坚实的基础。




图 2-2 卷积神经网络示例

CNN 主要针对具有局部空间相关性的数据进行建模，其核心思想在于利用卷积操作，通过局部感受野和共享权重，有效捕捉输入数据中的局部特征和空间层级结构。图 2-2 展示了一个 CNN 结构示例。卷积层通过一组可学习的卷积核在输入数据上滑动，对局部区域进行特征提取，提取出边缘、纹理等低级特

征，再经过多层卷积和池化操作逐步提取出高层次的语义信息。在网络的后端，通常会采用全连接层对提取的特征进行综合，完成分类、回归或其他任务的最终决策。CNN 能够有效捕捉局部特征和空间结构信息，适用于图像和模式识别任务。




图 2-3 循环神经网络示例

RNN 擅长处理顺序数据，具有独特的内部记忆功能，能够记忆序列中的上下文和顺序信息。这种能力使得 RNN 在涉及序列数据的任务中非常有效。图 2-3 展示了一个 RNN 结构示例。标准 RNN 单元在每个时刻接收当前输入及上一个时刻的隐藏状态，通过非线性映射更新隐藏状态。传统 RNN 虽然能建模短期依赖，但在处理长序列时常出现梯度消失或梯度爆炸的问题，为此衍生出 LSTM 和 GRU，通过门控机制在信息传递过程中进行有效调控。

GNN 专门设计用于处理图结构数据，图中的每个节点通过与其邻居节点的信息交互，不断更新自身的嵌入表示，进而捕捉图的局部和全局结构信息。图 2-5 展示了一个 GNN 结构示例。GNN 可以直接处理分子、社交网络、知识图谱等不规则数据，通过层层消息传递和聚合机制，提取出节点之间复杂的关系和图的整体特征，因而在分子性质预测、药物-靶标相互作用预测、推荐系统以及图分类等任务中显示出强大的能力。




图 2-4 图神经网络示例




图 2-5 Transformer 示例

Transformer 架构以自注意力机制为核心，克服了传统序列模型（如 RNN）在长距离依赖建模中的局限性。图 2-5 展示了一个 Transformer 结构示例。典型的 Transformer 由编码器和解码器组成，编码器负责将输入序列编码成上下文表示，解码器则利用编码器的输出生成目标序列。它不依赖于序列的逐步处理，而是通过位置编码为输入中的每个元素注入位置信息，并采用多头自注意力机制在整个序列上并行计算不同位置之间的相关性，动态地分配权重，从而捕捉长程依赖关系。多头自注意力机制允许模型同时捕捉多种语义关系和不同尺度的信息，进一步通过全连接神经网络对每个位置进行非线性变换，增强模型的表达能力。Transformer 在自然语言处理、机器翻译以及最近在图像、语音和生物信息学等领域中均取得了突破性的成果，其并行化计算和对长距离依赖的高效捕捉使其成为当前最具影响力的深度学习模型之一。

2.7 图神经网络

GNN 是专门用于处理图结构数据的深度学习模型，能够结合图计算与神经网络的优势，捕捉节点间的复杂关系以及图的全局结构信息。传统图计算方法虽擅长挖掘结构信息，但难以处理高维特征。图结构由节点和边构成，节点间的连接关系具有灵活性和不规则性，而传统神经网络则主要适用于欧氏空间数

据（如图像、文本），无法直接处理这种非欧氏空间的图结构数据。分子可以被有效地表示为图结构，其中原子或分子片段作为节点，化学键或分子片段间的连接关系作为边。GNN 正适合从这种表示中学习，利用多层消息传递机制实现信息的传播与融合。

GNN 的核心目标是通过图中的节点和边的邻接关系来学习节点或整个图的表示。每个节点的表示不仅仅依赖于该节点本身的信息，还依赖于它的邻居节点的信息。通过迭代的方式，GNN 能够将图中的信息传递到更广泛的区域，从而学习到全局的信息。具体而言，每个节点利用自身初始特征及其邻居节点的特征，经过多层次的消息传递与聚合操作，不断更新节点特征。在这一过程中，网络参数根据目标任务自动学习，捕捉图中潜在的结构模式和语义信息。以分子图为例，节点的初始特征包括原子类型、电荷、杂化状态等，而边缘特征包括键类型、键级等信息。GNN 方法不仅考虑了单个节点的性质，还综合了它们在分子内部的连接关系，为分子结构提供了更为细致和全面的理解，从而实现了分子性质和药物-靶标相互作用的准确预测。

图神经网络常见的模型有图卷积神经网络（Graph Convolutional Network, GCN）^[131]、图注意力网络（Graph Attention Network, GAT）^[132]、图同构网络（Graph Isomorphism Networks, GIN）^[133]、消息传递神经网络（Message Passing Neural Network, MPNN）^[134]等。GCN 通过归一化的邻接矩阵实现信息传递，适用于节点分类任务。GAT 引入注意力机制，动态加权邻居节点的重要性，提升模型对关键结构的敏感性。GIN 通过增强节点特征的聚合操作，使模型在区分不同图结构上更为敏感。MPNN 以消息传递机制为核心，通过反复迭代的方式在节点之间传递信息以更新节点表示。尽管这些方法在机制上存在差异，但其核心目标均在于解决在不规则的图结构上高效提取局部和全局信息的问题。

GNN 已在社交网络分析、推荐系统、知识图谱、计算化学和生物信息学等领域取得了显著成果。特别是在分子性质预测和药物-靶标相互作用预测任务中，GNN 通过有效建模分子内部的原子连接关系和局部化学环境，为揭示分子结构与功能之间的复杂关系提供了强有力的工具。例如，在分子性质预测任务中，AttentiveFP^[135]利用图注意力机制在不同距离上传递节点信息，有效表征了原子的局部化学环境以及长程相互作用，显著提升了预测精度。在药物-靶标相互作用预测任务中，MGraphDTA^[136]基于化学直觉构建深度多尺度图神经网络，同时捕捉化合物的局部和全局结构信息，有效识别候选分子，加速了先导化合物的发现进程。

2.8 消息传递神经网络

MPNN 是从图神经网络中抽象出来的一种通用框架，旨在通过定义标准化的消息传递流程，灵活处理图结构数据。MPNN 的模块化设计使其能够适应多种任务需求，并成为许多经典图神经网络模型的理论基础。MPNN 的核心思想在于通过节点之间的消息传递和读出阶段学习图中节点及整体结构的表示。

在消息传递阶段，特定节点的计算过程包括邻居消息聚合和自身节点特征更新，分别通过消息传递函数 M_t 和节点更新函数 U_t 实现。具体来说，在每一轮迭代中，对于图中任意一个节点，消息 m_i^{t+1} 可以表示为目标节点自身的特征 h_i^t 、邻居节点特征 h_j^t 以及边缘特征 e_{ij} 经过消息传递函数变换后的结果。接着，节点会将来自所有邻居的消息进行聚合，这一步骤能够捕捉到局部邻域的信息。具体过程如下：

$$m_i^{t+1} = \sum_{j \in N(i)} M_t(h_i^t, h_j^t, e_{ij}) \quad (2-1)$$

式中： m_i^{t+1} 表示节点 i 在第 $t+1$ 层接收到的信息， M_t 表示消息函数， h_i^t 表示节点 i 在第 t 层中的节点特征， $N(i)$ 表示节点 i 的邻居节点集合， h_j^t 表示在第 t 层中节点 i 的邻居节点 j 的节点特征， e_{ij} 表示节点 i 与节点 j 之间的边的特征。

在聚合之后，每个节点再通过节点更新函数，结合原有的节点特征和聚合后的消息，生成新的节点表示 h_i^{t+1} 。这个过程可以重复多次，从而使得节点表示能够逐步融入更广泛的图结构信息，甚至捕捉到全局的图特征。具体过程如下：

$$h_i^{t+1} = U_t(h_i^t, m_i^{t+1}) \quad (2-2)$$

式中： U_t 表示节点更新函数，该函数把原节点特征 h_i^t 和消息 m_i^{t+1} 作为输入，得到更新后的节点特征 h_i^{t+1} 。

读出阶段则负责将所有节点的隐藏状态进行聚合，生成整个分子图的综合特征向量 h_G ，用于后续的任务。具体过程如下：

$$h_G = \sum_{i \in G} h_i^{t+1} \quad (2-3)$$

式中： h_G 代表分子图的特征向量， G 代表图中所有的节点集合。

MPNN 的变体主要是在传统框架上针对特定问题进行改进与优化。其中，方向性消息传递神经网络（Directed Message Passing Neural Network, D-MPNN）是一种典型的变体，它将分子图中的化学键视为有向边，通过沿有向边传递消息，更精确地捕捉化学键的方向性特征和局部结构信息，从而避免了节点信息在传播过程中的重复累积，提升了分子表征的细粒度和准确性。上下文信息传递神经网络（Contextual Message Passing Neural Network, C-MPNN）则在消息传

递过程中引入条件化和耦合机制，在节点更新时同时考虑边和上下文信息，通过门控或注意力机制动态调节不同信息源的贡献，从而增强了模型对复杂分子结构特征的捕捉能力。这两种变体针对 MPNN 的固有缺陷（信息冗余、局部结构表征不足以及特征融合效率低下等），提出了更精细且高效的设计方案。

第三章 指纹增强分层图神经网络用于分子性质预测

3.1 研究背景

分子性质的精准预测在药物筛选与设计过程中具有重要的科学意义和应用价值^[137]。通过准确预测分子的生物活性、毒性、溶解性等关键性质，研究人员能够在早期阶段筛选出具有潜在药效的候选化合物，从而显著降低实验成本、缩短研发周期并减少失败风险^[107, 138, 139]。尽管实验测定仍是分子性质预测的金标准，但耗时、昂贵的特点极大地限制了它们的应用。近年来，基于计算机辅助的分子性质预测方法因其快速、准确的特点，受到了广泛关注。

机器学习方法通常以专家知识构建的化学描述符^[140]或分子指纹^[141]为输入，与 NB^[142]、RF^[143]、SVM 等经典机器学习算法相结合，构建分子性质预测模型。这些方法虽然在一定程度上能够描述分子的理化性质，但由于手工构造的特征难以全面捕捉分子内部的复杂结构与相互作用，尤其是在面对新型化学结构时，通常无法有效推广，导致其泛化能力受到较大限制。近年来，深度学习技术，特别是 GNN 的引入，为分子性质预测提供了新的解决方案。GNN 能够将分子自然地表示为图结构，其中原子作为节点，化学键作为边，从而直接建模分子拓扑结构。常见的 GNN 架构如 GCN^[144, 145]、GAT^[43, 146]和 MPNN^[44, 134]等，已在分子性质预测任务中展现出显著优势。特别是 D-MPNN^[147]通过引入方向性信息，进一步提升了分子结构信息的表达能力。然而，现有的 GNN 方法大多侧重于原子级别的特征提取，未能充分考虑分子结构的层次性，也缺乏对不同层次信息之间交互的有效建模。尽管部分研究尝试引入分子基序信息，例如基于自监督学习的基序生成框架^[148]和图对比学习方法^[149]，但这些方法往往缺乏统一的结构来整合原子级和基序级信息。

针对上述问题，本研究提出了一种指纹增强的分层图神经网络（Fingerprint-Enhanced Hierarchical Graph Neural Network, FH-GNN），旨在通过整合分层分子图表示与分子指纹特征，全面挖掘分子的全局和局部信息，从而提升分子性质预测的性能。FH-GNN 的核心设计包括以下三个方面：第一，构建了融合原子级、基序级和分子级信息的分层分子图，并建立不同层次之间的关联，实现对分子结构的多尺度建模；第二，引入分子指纹编码模块，使模型不仅能够自动学习分子的结构信息，还能充分利用化学领域的先验知识，从而弥补传统图神经网络在化学功能信息理解上的不足；第三，设计了一种自适应注意力机制，在融合分层分子图表示与指纹特征的过程中，动态调整不同信息来源的权重，生成更具判别性的分子表示。在 MoleculeNet 提供的八个基准

数据集上的结果表明, FH-GNN 在分类和回归任务中的性能均优于现有的基线模型, 充分证明了 FH-GNN 在分子信息捕获和性质预测方面的有效性。

3.2 算法运行设置

3.2.1 数据集

为了将 FH-GNN 与现有方法进行比较, 我们采用 MoleculeNet^[150]基准数据集对 FH-GNN 模型进行性能评估, 共选取 8 个具有代表性的分子性质预测任务, 包括 5 个分类任务和 3 个回归任务, 涵盖物理化学性质、生物物理学特性及生理活性等多个维度。在数据预处理阶段, 我们剔除了开源化学信息学工具包 RDKit 无法解析的分子结构以及单原子分子, 以确保数据质量与模型输入的有效性。表 3-1 详细列出了各数据集的统计信息。

表 3-1 FH-GNN 工作所使用的分子性质预测数据集的统计信息

数据集	任务数	数据量	英文全称	平均原子数	平均基序数	任务类型
BACE	1	1513	Beta-secretase 1 inhibitors	34	10	分类
BBBP	1	2039	Blood-brain barrier penetration	24	6	分类
Tox21	12	7831	Toxicology 21st	19	5	分类
SIDER	27	1427	Side effect resource	34	9	分类
ClinTox	2	1477	Clinical toxicity	26	7	分类
ESOL	1	1128	Aqueous solubility	13	4	回归
FreeSolv	1	642	Free solvation database	9	2	回归
Lipophilicity	1	4200	Lipophilicity dataset	27	8	回归

具体而言, 本研究选取的数据集包括: (1) BACE 数据集, 包含 1513 种人类 β -分泌酶 1 抑制剂, 用于单任务分类研究; (2) BBBP 数据集, 涵盖 2039 个具有二元标签的分子, 用于评估血脑屏障穿透能力, 该指标对中枢神经系统靶向药物的研发具有重要指导意义; (3) Tox21 数据集, 包含 7831 个分子及其针对 12 种药物毒性相关受体的多分类毒性谱; (4) SIDER 数据集, 收录 1427 种已上市药物的不良反应数据, 依据监管活动医学词典 (Medical Dictionary for Regulatory Activities, MedDRA) 标准将其副作用划分为 27 个系统器官类别; (5) ClinTox 数据集, 通过对比美国食品和药物监督管理局 (Food and Drug Administration, FDA) 批准的药物与因毒性终止临床试验的药物, 提供了 1477 种化合物的二元分类数据; (6) ESOL 数据集, 包含 1128 种化合物的水溶性数据; (7) FreeSolv 数据集, 提供 642 个小分子在水中的实验与计算水合自由能数据; (8) Lipophilicity 数据集, 来源于 ChEMBL 数据库^[151]中的亲脂性数据, 包含 4200 种化合物在 pH 7.4 条件下的辛醇/水分配系数 ($\log D$) 实

验结果。

3.2.2 评价指标

在模型性能评估方面，本研究针对不同任务类型采用差异化的评价指标体系。对于分类任务，选用受试者工作特征曲线下面积（Area Under the Receiver Operating Characteristic Curve, AUROC）作为主要评价指标。AUROC 通过量化真阳性率与假阳性率之间的权衡关系，评估模型在类别区分任务中的判别能力，其取值范围为[0.5,1]，数值越大表明模型分类性能越优。对于回归任务，采用均方根误差（Root Mean Square Error, RMSE）作为核心评价指标。RMSE 通过计算预测值与真实值之间差异的平方均值的平方根，量化模型预测精度。该指标具有与目标变量相同的量纲，数值越小表明模型的预测性能越好，能够直观反映预测结果与实际观测值的匹配程度。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (3-1)$$

3.2.3 基线模型

为全面评估 FH-GNN 的性能，本研究选择了十种具有代表性的基线模型。这些模型在设计理念或技术实现上与 FH-GNN 具有一定的相关性，主要可分为三类。第一类是分子指纹融合方法，包括 AttentiveFP^[135]、FP-GNN^[95]和 DGCL^[24]。这类方法通过融合分子指纹与图神经网络特征，增强分子表征的全面性。AttentiveFP 利用图卷积层与注意力机制识别关键原子或化学键，捕获分子局部和全局特征。FP-GNN 利用图注意力网络提取分子图特征，并与多种分子指纹特征相融合，提升分子表示的多样性和判别性。DGCL 提出了基于双图神经网络的对比学习框架，通过混合分子指纹特征增强分子表征学习。第二类是基序信息处理方法，如 MGSSL^[152]、HiMol^[91]、HimGNN^[153]和 Mix-Key^[154]。这些方法聚焦于分子基序的结构特征，挖掘分子功能结构的潜在规律。MGSSL 是一种基于图神经网络的自监督学习框架，通过基序生成任务捕获分子功能结构的拓扑和化学属性。HiMol 基于分层图神经网络进行预训练，实现了基序信息的编码与提取。HimGNN 通过 Transformer 网络增强局部基序与全局结构的交互，捕获更全面的分子表示。Mix-Key 开发了分子数据增强策略，通过随机替换分子基序，强化模型对关键功能基团的建模能力。第三类是消息传递优化方法，代表性模型有 D-MPNN^[147]、C-MPNN^[47]和 GROVER^[54]，它们通过优化图神经网络的消息传递机制，提升分子图的建模效率与效果。D-MPNN 采用定向消息传递机制（沿化学键方向传递信息），避免传统原子间消息传递中的环路

冗余问题，提升了计算效率。C-MPNN 提出上下文感知的消息交互机制，显式建模原子与化学键的协同关系，增强局部化学环境的表征能力。GROVER 将消息传递网络与 Transformer 网络结合，通过节点级、边级和分子级自监督任务，学习通用分子表示。通过与这些基线模型的对比，我们旨在从多个角度验证 FH-GNN 在整合分层分子图表示与分子指纹特征方面的优势，从而进一步证明其在分子性质预测任务中的优越性。

3.2.4 参数设置

为确保模型性能的最优化，本研究系统性地进行了超参数调优实验。针对不同数据集的特征，我们对学习率、批次大小、网络深度等超参数进行了调整。模型训练采用 Adam 优化器^[155]，在所有数据集上统一进行 100 个训练周期，以确保训练过程的充分性和结果的可比性。表 3-2 详细列出了各数据集上最终确定的最优超参数组合。

表 3-2 FH-GNN 的超参数配置表

数据集	训练周期	学习率	批次大小	编码器深度
BACE	100	1e-4	128	5
BBBP	100	1e-4	64	7
Tox21	100	1e-3	512	5
SIDER	100	1e-4	32	7
ClinTox	100	1e-4	128	5
ESOL	100	5e-4	32	5
FreeSolv	100	1e-4	32	5
Lipophilicity	100	5e-4	128	5

实验环境配置如下：硬件平台采用配备 NVIDIA RTX 3080 Ti GPU（12GB 显存）、Intel(R) Xeon(R) CPU E5-2640 v4 @ 2.40GHz 处理器和 64GB DDR4 内存的 Linux 服务器。软件环境基于 PyTorch Geometric 框架构建，具体包括：Python 3.7 作为编程语言，PyTorch 1.12 作为深度学习框架，RDKit 2018.03 用于分子结构处理，Numpy 1.21 和 Pandas 1.3 用于数据处理与分析。所有实验均在 CUDA 11.3 环境下运行，以充分利用 GPU 的并行计算能力。

3.3 方法描述

3.3.1 FH-GNN 框架概述

图 3-1 展示了本文提出的 FH-GNN 模型的框架示意图，该模型由三个核心模块构成：分层分子图表示模块、分子指纹编码模块以及融合与预测模块。首先，FH-GNN 采用 BRICS 算法对输入分子进行分解，构建具有层次结构的分子

图表示。随后，分层分子图表示模块利用定向消息传递神经网络对分子图进行编码，通过多层次的消息传递，捕获分子结构的全局拓扑特征和局部化学环境信息，实现对分子结构的多尺度建模。与此同时，分子指纹编码模块并行地提取分子的指纹特征，充分利用化学领域的先验知识。在特征融合阶段，模型引入自适应注意力机制，动态调整分层分子图表示与指纹特征的权重，生成更具判别性的分子表示。具体而言，该机制通过可学习的注意力参数，根据任务需求自动平衡两种特征的重要性，实现特征的有效互补。最终，融合后的分子表示被输入到一个多层感知器（Multilayer Perceptron, MLP）中进行目标性质的回归或分类预测。




图 3-1 FH-GNN 框架示意图。(A) 分层分子图表示模块，将分子表示为分层分子图，利用定向消息传递神经网络对分层分子图进行编码。(B) 分子指纹编码模块，利用多层感知机，提取分子的指纹特征。(C) 融合与预测模块，引入自适应注意力机制，动态调整分层分子图表示与指纹特征的权重，生成更具判别性的分子表示，最终，融合后的分子表示被输入到一个多层感知器中进行目标性质的回归或分类预测。

3.3.2 分层分子图表示模块

给定一个分子，我们首先将其表征为分子图 $G_n = (V_n, E_n)$ ，其中 V_n 是原子的集合， E_n 是化学键的集合。本研究中原子和化学键的初始特征如表 3-3 所示，其中原子特征被表示为 89 维向量，化学键特征被表示为 9 维向量。上述特征均使用 RDKit 生成。随后，我们采用 BRICS 算法对分子进行分解。BRICS 算法定义了 16 条基于化学反应的键断裂规则，能够识别分子中易于通过化学合成过程形成或断裂的化学键。如图 3-2 所示，该过程类似于化学家常用的逆合成分析方法，将复杂分子分解为更简单的前体结构。BRICS 算法能够有效保留分子中具有重要功能意义的成分，如芳香环、羟基、羧基等特征基团。随后，基于分解得到的基序构建基序图 $G_m = (V_m, E_m)$ ，其中 V_m 表示基序节点

集合, E_m 表示基序间的空间关系边集合。具体而言, 如果两个基序中的原子在分子图中相邻, 则在对应基序节点间添加一条边, 进而构建基序图。为了建立分子图与基序图之间的关联, 我们在每个基序节点与其覆盖的所有原子节点之间添加原子-基序边 E_{am} 。此外, 我们引入一个分子级超节点 V_g , 并通过基序-图边 E_{mg} 将其与所有基序节点相连。基序节点和分子级超节点的特征通过它们包含的所有原子的特征加和得到, 这种分层分子图表示方法能够同时捕获从原子级到基序级乃至分子级的多尺度拓扑信息, 为后续分子性质预测提供了丰富的特征表示。最终, 分层分子图可形式化表示为:

$$G = (V, E), V = [V_n, V_m, V_g], E = [E_n, E_m, E_{am}, E_{mg}] \quad (3-2)$$

表 3-3 原子特征与化学键特征的描述

特征	特征描述	长度
Atom type	原子类型	60
Degree	邻居原子数目	7
Formal charge	原子的电子电荷	6
Chirality	原子的手性类型	3
Number Hs	氢原子数目	5
Hybridization	原子的杂化类型	7
Aromaticity	原子是否为芳香体系的一部分	1
Bond type	化学键类型	4
Conjugation	化学键是否共轭	1
Ring	化学键是否为环的一部分	1
Stereo	化学键的立体构型	3




图 3-2 分层分子图构建示意图

我们使用传统消息传递神经网络的一种变体 D-MPNN，从分层分子图中学习节点和边缘的嵌入表示。与传统的以节点为中心的消息传递不同，D-MPNN 通过以边为中心的卷积操作来学习分层分子图的表示。D-MPNN 通过以边为中心的消息传递机制，有效捕获分子图的局部和全局结构信息，同时避免了传统消息传递神经网络中的循环问题。具体而言，在消息传递之前，将边的特征 e_{vw} 与起始原子特征 x_v 进行简单拼接，构造有向边的初始特征，并将其输入到具有可学习权重 $W_i \in R^{h \times h_i}$ 和非线性激活函数 τ 的神经网络层，构造有向边的隐藏特征 h_{vw}^0 。具体过程如下：

$$h_{vw}^0 = \tau(W_i \text{cat}(x_v, e_{vw})) \quad (3-3)$$

式中： $\text{cat}(x_v, e_{vw})$ 表示简单拼接， τ 表示校正线性单元（Rectified Linear Unit, ReLU）激活函数。

在消息传递阶段，信息沿着有向边的方向进行传递和更新。具体而言，每个有向边的隐藏状态基于来自共享相同起始节点的其他边的传入消息进行迭代更新。这个过程尊重边的方向性，确保信息流遵循分层分子图所规定的正确路径。具体过程如下：

$$h_{vw}^{t+1} = \tau(h_{vw}^0 + W_h \sum_{k \in \{N(v) \setminus w\}} h_{kv}^t) \quad (3-4)$$

式中： $N(v) \setminus w$ 表示不包括节点 w 的节点 v 的邻居集合。

在消息传递完成后，我们通过聚合所有进入目标节点的有向边的隐藏状态来更新节点特征。初始原子特征 x_v 与有向边的隐藏状态之和进行连接，并通过一个具有可学习权值 $W_\alpha \in R^{h \times h_i}$ 和非线性激活函数 τ 的神经网络层，产生更新后的原子特征 h_v 。具体过程如下：

$$h_v = \tau(W_\alpha \text{cat}(x_v, \sum_{w \in N(v)} h_{vw}^{t+1})) \quad (3-5)$$

最后，对分层分子图中所有节点的隐藏状态进行聚合，生成整个分子图的综合特征向量 h_G 。具体过程如下：

$$h_G = \sum_{v \in G} h_v \quad (3-6)$$

3.3.3 分子指纹编码模块

分子指纹是一种将分子编码为二进制字符串的计算方法，通过特定的规则指示分子中特定的结构或化学特征是否存在^[107]。根据编码策略的不同，分子指纹主要可分为子结构指纹、拓扑或路径指纹、圆形指纹以及药效团指纹^[108]。在本研究中，我们综合采用了五种具有代表性的指纹编码技术来全面表征分子结构信息：AtomPairs 指纹、MACCS 指纹、MorganBits 指纹、MorganCounts 指纹和药效团指纹。表 3-4 详细罗列了分子指纹的统计信息。

表 3-4 FH-GNN 中使用的分子指纹统计信息

指纹	结构信息	功能信息	拓扑信息	三维信息
AtomPairs 指纹	✓		✓	
MACCS 指纹	✓	✓		
MorganBits 指纹	✓		✓	
MorganCounts 指纹	✓		✓	
药效团指纹		✓		✓

AtomPairs 指纹通过捕捉分子中所有非氢原子对的拓扑信息来表征分子结构。每对原子按照其原子类型和原子间最短路径距离进行编码，从而捕捉分子内部的空间关系和结构特征。AtomPairs 指纹特别适用于描述分子中分散的功能团和整体结构关系。MACCS 指纹是基于 166 个结构密钥的二进制指纹，每个密钥对应一个特定的分子子结构或化学特征。若分子包含密钥定义的结构，则对应位置设为 1，否则为 0。由于具有较强的解释性，MACCS 指纹被广泛用于化合物相似性搜索和初步的分子描述。MorganBits 指纹是基于 Morgan 算法生成的

二进制指纹。Morgan 算法通过考虑特定范围内相邻原子的特征来捕获分子中每个原子的邻域信息。在我们的研究中，我们将 Morgan 算法的半径设为 2，比特数设为 2048。MorganBits 指纹通过迭代地将原子及其邻域信息编码为特征，指示特定圆形子结构是否存在。MorganBits 指纹的优势在于能够捕捉分子的局部环境信息，同时计算速度快，适用于大规模虚拟筛选。MorganCounts 指纹与 MorganBits 指纹类似，也是基于 Morgan 算法生成，但它记录的是每个子结构出现的次数，而不是简单的存在与否。MorganCounts 指纹不仅反映了子结构的多样性，还包含了其频率信息，对于需要量化特征的任务具有更高的描述能力。药效团指纹侧重于捕捉分子中的药理活性特征，记录如氢键供体、氢键受体、芳香环、正负电荷和疏水中心等药效团特征在分子三维空间中的距离和角度关系。它能够反映药物与靶标相互作用的关键化学特征，为药物设计和筛选提供更具功能性的描述。

上述五种指纹使用不同的编码策略，覆盖了一维到三维的分子特征，降低了单一指纹的偏倚风险。通过组合这些互补的分子指纹，可以构建更全面的分子表示，为深度学习模型提供丰富的特征输入。我们将这 5 种互补的分子指纹拼接并输入到分子指纹编码模块中，利用具有 ReLU 激活函数的 MLP 学习从输入空间到潜在特征空间的非线性映射。具体过程如下：

$$F(x) = \text{cat}(A(x), M(x), B(x), C(x), P(x)) \quad (3-7)$$

$$f_x = \tau(W_\beta \times F(x) + b_\beta) \quad (3-8)$$

式中： $A(x)$ 表示 AtomPairs 指纹， $M(x)$ 表示 MACCS 指纹， $B(x)$ 表示 MorganBits 指纹， $C(x)$ 表示 MorganCounts 指纹， $P(x)$ 表示药效团指纹， τ 表示 ReLU 激活函数， W_β 表示权重矩阵， b_β 表示偏置向量。

3.3.4 融合与预测模块

为了保证不同特征之间的兼容性和一致性，并最小化冗余信息，我们设计了一个融合与预测模块，用于生成联合表示并预测目标属性值。融合与预测模块的输入是前面步骤所提取的分层分子图表示和分子指纹特征。该模块采用自适应注意机制，将两类特征进行整合，形成更全面的分子表示。其中，分层分子图表示能够捕获分子在原子、基序及整体图层次的结构与关系，分子指纹特征则反映了特定化学结构或官能团的功能信息。根据上下文信息以及特征在不同任务中的相关性，自适应注意机制动态调整各个特征的重要性，实现优先级排序和冗余信息的有效抑制。最终，生成的分子表示通过具有 ReLU 激活函数

的 MLP 进行处理，输出预测的目标属性值。具体过程如下所示：

$$P = \text{mlp}(W_F * f_x + W_G * h_G + b) \quad (3-9)$$

式中： W_G 和 W_F 分别表示分层分子图的可学习权值和分子指纹的可学习权值， b 表示偏置向量。

3.4 结果与讨论

3.4.1 性能测试结果及分析

为系统验证 FH-GNN 的预测性能，本研究基于 MoleculeNet 的 8 个分子性质预测数据集，开展了多维度评估实验。我们采用基于分子结构骨架的分割方法，按照 8:1:1 的比例将各数据集划分为训练集、验证集和测试集。基于骨架的分割方法利用分子结构相似性进行聚类，确保不同集合间的分子在核心结构上具有显著差异。与随机分割相比，这种分割方式更能反映现实场景中模型对新型化合物的预测能力。为了消除随机性影响，我们使用不同的随机种子进行了五次独立实验，并记录每次实验的 AUROC（分类任务）和 RMSE（回归任务），最终性能指标取五次实验的均值以及标准差。

表 3-5 FH-GNN 与基准模型在分类任务中的分子性质预测性能对比

模型	BACE	BBBP	Tox21	SIDER	ClinTox
AttentiveFP	0.784 (0.000)	0.908 (0.050)	0.807 (0.020)	0.605 (0.060)	0.933 (0.020)
C-MPNN	0.821 (0.006)	0.927 (0.002)	0.806 (0.016)	0.616 (0.003)	0.902 (0.012)
MGSSL	0.791 (0.009)	0.697 (0.009)	0.765 (0.003)	0.618 (0.008)	0.807 (0.021)
Himol _{best}	0.846 (0.002)	0.732 (0.008)	0.762 (0.003)	0.625 (0.003)	0.808 (0.014)
FP-GNN	0.845 (0.028)	0.910 (0.027)	0.803 (0.024)	0.598 (0.014)	0.765 (0.038)
GROVER	0.835 (0.044)	0.911 (0.008)	0.806 (0.017)	0.621 (0.006)	0.882 (0.013)
D-MPNN	0.823 (0.038)	0.911 (0.048)	0.808 (0.023)	0.610 (0.027)	0.879 (0.040)
HimGNN	0.856 (0.034)	<u>0.928 (0.027)</u>	0.807 (0.017)	0.642 (0.023)	0.917 (0.030)
Mix-Key _{best}	0.849 (0.021)	0.845 (0.034)	<u>0.830 (0.002)</u>	0.640 (0.007)	0.855 (0.022)
DGCL	0.915 (0.017)	0.738 (0.006)	0.772 (0.003)	0.781 (0.022)	0.971 (0.029)
FH-GNN	<u>0.891 (0.008)</u>	0.956 (0.010)	0.842 (0.002)	<u>0.665 (0.008)</u>	<u>0.953 (0.007)</u>

表 3-5 与表 3-6 分别展示了 FH-GNN 在分类任务和回归任务中的性能表现。实验结果表明，本研究所提出的 FH-GNN 模型在分子性质预测任务中展现出显著的竞争优势和技术特色，在 BBBP 和 Tox21 数据集上取得了最佳的预测性能，而在其他数据集中也表现出次优的性能。在分类任务中，FH-GNN 的平均 AUROC 为 0.861，比当前最优方法 DGCL 高 3.11%。值得注意的是，DGCL 在 BBBP 数据集上的性能异常衰减，AUROC 比 FH-GNN 低 22.8%。可能源于其对

血脑屏障穿透相关的复杂立体化学特征捕捉不足，而 FH-GNN 通过分层分子图和指纹特征融合有效克服了这一局限。虽然 FH-GNN 在回归任务中的平均 RMSE 比 Mix-Key 略高，但 FH-GNN 在所有分类数据集上的表现均优于 Mix-Key。这种任务特异性的表现差异揭示了不同方法在特征捕获维度上的本质区别。FH-GNN 具有良好的鲁棒性和泛化能力，能够在不同数据集上保持稳定的性能。

表 3-6 FH-GNN 与基准模型在回归任务中的分子性质预测性能对比

模型	ESOL	FreeSolv	Lipophilicity
AttentiveFP	0.877 (0.029)	2.073 (0.183)	0.721 (0.001)
C-MPNN	0.845 (0.039)	1.833 (0.580)	0.658 (0.029)
MGSSL	1.346	2.980	0.751
Himol _{best}	0.833	2.283	0.708
FP-GNN	1.282 (0.332)	2.492 (0.649)	0.679 (0.152)
GROVER	0.921 (0.092)	2.026 (0.127)	0.646 (0.021)
D-MPNN	0.972 (0.097)	2.170 (0.536)	0.652 (0.051)
HimGNN	0.870 (0.154)	1.921 (0.474)	0.632 (0.016)
Mix-Key _{best}	0.755 (0.031)	1.270 (0.052)	0.737 (0.005)
DGCL	1.046 (0.050)	2.080 (0.027)	0.477 (0.031)
FH-GNN	0.785 (0.017)	<u>1.515 (0.086)</u>	<u>0.604 (0.013)</u>

3.4.2 消融实验结果及分析

为验证 FH-GNN 模型各模块的协同作用，我们设计了 5 种简化的 FH-GNN 变体，在相同实验设置下系统评估各组件对模型性能的贡献度：

FH-GNN_C：去除自适应注意力机制，采用简单串联方式整合分层分子图表示与分子指纹特征。

FH-GNN_F：去除分子指纹编码模块，仅使用分层分子图信息。

FH-GNN_A：构建基于原子的分子图表示，不包含基序信息。

FH-GNN_M：构建基于基序的分子图表示，不包含原子信息。

FH-GNN_E：构建分层分子图时不引入原子-基序边和基序-图边。

图 3-3 展示了 FH-GNN 在分类和回归任务中的消融实验结果。实验结果表明，融合分层分子图表示和分子指纹特征的 FH-GNN 模型在 7/8 数据集中取得了最优性能，验证了各组件间的协同效应。我们从三个角度分析各变体的性能表现。首先，FH-GNN 的表现普遍优于 FH-GNN_C，在分类任务中的平均 AUROC 比 FH-GNN_C 高 1.56%，回归任务中的平均 RMSE 比 FH-GNN_C 低 4.44%。FH-GNN_C 采用静态方式串联所有特征，忽略了特征间的非线性交互，无法适应任务相关的特征偏好。而自适应注意机制的引入使模型能够在各个阶

段为特征分配不同权重，从而更灵活地提取和组合相关信息。其次，在大多数数据集中，基于原子构建的 FH-GNN_A 优于基于基序构建的 FH-GNN_M，说明细粒度的原子特征能提供丰富的表征信息。但在特定任务上，基序之间的空间关系可能更为关键，进一步凸显了原子和基序特征在性质预测中的互补性。最后，FH-GNN_E 在所有基准测试中均出现性能下降的现象，证明了在分子表示学习中建立不同层次之间的连接，实现信息交互的重要性。层次连接允许在原子、基序和分子级别之间交换信息，确保模型全面考虑来自不同层次的信息。上述消融实验验证了 FH-GNN 框架的三个设计原则：动态特征融合优于静态拼接；多尺度建模需兼顾原子与基序特征；层次连接是跨尺度信息传递的关键。总之，我们的消融实验验证了将分层分子图表示与领域知识有效集成，能够显著提升模型在分类和回归任务中的预测性能和鲁棒性。




图 3-3 不同 FH-GNN 变体在(A)分类和(B)回归任务中的性能比较

此外，我们还探索了另外两种不同的碎片化方法：一种是只破坏环外键，保持分子环系统的完整性（FH-GNN_R）；另一种是同时破坏环外键和 BRICS 算法相关的键（FH-GNN_BR），生成更细粒度的分子碎片。图 3-4 展示了在分类和回归任务下，采用不同碎片化方法的实验结果。总体来看，FH-GNN 在分类任务和回归任务中的平均性能始终优于 FH-GNN_R 和 FH-GNN_BR。然而，FH-GNN_R 和 FH-GNN_BR 在特定数据集上表现出色，FH-GNN_R 在 BACE 数据集上性能最佳，AUROC 为 0.932；FH-GNN_BR 在 ClinTox 数据集上性能最佳，AUROC 为 0.974。这些结果表明，不同的碎片化方法的性能因数据集而异，然而，基于 BRICS 算法的碎片化方法在捕捉分子局部结构信息方面表现稳定且优异。




图 3-4 不同碎片化方法在(A)分类和(B)回归任务中的性能比较

3.4.3 可视化分析

为验证 FH-GNN 模型的表征学习能力,我们采用 t 分布随机邻居嵌入 (t-Distributed Stochastic Neighbor Embedding, t-SNE) 技术对 BBBP 和 BACE 数据集的分子表示空间进行可视化分析。图 3-5 展示了在 BBBP 和 BACE 数据集上,分子表示空间在模型训练前后的分布情况。模型训练之前,分子呈随机分布,不同类别之间重叠严重,难以区分。经过 FH-GNN 模型训练后,不同类别之间分离明显,聚类中心明确,正负标签的分子分别聚集在左上角和右下角。经过 HimGNN 模型训练后,不同类别的分子也显示出一定的分离趋势,但大多数分子仍呈现混沌和重叠的状态。可视化结果表明, FH-GNN 在捕捉分子的结构与物理化学性质关联方面具有显著优势,实现了对不同类别分子的有效区分。




图 3-5 分子表示空间的可视化分析。(A) BBBP 数据集和(B) BACE 数据集的分子表示空间的可视化结果。左列展示了初始分子表示空间，中列和右列分别展示了经过 FH-GNN 和 HimGNN 训练后的分子表示空间。图中橙色点表示正标签，蓝色点表示负标签。

3.4.4 案例及解释性分析

为探究 FH-GNN 的决策机制，我们从 BBBP 数据集中选取了两个典型分子，开展了基于注意力权重的可解释性分析。血脑屏障数据集提供了各类化合物的血脑屏障通透性信息，准确预测分子的血脑屏障通透性对于开发中枢神经系统药物以及规避相关副作用和毒性风险至关重要。图 3-6 展示了在不同模型中，各分子组分对血脑屏障通透性预测的贡献。与上面消融实验一致，FH-GNN_A 表示基于原子构建的分子图，FH-GNN_M 表示基于基序构建的分子图，FH-GNN 表示基于分层分子构建的分子图。在图中，蓝色区域表示有利于分子通过血脑屏障的原子，而红色区域则表示对通透性具有负面影响的原子。颜色越深，表示该区域在预测分子是否能穿过血脑屏障时的重要性越高。需要指出的是，由于分子指纹编码模块无法在原子层面获得表示，本次实验均基于分层分子图表示模块进行。




图 3-6 不同模型对 BBBP 数据集中两个典型分子的可解释性分析结果。(A) 能够穿透血脑屏障的分子；(B) 无法穿透血脑屏障的分子。图中蓝色表示对分子穿透血脑屏障具有促进作用的原子，红色表示对分子通透性具有抑制作用的原子。颜色深度与注意力权重的绝对值成正比，颜色越深表示该原子在模型决策中的重要性越高。

基于图 3-6 的案例研究，我们深入分析了分子结构特征与血脑屏障通透性之间的关系，揭示了 FH-GNN 模型在分子性质预测中的化学可解释性。图 3-6A 是一个可以穿过血脑屏障的例子，结果显示疏水性硝基咪唑支架是主要贡献者，其次是氯原子。硝基中的氧原子虽然在一定程度上限制了分子穿透屏障的能力，但其影响较为有限。这一观察与已知的药物化学理论一致：疏水性分子通常更容易穿透血脑屏障。硝基咪唑支架通过增强分子脂溶性显著促进了分子的通透性，氯原子则进一步强化了这一效果。相比之下，图 3-6B 中的分子由于含有多个亲水性基团（如羧基、醚基、哌嗪环），表现出较低的通透性。这些亲水性基团通过增加分子极性、形成分子内氢键以及提高水合自由能，显著阻碍了分子穿透血脑屏障的能力。尽管苯环在一定程度上提供了局部疏水性，但其促进作用被强极性基团所抵消。

在不同模型的对比中，大部分原子的贡献是一致的，只有少数原子表现出冲突的现象，例如，羟基在 FH-GNN_A 模型中显示出阻碍作用，而在 FH-GNN_M 模型中则表现为促进作用。这种差异反映了单一尺度建模的局限性，原子级模型能够精确捕捉局部化学环境，但可能忽略长程相互作用；而基序级模型虽然能够捕获功能基团的空间排列模式，却可能过度简化局部化学细节。FH-GNN 通过分层分子图整合了原子与基序信息，使得注意力权重的分配更加合理，从而提供了更具判别性的分子表征。这些发现不仅为我们理解分子的结构与血脑屏障通透性之间的关系提供了有价值的见解，也为中枢神经系统药物的研发提供了重要参考。

3.5 本章小结

本章提出了指纹增强分层图神经网络，旨在通过分层分子图与分子指纹的多尺度特征融合，解决现有分子表征方法在捕获复杂分子特征时的局限性。FH-GNN 利用自适应注意机制，动态整合分层分子图表示和分子指纹特征，生成具有任务自适应性的分子表征。通过分层分子图表示模块，FH-GNN 能够同时捕获原子级、基序级、分子级的多尺度拓扑信息；分子指纹编码模块则利用化学领域的先验知识，进一步增强了功能基团的表征能力。在 MoleculeNet 的 8 个基准数据集上的实验结果表明，FH-GNN 在分子性质预测的分类和回归任务上都优于基线模型，验证了全面捕获分子信息的能力。同时，模型中注意力权重的可视化为分子结构与物理化学性质之间的关系提供了直观解释，为药物设计与优化提供了有力参考。总之，FH-GNN 通过领域知识嵌入与层次化特征提取的协同作用，既弥补了传统图神经网络在捕捉分子功能信息上的不足，又通过多尺度建模提高了对分子细微结构差异的敏感性。FH-GNN 不仅提升了分子性质预测的准确性，还增强了模型的可解释性与鲁棒性，为分子表示学习与药物发现研究提供了新的方法论支持。

第四章 基于领域通用和领域特定特征的药物-靶标相互作用预测

4.1 研究背景

药物-靶标相互作用 (Drug-Target Interaction, DTI) 预测是药物发现的核心任务之一, 其目标是通过预测药物分子与靶标蛋白之间的结合能力, 筛选出高亲和力的候选化合物^[156-159]。湿实验方法虽然精度高, 但耗时耗力且成本高昂, 严重限制了在大规模药物筛选中的应用^[160]。近年来, 深度学习技术凭借其强大的特征学习能力在 DTI 预测中取得了显著进展。然而, 化学空间中化合物的总数极其庞大, 而已知的药物-靶标相互作用数据占比微乎其微^[161-163]。基于如此有限的已知数据训练的模型, 在面对分布外 (Out Of Distribution, OOD) 数据时, 往往难以实现有效的泛化。因此, 如何提升模型在 OOD 数据上的泛化能力, 仍然是当前 DTI 预测研究中的重大挑战。

为了应对这一挑战, 研究人员致力于开发具备强大泛化能力的模型, 以准确预测训练数据中未出现的药物-靶标对的相互作用^[164-167]。其中, 一种值得关注的方法是通过学习领域通用特征来提升模型的跨领域泛化能力^[168]。条件域对抗网络 (Conditional Domain Adversarial Network, CDAN) 通过对抗训练的方式最小化领域分布差异, 学习领域通用特征, 提升跨领域泛化能力^[169]。基于分歧的多样性训练 (Diversity-by-Disagreement Training, BAT) 方法通过在训练数据上强制模型达成一致, 而在测试数据上鼓励模型产生分歧, 促进模型学习多样化的领域通用特征^[170]。然而, 研究表明^[171-173], 在边缘标签分布差异显著的领域中, 单纯依赖领域通用特征会导致模型学习到伪特征。这些特征虽然在训练数据中表现良好, 但在 OOD 数据上往往失效, 进而导致模型性能下降。因此, 尽管领域通用特征的学习对于提升模型泛化能力至关重要, 但其本身并不足以保证模型在 OOD 数据上的成功泛化。

与此同时, 通过引入领域特定特征, 模型能够更有效地识别各领域独特的模式, 从而在相应领域的预测中取得更高的准确性^[174]。基于这一理念, 混合专家网络 (Mixture Of Experts, MOE) 作为一种广受欢迎的领域特定特征提取器, 在多种任务中取得了显著成功^[167]。在 MOE 框架下, 输入数据经过门控网络动态分配到各个专家模型中, 每个专家模型专注于处理特定领域的的数据, 从而高效提取与该领域密切相关的特征。近期研究表明, MOE 相较于传统神经网络展现出更强大的泛化能力, 尤其是在已知的数据规模增加时, 其性能提升更为显著^[175-177]。尽管 MOE 在多个领域取得了成功, 然而目前尚未有研究系统探索其

在 DTI 预测任务中的应用潜力。

本研究针对上述 DTI 预测任务中模型泛化能力不足的问题，提出了一种融合领域通用特征提取器与领域特定特征提取器的框架（Ensembles of Domain-Generic Feature Extractors and Domain-Specific Feature Extractors, E-DIS）。通过双分支架构实现了对全局共性特征和局部特异性特征的协同学习，突破了传统模型对单一特征依赖的局限性。通过一个可训练的门控网络，将训练集划分为多个领域，并在每个领域上分别训练专家网络，以捕获和对齐领域特定特征。E-DIS 直接将 MOE 应用于原始数据的特征提取，避免了编码器在学习过程中丢失关键特征。本研究首次在 DTI 预测任务中同时建模领域通用特征和领域特定特征，通过融合多样化的领域信息，更全面地刻画药物与靶标之间复杂的相互作用。为了验证 E-DIS 框架的有效性，我们在一系列 DTI 预测任务上，将 E-DIS 框架与基线模型进行了比较。结果表明，无论是在领域内还是跨领域的实验设置下，引入 E-DIS 框架后，模型在 DTI 预测任务中的性能均得到了显著提升。同时，在冷启动和基于聚类的分割设置下的结果表明，E-DIS 不仅显著提升了模型对新颖药物-靶标对的预测能力，而且在无需访问 OOD 数据的情况下，依然能够保持优异的表现。

4.2 算法运行设置

4.2.1 数据集

本研究选取了四个数据集对模型在分类任务和回归任务中的表现进行评估，各数据集的统计信息见表 4-1。在回归任务中，我们沿用了 DeepDTA^[58]研究中的基准数据集，即 Davis^[178]和 KIBA^[179]数据集。其中，Davis 数据集涵盖了 68 种药物与 442 个靶标间的 30056 个相互作用对，其结合亲和力通过解离常数（Kd）值进行量化，并进一步转换为 pKd 值用于预测，pKd 值的分布范围为 5.0 至 10.8。KIBA 数据集则包含了 2111 种药物与 229 个靶点间的 118254 个相互作用对，其结合亲和力采用 KIBA 评分^[179]来表征，该评分综合了 Kd、抑制常数（Ki）和半数抑制浓度（IC50）等多种异构信息源，评分范围为 0.0 至 17.2。在分类任务方面，我们采用了两个在 DTI 领域广泛认可的数据集：BindingDB^[180]和 BIOSNAP^[30, 181]。BindingDB 数据集由 Bai 等人^[180]基于 BindingDB 数据库精心构建，降低了数据偏差。在该数据集中，药物-靶标对的标签依据其 IC50 值进行划分：若 IC50 值低于 100 nM，则判定为正样本；若 IC50 值高于 10000 nM，则判定为负样本。BIOSNAP 数据集则由 Huang 等人^[30]从 DrugBank 数据库中提取并构建，该数据集正负样本数量平衡。针对数据集中

的冗余问题，我们制定了严格的清洗规则：对于蛋白质、配体及标签完全一致的重复实例，仅保留其中之一；而对于标签存在冲突的重复实例，则予以全部剔除，以确保数据的纯净性和可靠性。

表 4-1 E-DIS 工作所使用数据集的统计信息

数据集	任务类型	药物数目	靶点数目	相互作用数目
Davis	回归任务	68	442	30056
KIBA	回归任务	2111	229	118254
BindingDB	分类任务	14643	2,623	49199
BIOSNAP	分类任务	4510	2181	27464

4.2.2 评价指标

在模型性能评估方面，本研究针对不同任务类型采用差异化的评价指标体系。在回归任务的模型评估中，我们采用了多项指标以全面衡量模型的预测性能。具体而言，这些指标包括均方误差（Mean Squared Error, MSE）、平均绝对误差（Mean Absolute Error, MAE）、一致性指数（Concordance Index, CI）^[182]、修正平方相关系数（Modified Squared Correlation Coefficient, r_m^2 ）^[183]以及 Pearson 相关系数（Pearson Correlation Coefficient, Rp）。MSE 和 MAE 分别通过平方误差和绝对误差的形式量化了预测值与真实值之间的偏离程度。MSE 因对误差项进行了平方运算而对异常值更为敏感，而 MAE 则提供了更为直观的误差解释。CI 指标专注于评估模型在预测值排序上的准确性，从而补充了 MSE 在排序性能评估上的不足。 r_m^2 指标进一步拓展了评估维度，用于检验模型在 OOD 数据集上的泛化能力。同时，Rp 作为衡量变量间线性关系强度的经典指标，为模型预测的线性相关性提供了量化依据。

在分类任务的模型评估中，我们精心选取了 AUROC、精确召回曲线下面积（Area Under the Precision-Recall Curve, AUPRC）、准确率、敏感性和特异性等关键指标。AUROC 通过量化真阳性率与假阳性率之间的权衡关系，评估模型在类别区分任务中的判别能力；而 AUPRC 则聚焦于精确度与召回率之间的平衡，深入揭示了模型在正样本识别上的精确程度。这两项指标的值越大，均表明模型的整体性能越优越。准确率作为直观的分类正确率指标，反映了模型在整体样本上的分类准确性。此外，敏感性和特异性分别从正样本和负样本的识别角度，细致刻画了模型在不同类别上的分类效果，为模型的全面评估提供了多维度的量化支持。

4.2.3 基线模型

我们采用了多种基线模型与 E-DIS 框架进行对比，全面评估 E-DIS 框架在

回归任务和分类任务中的预测性能。这些基线模型涵盖了多种表征策略和深度学习架构，主要可分为四类。第一类是基于序列的模型，主要依赖蛋白质序列和配体 SMILES 进行特征提取，包括 DeepDTA[124]、WideDTA[132]和 DeepAffinity[133]。DeepDTA 利用卷积神经网络分别从蛋白质氨基酸序列和配体 SMILES 字符串中提取特征，并通过特征拼接实现 DTI 预测。WideDTA 通过多源文本信息捕捉药物-靶标局部功能特征，进而预测结合亲和力。DeepAffinity 通过创新的序列表示和半监督学习框架，联合利用未标记数据和标记数据，捕捉蛋白质和配体的长期非线性依赖关系。第二类是基于图神经网络的模型，通过图神经网络建模药物和靶标的结构信息，包括 GraphDTA[134]、MGraphDTA[135]和 DGraphDTA[43]。GraphDTA 将药物分子表示为图结构，并利用图卷积网络提取特征，实现 DTI 预测。MGraphDTA 基于化学直觉构建深度多尺度图神经网络，通过密集连接结构提高网络深度，同时捕捉化合物的局部和全局结构信息。DGraphDTA 利用图神经网络分别编码药物分子图和基于蛋白质序列预测的接触图，实现 DTI 预测。第三类是基于 Transformer 的模型，该类模型借助 Transformer 强大的特征建模能力预测 DTI，其中代表性模型为 MolTrans[27]。MolTrans 采用知识驱动的子结构挖掘算法和增强的 Transformer 编码器，结合大规模未标记数据，捕捉子结构之间复杂的语义关系。第四类是基于注意力机制的模型，主要依赖注意力机制进行特征融合，包括 DrugBAN[128]和 BINDTI[136]。DrugBAN 基于双向注意力网络和条件域对抗学习，通过显式捕捉局部相互作用并进行跨域特征对齐，提升模型的泛化能力。BINDTI 通过图卷积网络编码药物分子图，通过混合模型编码蛋白质序列，并利用注意力机制融合药物与靶标特征。

此外，在 E-DIS 框架的泛化性评估中，我们选取了两类常用的领域自适应方法作为基线模型：CDAN[115]和 BAT[116]。这两类方法分别从特征对齐和多样性学习两个角度提升模型的泛化能力，为 E-DIS 的性能对比提供了重要参考。CDAN 通过对抗训练的方式最小化领域分布差异，利用特征表示与分类器预测的交叉协方差，实现精准的领域对齐，从而提升模型在不同数据分布下的泛化能力。BAT 则通过在训练数据上强制模型达成一致，而在测试数据上鼓励模型产生分歧，促进模型学习多样化的预测特征。上述基线模型在特征表示、交互建模和模型解释性方面各有优势，为 E-DIS 的性能评估提供了多维度的对比基准。

4.2.4 参数设置

本研究中的 E-DIS 框架采用 MindSpore 实现，并利用 Adam 优化器^[155]更新

模型参数，权重衰减率为 $1e-5$ 。在 Davis 和 KIBA 数据集上，我们将模型训练了 2000 轮，而在 BindingDB 和 BIOSNAP 数据集上则训练了 100 轮。不同模型的训练参数设置如表 4-2 所示。

为保障实验的高效运行与结果的可重复性，E-DIS 框架的实验环境配置如下：实验硬件平台采用 Atlas 800-9000 高性能服务器，配备 Ascend 910 神经网络处理器和 32GB DDR4 内存。软件环境基于 MindSpore 2.0 深度学习框架构建，具体包括：Python 3.9 作为编程语言，RDKit 2023.3 用于分子结构处理，Numpy 1.21 和 Pandas 1.3 用于数据处理与分析。所有实验均在 CANN 7.1 环境下执行，以充分发挥硬件加速能力，提升计算效率。

表 4-2 不同模型的超参数配置表

模型	批次大小	学习率	配体特征维度	蛋白特征维度	多尺度块数目	过滤层数
MGraphDTA	512	$5e-4$	22	26	3	32
MGraphDTA_P	512	$5e-4$	22	33	3	32
E-DIS _{MGraphDTA_P}	512	$5e-4$	22	33	3	32

模型	批次大小	学习率	配体特征维度	蛋白特征维度	嵌入维度	注意力头数
MolTrans	32	$1e-4$	23532	16693	384	12
E-DIS _{MolTrans}	32	$1e-4$	23532	16693	384	12

模型	批次大小	学习率	配体特征维度	蛋白特征维度	嵌入维度	隐藏层维度
DrugBAN	32	$1e-4$	75	128	128	512
E-DIS _{DrugBAN}	32	$1e-4$	75	128	128	512

模型	批次大小	学习率	配体特征维度	蛋白特征维度	ACmix 层数	GCN 层数
BINDTI	64	$1e-4$	128	128	3	3
E-DIS _{BINDTI}	64	$1e-4$	128	128	3	3

4.3 方法描述

4.3.1 E-DIS 框架概述

图 4-1 展示了 E-DIS 框架的整体流程。首先利用完整的训练集对领域通用特征提取器进行训练，从数据中捕获通用的分子特征。随后，通过引入包含多个专家网络和门控网络的 MOE 模型，E-DIS 框架加强了对领域特定特征的学习。在这一过程中，门控网络扮演着关键角色，它依据领域通用特征提取器所提供

的特征，智能地将输入数据分配给擅长处理该数据的专家网络。专家网络直接从原始数据中进行特征提取，避免了编码器在学习过程中丢失关键特征。值得注意的是，专家网络可以采用任意的 DTI 预测模型。最终，E-DIS 框架综合领域通用特征提取器和领域特定特征提取器的预测值，通过加权平均的方式得到最终的 DTI 预测结果。




图 4-1 E-DIS 框架示意图

4.3.2 领域通用特征提取器

领域通用特征提取器是 E-DIS 框架的核心模块之一，其灵活性体现在可采用任意适用于 DTI 预测的神经网络结构，并利用全部训练数据集进行参数优化。在本研究中，领域通用特征提取器采用无交互模型，分别对小分子药物和蛋白质靶标进行编码，随后通过拼接操作将二者的表示向量整合为统一的领域通用特征 f 。具体过程如下：

$$f = D(x_d, x_p) \quad (4-1)$$

式中： x_d 表示药物分子初始特征， x_p 表示蛋白靶标初始特征， D 表示可学习的领域通用特征提取器。

领域通用特征在框架内发挥了多重关键作用，不仅为 DTI 预测提供了全局基础，还为后续的领域划分和专家网络选择奠定了重要支撑。具体而言，领域通用特征后续被直接输入至全连接层，用于预测药物与靶标之间的相互作用关系。通过对整个训练数据的学习，该特征能够有效捕捉数据中广泛存在的共性模式，为 DTI 预测任务提供稳定且可靠的全局表征基础。除了直接用于预测外，领域通用特征还作为门控网络的输入，用于建模药物-靶标对的潜在表示空间。门控网络通过分析领域通用特征，动态判断当前输入数据应分配至哪个专家网络进行下一步的特征提取与处理，从而实现领域特定特征的精准捕捉。

4.3.3 领域特定特征提取器

在 E-DIS 框架中,领域特定特征提取器通过 MOE 模型实现,其核心目标是捕获不同领域的特异性特征。与传统深度学习模型依赖单一神经网络处理所有输入数据不同,MOE 模型采用多个专家网络,实现领域特定特征的精细建模。MOE 模型将数据集划分为若干特定子集,并为每个子集配备一个专门的专家网络。在训练和推理过程中,MOE 模型能够根据输入数据的领域通用特征以及门控网络的专业判断,动态激活最适合的专家网络,从而提升模型对数据特定特征的捕捉能力。

MOE 模型的运行机制主要依赖于专家网络的专项处理、门控网络的智能分配以及输出结果的加权集成三个关键步骤。MOE 模型包含一组专家网络,每个专家网络专注于处理数据集中的特定部分,即某一领域的子集。在本研究中,我们配置了三个专家网络,但需要强调的是,专家网络的数量和具体架构可以根据任务需求灵活调整。每个专家网络拥有独立的、可训练的权重参数。尽管在本研究中所有专家网络采用了相同的架构设计,但理论上它们可以具备不同的网络结构,仅需保证输入和输出维度相同即可。这种设计灵活性使得 MOE 模型能够针对不同领域的特征进行专项优化,从而提升其在特定任务中的表现。门控网络在 MOE 模型中起到了关键作用,它根据领域通用特征提取器获得的特征,将原始数据智能地分配给最适合的专家网络。与直接使用特征表示作为专家网络输入的传统方法不同,本研究创新性地将原始数据作为专家网络的输入。这种设计避免了在特征提取过程中丢失有价值的信息,确保专家网络能够直接从原始数据中挖掘领域特定特征,从而提升模型对细节的敏感度和整体准确性。通过对所有专家网络输出进行加权集成得到 MOE 模型的最终输出。每个专家的输出权重是门控网络 G 根据领域通用特征 f 计算得到。具体过程如下:

$$y = \sum_{i=1}^n G(f)_i E_i(x_d, x_p) \quad (4-2)$$

式中: $G(f)_i$ 表示第 i 个专家网络对输出向量的贡献权重, $E_i(x_d, x_p)$ 表示第 i 个专家网络的输出。通过这种加权集成机制,MOE 模型能够综合各个专家网络的专项知识,形成对输入数据的全面表征,从而显著增强模型对复杂数据模式的建模能力。

4.4 结果与讨论

为全面评估 E-DIS 框架的性能及其在不同场景下的泛化能力,本研究设计并实施了两种互补的实验策略:领域内设置策略和跨领域设置策略。这两种策略分别从标准评估和真实应用的角度出发,旨在为模型的性能提供多维度的验

证。在领域内设置下，我们将数据集随机划分为训练集和测试集。这种随机划分的方式因简单易行，而在学术研究中较为常见。然而，由于潜在的信息泄露问题，随机划分可能会导致实验结果过于乐观，无法真实反映 DTI 预测模型在实际预测任务中的表现。在现实应用中，需要预测的药物-靶标对通常是训练数据中未曾出现的全新组合，化学空间的广度和复杂性对模型的泛化能力提出了更高要求。因此，为了更准确地模拟实际药物发现场景，验证 E-DIS 框架在 OOD 数据的泛化能力，我们采用了跨领域设置。在该设置中，我们采取了严格的措施，确保药物和靶标的结构信息不会从训练集泄露至测试集。这种设计不仅提高了实验的挑战性，还构建了一个更接近真实预测需求的评估环境。跨领域设置通过避免信息泄露，有效评估了 E-DIS 框架在 OOD 数据上的表现，为其在实际药物筛选中的潜力提供了有力证据。

4.4.1 领域内设置下性能测试结果及分析

4.4.1.1 回归任务

在回归任务中，我们将提出的 E-DIS 框架应用于 GraphDTA、MGraphDTA 和 DGraphDTA 三个模型，并与多个基准模型（包括 DeepDTA、WideDTA、GraphDTA、DeepAffinity、MGraphDTA 和 DGraphDTA）进行了系统的性能比较。通过深入分析现有模型的表征方式，我们发现大多数基准模型仅采用氨基酸类型对蛋白质序列进行表征，这种单一的表征方式难以全面捕捉蛋白质的复杂特性，从而限制了模型的预测性能。值得注意的是，DGraphDTA 模型创新地引入了基于 R 基团的附加属性（包括极性、分子量、带电性和芳香性等），这一改进显著提升了蛋白质表征的丰富度，进而提高了模型的预测精度。基于这一发现，本研究对 MGraphDTA 的蛋白质表示模块进行了优化，在保持模型其他部分与原始 MGraphDTA 一致性的基础上，整合了基于 R 基团的蛋白质特征。我们将优化后的模型命名为 MGraphDTA_P。这一改进策略旨在增强模型对蛋白质物理化学性质的表征能力，从而提升其在 DTI 预测任务中的性能。为确保性能比较的公平性与科学性，我们在 Davis 和 KIBA 数据集上采用了与先前研究^[58-60, 66, 136, 184]完全相同的训练集和测试集划分方案。此外，为了评估模型的稳健性，所有实验均使用不同随机种子重复进行了三次，通过多次实验结果的平均值来降低随机性带来的影响，从而为模型性能的客观评价提供可靠依据。

表 4-3 与图 4-2 展示了 E-DIS 框架与基线模型在 Davis 和 KIBA 数据集上的表现。结果表明，基于图神经网络的模型（GraphDTA、DGraphDTA、MGraphDTA）在各项指标上均优于基于序列的模型（DeepDTA、WideDTA 和 DeepAffinity），这一结果充分验证了图神经网络在 DTI 任务中的表征优势。进

一步分析发现,改进后的 MGraphDTA_P 模型通过引入蛋白质的性质特征,预测性能较原始 MGraphDTA 模型实现了稳定提升,证实了丰富蛋白质表征策略的有效性。同时, DGraphDTA 模型通过整合蛋白质的空间结构信息,在 Davis 和 KIBA 两个基准数据集上均表现出优异的性能。然而,尽管 E-DIS_{MGraphDTA_P} 模型并未利用蛋白质的空间结构信息,但其在所有评估指标上均优于其他对比模型,表明 E-DIS 框架通过融合领域通用特征与领域特定特征,实现了对药物和靶标的全面表征。

表 4-3 领域内设置下不同模型在 Davis 和 KIBA 数据集上的性能比较

模型	MSE↓	MAE↓	CI↑	r_m^2 ↑	Pearson↑
Davis					
DeepDTA	0.261		0.878	0.630	
WideDTA	0.262		0.886		0.820
GraphDTA	0.229		0.893		
DeepAffinity	0.253		0.900		
DGraphDTA	<u>0.202(0.002)</u>	0.294(0.001)	<u>0.903(0.005)</u>	0.708(0.007)	0.867(0.005)
MGraphDTA	0.207(0.001)	0.286(0.000)	0.900(0.004)	<u>0.710(0.005)</u>	<u>0.871(0.007)</u>
MGraphDTA_P	0.206(0.002)	<u>0.283(0.001)</u>	0.901(0.004)	0.709(0.003)	0.864(0.003)
E-DIS _{MGraphDTA_P}	0.193(0.001)	0.277(0.001)	0.909(0.002)	0.732(0.003)	0.889(0.005)
KIBA					
DeepDTA	0.194		0.863	0.673	
WideDTA	0.179		0.875		0.856
GraphDTA	0.139		0.891		
DeepAffinity	0.188		0.842		
DGraphDTA	<u>0.124(0.001)</u>	0.212(0.001)	0.904(0.001)	0.786(0.001)	0.903(0.004)
MGraphDTA	0.128(0.001)	0.221(0.001)	0.902(0.001)	<u>0.801(0.001)</u>	<u>0.914(0.003)</u>
MGraphDTA_P	<u>0.124(0.001)</u>	<u>0.208(0.000)</u>	<u>0.906(0.001)</u>	0.794(0.002)	0.909(0.006)
E-DIS _{MGraphDTA_P}	0.113(0.001)	0.193(0.002)	0.911(0.001)	0.811(0.001)	0.925(0.005)

如图 4-2 所示,所有基线模型在引入 E-DIS 框架后,其预测性能均取得了显著提升。为验证性能改进的统计学显著性,我们基于 MSE 指标对模型引入 E-DIS 框架前后的性能差异进行了 t 检验,具体结果如表 4-4 所示。统计分析表明,在 95%的置信区间,应用 E-DIS 框架前后模型的性能差异均具有统计学显著性 ($p < 0.05$)。具体而言,在 Davis 数据集上,GIN 模型在使用 E-DIS 框架后性能提升最为显著,其 MSE 值降低了 10.6%;而在 KIBA 数据集上, MGraphDTA_P 模型的改进最为突出,其 MSE 值降低了 6.7%。这些实验结果充分证实了 E-DIS 框架在提升 DTI 预测性能方面的有效性和普适性。




图 4-2 领域内设置下在(A) KIBA 和(B)Davis 两个数据集上模型引入 E-DIS 框架前后的性能比较

表 4-4 在 Davis 和 KIBA 数据集上基于 MSE 指标对模型引入 E-DIS 框架前后性能差异的统计分析结果

模型	Davis			KIBA		
	下降率	t 统计量	p 值	下降率	t 统计量	p 值
DGraphDTA	6.0%	2.284	0.035	3.1%	4.041	<0.01
MGraphDTA_P	9.7%	9.137	<0.001	6.7%	10.333	<0.001
GCN	9.4%	10.5	<0.001	5.8%	9.326	<0.001
GAT	9.9%	3.284	<0.01	3.1%	8.584	<0.001
GIN	10.6%	6.628	<0.001	5.6%	9.822	<0.001
GAT_GCN	8.5%	4.427	<0.01	5.6%	4.143	<0.01

4.4.1.2 分类任务

为了全面评估 E-DIS 框架在不同任务场景下的适应性与性能优势,本研究进一步将 E-DIS 框架应用于 BindingDB 和 BIOSNAP 两个分类数据集,并与现有基准模型进行了性能对比。其中,基准模型的性能数据均直接引用自相关文

献^[30, 181, 184, 185]的公开结果。为确保实验结果的可靠性与可重复性，所有实验均在相同条件下重复进行三次，并计算了预测结果的均值与标准差，以评估模型的稳定性。

图 4-3 与表 4-5 展示了 E-DIS 框架与基线模型在 BindingDB 和 BIOSNAP 分类数据集上的预测性能对比结果。实验结果表明，所有模型在引入 E-DIS 框架后，其预测性能均得到了显著提升，这一结果充分验证了领域通用特征与领域特定特征协同学习策略的有效性。具体而言，E-DIS_{DrugBAN} 模型在两个数据集上均表现出最优性能：在 BindingDB 数据集上，其 AUROC 评分达到 0.971；在 BIOSNAP 数据集上，其 AUROC 评分为 0.921。值得注意的是，在领域内设置下，所有模型在两个数据集上均表现出优异的性能，特别是在 BindingDB 数据集上，所有模型的 AUROC 值均超过了 0.95。这一现象表明，领域内设置可能会导致测试集中的信息泄露，从而使得模型的性能评估结果过于乐观，无法真实反映模型在实际应用场景中的预测能力。为克服领域内设置带来的评估局限性，并更严格地验证模型的泛化能力，本研究在分类任务中额外采用了跨领域设置策略。该策略通过构建更具挑战性的评估场景，能够更准确地反映模型在真实应用环境中的预测效果，从而为 E-DIS 框架及其对比模型的性能评估提供更加可靠的依据。




图 4-3 领域内设置下在(A) BindingDB 和(B) BIOSNAP 数据集上模型引入 E-DIS 框架前后的性能比较

表 4-5 领域内设置下不同模型在 BindingDB 和 BIOSNAP 数据集上的性能比较

模型	AUROC	AUPRC	准确性	敏感性	特异性
BindingDB					
GraphDTA	0.951(0.002)	0.934(0.002)	0.888(0.005)	0.882(0.012)	0.897(0.008)
MolTrans	0.952(0.002)	0.936(0.001)	0.887(0.006)	0.877(0.016)	0.902(0.009)
DrugBAN	<u>0.960(0.001)</u>	<u>0.948(0.002)</u>	<u>0.904(0.004)</u>	<u>0.900(0.008)</u>	<u>0.908(0.004)</u>
BINDTI	0.958(0.001)	0.944(0.002)	0.902(0.004)	0.899(0.013)	0.907(0.012)
MGraphDTA_P	0.958(0.001)	0.942(0.002)	0.901(0.002)	0.894(0.005)	0.907(0.009)
E-DIS _{MGraphDTA_P}	0.966(0.000)	0.954(0.001)	0.913(0.001)	0.915(0.010)	0.920(0.013)
BIOSNAP					
GraphDTA	0.887(0.008)	0.890(0.007)	0.800(0.007)	0.745(0.032)	<u>0.854(0.025)</u>
MolTrans	0.895(0.004)	0.897(0.005)	0.825(0.010)	0.818(0.031)	0.831(0.013)
DrugBAN	<u>0.903(0.005)</u>	0.902(0.004)	<u>0.834(0.008)</u>	<u>0.820(0.021)</u>	0.847(0.010)
BINDTI	<u>0.903(0.003)</u>	0.903(0.007)	<u>0.834(0.004)</u>	0.819(0.010)	0.849(0.004)
MGraphDTA_P	0.901(0.004)	<u>0.903(0.006)</u>	0.827(0.003)	0.801(0.017)	0.852(0.015)
E-DIS _{MGraphDTA_P}	0.914(0.002)	0.919(0.004)	0.839(0.002)	0.832(0.018)	0.864(0.012)

4.4.2 跨领域设置下性能测试结果及分析

在领域内设置下，由于训练集与测试集中可能存在相似或相同的药物分子和靶标蛋白，导致数据间存在信息泄露的风险，使得 DTI 预测任务的结果过于乐观，难以真实反映模型处理 OOD 数据时的实际能力。为模拟真实药物发现场景，本研究进一步采用跨领域设置，以更严格地评估模型的泛化能力。在跨领域设置中，我们参考已有研究的设计，实施了两种评估策略：冷启动策略^[65, 186]和基于聚类分割策略^[181]。冷启动策略通过确保测试集中的药物或蛋白质均未出现在训练集中，严格隔离训练与测试数据，从而有效避免了信息泄露问题。这种策略能够更真实地评估模型在面对全新药物-靶标对时的预测能力，为模型在实际应用中的性能提供了可靠的评估依据。基于聚类分割策略则通过聚类分析将数据划分为分布不同的训练集和测试集，模拟了真实场景中数据分布的异质性。这种策略进一步增加了实验的挑战性，旨在检验模型在面对分布差异的数据时的适应性与鲁棒性。通过上述两种跨领域设置，本研究不仅有效克服了领域内设置可能带来的评估偏差，还为 E-DIS 框架在真实预测场景中的性能提供了全面验证。冷启动策略侧重于评估模型对全新药物或靶标的预测能力，而基于聚类分割策略则着重考察模型在数据分布差异下的表现。这两种策略的结合使用，确保了实验结果能够更准确地反映模型在未知数据上的泛化性能，为 DTI 预测模型的实际部署提供了重要的理论依据和实践参考。

4.4.2.1 冷启动策略

为评估模型在跨领域场景下的预测性能，本研究在 BindingDB 和 BIOSNAP 两个数据集上实施了冷启动策略，并设计了三种不同的数据划分方式，以系统检验模型在不同冷启动场景下的适应能力。具体划分方式如下：

药物冷启动：测试集中的所有药物均未在训练集中出现，旨在模拟模型对全新药物的预测能力。这种设置能够有效评估模型在面对未知药物时的泛化性能。

靶标冷启动：测试集中的所有靶标均未在训练集中出现，用于评估模型对未知靶标的预测能力。这种设置能够检验模型在靶标信息缺失情况下的表现。

药物-靶标冷启动：测试集中的药物和靶标均未在训练集中出现，最大限度地模拟了真实应用场景中对全新药物-靶标对的预测需求。

具体而言，我们随机抽取 10% 的药物或靶标作为测试集，并确保与其相关的所有药物或靶点均从训练集中移除，以严格避免信息泄露。在此基础上，我们对比了基准模型（包括 MGraphDTA_P、MolTrans、BINDTI 和 DrugBAN）在引入 E-DIS 框架前后的性能表现。为确保实验的公平性与可重复性，所有模型

均采用相同的训练集和测试集，并在相同实验条件下重复运行三次，以计算性能指标的均值与标准差，从而获得稳健的评估结果。

图 4-4 和表 4-6 展示了在冷启动设置下三组实验的详细结果。实验结果表明，与领域内设置相比，冷启动划分策略下的模型预测性能普遍下降，这一现象验证了冷启动设置能够更真实地模拟实际应用场景中模型面对全新药物-靶标对时的性能表现。值得注意的是，在引入 E-DIS 框架后，四种基线模型在三种冷启动设置下均展现出不同程度的性能提升。

表 4-6 药物冷启动、靶标冷启动、药物-靶标冷启动设置下不同模型在 BindingDB 和 BIOSNAP 数据集上的性能比较

模型	BindingDB		BIOSNAP	
	AUROC	AUPRC	AUROC	AUPRC
药物冷启动				
MGraphDTA_P	0.952(0.002)	0.929(0.004)	0.864(0.005)	0.877(0.003)
E-DIS _{MGraphDTA_P}	0.961(0.002)	0.944(0.002)	0.877(0.004)	0.891(0.004)
MolTrans	0.949(0.002)	0.932(0.001)	0.846(0.002)	0.864(0.006)
E-DIS _{MolTrans}	0.954(0.002)	0.939(0.003)	0.865(0.003)	0.887(0.003)
BINDTI	0.959(0.003)	0.943(0.001)	0.857(0.003)	0.870(0.005)
E-DIS _{BINDTI}	0.969(0.001)	0.959(0.001)	0.881(0.000)	0.896(0.002)
DrugBAN	<u>0.964(0.002)</u>	<u>0.952(0.002)</u>	<u>0.880(0.005)</u>	<u>0.892(0.003)</u>
E-DIS _{DrugBAN}	0.969(0.001)	0.959(0.001)	0.897(0.002)	0.911(0.003)
靶标冷启动				
MGraphDTA_P	<u>0.703(0.018)</u>	<u>0.748(0.008)</u>	<u>0.778(0.002)</u>	<u>0.819(0.006)</u>
E-DIS _{MGraphDTA_P}	0.748(0.017)	0.786(0.013)	0.801(0.004)	0.841(0.005)
MolTrans	0.664(0.006)	0.711(0.014)	0.692(0.003)	0.747(0.004)
E-DIS _{MolTrans}	0.692(0.007)	0.741(0.012)	0.721(0.005)	0.776(0.016)
BINDTI	0.629(0.002)	0.653(0.011)	0.679(0.006)	0.733(0.012)
E-DIS _{BINDTI}	0.663(0.004)	0.685(0.023)	0.717(0.001)	0.766(0.003)
DrugBAN	0.668(0.004)	0.698(0.007)	0.675(0.016)	0.726(0.012)
E-DIS _{DrugBAN}	0.688(0.023)	0.712(0.023)	0.703(0.004)	0.761(0.005)
药物-靶标冷启动				
MGraphDTA_P	0.643(0.014)	0.679(0.018)	<u>0.669(0.003)</u>	0.495(0.009)
E-DIS _{MGraphDTA_P}	0.694(0.005)	0.733(0.004)	0.703(0.008)	0.535(0.009)
MolTrans	0.601(0.010)	0.647(0.009)	0.613(0.003)	0.457(0.007)
E-DIS _{MolTrans}	0.630(0.005)	0.682(0.006)	0.643(0.002)	0.500(0.011)
BINDTI	0.604(0.001)	0.651(0.005)	0.593(0.004)	0.425(0.008)
E-DIS _{BINDTI}	0.646(0.012)	0.691(0.010)	0.625(0.012)	0.438(0.003)
DrugBAN	0.633(0.009)	0.681(0.011)	0.627(0.006)	0.456(0.011)
E-DIS _{DrugBAN}	<u>0.662(0.011)</u>	<u>0.716(0.010)</u>	0.646(0.008)	<u>0.507(0.009)</u>




图 4-4 药物冷启动、靶标冷启动、药物-靶标冷启动设置下在(A) BindingDB 和(B) BIOSNAP 数据集上模型引入 E-DIS 框架前后的性能比较

具体而言，在药物冷启动设置下，BINDTI 模型引入 E-DIS 框架后性能提升最为显著，在 BindingDB 和 BIOSNAP 数据集上的 AUROC 值分别提升了 1.0%，2.8%。在靶标冷启动设置下，四种模型引入 E-DIS 框架后，在 BindingDB 数据集上的 AUROC 值平均提高了 4.8%，在 BIOSNAP 数据集上的 AUROC 值平均提高了 4.2%。其中，MGraphDTA_P 模型引入 E-DIS 框架后，在 BindingDB 数据集上的性能提升最为显著，AUROC 值提高了 6.4%；而 BINDTI 模型在 BIOSNAP 数据集上的性能提升最为显著，AUROC 值提高了 5.6%。

在最具挑战的药物-靶标冷启动设置下，虽然总体性能较单个冷启动设置有所下降，但随着任务难度的增加，引入 E-DIS 框架后模型性能的提升更为显著。在该设置下，四种模型引入 E-DIS 框架后，在 BindingDB 数据集上 AUROC 值平均提升了 6.1%，在 BIOSNAP 数据集上 AUROC 值平均提升了 4.6%。其中，MGraphDTA_P 模型引入 E-DIS 框架后，在 BindingDB 数据集上性能提升最为显著，AUROC 值提升了 7.9%；而 BINDTI 模型在 BIOSNAP 数据集上性能提升最为显著，AUROC 值提升了 5.4%。

这些结果充分表明,随着任务难度的增加,E-DIS 框架带来的性能提升幅度也随之增大,验证了其在处理极端分布偏移情况下的优越泛化能力。特别是在最具挑战性的药物-靶标冷启动场景中,E-DIS 仍能保持显著的性能提升,充分体现了其在实际药物发现应用中的潜在价值。

为进一步验证性能提升的统计学显著性,我们基于 AUROC 指标对模型引入 E-DIS 框架前后的性能差异进行了 t 检验,具体结果如表 4-7 所示。检验结果显示,在药物冷启动和药物-靶标冷启动两种设置下,四种模型的预测性能在引入 E-DIS 框架前后均存在显著性差异 ($p < 0.05$)。此外,在靶标冷启动设置下,MGraphDTA_P、MolTrans 和 BINDTI 模型在引入 E-DIS 框架后也表现出显著的性能提升 ($p < 0.05$)。总体而言,在 12 组实验中,有 11 组实验结果表明引入 E-DIS 框架的性能差异具有统计学显著性 ($p < 0.05$)。这一结果不仅证明了 E-DIS 框架能够显著提升模型的适应性,还表明其在面对完全未知的结构化数据时具备更强的泛化能力。与领域内设置下的高性能表现相比,冷启动设置下的实验结果更贴近实际药物发现场景,为 E-DIS 方法在真实应用中的潜力提供了有力的支持。

表 4-7 在 BindingDB 和 BIOSNAP 数据集上模型引入 E-DIS 框架前后基于 AUROC 值的统计分析结果

模型	BindingDB			BIOSNAP		
	下降率	t 统计量	p 值	下降率	t 统计量	p 值
药物冷启动						
MGraphDTA_P	1.0%	4.28	<0.01	1.5%	3.506	<0.01
MolTrans	0.5%	2.647	<0.01	2.2%	6.726	<0.001
DrugBAN	0.5%	3.158	<0.01	1.9%	4.424	<0.01
BINDTI	1.0%	2.941	<0.01	2.8%	14.702	<0.001
靶标冷启动						
MGraphDTA_P	6.4%	2.225	0.017	3.0%	7.115	<0.001
MolTrans	4.2%	3.729	<0.01	4.2%	5.991	<0.001
DrugBAN	3.0%	1.213	0.115	4.1%	2.392	0.014
BINDTI	5.4%	8.842	<0.001	5.6%	9.074	<0.001
药物-靶标冷启动						
MGraphDTA_P	7.9%	4.444	<0.01	5.1%	5.201	<0.001
MolTrans	4.8%	3.509	<0.01	4.9%	10.034	<0.001
DrugBAN	4.6%	2.543	0.012	3.0%	2.275	0.017
BINDTI	7.0%	5.714	<0.01	5.4%	3.476	<0.01

4.4.2.2 基于聚类分割策略

为进一步评估模型在未知数据分布上的预测能力,本研究采用了基于聚类的分割策略,以检验 E-DIS 框架及其对比基线在跨领域场景中的表现。在该策略中,我们沿用了 DrugBAN^[181]研究中定义的源域数据和目标域数据的划分方式,以确保实验设置的一致性与可比性。具体而言,首先基于 ECFP^[110]计算所

有药物分子的相似性矩阵。ECFP 是一种基于分子拓扑结构的特征表示方法，能够在不依赖三维结构的情况下，捕捉化合物的局部结构信息。同时基于伪氨基酸组成（Pseudo Amino Acid Composition, PseAAC）^[187]计算靶标蛋白的相似性矩阵。PseAAC 是一种蛋白质序列特征表示方法，通过结合氨基酸的组成信息和顺序特征，生成蛋白质的数值化表示。随后，利用单链接聚类法对药物和靶标分别进行聚类，确保类别间的结构差异显著。单链接聚类法是一种层次聚类方法，通过计算类别间最近样本的距离来确定类别合并顺序。完成聚类后，我们将 60% 的药物-靶标类别划分为源域数据，用于模型训练，而剩余 40% 的类别作为目标域数据，用于测试。通过聚类划分策略，我们能够更真实地评估模型在面对 OOD 数据时的泛化能力，为 E-DIS 框架在实际应用中的可靠性提供了严谨的验证基础。

表 4-8 基于聚类分割设置下 E-DIS、BAT 和 CDAN 方法在 BindingDB 和 BIOSNAP 数据集上的性能比较

模型	BindingDB		BIOSNAP	
	AUROC	AUPRC	AUROC	AUPRC
MolTrans	0.565(0.004)	0.520(0.011)	0.614(0.008)	0.607(0.010)
BAT _{MolTrans}	0.594(0.007)	<u>0.605(0.009)</u>	0.628(0.003)	0.649(0.037)
CDAN _{MolTrans}	0.606(0.012)	0.566(0.027)	0.625(0.004)	0.638(0.020)
E-DIS _{MolTrans}	0.618(0.004)	0.601(0.042)	0.656(0.011)	0.691(0.017)
DrugBAN	0.571(0.013)	0.526(0.007)	0.624(0.009)	0.605(0.009)
BAT _{DrugBAN}	0.587(0.015)	0.573(0.021)	0.648(0.008)	0.670(0.011)
CDAN _{DrugBAN}	0.604(0.014)	0.558(0.020)	0.682(0.012)	0.721(0.011)
E-DIS _{DrugBAN}	0.611(0.008)	0.609(0.027)	0.660(0.006)	0.690(0.010)
MGraphDTA_P	0.601(0.009)	0.549(0.012)	0.690(0.023)	0.683(0.021)
BAT _{MGraphDTA_P}	<u>0.624(0.021)</u>	0.568(0.021)	<u>0.714(0.016)</u>	<u>0.724(0.015)</u>
CDAN _{MGraphDTA_P}	0.617(0.014)	0.585(0.025)	0.693(0.003)	0.696(0.004)
E-DIS _{MGraphDTA_P}	0.630(0.004)	0.601(0.011)	0.721(0.004)	0.732(0.004)

表 4-8 和图 4-5 展示了 E-DIS 框架与当前最先进的领域自适应方法（BAT 和 CDAN）在基于聚类分割设置下的性能对比。实验结果表明，在 BindingDB 和 BIOSNAP 数据集上，引入 E-DIS 框架的模型（E-DIS_{MODEL}）均显著优于未引入 E-DIS 框架的基线模型（MODEL），且统计学差异显著（ $p < 0.01$ ）。具体而言，在 BindingDB 数据集上，E-DIS_{MODEL} 的平均 AUROC 比 MODEL 提升了 7.1%，平均 AUPRC 提升了 13.6%；在 BIOSNAP 数据集上，E-DIS_{MODEL} 的平均 AUROC 比 MODEL 提升了 5.7%，AUPRC 提升了 11.7%。上述结果充分证明了 E-DIS 框架在 OOD 泛化场景下的有效性。值得注意的是，E-DIS_{MGraphDTA_P} 在 AUROC 指标上始终领先于其他模型，同时在 AUPRC 指标上也表现出强劲的竞争力。这表明 E-DIS 方法能够有效提升模型对全新药物-靶点组合的预测能

力, 即使这些组合的分布与训练数据存在显著差异。这一特性对于加速新药研发具有重要意义, 不仅能够提高虚拟筛选的精准度, 还能够在面临新药物-靶标对时减少响应时间, 从而提升药物发现的效率。




图 4-5 基于聚类分割设置下 E-DIS、BAT 和 CDAN 方法在(A) BindingDB 和(B) BIOSNAP 数据集上的性能比较

实验结果进一步表明, 大多数引入 E-DIS 框架的模型在性能上超越了引入 BAT 或 CDAN 的模型。在 BindingDB 数据集上, 相较于引入 BAT 框架的模型 (BAT_{MODEL}), E-DIS_{MODEL} 的平均 AUROC 提升了 3.0%, 平均 AUPRC 提升了 3.8%; 相较于引入 CDAN 框架的模型 (CDAN_{MODEL}), E-DIS_{MODEL} 的平均 AUROC 提升了 1.7%, 平均 AUPRC 提升了 6.0%。在 BIOSNAP 数据集上, E-DIS_{MODEL} 的平均 AUROC 比 BAT_{MODEL} 提升了 2.4%, 平均 AUPRC 提升了 3.5%; E-DIS_{MODEL} 的平均 AUROC 比 CDAN_{MODEL} 提升了 1.9%, 平均 AUPRC 提升了 3.1%。然而, 在 BIOSNAP 数据集上, CDAN_{DrugBAN} 模型在 AUROC 和 AUPRC 指标上分别比 E-DIS_{DrugBAN} 提升了 3.2%, 4.3%。这一结果表明, CDAN 方法对于某些特定模型可能具有局部优势, 但总体而言, E-DIS 框架具有更稳定的跨领域泛化能力。值得注意的是, E-DIS 框架在训练过程中未使用任何来自目标

域的信息，而 BAT 和 CDAN 则需要利用目标域中未标记的数据作为辅助。E-DIS 通过在源域数据上训练多个专家网络，捕获广泛的特征模式，并将这些特征迁移至目标域，从而显著增强模型的泛化能力。这一设计使得 E-DIS 在训练数据与测试数据分布不同的情况下，依然能够保持较高的预测精度。

4.4.3 可视化分析

本研究通过可视化分析方法，深入探究了 E-DIS 框架中的领域通用特征提取器和领域特定特征提取器的特征学习机制。如图 4-6 所示，我们采用梯度加权亲和力激活映射（Gradient-Weighted Affinity Activation Mapping, Grad-AAM）方法^[136]，结合 RDKit 工具，对蛋白质数据库（Protein Data Bank, PDB）中两个复合物的原子贡献度进行了可视化表征。Grad-AAM 是一种基于图神经网络梯度信息的可解释性技术，通过提取网络最后一层的梯度信号，量化每个原子对最终预测结果的影响程度，并生成原子贡献的概率热力图。

可视化结果表明，两个特征提取器均能有效捕捉药物-靶标相互作用的关键物理化学特征，包括氢键作用、亲水、疏水特性及 π - π 相互作用等重要因素。进一步分析发现，两个特征提取器对原子贡献的关注点存在差异。具体而言，领域通用特征提取器主要关注亲水性、疏水性和 π - π 相互作用等特征，倾向于捕获药物和靶点之间较为普遍的物理化学交互模式，有助于模型构建对全局性特征的理解，为预测任务提供稳定的基础表征。领域特定特征提取器更侧重于氢键相互作用，强调特定领域内独特的化学键合特性，使得模型能够更精细地捕获药物-靶点对的局部交互细节。

上述发现表明，E-DIS 框架中的两个特征提取器在功能上形成了互补：领域通用特征提取器通过捕获普适的物理化学规律，为模型提供了基础性交互模式认知；领域特定特征提取器则通过突出特定特征的关键作用，进一步丰富了特征的多样性和深度。这种差异化的特征学习策略，使得 E-DIS 能够更全面地描述药物与靶点之间复杂的相互作用机制。通过融合领域通用特征与领域特定特征，E-DIS 框架显著增强了对全新药物-靶标对的泛化能力。可视化分析不仅验证了两个特征提取器在特征捕获上的协同效应，还更直观的揭示了 E-DIS 框架提升模型预测性能的内在原因。这一结果为 E-DIS 框架在 DTI 预测任务中的优越性提供了理论支持，同时也为后续研究如何优化特征提取模块以进一步提升模型性能提供了重要启示。




图 4-6 PDB 复合物 (A) 1BNM 和 (B) 1KZK 的关键特征可视化。在每个子图的左上角展示了原子在领域通用特征提取器中的重要性；左下角则呈现了原子在领域特定特征提取器中的重要性。子图的右侧展示了 Schrödinger 软件 (2019 版) 识别的药物-靶标复合物二维相互作用图谱。右下角提供了二维相互作用图谱的图例说明。

4.5 本章小结

本文提出了一种基于领域通用特征与领域特定特征协同的 E-DIS 框架，旨在解决 DTI 预测任务中模型泛化能力不足的问题。通过双分支特征提取架构，E-DIS 框架能够同时学习药物-靶标对的全局共性特征与局部特异性特征，降低了模型对单一特征的依赖。在 Davis 和 KIBA 回归数据集以及 BindingDB 和 BIOSNAP 分类数据集上的系统评估结果表明，无论是在领域内还是跨领域的实验设置下，引入 E-DIS 框架后，模型在 DTI 预测任务中的性能均得到了显著提升。E-DIS 框架在冷启动和基于聚类分割设置下展现了优异的泛化能力，显著优于现有的领域自适应方法（如 BAT 和 CDAN）。此外，通过可视化分析，我们揭示了 E-DIS 框架的特征学习机制，验证了其在捕捉多样化特征方面的有效

性。总之，E-DIS 框架通过融合领域通用特征与领域特定特征，显著增强了模型的泛化能力，不仅能够加速新药发现与验证过程，还能缩短新药物-靶标对的响应时间，为药物研发提供了高效、鲁棒的计算解决方案。

第五章 基于多模态融合的药物-靶标结合亲和力预测

5.1 研究背景

药物-靶标结合亲和力 (Drug-Target Affinity, DTA) 预测是计算机辅助药物发现的核心任务之一, 其目标是通过量化药物分子与靶标蛋白的结合强度, 指导先导化合物优化和虚拟筛选^[188]。传统的基于物理的方法, 如分子动力学模拟^[189]和量子力学, 虽然在预测精度上表现优异, 但由于计算复杂度高, 难以实现高通量筛选^[32]; 分子对接方法虽通过简化评分函数降低了计算复杂度, 却因忽略动态相互作用导致预测精度受限^[190]。近年来, 随着计算能力的提升与高质量生物数据的积累, 数据驱动的深度学习方法凭借其对复杂特征的自适应建模能力, 逐渐成为 DTA 预测领域的研究热点^[18-20]。

现有的深度学习模型主要可分为两类: 无交互模型和交互模型。无交互模型通常将配体表示为分子指纹、SMILES^[111]或图结构, 而将蛋白质表示为序列或接触图, 通过独立提取蛋白质与配体结构特征实现预测^[32]。这个过程虽然计算高效, 但忽略了原子级物理相互作用, 导致预测结果与生化机制脱节。交互模型则利用药物-靶标复合物的三维分子结构, 将其表示为接触图或三维网格, 从而显式建模原子级相互作用, 提升预测合理性。然而, 现有的交互模型大多依赖单一模态输入, 难以全面表征复合物的多尺度特性。尽管近期研究尝试将蛋白质序列、三维结构和表面信息等多模态数据融合^[104], 但其聚焦于靶标蛋白的多模态特征, 未能充分挖掘药物-靶标复合物的跨模态交互信息, 导致特征表达碎片化与信息融合不足。

为应对上述挑战, 本章提出了多模态融合网络 (Multimodal Fusion Network, MF-Net), 通过多模态特征融合全面解析药物-靶标复合物的相互作用机制。该网络整合了三个关键模态的特征表示: 序列特征、原子图特征和片段图特征。序列特征通过捕获分子的一维序列信息, 提供全局化学背景; 原子图特征基于分子拓扑结构, 精确描述原子级别的局部相互作用; 片段图特征则采用分子指纹信息作为初始特征, 有效表征高层次功能域间的交互模式。MF-Net 的创新性主要体现在以下四个方面: 首先, 通过构建互补的多模态特征表示, 解决了传统单模态模型信息表征片面的局限性。其次, 在片段图的特征设计中, 有效融合了领域知识, 实现了先验知识与学习表征的优势互补。同时, 引入数据驱动的自适应权重分配机制, 能够根据输入样本特征动态调整各模态的贡献权重, 提升对异构数据的鲁棒性。最后 MF-Net 还引入了对比损失, 通过相似性约束, 对齐不同模态的潜在空间分布, 增强了特征间的兼容性, 有效缓解了多模态数

据异质性带来的信息损失。这种多尺度、知识增强的融合策略不仅全面提升了模型对药物-靶标相互作用的理解深度，也为复杂生物分子系统的表征学习提供了新的方法论参考。实验结果表明，MF-Net 在保持模型可解释性的同时，显著提高了预测准确性，为药物发现中的虚拟筛选和结合亲和力预测等关键任务提供了可靠的计算工具。

5.2 算法运行设置

5.2.1 数据集

在本研究中，我们开展了两种类型的实验任务：DTA 预测（回归任务）和基于结构的虚拟筛选（分类任务）。对于 DTA 预测实验，我们采用 PDBBind V2016 数据集^[191] 作为基准数据集。PDBBind 数据集包含从 PDB 中提取的生物分子复合物及其实验测得的结合亲和力数据，其中结合亲和力以 K_d 、 K_i 和 IC_{50} 值表示。数据集的划分遵循先前研究的标准^[32, 192]，从精炼集中随机抽取 1000 个药物-靶标对作为验证集，剩余的精炼集与一般集合并作为训练集（共 11924 个样本），核心集作为测试集，并在划分过程中确保核心集中的药物-靶标对从训练集和验证集中完全去除，从而有效避免数据泄露问题。

为评估模型在基于结构的虚拟筛选任务中的性能，我们使用了 DUD-E^[193]、DEKOIS2.0^[194]和 LIT-PCBA^[195]三个基准数据集。DUD-E 数据集包含 102 个来自不同蛋白质家族的靶标，共计 22886 个活性化合物。每个活性化合物配以约 50 个具有相似物理化学性质但不同二维拓扑结构的诱饵分子。DEKOIS2.0 数据集包含 81 个结构多样的靶标蛋白，每个靶标蛋白有 40 个活性化合物和 1200 个诱饵分子。为确保评估结果的客观性并避免模型过拟合，我们采用跨数据集验证策略：在 DUD-E 数据集上进行训练和验证，在 DEKOIS2.0 数据集上进行测试。这种策略能够有效评估模型在不同结构特征数据集上的泛化能力。LIT-PCBA 数据集是使用非对称验证嵌入方法设计的无偏差数据集^[195]，其配体文库经过实验验证，活性与非活性化合物的分布符合虚拟筛选的实际场景。LIT-PCBA 数据集中的三维结构数据来自 Shen 等人的研究工作^[196]，我们仅选择其中活性化合物超过 100 个的 7 个靶点蛋白进行实验，并按照 LIT-PCBA 数据集原有的训练集和测试集进行模型训练与测试。

5.2.2 评价指标

在 DTA 预测任务中，我们采用了 RMSE、MAE、 R_p 和标准差（Standard Deviation, SD）等指标综合评估模型性能。其中，RMSE 用于衡量模型预测值

与真实值之间的平均差异，其值越小表示模型性能越好。RMSE 对较大误差较为敏感，能够反映预测结果的总体偏差。MAE 则通过计算所有样本预测误差绝对值的平均值来评估模型的预测准确性，其值越小表示模型性能越好。与 RMSE 相比，MAE 在异常值较少的情况下表现更为稳定。Rp 反映了模型预测值与真实值之间的线性相关性，其值越大表示模型性能越好。Rp 的取值范围为 [-1, 1]，其中 1 表示完全正相关，-1 表示完全负相关。SD 用于衡量预测值与真实值之间的离散程度或波动性，其值越小表示模型的预测结果越稳定。在基于结构的虚拟筛选任务中，我们采用富集因子（Enrichment Factor, EF）作为评估指标，分别在最高 0.1%、0.5%、1%和 5%水平（即 EF0.1%、EF0.5%、EF1%和 EF5%）计算其值。EF 用于衡量模型从大规模化合物库中正确预测和富集活性化合物的能力，其值越大表示模型的筛选效果越好。EF 的计算公式为：

$$EF = \frac{\frac{H_s}{N_s}}{\frac{H_t}{N_t}} \quad (5-1)$$

式中： N_s 为打分靠前的 N 个化合物， H_s 为打分靠前的 N 个化合物中真正为活性化合物的数量， N_t 为整个数据集中化合物的总数， H_t 为整个数据集中活性化合物的总数。EF0.1%、EF0.5%、EF1%和 EF5%分别表示筛选结果的最高 0.1%、0.5%、1%和 5%范围内活性化合物的富集程度，这些指标能够全面反映虚拟筛选方法的有效性和准确性。

5.2.3 基线模型

在本研究中，我们将 MF-Net 与一系列具有代表性的基线模型进行了对比。在 DTA 任务中，基线模型涵盖了无交互模型和交互模型两大类方法。无交互模型主要依赖药物分子和靶标蛋白的独立特征提取，未显式建模两者间的相互作用。在无交互模型中，DeepDTA^[58]通过卷积神经网络分别从蛋白质氨基酸序列和配体的 SMILES 字符串中提取特征，通过特征拼接预测结合亲和力；而 GAABind^[197]则引入几何感知注意力机制，结合多任务学习框架，通过捕捉空间几何关系提升预测精度。另一方面，交互模型显式建模药物-靶标相互作用，强调结合界面的动态特征。在交互模型中，Pafnucy^[31]将药物-靶标复合物转化为 3D 体素网格，并利用卷积神经网络提取空间特征，预测结合亲和力；OnionNet^[198]则利用不同距离范围内的原子接触特征来描述相互作用，增强对结合模式的物理化学解释性；IGN^[192]将复合物分解为配体分子图、蛋白质分子图和相互作用图，通过两个独立的图卷积网络分别学习分子内和分子间相互作用；MFE^[104]整合了蛋白质表面、三维结构及序列信息，并利用交叉注意力机制对齐

不同模态特征，生成统一表征；EHIGN^[32]则基于异质图神经网络，区分共价与非共价相互作用，通过可解释的原子对亲和力累加机制预测结合强度。此外，在虚拟筛选任务中，我们还对比了传统机器学习方法 RFscore-VS^[199]，该方法基于随机森林模型，通过特征工程提取原子对距离、氢键等相互作用特征，适用于大规模虚拟筛选。此外，我们还对比了经典的分子对接工具 Surflex^[200, 201]和 Glide-SP，Surflex 基于分子表面形状互补性和经验力场评分函数，支持柔性对接和高效虚拟筛选；Glide-SP 是 Schrödinger 公司开发的 Glide 分子对接软件中的一种中间精度模式，采用分层筛选策略，先快速生成候选构象，再通过经验力场优化和评分，平衡计算效率与准确性，适用于中等规模任务。

5.2.4 参数设置

为确保模型性能的最优化，本研究系统性地开展了超参数调优实验，具体超参数设置如表 5-1 所示。利用 Adam 优化器^[155]更新模型参数，初始学习率设置为 $2e-5$ ，权重衰减率为 $1e-6$ ，批次大小为 64。在所有数据集上均统一进行 200 个训练周期，同时为避免过拟合并节约计算资源，我们引入了早停技术^[202]：若验证集性能在连续 60 个训练周期内未提升，则训练自动停止。此外，学习率调度器在性能停滞 5 个周期后对学习率进行衰减，以进一步优化模型收敛过程。

表 5-1 MF-Net 的超参数配置表

超参数	值
优化器	Adam
训练周期	200
批次大小	64
初始学习率	$2e-5$
学习率忍耐轮次	5
早停忍耐轮次	60
权重衰减率	$1e-6$

实验环境配置如下：硬件平台采用配备 NVIDIA RTX 3080 Ti GPU（12GB 显存）、Intel(R) Xeon(R) CPU E5-2640 v4 @ 2.40GHz 处理器和 64GB DDR4 内存的 Linux 服务器。软件环境基于 PyTorch Geometric 框架构建，具体包括：Python 3.11 作为编程语言，PyTorch 2.1 作为深度学习框架，DGL 2.4.0 和 RDKit 2023.09 用于分子结构处理，Numpy 1.26 和 Pandas 2.1 用于数据处理与分析。所有实验均在 CUDA 12.4 环境下运行，以充分利用 GPU 的并行计算能力。

5.3 方法描述

5.3.1 MF-Net 框架概述




图 5-1 MF-Net 框架示意图

图 5-1 展示了本研究提出的 MF-Net 模型的整体框架。该模型采用多模态数据融合策略，旨在从多个尺度捕获药物-靶标之间的相互作用。具体而言，MF-Net 模型包含以下四个核心模块：序列特征提取模块、原子级特征提取模块、片段级特征提取模块以及融合与预测模块。模型通过序列特征提取模块对蛋白质序列和配体特征进行编码，生成药物-靶点对的组合描述符，以捕获全局信息。原子级特征提取模块利用原子图表示药物-靶标结合位点的局部结构，并利用 SchNet 模型获取精细的原子级特征表示。随后，通过分子间图卷积网络进一步强化和更新原子特征，从而高效捕捉药物-靶标之间复杂的原子级相互作用。片段级特征提取模块对蛋白质残基图和配体基序图进行处理，通过分子间图卷积操作捕获片段级相互作用信息。融合与预测模块采用卷积神经网络对药物-靶标

的序列级、原子级和片段级特征进行融合，自动学习各个特征的相对重要性。最后，融合后的特征被输入到多层感知机中，以准确预测 DTA。此外，为了最大限度地提高不同特征之间的兼容性和一致性，我们引入了一种基于相似性的对比损失函数，通过对比学习策略增强模型的特征融合能力。通过上述模块的协同作用，MF-Net 能够从序列、原子和片段三个尺度全面捕获药物-靶标相互作用，为结合亲和力预测提供了更精确的建模框架。

5.3.2 多模态输入




图 5-2 药物-靶标复合物的多模态表示

为了全面描述药物-靶标复合物的特征，本研究采用了多模态输入策略，将药物-靶标复合物表示为序列、原子图和片段图，如图 5-2 所示。首先，序列表示由蛋白质完整的氨基酸序列和配体的 SMILES 字符串构成，提供了全局分子背景信息。蛋白质的氨基酸序列蕴含其折叠成特定三维结构并执行生物功能的全部信息，能够全面反映其整体结构与功能特性。配体的 SMILES 字符串以一维线性形式表达其化学结构信息。其次，鉴于蛋白质结合位点在决定配体亲和力中的关键作用，我们在构建原子图和片段图时，仅关注结合位点区域。原子图表示通过构建原子级图结构，展现结合口袋内各原子之间的相互作用、连通性及空间关系。这种表示方式能够精准捕捉药物-靶标复合物的局部结构细节，为原子级相互作用建模提供坚实基础。片段图表示由蛋白质残基图和配体功能基序图构建，旨在揭示蛋白质氨基酸残基与配体功能基团之间的相互作用。这种表示方式能够捕捉原子级描述中可能被忽略的重要功能域及区域性交互信息，从而为高级功能建模提供有力支持。总体而言，这三种表示方式分别从全局（序列）、局部（原子图）和高级功能（片段图）三个层面对药物-靶标复合物进行全面描述，经过多模态特征融合，模型能够充分利用不同模态的互补性，

为 DTA 预测提供了坚实而全面的特征基础。

序列表示由蛋白质的氨基酸序列和配体的 SMILES 字符串构成。在蛋白质序列中, 每个字母代表一个氨基酸残基, 每种残基类型采用 One-Hot 编码为数值变量。此外, 为了增强序列特征的化学信息表达能力, 我们结合了氨基酸残基的 R 基团特性, 包括极性、分子量、酸碱性、芳香性等, 构建了 33 维的特征向量。这些附加特性能够更准确地描述氨基酸的化学性质, 为蛋白质提供更丰富的全局信息。配体的 SMILES 字符串通过开源工具 RDKit 转化为分子图表示, 其中节点代表原子, 边代表原子间的化学键。如表 5-2 所示, 我们选取了 8 个原子特征作为节点属性, 包括原子类型、电荷、杂化状态、电子构型、芳香性等, 构建了 36 维的特征向量。通过将蛋白质序列特征与配体分子图表示有机结合, 我们构建了全面的蛋白-配体描述符。这种表示方式不仅能够提供蛋白质和配体的全局化学背景信息, 还为模型提供了更丰富的结构细节。

表 5-2 原子图和配体图的原子特征以及化学键特征

特征	特征描述	值	长度
原子特征			
Atom type	原子类型	C,N,O,F,P,S,Cl,Br,I	9
Degree	邻居原子数目	0,1,2,3,4,5	6
Formal charge	原子的电子电荷	-1, -2, 1, 2, 0	5
Chirality	原子的手性类型	0, 1, 2, 3	4
Number Hs	氢原子数目	0, 1, 2, 3, 4	5
Hybridization	原子的杂化类型	sp, sp ² , sp ³ , sp ³ d, sp ³ d ²	5
Aromaticity	原子是否为芳香体系的一部分	0,1	1
Protein	原子是否属于蛋白质	0,1	1
化学键特征			
Bond type	化学键类型	单键, 双键, 三键, 芳香键, 其他	5
Aromaticity	化学键是否为芳香体系的一部分	0,1	1
Ring	化学键是否为环的一部分	0,1	1
Protein	化学键两端的原子是否属于蛋白质	0,1	1
Ligand	化学键两端的原子是否属于配体	0,1	1
Distance	键长	0.348, 0.253, ...	1

为了有效捕捉蛋白质结合口袋与配体之间的相互作用特征, 本研究还采用了原子图表示方法。该方法利用开源工具 RDKit 将蛋白质结合口袋和配体结构系统地转换为图表示, 其中原子作为节点, 化学键和空间关系作为边。与配体分子图表示类似, 每个节点的特征被表示为 36 维向量 (具体见表 5-2), 包括原子类型、电荷、杂化状态、电子构型、芳香性等关键物理化学性质。这些特征能够全面描述原子的局部化学环境, 为后续的相互作用建模提供基础。原子图中蛋白与配体之间的边基于原子之间的空间距离构建, 当蛋白质结合袋中的原子与配体原子之间的距离小于 5.0 Å 时, 建立边缘连接两者。这种距离阈值

能够有效捕捉氢键、范德华力等非共价相互作用，这些相互作用对理解结合亲和力和力至关重要。如表 5-2 所示，我们构建了 10 维的特征向量作为边的初始特征向量。所构建的原子图能够详细而准确地描述蛋白质结合袋与配体之间的相互作用。这种表示方法不仅能够捕获药物-靶点复合物的局部化学环境，还能够反映原子间的空间排列模式，为结合亲和力预测提供了丰富的结构信息。

为了捕获更高层次的相互作用信息，本研究还采用了片段图表示方法，专注于描述蛋白质结合口袋中氨基酸残基与配体功能基序之间的相互作用。这种表示方法以蛋白质的二级结构单元和配体的功能基团为基础，能够有效捕捉药物-靶标复合物的高阶特征。在蛋白质口袋片段图中，氨基酸残基作为节点，其特征与蛋白质序列特征保持一致，包括氨基酸类型和 R 基团特性。对于配体，我们采用 BRICS 算法将其分解为多个功能基序。BRICS 算法不仅能够将配体拆分为合理的片段，还能保留关键的结构和功能元素，如芳香环、羟基、羧基等。为进一步细化基序，我们不仅断裂了与 BRICS 算法相关的化学键，还破坏了环外键，以确保基序的功能性和代表性。配体片段图中的节点特征被表示为 194 维特征向量，包括 MACCS 指纹特征和药效团指纹特征。其中，MACCS 指纹通过一组预定义的编码捕捉不同拓扑距离上的原子属性、键属性及原子邻域信息；药效团指纹则通过药效团图谱描述分子中的功能基团特性（如氢键供体/受体、带电基团、疏水区域等）。片段图中蛋白与配体之间的边基于氨基酸残基与基序之间的空间距离构建，当距离小于 8.0 Å 时，建立边缘连接两者。边的初始特征为两节点间的距离。片段图表示方式能够突出关键功能域之间的相互作用，为高级功能建模提供支持。片段图能够从功能域层面描述药物-靶标复合物的相互作用，为结合亲和力预测提供了更高层次的结构信息。

5.3.3 序列特征提取模块

在序列特征提取模块中，我们利用 MGraphDTA 进行序列特征提取。该模块包括两种专门的架构：多尺度卷积神经网络（Multiscale Convolutional Neural Network, MCNN）和多尺度图神经网络（Multiscale Graph Neural Network, MGNN）。MCNN 用于捕获蛋白质序列中的残基水平模式，其架构由三个并行分支组成，每个分支采用不同大小的卷积核，以提取不同尺度的残基相互作用。较小的卷积核能够捕获短程相互作用（如氢键），而较大的卷积核则能够捕获长程相互作用（如疏水相互作用）。经过卷积操作后，通过最大池化层生成固定长度的特征向量。最后，这些不同尺度的特征被拼接并输入到一个全连接层中，生成蛋白质的序列表示 R_p 。具体过程如下：

$$R_p = W \operatorname{cat} \left(M \left(C_1(f_p) \right), M \left(C_2(f_p) \right), M \left(C_3(f_p) \right) \right) \quad (5-2)$$

式中： f_p 表示蛋白序列初始特征； C_i 表示包含 i 个卷积层的分支，可以将 f_p 映射成一个矩阵。 M 表示最大池化操作； $\operatorname{cat}()$ 表示简单的拼接； W 表示可学习的权重矩阵。

MGNN 用于建模配体图中的原子相互作用。MGNN 包括三个紧密连接的多尺度块，每个多尺度块后均设有一个过渡层，以实现多层次特征的提取与整合。每个多尺度块包含多个图卷积层，每一层的输出通过残差连接直接传递到后续层。这种设计不仅能够捕获配体图中不同尺度的原子相互作用，还能有效缓解梯度消失问题，提升模型的训练稳定性。过渡层连接相邻的多尺度块，并通过可学习的权重矩阵整合多尺度特征。过渡层通过减少特征通道的数量，在保持模型对复杂分子拓扑结构建模能力的同时，显著提升了计算效率。具体过程如下：

$$\begin{aligned} f_l^1 &= G_1(f_l^0) \\ f_l^2 &= G_2 \left(\operatorname{cat}(f_l^0, f_l^1) \right) \\ f_l^n &= G_n \left(\operatorname{cat}(f_l^0, f_l^1, \dots, f_l^{n-1}) \right) \end{aligned} \quad (5-3)$$

式中： f_l^0 表示配体图的初始原子特征； G_n 表示第 n 层 GCN。

利用图卷积操作对所有邻居节点的隐藏状态求和，迭代更新每个节点的隐藏状态。每次更新后，通过节点级批处理归一化操作（Node-Level Batch Normalization, BN）对节点特征进行标准化，以加速模型收敛并提高训练稳定性。具体过程如下：

$$f_l = \operatorname{BN} \left(W_1 \operatorname{cat}(f_l^0, f_l^1, \dots, f_l^n) + W_2 \sum_{j \in N(l)} \operatorname{cat}(f_j^0, f_j^1, \dots, f_j^n) \right) \quad (5-4)$$

式中： W_1 、 W_2 表示可学习的矩阵， $j \in N(l)$ 表示节点 l 的邻居集合， BN 表示节点级批处理归一化操作。

完成图卷积操作后，对所有节点的隐藏状态进行全局聚合，得到整个配体图的综合特征向量 R_L 。具体过程如下：

$$R_L = \frac{1}{|L|} \sum_{l \in L} f_l \quad (5-5)$$

式中： $|L|$ 表示配体图中的节点数。

最后，将蛋白质序列特征 R_p 与配体图特征 R_L 进行拼接，得到最终的序列特征 R_s 。具体过程如下：

$$R_s = \text{cat}(R_P, R_L) \quad (5-6)$$

5.3.4 原子级特征提取模块

在原子图特征提取模块中，我们采用 SchNet 网络和分子间图卷积模块相结合的策略，精确描述药物与靶标之间的原子级相互作用。我们首先使用 SchNet 网络迭代地更新节点特征，然后使用分子间图卷积模块有效描述药物与靶标之间成对原子相互作用，最终通过池化操作得到原子图特征。SchNet 是一种结合图神经网络与物理化学知识的深度学习架构，特别适用于原子图特征提取任务。它通过一系列的编码、卷积操作和信息传播来学习原子之间的复杂关系。对于图中的每条边，首先计算该边的空间距离，并使用高斯模糊策略将距离信息映射到离散特征空间，得到边的特征 e_{ij} 。高斯模糊策略利用高斯函数将连续的距离信息映射为一组平滑分布的特征向量，从而有效捕捉距离信息的连续变化。然后，通过一个包含多个线性层的神经网络，将边的特征映射到新的空间，生成卷积核 W_{ij} 。具体过程如下：

$$W_{ij} = NN(G(\|p_i - p_j\|)) \quad (5-7)$$

式中： p_i 和 p_j 分别表示节点 i 和节点 j 的空间坐标， G 表示高斯模糊策略， NN 是由两层线性层和非线性激活函数构成的网络。

获得卷积核后，通过消息传递机制对节点进行卷积操作，将邻居节点的特征传递给当前节点。具体来说，邻居节点的特征首先与卷积核 W_{ij} 相乘，以实现特征更新。随后，将所有邻居节点更新后的特征进行聚合，并通过残差连接与节点 i 的原始特征 x_0 结合，最终完成节点特征的更新。具体过程如下：

$$x_i = x_0 + \sum_{j \in N(i)} W_{ij} \cdot x_j \quad (5-8)$$

式中： x_i 表示节点 i 更新后的特征， x_0 表示节点 i 的原始特征， $N(i)$ 表示节点 i 的邻居， x_j 表示邻居节点 j 的特征。

更新后的节点特征被输入到分子间图卷积模块中，以进一步描述蛋白质原子与配体原子之间的成对相互作用。分子间图卷积模块首先将更新后的节点特征与药物-靶标对的初始边特征 e_{pl}^0 结合。然后，将节点与边的组合特征输入到 MLP 中，通过非线性变换得到新的边特征 e_{pl} 。具体过程如下：

$$e_{pl} = BN(MLP(\text{cat}(e_{pl}^0, x_i))) \quad (5-9)$$

式中： e_{pl}^0 表示药物-靶标对的初始边特征， BN 表示批处理归一化操作。

最后，通过加权和池化操作和最大池化操作得到原子图的全局表示 R_A ，其中最大池化操作可以突出信息强度最高的边缘特征，加权和池化操作可以利用边缘特征的总信息强度。具体过程如下：

$$R_A = cat(\sigma(W_e \cdot e_{pl}), M(e_{pl})) \quad (5-10)$$

式中： σ 表示 $\tanh$ 激活函数， W_e 表示可学习的矩阵， M 表示最大池化操作。

5.3.5 片段级特征提取模块

在片段图特征提取模块中，我们采用 CFTransformer 和分子间图卷积模块相结合的策略，以精确描述蛋白质残基与配体基序之间的相互作用。我们首先使用 CFTransformer 迭代地更新节点特征，然后使用分子间图卷积模块有效描述蛋白质残基与配体基序之间成对相互作用，最终通过池化操作得到片段图特征。CFTransformer 是一种基于 Transformer 的模型，通过多层注意力机制学习蛋白质残基与配体基序之间复杂的交互信息。

与原子图中对于边的处理一致，对于片段图，我们也是首先使用高斯模糊策略对节点间的距离进行编码，将距离信息映射到离散特征空间，得到边缘特征 e_{ij} 。具体过程如下：

$$e_{ij} = G(\|p_i - p_j\|) \quad (5-11)$$

CFTransformer 的核心在于其多层交互机制，该机制利用自注意力和多头注意力来捕捉节点间的复杂相互作用。在每一层交互中，模型融合节点特征与边特征，实现信息的传递与更新。在交互过程开始之前，首先对节点特征 x 进行层归一化（Layer Normalization, LN），以加速模型收敛并提高训练稳定性。然后，通过三个独立的卷积操作，将归一化后的节点特征分别映射到查询、键和价值空间。在多个头上并行执行注意力计算，以增强模型的学习能力。具体过程如下：

$$\begin{aligned} Q &= Conv(LN(x)) \\ K &= Conv(LN(x)) \\ V &= Conv(LN(x)) \end{aligned} \quad (5-12)$$

接下来，边特征 e_{ij} 会被映射到与节点特征匹配的空间，与查询、键一起计

算注意力权重。具体过程如下：

$$\alpha_{ij} = \frac{Q_i K_j}{\sqrt{e_{ij}}} \quad (5-13)$$

式中： Q_i 表示节点 i 的查询特征， K_j 表示节点 j 的键特征， e_{ij} 表示节点 i 与节点 j 之间的边特征。

在基于注意力机制的节点特征更新过程中，每个节点从其邻居节点接收信息，并根据注意力分数进行加权聚合，以实现特征更新。具体而言，首先使用计算得到的注意力权重 α_{ij} 对邻居节点 j 的值特征 V_j 进行加权，并对所有邻居节点加权后的特征进行聚合，得到节点 i 的聚合消息。将聚合消息与节点 i 的原始特征 x_0 结合，使用残差连接更新节点特征。每次交互后，节点特征都被更新，最终通过全连接层进行输出。这些输出代表了片段图中每个节点的最终嵌入，充分融合了其与邻居节点及边之间的复杂交互信息。具体过程如下：

$$x_i = \text{MLP}(x_0 + \sum_{j \in N(i)} \alpha_{ij} \cdot V_j) \quad (5-14)$$

完成节点特征更新后的操作与原子图特征提取模块一致。更新后的节点特征被输入到分子间图卷积模块中。分子间图卷积模块首先将更新后的节点特征与药物-靶标对的初始边特征 e_{pl}^0 相结合。然后，将节点与边的组合特征输入到 MLP 中，通过非线性变换得到新的边特征 e_{pl} 。最后，通过加权和池化操作和最大池化操作得到片段图的全局表示 R_F 。具体过程如公式 5-9，5-10 所示。

5.3.6 融合与预测模块

多模态模型的核心挑战不仅在于如何处理和构建多模态数据，更在于如何实现不同模态数据的有效融合。多模态融合指的是从多种数据源中提取、筛选和组合关键特征，以获得更全面的特征表示。对于给定的药物-靶标对，我们通过前面的步骤分别获得了三种关键特征：序列特征、原子图特征和片段图特征。序列特征捕捉了蛋白质和配体的全局化学背景信息；原子图特征描述了蛋白质结合口袋与配体之间的原子级相互作用；而片段图特征则揭示了蛋白质氨基酸残基与配体功能基序之间的高层次功能域交互信息。

在融合与预测模块中，我们首先将这三类特征进行拼接，得到统一的多模态特征向量。随后，该特征向量被输入到卷积神经网络中，自动提取局部特征并捕捉不同模态之间的空间依赖关系。低层次卷积层侧重于学习每个模态中的关键特征，而高层次卷积层则将这些局部特征进行整合，生成全局的多模态表示。最后，融合后的特征向量经过 MLP 处理，并通过 ReLU 激活函数进行非线性

性变换，最终生成预测结果。具体过程如下：

$$P = \text{mlp}(\text{Conv}(\text{cat}(R_S, R_A, R_F))) \quad (5-15)$$

多模态融合的优势在于其能够整合不同特征的关键信息，提供更全面的特征表示。通过融合序列特征、原子图特征和片段图特征，模型不仅能够捕获药物-靶标复合物的全局化学背景，还能精确描述原子级和高层次功能域的相互作用细节。从原子级到高层次功能域的多层次特征整合，增强了模型对复杂分子结构的建模能力，同时，模型能够自动学习不同模态的关键特征，并根据任务需求进行自适应融合，从而显著提升预测性能。

5.3.7 损失函数

为了增强序列、原子图和片段图这三种不同表示模块在特征空间中的一致性，我们引入了一种基于相似性的对比损失，以对齐不同表示的特征分布。传统的表征学习方法通常依赖下游任务的监督损失来引导模型训练，然而，由于多模态数据的异质性，不同模态学习到的潜在空间在分布和尺度上可能存在显著差异，这种差异可能削弱多模态信息的融合效果。为此，我们采用归一化温度标度交叉熵损失（Normalized Temperature-Scaled Cross Entropy Loss, NT-Xent）来缩小不同模态之间的差异。具体而言，对于每个分子，我们将其在不同模态下的特征表示视为正样本对，而将不同分子的特征表示视为负样本对。通过对比学习，模型将来自同一分子的特征拉近，同时将来自不同分子的特征拉远，有效对齐不同模态的特征空间，增强多模态信息的融合效果，从而提升 DTA 预测的性能。对比损失的公式如下：

$$L_{cl} = -\log \frac{\exp\left(\frac{\text{sim}(R_{S(i)}, R_{A(i)})}{T}\right)}{\sum_{j=1, i \neq j}^N \exp\left(\frac{\text{sim}(R_{S(i)}, R_{A(j)})}{T}\right)} - \log \frac{\exp\left(\frac{\text{sim}(R_{A(i)}, R_{F(i)})}{T}\right)}{\sum_{j=1, i \neq j}^N \exp\left(\frac{\text{sim}(R_{A(i)}, R_{F(j)})}{T}\right)} \\ - \log \frac{\exp\left(\frac{\text{sim}(R_{F(i)}, R_{S(i)})}{T}\right)}{\sum_{j=1, i \neq j}^N \exp\left(\frac{\text{sim}(R_{F(i)}, R_{S(j)})}{T}\right)} \quad (5-16)$$

式中： $R_{S(i)}$ 、 $R_{A(i)}$ 、 $R_{F(i)}$ 分别表示分子*i*的序列特征，原子图特征以及片段图特征； $R_{S(j)}$ 、 $R_{A(j)}$ 、 $R_{F(j)}$ 分别表示分子*j*的序列特征，原子图特征以及片段图特征； $\text{sim}()$ 表示相似度函数， T 表示温度参数，用于调节相似度分布的尖锐程度。

除了对比损失外，我们还计算了基于融合特征的预测标签 P 与真实标签 Y 之间的预测损失。根据任务类型的不同，我们采用不同的损失函数。对于分类任务，我们采用 BCEWithLogitsLoss 损失函数，该函数结合了 Sigmoid 激活函数和二元交叉熵损失，能够保证训练过程的数值稳定性。对于回归任务，我们采用均方误差损失函数（Mean Squared Error Loss, MSELoss），衡量模型预测值与实际值之间的差异。由于对比损失和预测损失在数值尺度上存在差异，我们引入权重 ω 来平衡不同损失函数的影响，确保训练过程的稳定性。通过这种多任务损失设计，模型不仅能够优化预测性能，还能通过对比损失增强多模态特征空间的一致性，从而提升整体泛化能力。最终的总损失函数如下：

$$L = l(P, Y) + \omega \cdot L_{cl} \quad (5-17)$$

式中： l 表示预测任务损失函数， P 表示预测标签， Y 表示真实标签。

5.4 结果与讨论

5.4.1 结合亲和力预测结果及分析

我们首先在 PDBBind v2016 数据集上对 MF-Net 模型在 DTA 预测任务中的性能进行了系统评估。表 5-3 展示了 MF-Net 与无交互模型（如 DeepDTA 和 GAABind）以及交互模型（如 Pafnucy、OnionNet、IGN、MFE 和 EHIGN）的对比结果。所有模型均采用相同的训练集和验证集，并在核心集上进行测试，基线模型的预测结果引用自相关文献。与以往只报告最佳性能的研究不同，为确保实验结果的可靠性，我们采用不同随机种子进行三次独立运行，并以平均值和标准差形式呈现结果。注意，表中未附标准差的数据代表最佳性能，而非平均值。

表 5-3 MF-Net 与基线模型在 PDBBind v2016 核心集上的结合亲和力预测性能对比

模型	RMSE↓	MAE↓	Rp↑	SD↓
DeepDTA	1.443	1.148	0.749	1.445
GAABind	1.298	1.026	0.803	-
Pafnucy	1.418	1.129	0.775	1.375
OnionNet	1.287	0.983	0.781	1.282
IGN	1.22	0.94	0.837	-
MFE	<u>1.151</u>	<u>0.882</u>	<u>0.851</u>	<u>1.138</u>
EHIGN	<u>1.150 (0.022)</u>	-	<u>0.854 (0.004)</u>	-
MF-Net	1.127(0.004)	0.865(0.005)	0.862(0.005)	1.116(0.008)

实验结果表明，MF-Net 在 RMSE (1.127 ± 0.004)、MAE ($0.865 \pm$

0.005)、Rp (0.862 ± 0.005) 和 SD (1.116 ± 0.008) 四个指标上均达到了当前最先进水平, 显著优于其他基线模型。此外, 融合蛋白质表面、三维结构和序列信息的 MFE 模型也展现出较强性能, 其 RMSE 为 1.151。融合多模态特征能够生成更全面的分子表征, 增强模型捕捉药物-靶标间复杂相互作用的能力, 进一步验证了多模态融合在提升模型精度和鲁棒性方面的有效性。进一步分析发现, 除无交互模型 GAABind 在部分情况下优于基于交互的 Pafnucy 外, 其余基于交互的模型均显著优于无交互模型。这表明, 引入结构信息和物理交互能够有效提升模型性能, 尤其是在捕获药物-靶标结合的关键相互作用方面。MF-Net 在三次独立运行中表现出较低的标准差 (如 RMSE 的标准差为 ± 0.004), 表明其具有较高的稳定性和鲁棒性。而 EHIGN 在 RMSE 上的标准差为 ± 0.022 , 显著高于 MF-Net, 说明其性能受随机初始化和训练过程的影响较大。

5.4.2 消融实验结果及分析




图 5-3 不同 MF-Net 变体在 PDBBind v2016 核心集上的结合亲和力预测性能对比

表 5-4 不同 MF-Net 变体在 PDBBind v2016 核心集上的结合亲和力预测性能对比

模型	RMSE↓	MAE↓	SD↓	Rp↑
MF-Net_S	1.359(0.023)	1.070(0.013)	1.332(0.014)	0.789(0.006)
MF-Net_M	1.202(0.012)	0.909(0.008)	1.186(0.006)	0.836(0.003)
MF-Net_A	1.258(0.014)	0.977(0.015)	1.226(0.021)	0.826(0.007)
MF-Net_F	1.298(0.034)	1.002(0.022)	1.258(0.016)	0.816(0.005)
MF-Net_L	1.209(0.015)	0.933(0.012)	1.187(0.017)	0.838(0.005)
MF-Net	1.127(0.004)	0.865(0.005)	1.116(0.008)	0.862(0.005)

为了验证 MF-Net 各模块对整体性能的贡献, 我们在相同实验设置下开展了消融实验, 构建了以下 5 种简化变体:

MF-Net_S: 去除序列特征提取模块;

MF-Net_A: 去除原子图特征提取模块;

MF-Net_M: 去除片段图特征提取模块;

MF-Net_F: 简单串联序列、原子图以及片段图特征;

MF-Net_L: 去除对比损失。

图 5-3 和表 5-4 展示了 MF-Net 在 PDBBind v2016 核心集上的消融实验结果。结果表明, 完整的 MF-Net 模型在四个评估指标上均取得了最优性能, 显著优于其他变体, 充分验证了各组成部分在 DTA 预测任务中的互补作用。首先, 去除序列特征提取模块后, 模型性能显著下降: RMSE 增加 20.6%, MAE 增加 23.7%, SD 增加 19.4%, 而 Rp 降低 8.5%。这一结果凸显了序列特征在提供蛋白质和配体全局化学背景方面的不可替代性。其次, 去除原子图特征提取模块或片段图特征提取模块都会导致性能下降, 其中去除原子图特征提取模块的影响更加显著 (RMSE 增加 11.6%, MAE 增加 12.9%), 表明原子图特征在捕捉蛋白质口袋与配体间细粒度交互方面具有更强的表征能力。此外, 将序列特征、原子图特征和片段图特征简单串联的 MF-Net_F 在 RMSE 和 MAE 指标上表现较差, 显著低于完整 MF-Net, 突显了有效特征融合策略在处理多模态数据中的必要性。同时, MF-Net_F 在 RMSE 上的标准差为 ± 0.034 , 显著高于其他变体, 说明通过简单串联的方式融合多模态特征会导致模型性能的不稳定性。最后, 去除对比损失导致模型 RMSE 增加 7.3%, MAE 增加 7.9%, 验证了对比损失在增强多模态特征一致性和提升模型鲁棒性方面的关键作用。综上所述, 消融实验结果充分证明, MF-Net 各模块之间的协同作用对于捕捉药物-靶标复杂相互作用至关重要, 有效的多模态特征融合策略能够显著提升 DTA 预测的准确性和稳定性。

5.4.3 基于通用结构的虚拟筛选结果及分析

为了进一步验证 MF-Net 模型的实用价值, 我们在基于通用结构的虚拟筛选任务中对其进行了评估。该任务要求模型在包含多种靶标的数据集上进行训练和测试, 以评估其泛化能力。实验中, 我们将 MF-Net 与基于图神经网络的方法 (IGN、EHIGN)、基于经典机器学习的方法 (RFscore-VS) 以及经典分子对接方法 (Glide-SP) 进行了对比。所有基于机器学习的方法均在 DUD-E 数据集上训练和验证, 并在 DEKOIS2.0 数据集上测试, 其中四个靶标 (cyp2a6、er- β 、jak3 和 pdk1) 因与 RFscore-VS 特征处理不兼容而被排除。

图 5-4 展示了不同方法在虚拟筛选任务中的表现。实验结果表明, 传统分子对接方法 (Glide-SP) 和机器学习方法 (RFscore-VS) 在各项指标上均明显落后于基于图神经网络的方法, 进一步验证了深度学习方法在分子识别和早期富集任务中的优势。MF-Net 在 EF0.1% 和 EF0.5% 指标上分别取得了 29.05 和 23.72 的最高富集因子, 显著优于其他方法, 表明 MF-Net 在筛选少量化合物时, 能

够更有效地将活性化合物优先排在前列，从而在早期识别潜在最佳分子方面具有明显优势。然而，随着筛选比例的增加，IGN 和 EHIGN 在综合表现上更为出色，而 MF-Net 虽保持了较好的性能，但在大范围内检出活性化合物的能力相对较弱。这一现象可能源于 MF-Net 的训练策略和对比损失设计。MF-Net 更专注于训练数据中高活性化合物的特征模式。然而，随着筛选比例增加，数据分布可能逐渐偏离训练集的分布，导致模型对低活性或中等活性化合物的预测能力下降。此外，对比损失通过增强多模态特征一致性，在高精度筛选中提升了模型性能，但在大范围筛选中可能导致特征空间过于紧凑，降低模型的全局搜索能力。这一结果对实际虚拟筛选工作具有重要启示：在高精度筛选（如 EF0.1%和 EF0.5%）场景下，MF-Net 能够显著提升早期富集能力；而在大范围筛选（如 EF1%和 EF5%）任务中，IGN 和 EHIGN 等模型可能更为适用。因此，应根据具体任务需求选择合适的模型，以实现最佳的虚拟筛选效果。




图 5-4 MF-Net 与基线模型在基于通用结构的虚拟筛选任务中的性能对比

5.4.4 基于特定结构的虚拟筛选结果及分析

多年来，DUD-E 数据集一直被认为是评估基于机器学习方法虚拟筛选性能的黄金标准。然而，近期研究表明，该数据集中人工生成的诱饵可能存在隐性偏差，这可能导致预测精度的高估^[203, 204]。为此，本研究基于无偏数据集 LIT-PCBA，对 MF-Net 模型在基于特定结构的虚拟筛选任务中的性能进行了系统性验证。LIT-PCBA 数据集中的所有活性分子和诱饵分子均在统一条件下从实验数据中获取，并通过精心设计的活性分子与诱饵分子比例，更好地模拟了真实的筛选场景。MF-Net 与传统分子对接方法（Surflex、Glide SP）、机器学习方法（RFscore-VS）及图神经网络方法（IGN、EHIGN）进行了对比。我们仅选择其中活性化合物超过 100 个的 7 个靶标蛋白（KAT2A、PKM2、FEN1、MAPK1、

GBA、ALDH1、VDR) 进行实验, 并按照 LIT-PCBA 数据集原有的训练集和测试集进行模型训练与测试。

表 5-5 MF-Net 与基线模型在基于特定结构的虚拟筛选任务中的性能对比

靶点	模型	EF0.1%	EF0.5%	EF1%	EF5%
KAT2A	IFP	-	-	3.61	-
	GRIM	-	-	3.61	-
	Surflex	-	-	2.58	-
	Glide SP	0.00	0.00	0.00	0.83
	Rfscore-VS	0.00	0.00	2.08	1.25
	IGN	0.00	4.16	4.16	1.67
	EHIGN	41.47	16.67	16.67	4.58
	MF-Net	62.21	20.83	16.67	5.42
PKM2	IFP	-	-	7.14	-
	GRIM	-	-	5.86	-
	Surflex	-	-	0.18	-
	Glide SP	0.00	0.00	0.00	0.97
	Rfscore-VS	8.30	1.66	1.66	1.83
	IGN	0.00	3.32	2.50	3.50
	EHIGN	21.78	7.33	8.08	4.56
	MF-Net	21.78	14.66	9.55	4.85
FEN1	IFP	-	-	6.78	-
	GRIM	-	-	7.32	-
	Surflex	-	-	4.34	-
	Glide SP	0.00	2.17	2.17	4.13
	Rfscore-VS	65.05	26.08	14.13	5.22
	IGN	119.26	41.29	30.42	10.65
	EHIGN	154.57	75.41	52.18	14.22
	MF-Net	209.77	66.54	42.19	13.33
MAPK1	IFP	-	-	1.62	-
	GRIM	-	-	3.90	-
	Surflex	-	-	1.62	-
	EHIGN	37.96	12.98	9.08	3.37
	MF-Net	50.61	18.17	11.68	4.41
GBA	IFP	-	-	9.64	-
	GRIM	-	-	10.84	-
	Surflex	-	-	8.43	-
	EHIGN	96.87	38.96	26.82	7.80
	MF-Net	121.05	48.69	29.25	9.27
ALDH1	IFP	-	-	15.35	-
	GRIM	-	-	15.76	-
	Surflex	-	-	0.96	-
	EHIGN	14.99	12.14	9.90	5.49
	MF-Net	20.24	13.64	11.84	6.13
VDR	IFP	-	-	1.24	-
	GRIM	-	-	1.24	-
	Surflex	-	-	0.00	-
	EHIGN	38.70	20.77	18.82	7.01
	MF-Net	38.70	22.07	16.88	6.88

表 5-5 展示了不同模型在 LIT-PCBA 数据集的 7 个代表性靶标上, 针对不同阈值 (EF0.1%、EF0.5%、EF1%、EF5%) 计算的富集因子。实验结果表明, 传

统分子对接方法（Glide SP 和 Surflex）在多数靶标蛋白上的表现接近随机筛选水平（如 Glide SP 在 KAT2A、PKM2 和 FEN1 靶标蛋白上的 EF0.1%均为 0.00），尤其在低 EF 阈值（如 EF0.1%）下，其预测能力显著受限，这凸显了 LIT-PCBA 数据集的高挑战性。相比之下，人工智能驱动的方法（如 MF-Net 和 EHIGN）展现出显著优势，其中 MF-Net 在早期富集能力（EF0.1%）上表现尤为突出：在 KAT2A 靶点中 EF0.1%达到 62.21，较次优模型 EHIGN 提升 50%；在 FEN1 靶点中 EF0.1%高达 209.77，较 EHIGN 提升 35.7%。此外，MF-Net 在 7 个靶点中的 5 个上取得最佳综合性能，并且在 EF5%水平上仍保持竞争力，验证了其跨靶点的鲁棒性和泛化能力。MF-Net 的卓越性能归因于多模态特征融合策略，通过整合序列、原子图和片段图特征，模型能够捕获药物-靶标相互作用的全局与局部特征，从而生成更具判别性的分子表征。此外，MF-Net 在早期富集任务中的显著优势表明，该模型能够高效筛选出高潜力化合物，显著缩短药物发现周期。这一结果对实际药物研发具有重要启示：在需要快速锁定先导化合物的早期筛选中，MF-Net 可作为优先工具。

5.4.5 可视化分析

为深入揭示不同模态特征对最终预测的贡献，我们对 PDB ID 为 2V3E 的药物-靶标复合物进行了配体原子重要性的可视化分析。图 5-5 展示了序列、原子图和片段图三种模态下分子组分对结合亲和力的影响，颜色深度表示原子对预测结果的重要性。同时，通过 Schrödinger 软件（2019 版）识别药物-靶标相互作用，并以二维图谱形式呈现（图 6-5E）。结果显示，配体上的四个羟基能够与残基 TRP179、TRP381、ASN234、ASP127、GLU340 和 ASN396 形成氢键。这些氢键不仅为药物-靶标相互作用提供了结合能量，还精确锚定了配体的位置，显著提高了选择性。此外，配体中的氨基与 GLU235 和 GLU340 形成盐桥，并与 TYR313 产生阳离子- π 相互作用。盐桥和阳离子- π 相互作用与氢键协同作用，进一步增强了配体的选择性和稳定性。这些相互作用（氢键、盐桥和阳离子- π ）对结合亲和力具有关键影响。

可视化结果表明，序列、原子图和片段图三种模态特征能够捕捉到氢键、盐桥、亲疏水性以及阳离子- π 等关键相互作用，但它们对分子中不同原子的关注程度存在差异，进一步揭示了不同模态的特征捕捉能力。具体而言，序列特征主要聚焦于对结合亲和力至关重要的氢键，因此在消融实验中去除序列信息后，模型性能下降最为明显；原子图特征在捕捉氢键、盐桥和阳离子- π 相互作用方面表现突出，能够精确描述原子级的局部化学环境；而片段图特征虽然能够捕捉到各个功能域，但在主次分配上相对模糊，表明其更适合用于捕捉全局

功能信息。通过融合序列、原子图和片段图三种模态特征，模型不仅能够同时捕捉氢键、盐桥、亲疏水作用和阳离子- π 等多种关键结合模式，还能对最重要的氢键给予更高权重。这种多模态融合策略显著增强了模型对药物-靶标复杂相互作用的表征能力，验证了其在结合亲和力预测中的有效性。




图 5-5 PDB 复合物 2V3E 的关键特征可视化。(A) 基于序列特征的关键特征可视化；(B) 基于原子图特征的关键特征可视化；(C) 基于片段图特征的关键特征可视化；(D) 基于融合特征的关键特征可视化；(E) Schrödinger 软件（2019 版）识别的药物-靶标复合物二维相互作用图谱。颜色深度表示原子对预测结果的重要性；二维相互作用图谱中紫色虚线箭头为氢键相互作用，彩色实线为盐桥，红色实线为阳离子- π 相互作用，灰色圆环为疏水作用。

5.5 本章小结

本章提出基于多模态特征融合的 MF-Net 模型，旨在通过整合药物-靶标复合物的序列、原子图和片段图特征，全面捕捉药物-靶标复合物在不同尺度上的交互信息，为 DTA 预测提供了新的解决方案。MF-Net 采用了多模态输入策略，全面捕捉药物-靶标的全局背景、局部原子级以及高层次功能域交互信息。将指纹特征作为片段节点的初始化特征，充分利用了先验知识与学习表征的优势。同时，引入自适应特征融合和对比损失，显著提升了模型对异构数据的处理能力。在 PDBBind v2016 数据集上进行的 DTA 预测实验中，MF-Net 展示了优于现有基线模型的先进性能；在 DUD-E、DEKOIS2.0 及无偏 LIT-PCBA 数据集上的虚拟筛选评估中，MF-Net 同样展现了出色的早期筛选能力和鲁棒性。上述结果充分验证了模型在捕捉药物-靶标复杂交互关系和快速识别活性化合物方面的优势。最后，消融实验和可视化分析进一步验证了各模态特征对模型性能的显著贡献，同时表明高效的特征融合策略在捕捉药物-靶标复杂相互作用中起到了关键作用。总体而言，MF-Net 不仅显著提升了结合亲和力预测的准确性，同时也为药物筛选和新药发现提供了稳健、全面的多尺度分子表征方法。

第六章 结论与展望

6.1 本文总结

分子性质与药物-靶标相互作用预测研究贯穿于药物研发的各个阶段，是加速新药发现、降低实验成本的关键环节。传统实验方法成本高、周期长，经典计算方法又难以适应大规模数据处理。近年来，以深度学习为代表的驱动技术通过自主学习分子结构与功能之间的关联，显著提升了预测效率。但受限于表征能力与模型可解释性，仍需融合化学领域知识以及多模态数据，构建更具通用性和鲁棒性的预测模型。本研究围绕知识引导与多模态融合策略，通过整合化学家的“因果推理”能力与深度学习的“关联挖掘”能力，提出了三个面向不同任务的深度学习模型。

首先，针对现有分子表征方法在多尺度结构与功能特征融合方面的不足，提出了指纹增强的分层图神经网络（FH-GNN）。该方法构建原子级、基序级和分子级的三级分层分子图，实现多尺度结构建模；同时引入分子指纹编码，结合化学先验知识，强化功能基团的表达能力。通过自适应注意力机制融合图表示与指纹特征，生成更具判别性的分子表示。实验结果显示，FH-GNN 在 MoleculeNet 提供的 8 个基准数据集（含分类与回归任务）中整体优于现有模型。注意力权重可视化进一步揭示了关键功能基团与理化性质之间的关联，增强了模型的可解释性。

其次，针对药物-靶标相互作用预测中模型泛化能力不足的问题，提出了双分支特征提取框架（E-DIS）。该框架通过同步学习领域通用特征与领域特定特征，并结合可训练门控网络动态加权特征贡献，克服了传统模型对单一特征模式的依赖。实验结果表明，E-DIS 在领域内与跨领域设置（如冷启动、聚类分割）下均显著优于现有领域自适应方法（如 BAT、CDAN）。此外，该框架具备良好的灵活性与可扩展性，可为新药发现提供高效支持，并推广至其他相关任务。

最后，为突破药物-靶标复合物多模态建模的局限，提出了多模态特征融合模型 MF-Net。该模型融合序列、原子图与片段图三类特征，分别捕捉全局化学背景、局部原子级交互以及高层次功能域间的相互作用，并将分子指纹引入片段节点初始化以整合化学先验知识。通过自适应特征融合与对比损失机制，动态分配各模态权重并对齐潜在空间分布，显著提升了异构数据处理能力。实验表明，MF-Net 在 PDBBind v2016 的 DTA 预测任务中优于基线模型，在 DUD-E、DEKOIS2.0 和 LIT-PCBA 的虚拟筛选任务中展现出优异的早期筛选能力与鲁棒

性。消融实验与可视化分析验证了多模态建模的有效性与可解释性。

总之，本论文在知识嵌入、特征融合与模型架构上实现了系统性创新。通过融合分子指纹、领域特征和多模态数据，强化了模型对化学知识与数据规律的联合建模能力，充分发挥了知识引导与数据驱动的协同优势。提出的 FH-GNN、E-DIS 与 MF-Net 分别面向分子性质预测、DTI 跨领域泛化及 DTA 多模态建模，显著提升了模型的表征能力、可解释性与鲁棒性。在分类、回归、跨领域泛化及虚拟筛选等多类任务中展现出优越性能，为分子计算与智能药物设计提供了可靠的技术支撑。

6.2 工作展望

本研究的创新性成果为分子性质预测及药物-靶标相互作用预测提供了新方法，但仍有若干方向值得进一步探索与完善：

模型可解释性的深化与验证：当前工作（如 FH-GNN 的注意力权重可视化）初步揭示了分子特征与性质间的关联，但化学作用的微观机制仍需更严谨的理论支撑。未来可结合因果推理模型或符号学习方法，构建可解释的化学规则库，量化功能基团、键合模式等对预测结果的贡献度，为药物设计提供更具指导性的理论依据。

动态交互与时空演化的建模：现有方法主要针对静态分子结构建模，而实际药物-靶标结合过程涉及构象变化与动态相互作用。未来可引入动态图神经网络或时序建模技术，捕捉分子结合过程中的能量变化与构象调整，提升对结合动力学行为的预测精度。

多模态数据的深度融合与扩展：尽管 MF-Net 已整合序列、原子图与片段图特征，但药物研发中还存在大量未充分利用的数据类型（如 3D 晶体结构、质谱数据或体外实验指标）。未来可探索跨模态对齐技术，将非结构化实验数据与计算模型结合，构建更全面的分子表征体系。

计算效率与泛化能力的协同优化：当前框架在提升预测精度和泛化能力的同时增加了模型的复杂度。未来需研究轻量化架构设计，在保证性能的前提下降低计算开销；同时，结合元学习技术，实现小样本场景下的快速领域自适应，拓展模型在资源受限场景的应用潜力。

自动化药物设计闭环的构建：未来可结合生成式模型（如扩散模型或强化学习），将分子性质预测、虚拟筛选与分子生成整合为闭环系统，实现从靶点识别到先导化合物优化的全流程自动化。例如，基于 FH-GNN 的预测结果指导生成模型定向优化分子结构，再通过 MF-Net 评估生成分子的结合亲和力，形

成迭代式设计范式。

跨学科应用场景的拓展：本研究的核心方法（如分层图建模与多模态融合）可迁移至材料设计、环境污染物降解预测或催化剂开发等领域。例如，将 FH-GNN 扩展至金属有机框架材料的孔隙率预测，或利用 E-DIS 框架分析催化剂在不同反应体系中的活性泛化规律，推动计算化学技术的跨领域渗透。

参考文献

- [1] DiMasi, J.A., Grabowski, H.G., Hansen, R.W. Innovation in the pharmaceutical industry: New estimates of R&D costs[J]. *Journal of Health Economics*, 2016, 47(3): 20-33.
- [2] Deore, A.B., Dhumane, J.R., Wagh, R., et al. The Stages of Drug Discovery and Development Process[J]. *Asian Journal of Pharmaceutical Research and Development*, 2019, 7(6): 62-67.
- [3] Paul, S.M., Mytelka, D.S., Dunwiddie, C.T., et al. How to improve RD productivity: The pharmaceutical industry's grand challenge[J]. *Nature Reviews Drug Discovery*, 2010, 9(3): 203-214.
- [4] De La Fuente, J., Serrano, G., Veleiro, U., et al. Towards a more inductive world for drug repurposing approaches[J]. *Nature Machine Intelligence*, 2025, 10(1038): 1-17.
- [5] Yao, L., Evans, J.A., Rzhetsky, A. Novel opportunities for computational biology and sociology in drug discovery[J]. *Trends in Biotechnology*, 2010, 28(4): 161-170.
- [6] McInnes, C. Virtual screening strategies in drug discovery[J]. *Current Opinion in Chemical Biology*, 2007, 11(5): 494-502.
- [7] Sim, J., Kim, D., Kim, B., et al. Recent advances in AI-driven protein-ligand interaction predictions[J]. *Current Opinion in Structural Biology*, 2025, 92(103020): 1-8.
- [8] Singh, N., Vayer, P., Tanwar, S., et al. Drug discovery and development: introduction to the general public and patient groups[J]. *Frontiers in Drug Discovery*, 2023, 3(5): 1-11.
- [9] Jensen, J.H., Kromann, J.C. The molecule calculator: A web application for fast quantum mechanics-based estimation of molecular properties[J]. *Journal of Chemical Education*, 2013, 90(8): 1093-1095.
- [10] Polgar, T., M. Keseru, G. Integration of Virtual and High Throughput Screening in Lead Discovery Settings[J]. *Combinatorial Chemistry & High Throughput Screening*, 2011, 14(10): 889-897.
- [11] Yi Liu, Limei Wang, Meng Liu, Yuchao Lin, Xuan Zhang, B.O.& S.J. Spherical message passing for 3D molecular graphs[A]. *International Conference on Learning Representations[C]*. 2022: 1-13.
- [12] Valsson, Í., Warren, M.T., Deane, C.M., et al. Narrowing the gap between machine learning scoring functions and free energy perturbation using augmented data[J]. *Communications Chemistry*, 2025, 8(1): 1-12.
- [13] Su, Q., Wang, J., Gou, Q., et al. Robust protein-ligand interaction modeling through integrating physical laws and geometric knowledge for absolute binding free energy calculation[J]. *Chemical Science*, 2025, 10(1039): 1-15.
- [14] Lu, Z., Song, G., Zhu, H., et al. DTIAM: a unified framework for predicting drug-target interactions, binding affinities and drug mechanisms[J]. *Nature Communications*, 2025, 16(2548): 1-17.
- [15] He, H., Chen, G., Tang, Z., et al. Dual modality feature fused neural network integrating binding site information for drug target affinity prediction[J]. *Digital Medicine*, 2025, 8(1):

- 1-14.
- [16] Martinez-Mayorga, K., Gonzalez-Ponce, K., Martinez-Mayorga, K., et al. The pursuit of accurate predictive models of the bioactivity of small molecules[J]. *Chemical Science*, 2024, 15(6): 1938-1952.
- [17] Wen, S., Nanda, K., Huang, Y., et al. Practical quantum mechanics-based fragment methods for predicting molecular crystal properties[J]. *Physical Chemistry Chemical Physics*, 2012, 14(21): 7578-7590.
- [18] Hasselgren, C., Oprea, T.I. Artificial Intelligence for Drug Discovery: Are We There Yet?[J]. *Annual Review of Pharmacology and Toxicology*, 2024, 64(3): 527-550.
- [19] Maguire, P., Speder, B., Tremble, L. Artificial intelligence in drug discovery: applications and techniques[J]. *Regulatory Rapporteur*, 2022, 21(1): 1-19.
- [20] Askr, H., Elgeldawi, E., Aboul Ella, H., et al. Deep learning in drug discovery: an integrative review and future challenges[J]. *Artificial Intelligence Review*, 2023, 56(7): 5975-6037.
- [21] Kang, L., Zhou, S., Fang, S., et al. Adapting differential molecular representation with hierarchical prompts for multi-label property prediction[J]. *Briefings in Bioinformatics*, 2024, 25(5): 1-10.
- [22] Yanmei, L., Yijia, W., Lei, D., et al. MvMRL: a multi-view molecular representation learning[J]. *Briefings in Bioinformatics*, 2024, 25(4): 298-312.
- [23] Rollins, Z.A., Cheng, A.C., Metwally, E. MolPROP: Molecular Property prediction with multimodal language and graph fusion[J]. *Journal of Cheminformatics*, 2024, 16(1): 1-11.
- [24] Jiang, X., Tan, L., Zou, Q. DGCL: dual-graph neural networks contrastive learning for molecular property prediction[J]. *Briefings in bioinformatics*, 2024, 25(6): 474-486.
- [25] Li, R., Lu, J., Liu, Z., et al. Reusability report: exploring the utility of variational graph encoders for predicting molecular toxicity in drug design[J]. *Nature Machine Intelligence*, 2024, 1(6): 1038-1051.
- [26] Song, L., Zhu, H., Wang, K., et al. LGGA-MPP: Local Geometry-Guided Graph Attention for Molecular Property Prediction[J]. *Journal of Chemical Information and Modeling*, 2024, 64(8): 3105-3113.
- [27] Zhou, Z., Kearnes, S., Li, L., et al. Optimization of Molecules via Deep Reinforcement Learning[J]. *Scientific Reports*, 2018, 9(7): 10752-10762.
- [28] Liu, S., Yu, J., Ni, N., et al. Versatile Framework for Drug-Target Interaction Prediction by Considering Domain-Specific Features[J]. *Journal of Chemical Information and Modeling*, 2024, 64(14): 5646-5656.
- [29] Wang, G., Zhang, H., Shao, M., et al. DeepTGIN: a novel hybrid multimodal approach using transformers and graph isomorphism networks for protein-ligand binding affinity prediction[J]. *Journal of Cheminformatics*, 2024, 16(147): 14711-14723.
- [30] Huang, K., Xiao, C., Glass, L.M., et al. MolTrans: Molecular Interaction Transformer for drug-target interaction prediction[J]. *Bioinformatics*, 2021, 37(6): 830-836.
- [31] Stepniewska-Dziubinska, M.M., Zielenkiewicz, P., Siedlecki, P. Development and evaluation of a deep learning model for protein-ligand binding affinity prediction[J]. *Bioinformatics*, 2018, 34(21): 3666-3674.

- [32] Yang, Z., Zhong, W., Lv, Q., et al. Interaction-Based Inductive Bias in Graph Neural Networks: Enhancing Protein-Ligand Binding Affinity Predictions From 3D Structures[A]. Transactions on Pattern Analysis and Machine Intelligence[C]. 2024, PP(8): 1-18.
- [33] Lin, X., Quan, Z., Wang, Z.J., et al. A novel molecular representation with BiGRU neural networks for learning atom[J]. Briefings in Bioinformatics, 2020, 21(6): 2099-2111.
- [34] Wu, C.K., Zhang, X.C., Yang, Z.J., et al. Learning to SMILES: BAN-based strategies to improve latent representation learning from molecules[J]. Briefings in Bioinformatics, 2021, 22(6): 1-9.
- [35] Nazarova, A.L., Yang, L., Liu, K., et al. Dielectric Polymer Property Prediction Using Recurrent Neural Networks with Optimizations[J]. Journal of Chemical Information and Modeling, 2021, 61(5): 2175-2186.
- [36] Wang, Z., Su, Y., Shen, W., et al. Predictive deep learning models for environmental properties: The direct calculation of octanol-water partition coefficients from molecular graphs[J]. Applications of Artificial Intelligence in Process Systems Engineering, 2021, 3(16): 39-66.
- [37] Hirohara, M., Saito, Y., Koda, Y., et al. Convolutional neural network based on SMILES representation of compounds for detecting chemical motif[J]. BMC Bioinformatics, 2018, 19(19): 526-538.
- [38] Chen, J.H., Tseng, Y.J. Different molecular enumeration influences in deep learning: An example using aqueous solubility[J]. Briefings in Bioinformatics, 2021, 22(3): 1-13.
- [39] Jiang, P., Chi, Y., Li, X.S., et al. Molecular persistent spectral image (Mol-PSI) representation for machine learning models in drug design[J]. Briefings in Bioinformatics, 2022, 23(1): 1-14.
- [40] Kuzminykh, D., Polykovskiy, D., Kadurin, A., et al. 3D Molecular Representations Based on the Wave Transform for Convolutional Neural Networks[J]. Molecular Pharmaceutics, 2018, 15(10): 4378-4385.
- [41] Liu, S., Li, J., Bennett, K.C., et al. Multiresolution 3D-DenseNet for Chemical Shift Prediction in NMR Crystallography[J]. Journal of Physical Chemistry Letters, 2019, 10(16): 4558-4565.
- [42] Sunseri, J., Koes, D.R. Libmolgrid: Graphics Processing Unit Accelerated Molecular Gridding for Deep Learning Applications[J]. Journal of Chemical Information and Modeling, 2020, 60(3): 1079-1084.
- [43] Xiong, Z., Wang, D., Liu, X., et al. Pushing the Boundaries of Molecular Representation for Drug Discovery with the Graph Attention Mechanism[J]. Journal of Medicinal Chemistry, 2020, 63(16): 8749-8760.
- [44] Withnall, M., Lindelöf, E., Engkvist, O., et al. Building attention and edge message passing neural networks for bioactivity and physical-chemical property prediction[J]. Journal of Cheminformatics, 2020, 12(1): 1-18.
- [45] Li, P., Li, Y., Hsieh, C.Y., et al. TrimNet: learning molecular representation from triplet messages for biomedicine[J]. Briefings in Bioinformatics, 2020, 5(33): 1-10.
- [46] Zhang, X., Chen, C., Meng, Z., et al. CoAtGIN: Marrying Convolution and Attention for Graph-based Molecule Property Prediction[A]. International Conference on

- Bioinformatics and Biomedicine[C]. 2022: 374-379.
- [47] Song, Y., Zheng, S., Niu, Z., et al. Communicative representation learning on attributed molecular graphs[A]. International Joint Conference on Artificial Intelligence[C]. 2020: 2831-2838.
- [48] Fuchs, F.B., Welling, M. Equivariant Attention Networks[A]. Neural Information Processing Systems[C]. 2020(3): 1-12.
- [49] Schütt, K.T., Unke, O.T., Gastegger, M. Equivariant Message Passing for the Prediction of Tensorial Properties and Molecular Spectra[A]. Proceedings of Machine Learning Research[C]. 2021, 139: 9377-9388.
- [50] Wang, S., Guo, Y., Wang, Y., et al. Smiles-Bert: Large scale unsupervised pre-training for molecular property prediction[A]. Computational Biology and Health Informatics[C]. 2019: 429-436.
- [51] Wang, Y., Chen, X., Min, Y., et al. MolCloze: A Unified Cloze-style Self-supervised Molecular Structure Learning Model for Chemical Property Prediction[A]. International Conference on Bioinformatics and Biomedicine[C]. 2021: 2896-2903.
- [52] Yüksel, A., Ulusoy, E., Ünlü, A., et al. SELFormer: molecular representation learning via SELFIES language models[J]. Machine Learning: Science and Technology, 2023, 4(2): 1-21.
- [53] Su, J., Ahmed, M., Lu, Y., et al. RoFormer: Enhanced transformer with Rotary Position Embedding[J]. Neurocomputing, 2024, 568(8): 1-12.
- [54] Rong, Y., Bian, Y., Xu, T., et al. Self-supervised message passing transformer on large-scale molecular data[A]. Advances in Neural Information Processing Systems[C]. 2020(33): 1-18.
- [55] Park, W., Chang, W., Lee, D., et al. GRPE: Relative Positional Encoding for Graph Transformer[A]. arXiv[C]. 2022: 1-8.
- [56] Hussain, M.S., Zaki, M.J., Subramanian, D. Global Self-Attention as a Replacement for Graph Convolution[A]. International Conference on Knowledge Discovery and Data Mining[C]. 2022: 655-665.
- [57] Yin, S., Zhong, G. LGI-GT: Graph Transformers with Local and Global Operators Interleaving[A]. International Joint Conference on Artificial Intelligence[C]. 2023, 8: 4504-4512.
- [58] Öztürk, H., Özgür, A., Ozkirimli, E. DeepDTA: Deep drug-target binding affinity prediction[J]. Bioinformatics, 2018, 34(17): i821-i829.
- [59] Öztürk, H., Ozkirimli, E., Özgür, A. WideDTA: prediction of drug-target binding affinity[A]. arXiv[C]. 2019: 1-12.
- [60] Karimi, M., Wu, D., Wang, Z., et al. DeepAffinity: Interpretable deep learning of compound-protein affinity through unified recurrent and convolutional neural networks[J]. Bioinformatics, 2019, 35(18): 3329-3338.
- [61] Li, T., Zhao, X.M., Li, L. Co-VAE: Drug-Target Binding Affinity Prediction by Co-Regularized Variational Autoencoders[J]. Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(12): 8861-8873.
- [62] Shin, B., Park, S., Kang, K., et al. Self-Attention Based Molecule Representation for

- Predicting Drug-Target Interaction[A]. Proceedings of Machine Learning Research[C]. 2019, 106: 230-248.
- [63] Zhang, L., Wang, C.C., Chen, X. Predicting drug-target binding affinity through molecule representation block based on multi-head attention and skip connection[J]. Briefings in Bioinformatics, 2022, 23(6): 1-12.
- [64] Monteiro, N.R.C., Oliveira, J.L., Arrais, J.P. DTITR: End-to-end drug-target binding affinity prediction with transformers[J]. Computers in Biology and Medicine, 2022, 147(7): 105772-105785.
- [65] Wang, J., Wen, N.F., Wang, C., et al. ELECTRA-DTA: a new compound-protein binding affinity prediction model based on the contextualized sequence encoding[J]. Journal of Cheminformatics, 2022, 14(1): 1-14.
- [66] Jiang, M., Li, Z., Zhang, S., et al. Drug-target affinity prediction using graph neural network and contact maps[J]. RSC Advances, 2020, 10(35): 20701-20712.
- [67] Jiang, M., Wang, S., Zhang, S., et al. Sequence-based drug-target affinity prediction using weighted graph neural networks[J]. BMC Genomics, 2022, 23(1): 1-17.
- [68] Lin, Z., Akin, H., Rao, R., et al. Evolutionary-scale prediction of atomic-level protein structure with a language model[J]. Science, 2023, 379(6637): 1123-1130.
- [69] Bi, X., Zhang, S., Ma, W., et al. HiSIF-DTA: A Hierarchical Semantic Information Fusion Framework for Drug-Target Affinity Prediction[J]. Journal of Biomedical and Health Informatics, 2023, 29(3): 1579-1590.
- [70] Kwon, Y., Shin, W.H., Ko, J., et al. AK-score: Accurate protein-ligand binding affinity prediction using an ensemble of 3D-convolutional neural networks[J]. International Journal of Molecular Sciences, 2020, 21(22): 1-16.
- [71] Wang, Y., Wei, Z., Xi, L. Sfcnn: a novel scoring function based on 3D convolutional neural network for accurate and stable protein-ligand affinity prediction[J]. Bioinformatics, 2022, 23(1): 1-18.
- [72] Tian, C., Wang, L., Cui, Z., et al. GTAMP-DTA: Graph transformer combined with attention mechanism for drug-target binding affinity prediction[J]. Computational Biology and Chemistry, 2024, 108(9): 107982.
- [73] Wu, H., Liu, J., Jiang, T., et al. AttentionMGT-DTA: A multi-modal drug-target affinity prediction using graph transformer and attention mechanism[J]. Neural Networks, 2024, 169(6): 623-636.
- [74] Wang, P., Zheng, S., Jiang, Y., et al. Structure-Aware Multimodal Deep Learning for Drug-Protein Interaction Prediction[J]. Journal of Chemical Information and Modeling, 2022, 62(5): 1308-1317.
- [75] Xiao, X., Wang, W., Xie, J., et al. HGTDPA-DTA: Hybrid Graph-Transformer with Dynamic Prompt for Drug-Target Binding Affinity Prediction[A]. arXiv[C]. 2024: 1-15.
- [76] Kuang, T., Liu, P., Ren, Z. Impact of Domain Knowledge and Multi-Modality on Intelligent Molecular Property Prediction: A Systematic Survey[J]. Big Data Mining and Analytics, 2024, 7(3): 858-888.
- [77] Abraham, M.H., Le, J. The correlation and prediction of the solubility of compounds in water using an amended solvation energy relationship[J]. Journal of Pharmaceutical

- Sciences, 1999, 88(9): 868-880.
- [78] Rubino, J.T., Yalkowsky, S.H. Cosolvency and Cosolvent Polarity[J]. *Pharmaceutical Research: An Official Journal of the American Association of Pharmaceutical Scientists*, 1987, 4(3): 220-230.
- [79] Maziarka, L., Danel, T., Mucha, S., et al. Molecule Attention Transformer[A]. *Machine Learning[C]*. 2020: 1-16.
- [80] Etworks, G.R.T.R.N., Chen, C. cheng J. Pre-training molecular graph representation with 3D geometry[A]. *International Conference on Learning Representations[C]*. 2020: 1-24.
- [81] Yin, Z., Song, W., Li, B., et al. Neural networks prediction of the protein-ligand binding affinity with circular fingerprints[J]. *Technology and health care : official journal of the European Society for Engineering and Medicine*, 2023, 31(S1): 487-495.
- [82] Kwon, S., Bae, H., Jo, J., et al. Comprehensive ensemble in QSAR prediction for drug discovery[J]. *Bioinformatics*, 2019, 20(1): 1-12.
- [83] Xie, L., Xu, L., Kong, R., et al. Improvement of Prediction Performance With Conjoint Molecular Fingerprint in Deep Learning[J]. *Frontiers in Pharmacology*, 2020, 11(12): 1-15.
- [84] Xie, L., Xu, L., Chang, S., et al. Multitask deep networks with grid featurization achieve improved scoring performance for protein–ligand binding[J]. *Chemical Biology and Drug Design*, 2020, 96(3): 973-983.
- [85] Stahlschmidt, S.R., Ulfenborg, B., Synnergren, J. Multimodal deep learning for biomedical data fusion: A review[J]. *Briefings in Bioinformatics*, 2022, 23(2): 1-15.
- [86] Baltrusaitis, T., Ahuja, C., Morency, L.P. Multimodal Machine Learning: A Survey and Taxonomy[J]. *Transactions on Pattern Analysis and Machine Intelligence*, 2019, 41(2): 423-443.
- [87] Sun, Y., Chen, Y., Ma, W., et al. PEMP: Leveraging Physics Properties to Enhance Molecular Property Prediction[A]. *International Conference on Information and Knowledge Management, Proceedings[C]*. 2022: 3505-3513.
- [88] Yang, S., Li, Z., Song, G., et al. Deep Molecular Representation Learning via Fusing Physical and Chemical Information[A]. *Advances in Neural Information Processing Systems[C]*. 2021, 20(NeurIPS): 16346-16357.
- [89] Zhou, G., Gao, Z., Ding, Q., et al. Uni-Mol: A universal 3D molecular representation learning framework[A]. *International Conference on Learning Representations[C]*. 2023: 1-31.
- [90] Gao, J., Shen, Z., Xie, Y., et al. TransFoxMol: predicting molecular property with focused attention[J]. *Briefings in Bioinformatics*, 2023, 24(5): 1-11.
- [91] Zang, X., Zhao, X., Tang, B. Hierarchical Molecular Graph Self-Supervised Learning for property prediction[J]. *Communications Chemistry*, 2023, 6(1): 34-44.
- [92] Gao, J., Gao, J., Ying, X., et al. Higher-Order Interaction Goes Neural: A Substructure Assembling Graph Attention Network for Graph Classification[J]. *Transactions on Knowledge and Data Engineering*, 2023, 35(2): 1594-1608.
- [93] Wu, F., Radev, D., Li, S.Z. Molformer: Motif-Based Transformer on 3D Heterogeneous Molecular Graphs[A]. *Conference on Artificial Intelligence[C]*. 2023, 37: 5312-5320.
- [94] Jiang, Y., Jin, S., Jin, X., et al. Pharmacophoric-constrained heterogeneous graph

- transformer model for molecular property prediction[J]. *Communications Chemistry*, 2023, 6(1): 1038-1047.
- [95] Cai, H., Zhang, H., Zhao, D., et al. FP-GNN: a versatile deep learning architecture for enhanced molecular property prediction[J]. *Briefings in Bioinformatics*, 2022, 23(6): 408-420.
- [96] Wang, X., Li, Z., Jiang, M., et al. Molecule Property Prediction Based on Spatial Graph Embedding[J]. *Journal of Chemical Information and Modeling*, 2019, 59(9): 3817-3828.
- [97] Liu, J., Lei, X., Zhang, Y., et al. The prediction of molecular toxicity based on BiGRU and GraphSAGE[J]. *Computers in Biology and Medicine*, 2023, 153(9): 106524-106536.
- [98] Guo, Z., Yu, W., Zhang, C., et al. GraSeq: Graph and Sequence Fusion Learning for Molecular Property Prediction[A]. *International Conference on Information and Knowledge Management, Proceedings[C]*. 2020: 435-443.
- [99] Liu, P., Ren, Y., Tao, J., et al. GIT-Mol: A multi-modal large language model for molecular science with graph, image, and text[J]. *Computers in Biology and Medicine*, 2024, 171(10): 108073-108084.
- [100] Wang, Z., Liu, M., Luo, Y., et al. Advanced graph and sequence neural networks for molecular property prediction and drug discovery[J]. *Bioinformatics*, 2022, 38(9): 2579-2586.
- [101] Tang, Q., Nie, F., Zhao, Q., et al. A merged molecular representation deep learning method for blood-brain barrier permeability prediction[J]. *Briefings in Bioinformatics*, 2022, 23(5): 1-10.
- [102] Hoogeboom, E., Satorras, V.G., Vignac, C., et al. Out-of-the-box deep learning prediction of pharmaceutical properties by broadly learned knowledge-based molecular representations[J]. *Nature Machine Intelligence*, 2021, 3(4): 334-343.
- [103] Chen, D., Gao, K., Nguyen, D.D., et al. Algebraic graph-assisted bidirectional transformers for molecular property prediction[J]. *Nature Communications*, 2021, 12(1): 3521-3530.
- [104] Xu, S., Shen, L., Zhang, M., et al. Surface-based multimodal protein-ligand binding affinity prediction[J]. *Bioinformatics*, 2024, 40(7): 1-8.
- [105] Ali Vefghi, Zahed Rahmati, M.A. Drug-target interaction/affinity prediction: deep learning models and advances review[A]. *arXiv[C]*. 2025: 1-64.
- [106] Zhang, T., Chen, S., Wulamu, A., et al. TransG-net: transformer and graph neural network based multi-modal data fusion network for molecular properties prediction[J]. *Applied Intelligence*, 2023, 53(12): 16077-16088.
- [107] Deng, J., Yang, Z., Wang, H., et al. A systematic study of key elements underlying molecular property prediction[J]. *Nature Communications*, 2023, 14(1): 6395-6415.
- [108] Cereto-Massagué, A., Ojeda, M.J., Valls, C., et al. Molecular fingerprint similarity search in virtual screening[J]. *Methods*, 2015, 71(C): 58-63.
- [109] Durant, J.L., Leland, B.A., Henry, D.R., et al. Reoptimization of MDL keys for use in drug discovery[J]. *Journal of Chemical Information and Computer Sciences*, 2002, 42(6): 1273-1280.
- [110] Rogers, D., Hahn, M. Extended-connectivity fingerprints[J]. *Journal of Chemical*

- Information and Modeling, 2010, 50(5): 742-754.
- [111] Weininger, D. SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules[J]. Journal of chemical information and computer sciences, 1988, 28(1): 31-36.
- [112] Weininger, D., Weininger, A., Weininger, J.L. SMILES. 2. Algorithm for Generation of Unique SMILES Notation[J]. Journal of Chemical Information and Computer Sciences, 1989, 29(2): 97-101.
- [113] Weininger, D. SMILES. 3. DEPICT. Graphical depiction of chemical structures[J]. Journal of Chemical Information and Computer Sciences, 1990, 30(3): 237-243.
- [114] Krenn, M., Häse, F., Nigam, A.K., et al. Self-referencing embedded strings (SELFIES): A 100% robust molecular string representation[J]. Machine Learning: Science and Technology, 2020, 1(4): 045024-045033.
- [115] Heller, S.R., McNaught, A., Pletnev, I., et al. InChI, the IUPAC International Chemical Identifier[J]. Journal of Cheminformatics, 2015, 7(23): 1-34.
- [116] Štěpánková, K., Ozaltin, K., Gorejová, R., et al. Sulfation of furcellaran and its effect on hemocompatibility in vitro[J]. International Journal of Biological Macromolecules, 2024, 258(5): 128840-128852.
- [117] Degen, J., Wegscheid-Gerlach, C., Zaliani, A., et al. On the art of compiling and using “drug-like” chemical fragment spaces[J]. ChemMedChem, 2008, 3(10): 1503-1507.
- [118] Lewell, X.Q., Judd, D.B., Watson, S.P., et al. RECAP - Retrosynthetic Combinatorial Analysis Procedure: A powerful new technique for identifying privileged molecular fragments with useful applications in combinatorial chemistry[J]. Journal of Chemical Information and Computer Sciences, 1998, 38(3): 511-522.
- [119] Bemis, G.W., Murcko, M.A. The properties of known drugs. 1. Molecular frameworks[J]. Journal of Medicinal Chemistry, 1996, 39(15): 2887-2893.
- [120] Liu, T., Naderi, M., Alvin, C., et al. Break Down in Order to Build Up: Decomposing Small Molecules for Fragment-Based Drug Design with eMolFrag[J]. Journal of Chemical Information and Modeling, 2017, 57(4): 627-631.
- [121] Kruger, F., Stiefl, N., Landrum, G.A. RdScaffoldNetwork: The Scaffold Network Implementation in RDKit[J]. Journal of Chemical Information and Modeling, 2020, 60(7): 3331-3335.
- [122] Chen, J., Luo, D.L., Mu, F.X. An improved ID3 decision tree algorithm[A]. International Conference on Computer Science and Education[C]. 2009: 127-130.
- [123] Marti, B. Support vector machines[J]. Intelligent Systems and their Applications, 1998, 13(4): 18-28.
- [124] Liangxiao Jiang, Dianhong Wang, Z.C.& X.Y. Survey of Improving Naive Bayes for Classification[J]. Advanced Data Mining and Applications, 2007, 4632(3): 134-145.
- [125] Jin, Z., Shang, J., Zhu, Q., et al. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [126] Chen, T., Guestrin, C. XGBoost: A scalable tree boosting system[A]. International Conference on Knowledge Discovery and Data Mining[C]. 2016: 785-794.
- [127] Rikiya Yamashita, Mizuho Nishio¹, Richard Kinh Gian Do, K.T. Convolutional neural networks: an overview and application in radiology[J]. Insights into Imaging, 2018, 9(4):

- 611-629.
- [128] Fogel, J.M.K.D.L.D.B. Recurrent Neural Networks[A]. Fundamentals of Computational Intelligence: Neural Networks[C]. 2016: 77-100.
- [129] Zhou, J., Cui, G., Hu, S., et al. Graph neural networks: A review of methods and applications[J]. AI Open, 2020, 1(1): 57-81.
- [130] Mohiuddin, K., Welke, P., Alam, M.A., et al. Attention Is All You Need[A]. Neural Information Processing Systems[C]. 2017: 4752-4758.
- [131] Kipf, T.N., Welling, M. Semi-supervised classification with graph convolutional networks[A]. International Conference on Learning Representations[C]. 2017: 1-14.
- [132] Velićković, P., Cucurull, G., Casanova, A., et al. Graph attention networks[A]. International Conference on Learning Representations[C]. 2018(1050): 1-12.
- [133] Keyulu, X., Weihua, H., Jure, L., et al. How powerful are graph neural networks?[A]. International Conference on Learning Representations[C]. 2019: 1-17.
- [134] Gilmer, J., Schoenholz, S.S., Riley, P.F., et al. Neural Message Passing for Quantum Chemistry[A]. International Conference on Machine Learning[C]. 2017: 1704-1714.
- [135] Xiong, Z., Wang, D., Liu, X., et al. Pushing the boundaries of molecular representation for drug discovery with the graph attention mechanism[J]. Journal of Medicinal Chemistry, 2020, 63(16): 8749-8760.
- [136] Yang, Z., Zhong, W., Zhao, L., et al. MGraphDTA: Deep multiscale graph neural network for explainable drug-target binding affinity prediction[J]. Chemical Science, 2022, 13(3): 816-833.
- [137] Hughes, J.P., Rees, S., Kalindjian, S.B., et al. Principles of early drug discovery[J]. British Journal of Pharmacology, 2011, 162(6): 1239-1249.
- [138] Jiang, J., Chen, L., Ke, L., et al. A review of transformers in drug discovery and beyond[J]. Journal of Pharmaceutical Analysis, 2024(2095-1779): 101081-101129.
- [139] Wu, T., Lin, R., Cui, P., et al. Deep learning-based drug screening for the discovery of potential therapeutic agents for Alzheimer's disease[J]. Journal of Pharmaceutical Analysis, 2024, 14(10): 101022-101063.
- [140] Moriwaki, H., Tian, Y.S., Kawashita, N., et al. Mordred: a molecular descriptor calculator[J]. Journal of Cheminformatics, 2018, 10(4): 4-18.
- [141] Capecchi, A., Probst, D., Reymond, J.L. One molecular fingerprint to rule them all: drugs, biomolecules, and the metabolome[J]. Journal of Cheminformatics, 2020, 12(43): 43-58.
- [142] Anderson, C.J., Cadeddu, R., Anderson, D.N., et al. A novel naïve Bayes approach to identifying grooming behaviors in the force-plate actometric platform[J]. Journal of Neuroscience Methods, 2024, 403(3): 110026-110034.
- [143] Zhang, Y. fei, Wang, Y. hao, Gu, Z. feng, et al. Bitter-RF: A random forest machine model for recognizing bitter peptides[J]. Frontiers in Medicine, 2023, 10(1): 1052923-1052934.
- [144] Sun, M., Zhao, S., Gilvary, C., et al. Graph convolutional networks for computational drug development and discovery[J]. Briefings in Bioinformatics, 2020, 21(January 2019): 919-935.
- [145] Feinberg, E.N., Sur, D., Wu, Z., et al. PotentialNet for Molecular Property Prediction[J].

- ACS Central Science, 2018, 4(11): 1520–1530.
- [146] Zhang, Z., Guan, J., Zhou, S. FraGAT: a fragment-oriented multi-scale graph attention model for molecular property prediction[J]. *Bioinformatics*, 2021, 37(18): 2981-2987.
- [147] Yang, K., Swanson, K., Jin, W., et al. Analyzing Learned Molecular Representations for Property Prediction[J]. *Journal of Chemical Information and Modeling*, 2019, 59(8): 3370-3388.
- [148] Zhang, Z., Liu, Q., Wang, H., et al. Motif-based Graph Self-Supervised Learning for Molecular Property Prediction[A]. *Advances in Neural Information Processing Systems*[C]. 2021, 19(2): 15870-15882.
- [149] Zhang, S., Hu, Z., Subramonian, A., et al. Motif-Driven Contrastive Learning of Graph Representations[A]. *Transactions on Knowledge and Data Engineering*[C]. 2024, 36: 4063–4075.
- [150] Wu, Z., Ramsundar, B., Feinberg, E.N., et al. MoleculeNet: A benchmark for molecular machine learning[J]. *Chemical Science*, 2018, 9(2): 513-530.
- [151] Zdrazil, B., Felix, E., Hunter, F., et al. The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods[J]. *Nucleic Acids Research*, 2024, 52(D1): D1180-D1192.
- [152] Zhang, Z., Liu, Q., Wang, H., et al. Motif-based Graph Self-Supervised Learning for Molecular Property Prediction[J]. *Advances in Neural Information Processing Systems*, 2021, 19(2): 15870-15882.
- [153] Han, S., Fu, H., Wu, Y., et al. HimGNN: a novel hierarchical molecular graph representation learning framework for property prediction[J]. *Briefings in Bioinformatics*, 2023, 24(5): 305-316.
- [154] Jiang, T., Wang, Z., Yu, W., et al. Mix-Key: graph mixup with key structures for molecular property prediction[J]. *Briefings in Bioinformatics*, 2024, 25(3): 165-175.
- [155] Kingma, D.P., Ba, J.L. Adam: A method for stochastic optimization[A]. *International Conference on Learning Representations*[C]. 2015: 1-15.
- [156] Luo, Y., Zhao, X., Zhou, J., et al. A network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information[J]. *Nature Communications*, 2017, 8(1): 573-586.
- [157] Chen, X., Yan, C.C., Zhang, X., et al. Drug-target interaction prediction: Databases, web servers and computational models[J]. *Briefings in Bioinformatics*, 2016, 17(4): 696-712.
- [158] Yamanishi, Y., Kotera, M., Kanehisa, M., et al. Drug-target interaction prediction from chemical, genomic and pharmacological data in an integrated framework[J]. *Bioinformatics*, 2010, 26(12): i246–i254.
- [159] Cheng, F., Liu, C., Jiang, J., et al. Prediction of drug-target interactions and drug repositioning via network-based inference[J]. *PLoS Computational Biology*, 2012, 8(5): e1002503-e1002515.
- [160] Zhao, Q., Xiao, F., Yang, M., et al. AttentionDTA: prediction of drug – target binding affinity using attention model[A]. *International Conference on Bioinformatics and Biomedicine*[C]. 2019: 64-69.
- [161] Wang, L., Zhou, Z., Yang, X., et al. The present state and challenges of active learning in

- drug discovery[J]. *Drug Discovery Today*, 2024, 29(6): 103985-103999.
- [162] Skinnider, M.A., Stacey, R.G., Wishart, D.S., et al. Chemical language models enable navigation in sparsely populated chemical space[J]. *Nature Machine Intelligence*, 2021, 3(9): 759-770.
- [163] Virshup, A.M., Contreras-García, J., Wipf, P., et al. Stochastic voyages into uncharted chemical space produce a representative library of all possible drug-like compounds[J]. *Journal of the American Chemical Society*, 2013, 135(19): 7296-7303.
- [164] Xu, Y., Lin, K., Wang, S., et al. Deep learning for molecular generation[J]. *Future Medicinal Chemistry*, 2019, 11(6): 567-597.
- [165] Chatterjee, A., Walters, R., Shafi, Z., et al. Improving the generalizability of protein-ligand binding predictions with AI-Bind[J]. *Nature communications*, 2023, 14(1): 1989-2004.
- [166] Li, B., Shen, Y., Yang, J., et al. Sparse Mixture-of-Experts are Domain Generalizable Learners[A]. *International Conference on Learning Representations[C]*. 2023: 10311-10326.
- [167] Zhang, D., Ahuja, K., Xu, Y., et al. Can Subnetwork Structure be the Key to Out-of-Distribution Generalization?[A]. *International Conference on Machine Learning[C]*. 2021, 139: 12356-12367.
- [168] Ganin, Y., Ustinova, E., Ajakan, H., et al. Domain-adversarial training of neural networks[J]. *Computer Vision and Pattern Recognition*, 2017, 17(9): 189-209.
- [169] Long, M., Cao, Z., Wang, J., et al. Conditional adversarial domain adaptation[A]. *Neural Information Processing Systems[C]*. 2018: 10311-10321.
- [170] Ecomposition, M.A.D., Geng, Z., Guo, M. hao. Agree to Disagree: Diversity through Disagreement for Better Transferability[A]. *International Conference on Learning Representations[C]*. 2023: 10411-10435.
- [171] Li, B., Wang, Y., Zhang, S., et al. Learning Invariant Representations and Risks for Semi-supervised Domain Adaptation[A]. *Computer Society Conference on Computer Vision and Pattern Recognition[C]*. 2021: 1104-1113.
- [172] Ahuja, K., Shanmugam, K., Varshney, K.R., et al. Invariant Risk Minimization Games[A]. *International Conference on Machine Learning[C]*. 2020, 119(15): 145-155.
- [173] Zhao, S., Li, B., Reed, C., et al. Multi-source Domain Adaptation in the Deep Learning Era: A Systematic Survey[A]. *ArXiv[C]*. 2020.
- [174] Bui, M.H., Tran, T., Tran, A.T., et al. Exploiting Domain-Specific Features to Enhance Domain Generalization[A]. *Neural Information Processing Systems[C]*. 2021: 10231-10244.
- [175] Riquelme, C., Puigcerver, J., Mustafa, B., et al. Scaling Vision with Sparse Mixture of Experts[A]. *Neural Information Processing Systems[C]*. 2021: 1331-1374.
- [176] Havasi, M., Jenatton, R., Fort, S., et al. Training independent subnetworks for robust prediction[A]. *International Conference on Learning Representations[C]*. 2021: 1033-1046.
- [177] Frankle, J., Carbin, M. The lottery ticket hypothesis: Finding sparse, trainable neural networks[A]. *International Conference on Learning Representations[C]*. 2019: 1312-1354.
- [178] Davis, M.I., Hunt, J.P., Herrgard, S., et al. Comprehensive analysis of kinase inhibitor selectivity[J]. *Nature Biotechnology*, 2011, 29(11): 1046-1051.

- [179] Tang, J., Szwajda, A., Shakyawar, S., et al. Making sense of large-scale kinase inhibitor bioactivity data sets: A comparative and integrative analysis[J]. *Journal of Chemical Information and Modeling*, 2014, 54(3): 735-743.
- [180] Bai, P., Miljkovic, F., Ge, Y., et al. Hierarchical Clustering Split for Low-Bias Evaluation of Drug-Target Interaction Prediction[A]. *International Conference on Bioinformatics and Biomedicine*[C]. 2021: 641-644.
- [181] Bai, P., Miljković, F., John, B., et al. Interpretable bilinear attention network with domain adaptation improves drug-target prediction[J]. *Nature Machine Intelligence*, 2023, 5: 126–136.
- [182] Wang, W., Hu, C. Concordance probability and discriminatory power in proportional hazards regression[J]. *Biometrika*, 2005, 92: 965-970.
- [183] Roy, P.P., Paul, S., Mitra, I., et al. On two novel parameters for validation of predictive QSAR models[J]. *Molecules*, 2009, 14(5): 1660-1701.
- [184] Nguyen, T., Le, H., Le, T., et al. GraphDTA: prediction of drug–target binding affinity using graph convolutional networks Thin[J]. *Bioinformatics*, 2021, 37(8): 1140-1147.
- [185] Peng, L., Liu, X., Yang, L., et al. BINDTI: A bi-directional Intention network for drug-target interaction identification based on attention mechanisms[J]. *Journal of Biomedical and Health Informatics*, 2024, 3(4): 1-11.
- [186] Wu, H., Liu, J., Jiang, T., et al. AttentionMGT-DTA: A multi-modal drug-target affinity prediction using graph transformer and attention mechanism[J]. *Neural Networks*, 2024, 169(6): 623-636.
- [187] Cao, D.S., Xu, Q.S., Liang, Y.Z. Propy: A tool to generate various modes of Chou's PseAAC[J]. *Bioinformatics*, 2013, 29(7): 960-962.
- [188] Li, S., Zhou, J., Xu, T., et al. Structure-aware Interactive Graph Neural Networks for the Prediction of Protein-Ligand Binding Affinity[A]. *International Conference on Knowledge Discovery and Data Mining*[C]. 2021: 975-985.
- [189] Deng, Y., Roux, B. Computations of standard binding free energies with molecular dynamics simulations[J]. *Journal of Physical Chemistry B*, 2009, 113(8): 2234-2246.
- [190] Zhang, X., Shen, C., Liao, B., et al. TocoDecoy: A New Approach to Design Unbiased Datasets for Training and Benchmarking Machine-Learning Scoring Functions[J]. *Journal of Medicinal Chemistry*, 2022, 65(11): 7918-7932.
- [191] Su, M., Yang, Q., Du, Y., et al. Comparative Assessment of Scoring Functions: The CASF-2016 Update[J]. *Journal of Chemical Information and Modeling*, 2019, 59(2): 895-913.
- [192] Jiang, D., Hsieh, C.Y., Wu, Z., et al. InteractionGraphNet: A Novel and Efficient Deep Graph Representation Learning Framework for Accurate Protein-Ligand Interaction Predictions[J]. *Journal of Medicinal Chemistry*, 2021, 64(24): 18209-18232.
- [193] Mysinger, M.M., Carchia, M., Irwin, J.J., et al. Directory of useful decoys, enhanced (DUD-E): Better ligands and decoys for better benchmarking[J]. *Journal of Medicinal Chemistry*, 2012, 55(14): 6582-6594.
- [194] Bauer, M.R., Ibrahim, T.M., Vogel, S.M., et al. Evaluation and optimization of virtual screening workflows with DEKOIS 2.0 - A public library of challenging docking

- benchmark sets[J]. *Journal of Chemical Information and Modeling*, 2013, 53(6): 1447-1462.
- [195] Tran-Nguyen, V.K., Jacquemard, C., Rognan, D. LIT-PCBA: An unbiased data set for machine learning and virtual screening[J]. *Journal of Chemical Information and Modeling*, 2020, 60(9): 4263-4273.
- [196] Shen, C., Hu, Y., Wang, Z., et al. Beware of the generic machine learning-based scoring functions in structure-based virtual screening[J]. *Briefings in Bioinformatics*, 2021, 22(3): 1-22.
- [197] Tan, H., Wang, Z., Hu, G. GAABind: a geometry-aware attention-based network for accurate protein-ligand binding pose and binding affinity prediction[J]. *Briefings in bioinformatics*, 2023, 25(1): 1-14.
- [198] Zheng, L., Fan, J., Mu, Y. OnionNet: A Multiple-Layer Intermolecular-Contact-Based Convolutional Neural Network for Protein-Ligand Binding Affinity Prediction[J]. *ACS Omega*, 2019, 4(14): 15956-15965.
- [199] Li, H., Leung, K.S., Wong, M.H., et al. Improving autodock vina using random forest: The growing accuracy of binding affinity prediction by the effective exploitation of larger data sets[J]. *Molecular Informatics*, 2015, 34(2-3): 115-126.
- [200] Jain, A.N. Surflex: Fully automatic flexible molecular docking using a molecular similarity-based search engine[J]. *Journal of Medicinal Chemistry*, 2003, 46(4): 499-511.
- [201] Jain, A.N. Surflex-Dock 2.1: Robust performance from ligand energetic modeling, ring flexibility, and knowledge-based search[J]. *Journal of Computer-Aided Molecular Design*, 2007, 21(5): 281-306.
- [202] Prechelt, L. Automatic early stopping using cross validation: Quantifying the criteria[J]. *Neural Networks*, 1998, 11(4): 761-767.
- [203] Yang, J., Shen, C., Huang, N. Predicting or Pretending: Artificial Intelligence for Protein-Ligand Interactions Lack of Sufficiently Large and Unbiased Datasets[J]. *Frontiers in Pharmacology*, 2020, 11(2): 1-9.
- [204] Chen, L., Cruz, A., Ramsey, S., et al. Hidden bias in the DUD-E dataset leads to misleading performance of deep learning in structure-based virtual screening[J]. *PLoS ONE*, 2019, 14(8): 1-22.

缩略词表

英文缩写	英文全称	中文全称
3D-CNN	Three-Dimensional Convolutional Neural Network	三维卷积神经网络
AUPRC	Area Under the Precision-Recall Curve	精确召回曲线下面积
AUROC	Area Under the Receiver Operating Characteristic Curve	受试者工作特征曲线下面积
BAT	Diversity-by-Disagreement Training	基于分歧的多样性训练
BN	Node-Level Batch Normalization	节点级批处理归一化
BRICS	Breaking of Retrosynthetically Interesting Chemical Substructures	逆转录合成有趣化学子结构
CDAN	Conditional Domain Adversarial Network	条件域对抗网络
CI	Concordance Index	一致性指数
C-MPNN	Contextual Message Passing Neural Network	上下文信息传递神经网络
CNN	Convolutional Neural Network	卷积神经网络
D-MPNN	Directed Message Passing Neural Network	方向性消息传递神经网络
DTA	Drug-Target Affinity	药物-靶标结合亲和力
DTI	Drug-Target Interaction	药物-靶标相互作用
ECFP	Extended-Connectivity Fingerprint	拓展连通性指纹
EF	Enrichment Factor	富集因子
FCNN	Fully Connected Neural Networks	全连接神经网络
FDA	Food and Drug Administration	美国食品和药物监督管理局
GAT	Graph Attention Network	图注意力网络
GBDT	Gradient Boosting Decision Trees	梯度提升树
GCN	Graph Convolutional Network	图卷积神经网络
GIN	Graph Isomorphism Networks	图同构网络
GNN	Graph Neural Network	图神经网络
GRU	Gated Recurrent Unit	门控循环单元
InChI	International Chemical Identifier	国际化学标识符
LN	Layer Normalization	层归一化
LSTM	Long Short-Term Memory	长短期记忆网络
MAE	Mean Absolute Error	平均绝对误差
MCNN	Multiscale Convolutional Neural Network	多尺度卷积神经网络
MedDRA	Medical Dictionary for Regulatory Activities	监管活动医学词典
MGNN	Multiscale Graph Neural Network	多尺度图神经网络
MLP	Multilayer Perceptron	多层感知器
MOE	Mixture Of Experts	混合专家网络
MPNN	Message Passing Neural Network	消息传递神经网络
MSE	Mean Squared Error	均方误差

NB	Naive Bayes	朴素贝叶斯
NT-Xent	Normalized Temperature-Scaled Cross Entropy Loss	归一化温度标度交叉熵损失
OOD	Out Of Distribution	分布外
PDB	Protein Data Bank	蛋白质数据库
RECAP	Retrosynthetic Combinatorial Analysis Procedure	逆转录合成组合分析程序
RF	Random Forest	随机森林
RMSE	Root Mean Square Error	均方根误差
RNN	Recurrent Neural Network	循环神经网络
Rp	Pearson Correlation Coefficient	皮尔逊相关系数
SD	Standard Deviation	标准差
SELFIES	Self-Referencing Embedded Strings	自引用嵌入字符串
SMILES	Simplified Molecular Input Line Entry System	简化分子线性输入系统
SVM	Support Vector Machine	支持向量机
t-SNE	t-Distributed Stochastic Neighbor Embedding	t 分布随机邻居嵌入