

学校代码: 10286  
分类号: TP183  
密 级: 公开  
U D C: 004.8  
学 号: 214881



东南大学

# 电子信息硕士学位论文

面向性质预测的分子表示学习方法的研究与实现

(学位论文形式: 应用研究)

研究生姓名: 王卓渊

导师姓名: 何洁月 教授

卢山 高工

申请学位类别 电子信息硕士 学位授予单位 东南大学

领域名称 人工智能 论文答辩日期 2024 年 5 月 21 日

研究方向 数据挖掘 学位授予日期

答辩委员会主席 陈阳 评 阅 人 盲审

2024 年 6 月 13 日

東南大學

# 电子信息硕士学位论文

面向性质预测的分子表示学习方法的研究与实现

专业名称: 人 工 智 能

研究生姓名: 王 卓 渊

导师姓名: 何 洁 月      教 授

卢 山      高 工

# RESEARCH AND IMPLEMENTATION OF MOLECULAR REPRESENTATION LEARNING METHODS FOR PROPERTY PREDICTION

A Thesis Submitted to

Southeast University

For the Professional Degree of Master of Engineering

BY

WANG Zhuo-Yuan

Supervised by

Prof. HE Jie-Yue

and

Senior Enginner. LU Shan

Southeast University-Monash University Joint Graduate School

Southeast University

June 2024

## 摘 要

面向性质预测的分子表示学习方法是通过机器学习和深度学习技术，将分子的复杂结构信息转换为数学表示，进而利用这些表示来解决与分子性质相关的各种任务。这些性质涵盖了药理活性、生物活性、溶解度、毒性等多个方面，是药物设计、材料科学和环境保护等领域中至关重要的因素。尽管分子领域存在大量数据，但是拥有高质量标签的分子数据却相对稀少，因此基于监督学习的方法在分子性质预测任务上的表现往往不尽如人意。目前先进的一些自监督方法往往基于分子单一模态信息，导致其表征分子时角度过于片面。因此，寻找有效的方法表示分子并准确的预测分子的性质成为了当前亟需解决的问题。

本论文利用分子的多模态特性研究提出面向性质预测的分子表示学习方法并设计实现了一个分子性质预测工具。本文的主要工作如下：

(1) 针对分子领域有标签的数据较为稀少，且当前研究通常只利用了单一模态的分子信息，忽略了不同分子模态之间的互补性的问题，本论文研究提出基于图和图像的多模态分子表示学习方法 (**Multi-Modal Molecular Representation Learning Based on Image And Graph, MolIG**)。该方法在预训练阶段，通过整合分子的图表示和图像表示，并在隐空间中最大化这两种表示的一致性，以捕获高阶语义信息的分子表征。在不改变语义信息的情况下，利用图像增强策略，模型可以学习到更加鲁棒的分子表示，同时提升其泛化能力。在 MoleculeNet 和 ADMET 基准组上的实验结果表明，MolIG 方法在分子性质预测任务上能够取得相较基线模型更优的性能，且能够有效提取分子的结构特征并捕获高阶的语义信息。

(2) 进一步，鉴于上述方法仅依赖数据驱动，缺乏专家知识引导，存在一定的局限性。本论文研究提出大语言模型赋能的多层级分子表示学习方法 (**Multi-Level Molecular Representation Learning Empowered by LLM, Mol-LLM**)。在 MolIG 的基础上，本研究引入分子指纹作为专家知识，捕获不同子结构下的交互模式，进一步补充了图神经网络的表达能力。同时，该方法采用双线性注意力网络来融合不同层级的信息，根据数据驱动的原子级别表征和专家知识驱动的子结构级别表征动态地调整其贡献，使得二者更好的进行融合。此外，本研究还考虑到当前分子描述文本的稀缺性，创新性地结合了大语言模型并精心设计 prompt 以获取丰富的分子描述信息，通过融合这些信息，以生成更



全面和细致的分子表征。与基于大语言模型和分子描述信息的基线模型的实验比较结果验证了本方法的有效性。

(3) 基于以上方法, 本文设计并实现了一个分子性质预测工具 ADMET-P, 该工具基于为生物医药研究人员提供一个易于使用的分子性质预测工具, 加速药物研发进程。ADMET-P 分别实现分子可视化、分子基本信息计算、分子性质预测和性质建议等功能。

**关键词:** 分子图, 分子图像, 对比学习, 分子指纹, 大语言模型, 分子性质预测

## Abstract

Molecular representation learning methods for property prediction utilize machine learning and deep learning techniques to transform the complex structural information of molecules into mathematical representations. These representations are then utilized to address various tasks related to molecular properties. These properties encompass aspects such as pharmacological activity, biological activity, solubility, toxicity, among others, which are crucial factors in drug design, materials science, and environmental protection. Despite the abundance of data in the molecular domain, high-quality labeled molecular data is relatively scarce. Therefore, supervised learning-based approaches often underperform in molecular property prediction tasks. State-of-the-art self-supervised methods often rely on a single modality of molecular information, leading to a narrow perspective when representing molecules. Hence, finding effective methods to represent molecules and accurately predict their properties is a pressing issue.

This thesis addresses the aforementioned challenges by proposing a multi-modal molecular representation learning method for property prediction and designing and implementing a molecular property prediction tool. The main contributions of this work are as follows:

(1) Considering the scarcity of labeled data in the molecular domain and the tendency of current research to utilize only a single modality of molecular information, neglecting the complementarity between different molecular modalities, we propose the Multi-Modal Molecular Representation Learning Based on Image And Graph (MolIG) method. This method consists of two main stages: pre-training and fine-tuning. In the pre-training stage, we integrate the graph representation and image representation of molecules and maximize the consistency between these two representations in latent space to capture high-level semantic information of molecules. By leveraging image augmentation strategies, the model can learn more robust molecular representations while enhancing its generalization ability. Experimental results on MoleculeNet and ADMET benchmark datasets demonstrate that the MolIG method achieves superior performance compared to baseline models in molecular property prediction tasks and effectively extracts structural features of molecules while capturing high-order semantic information.

(2) Furthermore, considering that the above method relies solely on data-driven approaches and lacks expert knowledge guidance, which poses certain limitations, we propose the Multi-Level Molecular Representation Learning Empowered by Large Language Models (Mol-LLM) method. Building upon MolIG, this study introduces molecular fingerprints as expert knowledge to capture interaction patterns under different substructures, further supplementing the expressive power of graph neural networks. Moreover, this method employs bilinear attention networks to fuse information from different levels dynamically, adjusting their contributions based on data-driven atomic-level representations and expert knowledge-driven substructure-level representations for better integration. Additionally, considering the scarcity of current molecular description texts, this study innovatively combines large language models and carefully designed prompts to obtain rich molecular description information. By integrating these pieces of information, more comprehensive and detailed molecular representations are generated. In the experimental evaluation process, comparisons are made with baseline models based on large language models and molecular description information to demonstrate the effectiveness of this method.

(3) Based on the above methods, this thesis designs and implements a molecular property prediction tool ADMET-P, which provides an easy-to-use molecular property prediction tool for biomedical researchers to accelerate the drug development process. ADMET-P achieves functions such as molecular visualization, calculation of basic molecular information, prediction of molecular properties, and property recommendations.

**Keywords:** Molecular Graph, Molecular Image, Contrastive Learning, Molecular Fingerprint, Large Language Model, Molecular Property Prediction

# 目 录

|                               |    |
|-------------------------------|----|
| 第一章 绪论.....                   | 1  |
| 1.1 研究背景及意义.....              | 1  |
| 1.2 国内外研究现状.....              | 2  |
| 1.2.1 基于 SMILES 的分子表示学习 ..... | 2  |
| 1.2.2 基于图的分子表示学习.....         | 3  |
| 1.2.3 基于图像的分子表示学习.....        | 4  |
| 1.2.4 基于多模态的分子表示学习.....       | 5  |
| 1.3 论文研究内容.....               | 5  |
| 1.4 论文组织架构.....               | 6  |
| 第二章 相关概念及技术 .....             | 9  |
| 2.1 SMILES 字符串 .....          | 9  |
| 2.2 图神经网络.....                | 9  |
| 2.3 残差网络.....                 | 12 |
| 2.4 Transformer.....          | 13 |
| 2.5 预训练微调范式.....              | 14 |
| 2.6 本章小结.....                 | 15 |
| 第三章 基于图和图像的多模态分子表示学习方法 .....  | 17 |
| 3.1 问题定义.....                 | 17 |
| 3.2 方法.....                   | 18 |
| 3.2.1 分子图和分子图像.....           | 18 |
| 3.2.2 分子图和分子图像编码器.....        | 19 |
| 3.2.3 分子图和分子图像表征映射器.....      | 21 |
| 3.2.4 对比学习框架.....             | 21 |
| 3.2.5 微调.....                 | 22 |
| 3.2.6 算法伪代码.....              | 23 |
| 3.3 实验及结果分析.....              | 24 |
| 3.3.1 预训练数据集和图像数据增强.....      | 24 |
| 3.3.2 下游任务数据集.....            | 25 |
| 3.3.3 实验环境配置.....             | 30 |
| 3.3.4 实验评价指标.....             | 30 |
| 3.3.5 对比方法.....               | 31 |
| 3.3.6 对比实验.....               | 33 |
| 3.3.7 消融实验.....               | 36 |
| 3.3.8 参数敏感度实验.....            | 38 |

|                                |    |
|--------------------------------|----|
| 3.3.9 分子相似度查询.....             | 39 |
| 3.4 本章小结.....                  | 40 |
| 第四章 大模型赋能的多层级分子表示学习方法 .....    | 41 |
| 4.1 方法.....                    | 41 |
| 4.1.1 专家知识驱动的子结构级别表征模块 .....   | 42 |
| 4.1.2 双线性注意力融合模块.....          | 44 |
| 4.1.3 大语言模型赋能的分子描述信息表征模块 ..... | 46 |
| 4.1.4 算法伪代码.....               | 49 |
| 4.2 实验及结果分析.....               | 50 |
| 4.2.1 对比方法.....                | 50 |
| 4.2.2 对比实验.....                | 51 |
| 4.2.3 消融实验.....                | 55 |
| 4.2.4 参数敏感度实验.....             | 56 |
| 4.2.5 分子描述信息注意力可视化.....        | 57 |
| 4.3 本章小结.....                  | 58 |
| 第五章 分子性质预测工具的设计与实现 .....       | 61 |
| 5.1 需求分析.....                  | 61 |
| 5.1.1 功能需求.....                | 61 |
| 5.1.2 非功能需求.....               | 62 |
| 5.2 系统设计.....                  | 62 |
| 5.2.1 架构设计.....                | 62 |
| 5.2.2 软件架构设计.....              | 64 |
| 5.2.3 数据库设计 .....              | 64 |
| 5.3 工具实现.....                  | 66 |
| 5.3.1 开发技术与运行环境.....           | 66 |
| 5.3.2 模块实现.....                | 67 |
| 5.4 测试.....                    | 69 |
| 5.4.1 功能测试.....                | 69 |
| 5.4.2 非功能测试.....               | 71 |
| 5.5 本章小结.....                  | 71 |
| 第六章 总结与展望 .....                | 73 |
| 6.1 总结.....                    | 73 |
| 6.2 未来工作.....                  | 74 |
| 参考文献.....                      | 75 |

## 插图目录

|     |                                                                       |    |
|-----|-----------------------------------------------------------------------|----|
| 1-1 | 新药研发过程周期 <sup>[1]</sup> . . . . .                                     | 2  |
| 2-1 | Transformer 架构图 <sup>[2]</sup> . . . . .                              | 13 |
| 3-1 | MolIG 方法架构图 . . . . .                                                 | 18 |
| 3-2 | 分子图和分子图像模态 . . . . .                                                  | 19 |
| 3-3 | 随机划分和骨架划分 <sup>1</sup> . . . . .                                      | 29 |
| 3-4 | MolIG 在 MoleculeNet 基准组上消融实验结果 . . . . .                              | 37 |
| 3-5 | MolIG 在 MoleculeNet 基准组上参数实验结果 . . . . .                              | 38 |
| 3-6 | 分子相似度查询 . . . . .                                                     | 39 |
| 4-1 | Mol-LLM 方法架构图 . . . . .                                               | 42 |
| 4-2 | MACCS 分子指纹 . . . . .                                                  | 43 |
| 4-3 | SubTE 模型架构图 . . . . .                                                 | 43 |
| 4-4 | 双线性注意力融合网络架构图 . . . . .                                               | 45 |
| 4-5 | DesBERTa 方法架构图 . . . . .                                              | 47 |
| 4-6 | ChatGPT 生成的分子描述信息 . . . . .                                           | 48 |
| 4-7 | Mol-LLM 在 MoleculeNet 基准组上不同嵌入维度的参数实验结果 . . . . .                     | 56 |
| 4-8 | Mol-LLM 在 MoleculeNet 基准组上 SubTE 模块不同注意力头数和编码器<br>层数的参数实验结果 . . . . . | 57 |
| 4-9 | 分子描述信息注意力可视化 . . . . .                                                | 58 |
| 5-1 | ADMET-P 系统架构图 . . . . .                                               | 63 |
| 5-2 | ADMET-P 工具软件架构图 . . . . .                                             | 64 |
| 5-3 | 分子性质预测流程图 . . . . .                                                   | 68 |
| 5-4 | ADMET-P 工具主页 . . . . .                                                | 69 |
| 5-5 | ADMET-P 工具性质预测页面 . . . . .                                            | 70 |
| 5-6 | ADMET-P 工具性质预测页面-续 . . . . .                                          | 70 |

## 表格目录

|     |                                               |    |
|-----|-----------------------------------------------|----|
| 2.1 | SMILES 示意图 . . . . .                          | 10 |
| 3.1 | 原子和化学键初始特征 . . . . .                          | 20 |
| 3.2 | MolecuNet 基准组基本信息 . . . . .                   | 25 |
| 3.3 | ADMET 基准组基本信息 . . . . .                       | 26 |
| 3.4 | 关键软件配置信息 . . . . .                            | 30 |
| 3.5 | MolIG 在 MoleculeNet 基准组上的对比实验结果 . . . . .     | 34 |
| 3.6 | MolIG 在 ADMET 基准组上的实验结果 . . . . .             | 36 |
| 3.7 | MolIG 不同温度系数下在 MoleculeNet 基准组上的平均值 . . . . . | 39 |
| 4.1 | Mol-LLM 在 MoleculeNet 基准组上的对比实验结果 . . . . .   | 53 |
| 4.2 | Mol-LLM 在 ADMET 基准组上的对比实验结果 . . . . .         | 54 |
| 4.3 | Mol-LLM 在 MoleculeNet 基准组上的消融实验结果 . . . . .   | 56 |
| 5.1 | 分子结构表 . . . . .                               | 65 |
| 5.2 | 分子指纹表 . . . . .                               | 65 |
| 5.3 | 分子描述信息表 . . . . .                             | 65 |
| 5.4 | 分子性质表 . . . . .                               | 65 |
| 5.5 | ADMET-P 工具部署环境 . . . . .                      | 67 |

## 算法目录

|     |                           |    |
|-----|---------------------------|----|
| 3.1 | 基于图和图像的多模态分子表示学习方法 MolIG  | 23 |
| 4.1 | 大模型赋能的多层级分子表示学习方法 Mol-LLM | 49 |



## 专业术语表

| 缩略词     | 术语全称                                                                                              | 含义                      |
|---------|---------------------------------------------------------------------------------------------------|-------------------------|
| SMILES  | <b>S</b> implified <b>M</b> olecular <b>I</b> ntput <b>L</b> ine <b>E</b> ntry <b>S</b> ystem     | 简化分子线性输入规范              |
| GNN     | <b>G</b> raph <b>N</b> eural <b>N</b> etwork                                                      | 图神经网络                   |
| GAT     | <b>G</b> raph <b>A</b> ttention <b>N</b> etwork                                                   | 图注意力网络                  |
| GCN     | <b>G</b> raph <b>C</b> onvolutional <b>N</b> etwork                                               | 图卷积网络                   |
| GIN     | <b>G</b> raph <b>I</b> somorphism <b>N</b> etwork                                                 | 图同构网络                   |
| CNN     | <b>C</b> onvolutional <b>N</b> eural <b>N</b> etwork                                              | 卷积神经网络                  |
| ResNet  | <b>R</b> esidual <b>N</b> etwork                                                                  | 残差网络                    |
| MPP     | <b>M</b> olecular <b>P</b> roperty <b>P</b> rediction                                             | 分子性质预测                  |
| QSAR    | <b>Q</b> uantitative <b>S</b> tructure- <b>A</b> ctivity <b>R</b> elationship                     | 定量构效关系                  |
| MLM     | <b>M</b> asked <b>L</b> anguage <b>M</b> odeling                                                  | 掩蔽语言建模                  |
| MAM     | <b>M</b> asked <b>A</b> tom <b>M</b> odeling                                                      | 掩蔽原子建模                  |
| MACCS   | <b>M</b> olecular <b>A</b> CCess <b>S</b> ystem                                                   | 分子访问系统                  |
| LM      | <b>L</b> anguage <b>M</b> odel                                                                    | 语言模型                    |
| LLM     | <b>L</b> arge <b>L</b> anguage <b>M</b> odel                                                      | 大语言模型                   |
| MolIG   | Multi-Modal <b>M</b> olecular Representation<br>Learning Based on <b>I</b> mage And <b>G</b> raph | 基于图和图像的多模态分子<br>表示学习方法  |
| Mol-LLM | Multi-Level <b>M</b> olecular Representation<br>Learning Empowered by <b>LLM</b>                  | 大语言模型赋能的多层次分子<br>表示学习方法 |


# 第一章 绪论

## 1.1 研究背景及意义

新药研发是一个时间消耗长、成本高昂且失败率极高的过程<sup>[3]</sup>。据统计，一款新药从研发到最终上市需要超过十年的时间和数十亿美元的投资，从药物筛选的小分子到先导化合物再到临床前研究阶段，成功率不足三分之一，临床二期到三期，只有四分之一的通过率，而通过三期实验最终上市的药物仅有不到六分之一<sup>[4]</sup>，大多数没有通过临床试验的药物是因为在受试者身上未能展现出足够的疗效和安全性<sup>[5]</sup>。因此，在药物研发的早期阶段，发现具有良好疗效和安全性的药物对于长期而艰难的药物研发过程至关重要。图1-1展示了药物研发的不同阶段。

近年来，随着机器学习方法的发展，数据驱动的分子表示学习及其应用，包括化学性质预测、化学建模和分子设计，受到越来越多的关注。面向性质预测的分子表示学习方法是通过对机器学习技术和深度学习技术，将分子的复杂结构信息转换为数学表示，进而利用这些表示来解决与分子性质相关的各种任务。这些性质涵盖了药理活性、生物活性、溶解度、毒性等多个方面，是药物设计、材料科学和环境保护等领域中至关重要的因素。因此，利用分子表示学习技术在药物研发的早期阶段及时发现优质的候选化合物可以大大降低研发时间和成本，加速推进药物上市。然而，由于三个主要挑战，学习有效的分子表示非常困难。首先，分子信息难以全面表达。例如，基于 SMILES 的表示无法直接编码重要的拓扑信息，而图像表示缺少先验知识的注入，且缺乏原子和键之间的相互作用，因此其在各项下游任务上的表现并不理想。为了保留丰富的结构信息，最近的一些工作利用图神经网络编码分子图，在分子特性预测方面展示出了有竞争力的表现<sup>[6,7]</sup>。其次，与潜在化学空间的大小相比，用于分子学习任务的标签数据十分昂贵且极度稀缺，而获得分子性质的标签通常需要复杂且耗时的实验室实验，在极度有限的标签下训练模型非常容易出现过拟合，这使得使用监督学习方法在性质预测任务上的表现不佳。第三，潜在的具有活性的药物分子成药空间十分巨大，约为  $10^{60}$ ，因此化合物通常展现出显著的结构多样性，这对模型的泛化性能提出了更高的要求。

综上所述，当前面向性质预测的分子表示学习方法存在诸多挑战。为了解决上述问题，本研究将利用分子的多模态信息，在大规模无标签的数据集上进行预训练，同时对分子模态进行增强操作，以此学习数据驱动的分子表示，解决单一的分子模态信息无法

图 1-1 新药研发过程周期<sup>[1]</sup>

完整表达分子信息和数据标签稀缺的问题。为了进一步扩展预训练模型的能力，本研究将引入了专家知识和大语言模型作为数据驱动方法的补充，以丰富输入特征，从而解决当前方法泛化性不足的问题。此外，还采用双线性注意力网络来学习数据驱动方法和专家知识方法之间的一致性和差异性，以获得更具判别性的表示。通过以上方法，本研究旨在提高分子表示学习方法在不同分子性质预测任务上的准确性和可靠性，为新药研发提供有价值的参考。

## 1.2 国内外研究现状

分子表示学习方法是化学和生物信息学领域的重要研究方向之一。随着计算能力的提高和机器学习技术的不断创新，研究人员对于如何更准确、高效地表示和理解分子结构的追求变得日益迫切。当前的研究主要基于以下四类，即 SMILES、分子图、分子图像以及多模态。本节将论述这四类表示学习方法的国内外最新研究进展，以及其在分子性质预测领域的应用。

### 1.2.1 基于 SMILES 的分子表示学习

简化分子线性输入规范 (SMILES)<sup>[8]</sup> 是一种化学分子的字符串表示法，旨在以文本形式描述分子的结构、连接和拓扑信息。在基于 SMILES 的研究方法中，掩蔽语言建模

(MLM) 通常用于预训练,并在特定的下游任务中进行细化调整。例如,Chithrananda 等人<sup>[9]</sup>开创性地采用 RoBERTa 架构<sup>[10]</sup>,在包含七千七百万个 SMILES 的数据集上进行 MLM 预训练,并在 MoleculeNet 基准组<sup>[11]</sup>上进行评估。该研究还探讨了预训练数据集的规模及不同 Tokenization 策略对下游任务性能的影响,从而证明了在分子领域中 MLM 方法的有效性。然而,SMILES 表示存在一定的局限性,例如其一致性问题——不同分子可能对应相同的 SMILES 字符串。为解决此问题,Zhang 等人<sup>[12]</sup>提出了 MTL-BERT,该方法通过对 SMILES 进行枚举数据增强,并采用多任务学习策略在下游任务中进行微调。进一步地,Ross 等人<sup>[13]</sup>提出的 Molformer,通过在传统 Transformer 模型<sup>[2]</sup>中使用旋转位置编码代替传统位置编码,并在超过十一亿个 SMILES 数据上进行 MLM,极大地扩展了预训练数据集的规模,显著提高了分子性质预测的性能。同样,直接在 SMILES 字符串上应用 MLM 策略的 X-Mol<sup>[14]</sup>、SMILES-BERT<sup>[15]</sup>、BARTSmiles<sup>[16]</sup>等方法,尽管先前的研究工作证实了 MLM 策略的适用性,然而,SMILES 表示本质上缺乏对空间化学结构信息以及原子和化学键之间复杂拓扑关系的表达。因此,在处理更复杂的化学问题时,往往需要依赖大量的数据和更加复杂的模型,这一挑战促使研究者转向基于分子图的表示学习方法。

### 1.2.2 基于图的分子表示学习

基于图的分子表示学习是目前最流行的方法,其核心思想与基于 SMILES 表示的方法相似,大多遵循预训练-微调的范式。在这一背景下,制定有效的预训练策略成为提升分子表征质量的关键。借鉴自然语言处理领域的经验,分子表示学习引入 MLM,并针对性地发展出原子掩蔽策略 (MAM),即预测分子中被掩蔽的原子和化学键,此策略旨在通过图神经网络的编码能力,捕捉分子结构的核心特征及其内在关联,并根据上下文信息预测被掩蔽的原子属性,从而增强模型对于分子知识的学习。Hu 等人<sup>[17]</sup>在此基础上进一步探索,通过构建上下文预测和属性预测两种预训练任务,旨在训练模型学习有意义的分子表示。然而,后续研究<sup>[18]</sup>指出,当使用 MAM 进行预训练时,可能在一些性质预测的下游任务中出现负迁移现象。这一问题源于分子词汇表的固有特点:不同于自然语言的丰富词汇,分子词汇表仅包含约 116 种原子,其中碳原子占据绝大多数,这容易导致模型过度偏向于常见元素,而忽视其他元素。为了解决这一问题,Xia 等人<sup>[18]</sup>提出了一种基于 VQ-VAE<sup>[19]</sup>的变体,作为一个上下文感知的分词器,将原子属性转化为具有化学意义的离散代码。这一创新有效扩展了原子词汇表,并减少了主要原子与稀有原子间的数量差异。同时,将图神经网络与 Transformer 的融合也是一种有前

景的方向,这种策略不仅有助于模型捕捉分子结构中的全局与局部关系,还通过自注意力机制有效学习分子内部的长距离依赖,为分子表征提供了更为丰富和全面的视角。GROVER<sup>[7]</sup>将消息传递网络集成到Transformer中,通过预测上下文属性和Motif信息学习节点嵌入。MPG<sup>[20]</sup>在Transformer架构的基础上,同时引入节点级别的属性预测任务和图级别的合法分子预测任务。Graphormer<sup>[21]</sup>将分子的关键信息例如中心编码、空间编码等融合到注意力机制中,使得Transformer也能编码具有空间结构的分子图。此外,对比学习<sup>[22]</sup>作为一种强大的无监督学习方法,在分子表示学习领域也得到了广泛应用。KCL<sup>[23]</sup>构建化学元素知识图谱,并将其应用于分子图的增强操作。通过最大化原始分子图和知识图谱增强图的一致性学习分子全局表示。MolCLR<sup>[6]</sup>则是对分子图进行随机增强操作,例如节点掩蔽、边删除、子图移除等,优化不同增强策略下的分子图隐空间的表示。以上方法大都基于掩蔽原子、化学键或子图并不会改变其语义信息这一先验知识,然而在真实场景下,该先验并不成立。这是因为在化学分子领域中,化合物结构中微小的改变可能会导致它们的生物活性发生显著变化,正是因为这一现象的存在,在分子图上进行此类增强操作会限制模型的在下游任务上的表现。

### 1.2.3 基于图像的分子表示学习

在最近的研究中,基于分子二维图像的卷积神经网络(CNN)模型已经展现了在预测分子的吸收、分布、代谢、排泄和毒性(ADMET)特性方面的显著潜力。特别地,ADMET-CNN<sup>[24]</sup>代表了这一新兴领域的一个重要进展,该模型通过将传统的分子表示法转换为二维图像,利用CNN的强大特征提取能力,实现了对ADMET特性的准确预测。这表明,将复杂的分子结构信息编码成图像格式,并利用深度学习算法进行分析,可以为药物发现和化学生物学研究提供新的视角。此外,QSAR-CNN<sup>[25]</sup>模型通过结合迁移学习和数据增强技术,进一步拓展了基于图像的分子表示学习的应用范围。该研究使用DenseNet架构处理分子图像,并开发了定量构效关系(QSAR)模型,以预测化合物与OH自由基的反应速率常数,这表明通过适当的技术调整,预训练的图像识别网络可以有效地适用于化学数据,从而在没有大量化学训练数据的情况下也能实现高性能的模型。Chemception<sup>[26]</sup>模型则进一步证实了基于CNN的方法在分子性质预测方面的有效性,通过引入特定于化学的设计元素,例如特定的过滤器和池化策略,Chemception能够直接从原始图像中学习分子的相关性质,无需依赖于传统的分子描述符或预先定义的化学知识。ImageMol<sup>[27]</sup>采用了ResNet架构,并通过设计多个预训练任务来改善模型对分子图像的理解,包括考虑分子的合理性、一致性和相关性。这种方法通过综合考虑



多个维度的信息，提高了模型对分子结构的识别和分析能力。然而，尽管这些研究取得了令人鼓舞的成果，基于分子图像的代表学习方法仍面临一些挑战。最显著的是，将分子数据转换到欧几里得空间中的二维图像，这一过程可能会丢失关于原子和键之间复杂相互作用的信息。由于缺乏这些原子级别的属性，直接使用分子图像进行性质预测可能无法达到最佳的性能。

#### 1.2.4 基于多模态的分子表示学习

在化学信息学和计算化学领域，基于多模态的分子表示学习逐渐成为一个重要的研究方向，标志着研究者在探索分子性质预测方法上迈出了新的步伐。多模态学习的核心理念在于整合来自不同数据源的信息，如图像、文本、以及分子结构等，从而构建一个综合性更强、细节更丰富的分子表示模型。GraphMVP<sup>[28]</sup> 是一个创新的框架，它利用分子的二维 (2D) 和三维 (3D) 模态，通过自适应地整合 2D 和 3D 图的信息，来学习具有空间语义的分子表征。这种方法使得模型能够更好地理解分子结构的空間关系和化学性质，进而在多种化学预测任务中展示出了卓越的性能。另一个例子是 GeomGCL<sup>[29]</sup>，该方法也基于分子的 2D 和 3D 信息，采用了几何图对比学习机制，通过四种不同的消息传递机制增强模型对几何特性的理解来提高分子表示的质量。DMP<sup>[30]</sup> 则最大化 SMILES 表示和分子图之间的一致性。分别为文本模态和图模态设计特定的 MLM 和 MAM 预训练任务。这表明了在多模态学习框架下，对每种数据模态进行专门优化能够显著提升整体模型的表现。MoleculeSTM<sup>[31]</sup> 进一步扩展了多模态分子表示学习的范围，通过收集来自 PubChem 数据库<sup>[32]</sup> 的大量分子描述文本，并建立其与分子图之间的一致性。这种结合了文本描述与图结构信息的方法，为分子的语义理解和特性预测提供了新的维度。然而，分子 3D 结构的信息通常依赖 DFT 等量子化学计算手段<sup>[33]</sup>，这种昂贵的计算成本导致利用分子 3D 结构进行大规模预训练的方法并不现实。此外，SMILES 和分子描述信息往往需要昂贵的计算资源。因此，寻求一种高效轻量且能利用大规模数据进行训练的方法，成为当前研究关注的重点。

### 1.3 论文研究内容

综合以上分析，本论文研究如何利用分子的多模态信息设计实现面向性质预测的分子表示学习方法。具体的研究内容分为以下几个部分：

(1) 针对当前的研究通常限于单一模态的分子信息，而未考虑到不同模态之间的互补性的问题。研究提出一种基于图和图像的多模态分子表示学习方法 MolIG (Multi-

Modal **M**olecular Representation Learning Based on Image And Graph, MolIG)。该方法通过整合分子的图表示和图像表示,结合预训练和微调两个阶段,以最大化这两种表示在隐空间中的一致性,以捕获分子表征中的高阶语义信息。进一步,通过与图像模态进行不改变语义信息的图像增强策略,使得模型学习到分子更具鲁棒性的表示,同时提高模型的泛化能力。在 MoleculeNet 和 ADMET 等分子性质预测任务上进行实验,以验证 MolIG 方法能够有效提取分子的结构特征,并捕获高阶的语义信息。

(2) 进一步,鉴于上述方法仅依赖数据驱动,缺乏专家知识引导,存在一定局限性。研究提出大语言模型赋能的多层级分子表示学习方法 (Multi-Level **M**olecular Representation Learning Empowered by **LLM**, Mol-LLM)。在 MolIG 的基础上,本研究引入分子指纹作为专家知识,捕获不同子结构下的交互模式,进一步补充了图神经网络的表达能力。同时,该方法采用双线性注意力网络来融合不同层级的信息,根据数据驱动的原子级别表征和专家知识驱动的子结构级别表征动态地调整其贡献,使得二者更好的进行融合。此外,本研究还考虑到当前分子描述文本的稀缺性,创新性地结合了大语言模型并精心设计 prompt 以获取丰富的分子描述信息,通过融合这些信息,以生成更全面和细致的分子表征。在实验评估过程中,设计与基于大语言模型和分子描述信息的基线模型进行比较,以证明本方法的有效性。

(3) 基于以上方法,本文设计并实现一个分子性质预测工具,为生物医药研究人员提供一个易于使用的分子性质预测工具。

## 1.4 论文组织架构

本文由六个章节构成,各章节的简要介绍如下所示:

第一章:绪论。本章首先阐述分子表示学习的研究背景及意义,根据使用方法总结国内外研究现状,最后概述本文的主要研究内容。

第二章:相关技术。本章对实现分子表示学习所涉及的相关技术进行了综述和整理,包括图神经网络、残差网络和 Transformer 架构等,旨在为后续章节中方法的提出和实现提供理论基础和技术背景。

第三章:基于图和图像的多模态分子表示学习方法。本章首先对分子性质预测问题进行了明确的定义和阐述。随后,详细介绍了多模态分子表示学习方法 MolIG 的框架结构、各个组成模块及其算法伪代码。最终,通过在 MoleculeNet 和 ADMET 基准组上的实验验证了 MolIG 方法的有效性。

第四章:大语言模型赋能的多层级分子表示学习方法。在 MolIG 方法的基础上,本

章指出其存在的局限性，并引入了专家知识、双线性注意力网络以及大语言模型等新元素。详细阐述了 Mol-LLM 方法的框架、关键模块及算法流程，并通过在相同的基准组上进行实验，证实了 Mol-LLM 方法的改进效果和有效性。

第五章：工具实现。本章详细描述了基于本论文研究成果开发的分子性质预测工具，包括需求分析、系统设计、功能实现及使用指南等，旨在将研究成果转化为实际可用的科研或工业应用工具。

第六章：总结与展望。本章总结了本文的主要研究成果和贡献，对当前研究方法的不足进行了反思和分析，并针对分子表示学习领域的未来发展方向和研究重点提出的展望。





## 第二章 相关概念及技术

本章将对本文后续所使用的相关概念和技术进行详细介绍，包括 SMILES 表示法、图神经网络、残差网络、Transformer 架构，以及预训练微调范式。



### 2.1 SMILES 字符串

SMILES<sup>[8]</sup> 是一种用于描述化学分子结构的字符串表示法。它将分子结构简化为一系列 ASCII 字符的线性序列，不仅包含原子和化学键的信息，还能表示分子中的立体化学特征。由 Arthur Weininger 在 1980 年代初期开发，SMILES 已成为化学信息学领域的一个标准工具，用于分子数据的存储、检索和交换。在 SMILES 语法中，分子由原子、键、分支和环等基本元素构成。原子通常用相应的化学元素符号表示，如 C 代表碳，O 代表氧。对于标准的有机分子中常见的原子（碳、氢、氮、氧、磷、硫），当它们的价态符合典型的有机化合物时，通常省略掉连接的氢原子和单键。非标准的原子和有机元素中的非典型价态则需用方括号括起来，并明确给出连结的氢数量和电荷状态，如 [Na] 和 [OH3+]。化学键的符号包括 “-”（单键，通常省略）、“=”（双键）、“#”（三键）以及 “.”（不连通的两部分）。若不特别指定，则默认为单键。分支结构通过圆括号表示，例如乙烷（CH<sub>3</sub>CH<sub>3</sub>）可写为 C(C)。SMILES 通过数字来标识环的连接，相同的数字表示环的开始和结束。例如，环己烷（C<sub>6</sub>H<sub>12</sub>）在 SMILES 中表示为 C1CCCCC1。SMILES 也支持立体化学的表示，包括双键的几何构型以及手性中心的描述。例如，双键使用 “/” 和 “\” 符号区分顺反异构体，而手性中心则通过在原子符号后加上 “@” 或 “@@” 来区分，分别对应不同的立体配置。SMILES 表示法以其简洁、高效的特点，在化学信息学和计算化学领域占据了不可替代的地位。它不仅提高了化学数据处理的效率，还为分子结构的分析、药物发现和材料设计等研究提供了重要的工具。图2.1展示了不同 SMILES 的示意图。

### 2.2 图神经网络

图神经网络（Graph Neural Network, GNN）是一类用于处理图结构数据的神经网络模型。与传统神经网络不同，GNN 能够直接在图上操作，捕捉节点之间的复杂关系

表 2.1 SMILES 示意图

| 分子   | 结构                                                                                | SMILES                                   |
|------|-----------------------------------------------------------------------------------|------------------------------------------|
| 褪黑激素 |  | <chem>CC(=O)NCCC1=CNC2C1cc(OC)cc2</chem> |
| 尼古丁  |  | <chem>CN1CCC[C@H]1c2cccnc2</chem>        |

和图结构的整体特征。它们已广泛应用于社交网络分析、知识图谱、分子化学结构分析等多个领域。其核心思想是通过节点的邻域聚合（或消息传递）过程来更新节点状态，使每个节点能够收集并利用周围邻居的信息。通过一系列的更新迭代，每个节点能够捕获到包含更远邻居信息的表示，从而实现图结构数据的深度学习。

对于一个图  $G = (V, E)$ ，其中  $V$  是节点集合  $E$  是边集合。图神经网络的一次迭代更新可以表示为消息传递和特征更新两个部分。消息传递机制中，每个节点  $v$  接收来自其邻居  $u \in \mathcal{N}(v)$  的信息，其中  $\mathcal{N}(v)$  表示节点  $v$  的邻域，该过程如公式(2.1)所示：

$$\mathbf{m}_v^{(l+1)} = \sum_{u \in \mathcal{N}(v)} M^{(l)}(\mathbf{h}_v^{(l)}, \mathbf{h}_u^{(l)}, \mathbf{e}_{uv}) \quad (2.1)$$

其中， $\mathbf{m}_v^{(l+1)}$  是节点  $v$  在第  $l+1$  层的聚合消息， $M^{(l)}$  是消息函数， $\mathbf{h}_v^{(l)}$  和  $\mathbf{h}_u^{(l)}$  分别是节点  $v$  和  $u$  在第  $l$  层的特征表示， $\mathbf{e}_{uv}$  是连接节点  $u$  和  $v$  的边的特征。此时，节点  $v$  根据聚合得到的消息更新自己的特征表示，该过程如公式(2.2)所示：

$$\mathbf{h}_v^{(l+1)} = U^{(l)}(\mathbf{h}_v^{(l)}, \mathbf{m}_v^{(l)}) \quad (2.2)$$

其中  $U^{(l)}$  表示更新函数， $\mathbf{h}_v^{(l+1)}$  表示节点  $v$  的第  $l+1$  层的新特征。最后，使用读出函数生成全图表示，该过程如公式(2.3)所示：

$$\mathbf{h}_G = R^{graph}(\{\mathbf{h}_v^{(L)} | v \in V\}) \quad (2.3)$$

其中， $R^{graph}$  是图级读出函数，通常是节点特征的某种聚合，例如求和、平均、最大值等。

GNN 通过迭代更新过程有效捕获图中节点的拓扑结构，使每个节点的表示包含其邻域的信息。与传统的深度学习模型相比，GNN 在处理图结构数据时能够更好地利用数据的关系信息，为图数据分析提供了一种强有力的工具。本章接下来将介绍当前最主流的图神经网络。

### (1) 图注意力网络

图注意力网络<sup>[34]</sup> (GAT) 是由 Veličković 等人在 2017 年提出的一种图神经网络结构，旨在通过注意力机制来动态地计算节点间的边权重，使网络能够专注于每个节点的重要邻居节点，从而提升图数据的表示能力。在 GAT 中，注意力机制被用来计算节点间的权重，这些权重表示一个节点应该在多大程度上关注其邻居节点的特征。与传统的图卷积网络 (GCN) 相比，GAT 不需要预定义邻接矩阵中的边权重，而是可以通过学习得到，使得网络能够更加灵活地捕获图结构的特性。通过自注意力 (Self-Attention) 机制来计算图中每一对节点之间的注意力系数。具体来说，给定一个图中的节点特征集合  $\{\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_N\}$  的特征向量，GAT 首先利用一组可学习的参数权重将每个节点的特征线性变换到更高维空间，然后计算变换后的特征之间的相似度，以得到节点间的注意力系数，公式如(2.4)所示：

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^T [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j]) \quad (2.4)$$

这里， $\mathbf{W}$  是共享的线性变换矩阵， $\parallel$  代表拼接操作， $\mathbf{a}$  是可学习的权重向量，用于计算节点  $i$  和节点  $j$  的特征之间的相似度，LeakyReLU 是非线性激活函数。然后，GAT 通过 softmax 函数对所有节点的注意力系数进行归一化，以确保对于每个节点，其所有邻居节点的注意力系数之和为 1：

$$\alpha_{ij} = \text{softmax}_j(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})} \quad (2.5)$$

一旦计算得到注意力系数，GAT 将通过加权组合邻居节点的特征来更新每个节点的特征向量，其中 GAT 采用了多头注意力机制，即并行运行多个独立的注意力机制（即“头”），然后将这些头的输出拼接起来，以形成下一层的输入：

$$\mathbf{h}'_i = \parallel_{k=1}^K \sigma \left( \sum_{j \in \mathcal{N}(i)} \alpha_{ij}^k \mathbf{W}^k \mathbf{h}_j \right) \quad (2.6)$$

其中， $\sigma$  表示激活函数，通常是 ReLU 或者其他非线性函数。 $\mathbf{h}'_i$  是节点  $i$  的新特征向量。为了提高模型的表达能力， $K$  是头的数量， $\parallel$  代表拼接操作， $\alpha_{ij}^k$  和  $\mathbf{W}^k$  分别是第  $k$  个头的注意力系数和线性变换矩阵。通过这种方式，GAT 能够在不同的子空间学习节点间的不同的特征表示，增强了模型的表示能力。GAT 的这种灵活性和有效性使其在节点分类、图分类等图相关的任务中都展现出了优异的性能。

(2) 图卷积网络图卷积网络 (GCN) 旨在直接在图结构数据上进行学习。GCNs 通过将传统的卷积运算推广到图数据上, 使得网络能够捕捉图结构中的节点关系和特征信息。它们广泛应用于节点分类、图分类、链路预测等任务。在 GCN 中, 图由图邻接矩阵  $\mathbf{A}$  和节点特征矩阵  $\mathbf{X}$  表示。每一层的图卷积操作可以表示为:

$$\mathbf{H}^{(l+1)} = \sigma(\hat{\mathbf{D}}^{-\frac{1}{2}} \hat{\mathbf{A}} \hat{\mathbf{D}}^{-\frac{1}{2}} \mathbf{H}^{(l)} \mathbf{W}^{(l)}) \quad (2.7)$$

其中,  $\mathbf{H}^{(l)}$  是第  $l$  层的节点特征矩阵,  $\mathbf{H}^{(0)} = \mathbf{X}$  是初始节点特征。 $\hat{\mathbf{A}} = \mathbf{A} + \mathbf{I}_N$  是邻接矩阵  $\mathbf{A}$  加上单位矩阵  $\mathbf{I}_N$  (为了加入自连接),  $\mathbf{I}_N$  是  $N \times N$  的单位矩阵,  $N$  是节点数。 $\hat{\mathbf{D}}$  是  $\hat{\mathbf{A}}$  的度矩阵, 其对角元素  $\hat{D}_{ii} = \sum_j \hat{A}_{ij}$ 。 $\mathbf{W}^{(l)}$  是第  $l$  层的可学习权重矩阵。 $\sigma(\cdot)$  是非线性激活函数, 如 ReLU。这个公式将每个节点的特征与其邻居的特征结合起来, 使用归一化的邻接矩阵 ( $\hat{\mathbf{D}}^{-\frac{1}{2}} \hat{\mathbf{A}} \hat{\mathbf{D}}^{-\frac{1}{2}}$ ) 确保信息传递过程中保持稳定。

## 2.3 残差网络

残差网络<sup>[35]</sup> (ResNet) 是由何恺明等人于 2015 年提出的深度神经网络架构。ResNet 通过引入残差模块 (Residual Blocks) 有效解决了深度神经网络中的梯度消失和梯度爆炸问题, 使得网络能够顺利地训练数百甚至数千层的深度, 从而大幅提高了深度学习模型在图像识别、物体检测等任务中的性能。


残差网络的核心思想是引入“残差学习”, 对于一个浅层网络, 其输出可以直接作为深层网络的一部分。具体来说, 期望学习的目标映射为  $\mathcal{H}(\mathbf{x})$ , 让网络去拟合残差映射  $\mathcal{F}(\mathbf{x}) := \mathcal{H}(\mathbf{x}) - \mathbf{x}$ , 而不是直接拟合  $\mathcal{H}(\mathbf{x})$ 。则网络的输出变为  $\mathcal{F}(\mathbf{x}) + \mathbf{x}$ 。这种结构可以通过使用快捷连接 (Shortcut Connections) 或跳跃连接 (Skip Connections) 来实现, 这些连接直接将输入  $\mathbf{x}$  添加到网络的深层输出上。残差模块的基本形式可以用下面的公式表示:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\}) + \mathbf{x} \quad (2.8)$$

其中,  $\mathbf{x}$  和  $\mathbf{y}$  分别是网络层的输入和输出,  $\mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\})$  表示残差映射,  $\{\mathbf{W}_i\}$  代表残差模块中的权重。为了解决输入输出维度不一致的问题, 可以引入一个线性投影  $\mathbf{W}_s$  来调整维度:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\}) + \mathbf{W}_s \mathbf{x} \quad (2.9)$$

这里,  $\mathbf{W}_s \mathbf{x}$  是通过一个线性投影调整维度后的输入, 以确保  $\mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\})$  和  $\mathbf{x}$  在加法操作中维度一致。

图 2-1 Transformer 架构图<sup>[2]</sup>

ResNet 的网络结构通过堆叠多个这样的残差模块来构建。例如，一个典型的 ResNet 模型可能包含多个残差块，每个块内可能有两层或三层卷积层。根据残差模块的数量，常见的 ResNet 有 ResNet-18、ResNet-34、ResNet-50、ResNet-101 和 ResNet-152 等版本，数字代表网络中的层次数量。

ResNet 通过解决了深度学习中的退化问题，使得训练极深的网络成为可能，极大地推动了深度学习的发展。在 ImageNet<sup>[36]</sup> 这样的大规模图像识别任务中，ResNet 展现出了显著的性能提升，成为许多后续深度学习研究和应用的基础架构。总的来说，ResNet 的引入标志着深度学习领域的一个重要里程碑，它不仅解决了训练深层网络的技术障碍，还为后续的深度网络设计和优化提供了新的思路和范例。

## 2.4 Transformer

Transformer<sup>[2]</sup> 是一种基于自注意力机制（Self-Attention Mechanism）的深度学习模型，最初由 Vaswani 等人在 2017 年提出，用以解决序列到序列（seq2seq）的任务，例如机器翻译。由于其独特的结构和出色的性能，Transformer 已经成为自然语言处理（NLP）等领域的一个标准工具。Transformer 模型主要由编码器（Encoder）和解码器（Decoder）两部分组成，每部分由多个相同的层堆叠而成。每一层包含两个主要子层：多头自注意力机制（Multi-Head Self-Attention）和前馈全连接网络（Position-wise Feed-Forward Network）。

自注意力机制允许输入序列中的每个位置的元素“关注”序列中的其他位置，为每个位置计算一个加权平均输出。具体来说，对于每个位置，通过下面的公式计算自注意力：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V} \quad (2.10)$$

这里， $\mathbf{Q}, \mathbf{K}, \mathbf{V}$  分别是查询 (Query)、键 (Key) 和值 (Value) 矩阵，由输入经过不同的线性变换得到， $d_k$  是键向量的维度。softmax 操作确保所有位置的权重总和为 1。在多头自注意力机制中，将  $\mathbf{Q}, \mathbf{K}, \mathbf{V}$  分别映射到不同的表示空间，并行计算多次自注意力：

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad (2.11)$$

$$\text{where head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V) \quad (2.12)$$

这里， $\mathbf{W}_i^Q, \mathbf{W}_i^K, \mathbf{W}_i^V$  和  $\mathbf{W}^O$  是可学习的参数矩阵， $h$  是头的数量，Concat 表示拼接操作。

每个 Transformer 层还包括一个前馈全连接网络，对每个位置应用相同的线性变换：

$$\text{FFN}(x) = \max(0, \mathbf{x}\mathbf{W}_1 + b_1) \mathbf{W}_2 + b_2 \quad (2.13)$$

这里， $\mathbf{W}_1, \mathbf{W}_2, b_1, b_2$  是可学习的参数， $\max(0, x)$  是 ReLU 激活函数。

编码器由多个相同的层堆叠而成，每层有两个子层：多头自注意力机制和前馈全连接网络。每个子层后面都跟着一个残差连接和层归一化。解码器也由多个相同的层组成，但每层有三个子层：解码器自注意力、编码器-解码器注意力和前馈全连接网络。解码器自注意力和编码器-解码器注意力在功能上与编码器中的自注意力相似，但解码器自注意力会防止位置关注到“未来”的位置，保证了信息流的方向性和自回归特性。

Transformer 通过其独特的自注意力机制和多头注意力设计，在处理序列数据方面展现出了极高的效率和强大的性能。其无需依赖循环结构处理序列，使得模型能够更容易并行化和捕捉长距离依赖，这些优点使得 Transformer 迅速成为了许多 NLP 任务的基础架构。

## 2.5 预训练微调范式

预训练微调范式 (Pre-training and Fine-tuning paradigm) 是深度学习中一种常见的训练框架，尤其在自然语言处理 (NLP)、计算机视觉 (CV) 等领域广泛应用。这一范式基于一个关键的假设：通过在大规模的数据集上预训练，模型能够学习到普适的特征或语言规律，然后可以通过在特定任务的较小数据集上微调来调整模型，使其更好地解决特定问题。化学领域拥有海量的分子数据，但大部分数据未被充分标注，传统的监督学



习方法直接应用于这些数据并不能取得良好的性能。预训练允许模型首先在这些大规模的未标注数据上学习，从而掌握分子的一般性质和规律，例如原子间的相互作用、分子结构的特点等。该范式包括两个主要阶段：预训练（Pre-training）和微调（Fine-tuning）。

在预训练阶段，模型通常在大规模的未标注分子数据集上进行训练，目标是学习分子的通用表示。典型的预训练任务包括分子重建、掩码分子片段预测、对比学习等。以掩码分子片段预测为例，其预训练任务可以表示为：

$$L_{pre} = -\frac{1}{N} \sum_{i=1}^N \log P(X_{masked}|X_{observed}; \theta) \quad (2.14)$$

这里， $X_{observed}$  是观察到的分子片段， $X_{masked}$  是被掩码的分子片段（例如，通过随机遮盖分子中的一部分原子或键）， $N$  是批量大小， $\theta$  表示模型参数。 $P(X_{masked}|X_{observed}; \theta)$  是在给定观察到的片段时，模型预测被掩码片段的概率。

预训练完成后，模型在特定的下游任务（例如，分子性质预测、分子活性分类）上进行微调。此时，模型利用较小的、针对特定任务标注的数据集进行训练。微调可以使用以下损失函数：

$$L_{fine} = -\frac{1}{M} \sum_{j=1}^M \log P(y_j|X_j; \theta_{fine}) \quad (2.15)$$

这里， $X_j$  表示分子的输入表示， $y_j$  是对应的标签（例如，分子是否有活性）， $M$  是标注样本的数量， $\theta_{fine}$  是微调后的模型参数。 $P(y_j|X_j; \theta_{fine})$  表示给定分子表示时，模型预测正确标签的概率。通过这种范式，模型能够有效地利用大规模未标注数据来学习有意义的分子表示，同时保持在特定化学任务上的高性能，加速新药发现和化学研究的过程。

## 2.6 本章小结

本章为后续研究提供了关键技术和理论基础，包括 SMILES 表示法、图神经网络、残差网络、Transformer 架构，以及预训练微调范式。这些概念和技术是理解和实施分子表示学习的基石，特别是在处理化学数据和理解分子结构方面的应用，为后续章节中的实验设计和结果分析奠定坚实的理论和技術基础。





### 第三章 基于图和图像的多模态分子表示学习方法

准确预测药物分子性质是人工智能药物发现的基础性问题之一<sup>[11,37,38]</sup>，而寻找有效的药物分子表示方法是其关键。尽管分子领域存在大量数据，但是拥有高质量标签的分子数据却相对稀少，这是因为进行湿实验以获取分子性质标签是一项耗时且耗力的任务，因此基于监督学习的方法在分子性质预测任务上的表现往往不尽如人意。目前最先进的研究采用自监督学习方法从大规模无标签的分子数据中学习有意义的结构表示，并针对不同类型的下游任务进行微调。然而，这些研究通常只利用了单一模态的分子信息<sup>[6,27]</sup>，如分子图像或 SMILES，忽略了不同分子模态之间的信息互补性。

尽管先前基于图或者 SMILES 的模型取得了不错的效果，但单一模态所提供的信息仍然有限。受到计算机视觉和自然语言处理<sup>[39]</sup>中利用大量无标签数据取得巨大成功的启发，本章提出一种基于图和图像的多模态分子表示学习方法（Multi-Modal Molecular Representation Learning Based on Image And Graph, MolIG）。分子图捕获了分子的化学属性，如原子类型、化学键和局部连接结构。这些特征反映了分子的微观结构信息，为理解分子的化学本质提供基础。然而，该模态通常缺乏表达分子空间形态和全局信息的能力。相反，分子图像为分子的几何形状和空间排列提供了直观的全局视角，尽管它们可能不直接反映化学细节，但其包含了分子的整体空间信息和外形特征。此外，分子图像还能揭示分子中原子和官能团的相对位置关系，为模型提供更为宏观的结构信息。MolIG 方法通过整合分子图和分子图像的信息，以微观和宏观的两种视角理解分子特征。通过在对比学习框架下联合训练两种模态的信息，MolIG 不仅可以提取分子结构特征，还能够捕获高阶语义信息。

本章3.1节将对分子性质预测问题进行定义；3.2节将介绍 MolIG 方法的整体框架、各个子模块及其算法伪代码；3.3节将对 MolIG 方法的性能进行系统评估，通过多种实验证明 MolIG 的有效性；3.4节将对本章工作进行总结。

#### 3.1 问题定义

**分子性质预测问题定义：**对于给定的药物  $d$  及其对应的 SMILES，分子表示学习方法对药物  $d$  进行编码获得其特征向量  $\mathbf{h}_d$ ，并通过预测模块计算其具有性质  $p$  的概率或该性质的具体数值  $\hat{y}_{p,d}$ 。即方法的目标是学习一个预测函数  $\hat{y}_{p,d} = \Gamma(p|\theta, SMILES_d)$ ，其

中  $\theta$  表示模型的参数。

## 3.2 方法

本章提出的基于图和图像的多模态分子表示学习方法 MolIG 主要由两个模块组成, 分别是预训练模块和微调推理模块。如图3-1所示, 预训练模块主要由分子图和分子图像编码器、分子图和分子图像表征映射器、对比学习框架组成。在预训练模块中, 本章使用不同的编码器分别编码分子图模态和图像模态, 将其映射到新的表征空间后通过对比学习增强同一分子在不同模态下的一致性, 以此使得模型学习到更优秀的表征。在微调推理模块中, 本章使用预训练阶段的图神经网络对下游任务中的分子进行编码, 随后通过性质预测器预测分子性质。




图 3-1 MolIG 方法架构图

### 3.2.1 分子图和分子图像

本章提出的 MolIG 方法使用分子的两种模态, 即分子图模态和分子图像模态, 图3-2展示了二者之间的区别和联系。分子图是一种图表示, 它将分子的结构抽象为图论中的图。在这种表示下, 分子中的原子被视为节点, 而原子间的化学键则对应图中的边。其为模型提供了关于分子结构的详细信息, 包括原子类型和化学键类型等, 这种明确的信息使模型能够直观理解分子的微观方面。在使用图神经网络编码分子图时, 模型的每一层都通过聚合邻居信息来更新节点的特征表示。然而, 这种聚合通常会增加节点间的




图 3-2 分子图和分子图像模态

相似性，进而导致过平滑，限制模型在处理复杂结构时的表达能力。

与基于图的表征形式相比，分子图像的优势在于其不依赖于特定的描述符或编码方式。这使得分子图像能够提供更灵活、通用的表示。虽然图像模态并未直接提供关于原子化学键等细节信息，但是得益于其高分辨率，原子间的相对位置、化学键长度、角度以及其它几何信息可以非常直观的体现，且图像模态受益于卷积运算的全局性质，使得每个像素都能感知图像的整体信息，这些空间信息是分子图模态所不具备的。因此图模态可以看作局部模态，侧重于微观细节的表达，图像模态可被视为全局模态，在提供额外空间信息的同时注重捕捉整体结构。

### 3.2.2 分子图和分子图像编码器

#### (1) 分子图编码器

分子图  $G$  将分子表示为 2D 图，分别以原子为节点、化学键为边。本文将分子图定义为  $G = (V, E)$ ，其中节点  $v \in V$  表示节点  $v$ ， $e_{uv} \in E$  表示原子  $u$  和原子  $v$  之间的化学键。特别的，本章将 Atomic Num 和 Chirality 作为原子初始特征，将 Bond Type 和 Direction 作为化学键初始特征，具体信息如表 3.1 所示：

表 3.1 原子和化学键初始特征

| 类型  | 特征名            | 范围                                           |
|-----|----------------|----------------------------------------------|
| 原子  | Atomic Num     | [1, 118]                                     |
|     | Chirality      | UNSPECIFIED, TETRAHEDRAL CW, TETRAHEDRAL CCW |
| 化学键 | Bond Type      | SINGLE, DOUBLE, TRIPLE, AROMATIC             |
|     | Bond Direction | NONE, ENDUPRIGHT, ENDDOWRIGHT                |

初始表征公式如(3.1)和(3.2)所示：

$$\mathbf{h}_v^{(0)} = \text{AtomEmb}(G) + \text{ChiralityEmb}(G) \quad (3.1)$$

$$\mathbf{e}_{uv}^{(0)} = \text{BondTypeEmb}(G) + \text{DirectionEmb}(G) \quad (3.2)$$

其中，AtomEmb、ChiralityEmb、BondTypeEmb、DirectionEmb 将低维的表示类型映射为高维分子初始表征。 $\mathbf{h}_v^{(0)}$  和  $\mathbf{e}_{uv}^{(0)}$  分别表示原子  $u$  和化学键  $e$  的初始表征。图神经网络的聚合和更新操作如公式(3.3)和(3.4)所示：

$$\mathbf{a}_v^{(k)} = \sum_{u \in \mathcal{N}(v)} \left( \mathbf{h}_v^{(k-1)} + \text{MLP}_{\text{bond}}^{(k)}(\mathbf{e}_{uv}^{(k-1)}) \right) \quad (3.3)$$

$$\mathbf{h}_v^{(k)} = \text{MLP}_{\text{atom}}^{(k)}(\mathbf{a}_v^{(k)} + \mathbf{h}_v^{(k-1)}) \quad (3.4)$$

其中， $\mathcal{N}(v)$  表示节点  $v$  的邻居集合， $\mathbf{h}_v^{(k)}$  表示节点  $v$  在第  $k$  层的表征。经过  $k$  次迭代后， $\mathbf{h}_v^{(k)}$  可以捕捉到他们  $k$ -hop 的邻域信息。 $\text{MLP}_{\text{atom}}^{(k)}$  和  $\text{MLP}_{\text{bond}}^{(k)}$  分别表示原子层级和化学键层级第  $k$  个 MLP 层。公式(3.3)将节点  $v$  相邻节点的信息聚合，公式(3.4)则更新聚合后的特征。本章使用图同构网络 (GIN)<sup>[40]</sup> 作为分子图编码器。但是，由于分子图不同于其他类型的图结构，化学键的信息对于下游任务的影响较大，为此，公式(3.3)在聚合邻居节点的同时也聚合相邻化学键的信息。

为了进一步提取图级特征  $\mathbf{h}_G$ ，本章使用平均池化操作整合了图  $G$  中所有节点的特征。如公式(3.5)所示：

$$\mathbf{h}_G = \frac{1}{N} \sum_{v \in V} \mathbf{h}_v^{(k)} \quad (3.5)$$

以上公式可以被总结为公式(3.6)：

$$\mathbf{h}_G = \text{GraphEncoder}(G) \quad (3.6)$$

## (2) 分子图像编码器

本章采用 ResNet-34<sup>[35]</sup> 作为分子图像编码器，旨在从图像模态中高效地提取特征。ResNet-34 属于残差神经网络，其通过残差连接改善了深层网络的训练问题，因此其在维持较低的模型复杂度的同时，具备出色的特征提取能力。在图像编码领域存在多种选择，例如 DenseNet<sup>[41]</sup>、EfficientNet<sup>[42]</sup> 和 Vision Transformer (ViT)<sup>[43]</sup> 等，这些架构在多个图像处理任务上均展现了卓越的性能，但针对本研究的分子性质预测任务，本章特别选用了 ResNet-34。这一选择基于其相对较低的模型复杂度及良好的特征提取效率，可以平衡性能和计算资源之间的需求。需要特别强调的是，由于分子图像与常规的 ImageNet<sup>[36]</sup> 图像在视觉特征上存在显著差异，直接应用在 ImageNet 上训练的模型并不能达到最优效果。因此，本章选择从零开始训练 ResNet-34 编码器，以确保模型能够更准确地适应分子图像的特定表征形式，为后续的分子性质预测任务提供强有力的特征支持。分子图像编码器公式化如(3.7)所示：

$$\mathbf{h}_I = \text{ImageEncoder}(I) \quad (3.7)$$

其中， $I$  为药物分子  $d$  的图像模态。

### 3.2.3 分子图和分子图像表征映射器

表征映射器是 MolIG 方法中的关键模块，其用于将分子图和分子图像编码器提取到的高维特征向量映射到低维空间。具体来说，表征映射器可以看作是一个多层感知机，其目的是学习在低维空间中更具区分性的表示，以便进行对比学习。本章遵循 Chen 等人<sup>[44]</sup> 提到的非线性多层感知机作为表征映射器。鉴于分子图和分子图像在模态特性上存在显著差异，本章设计了两个结构相同但参数独立的表征映射器，分别针对分子图和分子图像的特征进行处理。这种设计使得每个映射器针对其对应模态的学习最优的对比特征表示，同时避免了不同模态之间特征表示的直接混合，从而在分子性质预测的下游任务中实现更准确的结果。表征映射器的形式化表述如公式(3.8)和(3.9)所示：

$$\mathbf{z}_G = \text{GraphMapper}(\mathbf{h}_G) \quad (3.8)$$

$$\mathbf{z}_I = \text{ImageMapper}(\mathbf{h}_I) \quad (3.9)$$

其中 GraphMapper 和 ImageMapper 分别表示分子图和分子图像表征映射器。

### 3.2.4 对比学习框架

在本章中，给定包含  $N$  个分子的批次  $\{d_0, d_1, d_2 \dots d_{n-1}\}$ ，首先使用 Rdkit<sup>[45]</sup> 软件包将其转换成相应的图结构  $\{G_0, G_1, G_2 \dots G_{n-1}\}$  和图像  $\{I_0, I_1, I_2 \dots I_{n-1}\}$ 。来自于同



一分子的图和图像构成正样本，而来自不同分子的图和图像则视为负样本对。基于图神经网络的分子图编码器将  $G_i$  编码为  $\mathbf{h}_i^G$ ，基于残差卷积神经网络的分子图像编码器将  $I_i$  编码为  $\mathbf{h}_i^I$ 。由于分子图与分子图像在模态上存在显著差异，直接使用  $\mathbf{h}_i^G$  和  $\mathbf{h}_i^I$  作为对比损失的输入往往会使得模型在下游任务上的表现较差。针对这个问题，3.2.3节设计了图模态和图像模态的表征映射器，将分子图表征映射为  $\mathbf{z}_i^G$ ，将分子图像表征映射为  $\mathbf{z}_i^I$ ，使其在同一个投影空间中计算对比损失。

在本章中，对比学习的目标是最大化正样本中分子图和分子图像模态在投影空间中的表征一致性，同时将不属于同一样本的分子图和分子图像嵌入表示拉远。本章采用归一化温度交叉熵损失（NT-Xent）作为优化目标，以此来增强不同模态间表征的相似性，形式化表述如公式(3.10)所示：

$$\mathcal{L}_{i,j} = -\log \frac{\exp(\text{sim}(\mathbf{z}_i^G, \mathbf{z}_j^I)/\tau)}{\sum_{k=1}^{2N} 1 \cdot (k \neq i) \exp(\text{sim}(\mathbf{z}_i^G, \mathbf{z}_k^I)/\tau)} \quad (3.10)$$

其中， $\tau$  表示为温度系数， $\text{sim}(\cdot)$  表示相似度计算，计算方式如公式(3.11)所示，最终的损失在同一个批次中计算。

$$\text{sim}(\mathbf{z}_i, \mathbf{z}_j) = \frac{\mathbf{z}_i^T \mathbf{z}_j}{\|\mathbf{z}_i\|_2 \cdot \|\mathbf{z}_j\|_2} \quad (3.11)$$

通过将分子图和分子图像两种模态进行对比学习，模型可以在不需要标签数据的情况下学习数据驱动的分子表示。同时编码器可以捕获不同模态下的分子特征信息，从而丰富分子的整体表示，更全面地反映分子的特性。此外，对比学习学习到的表示具有较强的泛化能力，因为它强调了样本之间的相似性，使得相似的样本在表示空间中更加接近，从而在面对分布外泛化的数据时，模型也能更好的理解新样本。

### 3.2.5 微调

为了更好地拟合下游任务的数据分布，本章将对预训练模型进行微调。具体而言，沿用预训练阶段得到的分子图编码器和参数，专注于分子结构信息的学习。预训练的分子图编码器在此阶段被用来提取下游任务中分子的特征表示。为了适应特定的分子性质预测任务，本章在预训练分子图编码器之后附加了一个全连接层  $\text{PropertyPredictor}(\mathbf{w})$ ，其中  $\mathbf{w}$  代表该层的参数。在微调过程中，药物分子  $d$  的分子图  $G$  被送入预训练分子图编码器，以获取其潜在表示  $\mathbf{h}_G$ 。随后，这一潜在表示被进一步传递至性质预测器  $\text{PropertyPredictor}$ ，以预测分子的特定性质，例如计算分子具有性质  $p$  的概率或该性质

的具体数值  $\hat{y}_{p,d}$ 。通过这种方法,模型能够充分利用预训练阶段学习到的丰富分子表示,进一步拟合特定任务的数据分布,从而在分子性质预测任务上获得更精确和鲁棒的结果,其形式化表述如公式(3.12)所示:

$$\hat{y}_{p,d} = \text{PropertyPredictor}(\text{GraphEncoder}(G)) \quad (3.12)$$

在微调阶段,对于分类任务,采用交叉熵 (Cross Entropy, CE) 损失进行优化,计算公式如(3.13)所示:

$$CE = \frac{1}{N} \sum_i^N - \left[ y_{p,i} \log(\hat{y}_{p,i}) + (1 - y_{p,i}) \log(1 - \hat{y}_{p,i}) \right] \quad (3.13)$$

其中  $N$  为 batch size 的大小。对于回归任务,采用均方损失 (Mean Square Error, MSE) 进行优化,计算公式如(3.14)所示:

$$MSE = \frac{1}{N} \sum_i^N = (y_{p,i} - \hat{y}_{p,i})^2 \quad (3.14)$$

### 3.2.6 算法伪代码

MolIG 算法的伪代码如算法3.1所示。模型分为预训练、微调两个阶段。1-14 行表示预训练阶段,其中 4-6 行为分子表征计算,利用分子图编码器和分子图像编码器分别对两种模态进行编码;7-9 行为分子映射计算,将上述编码映射到计算对比损失的隐空间;10-12 行为对比学习过程,并计算对比损失用来更新参数。预训练阶段结束后,保存参数用以微调。16-25 行表示微调阶段,第 17 行首先加载预训练参数  $\theta$ ,20-23 行为分子性质预测并进一步更新参数。

---

#### 算法 3.1 基于图和图像的多模态分子表示学习方法 MolIG

---

**输入:** 分子图  $G$  和分子图像  $I$ ; 预训练时的批次数  $B_p$ 、训练迭代轮次  $E_p$ ; 微调时的批次数  $B_f$ 、训练迭代轮次  $E_f$

**输出:** 分子具有性质  $p$  的概率或该性质的具体数值  $\hat{y}_{p,d}$

1: **预训练阶段:**

2: **for** epoch = 0; epoch <  $E_p$  **do**

3:     **for** batch = 0; batch <  $B_p$  **do**

4:         **分子表征计算:**

5:             根据公式(3.6)计算分子图的表征  $\mathbf{h}_G \leftarrow \text{GraphEncoder}(G)$

6:             根据公式(3.7)计算分子图像的表征  $\mathbf{h}_I \leftarrow \text{ImageEncoder}(I)$

7:         **分子映射计算:**



---

```

8:         根据公式(3.8)计算分子图的映射表征  $z_G \leftarrow \text{GraphMapper}(h_G)$ 
9:         根据公式(3.9)计算分子图像的映射表征  $z_I \leftarrow \text{ImageMapper}(h_I)$ 
10:    对比学习:
11:        根据公式(3.10)进行对比学习, 并计算 NT-Xent 损失  $L$ 
12:        通过反向传播更新 MolIG 方法参数
13:    end for
14: end for
15: 返回 MolIG 预训练参数  $\theta$ 
16: 微调阶段:
17: 加载 MolIG 预训练参数  $\theta$ 
18: for epoch = 0; epoch <  $E_f$  do
19:     for batch = 0; batch <  $B_f$  do
20:         分子性质预测:
21:         根据公式(3.12)计算分子性质  $\hat{y}_{p,d} \leftarrow \text{PropertyPredictor}(\text{GraphEncoder}(G))$ 
22:         根据公式(3.13)和公式(3.14)计算微调损失  $Loss$ 
23:         通过反向传播进一步更新 MolIG 方法参数  $\theta$ 
24:     end for
25: end for

```

---

### 3.3 实验及结果分析

为了验证 MolIG 方法的有效性, 本章首先将其在两个基准组上进行实验, 以证明其在分子性质预测方面的有效性。随后讨论了预训练以及对比损失中的温度系数对下游任务的影响。最后, 本章通过展示 MolIG 在分子相似性搜索任务中的表现来进一步评估其性能。

#### 3.3.1 预训练数据集和图像数据增强

为构建预训练数据集, 本研究从 PubChem<sup>1</sup>数据库中选取一千万个未经标注的潜在药物分子。经过初步筛选排除化学结构不合理或信息缺失的小分子后, 最终获得了包含 9,999,917 个小分子的预训练数据集。随后, 按照 0.95/0.05 的比例将数据集分割为训练集和验证集。

---

<sup>1</sup><https://pubchem.ncbi.nlm.nih.gov/>

数据增强是一种有效提高模型泛化能力和鲁棒性的方法,通过在训练过程中引入更多的数据变化,可以使模型更好地应对真实世界中的复杂场景。在计算机视觉和多模态领域,数据增强已经被广泛应用。然而,对于分子图,如随机屏蔽原子、边扰动或者子图采样等常用的数据增强方式容易破坏分子的结构信息,导致其学习到的表征无法很好的拟合下游任务上的数据。因此,针对预训练阶段,本章未对分子图进行任何增强操作以保持其结构的完整性。相对地,考虑到分子图像相比一般图像更稀疏,即超过 90% 的像素值为 0<sup>[26]</sup>,因此本章采取了三种适度的图像增强策略:随机水平翻转、随机灰度化以及随机旋转。这些操作各自以 25% 的概率执行,并且都不会对分子图像的基本结构造成改变,同时可以增加模型面对数据变动的适应性,帮助模型学习到更具鲁棒性的特征表示。

### 3.3.2 下游任务数据集

本章将介绍评估 MolIG 的两个基准组, MoleculeNet 基准组<sup>[11]</sup>和 ADMET 基准组<sup>[46]</sup>。

#### (1) MoleculeNet 基准组

MoleculeNet 基准组是一个用于评估分子机器学习和深度学习方法性能的基准数据集和基准测试平台,并在 2017 年首次发布。MoleculeNet 旨在促进分子机器学习领域的研究,通过一系列具有挑战性的任务和相应的分子数据集,使研究人员能够系统的比较不同的方法,是近年来分子性质预测领域公认的基准数据组。本章选取 MoleculeNet 基准组中的 7 个药物分子性质预测数据集对 MolIG 方法进行性能评估。数据集的基本信息如表 3.2 所示:

表 3.2 MoleculeNet 基准组基本信息

| 数据集     | 任务分类   | 分子数    | 任务数 | 任务类型 | 评价指标    | 划分方式 |
|---------|--------|--------|-----|------|---------|------|
| BBBP    | 生理学与毒性 | 2,039  | 1   | 分类任务 | ROC-AUC | 骨架划分 |
| BACE    | 生物学    | 1,513  | 1   | 分类任务 | ROC-AUC | 骨架划分 |
| SIDER   | 生理学与毒性 | 1,427  | 27  | 分类任务 | ROC-AUC | 骨架划分 |
| Tox21   | 生理学与毒性 | 7,831  | 12  | 分类任务 | ROC-AUC | 骨架划分 |
| HIV     | 生物学    | 41,127 | 1   | 分类任务 | ROC-AUC | 骨架划分 |
| ToxCast | 生理学与毒性 | 8,575  | 617 | 分类任务 | ROC-AUC | 骨架划分 |
| ClinTox | 生理学与毒性 | 1,478  | 2   | 分类任务 | ROC-AUC | 骨架划分 |

具体描述信息如下:

BBBP<sup>[11]</sup>: 血脑屏障渗透性 (Blood-Brain Barrier Penetration) 数据集专为屏障渗透性建模和预测而设计。作为分隔循环血液和脑细胞外液的膜, 血脑屏障可阻挡大多数药物、激素和神经递质。因此, 屏障的穿透形成了针对中枢神经系统的药物开发中长期存在的问题。该数据集记录了药物分子是否能通过中枢神经系统。

BACE<sup>[11]</sup>: 该数据集提供了一组人类  $\beta$ -分泌酶 1 (BACE-1) 抑制剂的定量 (IC50) 和定性 (二元标签) 结合结果。

SIDER<sup>[11]</sup>: 副作用资源 (The Side Effect Resource) 是已上市药物和药物不良反应 (ADR) 的数据库。专注于预测药物的副作用。

Tox21<sup>[11]</sup>: 21 世纪毒理学 (The Toxicology in the 21st Century) 致力于预测化合物对人体细胞中毒性的影响。该数据集包含化合物对 12 个不同目标 (包括核) 的定性毒性测量结果。

HIV: 艾滋病数据集由药物治疗计划 (DTP) 艾滋病抗病毒筛查引入, 该筛查测试了 40,000 多种化合物抑制 HIV 复制的能力。

ToxCast<sup>[11]</sup>: 该数据集是与 Tox21 同一计划的扩展数据集, 为基于体外高通量筛选的大型化合物库提供毒理学数据, 处理后的集合包括 8k 化合物的 600 多个实验的定性结果。

ClinTox<sup>[11]</sup>: 比较了 FDA 批准的药物和因毒性原因而未能通过临床试验的药物。

## (2) ADMET 基准组

ADMET<sup>[46]</sup> 是药物研究和开发过程中非常重要的一个概念, 代表着药物的吸收、分布、代谢、排泄和毒性等性质。ADMET 预测可以帮助研究人员在早期阶段识别具有潜在治疗价值的化合物, 并在后续药物优化和开发过程中指导化合物的设计和合成。与 MoleculeNet 基准组一致, 本章将 MolIG 在 ADMET 基准组提供的 21 个任务上进行微调。数据集的基本信息如表 3.3 所示:

表 3.3 ADMET 基准组基本信息

| 任务分类 | 数据集             | 分子数量  | 任务类型 | 评价指标    | 划分方式 |
|------|-----------------|-------|------|---------|------|
| 吸收   | Caco2           | 906   | 回归   | MAE     | 骨架划分 |
|      | HIA             | 578   | 分类   | ROC-AUC | 骨架划分 |
|      | Pgp             | 1,212 | 分类   | ROC-AUC | 骨架划分 |
|      | Bioavailability | 640   | 分类   | ROC-AUC | 骨架划分 |

续表 3.3

| 任务分类 | 数据集                  | 分子数量   | 任务类型 | 评价指标     | 划分方式 |
|------|----------------------|--------|------|----------|------|
| 分布   | Lipophilicity        | 4,200  | 回归   | MAE      | 骨架划分 |
|      | Solubility           | 9,982  | 回归   | MAE      | 骨架划分 |
|      | PPBR                 | 1797   | 回归   | MAE      | 骨架划分 |
|      | VDss                 | 1130   | 回归   | Spearman | 骨架划分 |
| 代谢   | CYP2D6 inhibition    | 13130  | 分类   | PR-AUC   | 骨架划分 |
|      | CYP3A4 inhibition    | 12,328 | 分类   | PR-AUC   | 骨架划分 |
|      | CYP2C9 inhibition    | 12,092 | 分类   | PR-AUC   | 骨架划分 |
|      | CYP2D6 substrate     | 664    | 分类   | PR-AUC   | 骨架划分 |
|      | CYP3A4 substrate     | 667    | 分类   | ROC-AUC  | 骨架划分 |
|      | CYP2C9 substrate     | 666    | 分类   | PR-AUC   | 骨架划分 |
| 排泄   | Half life            | 667    | 回归   | Spearman | 骨架划分 |
|      | Clearance microsome  | 1,102  | 回归   | Spearman | 骨架划分 |
|      | Clearance hepatocyte | 1,020  | 回归   | Spearman | 骨架划分 |
| 毒性   | hERG                 | 648    | 分类   | ROC-AUC  | 骨架划分 |
|      | Ames                 | 7,255  | 分类   | ROC-AUC  | 骨架划分 |
|      | DILI                 | 475    | 分类   | ROC-AUC  | 骨架划分 |
|      | LD50                 | 7,385  | 回归   | MAE      | 骨架划分 |

具体描述信息如下：

**Caco2<sup>[46]</sup>**：使用人类结肠上皮癌细胞系 Caco-2 作为体外模型来模拟人类肠道组织。药物通过 Caco-2 细胞速率的实验结果可以近似药物渗透人体肠道组织的速率。该数据集预测 Caco-2 细胞的有效渗透性。

**HIA<sup>[46]</sup>**：药物口服时，需要从人体胃肠系统吸收到人体血液中。这种吸收能力称为人体肠道吸收（HIA）。该数据集预测 HIA 活性。

**Pgp<sup>[46]</sup>**：P-糖蛋白（Pgp）是一种 ABC 转运蛋白，参与肠道吸收、药物代谢和脑渗透，其抑制可严重改变药物的生物利用度和安全性。该数据集预测 Pgp 抑制的活性。

**Bioavailability<sup>[46]</sup>**：口服生物利用度定义为“活性成分或活性部分从药物产品中吸收并在作用部位变得可用的速率和程度”。该数据集预测生物利用度的活性。

**Lipophilicity<sup>[46]</sup>**: 亲脂性衡量药物在脂质（例如脂肪、油）环境中溶解的能力。高亲脂性往往导致代谢率高、溶解度差、周转率高、吸收低。该数据集用来预测其亲脂性活性。

**Solubility<sup>[46]</sup>**: 水溶解度衡量药物在水中溶解的能力。该数据集用来预测其溶解度的活性。

**PPBR<sup>[46]</sup>**: 人血浆蛋白结合率（PPBR）表示为药物与血液中血浆蛋白结合的百分比。该数据集用来预测其 PPBR 的比率。

**VDss<sup>[46]</sup>**: 稳态分布容积（VDss）衡量药物在身体组织中的浓度与血液中浓度的比较程度。VD 越高，表明在组织中的分布越高，通常表明药物具有高脂溶性、低血浆蛋白结合率。该数据集用来预测其分布容积。

**CYP2D6 inhibition<sup>[46]</sup>**: CYP 2D6 主要在肝脏中表达。它也在中枢神经系统区域高度表达，包括黑质。该数据集用来预测其 CYP2D6 抑制。

**CYP3A4 inhibition<sup>[46]</sup>**: CYP3A4 是体内一种重要的酶，主要存在于肝脏和肠道中。它氧化小外来有机分子（异生素），例如毒素或药物，以便将它们从体内清除。该数据集用来预测 CYP3A4 抑制。

**CYP2C9 inhibition<sup>[46]</sup>**: CYP 2C9 在外源化合物和内源化合物的氧化中发挥着重要作用。该数据集用来预测其 CYP2C9 抑制。

**CYP2D6 substrate<sup>[46]</sup>**: CYP 2D6 主要在肝脏中表达。它也在中枢神经系统区域高度表达，包括黑质。该数据集用来预测其是否是酶的底物。

**CYP3A4 substrate<sup>[46]</sup>**: CYP 3A4 是体内重要的酶，主要存在于肝脏和肠道中。它氧化小外来有机分子（异生素），例如毒素或药物，以便将它们从体内清除。该数据集用来预测其是否是酶的底物。

**CYP2C9 substrate<sup>[46]</sup>**: CYP 2C9 在外源化合物和内源化合物的氧化中发挥重要作用。该数据集用来预测其是否是酶的底物。

**Half life<sup>[46]</sup>**: 药物的半衰期是指药物在体内的浓度降低一半的持续时间。该数据集用来预测其药物作用的持续时间。

**Clearance microsome<sup>[46]</sup>**: 药物清除率定义为在指定时间段内清除药物的血浆体积，它测量活性药物从体内清除的速率。该数据集用来预测其清除活性。

**Clearance hepatocyte<sup>[46]</sup>**: 药物清除率定义为在指定时间段内清除药物的血浆体积，该数据集用来预测其活性药物从体内清除的速率。

**hERG<sup>[46]</sup>**: 人类 ether-à-go-go 相关基因（hERG）对于心脏跳动的协调至关重要。该数据集用来预测其是否会阻止 hERG。



Ames<sup>[46]</sup>: 致突变性是指药物诱导基因改变的能力。该数据集用来预测其是否具有诱变性。


DILI<sup>[46]</sup>: 药物性肝损伤 (DILI) 是由药物引起的致命性肝病, 该数据集用来预测其是否会导致肝损伤。

LD50<sup>[46]</sup>: 急性毒性 LD50 测量可导致致命不良反应的最保守剂量。剂量越高, 药物的致死率越高。该数据集用来预测其急性毒性。

### (3) 数据集划分

骨架划分法<sup>[11]</sup> 旨在测试模型对分布外 (**Out-of-Distribution**, OOD) 数据的泛化能力, 这在分子性质预测领域尤为关键, 因为实际应用中训练和测试数据的分子分布可能存在显著差异。由于不同来源的数据集通常覆盖了化学空间中结构各异的化合物, 这些化合物展现出显著的结构多样性。通过骨架划分, 可以确保训练集、验证集和测试集中的分子在骨架结构上保持不同, 从而提供了一种模拟化学空间分布变化的有效方法。这种划分策略不仅消除了随机划分时可能的偏差, 确保了每一次划分结果的稳定性和一致性, 而且更加公正地考察了模型的泛化能力, 尤其是在处理结构异质性高的未见分子时的性能表现。图3-3展示了 BACE 数据集在随机划分和骨架划分下的数据分布, 其中红色表示训练集, 蓝色表示测试集。从图中可以看出, 随机划分后的训练集和测试集分布类似, 而骨架划分的训练和测试集分布几乎没有重叠。

(a) 随机划分



(b) 骨架划分




图 3-3 随机划分和骨架划分<sup>2</sup>

因此, 为了更可靠的评估 MolIG 预测现实世界分子性质的能力, MoleculeNet 基准组中的数据集均严格按照骨架划分对训练集、验证集、测试集进行 8:1:1 的划分; 为确保 MolIG 方法在 ADMET 基准组上性能评估的公正性, 本章遵循 ADMET 官方提供的数据集分割标准, 将数据划分为训练集、验证集和测试集三部分进行模型的训练和评估。

<sup>2</sup><https://www.oloren.ai/blog/scaff-split>

### 3.3.3 实验环境配置

本文所有实验均使用统一的硬件环境配置，操作系统为 Centos 7.9.2009；GPU 为 NVIDIA GeForce RTX 3090，显存容量为 24GB；CPU 为 Intel Xeon(R) Gold 5218R CPU @ 2.10GHz，内容容量为 192GB；程序代码使用 Python 语言编码，相关软件包配置如表3.4所示。

表 3.4 关键软件配置信息

| 名称 | Python | CUDA | Torch       | PyG   | RDKit    | Numpy  |
|----|--------|------|-------------|-------|----------|--------|
| 版本 | 3.7.16 | 11.4 | 1.9.1+cu111 | 1.7.1 | 2022.3.4 | 1.21.6 |

### 3.3.4 实验评价指标

如本章3.1节所述，对于分类任务，MolIG 的目标是预测其具有性质  $p$  的概率，本文引入受试者工作特征曲线下面积大小 (ROC-AUC)、Precision-Recall 曲线下的面积大小 (PR-AUC) 作为评价指标；对于回归任务，MolIG 的目标是性质  $p$  的具体数值，本文引入平均绝对误差 (MAE) 和 Spearman 作为评价指标。

分类任务最终输出是预测概率，当模型预测的概率大于阈值（例如 0.5）时，则其被预测为正例。混淆矩阵 (Confusion Matrix) 是一种评估分类模型性能的表格，其中包含四个重要的指标：真正例 (True Positive, TP)，假正例 (False Positive, FP)，假负例 (False Negative, FN)，和真负例 (True Negative, TN)。

真正例 (True Positive, TP)：表示模型正确地将正类别样本预测为正类别。例如，模型预测某种药物具有抗癌活性，而实际上它确实对癌症有治疗效果。

假正例 (False Positive, FP)：表示模型错误地将负类别样本预测为正类别。例如，模型预测某种分子具有抗癌活性，但实际上在实验中并没有表现出对癌症的治疗效果。

假负例 (False Negative, FN)：表示模型错误地将正类别样本预测为负类别。例如，模型未能识别某种潜在的药物，实际上这种药物具有抗癌活性。

真负例 (True Negative, TN)：表示模型正确地将负类别样本预测为负类别。例如，模型正确地预测某种非活性分子确实不具有抗癌活性。

精确率 Precision 衡量的是模型在预测为正类别的样本中，有多少是真正的正类别。计算方法如公式(3.15)所示：

$$Precision = \frac{TP}{TP + FP} \quad (3.15)$$

真正例率 (TPR) 又称召回率 (Recall), 衡量的是模型在所有实际正例中, 有多少被成功地预测为正类别。计算方法如公式(3.16)所示:

$$TPR = \frac{TP}{TP + FN} \quad (3.16)$$

假正例率 (FPR), FPR 表示在所有实际负例中, 模型错误地将其预测为正例的比例。计算方法如公式(3.17)所示:

$$FPR = \frac{FP}{FP + TN} \quad (3.17)$$

ROC-AUC 是以真正例率为纵轴, 假正例率为横轴的曲线。该曲线绘制了在不同阈值下模型的表现, 展示了在牺牲特定类别的性能时, 模型能够达到的另一类别的性能水平。ROC 曲线下的面积即为 AUC, 表示模型在不同阈值下的整体性能。AUC 的取值范围在 0 到 1 之间, 越接近 1 表示模型性能越好。一个完全随机的分类器的 ROC-AUC 值为 0.5, 而一个完美的分类器的 ROC 曲线 AUC 值接近 1。

PR-AUC 是用于评估分类模型性能的指标, 特别适用于处理类别不平衡的情况。PR-AUC 是基于 Precision-Recall 曲线的, 而不是 ROC 曲线。Precision 和 Recall 分别是分类模型性能的两个关键指标, 前者衡量模型预测为正例的样本中有多少是真正例, 后者衡量模型成功预测为正例的样本占总的正例样本的比例。Precision-Recall 曲线以 Recall 为横轴, Precision 为纵轴, 显示在不同阈值下模型的表现。PR-AUC 是 Precision-Recall 曲线下的面积, 表示模型在不同阈值下的整体性能。与 ROC-AUC 不同, PR-AUC 更适用于类别不平衡的情况。

回归任务最终的输出是预测性质的具体数值, 平均绝对误差 (MAE) 衡量了模型预测值和真实值之间的平均绝对差异, 计算公式如(3.18)所示:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.18)$$

Spearman 相关系数是一种用于衡量两个变量之间的单调关系的统计指标。它是非参数的、基于秩次的方法, 因此不要求数据呈正态分布。Spearman 相关系数可以用于评估变量之间的单调性, 而不仅仅是线性关系。其值范围在 -1 到 1 之间, 其中: 1 表示完全的正相关 (正的单调关系); -1 表示完全的负相关 (负的单调关系); 0 表示无单调关系。

### 3.3.5 对比方法

本章将 MolIG 与其他分子性质预测模型进行比较, 以证明 MolIG 的有效性。基线模型的选取主要考虑到以下几个方面:



(1) 本章提出的预训练策略是否有效? 因此, 本章选取 GCN、GIN 和 Attentive FP 等自监督模型作为对比。

(2) 本章提出的多模态方法是否优于单一模态的方法? 因此本章选取基于 SMILES 的预训练方法 (MFBERT、BARTSmiles 等) 和基于图的预训练方法 (GraphCL、MolCLR 等) 作为对比。

(3) 本章提出的基于图和图像的方法是否优于其他多模态方法? 因此本章选取基于多模态的预训练方法 (GraphMVP、3DInfoMax 等) 作为对比。

基线模型具体描述信息如下所示:

GCN<sup>[47]</sup>: 图卷积神经网络 (GCN) 是一种图神经网络, 通过学习节点嵌入来捕捉图结构的局部信息, 基于节点的邻居关系实现有效的图表示学习。

GIN<sup>[40]</sup>: 图同构网络 (GIN) 是一种图神经网络, 通过将节点嵌入的特征进行可交换性处理, 使得模型对图同构性更加鲁棒, 适用于处理不同图之间的相似性学习。

Attentive FP<sup>[48]</sup>: 一种基于注意力机制的图神经网络。该算法结合注意力机制和分子指纹捕获原子和化学键之间的复杂相互作用。

MFBERT<sup>[49]</sup>: 一种基于 Transformer 的方法, 通过分布式计算进行化学指纹处理, 包括预训练和微调过程。

BARTSmiles<sup>[16]</sup>: 一种基于生成式掩码语言模型的自监督策略, 通过训练 BART 模型, 学习有效的分子表征。

GraphCL<sup>[22]</sup>: 一种基于图神经网络的对比学习方法, 通过最大化两种不同增强策略下图的互信息学习分子表征。

3DInfoMax<sup>[50]</sup>: 一种在隐空间中引入 3D 几何信息并最大化 2D 信息和 3D 信息一致性的对比学习方法。

GraphMVP<sup>[28]</sup>: 一种将分子 3D 几何信息合并到图自监督任务中的方法, 同时利用对比式任务和生成式任务学习分子表征。

CGIP<sup>[51]</sup>: 一种利用图和图像的表示学习方法, 通过对二者进行屏蔽操作进行对比学习学习图级表示。

GraphMAE<sup>[52]</sup>: 一种将掩蔽自编码器<sup>[53]</sup>应用于图上的生成方法, 通过重构节点特征学习有效信息。

GROVER<sup>[7]</sup>: 将 GNN 和 Transformer 结合, 通过上下文预测和 Motif 预测两个预训练任务学习分子表征。

MGSSL<sup>[54]</sup>: 一种通用的基于官能团的生成预训练模型, 通过对分子中的原子和常见官能团进行掩蔽并预测学习分子表示。

MolCLR<sup>[6]</sup>: 一种基于图神经网络和对比学习的分子表示学习算法, 通过设计三种不同的增强策略, 对分子图进行对比学习, 从而学习分子数据驱动的特征。

Mole-Bert<sup>[18]</sup>: 一种将原子编码转化为具有化学意义的离散编码并将掩蔽原子建模和对比学习结合起来的分子表示学习方法。

SimSGT<sup>[55]</sup>: 一种基于掩蔽图建模 (MGM) 的预训练方法, 利用简单 GNN 作为分词器, 通过重建子图的嵌入表示学习分子表征。

FG-BERT<sup>[56]</sup>: 一种基于 BERT 的自监督方法, 通过掩蔽具有化学语义的官能团学习具有领域知识的分子表征。

ADMET 基准组提供了一个官方性能排行榜, 旨在为其数据集上的模型性能提供标准化评估。除 MolCLR<sup>[6]</sup> 外, 本研究选取的所有对比模型均来自于该基准组的官方推荐列表。

### 3.3.6 对比实验

为了验证 MolIG 在分子性质预测领域的有效性, 本章在 MoleculeNet 基准组和 ADMET 基准组上将 MolIG 和各种分子性质预测方法进行对比。为了保证公平性, 实验中所有基线模型的数据划分方式均与 MolIG 一致。

在预训练阶段, 模型参数初始化采用 Xavier 初始化方法, 使用 Adam 优化器进行梯度更新。训练轮次为 50 轮, 批次大小为 512。分子图编码器的学习率为  $5e-4$ , 嵌入维度为 300, 采用 5 层结构网络, 池化方法为平均池化。分子图像编码器的学习率为  $1e-2$ 。权重衰退为  $1e-5$ , 对比学习的温度系数为 0.1。在微调阶段, 继承预训练模型参数, 使用 Adam 优化器进行梯度更新, 训练轮次为 50 轮, 批次大小为 32, 学习率为  $5e-4$ , 权重衰退为  $1e-6$ 。

(1) MolIG 在 MoleculeNet 基准组上的七个基准数据集的结果如表 3.5 所示。表中汇报了 MolIG 和对比基线模型在不同数据集下的平均性能和标准差。AVG 表示 7 个数据集的平均结果。**加粗**表示该数据为最优结果。

从表 3.5 中可以看出, MolIG 在五个数据集上取得最优, 包括 BBBP (ROC-AUC=73.4%), BACE (ROC-AUC=84.5%), SIDER (ROC-AUC=66.1%), HIV (ROC-AUC=79.8%), Clin-Tox (ROC-AUC=89.1%); 在 Tox21 (ROC-AUC=75.9%) 和 ToxCast (ROC-AUC=64.8%) 数据集上同样取得了不俗的性能; 同时所有数据集上的平均值取得最佳性能, 平均 ROC-AUC 为 76.2%。与其他基线模型相比, MolIG 平均提高了 5.4%。

与自监督模型 GCN、GIN 和 Attentive FP 相比, MolIG 平均提高 8.1%, 这体现了

表 3.5 MolIG 在 MoleculeNet 基准组上的对比实验结果

| 数据集          | BBBP             | BACE             | SIDER            | Tox21            | HIV              | ToxCast          | ClinTox          | AVG         |
|--------------|------------------|------------------|------------------|------------------|------------------|------------------|------------------|-------------|
| 分子数量         | 2,039            | 1,513            | 1,427            | 7,831            | 41,127           | 8,575            | 1,478            | -           |
| 任务数量         | 1                | 1                | 27               | 12               | 1                | 617              | 2                | -           |
| 划分方式         | 骨架划分             | 骨架划分             | 骨架划分             | 骨架划分             | 骨架划分             | 骨架划分             | 骨架划分             | -           |
| GCN          | 71.8(0.1)        | 71.6(2.0)        | 53.6(3.2)        | 70.9(2.6)        | 74.0(3.0)        | 60.1(1.3)        | 62.5(2.8)        | 66.3        |
| GIN          | 65.8(4.5)        | 70.1(5.4)        | 57.3(1.6)        | 74.0(0.8)        | 75.3(1.9)        | 62.2(1.9)        | 58.0(4.4)        | 66.1        |
| Attentive FP | 64.3(1.8)        | 78.4(0.1)        | 60.6(3.2)        | 76.1(0.5)        | 75.7(1.4)        | 63.7(0.2)        | 84.7(0.3)        | 71.9        |
| MFBERT       | 71.6(3.3)        | 71.6(4.4)        | 61.1(7.4)        | 63.9(4.8)        | 71.1(2.4)        | 63.7(8.3)        | 77.9(10.2)       | 68.7        |
| BARTSmiles   | 70.9(3.7)        | 83.2(3.3)        | 57.6(6.9)        | 65.1(5.0)        | 70.9(2.6)        | 64.9(8.6)        | 79.3(7.5)        | 70.3        |
| GraphCL      | 67.5(3.3)        | 68.7(7.8)        | 60.1(1.3)        | 74.4(0.7)        | 75.0(0.4)        | 63.0(0.4)        | 78.9(4.2)        | 69.6        |
| GraphMVP     | 68.5(0.2)        | 76.8(1.1)        | 62.3(1.6)        | 74.5(0.4)        | 74.8(1.4)        | 62.7(0.1)        | 79.0(2.5)        | 71.2        |
| 3DInfoMax    | 69.1(1.0)        | 79.4(1.9)        | 53.3(3.3)        | 74.5(0.7)        | 76.1(1.3)        | 63.5(0.8)        | 59.4(3.2)        | 67.9        |
| GROVER       | 68.0(1.5)        | 79.5(1.1)        | 60.7(0.5)        | 76.3(0.6)        | 77.8(1.4)        | 63.4(0.6)        | 76.9(1.9)        | 71.8        |
| MGSSL        | 69.7(0.9)        | 79.1(0.9)        | 61.8(0.8)        | 76.5(0.3)        | 78.8(1.2)        | 63.3(0.5)        | 80.7(2.1)        | 72.8        |
| MolCLR       | 71.6(0.7)        | 81.9(1.5)        | 59.9(0.9)        | 75.0(0.4)        | 78.3(0.4)        | 64.7(0.1)        | 81.9(1.2)        | 73.3        |
| CGIP         | 68.5(0.3)        | 79.2(0.2)        | 60.7(0.2)        | 73.9(0.1)        | 78.0(0.8)        | 64.3(0.6)        | 73.1(0.1)        | 71.1        |
| Mole-Bert    | 71.9(1.6)        | 80.8(1.4)        | 62.8(1.1)        | 76.8(0.5)        | 78.2(0.8)        | 64.3(0.2)        | 78.9(3.0)        | 73.3        |
| SimSGT       | 72.3(0.7)        | 83.6(0.8)        | 60.6(0.5)        | 75.7(0.5)        | 77.7(0.8)        | 64.1(0.4)        | 82.0(2.6)        | 73.7        |
| FG-BERT      | 70.2(0.9)        | 84.5(1.5)        | 64.0(0.7)        | <b>78.4(0.8)</b> | 77.4(1.0)        | <b>66.3(0.8)</b> | 83.2(1.6)        | 74.8        |
| MolIG        | <b>73.4(0.7)</b> | <b>84.5(0.2)</b> | <b>66.1(0.5)</b> | 75.9(0.1)        | <b>79.8(0.6)</b> | 64.8(0.1)        | <b>89.1(2.0)</b> | <b>76.2</b> |

MolIG 从大量无标签分子数据中挖掘和学习分子性质相关知识的强大能力，并迁移到下游任务数据集中。特别是在 ClinTox 数据集上，提升了近 40%，这表明 MolIG 还能够深入理解与毒性相关的复杂化学性质和生物活性。同时，MolIG 相比自监督模型有着更低的标准差，这表明在面对分布外泛化的数据分布时，即使在未见过的分子数据上，MolIG 仍然具有较好的稳定性和泛化能力。与仅基于 SMILES 的方法如 MFBERT 和 BARTSmiles 相比，MolIG 提升了 6.7%。SMILES 表示本质上缺乏对空间化学结构信息以及原子和化学键之间复杂拓扑关系的表达。因此，在处理更复杂的化学问题时，往往需要依赖大量的数据和更加复杂的模型。

与仅基于分子图的方法如 GraphCL、GraphMAE、MolCLR、Mole-Bert 等相比，MolIG 的性能相比有 3.5% 的增长。单一依靠分子图结构来表征分子的方法更关注分子内部原子和化学键之间的连接，而忽略了分子的空间结构和全局上下文信息。此外，这类方法不可避免的对分子图进行掩蔽操作，如果掩蔽的是分子中非常重要的部分，如活性位点或关键的官能团，模型可能无法正确学习到这些结构对分子功能的贡献。特别是对于一些活性悬崖分子数据，掩蔽操作并不是一个合适的选择。

与使用分子 3D 几何信息的多模态表示学习方法如 3DInfoMax、GraphMVP 相比，MolIG 同样表现出更强的竞争力，性能提升 6.7% 了。这些三维信息旨在帮助捕获分子空间结构的细节，从而提高模型对分子性质预测的准确性。然而分子 3D 结构的信息通常依赖 DFT 等量子化学计算手段<sup>[33]</sup>，这种昂贵的计算成本导致利用分子 3D 结构进行大规模预训练的方法并不现实。而分子图像依然能提供原子之间的相对位置、键长、键角等关键信息，这使得 MolIG 可以在较低计算资源的条件下在大规模分子数据上进行预训练，说明了图像模态在分子性质预测领域的高可用性。MolIG 所展示的卓越性能可以归因于预训练模型在整合分子图像和图结构信息方面的有效性。这两种模态的信息共同为分子性质预测提供了丰富的上下文信息，从而提高预测的精度。

(2) 表3.6展示了 MolIG 在 21 个任务上的具体性能，**加粗**表示该数据为最优结果，下划线表示该数据为次优结果。

从表3.6中可以看出，与基线模型相比，MolIG 在其中 17 个数据集上取得最佳的分子预测性能，在 4 个数据集上取得次优性能。且 MolIG 在所有回归任务上取得最优结果。值得注意的是在 VDss 数据集中，和最佳基准模型相比较，MolIG 性能提升了近 17%，在 CYP2D6 substrate 数据集中实现了近 9% 的性能提升。在 CYP2D6 inhibition、CYP3A4 inhibition 和 CYP2C9 inhibition 等预测任务中，MolIG 方法展现了稳定且较高的 PR-AUC 值，说明 MolIG 在处理不平衡数据集方面表现优异，能够有效识别少数类样本。这一结果表明，MolIG 对生物体内更复杂的性质预测下游任务具有显著的优势。MolIG 在

ADMET 基准组上的出色表现证明了多模态预训练方法在分子性质预测领域的有效性。

表 3.6 MolIG 在 ADMET 基准组上的实验结果

| 数据集                  | 评价指标     | GCN          | AttentiveFP  | MolCLR       | MolIG        |
|----------------------|----------|--------------|--------------|--------------|--------------|
| Caco2                | MAE      | 0.599        | 0.401        | <u>0.434</u> | <b>0.341</b> |
| Lipophilicity        | MAE      | 0.541        | 0.572        | <u>0.496</u> | <b>0.461</b> |
| Solubility           | MAE      | 0.907        | 0.776        | <u>0.776</u> | <b>0.753</b> |
| PPBR                 | MAE      | 10.194       | 9.373        | <u>9.196</u> | <b>8.499</b> |
| LD50                 | MAE      | 0.649        | 0.678        | <u>0.435</u> | <b>0.428</b> |
| HIA                  | ROC-AUC  | 0.936        | <b>0.974</b> | 0.956        | <u>0.966</u> |
| Pgp                  | ROC-AUC  | <u>0.895</u> | 0.892        | 0.861        | <b>0.921</b> |
| Bioavailability      | ROC-AUC  | 0.566        | 0.632        | <b>0.738</b> | <u>0.725</u> |
| CYP3A4 substrate     | ROC-AUC  | <u>0.590</u> | 0.576        | 0.543        | <b>0.655</b> |
| hERG                 | ROC-AUC  | 0.738        | <u>0.825</u> | 0.821        | <b>0.831</b> |
| Ames                 | ROC-AUC  | 0.818        | 0.814        | <b>0.887</b> | <u>0.883</u> |
| DILI                 | ROC-AUC  | 0.856        | <u>0.886</u> | 0.871        | <b>0.921</b> |
| CYP2D6 inhibition    | PR-AUC   | 0.616        | 0.646        | <u>0.686</u> | <b>0.693</b> |
| CYP3A4 inhibition    | PR-AUC   | 0.840        | <b>0.851</b> | 0.840        | <u>0.841</u> |
| CYP2C9 inhibition    | PR-AUC   | 0.735        | 0.749        | <u>0.781</u> | <b>0.802</b> |
| CYP2D6 substrate     | PR-AUC   | <u>0.617</u> | 0.547        | 0.486        | <b>0.702</b> |
| CYP2C9 substrate     | PR-AUC   | 0.344        | <u>0.375</u> | 0.353        | <b>0.400</b> |
| Half life            | Spearman | <u>0.239</u> | 0.085        | 0.133        | <b>0.357</b> |
| VDss                 | Spearman | 0.457        | 0.241        | <u>0.547</u> | <b>0.717</b> |
| Clearance microsome  | Spearman | <u>0.532</u> | 0.365        | 0.525        | <b>0.561</b> |
| Clearance hepatocyte | Spearman | 0.366        | 0.289        | <u>0.386</u> | <b>0.387</b> |

### 3.3.7 消融实验

在本节中，通过消融实验来评价预训练策略和数据增强策略对模型性能的影响。具体来说，实验设计包括以下变体：

(1) 未应用预训练策略的模型（标记为 w/o Pretrain，以粉色条展示），表示直接在图神经网络上进行有监督学习而不采用预训练；

(2) 未采用图像增强策略的模型（标记为 w/o Img Aug，以蓝色条展示），表示在预训练阶段没有执行任何图像增强操作。

(3) 对比模型 MolIG（表示为灰色条）包括完整的预训练和数据增强流程。

本节在 MoleculeNet 基准数据集上对这些变体架构进行实验，实验结果如图3-4所示。从结果可以看出，MolIG 方法在所有测试数据集上均实现了最优性能，而 w/o Img Aug 变体获得了次优结果，w/o Pretrain 变体在所有情况下性能最差，相对于没有预训练的模型，MolIG 实现了平均 5.9% 的性能提升，这表明 MolIG 方法的预训练策略可以从大量无标签分子数据中挖掘和学习分子性质相关知识的强大能力，并迁移到下游任务数据集中。此外，MolIG 与 w/o Img Aug 变体相比，在所有数据集上平均提升了 0.7%，这表明在面对分布外泛化的数据集，数据增强策略可以进一步提升模型的鲁棒性和泛化能力。值得注意的是，本章在下游任务仅采用分子图模态和分子图编码器，而没有使用图像模态；这是因为图和图像模态在对比学习过程中，其嵌入表示趋于一致。因此，使用两种模态的信息无法再下游任务上展现出显著的性能提升，且图像编码器参数数量较大，因此其运行时间也较长。




图 3-4 MolIG 在 MoleculeNet 基准组上消融实验结果

综上所述，本节的实验结果充分展示了所提出的预训练策略和图像增强策略在提升模型预测性能方面的有效性，进一步强调了这些方法在化学信息学和分子性质预测领域



的应用价值。

### 3.3.8 参数敏感度实验

为探究 MolIG 方法中的重要参数对于下游任务数据集性能的影响, 本节进行超参数实验。温度系数在对比学习框架中起着至关重要的作用, 它调节了模型对正样本与负样本之间相似度得分的敏感度。本节分别测试了三种不同的温度系数值, 分别是 0.05、0.1 和 0.5, 并在 MoleculeNet 基准组上进行了评估。不同温度系数下不同数据集的实验结果如图3-5所示, 平均结果如表3.7所示。




图 3-5 MolIG 在 MoleculeNet 基准组上参数实验结果

从表3.7中可以看出, 设置温度系数为 0.1 时, MolIG 方法在下游任务的平均值上达到了最优性能, 这表明一个适中的温度系数可以有效协助模型区分正负样本, 从而在性质预测任务上展示出更好的性能。反之, 当温度系数减小到 0.05 时, 方法性能相对于温度系数为 0.1 时下降了 2%, 这可能是由于分子图像的稀疏性问题, 导致模型倾向于将图像模态的冗余信息过度传递给分子图编码器。此外, 温度系数设定为 0.5 时, 模型展现出了较快的收敛速度, 但同时对比损失的优化变得更加困难, 这表明过高的温度系数减弱了模型区分正负样本的能力, 进而阻碍了有意义的表示学习, 导致在所有探索的温度系数设置中性能最弱。

综上所述, 选择恰当的温度系数对于 MolIG 方法的优化至关重要。适当的温度系数设置能够平衡模型对正负样本的判别力, 进而促进更有效的学习和更好的下游任务性能。



表 3.7 MolIG 不同温度系数下在 MoleculeNet 基准组上的平均值

| 温度系数 $\tau$    | 0.05 | 0.1  | 0.5  |
|----------------|------|------|------|
| 平均 ROC-AUC (%) | 74.2 | 76.2 | 73.4 |

### 3.3.9 分子相似度查询

为进一步探讨 MolIG 方法的表征能力，本研究在分子相似性搜索领域对其性能进行了评估。实验设计中，首先从 PubChem 数据库随机选取了 100,000 个分子作为查询集合，对于查询分子，利用 MolIG 获得其分子表征，并进一步计算其与数据库中其余分子表征的余弦相似度。




图 3-6 分子相似度查询

基于所计算的相似性得分，实验结果展示了与查询分子相似度最高的几个分子实例，并通过图3-6呈现。例如，针对查询分子 a，该分子结构特征由若干苯环构成，MolIG 成功检索到了结构上具有相似苯环排列和中心氮原子的分子。这一结果验证了 MolIG 在捕获原子级别结构信息方面的有效性。对于查询分子 b，MolIG 准确识别了其关键官

能团  $\text{O}=\text{S}=\text{O}$ ，显示了模型对分子官能团的识别能力。在分子 c 的查询实验中，MolIG 检索到的分子普遍含有卤素元素，如氟或氯，并共有毒性特性，表明 MolIG 能从分子性质的角度进行有效理解。综上所述，这些实验结果表明，MolIG 不仅能够精确捕捉分子的结构细节，而且能够理解更高阶的分子语义信息，如官能团的特征及分子的潜在属性。

### 3.4 本章小结

本章提出了一种多模态分子预训练方法 MolIG，其通过在预训练阶段引入分子图模态和分子图像模态，在保证分子图像语义信息完整的条件下，对其进行三种增强操作，并通过最大化二者表征的一致性来学习分子表征。在 MoleculeNet 基准组和 ADMET 基准组等药物发现任务上的实验证明了 MolIG 优于目前最先进的基线模型，表明 MolIG 不仅可以提取分子的结构特征，还能够捕获到更高阶的语义信息并迁移到分子性质预测的生物学相关任务。消融实验证明了预训练策略和图像增强策略的有效性；分子相似度查询实验进一步证明了 MolIG 可以深刻的理解化学语义信息。

## 第四章 大模型赋能的多层级分子表示学习方法

第三章提出的基于图和图像的多模态分子表示学习方法 MolIG 通过最大化不同模态下分子的一致性学习到具有高阶语义信息的表示，并将其应用于分子性质预测任务上。尽管 MolIG 在这些任务上表现出色，但是也存在一些潜在的问题和挑战。一方面，真实场景下的药物分子在人体内的反应错综复杂，难以捕捉到其在不同环境和条件下的动态变化，因此仅通过分子结构去预测性质的方法具有一定的局限性。另一方面，不同模态下的数据具有不同的表征形式，有效地整合这些信息并学习到高效的共同表示是一个复杂的问题，模态融合的方式和策略对于 MolIG 整体性能的影响需要进一步的研究和优化。

为了有效解决上述问题，本章提出大语言模型赋能的多层级分子表示学习方法 (Multi-Level Molecular Representation Learning Empowered by LLM, Mol-LLM)，该方法与第三章的 MolIG 方法是递进关系。在分子科学领域，专业领域知识涵盖了极为丰富的化学信息，包括原子之间的关联、特定的化学键类型、子结构性质等，这些专业知识可以提供分子更具体的信息，但是先前的工作较少使用专家知识引导模型。另一方面，分子文本描述可以更全面的表示分子，其涵盖了包括基本原子、复杂集合和相互作用等更丰富的信息，然而分子描述信息通常难以获取，因此也鲜有工作利用这种信息进行性质预测。本研究利用 MACCS 分子指纹<sup>[25]</sup>作为专家知识，用以提取包含化学意义的子结构信息。通过双线性注意力网络<sup>[57]</sup>，将这些领域知识与 MolIG 学到的原子级别表征进行多层的特征融合，以克服数据驱动表征和专家知识表征之间的局限性。此外，本研究还利用大语言模型获取分子描述信息作为补充，融合已有表征得到更加全面和丰富的分子表示，并应用于性质预测任务中。

本章4.1节将介绍 Mol-LLM 方法的整体框架、各个子模块及其算法伪代码；4.2节将对 Mol-LLM 方法的性能进行系统评估，通过多种实验证明 Mol-LLM 的有效性；4.3节将对本章工作进行总结。

### 4.1 方法

相比于第三章的 MolIG 方法，本章提出的多层级分子表示学习方法 Mol-LLM 通过整合专业领域知识和大语言模型生成的分子描述信息，致力于提高分子表示的表达能力

和泛化性。Mol-LLM 方法的框架如图4-1所示。该方法由四个模块构成：

(1) 数据驱动的原子级别表征模块：本模块与第三章3.2节提出的方法一致，使用预训练模型 MolIG 提取分子原子级别的表征，因此本章将不再对该内容进行介绍。

(2) 专家知识驱动的子结构级别表征模块：本模块引入 MACCS 分子指纹作为专家知识，提取有关化学子结构的信息，并计算其相互作用以得到子结构级别分子表征。

(3) 双线性注意力融合模块：本模块引入双线性注意力网络融合不同层级的分子信息。其采用注意力机制，根据数据驱动的原子级别表征和专家知识驱动的子结构级别表征动态地调整其贡献，使得二者更好的融合。

(4) 大语言模型赋能模块：为充分发挥大语言模型的生成能力，本模块精心设计 prompt 指导大语言模型针对性地生成与分子相关的详细描述信息，如分子的基本信息、可能的生物活性和安全性等，并融合已有表征得到更加全面和丰富的分子表示。




图 4-1 Mol-LLM 方法架构图

#### 4.1.1 专家知识驱动的子结构级别表征模块

本章引入 MACCS<sup>[25]</sup> 分子指纹作为专家知识，MACCS 一种二进制编码的分子表示方法，用于描述分子的子结构和特征。其主要关注分子中特定子结构的存在或缺失，而对这些子结构的拓扑位置并不关心。MACCS 分子指纹使用了 166 个预定义的结构片段，这些片段代表不同的化学官能团、环结构、原子类型等。在药物发现、定量构效关系 (QSAR) 研究、以及药物的 ADMET (吸收、分布、代谢、排泄和毒性) 性质预测等领域，MACCS 分子指纹已被广泛应用。因其能够有效捕获分子的化学多样性，为后续的化学和生物学性质分析提供基础。图4-2展示了

MACCS 分子指纹的可视化示例。




图 4-2 MACCS 分子指纹

为提取 MACCS 分子指纹提供的子结构特征以及捕获不同子结构之间的相互作用关系,本章使用子结构 Transformer 编码器<sup>[2]</sup> (**S**ub**s**tructures **T**ransformer **E**ncoder, SubTE) 对其编码, SubTE 模型架构如图4-3所示。




图 4-3 SubTE 模型架构图

对于 SubTE, MACCS 经过子结构编码和位置编码得到其嵌入表示  $M_s \in \mathbb{R}^{n \times d}$ , 并输入到多头注意力计算模块中, 计算该模块的  $Q$ 、 $K$ 、 $V$ , 计算公式如(4.1)-(4.4)所示:

$$M_s = \text{SubstructuresEmb}(\text{MACCS}) + \text{PositionEmb}(\text{MACCS}) \quad (4.1)$$

$$Q_s = M_s W_Q, \quad (4.2)$$

$$K_s = M_s W_K, \quad (4.3)$$

$$V_s = M_s W_V \quad (4.4)$$

其中, SubstructuresEmb 和 PositionEmb 分别表示子结构编码和位置编码,  $\mathbf{Q}_s$ 、 $\mathbf{K}_s$ 、 $\mathbf{V}_s \in \mathbb{R}^{d \times d}$  分别表示查询、键、值,  $\mathbf{W}_Q$ 、 $\mathbf{W}_K$ 、 $\mathbf{W}_V \in \mathbb{R}^{d \times d}$  是用于计算的投影矩阵, 将  $\mathbf{Q}_s$ 、 $\mathbf{K}_s$  和  $\mathbf{V}_s$  分别投影到不同的表征空间。不同子结构的自注意力模块计算公式如(4.5)所示:

$$\text{Substructures Attention} = \text{softmax}\left(\frac{\mathbf{Q}_s \mathbf{K}_s^T}{\sqrt{d_k}}\right) \mathbf{V}_s \quad (4.5)$$

自注意力模块致力于捕获不同子结构之间的相互作用, 不同的注意力头可以从不同的角度理解子结构, 丰富其特征表示。多头注意力计算公式如(4.6)和(4.7)所示:

$$\text{head}_i = \text{Attention}(\mathbf{Q}_s^i, \mathbf{K}_s^i, \mathbf{V}_s^i) \quad (4.6)$$

$$\mathbf{h}_{\text{multi}} = \text{Multi-Head}(\mathbf{Q}_s, \mathbf{K}_s, \mathbf{V}_s) = \text{Concat}(\text{head}_1 \dots \text{head}_h) \mathbf{W}^m \quad (4.7)$$

从不同的注意力头中提取不同的特征信息, 然后将其拼接在一起, 并使用  $\mathbf{W}^m$  投影到与原始特征相同的维度。Add 和 Norm 分别表示残差连接和归一化, FFN 为前馈神经网络, 用以输出具有专家知识的分子表征:

$$\mathbf{h}'_s = \text{Norm}(\mathbf{M}_s + \mathbf{h}_{\text{multi}}) \quad (4.8)$$

$$\mathbf{h}_s = \text{Norm}\left(\text{FFN}(\mathbf{h}'_s) + \mathbf{h}'_s\right) \quad (4.9)$$

以上公式可以被形式化为(4.10):

$$\mathbf{h}_s = \text{SubTE}(\text{MACCS}) \quad (4.10)$$

MACCS 指纹包含了分子中的子结构信息, 但传统的方法往往只考虑了子结构的存在与否, 而未考虑它们之间的相互作用。使用 SubTE 编码 MACCS 指纹可以同时考虑不同子结构之间的相互作用, 从而更全面地理解分子的结构特征, 补充了图神经网络的表达能力。

#### 4.1.2 双线性注意力融合模块

双线性注意力融合网络<sup>[57]</sup>最初设计用于解决视觉问答 (VQA) 问题, 该问题涉及到对图像内容和相关文本问题进行综合理解的多模态学习任务。在 VQA 场景中, 模型需要精确匹配图像内容与文本问题, 并据此生成正确的答案。类似地, 原子和子结构的匹配也是一个多模态问题, 它涉及到分子原子的理解及其与不同子结构的关系解析。双线性注意力网络通过构建双线性注意力图来优化多模态数据之间的交互学习。该方法允许模型细致地分析每一对多模态输入通道 (例如, 分子中的原子与分子中的子结构),




图 4-4 双线性注意力融合网络架构图

以学习它们之间的细粒度交互表示。相对于传统单一注意力机制，双线性注意力网络能够更深层次地挖掘和融合多模态信息，同时确保计算效率。鉴于视觉问答和分子性质预测之间的这种潜在相似性，本研究借鉴了双线性注意力网络的核心思想，引入了一个成对交互模块以增强 MolIG。此模块旨在捕获数据驱动的 MolIG 方法中原子级别表征与专家知识驱动的 SubTE 方法中子结构级别表征之间的相互作用。如图4-4所示，该交互模块主要由两个部分组成：一个负责计算注意力权重的双线性注意力模块，以及一个用于整合多模态特征的双线性池化模块。

MolIG 和 SubTE 分别生成原子级别的分子表示  $H_m = \{h_0^m, h_1^m \dots h_{N-1}^m\}$  和子结构级别的分子表示  $H_s = \{h_0^s, h_1^s \dots h_{N-1}^s\}$ ， $N$  表示分子的数量。MolIG 的公式形式化为(4.11)。然后根据这些表示构建双线性交互映射从而产生单头的交互矩阵  $I \in \mathbb{R}^{N \times N}$ ，公式如(4.12)所示：

$$h_m = \text{MolIG}(G) \quad (4.11)$$

$$I = \left( (1 \cdot q^T) \circ \sigma((H_m)^T U) \cdot \sigma(V^T H_s) \right) \quad (4.12)$$

其中， $G$  为药物  $d$  的分子图， $U \in \mathbb{R}^{d_m \times K}$  和  $V \in \mathbb{R}^{d_s \times K}$  是 MolIG 表征和 SubTE 表征的可学习权重矩阵， $q \in \mathbb{R}^K$  是一个可学习的参数， $1 \in \mathbb{R}^M$  是固定的全 1 向量， $\circ$  是表示 Hadamard (element-wise) 乘积。双线性交互使用权重  $U$  和  $V$  将两种不同层级的表征映射到公共嵌入空间，并学习其相互作用。

为获得联合表示  $h_{fuse}$ ，本章在相互作用注意力图  $I$  上引入双线性池化层。具体来说， $f' \in \mathbb{R}^K$  的第  $k$  个元素计算公式如(4.13)所示：

$$f'_k = \sigma(H_m^T U)_k^T \cdot I \cdot \sigma(H_s^T V)_k^T = \sum_{i=1}^N \sum_{j=1}^N I_{i,j} (h_i^m)^T (U_k V_k^T) h_j^s \quad (4.13)$$

值得注意的是，这一层没有可学习的参数矩阵。权重矩阵  $U$  和  $V$  与交互阶段共享参数以减少过拟合。最后，在联合表示向量上使用求和和池化以获得更紧凑的特征图，SumPool



函数是步幅为  $s$  的一维非重叠求和池运算。池化公式(4.14)如下所示：

$$\mathbf{h}_{fuse} = \text{SumPooling}(\mathbf{f}', s) \quad (4.14)$$

双线性注意力融合网络可以被形式化为公式(4.15)：

$$\mathbf{h}_{fuse} = \text{BAN}(\mathbf{h}_m, \mathbf{h}_s) \quad (4.15)$$

双线性注意力融合网络 BAN 用于捕捉输入分子中不同原子和子结构之间的关联性和交互模式，分子的性质不仅和其所包含的原子有关，也和其重要子结构尤其相关；因此，单独考虑原子级别表征和子结构级别表征往往会限制建模能力和预测能力，BAN 可以充分考虑两种级别下的分子表征，通过联合建模的方法丰富分子信息。

#### 4.1.3 大语言模型赋能的分子描述信息表征模块

##### (1) 分子描述信息

分子描述信息是对分子结构、性质或其他相关信息进行文本化描述的数据形式，这种信息可以提供有关分子的详细特征，涵盖从基本的原子、化学键信息到更高级别的结构和相互作用的内容，然而利用分子描述信息作为辅助信息帮助模型进行预测比较困难。因为这些专业信息通常分散在大量化学文献中，如科学期刊文章、专利、实验报告。因此需要广泛查阅文献，这一过程十分耗时且需要专业领域知识。此外，不同文献中的分子信息可能采用不同的描述方法，使得数据的标准化和整合问题变得非常困难。特别的，对于实验室合成的全新分子，在文献中并没有其相关信息，这将导致分子描述信息无法利用。因此，要获得全面、准确的分子描述信息，研究者需要克服一系列困难，这使得获取分子描述信息成为科学研究中的一项具有挑战性的任务。

##### (2) 大语言模型 (LLM) 和语言模型 (LM)

大语言模型 (LLM) 和传统语言模型 (LM) 都是自然语言处理 (NLP) 领域的关键技术，用于理解和生成文本。LM 如 BERT<sup>[58]</sup>、RoBERTa<sup>[10]</sup>、GPT<sup>[59]</sup> 等在自然语言处理任务上的成功应用引发了研究人员对分子领域的深入关注。LLM 如 ChatGPT<sup>1</sup>、QWen<sup>[60]</sup> 等，通常指的是具有极大数量参数（从数百亿到数千亿级别）的语言模型，其通过大规模的数据集和大量的计算资源进行训练，学习语言的深层结构和语义。

考虑到获取分子的详细描述信息往往充满挑战，而 LLM 又展现出卓越的推理和分析能力，一个自然的策略是利用 LLM 的高级推理功能来生成丰富的分子描述。随后可以使用传统的较小的 LM 对这些生成的描述信息进行编码。这种方法的优势在于它仅需

<sup>1</sup><https://chat.openai.com/>




图 4-5 DesBERTa 方法架构图

要通过 API 访问 LLM 即可执行，而无需对 LLM 本身进行微调，因此大大降低了对计算资源的需求。基于以上内容，本章提出分子描述信息表征方法（Molecular **Des**cription **RoBERTa**, DesBERTa）。具体来说，首先设计一个用于引导 LLM 生成分子描述信息的提示（prompt），随后利用 prompt 和 ChatGPT 为 SMILES 生成文本表示。在得到分子文本描述信息后，利用 RoBERTa 进一步提取其嵌入表示，本章使用 GPT-3.5 Turbo 版本作为 LLM 执行分子描述信息生成任务。图4-5展示了 DesBERTa 的方法架构。

### （3）prompt 设计

prompt 指的是输入到 LLM 中的文本，用于引导模型理解执行用户给定的任务。prompt 通常模仿自然语言的询问方式或以指令的形式，激活 LLM 中的相关知识，从而得到期望的输出，合适的 prompt 可以使得 LLM 生成高质量的内容。因此，为了获得高质量的分子描述信息，本节采用 “As a expert in the field of chemistry, you have the capability to generate important and valuable features about molecular SMILES. Please generate a description for the molecule with the SMILES code {SMILES}” 作为 prompt 引导 LLM，以生成分子最有价值的特征描述。图4-6展示了使用该 prompt 生成的分子描述信息，不难看出，分子描述信息不仅包含了最基本的 SMILES 表示，还包含了一些额外的信息，例如融合环系统、胺基团、羧酸基团等。特别的，该描述信息还指出了像环状尿素基团 (N=C(OCCC2)N)，这是许多药物中常见的药效团，可能会帮助一些生物活性预测的下游任务。

### （4）大语言模型的幻觉

虽然大模型可以提供丰富的分子描述信息，但是其非常容易出现幻觉<sup>[61]</sup>，即输入冲突幻觉、上下文冲突幻觉和与事实矛盾幻觉。输入冲突指的是 LLM 偏离用户的输入，例如其生成的描述信息和输入的目标分子无关。为了最大程度地减少大模型受输入冲突幻觉的影响，在获取分子描述信息后，本章将对比原始 SMILES 和文本中的 SMILES。



As a expert in the field of chemistry, you have the capability to generate important and valuable features about molecular SMILES. Please generate a description for the molecule with the SMILES code c12c3c(N4CCN(C)CC4)c(F)cc1c(c(C(O)=O)cn2C(C)CO3)=O

The given SMILES molecule c12c3c(N4CCN(C)CC4)c(F)cc1c(c(C(O)=O)cn2C(C)CO3)=O represents a complex organic compound with several important features.

1. The molecule has a fused ring system consisting of three rings, with two six-membered rings and one five-membered ring. The rings are numbered as 1, 2, and 3.
2. The molecule contains a nitrogen atom (N) at position 4 of the second ring, which is connected to a cyclic amine group (CCN(C)CC) and a fluorine atom (F) at position 6 of the first ring.
3. The first ring also contains a carboxylic acid group (C(O)=O) at position 5, which is connected to a nitrogen-containing heterocycle (cn2C(C)CO3) at position 7 of the second ring.
4. The heterocycle contains a nitrogen atom (N) at position 1, which is connected to a cyclic ether group (C(C)CO) at position 4 of the third ring.
5. The molecule also contains a carbonyl group (=O) at position 8 of the first ring, which is connected to the aromatic system. Overall, the given SMILES molecule represents a complex organic compound with multiple functional groups and a fused ring system. The features described above can be used to identify and verify the structure of the molecule.



As a expert in the field of chemistry, you have the capability to generate important and valuable features about molecular SMILES. Please generate a description for the molecule with the SMILES code Clc1ccc(nc1)C(=O)Nc1cc(C2(N=C(OCCC2)N)C)c(F)cc1

The given SMILES molecule Clc1ccc(nc1)C(=O)Nc1cc(C2(N=C(OCCC2)N)C)c(F)cc1 represents a chemical compound with a complex structure. Here is a breakdown of the important and verifiable features of this molecule:

1. The molecule contains 26 atoms, including 9 carbon atoms, 2 nitrogen atoms, 1 oxygen atom, 1 chlorine atom, and 13 hydrogen atoms.
  2. The molecule has a ring structure, with a six-membered ring containing both nitrogen and carbon atoms.
  3. The molecule contains a carbonyl group (C=O) and an amide group (C(=O)N) which are important functional groups in organic chemistry.
  4. The molecule contains a substituted pyridine ring, which is a common heterocyclic ring system found in many organic compounds.
  5. The molecule contains a fluorine atom and a chlorine atom, which are both halogens and can have important effects on the reactivity and properties of the molecule.
  6. The molecule contains a cyclic urea group (N=C(OCCC2)N), which is a common pharmacophore in many drugs and can have important biological activity.
- Overall, the given SMILES molecule represents a complex and potentially biologically active compound with a diverse array of functional groups and structural features.



图 4-6 ChatGPT 生成的分子描述信息

如果两者不匹配，则重新将该分子的 SMILES 输入大模型，以生成相应的文本描述。上下文冲突指的是 LLM 在生成冗长或多轮响应时可能会表现出自相矛盾，由于本章使用调用 API 的方式生成描述信息，因此此类幻觉并不会出现在本方法中。与事实矛盾幻觉指的是 LLM 生成的信息与真实世界的信息或文本相悖，对于这种情况，当前很难有较好的解决办法。先前的一些工作<sup>[62]</sup>证明，在输入的文字中要求模型扮演某个身份，可以有效地提升模型在对应领域的表现。本章尝试使用“角色扮演”尽可能的激发大模型的领域知识，因此本章采用“As a expert in the field of chemistry”作为角色扮演引导 prompt，以减少事实矛盾幻觉带来的影响。

#### (4) DesBERTa 框架

本章利用在大型自然语言文本语料库（BOOKCORPUS、CC-NEWS、OPENWEBTEXT 和 STORIES）<sup>[10]</sup>上预训练 RoBERTa 模型来提取分子描述信息表征。对于 DesBERTa 的输入，遵循 RoBERTa 的协议，对其进行 Token Embedding、Position Embedding 和 Segment Embedding 等标记化，然后通过预训练的 RoBERTa 编码器。随后，将编码器表征的第一个 [CLS] Token 作为最终的本章表征用以预测分子性质。DesBERTa 方法

的公式如(4.16)所示:

$$\mathbf{h}_{des} = \text{DesBERTa}(\text{LLM}(\text{SMILES}, \text{prompt})) \quad (4.16)$$

将分子描述信息表征  $\mathbf{h}_{des}$  与公式(4.15)得到的融合表征  $\mathbf{h}_{fuse}$  相加得到分子最终表示  $\mathbf{h}_d$ , 最后将其转发到同公式(3.12)中性质预测器中预测最终性质, 公式如(4.17)和(4.18)所示:

$$\mathbf{h}_d = \mathbf{h}_{des} + \mathbf{h}_{fuse} \quad (4.17)$$

$$\hat{y}_{p,d} = \text{PropertyPredictor}(\mathbf{h}_d) \quad (4.18)$$

#### 4.1.4 算法伪代码

Mol-LLM 方法的伪代码如算法4.1所示。首先第一行加载 MolIG 和 DesBERTa 的预训练参数, 4-5 行利用 SubTE 提取分子子结构级别表征; 6-7 行利用 MolIG 提取分子原子级别表征; 8-9 行利用双线性注意力网络融合分子原子级别表征和子结构级别表征; 10-12 行利用 DesBERTa 提取分子描述信息表征并融入现有特征中; 13-15 行为分子性质预测, 并通过反向传播更新参数。

---

#### 算法 4.1 大模型赋能的多层级分子表示学习方法 Mol-LLM

---

**输入:** 分子图  $G$ ; MACCS 指纹; 分子描述信息 Des; 训练批次数  $B$ 、训练迭代轮次  $E$ ;

MolIG 预训练参数  $\theta$ , DesBERTa 预训练参数  $\phi$

**输出:** 分子具有性质  $p$  的概率或该性质的具体数值  $\hat{y}_{p,d}$

- 1: 加载 MolIG 预训练参数  $\theta$ , 加载 DesBERTa 预训练参数  $\phi$
- 2: **for** epoch = 0; epoch <  $E$  **do**
- 3:     **for** batch = 0; batch <  $B$  **do**
- 4:         **子结构级别表征计算:**
- 5:             根据公式(4.10)获取子结构级别表征  $\mathbf{h}_s \leftarrow \text{SubTE}(\text{MACCS})$
- 6:         **原子级别表征计算:**
- 7:             根据公式(4.11)获取原子级别表征  $\mathbf{h}_m \leftarrow \text{MolIG}(G)$
- 8:         **双向线性注意力融合:**
- 9:             根据公式(4.15)捕获相互作用, 得到融合表征  $\mathbf{h}_{fuse} \leftarrow \text{BAN}(\mathbf{h}_m, \mathbf{h}_s)$
- 10:         **分子描述信息表征计算:**
- 11:             根据公式(4.16)获取分子表述信息表征  $\mathbf{h}_{des} \leftarrow \text{DesBERTa}(\text{Des})$
- 12:             根据公式(4.17)通过相加得到最终的分子表征  $\mathbf{h}_d \leftarrow \mathbf{h}_{fuse} + \mathbf{h}_{des}$
- 13:         **分子性质预测:**

---

```

14:         根据公式(4.18)计算分子性质  $\hat{y}_{p,d} \leftarrow \text{PropertyPredictor}(\mathbf{h}_d)$ 
15:         通过反向传播更新 Mol-LLM 方法参数
16:     end for
17: end for

```

---

## 4.2 实验及结果分析

为了验证 Mol-LLM 方法的有效性,本章首先将其在 MoleculeNet 基准组和 ADMET 基准组上进行实验,以证明其在分子性质预测方面的有效性。并讨论不同模块以及重要参数对下游任务的影响。最后,本节通过展示分子描述信息注意力可视化提供 Mol-LLM 的可解释性。

### 4.2.1 对比方法

在本节中,评估 Mol-LLM 所使用的数据集与表3.2和表3.3一致;为了验证 Mol-LLM 的有效性,基线模型的选取主要考虑到以下几个方面:

(1) 本章提出的方法是否优于其他基于专家知识的方法? 因此本章选取基于分子指纹作为专家知识的方法 (Morgan-FP、MOCO、GROVER 等) 作为对比。

(2) 本章提出的方法是否优于其他基于分子描述信息的方法? 因此本章选取基于分子自然语言文本的方法 (MoMu、MoleculeSTM、GIT-Mol 等) 作为对比。

(3) 本章提出的方法是否优于其他基于大语言模型的方法? 因此本章选取基于 LLM 的方法 (GAL30B、GAL120B 等) 作为对比。

(4) 此外,本章还将第三章中性能表现最好的方法 (FG-BERT、MolIG) 作为基线模型。

基线模型具体描述信息如下所示:

Morgan-FP<sup>[63]</sup>: 一种利用摩根分子指纹<sup>[64]</sup>的方法,使用 MLP 直接对该指纹进行特征提取。

MOCO<sup>[65]</sup>: 一种利用分子指纹,分子图,分子 3D 几何结构和 SMILES 进行联合对比学习的自监督预训练方法,通过最大化四种模态的一致性学习有意义的分子表示。

GROVER<sup>[7]</sup>: 将 GNN 和 Transformer 结合,通过上下文预测和 Motif 预测两个预训练任务学习分子表征,此外 GROVER 引入专家知识,其集成了 RDKit2D 描述符,涵盖了 200 个分子特征。

MoMu<sup>[66]</sup>: 一种分子多模态基础模型,将分子图与文献中分子的自然语言描述联系



起来, 通过对比学习从而实现跨模态转移和联合多模态建模。

MoMu2<sup>[67]</sup>: 一种基于神经文本检索策略的改进 MoMu 方法, 该策略通过每个文本片段与其描述的分子的相关性来选择正负样本。

KV-PLM<sup>[68]</sup>: 一种生物文本阅读方法, 在特定专业领域语料库进行预训练从而链接 SMILES 和生物学文本。

MoleculeSTM<sup>[31]</sup>: 一种多模态分子结构文本模型, 通过对化学结构和文本描述进行联合学习, 以实现基于文本的检索和编辑。

MolT5<sup>[69]</sup>: 一种自我监督学习框架, 用于在大量未标记的自然语言文本和 SMILES 上执行 MLM 预训练任务。

GAL30B<sup>[70]</sup> 和 GAL120B<sup>[70]</sup>: 一种可以存储、组合和推理科学知识的大型语言模型, 其使用大量论文、参考资料、知识库和许多其他来源的科学语料库进行训练。30B 和 120B 分别表示对应模型的参数量。

CLAMP<sup>[63]</sup>: 一种和 MoMu 在策略上类似的方法, 不同的是 CLAMP 是从 PubChem 数据库中收集分子描述信息, 而 MoMu 则是从 S2orc 数据库<sup>[71]</sup>中已发表的科学论文采集。

GIT-Mol<sup>[72]</sup>: 一种多模态大语言模型, 集成了分子图、图像、SMILES 和分子描述信息, 利用交叉注意力机制捕获不同模态之间的相互作用。

#### 4.2.2 对比实验

为了验证 Mol-LLM 在分子性质预测领域的有效性, 本节在 MoleculeNet 基准组和 ADMET 基准组上将 Mol-LLM 和各种分子性质预测方法进行对比。为了保证公平性, 实验中的数据集、实验环境、评价指标以及基线模型的数据划分方式均与第三章保持一致。

在训练过程中, MolIG 和 DesBERTa 模块采用从预训练得到的参数进行初始化, 其他模块使用 Xavier 作为初始化器初始化模型参数, 选用 Adam 优化器进行梯度更新。SubTE 层数为 1 层, 注意力头数为 8, token 数量为 166。MolIG、SubTE 和 BAN 的学习率统一设定为  $1e-4$ , DesBERTa 的学习率为  $1e-5$ , MolIG 的丢弃率为 0.2, SubTE 的丢弃率为 0.1, 最后一层预测器的丢弃率为 0.5, 批处理大小固定为 32, 训练轮次为 30, 早停轮次为 10。

(1) Mol-LLM 在 MoleculeNet 基准组上的七个基准数据集的结果如表 4.1 所示, 表中展示了 Mol-LLM 和其他基线模型在 MoleculeNet 基准组上的性能和标准差。其中, AVG

表示 7 个数据集的平均结果。**加粗**的数值代表该数据集上的最优结果，下划线 的数值则表示次优结果。

从表4.1中可以看出, Mol-LLM 在六个数据集上取得最优, 包括 BBBP (ROC-AUC=74.6%), BACE(ROC-AUC=84.5%), SIDER(ROC-AUC=67.5%), Tox21(ROC-AUC=79.9%), HIV (ROC-AUC=81.4%), ClinTox (ROC-AUC=97.8%); 在 ToxCast (ROC-AUC=67.1%) 数据集上取得次优, 同时所有数据集上的平均值取得整体最佳性能, 平均 ROC-AUC 为 78.8%。与其他基线模型相比, Mol-LLM 平均提高了 7.7%。值得注意的是, 在 ClinTox 数据集上, Mol-LLM 相比于 MolIG 在性能上提高了 8.7% 的同时, 标准差减少了 1.1%, 且所有数据集上的平均值提高了 2.6%, 展现了显著的性能提升, 同时稳定性也有所增强。

与使用专家知识的方法 (Morgan-FP、MOCO、GROVER) 相比, Mol-LLM 平均提高 7.6%。这些方法均使用分子指纹增强模型表达能力, 但是他们仅仅将分子指纹作为额外的特征计算其对最终结果的贡献程度, 而没有考虑分子指纹内部不同子结构之间的相互作用。本章提出的 SubTE 模块利用 Transformer 捕捉子结构之间的注意力使得每一个子结构表征充分考虑了当前分子中的上下文信息, 这种信息对于准确预测分子性质至关重要。与使用分子描述信息 (MoleculeSTM、MolT5) 和文本信息 (MoMu、MoMu2 等) 的方法相比, Mol-LLM 平均提高 8.3%。这些方法从 PubChem 或科学文献中收集大量的分子文本, 然而这些分子文本是通常针对特定领域进行设计, 因此其所包含的信息相对片面, 而本章使用精心设计的 prompt 帮助大模型生成全面和细致的描述信息用以解决文献和数据库中的文本信息不足的问题。此外, 分子固有的结构信息对于性质至关重要, 因此从表中不难看出, 仅依赖文本信息进行预测在性能层面仍然无法超过基于图的方法, 而 Mol-LLM 通过集成基于图和分子描述信息等多种层级的信息取得了当前研究最先进的性能。

与使用大语言模型 (GAL30B、GAL120B) 的方法相比, Mol-LLM 平均提高 9.42%。这两种方法均使用提示微调进行性质预测, 对应的输入为 prompt+SMILES。例如对于 BBBP 数据集, 其输入为“Here is a SMILES formula: [START\_I\_SMILES]O=C(O)CCCC1=CC=C(N(CCCl)CCCl)C=C1[END\_I\_SMILES].Question: Will the chemical compound penetrate the blood-brain barrier?”。这需要对每一个任务都精心设计 prompt, 且直接使用 LLM 进行微调对计算资源的要求很高。本章提出的方法不依赖 LLM 直接预测, 而是利用 LLM 强大的推理能力生成具有丰富特征的描述信息以帮助小模型取得更佳的性能。

(2) Mol-LLM 在 ADMET 基准组上的实验结果如表4.2所示。表中展示了 Mol-LLM 在 21 个任务上的具体性能, 其中**加粗**的数据表示在相应任务上的最佳性能, 而下划线



表 4.1 Mol-LLM 在 MoleculeNet 基准组上的对比实验结果

| 数据集         | BBBP      | BACE      | SIDER     | Tox21     | HIV       | ToxCast   | ClinTox   | AVG  |
|-------------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|------|
| 分子数量        | 2,039     | 1,513     | 1,427     | 7,831     | 41,127    | 8,575     | 1,478     | -    |
| 任务数量        | 1         | 1         | 27        | 12        | 1         | 617       | 2         | -    |
| 划分方式        | 骨架划分      | 骨架划分      | 骨架划分      | 骨架划分      | 骨架划分      | 骨架划分      | 骨架划分      | -    |
| Morgan-FP   | 66.0(3.8) | 80.9(3.5) | 59.0(8.0) | 59.1(8.9) | 71.3(2.7) | 64.6(4.9) | 74.9(9.5) | 67.9 |
| MOCO        | 71.6(1.0) | 82.6(0.3) | 61.2(0.6) | 76.7(0.4) | 78.3(0.4) | 64.9(0.8) | 81.6(3.7) | 73.8 |
| GROVER      | 68.0(1.5) | 79.5(1.1) | 60.7(0.5) | 76.3(0.6) | 77.8(1.4) | 63.4(0.6) | 76.9(1.9) | 71.8 |
| MoMu        | 70.5(2.0) | 76.7(2.1) | 60.5(0.9) | 75.6(0.3) | 75.9(0.8) | 63.4(0.5) | 79.9(4.1) | 71.7 |
| MoMu2       | 68.2(2.3) | 72.7(0.5) | 60.1(1.0) | 74.7(0.4) | -         | 63.7(0.5) | 62.2(1.6) | 66.9 |
| KV-PLM      | 70.5(0.5) | 78.5(2.7) | 59.8(0.6) | 72.1(1.0) | 65.4(1.6) | 55.0(1.7) | 89.1(2.7) | 70.0 |
| MoleculeSTM | 70.7(1.9) | 81.9(0.4) | 63.7(0.8) | 75.7(0.8) | 77.0(0.4) | 65.1(0.3) | 86.6(2.2) | 74.3 |
| MolT5-L     | 65.0(3.9) | 63.4(4.6) | 53.2(7.4) | 63.6(4.4) | 72.8(2.7) | 62.9(8.5) | 73.7(8.6) | 64.9 |
| GAL30B      | 59.6      | 72.7      | 61.3      | 68.5      | 75.9      | -         | 82.2      | 68.7 |
| GAL120B     | 66.1      | 61.7      | 63.2      | 68.9      | 74.5      | -         | 82.6      | 69.0 |
| CLAMP       | 68.2(3.8) | 84.2(3.4) | 65.1(7.5) | 78.2(4.2) | 76.3(2.4) | 74.0(7.7) | 75.3(7.8) | 74.5 |
| GIT-Mol     | 71.9(1.8) | 68.4(1.7) | 60.1(1.1) | 73.9(0.7) | -         | 62.1(0.4) | 83.5(3.1) | 70.0 |
| FG-BERT     | 70.2(0.9) | 84.5(1.5) | 64.0(0.7) | 78.4(0.8) | 77.4(1.0) | 66.3(0.8) | 83.2(1.6) | 74.8 |
| MolIG       | 73.4(0.7) | 84.5(0.2) | 66.1(0.5) | 75.9(0.1) | 79.8(0.6) | 64.8(0.1) | 89.1(2.0) | 76.2 |
| Mol-LLM     | 74.6(0.4) | 84.5(0.2) | 67.5(0.3) | 79.9(0.2) | 81.4(0.7) | 67.1(0.8) | 97.8(0.9) | 78.8 |

的数据则表示次优结果。

与基线模型相比, Mol-LLM 在其中 17 个数据集上取得最佳的分子预测性能。在具体任务上, 例如 HIA 评估中, Mol-LLM 展现出了非常卓越的性能, 其 ROC-AUC 值达到 0.988, 显著高于其他模型。这表明 Mol-LLM 在预测药物的肠道吸收能力方面的高准确性, 准确预测药物分子在人体内的吸收情况对于药物开发过程中早期阶段的筛选具有重要意义。在 DILI (药物引起的肝损伤) 评估任务中, Mol-LLM 以 0.931 的 ROC-AUC 值再次领先于其他模型, 这一结果表明 Mol-LLM 能够有效预测药物的潜在肝毒性。DILI 一旦发生, 通常会影​​响原发病的治疗, 严重者可导致急性肝衰竭, 危及生命。准确的预测 DILI 可为药物的安全性提供强有力的支持。此外, 在 Pgp 抑制任务中, Mol-LLM 以 0.937 的 ROC-AUC 值表现出色, 这反映了模型在识别药物与 Pgp 泵相互作用方面的有效性, 有助于理解药物在体内的分布和排泄过程。

Mol-LLM 的出色表现可以归因于其采用的多层级分子表示学习策略。通过整合 MACCS 分子指纹作为专家知识, Mol-LLM 能够深入理解分子结构的详细化学特性, 进而获得对分子的高层次语义理解, 这大大增强了其在分子性质预测任务上的准确度。此外, 结合大语言模型 (LLM) 的高级生成能力, Mol-LLM 能够更细致和全面地描绘分子特征, 覆盖从基础原子信息到复杂的结构集合信息等各个方面。这一优越性的体现不仅在平均性能上, 同时也体现在标准差上, 这意味着 Mol-LLM 对于不同数据集的稳健性更强。总体而言, Mol-LLM 的综合性能在多个分子性质预测任务中取得了显著的提​​升, 为该领域的研究和实际应用提供了有价值的探索。

表 4.2 Mol-LLM 在 ADMET 基准组上的对比实验结果

| 数据集           | 评价指标    | GCN    | AttentiveFP  | MolCLR       | MolIG        | Mol-LLM      |
|---------------|---------|--------|--------------|--------------|--------------|--------------|
| Caco2         | MAE     | 0.599  | 0.401        | 0.434        | <b>0.341</b> | <u>0.363</u> |
| Lipophilicity | MAE     | 0.541  | 0.572        | 0.496        | <u>0.461</u> | <b>0.460</b> |
| Solubility    | MAE     | 0.907  | 0.776        | <u>0.776</u> | <b>0.753</b> | 0.895        |
| PPBR          | MAE     | 10.194 | 9.373        | 9.196        | <u>8.499</u> | <b>8.367</b> |
| LD50          | MAE     | 0.649  | 0.678        | <u>0.435</u> | <b>0.428</b> | 0.598        |
| HIA           | ROC-AUC | 0.936  | <u>0.974</u> | 0.956        | 0.966        | <b>0.988</b> |

续表 4.2

| 数据集                  | 评价指标     | GCN   | AttentiveFP  | MolCLR       | MolIG        | Mol-LLM      |
|----------------------|----------|-------|--------------|--------------|--------------|--------------|
| Pgp                  | ROC-AUC  | 0.895 | 0.892        | 0.861        | <u>0.921</u> | <b>0.937</b> |
| Bioavailability      | ROC-AUC  | 0.566 | 0.632        | <u>0.738</u> | 0.725        | <b>0.740</b> |
| CYP3A4 substrate     | ROC-AUC  | 0.590 | 0.576        | 0.543        | <u>0.655</u> | <b>0.660</b> |
| hERG                 | ROC-AUC  | 0.738 | 0.825        | 0.821        | <u>0.831</u> | <b>0.846</b> |
| Ames                 | ROC-AUC  | 0.818 | 0.814        | <b>0.887</b> | <u>0.883</u> | 0.858        |
| DILI                 | ROC-AUC  | 0.856 | 0.886        | 0.871        | <u>0.921</u> | <b>0.931</b> |
| CYP2D6 inhibition    | PR-AUC   | 0.616 | 0.646        | 0.686        | <u>0.693</u> | <b>0.727</b> |
| CYP3A4 inhibition    | PR-AUC   | 0.840 | <u>0.851</u> | 0.840        | 0.841        | <b>0.900</b> |
| CYP2C9 inhibition    | PR-AUC   | 0.735 | 0.749        | 0.781        | <u>0.802</u> | <b>0.838</b> |
| CYP2D6 substrate     | PR-AUC   | 0.617 | 0.547        | 0.486        | <u>0.702</u> | <b>0.717</b> |
| CYP2C9 substrate     | PR-AUC   | 0.344 | 0.375        | 0.353        | <u>0.400</u> | <b>0.527</b> |
| Half life            | Spearman | 0.239 | 0.085        | 0.133        | <u>0.357</u> | <b>0.522</b> |
| VDss                 | Spearman | 0.457 | 0.241        | 0.547        | <u>0.717</u> | <b>0.755</b> |
| Clearance microsome  | Spearman | 0.532 | 0.365        | 0.525        | <u>0.561</u> | <b>0.652</b> |
| Clearance hepatocyte | Spearman | 0.366 | 0.289        | 0.386        | <u>0.387</u> | <b>0.436</b> |

### 4.2.3 消融实验

为了评估 Mol-LLM 中各个新增组件的贡献度, 本节进行了一系列消融实验, 以探究去除不同模块后模型性能的变化。具体地, 消融实验包括: w/o BAN: 表示去除双线性注意力融合模块; w/o SubTE: 表示去除专家知识驱动的子结构表征模块; w/o DesBERTa: 表示去除分子描述信息表征模块。

相关实验结果在 MoleculeNet 基准数据集上进行评估, 并在表4.3中展示具体性能。实验结果表明, 去除大语言模型赋能的分子描述信息表征模块 (w/o DesBERTa) 对 Mol-LLM 的整体性能产生了最显著的影响, 平均性能下降了 1.7%。这一发现突显了大语言模型在引入额外的上下文和语义信息方面的重要作用, 极大地丰富了模型对分子结构的理解, 这对处理复杂的分子表示学习任务至关重要。虽然去除双线性注意力融合模块 (w/o BAN) 对模型性能的影响相对较小, 但性能的下降 (0.8%) 依旧验证了该模块的有效性。这也间接证实了在第三章中提出的 MolIG 方法能够通过分子子结构信息实现深度理解。

表 4.3 Mol-LLM 在 MoleculeNet 基准组上的消融实验结果

|              | BBBP             | BACE             | SIDER            | Tox21            | HIV              | ToxCast          | ClinTox          | AVG         |
|--------------|------------------|------------------|------------------|------------------|------------------|------------------|------------------|-------------|
| w/o BAN      | 73.7(0.8)        | 84.2(0.4)        | 66.5(0.2)        | 78.5(0.5)        | 80.6(0.7)        | 67.1(0.3)        | 95.6(2.3)        | 78.0        |
| w/o SubTE    | 73.5(0.2)        | 82.4(0.1)        | 64.2(0.3)        | 79.2(0.1)        | 80.6(0.2)        | 65.1(0.2)        | 96.7(0.5)        | 77.4        |
| w/o DesBERTa | 73.3(0.9)        | 83.2(1.6)        | 66.1(0.2)        | 79.2(0.2)        | 80.2(1.1)        | 65.1(0.7)        | 92.7(1.7)        | 77.1        |
| Mol-LLM      | <b>74.6(0.4)</b> | <b>84.5(0.2)</b> | <b>66.6(0.1)</b> | <b>79.9(0.2)</b> | <b>81.4(0.7)</b> | <b>67.1(0.8)</b> | <b>97.8(0.9)</b> | <b>78.8</b> |

通过这一系列消融实验，可以明显观察到，Mol-LLM 中的各个组成部分，包括大语言模型模块、双线性注意力融合模块，以及专家知识驱动的子结构表征模块，都对模型的整体性能有着积极的贡献。这些组件的综合运用提高了 Mol-LLM 在分子性质预测领域的准确性和可靠性，证明了本模型在多方面都具有优越性和实用价值。

#### 4.2.4 参数敏感度实验

本节旨在研究 Mol-LLM 方法对最后一层嵌入维度、SubTE 模块注意力头数和编码器层数的敏感度。具体的实验设置为最后一层嵌入维度的范围为 {64, 128, 256, 512}; SubTE 模块注意力头数和层数的范围为 { (1, 8), (2, 16), (4, 32) }。图4-7和图4-8分别展示了两组超参数在 MoleculeNet 基准组上各个数据集的实验结果。




图 4-7 Mol-LLM 在 MoleculeNet 基准组上不同嵌入维度的参数实验结果

在 Mol-LLM 中，嵌入维度是一个关键超参数，其决定了分子表征所包含信息的多少。从图4-7中可以观察到，当嵌入维度设定为 256 时，Mol-LLM 在各个数据集上取得

了最佳平均性能；而随着嵌入维度的增加或者减少，平均性能都均呈下降趋势。过低的嵌入维度可能会对导致信息丢失，降低模型泛化能力；同时，模型可能混淆一些关键特征，导致特征冗余，使其在区分不同类别或任务时更为困难。较高的嵌入维度可能引入噪声，使模型学到的特征过于抽象，失去了对数据底层结构和关键特征的敏感性。值得注意的是，在 **SIDER**、**Tox21**、**ClinTox** 数据集，随着嵌入维度的增加，模型性能总体呈现出改善的趋势。这可能是因为这些数据集均包含多个不同的任务，较高的嵌入维度包含更多的信息从而更好地适应每一个任务。




图 4-8 Mol-LLM 在 MoleculeNet 基准组上 SubTE 模块不同注意力头数和编码器层数的参数实验结果

Mol-LLM 中的另一个关键超参数是 SubTE 模块中的注意力头数和编码器层数。从图4-8中明显可以观察到，随着头数和层数的增加，Mol-LLM 在各个数据集的性能均呈下降趋势。这可能是因为 MoleculeNet 基准组上的分子均为小分子，其包含的子结构相对较少。对于包含少量原子和结构简单的小分子而言，增加注意力头数和编码器层数可能导致过度拟合。过于复杂的可能会捕捉训练数据中的噪声和小样本特有的变异，从而影响其在未见数据上的泛化性。这充分说明了在小分子数据集下，增加注意力头数和编码器层数并不总是能够带来性能的提升。

#### 4.2.5 分子描述信息注意力可视化

注意力分数指的是两个 Token 之间的系数指标，这个这个分数可以深入了解 DesBERTa 每一个 Token 对于结果的贡献。为了说明这一点，本节选取两个分子作为样例，使用 Attention Visualizer 包进行可视化，在图4-9中，展示了 DesBERTa 最终隐藏层的注意力分数可视化。

颜色越深代表注意力分数越高，对最终表征的贡献越大；反之则贡献越小。不难看出，DesBERTa 对于 SMILES 分配了很高的注意力，这表明 Mol-LLM 可以捕获最基本

的分子表征信息。其次，DesBERTa 对关键官能团具有高度敏感性，特别是某些环状官能团例如 benzene ring 和 pyridine ring。这些官能团对分子的性质有着决定性的作用。此外，DesBERTa 还会注意到文本中的关键数值信息，例如分子重量等。这为模型增加了可解释性的维度。




图 4-9 分子描述信息注意力可视化

### 4.3 本章小结

本章提出了一种多层级分子表示学习方法 Mol-LLM，Mol-LLM 在已有的训练模型 MolIG 的基础上，通过引入分子指纹作为专家知识，旨在弥补数据驱动方法的不足，为了更好地融合数据驱动表示和专家知识表示，本章引入双线性融合模块计算二者相互作用和最最终表征的贡献程度。此外，为了进一步丰富分子表征，本章还精心设计 prompt，创新性的利用大语言模型强大的推理能力生成相关分子描述信息并对其进行编码。在 MoleculeNet 基准组和 ADMET 基准组等药物发现任务上的实验证明了 Mol-LLM 优于目前最先进的基于分子描述信息、大语言模型和图的方法。消融实验证明了子结构模块、双向线性注意力融合模块和大语言模型的有效性；分子描述信息注意力可视化为分子的性质预测提供了可解释性。综上所述，Mol-LLM 通过引入分子指纹作为专家知识表示，并结合双线性融合模块和大语言模型的创新应用，提高模型对分子特征的抽象和

表示能力。这一多层级的设计使得模型能够更好地适应不同层次和任务的学习需求，为分子表示学习领域的深度研究提供了新的思路和方法。





## 第五章 分子性质预测工具的设计与实现

在药物研发中,除了候选药物具有良好的活性外,成功的药物候选物还必须具备优良的 ADMET 性质。ADMET 性质包括吸收、分布、代谢、排泄和毒性等多个方面,这些属性直接影响药物在人体内的表现。药物的有效性和安全性取决于其在人体内的行为,因此成药性的评估至关重要。传统的实验方法虽然取得了进展,但存在着耗时、劳力和资源大的缺点。随着计算机科学和人工智能的发展,分子性质预测模型成为了药物研发领域的热门课题。分子性质预测工具能够及时发现化合物的成药性质,促进药物研发,为药物制造商的决策提供支持。基于以上的研究成果,参考 ADMETLab 2.0<sup>[73]</sup> 本章设计并实现了一个分子性质预测工具 ADMET-P,旨在方便药物研发人员通过本工具实时预测分子性质,加速药物研发进程。ADMET-P 分别实现分子可视化、分子基本信息计算、分子性质预测和性质建议等功能。

本章 5.1 节将对分子性质预测工具进行需求分析; 5.2 节将介绍系统总体设计,包括架构设计和数据库设计; 5.3 节将介绍系统实现,并展示系统功能; 5.4 节对分子性质预测工具的功能进行测试; 5.5 节对本章内容进行小结。

### 5.1 需求分析

#### 5.1.1 功能需求

ADMET-P 旨在为医药研发人员提供分子性质预测工具,并对目标分子进行合理预测。因此,本章设计的 ADMET-P 具备以下功能:

(1) 分子可视化: 提供用户友好的界面,接受 SMILES 作为输入,并将其以可视化的方式展示出来,以使用户直观地观察分子的结构。

(2) 分子基本信息: 展示与输入的分子相关的基本信息,如分子量、环数、氢键受体的数量等,帮助用户了解分子的基本特征。此外,针对其基本性质,该功能还提供了建议区间。

(3) 分子性质预测: 基于用户输入的 SMILES,预测其相关的性质,如 ADMET 性质(吸收、分布、代谢、排泄和毒性)等。

(4) 性质建议: 基于预测的分子性质结果,提供对分子性质的建议范围和解释。

### 5.1.2 非功能需求

对于分子性质预测工具 ADMET-P，可能的非功能需求包括以下几个方面：

(1) 性能要求：响应时间：确保系统在用户输入分子结构并请求性质预测时能够快速响应，保持较低的延迟。吞吐量：系统应当能够处理大量的用户请求，同时保持稳定的性能，以满足高并发的需求。

(2) 可用性：系统应当保证高可用性，确保在大部分时间内可供用户访问和使用，降低系统故障导致的服务中断时间。容错性：系统应具备容错机制，能够在部分组件或功能出现故障时保持基本的功能运行。

(3) 数据安全：用户上传的分子结构数据应当得到保护，确保数据不被未经授权的用户访问或篡改。

(3) 用户界面友好性：系统的用户界面应当设计友好，操作简单直观，减少用户的学习成本和操作复杂度。系统文档：提供详细的系统文档和帮助信息，帮助用户了解系统的功能和操作方法。

(4) 可扩展性：系统应当具备良好的扩展性，能够方便地添加新功能或修改现有功能以满足未来的需求变化。可维护性：系统的代码结构应当清晰易懂，便于维护和修改，同时应当有良好的注释和文档。

综上所述，分子性质预测工具的非功能需求涉及到系统的性能、可靠性、安全性、易用性、可维护性等方面，这些需求对于确保 ADMET-P 工具的稳定运行和用户满意度具有重要意义。

## 5.2 系统设计

### 5.2.1 架构设计

ADMET-P 采用 B/S 架构，用户可以通过浏览器轻松访问工具，无需安装额外的客户端软件，同时所有的业务逻辑和数据处理都集中在服务器端进行，保证了数据的安全性和一致性。MVC 设计模式将应用程序分为模型、视图和控制器三个部分，使得系统的业务逻辑、用户界面和数据模型得以有效分离，提高了代码的可维护性和可扩展性。ADMET-P 工具旨在为用户提供高效准确的分子性质预测服务，实现了系统架构的合理分层和功能模块化，提升了用户体验和工具的整体性能。ADMET-P 的架构如图5-1所示。

ADMET-P 采用 MVC (Model-View-Controller) 设计模式，该设计模式将应用程序




图 5-1 ADMET-P 系统架构图

分为三个核心组件：模型（Model）、视图（View）和控制器（Controller）。下面详细介绍 ADMET-P 中每个组件的功能和作用：

**模型层（Model）：**模型层代表了 ADMET-P 中的数据和业务逻辑，将数据库中的数据数据进行格式转换，使其能够变为控制层可以使用的数据模式。

**控制层（Controller）：**控制层是模型和视图之间的中介，负责接收用户的请求，并根据请求调用相应的模型进行数据处理，并将处理结果传递给视图进行展示。在 ADMET-P 中，控制器负责接收用户输入的分子结构数据、调用模型进行特征提取和性质预测，并将预测结果传递给视图进行展示。控制器层实现了系统的业务逻辑和用户请求处理，负责将用户输入转化为对模型的操作，同时将模型的结果呈现给用户。通过 MVC 设计模式，ADMET-P 实现了业务逻辑、用户界面和数据模型的有效分离，提高了系统的可维护性、可扩展性和可重用性。每个组件之间的解耦使得系统的各个部分可以独立开发、测试和维护，同时也使得系统更易于理解和修改。MVC 设计模式的应用使得 ADMET-P 能够提供高效准确的分子性质预测服务，并为用户提供良好的用户体验。

视图层 (View): 视图负责将模型中的数据呈现给用户, 以图形界面的形式展示给用户。在 ADMET-P 中, 视图通过 Web 界面展示给用户, 用户可以在浏览器中直观地查看分子结构、输入数据、预测结果等。视图层需要设计用户友好的界面, 包括页面布局、交互方式、信息展示等, 以提高用户体验和可用性。

### 5.2.2 软件架构设计

本节将对 ADMET-P 工具的软件架构进行概述, 如图5-2所示, 分子性质预测模块是其核心模块, 用户可以通过该模块获得分子的结构信息、基本性质和 ADMET 性质等信息。




图 5-2 ADMET-P 工具软件架构图

### 5.2.3 数据库设计

ADMET-P 工具的数据库设计主要用于存储分子数据和分子性质数据, 根据以上需求数据库可以设计为 5 个数据表, 即分子结构表、分子性质表、分子指纹表、分子基本信息表和分子描述信息表, MySQL 具有稳定性高、性能优越、易于管理和扩展等优点, 能够满足 ADMET-P 工具对数据存储的需求, 因此本章选用 MySQL 数据库进行存储。

分子结构表的详细设计如表5.1所示, 其中 AI 表示该字段为自增类型, PK 表示该字段为表的主键, NN 表示该字段非空, NQ 表示该字段不能被重复。分子结构表包括 molecule\_id、pubchem\_id、SMILES 和 InChI 三个字段组成。由于多个 SMILES 可以表示同一分子, 因此分子结构表加入 pubchem\_id 字段以保证同一分子只存储一次。

分子指纹表的详细设计如表5.2所示, 用以存储分子的各类指纹。

表 5.1 分子结构表

| 字段          | 类型      | 属性     | 含义                |
|-------------|---------|--------|-------------------|
| molecule_id | INT     | PK, AI | 分子 ID, 唯一标识每个分子   |
| pubchem_id  | INT     | NN, NQ | 分子在 pubchem 中的 ID |
| SMILES      | VARCHAR | NN     | 分子的 SMILES 表示     |
| InChI       | VARCHAR |        | 分子的 InChI 表示      |

表 5.2 分子指纹表

| 字段           | 类型      | 属性     | 含义              |
|--------------|---------|--------|-----------------|
| molecule_id  | INT     | PK, AI | 分子 ID, 唯一标识每个分子 |
| maccs_keys   | VARCHAR | NN     | 分子的 MACCS 指纹    |
| pubchem_fp   | VARCHAR |        | 分子的 PubChem 指纹  |
| rdkit2d_keys | VARCHAR |        | 分子的 rdkit2d 描述符 |

分子描述信息表的详细设计如表5.2所示, 用以存储分子的描述信息。

表 5.3 分子描述信息表

| 字段          | 类型      | 属性     | 含义              |
|-------------|---------|--------|-----------------|
| molecule_id | INT     | PK, AI | 分子 ID, 唯一标识每个分子 |
| SMILES      | VARCHAR | NN     | 分子的 SMILES 表示   |
| description | VARCHAR |        | 分子的描述信息         |

分子性质表的详细设计如表5.4所示, 用以存储分子的 ADEMT 性质。

表 5.4 分子性质表

| 字段          | 类型      | 属性     | 含义              |
|-------------|---------|--------|-----------------|
| molecule_id | INT     | PK, AI | 分子 ID, 唯一标识每个分子 |
| SMILES      | VARCHAR | NN     | 分子的 SMILES 表示   |
| BBBP        | FLOAT   |        | BBBP 数据集对应的性质   |
| BACE        | FLOAT   |        | BACE 数据集对应的性质   |
| Caco2       | FLOAT   |        | Caco2 数据集对应的性质  |

续表 5.4

| 字段                   | 类型    | 属性 | 含义                            |
|----------------------|-------|----|-------------------------------|
| HIA                  | FLOAT |    | HIA 数据集对应的性质                  |
| Pgp                  | FLOAT |    | Pgp 数据集对应的性质                  |
| Bioavailability      | FLOAT |    | Bioavailability 数据集对应的性质      |
| Lipophilicity        | FLOAT |    | Lipophilicity 数据集对应的性质        |
| Solubility           | FLOAT |    | Solubility 数据集对应的性质           |
| PPBR                 | FLOAT |    | PPBR 数据集对应的性质                 |
| VDss                 | FLOAT |    | VDss 数据集对应的性质                 |
| CYP2D6_inhibition    | FLOAT |    | CYP2D6 inhibition 数据集对应的性质    |
| CYP3A4_inhibition    | FLOAT |    | CYP3A4 inhibition 数据集对应的性质    |
| CYP2C9_inhibition    | FLOAT |    | CYP2C9 inhibition 数据集对应的性质    |
| CYP2D6_substrate     | FLOAT |    | CYP2D6 substrate 数据集对应的性质     |
| CYP3A4_substrate     | FLOAT |    | CYP3A4 substrate 数据集对应的性质     |
| CYP2C9_substrate     | FLOAT |    | CYP2C9 substrate 数据集对应的性质     |
| Half_life            | FLOAT |    | Half life 数据集对应的性质            |
| Clearance_microsome  | FLOAT |    | Clearance microsome 数据集对应的性质  |
| Clearance_hepatocyte | FLOAT |    | Clearance hepatocyte 数据集对应的性质 |
| hERG                 | FLOAT |    | hERG 数据集对应的性质                 |
| Ames                 | FLOAT |    | Ames 数据集对应的性质                 |
| DILI                 | FLOAT |    | DILI 数据集对应的性质                 |
| LD50                 | FLOAT |    | LD50 数据集对应的性质                 |

### 5.3 工具实现

本节主要介绍 AMDET-P 工具的开发技术和软硬件环境，以及分子性质预测功能的具体实现。

#### 5.3.1 开发技术与运行环境

ADMET-P 工具使用 Flask 框架进行开发，结合前后端分离、Ajax 异步技术、MySQL 数据库和集成深度学习模型等技术实现了一个功能丰富的药物 ADMET 性质预测工具。前端部分采用 HTML、CSS、JavaScript 等技术进行开发，负责页面的展示和用户交互。



后端部分采用 Flask 框架进行开发，负责处理业务逻辑、数据请求和响应。前端页面通过 Ajax 技术向后端发送异步请求，不需要刷新整个页面即可获取数据或更新部分内容。后端接收到 Ajax 请求后，处理相应的业务逻辑并返回 JSON 格式的数据给前端。使用 MySQL 数据库存储用户信息、分子结构数据、分子性质数据等信息。后端 Flask 应用通过 SQLAlchemy 等 ORM 工具与 MySQL 数据库进行交互，进行数据的增删改查操作。部署环境如表 5.5 所示。

表 5.5 ADMET-P 工具部署环境

|    | 名称      | 软件版本或资源描述                       |
|----|---------|---------------------------------|
| 硬件 | CPU     | Intel(R) Xeon(R) Gold 5218R CPU |
|    | GPU     | NVIDIA RTX3090                  |
| 软件 | Flask   | 2.0.2                           |
|    | MySQL   | 7.1                             |
|    | Python  | 3.7                             |
|    | Pytorch | 1.9.1+cu111                     |

### 5.3.2 模块实现

ADMET-P 工具可在 web 页面上直接使用分子性质预测功能，该功能流程如图 5-3 所示。该工具接受用户输入的 SMILES 作为预测目标，考虑到本文提出的 Mol-LLM 需要用到 ChatGPT 生成对应的分子描述信息，因此还需要用户输入自己的 OpenAI API Key。点击提交后，系统首先会检测用户输入的 SMILES 是否合法，同时也会检测用户是否输入 Key，若没有，系统调用 MolIIG 进行性质预测；否则会先调用 ChatGPT 生成对应的分子描述信息并输入 Mol-LLM 进行性质预测。

(1) 分子结构看板：为增强用户体验、方便用户直观观察分子结构，分子结构看板提供分子对应的结构信息。当用户点击提交按钮后，会向后台发送 HTTP POST 请求。接下来调用 RDKit 中的 Draw.MolToImageFile 方法生成对应的结构图像，并向前端页面发送响应。前端页面收到服务器的响应结果，在分子结构看板区域加载分子图像。在用户提交分子信息之前，进行基本的输入验证，确保输入的分子格式合法。如果不合法，给出提示信息，避免无效请求发送到后台。对于常用或重复查询的分子结构，可以实现图像缓存，避免每次都重新生成图像，提高响应速度。如果调用 RDKit 生成图像失败，返回适当的错误信息，提示用户检查输入。

(2) 分子基本性质看板：该看板展示与输入的分子相关的基本信息，如分子量、环




图 5-3 分子性质预测流程图

数、氢键受体的数量等，帮助用户了解分子的基本特征。后台接收到请求后，调用 RDkit 中的对应性质模块计算分子基本信息，前端页面接收到服务器响应后，解析对应内容并在基本性质看板展示，使用多线程或异步计算来提高响应速度，特别是在计算多个性质时。在后台对计算结果进行校验，确保数据准确无误。例如，分子量应在合理范围内。此外，针对其基本性质，此看板还内嵌了建议区间雷达图，以向用户提供交互式图表。

(3) 分子 ADMET 性质看板：该看板展示分子具体的 ADMET 性质，包括 MoleculeNet、吸收、分布、代谢、排泄、毒性等性质。后台接收到请求后，首先将分子 SMILES 转化为对应的图结构和 MACCS 分子指纹，若用户输入 OpenAI API，则调用 ChatGPT API 接口生成对应的分子描述信息。随后针对不同的性质调用不同的微调模型，后台将预测结构封装为 HTTP 响应，并在前端分子 ADMET 性质看板模块展示。针对不同的 ADMET 性质，采用并行计算方式，提高处理速度。对于 ChatGPT API 等外部 API 调用，设置 10s 的超时时间和重试机制，确保系统稳定性。

(4) 性质建议看板：该看板根据分子的 ADMET 性质，提供建议。若某性质数值在合理区间内，则将该看板置为绿色；否则置为红色用以提示用户该分子在某性质出可能存在潜在风险。不仅用颜色提示合理区间，还使用图标或文本描述进一步说明某性质值的意义。

## 5.4 测试

### 5.4.1 功能测试

分子性质预测首页如图5-4所示，该页面允许用户输入 SMILES 和 OpenAI 的 API Key，单击提交任务按钮即可提交分子性质预测任务。




图 5-4 ADMET-P 工具主页

分子性质预测页如图5-5和图5-6所示，本章以 CC(=O)NCCC1=CNc2c1cc(OC)cc2 分子为例进行预测，在输入 SMILES 后，系统会调用不同性质对应的模型对结果进行预测。首先，ADMET-P 会对 SMILES 进行可视化展示，以使用户直观地观察分子的结构。此外本工具还会归纳分子的基本性质以使用户更深入的了解分子，并根据成药性性质范围以雷达图的形式展示，最后展示分子的 ADMET 性质以及是否符合该性质在人体内的标准。

如图5-5所示：

(1) 分子结构看板：红色边框部分为分子的可视化展示，方便药物研发人员直观地观察分子结构，为后续分子优化和合成提供指导。

(2) 分子基本性质看板：绿色部分展示了分子基本信息，此外，针对其基本性质，该功能在黑色边框部分还提供了建议区间和 eChart 图表用以交互，在图表上显示具体数值、单位和鼠标悬停提示；

(3) 分子 ADMET 性质看板：展示分子吸收、分布、代谢、排泄和毒性等 ADMET




图 5-5 ADMET-P 工具性质预测页面




图 5-6 ADMET-P 工具性质预测页面-续

性质，蓝色部分展示了模型预测的药物分子具体性质；

(4) 性质建议看板：黄色部分基于预测出来的具体数值提供预测建议，其中绿色表示当前性质符合建议值，红色表示不符合建议值，方便用户清晰直观地观察当前分子是否符合成药需求。

此外，用户还可以自行下载分子数据的 csv 文件。

#### 5.4.2 非功能测试

本章从 MoleculeNet 基准组中选取 10 个分子数据进行用户输入模拟，从用户点击提交任务按钮开始计时，到页面反馈分子性质结束计时。其中，调用 MolIG 方法平均用时 5.5s；调用 Mol-LLM 方法平均用时 23.2s，这些时间在一般情况下，用户都能够接受，并且不会对他们的使用体验产生显著影响。与 ADMETLab2.0 相比，本工具在预训练模型 MolIG 的基础上综合分子结构信息、分子指纹专家知识、分子描述信息等，以达到更好的模型精度。

### 5.5 本章小结

本章基于 MolIG 和 Mol-LLM 设计并实现了一个分子性质预测工具 ADMET-P，其包括分子可视化、分子基本信息、分子性质预测和性质建议四个主要模块，并基于 Flask 框架完成 ADMET-P 工具的实现。本章首先对分子性质预测工具进行需求分析，并基于此介绍工具的系统架构和系统实现，最后介绍 ADMET-P 的功能测试。



## 第六章 总结与展望

### 6.1 总结

分子性质预测是利用深度学习技术对分子的结构、性质或活性进行预测和分析的过程。这种方法通过处理大量的分子数据和相关属性，例如分子结构、物理性质和活性，来构建模型，并通过学习这些数据之间的复杂关系来预测新分子的性质或行为。模型能够从大量的化学数据中学习和发现隐藏的规律和关联，有助于深入理解分子之间的结构-活性关系及其他化学规律。从而大大加速药物研发过程，通过快速筛选候选药物，降低了研发时间和成本。然而，含有标签的分子数据十分稀少，因此当前的监督学习方法在性质预测任务上的表现不佳。最先进的一些自监督方法往往基于分子单一模态信息，导致其表征分子时角度过于片面。因此，寻找有效的方法表示分子并准确的预测分子的性质成为了当前亟需解决的问题。

本论文利用分子的多模态特性研究提出面向性质预测的分子表示学习方法并设计实现了一个分子性质预测工具。本文的主要工作如下：

(1) 针对分子领域有标签的数据较为稀少，且当前研究通常只利用了单一模态的分子信息，忽略了不同分子模态之间的互补性的等问题，研究提出基于图和图像的多模态分子表示学习方法 (**Multi-Modal Molecular Representation Learning Based on Image And Graph, MolIG**)。该方法包括预训练和微调两个主要阶段。在预训练阶段，通过整合分子的图表示和图像表示，并在隐空间中最大化这两种表示的一致性，以捕获高阶语义信息的分子表征。在不改变语义信息的情况下，利用图像增强策略，模型可以学习到更加鲁棒的分子表示，同时提升其泛化能力。在 MoleculeNet 和 ADMET 基准组上的实验结果表明，MolIG 方法在分子性质预测任务上能够取得相较基线模型更优的性能，且能够有效提取分子的结构特征并捕获高阶的语义信息。

(2) 鉴于 MolIG 方法仅依赖数据驱动，缺乏专家知识引导，存在一定局限性。研究进一步提出大语言模型赋能的多层级分子表示学习方法 (**Multi-Level Molecular Representation Learning Empowered by LLM, Mol-LLM**)。在 MolIG 的基础上，本研究引入分子指纹作为专家知识，捕获不同子结构下的交互模式，进一步丰富了图神经网络的表达能力。同时，该方法采用双线性注意力网络来融合不同层级的信息，根据数据驱动的原子级别表征和专家知识驱动的子结构级别表征动态地调整其贡献和学习其匹配模式，



使得二者更好的进行融合。此外，本研究还考虑到当前分子描述文本的稀缺性，创新性地结合了大语言模型并精心设计 prompt 以获取丰富的分子描述信息，通过融合这些信息，以生成更全面和细致的分子表征。在实验评估过程中，设计与基于大语言模型和分子描述信息的基线模型进行比较，以证明本方法的有效性。

(3) 基于以上方法，本文设计并实现了一个分子性质预测工具，为生物医药研究人员提供一个易于使用的分子性质预测工具。

## 6.2 未来工作

本文提出的 MolIG 和 Mol-LLM 方法在分子性质预测任务上取得了良好的效果，但以上方法仍存在需要改进的地方，未来可以在以上几个方面进一步完善：

### (1) 大语言模型的应用

本文提出的方法使用基于 GPT-3.5 的大语言模型，然而其他大语言模型在分子描述信息生成领域的表现还有待探索，例如 GPT-4 等。本文采用的方法将大语言模型视为生成器，通过大模型强大的推理能力帮助小模型，除此之外，如何将大语言模型作为编码器、预测器也是一个有前途的方向。

### (2) 引入分子的 3D 信息

分子的三维结构对于分子性质预测至关重要。分子在三维空间中的排布和分子间的相互作用方式直接影响着其化学性质、生物活性以及其他重要特性。在分子的三维结构中，每个原子的位置、键长、键角以及空间构型都承载着丰富的信息，这些信息在分子之间的相互作用中起着关键的作用。因此，在分子性质预测的研究中，引入分子的三维信息是不可或缺的重要步骤，有助于提升预测模型的性能和应用价值。

### (3) 更大规模的分子预训练

在本研究中，第三章强调了大规模预训练在分子性质预测中的重要性。大规模预训练使得模型能够从海量的分子数据中学习到丰富的分子表示。这些表示不仅包括分子的结构信息，还包括了分子间的相互作用、化学环境等重要特征。通过在大规模数据集上进行预训练，模型可以更好地理解分子的多样性和复杂性，从而提高了性质预测模型的泛化能力和性能表现。此外，大规模预训练还能够减少在特定任务上的训练时间和数据需求，提高了模型的效率和可扩展性。因此，将更大规模的预训练（例如十亿分子）引入分子性质预测的研究中，对于提升模型的准确性、鲁棒性和适用范围具有重要的意义和价值。

## 参考文献

- [1] GAUDELET T, DAY B, JAMASB A R, et al. Utilizing graph machine learning within drug discovery and development[J]. Briefings in bioinformatics, 2021, 22(6):bbab159.
- [2] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [3] MOHS R C, GREIG N H. Drug discovery and development: Role of basic biological research[J]. Alzheimer's & Dementia: Translational Research & Clinical Interventions, 2017, 3(4):651-657.
- [4] DOWDEN H, MUNRO J. Trends in clinical success rates and therapeutic focus[J]. Nat Rev Drug Discov, 2019, 18(7):495-496.
- [5] SLIWOSKI G, KOTHIWALE S, MEILER J, et al. Computational methods in drug discovery[J]. Pharmacological reviews, 2014, 66(1):334-395.
- [6] WANG Y, WANG J, CAO Z, et al. Molecular contrastive learning of representations via graph neural networks[J]. Nature Machine Intelligence, 2022, 4(3):279-287.
- [7] RONG Y, BIAN Y, XU T, et al. Self-supervised graph transformer on large-scale molecular data[J]. Advances in Neural Information Processing Systems, 2020, 33:12559-12571.
- [8] WEININGER D. Smiles, a chemical language and information system. 1. introduction to methodology and encoding rules[J]. Journal of chemical information and computer sciences, 1988, 28(1):31-36.
- [9] CHITHRANANDA S, GRAND G, RAMSUNDAR B. Chemberta: Large-scale self-supervised pretraining for molecular property prediction[J]. arXiv preprint arXiv:2010.09885, 2020.
- [10] LIU Y, OTT M, GOYAL N, et al. Roberta: A robustly optimized bert pretraining approach [J]. arXiv preprint arXiv:1907.11692, 2019.

- [11] WU Z, RAMSUNDAR B, FEINBERG E N, et al. Moleculenet: a benchmark for molecular machine learning[J]. Chemical science, 2018, 9(2):513-530.
- [12] ZHANG X C, WU C K, YI J C, et al. Pushing the boundaries of molecular property prediction for drug discovery with multitask learning bert enhanced by smiles enumeration [J]. Research, 2022, 2022:0004.
- [13] ROSS J, BELGODERE B, CHENTHAMARAKSHAN V, et al. Large-scale chemical language representations capture molecular structure and properties[J]. Nature Machine Intelligence, 2022, 4(12):1256-1264.
- [14] XUE D, ZHANG H, XIAO D, et al. X-mol: large-scale pre-training for molecular understanding and diverse molecular analysis[J]. bioRxiv, 2020:2020-12.
- [15] WANG S, GUO Y, WANG Y, et al. Smiles-bert: large scale unsupervised pre-training for molecular property prediction[C]. Proceedings of the 10th ACM international conference on bioinformatics, computational biology and health informatics. 2019. 429-436.
- [16] CHILINGARYAN G, TAMOYAN H, TEVOSYAN A, et al. Bartsmls: Generative masked language models for molecular representations[J]. arXiv preprint arXiv:2211.16349, 2022.
- [17] HU W, LIU B, GOMES J, et al. Strategies for pre-training graph neural networks[J]. arXiv preprint arXiv:1905.12265, 2019.
- [18] XIA J, ZHAO C, HU B, et al. Mole-bert: Rethinking pre-training graph neural networks for molecules[C]. The Eleventh International Conference on Learning Representations. 2022.
- [19] VAN DEN OORD A, VINYALS O, et al. Neural discrete representation learning[J]. Advances in neural information processing systems, 2017, 30.
- [20] LI P, WANG J, QIAO Y, et al. An effective self-supervised framework for learning expressive molecular global representations to drug discovery[J]. Briefings in Bioinformatics, 2021, 22(6):bbab109.
- [21] YING C, CAI T, LUO S, et al. Do transformers really perform badly for graph representation?[J]. Advances in neural information processing systems, 2021, 34:28877-28888.

- [22] YOU Y, CHEN T, SUI Y, et al. Graph contrastive learning with augmentations[J]. Advances in neural information processing systems, 2020, 33:5812-5823.
- [23] FANG Y, ZHANG Q, YANG H, et al. Molecular contrastive learning with chemical element knowledge graph[C]. Proceedings of the AAAI Conference on Artificial Intelligence: volume 36. 2022. 3968-3976.
- [24] SHI T, YANG Y, HUANG S, et al. Molecular image-based convolutional neural network for the prediction of admet properties[J]. Chemometrics and Intelligent Laboratory Systems, 2019, 194:103853.
- [25] CERETO-MASSAGUÉ A, OJEDA M J, VALLS C, et al. Molecular fingerprint similarity search in virtual screening[J]. Methods, 2015, 71:58-63.
- [26] GOH G B, SIEGEL C, VISHNU A, et al. Chemception: a deep neural network with minimal chemistry knowledge matches the performance of expert-developed qsar/qspr models[J]. arXiv preprint arXiv:1706.06689, 2017.
- [27] ZENG X, XIANG H, YU L, et al. Accurate prediction of molecular properties and drug targets using a self-supervised image representation learning framework[J]. Nature Machine Intelligence, 2022, 4(11):1004-1016.
- [28] LIU S, WANG H, LIU W, et al. Pre-training molecular graph representation with 3d geometry[C/OL]. International Conference on Learning Representations. 2022. <https://openreview.net/forum?id=xQUe1pOKPam>.
- [29] LI S, ZHOU J, XU T, et al. Geomgcl: Geometric graph contrastive learning for molecular property prediction[C]. Proceedings of the AAAI Conference on Artificial Intelligence: volume 36. 2022. 4541-4549.
- [30] ZHU J, XIA Y, QIN T, et al. Dual-view molecule pre-training[J]. arXiv preprint arXiv:2106.10234, 2021.
- [31] LIU S, NIE W, WANG C, et al. Multi-modal molecule structure-text model for text-based retrieval and editing[J/OL]. Nature Machine Intelligence, 2023, 5(12):1447-1457. <https://doi.org/10.1038/s42256-023-00759-6>.

- [32] KIM S, CHEN J, CHENG T, et al. Pubchem 2019 update: improved access to chemical data[J]. *Nucleic acids research*, 2019, 47(D1):D1102-D1109.
- [33] WANG X, ZHAO H, TU W W, et al. Automated 3d pre-training for molecular property prediction[C]. *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2023. 2419-2430.
- [34] VELICKOVIC P, CUCURULL G, CASANOVA A, et al. Graph attention networks[J]. *stat*, 2017, 1050(20):10-48550.
- [35] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016. 770-778.
- [36] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. *Communications of the ACM*, 2017, 60(6):84-90.
- [37] GOH G B, HODAS N O, VISHNU A. Deep learning for computational chemistry[J]. *Journal of computational chemistry*, 2017, 38(16):1291-1307.
- [38] CHEN H, ENGKVIST O, WANG Y, et al. The rise of deep learning in drug discovery[J]. *Drug discovery today*, 2018, 23(6):1241-1250.
- [39] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]. *International conference on machine learning*. PMLR, 2021. 8748-8763.
- [40] XU K, HU W, LESKOVEC J, et al. How powerful are graph neural networks?[C/OL]. *International Conference on Learning Representations*. 2019. <https://openreview.net/forum?id=ryGs6iA5Km>.
- [41] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely connected convolutional networks[C]. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017. 4700-4708.
- [42] TAN M, LE Q. Efficientnet: Rethinking model scaling for convolutional neural networks [C]. *International conference on machine learning*. PMLR, 2019. 6105-6114.

- [43] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [44] CHEN T, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C]. International conference on machine learning. PMLR, 2020. 1597-1607.
- [45] LANDRUM G. Rdkit: Open-source cheminformatics. 2006[J]. Google Scholar, 2006.
- [46] HUANG K, FU T, GAO W, et al. Therapeutics data commons: Machine learning datasets and tasks for drug discovery and development[J]. arXiv preprint arXiv:2102.09548, 2021.
- [47] KIPF T N, WELLING M. Semi-supervised classification with graph convolutional networks[C]. International Conference on Learning Representations (ICLR). 2017.
- [48] XIONG Z, WANG D, LIU X, et al. Pushing the boundaries of molecular representation for drug discovery with the graph attention mechanism[J]. Journal of medicinal chemistry, 2019, 63(16):8749-8760.
- [49] ABDEL-ATY H, GOULD I R. Large-scale distributed training of transformers for chemical fingerprinting[J]. Journal of Chemical Information and Modeling, 2022, 62(20):4852-4862.
- [50] STÄRK H, BEAINI D, CORSO G, et al. 3d infomax improves gnns for molecular property prediction[C]. International Conference on Machine Learning. PMLR, 2022. 20479-20502.
- [51] XIANG H, JIN S, LIU X, et al. Chemical structure-aware molecular image representation learning[J/OL]. Briefings in Bioinformatics, 2023, 24(6):bbad404. <https://doi.org/10.1093/bib/bbad404>.
- [52] HOU Z, LIU X, CEN Y, et al. Graphmae: Self-supervised masked graph autoencoders [C]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022. 594-604.
- [53] HE K, CHEN X, XIE S, et al. Masked autoencoders are scalable vision learners[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022. 16000-16009.

- [54] ZHANG Z, LIU Q, WANG H, et al. Motif-based graph self-supervised learning for molecular property prediction[J]. *Advances in Neural Information Processing Systems*, 2021, 34:15870-15882.
- [55] LIU Z, SHI Y, ZHANG A, et al. Rethinking tokenizer and decoder in masked graph modeling for molecules[J]. *Advances in Neural Information Processing Systems*, 2024, 36.
- [56] LI B, LIN M, CHEN T, et al. Fg-bert: a generalized and self-supervised functional group-based molecular representation learning framework for properties prediction[J]. *Briefings in Bioinformatics*, 2023, 24(6):bbad398.
- [57] KIM J H, JUN J, ZHANG B T. Bilinear attention networks[J]. *Advances in neural information processing systems*, 2018, 31.
- [58] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. *arXiv preprint arXiv:1810.04805*, 2018.
- [59] RADFORD A, WU J, CHILD R, et al. Language models are unsupervised multitask learners[J]. *OpenAI blog*, 2019, 1(8):9.
- [60] BAI J, BAI S, CHU Y, et al. Qwen technical report[J]. *arXiv preprint arXiv:2309.16609*, 2023.
- [61] HUANG L, YU W, MA W, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions, november 2023[J]. *arXiv preprint arXiv:2311.05232*, 2023.
- [62] SHANAHAN M, MCDONELL K, REYNOLDS L. Role play with large language models [J]. *Nature*, 2023, 623(7987):493-498.
- [63] SEIDL P, VALL A, HOCHREITER S, et al. Enhancing activity prediction models in drug discovery with the ability to understand human language[C]. *International Conference on Machine Learning*. PMLR, 2023. 30458-30490.
- [64] MORGAN H L. The generation of a unique machine description for chemical structures-a technique developed at chemical abstracts service.[J]. *Journal of chemical documentation*, 1965, 5(2):107-113.



- [65] ZHU Y, CHEN D, DU Y, et al. Molecular contrastive pretraining with collaborative featureizations[J]. Journal of Chemical Information and Modeling, 2024.
- [66] SU B, DU D, YANG Z, et al. A molecular multimodal foundation model associating molecule graphs with natural language[J]. arXiv preprint arXiv:2209.05481, 2022.
- [67] LACOMBE R, GAUT A, HE J, et al. Extracting molecular properties from natural language with multimodal contrastive learning[J]. arXiv preprint arXiv:2307.12996, 2023.
- [68] ZENG Z, YAO Y, LIU Z, et al. A deep-learning system bridging molecule structure and biomedical text with comprehension comparable to human professionals[J]. Nature communications, 2022, 13(862).
- [69] EDWARDS C, LAI T, ROS K, et al. Translation between molecules and natural language [J]. arXiv preprint arXiv:2204.11817, 2022.
- [70] TAYLOR R, KARDAS M, CUCURULL G, et al. Galactica: A large language model for science[J]. arXiv preprint arXiv:2211.09085, 2022.
- [71] LO K, WANG L L, NEUMANN M, et al. S2orc: The semantic scholar open research corpus[J]. arXiv preprint arXiv:1911.02782, 2019.
- [72] LIU P, REN Y, TAO J, et al. Git-mol: A multi-modal large language model for molecular science with graph, image, and text[J]. Computers in Biology and Medicine, 2024, 171: 108073.
- [73] XIONG G, WU Z, YI J, et al. Admetlab 2.0: an integrated online platform for accurate and comprehensive predictions of admet properties[J]. Nucleic acids research, 2021, 49 (W1):W5-W14.

## 毕业/学位论文答辩委员会名单

|                                 |             |                       |          |              |
|---------------------------------|-------------|-----------------------|----------|--------------|
| 毕业/学位论文题目                       |             | 面向性质预测的分子表示学习方法的研究与实现 |          |              |
| 作 者                             |             | 王卓渊                   |          |              |
| 专 业                             |             | 人工智能                  |          |              |
| 研究方向                            |             | 数据挖掘                  |          |              |
| 导 师                             |             | 何洁月                   |          |              |
| 答<br>辩<br>委<br>员<br>会<br>组<br>成 | 姓 名         | 职 称                   | 学科专业     | 工作单位         |
|                                 | 陈阳<br>(主席)  | 教授                    | 计算机科学与技术 | 东南大学         |
|                                 | 刘志昊         | 副教授                   | 计算机科学与技术 | 东南大学         |
|                                 | 徐翔宇         | 副研究员                  | 计算机科学与技术 | 东南大学         |
|                                 | 王宏宇         | 高级工程师                 | 计算机科学与技术 | 江苏金智科技股份有限公司 |
|                                 | 蔡志玲<br>(秘书) | 研究实习员                 | 计算机科学与技术 | 计算机科学与工程学院   |

心於至善

---

